K-water연구원
2025-TE-RR-5-113
G230317
Final Report

거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석

Analysis of Water Industry Technological Information using Large Language Models and Natural Language Processing

2024. 12

KOREA
WATER RESOURCES
CORPORATION

한국수자원공사

거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석

K water 한국수자원공사

거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석

Analysis of Water Industry Technological Information using Large Language Models and Natural Language Processing

2024. 12

K water 한국수자원공사

제 출 문

사 장 귀하

이 보고서를 2024년도 K-water연구원 연구관리처에서 수행한 “거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석”의 최종 연구보고서로 제출합니다.

2024. 12.

연구책임자 : K-water연구원 수석위원 김 성 훈

연구수행자 : K-water연구원 전 산 3 급 김 세 훈

전 통 3 급 정 희 진

전 산 4 급 이 소 령

위촉연구원 이 승 한

원 급 김 학 준

연구개발결과 활용보고서

<table>
<tr><td rowspan="12">1. 연구 총괄</td><td colspan="2">[간행물관리번호: 2025-TE-RR-5-113]</td><td colspan="3">[과제번호: G230317]</td></tr>
<tr><td>(1)연구과제명</td><td colspan="4">거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석</td></tr>
<tr><td rowspan="4">(2)수행부서</td><td rowspan="4">연구관리처</td><td rowspan="4">(3)연구책임자</td><td>성명</td><td>김 성 훈</td></tr>
<tr><td>소속</td><td>연구관리처</td></tr>
<tr><td>전화번호</td><td>042-870-7332</td></tr>
<tr><td>E-mail</td><td>sunghoonkim@kwater.or.kr</td></tr>
<tr><td>(4)연 구 기 간</td><td>2023. 8 . ~ 2024. 12.
(총 17개월)</td><td rowspan="3">(5)총연구개발비
(천원)</td><td>총액</td><td>92,972천원</td></tr>
<tr><td>(6)협 동 기 관</td><td>-</td><td>정부</td><td>-</td></tr>
<tr><td>(7)참 여 기 업</td><td>-</td><td>기업</td><td>-</td></tr>
<tr><td>(8)기 술 분 야</td><td>-</td><td>(9)참여 연구원</td><td colspan="2">5명</td></tr>
<tr><td colspan="5">(10)연구개발목표</td></tr>
<tr><td colspan="5">○ (최종목표) 언어모델 및 자연어처리를 활용한 물산업 기술정보 분석 및 솔루션 개발
○ (1차년도) 물산업 관련 국·내외 기술정보 수집 및 분석
○ (2차년도) 물산업 관련 기술정보 분석 및 솔루션 개발</td></tr>
<tr><td colspan="5">(11)주요연구내용</td></tr>
<tr><td colspan="5">○ 물산업 관련 국·내외 기술정보 수집 및 분석
- 기술정보 문헌정보 수집 방법 탐색 및 DB구축(국내외 논문, 특허, 보고서, STP 등)
- 자연어처리를 위한 전처리 및 탐색적 데이터 분석(EDA)

○ 물산업 관련 기술정보 분석 및 솔루션 개발
- NLP, 최신 AI 알고리즘을 사용한 물산업 관련 기술정보 분석 및 시사점 도출
- 트랜스포머 기반의 기술문서 자동분류 딥러닝 모델 개발(정확도 90% 이상)

○ 경영지원 및 솔루션
- AI 양정 가이드라인 및 유사문서 검색 알고리즘 개발
- K-water 사규·심리상담 AI 챗봇 개발(방울이봇.C)
- 물산업 기술정보 요약기(방울이봇.S)
- 감사 관련 규정 질의응답 챗봇 개발(방울이봇.A)
- AI활용 위험영역 텍스트 분석 및 예측 모델</td></tr>
</table>

<table>
<tr><td rowspan="5">2. 연구성과 활용 유형 및 주요 연구성과</td><td colspan="8">(12) 연구결과의 활용</td></tr>
<tr><td rowspan="2">구분</td><td colspan="4">기술실용화</td><td rowspan="2">교육 및 지도</td><td rowspan="2">정책활용</td><td rowspan="2">설계기준, 시방서, 지침에 활용</td><td rowspan="2">기타</td></tr>
<tr><td>실용화 완료</td><td>실용화 추진중</td><td>실용화 보류 (중단)</td><td>선행 연구</td></tr>
<tr><td>○</td><td>○</td><td></td><td></td><td></td><td></td><td></td><td></td></tr>
<tr><td colspan="8"></td></tr>
<tr><td colspan="9">(13) 주요 연구성과 및 기술 개발단계</td></tr>
<tr><td colspan="4">◦기 술 명 :
- 자연어처리 알고리즘의 성능 향상을 위한 텍스트데이터 전처리 기법
- Transformers 기반의 기술문서 자동분류 딥러닝 모델</td><td colspan="5">◦기술의 완성도
기초, 탐색연구단계 ( ), 응용연구단계 (○),
개발연구단계 ( ), 기업화 준비단계 ( ),
상품화 완료단계 ( )

◦기술 수명주기
기술개념 정립기 ( ), 기술 실험기 ( )
기술적용 시작기 ( ), 기술적용 성장기 ( )
기술적용 성숙기 ( ), 기술적용 쇠퇴기 ( )</td></tr>
<tr><td rowspan="12">3. 경제적 효과</td><td colspan="9">(14) 현장적용실적</td></tr>
<tr><td>① 공사현장 정보</td><td>공사명</td><td colspan="2">공사기간</td><td>물량 (총물량)</td><td>발주기관</td><td>시공기관</td><td colspan="2">R&D 참여자 역할</td></tr>
<tr><td></td><td></td><td colspan="2"></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td></td><td></td><td colspan="2"></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td rowspan="8">② 공사 현장별 적용효과</td><td colspan="8">가. 현장명</td></tr>
<tr><td>구분</td><td>기 존 (A)</td><td>개 선 (B)</td><td>단위효과 (C=A-B)</td><td>현장 총물량 (D)</td><td>향상도</td><td colspan="2">적용현장 총효과 (C×D)</td></tr>
<tr><td>공사비 (백만원/㎡)[1)]</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td>유지관리비 (백만원/㎡)[1)]</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td>기타비용절감 (백만원/㎡)[1)]</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td>사고율 (명/UC)</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td>고 용 (명/UC)</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td>공 기 (일/UC)</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
<tr><td>내구성 (年)</td><td></td><td></td><td></td><td></td><td></td><td colspan="2"></td></tr>
</table>

4. 기술적 효과

(15) 기술개발목표 달성도

구분	지표명 (단위)	개발전 국내수준	당개발사업 최종목표치	개발결과 실제달성치	현재국내 기술수준	세계 최고 기술수준
기술 성능 지표						

(16) 산업재산권 (발명특허·실용신안·의장·s/w)

구분	명칭	출원국	출원 및 등록자	출원		등록	
				출원일	출원번호	등록일	등록번호
SW	방울이봇.C(사규·심리상담 AI(인공지능)챗봇)프로그램	국내	김세훈 주경원 이소령 김성훈			2023.12.14	C-2023-060146
SW	방울이봇.S(AI(인공지능) 문서요약)프로그램	국내	김세훈 주경원 이소령 김성훈			2023.12.7	C-2023-057927
SW	딥러닝 기반 감사문서 분류 프로그램	국내	주경원 박대원			2023.12.7	C-2023-057926
SW	거대언어모델 기반 방울이봇A(감사규정 AI챗봇) 프로그램	국내	이소령 김성훈 김세훈			2024.12.3	C-2024-050101
SW	인공지능 기반 위험영역 예측 분류 프로그램	국내	김세훈 김성훈 이소령			2024.12.3	C-2024-050100

(17) 건설신기술 지정

명 칭	출 원 일	고 시 일	보호기간	지정번호

(18) 기타 등록 및 지정현황(상품, 서비스 등록, KT 마크 등)

명 칭	출 원 일	고 시 일	보호기간	기 타

5. 학술적 효과

(19) 국내외 전문학술지 게재

구분	논문제목	학술지명	국명	통권, 호	년,월
국외 학술지 (ACM) (Scopus)	Comparative Analysis of Technology Trends in the Water Field across IP5 Countries Using Natural Language Processing	ACM (NLPIR 2024 International Conference Proceedings Series)	국외	ISBN:979-8-4007-1738-3	2024년 12월
국외 학술지 (ACM) (Scopus)	Artificial Intelligence-Based Prediction Modeling of Audit Dispositions in Korean Public Institutions	ACM (NLPIR 2024 International Conference Proceedings Series)	국외	ISBN:979-8-4007-1738-3	2024년 12월
국내 학술지 (KCI)	감사처분 예측모델 개발 연구	감사논집	국내	2023_제41호 ISSN-1975-3896	2023년 10월

(20) 학술회의 발표

논문제목	학술회의 명칭	국 명	연 도 · 호
공공부문 행정효율화를 위한 딥러닝과 자연어처리 연구	실용인공지능 컨퍼런스	국내	2023년 12월
기후변화 대응기술 탐색을 위한 자연어처리기반 트렌드 분석 연구	한국수자원학회 학술발표회	국내	2024년 5월
LDA 기반 토픽모델링을 활용한 물산업 분야 기술 트렌드 분석 연구	실용인공지능 컨퍼런스	국내	2024년 6월
Comparative Analysis of Technology Trends in the Water Field across IP5 Countries Using Natural Language Processing	NLPIR	국외	2024년 12월
Artificial Intelligence-Based Prediction Modeling of Audit Dispositions in Korean Public Institutions	NLPIR	국외	2024년 12월

6. 공공적 효과

(21) 법、제도 (설계기준, 시방서, 지침) 등에 활용

구분	명칭 및 조항[1)]	시행일시	기 존 내 용	신 규 내 용
법				
규정/지침				
기준				
시방서				

(22) 정책수립에 활용

정책명	정책추진 실적	정책추진 일시	담당부처、팀	기대효과

(23) 교육 및 지도에 활용

구분	교육명	교육내용	교육대상	교육시간	교육인원	교육회수
교육훈련						
기술상담						
현장기술지도						

(24) 사회적 성과

요 약 문

1. 연구제목

거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석

2. 연구기간

2023. 8. 1 ~ 2024. 12. 31

3. 연구목적

□ (최종목표) 언어모델 및 자연어처리를 활용한 물산업 기술정보 분석 및 솔루션 개발

○ 1차년도

- 물산업 관련 국내·외 기술정보 문헌 수집(국내외 논문, 특허, 보고서, K-water기술통합관리시스템(STP) 등)
- 기술정보의 자연어처리를 위한 전처리 및 탐색적 데이터 분석
- 언어모델 기반 AI 양정 가이드라인 및 유사문서 검색 알고리즘 고도화

○ 2차년도

- 단어별 의미론적 추론이 가능한 워드 임베딩 벡터 도출 및 시각화
- Transformers 기반의 기술문서 자동분류 딥러닝 모델 개발(정확도 90%↑)
- 언어모델에 기반한 물산업 기술분야별 정보제공 솔루션 개발
- 사내 수요조사를 통한 자연어처리 및 언어모델 기반 솔루션 개발

4. 연구내용

가. 물산업 관련 국·내외 기술정보 수집 및 분석

- 기술정보 문헌정보 수집 방법 탐색 및 DB구축(국내외 논문, 특허, 보고서, STP 등)
- 자연어처리를 위한 전처리 및 탐색적 데이터 분석(EDA)

나. 물산업 관련 기술정보 분석 및 솔루션 개발

- 자연어처리, 최신 AI 알고리즘을 사용한 물산업 관련 기술정보 분석 및 인사이트 도출
- 트랜스포머 기반의 자연어 딥러닝 모델 개발(정확도 90%↑)

다. 경영지원 및 솔루션

- AI 양정 가이드라인 및 유사문서 검색 알고리즘 개발
- K-water 사규·심리상담 AI 챗봇 개발(방울이봇.C)
- 물산업 기술정보 요약기(방울이봇.S)
- 감사 관련 규정 질의응답 챗봇 개발(방울이봇.A)
- AI활용 위험영역 텍스트 분석 및 예측모델

S U M M A R Y

1. Project Title/Subtitle

Analysis of Water Industry Technological Information using Large Language Models and Natural Language Processing

2. Research Period

August 1, 2023 - December 31, 2024

3. Objective of Research

□ (Final Goal) Development of a solution for analyzing technological information in the water industry using large language models and natural language processing

○ First-year Goals

- Collection of domestic and international documents related to water industry technological information (e.g., domestic and international papers, patents, reports, K-water technology integration system (Smart Tech Pedia; STP), etc.)
- Comprehensive processing and exploratory data analysis of technological information using natural language processing
- Advancement of AI-based text generation guidelines and similar document search algorithms

○ Second-year Goals

- Extraction and visualization of word embedding vectors capable of inferring word meanings
- Development of an automated deep learning model for technological document classification based on Transformers (Target accuracy: 90%)
- Development of an AI-based technological information provision solution for the water industry
- Development of a solution utilizing natural language processing and AI-based modeling to meet internal demand

4. Content, Scope and Method of Research

A. Collection and Analysis of Water Industry-Related Technological Information

- Establishment of a document database for technological information collection methods (including domestic and international papers, patents, reports, STP, etc.)
- Comprehensive processing and exploratory data analysis (EDA) of technological information using natural language processing

B. Development of Water Industry Technological Information Analysis and Solutions

- Extraction of insights related to water industry technological information using state-of-the-art AI algorithms for natural language processing
- Development of a Transformer-based deep learning model for natural language processing (target accuracy: 90%)

C. Competitive Solutions

- Development of AI-based text generation guidelines and document search algorithms
- Development of K-water chatbot for water-related technology consultation (model C)
- Development of AI-based technology information provision solutions (model S)
- Development of a chatbot solution for responding to water-related regulatory inquiries (model A)
- Risk factor analysis and modeling of hazardous text analysis

목 차

제 1 장 서론 ····· 1

1.1 연구 배경 및 목적 ····· 1
1.1.1 연구배경 ····· 1
1.1.2 연구목적 ····· 2
1.2 연구 내용 및 범위 ····· 3

제 2 장 이론 및 문헌연구 ····· 3

2.1 AI를 활용한 의사결정지원 관련 동향 ····· 3
2.2 이론적 배경 ····· 4
2.2.1 자연어처리와 이의 활용 ····· 4
2.2.2 기술정보 분석 관련 기본 이론 ····· 6
2.2.3 문서 내 단어의 중요성 평가 방법 ····· 7
2.2.4 자연어처리를 위한 딥러닝 방법론 ····· 7
2.3 국내 기술 수준 및 현황 ····· 9
2.3.1 국내 기술 수준 및 현황 ····· 9
2.3.2 관련 선행 연구 검토 ····· 10

제 3 장 기술정보 분석 ····· 13

3.1 국내외 기술정보 문헌 수집 ····· 14
3.1.1 특허자료 수집 방법론 ····· 14
3.1.2 논문자료 수집 방법론 ····· 15
3.1.3 K-water 연구보고서 수집(STP) ····· 18
3.2 데이터 전처리 방법론과 적용 ····· 19
3.2.1 전처리 필요성과 일반 이론 ····· 19
3.2.2 기술정보 분석을 위한 텍스트 전처리 방법 적용 ····· 22
3.3 기술정보 자연어처리 방법론 및 적용 ····· 24
3.3.1 기술 트렌드 분석 방법론 (LDA) ····· 24
3.3.2 문맥 기반 핵심 키워드 도출 방법론 (KeyBERT 알고리즘) ····· 25
3.4 기술정보 분석 ····· 27
3.4.1 토픽 라벨링(Topic Labeling) ····· 27
3.4.2 네트워크 분석(Network Analysis) ····· 28
3.4.3 분석 결과 ····· 28

제 4 장 인공지능 언어모델 기반 솔루션 개발 적용 ····· 30
4.1 배경 및 목표 ····· 30
4.2 OASIS 감사시스템 AI 기반 양정예측 프로그램 개발 ····· 30
4.2.1 개요 ····· 30
4.2.2 양정 예측 모델 개발 과정 ····· 31
4.2.3 유사사례 및 관련 규정 검색 알고리즘 개발 ····· 35
4.3 AI활용 위험영역 예측 모델 개발 ····· 36
4.3.1 개요 ····· 36
4.3.2 윤리 키워드 텍스트 분석 ····· 37
4.3.3 AI 예측 분류모델 개발 ····· 42
4.3.4 데모용 웹 애플리케이션 개발 ····· 46
4.4 LLM활용 챗-에이전트 개발 ····· 46
4.4.1 개요 ····· 46
4.4.2 방울이봇.C^{Chatbot} ····· 47
4.4.3 방울이봇.A^{Audit} ····· 49
4.5 LLM활용 문서요약기 개발 ····· 51
4.5.1 개요 ····· 51

제 5 장 결론 ····· 54

Appendix ····· 55

참 고 문 헌 ····· 60

표 목 차

표 1 자연어처리 핵심 기술 및 응용사례 ····· 5
표 2 자연어처리를 위한 검토 요소 ····· 6
표 3 관련 연구 및 유사 과제 현황 ····· 10
표 4 정적 크롤링 vs 동적 크롤링 ····· 17
표 5 데이터 정제 주요 기법 요약 ····· 20
표 6 데이터 변환 기법 비교 ····· 21
표 7 데이터 축소 전후 비교 ····· 21
표 8 데이터 구조화 사례 ····· 22
표 9 전처리 과정 ····· 32
표 10 수정된 양정결과 예시 ····· 32
표 11 감사 양정 모델별 성능 비교 ····· 35
표 12 TF, TF-IDF 비교 ····· 37
표 13 수정된 양정결과 예시 ····· 38
표 14 키워드 도출 (활용:제목, TF, [Bi+Trigram]) ····· 39
표 15 키워드 도출 (활용: 제목, TF-IDF, [Bi+Trigram]) ····· 40
표 16 키워드 도출 (활용: 내용, TF-IDF, [Bi+Trigram]) ····· 41
표 17 문장 교정 전/후 비교 ····· 42
표 18 사용자 키워드 추가 전/후 비교 ····· 42
표 19 윤리위험 유형별 AI 예측모델 성능 ····· 44
표 20 결과 출력 예시(1) ····· 44
표 21 결과 출력 예시(2) ····· 45
표 22 결과 출력 예시(3) (입력: 타기관 감사조치요구서) ····· 45
표 23 웹·애플리케이션 화면 예시 ····· 46
표 24 RAG 기술 개요 ····· 49

그 림 목 차

그림 1 딥러닝 기반 기술 클러스터 성장 가능성 예측 모형(KISTI) ····· 2
그림 2 LDA 방법을 이용한 토픽모델링 ····· 6
그림 3 (ETRI) 형태소 기반 언어모델(KorBERT)과 구글의 언어모델(BERT) 비교 ····· 9
그림 4 카카오의 GPT기반 KoGPT, 이미지 수정 모델인 Karlo ····· 10
그림 5 Wintelips 특허자료 조회 예시 ····· 14
그림 6 CPC코드 Y02A-0020 특허 ····· 15
그림 7 논문 수집 대상 저널 예시(MDPI) ····· 16
그림 8 수집한 논문 예시 ····· 17
그림 9 (Python코드) 논문 정보 크롤링 함수 정의 ····· 18
그림 10 (Python코드) iframe 처리 함수 정의 ····· 18
그림 11 수집 완료된 논문 정보 예시 ····· 18
그림 12 K-water 연구과제 초록 ····· 19
그림 13 기술정보 텍스트 전처리 적용 함수 ····· 24
그림 14 LDA 목적함수 ····· 24
그림 15 Topic Modeling 알고리즘 ····· 25
그림 16 LDA 분석 결과 (한국, 중국, 일본, 미국, 유럽 외 4개국) ····· 25
그림 17 KeyBERT 알고리즘 ····· 26
그림 18 토픽 라벨 후보군 (22개) ····· 27
그림 19 토픽 라벨링 과정 ····· 27
그림 20 Gephi 프로그램 설명 ····· 28
그림 21 국가별 기술정보 분석 결과 ····· 29
그림 22 감사양정 예측 프로그램 개요 ····· 31
그림 23 AI 양정가이드 양정 추천 예시 ····· 31
그림 24 감사조치요구서 문서 길이 ····· 33
그림 25 처분결과 분포 그래프 ····· 33
그림 26 예측결과 출력 모습 예시 ····· 34
그림 27 출력 예시 ····· 36
그림 28 윤리위험 유형별 EDA ····· 43
그림 29 방울이봇.C 서비스 화면 ····· 48
그림 30 방울이봇.C 스키마 ····· 48
그림 31 방울이봇.A 실행 화면 ····· 50
그림 32 활용된 클라우드 스펙 (AWS) ····· 52
그림 33 방울이봇.S 서비스 화면 ····· 53
그림 34 방울이봇.S 모델 스키마 ····· 53

제 1 장 서론

1.1 연구 배경 및 목적

1.1.1 연구배경

최근 디지털 전환이 가속화되며, 다양한 산업 분야에서 정보의 체계적 분석과 활용이 경쟁력의 핵심 요소로 자리잡고 있다. 그 중에서도 특히 물산업은 기후변화, 인구증가, 산업화 등 환경적 변화 속에서 지속 가능한 물관리와 관련 기술의 개발이 필수적인 분야 중 하나이다. 세계 물 시장 규모는 2022년 기준 약 3,028억 1천만 달러(411조원)로 평가되었으며, 2030년 말까지 연평균 성장률(CAGR) 4.51%로 성장할 것으로 예상된다. (Zion Market Research Report, 미국) 물관련 기술 분야의 발전과 시장 규모의 급속한 성장은 체계적이고 전략적인 접근 및 미래기술 준비 필요성을 요구하고 있다. 물산업 기술정보의 분석은 글로벌 경쟁력 확보의 핵심 요소로써 국가별로 특화된 기술 영역을 비교하고, 기술 개발의 전략적 우선순위를 결정하는 것은 글로벌 물산업 시장에서의 우위를 점하기 위해 필수적이다. 그러나 물산업 기술정보는 방대한 양의 비정형 데이터로 존재하고 있으며, 언어와 포맷의 다양성으로 인해 체계적인 분석과 활용이 어렵다는 한계를 가지고 있다. 기존에도 급격히 증가하는 텍스트 데이터를 활용하여 자연어처리 연구를 하려는 시도는 있었으나, 그 수준은 빈도 분석이나 워드클라우드 수준에 머물러 이러한 요구를 충족시키기에는 한계가 있었다.

이러한 제약 환경에서 거대언어모델(GPT, BERT 등)과 자연어처리(Natural Language Processing, NLP) 기술의 발전은 물산업 기술정보 분석의 새로운 가능성을 열어주었다. 거대언어모델은 대규모 텍스트 데이터를 이해하고 처리하는 뛰어난 능력을 바탕으로 기존의 수작업 분석 방식을 대체할 수 있는 혁신적인 도구로 자리잡았다. 특히 기술 문서, 특허 데이터, 연구 초록, 논문 등 비정형 데이터에서 유의미한 패턴과 통찰을 도출할 수 있는 가능성을 제공함으로써, 물산업 관련 미래 유망기술 선정을 위한 기술정보 분석 및 예측에도 자연어처리(NLP) 기술을 활용한 연구가 주목받고 있다.

2019년 KISTI는 [그림 1]과 같이 기술군별 논문 데이터를 활용한 딥러닝 기반의 기술 클러스터 성장 가능성 예측 모형을 개발하여, 미래 기술의 잠재력 및 발전 가능성을 예측하고 이에 따라 연구개발 전략을 수립하고자 하였다. 이처럼 K-water에서도 디지털 전환 가속화를 위해 최신 AI 기술인 자연어처리 및 딥러닝 모델을 개발하여 계량화된 증거 기반의 기술 전망 프로세스를 구축할 필요가 있다. 또한, 자연어처리 기술은 단순히 물산업 기술 분석에만 그치지 않고, K-water내 다양한 부서에 텍스트 데이터를 활용하여 문제를 해결하고 업무 효율성을 높이는 데 기여할 수 있는 잠재력을 가지고 있으므로 관련 기술의 내재화가 필요하다.

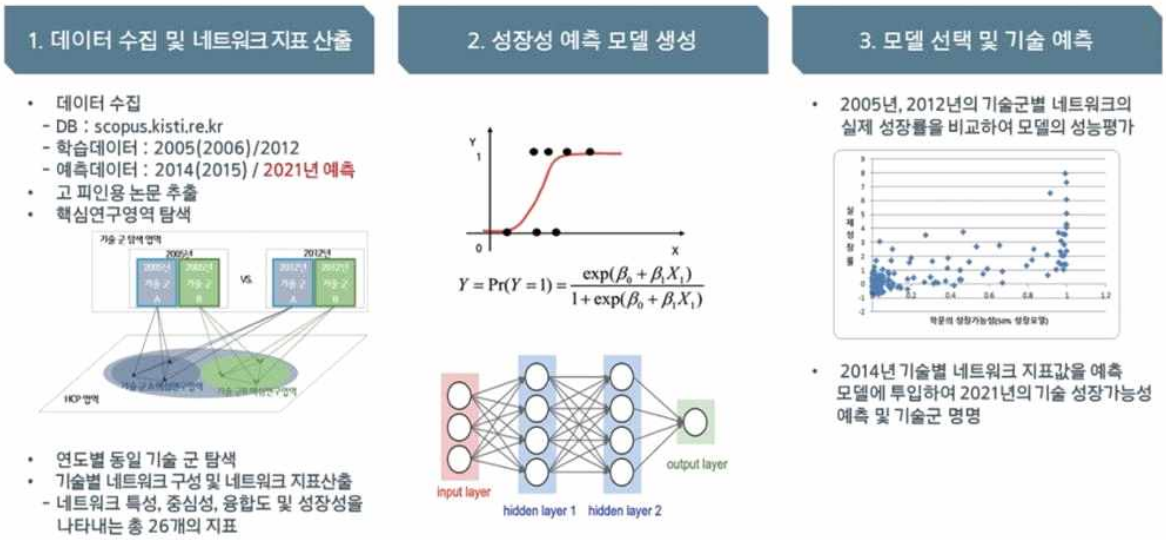


그림 1 딥러닝 기반 기술 클러스터 성장 가능성 예측 모형(KISTI)

1.1.2 연구목적

본 연구는 거대언어모델과 자연어처리 기술을 활용하여 물산업 기술정보를 체계적으로 수집, 분석, 활용할 수 있는 데이터 기반 의사결정 프로세스를 구축하는 것을 목적으로 한다. 물산업 분야를 중심으로 방대한 텍스트 데이터를 분석하여 국가별 물산업 기술 동향과 세부 기술 영역을 도출하고, 글로벌 경쟁력을 확보하기 위한 전략적 연구개발의 방향성을 제시하고자 한다. 또한, 자연어처리 기술의 확장성을 바탕으로 물산업뿐만 아니라 다양한 분야에서 텍스트 데이터 활용의 가능성을 모색한다. 구체적으로 본 연구는 아래의 세 가지 주요 목적을 가진다.

첫째, 물산업 기술정보의 DB화를 목표로 연구 초록, 특허 데이터 등 비정형 데이터를 효과적으로 수집하고 전처리하는 기술을 개발하여 데이터의 품질을 높이고 연구 개발과 기술 동향 분석을 위한 기반을 마련한다. 두 번째로, LDA/KeyBERT/네트워크 분석 등 자연어처리 기술을 활용하여 물산업 기술 간의 연관성을 분석하고 국가별 핵심 기술과 트렌드를 시각적으로 도출한다. 이를 통해 국가 간 기술 경쟁력을 비교할 수 있는 구체적인 정보 제공 및 K-water의 경쟁력을 확보하기 위한 미래 방향성을 제시하고자 한다. 마지막으로, 자연어처리 기술을 활용하여 인공지능 언어모델 기반의 다양한 솔루션을 개발함으로써 연구 성과가 단순한 분석에 그치지 않고 실질적인 의사결정과 업무 프로세스 개선으로 이어질 수 있도록 한다. 이러한 연구를 통해 자연어처리 기술의 실질적 응용 가능성을 확장하여 데이터 기반 의사결정과 디지털 전환을 지원하고, 조직 전반의 데이터 활용 역량을 강화하는 데 기여하고자 한다.

1.2 연구 내용 및 범위

본 연구는 거대언어모델과 자연어처리 기술을 활용하여 물산업 기술정보를 분석하여 국가별 물산업 기술 동향과 세부 기술 영역을 도출하고 실질적인 응용 가능성을 탐구한다. 분석 데이터는 K-water 연구과제 초록과 WINTELIPS DB의 IP5 국가 특허 데이터이며, 전처리 과정에서 비정형 데이터를 정규화하고 주요 기술 영역을 정의하였다. 분석 방법론으로는 LDA(Latent Dirichlet Allocation)기반의 토픽모델링을 활용하여 국가별 기술 동향과 세부 기술 영역을 도출하였다. 다음으로 KeyBERT와 네트워크 분석을 활용하여 기술 간 연관성을 파악하고 기술 발전 트렌드와 국가 간 경쟁력을 비교하여 전략적 R&D 방향성을 제안하였다. 기술 트렌드와 융합 가능성을 시각적으로 표현하고, 국가별 기술 특성을 분석하여 연구개발 방향성을 구체화였다. 또한, 연구 결과를 응용하여 딥러닝 기반의 윤리위험 분석 모델, AI 기반 양정 가이드라인, 방울이봇(S,C) 프로토타입과 같은 시스템을 개발하고 이를 통해 실질적인 문제 해결과 업무 효율화를 지원하고자 한다. 본 연구는 물산업 기술정보뿐만 아니라 K-water 내 다양한 부서에서 자연어처리 기술을 적용하여 데이터 기반 업무 혁신을 구현할 수 있는 가능성을 제시한다.

제 2 장 이론 및 문헌연구

2.1 AI를 활용한 의사결정지원 관련 동향

인공지능은 현재 산업 전반에서 의사결정을 지원하는 핵심 기술로 자리 잡고 있다. 정치, 경제, 사회, 문화 등 다양한 분야에서 인공지능은 방대한 데이터를 활용해 인간이 발견하기 어려운 패턴을 찾아내고 이를 바탕으로 통찰력 있는 결정을 내릴 수 있도록 돕고 있다.

재난 및 재해 대응 분야에서는 사물인터넷(IoT) 기반의 센서를 통해 축적된 데이터를 분석하여 재난 상황을 예측하고 대응 방안을 마련하는 데 AI가 활용되고 있다. 특히 복잡한 데이터를 종합적으로 해석하여 신속하고 적절한 결정을 내리는 데 기여한다.

의료 분야에서는 임상의사결정지원시스템(Clinical Decision Support System)에 인공지능을 적용해 의사들이 환자 진료와 관련된 정확하고 신속한 결정을 내릴 수 있도록 돕고 있다. 인공지능은 방대한 의학 정보를 환자 데이터와 비교·분석하며 육안으로 감지하기 어려운 영상 이미지를 판독해 의학적 판단을 지원하고 있다.

디지털 국정관리 분야에서도 인공지능이 중요한 역할을 하고 있다. 일자리, 부동산, 경제, 민생 등 주요 지표에 이상이 발생할 경우 인공지능은 데이터를 분석하고 정책을 예측해 대안을 모색하는 데 활용되고 있다. 정책 시뮬레이션을 통해 다양한 시나리오를 검토하고 최적의 대안을 탐색하는 데에도 활용하고 있다.

사법 분야에서는 리걸 테크(Legal Tech)라는 이름으로 AI가 사용되고 있다. AI는 판례 분석, 형량 예측, 법조 생성형 AI, 변호사 업무 자동화 등 법률 서비스를 지원하기 위해 발전하고 있으며 판사, 검사, 변호사 등의 법률 전문가 의사결정에 도움을 주고 있다. 감사 분야에서도 인공지능은 대규모 데이터를 신속하고 정확하게 분석해 감사 업무의 효율성을 높이는 데 기여하고 있다.

참고 **법무 분야 AI의 적용 사례**

□ (사례) 대표적인 리걸 테크로 미국 기업 '노스포인트'가 인공지능 기술을 적용하여 개발한 '컴퍼스[1](COMPAS)'가 있음. '컴퍼스'는 사건을 분석하고 판결을 예측하여 의사결정의 판단자료로 활용할 수 있게 해주는 법률 분석 프로그램으로 미국 법정에서 폭력 사범인 피고인의 재범 가능성을 분석하는데 활용됨(이나래, 2019). 또한, ChatGPT로 대표되는 생성형 AI가 적용된 서비스도 있음. 대표적인 것 중 하나가 미국 법률 데이터베이스 렉시스넥시스가 준비하고 있는 '렉시스+AI' 임. '렉시스+AI'는 법조인 대신 법률 문서·판결문 작성, 판례 검색 등을 함. 또한, 수백 페이지의 법률 문장을 몇 초안에 요약하고, 참고 자료를 비롯한 판례, 법령 등을 정리하고 전문적인 법률 질문에 답할 수 있음(ZDNet Korea, 2023). 국내의 리걸 테크는 공개 법률 데이터 부족, 리걸 테크 인력 부족, 인증제도 관련 규제, 변호사법 등으로 인해 미국과 비교해 발전이 느리지만, 향후 법률 업무 효율화와 자동화, 법률 서비스의 질 제고, 고객 경험의 개선 등 사법 관련 업무처리가 혁신될 것이라고 보고 있음

인공지능은 인간의 판단을 보조하는 수준일뿐이지만, 기술발전과 사회적 수용이 점차 이루어지면서 의사결정 지원 역할이 강화되고 있다. 머신러닝의 지도학습(Supervised Learning) 개념을 기반으로 학습한 인공지능은 방대한 빅데이터 속에서 인간이 발견하기 어려운 규칙을 찾아내고 이를 통해 의사결정을 지원하는 데 있어 중요한 역할을 하고 있다.

2.2 이론적 배경

2.2.1 자연어처리와 이의 활용

자연어처리(Natural Language Processing)는 컴퓨터와 인간 언어 간의 상호작용 기술로, 텍스트 데이터의 정보를 추출하고 해석하기 위한 다양한 알고리즘과 모델을 개발하는 데 초점이 맞춰져 있다. 자연어처리는 텍스트 및 음성 처리, 문법 분석, 감성 분석, 객체 간 관계 추출, 참/거짓 구분 등의 기본적인 작업에서부터 자동 요약, 원고 작성, 문법 교정, 기계 번역, 텍스트-이미지 생성, 챗봇 등 고급 작업까지 수행할 수 있다.

물산업 기술동향 분석에 있어 자연어 처리를 활용하여 경쟁력을 유지하고 혁신을 추구할 수 있다. 이는 시장 변화를 예측하고 새로운 기술 개발 방향을 설정하는데 중요하다. 최근 자연어처리는 산업 기술동향 분석에 광범위하게 활용되고 있으며, 특히 대규모 텍스트 데이터에서 유의미한 정보를 자동으로 추출하고 이를 분석하여 산업의 미래 동향을 예측하는 데 기여하고 있다.

기술적으로 자연어처리를 위한 주요 프로그래밍 언어와 라이브러리로는 NLTK, SpaCy, Gensim, TensorFlow, PyTorch 등이 사용된다. 이러한 도구들은 텍스트 처리와 기계 학습 작업

1) 기존의 상습성 판단 또는 가석방 여부 판단 데이터에 대한 학습을 근간으로 만들어짐

을 지원하며 자연어처리의 효율성을 높이는 데 활용되고 있다. 그러나 텍스트 분석 작업에서는 데이터 품질과 접근성 측면에서 고품질 데이터를 확보하는 데 어려움이 존재하며 실시간 데이터 스트림을 처리하는 기술 개발이 필요하다.

표 1 자연어처리 핵심 기술 및 응용사례

□ 자연어처리 핵심기술

① 텍스트 마이닝: 비정형 데이터에서 유용한 정보를 추출하는 기술

② 기계 학습: 데이터 패턴을 학습하여 미래의 데이터를 예측하거나 분류하는 모델을 만드는 것

③ 딥 러닝: 특히, 자연어 이해(Natural Language Understanding, NLU)에서 중요한 역할을 함

□ 응용사례

① 특허 분석: 특허 문서에서 기술 트렌드와 혁신을 추적

② 학술 논문 분석: 최신 연구 동향과 연구 갭을 식별

③ 소셜 미디어 분석: 산업 관련 대화에서 인사이트를 추출

기술적인 개발 능력뿐만 아니라 다양한 언어와 문화적 맥락을 이해하는 모델 또한 요구된다. 최근 생성형 모델의 활용이 증가함에 따라 상호작용성이 강화되고 있으며 사용자의 피드백을 통해 더 정확한 결과를 도출하려는 시도가 확대되고 있다. 이러한 발전은 자연어처리가 다양한 응용 분야에서 더욱 중요하게 자리 잡고 있음을 보여준다.

2.2.2 기술정보 분석 관련 기본 이론

자연어처리 기반의 기술정보 분석을 위해서는 다음과 같은 요소 검토가 필수적이다.

표 2 자연어처리를 위한 검토 요소

① 구문 분석(Syntax Analysis): 문장의 구조를 분석하여 문법적 관계를 이해
② 의미 분석(Semantic Analysis): 단어와 문장에서 의미를 추출
③ 맥락 분석(Context Analysis): 대화나 문서의 맥락을 이해하고, 해당 정보를 바탕으로 의미를 해석

기술정보 분석과 관련된 기본 이론 중 하나는 텍스트 데이터 내 주제를 모델링하는 확률적 토픽 모델이 있다. 토픽 모델은 구문 분석, 의미 분석, 맥락 분석과 유사하지만, 그 목적과 방식에서 차이가 있다. 확률적 토픽 모델은 텍스트 데이터에서 주제를 발견하고 이를 바탕으로 구조적 인사이트를 도출하는 데 초점을 맞춘다.

토픽 모델링은 산업 및 기술 분야에서 기술 분류체계를 구축하고 이를 활용하여 시사점 도출에 주로 사용된다. 이 중에서도 잠재 디리클레 할당(LDA, Latent Dirichlet Allocation)은 주어진 문서에서 어떤 주제들이 존재하는지를 확률적으로 서술하는 대표적인 기법이다. LDA는 문서가 여러 주제의 조합으로 이루어져 있다는 가정하에, 각 문서의 주제 분포와 각 주제 내 단어의 분포를 학습한다. 이를 통해 대량의 텍스트 데이터에서 중요한 주제와 패턴을 식별하고 이를 구조화함으로써 비정형 데이터를 정형화하고 트렌드를 분석하는 데 기여한다.

LDA의 주요 목적은 문서 집합 내에서 잠재되어있는 주제를 발견하고 각 문서가 어떤 주제들로 구성되어 있는지를 추론하는 것으로, 텍스트 데이터의 의미적 구조를 탐색하고 의미를 분석하는 것이다. 이러한 점에서 구문분석이나 맥락분석과 차이가 있다. 구문 분석은 문장의 구조와 문법적 관계를 해석하는 데 중점을 두는 반면, LDA는 텍스트의 의미적 내용을 주제별로 구분하려는 데 목적이 있다. 또한, 맥락분석은 특정 문맥에서 단어나 문장의 의미를 해석하는 데 초점을 맞추지만, LDA는 보다 넓은 문서나 데이터셋 전체에서 주제를 모델링하는 데 중점을 둔다.

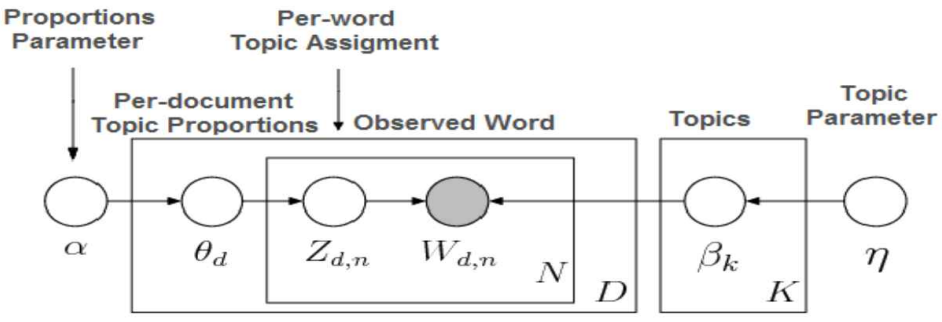


그림 2 LDA 방법을 이용한 토픽모델링

따라서 LDA는 대량의 텍스트 데이터에서 잠재적인 주제를 식별하고 이를 바탕으로 의미있는 정보를 도출하는 데 있어 강력한 도구로 활용될 수 있다. 이러한 점에서 LDA는 기술정보 분석 및 트렌드 파악에서 중요한 역할을 하며 비정형 데이터를 구조화하는 데 유용하다.

2.2.3 문서 내 단어의 중요성 평가 방법

문서 내 단어의 중요성을 평가하는 방법으로는 Term Frequency(TF)와 Inverse Document Frequency(IDF)가 있다. TF는 특정 단어가 문서 내에서 등장하는 빈도를 의미하며 해당 단어의 빈도를 문서의 총 단어 수로 나눈 값으로 표현된다. 반면, IDF는 특정 단어가 다른 문서에 얼마나 자주 등장하는지를 측정하는 지표로, 전체 문서 수를 단어가 등장한 문서의 수로 나눈 후 로그를 취한 값으로 계산된다. TF와 IDF를 결합한 TF-IDF는 문서 검색, 정보 검색, 텍스트 마이닝에서 키워드의 중요성을 판단하고 문서의 핵심 주제를 파악하는 데 유용하며 텍스트 데이터에서 의미 있는 정보를 추출하고 분석할 수 있다.

또한, TDM(Term Document Matrix)은 문서 집합에서 각 단어가 각 문서에 얼마나 많이 나타나는지를 행렬 형태로 표현한 것이다. TDM은 문서는 열로, 단어는 행으로 구성하며 각 셀에는 특정 문서에서 해당 단어가 나타난 빈도가 기록된다. TDM은 텍스트 데이터를 구조화된 형식으로 변환하여 다양한 통계적 분석이나 기계 학습 알고리즘을 적용하기 쉽게 만든다. 그러나 대부분의 TDM은 데이터 희소성 문제를 가지는데, 많은 단어가 대부분의 문서에서 등장하지 않기 때문이다.

TDM은 문서 분류, 감성 분석, 주제 모델링 등 다양한 자연어처리(NLP) 작업에 활용된다. 예를 들어, TDM을 기반으로 문서 간의 유사성을 계산하거나 특정 주제에 가장 관련이 깊은 단어를 식별할 수 있다. TF-IDF와 TDM은 텍스트 분석의 기본적이면서도 강력한 도구로, 텍스트 데이터의 숨겨진 패턴과 구조를 밝혀내는 데 중요한 역할을 한다. 이러한 기술들은 데이터 과학과 정보 검색 분야에서 널리 사용되며 디지털 시대에 정교한 텍스트 분석 기술의 기반이 되고 있다.

2.2.4 자연어처리를 위한 딥러닝 방법론

가. CNN(Convolutional Neural Network)

CNN(Convolutional Neural Network, 합성곱 신경망)은 딥러닝에서 주로 이미지 데이터 처리를 위해 사용되는 신경망 구조이다. CNN은 데이터의 공간적 구조를 고려하여 특징을 추출하고 이를 기반으로 패턴을 학습하는 데 강점이 있다.

CNN은 주로 이미지 분류, 객체 검출, 얼굴 인식, 자율주행 차량의 시각 시스템 등 다양한 컴퓨터 비전 작업에 활용되며, 텍스트와 시계열 데이터와 같은 다른 데이터 유형에서도 변형된 형태로 적용할 수 있다. CNN은 데이터의 특징을 효율적으로 학습할 수 있어 이미지 처리와 관련된 많은 문제를 해결하는 데 핵심 기술로 자리 잡고 있다. 아래는 CNN의 주요 구성요소에 대한 설명이다.

- Convolutional Layer(합성곱 층): 특정 이미지에서 특징을 추출하는 역할을 하며, 이는 작은 필터(또는 커널)를 사용하여 입력 이미지의 부분과 합성곱 연산을 수행함으로써 이루어짐
- Pooling Layer(풀링 층): 차원 축소를 통해 연산량을 줄이고, 특징 맵의 공간적 크기를 줄임. 풀링은 Max Pooling과 Average Pooling을 사용하여 이루어짐

- ReLU Layer(Rectified Linear Unit): 비선형 활성화 함수로, 음수 값을 0으로 변환하여 모델의 표현력을 높임
- Fully Connected Layer(완전 연결 층): 추출된 특징을 바탕으로 최종 분류를 수행하며 모든 뉴런이 서로 연결된 구조

나. Transformer(트랜스포머)

Transformer는 자연어처리(NLP) 분야에서 혁신적인 변화를 가져온 딥러닝 모델로 특히 시퀀스 데이터를 처리하는 데 효과적이다. RNN(Recurrent Neural Network)이나 LSTM(Long Short-Term Memory)과 같은 기존의 순환 신경망 구조와 달리, Transformer는 전체 시퀀스를 병렬적으로 처리할 수 있어 학습 속도가 빠르고 성능이 우수하다.

Transformer의 핵심 개념은 Self-Attention 메커니즘이다. 이 메커니즘은 입력 데이터의 각 단어가 문맥에서 다른 단어들과 어떻게 관련되어 있는지를 동적으로 학습하며, 이를 통해 단어 간의 상관관계를 효율적으로 파악하고 문장의 문맥을 이해하는 데 중요한 역할을 한다.

Transformer는 다양한 자연어처리 작업에서 사용되며 기계 번역, 문서 요약, 질문 응답 시스템 등에서 뛰어난 성능을 발휘한다. 특히, Transformer를 기반으로 한 BERT(Bidirectional Encoder Representations from Transformers)와 GPT(Generative Pre-trained Transformer) 같은 모델들은 사전 학습(pre-training)과 미세 조정(fine-tuning) 기법을 활용해 다양한 언어 이해와 생성 작업에서 성과를 거두고 있으며, Transformer는 음성 및 비전 작업 등 다양한 영역에서도 활용 범위를 넓혀가고 있다. 아래는 Transformer의 주요 구성 요소에 대한 설명이다.

- Encoder(인코더): 입력 시퀀스를 받아서 정보를 압축하여 인코딩함. 인코더는 여러 개의 셀프 어텐션(Self-Attention) 층과 피드포워드(Feedforward) 신경망 층으로 구성되어 있으며, 셀프 어텐션은 각 단어가 다른 단어들과의 관계를 이해할 수 있게 함
- Decoder(디코더): 인코더가 출력한 정보를 받아서, 출력 시퀀스를 생성함. 디코더는 인코더의 출력을 바탕으로 셀프 어텐션과 인코더-디코더 어텐션(Encoder-Decoder Attention)을 사용하여 다음 단어를 예측함
- Attention Mechanism(주의 메커니즘): 입력 시퀀스의 모든 단어가 서로 어떻게 연관되어 있는지를 계산하며 이는 중요한 단어에 더 높은 가중치를 부여하여 문맥을 파악하게 함

다. BERT(Bidirectional Encoder Representations from Transformers)

BERT(Bidirectional Encoder Representations from Transformers)는 자연어처리 분야에서 문맥을 이해하기 위해 설계된 딥러닝 모델이다. Transformer 구조를 기반으로 하며 문장의 앞뒤 맥락을 모두 고려해 단어의 의미를 파악할 수 있도록 양방향 인코더 구조를 사용한다. 이를 통해 기존 단방향 모델의 한계를 극복하며 텍스트 데이터의 의미를 더 깊이 이해할 수 있다.

BERT는 사전 학습(Pre-training)과 미세 조정(Fine-tuning)의 두 단계로 학습되는데, 사전 학습 과정에서 모델은 Masked Language Model(MLM)과 Next Sentence Prediction(NSP) 작업을 통해 문맥을 이해하는 능력을 강화한다. 이후 미세 조정 단계에서 다양한 NLP 작업에

맞게 추가적인 학습이 이루어진다. 아래는 BERT 주요 구성 요소이다.

- 인코더(Encoder): 문장의 앞뒤 맥락을 모두 고려하며, 셀프 어텐션(Self-Attention) 메커니즘과 피드포워드(Feedforward) 신경망 층으로 구성
- Masked Language Model (MLM): 문장에서 일부 단어를 마스킹하고, 해당 단어를 예측하는 작업을 통해 모델이 문맥 정보를 학습
- Next Sentence Prediction (NSP): 두 문장이 주어졌을 때, 두 번째 문장이 첫 번째 문장의 다음 문장인지 여부를 예측
- 사전 학습(Pre-training): 대규모 텍스트 데이터셋을 활용해 MLM과 NSP 작업을 수행하며, 모델의 초기 가중치를 학습
- 미세 조정(Fine-tuning): 사전 학습된 모델에 추가적인 층을 쌓아 특정 NLP 작업(예: 문서 분류, 질문 답변, 감정 분석 등)에 맞게 학습
- 셀프 어텐션(Self-Attention): 문장 내 단어 간 관계를 학습하며, 단어 간의 상호작용을 모델링

2.3 국내 기술 수준 및 현황

2.3.1 국내 기술 수준 및 현황

한국전자통신연구원(ETRI)은 과학기술정보통신부의 지원을 받아 구글의 BERT (Bidirectional Encoder Representation from Transformers) 언어 표현 방법을 기반으로 한국어 언어 모델인 'KorBERT'를 공개하였으며, 기업군에서는 카카오, 카카오 Brain, 네이버 Clova와 같은 IT 기업에서 주도하여 자연어 범용 모델 '뽀로로(PORORO)', 딥러닝 기반 형태소 분석기 '카이(khaii)' 등을 오픈소스 형태로 공개하였다.

언어모델 분야에서는 카카오의 GPT기반 KoGPT, 이미지 수정 모델은 Karlo가 있으며 네이버는 HyperCLOVA 모델을 통해 한국어 언어모델을 제공하고 있다.

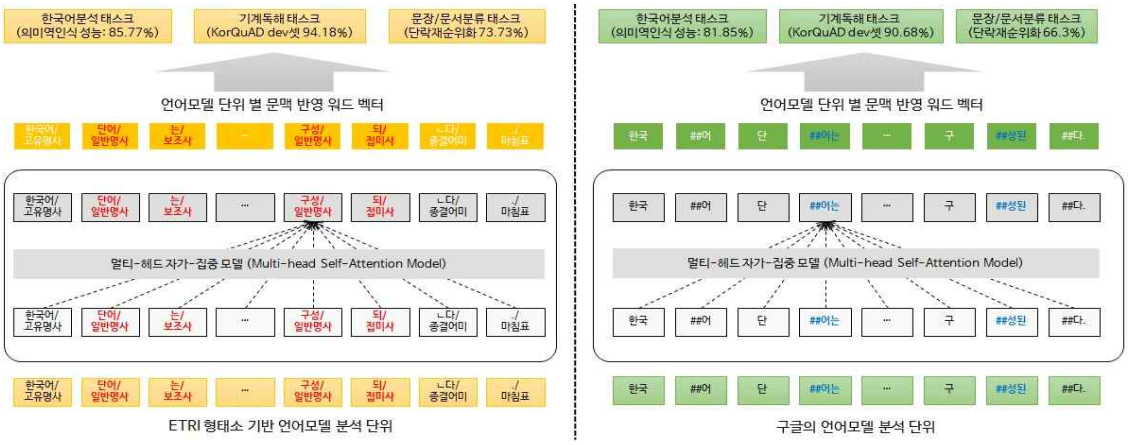


그림 3 (ETRI) 형태소 기반 언어모델(KorBERT)과 구글의 언어모델(BERT) 비교

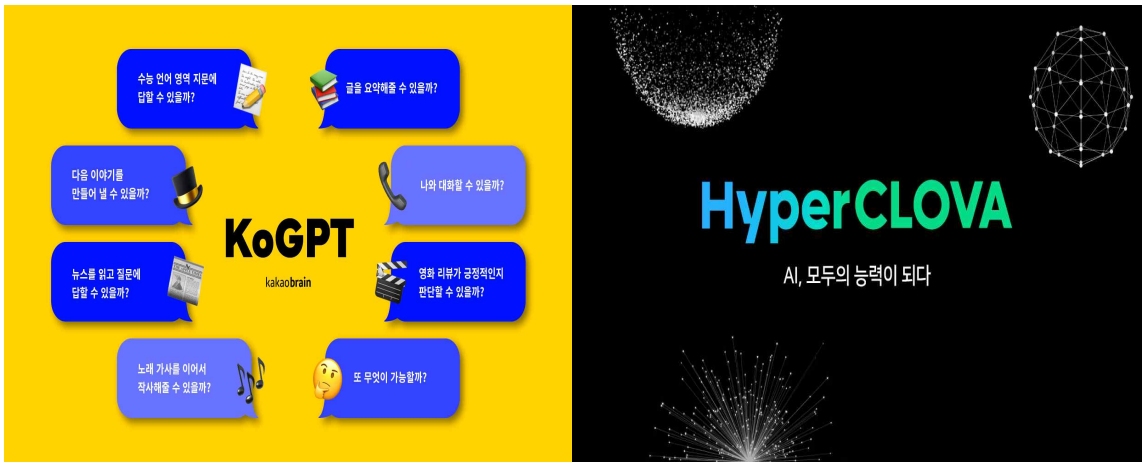


그림 4 카카오의 GPT기반 KoGPT, 이미지 수정 모델인 Karlo

표 3 관련 연구 및 유사 과제 현황

연구수행기관	연구개발 내용	연구개발성과의 활용현황
KISTI (상시)	논문 및 특허정보를 활용하여 최신 과학기술 트렌드 및 미래유망기술 탐색	신기술 분석 플랫폼 'MIRIAN'을 구축하여 미래기술 지식베이스, 디렉토리, 미래유망기술 등을 도출
KISTEP (격년)	10대 미래유망기술 선정 및 분석 (문헌조사, 언론보도 분석, 전문가 의견수렴 수행)	KISTEP 내부의 기술기획 및 기술예측 역량 강화 및 사업기획에 활용가능한 기초자료 제공
NIGT (2018) (前GTC)	기후기술 수준조사 및 중점 육성분야 발굴 연구(3년 주기)	논문, 특허, 언론자료를 수집하여 토픽모델링을 수행하고, 10대 메가트렌드 기술분야 도출

2.3.2 관련 선행 연구 검토

가. KeyBERT와 BERTopic을 활용한 텍스트마이닝 연구동향 분석

(1) 연구 내용

텍스트마이닝 기법으로 널리 사용되는 KeyBERT와 BERTopic의 성능을 비교하였으며, 한국어 데이터를 이용하여 두 모델의 토픽 모델링 및 키워드 추출 능력을 평가하고, 이를 바탕으로 연구 동향 분석에의 적용 가능성 비교 연구를 수행하였다.

(2) 주요 결과

클러스터링 기반 분석에 있어 토픽 간 응집도와 일관성이 우수한 BERTopic과, 핵심 키워드를 간결하게 도출하며 문맥적 의미를 반영하여 핵심 키워드를 간결하게 도출할 수 있는 알고리즘인 KeyBERT 모두 최신 텍스트마이닝 기법으로서의 유용성이 LDA보다 우수하다는 것을 입증하였다.

(3) 시사점

텍스트마이닝 기법은 한국어뿐만 아니라, 다국어 데이터에서 연구 동향 분석 및 기술 트렌드 도출에 활용이 가능하며, 데이터 크기와 언어적 특징에 따라 최적의 기법을 선택하여 성과를 극대화 할 수 있다.

나. BERTopic을 활용한 텍스트마이닝 기반 인공지능 반도체 기술 및 연구동향 분석

(1) 연구 내용

AI 반도체 분야의 특허 및 논문 데이터를 활용해 기술 트렌드와 연구동향을 분석하였고, BERTopic을 활용하여 주요 기술 토픽을 도출하고, 각 기술의 발전 경향을 시각적으로 분석하였다.

(2) 주요 결과

CNN 가속 기술, 뉴럴 네트워크 최적화, 자율주행 시스템을 위한 AI 반도체 기술이 주요 토픽임을 확인하였고, 이로 인해 저전력 고효율 반도체 기술의 중요성이 부각되며 관련 특허의 출원이 증가로 인해 기술 융합의 가능성의 증가와 함께 연구개발의 방향성이 명확해졌다.

(3) 시사점

AI 반도체 기술뿐만 아니라 다양한 첨단 기술 분야에서 연구 트렌드 분석 도구로 BERTopic의 활용 가능성을 확인하였고, 효율적이고 직관적인 시각화를 통해 연구자와 실무자 모두에게 유용한 결과를 제공하였다.

다. Hierarchical Dirichlet Process(HDL)

(1) 연구 내용

LDA의 고정된 토픽 수 설정 문제를 극복하기 위해 데이터 크기와 특성에 따라 토픽 수를 자동으로 조정하며 그룹 간 공통 구조를 반영하는 알고리즘인 HDP를 활용한 비모수 베이지안 토픽 모델링을 제안하였다.

(2) 주요 결과

HDP는 LDA 대비 토픽 중복을 줄이는 효과를 보였으며, 대규모 데이터에서도 유연하고 강력한 모델링이 가능함을 입증하였고, 이를 통해 그룹 간 공통성을 효과적으로 반영하여 다양한 데이터 세트에서 성능이 향상되었다.

(3) 시사점

고정된 하이퍼파라미터 설정의 제약을 극복하며, 데이터 기반 토픽 모델링의 새로운 가능성을 제시하는 HDP는 비모수적 접근으로 다양한 데이터 그룹에서 적용적으로 활용

이 가능함을 시사한다.

라. Stochastic Variational Inference(SVI)

(1) 연구 내용

SVI는 대규모 데이터에서 효율적인 변분 추론을 수행하기 위해 도입된 기법으로, 기존의 MCMC(마코프 체인 몬테카를로) 기반 방법과 성능을 비교하며 연구가 진행되었다.

(2) 주요 결과

SVI는 미니배치 샘플링을 통해 연산 효율성을 극대화하면서 대규모 문서 데이터에서도 빠른 처리 속도를 달성하였다. 기존 MCMC 접근법과 유사한 정확도를 유지하면서 계산 비용을 대폭 절감하였고 데이터 크기에 비례하지 않는 확장성을 보여주었다.

(3) 시사점

SVI는 대규모 데이터 처리와 복잡한 베이지안 모델링에서 실용적인 도구로 사용될 수 있으며 특히 고성능 데이터 분석과 실시간 처리를 요구하는 환경에서 유리하다.

마. Rethinking LDA : Why Priors Matter

(1) 연구 내용

LDA 모델에서 대칭 및 비대칭 Dirichlet Prior가 모델 성능과 토픽 품질에 미치는 영향을 분석하였으며, Priors 설정이 결과 해석에 미치는 영향을 평가하였다.

(2) 주요 결과

비대칭 Prior는 현실 데이터를 더 잘 반영하며, 토픽 간 중복을 줄이고 응집력을 높이는 데 기여한다. 또한, 하이퍼파라미터 최적화를 통해 사용자 설정의 민감도를 완화하였고 데이터 특성과 분석 목적에 따라 Priors를 최적화하는 것이 중요하다.

(3) 시사점

LDA 모델에서 Priors 설정은 결과의 신뢰도와 해석 가능성에 중요한 영향을 미치며, 정교한 Priors 최적화를 통해 모델 성능을 극대화할 수 있다.

바. 빅데이터 활용 특허분석을 기반으로 한 스마트 팜 유망기술 발굴 및 기술 로드맵 개발

(1) 연구 내용

스마트 팜 분야에서 특허 데이터를 활용하여 유망 기술과 공백 기술을 식별하고, 이를 바탕으로 기술 로드맵을 제안하였다.

(2) 주요 결과

유망 기술로는 농작물 원격 재배, 데이터 취합 자동화, 환경 모니터링 기술이 도출되었으며, 공백 기술로는 고효율 에너지 관리 기술과 다목적 센서 활용 기술이 확인되었다. 기술 발전 단계별 전략과 우선순위를 제안하여 유망 기술 발굴을 지원하였다.

(3) 시사점

스마트 팜 기술의 정량적 데이터 분석을 통해 기술 로드맵을 설계하는 접근법이 농업 기술 개발에서 중요한 역할을 하며, 이와 같은 데이터 기반 접근법은 다른 산업 분야에서도 활용 가능성을 보인다.

사. BERTopic: Neural topic modeling with a class-based TF-IDF procedure

(1) 연구 내용

BERT 기반 임베딩과 클러스터링을 결합한 BERTopic 기법을 활용하여 텍스트 데이터를 분석하고, 기존 LDA 및 HDP 기법과의 성능을 비교하였다.

(2) 주요 결과

BERTopic은 class-based TF-IDF 기법과 결합하여 높은 토픽 일관성과 다양성을 달성하였다. 다국어 데이터 분석에서도 안정적인 성능을 보이며 언어적 제약 없이 효과적인 모델링이 가능하였고, 클러스터링과 토픽 분석의 통합으로 직관적 결과를 제공하였다.

(3) 시사점

BERTopic은 기존 토픽 모델링 기법의 한계를 극복하며, 다양한 텍스트 데이터 분석 응용에서 강력한 도구로 활용 가능하다. 특히 언어적 제약을 넘어 다국어 환경에서도 안정적으로 작동한다.

아. 5개국 바이오헬스 산업의 기술융합과 트렌드 분석

(1) 연구 내용

미국, 유럽, 일본, 중국, 한국 등 5개국의 바이오헬스 산업 특허 데이터를 분석하여 주요 기술과 융합 트렌드를 파악하고, 국가별 강점과 시장 동향을 비교하였다.

(2) 주요 결과

주요 기술군으로는 치료용 의료기기, 의료데이터 프로세싱, 생체계측용 의료기기가 도출되었다. 특히 생체 신호 측정 기술과 데이터 프로세싱 기술 간의 융합이 두드러졌으며, AI를 활용한 진단 및 치료 기기의 특허 출원이 급증하였다. 미국은 시장과 기술을 선도하고, 한국은 데이터 프로세싱 분야에서 강점을 보였다.

(3) 시사점

바이오헬스 산업은 기술 융합이 핵심 동력으로 작용하며, 데이터 기반 의료 기술의 중요성이 강조된다. 각 국가의 기술 강점을 기반으로 협력과 전략적 연구개발 투자를 강화할 필요가 있다.

제 3 장 기술정보 분석

3.1 국내외 기술정보 문헌 수집

3.1.1 특허자료 수집 방법론

가. 특허자료 수집 대상(Wintelips) 개요

Wintelips는 (주)윕스가 제공하는 특허 전문가를 위한 프리미엄 특허 검색 및 분석 서비스이다. 이 플랫폼은 심판소송, 의약특허, IP 전략 수립 등 다양한 특허 업무에 최적화된 기능을 제공하여, 특허 전문가들이 효율적으로 업무를 수행할 수 있도록 지원한다.



그림 5 Wintelips 특허자료 조회 예시

Wintelips는 고성능 검색엔진을 탑재하여 대량의 특허 데이터를 신속하게 검색하고, 무제한 필터링 및 필터 차트를 통해 원하는 정보를 정확하게 추출할 수 있다. 또한 AI 기술이 적용된 스마트한 검색 기능을 통해 입력한 문장으로 유사 문헌을 추출하는 AI 검색, 도면의 설정이나 부호로 선행 문헌을 제공하는 도면 검색 등 다양한 기능을 제공한다.

Wintelips는 이러한 기능들을 통해 연구개발(R&D) 전략 수립, 기술 경쟁력 평가, 선행 기술 조사 등 다양한 특허 분석 업무에 효율성을 제공하며, 사용자들이 기술 정보를 신뢰성 있게 활용할 수 있도록 지원한다.

나. 특허 수집 및 활용

본 연구에서는 국내외 기술정보 문헌 수집을 위해 Wintelips를 활용하여 CPC 코드 중, Y02A-0020에 해당하는 특허를 수집하였다. CPC(Classification of Patents by Cooperative Patent Classification)는 국제 특허 분류의 세부화된 체계로, 특허 기술을 상세히 분류하여 검색 및 분석을 용이하게 한다.

Y02A-0020은 기후변화 완화 기술 중 물 관련 기술 분야를 포함하며, 이 특허 코드를 통해 해당 기술에 특화된 특허 문헌을 확보하였다.

수집한 특허 문헌은 총 20,091건으로, 대표청구항을 중심으로 데이터를 분석하였다. 대표청구항은 특허의 핵심 기술 내용을 가장 압축적으로 나타내는 부분으로, 이를 통해 특허가 보유한

기술적 차별성과 주요 연구 방향을 파악할 수 있다. 이러한 분석을 기반으로 해당 기술 분야의 연구개발 동향, 상업적 활용 가능성, 기술적 한계점 등을 도출할 수 있다.

Wintelips의 활용은 방대한 특허 문헌 중에서도 특정 기술과 직접적으로 연관된 정보를 빠르고 정확하게 수집하는 데 기여하였으며, 대표청구항 데이터를 중심으로 의미 있는 기술정보 분석 결과를 도출할 수 있었다.



그림 6 CPC코드 Y02A-0020 특허

3.1.2 논문자료 수집 방법론

가. 수집 대상(MDPI)의 개요

MDPI(Multidisciplinary Digital Publishing Institute)는 1996년에 설립되어 스위스에 본사를 둔 오픈 액세스 출판사로 다양한 학문 분야에서 학술 저널을 발간하고 있다. MDPI는 과학, 기술, 공학, 의학 및 사회 과학 등 다양한 주제를 다루며 연구자와 학계 간의 지식 공유를 촉진하는 데 중점을 둔다. MDPI의 주요 특징은 다음과 같다.

- 오픈 액세스(Open Access): 모든 논문은 출판 후 무료로 열람할 수 있으며 이는 학문적 지식의 개방성과 접근성을 보장함
- 동료 검토(Peer Review): 모든 제출된 논문은 철저한 동료 검토 과정을 거쳐 학문적 기준을 유지함
- 빠른 출판 과정: 제출부터 출판까지의 시간이 비교적 짧아 연구자들이 최신 연구 결과를 빠르게 발표할 수 있음
- 다양한 저널 포트폴리오: 400개 이상의 학술 저널을 운영하며 대표적으로 Sensors, Molecules, Sustainability 등이 있음
- 국제적 범위: 전 세계 연구자와의 협력을 통해 국제적인 연구 커뮤니티를 구축하고 있으며 다양한 언어와 문화권의 연구자들을 지원함

MDPI는 연구 윤리를 준수하며 학문적 투명성과 신뢰성을 중요시한다. 특히 연구 데이터 공유와 재현 가능성을 강조하며 학술적 논문의 질과 영향력을 높이는 데 기여한다. 이러한 특성으로 인해 MDPI는 해당 연구과제 수행을 위한 논문 데이터베이스 구축에 적합한 플랫폼으로 선정되었다.

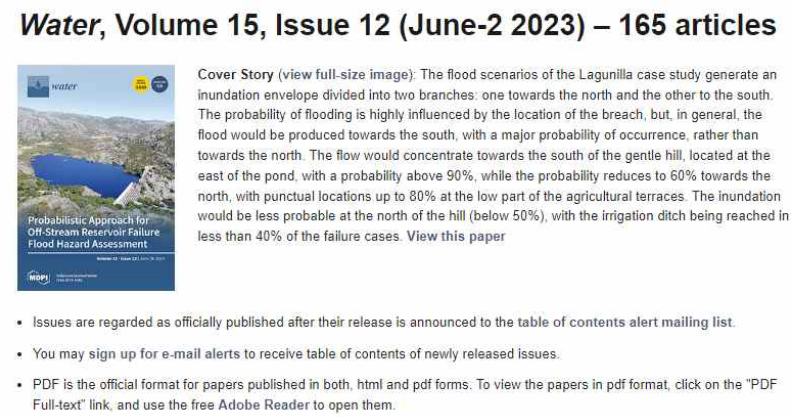


그림 7 논문 수집 대상 저널 예시(MDPI)

나. 수집 방법

(1) 외부데이터 수집 방법(Web Crawling)

웹 크롤링(Web Crawling)은 특정 웹사이트에서 원하는 정보를 자동화된 방식으로 추출하는 기술이다. 이를 통해 다양한 페이지에서 효율적이고 빠르게 정보를 탐색하고 수집할 수 있다. 웹 크롤링의 종류에는 정적 크롤링과 동적 크롤링이 있으며, 그 특징은 아래와 같다.

① 정적 크롤링: 변하지 않는 정적인 데이터를 수집하는 방법으로, 웹 페이지의 제목, 저자, 본문 등의 정보를 수집하는 경우에 사용된다. 파이썬의 BeautifulSoup 라이브러리를 사용하여 간편하고 빠르게 데이터를 수집할 수 있다는 장점이 있다. 그러나 크롤링 검사기에 의해 차단될 가능성이 있어 대규모 데이터 수집에는 한계가 있을 수 있다.

② 동적 크롤링: 실시간으로 변하는 데이터를 수집하는 방식으로, 좋아요 수나 댓글과 같이 실시간으로 변동되는 데이터 수집에 적합하다. 동적 크롤링에는 파이썬 Selenium 라이브러리와 크롬 드라이버가 사용된다. Selenium은 실제 브라우저 창을 열어 사용자가 웹페이지를 탐색하는 것과 동일한 방식으로 데이터를 수집하기 때문에 크롤링 검사기를 피할 수 있는 장점이 있다. 그러나 매번 웹 페이지를 로드해야 하므로 속도가 느리다는 단점이 있다.

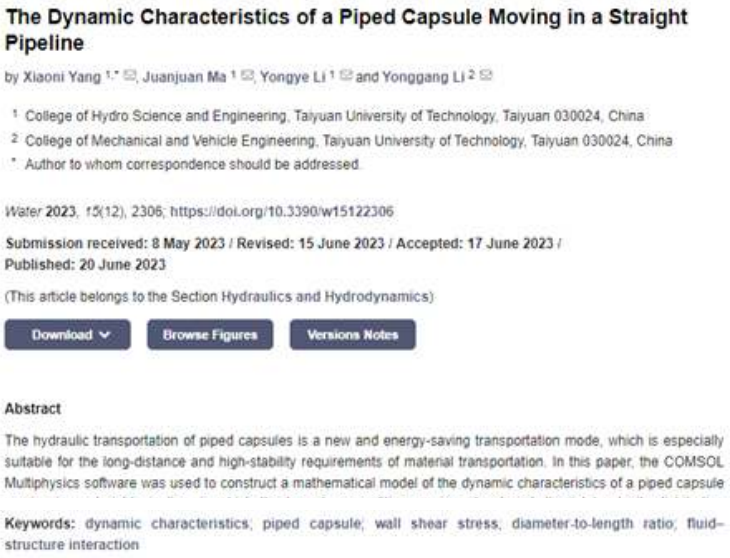
웹 크롤링 기술은 데이터 수집의 효율성을 크게 높일 수 있지만 수집하려는 데이터의 형식과 목적에 따라 적절한 방식을 선택하는 것이 중요하다.

표 4 정적 크롤링 vs 동적 크롤링

	정적 크롤링	동적 크롤링
연속성	주소를 통해 단발적으로 접근	브라우저를 통해 연속적으로 접근
수집 능력	수집 데이터의 한계가 존재 (ex. 좋아요 개수 수집 불가)	한계 없음
속도	빠름	느림
라이브러리	requests, BeautifulSoup	Selenium, Chromedriver
크롤링 검사기	걸림	해결 가능성 존재

(2) 크롤링 대상 및 방식

본 연구에서는 MDPI의 "Water, Volume 15, Issue 12 (June 2023)"에 게재된 165개의 논문 정보를 수집하기 위해 웹 크롤링을 활용하였다. 수집대상은 각 논문의 제목, 저자, DOI, 초록, 키워드 이며, 크롤링 방식으로는 동적 클롤링과 정적 크롤링을 혼합하여 사용하였다.



The Dynamic Characteristics of a Piped Capsule Moving in a Straight Pipeline

by Xiaoni Yang [1,*], Juanjuan Ma [1], Yongye Li [1] and Yonggang Li [2]

[1] College of Hydro Science and Engineering, Taiyuan University of Technology, Taiyuan 030024, China
[2] College of Mechanical and Vehicle Engineering, Taiyuan University of Technology, Taiyuan 030024, China
* Author to whom correspondence should be addressed.

Water 2023, *15*(12), 2306; https://doi.org/10.3390/w15122306

Submission received: 8 May 2023 / Revised: 15 June 2023 / Accepted: 17 June 2023 / Published: 20 June 2023

(This article belongs to the Section Hydraulics and Hydrodynamics)

Download Browse Figures Versions Notes

Abstract

The hydraulic transportation of piped capsules is a new and energy-saving transportation mode, which is especially suitable for the long-distance and high-stability requirements of material transportation. In this paper, the COMSOL Multiphysics software was used to construct a mathematical model of the dynamic characteristics of a piped capsule

Keywords: dynamic characteristics; piped capsule; wall shear stress; diameter-to-length ratio; fluid–structure interaction

그림 8 수집한 논문 예시

정적 크롤링(BeautifulSoup)만 사용하였을 경우 로봇검사기로 인해 원활한 정보수집이 불가능하였으며, 동적 크롤링(Selenium) 방식만 사용하였을 경우 165개 데이터를 수집하는데 약 1시간 이상의 시간이 소요되는 문제가 발생하였다.

이를 해결하기 위해 정작과 동적 방식을 혼합한 방안을 도입하였다. 우선 Selenium으로 MDPI 웹 페이지에 접근한 후 BeautifulSooup을 통해 해당 페이지의 데이터를 수집하였으며, 이를 통해 전체 시간을 약 1/3(37분 소요)로 단축하였다. 이를 통해 정적 및 동적 크롤링 방식을 적절히 병행함으로써 데이터 수집의 효율을 극대화할 수 있음을 보여준다.

```python
def find_mdpi_ele(url, titles, authors_collect, dois, abstracts, keywords_collect):

    driver.get(url)

    #explicitly wait
    wait = WebDriverWait(driver, 8)
    element = wait.until(EC.presence_of_element_located((By.XPATH, '//*[@id="abstract"]/div[2]/article/div/h1')))


    #bs4
    html = driver.page_source
    soup = BeautifulSoup(html, 'html.parser')


    #titles
    tit = soup.find('h1').get_text()
    titles.append(tit)
```

그림 9 (Python코드) 논문 정보 크롤링 함수 정의

크롤링 시 나타나는 크롤링 로봇 검사기를 처리하기 위하여 HTML의 iframe을 처리하는 방식으로 진행하였으며 코드는 아래 이미지와 같다.

```python
if EC.presence_of_element_located((By.XPATH, '//*[@id="main-content"]/h1')):

    #iframe으로 이동
    WebDriverWait(driver, 3).until(EC.frame_to_be_available_and_switch_to_it((By.CSS_SELECTOR,"iframe[src^='https://challenges.cloud

    #체크박스가 있으면 클릭, 없으면 pass
    try:
        WebDriverWait(driver, 8).until(EC.element_to_be_clickable((By.XPATH, '//*[@id="challenge-stage"]/div/label'))).click()
    except:
        pass
```

그림 10 (Python코드) iframe 처리 함수 정의

산출물(논문 제목, 저자, DOI, 초록, 키워드)은 아래 이미지와 같이 csv 파일로 정리된다.

	titles	authors_collect	dois	abstract
1	The Dynamic Characteristics of a Piped Capsule Movi...	['Xiaoni Yang', 'Juanjuan Ma', 'Yongye Li', 'Yonggang Li']	https://doi.org/10.3390/w15122306	The hydraulic transportation of piped capsul...
2	Performance Assessment of Household Water Treatm...	['Shekhar Khanal', 'Shinobu Kazama', 'Sawangjang Benyapa',...	https://doi.org/10.3390/w15122305	Although many households in the Kathmand...
3	Hydrochemical Response of Karst Groundwater to Ra...	['Rui Wang', 'Xiaohan Li', 'Fenggang Dai', 'Zhichao Cai', 'We...	https://doi.org/10.3390/w15122304	Karst groundwater is the main water source f...

그림 11 수집 완료된 논문 정보 예시

3.1.3 K-water 연구보고서 수집(STP)

가. 수집대상(STP) 개요

STP(Smart Tech-Pedia)는 K-water에서 수행하는 기술기획 및 기술개발과 관련된 다양한 업무를 지원하는 기술통합관리시스템이며, K-water가 보유하고 있는 우수한 기술들에 대한 세부적인 분류체계 및 기술 수준을 평가할 수 있는 기준을 제공한다. 또한, 새로이 발명하고 있는 신기술에 대한 저작권 신청 등, K-water의 지식재산권을 관리할 수 있도록 다양한 업무를 지원하고 있으며 수행하는 과제와 관련한 자문, 평가, 성과 업무를 지원하는 다양한 시스템을 제공한다.

나. 연구과제 수집 및 활용

본 연구에서는 STP(Smart Tech-Pedia)를 활용하여 K-water가 수행한 연구과제 데이터를 체계적으로 수집하였다. STP는 K-water의 기술기획 및 기술개발과 관련된 다양한 업무를 지원하

는 통합관리시스템으로, 과제 관리와 기술 수준 평가를 위한 종합적인 데이터베이스를 제공한다. 이러한 시스템은 K-water의 연구과제가 보유한 기술적 성과를 객관적으로 평가하고, 해당 데이터를 기반으로 기술 트렌드를 분석하는 데 중요한 역할을 한다.

연구과제 데이터는 CPC 코드 Y02-0020 특허와의 기술적 연관성을 중심으로 선별적으로 수집되었다. Y02A-0020은 기후변화 완화 기술 중 물 관련 기술 분야를 포함하고 있으며, 이는 K-water가 집중적으로 수행해 온 연구과제와 직접적으로 연계되는 영역이다. 이와 같은 연계성은 수집된 연구과제 데이터가 기후변화 대응을 위한 기술적 방향성을 평가하고 분석하는 데 적합한 자료임을 보여준다.

수집된 연구과제 데이터는 총 1,398건으로, 초록을 중심으로 분석되었는데, 연구과제 초록은 과제의 핵심 내용을 간결하게 요약하고 있어 연구 목적, 방법론, 주요 결과를 신속히 파악할 수 있는 중요한 자료이다.

STP를 활용한 연구과제 데이터의 수집과 분석은 K-water의 기술적 강점과 해당 기술 분야에서의 기여도를 명확히 보여주는 중요한 자료로 활용되었다. 이러한 데이터는 Y02A-0020 특허 데이터를 기반으로 한 분석 결과와 결합하여 더욱 심층적인 기술정보 분석 및 연구개발 전략 수립에 중요한 인사이트를 제공하였다.



그림 12 K-water 연구과제 초록

3.2 데이터 전처리 방법론과 적용

3.2.1 전처리 필요성과 일반 이론

가. 전처리 필요성

데이터 전처리는 원시 데이터를 분석 및 모델링에 적합한 형태로 변환하기 위한 핵심적인 과정으로, 데이터의 품질을 제고하고 분석 결과의 신뢰성을 확보하기 위해 반드시 수행되어야 한다.

일반적으로 원시 데이터는 결측치, 중복 데이터, 비정상적인 값 등 여러 문제를 내포하고 있어, 이러한 문제를 그대로 둔 채로 분석을 진행할 경우 모델의 성능 저하와 분석 결과의 왜곡을 초래할 수 있다. 따라서 데이터를 정제하여 품질을 향상하게 시키고, 분석 및 모델링의 효율성과 신뢰성을 극대화하는 것이 전처리의 주된 목적이다.

전처리는 데이터 품질 확보와 분석 효율성 향상, 그리고 결과의 신뢰성 확보라는 측면에서 그 중요성이 강조된다. 예를 들어, 데이터셋 내 오류나 결측치를 보완함으로써 데이터의 정확성을 강화할 수 있으며, 노이즈를 제거하면 분석의 속도와 정확도를 동시에 높일 수 있다. 이와 함께 일관성 있는 정제 데이터를 기반으로 한 분석은 결과의 재현 가능성을 확보할 수 있도록 한다. 특히, 기술정보 데이터는 전문 용어와 복잡한 구문 구조를 포함하는 대규모 비정형 데이터가 주를 이루기 때문에, 전처리 과정이 더욱 중요하다.

나. 일반적인 전처리 방법론

데이터는 크게 데이터 정제(Data Cleaning), 데이터 변환(Data Transformation), 데이터 축소(Data Reduction), 데이터 구조화(Data Structuring)라는 네 가지 주요 단계로 구분된다.
각 단계는 데이터의 결함을 수정하고 분석 가능성을 제고함으로써, 분석 및 모델링 작업의 기반을 제공한다.

(1) 데이터 정제(Data Cleaning)

데이터 정제는 원시 데이터의 결함을 보완하고 노이즈를 제거하여 데이터의 신뢰성을 높이는 과정이다. 구체적으로, 결측치 처리에서는 누락된 데이터를 삭제하거나 평균, 중위값, 또는 예측모델을 이용해 보완한다. 중복 데이터는 데이터셋의 일관성을 유지하기 위해 탐지 및 제거하며 비정상적인 값은 정의된 기준에 따라 수정된다. 이와 함께 분석에 불필요한 특수문자, 공백, 주석 등을 제거함으로써 데이터의 간결성을 확보한다.

표 5 데이터 정제 주요 기법 요약

기법	목적	설명
결측치 처리	데이터 완전성 확보	평균, 최빈값 대체, 삭제 등
이상치 제거	분석 정확성 향상	Z-Score, 도메인 지식 활용
중복 제거	데이터 중복 방지	동일 데이터 중복 여부 검사 후 삭제

(2) 데이터 변환(Data Transformation)

데이터 변환은 데이터를 분석 및 모델링에 적합한 형태로 변형하는 과정으로, 스케일링(Scaling)과 범주형 데이터의 인코딩이 주로 수행된다. 스케일링은 Min-Max 정규화나 Z-Score 정규화를 통해 변수의 범위를 조정하여 알고리즘의 민감도를 낮춘다. 범주형

데이터는 원-핫 인코딩(One-Hot Encoding)이나 레이블 인코딩(Label Encoding)을 통해 수치형 데이터로 변환된다. 이외에도 피처 엔지니어링(Feature Engineering)을 통해 새로운 변수(피처)를 생성하거나 기존 변수를 결합하여 분석의 설명력을 향상한다.

표 6 데이터 변환 기법 비교

기법	목적	설명
Min-Max Scaling	데이터 범위를 [0,1]로 조정	최솟값과 최댓값을 사용해 정규화
Z-score Normalization	데이터 분포의 표준화 (평균=0, 표준편차=1)	각 값에서 평균을 빼고 표준편차로 나눔
One-Hot Encoding	범주형 데이터를 수치형으로 변환	각 범주를 고유한 이진 벡터로 변환

(3) 데이터 축소(Data Reduction)

데이터 축소는 데이터의 복잡성을 감소시키면서도 핵심 정보를 유지하는 과정을 포함한다. 차원 축소는 PCA(Principal Component Analysis)와 같은 기법을 통해 변수의 수를 줄여 데이터를 단순화하며, 샘플링은 데이터셋의 일부를 대표성 있게 추출하여 분석 속도를 개선한다.

표 7 데이터 축소 전후 비교

기법	축소 전 데이터/차원	축소 후 데이터/차원	설명
PCA	10차원	2차원	데이터의 분산을 가장 잘 설명하는 주성분을 추출하여 차원 축소
랜덤 샘플링	100,000건	10,000건	데이터셋에서 임의의 데이터를 추출하여 데이터 크기를 축소
계층적 샘플링	100,000건	10,000건	각 계층(범주)의 비율을 유지하며 데이터 샘플링

(4) 데이터 구조화(Data Structuring)

데이터 구조화는 비정형 데이터를 분석 가능한 구조로 재조정하는 과정이다. 여러 데이터 소스를 통합하여 일관된 데이터셋을 생성하고, 분석에 필요한 열(Column)과 행(Row)을 선택하여 데이터를 정리한다. 이 과정은 복잡한 데이터셋에서 구조적 일관성을 유지하며, 분석 작업을 보다 효율적으로 수행할 수 있도록 한다.

이와 같은 데이터 전처리 과정은 정형 데이터뿐만 아니라 비정형 데이터에서도 적용되며, 분석 결과의 품질과 신뢰성을 높이는 데 핵심적인 역할을 한다. 데이터의 유형과 분석 목적에 따라 전처리 전략을 설계하는 것은 성공적인 데이터 분석 및 모델링의 필수적인 조건이다.

표 8 데이터 구조화 사례

데이터 유형	원본 형식	구조화 후	설명
텍스트 데이터	문장	키워드 테이블	NLP 기반 키워드 추출 후 테이블화
JSON 데이터	계층적 JSON 객체	열(column) 기반 테이블	JSON 필드값을 열로 변환

3.2.2 기술정보 분석을 위한 텍스트 전처리 방법 적용

기술정보 분석에서 텍스트 데이터의 전처리는 자연어처리(Natural Language Processing, NLP) 작업의 필수적인 단계로, 분석 과정의 성공 여부를 결정짓는 중요한 역할을 한다. 특허 문헌의 대표청구항이나 연구과제 초록과 같은 데이터는 구조적 특성과 함께 기술적 용어, 긴 문장, 보잡한 문법 등을 포함하고 있어, 이를 효과적으로 분석하기 위해 체계적인 전처리 과정이 요구된다. 전처리는 텍스트 데이터에서 불필요한 요소를 제거하고, 분석 목적에 적합한 형태로 데이터를 변환하여 품질 높은 정보를 도출하는 데 기여한다.

특허와 연구과제 문헌은 전문성이 강한 용어와 문장이 다수를 차지하므로, 자연어처리 알고리즘이 효과적으로 작동하기 위해 전처리 단계에서 데이터의 정제와 변환이 필수적이다. 전처리를 통해 텍스트 데이터의 노이즈를 제거하고, 분석 대상의 본질적인 의미를 유지하면서도 단순화함으로써 분석의 신뢰성과 정확성을 높일 수 있다. 특히, 전처리 과정을 거친 데이터는 알고리즘이 더 정확하고 일관성 있는 결과를 도출한다.

본 연구에서는 특허 문헌의 대표청구항과 연구과제 초록 데이터를 기반으로 아래와 같은 전처리 과정을 수행하였다.

가. 중복 단어 제거

특허 문헌 및 연구과제 초록 데이터는 특정 단어가 반복적으로 등장하는 특성을 가지며, 이는 기술문서의 구조적 특성과 밀접하게 연관된다. 동일한 용어가 반복 사용되면 데이터의 복잡성을 증가시키고 분석 과정에서 불필요한 자원 소모를 초래할 수 있다. 본 연구에서는 이러한 중복 단어를 제거함으로써 데이터의 간결성과 분석 효율성을 강화하였다. 이를 통해 자연어처리 과정에서 발생할 수 있는 불필요한 자원 소모를 줄이고, 핵심 정보에 보다 집중할 수 있는 데이터 환경을 구축하였다.

나. 토큰화 수행

텍스트 데이터를 정제하고 일관성을 유지하기 위해 정규표현식을 사용하여 소문자와 대문자 사이에 공백을 삽입하여 단어를 구분한 뒤 텍스트를 단어 단위로 분리하는 토큰화 과정을 수행하였다. 이후 모든 텍스트를 소문자로 변환하여 대소문자로 인해 발생할 수 있는 불필요한

데이터 다양성을 제거하였다. 구두점과 같은 문장 부호는 텍스트의 분석 목적상 중요하지 않은 정보로 간주하여 제거하였으며, 길이가 3자 미만인 단어를 제거하여 데이터에서 불필요한 노이즈를 감소시켰다. 이러한 일련의 과정을 통해 데이터는 더욱 간결하고 분석 가능한 형태로 정제되었으며, 자연어처리 알고리즘의 성능을 최적화하는 기반을 마련하였다.

다. 숫자 제거

특허 문헌과 연구과제 초록 데이터에서 숫자는 종종 발견되지만, 대부분 본 연구의 분석 목표와 직접적인 연관성을 가지지 않는다. 이러한 숫자는 텍스트 데이터의 복잡성을 증가시키고, 분석 과정에서 불필요한 노이즈로 작용할 가능성이 크다. 따라서 데이터 정제 단계에서 모든 숫자를 제거하는 과정을 통해 분석 모델이 비본질적인 정보에 자원을 낭비하지 않도록 처리하였다. 이 작업은 텍스트 데이터의 간결성을 확보하고, 알고리즘이 실제로 중요한 텍스트 패턴에 집중할 수 있는 환경을 조성하였다.

라. 표제어 추출(Lemmatization)

텍스트 데이터의 일관성을 유지하고 분석의 정확도를 높이기 위해 표제어 추출(Lemmatization)을 수행하였다. 이 과정은 “running”, “ran”, “runs”와 같은 다양한 형태의 단어를 기본형인 “run”으로 변환하여 단어의 변형으로 인해 발생할 수 있는 데이터의 중복성을 줄이는 데 기여한다. 특히, 특허 문헌과 연구과제 초록 데이터에서 기술 용어와 학술적 표현이 빈번히 등장하는 점을 고려할 때 표제어 추출은 데이터의 일관성을 유지하며 분석의 신뢰도를 높이는 중요한 과정으로 작용하였다.

마. 불용어 제거

“and”, “the”, “of”와 같이 의미적으로 중요하지 않은 불용어(Stop Words)는 텍스트 분석 과정에서 노이즈로 작용하는 경우가 많다. 이러한 불용어를 제거함으로써 데이터의 본질적인 정보를 더욱 강조하였으며 모델이 더 의미 있는 패턴에 집중할 수 있는 환경을 마련하였다.

바. N-단위 단어 묶음(N-gram) 생성

텍스트 데이터의 문맥 정보를 강화하기 위해 Bi-gram과 Tri-gram을 생성하였다. 이 과정은 단일 단어 분석에서 발생할 수 있는 문맥적 한계를 보완하고, 단어 간 연관성과 구문적 패턴을 보다 명확히 분석할 수 있는 기반을 제공한다. 예를 들어, “climate change adaptation”이라는 문장에서 “climate change”와 “change adaptation”이라는 Bi-gram을 생성하여 단어 간 의미적 관계를 정교하게 반영하였다. 생성된 N-gram은 기존의 토큰 리스트에 추가되었으며 데이터의 정보 밀도를 높이고 의미적 구조를 강화하는 데 활용되었다.

본 연구에서 수행된 텍스트 전처리 과정은 특허 문헌의 대표청구항과 연구과제 초록 데이터를 고도로 정제된 형태로 변환하는 데 중점을 두었다. 이를 통해 자연어처리 알고리즘의 성능을 최적화하고, 분석의 신뢰도와 효율성을 제고하였다. 전처리 작업의 결과를 활용하여 기술정보 분석의 심층적 이해와 데이터 기반 연구의 전략적 활용 가능성을 높일 수 있다.

```
def preprocess(text):
    """ Applies all preprocessing steps to the input text. """
    tokens = reduce_repetitive_words(text)
    tokens = initial_tokenize(tokens)
    tokens = remove_numbers(tokens)
    tokens = lemmatize(tokens)
    tokens = remove_stopwords(tokens)
    tokens = create_ngrams(tokens)
    return tokens
```

그림 13 기술정보 텍스트 전처리 적용 함수

3.3 기술정보 자연어처리 방법론 및 적용

3.3.1 기술 트렌드 분석 방법론 (LDA)

LDA(Latent Dirichlet Allocation)은 문서 집합에서 잠재적인 주제를 도출하고, 문서 내에 포함된 주제의 혼합 비율을 파악하기 위한 확률적 토픽 모델링 알고리즘이다. LDA는 문서와 단어의 분포를 기반으로 주제를 식별하며, 각 주제를 구성하는 단어 간의 관계를 통계적으로 학습한다.

본 연구에서는 Y02A-0020 특허 문헌 20,091건과 K-water 연구과제 초록 1,398건을 분석 대상으로 설정하였다. 데이터는 IP5 국가별로 구분하였으며, 각 국가별로 8개의 토픽을 도출하였다. LDA 모델의 하이퍼파라미터는 Coherence 점수와 Perplexity 지표를 활용하여 최적화하였으며, 최종적으로 토픽 수는 8, passes 값은 5, iterations 값은 100으로 설정하였다.

LDA 분석 결과는 pyLDAvis 라이브러리를 활용하여 시각화하였는데, 이 시각화 도구는 각 토픽의 상대적 크기와 분포 그리고 토픽 간의 연관성을 직관적으로 표현할 수 있는 기능을 제공한다. 이를 통해 각 국가의 기술적 초점과 토픽 간 유사성을 파악할 수 있으며, 기술 발전의 전반적 경향성을 도출하는 데 유용한 기초 자료를 제공하였다.

$$p(\phi_{1:K}, \theta_{1:D}, z_{1:D}, w_{1:D}) =$$
$$\prod_{i=1}^{K} p(\phi_i|\beta) \prod_{d=1}^{D} p(\theta_d|\alpha) \left(\prod_{n=1}^{N} p(z_{d,n}|\theta_d) p(w_{d,n}|\phi_{1:K}, z_{d,n}) \right)$$

그림 14 LDA 목적함수

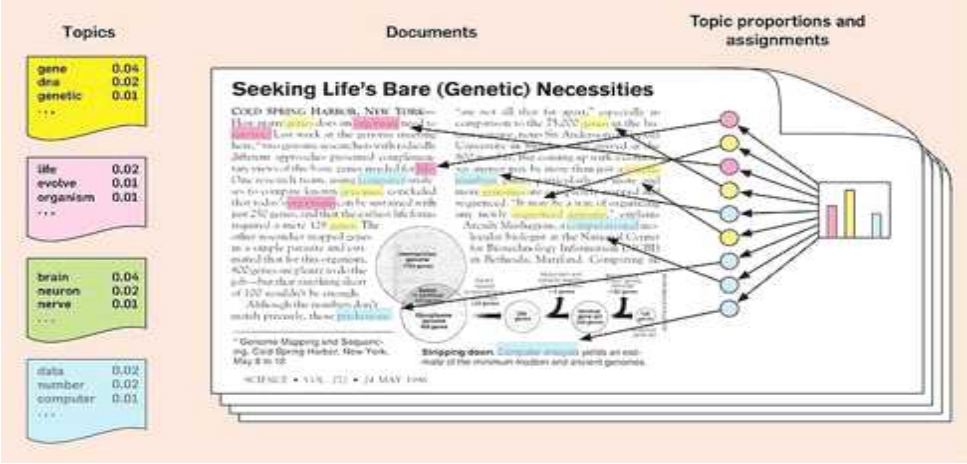


그림 15 Topic Modeling 알고리즘

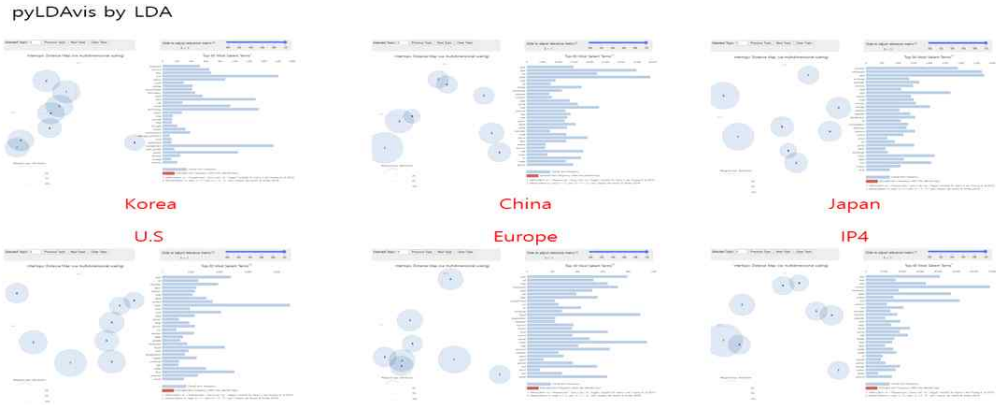


그림 16 LDA 분석 결과 (한국, 중국, 일본, 미국, 유럽 외 4개국)

3.3.2 문맥 기반 핵심 키워드 도출 방법론 (KeyBERT 알고리즘)

KeyBERT(Keyphrase Extraction by BERT)는 BERT(Bidirectional Encoder Representation from Transformers) 언어 모델을 기반으로 한 핵심 키워드 추출 알고리즘이다. BERT는 문장 내 단어와 문장 간의 문맥적 관계를 깊이 학습하는 사전 학습된 언어 모델로 텍스트 데이터의 의미 구조를 정교하게 이해할 수 있는 강점을 가진다.

KeyBERT는 특정 텍스트의 문장 임베딩(Sentence Embedding)을 생성한 후, 각 단어와 텍스트 전체 간의 유사도를 계산하여 문맥적으로 중요한 키워드를 추출한다. 단순히 빈도에 기반하지 않고 문맥적 중요도를 반영함으로써, 텍스트의 본질적인 의미를 대변하는 키워드를 효과적으로 도출할 수 있다.

본 연구에서는 LDA로 도출된 각 토픽에 대해 KeyBERT를 적용하여 상위 10개의 핵심 키워드를 추출하였다. 이 과정은 토픽의 기술적 특성을 정의하고, 후속 라벨링 작업의 기초 자료로 활용되었다.

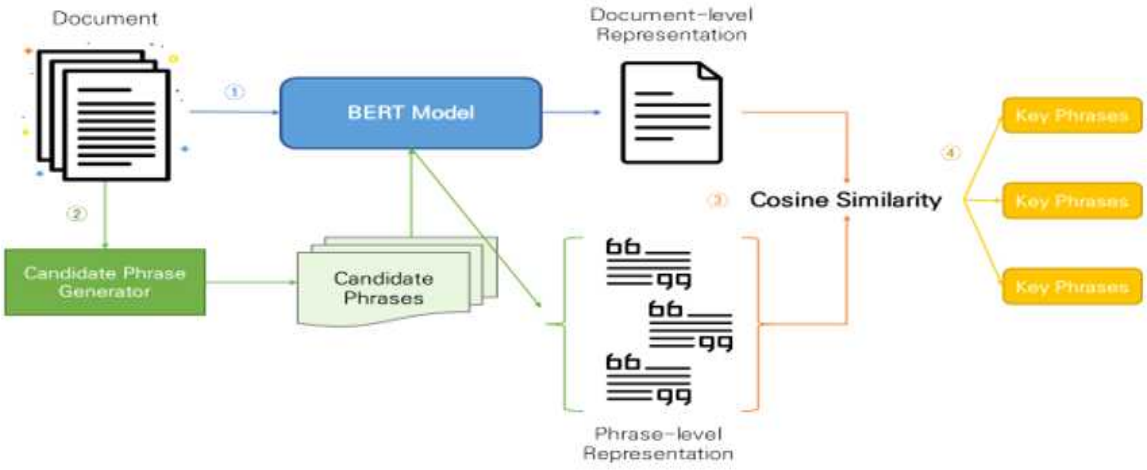


그림 17 KeyBERT 알고리즘

가. 핵심 키워드 도출 및 분석

LDA와 KeyBERT 알고리즘을 통해 도출된 핵심 키워드는 각 토픽이 다루는 기술적 주제를 명확히 규정하며 IP5 국가 간의 기술적 차이와 공통점을 비교하는 데 중요한 기초 자료로 활용되었다. 이 과정에서 도출된 키워드는 각 국의 연구 및 기술 개발 전략을 분석하고, 국가 간 기술 협력 가능성을 탐색하는 데 있어 핵심적인 역할을 수행하였다.

예를 들어, “water desalination”, “membrane technology”, “brine management”와 같은 키워드가 포함된 토픽은 해당 국가가 해수 담수화 기술에 초점을 맞추고 있음을 시사한다. 이처럼 도출된 키워드는 각 국가가 중점적으로 연구하는 기술 영역을 정량적, 정성적으로 분석할 수 있는 근거 자료로 사용되었고 다음과 같은 두 가지 주요 목적으로 활용되었다.

(1) 토픽의 기술적 정체성 확인

도출된 키워드는 각 토픽이 다루는 주요 기술적 내용을 정의하고 주제의 의미를 명확히 전달하는 데 사용되었으며, 이를 통해 각 토픽이 어떤 기술 분야를 대표하는지를 설명하는 중요한 근거 자료로 활용되었다.

(2) 토픽 라벨링 작업의 기준 제공

각 토픽의 키워드는 후속 라벨링 작업의 기초 자료로 활용되었으며 각 토픽에 적합한 라벨링을 정의하기 위한 기준으로 작용하여 토픽의 분류와 해석을 가능하게 하였다.

연구 데이터의 기술적 초점을 이해하는 데 있어 도출된 키워드들은 단순히 보조적 역할로만 활용되지 않고 연구의 주요 결론을 도출하고 분석을 체계적으로 구성하는 데 핵심적인 역할을 하였다.

3.4 기술정보 분석

3.4.1 토픽 라벨링(Topic Labeling)

토픽 라벨링의 목적은 각 토픽이 다루는 기술적 주제를 명확히 정의하고 이를 기반으로 국가 간 기술 집중 영역을 비교할 수 있도록 하는 것이다. 이 작업은 K-water 도메인 전문가와의 여러 번의 미팅과 생성형 AI(ChatGPT) 활용을 통해 이루어졌다.

각 토픽별 도출된 키워드를 기반으로, 22개의 라벨 후보군을 도출하였고, 이후 ChatGPT를 활용하여 각 토픽의 키워드와 라벨 후보 간의 연관성을 평가하여 각 토픽에 가장 적합한 라벨을 맵핑하였다.

예를 들어, “brine management”, “desalination”, “reserve osmosis”와 같은 키워드를 포함하는 토픽은 “해수 담수화 기술”로 라벨링되었다. 이 과정은 단순히 토픽을 분류하는 작업을 넘어 각 토픽의 기술적 정체성을 구조화하고 국가별 연구 방향성을 명확히 하는 데 기여하였다. 라벨링 작업을 통해 각국의 기술 집중 영역이 명확히 드러났으며, 국가 간 기술적 공통점과 차이점을 보다 체계적으로 분석할 수 있는 기반이 마련되었다.

```
# Data Preparation
labels = [
    "Chemical Treatment", "Low Impact Development (LID)", "Physical Treatment",
    "Biological Treatment", "Water Treatment Technology",
    "Water Quantity Measurement", "Dam and River Management",
    "Dam Safety Management","Water Market Analysis",
    "Trace Harmful Substance Treatment", "Water Purification",
    "Surface Water Quality Management", "Groundwater Management",
    "Alternative Water Resources (Membrane)", "Alternative Water Resources (Other)",
    "Rainwater Harvesting", "Rainwater Storage Infrastructure", "Water Use Energy Management",
    "Water Supply Pipeline Management", "Renewable Energy","Aquatic Ecosystem Management",
    "Water Quality General"
]
```

그림 18 토픽 라벨 후보군 (22개)

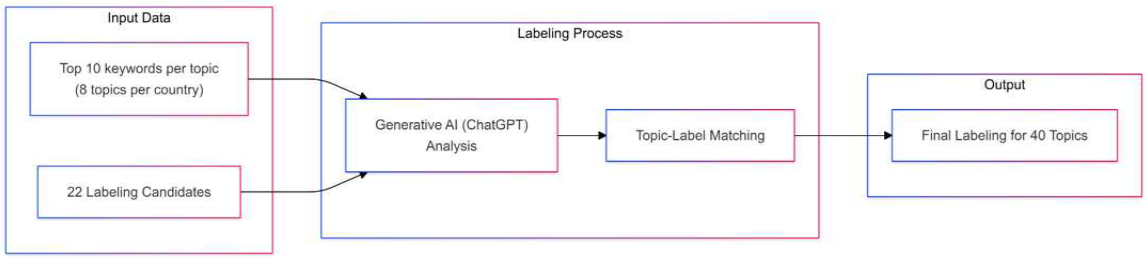


그림 19 토픽 라벨링 과정

3.4.2 네트워크 분석(Network Analysis)

네트워크 분석은 국가별 기술 집중 영역과 토픽 간의 연관성을 시각화하고, 각국의 기술적 강점과 협력 가능성을 도출하는 데 중요한 역할을 한다. 본 연구에서는 Gephi를 활용하여 토픽과 키워드 간의 관계를 네트워크 그래프로 표현하였다. 네트워크는 노드(Node)와 엣지(Edge)로 구성되었으며 노드는 도출된 토픽과 키워드를, 엣지는 이들 간의 연관성을 나타낸다.

가. 네트워크 구성 및 시각화

네트워크 구성은 각 토픽에 포함된 주요 키워드와 국가 간 기술 집중도를 반영한 구조로 설계되었다. 토픽과 키워드 간의 연관성은 키워드 빈도와 토픽 내 중요도를 기반으로 계산되었으며 이를 통해 네트워크 내 노드 간 연결 강도를 수치화하였다.

Gephi를 사용하여 생성된 네트워크 그래프는 각 국가별 기술 집중 영역을 시각적으로 표현하며 국가 간 공통된 연구 관심사와 독자적인 기술 주제를 한눈에 파악할 수 있도록 설계되었다. 시각화 결과는 국가별 기술적 전략을 비교하고, 협력 가능성을 탐색하는 데 유용한 정보를 제공하였다.

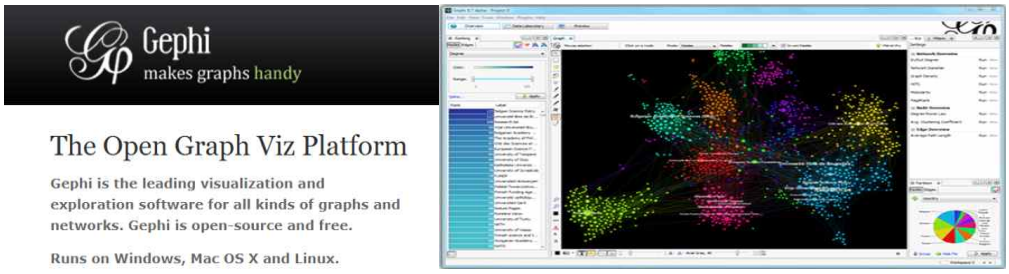


그림 20 Gephi 프로그램 설명

나. 주요 분석 지표

특정 노드가 네트워크 내에서 얼마나 중심적 역할을 하는지 평가하는 중심성 지표인, Closeness Centrality와 Harmonic Centrality 개념을 결합한 Harmonic Closeness Centrality를 활용하여 주요 토픽과 키워드를 식별하였으며 각 노드와 연결된 엣지의 가중치를 측정하여 네트워크 내에서 가장 중요하거나 연관성이 높은 요소를 파악하는 Weighted Degree 지표를 활용하여 국가 간 기술적 유사성 및 차이를 확인하였다.

다. 네트워크 분석의 시사점

네트워크 분석 결과는 IP5 국가 간 기술적 협력 가능성과 독자적 연구 영역을 명확히 제시하였다. 공통 관심사가 있는 국가 간 협력은 기술적 시너지를 창출할 수 있는 잠재력을 가지며 독립적인 기술 초점은 각국의 차별화된 연구 강점을 나타낸다. 이러한 결과는 글로벌 기술 전략 수립과 국가 간 협력 가능성을 평가하는 데 있어 중요한 기초 자료로 활용될 수 있다.

3.4.3 분석 결과

가. 자연어처리 알고리즘을 활용한 주제 도출과 라벨링 과정

본 연구는 LDA(Latent Dirichlet Allocation)와 KeyBERT(Keyphrase Extraction by BERT) 알고리즘을 활용하여 IP5 국가에서 연구 및 개발 중인 기술 분야를 분석하였다.

LDA 알고리즘을 통해 국가별로 주요 기술 주제를 토픽 모델링으로 도출하였으며, KeyBERT를 사용하여 각 토픽의 핵심 키워드를 추출하였다. 도출된 핵심 키워드를 바탕으로 토픽 라벨링 후보를 선정하였고, 생성형 AI(ChatGPT)를 활용하여 각 토픽의 라벨링 후보와 핵심 키워드 간의 적합성을 평가하여 최적의 라벨을 매핑하였다.

이를 통해 국가별로 8개의 주요 기술 토픽이 도출되었으며, 국가 간 기술적 집중 영역을 비교할 수 있는 기초 자료가 마련되었다.

나. 국가별 연구개발 패턴 도출

라벨링 및 토픽 모델링 결과를 기반으로 작성된 그래프는 IP5 국가 간 기술적 공통점과 차이점을 명확히 시각화하였다.

그래프에서 다수의 국가가 동일한 라벨에 높은 비중을 보이는 기술 주제는 전 세계적으로 중요한 연구 분야임을 나타낸다. 예를 들어, 물 관리나 지속 가능성과 같은 기술은 IP5 국가에서 공통적으로 높은 관심을 받고 있다.

특정 라벨에서 일부 국가가 높은 집중도를 보이는 경우, 해당 국가는 그 분야에서 독창적이고 특화된 연구를 수행하고 있음을 나타내며, 이를 통해 국가별 기술 전략과 우선순위의 차이를 반영할 수 있다.

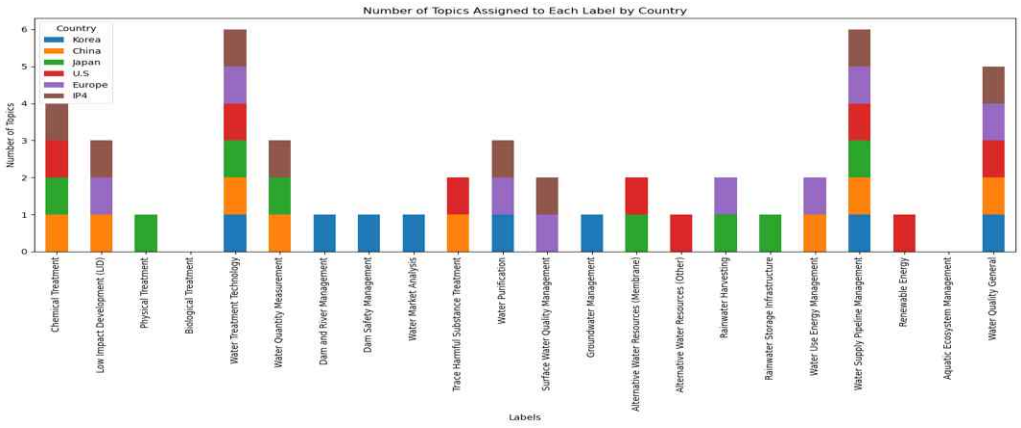


그림 21 국가별 기술정보 분석 결과

다. 연구 결과의 의의 및 시사점

본 연구 결과는 IP5 국가의 연구개발 전략과 기술 집중 영역을 보다 명확히 이해하는 데 기여한다. 공통된 연구 주제는 글로벌 기술 협력 가능성을 탐색할 기초 자료를 제공하며 다자간 기술 교류의 필요성을 시사한다. 차별화된 연구 주제는 국가별 기술 강점을 기반으로 한 맞춤형 연구개발(R&D) 전략 수립에 중요한 인사이트를 제공한다.

그래프는 IP5 국가 간의 기술적 연관성을 직관적으로 보여주며, 기술 정책 및 투자 우선순위

설정을 위한 유용한 시각적 자료로 활용될 수 있다. 연구 결과는 글로벌 R&D 동향을 이해하고 국가 간 경쟁과 협력을 조화롭게 설계하는 데 중요한 기초자료로 기능할 수 있을 것이다.

제 4 장 인공지능 언어모델 기반 솔루션 개발 적용

4.1 배경 및 목표

최근 공공부문과 연구기관에서 인공지능(AI) 기술의 도입과 활용이 급격히 확대되고 있으며 빅테크 기업(Naver, Kakao, Google, OpenAI 등)을 중심으로 신규 언어모델이 지속적으로 공개되면서 그 활용처와 분야가 다양하게 확장되고 있다. 이러한 변화는 AI 기술이 연구와 행정 업무의 효율성을 높이는 도구로 자리 잡을 가능성을 더욱 증대하고 있다. 이에 따라 K-water는 AI 언어모델의 기술 및 행정 업무 실무 활용 수준을 내재화하여 지속적으로 발전하는 AI 기술 환경에 대응하고 공공부문에서의 디지털 전환을 가속하고자 다양한 솔루션을 개발하였다.

주요 솔루션으로는 방울이봇.C, 방울이봇.A, 방울이봇.S, 윤리위험 유형별 예측 모형 등이 있다. 방울이봇.C는 알리오 공시 내부 규정 질의응답을 지원하여 신속하고 정확한 정보 제공과 간단한 심리상담을 목표로 하며, 방울이봇.A는 감사규정 관련 질의를 처리해 반복적인 행정 업무를 자동화한다. 방울이봇.S는 논문, 신문기사, 보고서 등의 문서를 간결하고 효율적으로 요약하여 연구자와 실무자의 정보 접근성을 높인다. 또한, 윤리위험 예측 모형은 공공부문에서 발생 가능한 윤리적 리스크를 사전에 식별하고 대응할 수 있는 체계를 제공하여 공공부문 내에서의 신뢰도와 윤리적 기준을 강화한다.

이들 솔루션은 최신 언어모델(LLM) 기술과 자연어 처리(NLP) 기술을 기반으로 설계되었으며 데이터 전처리, 보안 강화, 기술 내재화를 통해 K-water의 특성과 공공부문의 요구를 충실히 반영하였다. 특히, 빅테크 기업이 주도하는 AI 기술 발전 속도에 맞춰 기술을 내재화함으로써 장기적인 활용 가능성과 자립성을 확보하고자 한다. 이러한 기술들은 K-water의 디지털 전환을 가속화하고, 공공부문의 업무 효율성을 극대화하는 동시에 AI 기술 도입과 활용의 성공적인 사례로 자리 잡을 것으로 기대된다. 궁극적으로 K-water는 AI 언어모델을 통해 기술 혁신과 행정 효율성을 선도하며 공공부문 내 AI 도입과 활용방안을 제시 하고자 한다.

4.2 OASIS 감사시스템 AI 기반 양정예측 프로그램 개발

4.2.1 개요

연구과제 솔루션 중 하나인 언어모델 기반 AI 양정 가이드라인 및 유사문서 검색 알고리즘 고도화를 진행하였다. 감사는 업무를 수행하는 데 감사인의 역량(경험 등)이 절대적으로 반영됨에 따라 감사인별 감사 결과의 편차가 우려되며, 절대 업무량 증가 및 단순, 반복적 업무 등의 양적 증가에 따라 업무 효율을 개선할 필요가 있다. 이에 따라 조치요구서에 대한 양정 가이드 제공을 위한 AI 모델을 개발하였으며 입력된 조치요구서에 따른 양정 추천 및 유사사례, 관련 법령/규정 검색 기능을 제공하였다.



그림 22 감사양정 예측 프로그램 개요

징계요구	경고요구	주의요구	부서주의	기관경고	기관주의	시정(금액)	시정(기타)	개선	권고	통보	통보(시정)	현지조치
12.9%	61.1%	19.5%	15.0%	15.1%	13.8%	15.2%	14.1%	26.4%	14.2%	86.5%	14.2%	12.7%

그림 23 AI 양정가이드 양정 추천 예시

이를 통해 감사인의 성향, 판단에 좌우되지 않는 공정하고 객관적인 양정을 실현할 수 있으며 감사 지연을 방지하고 속도감 있는 감사 수행을 통해 업무 효율을 개선할 수 있으리라는 기대효과가 있다.

4.2.2 양정 예측 모델 개발 과정

가. 데이터셋 검토

(1) 원자료 (raw data)

최근 21년('02~'22)의 감사결과 자료를 송부받았으며, 자연어처리를 하기가 충분한 텍스트가 존재하고 조치요구서가 표준화된 시점을 기준으로 데이터를 분리하여 2014년부터 최근까지의 약 4천여건에 해당하는 자료를 활용하였다.

(2) 데이터 파일 포맷 변환 (hwp5txt)

해당 9년간의 감사 건은 약 4천여건에 해당하며 해당 파일은 대부분 한글파일(*.hwp*)로 존재하기 때문에, python 환경에서 hwp 파일을 text 파일로 변환하는 hwp5txt 프로그램을 활용하여 변환하였다. 현재 적용된 hwp5txt는 한글문서 내의 표 및 그림을 텍스트로 변환할 수 없어 이 과정에서 일부 정보가 누락되고 있으며 향후 개선해야 할 사항이다.

(3) 감사문서의 구조

감사문서는 제목, 소관부서, 조치부서, 내용, 관련부서 의견, 조치할 사항으로 구조화되어있으며, 이 중 내용에는 업무개요, 관계규정 및 판단기준, 감사결과 확인된 문제점으로 나뉜다. 다만, 이러한 구조는 시간에 따라 계속 변화해온 것으로 보이며, 작성자 또는 감사사안에 따라 위의 구조를 일부 따르지 않는 문서도 다수 존재한다.

(4) 딥러닝 모델링을 위한 데이터 변환 및 설계

감사 사안에 대해 양정을 예측하는 AI 모델은 기존 감사문서(조치요구서)를 학습자료로 하는 지도학습(supervised learning)에 해당한다. 지도학습을 수행하기 위해서는 입력값(X)과 목표값(y)이 필요 해당 모델에서는 조치할 사항의 텍스트 중 처분요구 항목들이 y값에 해당하며, 조치할 사항 이전의 내용들이 X에 해당한다.

(5) 목표값(처분요구) 항목의 종류

「감사규정 별표3 감사결과에 대한 처분요구 기준 참고」의 항목은 다음과 같다: 징계요구, 변상명령, 경고요구, 주의요구, 부서주의, 기관경고, 기관주의, 시정(금액), 시정(기타), 개선, 권고, 통보, 통보(시정완료), 통보(모범사례), 고발요구, 현지조치

일반적인 하나의 종류로 분류하는 문서 분류 모델과 달리 2개 이상의 처분요구가 내려지는 경우가 많으므로 다중분류(multi-label) 모델이면서, 다중출력(multi-output)분류 모델의 개발이 필요하다.

나. 텍스트 전처리

(1) 문서 교정 등

한글문서로부터 변환한 텍스트 데이터는 문서의 양식을 유지하기 위해 단어 내에서도 띄어쓰기가 이루어지는 등의 오염이 있어 이를 처리해야 하며, 이를 위해 회사 내에서 사용되는 고유명사 등을 하나의 단어로 인식하게 하기 위해 사용자 정의 사전을 구성하고 이를 띄어쓰기에 활용하였다.

표 9 전처리 과정

전처리 방법	전처리 전 (예)	전처리 후 (예)
줄바꿈 제거	~있습니다. \n 구미권~	~있습니다. 구미권~
띄어쓰기 제거	관 련 부 서	관련부서
양정결과 교정	시정/금액, (징계)	시정(금액), (징계요구)
띄어쓰기 수행*	~이원화사업및국가산단~	~이원화사업 및 국가산단~

* pykospacing 패키지 활용

(2) 입력값과 목표값 분리

전처리 중 정규식을 활용하여 '제목'과 '조치할 사항'을 기준으로 문서를 분리하였으며, 앞부분이 입력값, 뒷부분 중 양정 결과가 목표값에 해당하도록 정의하였다.

(3) 양정결과 추출

조치할 사항 이후의 텍스트로 목표값을 정의하였지만 실제로는 처분요구 항목에 따라 분류되기 때문에 이를 위해 괄호를 기준으로 추출하였다. 한계점으로, 분류모델은 각 양정에 따라 YES/NO를 판단하는 모델로, 특정 처분이 몇 사람(건)에게 적용되는지는 판단할 수 없다.

표 10 수정된 양정결과 예시

조치할 사항	(실제) 목표값
① ~반영추진을 협의하시기 바랍니다. (통보) ② ~안전관리 대책을 보완하시기 바랍니다. (통보) ③ ~사업비(O원)를 조정하시기 바랍니다. (시정(금액))	['통보', '시정(금액)']

다. 탐색적 데이터 분석

(1) 입력값

입력자료는 앞서 기술된 바와 같이 '제목'과 '조치할 사항' 사이에 해당하는 문자열에 해당하며 글자 수의 분포는 아래의 그림과 같으며, 대부분이 4,000자 미만으로 작성되어 있고 1,000자 내외의 값이 빈도가 가장 높다.

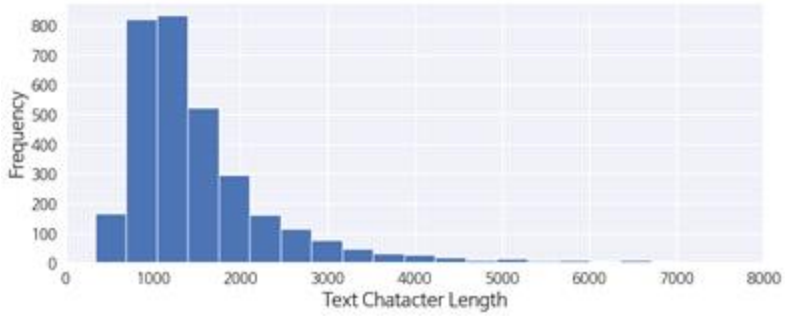


그림 24 감사조치요구서 문서 길이

(2) 처분결과의 분포

양정 처분요구에 따른 분포는 아래의 그림과 같다. 양정(클래스)별로 불균형이 두드러지며, '통보'가 가장 큰 비율을 차지한다. 또한, '변상명령'과 '고발요구' 항목의 경우에는 사례가 존재하지 않으며, '징계요구'(7건, 0.2%), '기관경고'(10건, 0.3%), '기관주의'(18건, 0.6%), '통보(시정완료)'(23건, 0.7%), '부서주의'(49건, 1.5%)의 경우에도 매우 낮은 빈도를 보인다.

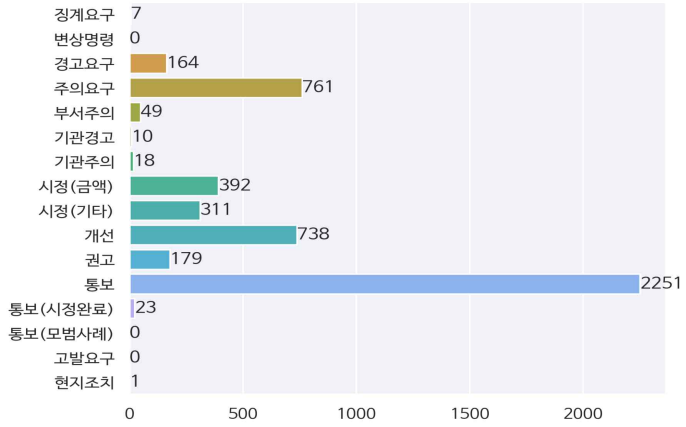


그림 25 처분결과 분포 그래프

라. 양정 분류 모델개발

(1) 딥러닝(1D-CNN)

예측 모델에 입력되는 자료를 더욱 구체화하기 위해 감사규정의 처분 종류 13개에 대한 키워드를 구성하고, 이에 대한 TDM(Term-Document Matrix)과 TF-IDF(Term Frequency-Inverse Document Frequency)를 통해 Cosine Similarity를 추가 입력자료로 구성하였으며, 과적합 방지를 위해K-fold(k=5) 교차검증 방식을 사용한다.

데이터 분류 시 여러 후보 중 하나를 선택하여 분류하는 Multi Classification에서는 softmax를 활성화 함수로 활용하여 전체 처분별 확률의 합이 100%가 되도록 설계하지만, 본 연구에서는 처분의 종류가 2개 이상이 될 수 있는 Multi Label Classification 문제이므로 각 처분에 대해 각각 이진분류를 수행할 수 있도록 마지막 레이어에 'Sigmoid' 활성함수를 사용하였다.

(2) 트랜스포머(BERT)

트랜스포머 모델 중 BERT 모델 'bert-base-multilingual-cased'를 활용함. 해당 모델은 한국어를 포함한 104개의 언어를 이해할 수 있는 능력을 갖추고 있으며 방대한 언어 데이터 말뭉치에서 사전 학습되어 복잡한 언어 구조와 의미를 이해하는데 필요한 지식을 보유하고 있다. 이러한 특징은 한국어 텍스트의 특성과 문맥을 분석하는 데 유용하며 또한, 사전 학습된 모델이기 때문에 학습에 걸리는 시간과 자원을 절약할 수 있다. 선정된 BERT모델은 문맥과 구문 구조를 본질적으로 학습한다는 점에 근거하여 TDM, TF-IDF 등의 전처리는 수행하지 않았다. 데이터셋은 8:2의 비율로 학습용과 테스트용으로 분리한 모델과 k-fold(k=5)로 한 모델 2가지로 성능을 비교하였다.

마. 예측 결과 및 모델별 성능 비교

(1) 예측 결과

감사 양정 예측 모델은 몇 개의 처분이 요구되는지와 어떤 처분이 요구되는지에 대한 2가지 예측이 필요하다. 각 양정별 확률이 출력되도록 구성하였으며 엑셀 파일을 통해 표출 시 아래와 같은 그림으로 각 감사 건에 관한 결과를 확인할 수 있다.

fname	contents	result	result_str	징계요구	경고요구	주의요구	부서주의	기관경고	기관주의	시정(금액)	시정(기타)	개선	권고	통보	통보(시정)	현지조치
2022-080_15_(36) 건설사업관리용역 관리 미흡.tx	건설사업관리용역관리 미흡	울산권지사	['통보', '통보(시정	13.9%	20.4%	25.5%	15.2%	14.3%	14.5%	18.6%	12.5%	11.3%	12.9%	83.6%	16.2%	13.4%
2022-080_1_(04) 실정보고 처리 부적정.txt	실정보고 처리 부적정 소관	③포항권지	['시정(금액)']	12.7%	29.2%	24.8%	14.9%	12.5%	12.9%	67.3%	15.8%	14.3%	15.2%	29.3%	12.3%	11.7%
2022-080_22_(1) 용역 적격심사 철저.txt	용역적격심사가정 부 여 부	③인재경영	['경고요구', '통보	13.6%	45.5%	51.5%	16.0%	13.6%	14.0%	16.3%	12.9%	22.8%	16.3%	61.5%	13.1%	12.2%
2022-080_23_(조치요구서) 보안성 검토 이행 미	보안성 검토 이행 미흡 소관	③포항권지	['통보']	12.4%	13.2%	18.7%	12.8%	12.7%	12.9%	12.3%	10.2%	10.7%	11.2%	90.9%	13.0%	12.2%
2022-080_24_(조치요구서) 경보 SMS 발송 시스	경보 SMS 발송 시스템 개선	③ 유역수	['통보']	13.2%	13.1%	19.6%	12.9%	13.3%	13.6%	14.8%	11.9%	11.0%	12.1%	86.6%	13.3%	12.9%
2022-080_25_(조치요구서) 유량계 유지관리 미흡	유량계 유지관리 미흡 소관	③인재경영	['주의요구', '통보	13.6%	17.5%	59.8%	13.4%	13.9%	13.9%	11.7%	10.5%	13.5%	12.6%	83.5%	14.1%	13.3%
2022-080_26_(조치요구서) 운문정수장 구간 유수	운문정수장 유수율 정상화	운문권지사	['통보']	12.6%	12.9%	12.6%	12.9%	12.6%	13.2%	12.4%	10.9%	9.5%	14.2%	88.9%	12.9%	12.3%
2022-080_27_(조치요구서) 화상감시설비 설치 미	화상감시설비 설치 미흡 소	운문권지사	['통보']	13.3%	13.5%	17.6%	13.4%	13.4%	13.9%	15.2%	11.1%	11.5%	12.1%	85.5%	13.6%	13.0%
2022-080_28_(조치요구서) 온산정수장 수도제어	온산정수장 수도제어망이중	③울산권지	['통보']	13.0%	12.1%	13.7%	13.0%	13.2%	13.5%	12.8%	13.2%	15.8%	13.3%	87.8%	13.6%	12.7%
2022-080_29_(조치요구서) 펌프 하자만료 검사	펌프 하자 만료검사 미흡 소	③인재경영	['주의요구', '통보	12.8%	19.3%	74.1%	12.1%	13.0%	13.0%	10.8%	8.8%	10.5%	11.6%	88.0%	13.2%	12.7%
2022-080_2_(05) 용수댐 계측기기 운영관리 미흡	용수댐계측기기 운영관리	③인재경영	['주의요구', '통보	12.5%	14.4%	62.3%	13.0%	12.8%	12.9%	10.3%	11.3%	14.2%	11.8%	91.4%	13.2%	12.5%
2022-080_30_(3) 시택(임차사택, 합숙소) 운용관	시택(임차사택, 합숙소) 운	운문권지사	['통보']	13.1%	21.8%	21.8%	13.9%	13.5%	13.2%	18.5%	11.8%	16.1%	12.7%	88.8%	13.3%	12.6%
2022-080_31_(9) 국유재산(수도용지) 사용허가 건	국유재산(수도용지) 사용 적	③인재경영	['경고요구', '통보	14.0%	40.5%	22.6%	14.6%	14.7%	14.5%	15.3%	32.8%	23.3%	17.1%	82.4%	15.0%	13.7%
2022-080_32_(10) 수돗물 사용량 검침업무 부적	수돗물 사용량 검침 업무 부	포항권지사	['통보']	12.7%	15.5%	13.4%	13.7%	12.9%	13.3%	15.1%	19.3%	13.4%	13.9%	76.1%	12.5%	12.4%
2022-080_33_(20) 재산종합보험 가입업무 부적정	재산종합보험 가입 업무 부	③인재경영	['주의요구', '통보	12.6%	14.4%	66.4%	11.6%	12.6%	13.0%	10.0%	14.1%	10.4%	13.2%	86.0%	12.2%	12.6%
2022-080_3_(06) 정수처리시설 종합개선계획 수	정수처리시설 종합개선계획	③ 수도관	['개선', '통보']	12.1%	14.5%	34.7%	13.4%	12.4%	12.6%	14.5%	14.4%	84.7%	27.7%	68.0%	12.0%	12.5%
2022-080_44_(포항19)수질시험실 폐액 관리 부적	수질시험실 폐액 관리 부적	③포항권지	['주의요구', '통보	13.7%	37.1%	85.0%	12.8%	14.1%	14.0%	11.8%	14.3%	14.1%	13.2%	86.6%	14.0%	13.6%
2022-080_45_(포항20)학야정수장 알루미늄 관리	학야정수장 알루미늄 관리	③포항권지	['통보']	13.7%	14.8%	9.9%	13.4%	13.5%	13.8%	15.4%	9.3%	18.7%	19.2%	77.5%	13.3%	13.3%
2022-080_46_(운문28)정수장 망간 대응 부적정_2	정수장 망간 대응 부적정 관	운문권지사	['통보']	12.9%	13.8%	11.8%	12.6%	13.1%	13.3%	16.1%	12.0%	16.8%	13.4%	87.5%	12.9%	12.6%
2022-080_47_(운문29)정수장 배출수처리시설 운	정수장 배출수 처리시설 운	운문권지사	['통보']	13.2%	12.3%	24.2%	12.5%	13.3%	13.8%	13.4%	14.0%	15.8%	14.1%	88.5%	13.0%	13.0%
2022-080_48_(운문30)원격사업장 수질시험실 관	원격사업장 수질시험실 관	③ 수도관	['통보']	12.3%	14.2%	13.9%	13.2%	12.0%	12.6%	12.6%	15.9%	13.5%	12.5%	83.8%	12.5%	11.6%
2022-080_49_(울산40)취수원 및 정수장 조류대응	취수원 및 정수장 조류 대응	③울산권지	['개선', '통보']	12.5%	12.8%	10.9%	11.9%	12.3%	12.3%	11.2%	11.0%	81.6%	15.0%	82.9%	12.1%	12.0%
2022-080_4_(07) 긴급복구공사 위험성평가 시행	긴급복구공사 위험성 평가	③포항권지	['통보']	11.9%	12.0%	14.5%	12.0%	12.4%	12.4%	10.4%	10.2%	10.0%	12.0%	89.5%	13.1%	11.7%
2022-080_50_(울산41)탈수기 여과포 관리 부적정	온산정수장 탈수기 여과포	울산권지사	['통보']	12.8%	16.2%	17.6%	12.7%	13.3%	13.3%	14.7%	12.4%	18.0%	14.6%	81.8%	12.7%	12.4%
2022-080_51_(울산42)수도 및 수질사고 초기대응	원격사업장 사고 시 수질분	울산권지사	['통보']	12.5%	14.6%	9.3%	12.4%	12.6%	13.1%	15.3%	16.8%	14.1%	14.3%	78.0%	12.4%	12.2%
2022-080_5_(13) 환경영향평가 업무처리 철저.txt	환경영향평가 업무처리 철	포항권지사	['통보']	12.7%	18.2%	14.3%	13.2%	12.9%	12.9%	12.9%	11.5%	6.5%	14.9%	90.2%	13.9%	12.2%
2022-080_61_(02) 동일유사 물품의 분할 수의계약	동일· 유사물품 분할 수의	③포항권지	['통보']	12.4%	21.5%	41.6%	13.3%	12.6%	12.9%	13.7%	12.0%	14.2%	14.9%	73.7%	12.0%	11.6%
2022-080_62_(11) 준공계약의 단기선급금 미반제	준공계약의 단기 선급금 미	포항권지사	['통보', '통보(시정	14.2%	17.1%	14.9%	16.0%	14.7%	14.1%	27.7%	12.8%	18.9%	14.3%	91.1%	16.8%	14.3%
2022-080_63_(12) 임차사택 지원금 미반납.txt	전보 시 퇴근무지 임차사택	③포항권지	['개선']	14.4%	26.6%	33.3%	14.9%	14.7%	14.5%	28.6%	12.1%	66.4%	12.4%	37.3%	13.8%	14.0%

그림 26 예측결과 출력 모습 예시

(2) 모델별 성능비교

처분의 개수를 예측하지 못하거나 종류를 잘못 예측할 경우 오답으로 처리되어야 한다는 점을 고려하여, 모델에서 예측한 각 처분요구 종류별 확률 중 상위 1위부터 3위까지 예측 결과가 실제 처분요구 항목에 포함되는 경우를 계산하였으며 모델별 성능은 아래 표와 같다.

표 11 감사 양정 모델별 성능 비교

	Top1	Top2	Top3
1D-CNN	75.3%	91.8%	96.8%
BERT(8:2)	89.4%	95.7%	98.0%
BERT(5folds)	84.1%	94.1%	97.8%

성능비교 결과, BERT기반 모델들이 1D-CNN 모델보다 모든 평가 지표에서 우수한 성능을 보였다. 1D-CNN 모델의 경우 상위 1종류가 실제 처분요구 항목에 포함될 확률은 75.3%이며 상위 2개의 경우에는 91.8%, 상위 3개의 경우에는 96.8%을 기록한 반면, 8:2 분할 방식의 BERT모델은 89.4%, 95.7%, 98.0%의 정확도를 보인다. 5-fold 교차 검증을 적용한 BERT 모델 역시 1D-CNN보다 좋은 성능을 보여 84.1%, 94.1%, 97.8%의 정확도를 기록하였다. BERT 모델들은 특히 상위 1종류를 예측하는 정확도에서 1D-CNN 모델보다 약 14% 포인트의 큰 성능 향상을 보인다.

반면 BERT모델 중 교차검증을 한 경우가 8:2 분할을 했을 때 보다 상위 1개가 포함될 확률이 5%포인트 낮다. 이는 특정 처분요구 종류의 편중과 데이터 수량의 한계 때문으로 보인다. 처분요구 종류는 '통보'가 다수를 차지하고 있고 '변상명령'과 '고발요구'는 0건으로 그 편중이 심하며, 데이터 셋은 3,700건으로 BERT와 같은 대형 트랜스포머 기반의 모델을 적용하기에는 수가 적다.

이러한 불균형 때문에 5-fold 교차 검증 시 각 훈련 세트의 균형이 더욱 악화된 것으로 보인다. 그럼에도 불구하고 BERT 모델은 상위 2개 및 3개 처분요구 예측의 정확도에서는 일관된 성능을 보여주는데 이는 BERT가 CNN에 비해 불균형 데이터 환경에서도 비교적 안정적인 성능을 발휘할 수 있음을 시사한다.

4.2.3 유사사례 및 관련 규정 검색 알고리즘 개발

가. 유사사례 검색의 필요성

법원에서 판결 시 '판례'를 중요하게 여기듯, 감사인이 어떤 사안에 대해 감사를 진행할 시에는 과거 유사한 사례를 찾아 참고하는 것이 매우 중요한 과정이다. 유사한 사례를 찾기 위해 파일 제목 만을 통해 검색하는 것이 정보획득에 매우 불리하며, 이를 개선하기 위해 문서의 내용을 벡터화해두고 새로운 문장이 입력될 시 가장 유사한 문서를 찾아주는 모듈을 개발하였다.

나. 검색 프로그램

기존의 각 문서를 TF-IDF vectorizer를 통해 벡터화 해두고 새로운 문장(또는 파일)이 입력될 시 새로운 문장과 기존 문서간의 cosine 유사도를 계산하고 상위 K개(사용자 지정 가능)의 문서 리스트와 참고 규정을 출력하였다.

다. 활용예시

- 사용자 입력 텍스트 : “신기술 및 특허공법에 대해 하도급 계약 체결을 통해 신기술 개발을 진행하기로 약속하였으나, 아직 기술 사용료가 정산되어 있지 않았다.”
- 결과 출력: 파일명(fname), 내용(contents), 양정결과(result_str), 참고 규정(rules)

fname	contents	result_str	rules
2014-023_37_신기술사용료 정산 미흡.txt	신기술 사용료 정산미흡 관련부서 [redacted] 건설단, [redacted] 운	['시정(금액)']	[['정부 입찰·계약집행 기준 ', '신기술·신제품 등 의 업무처리 기준 ']]
2022-044_52_(05) 신기술 사후관리 및 기술사용료 지급 부적정.txt	신기술 사후관리 및 기술사용료 지급 부적정 소관부서 [redacted] 사업	['통보']	['건설기술진흥법 ', '신기술·신제품 등의 업무처리 기준 ', '신기술·신제품 등의 업무처리 기준 ', []]
2016-027_11_20161222083610-172.29.12.10-조치요구서(신기	기술사용료 정산부적정 및 특정공법 적용심사위원회 미심의 관	['주의요구', '시정(금액)', '개선']	[[[redacted] 정수장 건축물 보수공사', '신기술 · 신 제품 등의 업무처리 기준 ', '2015년 평화의댐정밀 안전진단 보수 보강공사', '신기술 · 신제품 등의 업무
2015-009_88_79 [redacted] 건설단_퇴적토 처리공사 신기술 사용료 정	퇴적토 처리 공사 신기술 사용료 정산미흡 관련부서 [redacted] 건	['시정(금액)']	[['정부 입찰 · 계약집행 기준 ', '신기술 · 신제품 등의 업무처리 기준 ']]
2022-078_84_(29) 신기술 사용료 정산 시행 및 사후관리 절차 이행	신기술 사용료 정산시행 및 사후관리 절차 이행미흡 소관부서	['통보', '통보(시정완료)']	[['신기술·신제품 등의 업무처리 기준 ', ' 건설기술진흥법 시행령 ', '신기술·신제품 등의 업무처리 기준 ']]

그림 27 출력 예시

4.3 AI활용 위험영역 예측 모델 개발

4.3.1 개요

가. 추진 배경 및 필요성

선제적 부패관리에 대한 대내외 요구에 따라 예측 타겟 통제 중심의 윤리경영 체계를 고도화하여 윤리 리스크를 원천차단하는 것이 필요하다. 이를 위해 부서의 잠재 위험을 포함한 다양한 정보자원을 활용하여 데이터 기반의 내부통제 관리로 전환함으로써, 보이지 않는 취약 지점을 정확히 예측하고 성과를 견인하고자 한다. 이러한 접근은 감사원과 기획재정부의 경영평가에서 제시된 “적극적인 내부 통제 강화 노력 필요”라는 지적사항에 대응하기 위한 조치이기도 하다.

또한, 디지털 혁신은 업무효율화와 일하는 방식 전환이라는 혁신적 트렌드를 반영한 것이다. 정부 차원에서 데이터 분석과 예측을 통한 국정 운영의 과학화를 강조하고 있으며 이는 120대 국정과제 중 하나이다. 이에 따라 K-water는 경영 변화를 선도하기 위해 디지털 혁신 의지*를 표명하고 있다. 이러한 배경을 바탕으로 본 솔루션은 윤리적 리스크 관리와 디지털 혁신이라는 두 축을 중심으로 AI를 활용한 위험영역 예측 모델을 개발하여 조직의 투명성과 효율성을 제고하려 한다.

* K-water 중장기 전략과제('24～'28)(디지털플랫폼 구축·운영 및 데이터 분석·활용 강화)관련

4.3.2 윤리 키워드 텍스트 분석

가. 분석 개요

분석 대상은 문서 형태가 정형화된 시기인 2014~2023년까지 10년간 감사조치요구서 총 3,706건이며, 자연어처리(NLP) 기법을 활용하여 전처리 후 위험 키워드 텍스트 분석을 진행하였다. 보다 정확한 텍스트 분석을 위해 감사조치요구서의 제목과 내용으로 분석 대상을 나누었고 자연어처리로는 TF와 TF-IDF 방법을 사용하였다. 텍스트 분석 단위는 Unigram, Bigram, Trigram, Bi+Trigram 총 4가지 종류로 살펴본다.

나. 분석 방법 및 분석 단위

(1) 분석 방법

TF(Term Frequency)와 TF-IDF(Term Frequency-Inverse Document Frequency)는 텍스트 데이터에서 단어의 중요도를 평가하는 기본적인 자연어처리 기법이다.

TF는 특정 단어가 문서 내에서 얼마나 자주 등장하는지를 측정하며 이를 통해 해당 문서에서 상대적으로 중요한 단어를 식별할 수 있다. 반면, TF만으로는 모든 문서에서 자주 등장하는 일반적인 단어를 필터링하기 어려우므로, 이를 보완하기 위해 IDF(Inverse Document Frequency)를 결합한 TF-IDF가 활용된다. IDF는 특정 단어가 전체 문서 집합에서 얼마나 드물게 등장하는지를 측정하여 드문 단어에 더 높은 가중치를 부여한다.

TF-IDF는 단어의 빈도(TF)와 드물게 등장하는 정도(IDF)를 결합하여 문서 내에서 특정 단어의 상대적 중요도를 계산한다. 이 기법은 문서 검색, 키워드 추출, 문서 간 유사도 측정 등 다양한 텍스트 데이터 처리 작업에서 효과적으로 활용된다. 간결하면서도 효율적인 특성으로 인해 자연어처리의 기본적인 분석 도구로 널리 사용되고 있다.

표 12 TF, TF-IDF 비교

구 분	내 용
TF	문서 내 특정 단어가 나타나는 빈도를 계산하여 단어의 중요성을 측정하는 방법
TF-IDF	특정 단어가 문서 내에서 자주 등장하지만, 전체 문서 집합에서는 드물게 등장할수록 더 중요한 단어로 평가하는 방법

(2) 분석 단위

텍스트 데이터 분석에서 사용하는 주요 단위는 Unigram, Bigram, Trigram, Bi+Trigram이다.

① Unigram: 단일 단어를 분석 단위로 사용하는 방식임. 가장 단순한 형태로, 각 단어의 빈도를 기반으로 텍스트의 특징을 추출할 수 있음. 예를 들어, "자연어 처리"라는 문장

은 "자연어"와 "처리"라는 두 개의 Unigram으로 표현됨

② Bigram: 두 단어씩 묶어서 분석 단위로 사용하는 방식으로, 단어 간의 연속적인 관계를 반영할 수 있으며 문맥 정보를 보다 풍부하게 포함할 수 있음. "자연어 처리"는 "자연어 처리"라는 Bigram으로 표현됨

③ Trigram: 세 단어를 하나의 단위로 묶어 분석하는 방식으로, Bigram보다 더 긴 문맥 정보를 제공하며 문장의 구조나 구체적인 표현을 분석하는 데 유용함. 예를 들어, "자연어 처리 기술"은 "자연어 처리 기술"이라는 Trigram으로 표현됨

④ Bi+Trigram: Bigram과 Trigram을 결합하여 분석에 사용하는 방식임. 두 단위의 장점을 결합하여 단어 간의 짧은 관계와 긴 문맥 정보를 동시에 활용할 수 있음. 이를 통해 텍스트 데이터의 특징을 더욱 풍부하게 추출할 수 있음

이러한 분석 단위는 텍스트의 성격과 목적에 따라 선택적으로 활용되며 TF와 TF-IDF와 같은 기법과 결합하여 텍스트 데이터 처리의 효율성을 높이는 데 기여한다.

표 13 수정된 양정결과 예시

구 분	내 용
Unigram	문서를 단어 단위로 나누어 각 단어를 하나의 토큰으로 처리하는 방법
Bigram	문서를 두 단어씩 묶어 연속된 단어 쌍을 하나의 토큰으로 처리하는 방법
Trigram	문서를 세 단어씩 묶어 연속된 세 단어 조합을 하나의 토큰으로 처리하는 방법
Bi + Trigram	Bigram + Trigram의 결과를 합병하는 방법

다. 분석 결과

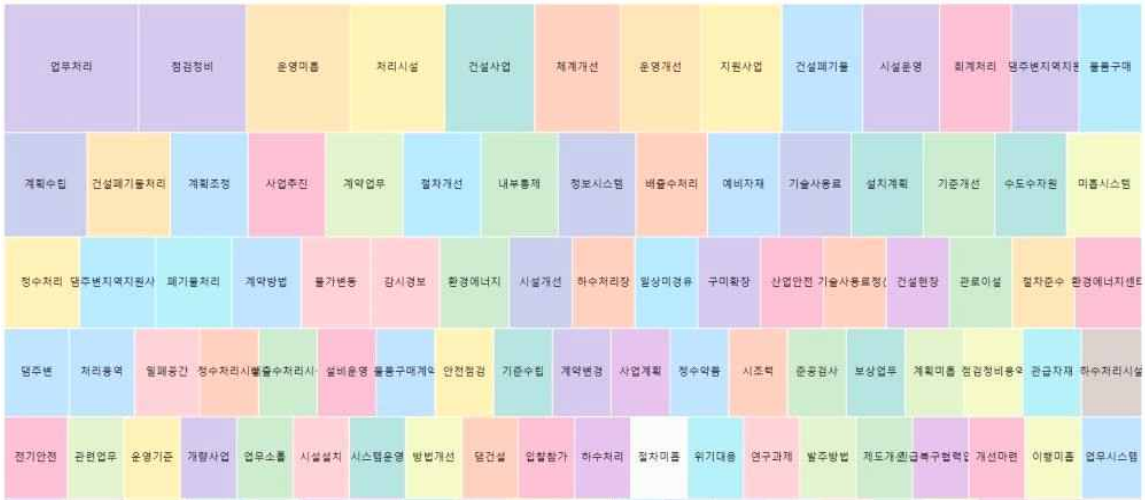
(1) 감사조치요구서 제목(Title) + TF + [Bi+Trigram]

도출된 주요 키워드는 업무처리, 점검정비, 운영미흡, 처리시설, 건설사업 순이다.

표 14 키워드 도출 (활용:제목, TF, [Bi+Trigram])



01) 업무처리: 30	02) 점검정비: 24	03) 운영미흡: 23	04) 처리시설: 21	05) 건설사업: 20
06) 체계개선: 19	07) 운영개선: 18	08) 지원사업: 18	09) 건설폐기물: 18	10) 시설운영: 17
11) 회계처리: 16	12) 댐주변지역지원: 15	13) 물품구매: 15	14) 계획수립: 15	15) 건설폐기물처리: 15
16) 계획조정: 14	17) 사업추진: 14	18) 계약업무: 14	19) 절차개선: 14	20) 내부통제: 14
21) 정보시스템: 14	22) 배출수처리: 13	23) 예비자재: 13	24) 기술사용료: 13	25) 설치계획: 13
26) 기준개선: 13	27) 수도수자원: 13	28) 미흡시스템: 13	29) 정수처리: 12	30) 댐주변지역지원사업: 12
31) 폐기물처리: 12	32) 계약방법: 11	33) 물가변동: 11	34) 감시경보: 11	35) 환경에너지: 11
36) 시설개선: 10	37) 하수처리장: 10	38) 일상미경유: 10	39) 구미확장: 10	40) 산업안전: 10
41) 기술사용료정산: 10	42) 건설현장: 10	43) 관로이설: 10	44) 절차준수: 10	45) 환경에너지센터: 10
46) 댐주변: 10	47) 처리용역: 10	48) 밀폐공간: 10	49) 정수처리시설: 9	50) 배출수처리시설: 9



(2) 감사조치요구서 제목(Title) + TF-IDF + [Bi+Trigram]

도출된 주요 키워드는 업무처리, 운영미흡, 점검정비, 체계개선, 건설사업 순이다.

표 15 키워드 도출 (활용: 제목, TF-IDF, [Bi+Trigram])



01) 업무처리: 24.31	02) 운영미흡: 20.74	03) 점검정비: 19.5	04) 체계개선: 18.67	05) 건설사업: 16.42
06) 운영개선: 15.91	07) 지원사업: 15.08	08) 회계처리: 14.64	09) 처리시설: 14.24	10) 건설폐기물: 13.14
11) 수도수자원: 13	12) 절차개선: 12.85	13) 계획조정: 12.75	14) 기준개선: 12.68	15) 예비자재: 12.54
16) 정보시스템: 12.52	17) 계획수립: 12.43	18) 설치계획: 12.33	19) 시설운영: 12.29	20) 계약업무: 11.98
21) 사업추진: 11.46	22) 물품구매: 11.39	23) 댐주변지역지원: 10.71	24) 내부통제: 10.52	25) 폐기물처리: 10.47
26) 미흡시스템: 10.33	27) 건설현장: 10	28) 일상미경유: 10	29) 건설폐기물처리: 9.75	30) 시설개선: 9.49
31) 계약방법: 9.46	32) 하수처리장: 9.41	33) 관로이설: 9.12	34) 물가변동: 9.12	35) 기술사용료: 9.11
36) 사업계획: 8.68	37) 정수처리: 8.58	38) 절차준수: 8.54	39) 감시경보: 8.38	40) 계획미흡: 8.37
41) 보상업무: 8.31	42) 관급자재: 8.17	43) 설비운영: 8.11	44) 안전점검: 8.09	45) 관련업무: 8
46) 정수약품: 7.99	47) 댐주변지역지원사업: 7.96	48) 기준수립: 7.93	49) 환경에너지: 7.77	50) 계약변경: 7.76

(3) 감사조치요구서 문서내용(Description) + TF-IDF + [Bi+Trigram]

도출된 주요 키워드는 계약체결, 계약금액, 계획수립, 계약상대자, 건설기술 순이다.

표 16 키워드 도출 (활용: 내용, TF-IDF, [Bi+Trigram])



01) 계약체결: 146.83	02) 계약금액: 129.96	03) 계획수립: 111.09	04) 계약상대자: 96.9	05) 건설기술: 84.43
06) 업무수행: 79.92	07) 용수공급: 72.45	08) 정보시스템: 71.32	09) 사고발생: 64.1	10) 건설사업: 63.52
11) 점검정비: 61.72	12) 준공예정: 59.34	13) 개선필요: 59.06	14) 처리시설: 57.37	15) 사업추진: 57.06
16) 정수처리: 56.76	17) 사업계획: 55.94	18) 계약업무: 54.89	19) 사업장운영: 53.84	20) 시설설치: 52.82
21) 현황단위: 51.19	22) 댐건설: 50.32	23) 법시행령: 49.37	24) 수립시행: 48.47	25) 시설운영: 47.78
26) 국토교통부: 47.63	27) 안전점검: 47.55	28) 사업장운영업무기준: 47.37	29) 계획변경: 47.35	30) 사업시행: 46.44
31) 물품구매: 46.3	32) 시스템구축: 46.25	33) 업무처리: 46.25	34) 유지보수: 46.2	35) 지적사항: 46.15
36) 설치운영: 45.86	37) 미흡소관부서: 44.97	38) 부서장: 44.84	39) 산업안전: 43.06	40) 개발사업: 42.85
41) 수력발전: 42.29	42) 협약서: 42.22	43) 주관부서: 41.8	44) 시설개선: 41.68	45) 수도건설: 41.51
46) 필요실정: 41.29	47) 기본계획: 40.85	48) 설치계획: 40.81	49) 협약체결: 40.43	50) 다목적댐: 40.12

4.3.3 AI 예측 분류모델 개발

가. 개발 개요

AI예측 분류모델은 AI를 활용하여 새로운 감사조치요구서가 입력되었을 때 윤리위험 유형별 어느 카테고리에 속하는지에 대한 확률을 나타내며 윤리위험 유형별로 분류 가능성을 확인하는 것을 목표로한다. 모델에 사용된 데이터는 감사조치요구서 중 윤리위험 유형별로 분류된 문서 총 373건이며, AI 예측 분류 모델 개발에 사용된 언어모델은 한국어 기반 트랜스포머 KLUE-BERT이다. KLUE-BERT는 한국어 언어 이해를 위한 사전 학습된 언어 모델로 한국어 자연어처리(NLP) 성능 향상을 목적으로 개발되었다. KLUE(Korean Language Understanding Evaluation) 벤치마크를 기반으로 다양한 NLP 작업에서 우수한 성능을 보이며, 한국어 텍스트 분류, 감성 분석, 질문 응답 등 다양한 과제에 활용된다. KLUE-BERT는 한국어 데이터를 학습하여 한국어 문맥 이해에 최적화되어 있으므로 본 개발에 적합하여 베이스 모델로 선정하였다.

나. 개발 방법

(1) 데이터셋 검토

최근 10년(2014~2023) 감사조치요구서 3,706건 중 윤리위험 유형별 분류문서 총 373건을 활용하였으며 유형별 분류는 K-water 경영혁신실에서 제공하였다. 분류된 윤리위험은 총 9가지로 예산낭비, 불공정계약, 회계위반, 보안위반, 자회사비위, 이해충돌, 채용비위, 부정청탁, 근태위반이다.

(2) 한국어 전처리

한글은 영미권 라틴계 언어와 달리, 형태소 분석과 복합어 처리 등의 규칙이 복잡하여 AI 코딩을 함에 있어 도전적이며, 한글 파일(.hwp)을 텍스트형식(.txt)으로 변환하는 과정을 거친다. 그 후 띄어쓰기, 탭, 줄바꿈 제거, 띄어쓰기 재수행과 같은 문장 교정이 수행되었으며, K-water에서 주로 사용되는 사용자 키워드를 추가하여 성능 향상을 도모하였다.

표 17 문장 교정 전/후 비교

전처리 방법	전처리 전 (예)	전처리 후 (예)
줄바꿈 제거	~있습니다. \n 구미권~	~있습니다. 구미권~
띄어쓰기 제거	관 련 부 서	관련부서
양정결과 교정	시정/금액, (징계)	시정(금액), (징계요구)
띄어쓰기 수행*	~이원화사업및국가산단~	~이원화사업 및 국가산단~

표 18 사용자 키워드 추가 전/후 비교

전처리 방법	전처리 전 (예)	전처리 후 (예)
키워드 사전추가	수자원 개발 처	수자원개발처

다. 탐색적 데이터 분석(EDA, Exploratory Data Analysis)

윤리위험 유형별 분포는 아래 그림과 같이 '예산낭비'(216건, 58%)와 '불공정거래'(92건, 25%)가 전체의 83%로 대부분을 차지하며, '이해충돌'(1건, 0.002%)과 '자회사비위'(5건, 0.01%)는 매우 낮은 빈도를 보인다. 이처럼 클래스가 불균형할 경우 학습 및 예측이 매우 어렵다.

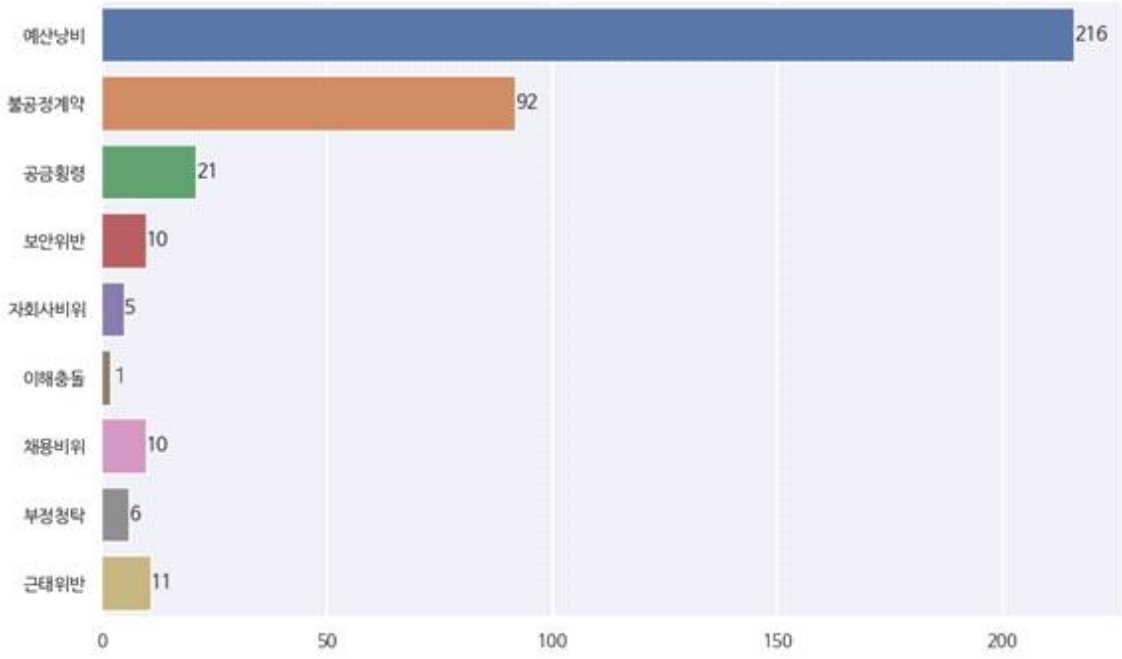


그림 28 윤리위험 유형별 EDA

라. 데이터셋 분할

'이해충돌'은 1건이나, AI 학습을 위해 데이터를 2건으로 증강하여 진행하였으며, 클래스간 불균형을 해소하기 위해 클래스별로 훈련:테스트=8:2로 구분하였다.

마. 모델개발

본 모델은 입력(input)에 대해 결과(output)으로 윤리위험 클래스마다 해당하는 확률을 출력해야 하므로, 일반적인 Multi-Classification이 아닌 Multi-Label-Classification 분류 문제로 접근이 필요하다. 더불어 한국어의 특수성과 데이터 불균형, 텍스트의 문맥 파악이 가능해야 하므로 트랜스포머 기반 사전 학습된 한국어 특화 모델 중 Hugging-Face*에서 8만번 이상 다운로드 된 KLUE-BERT를 사용하였다.

* 자연어처리(NLP) 등의 모델 공유 및 협업을 위한 오픈 소스 플랫폼

바. 모델 성능

예측값으로 출력되는 카테고리 중 가장 높은 확률로 예측되는 결과 1개가 정답일 확률은 93.3%, 결과 상위 2개가 정답에 포함될 확률은 98.7%, 상위 3개는 99.2%로 높은 정확도를 보였다.

표 19 윤리위험 유형별 AI 예측모델 성능

정답이 포함될 확률 (정확도)	top1	top2	top3
	93.3%	98.7%	99.2%

사. 결과 출력

텍스트 입력 시 9개의 윤리위험 카테고리 각각의 확률이 출력되도록 구성하였으며, K-water 감사조치요구서 외에 뉴스, 판례, 타 기관 조치요구서 등 다른 텍스트에 대해서도 예측 확률도 도출되는 것을 확인할 수 있었다. 해당 모델은 사용자 편의를 위해 사내 K-water사내 망(오아시스)내의 데이터스튜디오에 탑재되었다.

표 20 결과 출력 예시(1)
(입력: K-water 감사조치요구서)

(예시1) K-water 감사조치요구서

수자원 사업 처 내용 ○○○○○○○○○○○에서는 (중략) 10월까지 편의점 4개소, 휴게음식점 1개소에 대한 임대차 계약을 체결하였습니다. 이후 업무 분장 변경 (생략)

(출 력) 정답: 예산낭비

	text	근태위반	보안위반	부정청탁	불공정계약	예산낭비	이해충돌	자회사비위	채용비위	회계위반
관리처에서는 '...		0.432393	0.212257	0.285797	0.519173	0.995544	0.242325	0.408592	0.19494	0.451107

Top3 Categories:

예산낭비: 0.995544

불공정계약: 0.519173

회계위반: 0.451107

표 21 결과 출력 예시(2)
(입력: 채용비위관련 뉴스기사)

(예시2) 채용비위 사례
(자격기준 임의 변경) 자신의 자녀가 기존의 평가 기준을 그대로 적용할 경우 (중략) 해당 특정인이 선발되어야한다는 취지로 부당하게 개입하여 (생략)
(출 력) 정답: 채용비위

text	근태위반	보안위반	부정청탁	불공정계약	예산낭비	이해충돌	자회사비위	채용비위	회계위반
경우 합...	0.4213	0.453782	0.313805	0.463293	0.264019	0.440231	0.453848	0.986141	0.311645

Top3 Categories:

채용비위: 0.986141

불공정계약: 0.463293

자회사비위: 0.453848

표 22 결과 출력 예시(3)
(입력: 타기관 감사조치요구서)

(예시3) 한국관광공사 감사조치요구서
1. 업무개요 감사실은 임직원의 청렴성 (중략) 3. 점검결과 확인된 문제 A는 시업시간이 지난 09시 04분에, ㅇㅇ원의 2급 B는 09시 06분에, (생략)
(출 력) 정답: 근태위반

text	근태위반	보안위반	부정청탁	불공정계약	예산낭비	이해충돌	자회사비위	채용비위	회계위반
한국관광공사의 ...	0.92506	0.532882	0.428085	0.179154	0.688167	0.230619	0.518304	0.287172	0.311962

Top3 Categories:

근태위반: 0.92506

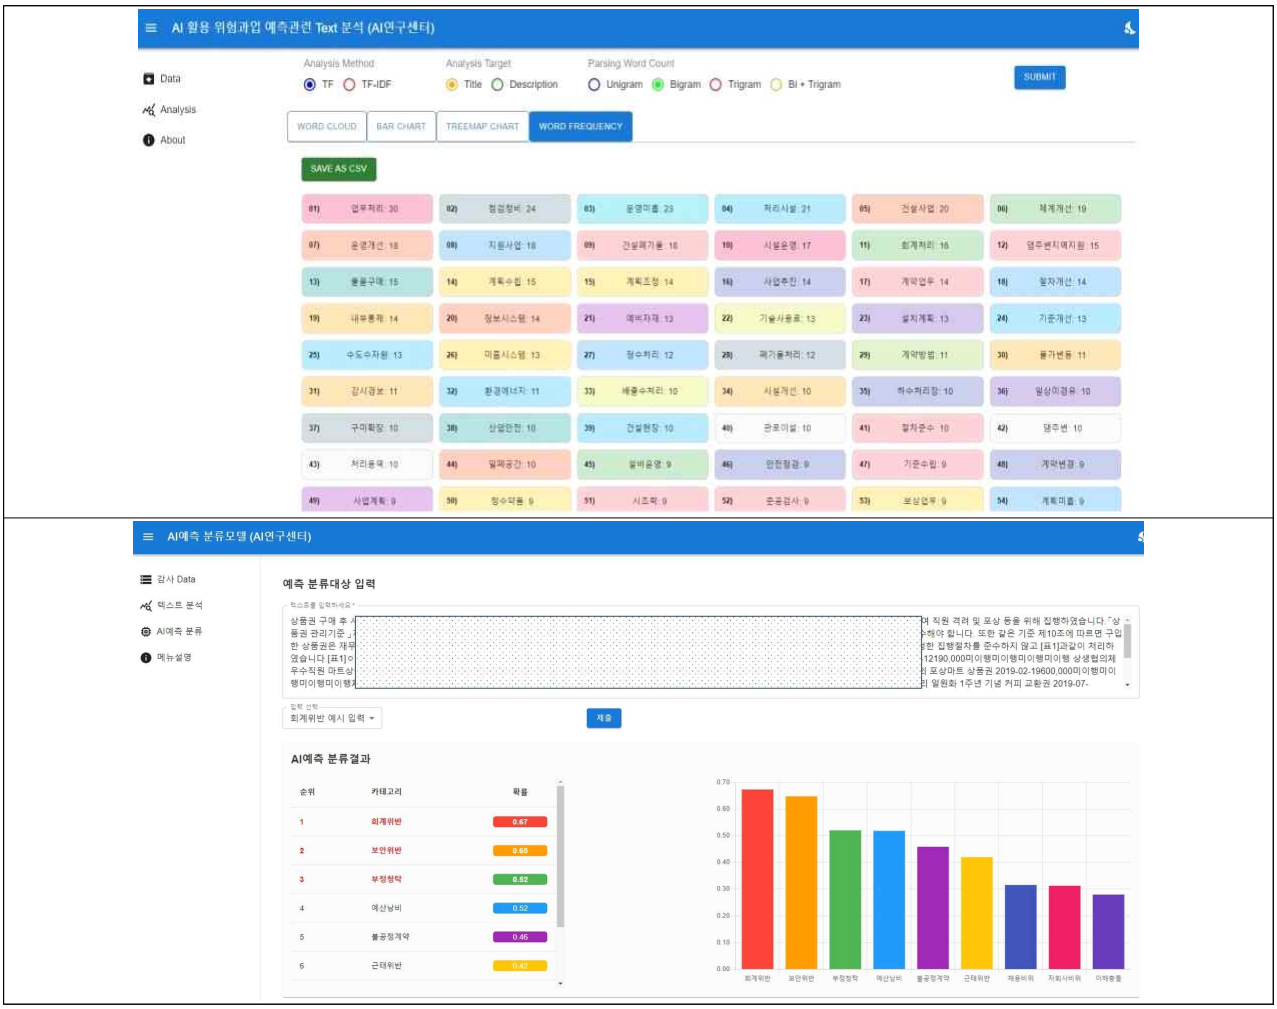
예산낭비: 0.688167

보안위반: 0.532882

4.3.4 데모용 웹 애플리케이션 개발

데모를 위해 React와 RESTful API를 활용하여 웹 애플리케이션을 개발하였다.

표 23 웹 · 애플리케이션 화면 예시



4.4 LLM활용 챗-에이전트 개발

4.4.1 개요

가. 추진배경 및 목적

공공부문의 인공지능(AI) 기술 도입과 활용 범위 확대는 업무 생산성과 효율성을 높이는 데 필수적이다. 특히 기후변화의 가속화와 기술 융복합화에 대응하기 위한 공공부문의 디지털 전환 필요성이 증대됨에 따라 물관리 분야에서 실질적인 AI 기술 응용이 요구되고 있다.

주요국 정부는 데이터 품질, 신뢰성 및 편향성 문제 등 장애 요인에도 불구하고 공공부문 AI 기술 도입을 적극적으로 추진하고 있으며, 챗봇, 데이터 분석, 생체인식 등에서 활용도가 증가하고 있다. 이에 반해 국내 공공부문은 기술적, 인력적, 예산적 제약과 더불어 보안 및 사

회적 우려로 인해 도입 속도가 더딘 상황이다. 본 연구는 기존 AI 개발 역량을 활용하여 기술 성숙도가 높아지고 있는 AI 언어모델을 공공 행정 및 기술 업무에 실질적으로 활용하기 위한 내재화 방안을 제시하고자 한다.

나. 개발방향 및 목적

거대언어모델(LLM)을 기반으로 K-water 규정에 대한 질의응답을 하는 챗-에이전트 시스템을 개발하였다. 개발된 모델은 크게 2가지로, 방울이봇.C^{Chatbot}는 알리오에 공시된 108개 규정에 대해 질의응답과 간단한 심리상담 서비스를 제공하며, 방울이봇.A^{Audit}은 외부공개 가능 규정과 감사실에서 제공한 Q&A 세트에 대한 질의응답이 가능한 챗봇이다. 이를 통해 K-water 규정에 대한 신속하고 정확한 정보를 제공하고, 반복되는 업무(질의응답) 부담을 줄여 본연의 업무에 보다 집중할 수 있도록 돕는다. 공공부문의 데이터 보안 이슈를 고려하여 공개 가능한 데이터만 사용하였으며 속도감 있는 프로토타입 개발을 위해 OpenAI의 API와 Langchain Community를 활용하여 기술의 내재화와 실효성을 확보하고자 하였다.

4.4.2 방울이봇.C^{Chatbot}

가. 개요

방울이봇.C는 알리오에 공시된 108개 사규에 대한 질의응답과 세브란스병원 데이터를 기반으로 간단한 심리상담을 제공하는 AI 챗봇 모델이다. 주요 기능은 인사, 급여, 연구개발 등 다양한 규정에 대해 신속하고 정확한 정보를 제공하는 것이다.

나. 개발 방법 및 화면

LLM을 활용하기 위해 1,400명 이상의 개발자가 기여한 오픈소스 프레임워크인 랭체인(LangChain)을 기반으로 개발되었으며, OpenAI의 API를 활용하였다.

- 전처리: 규정, 세칙 등 데이터(pdf, hwp, 표 등)에 따라 전처리 모듈 개발
- 문장분리: 수집된 원데이터를 적정 수준의 길이로 분리 최적화(Chunking)
- 벡터화: 분리된 각 텍스트를 기계어로 변환(embedding)하고 저장
- 기억저장규모: 맥락에 따라 대화할 수 있도록 Buffer 메모리 구성을 최적화
- 대화형 체인: ChatGPT(3.5-turbo) 모델을 기반으로 챗봇 개발
- RAG 기법 활용: 할루시네이션을 줄이기 위해 도입

해당 챗봇은 GUI를 통해 사용자 친화적인 입력과 결과 출력을 지원하였다. 또한, AI연구센터 과제 '클라우드 서비스 선정 및 이용방안 마련 연구'와 연계하여 클라우드 기반의 안정적인 운영 체계를 마련하였다.



그림 29 방울이봇.C 서비스 화면

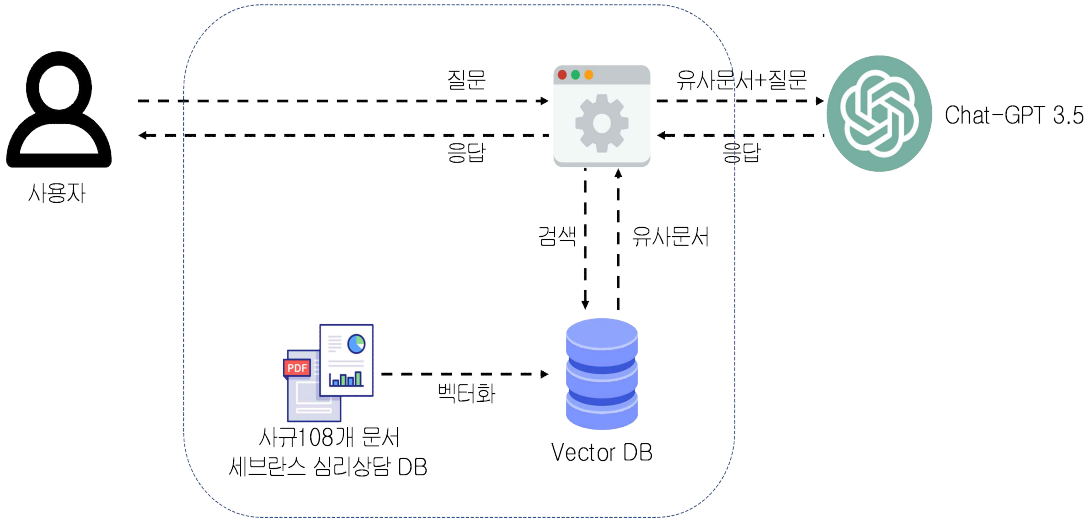


그림 30 방울이봇.C 스키마

4.4.3 방울이봇.A[Audit]

가. 개발 개요

감사 규정관련 질의응답에 대한 AI 자동화를 적용하여 직원의 편의를 위한 적극 행정 지원을 통해 감사규정 검색 및 답변 도구인 챗-에인전트를 개발하였다. 신뢰성 있는 결과를 위해 문서 검색기반으로 답변하는 RAG(Retrieval-Augmented Generation, 검색 증강 생성) 기법을 적용하였으며, 최신 AI 언어모델(OpenAI API)을 활용하여 대화형 질의 응답 챗봇을 구축했다.

표 24 RAG 기술 개요

▶ 사용자 질문에 대해 임베딩 벡터 데이터베이스에서 관련 정보를 검색한 후 이를 기반으로 AI 모델이 응답을 생성하여 답변의 신뢰성을 높이는 기술



나. 개발 방법

데이터셋은 감사실에서 제공한 외부에 공개가 가능한 규정만 사용하였으며 감사규정 질의응답 세트 101개 또한 사용하였다. 더불어 RAG 기법과 프롬프팅 엔지니어링을 활용하여 거대언어 모델의 고질적인 문제인 할루시네이션 문제를 해결하고자 하였다. 더불어 OpenAI의 API를 사용한다는 점에 기반하여 원래 목적인 사규 질의응답이 아닌, 일반적인 용도로 사용될 가능성을 차단하기 위해서 사규에 대한 질문만 가능하도록 조정하였다.

성능 개선을 위하여 문서조각(chunk)과 겹침정도(overlap)를 여러 조합(300-50, 400-100, 400-50, 300-100)으로 조절하여 답변의 정확도를 향상하고자 하였으며 OpenAI API 또한 4.0-Turbo, omni 등을 사용하여 가장 높은 정확도를 보이는 모델을 선택하였다. 그 순서는 아래와 같다.

(1) (데이터셋) 외부 공개 가능 데이터 사용(감사실 제공)

① 감사규정세칙, 노동조합규정 등 200여개 사내 규정

② 감사규정 질의응답 세트 101개

(2) (전처리) 한글 문서 변환 작업(.hwp → .txt), 불필요 문자 삭제 등

(3) (DB구축) OpenAI의 임베딩모델을 사용하여 데이터셋을 DB로 저장

(4) (미세조정) 프롬프트를 통해 AI모델 환각(Hallucination) 방지, 문서조각(chunking)과 겹침(overlap)을 최적화하여 답변정확도 향상, OpenAI ChatGpt 4-turbo 사용으로 성능 향상

(5) (웹앱구현) 오픈소스 GUI(Streamlit) 활용 질의응답, 유사 규정 검색 등

(6) (사용 SW) Python, OpenAI ChatGpt, Langchain(언어모델 개발 프레임워크), 임베딩 벡터DB(ChromaDB), Streamlit 등

다. 결과 및 성과 활용

반복적인 감사 질의응답 자동화를 위하여 수요 부서(감사실)의 피드백을 반영하여 활용 가능성 검토를 진행하였으며 이를 바탕으로 수정/개발을 반복하여 챗봇으로서의 완성도를 높였다. 해당 개발 소스는 환경부 산하기관으로 구성된 적극행정협의체를 통해 성과를 공유하고, 피드백에 따라 고도화 개발 등을 추진하여 공공부문 전반에 확산 가능성을 높이는 데 활용할 수 있다.



그림 31 방울이봇.A 실행 화면
(좌)감사규정 유사문서 검색결과 (우) 질의 응답내용

4.5 LLM활용 문서요약기 개발

4.5.1 개요

가. 개요

방울이봇.S^{Summary}는 논문, 신문기사, 보고서 등 다양한 문서를 효율적으로 요약할 수 있는 AI 기반 문서 요약 시스템으로 연구 환경에서 특히 유용하게 활용될 수 있도록 설계되었다. 방대한 텍스트를 간결하고 핵심적인 내용으로 변환함으로써 연구자들이 방대한 자료를 신속히 이해하고 문헌 조사 및 연구보고서 작성 시간을 대폭 줄일 수 있도록 지원한다. 최신 언어모델(LLM) 기술을 활용한 방울이봇.S는 문서의 주요 논점과 데이터를 자동으로 분석해 고품질의 요약 결과를 제공하며, 연구업무의 생산성과 정확성을 크게 향상할 수 있다.

특히, 방울이봇.S는 다양한 문서 형식과 주제를 지원하며 자연어 처리(NLP) 기술을 활용한 문맥 분석 및 중요한 정보 추출 기능을 갖추고 있어 연구기관에서 다루는 학술 논문, 보고서 등의 자료를 효과적으로 다룰 수 있다. 이를 통해 연구자들이 핵심 정보에 보다 쉽게 접근하고 분석 및 결과 도출 과정을 효율적으로 수행할 수 있어 연구 생산성을 극대화하고 데이터 기반 의사결정을 강화하는 데 기여할 것으로 기대된다.

나. 주요기능

방울이봇.S는 총 4개의 포맷의 텍스트 데이터를 입력자료로 받을 수 있으며 입력자료에 대해 요약과 번역 기능을 제공한다.

(1) 입력 가능 형태

① 직접 입력: 사용자가 텍스트를 직접 입력

② WEB URL: 웹사이트의 주소를 입력하여 해당 문서의 내용 입력 가능

③ DOI: MDPI에서 제공하는 논문에 대하여 DOI 입력 가능

④ Upload File: 사용자가 원하는 파일 업로드 가능

(2) 요약번역

① GPT-3.5, 다국어(mT5), 영어(T5) 거대언어모델을 선택할 수 있으며, 입력된 자료에 대해 요약과 번역(영어, 중국어, 일본어, 프랑스어 등)을 제공

다. 클라우드 활용 플랫폼 구축

AWS 클라우드를 활용하여 방울이봇.S 플랫폼을 구축하였으며 적용된 스펙은 아래와 같다.

○ AWS(Amazon Web Service) 활용 클라우드 인스턴스 서비스

○ g4dn.4xlarge(vCPU : 16개, GPU : 1개, Mem: 64GB, 저장장치 : 100GB SSD)

○ 운영체제(OS) : Linux(Ubuntu 22.04)

○ 프로그래밍 : Python 3.10, DASH, Plotly, Streamlit, Responsive web (모바일 가능)

○ Elastic IP를 이용한 공인 IP 할당

○ DNS 도메인 네임 할당 및 SSL 인증서를 통한 전송 구간 암호화(HTTPS) 보안 적용

○ WEB - WAS 구성으로 대규모 부하 고려, port 포워딩, 로드 밸런싱 구현

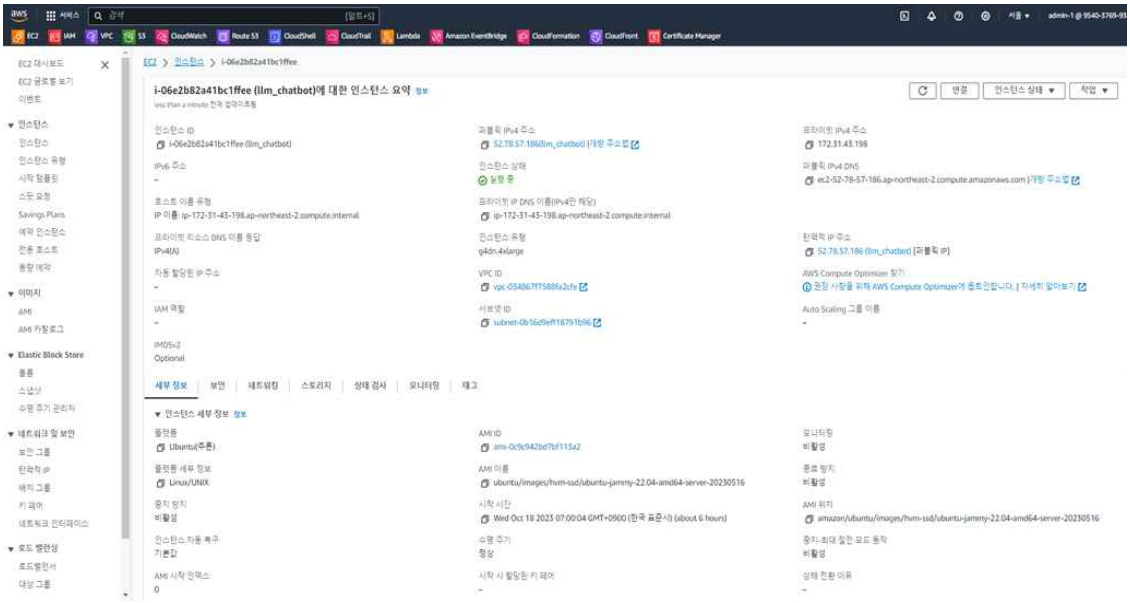


그림 32 활용된 클라우드 스펙(AWS)



그림 33 방울이봇.S 서비스 화면

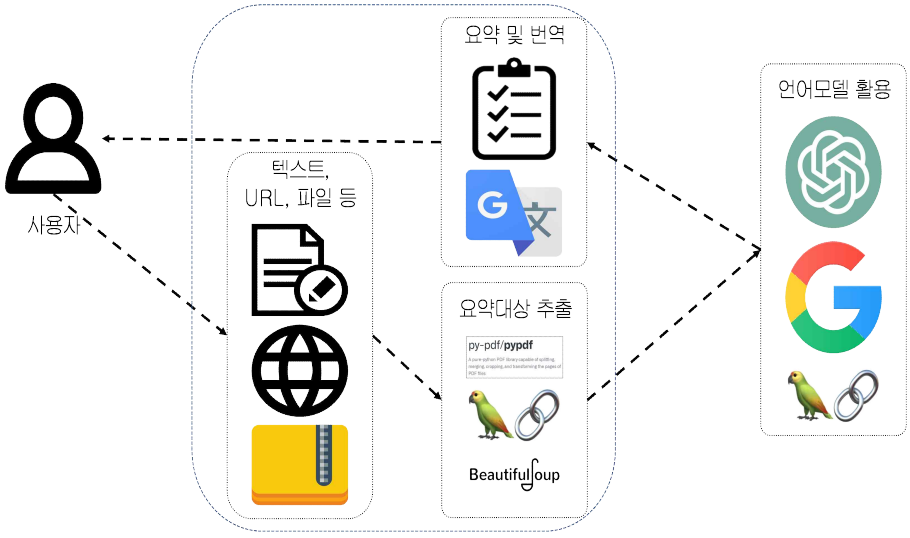


그림 34 방울이봇.S 모델 스키마

제 5 장 결론

본 연구는 물산업 기술정보 분석에서 거대언어모델과 자연어처리 기술을 활용하여 텍스트 데이터를 중심으로 한 분석의 효과성과 활용성을 검토하고, 물산업 및 물관리 기관의 내부 업무와 관련된 다양한 분야에서 자연어처리 기술을 적용한 결과를 제시하였다. 첫 번째로 주요 분석 대상을 K-water에서 기 수행한 연구과제의 초록 데이터 및 IP5 국가(한국, 중국, 일본, 미국, 유럽)의 물산업 관련 특허 데이터(Y02A-0020)로 하였으며, 데이터의 수집 및 전처리를 수행한 후 LDA 기반 토픽 모델링, KeyBERT 알고리즘, 네트워크 분석 등을 통해 국가별 기술 동향과 세부 기술 영역을 구조화하여 국가별 특화 분야를 도출하여 제시하고자 하였다. 이 과정에서 생성형 AI를 활용하여 주요 물산업 주제 영역과 라벨링 키워드와의 연관성을 검토하고 각각의 주제영역에 적합하게 매핑하는 방법을 병행하여 활용하였다. 이를 바탕으로 물산업과 관련된 글로벌 기술 현황에 따른 국가별의 기술 집중도에 대한 평가 및 K-water와 같은 기관에서 중점으로 추진중인 전략방향 및 연구개발의 방향성을 검토하는 경우에 있어서 상호비교 평가 등에 관한 역량 제고 등의 기여도가 있을 것으로 판단된다.

다음으로 본 연구에서 검토되고 개발된 자연어처리 기반의 다양한 기법을 활용한 업무용 솔루션을 구현하여 실용적 가치 제고를 도모하고자 하였다. 생성형 모델을 기반으로 하는 물산업 관련 문헌정보 및 기술정보 요약기를 구현하였고, 자연어처리 분류 기법을 적용하여 기관 내의 윤리 위험 분석 모델과 AI 기반 양정 가이드라인 고도화 기술을 개발, 시스템 구현까지 수행하였다. 부가적으로는 외부 개방이 가능한 정보만을 기반으로 하는 감사 관련 규정 질의응답 챗봇 시스템도 시범 구축하였다. 윤리 위험 분석 및 양정 가이드라인 고도화의 경우 분류기 적용을 위해서 1D-CNN과 트랜스포머 기반의 BERT모델을 병행하여 활용하고 비교하였는데, 본 연구에서 사용된 자료를 기반으로 할 때, 예측값으로 출력되는 라벨의 상위 2건이 실제 값을 추론하였는지를 평가기준으로 설정한 경우, 1-CNN이 약 92%, BERT의 경우 약 94~96% 수준으로 나타났다.

본 연구는 거대언어모델과 자연어처리 기술을 활용하여 물산업 기술정보 분석과 함께, 연구개발, 경영 지원, 기관 내 활용 가능성 등의 다양한 영역에서 데이터 기반 업무 프로세스의 개선 가능성을 살펴보고 일부 실증하는 등에서 의의가 있다. 그럼에도 불구하고, 수행기간 동안의 데이터 수집 범위가 K-water의 내부 연구와 일부 특허 및 외부 연구자료로 한정되었다는 측면은 존재한다. 또한, 기존 토픽 모델링 기법인 LDA를 활용하였으나, 문맥적 정보를 보다 충분히 반영할 수 있는 기법을 적용할 수 있도록 다양한 심층 분석을 위한 향후 연구의 지속 필요성이 있다. 따라서, 본 연구과제의 성과를 기반으로 추가적인 논문 데이터 수집 및 출원 정보와 인용 특허 등 메타 정보 등을 보다 심층적 활용하여 데이터의 신뢰도를 보완할 필요성이 있다. 아울러서 Dynamic LDA 및 BERTopic과 같은 고도화된 자연어처리 분석 기법의 적용 등을 도모하여 시기별 흐름에 따른 기술 변화 분석 및 유망기술 발굴, 기술 로드맵 제시 등 연구결과의 적용 및 확장이 가능할 것으로 기대된다.

APPENDIX

1. 프로그램 저작권

○ 딥러닝 기반 감사문서 분류 프로그램



제 C-2023-057926 호

저작권 등록증

1. 저작물의 제호(명칭)	딥러닝 기반 감사문서 분류 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>시스템프로그램>언어처리>자연어처리 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	184171-0000052
5. 창작연월일	2023년11월01일
6. 공표연월일	2023년11월06일
7. 등록연월일	2023년12월07일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2023.11.01

『저작권법』 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2023년 12월 15일

한국저작권위원회

○ 방울이봇.C(사규·심리상담 AI(인공지능) 챗봇) 프로그램



제 C-2023-060146 호

저작권 등록증

1. 저작물의 제호(명칭)	방울이봇.C(사규 · 심리상담 AI(인공지능) 챗봇) 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>시스템프로그램>언어처리>자연어처리 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	164171-0000052
5. 창작연월일	2023년10월25일
6. 공표연월일	2023년11월06일
7. 등록연월일	2023년12월14일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2023.10.25

『저작권법』 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2023년 12월 15일

한국저작권위원회

○ 방울이봇.S(AI(인공지능) 문서요약) 프로그램



제 C-2023-057927 호

저작권 등록증

1. 저작물의 제호(명칭)	방울이봇.S(AI(인공지능) 문서요약) 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>시스템프로그램>언어처리>자연어처리 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	164171-0000052
5. 창작연월일	2023년10월25일
6. 공표연월일	2023년11월06일
7. 등록연월일	2023년12월07일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2023.10.25

「저작권법」 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2023년 12월 15일

한국저작권위원회

○ 거대언어모델 기반 방울이봇.A(감사규정 AI 챗봇) 프로그램

제 C-2024-050101 호

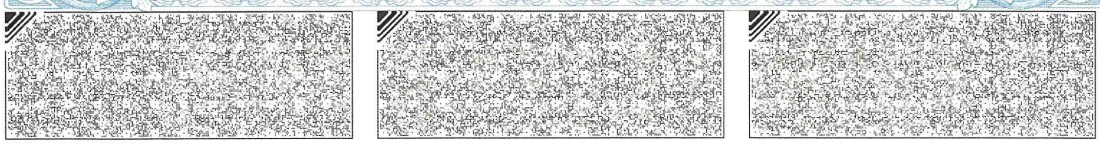
저작권 등록증

1. 저작물의 제호(명칭)	거대언어모델 기반 방울이봇.A(감사규정 AI챗봇) 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>시스템프로그램>언어처리>자연어처리 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	164171-0000052
5. 창작연월일	2024년11월19일
6. 공표연월일	2024년11월20일
7. 등록연월일	2024년12월03일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2024.11.19, 공표 : 2024.11.20

『저작권법』 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2024년 12월 04일

한국저작권위원회



○ 인공지능 기반 위험영역 예측분류 프로그램

제 C-2024-050100 호

저작권 등록증

1. 저작물의 제호(명칭)	인공지능 기반 위험영역 예측분류 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>응용프로그램>과학기술>시뮬레이션 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	164171-0000052
5. 창작연월일	2024년11월19일
6. 공표연월일	2024년11월20일
7. 등록연월일	2024년12월03일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2024.11.19, 공표 : 2024.11.20

「저작권법」 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2024년 12월 04일

한국저작권위원회

참 고 문 헌

1. Blei, David M., Andrew Y. Ng, and Michael I. Jordan. "Latent dirichlet allocation." Journal of machine Learning research 3.Jan (2003): 993-1022.

2. Chauhan, Uttam, and Apurva Shah. "Topic modeling using latent Dirichlet allocation: A survey." ACM Computing Surveys (CSUR) 54.7 (2021): 1-35.

3. Wang, Chen, and Qigan Shao. "LDA-BASED COSMETIC SATISFACTION FACTORS MINING." Proceedings of the 7th International Conference on Information Systems Engineering. 2022.

4. Yiran, Ye, and Sangeet Srivastava. "Aspect-based Sentiment Analysis on mobile phone reviews with LDA." Proceedings of the 2019 4th International Conference on Machine Learning Technologies. 2019.

5. Deng, Guohua, Yixuan Shen, and Chang Xu. "Research on the Topic Evolution of Digital Economy Based on LDA." Proceedings of the 5th International Conference on Information Management and Management Science. 2022.

6. Joo, Kyungwon, Mina Lee, and Gooyong Lee. "Technology originality and convergence analysis in the wind power field using patents." Energies 15.9 (2022): 3316.

7. Zhu, Dandan, et al. "Intuitive topic discovery by incorporating word-pair's connection into LDA." 2012 IEEE/WIC/ACM International Conferences on Web Intelligence and Intelligent Agent Technology. Vol. 1. IEEE, 2012.

8. Nadim, Mohammad, David Akopian, and Adolfo Matamoros. "A Comparative Assessment of Unsupervised Keyword Extraction Tools." IEEE Access (2023).

9. Prachi, Noshin Nirvana, et al. "Detection of Fake News Using Machine Learning and Natural Language Processing Algorithms [J]." Journal of Advances in Information Technology 13.6 (2022).

10. Park, Doohong, Donggoo Kang, and Joonki Paik. "Defense Issue Analysis Using BERT and LDA Topic Modeling: Focused on Defense Innovation 4.0." 2024 International Conference on Electronics, Information, and Communication (ICEIC). IEEE, 2024.

11. Park, Ja-Hyun, and Min Song. "A study on the research trends in library & information science in Korea using topic modeling." Journal of the Korean society for information management 30.1 (2013): 7-32.

12. Choi, Dong-In, and Chungsoo Lim. "Analysis of trends in deep learning and reinforcement learning." Journal of The Korea Society of Computer and Information 28.10 (2023): 55-65.

13. Voss, Julia, and David J. Simmons. "Technology-Assisted Review Makes Main

Street." Litig. News 43 (2017): 2.

14. Hezam, Yaseen AA, Lilian Anthonysamy, and Susela Devi K. Suppiah. "Big data analytics and auditing: A review and synthesis of literature." Emerging Science Journal 7.2 (2023): 629-642.

15. Hosaka, Tadaaki. "Bankruptcy prediction using imaged financial ratios and convolutional neural networks." Expert systems with applications 117 (2019): 287-299.

16. Xiang, Rui, Weibo Li, and Hua Yan. "Research on BERT-Based Audit Entity Extraction Method." 2021 4th International Conference on Robotics, Control and Automation Engineering (RCAE). IEEE, 2021.

17. Al-Haider, Malak Fahad, et al. "Classification of Obsessive-Compulsive Disorder Symptoms in Arabic Tweets Using Machine Learning and Word Embedding Techniques." Journal of Advances in Information Technology 15.7 (2024).

18. Zamsuri, Ahmad, Sarjon Defit, and Gunadi Widi Nurcahyo. "Development and Comparison of Multiple Emotion Classification Models in Indonesia Text Using Machine Learning." Journal of Advances in Information Technology 15.4 (2024).

19. Mikolov, Tomas. "Efficient estimation of word representations in vector space." arXiv preprint arXiv:1301.3781 3781 (2013).

20. Devlin, Jacob. "Bert: Pre-training of deep bidirectional transformers for language understanding." arXiv preprint arXiv:1810.04805 (2018).

21. Rakhlin, A. "Convolutional neural networks for sentence classification." GitHub 6 (2016): 25.

22. Soni, Sanskar, Satyendra Singh Chouhan, and Santosh Singh Rathore. "TextConvoNet: A convolutional neural network based architecture for text classification." Applied Intelligence 53.11 (2023): 14249-14268.

23. Vaswani, A. "Attention is all you need." Advances in Neural Information Processing Systems (2017).

24. 김지현, 이지현 "토픽 모델링(Topic Modeling)을 활용한 한국어 듣기 교육 연구 동향 분석" 외국어로서의 한국어교육 66 pp.47-67 (2022) : 47.

25. 김도희, 이상재, 조수현, 박세길, 배혜림 "해양사고 데이터 기반 해역 그리드화 및 심각도 지표 도출 연구" 한국전자거래학회지 29.1 pp.57-72 (2024) : 57.

26. 김승래. "AI 시대 리걸테크의 발전과 미래 법률시장의 변화 모색." 법이론실무연구 8.3 (2020): 85-128.

27. 김병필. "재판 예측 인공지능 기술의 현황과 한계." 저스티스 182-2 (2021): 89-117.

28. 송현호, and 김민한. "공공감사 디지털화에 대한 담론 연구: 전문가의 인식과 태도를 중심으로." 한국공공관리학보 37.2 (2023): 209-233.

29. 한영우, 서보성, 이수원 "인공지능 기법을 활용한 공직기강 감찰활동 효과성 향상에 관한 연구" 감사논집 35 pp.101-121 (2020) : 101.

30. 이상우, 권정혁, 김남, 최형도, 김의직 "전자파 인체영향 연구논문에 대한 연구형태 자동분류 연구" 한국전자파학회 논문지 31.10 pp.839-842 (2020) : 839.

31. 김성훈, 김승천 "특허문서의 상세한 설명을 이용한 특허 자동분류에 1D-Convolutional Layer를 적용한 모델의 성능비교" 전자공학회논문지 59.1 pp.21-28 (2022) : 21.

32. https://github.com/google-research/bert?tab=readme-ov-file

참 여 연 구 원 현 황

연구원	참 여 내 역	비 고
김성훈	○ 연구업무총괄 (연구책임자) ○ 참여분야 : 물산업 기술정보 분석 알고리즘, 경영지원, 솔루션 등 총괄 ○ 참여내역 - 3장 기술정보 분석 총괄 - 4장 인공지능 언어모델 기반 솔루션 개발 적용 총괄	- '23.8 ~ '24.12 - K-water연구원 AI연구센터 - 042-870-7332
정희진	○ 연구업무 (연구참여자) ○ 참여분야 : 자연어처리, 거대언어모델 솔루션 서비스 연구 ○ 참여내역 - 2장 이론 및 문헌 연구 - 3장 기술정보 분석 참여 - 4장 인공지능 언어모델 기반 솔루션 개발 적용 참여	- '23.8 ~ '24.12 - K-water연구원 AI연구센터 - 042-870-7683
김세훈	○ 연구업무 (연구참여자) ○ 참여분야 : 자연어처리, 거대언어모델 솔루션 서비스 연구 ○ 참여내역 - 2장 이론 및 문헌 연구 - 4장 인공지능 언어모델 기반 솔루션 개발 적용 플랫폼 개발 등	- '23.8 ~ '24.12 - K-water연구원 AI연구센터 - 042-870-7335
이소령	○ 연구업무 (실무, 연구참여자) ○ 참여분야 : 언어모델 적용 및 솔루션 개발 ○ 참여내역 - 2장 이론 및 문헌 연구 - 4장 인공지능 언어모델 기반 솔루션 개발	- '23.8 ~ '24.12 - K-water연구원 AI연구센터 - 042-870-7341
이승한	○ 연구업무 (연구참여자) ○ 참여분야 : 물산업 기술정보 분석 ○ 참여내역 - 2장 이론 및 문헌 연구 - 3장 기술정보 분석	- '23.8 ~ '24.12 - K-water연구원 AI연구센터 - 042-870-7345

서 지 자 료

(1) 기술분류	(2) 수행방법	(3) 제출일
소프트웨어 인공지능	자체	2024. 12. 31

(4) 제목/부제	(5) 연구기간
거대언어모델 및 자연어처리를 활용한 물산업 기술정보 분석	2023.08.01. - 2024.12.31.
(6) 연구수행부서	**(7) 연구수행자(소속)**
한국수자원공사, K-water연구원 연구관리처	김 성 훈
(8) 수행부서 주소	**(9) 연구의뢰기관**
대전광역시 유성구 유성대로 1689번길 125	

(10) 초록

본 연구는 거대언어모델과 자연어처리(NLP) 기술을 활용해 물산업 기술정보를 체계적으로 수집, 분석, 활용할 수 있는 프로세스를 구축하는 것을 목적으로 한다. 연구 초록과 특허 데이터를 전처리하고, LDA 기반 토픽모델링, KeyBERT 및 네트워크 분석을 통해 국가별 물산업 기술 동향과 세부 기술 영역을 도출하였다. 이를 통해 글로벌 경쟁력 강화를 위한 전략적 연구개발 방향성을 제시하고, 기술 간 연관성과 발전 트렌드를 시각화하였다.

또한, 딥러닝 기반 윤리 위험 분석 모델, AI 기반 양정 가이드라인, 방울이봇 등 실무에 적용 가능한 프로토타입을 개발하여 연구 결과가 의사결정 및 업무에 기여하도록 하였다. 이를 통해 K-water의 데이터 기반 의사결정 및 업무의 효율을 높이고, 향후 NLP 기술 활용 가능성을 확대하여 다양한 부서에서의 디지털 전환에 기여하고자 한다.

(11) 키워드

거대언어모델, 자연어처리, 토픽모델링, KeyBERT, 물산업 기술정보

(12) #태그

(13) 공개여부	(14) 총면수
예	82 페이지

BIBLIOGRAPHIC DATA SHEET

(1) Classification of Technology	(2) Research Method	(3) Submission Date
Software Artificial Intelligence	Self-execution	Dec. 31, 2024

(4) Title/Subtitle	(5) Research Period
Analysis of Water Industry Technological Information using Large Language Models and Natural Language Processing	Aug. 1, 2023 ~ Dec. 31, 2024
(6) Performing Organizatio	**(7) Author(s)**
R&D Management Dept., KIWE, K-water	Sunghoon, Kim
(8) Performing Organization Address	**(9) Sponsoring Agency**
125, Yuseong-daero 1689, Yuseong-gu, Daejeon, Republic of Korea	

(10) Abstracts

This study aims to establish a systematic process for collecting, analyzing, and utilizing technological information in the water industry by leveraging large language models and natural language processing (NLP) technologies. The study involved preprocessing research abstracts and patent data, conducting topic modeling using LDA, applying KeyBERT for keyword extraction, and performing network analysis to map national-level water industry technology integration and sub-technology domains. These analysis provided insights for strategic R&D directions to enhance global competitiveness and identify interdisciplinary connections and emerging trends.

Additionally, deep learning-based risk analysis models, AI-based text generation guidelines, and regulatory chatbots were developed as practical prototypes to enhance decision-making and workflow efficiency. These contributions improved K-water's data-driven decision-making processes and operational effectiveness. Furthermore, by expanding the applicability of NLP technologies, this research aims to support the digital transformation of various departments in the future.

(11) Keyword

Large Language Models, Natural Language Processing, Topic Modeling, KeyBERT, Water Industry Technological Information

(12) # Tag

(13) Security	(14) No. of Pages
Yes	82 pages

주의사항

본 보고서의 저작권은 한국수자원공사에 있으므로, 본 자료의 내용을 허가없이 인용, 복사, 전재, 재배포를 할 경우 법적 제재를 받을 수 있습니다.

Copyright ⓒ 2024

by

Korea Water Resources Corporation

발행인 : 한국수자원공사 사장 윤석대

발행일 : 2024. 12. 31

발행처 : 한국수자원공사 K-water연구원

대전광역시 유성구 유성대로 1689번길 125

Tel. (042) 870-7332

한국수자원공사는 친환경 기업윤리 이념을 구현하기 위하여 2000. 12. 00『**환경경영**』을 선포하고, 모든 보고서 발간에 『**재생용지 및 무코팅 방식**』을 사용하고 있습니다.