K-water연구원
2026-WR-RR-21-107
G240159
Final Report

수리특성을 고려한 자료기반 인공지능 녹조·수질 예측모형 개발

Development of an Algal Blooms Prediction Model via Data-driven AI Technique considering Hydraulic Characteristics

2025. 12

수리특성을 고려한 자료기반 인공지능 녹조·수질 예측모형 개발

KOREA
WATER RESOURCES
CORPORATION

K water 한국수자원공사

K water 한국수자원공사

수리특성을 고려한 자료기반 인공지능 녹조·수질 예측모형 개발

Development of an Algal Blooms Prediction Model via Data-driven AI Technique considering Hydraulic Characteristics

2025. 12

K water 한국수자원공사

제　　출　　문

사 장　귀하

이 보고서를 2025년도 K-water연구원 연구관리처에서 수행한 “수리특성을 고려한 자료기반 인공지능 녹조·수질 예측 모형 개발”의 최종 연구보고서로 제출합니다.

2025. 12.

연구책임자 :	K-water연구원	수석위원	이 충 성
연구수행자 :	K-water연구원	수석위원	김 성 훈
	K-water연구원	수석위원	정 지 영
	K-water연구원	선임연구원	류 제 완
	K-water연구원	위촉연구원	이 준 행
겸직연구원 :	물환경계획처	책임위원	이 승 재
	물환경관리처	책임위원	윤 석 제

연구개발결과 활용보고서

<table>
<tr><td rowspan="15">1. 연구 총괄</td><td colspan="2">[간행물 관리번호: 2026-WR-RR-21-107]</td><td colspan="3">[과제번호: G240159]</td></tr>
<tr><td>(1)연구과제명</td><td colspan="4">수리특성을 고려한 자료기반 인공지능 녹조·수질 예측 모형 개발</td></tr>
<tr><td rowspan="4">(2)수행부서</td><td rowspan="4">연구관리처</td><td rowspan="4">(3)연구책임자</td><td>성명</td><td>이 충 성</td></tr>
<tr><td>소속</td><td>연구관리처</td></tr>
<tr><td>전화번호</td><td rowspan="2"></td></tr>
<tr><td>E-mail</td></tr>
<tr><td>(4)연 구 기 간</td><td>2024. 2 . ~ 2025. 12
(총 23개월)</td><td rowspan="3">(5)총연구개발비
(천원)</td><td>총액</td><td>85,231천원</td></tr>
<tr><td>(6)협 동 기 관</td><td>-</td><td>정부</td><td>-</td></tr>
<tr><td>(7)참 여 기 업</td><td>-</td><td>기업</td><td>-</td></tr>
<tr><td>(8)기 술 분 야</td><td>-</td><td>(9)참여 연구원</td><td colspan="2">6명</td></tr>
<tr><td colspan="5">(10)연구개발목표</td></tr>
<tr><td colspan="5">○ 자료 가용성, 활용 목적 등 현장 특성을 반영한 AI 녹조 예측 모델의 분석·개발 표준안(SOP) 마련
- 다양한 영향 인자를 고려한 녹조 예측 및 영향평가 AI 알고리즘 제안</td></tr>
<tr><td colspan="5">(11)주요연구내용</td></tr>
<tr><td colspan="5">○ 전처리 및 EDA SOP 개발
- 전처리 SOP : 이상값 탐지(anomaly detection) 및 결측값 대체(missing data imputation) 성능평가 및 최적 기법 추천 Framework 개발
- EDA SOP : 일변량 분석(uni-variate analysis), 다변량 분석(multi-variate analysis)을 통한 개별 변수 특성 및 변수 간 관계 파악
○ 변수선택 SOP 개발
- 시계열분석에 따른 최적 변수선택 Framework 개발로 AI 모델 경량화, 성능 향상 등 효율화 추구
○ 데이터 증강(Data Augmentation) 기법 적용
- 희소한 녹조사상(1,000~10,000셀/mL 이상)을 AI 알고리즘을 활용해 과표집(over sampling) 하여 불균형 해소, 모델 학습 능력 향상
* SMOGN(SMOTE with Gaussian Noise), GAN(Generative Adversarial Networks), Time GAN 비교·검토
○ 녹조 예측을 위한 적정 AI 알고리즘 선정
- 학습데이터 부족에도 유연한 앙상블 기법인 Decision Tree 적용, 지연변수 (Lagged variable) 및 차분변수(Differenced variable) 설정으로 시·공간적 의존성 반영
* Random Forest, GBM, XGBoost 모델 적용
○ AI 녹조예측 모델 구축 및 적용
- (학습자료) 조류경보제, 국가수질측정망, K-water 댐 운영자료, 기상청 기상자료 등 27개 항목에 대한 관측지점별 자료 수집
- (적용대상) 대청댐, 주암댐</td></tr>
</table>

2. 연구성과 활용 유형 및 주요 연구성과

(12) 연구결과의 활용

구분	기술실용화				교육 및 지도	정책활용	설계기준, 시방서, 지침에 활용	기타
	실용화 완료	실용화 추진중	실용화 보류(중단)	선행 연구				
		○						

(13) 주요 연구성과 및 기술 개발단계

○기 술 명	◦기술의 완성도
- (자료분석) 현장 맞춤형 학습데이터셋(site specific training datasets) 구축으로 AI 모델 최적화 - (자료보완) 희소한 고농도 녹조사상을 효과적으로 증강해 학습력 향상 - (AI 녹조예측) 녹조·수질예측에 적합한 AI 알고리즘 검토 및 모바일 웹서비스를 위한 플랫폼(Streamlit) 개발	기초, 탐색연구단계 ( ), 응용연구단계 ( ), 개발연구단계 (○) 기업화 준비단계 ( ), 상품화 완료단계 ( ) ◦기술 수명주기 기술개념 정립기 ( ), 기술 실험기 ( ) 기술적용 시작기 ( ), 기술적용 성장기 (○) 기술적용 성숙기 ( ), 기술적용 쇠퇴기 ( )

3. 경제적 효과

(14) 현장적용실적

① 공사현장 정보	공사명	공사기간	물량 (총물량)	발주기관	시공기관	R&D 참여자 역할

② 공사 현장별 적용효과

가. 현장명

구분	기 존 (A)	개 선 (B)	단위효과 (C=A-B)	현장 총물량 (D)	향상도 $(\frac{A-B}{A}X100)$	적용현장 총효과 (C×D)
공사비 (백만원/㎡)[1]						
유지관리비 (백만원/㎡)[1]						
기타비용절감 (백만원/㎡)[1]						
사고율 (명/UC)						
고 용 (명/UC)						
공 기 (일/UC)						
내구성 (年)						

4. 기술적 효과

(15) 기술개발목표 달성도

구분	지표명 (단위)	개발전 국내수준	당개발사업 최종목표치	개발결과 실제달성치	현재국내 기술수준	세계 최고 기술수준
기술 성능 지표						

(16) 산업재산권 (발명특허·실용신안·의장·s/w)

구분	명칭	출원국	출원 및 등록자	출원		등록	
				출원일	출원번호	등록일	등록번호
S/W	AI 녹조예측을 위한 EDA SOP 프로그램	국내	이충성 이준행 류제완 김성훈 정지영			2025.11.27	C-2025-053068
S/W	녹조예측 데이터 오버샘플링 프로그램	국내				2025.11.27	C-2025-053067

(17) 건설신기술 지정

명 칭	출 원 일	고 시 일	보호기간	지정번호

(18) 기타 등록 및 지정현황(상품, 서비스 등록, KT 마크 등)

명 칭	출 원 일	고 시 일	보호기간	기 타

5. 학술적 효과

(19) 국내외 전문학술지 게재

구분	논문제목	학술지명	국명	통권, 호	년,월
일반 학술지	A Study on the Comparison for Deep-learning based Imputations for Green Algae and Water Quality Data	위기관리 이론과 실천	한국	제21권 제2호	2025.2
	Impact of Oversampling on the Predictive Performance of Machine Learning Models: Empirical Analysis of Algal Bloom Prediction	한국수자원학회 논문집	한국	제59권 제2호 (게재예정)	2026.2

(20) 학술회의 발표

논문제목	학술회의 명칭	국 명	연 도 · 호
수치모델 기반 AI 하이브리드 하구 수리해석 기법 연구	한국수자원학회 학술발표회	한국	2024년 5월
정수공정에서의 AI 기반 소독부산물(THMs) 예측 모델 개발	대한토목학회 학술발표회	한국	2024년 10월
저수지 녹조관련 시계열자료에 대한 이상 탐지 기법 비교 분석	한국수자원학회 학술발표회	한국	2025년 5월
녹조 및 수질 시계열 자료의 결측치 대체 기법 성능 비교	한국수자원학회 학술발표회	한국	2025년 5월
머신러닝 기반 녹조 예측을 위한 데이터 증강 기법 분석 및 적용 전략	한국습지학회 학술발표회	한국	2025년 8월

6. 공공적 효과

(21) 법.제도 (설계기준, 시방서, 지침) 등에 활용

구분	명칭 및 조항[1)]	시행일시	기 존 내 용	신 규 내 용
법				
규정/지침				
기준				
시방서				

(22) 정책수립에 활용

정책명	정책추진 실적	정책추진 일시	담당부처.팀	기대효과

(23) 교육 및 지도에 활용

구분	교육명	교육내용	교육대상	교육시간	교육인원	교육회수
교육훈련						
기술상담						
현장기술지도						

(24) 사회적 성과

요 약 문

1. 연구제목

수리특성을 고려한 자료기반 인공지능 녹조·수질 예측 모형 개발

2. 연구기간

2024. 2. 1 ~ 2025. 12. 31

3. 연구목적

○ 자료 가용성, 활용 목적 등 현장 특성을 반영한 AI 녹조 예측 모델의 분석·개발 표준안(SOP) 마련

- 다양한 영향 인자를 고려한 녹조 예측 및 영향평가 AI 알고리즘 제안

4. 연구내용

핵심내용 : 자료분석 SOP → 자료보완 기법 → AI 예측모델 구축

가. 자료분석 SOP

○ 현장 맞춤형 학습데이터셋(site specific training datasets) 구축으로 AI 모델 최적화

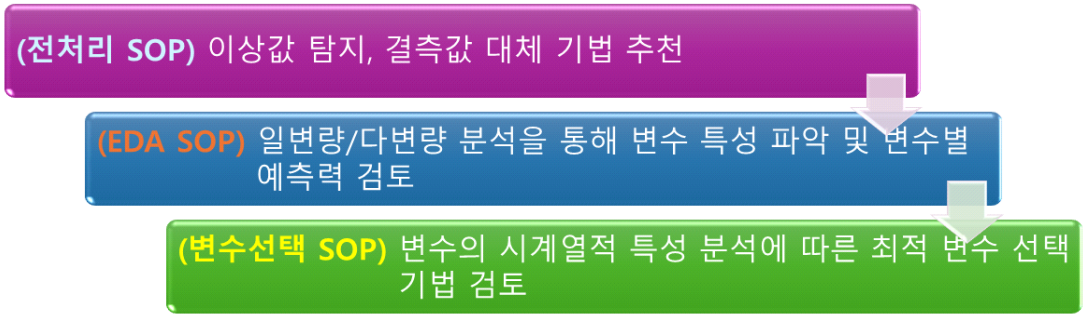

나. 자료보완 기법

○ 희소한 고농도 녹조사상을 효과적으로 증강해 학습력 향상

※ Resampling, SMOTE, T-SMOTE, Generative Adversarial Network(GAN)

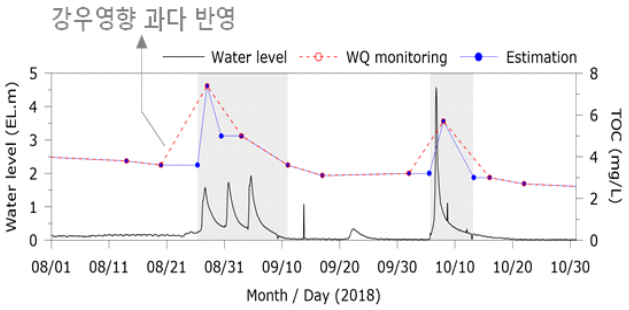

【시간해상도 불일치(7일 간격 수질자료)】

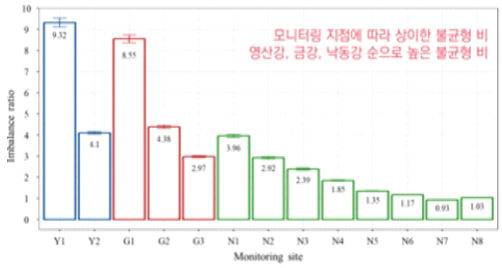

✓ 자료 불균형 발생 시 수질 사고, 녹조발생 등 소수 계급에 대한 예측 성능 감소 → 모델의 활용도 감소

* 차윤경(2024). K-water 녹조관리 세미나

다. AI 예측모델 구축

○ 녹조·수질예측에 적합한 AI 알고리즘 검토

- 수질·녹조 자료의 낮은 시간해상도, 자료 불균형 고려, 의사결정나무 기반 모델 선정 (Random Forest, GBM, XGBoost 등)

5. 연구결과

가. 전처리 및 EDA SOP 개발

○ 전처리 SOP : 이상값 탐지(anomaly detection) 및 결측값 대체(missing data imputation) 성능평가 및 최적 기법 추천 Framework 개발

○ EDA SOP : 일변량 분석(uni-variate analysis), 다변량 분석(multi-variate analysis)을 통한 개별 변수 특성 및 변수 간 관계 파악

나. 변수선택 SOP 개발

○ 시계열분석에 따른 최적 변수선택 Framework 개발로 AI 모델 경량화, 성능 향상 등 효율화 추구

다. 데이터 증강(Data Augmentation) 기법 적용

○ 희소한 녹조사상(1,000~10,000셀/mL 이상)을 AI 알고리즘을 활용해 과표집(over sampling) 하여 불균형 해소, 모델 학습 능력 향상

* SMOGN(SMOTE with Gaussian Noise), GAN(Generative Adversarial Networks), Time GAN 비교·검토

라. 녹조 예측을 위한 적정 AI 알고리즘 선정

○ 학습데이터 부족에도 유연한 앙상블 기법인 Decision Tree 적용, 지연변수 (Lagged variable) 및 차분변수(Differenced variable) 설정으로 시·공간적 의존성 반영

* Random Forest, GBM, XGBoost 모델 적용

마. AI 녹조예측 모델 구축 및 적용

○ (학습자료) 조류경보제, 국가수질측정망, K-water 댐 운영자료, 기상청 기상자료 등 27개 항목에 대한 관측지점별 자료 수집

* (적용대상) 대청댐, 주암댐

S U M M A R Y

1. Project Title/Subtitle

Development of an algal blooms prediction model via data-driven AI technique considering hydraulic characteristics

2. Research Period

2024. 2. 1 ~ 2025. 12. 31

3. Objective of Research

○ Development of a Standard Operating Procedure (SOP) for the analysis and development of AI-based algal bloom prediction models that reflect field characteristics such as data availability and application objectives

- Proposal of AI algorithms for algal-bloom prediction and impact assessment that account for diverse influencing factors

4. Research Result

A. Development of Preprocessing and EDA SOPs

○ Preprocessing SOP: Development of a framework for performance evaluation and optimal-method recommendation for anomaly detection and missing-data imputation

○ EDA SOP: Identification of individual variable characteristics and inter-variable relationships through univariate and multivariate analyses

B. Development of a Variable-Selection SOP

○ Pursuit of efficiency—such as AI-model simplification and performance improvement—through the development of an optimal variable-selection framework based on time-series analysis

C. Application of Data-Augmentation Techniques

- ○ Mitigation of data imbalance and improvement of model learning capability by oversampling sparse algal-bloom events (≥1,000–10,000 cells/mL) using AI algorithms
  - * Comparative review of SMOGN(SMOTE with Gaussian Noise), GAN(Generative Adversarial Networks), and TimeGAN

D. Selection of Appropriate AI Algorithms for Algal-Bloom Prediction

- ○ Application of decision-tree-based ensemble methods, which are robust even with limited training data, and incorporation of temporal–spatial dependence through lagged and differenced variables
  - * Application of Random Forest, GBM, and XGBoost models

E. Development and Application of the AI Algal-Bloom Prediction Model

- ○ Training data: Compilation of site-specific datasets for 27 variables from the Algal Bloom Alert System, National Water-Quality Monitoring Network, K-water dam-operation data, and Korea Meteorological Administration weather data
  - * Application sites: Daecheong Dam, Juam Dam, and Paldang Dam

C O N T E N T S

Preface ····· i
Summary ····· xi
Table of Contents ····· xiii

Chapter 1 Introduction ····· 1

1.1 Research Background and Necessity ····· 1

1.2 Research Goals and Content ····· 2

Chapter 2: Development of Data Preprocessing Standard Operating Procedures (SOP) ····· 5

2.1 General Data Review ····· 5

2.2 Anomaly Detection ····· 8

2.2.1 Anomaly Detection Algorithms ····· 8

2.2.2 Performance Evaluation of Anomaly Detection Algorithms ····· 18

2.3 Missing Value Imputation ····· 41

2.3.1 Mechanisms of Missing Values and Processing Methods ····· 41

2.3.2 Deep Learning-Based Missing Value Imputation Algorithms ····· 45

2.3.3 Performance Evaluation of Missing Value Imputation Algorithms ····· 50

Chapter 3: Development of Exploratory Data Analysis (EDA) Standard Operating Procedures (SOP) ····· 61

3.1 Overview of EDA ····· 62

3.2 Uni-variate Analysis ····· 66

3.2.1 Uni-variate Non Graphic ····· 66

3.2.2 Uni-variate Graphic ····· 72

3.3 Multi-variate Analysis ····· 79

3.3.1 Correlation and Causality ····· 79

3.3.2 Multi-variate Non-Graphic ····· 80

3.3.3 Multi-variate Graphic ····· 89

Chapter 4: Development of Feature Selection SOP ····· 95

4.1 Feature Selection Methodologies ····· 95

4.1.1 Filter-Based Selection ····· 95

4.1.2 Wrapper-Based Selection ····· 96

4.1.3 Embedded Selection ····· 97

4.1.4 Dimensionality Reduction ····· 99

4.1.5 Model-Based Selection ····· 105

4.2 Time Series Preprocessing ····· 112

4.2.1 Stationarity Diagnosis ····· 112

4.2.2 Stationarity Transformation ····· 115

4.3 Development of Feature Selection Algorithm for Algae Prediction ····· 119

4.3.1 Time Series Preprocessing ····· 120

4.3.2 Removing Redundancy Between Independent Variables ····· 121

4.3.3 Correlation Analysis with Dependent Variables ····· 127

Chapter 5: Development of Optimal AI Algorithms Considering Mathematical Properties ····· 129

5.1 Review of AI Algorithms and Selection of Optimal Models ····· 129

5.1.1 Review of Various AI Algorithm Characteristics ····· 129

5.1.2 Selection of Models Suitable for Algae Prediction ····· 136

5.1.3 Limitations of Tree-Based Prediction Models and Strategies for Complementing Time Series Structure ····· 138

5.2 Data Augmentation Techniques to Address Observation Data Imbalance ····· 145

5.2.1 Background and Necessity ····· 145

5.2.2 Theoretical Background ····· 145

Chapter 6: Development and Application of Algae and Water Quality Prediction AI Models ····· 149

6.1 Characteristics, Influence, and Interaction of Algae-Causing Factors ····· 149

6.1.1 Water Quality Factors ····· 150

6.1.2 Hydrological and Meteorological Factors ····· 154

6.2 Survey and Analysis of Water Quality Data for Target Areas ····· 156

6.2.1 Survey of Data Management and Service Status by Water Management Institutions ····· 156

6.2.2 Characteristics of Algae Occurrence in Target Areas ····· 161

6.3 Construction of Algae and Water Quality Prediction Models ····· 168

6.3.1 Overview of Target Locations ····· 168

6.3.2 Data Collection ····· 169

6.3.3 Data Preprocessing ····· 170

6.3.4 EDA ····· 173

6.3.5 Model Configuration ····· 178

6.4 Results and Analysis from Daecheong Lake Application ····· 181

6.4.1 Oversampling ····· 181

6.4.2 Prediction Performance Improvement Effects ····· 182

6.4.3 Validation of Model Generalization Performance ····· 185

6.5 Results from Pilot Application to Juam Dam ····· 188

6.5.1 Results at the Juam Dam Front Location ····· 188

6.5.2 Results at the Juam Dam Sinpyeong Bridge Location ····· 190

Chapter 7: Hybrid AI Integration Based on Existing Platforms ····· 191

7.1 Overview of Hybrid Prediction Technology ····· 191

7.2 Hybrid Model Construction Strategies ····· 194

Chapter 8: Conclusion ····· 201

References ····· 203

Appendix A: Advisory Report ····· 211

A-1 Correlation Analysis Methods for Time-Series Variables Influencing Algal Blooms · 211

A-2. Explainable AI Algorithms and Application Strategies for Assessing the Predictive Power of Independent Variables Affecting Algal Blooms and Water Quality ····· 237

A-3. Causes and Mitigation Strategies for Data Imbalance in Algal Bloom and Water Quality Datasets ····· 269

A-4. Review and Recommendations for Improving AI Algorithms for Water Quality and Algal Bloom Prediction ····· 295

Appendix B: ····· 327

목 차

제 출 문 ····· i
요 약 문 ····· vii
목 차 ····· xvii
표 목 차 ····· xxi
그림목차 ····· xxiv

제 1장 서론 ····· 1

1.1 연구개발 배경 및 필요성 ····· 1

1.2 연구개발 목표 및 내용 ····· 2

제 2장 데이터 전처리 표준운영절차(SOP) 개발 ····· 5

2.1 전체적인 데이터 확인 ····· 5

2.2 이상값 탐지 (Anomaly Detection) ····· 8

2.2.1 이상 탐지 알고리즘 ····· 8

2.2.2 이상값 탐지 알고리즘 성능평가 방안 ····· 18

2.3 결측값 대체(Missing Value Imputation) ····· 41

2.3.1 결측값 발생 메커니즘 및 처리 방법 ····· 41

2.3.2 딥러닝을 활용한 결측값 대체 알고리즘 ····· 45

2.3.3 결측값 대체 알고리즘 성능평가 방안 ····· 50

제 3장 탐색적 데이터 분석(EDA) 표준운영절차(SOP) 개발 ····· 61

3.1 EDA 개요 ····· 62

3.2 일변량 분석 (Uni-variate Analysis) ····· 66

3.2.1 일변량 비시각화 (Univariate Non Graphic) ····· 66

3.2.2 일변량 시각화 (Univariate Graphic) ····· 72

3.3 다변량 분석 (Multi-variate Analysis) ····· 79
3.3.1 상관성과 인과성 ····· 79
3.3.2 다변량 비시각화 (Multi-variate Non Graphic) ····· 80
3.3.3 다변량 시각화 (Multi-variate Graphic) ····· 89

제 4장 변수 선택 표준운영절차(SOP) 개발 ····· 95

4.1 변수 선택(Feature Selection) 방법론 ····· 95
4.1.1 필터 기반(Filter-based) 선택법 ····· 95
4.1.2 래퍼 기반 (Wrapper-based) 선택법 ····· 96
4.1.3 임베디드 (Embedded) 선택법 ····· 97
4.1.4 차원 축소 (Dimensionality Reduction) ····· 99
4.1.5 모델 기반 (Model based) 선택법 ····· 105
4.2 시계열 전처리 (Time Series Preprocessing) ····· 112
4.2.1 정상성 진단 (Stationarity test) ····· 112
4.2.2 정상성 변환 (Stationarity Transformation) ····· 115
4.3 녹조 예측을 위한 변수 선택 알고리즘 개발 ····· 119
4.3.1 시계열 전처리 ····· 120
4.3.2 독립변수간 중복성 제거 ····· 121
4.3.3. 종속변수와의 상관성 분석 ····· 127

제 5장 수리특성을 고려한 적정 AI 알고리즘 개발 ····· 129

5.1 AI 알고리즘 검토 및 적정 모델 선정 ····· 129
5.1.1 다양한 AI 알고리즘 특성 검토 ····· 129
5.1.2 녹조 예측에 적합한 모델 선정 ····· 136
5.1.3 트리 기반 예측모델의 한계와 시계열 구조 보완 전략 ····· 138
5.2 관측자료 불균형 해소를 위한 데이터 증강기법 ····· 145

5.2.1 배경 및 필요성 ····· 145
5.2.2 이론적 배경 ····· 145

제 6장 녹조·수질 예측 AI 모델 개발 및 적용 ····· 149

6.1 녹조 영향인자의 특성 및 영향과 상호작용 ····· 149
6.1.1 수질 인자 ····· 150
6.1.2 수문·기상 인자 ····· 154
6.2 대상지역 수질 환경 자료 조사·분석 ····· 156
6.2.1 물관리 기관별 자료 관리 및 서비스 현황 조사 ····· 156
6.2.2 대상 지역 조류 발생 특성 ····· 161
6.3 녹조·수질 예측 모델 구축 ····· 168
6.3.1 대상지점 개요 ····· 168
6.3.2 데이터 수집 ····· 169
6.3.3 데이터 전처리 ····· 170
6.3.4 EDA ····· 173
6.3.5 모델 설정 ····· 178
6.4 대청호 적용 결과 및 분석 ····· 181
6.4.1 오버샘플링 ····· 181
6.4.2 예측성능 개선 효과 ····· 182
6.4.3 모델의 일반화 성능 검증 ····· 185
6.5 주암호 시험적용 결과 ····· 188
6.5.1 주암호 댐앞 지점 적용 결과 ····· 188
6.5.2 주암호 신평교 지점 적용 결과 ····· 190

제 7장 기존 플랫폼 기반 하이브리드 AI 연계 방안 ····· 191

7.1 하이브리드 예측 기술의 개요 ····· 191

7.2 하이브리드 모델 구축 방안 ····· 194

제 8장 결론 ····· 201

참 고 문 헌 ····· 203

부록 A 자문보고서 ····· 211

A-1 녹조 영향 시계열 변수들의 상관성 분석 기법 ····· 211

A-2. 녹조·수질 영향 독립변수들의 설명력 검정을 위한 설명가능한 AI(XAI: eXplainable AI) 기술 알고리즘 및 활용방안 제시 ····· 237

A-3. 녹조·수질 데이터 불균형 문제의 원인 및 처리방안 제시 ····· 269

A-4. 수질·녹조 예측 AI 알고리즘 개량 검토·제언 ····· 295

부록 B 추진성과 ····· 327

표 목 차

<표 2.1> 자료 형태의 분류 ····· 6

<표 2.2> 대상지역에서 수집된 저수지 녹조·수질 관련 시계열 자료 ····· 26

<표 2.3> 주단위 재표집(resampling)을 위한 변수별 대푯값 설정 기준 ····· 29

<표 2.4> 평가 방법별 성능지표 평균(28개 시계열 변수) ····· 33

<표 2.5> 시계열 자료 항목별 유형 분류 및 탐지기법 성능평가 결과 ····· 40

<표 2.6> 결측값 비율에 따른 처리 방법 ····· 43

<표 2.7> 결측값 삽입 기간 ····· 54

<표 2.8> 결측값 대체 실험의 조건 설정 ····· 55

<표 2.9> 주간단위 수질 자료에 대한 결측값 대체 알고리즘별 성능평가 결과 비교 ····· 56

<표 3.1> 단순 및 누적 빈도표 예시 ····· 71

<표 3.2> 데이터 특성과 분석 목적에 따른 시각화 방법 ····· 72

<표 3.3> 일반적으로 사용되는 커널함수 ····· 74

<표 3.4> 변수의 자료형태에 따른 다면량 분석 방법 ····· 79

<표 3.5> VIF 값의 해석 기준 ····· 84

<표 3.6> 교차빈도표 예시 (빈도기준) ····· 85

<표 3.7> 교차비율표 예시 (왼쪽: 행 기준, 오른쪽: 전체 기준) ····· 85

<표 3.8> 스피어만 상관계수 (Spearman's ρ) 활용 사례 ····· 87

<표 3.9> 켄달 상관계수 (Kendall's Tau) 활용 사례 ····· 88

<표 4.1> 주성분 분석(PCA)과 선형 판별분석(LDA)의 비교 ····· 100

<표 4.2> 오토인코더와 트랜스포머 인베딩을 활용한 비선형 차원축소 방식의 비교 ····· 105

<표 4.3> Bagging과 Boosting의 변수 중요도 산정 방식 비교 ····· 108

<표 4.4> SHAP과 LIME의 특징 비교 ····· 111

<표 4.5> Augmented Dickey-Fuller test 해석 기준 ····· 113

<표 4.6> Phillips-Perron test 해석 기준 ····· 113

<표 4.7> Kwiatkowski-Phillips-Schmidt-Shin test 해석 기준 ····· 114

<표 4.8> 변수쌍 (X, Z)에서 단순상관과 편상관 비교를 통한 변수 제거 규칙 ····· 124

<표 5.1> Lag 기반 피처엔지니어링을 통한 시공간 의존성 반영의 장점과 한계 ····· 141

<표 5.2> 외생변수 유형별 차분 적용의 적합성 및 물리적 의미 ····· 142

<표 5.3> 지연 변수와 차분 변수의 역할과 보완적 특징 ····· 143

<표 6.1> 환경부 조류경보제 개요 ····· 157

<표 6.2> 조류경보단계에 따른 남조류세포수 발령기준 ····· 157

<표 6.3> 조류경보 단계별 조치사항 ····· 158

<표 6.4> 조류측정망 수질인자 측정항목 ····· 158

<표 6.5> 조류경보제 대상 댐 중 K-water 관리 13개 댐의 총 발령일수 현황 ····· 159

<표 6.6> K-water 녹조 관련 정보 유통 및 공유체계 ····· 160

<표 6.7> 지상기상관측(종관) 개요 ····· 161

<표 6.8> 금강 수계 최근 5년간 조류경보 발령일수 ····· 162

<표 6.9> 영산강 수계 최근 5년간 조류경보 발령일수 ····· 162

<표 6.10> 원시자료 수집 목록 ····· 164

<표 6.11> 대청댐 조류경보제 및 국가수질측정망(일반) 지점 비교 ····· 165

<표 6.12> 대청댐3 일부 발췌 자료 ····· 165

<표 6.13> 대청댐 관련 지점별 자료 제원 ····· 166

<표 6.14> 주암댐 관련 지점별 자료 제원 ····· 167

<표 6.15> 수집한 관측 데이터 현황 ····· 170

<표 6.16> 오버샘플링 모델별 하이퍼파라미터 설정 ····· 179

<표 6.17> 오버샘플링 기법별 예측 성능지표 비교 ····· 184

<표 6.18> Rolling Cross-Validation 수행 결과 ····· 186

<표 7.1> 물리 기반 모델과 AI 데이터 기반 모델의 주요 특성 비교 ····· 192

<표 7.2> 하이브리드 모델 유형 비교표 ····· 196

그 림 목 차

<그림 2.1> 데이터 병합의 방법 ····· 7

<그림 2.2> Z-score 방법에 의한 이상값 판정 기준 ····· 9

<그림 2.3> 4분위수 방법에 의한 이상값 판정 기준 ····· 10

<그림 2.4> Cook Distance 방법에 의한 이상값 판정 ····· 16

<그림 2.5> DBSCAN의 군집화 개념 ····· 16

<그림 2.6> 오토인코더 기반 이상 탐지/분할의 개념 ····· 17

<그림 2.7> 이상값 탐지기법 성능평가 방법 및 절차 (대청댐 사례연구) ····· 19

<그림 2.8> 이상값(anomaly)의 개념과 유형 분류 ····· 20

<그림 2.9> 혼동행렬(confusion matrix) ····· 23

<그림 2.10> 정확도(Accuracy) 지표의 혼동행렬 ····· 24

<그림 2.11> 정밀도(Precision) 지표의 혼동행렬 ····· 24

<그림 2.12> 재현율(Recall) 지표의 혼동행렬 ····· 25

<그림 2.13> 수집된 자료의 변수별 데이터의 시간해상도 ····· 27

<그림 2.14> Z-Score에 의한 사전 이상값 필터링 결과 (TOC, 수온) ····· 28

<그림 2.15> 주단위 재표집(resampling) 결과 데이터 분포 ····· 29

<그림 2.16> k-NN에 의한 결측값 대체 결과(TOC) ····· 30

<그림 2.17> 결측값 대체 결과 데이터 분포 ····· 30

<그림 2.18> 합성 이상값 주입 및 합의 기반 평가 결과의 평균 비교 ····· 33

<그림 2.19> 결측값 처리 방법 ····· 42

<그림 2.20> LSTM의 구조 ····· 45

<그림 2.21> GRU-D 구조 ····· 46

<그림 2.22> BRITS의 결측값 처리 방식 ····· 47

<그림 2.23> NAOMI 구조 ····· 47

<그림 2.24> GAIN 모델에 의한 결측값 대체 아키텍쳐 ····· 48

<그림 2.25> 오토인코더 모델에 의한 결측값 대체 아키텍쳐 ····· 49

<그림 2.26> 연구대상 지역 (대청댐 추동지점) ····· 52

<그림 2.27> 주간 단위의 수질 항목별 시계열 자료 현황 ····· 53

<그림 2.28> 주간 단위 시계열 자료의 상자그림 ····· 53

<그림 2.29> 결측 기간에 따른 결측값 대체 모델별 성능 비교(RMSE 기준) ····· 57

<그림 2.30> 결측 기간에 따른 결측값 대체 모델별 성능 비교(MAPE 기준) ····· 58

<그림 3.1> 데이터 과학자들의 데이터 분석 단계별 소비 시간 ····· 61

<그림 3.2> 확증적 데이터 분석 과정 ····· 62

<그림 3.3> 탐색적 데이터 분석 과정 ····· 62

<그림 3.4> 데이터 분석 과정에서 EDA의 목적에 따른 분석 방법 ····· 63

<그림 3.5> EDA의 반복적 분석단계 ····· 65

<그림 3.6> 왜도(Skewness)의 개념 ····· 68

<그림 3.7> 정규분포와 동일한 분산을 갖는 분포들의 첨도(kurtosis) 비교 ····· 68

<그림 3.8> 히스토그램 시각화 ····· 72

<그림 3.9> 히스토그램과 커널밀도추정(KDE) 비교 ····· 73

<그림 3.10> Normal Q-Q 플롯의 개념 ····· 75

<그림 3.11> Q-Q 플롯을 이용한 데이터 분포 파악 ····· 75

<그림 3.12> 상자 그래프(Box Plot)의 구성 요소 ····· 76

<그림 3.13> 다양한 형태의 막대그래프 ····· 77

<그림 3.14> 원그래프(Pie Chart) 구성 요소 ····· 77

<그림 3.15> 점도표(Dot plot) ····· 78

<그림 3.16> 상관계수 값에 따른 데이터 분포 형태 ····· 81

<그림 3.17> 두 변수의 지연시간(lag)에 따른 교차상관계수 ····· 83

<그림 3.18> 연속형 변수 와 범주형 변수 ····· 89

<그림 3.19> 산점도의 다양한 활용 ····· 90

<그림 3.20> 히트맵 예시 ····· 91

<그림 3.21> 모자이크 플롯 예시 (타이타닉 생존 데이터) ····· 92

<그림 3.22> 생키 다이어그램 예시(웹사이트 방문자) ····· 93

<그림 3.23> 트리맵 예시 (주가 변동) ····· 94

<그림 4.1> 주성분 분석(PCA)의 기본 원리 ····· 99

<그림 4.2> 선형 판별분석(LDA)의 기본 원리 ····· 100

<그림 4.3> 오토인코더에 의한 비선형 차원축소 개념 ····· 102

<그림 4.4> 트랜스포머 임베딩 기반 비선형 차원 축소 모델 아키텍쳐 ····· 104

<그림 4.5> Bagging 기반 앙상블 모델에 의한 변수 기여도 산정 구조 ····· 106

<그림 4.6> Boosting 기반 앙상블 모델에 의한 변수 기여도 산정 구조 ····· 107

<그림 4.7> 대청댐 유입량 대상 자기 상관함수 분석 결과 (2000~2023) ····· 115

<그림 4.8> 녹조 예측 모델의 변수 선택 알고리즘 ····· 119

<그림 5.1> 의사결정나무의 개념도 ····· 134

<그림 5.2> 랜덤 포레스트의 개념도 ····· 135

<그림 5.3> XGBoost의 개념도 ····· 135

<그림 5.4> 지연변수 도입에 따른 시·공간적 의존성 반영 개념 ····· 139

<그림 5.5> LDV 및 LDV+차분 변수 입력 시 예측 반응의 차이 ····· 143

<그림 5.6> 녹조 예측 머신러닝 알고리즘 개선을 위한 피처엔지니어링 적용 절차 ····· 144

<그림 6.1> 호소의 부영양화와 기후 요인이 남조류 번성에 미치는 영향 ····· 149

<그림 6.2> 조류경보제 발령지점 ····· 156

<그림 6.3> 대청댐 관련 지점 위치 ····· 165

<그림 6.4> 주암댐 관련 지점 위치 ····· 166

<그림 6.5> 대상 지점 현황(대청댐) ····· 168

<그림 6.6> 대상 지점 현황(주암댐) ····· 169

<그림 6.7> 자료별 시간해상도 불일치(위)와 일주일 단위 재표집 결과(아래) (대청호 예시) 171

<그림 6.8> 이상값 처리 완료된 남조류세포수 데이터 (2005～2024, 대청호 예시) ····· 172

<그림 6.9> 결측값 대체 완료된 수온 데이터 (2005～2024, 대청호 예시) ····· 172

<그림 6.10> 전처리 완료된 남조류세포수 데이터 (2005～2024, 대청호 예시) ····· 172

<그림 6.11> 수치형 변수의 요약통계량 계산 (대청호 예시) ····· 173

<그림 6.12> 히스토그램과 Q-Q플롯, 상자그림을 이용한 DO의 일변량 시각화(대청호 예시) 175

<그림 6.13> 피어슨 상관계수로 상관행렬 및 편상관행렬 산출(대청호 예시) ····· 176

<그림 6.14> 상관행렬 히트맵(대청호 예시) ····· 177

<그림 6.15> 상관행렬 산점도(대청호 예시) ····· 177

<그림 6.16> 독립변수 간 중복성 제거에 따른 단계적 변수 선택(Greedy 방식) ····· 178

<그림 6.17> 리드타임 1주 후 오버샘플링 결과 ····· 181

<그림 6.18> 리드타임 2주 후 오버샘플링 결과 ····· 181

<그림 6.19> 리드타임 3주 후 오버샘플링 결과 ····· 182

<그림 6.20> 랜덤포레스트 모델의 예측 결과 ····· 183

<그림 6.21> 리드타임에 따른 모델 성능 ····· 184

<그림 6.22> SMOGN 적용과 미적용의 RMSE 차이 ····· 187

<그림 6.23> 주암호 댐앞 지점 학습데이터 및 훈련/시험 조건 ····· 188

<그림 6.24> 주암호 댐앞 지점 랜덤포레스트 모델 예측 결과 (1주 후 예측) ····· 189

<그림 6.25> 주암호 댐앞 지점 랜덤포레스트 모델 예측 결과 (2주 후 예측) ····· 189

<그림 6.26> 주암호 댐앞 지점 랜덤포레스트 모델 예측 결과 (3주 후 예측) ····· 189

<그림 6.27> 주암호 신평교 지점 학습데이터 및 훈련/시험 조건 ····· 190

<그림 6.28> 주암호 신평교 지점 랜덤포레스트 모델 예측 결과 (1주 후 예측) ····· 190

<그림 6.29> 주암호 신평교 지점 랜덤포레스트 모델 예측 결과 (2주 후 예측) ····· 190

<그림 6.30> 주암호 신평교 지점 랜덤포레스트 모델 예측 결과 (3주 후 예측) ····· 190

<그림 7.1> 수리안과 AI 예측모델을 통합한 하이브리드 예측 구조 예시 ····· 196

제 1장 서론

1.1 연구개발 배경 및 필요성

수질관리 분야에서는 오랫동안 기상, 지형 등의 물리적 기작을 반영한 수치모델을 통해 오염물질 거동을 예측해왔다. 그러나 최근 인공신경망 및 머신러닝 기술의 접근성이 좋아지면서 일부 물리적 과정을 대체하는 데이터 기반 단기 예측기법이 활발히 도입되고 있다. 특히 맛·냄새 유발 물질이나 신규 오염물질처럼 물리적 발생 원리가 명확하지 않은 경우에는, 관측 데이터에 근거한 AI/ML 모델이 효과적인 대안이 될 수 있음이 보고되고 있다. 한편 이러한 자료기반 모델은 입력 데이터의 수집·전처리 품질에 따라 예측성능 변화가 크지만, 아직까지 자료 품질 확보 및 모델 구축을 위한 표준화된 기준이 부재하여 예측 지점별로 다양한 기법이 임의 적용되고 있으며, 방법론 간 성능을 객관적으로 비교할 수 있는 체계도 미흡한 실정이다. 이에 따라 자료의 신뢰성을 높이고 현장 적용성을 확보하기 위한 표준적인 AI 예측모델 개발 필요성이 대두되고 있다.

녹조 발생 예측의 경우, 물리·수리적 특성이 강하게 작용하는 대표적인 사례로 꼽힌다. 예를 들어 녹조는 부력 영향으로 저수지 상층에 집중되는 경향이 있어, 밀도 성층화나 체류시간 등 수체의 수리학적 조건이 발생 양상에 영향을 미친다. 이러한 요인은 전통적인 물리 모델에서는 일부 정량화하여 고려할 수 있으나, 시계열자료에 기반한 AI 예측 모델만으로는 녹조 발생의 물리적 과정을 체계적으로 설명하고 예측하기에 한계가 있다. 최근 들어 이와 같은 수리특성을 고려하기 위해 수온, 밀도 등 추가 변수를 고려한 데이터 기반 예측기법이 연구에서 제시되고 있으나, 아직은 실험적 단계에 머물러 있으며 수리·수문, 수질, 기상 등 현장 특성 자료를 통합하여 실무 적용성을 검증할 필요가 있다는 지적이 있다.

본 연구는 K-water에서 그간 산발적으로 이루어지던 자료 기반 녹조·수질 예측기법들을 현장 데이터 가용성과 활용 목적 등 현장 특성에 따라 분류하고, 현업화에 적합한 일반화 된 AI 녹조예측 모델 개발의 표준 절차를 확립하여 현업에 적용하기 위한 정량적 기준을 마련하고자 한다. 이러한 배경에서, 본 연구는 궁극적으로 기존 수치모델에 필적하거나 그 이상의 예측 성능을 갖는 데이터 기반 녹조 예측모델을 개발하고자 하였다.

1.2 연구개발 목표 및 내용

1) 연구 목표

앞서 언급한 필요성에 기반하여, 본 연구는 수리특성을 고려한 자료기반 인공지능 녹조 예측모델을 개발하고 그 실무 적용성을 검증하는 것을 목표로 한다. 구체적으로는 K-water 관리 저수지의 조류경보 대응을 위해 AI 녹조 예측 모델의 분석·개발에 대한 표준안(SOP)을 마련하고자 하였으며, 다양한 현장 조건에서도 일관되게 적용할 수 있는 일반화된 예측 프레임워크를 제시하고자 하였다. 이를 통해 관측자료의 가용성, 품질 향상 및 표준화된 모델링 기법을 확보함으로써, 향후 K-water의 기존 수치모델과 결합한 하이브리드 녹조 예측 시스템 구축의 기반을 마련하는 것을 최종 목표로 삼았다.

2) 주요 연구내용

본 연구에서는 목표 달성을 위해 다섯 가지 핵심 세부내용을 단계적으로 수행하였다. 단계별 주요 연구내용은 다음과 같다.

가. 데이터 전처리 SOP 개발

관측자료의 이상값과 결측값 처리는 학습데이터의 신뢰성 확보를 위한 필수 과정이다. 본 연구에서는 데이터 정합성을 높이기 위해 이상값 탐지 및 결측값 대체 기법들을 검토하고 성능을 평가하여 최적의 전처리 방법을 표준운영절차(SOP)로 정립하였다. 다양한 통계 및 평활화 기반의 이상값 탐지기법과 처리, 머신러닝 기반 결측값 대체기법 등을 시험하여 자료 손실을 최소화하면서 모델 예측력을 저해하지 않는 방안을 제시하였다. 이를 통해 구축된 전처리 SOP는 향후 새로운 자료에 대해서도 일관된 품질관리를 수행할 수 있도록 하는 기준을 제공 할 것이다

나. 탐색적 데이터 분석(EDA) SOP 개발

자료 기반 예측모델의 효과적인 개발을 위해서는 변수들의 분포 특성과 상호 관계를 면밀히 파악하는 작업이 선행되어야 한다. 이에 본 연구에서는 기술통계를 중심으로 변수별 고유 특성을 파악하는 일변량분석을 통해 각 예측 변수들의 분포, 경향성을 분석하고, 다양한 통계 및 시계열 기법들을 통한 다변량 분석을 통해 변수들간 상관관계와 패턴을 탐색하는 EDA 표준절차를 마련하였다. 예를 들어 조류 발생량(종속변수)과 수질·기상 인자들(독립변수) 간의 관계를 시각화하고 분석함으로써, 잠재적으로 중요한 예측인자를 초기 단계에서 식별하였다. 이러한 EDA 결과는 이후 변수 선택과 모델 설계 시 근거자료로 활용되어 모델 개발의 효율성과 설명력을 높이는 데 기여하였다

다. 변수 선택 SOP 개발

효율적인 AI 모델을 위해서는 불필요한 입력변수를 줄이고 예측에 기여도가 높은 변수들을 선별하는 과정이 필요하다. 본 연구에서는 필터, 래퍼, 임베디드, 차원축소 등 다양한 변수 선택 기법을 검토하였으며, 특히 상관분석 기반의 필터 기법을 중심으로 한 시계열 변수 선택 SOP를 개발하였다. 독립변수들간 중복 정보를 제거하고 다중공선성을 완화하기 위해 단계적 선택법(greedy algorithm)을 적용하여 최적 변수 조합을 일차 선별하고, 이차적으로 종속변수인 남조류 농도와 유의한 상관성을 갖는 후보 변수를 도출하였다. 이러한 필터 기반 변수 선정 절차를 표준화함으로써, 데이터 특성이 다른 여러 현장에도 적용 가능한 경량화된 예측 모델 구성이 가능하게 하였다.

라. 수리특성을 고려한 적정 AI 알고리즘 개발

자료 기반 녹조 예측모델의 성능을 극대화하기 위해서는 데이터 특성에 부합하는 학습 알고리즘의 선정이 중요하다. 본 연구에서는 수질·녹조 자료의 낮은 시간해상도(주간 또는 월간 자료 간격)와 관측치 불균형 등을 고려하여, 적은 데이터에서도 안정적으로 학습이 가능한 의사결정나무 계열의 앙상블 알고리즘(예: Random Forest, Gradient Boosting, XGBoost)을 중심으로 모델을 검토·선정하였다. 또한 밀도성층, 지형, 체류시간 등 수체의 수리학적 특성 인자들을 모델 입력에 반영함으로써, 현상 예측의 물리적 타당성과 성능 향상을 도모하였다. 한편, 관측자료의 극심한 불균형 문제를 완화하기 위해 데이터 증강(Data Augmentation) 기법을 병행하였다. 고농도 녹조 발생 사례가 드문 특성을 보완하고자, SMOTE 기법을 개량한 SMOGN(SMOTE with Gaussian Noise) 및 생성적 적대신경망(GAN) 기반 오버샘플링을 활용하여 희소 구간의 데이터를 인공적으로 증대시켰다. 이렇게 증강된 데이터셋으로 모델을 재학습시킨 결과, 희소한 고농도 녹조 발생에 대한 예측 정확도 향상 등 모델 학습 능력 제고에 기여할 것으로 기대된다. 증강 기법별로 모델 예측 성능에 미치는 영향을 비교·분석함으로써, 향후 수질 예측 분야에서 불균형 데이터 문제의 완화 방안을 제시하였다.

마. 녹조·수질 예측모델 개발 및 적용

이상의 과정을 거쳐 현장 적용이 가능한 녹조 예측 AI 모델을 구축하고, 이를 실제 대상지에 적용하는 단계이다. 먼저 대청댐, 주암댐 등 대상 저수지의 수질·환경 자료를 종합적으로 조사·분석하여, 댐별 수체 특성과 데이터 가용 범위를 파악하였다. 문헌조사와 현장자료 검토를 통해 대상 지역별 자료 분류 및 활용도 분석을 실시하고, 이를 토대로 예측모델 개발에 활용할 학습 데이터셋을 구성하였다. 특히 조류경보제 데이터, 국가 수질측정망 자료, K-water 댐 운영 자료, 기상청 기상 자료 등 여러 출처의 이종 데이터를 통합하여 총 27개 변수 항목으로 구성된 데이터셋을 구축하였고, 각 대상 지점별로 이러한 데이터를 모델 학습에 투입하였다. 최종적으로 선정된 알고리즘과 변수 조합을 바탕으로 대청댐에 대해 AI 녹조 예측모델을 개발하고, 이를 주암댐에도 시험 적용하여 모델의 예측 성능과 실용성을 검증하였다. 모델 적용 결

과를 통해 현장 특성에 따른 예측 정확도, 자료 부족 시 한계점을 분석하였으며, 이는 차후 모델 개선과 타 지역 확장 적용을 위한 피드백으로 활용될 것이다.

이상과 같은 연구개발 내용을 바탕으로, 본 연구는 수리적 특성을 고려한 자료기반 AI 녹조 예측모델의 체계적인 개발 절차와 적용방안을 제시하였다. 이는 향후 K-water의 녹조 예보 체계에 AI 기술을 접목하여 조류경보 대응의 신속성과 정확성을 향상시키기 위한 기초를 제공할 것으로 기대된다.

제 2장 데이터 전처리 표준운영절차(SOP) 개발

데이터 전처리(Data Processing)는 머신러닝 모델의 성능을 극대화하기 위한 필수 과정으로 수집한 데이터 질 향상을 위해 분석에 적합한 형태로 가공하는 과정을 총칭한다. 대표적인 가공 형태는 불필요한 데이터의 제거, 이상값 탐지나 결측값 대체 등으로, 이렇게 가공된 데이터는 분석 모델을 구축하고 결과를 도출하는 데에 더욱더 유용하게 활용될 수 있다. 다시 말해서, 데이터 전처리는 불완전하거나 부정확한 데이터를 정제해 모델이 효과적으로 학습할 수 있도록 변환하는 과정이다.

2.1 전체적인 데이터 확인

1) 데이터 구조 확인

전체적인 데이터 탐색의 첫 번째 단계는 분석할 데이터를 확인하여 해결하고자 하는 목표를 파악하는 것이다. 이를 통해 종속변수 및 독립변수를 구분하고 관련이 없는 변수(예: ID, No.와 같이 데이터 관리를 위해 단순 부여한 번호)는 없는지 확인하고 필요시 제외한다. 또한 데이터 가공 과정에서 구조적인 오류나 누락으로 데이터셋의 정합성이 안 맞는 경우(예: 데이터 행이 밀린 경우 등)가 있으므로 데이터셋의 Head와 Tail 부분을 간단히 확인하도록 한다.

그다음은 데이터셋의 객체(Object or Record)와 속성(Attribute or Field)들의 기본적인 구조 및 특성을 확인하여야 한다. 변수별 데이터 객체 수나 측정 주기가 서로 다른 '데이터 불균형' 문제 존재 여부 확인, 각 변수의 속성값이 일반적으로 예상되는 범위와 분포를 보이는지 간단한 기술통계량을 통해 확인한다.

마지막 단계는 자료 형태를 판단해야 한다. 자료 형태란 속성값의 고유한 성질, 일반적으로 데이터 척도에 따른 구분법이다. 자료 형태를 구분해야 하는 이유는 EDA에서 활용 가능한 요약통계 지표나 시각화 방법, 변수 간 관계 분석 방법이 자료 형태에 따라 달라질 수 있기 때문이다.

2) 데이터 형태 파악

자료는 일반적으로 수치형 자료(numerical data)와 범주형 자료(categorical data)의 두 가지 형태로 구분한다. 양적 자료(quantitative data)라고도 불리는 수치형 자료는 관측된 값이 수치로 측정되는 자료를 의미한다. 예를 들어 남조류세포수, 클로로필-a 농도, 수질측정 횟수 등이 있다. 수치형 자료는 관측되는 값의 성질에 따라 다시 남조류세포수, 클로로필-a 농도 등과 같이 연속적인 형태의 소수점으로 나타낼 수 있는 연속형 자료(continuous data)와 수질측정 횟

수 등과 같이 소수점으로 나타낼 수 없는 이산형 자료(discrete data)로 구분할 수 있다.

질적 자료(qualitative data)라고도 불리는 범주형 자료는 관측 결과를 여러 개의 등급(class) 또는 항목(category)의 형태로 나눌 수 있는 자료를 말한다. 예를 들어 조류경보제 발령단계(관심, 경계, 대발생), 수계 구분(한강, 낙동강, 금강 등), 발령시기(년, 월, 일, 시 등) 등이 있다. 범주형 자료는 조류경보제 발령단계 등과 같이 범주 간에 우열이나 선호의 의미가 있으면 순서형 자료(ordinal data), 수계 구분, 날짜 등과 같이 의미가 없으면 명목형 자료(nominal data)로 구분할 수 있다.

<표 2.1> 자료 형태의 분류

구 분		특 성
수치형 자료 (numerical data) 또는 양적 자료 (quantitative data)	연속형 자료 (continuous data)	(형태) 소수점 형태의 표현 가능, 연산 가능 (집계) 합계, 평균, 표준편차, 분산, 퍼센트 계산 가능
	- 구간형 자료 (interval data)	(형태) 절대적 원점(기준)이 없어 상대적 차이는 의미가 있으나, 그 비율은 의미가 없음
	- 비율형 자료 (rational data)	(형태) 절대적 원점(기준)이 있어 상대적 차이와 그 비율이 모두 의미가 있음
	이산형 자료 (discrete data)	(형태) 소수점 형태의 표현 불가능, 연산 가능 (집계) 합계, 퍼센트 계산 가능(평균, 표준편차, 분산 등도 계산할 수 있으나, 수학적 의미는 없음)
범주형 자료 (categorical data) 또는 질적 자료 (qualitative data)	순서형 자료 (ordinal data)	(형태) 서열이나 선호도 의미, 연산 불가능 (집계) 범주별 개수와 퍼센트 계산 가능, 등간격 척도이면 평균 계산 가능(수학적 의미 없음)
	명목형 자료 (nominal data)	(형태) 서열이나 선호도 의미 없음, 연산 불가능 (집계) 범주별 개수와 퍼센트 계산 가능

3) 데이터 제거(Removal) 및 병합(Merging)

데이터 전처리 과정에서는 분석 목적과 직접적인 연관성이 낮거나, 모델 성능에 기여하지 않는 변수들을 선별하여 열(Column) 단위로 삭제하는 데이터 제거(Data Removal) 절차를 수행할 수 있다. 이러한 변수들은 정보량이 매우 적거나 통계적 변동성이 거의 없는 경우, 다른 변수와 높은 중복성을 보이는 경우, 혹은 현상 설명과 인과적 연계성이 부족한 경우에 해당한다. 불필요한 변수를 그대로 포함할 경우, 모델 복잡도가 불필요하게 증가하고 과적합 위험이 높아질 수 있으며, 해석 가능성과 계산 효율성 또한 저하될 수 있다. 대표적으로 관측데이터 수집 과정에서 데이터 관리를 위해 단순 부여한 ID, No.와 같은 번호 등이 해당할 수 있다.

데이터 제거와는 반대로 데이터를 효과적으로 분석하고 학습(training) 및 시험(test)하기 위해서는 다른 경로로 수집된 여러 개의 원시 데이터(raw data)를 병합하여 정합성 있는 하나의 데이터셋으로 만들 필요도 있다. 물론 이를 위해서는 각 원시 데이터들에 병합의 기준이 될 공통되는 속성(column)이 반드시 존재해야 한다. 병합할 원시 데이터들은 객체(row) 수가 각기 다를 수 있으므로 <그림 2.1>과 같이 데이터 구조를 결정하는 병합의 방법을 정해야 한다.

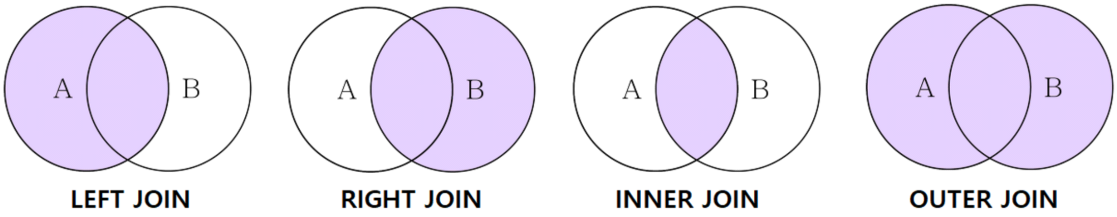

<그림 2.1> 데이터 병합의 방법

왼쪽 또는 오른쪽 기준 병합(Left Join, Right Join)은 기준으로 정해진 쪽의 데이터 구조를 따르도록 병합하는 것으로 피 병합되는 데이터에 없는 값은 결측값으로 처리된다. 교집합 기준 병합(Inner Join)은 양쪽에 공통으로 있는 값들만 나타내므로 결과적으로 결측값을 제거(Deletion)하는 것과 같다. 합집합 기준 병합(Outer Join)은 모든 값이 나타나게 되며, 양쪽에 없는 값들은 모두 결측값으로 처리된다.

데이터를 병합하면 각 원시 데이터의 구조에 따라서 많은 수의 결측값이 발생하게 된다. 특히 수질 자료와 같이 측정 항목별로 관측 주기가 다양한 시계열 데이터의 경우 병합의 기준이 되는 시간 속성의 해상도가 다르므로 비어 있는 관측 간격을 채워 줄 결측값 대체(Missing Value Imputation) 또는 데이터 증강(Data Augmentation)을 수행할 필요성이 있다. 따라서 데이터 병합은 일반적으로 전처리 과정의 가장 첫 단계로 수행하게 된다.

2.2 이상값 탐지 (Anomaly Detection)

2.2.1 이상 탐지 알고리즘

이상값(Anomaly)이란 일반적인 데이터 분포를 따르지 않는 값으로, 관측된 데이터의 범위에서 많이 벗어난 아주 작은 값이나 큰 값을 의미한다. 이상값은 상대적인 개념이며 데이터를 무슨 기준으로 판별할 것인가에 따라 달라질 수 있다. 대표적인 이상값 탐색 방법은 통계적 방법의 표준편차(Standard Deviation)를 이용한 Z-score 방법, 사분위수(Quartiles)를 이용한 IQR(Inter-Quartile Range) 방법, 이동평균(Moving Average)을 이용한 방법, STL(Seasonal and Trend decomposition using Loess) 분해 등이 있다. 그 외에도 기계학습의 K-means 기법, Static based detection, Deviation based method, Distance based Detection 기법 등 다양한 방법이 존재한다. 이상값은 오차 분산을 증가시키고 추정치가 편향되는 등 모델의 학습과 추론 능력에 영향을 미치게 되므로 제거하거나 대체해줄 필요가 있다.

이상값은 아니어도 거의 나타나지 않는 희소값도 처리가 필요하다. 범주형 변수에 대해 희소값이 존재하는 경우, 이는 데이터의 경향을 파악하기 어렵게 만들어 해석을 어렵게 하고 기계학습의 성능을 낮출 수 있다. 인코딩을 진행할 때도 오랜 계산시간과 많은 컴퓨팅 성능을 요구하기도 한다. 따라서 희소값들의 경우 '기타'와 같이 묶어주거나, 결측값 처리해주기도 한다.

1) 표준화 점수(Z-score)

Z-score 방법은 우리가 잘 알고 있는 평균과 표준편차를 활용한 표준화 점수를 이용해 이상값을 탐색하는 방법이며, 용어에서 알 수 있듯이 데이터의 분포가 정규분포를 따른다는 가정이 필요하다. Z-score($Z = |x-\mu|/\sigma$)는 <그림 2.2>에 나타내었듯이 각각의 데이터 값과 평균의 거리가 표준편차와 비교해 특정 범위를 벗어나면($|x-\mu| > Z\sigma$) 이상값으로 판정하고 제거해준다. 여기서, 특정 범위는 일반적으로 Z = 3을 기준으로 하지만 데이터의 특성을 잘 알고 있는 분석자의 경험에 따라 설정을 달리 할 수 있다.

Z-score 방법에서는 필요시 데이터가 정규분포를 따르도록 조정하거나 변환하는 방안을 고려할 수 있다. 정규성을 강화하면 통계적 검정 및 모델링 과정에서 가정되는 정규분포에 더 잘 부합하도록 만들어 결과의 신뢰도 향상도 기대할 수 있다. 정규성을 강화를 위한 데이터 변환 방법으로는 로그 변환 및 제곱근 변환(값>0), Box-Cox 변환(값>0), Yeo-Johnson 변환(음수와 0 값 처리 가능) 등이 많이 이용된다.

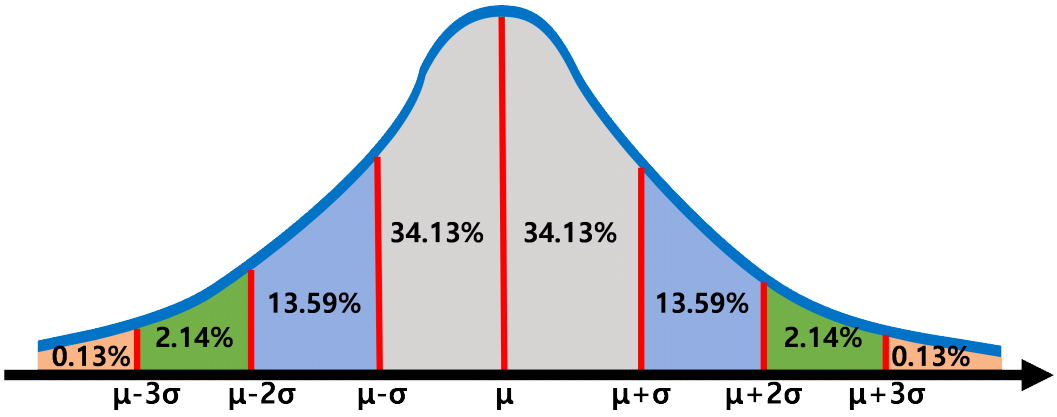

<그림 2.2> Z-score 방법에 의한 이상값 판정 기준

2) 수정 표준화 점수(Adjusted Z-score)

수정 Z-score 방법은 일반적인 Z-score 방법과 유사하지만, 이상값 판정 기준을 표준편차 대신 중앙값절대편차(MAD: Median Absolute Deviation)를 사용한다는 것이 차이점이다. 이는 Z-score 방법의 이상값 판정 기준인 평균과 표준편차는 이상값의 영향을 많이 받지만, 중앙값과 MAD는 이상값에 상대적으로 강건하므로 이상값을 더 견고하게 탐색할 수 있다는 장점이 있다. 수정 Z-score 방법은 식(2.1)과 같이 계산된다.

$$M_i = \frac{0.6745(x_i - \tilde{x})}{MAD} \quad (i = 1, 2, 3, \cdots, n) \qquad \text{식(2.1)}$$

여기서, M_i는 데이터 x_i의 수정 Z-score

x_i는 개별 데이터값

$\tilde{x}$는 데이터의 중앙값(Median)으로 관측치의 수가 짝수면 중앙에 있는 두 값의 평균으로 산출

MAD는 중앙값절대편차(Median Absolute Deviation)로 관측치와 중앙값 차이의 절댓값에 대한 중앙값, $MAD = median(|x_i - \tilde{x}|)$

0.6745는 정규 분포의 특성을 반영하는 상수(일반 Z-score와 일관성 유지 목적)

수정 Z-score 방법을 활용한 이상값 탐색은 데이터가 정규분포를 따르지 않을 때, 이상값이 극단적이거나 많을 때, 또는 관측치의 수가 적어 이상값이 평균과 표준편차에 큰 영향을 미칠 때 일반 Z-score보다 적합하다고 알려져 있으며, Iglewicz와 Hoaglin(1993)은 수정 Z-score의 절댓값이 3.5보다 큰 경우($|M_i| > 3.5$)에 이상값으로 판정하는 것을 제안하였다.

3) 4분위수(IQR)

4분위수(Quartiles) 방법은 EDA를 개발한 존 튜키가 제안하였으며, 데이터가 정규분포를 이루지 않을 때 활용할 수 있는 간단하고 직관적인 이상값 탐색 방법이다. 4분위수 방법 적용을

위해 데이터를 값 기준으로 정렬한 후, 데이터의 분포에 따라 4등분 해 각 부분의 값을 각각 1사분위, 2사분위, 3사분위, 4사분위로 나타낸다. 4분위로 정렬한 데이터는 <그림 2.3>과 같은 상자 그래프(Box Plot)에서 맨 왼쪽은 데이터의 최소값을, 맨 오른쪽은 데이터의 최대값을, 가운데는 중앙값을 나타낸다. 그림에서 Q_1과 Q_3는 데이터를 4등분 했을 때의 범위로 Q_1은 최소값을 포함한 하위 25% 범위를, Q_3는 최대값을 포함한 상위 25%의 범위를 나타낸다. 이때, Q_3에서 Q_1을 뺀 값을 IQR(Inter Quartile Range)이라 한다.

4분위수 방법에서는 이상값 판정 기준을 식(2.2)와 같이 Q_3와 Q_1에서 IQR의 특정 배수 이상 벗어난 값들로 정의한다. 여기서, 특정 배수 k값은 보통 1.5~3을 사용하지만, 그 이상의 값을 곱하기도 하며, 값이 클수록 더욱 이상값의 기준이 엄격해진다.

$$\text{하한: } Q_1 - k \times IQR\ , \qquad \text{상한: } Q_3 + k \times IQR \qquad \text{식(2.2)}$$

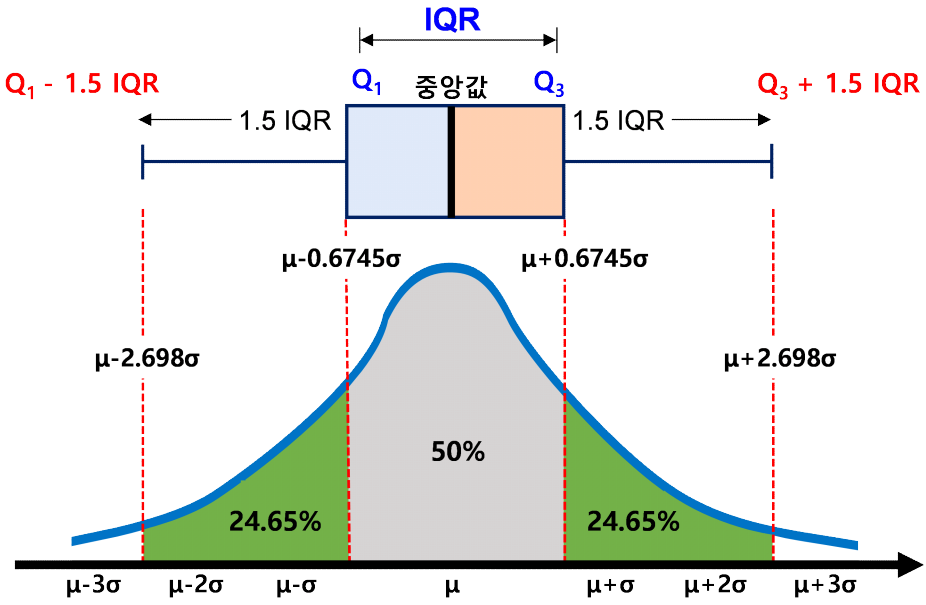

<그림 2.3> 4분위수 방법에 의한 이상값 판정 기준

4) 수정 4분위수(M-IQR)

수정 4분위수(Modified IQR) 방법은 정규분포를 따르지 않는 데이터에도 적용할 수 있도록 4분위수 방법을 일반화한 것으로 왜도(skewness)를 활용함으로써 데이터의 왜곡이 심하거나 극단치의 영향을 크게 받는 비대칭분포에서 이상값 탐색에 합리적이다. 왜도에 대한 강건한 통계량인 medcouple(MC)을 적용하여 이상값을 정의하며, MC값은 식(2.3)와 같다.

$$MC = median\{h(x_i, x_j)\}, \quad x_i \le \tilde{x} \le x_j \qquad \text{식(2.3)}$$

여기서, $\tilde{x}$는 중앙값,

$$h(x_i, x_j) = \frac{(x_j - \tilde{x}) - (\tilde{x} - x_i)}{x_j - x_i}$$

수정 4분위수 방법에서는 이상값 판정 기준을 일반 4분위수 방법과 같이 Q_3와 Q_1에서 IQR의 특정 배수 이상 벗어난 값들로 정의한다. 여기서, 특정 배수는 식(2.4)와 같이 MC값을 지수 함수 형태로 나타낸 것이다.

하한: $Q_1 - 1.5e^{-4MC} \times IQR$, 상한: $Q_3 + 1.5e^{3MC} \times IQR$, if $MC \geq 0$ 식(2.4)

하한: $Q_1 - 1.5e^{-3MC} \times IQR$, 상한: $Q_3 + 1.5e^{4MC} \times IQR$, if $MC < 0$

여기서, $MC > 0$이면 데이터가 오른쪽으로 치우침(right-skewed)

$MC < 0$이면 데이터가 왼쪽으로 치우침(left-skewed)

$MC \approx 0$이면 데이터가 대칭(symmetry)에 가깝고, $MC = 0$이면 $e^0 = 1$이므로 4분위수 방법과 같게 됨

5) 이동평균(MA)

시계열 데이터는 시간이 지남에 따라 추세나 계절성을 포함하는 경우가 많아서 전역적인 정규분포 가정을 하기 어렵게 된다. 시계열 데이터의 이상값을 탐지하는 방법의 하나로, 식(2.5)에 나타낸 것과 같이 이동평균(MA: Moving Average)과 이동표준편차(MSD: Moving Standard Deviation)를 활용할 수 있다. 이 방법은 시계열 데이터에서 국지적인 구간(이동 창, window) 내의 평균과 표준편차를 분석하므로 전체 데이터의 분포와 무관하게 데이터의 단기적인 변화 추이를 파악하고, 그 변화가 특정 기준을 벗어날 때 이상값으로 판정할 수 있다.

$$MA_t = \frac{1}{W} \sum_{i=t-W+1}^{t} X_i \quad \text{식(2.5)}$$

$$MSD_t = \sqrt{\frac{1}{W} \sum_{i=t-W+1}^{t} (X_i - MA_t)^2}$$

여기서, MA_t: 시점 t에서의 이동평균값

MSD_t: 시점 t에서의 이동표준편차

X_i: 시계열 데이터

W: 이동평균을 계산하는 윈도우 크기(Window Size)

t: 현재 시점

이동평균 방법에서는 이상값 판정 기준을 식(2.6)과 같이 시점별 데이터값과 이동평균의 잔차가 이동표준편차의 일정 배수 이상을 벗어난 값들로 정의한다. 일정 배수 k의 범위는 보통

1.5~2를 사용한다.

하한: $MA_t - k \times MSD_t$, 상한: $MA_t + k \times MSD_t$ 식(2.6)

6) 지수가중이동평균(EWMA)

지수가중이동평균(EWMA: Exponentially Weighted Moving Average)은 Roberts(1959)에 의해 소개되었으며, 주로 공정관리나 품질관리 분야에서 "프로세스의 평균 변화"를 모니터링하여 작은 변화나 이상 신호를 감지하는 데 사용되었다. 즉, 데이터의 평균이 정상 범위를 벗어나는지를 지속해서 감시하는 데 유용하다. EWMA의 기본 개념은 식(2.7)에 나타낸 바와 같이 현재와 가까운 관측값에 더 큰 가중치를 주는 방식으로 최근의 변화를 반영하여 이상값을 탐지할 수 있다. EWMA의 이상값 판정 기준은 식(-)와 같이 제어한계(Control Limits)를 결정하여 시점 t에서 EWMA 값(Z_t)이 하한(LCL: Lower Control Limits)과 상한(UCL: Upper Control Limits)을 벗어난 값(X_t)으로 정의한다.

$$Z_t = \lambda X_t + (1-\lambda) Z_{t-1} \ , \ (t = 1, 2, \cdots, n) \quad \text{(식2.7)}$$

여기서, Z_t: 시점 t에서의 EWMA 값(연쇄적으로 누적된 가중 평균)

X_t: 시점 t에서의 실제 데이터

λ: 최근 데이터 반영 정도를 조절하는 평활 계수($0 < \lambda \leq 1$)

$$LCL_t = \mu - L \cdot \sigma_Z(t), \quad UCL_t = \mu + L\sigma_Z(t) \quad \text{식(2.8)}$$

$$\sigma_Z(t) = \sigma \cdot \sqrt{\frac{\lambda}{2-\lambda}\left[1-(1-\lambda)^{2t}\right]}$$

여기서, μ와 σ: 전체 데이터의 평균과 표준편차, 실시간 자료의 경우 초기 평균값 또는 경험치, 목푯값 등 사용

$\sigma_Z(t)$: EWMA 통계량 Z_t의 표준편차 근삿값

$1-(1-\lambda)^{2t}$: 초기 불확실성을 고려해 제어한계를 넓히고 시간에 따라 좁아지도록 하는 감소 항, t가 커지면 1에 수렴하므로 과거 자료에서는 생략

L: 제어한계의 폭을 결정하는 계수, 일반적으로 $L = 2 \sim 3$

EWMA 값(Z_t)과 제어한계(LCL, UCL)는 가중치 계수 λ에 따라 민감하게 반응한다. λ가 크면 상대적으로 최근 데이터에 더 큰 가중치를 부여하여 데이터의 단기적인 변화 추이를 빠르게 반영하고, 반대로 λ가 작으면 상대적으로 과거 데이터의 영향을 많이 받아 데이터를 평활화(smoothing)하므로 변화를 점진적으로 반영하게 된다. Hunter(1986)는 $0.2 \leq \lambda \leq 0.3$를 적정 값으로 제시했으며, Montgomery(2005)는 $0.05 \leq \lambda \leq 0.25$를 권장했다. Lucas and Saccucci(1990)는

가중치 정의를 위한 테이블을 제시한 바 있다. 이 외에도 여러 연구에서 다양한 제안이 있었으나, 연구자의 경험적 판단으로 결정하는 것이 가장 합리적이다.

EWMA 방법은 단순 이동평균(Moving Average)의 장점인 데이터의 점진적 변화에 반응하는 것에서 더 나아가 시점에 따른 가중치를 부여함으로써 노이즈 제거와 변동성을 계산 결과에 반영하고 계절성을 보이며 변이가 큰 시계열 데이터에도 적용할 수 있다. 특히, 통계적으로 정의된 제어한계가 명시되어 있어 이상값 판정에 명확한 기준을 제공한다는 장점이 있다. 반면, 시계열 데이터에 정상성(stationary)이 전제되어야 하며, 추세나 계절성이 강한 데이터에는 추가 조정이 필요하다.

7) 지수평활법(ES)

지수평활법(ES: Exponential Smoothing)은 시계열 데이터의 예측(forecasting)과 평활화(smoothing)를 위해 사용되는 방법으로, 기본적으로 과거 데이터에 지수적으로 감소하는 가중치를 부여하여 최근 데이터에 더 높은 영향을 주도록 하는 지수가중이동평균법(EWMA)과 같은 개념을 기반으로 한다. 그러나 EWMA가 이상값 탐지를 위해 설계된 방법인 데 반해 지수평활법은 예측 모델로 활용되며, 이상값 탐색에 활용하려면 평활화된 예측값과 관측값의 잔차를 분석하는 추가적인 과정이 필요하다.

지수평활법은 EWMA와 마찬가지로 단기적인 노이즈에 반응하지 않고 구조적인 이상값에만 반응한다는 장점이 있으나, 단순한 형태로 적용하면 추세(trend)나 계절성(seasonality)을 반영하지 못하는 한계가 있다. 단순 지수평활법(SES: Simple Exponential Smoothing)은 EWMA와 같은 형태로 식(2.9)와 같이 정의된다.

$$S_t = \alpha X_t + (1-\alpha) S_{t-1}\ ,\ (t = 1, 2, \cdots, n) \qquad \text{식(2.9)}$$

여기서, S_t는 시점 t에서의 평활값(예측값)

X_t는 시점 t에서의 실제 데이터

α는 최근 데이터 반영 정도를 조절하는 평활 계수($0 < \alpha \leq 1$)

식(2.9)에서 α가 크면 최근 데이터에 더 많은 가중치가 부여되어 빠르게 변화하는 데이터에 반응하지만, 노이즈도 많이 반영된다. 반면에 α가 작으면 과거 데이터를 더 많이 반영하여 노이즈 제거 효과가 크지만, 변화 감지 속도가 느려진다.

지수평활법에서는 평활화된 예측값과 관측된 실제값의 차인 잔차(residuals)를 구한 후, 잔차의 절대값이 표준편차의 일정 배수 k를 초과하는 경우를 이상값으로 판정한다($|S_t - X_t| > k\sigma$). 일정 배수는 일반적으로 k=3을 기준으로 하지만 데이터의 특성을 잘 알고 있는 분석자의 경험에 따라 달리 적용할 수 있다.

지수평활법은 단순 지수평활법(SES) 외에도 추세(trend) 항을 추가해 이중 지수평활법(DES: Double Exponential Smoothing)이라고도 불리는 Holt's Method, 추세뿐만 아니라 계절성(seasonality) 항까지 반영해 삼중 지수평활법(TEX: Triple Exponential Smoothing)으로도 불리

는 Holt-Winters 지수평활법 등 확장된 형태가 존재한다. Holt-Winters는 계절성을 나타내는 방식에 따라 가법적 모델(additive model)과 승법적 모델(multiplicative model)로 구분하는데, 가법적 모델은 계절성이 일정한 크기로 유지되는 경우(X_t의 변화폭이 일정함) 사용하고 승법적 모델은 계절성이 데이터 크기에 따라 비례적으로 변하는 경우(X_t가 증가할수록 계절성 변화도 커짐) 사용한다.

식(2.10)~식(2.13)은 Holt-Winters 방법을 나타낸 것으로 레벨(Level), 추세(Trend), 계절성(Seasonality) 세 가지 요소를 모두 반영하므로 상대적으로 복잡한 시계열 변수의 예측도 가능하지만, 파라미터 설정이 복잡하고 시계열의 계절 주기를 미리 알고 있어야 하는 점 등은 제약사항이다. 식에서는 추세와 계절성을 모두 가법적 또는 승법적으로 설정할 경우를 나타내고 있다.

가. 레벨(평활화) 업데이트

$$S_t = \alpha\,(X_t - C_{t-L}) + (1-\alpha)\,(S_{t-1} + b_{t-1}) \quad \text{(additive)} \qquad \text{식(2.10)}$$

$$S_t = \alpha\,\frac{X_t}{C_{t-L}} + (1-\alpha)\,(S_{t-1} \cdot b_{t-1}) \quad \text{(multiplicative)}$$

- 여기서, C_{t-L}: 이전 계절 주기의 계절성 요인
- L: 계절 주기(예: 월별 데이터라면 $L=12$)

나. 추세 업데이트

$$b_t = \beta(S_t - S_{t-1}) + (1-\beta)b_{t-1} \quad \text{(additive)} \qquad \text{식(2.11)}$$

$$b_t = \beta\frac{S_t}{S_{t-1}} + (1-\beta)b_{t-1} \quad \text{(multiplicative)}$$

여기서, b_t: 시점 t에서의 추세(Trend)

β: 추세 평활 계수(0~1)

다. 계절성 업데이트

$$C_t = \gamma\,(X_t - S_t) + (1-\gamma)\,C_{t-L} \quad \text{(additive)} \qquad \text{식(2.12)}$$

$$C_t = \gamma\,\frac{X_t}{S_t} + (1-\gamma)\,C_{t-L} \quad \text{(multiplicative)}$$

여기서, C_t: 시점 t에서의 계절성 요인(Seasonal Component)

γ: 계절성 평활 계수 (0~1)

라. 미래 예측

$$\hat{X}_{t+h} = S_t + h\,b_t + C_{t+h-L(k+1)} \quad \text{(additive)} \qquad \text{식(2.13)}$$

$$\hat{X}_{t+h} = (S_t \cdot b_t^h) \cdot C_{t+h-L(k+1)} \quad \text{(multiplicative)}$$

여기서, k: 예측하는 미래 시점이 몇 번째 계절 주기인지 계산하는 변수

8) STL 분해

STL은 Seasonal and Trend decomposition using LOESS의 약자로 R.B.Cleveland, McRae, & Terpenning(1990)에 의해 개발되었다. 계절성이 있는 시계열 데이터를 추세(trend), 계절성(seasonal), 추세와 계절성을 뺀 잔여(residual or remainder) 요소로 분해하기 위한 과정이다. 비선형 관계를 추정하는 LOESS(Locally Estimated Scatterplot Smoothing) 방법을 연속적으로 적용해서 추세와 계절성을 부드럽게 분해하고 데이터의 가산적 분해를 수행하는 기법이다.

데이터의 각 지점에서 다항식을 사용한 Locally weighted regression을 적용하며, 이상값이 추세와 계절성에 영향을 거의 주지 않아 분해된 요소에 대해 높은 신뢰도를 갖는다. 또한, 성분 분해 시 인접 시점의 결과를 독립적으로 처리해 계절성 강도가 변할 때도 잘 대응 할 수 있다. 따라서, STL 분해 기법은 광범위한 시계열에 적용할 수 있으며, 다양한 표본 집합에 적용할 수 있다는 이점이 있다(김동현 등, 2023). 각각의 시점 t에서 시계열 데이터 Y_t를 추세(T), 계절성(S), 잔여 요소(R)로 나타내면 다음의 식(1.14)와 같다.

$$Y_t = T_t + S_t + R_t \qquad \text{식(2.14)}$$

9) Cook Distance

Cook Distance는 특정 관측치가 회귀모델에 미치는 영향력을 나타내는 측도로 미국의 통계학자 Dennis Cook(1977)에 의해 제안되었다. Cook Distance는 전체 데이터로부터 얻은 회귀계수들과 i번째 관측치를 제거하고 얻은 회귀계수들의 차이를 측정하거나, 전체 데이터로부터 얻은 적합값들과 i번째 관측치를 제거하고 얻은 적합값들의 차이를 측정하는 방식으로 i번째 관측치의 이상값 여부를 판단한다. Cook Distances는 다음의 식(2.15)에 의해 계산할 수 있다.

$$D_i = \frac{\sum_{j=1}^{n}\left(\hat{y_j} - \widehat{y_{j(i)}}\right)^2}{p \cdot MSE} \quad (i = 1, 2, \cdots, n) \qquad \text{식(2.15)}$$

<그림 2.4>에 나타낸 바와 같이 특정 관측값이 회귀모델 예측에 미치는 영향력이 크다면 그 관측값을 제외할 때, 회귀모델의 예측 결과에 큰 변화가 일어날 것이며, 따라서 D_i의 값이 커지게 될 것이다. 따라서 큰 D_i값은 그 관측값이 영향력이 있음을 나타낸다. 일반적으로 $D_i > 1$인 경우 영향력 있는 관측값으로 판단하여 이상값으로 취급할 수 있다. 그러나 어떤 고정된 기준을 이용하는 것보다 모든 D_i값을 비교하여 상대적으로 영향력이 돋보이는 관측치를 이상값으로 판단할 수도 있다.

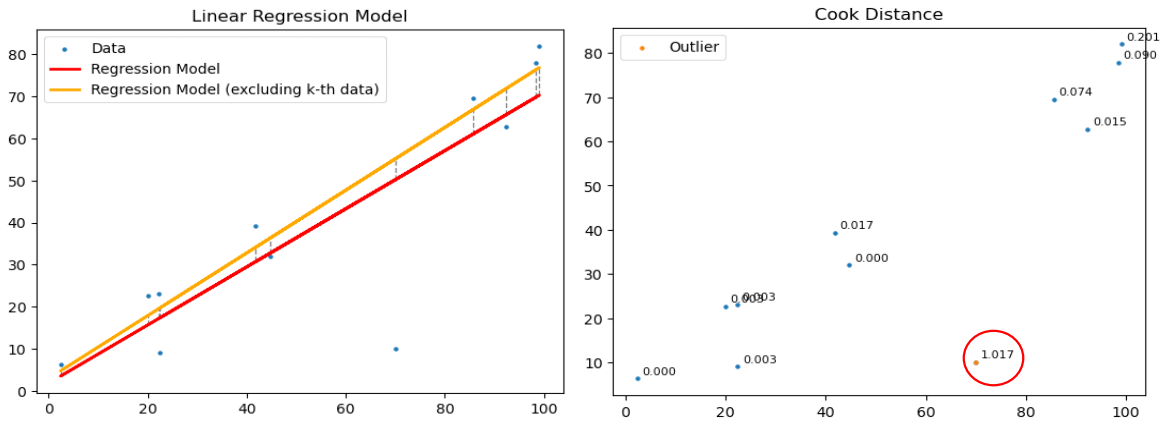

<그림 2.4> Cook Distance 방법에 의한 이상값 판정

10) DBSCAN

DBSCAN(Density-Based Spatial Clustering of Applications with Noise)은 머신러닝에서 주로 사용되는 군집화(clustering) 알고리즘의 하나로 미리 지정한 밀도를 기준으로 특정 데이터 점에서 서로 가까운 점들을 군집에 포함하는 방식의 알고리즘이다. 다른 군집화 기법들과 비교해 보면, 많이 활용되고 있는 K-Means나 Hierarchical 클러스터링은 군집 간의 거리만을 이용하는 방법인 데 비해 DBSCAN이 활용하는 밀도 기반 군집화는 특정 데이터점을 기준으로 일정 반경 내에 점들이 조밀하게 몰려 있어서 동질도가 높은 부분을 군집으로 묶는 방식이다.

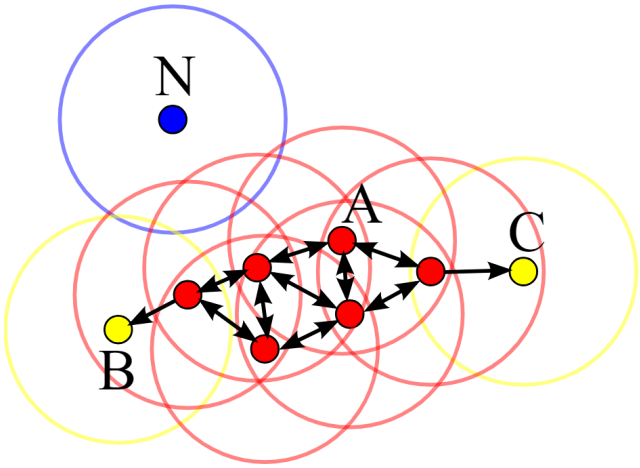

<그림 2.5> DBSCAN의 군집화 개념

출처: https://en.wikipedia.org/wiki/DBSCAN

DBSCAN 알고리즘은 2개의 하이퍼파라미터가 있다. 기준이 되는 중심점(core point)으부터의 거리 epsilon(ε) 값과, 이 반경 내에 있는 점의 수 minPts를 결정해야 한다. 이 두 가지 파라미터만 설정해 준다면 K-Means와 같이 군집의 수를 따로 정하지 않아도 밀도에 따라서 점들을 서로 연결하기 때문에 기하학적인 모양을 갖는 군집도 잘 찾을 수 있다. 따라서 DBSCAN은 밀도가 다양하거나 형태가 불규칙한 데이터를 처리할 때 유용하며 어느 군집에도

속하지 않는 잡음점(noise point)을 구분하므로 이상값 탐색 방법으로 활용할 수도 있다.

<그림 2.5>는 반경 ε에서 minPts = 4로 설정된 군집화 예를 나타내고 있다. 그림에서 점 A를 포함한 빨간색 점들은 반경(ε) 내에서 자신을 포함해 최소 4개의 점이 포함되어 있어 중심점이 된다. 이들은 모두 서로 연결 가능하므로 단일 클러스터를 형성하게 된다. 노란색 점 B와 C는 자신을 기준으로 한 반경 내에 4개의 점을 이룰 수 없는 경우로서 중심점은 아니지만, 빨간색 중심점들의 반경 내에 포함되므로 같은 군집으로 묶이게 되며, 이런 점들을 경계점(border point)이라고 한다. 파란색 점 N은 중심점도 아니고 경계점도 아니므로 군집에 포함될 수 없는 잡음점, 즉 이상값으로 구분할 수 있다.

11) 오토인코더 (Autoencoder)

오토인코더는 입력 데이터를 효율적으로 압축(인코딩)한 후, 이를 다시 원본 데이터로 복원(디코딩)하도록 학습하는 비지도 학습(Unsupervised Learning) 방식의 인공 신경망으로, 기본 구조는 크게 인코더, 잠재변수, 디코더 세 부분으로 구성된다. 인코더(Encoder)는 고차원의 입력 데이터를 저차원의 핵심 특징 데이터인 잠재변수로 압축하는 역할을 하며, 잠재변수(Latent Vector/Code)는 압축된 데이터의 핵심 정보만 남은 상태를 의미한다. 디코더(Decoder)는 압축된 정보를 바탕으로 원래의 입력 데이터와 최대한 유사하게 복원하는 역할을 한다.

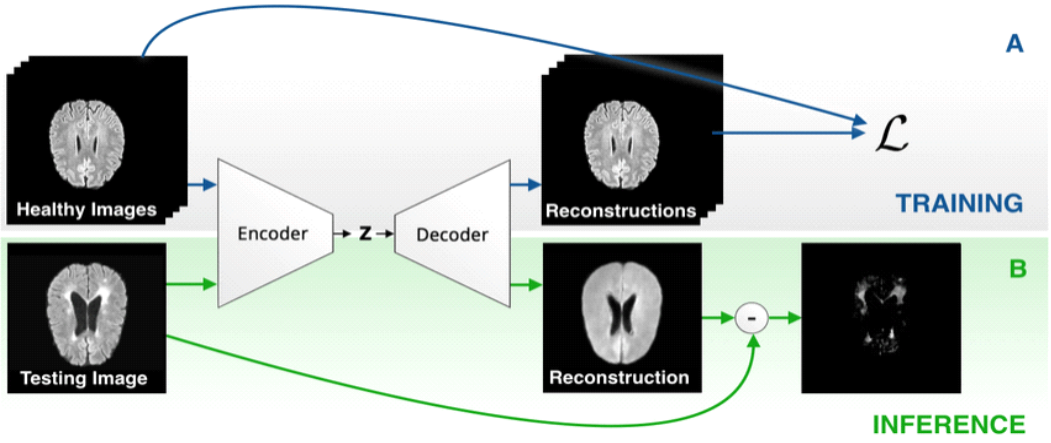

<그림 2.6> 오토인코더 기반 이상 탐지/분할의 개념

A) 정상 샘플만을 사용한 모델 학습
B) 이상을 포함할 수 있는 입력 샘플의 오류가 있는 재구성으로부터의 이상 분할

오토인코더는 원래 차원 축소와 변수 추출 등을 위해 제안되었으나, 학습 과정에서 "정상 패턴을 잘 복원한다"는 특성 때문에 이상값 탐지에도 널리 활용되고 있다. <그림 2.6>은 오토인코더를 활용한 이상값 탐지 개념을 나타내고 있다(Baur et al., 2020). 정상 데이터만으로 오토인코더를 학습하면, 모델은 정상 패턴에 대해서는 재구성 오차가 작고, 학습되지 않은 비정상 패턴에 대해서는 오차가 커지는 경향을 보인다. 따라서 입력과 복원값 사이의 재구성 오차를 이상 점수로 사용하고, 이 값이 미리 설정한 임계값을 초과하면 이상값으로 판단하는 구조가 일반적이다. Torabi 등(2023)은 네트워크 트래픽 데이터에서 Autoencoder를 사용해 정상 트

래픽의 표현을 학습한 뒤, 재구성 오차 분포를 기반으로 이상 패킷을 탐지하는 방식을 제안하며, 재구성 오차가 오토인코더 기반 이상 탐지에서 핵심 지표임을 강조한다.

시계열 데이터에서는 시점 간 의존성을 반영하기 위해 순환 신경망을 도입한 LSTM 오토인코더(LSTM-AE), 또는 1차원 합성곱을 이용한 CNN 기반 오토인코더가 주로 사용된다. 다양한 연구에서 LSTM-AE는 센서 시계열, 교통량, 환경 모니터링 데이터 등에서 정상 패턴의 시간적 구조를 잘 학습하고, 재구성 오차를 통해 이상 시점이나 이상 구간을 효과적으로 탐지하는 것으로 보고된다. 예를 들어 Rassam 등(2024)은 생리신호 데이터에 오토인코더 기반 모델을 적용해 높은 F1-score로 이상 상태를 탐지할 수 있음을 보였으며, 오토인코더가 고차원 시계열에서도 실용적인 이상 탐지 도구가 될 수 있음을 보여준다.

그러나 오토인코더 기반 이상 탐지가 항상 신뢰할 만한 결과를 내는 것은 아니라는 비판도 최근 제기되고 있다. Bouman & Heskes(2025)는 선형 및 비선형 오토인코더 모두에서 “정상 데이터로 학습했음에도, 분포 바깥에 있는 이상 샘플을 매우 잘 재구성해 버릴 수 있다”는 이론적·실증적 결과를 제시하며, 재구성 오차만을 신뢰하는 것은 위험할 수 있다고 지적한다. 이는 모델 용량이 크고 정규화가 부족할수록 이상 패턴까지 일반화해 버리는 과적합 문제가 특히 심각해질 수 있음을 시사한다. 이와 같은 논쟁에도 불구하고 오토인코더는 정상 패턴을 비지도 학습하고 재구성 오차를 이상 점수로 활용하는 대표적인 이상값 탐지 알고리즘으로서 다양한 산업·환경 데이터에 적용되고 있다.

12) 도메인 지식 활용

설명변수가 다양하고 그들 간의 인과관계가 복잡한 분석 대상일수록 도메인 지식이 충분치 않다면 기본적으로 정상/이상값의 구분이 어려울 수 있다. 부족한 도메인 지식은 데이터가 생성, 측정되는 물리적 과정에 대한 이해도를 떨어뜨리므로 데이터 측정 과정에서 발생하는 노이즈나 손상을 정상적인 데이터와 구별하지 못하는 문제를 발생시킬 수 있다. 특히 시계열 데이터에서는 값 자체의 통계적 특성뿐 아니라 규칙성도 중요한 요소로 작용하는데, 이는 도메인에 대한 깊은 이해 없이 판별하기가 어려울 수 있다.

따라서 통계 기법이나 기계학습에 의한 이상값 탐색과 함께, 데이터의 맥락, 출처, 목적 등 도메인 전문가들의 지식과 경험을 기반으로 불합리하거나 믿기 어려운 값을 사전에 정의한 후 정해진 규칙에 따라 이상값을 판별하면 분석 효과를 높일 수 있다. 다만, 분석자의 전문 지식과 성향에 따라 주관성이 개입되므로 결과에 영향을 미칠 수 있는 문제도 있다.

2.2.2 이상값 탐지 알고리즘 성능평가 방안

1) 배경 및 필요성

저수지의 녹조 발생은 수자원의 안정적 관리에 중대한 위협으로 이를 효과적으로 예측하기 위해서는 수질, 수리·수문, 기상 등 다양한 시계열자료 활용이 필수적이나 시간의 흐름에 따라 수집되는 특성상 계측·처리 단계에서의 오류 등 비자연적 요인과 극한사상 같은 자연적 요인

등으로 이상값(anomaly)이 발생하기 쉽다. 이렇게 재현성이 매우 작은 값들은 예측모델의 일반화 성능을 저하하고 과적합의 원인이 될 수 있으므로 사전에 적절한 탐지 및 처리 과정이 필수적이다.

수질과 같은 시계열자료의 이상값 탐지기법으로는 통계적 접근법, 기계학습 기반 방법, 신호 처리 기법 등이 다양하게 이용되었으나 자료의 시계열적 특성에 따라 탐지 성능은 상이할 수 있다. 그러나 성능평가를 위한 참값(ground truth)을 얻기가 어렵고, 전문가의 도메인 지식에 의존하는 경우가 많아 자료의 특성별로 적합한 탐지 기법을 판별하기란 쉽지 않다. 본 연구는 합성 이상값 주입(Synthetic Anomaly Injection), 합의 기반 평가(Consensus-based Evaluation) 전략을 통해 수질, 수리·수문, 기상 등 저수지 녹조발생과 관련된 시계열자료의 특성을 고려한 다양한 이상값 탐지기법의 성능을 비교하여 효과적인 기법을 제안하고자 한다.

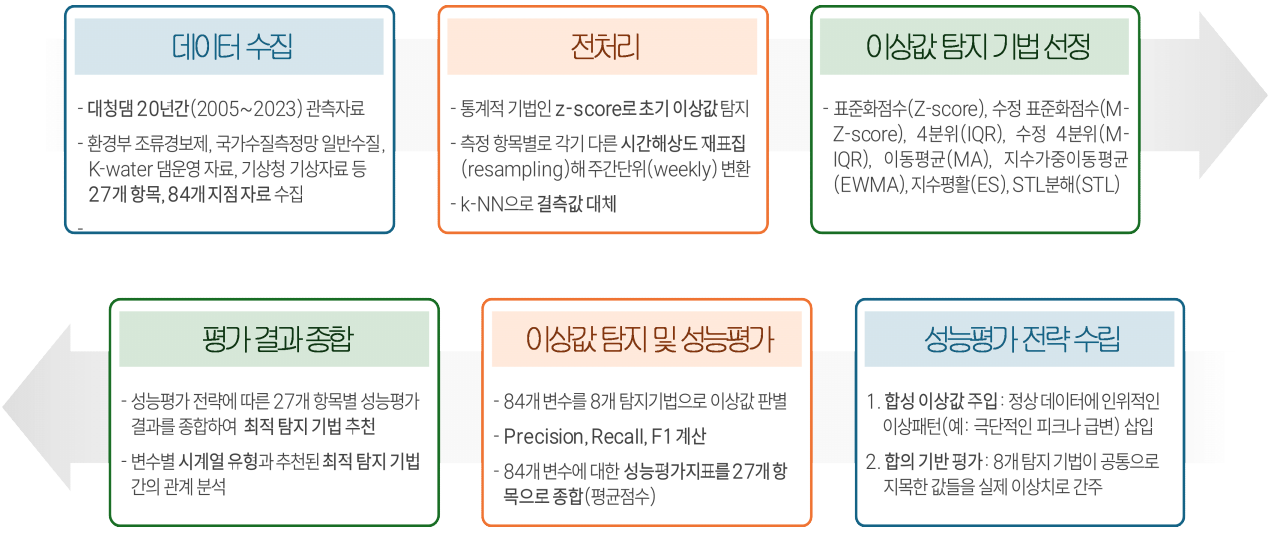

<그림 2.7> 이상값 탐지기법 성능평가 방법 및 절차 (대청댐 사례연구)

2) 이론적 배경

가. 이상값(anomaly)의 개념과 유형 분류

이상값(anomaly 또는 outlier)은 일반적으로 데이터가 따르는 정상적인 생성 메커니즘이나 통계적 분포에서 유의하게 벗어나는 관측치를 의미한다. 이상값은 단순히 극단적인 수치(extreme value)를 지칭하는 개념을 넘어, 관측값 자체의 특성, 주변 맥락(context), 그리고 시간적·공간적 집합 구조에 따라 다양한 유형으로 구분될 수 있다. 이러한 유형 구분은 이상값 탐지기법을 선택하고 결과를 해석하는 데에 있어 중요한 이론적 근거를 제공한다.

본 연구에서는 기존 문헌에서 널리 활용되는 분류 체계를 바탕으로 <그림 2.8>과 같이 이상값을 점 이상값(Point anomaly), 맥락적 이상값(Contextual anomaly), 집합적 이상값(Collective anomaly)의 세 가지 유형으로 구분한다.

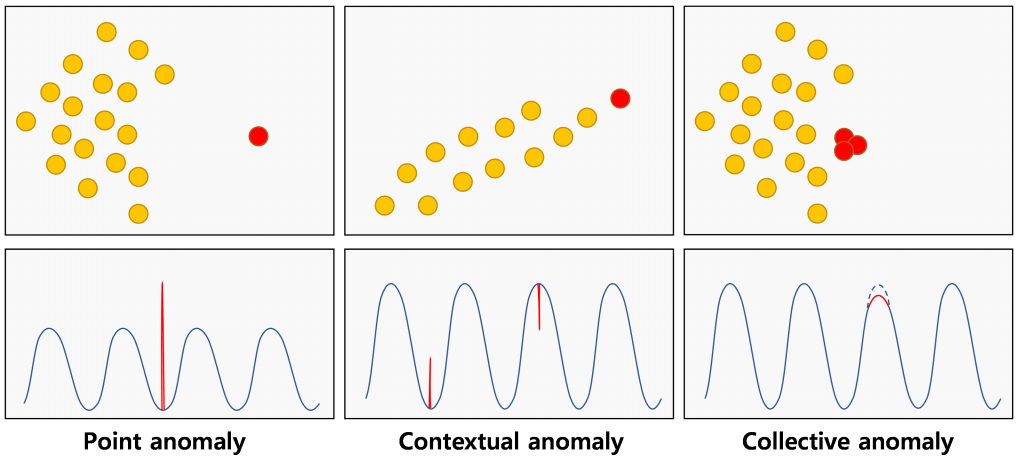

<그림 2.8> 이상값(anomaly)의 개념과 유형 분류

① 점 이상값 (Point anomaly)

점 이상값은 개별 관측값 하나가 전체 데이터 분포 또는 지역적 분포에 비추어 비정상적으로 나타나는 경우를 의미한다. 이는 가장 직관적이고 전통적인 이상값 개념으로, 단일 관측치의 크기나 위치가 통계적으로 유의미한 이탈을 보일 때 정의된다.

예를 들어, 수질 시계열 자료에서 대부분의 관측값이 일정 범위 내에 분포하는 상황에서, 특정 시점의 값이 평균이나 중앙값으로부터 극단적으로 벗어난 경우는 point anomaly로 간주될 수 있다. 이러한 이상값은 Z-score, IQR, 수정 Z-score 등과 같은 단변량 또는 다변량 통계 기반 기법으로 비교적 용이하게 탐지된다. 다만 point anomaly는 맥락 정보(context)를 고려하지 않는다는 한계를 가지며, 계절성이나 추세가 강한 시계열 자료에서는 정상적인 변동임에도 불구하고 이상값으로 오인될 가능성이 존재한다.

② 맥락적 이상값 (Contextual anomaly)

맥락적 이상값은 관측값 자체만 놓고 보면 정상 범위에 속하지만, 특정 맥락(context) 하에서는 비정상적으로 해석되는 경우를 의미한다. 여기서 맥락이란 시간, 공간, 계절, 운영 조건, 외생 환경 변수 등 관측값의 해석에 영향을 미치는 조건적 정보(conditioning information)를 포괄한다. 대표적인 예로, 여름철에 관측된 높은 수온은 정상적인 현상일 수 있으나, 겨울철 동일한 수온 값은 명백한 이상 상태로 해석될 수 있다. 이 경우 수온 값 자체는 동일하지만, 계절이라는 맥락에 따라 정상/이상 여부가 달라진다는 점에서 contextual anomaly에 해당한다. Contextual anomaly는 주로 시계열 자료나 환경·수문·수질 자료에서 빈번히 발생하며, 이동 평균 기반 기법, 계절 분해(STL), 상태공간모델, 또는 조건부 분포를 고려하는 머신러닝 기반 접근법을 통해 탐지된다.

③ 집합적 이상값 (Collective anomaly)

집합적 이상값은 개별 관측값은 각각 정상 범위에 속하더라도, 연속된 관측값들의 집합이 하나의 비정상적인 패턴을 형성하는 경우를 의미한다. 즉, 이상 여부는 단일 시점이 아니라 연속성, 패턴, 구조적 변화를 기준으로 판단된다. 예를 들어, 특정 수질 변수의 값이

평상시와 유사한 범위 내에서 변화하더라도, 일정 기간에 지속해서 상승하거나 비정상적인 진동 패턴을 보이는 경우, 해당 구간 전체는 collective anomaly로 간주될 수 있다. 이는 단기 스파이크(spike)가 아닌 체계적 변화(regime change) 또는 이상 상태의 지속성을 반영한다. Collective anomaly는 시계열 이상 탐지에서 특히 중요하며, 이동 윈도우 기반 통계, 변화점 탐지(change-point detection), 오토인코더 기반 재구성 오류, 순환 신경망(RNN) 및 Transformer 계열 모델을 통해 탐지되는 경우가 많다.

이상값을 유형별로 구분하는 것은 단순한 개념 정리에 그치지 않고, ① 이상값 탐지기법 선택, ② 전처리 과정에서의 데이터 보존 여부 판단, ③ 극단값 분석 및 예측모델 성능 평가의 신뢰성 확보 등의 측면에서 중요한 의미가 있다. 특히, 환경·수질과 같이 계절성과 비정상성이 공존하는 시계열 자료에서는, point anomaly만을 기준으로 이상값을 제거할 경우 실제로 중요한 고농도 피크나 이상 현상을 왜곡할 가능성이 있다. 따라서 본 연구에서는 이러한 이상값 유형 분류를 이론적 배경으로 삼아, 탐지 결과의 해석과 활용에 있어 맥락적·구조적 특성을 함께 고려하고자 한다.

나. 이상값 탐지기법

본 연구에서는 성능평가 대상 이상값 탐지기법으로 Z-score, 사분위범위법(IQR)과 같은 대표적인 단순 통계기반 기법 4개와, 지수평활(Exponential Smoothing), STL(Seasonal-Trend decomposition using Loess) 등 평활 기반 시계열 기법 4개 등 총 8가지의 대표적인 시계열 이상값 탐지기법을 변수별로 적용하고 비교·평가하였다.

① **표준화점수(Z-score)**: 해당 시계열의 평균과 표준편차를 이용하여 표준화 점수를 계산한 후, 설정된 임계치(예: |Z| > 3) 이상인 데이터를 이상치로 간주하는 전통적인 방법, 자료 분포가 정규분포를 따르면 효과적이지만, 분포의 긴 꼬리나 극단치에 크게 영향

② **수정 표준화점수(Modified Z-score)**: 평균 대신 중앙값(Median)과 중앙값절대편차(MAD=median(|xi-median(x)|)를 사용해 이상치에 대한 robust한 특성, 일반적으로 수정 Z-score Mi의 절대값이 3.5~4.0을 임계치(예: |Mi| > 3.5)로 활용

③ **4분위(IQR)**: 자료의 제1사분위(Q1)와 제3사분위(Q3)의 범위(IQR = Q3 - Q1)를 이용한 이상치 탐지로, 통상 Q1 - k×IQR 이하이거나 Q3 + k×IQR 이상인 데이터를 이상치로 식별(k는 1.5~3.0), 분포 가정에 구애받지 않고 극단치에 강건하지만, 자료의 25%~75% 구간 밖에 있는 값만 탐지하므로 내재 변동이 큰 경우 한계

④ **수정 4분위(M-IQR)**: IQR 방법의 변형으로 왜도에 대한 강건한 통계량인 medcouple (MC)을 적용하여 데이터 왜곡이나 극단값 영향을 줄인 방법

⑤ **이동평균(MA)**: 일정 길이의 이동창에 대한 단순 이동평균을 구하여 직전 시점의 예측값으로 사용하고, 실제 관측값과의 잔차(residual)가 설정 임계치를 넘어서는 경우 이상값으로 간주, Windowsize는 각 시계열의 계절 주기를 감안하여 결정하며, 임계치는 잔차의 표준편차 배수로 설정

⑥ **지수가중이동평균(EWMA)**: 최근 데이터일수록 더 높은 가중치를 지수적으로 감소하도록 부여하여 이동평균으로 예측을 수행하는 방법으로 산업공정의 실시간 이상 탐지 등에 널리 사용

⑦ **지수평활(ES)**: EWMA와 같은 이론 기반, 예측값의 잔차가 통계적 범위 초과시 이상값 판정, 시간에 따라 변화하는 수준(level)과 추세, 계절성 반영을 위해 Holt-Winters 삼중 지수 평활법 적용

⑧ **STL 분해(STL)**: 시계열을 계절(seasonal), 추세(trend), 잔차(residual) 성분으로 분해한 후, 잔차항에 대한 통계적 기준으로 이상값을 탐지, 비선형 계절성도 포획 가능한 유연한 방법으로 이상치가 포함된 데이터에도 비교적 강건하며, 계절적 구조가 뚜렷한 데이터에서 특히 효과적

다. 성능평가 지표

이상값 탐지는 관측치(또는 시점/구간)를 정상(normal)과 이상(anomaly)으로 구분하는 문제로 정식화될 수 있으며, 이는 통계적·기계학습적 관점에서 이진 분류 문제로 해석된다. 이때 탐지기법의 출력은 각 샘플에 대한 이진 예측값(이상/정상) 혹은 이상 점수(anomaly score)와 임계값(threshold)을 통한 이진 판정으로 표현된다. 성능평가의 핵심은 실제 참값(ground truth/real value) 과 모델의 예측 결과를 비교하여, 탐지 성능을 “얼마나 많이 맞추었는가”뿐 아니라 “어떤 종류의 오류가 발생했는가(오탐/미탐)”를 정량화하는 데 있다. 특히 이상값 탐지는 대체로 이상 클래스가 희소(imbalanced)하므로, 단순한 정확도만으로는 모델의 유효성을 충분히 설명하기 어렵고, 정밀도(precision), 재현성(recall), 그리고 이 둘의 균형을 나타내는 F1 스코어 등이 널리 활용된다.

① 혼동행렬 (Confusion Matrix)

혼동행렬은 분류기의 예측 결과를 참값과의 교차표 형태로 요약한 것으로, 이진 분류에서는 다음의 네 범주로 구성된다. 이상값 탐지에서는 보통 이상값을 양성(positive), 정상값을 음성(negative)으로 정의한다.

- TP (True Positive, 진양성): 실제 이상인데 이상으로 탐지
- FP (False Positive, 위양성): 실제 정상인데 이상으로 오탐지(오경보, false alarm)
- TN (True Negative, 진음성): 실제 정상인데 정상으로 판정

○ FN (False Negative, 위음성): 실제 이상인데 정상으로 놓침(미탐지, miss)

이를 행렬로 나타내면 <그림 2.9>와 같다.

Confusion Matrix		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive (Type 1 error)
	Negative	False Negative (Type 2 error)	True Negative

<그림 2.9> 혼동행렬(confusion matrix)

혼동행렬은 단순히 맞고 틀림의 합계가 아니라, 오류의 성격을 구조적으로 보여준다. 예를 들어 FP가 크면 정상 상태를 이상으로 잘못 판단하여 경보가 과도해지고(운영 부담 증가), FN이 크면 실제 이상을 놓쳐 사고·품질 저하를 일으킬 수 있다(리스크 증가). 따라서 이상값 탐지에서는 문제 맥락(운영 비용 vs 위험 비용)에 따라 FP와 FN의 상대적 중요도가 달라지며, 이를 반영하는 평가지표를 선택해야 한다.

② 기본 평가지표: Accuracy, Precision, Recall

이 절에서는 혼동행렬 요소(TP, FP, TN, FN)를 기반으로 가장 널리 쓰이는 기본 지표들을 정의한다. 이상값 탐지 문제에서 전체 샘플 수를 N이라고 하면 탐지 결과는 식(2.16)과 같이 나타낼 수 있다.

$$N = TP + FP + TN + FN \qquad \text{식(2.16)}$$

○ 정확도(Accuracy)

정확도(accuracy)는 식(2.17) 및 <그림 2.10>과 같이 나타낼 수 있는데, 정상과 이상을 모두 포함해 전체적으로 얼마나 맞추었는가를 나타낸다. 즉, 전체 예측 중에서 참값을 맞힌 비율로써 가장 직관적인 성능지표이다.

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \qquad \text{식(2.17)}$$

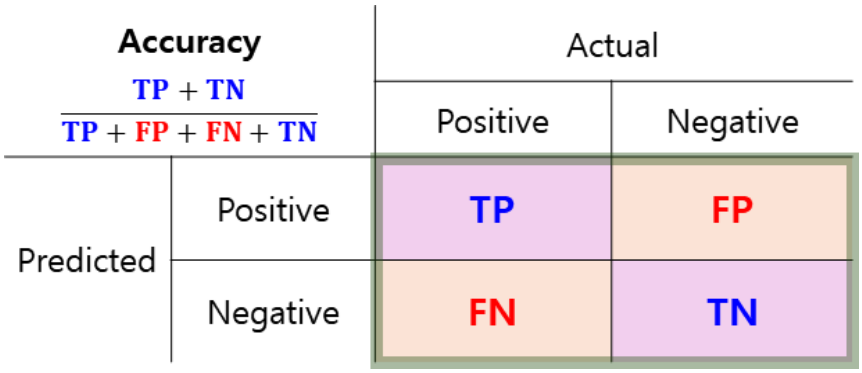

<그림 2.10> 정확도(Accuracy) 지표의 혼동행렬

이상값 탐지 맥락에서는 이상 클래스가 매우 희소한 경우(예: 이상 1%, 정상 99%), 이상값을 전혀 탐지하지 못해도(모든 샘플을 정상으로 예측) 정확도는 0.99로 높게 나타날 수 있다. 즉, 정확도는 불균형 데이터에서 이상 탐지 성능을 과대평가할 수 있는 문제가 있다.

ㅇ 정밀도(Precision)

정밀도(precision)는 모델이 이상값이라고 판정한 것 중에서 실제로 이상인 비율로서 식(2.18) 및 <그림 2.11>과 같이 나타낼 수 있다. 이는 매우 신중하고 보수적인 관점으로, 오탐지(FP)를 얼마나 억제했는지에 초점이 있다. 즉, 이상으로 경보를 울렸을 때 그 경보가 얼마나 믿을 만한가를 의미하며, 정밀도가 높을수록 거짓 경보(false alarm)가 적다.

$$\text{Precision} = \frac{\text{TP}}{\text{TP}+\text{FP}} \qquad \text{식(2.18)}$$

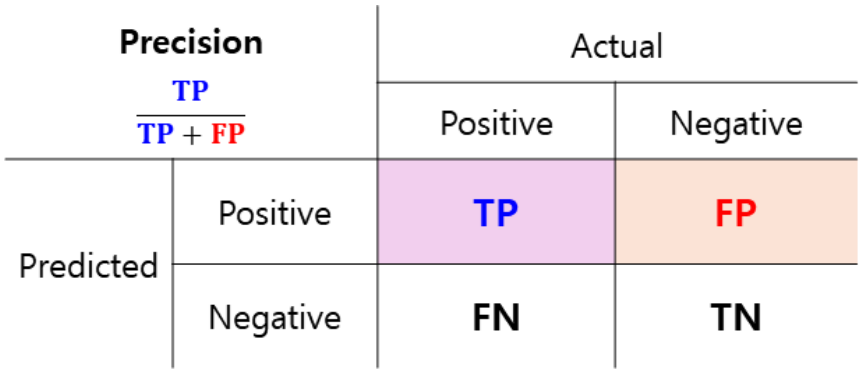

<그림 2.11> 정밀도(Precision) 지표의 혼동행렬

경보 기반 의사결정(현장 출동, 긴급 점검, 공정 제어 등)에서 FP가 많으면 불필요한 비용과 피로(alarm fatigue)가 누적될 수 있다. 따라서 운영 비용이 큰 환경에서는 정밀도를 중요한 목표로 둘 수 있다.

ㅇ **재현성(Recall, Sensitivity, TPR)**

재현성(recall)은 실제 이상 중에서 모델이 이상값으로 올바르게 탐지한 비율로서 식(2.19) 및 <그림 2.12>와 같이 나타낼 수 있다. 이는 매우 공격적인 관점으로 즉, 미탐지(FN)를 얼마나 줄였는지에 초점이 있다. 재현성은 민감도(sensitivity) 또는 진양성률(TPR: true positive rate)로도 불린다.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \qquad \text{식(2.19)}$$

Recall $\frac{TP}{TP+FN}$		Actual	
		Positive	Negative
Predicted	Positive	TP	FP
	Negative	FN	TN

<그림 2.12> 재현율(Recall) 지표의 혼동행렬

안전·품질·규제준수처럼 이상 발생을 놓치면 큰 피해가 발생하는 환경에서는 FN 감소가 핵심이며, 재현성을 우선시할 수 있다.

③ 조화지표: F1 스코어(F1-score)

정밀도와 재현성은 일반적으로 상충(trade-off) 관계에 있다. 예컨대 임계값을 낮추면 이상 판정이 늘어 재현성은 증가할 수 있으나 FP도 늘어 정밀도는 감소할 수 있다. 이러한 상황에서 단일 지표로 두 성능을 균형 있게 요약하기 위해 F1 스코어가 널리 사용된다. F1 스코어는 정밀도와 재현성의 조화평균(harmonic mean)으로 식(2.20)과 같이 정의된다.

$$\text{F}_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \qquad \text{식(2.20)}$$

식(2.20)을 혼동행렬 항으로 전개하면 다음의 식(2.21)과 같이 정리할 수 있다.

$$\text{F}_1 = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}} \qquad \text{식(2.21)}$$

F1은 precision과 recall이 모두 높을 때 크게 증가하며, 둘 중 하나라도 낮으면 값이 크게 제한된다(조화평균의 특성). 즉, 오탐지 억제와 미탐지 감소를 동시에 고려하는 균형 지

표로 활용된다. 이상값 클래스가 희소한 상황에서는 accuracy가 과대평가될 수 있는 반면, F1은 TP, FP, FN을 직접 반영하므로 이상 탐지 성능의 실질적인 품질을 비교하는 데 유용하다. 다만 F1 역시 TN을 직접 반영하지 않으므로(식에서 TN이 나타나지 않음), "정상 판정의 정확성"까지 함께 강조해야 하는 맥락에서는 accuracy 또는 다른 지표와 함께 해석하는 것이 바람직하다.

3) 연구 방법

가. 데이터 수집

본 연구의 적용 대상은 대청댐 추동 조류경보제 지점으로 약 20년간(2005~2023년)의 환경부 조류경보제 및 국가수질측정망 자료, 수자원공사 댐 운영 자료, 기상청 자료 등에서 총 27종(남조류, 클로로필-a, 수온, pH, DO, BOD, COD, TN, TP, TOC, pH, EC, SS, 강우량, 유입량, 최대유입량, 최대방류량, 저수량, 저수위, 평균기온, 최고기온, 평균풍속, 상대습도, 일조시간, 최다일사량, 일사량, 증발량), 지점별 84개의 시계열 자료를 수집하였다.

<표 2.2> 대상지역에서 수집된 저수지 녹조·수질 관련 시계열 자료

구 분	지점 / 자료출처	측정 지표(단위)
녹조	대청댐(추동) / 조류경보제	남조류 세포수 (cells/mL)
일반 수질	대청댐1 / 국가수질관측망	수온(℃), DO(mg/L), BOD(mg/L), COD(mg/L), 클로리필-a(Chl-a, mg/㎥), TN(mg/L), TP(mg/L), TOC(mg/L), 용존총질소(DTN, mg/L), 용존총인(DTP, mg/L),암모니아성질소(NH3-N, mg/L), 질산성질소(NO3-N, mg/L), 인산염인(PO4-Pmg/L)
댐운영	대청댐 / K-water 댐운영자료	일평균 유입량(㎥/s), 일최대 유입량(㎥/s), 일평균 방류량(㎥/s), 일최대 방류량(㎥/s)
기상	보현, 금산, 추풍령, 대전 관측소 / 기상청 지상관측 자료	일평균 기온(℃), 일최대기온(℃), 일강수량(mm), 일조시간(hr), 총일사량(MJ/m^2), 최대 시간당 일사량(MJ/m^2)

나. 데이터 전처리

본 연구에서 활용된 저수지 녹조 관련 시계열 데이터는 <그림 2.13>에 나타낸 바와 같이 서로 다른 생산 주기(시간해상도)에 의한 구조적 결측값과 관측환경 등에 의한 결측값이 혼재되어있는 것을 알 수 있다. 이러한 데이터 특성은 모델 학습 과정에서 노이즈 증가, 파라미터 추정의 왜곡, 예측 안정성 저하 등을 일으킬 가능성이 있으므로, 분석 이전에 체계적인 전처리 과정이 요구된다. 특히 본 연구와 같이 이상값 탐지기법의 성능을 비교·평가하기 위해서는 적절한 결측값 대체를 통해 데이터의 분포적 일관성과 시계열적 연속성 확보가 필요하다.

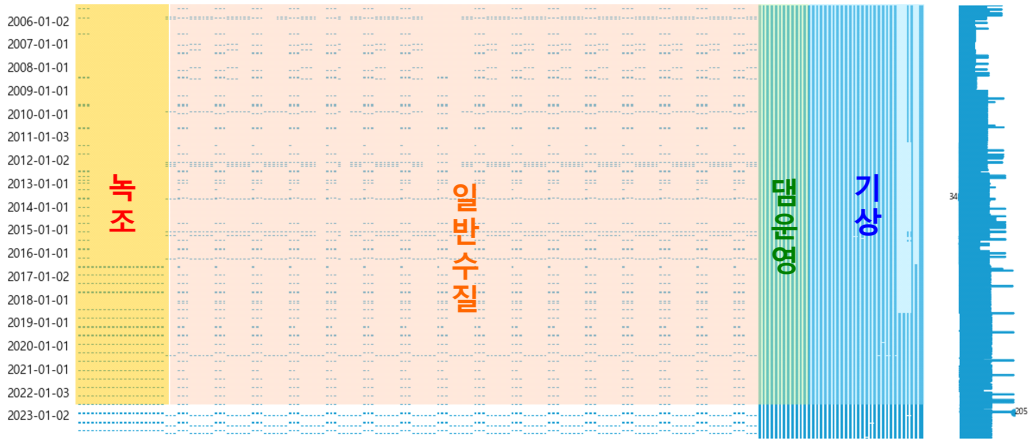

<그림 2.13> 수집된 자료의 변수별 데이터의 시간해상도

① 사전 이상값 필터링

결측값 대체(imputation)를 이상값이 처리되지 않은 상태에서 수행하면 해당 이상값이 대체값 산정 과정에 직접 관여하게 되어 결과적으로 비현실적 또는 왜곡된 대체값을 생성할 가능성이 크다. 예를 들어, k-NN, MICE 등의 머신러닝 기반 결측값 대체기법은 주변 자료 분포에 의존하여 대체값을 추정하는 특성을 갖는데, 이 과정에서 극단적으로 큰(또는 작은) 이상값이 포함되면 국지적 분포를 왜곡하여 인접 샘플 간 유사성 계산과 회귀 추정에 부정적인 영향을 미칠 수 있다.

따라서 본 연구에서는 결측값 대체 이전에 사전 단계로 <그림 2.14>와 같이 Z-score 기반의 통계적 기준($Z > 3$)을 적용하여 비정상적 초극단값을 사전 식별 및 제거하여 이상값 영향이 제거된 상태에서 결측값 대체 수행의 단계로 진행하였다. 이 과정은 자료 생산·입력 과정에서 발생했을 가능성이 높은 단발성(point anomaly)·초극단값을 식별하여 물리적으로 재현 가능성이 낮거나, 센서 이상·데이터 입력 오류로 인한 값일 가능성이 높은 관측치를 사전 배제하기 위한 목적이므로, 현상적 의미가 있는 장기적 경향 또는 맥락적 이상값(contextual anomaly)은 제거하지 않도록 주의를 기울였으며, 오직 데이터 품질 관점에서 "명백하게 비정상적이고 희귀한 값"에 한정하여 필터링을 수행하였다.

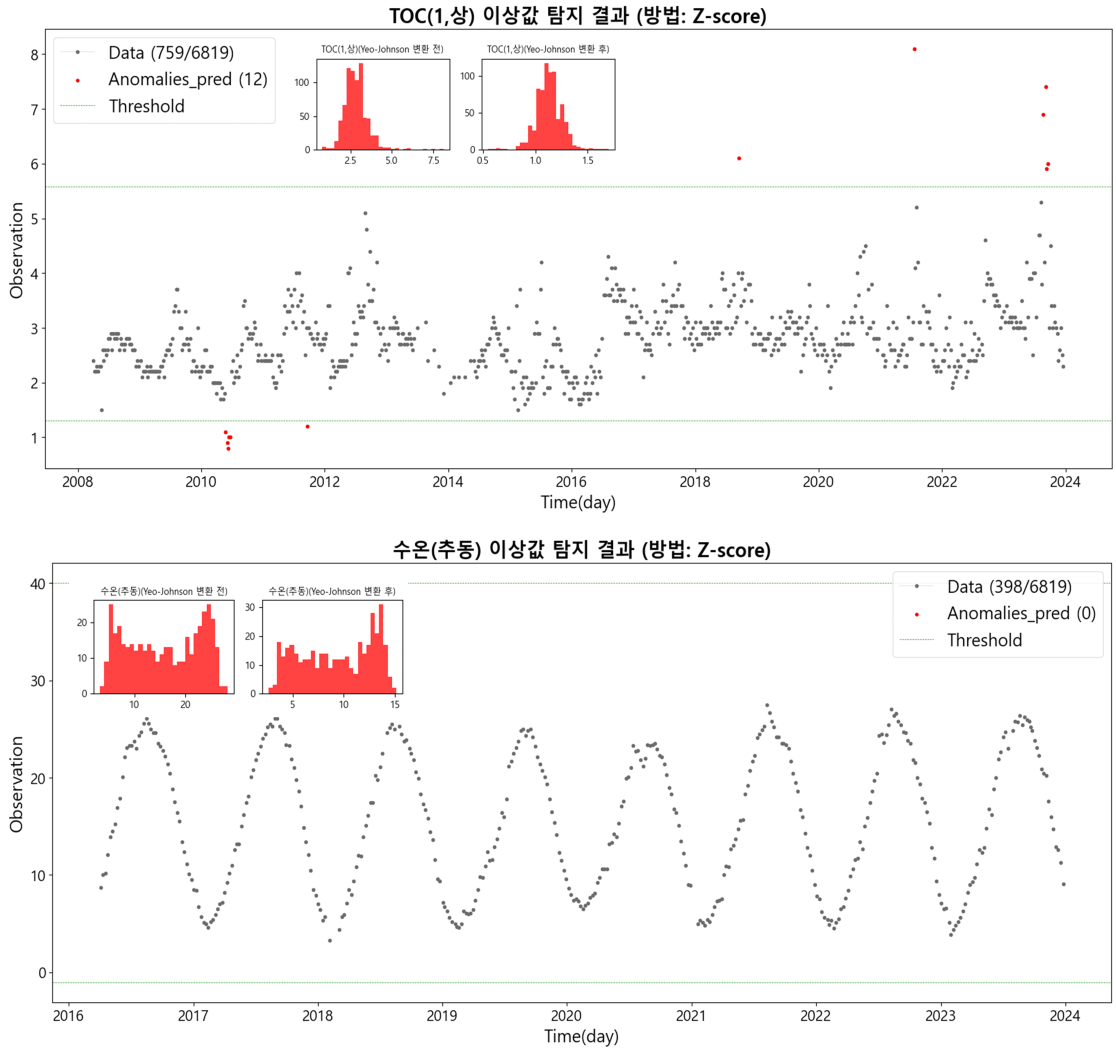

<그림 2.14> Z-Score에 의한 사전 이상값 필터링 결과 (TOC, 수온)

② 시간해상도 불균형에 따른 재표집 (resampling)

녹조, 수질, 댐운영, 기상자료는 서로 다른 관측 주기(예: 시간별, 일별, 주별, 월별)로 생산되므로, 상위 시간해상도로 병합하는 경우 의도적으로 값이 존재하지 않는 시점이 발생한다. 이처럼 관측 설계·표본추출 체계에 의해 발생하는 결측은 일반적인 의미의 무작위 결측(MAR: missing at random)이 아니라, 측정 자체가 수행되지 않은 상태에서 발생한 구조적 결측(structural missingness)으로 해석된다. 구조적 결측은 원자료의 관측 체계에 내재된 특성이므로, 이를 통계적 대체값으로 채우는 것은 존재하지 않았던 관측값을 인위적으로 생성하는 행위이며, 결과적으로 시간적 샘플링 체계를 왜곡시킬 수 있다. 따라서 구조적 결측은 대체 대상이 아니라, 삭제 및 해상도 표준화 대상으로 간주하는 것이 합리적이다.

본 연구는 결측을 인위적으로 대체하기보다 가장 낮은 시간해상도(주별)를 기준으로 하향 표집(down-sampling) 방식의 재표집(resampling)을 수행하였다. 이는 관측자료가 본래의 주기와 목적에 맞게 생산되었다는 점을 고려할 때, 측정 단위와 물리적 의미를 훼손하지 않고 원자료의 관측 설계를 보존하기 위한 조치이다. 낮은 해상도 기준으로 자료를 통합하면

모든 변수의 관측 단위가 동일해짐으로써 변수 간 통계적 비교가능성(statistical comparability) 이 확보되고, 공분산 구조 분석, 시계열 회귀, 머신러닝 기반 예측모델 학습 등에서 편향 없는 비교·추정이 가능해진다. 이러한 점에서, 최저 해상도 기준의 재표집은 본 연구의 분석 목적에 부합하는 합리적인 전처리 전략으로 판단된다. 재표집 시 일주일 내 2개 이상의 자료가 있는 경우에는 <표 2.3>에 나타낸 바와 같이 변수별 특성을 고려해 평균, 합계, 최댓값, 최솟값 등의 대푯값으로 대체하였다. 재표집 결과, <그림 2.15>와 같이 결측값이 삭제되었다.

<표 2.3> 주단위 재표집(resampling)을 위한 변수별 대푯값 설정 기준

구 분	변 수
평 균	수온, pH, DO, 투명도, 탁도, BOD, COD, TN, TP, TOC, EC, DTN, NH3-N, NO3-N, DTP, PO4-P, SS, 저수량, 저수위, 평균기온, 평균풍속, 상대습도, 일사량, 전운량
합 계	평균강우량, 유입량, 방류량, 강수량, 일조시간, 증발량
최댓값	남조류, 클로로필-a, 최대유입량, 최대방류량, 최고기온, 최대일사량
최솟값	-

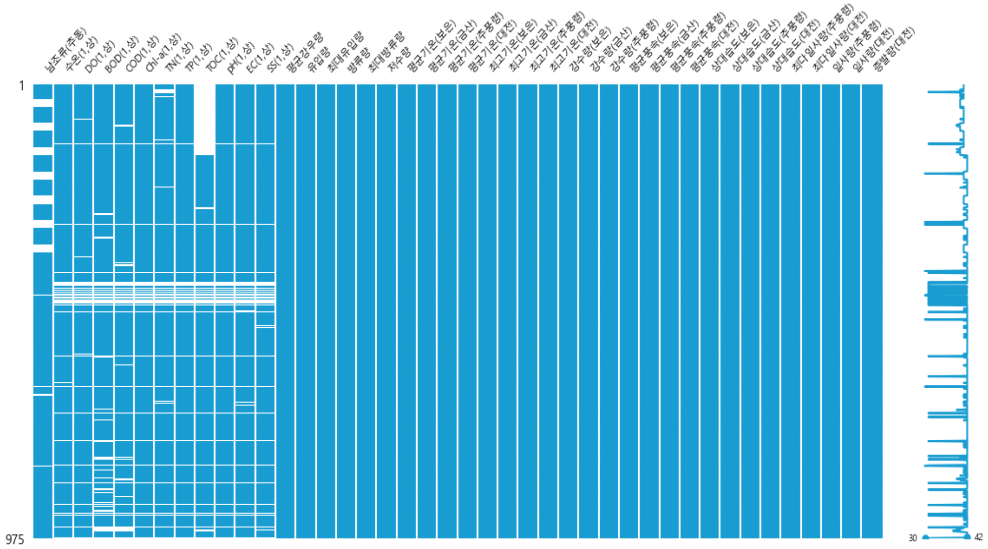

<그림 2.15> 주단위 재표집(resampling) 결과 데이터 분포

③ 결측값 대체 (K-NN)

시간해상도 불일치에 의한 구조적 결측에 대한 재표집 수행 후, 발견되는 결측값은 거리 기반 알고리즘인 k-NN을 활용하여 대체하였다. k-NN은 결측 시점과 유사한 이웃 관측치의 값을 가중 평균하는 방식으로 보간하므로, 원자료에 존재하지 않는 급격한 변동이나 인위적인 피크를 새로 생성하지 않는다는 방법론적 특성을 가진다. <그림 2.16>과 <그림 2.17>는 k-NN에 의한 결측값 대체 결과를 나타내고 있다.

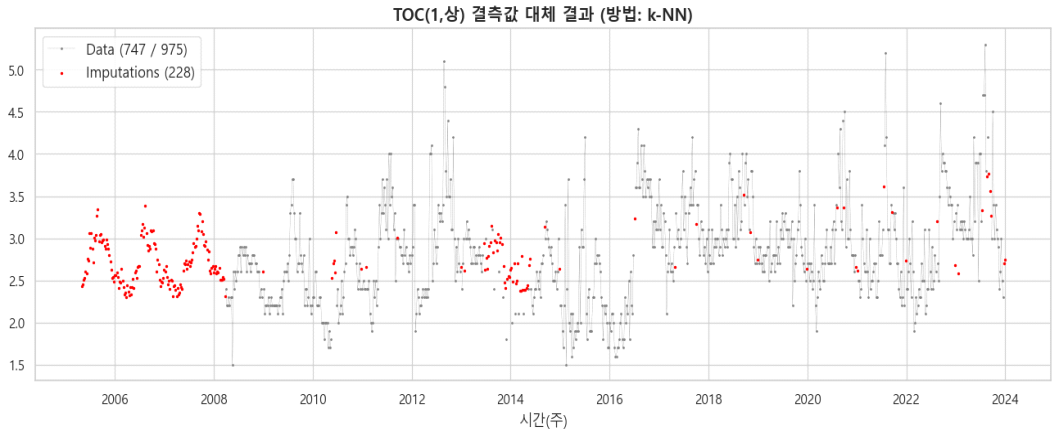

<그림 2.16> k-NN에 의한 결측값 대체 결과(TOC)

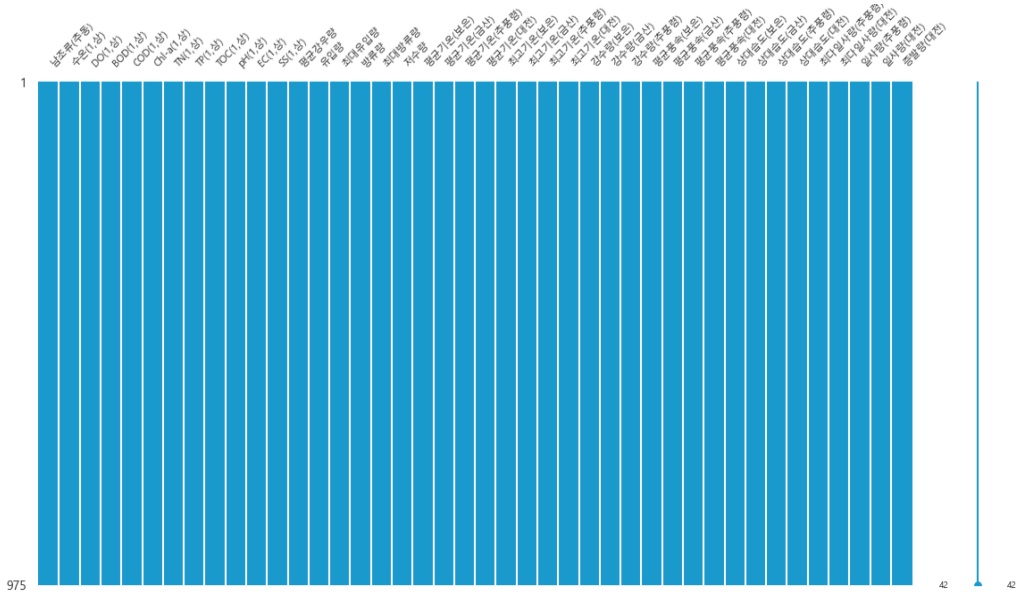

<그림 2.17> 결측값 대체 결과 데이터 분포

다. 성능평가 전략 수립

시계열 데이터에서 이상치를 조기에 탐지하는 것은 수질 관리, 산업 설비 모니터링, 금융 사기 탐지 등 다양한 분야에서 매우 중요한 과제이다. 그러나 이상치는 정상 패턴에 비해 극히 드물게 나타나기 때문에, 탐지 알고리즘의 성능을 정확히 평가하는 것이 어렵다. 이상값 탐지 성능 평가를 위한 지표로는 지도학습 기반의 전통적 분류 성능지표인 정밀도(precision)와 재현율(recall)이 활용될 수 있으며, 두 지표의 조화평균인 F1-점수로 종합 성능을 판단할 수 있다. 정밀도는 탐지된 이상치 중 실제 이상치의 비율, 재현율은 실제 이상치 중 탐지된 비율을 의미한다. 이상 탐지에서는 놓치는 오류를 최소화하기 위해 재현율을 높게 유지하면서도, 오경보를 피하기 위해 정밀도 역시 확보해야 한다.

그러나 현실의 환경·수문·수질·운영 데이터와 같은 실제 관측자료에서는 이상 발생에 대한 객관적 참값(ground truth)이 사전에 정의되지 않은 경우가 일반적이다. 이러한 상황에

서는 분류 성능지표(precision, recall, F1-score 등)를 적용할 수 없으므로 비지도 환경에 적합한 간접적·상대적 평가 방법을 활용해야 한다. 본 연구에서는 이러한 한계를 고려하여 두 가지 평가 접근법을 활용했다. 첫째는 합성 이상값 주입(Synthetic Anomaly Injection) 방법으로, 정상 데이터에 인위적으로 이상 패턴을 삽입한 후 알고리즘이 이를 얼마나 잘 잡아내는지 평가하는 방법이다. 둘째는 모델 합의 기반 평가(Consensus-Based Evaluation) 방법으로, 복수의 이상값 탐지기법이 공통으로 탐지한 샘플을 잠정 이상값으로 정의하고, 각 탐지기법이 이에 얼마나 동의하는지를 평가한다. 본 연구에서는 이러한 두 가지 성능평가 방법을 종합 평가하여 이상 탐지 성능 지표의 차이와 그 의미를 고찰한다. 특히 어떤 평가 지표가 각 상황에 적합한지를 분석하고, 평가 결과의 시각화와 요약 통계를 통해 방법별 성능 특성을 비교하였다.

① 합성 이상값 주입 (Synthetic Anomaly Injection)

합성 이상값 주입 방법은 실제 관측자료의 통계적·시계열적 특성을 최대한 유지한 상태에서 인위적인 이상 패턴을 삽입하고, 이를 참값(ground truth)으로 간주하여 탐지 성능을 평가하는 준지도(semi-supervised) 접근법의 일종이다. 합성 이상값은 실제 데이터에서 관측되는 이상 현상의 특성을 반영하여, 발생 빈도(frequency), 진폭(amplitude), 지속시간(duration)을 고려한 시나리오 기반으로 생성하였다. 이상값 주입 비율(anomaly fraction)은 일반적으로 활용되는 기준에 따라 전체 관측치의 5% 수준으로 설정하였다. 이상값의 크기는 표준화 확률변수(Z-score)를 기준으로 정의하였으며, 이상값 진폭에 무작위성을 부여하기 위해 Z = 2.5∼3.5 범위에서 임의로 생성하였다. 또한, 이상값이 지나치게 인위적으로 보이는 것을 방지하고 미세한 변동성을 반영하기 위해, 생성된 이상값에는 ±0.1σ 수준의 소량의 가우시안 잡음(Gaussian noise)을 추가하였다.

이상 패턴의 유형은 전역 통계 기반 점 이상값(point anomaly)과 지역 통계 기반 문맥적 이상값(contextual anomaly)으로 구분하여, 각각 50%의 확률로 생성하였다. 전역 통계 기반 이상값은 전체 시계열의 평균과 표준편차를 기준으로 정상 범위를 벗어나는 단일 관측치를 생성하는 방식이며, 지역 통계 기반 이상값은 이동 평균과 이동 표준편차를 활용하여 국지적 맥락에서 비정상적인 값을 갖는 관측치를 생성하였다. 이때 지역 통계는 window size 10의 이동 구간을 기준으로 산정하였다.

② 합의 기반 평가 (Consensus-based evaluation)

합성 이상값 주입이 인위적인 이상값을 만드는 방식으로 이상값 탐지기법의 성능을 시험했다면, 참값(ground truth) 없이 탐지 결과의 신뢰도를 간접적으로 평가하는 방안으로 모델 합의 기반 평가(consensus-based evaluation) 방법을 적용하였다. 이 방법은 데이터에 복수의 이상값 탐지기법을 적용한 뒤, 기법 간 탐지 결과의 일치 정도를 활용하여 잠정적인 이상값 집합을 구성하고, 이를 참값으로 가정해 개별 알고리즘의 상대적 성능을 비교하는 접근법이다.

본 연구에서는 평가 대상인 8개의 탐지기법을 적용하였으며, 각 시점(또는 샘플)에 대해 이상으로 판정한 기법의 수를 집계하였다. 그 결과 8개의 기법 중 절반을 넘는 4개 이상의 탐지기법이 이상값으로 판정하면 해당 시점을 합의 이상값(consensus anomaly)으로 정의하였다. 합의 이상값은 단일 기법의 특이한 판단이 아니라, 다수의 서로 다른 탐지 논리에 의해 공통으로 식별된 이상값이라는 점에서 상대적으로 높은 신뢰도를 갖는 가상의 참값으로 간주할 수 있다.

③ 평가 결과 종합화 방법

분류성능 평가지표 관점에서 보면, 합성 이상값 주입의 경우 참값(ground truth)이 있는 경우로 정밀도(precision)로 평가할 수 있는 오탐지(FP: False Positive) 억제성능과 재현율(recall)로 평가할 수 있는 누락(FN: False Negative) 방지성능 간의 균형을 평가할 수 있는 F1-점수를 기준으로 평가하는 것이 타당한 것으로 판단하였다. 여기서 정밀도는 탐지된 이상값 중 실제로 주입된 이상값의 비율로 정의되며, 재현율은 주입된 전체 이상값 중 탐지된 비율을 의미한다. 합의 기반 평가의 경우 “다른 탐지기법들도 공통적으로 식별한 이상값만을 신뢰한다”는 보수적 관점에 기반한 평가 방식이므로, 오탐지를 억제하는 것이 중요한 평가 목표가 된다. 이러한 특성을 고려할 때, 정밀도(precision)는 개별 알고리즘의 탐지 결과가 다른 기법들과 얼마나 일관되게 일치하는지를 나타내는 핵심 지표로 해석될 수 있다. 해당 기법의 정밀도가 낮으면 단독으로 탐지한 이상값의 비중이 상대적으로 높았음을 나타낸다.

방법론적 관점에서 보면, 합성 이상값 주입 기반 평가는 비지도 환경에서도 객관적인 성능 비교가 가능하다는 장점이 있으나, 인위적으로 생성된 이상 패턴이 실제 현장에서 발생하는 모든 이상 현상을 완전히 대변하지는 못한다는 한계가 있다. 반면, 합의 기반 평가는 참값을 알 수 없는 상황에서도 탐지기법간 비교를 가능하게 하는 장점이 있으나, 합의 이상값 자체가 절대적인 참값을 의미하지 않는 한계가 있다.

이러한 점을 종합적으로 고려하여 본 연구에서는 알고리즘의 내재적 성능확인에 적합한 합성 이상값 주입에 의한 F1-점수를 우선 평가하고, 합의 적합도(consensus conformity)를 나타내는 합의 기반 평가에 의한 정밀도를 보조적 수단으로 평가하며, 마지막으로 도메인적 관점에서 전문가 검증으로 평가 결과를 검증하는 다층적 접근방식을 수립하였다.

4) 성능평가 결과

본 연구는 대청댐 추동지점의 조류경보제 관련 27개 녹조 및 일반수질, 댐 운영, 기상자료 항목에 대해 합성 이상값 주입 및 합의 기반 평가 방법에 의해 표준화점수(Zs), 수정 표준화점수(M-Zs), 4분위(IQR), 수정 4분위(M-IQR), 이동평균(MA), 지수가중이동평균(EWMA), 지수평활(ES), STL 분해(STL) 등 8개 탐지기법의 성능을 평가하였다. 평가 결과는 27개 항목의 평균적 성능과 항목별 성능으로 정리해 분석하였다.

가. 평균적 결과 분석

① 합성 이상값 주입 결과

<표 2.4>와 <그림 2.18>에 나타난 결과에서, STL과 ES, MA 등 변화 추세(패턴)를 포착하는 계열의 방법들이 상대적으로 우수한 성능을 보였다. 특히 STL은 평균 정밀도 0.73, 재현율 0.37, F1 0.48로 전체 기법 중 가장 높은 F1을 기록하였으며, ES는 정밀도 0.70, 재현율 0.37, F1 0.47로 STL과 유사한 수준의 높은 성능을 나타냈다. 이는 합성 이상값이 단순 단발성 극단값 보다는 추세 변화 또는 구간적 변동을 포함하는 형태로 주입된 경우, 분해(STL)나 평활(ES) 기반 기법이 작은 추세 이상을 안정적으로 분리·강조할 수 있음을 시사한다.

반면 단순 통계 기반의 점 이상 탐지기법은 상대적으로 제한적인 성능을 보였다. Z-score(Zs)는 정밀도 0.65로 "탐지한 것의 정확성"은 일정 수준 확보하였으나, 재현율이 0.10, F1 0.17로 매우 낮았다. 이는 분산이 큰 시계열에서 임계치를 초과하지 않는 한 이상을 놓치는 경향이 존재함을 의미하며, 결과적으로 추세 변화적 이상값과 같은 점진적 변화는 단순 임계치 기반의 전역 통계량(Z-score)으로 충분히 포착되기 어렵다는 해석으로 연결된다. IQR 기반(IQR, M-IQR) 또한 IQR(0.27, 0.19, 0.14), M-IQR(0.53, 0.34, 0.35)로, 특히 수정 IQR은 IQR 대비 재현율과 F1이 개선되었으나, 최상위 기법(STL/ES) 대비 일관되게 낮은 수준에 머물렀다.

<표 2.4> 평가 방법별 성능지표 평균(28개 시계열 변수)

탐지기법	합성 이상값 주입			합의 기반 평가		
	precision	recall	F1	precision	recall	F1
Zs	0.65	0.10	0.17	0.26	0.19	0.20
M-Zs	0.36	0.30	0.21	0.32	0.61	0.38
IQR	0.27	0.19	0.14	0.34	0.46	0.36
M-IQR	0.53	0.34	0.35	0.25	0.54	0.29
MA	0.73	0.17	0.25	0.13	0.06	0.06
EWMA	0.09	0.16	0.11	0.13	0.59	0.19
ES	0.70	0.37	0.47	0.33	0.48	0.34
STL	0.73	0.37	**0.48**	**0.46**	0.59	0.45

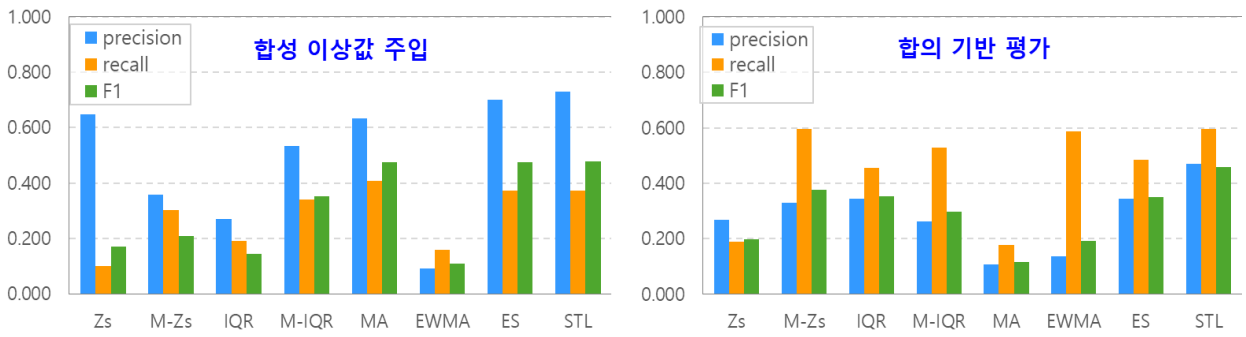

<그림 2.18> 합성 이상값 주입 및 합의 기반 평가 결과의 평균 비교

EWMA는 평균 정밀도 0.09, 재현율 0.16, F1 0.11로 가장 낮은 성능군에 속하였다. 이는 합성 이상값 주입 환경에서 EWMA가 이상과 정상의 분리를 충분히 제공하지 못했거나(예: 임계구간 설정의 보수성 또는 반대로 과도한 정상 흡수), 주입된 이상 패턴(추세 변화 및 구간 변화)에 대한 민감도가 제한적이었음을 시사한다. MA는 정밀도 0.73, 재현율 0.17, F1 0.25로 높은 정밀도 대비 재현율이 낮아, “탐지하는 이상은 비교적 정확하나 많은 이상을 놓치는” 특성을 보였다.

종합하면, 합성 이상값 주입 평가에서의 평균 성능은 Z-점수나 IQR처럼 ‘극단값 여부’를 중심으로 판단하는 기법보다, 이동평균/지수평활/계절-추세 분해(STL)처럼 ‘변화 추세’를 포착하는 기법이 더 효과적이었으며, 이는 주입된 이상값 패턴의 성격(특히 추세 변화)이 결과에 직접적으로 반영된 것으로 해석된다.

② 합의 기반 평가 결과

<표 2.4>와 <그림 2.18>에 나타난 합의 기반 평가의 평균 결과는 합성 주입 평가 대비 전반적으로 정밀도가 낮아지는 경향이 관찰되었다. 이는 합의 이상값이 “다수 기법이 공통으로 찾아낸 이상만을 참으로 본다”는 보수적 정의를 갖기 때문에, 특정 기법이 합의 집합 밖의 이상(혹은 해당 기법만의 탐지)을 많이 표시하는 경우 정밀도가 구조적으로 낮아질 수 있기 때문이다. 다만 재현율은 다수 기법에서 비교적 높게 나타나, 합의 이상값에 대해서는 상당수 방법이 민감하게 반응하는 양상이 확인되었다.

기법별로 보면, STL이 평균 정밀도 0.46, 재현율 0.59, F1 0.45로 합의 기반 평가에서도 가장 높은 F1을 기록하였다. ES는 정밀도 0.33, 재현율 0.48, F1 0.34로 중상 수준의 균형을 보였으며, M-Zs는 정밀도 0.32, 재현율 0.61, F1 0.38로 재현율이 매우 높아 합의 이상값을 놓치지 않는 성향이 두드러졌다. IQR은 정밀도 0.34, 재현율 0.46, F1 0.36으로 M-Zs와 유사한 중상 성능군에 속하였다.

반면 MA는 정밀도 0.13, 재현율 0.06, F1 0.06으로 최저 성능을 보였다. 이는 MA가 국지적 변화에 상대적으로 민감하여 단독으로 많은 이상을 표시(오탐 가능성 증가)하거나, 합의 이상값(다수 기법이 공통으로 지적한 이벤트)과는 다른 유형의 변동에 반응하여 합의 집합과의 일치도가 크게 낮아졌기 때문으로 해석할 수 있다. EWMA는 정밀도 0.13, 재현율 0.59, F1 0.19로 재현율은 높으나 정밀도가 낮아 F1이 제한되는 형태를 보여, 이상값으로 탐지는 많이 하지만 합의된 이상값과의 일치성은 낮은 탐지 성향이 나타났다.

합의 기반 평가의 목적이 오탐율을 줄이고(보수적 관점) ‘다른 기법들도 탐지하는 이상값’을 신뢰 가능한 값으로 보려는 것에 있다는 점을 고려하면, 합의 기반 평가에서는 특히 정밀도가 타 기법과의 일치성 판단의 핵심 척도로 기능한다. 이러한 관점에서 STL은 합의 기반 평가에서도 가장 높은 정밀도(0.46) 및 F1(0.45)을 보이며, 다양한 데이터 조건에서 상대적으로 안정적인 탐지 일관성을 가진 것으로 판단된다.

③ 분석 및 고찰

두 평가 체계를 종합하면 다음의 해석이 가능하다. 첫째, 합성 이상값 주입 평가에서는 이상 패턴이 추세 변화를 포함할수록 STL, ES 등 평활 기반 방법의 우수성이 강화되며, 단순 임계치 기반(Z-score, IQR)은 분산이 큰 시계열 또는 점진적 변화에 대해 재현율이 제한될 수 있다. 둘째, 합의 기반 평가는 “보수적 참값”을 상정하기 때문에, 개별 기법이 탐지한 이상 중 합의 집합과 일치하는 비율, 즉 정밀도가 상대적으로 중요해지며, 이 관점에서도 STL이 가장 균형 잡힌 성능을 유지하였다. 셋째, MA와 EWMA는 평가 체계에 따라 성능 해석이 크게 달라질 수 있는데, 특히 합의 기반 평가에서 낮은 정밀도는 오탐이라기보다 다른 기법과의 불일치(독자적 탐지 성향)를 의미할 수 있으므로, 해당 결과는 기법 선택 시 목표(보수적 운용 vs 민감한 경보)의 차원에서 해석되어야 한다.

나. 항목별 결과 분석

시계열 자료의 항목별 성능평가 결과에 대한 분석은 물리적·통계적 시계열 특성에 따라 이상값 탐지기법의 적합성이 달라질 수 있다는 점을 체계적으로 논의하기 위해 각 항목을 시계열분석 관점에서 정적(stationary), 구조적(structured), 불확정(unstructured) 시계열로 분류하였다. 이후 각 분류군 내에서 (i) 합성 이상값 주입 평가의 F1-score, (ii) 합의 기반 평가의 정밀도를 순차적으로 고려하여 <표 2.5>와 같이 항목별 최적 탐지기법을 도출하였다.

① 시계열 유형 분류의 근거

첫째, 정적 시계열(stationary time series)은 장기적으로 평균과 분산이 비교적 일정하고 계절성 및 추세가 거의 관찰되지 않는 자료를 의미한다. 이러한 자료에서 이상값은 대체로 드물게 외부 사건에 의해 발생하는 갑작스런 점 이상값(point anomaly)의 형태로 나타나며, 평상시에는 분포가 안정적으로 유지된다. 예로, 완충능력이 작용하는 수질 항목(pH 등)은 일반적으로 큰 변동 없이 일정 범위를 유지하는 경향이 있다.

둘째, 구조적 시계열(structured time series)은 뚜렷한 계절 주기 또는 장기 추세 등 구조적 패턴이 존재하여, 시기에 따라 정상 범위가 달라지는 자료이다. 이 경우 이상값은 절대적인 임계치 초과만으로 정의되기보다는, 해당 시점의 맥락(context)을 고려한 문맥적 이상(contextual anomaly)으로 판단되어야 한다. 따라서 구조적 시계열에서는 계절·추세를 반영할 수 있는 분해(STL) 또는 평활(ES 등) 계열의 적용이 요구된다.

셋째, 불확정 시계열(unstructured time series)은 부분적으로 계절성 및 추세가 존재하더라도 외부요인(폭우, 오염 유입, 국지적 교란, 생물학적 증식 등)에 의해 변동성이 크고 불규칙성이 강한 자료를 의미한다. 이 유형은 평상시 낮은 값이 유지되다가 특정 조건을 만족하면 급격한 변화(스파이크)가 발생하기도 하며, 이상 기준(임계값) 자체의 설정이 어려운 경향이 있다. 따라서 이동창 기반 통계량(MA, IQR 등), 적응형 임계기법(EWMA, ES, STL), 또는 로버스트 통계(M-Zs, M-IQR) 등을 활용하여 오탐 가능성을 완화하는 것이 중요하다.

② 항목별 성능 비교 및 최적 기법 선정 결과

ㅇ 정적 시계열: pH, NH_3 -N

정적 시계열로 분류된 항목은 pH, NH3-N이며, 두 항목 모두 대체로 일정 범위를 유지하고 급격한 변화가 발생할 경우를 이상값으로 탐지 가능하다는 점에서 점 이상 탐지가 핵심이다.

- **pH**: 합성 이상값 주입 평가에서 ES(F1=0.48), STL(0.46), M-IQR(0.43)이 상위권을 형성하였다. 합의 기반 평가(precision)에서도 ES(0.16)와 STL(0.25)이 확인되어, 전반적으로 ES가 탐지 성능과 안정성을 동시에 확보하는 것으로 나타났다. 이에 따라 pH의 최적 기법은 ES로 선정하였다.
- **NH3-N**: 합성 이상값 주입 평가에서 M-Zs(0.43), STL(0.41), ES(0.40)이 경쟁적 성능을 보였으나, 합의 기반 평가의 정밀도에서는 M-Zs(0.45), STL(0.84), ES(0.78)로 STL의 일치성이 특히 높게 나타났다. 이는 NH3-N에서 일부 기간을 제외하면 값이 안정적이나 특정 시점의 피크가 이상으로 나타나는 특성이 존재하며, STL이 잡음과 국지적 구조를 분리해 타 기법들과 공통으로 탐지되는 이벤트를 상대적으로 잘 포착했기 때문으로 해석된다. 이에 따라 NH3-N의 최적 기법은 STL로 선정하였다.

요약하면, 정적 시계열에서는 단순 극단값 검출만으로도 일정 수준 성능이 가능하나, 실제 데이터에서 나타나는 미세한 구조(짧은 변동 구간, 국지적 패턴)를 고려할 때 ES 또는 STL과 같은 평활·분해 기반 접근이 평균 성능 및 합의 일치성 측면에서 유리하였다.

ㅇ 구조적 시계열: 수온, DO, 저수량/저수위, 기온, 상대습도, 일조시간, (최대)일사량, 증발량, 전기전도도

구조적 시계열은 계절성 및 추세가 뚜렷하여 정상 범위가 시기별로 달라지고, 이상은 문맥적 맥락에서 판정되어야 한다. 분석결과, 이 범주에서는 전반적으로 STL 및 ES가 우세하였다.

- **수온**: 합성 이상값 주입 F1에서 ES(0.65), STL(0.63)로 상위 성능을 보였으며, 최적기법은 ES로 선정하였다. 계절 패턴 위에서 단기 급변이 발생한다는 분류근거에 부합한다.
- **DO**: 합성 이상값 주입 평가에서 STL(0.61), ES(0.60)이 상위권이며, 최적기법은 STL로 선정하였다. DO는 수온·광량 등과 연계된 계절성이 뚜렷하여, 분해 기반의 문맥 고려가 적합한 것으로 해석된다.
- **저수량/저수위**: 누적량 기반이며 장기 추세(운영·강우 누적 효과)가 존재하므로 STL(0.63), ES(0.61)이 유사한 성능을 보였고, 최적기법은 STL로 선정하였다.
- **평균/최고기온**: 계절 패턴이 매우 뚜렷하고 여름/겨울 기준이 달라 문맥적 판단이 필요하여 ES(0.65), STL(0.63) 성능을 바탕으로 최적기법은 ES로 선정하였다.

- **상대습도**: 장기 계절성이 존재하며 ES(0.53), STL(0.53)의 동률 수준 성능을 보였고, 최적기법은 ES로 선정하였다.
- **일조시간**: 계절성이 뚜렷하되 흐림 등 일시 요인의 영향이 큰 변수로, 합성 주입 평가에서 M-IQR(0.59)이 두드러졌고 최적기법은 M-IQR로 선정하였다. 이는 일조시간에서 이상이 절대값의 극단이라기보다 특정 구간에서의 비정상적 편차로 나타나며, 강건한 지역통계 기반 판정이 오탐 억제에 유리했음을 시사한다.
- **일사량/최대일사량**: 일조시간과 유사한 구조를 가지며 계절 조정이 필요하여 STL(0.65), ES(0.64) 성능을 바탕으로 최적기법은 STL로 선정하였다.
- **증발량**: 온도·일사량과 연계된 계절성이 존재하여 ES(0.57), STL(0.57) 수준이며, 최적기법은 ES로 선정하였다.
- **전기전도도**: 계절성과 함께 수온·운영(유입/방류) 조건의 영향을 받아 STL(0.65), ES(0.62)로 나타났고 최적기법은 STL로 선정하였다.

한편, 구조적 시계열의 다수 항목에서 합의 기반 평가 항목에 “합의 이상값 없음”이 관찰되었다. 이는 과반수 합의(≥50%) 기준으로 정의된 합의 이상값 집합이 해당 변수에서는 형성되지 않았음을 의미하며, 즉 기법들이 공통으로 지목하는 이상 이벤트가 충분히 강하거나 일관되게 나타나지 않았을 가능성을 시사한다. 이러한 경우 합의 기반 평가의 정밀도는 해석력이 제한되므로, 본 연구에서는 합성 이상값 주입 평가(F1-score)와 항목별 시계열 특성(계절 및 추세 보유 여부)을 중심으로 최적기법을 결정하였다. 결과적으로 구조적 시계열에서는 STL/ES가 대부분의 변수에서 우수 또는 최적으로 선정되어, 계절·추세 분리(STL) 및 평활 기반 기법(ES, EWMA, MA)을 통한 문맥 이상값 고려가 핵심임이 재확인되었다.

○ 불확정 시계열: 남조류세포수, 클로로필-a, 유기물/영양염/부유물질, 강우·유입·방류·풍속

불확정 시계열은 변동성이 크고 불규칙성이 강해, 이상값 기준의 설정이 어렵고, 오탐 및 누락 간 균형이 항목별로 크게 달라질 수 있다. 본 연구에서는 각 항목의 물리적 의미(외부 유입 민감도, 생물학적 증식 특성, 스파이크 발생 등)와 함께 합성 이상값 주입 평가의 F1-scroe 및 합의 기반 평가의 정밀도 결과를 종합하여 최적기법을 도출하였다.

- **남조류세포수**: 합성 이상값 주입 평가에서 MA(F1=0.48)가 대표적으로 제시되었고, 합의 기반 정밀도에서도 MA(0.04)로 낮게 나타났다. 이는 남조류세포수가 평상시 저농도 유지 후 특정 조건에서 급격히 변화하는 특성을 가지며, 다수 기법이 동일 이벤트에 합의하기보다는 각 기법이 서로 다른 기준으로 반응할 가능성이 크다는 점을 시사한다. 본 연구에서는 이벤트 민감도를 확보하는 관점에서 MA를 최적기법으로 선정하였다.
- **클로로필-a**: 합성 이상값 주입 평가의 F1-score에서 ES(0.40), STL(0.38), MA(0.38)로 유사했으나, 합의 기반 평가의 정밀도에서는 ES(0.58), STL(0.77), MA(0.33)로 STL의 일치성이 높아 최적기법은 STL로 선정하였다.

- **BOD, COD**: 유기물 계열은 계절성 경향 위에 외부 유입에 따른 급변이 중첩되어 나타나는 경우가 많다. BOD는 M-IQR(0.39), ES(0.38), STL(0.37) 중 최적기법을 STL로, COD는 ES(0.60), STL(0.57) 결과를 바탕으로 STL로 선정하였다.
- **TN**: 합성 이상값 주입 평가에서 M-IQR(0.52), M-Zs(0.50)이 상위이며, 합의 기반 평가에서도 M-IQR(0.30), M-Zs(0.73)이 확인되어 최적기법은 M-Zs로 선정하였다. 이는 TN이 외부유입과 배경 농도의 변동이 혼재한 상황에서 강건한 중심·산포 추정 기반의 점이상 판정이 효과적일 수 있음을 시사한다.
- **TP**: IQR(0.39), M-Zs(0.38) 결과를 바탕으로 최적기법은 IQR로 선정하였다.
- **TOC**: ES(0.57), STL(0.55) 성능을 바탕으로 최적기법은 STL로 선정하였다.
- **DTN**: M-IQR(0.54), ES(0.50) 결과를 바탕으로 최적기법은 ES로 선정하였다.
- **NO3-N**: ES(0.51), STL(0.47), M-Zs(0.47) 중 합의 기반에서 M-Zs(0.56)이 제시되며 최적기법은 M-Zs로 선정하였다.
- **DTP**: STL(0.39), IQR(0.38), ES(0.35), M-Zs(0.34) 가운데 합의 기반에서 STL(0.88)이 두드러져 최적기법은 STL로 선정하였다.
- **PO4-P**: IQR(0.33), M-Zs(0.30), ES(0.29), STL(0.29) 중 합의 기반에서 STL(0.94)로 매우 높아 최적기법은 STL로 선정하였다.
- **SS**: M-Zs(0.41), IQR(0.39), ES(0.38)로 나타났으며 최적기법은 IQR로 선정하였다. 이는 강우·유출 사건의 급격한 탁도/부유물질 변동에서 IQR 기반의 극단값 판정이 실질적인 이벤트 포착에 유효했음을 시사한다.
- **강우량**: STL(0.43) 및 합의 기반 평가의 정밀도에서 STL(0.98)이 제시되어, 최적기법은 STL로 선정하였다.
- **유입량/최대유입량**: 합성 주입에서 MA(0.43)로 나타나 최적기법은 MA로 선정하였다. 강우-유입 연계의 급변 이벤트에서 단기 변동 탐지가 중요하게 작동했음을 의미한다.
- **방류량/최대방류량**: MA(0.36), M-Zs(0.32) 중 합의 기반에서도 MA(0.28), M-Zs(0.44)가 제시되어 최적기법은 M-Zs로 선정하였다. 방류는 운영 계획의 영향을 받아 급변이 "운영상 정상이지만 통계적으로 이례적"일 수 있으므로, 로버스트 기준이 상대적으로 적합했을 가능성이 있다.
- **평균풍속**: M-IQR(0.60) 및 합의 기반 precision에서도 M-IQR(0.21)로 제시되어 최적기법은 M-IQR로 선정하였다.

종합하면, 불확정 시계열에서는 STL/ES가 영양염·유기물·강우 등 다수 변수에서 강세를 보였으나, TN, NO3-N, 방류량, 풍속 등 일부 변수에서는 강건한 통계(M-Zs, M-IQR)가, 남조류세포수·최대유입량과 같이 단기 급변 이벤트 포착이 중요한 변수에서는 MA가 최적으로 선정되는 등, 변수의 물리적 생성 메커니즘과 변동 양상에 따라 최적기법이 분화되는 양상이 뚜렷하였다.

③ 결과의 핵심 시사점

첫째, 변수의 시계열 유형을 고려하지 않은 일괄적 탐지기법 적용은 성능 손실로 이어질 수 있으며, 특히 구조적 시계열에서는 문맥을 반영하는 STL/ES 계열이 사실상 표준적 선택지로 작동하였다. 둘째, 불확정 시계열은 변동성의 원인이 복합적이므로, 합의 기반 평가에서 일치성이 높게 나타나는 기법(STL 등)을 우선 고려하되, 특정 항목(생물학적 급변, 운영 급변 등)에서는 이벤트 민감도를 확보하는 MA 또는 강건한 통계 기반 방법을 병행하는 전략이 필요하다. 셋째, 과반수 합의 기준에서 합의 이상값이 없는 것으로 나타난 항목들은 공통 이상 이벤트가 희소하거나 기법 간 탐지 기준이 크게 다를 가능성을 내포하므로, 이 경우에는 합의 기반 지표만으로 결론을 내리기보다는 합성 이상값 주입 평가 및 도메인 기반 해석을 결합하여 최적기법을 결정하는 것이 타당하다.

<표 2.5> 시계열 자료 항목별 유형 분류 및 탐지기법 성능평가 결과

항목	시계열 유형	분류 근거	F1-Score(합성 이상값주입)	Precision(합의 기반 평가)	최적기법
pH	정적	대체로 일정 범위, 급격한 변화는 이상	ES(0.48), STL(0.46), M-IQR(0.43)	ES(0.16), STL(0.25), M-IQR(0.07)	**ES**
NH3-N	정적	일부 시기 외에는 거의 일정, 피크만 이상	M-Zs(0.43), STL(0.41), ES(0.40)	M-Zs(0.45), STL(0.84), ES(0.78)	**STL**
수온	구조적	계절에 따른 규칙적 패턴, 단기적 급변 발생	ES(0.65), STL(0.63)	합의 이상값 없음	**ES**
DO	구조적	수온·광량 등에 따라 계절성 뚜렷	STL(0.61), ES(0.60)	STL(0.03), ES(0.02)	**STL**
저수량/저수위	구조적	누적량기반, 장기 추세 기반 탐지 필요	STL(0.63), ES(0.61)	합의 이상값 없음	**STL**
평균/최고 기온	구조적	뚜렷한 계절 패턴, 여름/겨울 기준 달라야	ES(0.65), STL(0.63)	합의 이상값 없음	**ES**
상대습도	구조적	장기 계절성 존재	ES(0.53), STL(0.53)	합의 이상값 없음	**ES**
일조시간	구조적	계절성 뚜렷함, 흐림 등 일시 요인 존재	M-IQR(0.59)	합의 이상값 없음	**M-IQR**
(최대)일사량	구조적	일조시간과 유사, 계절 조정 필요	STL(0.65), ES(0.64)	STL(0.10), ES(0.07)	**STL**
증발량	구조적	온도·일사량 연계 계절성 존재	ES(0.57), STL(0.57)	합의 이상값 없음	**ES**
전기전도도	구조적	계절성·수온·혼입물질 등 영향	STL(0.65), ES(0.62)	STL(0.12), ES(0.10)	**STL**
남조류세포수	불확정	계절 경향 있으나 매년 다름, 외부요인 영향 큼	MA(0.48)	MA(0.04)	**MA**
클로로필-a	불확정	조류 개체수에 비례, 해마다 패턴 다름	ES(0.40), STL(0.38),MA(0.38)	ES(0.58), STL(0.77),MA(0.33)	**STL**
BOD	불확정	계절성 약하며 유입 유기물에 따라 급변	M-IQR(0.39), ES(0.38), STL(0.37)	M-IQR(0.28), ES(0.27), STL(0.45)	**STL**
COD	불확정	BOD와 유사, 급성 유입 영향	ES(0.60), STL(0.57)	ES(0.33),STL(0.54)	**STL**
TN	불확정	계절성 있음, 특히 비 후 유입량 영향	M-IQR(0.52), M-Zs(0.50)	M-IQR(0.30), M-Zs(0.73)	**M-Zs**
TP	불확정	TN과 유사, 수온·유입수량 영향	IQR(0.39), M-Zs(0.38)	IQR(0.46), M-Zs(0.23)	**IQR**
TOC	불확정	유기물 유입에 민감, 장기패턴 불안정	ES(0.57), STL(0.55)	ES(0.12), STL(0.25)	**STL**
DTN	불확정	유입에 따라 급변 가능, 계절성 약함	M-IQR(0.54), ES(0.50)	M-IQR(0.19),ES(0.40)	**ES**
NO3-N	불확정	농업기반 유입에 민감, 장기 변화 큼	ES(0.51), STL(0.47), M-Zs(0.47)	ES(0.08), STL(0.29),M-Zs(0.56)	**M-Zs**
DTP	불확정	외부유입 급등 가능성, 예측 어려움	STL(0.39), IQR(0.38), ES(0.35), M-Zs(0.34)	STL(0.88), IQR(0.57), ES(0.50), M-Zs(0.26)	**STL**
PO4-P	불확정	DTP와 유사, 변동성 큼	IQR(0.33), M-Zs(0.30),ES(0.29),STL(0.29)	IQR(0.55), M-Zs(0.44),ES(0.66),STL(0.94)	**STL**
SS	불확정	강우 영향 큼, 특정 시점 급증	M-Zs(0.41), IQR(0.39), ES(0.38)	M-Zs(0.39), IQR(0.73), ES(0.61)	**IQR**
강우량	불확정	계절 경향 있으나 기상 영향으로 변동성 높음	STL(0.43)	STL(0.98)	**STL**
(최대)유입량	불확정	강우와 연계된 변동성 존재	MA(0.43)	MA(0.35)	**MA**
(최대)방류량	불확정	유입량과 연계, 운용 계획 영향 받음	MA(0.36), M-Zs(0.32)	MA(0.28), M-Zs(0.44)	**M-Zs**
평균풍속	불확정	일교차 큼, 일정한 계절성 어려움	M-IQR(0.60)	M-IQR(0.21)	**M-IQR**

2.3 결측값 대체(Missing Value Imputation)

결측값은 관측되어야 할 값을 얻지 못한 데이터로, 발생 메커니즘과 결측의 비율에 따라 분석결과의 편향(bias)이나 통계적 검정력(statistical power)에 문제를 일으키게 된다(고길곤과 탁현우, 2016). 따라서 전처리 단계에서 결측값을 제거(deletion)하거나 적절하게 대체(imputation)하여 데이터의 일관성을 유지해야 한다. 데이터셋에서 결측값은 N/A(Not Available), NaN(Not a Number), Null 등으로 표시되어 있을 수 있으나, 공백, "-", "0" 등 다양한 형태로 나타날 수 있다. 따라서 자료의 도수분포를 살펴보거나 히스토그램을 살펴보는 등 다양한 방법으로 결측값을 확인할 필요가 있다.

2.3.1 결측값 발생 메커니즘 및 처리 방법

1) 발생 메커니즘

결측값은 발생 메커니즘에 따라 완전 무작위 결측(MCAR: Missing Completely At Random), 무작위 결측(MAR: Missing At Random), 비무작위(MNAR: Missing Not At Random) 결측으로 나눌 수 있다.

가. 완전 무작위 결측(MCAR)

결측값의 발생이 다른 변수들과 아무런 관련 없이 순전히 확률적으로 결정되는 경우로 여기에 해당하는 경우는 드문 편이다. 대표적으로 계측장비의 고장이나 전산오류, 입력하는 사람의 실수 등이 이에 해당하며, 이 경우 대규모 데이터셋에서 무작위 표본추출을 통해 대체할 수 있다.

나. 무작위 결측(MAR)

결측값의 발생이 특정 변수와 관련이 있으나, 알고자 하는 결과(결측이 발생한 변수)와는 상관이 없는 경우로 대부분의 결측이 여기에 해당한다. 예를 들어, 수질 측정 시 신입 조사원의 숙련도 부족으로 결측이 발생할 수 있지만, 조사원의 근무연수와 수질 자체는 아무런 관련이 없으므로 무작위 결측(MAR)에 해당한다.

다. 비무작위 결측(MNAR)

결측값의 발생이 결측값이 발생한 변수 자체와 상관성이 있는 경우이다. 만약 체중이 무거운 사람들이 자신의 체중을 설문조사에 응답하지 않았다고 했을 때, 체중에 대한 응답이 누락된 것이 체중 자체에 영향을 받았기 때문에 이는 비무작위 결측(MNAR)에 해당한다. 다만, 체중에 대한 응답이 관측되지 않았기 때문에 실제 관계가 있는지를 검증하는 것은 불가능하다.

앞서 살펴본 결측의 발생 메커니즘은 결측값 처리 방법과 밀접한 관계가 있다. 완전제거법과 같은 전통적인 결측값 대체방법은 MCAR 가정하에서 활용 가능한 방법인 데 비해, 최

근의 다중대체법은 대부분 더 완화된 가정인 MAR에서 불편추정량을 얻는 방법으로 알려져 있다(Baraldi & Enders, 2010).

2) 결측값 처리 방법

<그림 2.19>에 나타낸 것과 같이 결측값을 처리하는 방법으로는 크게 제거(Deletion), 단일대체(Single Imputation), 다중대체(Multiple Imputation), 딥러닝 기반 대체가 있다. 제거는 말 그대로 결측값이 있는 행이나 열 전체를 삭제하는 방법이다. 하지만 데이터를 삭제하는 행동 자체가 중요한 정보를 가진 데이터를 잃을 위험이 있다. 단일대체는 각각의 결측값을 일정한 과정을 통해 생성된 하나의 값으로 대체하는 방법으로, 간단하다는 장점은 있으나 대체로 인한 불확실성을 설명하기에는 미비하다는 단점을 동시에 가지고 있다. 반면 다중대체는 결측값에 대해 대체를 여러 번 수행하여 이들의 평균과 분산으로 분석을 수행하는 방법으로, 대체로 인한 불확실성을 용이하게 추정할 수 있는 장점이 있으나 여러 번의 대체를 해야 하는 부담이 있다.

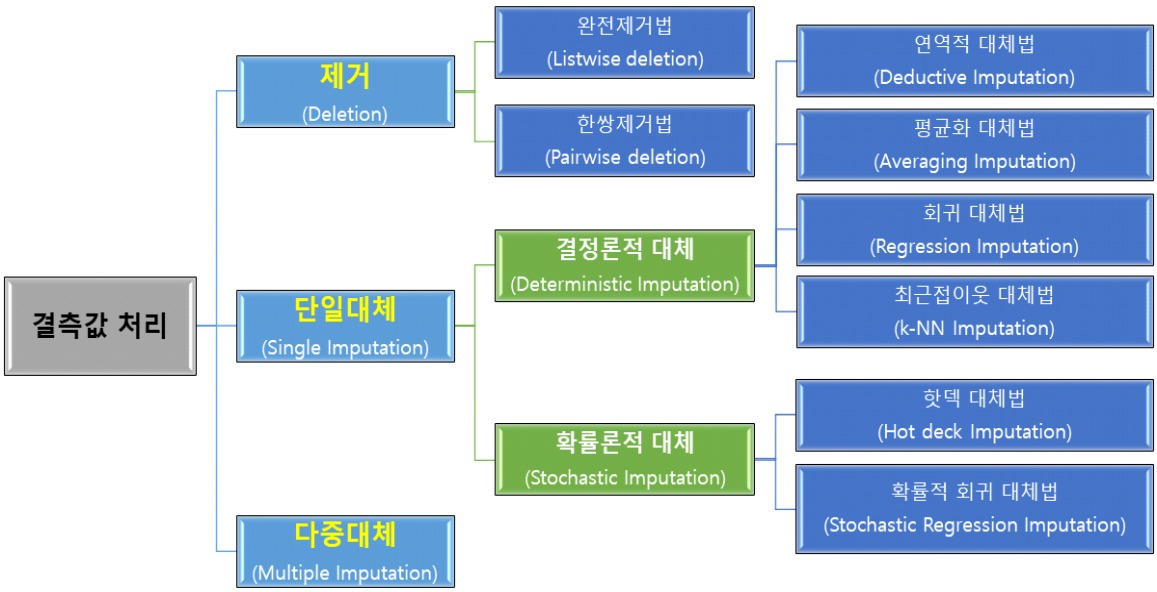

<그림 2.19> 결측값 처리 방법

결측값의 유형이 무작위 결측(MCAR 또는 MAR)이라면, 대부분 가장 전통적인 방법은 제거하는 것이다. 그러나 결측값이 무작위성을 가졌다 해도 단순히 제거하면 데이터 Sample 축소 또는 편향(bias) 등 왜곡이 발생할 수도 있다. 따라서 학습을 위한 데이터가 충분하거나 결측된 데이터의 비율이 높지 않으면(일반적으로 10% 미만) 객체 단위로 제거하고, 그 외에는 최대한 학습데이터 확보를 위해 적절한 값으로 대체하는 것이 바람직하다. 그러나 결측 비율이 지나치게 높으면(일반적으로 50% 이상) 통계적 의미를 찾기 어려우므로 해당 변수를 제거하는 것이 좋다. 물론 대체 후에도 데이터의 왜곡으로 추정량의 편향과 분산의 과소추정 가능성의 왜곡 가능성은 여전히 남아 있다. <표 2.6>은 결측값 비중에 따른 처리 방법을 분류한 것이다.

<표 2.6> 결측값 비율에 따른 처리 방법

결측값 비율	추천되는 결측값 처리 방법
10% 미만	제거 or 대체(대부분의 방법 가능)
10% 이상 20% 미만	핫덱, 회귀, 모델 기반(k-NN 등)
20% 이상 50% 미만	회귀, 모델 기반(k-NN 등)
50% 이상	변수 제거

가. 제거 (Deletion)

① 완전제거법 (Listwise Deletion)

하나의 변수라도 결측값 존재시 행 전체를 제거하는 것으로 불완전한 자료는 모두 무시하고 완전하게 관측된 자료로만 분석하는 방법이다.

② 한쌍제거법 (Pairtwise Deletion)

여러 변수 중 결측값 변수만 해당 분석에서 제외하는 방법으로 각 분석단계에서 사용 가능한 자료를 이용한다. 상관관계 분석과 같이 두 변수 간의 관계를 분석하는 경우, 분석의 대상이 되는 두 변수만 모두 관측되면 분석에 포함하는 방식으로 적용한다.

나. 단일대체 (Simple Imputation) - 결정론적 대체 (Deterministic Imputation)

① 연역적 대체법 (Deductive Imputation)

논리적인 제약조건이나 다른 기록에 의하여 확실하게 대체값을 지정하여 결측값을 대체하는 방법을 말한다. 설문응답을 예로 들면, 같은 조사표상의 비슷한 다른 항목에서 주어진 응답 패턴을 근거로 연역적으로 유추하여 결측값을 대체한다.

② 평균화 대체법 (Averageing Imputation)

관측자료의 평균값, 중앙값, 최빈값 등으로 대체하는 것을 말한다. 간단하게 결측값을 대체할 수 있지만 해당 변수의 분산을 작게 하는 문제와 함께 다른 변수와의 상관관계를 낮추는 등 편향된 추정치를 발생시킨다.

③ 회귀 대체법(Regression Imputation)

관측된 데이터로 단순선형회귀분석(Simple Linear Regression)을 실시하여 얻은 추정치로 결측값을 대체하는 것으로, 결측된 변수의 관측된 값을 종속변수로 하고, 나머지 변수를 설명변수로 하여 추정한 단순선형회귀분석(Simple Linear Regression) 결과를 활용하여 결측된 변수의 결측값을 추정하여 대체한다. 평균화 대체와 달리 설명변수의 조건부 평균으로 결측을 대체하기 때문에 더욱 발전된 방법으로 생각되지만, 이 경우에도 단일대체가 가지는 한계를 그대로 가진다. 즉, 이미 존재하는 값들로 추정한 회귀식이라는 변동이 전혀 없는 고정된 값(fitted value)으로 대체하므로 추정치에 대한 신뢰도가 과대평가 된다는 것이다.

④ 최근접이웃 대체법(k-Nearest Neighbor Imputation)

최근접이웃 대체법은 공간적 다수결 분류법, K-최근린법, 또는 k-NN 법 등으로 불리며, 분석대상을 중심으로 가장 가까운 k개 요소(이웃)들의 평균으로 대체하는 방법이다. 서로 다른 시점 간의 유사도는 주로 유클리드 거리와 같은 거리 기반 함수로 정량화된다. 유사도 함수에 기반하여 서로 다른 k개의 이웃 값들을 추출한 후, 평균 또는 가중평균으로 결측값 대체가 이루어지며(Liu et al., 2019) 직관적인 이론 및 적용 용이성으로 널리 활용되고 있다. 그러나, 고차원 데이터에 적용하는 경우 차원의 저주(curse of dimensionality)로 각 시점 간의 유의미한 유사도 차이를 구별하기 어려워 성능 저하를 겪을 수 있다. 또한, 결측이 빈번하거나 연속적으로 발생하는 경우 적절한 이웃 값을 찾기 어려워지기 때문에 적용이 어려워진다. 결측값과 가까운 정도를 거리 개념으로 파악하므로 변수의 스케일이 중요하고 이상값에도 민감하다. 또한 숫자로만 계산이 가능하므로 범주형 변수에 대해서는 가변수화 이후 진행해주어야 한다.

다. 단일대체 (Simple Imputation) - 확률론적 대체 (Stochastic Imputation)

① 핫덱 대체법(Hot deck Imputation)

다른 변수에서 동일한 특성을 갖는 속성 값을 무작위 추출(random sampling)하여 그 값으로 대체하는 방법으로, 결정론적 대체와 달리 대체 후에도 표본의 분포가 그대로 유지되므로 통계량의 형태에 무관하게 이용할 수 있다.

② 확률적 회귀 대체법(Stochastic Regression Imputation)

결정론적 대체 방식이 결측된 변수의 분산을 과소 추정하는 문제를 줄이기 위하여 소개되었다. 즉, 회귀식에 의해 추정된 값(fitted value)에 일정한 확률오차항(random error term)을 포함해 변동성(variability)을 고려하는 방식인데, 무작위 결측(MAR) 가정하에서 불편 추정치를 유도하지만, 표본오차를 과소 추정하여 1종 오류를 초래하는 문제가 있다(고길곤과 탁현우, 2016).

라. 다중대체 (Multiple Imputation)

한 번의 대체 값으로 결측값을 다루는 단일대체 방식이 갖는 신뢰도 과대평가 문제를 해결하기 위해 단일대체를 거친 여러 개의 데이터셋을 만들어 평가하는 방식이다. 결측값을 제외한 나머지 변수들을 이용해 여러 번 반복을 통해 다수의 대체 값을 생성하고 이들의 평균으로 결측값을 대체한다.

다중대체는 3단계로 구성되는데 가능한 대체 값의 분포에서 추출된 서로 다른 값으로 결측값을 처리한 복수의 데이터셋을 생성한 뒤(imputation phase), 이들 데이터셋에 대하여 각각 분석을 수행하고(analysis phase), 그 결과 얻은 모수의 추정량과 표준오차를 Rubin's rule[1)]에 의해 결합하여(pooling phase) 하나의 대체 값을 도출한다.

이 외에도 대체 방법에는 여러 가지가 있으며, 대체 모델에서는 대체될 변수가 종속변수

이기 때문에 대체될 변수의 데이터 형태에 따라 적절한 대체 방법을 선택해야 한다.

2.3.2 딥러닝을 활용한 결측값 대체 알고리즘

딥러닝 기술은 데이터 내의 복잡하고 비선형적인 패턴을 학습하는 능력을 바탕으로, 기존의 통계적 방법론으로는 포착하기 어려웠던 결측값 대체(Imputation) 문제를 해결하는 데 큰 역할을 하고 있다. 딥러닝 기반의 대체 알고리즘은 손실된 데이터를 가장 그럴듯하고 현실적인 값으로 복원하여 데이터 분석의 신뢰도를 높이는 것을 목표로 한다. 특히 이미지, 시계열, 또는 고차원 테이블 데이터와 같이 구조적 복잡도가 높은 데이터셋에서 강력한 성능을 발휘한다.

1) RNN (Recurrent Neural Network)

시계열 데이터나 순차적 데이터를 학습하여, 시간에 따른 데이터의 변화를 예측할 수 있는 기본적인 순환 신경망이다. RNN은 순차적 입력에 따라 결과를 도출하며, 주로 다변량 데이터를 활용해 결측치를 대체하는 데 사용된다. 최근에는 불규칙한 시계열 데이터에서 결측치를 처리하는 다양한 연구가 진행되고 있다.

2) LSTM (Long Short-Term Memory)

Hochreiter and Schmidhuber (1997)이 제안한 순환 신경망으로 메모리 셀을 추가해 내부에 입력층, 출력층, 망각층으로 구성해 기존 RNN에 있던 가중치 소실 문제를 해결하고 시계열 데이터에 특화되어 있다. 결측값이 없는 완전한 시계열 데이터로 예측 모델을 학습하고 그 결과를 결측값을 포함한 시계열 데이터를 예측하기 위한 모델로 전달해 결측값을 처리한다(황희선과 민대기, 2023).

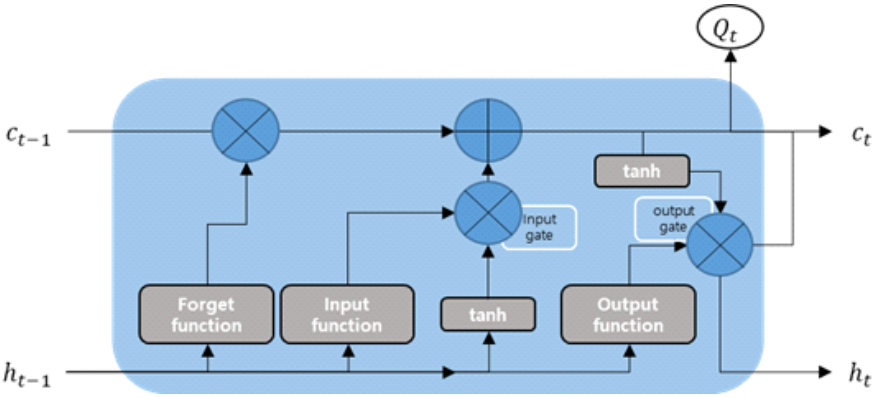

<그림 2.20> LSTM의 구조

1) 각 데이터셋 별로 구한 추정치($\bar{Q}$)와 표준오차($\sqrt{T}$)를 결합하는 과정은 다음과 같다. 추정치의 결합은 각 데이터셋으로부터 구한 추정치의 평균으로 정의된다. $\bar{Q}$의 분산 T는 대체내 분산(within-imputation variance) W와 대체간 분산(between-imputation variance) B의 결합값으로 정의된다.

3) GRU-D (Gated Recurrent Unit with a Decay mechanism)

GRU-D 모델은 GRU(Gated Recurrent Unit)를 기반으로 제안되었다. GRU 모델은 LSTM 모델의 구조를 간략화한 변형 모델 중 하나로 데이터의 결측 구간이 길어짐에 따라 대체된 입력값이 축적되어 예측 성능이 저하되게 된다. 이를 개선하기 위해 GRU-D는 결측치 정보를 마스킹하여 시간 간격을 고려한 감쇠율을 추가, 기존 모델 아키텍처를 보완했다(김에덴 외 3인, 2021). 감쇠율은 결측치와 실제 값들이 시간 간격에 따라 상호작용하는 방식을 모델링하여 결정된다. 이 방법은 시계열의 장기적인 의존성을 처리할 수 있으며, 누락된 결측값 발생 패턴을 반영해 결측치를 더 정확히 예측할 수 있다.

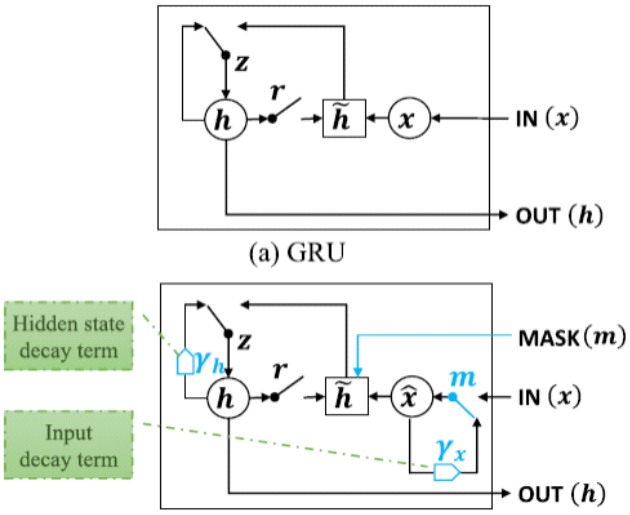

<그림 2.21> GRU-D 구조

출처: Zhengping Che 등(2018)

4) BRITS (Bidirectional Recurrent Imputation for Time Series)

BRITS는 순환신경망 기반의 양방향 결측 대체 모델(Cao, Wei, et al., 2018)로 시계열 데이터의 결측값을 처리하기 위해 제안되었다. LSTM 모델을 이용하여 결측치가 발생한 부분의 값을 예측하며, 연속된 결측치의 경우 이전 결측에 대한 예측값을 입력값으로 활용하여 연속된 결측 구간을 대체한다. 양방향 대체를 통해 단방향 모델(RITS)의 편향 증폭(bias exploding) 문제를 해결하였다. 단일 변수의 시계열적 상관성을 고려한 단방향 및 양방향 모델을 각각 RITS-i, BRITS-i로 제시하였고, 이를 다변량 시계열 데이터에 적용할 수 있도록 확장시켜 RITS 및 BRITS 모델을 제시하였다. RITS 및 BRITS 모델은 공간적 유사도 등 변수 사이의 상관성을 동시에 고려할 수 있도록 설계되었다. 모델들의 학습 과정에서 손실은 평균절대오차(MSE)로 계산되며, 각 스텝별로 축적된 손실 시퀀스를 최소화하도록 학습이 이루어진다. 수질측정망의 측정 자료는 사이의 시계열적 상관관계 및 변수간 상관관계를 동시에 고려할 필요가 있으며, 이에 따라 BRITS 모델을 이용한 결측 대체가 적절하다고 판단된다.

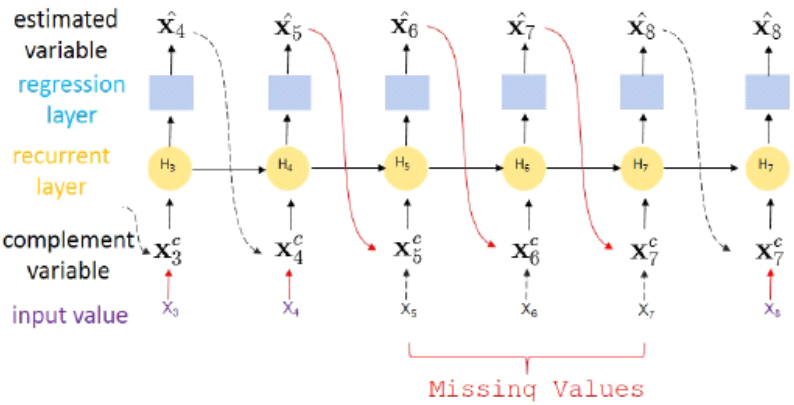

<그림 2.22> BRITS의 결측값 처리 방식

출처: Wei Cao 등(2018)

5) NAOMI(Non-Autoregressive Multiresolution Sequence Imputation)

Liu, Yukai, et al.(2019)이 제안한 NAOMI는 분할정복(divide and conquer) 개념을 기반으로 시계열 자료의 연속된 결측값에 대해 다중 해상도를 고려한 계층적 대체가 이루어지는 비자기회귀적 방법이다. 각 단계의 관측값과 이전 단계의 대체된 결측값을 종합하여 현재 단계의 결측값을 대체한다. 비자기회귀 방식을 채택해 빠르고 병렬적인 대체가 가능하며, 연속된 긴 결측값이나 불규칙한 결측 패턴에서도 높은 성능을 발휘한다. 시계열적 패턴에 대한 명시적 학습이 이루어지지 않는다는 점에서 BRITS와 같은 자기회귀적 모델과 차별화된다.

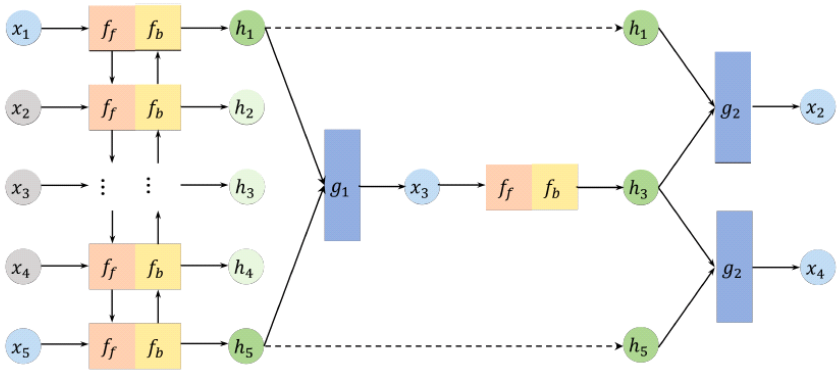

<그림 2.23> NAOMI 구조

출처: Yukai Liu 등(2019)

6) GAIN (Generative Adversarial Imputation Network)

GAIN은 GAN 모델을 활용하여 결측값을 대체하는 방법으로, 생성자 네트워크와 구별자 네트워크가 협력하여 결측값을 예측한다. 생성자는 결측값을 예측하고, 구별자는 생성된 값이 실제 데이터와 얼마나 유사한지 판별한다. 기존 GAN 모델에서 발생할 수 있는 학습 불안정 문제를 해결하기 위해, GAIN은 Hint 행렬을 사용해 구별자의 학습 속도를 생성자와 동일하게 맞추어 두 네트워크 간의 균형 있는 학습을 가능하게 한다(김주영과 김광재, 2022). GAN의 기본 원리는 데이터의 확률적 분포를 학습하여 새로운 데이터를 생성하는 것이다.

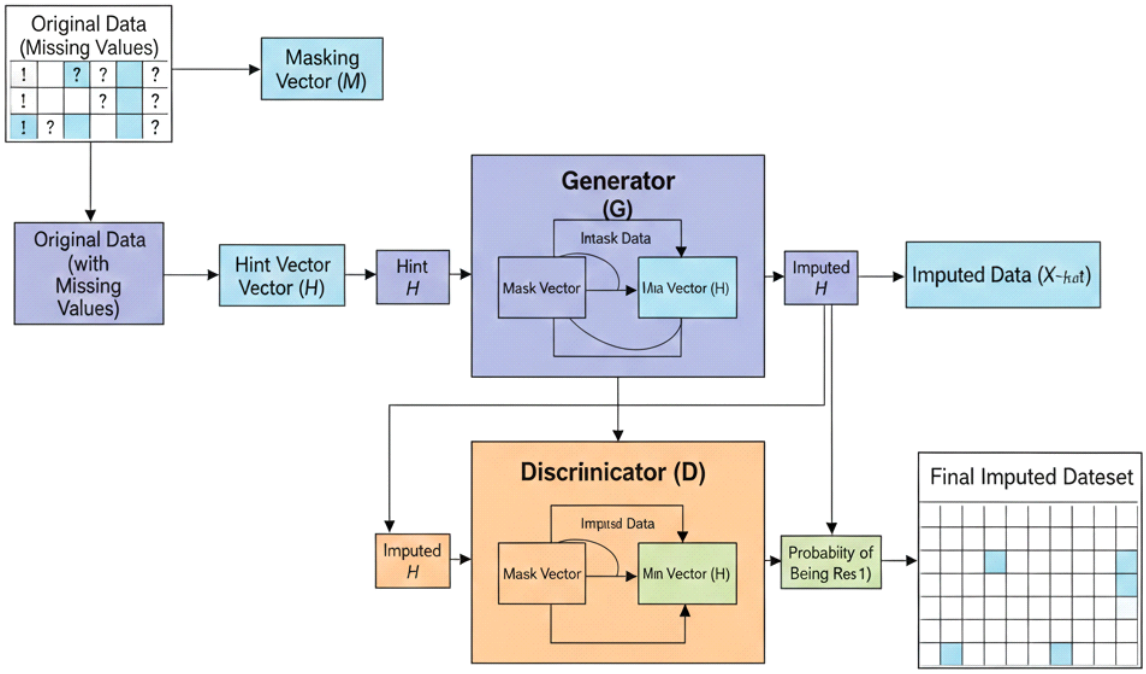

<그림 2.24> GAIN 모델에 의한 결측값 대체 아키텍쳐

출처: Gemini 3(나노 바나나 프로)로 생성한 이미지

생성자(G)는 실제 데이터와 유사한 데이터를 생성하고, 구별자(D)는 실제 데이터와 생성된 데이터를 분류한다. 네트워크는 서로 상호 작용하면서 성능을 개선한다. GAIN은 생성자가 실제 데이터의 일부를 관찰 후, 이를 기반으로 결측 데이터를 대체한다. 구별자는 대체된 값이 실제 데이터와 일치하는지 판별하고 이를 통해 생성자는 실제 데이터 분포를 더 잘 학습할 수 있게 된다.

7) 오토인코더 (Autoencoder)

오토인코더는 입력 데이터를 잠재 공간(Latent Space)으로 압축하는 인코더(Encoder)와, 이를 다시 원래의 입력으로 복원하는 디코더(Decoder)로 구성된 비지도 학습 기반의 신경망 모델이다. 결측값 대체 맥락에서 오토인코더는 데이터 내부의 복잡한 상관관계와 비선형적 패턴을 학습하여, 누락된 정보를 가장 그럴듯한 값으로 예측하여 재구성하는 역할을 한다. 오토인코더를 활용한 결측값 대체 과정은 일반적으로 초기화, 특징 추출, 복원 및 예측, 결측값 업데이트의 단계로 진행된다.

초기화는 결측값을 해당 변수의 평균, 중앙값 또는 0으로 임시 대체하여 완전한 행렬 형태를 만드는 단계이며, 특징 추출은 이 행렬을 코드화(Encoding)하는 단계로 인코더를 통해 입력 데이터의 핵심적인 특징을 저차원의 잠재변수로 압축하게 된다. 이 과정에서 데이터의 노이즈가 제거되고 중요한 구조적 정보만 남게 된다. 복원 및 예측(Decoding) 단계에서는 디코더가 잠재 변수를 활용하여 원래의 입력 데이터를 재구성(Reconstruction)하며, 최종적으로 결측값 업데이트 단계에서 재구성된 출력값 중 원래 결측되었던 위치의 값들을 새로운 예측값으로 업

데이트하게 된다. 이 과정을 반복 수행하여 수렴된 값을 최종 대체값으로 사용할 수도 있다.

오토인코더를 이용한 결측값 대체는 평균 대치, 선형회귀와 같은 전통적 통계 기법과 달리, 다층 신경망을 통해 데이터 간의 복잡한 비선형적 상관관계를 효과적으로 학습할 수 있으며, 변수가 많은 고차원 데이터셋에서도 변수 간의 잠재적 패턴을 추출하여 일관성 있는 대체가 가능하다. 또한 별도의 참값(ground truth) 레이블 없이도 데이터 자체의 분포를 학습하므로 대규모 미분류 데이터셋에 적용하기 유리한 장점이 있다. 오토인코더는 연구의 성격에 따라 기본 모델 외에도 많은 파생형이 사용되고 있다. Denoising Autoencoder (DAE)는 입력 데이터에 의도적으로 노이즈를 추가하거나 일부를 가린 뒤 원래의 데이터를 복원하도록 학습시켜, 결측값 복원 성능을 극대화한 모델이며, Variational Autoencoder (VAE)는 데이터의 확률 분포를 학습하여, 보다 통계적으로 견고한 대체를 수행한다.

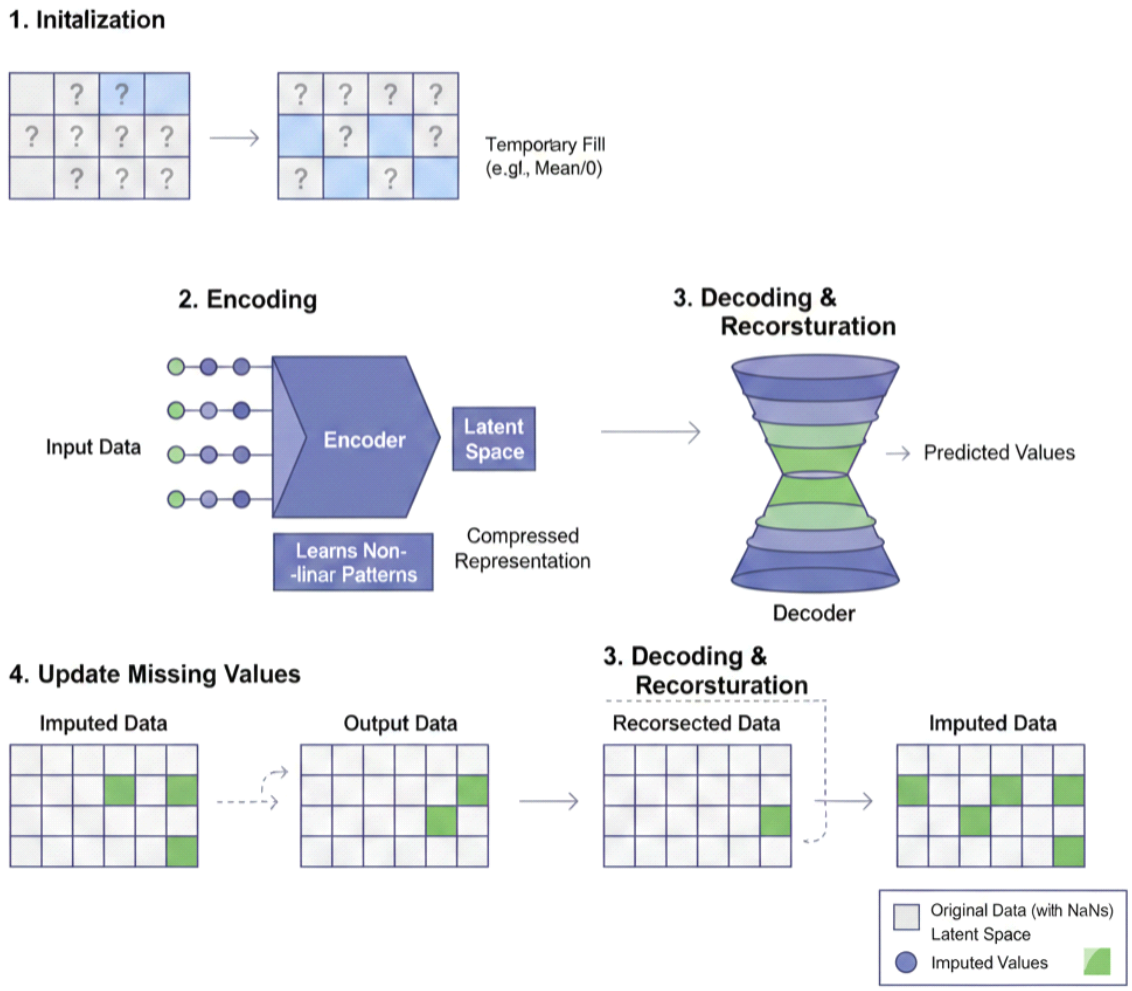

<그림 2.25> 오토인코더 모델에 의한 결측값 대체 아키텍쳐

출처: Gemini 3(나노 바나나 프로)로 생성한 이미지

2.3.3 결측값 대체 알고리즘 성능평가 방안

1) 배경 및 필요성

녹조 현상은 전 세계적으로 심각한 환경문제가 되고 있다. 기후변화로 인한 수온 상승과 산업화에 따른 오염 부하량의 증가로 인해 조류 발생의 빈도와 심도가 매년 확대되고 있으며, 이에 따른 수질 악화와 생태계 교란은 인류에게 지속 가능한 물 관리의 과제를 제기하고 있다(Paerl & Otten, 2013; Smith et al., 1999). 조류는 식물성 플랑크톤이 과다 증식하여 물이 짙은 녹색으로 변하는 현상으로, 이는 영양염류, 수온, 일사량, 체류시간 등 복합적인 요인에 의해 발생한다(Anderson et al., 2002). 조류는 일반적으로 특성에 따라 규조류, 녹조류, 남조류로 구분되며, 특히 남조류 중 독성물질을 생성하는 유해 남조류(마이크로시스티스, 아나베나, 오실라토리아, 아파니조메논)의 증식은 심각한 녹조 현상(HABs, Harmful Algal Blooms)을 유발할 수 있다. 이러한 유해 녹조 현상은 생태계와 공공 보건에 직접적인 위협을 가하므로, 조류 증식의 원인과 특성을 파악하여 선제적으로 관리하는 체계가 필요하다(Wurtsbaugh et al., 2019).

이를 위하여 환경부는 물환경보전법 제21조에 의거, 물환경측정망 및 조류경보제 운영을 통해 전국적으로 녹조 발생을 모니터링하고 있다(환경부, 2024). 물환경측정망은 측정 목적과 대상에 따라 수질측정망, 총량측정망, 자동측정망 등으로 구성되며, 조류경보제는 이러한 측정 자료를 바탕으로 운영된다. 현재 전국의 29개소(상수원 호소 22개소, 상수원 하천 6개소, 친수활동 구간 1개소)조류경보제 지점을 대상으로 수온, pH, 용존산소(DO), 클로로필-a, 유해 남조류 세포 수 등을 주 1회 이상 측정하고 있으며, 경계 단계 이상의 경보 발령 시 주 2회로 측정 빈도를 확대한다. 이러한 자료는 K-water에서 관리되는 일부 측정소를 포함하여 물환경정보포털을 통해 공개되어 다양한 연구와 정책적 목적으로 활용되고 있다.

그러나, 수집된 데이터는 여전히 몇 가지 한계를 가지고 있다. 첫째, 측정 과정에서 발생하는 데이터의 결측치(missing data)는 분석의 정확성과 신뢰성을 저하시킬 수 있다. 둘째, 녹조 및 관련 변수는 기상 요인, 수문학적 요인 등 다양한 요인들과 상호작용하기 때문에(김영우 외, 2017) 단일한 결측 대체 방법을 일괄적으로 적용하기 어려운 특징을 지닌다. 기존 연구에서 결측치를 대체하는 방법은 주로 단순 대체 기법이거나, 모든 변수에 대해 동일한 전처리 방식을 사용하는 경우가 많았다. 이러한 접근법은 각 변수의 특성과 상관성을 충분히 고려하지 못해 대체 과정에서 오차가 발생할 가능성이 높다.

최근 딥러닝의 발전은 데이터 결측 대체 문제에도 새로운 가능성을 제시하고 있다. 특히, 순환신경망(최한준 외, 2022), 어텐션 메커니즘 기반 모델(Du et al. 2023) 등 고도화된 딥러닝 모델들은 데이터의 시계열적 특성과 복잡한 상관관계를 활용하여 높은 성능을 보여주고 있다. 그러나 최신 알고리즘이 항상 모든 상황에서 가장 우수한 성능을 보이는 것은 아니다. 모델의 성능은 데이터의 특성과 결측 양상에 따라 크게 달라질 수 있으며, 데이터 품질에 대한 높은 의존성을 가진다. 따라서 각 변수의 특성과 상황에 따라 적합한 결측 대체 방안을 고려할 필요가 있다.

본 연구에서는 녹조 및 녹조 관련 변수들을 대상으로 다양한 결측 대체 기법을 적용하고,

그 성능을 비교·분석하고자 한다. 특히, 딥러닝 기법뿐만 아니라 전통적인 대체 기법과의 성능 비교를 통해 각 변수와 결측 양상에 적합한 대체 기법을 제시한다. 이를 통해 데이터 품질을 개선하고, 녹조 관리와 예측의 신뢰성을 높이는 데 기여하고자 한다.

2) 이론적 배경

가. K-nearest Neighbors Imputation

KNN 기반 대체는 결측값을 대체하기 위해 가장 가까운 k개의 이웃 값을 활용하는 방법이다. 서로 다른 시점 간의 유사도는 주로 유클리드 거리와 같은 거리 기반 함수로 정량화된다. 유사도 함수에 기반하여 서로 다른 k개의 이웃 값들을 추출한 후, 평균 또는 가중평균으로 결측값 대체가 이루어진다 (Liu et al., 2019). KNN 기반 대체는 직관적인 이론 및 적용 용이성으로 널리 활용되고 있다. 그러나, 고차원 데이터에 적용하는 경우 차원의 저주(curse of dimensionality)로 각 시점 간의 유의미한 유사도 차이를 구별하기 어려워 성능 저하를 겪을 수 있다. 또한, 결측이 빈번하거나 연속적으로 발생하는 경우 적절한 이웃 값을 찾기 어려워지기 때문에 적용이 어려워진다.

나. BRITS

BRITS(Bidirectional Recurrent Imputation for Time Series)는 순환신경망 기반의 양방향 결측 대체 모델이다(Cao, Wei, et al., 2018). LSTM 모델을 이용하여 결측치가 발생한 부분의 값을 예측하며, 연속된 결측치의 경우 이전 결측에 대한 예측값을 입력값으로 활용하여 연속된 결측 구간을 대체한다. 양방향 대체를 통해 단방향 모델(RITS)의 편향 증폭(bias exploding) 문제를 해결하였다.

단일 변수의 시계열적 상관성을 고려한 단방향 및 양방향 모델을 각각 RITS-i, BRITS-i로 제시하였고, 이를 다변량 시계열 데이터에 적용할 수 있도록 확장시켜 RITS 및 BRITS 모델을 제시하였다. RITS 및 BRITS 모델은 공간적 유사도 등 변수 사이의 상관성을 동시에 고려할 수 있도록 설계되었다. 모델들의 학습 과정에서 손실은 평균절대오차(MSE)로 계산되며, 각 스텝별로 축적된 손실 시퀀스를 최소화하도록 학습이 이루어진다. 수질측정망의 측정 자료는 사이의 시계열적 상관관계 및 변수간 상관관계를 동시에 고려할 필요가 있으며, 이에 따라 BRITS 모델을 이용한 결측 대체가 적절하다고 판단된다.

다. NAOMI

Liu, Yukai, et al.(2019)이 제안한 NAOMI (Non-autoregressive multiresolution sequence imputation)는 분할정복(divide and conquer) 개념을 기반으로 시계열 자료의 연속된 결측값에 대해 다중 해상도를 고려한 계층적 대체가 이루어지는 비자기회귀적 방법이다. 각 단계의 관측값과 이전 단계의 대체된 결측값을 종합하여 현재 단계의 결측값을 대체한다. 비자기회귀 방식을 채택해 빠르고 병렬적인 대체가 가능하며, 연속된 긴 결측값이나 불규칙한

결측 패턴에서도 높은 성능을 발휘한다. 시계열적 패턴에 대한 명시적 학습이 이루어지지 않는다는 점에서 BRITS와 같은 자기회귀적 모델과 차별화된다.

3) 연구 방법

가. 데이터 수집

다양한 조류경보제 지점 중, 데이터 수집 기간 및 수집 항목의 수를 고려하여 대청댐 일대를 분석 대상으로 선정하고 데이터를 수집하였다. 환경부 물환경정보시스템, 기상청 기상자료개발포털, K-water 물정보포털로부터 2004년 4월 1일부터 2023년 12월 31일까지 녹조 및 수질 관련 자료, 기상자료, 댐 운영 자료를 수집하였다. 수집된 데이터는 일 단위 및 주 단위로 데이터가 혼재하여 일 단위 데이터는 주간 평균을 산출하여 분석에 활용하였다. 총 206개의 측정 항목이 수집되었으나, 장기적으로 연속된 결측이 존재하거나 결측 비율이 지나치게 높은 항목들을 제외하고 83개 항목을 분석에 활용하였다. 최종적으로 분석에 활용된 데이터는 1,253개의 데이터 샘플에 83개 데이터 항목을 가지며, 데이터 수집 지점이 <그림 2,26>에 나타나 있다.

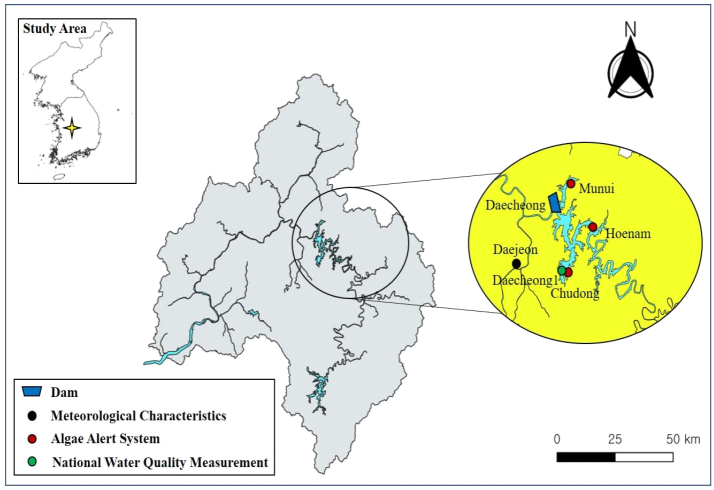

<그림 2.26> 연구대상 지역 (대청댐 추동지점)

조류경보제의 법적 기준이 되는 남조류 세포 수 및 남조류 세포 수와 관련이 높은 클로로필-a 농도를 대체 알고리즘 적용 데이터로 선정하였다. 또한, 녹조 현상의 주요 영향 인자인 수온 및 총인을 함께 포함시켰다. <그림 2.28>과 <그림 2.29>는 분석 대상인 남조류 세포 수, 클로로필 a 농도, 수온, 총인을 각각 시계열 그래프 및 상자 그림(box plot)으로 나타낸 것이다.

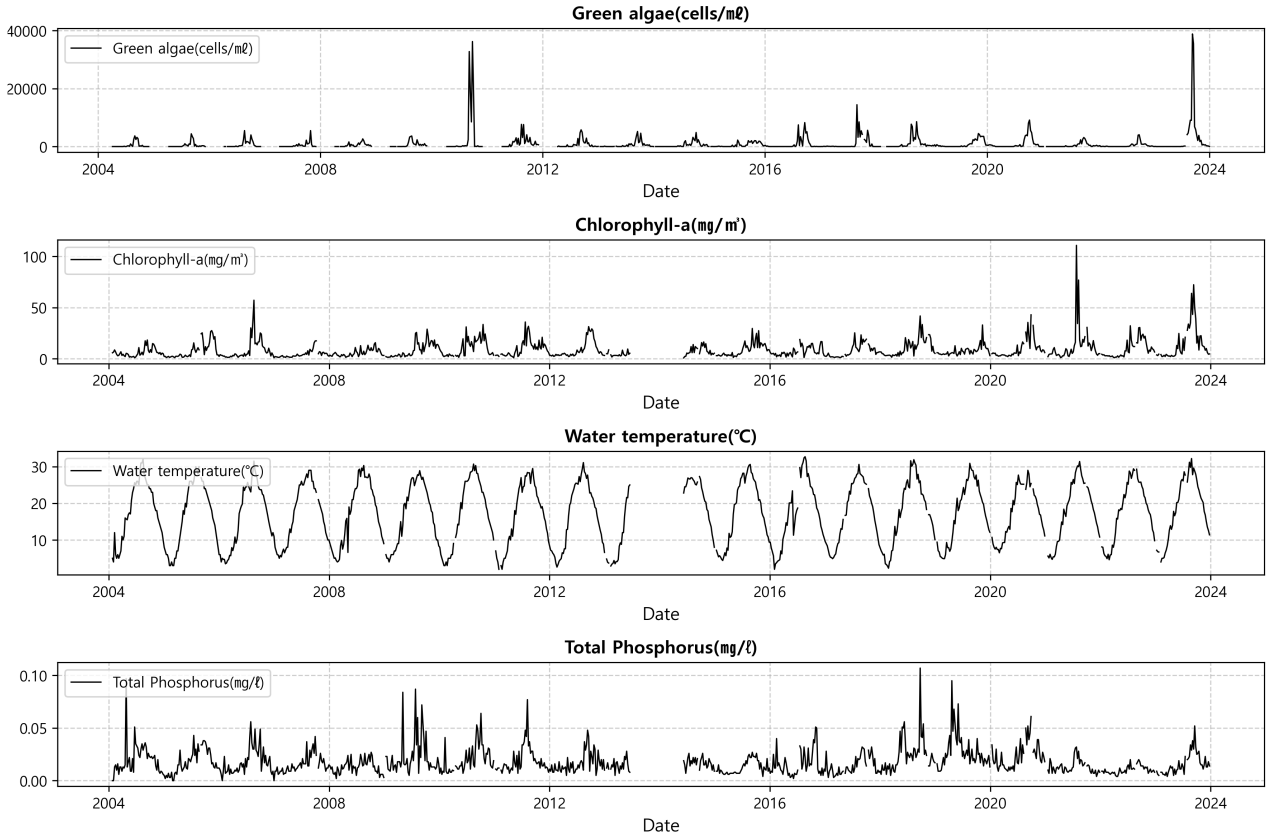

<그림 2.27> 주간 단위의 수질 항목별 시계열 자료 현황

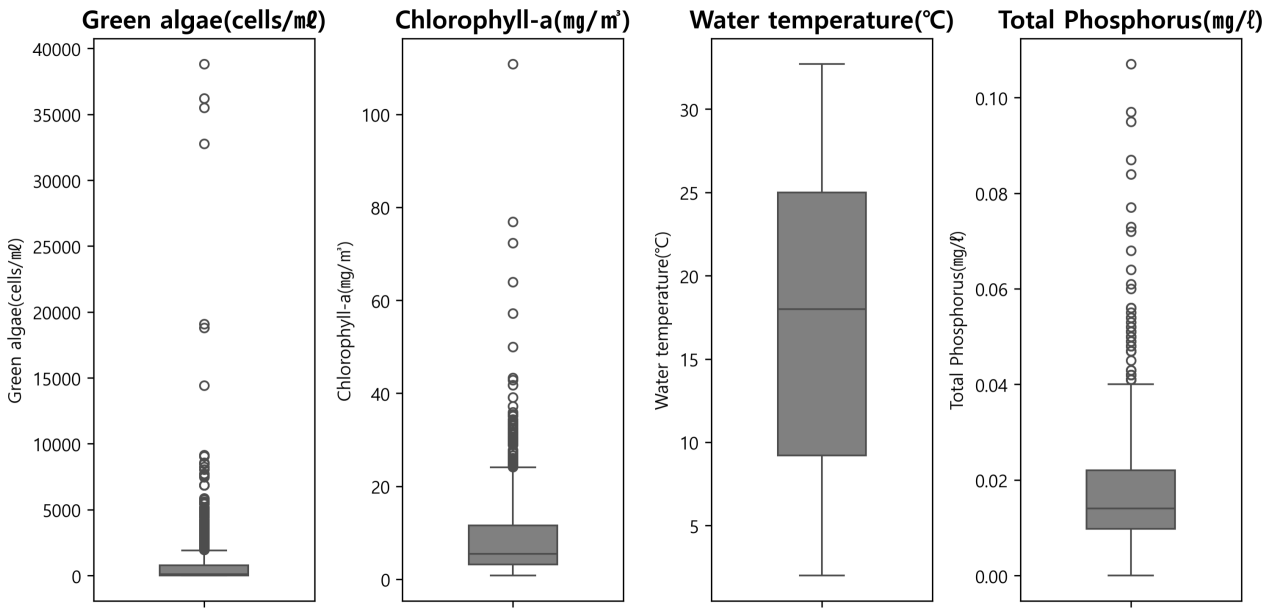

<그림 2.28> 주간 단위 시계열 자료의 상자그림

나. 대체 성능 비교를 위한 결측 삽입

대체 알고리즘의 성능을 비교하기 위해 실제 측정값을 알고 있는 구간에 결측을 삽입하였다. 연속적인 결측 기간에 따른 대체 알고리즘의 성능을 비교하기 위하여 결측 기간을 <표 2.7>과 같이 2주, 4주, 8주로 설정하였다. 남조류 세포수의 변동이 강한 하절기의 대체 성능이 상대적으로 중요할 것으로 판단되어 결측 생성 시점은 하절기로 선정하였다.

<표 2.7> 결측값 삽입 기간

기간	결측값 삽입 기간
2주간	2016-09-01 00:00:00 ~ 2016-09-15 00:00:00, 2018-09-01 00:00:00 ~ 2018-09-15 00:00:00
4주간	2016-09-01 00:00:00 ~ 2016-10-01 00:00:00, 2018-09-01 00:00:00 ~ 2018-10-01 00:00:00
8주간	2016-08-01 00:00:00 ~ 2016-10-01 00:00:00, 2018-08-01 00:00:00 ~ 2018-10-01 00:00:00

다. 대체 알고리즘 적용 및 성능 비교

남조류 세포 수, 클로로필 a 농도, 수온, 총인에 대해서 <표 2.6>의 구간에 따라 삽입된 결측값을 선형 보간, k-NN, BRITS, NAOMI 기법을 활용하여 대체하였다. 선형 보간법의 경우 별도의 최적화 과정이 수반되지 않지만, k-NN, BRITS, NAOMI 기법의 경우 trial-and-error를 통해 하이퍼파라미터를 최적화하였다. k-NN 알고리즘의 경우, 변수의 수가 많아서 모든 변수를 이용하여 데이터 간 유클리드 거리를 계산할 경우 유의미한 거리를 측정하기 어렵다. 따라서, 변수 간 피어슨 상관계수를 산출한 후 각 대상 변수와 0.5 이상의 피어슨 상관계수를 갖는 변수만을 추출하여 최근접 이웃 계산에 활용했다. 또한, 최근접 이웃의 수를 적게 설정할수록 단일 데이터 포인트의 영향이 커지고 크게 설정할수록 여러 데이터 포인트의 평균적인 경향을 반영하게 되므로 적절한 값을 찾아야 한다. 최근접 이웃의 수는 10으로 설정하였다.

BRITS와 NAOMI는 별도의 변수 선정 과정 없이 모든 변수를 모델의 입력 변수로 활용하고, 이에 부합하는 충분한 모델의 복잡도를 부여하였다. 두 모델의 적용에서 공통적으로 은닉층의 크기는 256, 학습률은 0.001, 옵티마이저는 adam, 배치 크기는 32로 설정하였다. 학습 손실의 수렴을 모니터링하여 각각 에폭의 값은 30, 80으로 설정하였다. 대체 실험의 조건들을 설정한 내용이 <표 2.8>에 요약되어 있다.

<표 2.8> 결측값 대체 실험의 조건 설정

	k-NN	BRITS	NAOMI
타겟변수	남조류세포수, 클로로필-a, 수온, TP		
입력값	r > 0.5	모든 변수	모든 변수
하이퍼파라미터	k=10	h=256 epoch=30 learning rate=0.001 optimizer = adam batch size = 32	h=256 epoch=80 learning rate=0.001 optimizer = adam batch size = 32

본 연구에서는 대체 알고리즘의 성능을 평가하기 위해 RMSE(Root Mean Squared Error)와 MAPE(Mean Absolute Percentage Error) 식(2.22) 및 식(2.23)과 같은 두 가지 성능지표를 사용하였다. RMSE는 예측값과 실제값의 오차의 제곱 평균에 루트를 취한 값으로, 예측값이 실제값에 얼마나 가까운지를 측정한다. 반면, MAPE는 실제값에 대한 예측값과 실제값 간 오차의 비율을 백분율로 나타낸 것이다. RMSE는 제곱을 취하는 방식으로 극단적인 값이나 큰 오차에 민감하게 반응한다. MAPE는 실제값에 대한 오차의 비율을 취하는 방식으로 작은 값에서의 오차에 민감하다. 상호보완적으로 활용될 수 있는 두 성능 지표를 통해 대체 알고리즘의 성능을 확인하였다.

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2} \qquad \text{식(2.22)}$$

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y_i}}{y_i}\right| \qquad \text{식(2.23)}$$

4) 결과 분석

가. 변수별 결측 길이에 따른 대체 알고리즘 성능 비교

변수별로 결측 길이에 따른 대체 알고리즘의 성능을 비교하였다. 남조류 세포수, 클로로필-a, 수온, 총인의 네 가지 변수에 대해 각각 2주, 4주, 8주의 연속적인 결측 구간을 설정하여 RMSE와 MAPE 지표를 통해 성능을 평가하였다. 결측 대체 결과에 대한 성능지표는 <표 2.9>에 정리되어 있으며, <그림 2.29> 및 <그림 2.30>과 같이 그래프로 나타내었다.

<표 2.9> 주간단위 수질 자료에 대한 결측값 대체 알고리즘별 성능평가 결과 비교

항목	결측기간	성능지표	Linear	k-NN	BRITS	NAOMI
남조류 세포수 (대청댐 추동) cells/mL	2weeks	RMSE	2737.95	1957.05	2227.54	2039.66
		MAPE	600.35	257.22	164.55	446.72
	4weeks	RMSE	2935.14	3195.34	4399.57	3354.98
		MAPE	213.00	127.68	102.00	192.99
	8weeks	RMSE	3148.95	2955.31	4622.05	3225.05
		MAPE	181.55	145.53	86.94	201.52
클로로필-a (mg/L)	2weeks	RMSE	3.83	1.89	1.93	6.99
		MAPE	22.37	14.20	14.49	47.94
	4weeks	RMSE	6.71	3.77	12.07	9.27
		MAPE	21.71	17.78	37.24	44.77
	8weeks	RMSE	8.67	5.20	9.27	8.85
		MAPE	156.56	100.82	97.67	102.32
수온 (℃)	2weeks	RMSE	1.77	2.38	1.15	1.72
		MAPE	5.34	8.00	3.17	5.56
	4weeks	RMSE	1.49	1.89	1.36	2.53
		MAPE	4.73	5.83	4.53	8.62
	8weeks	RMSE	2.40	2.83	5.67	5.88
		MAPE	6.68	7.60	16.59	16.99
TP (mg/L)	2weeks	RMSE	0.0098	0.0113	0.0064	0.0077
		MAPE	26.23	40.79	26.31	31.30
	4weeks	RMSE	0.0251	0.0320	0.0284	0.0311
		MAPE	23.84	41.73	40.72	40.79
	8weeks	RMSE	0.0187	0.0240	0.0219	0.0236
		MAPE	28.63	39.79	39.63	53.16

남조류 세포수의 경우 RMSE의 관점에서, 2주의 짧은 결측 구간에서는 k-NN, BRITS, NAOMI가 선형 보간에 비해 우수한 성능을 보였다. 그러나 결측 구간이 길어지면서 <그림 2.29>와 같이 BRITS의 성능은 급격히 저하되었고, 8주의 긴 결측 구간에서는 NAOMI가 가장 우수한 성능을 나타내었다. 이는 BRITS가 연속적인 결측을 처리할 때 입력 데이터의 품질에 민감한 반면, NAOMI는 계층적 대체 구조를 통해 장기 결측 처리에 강점을 가지기 때문으로 판단된다. MAPE의 관점에서는 <그림 2.30>과 같이 모든 결측 구간에서 BRITS와 NAOMI가 선형 보간보다 우수한 성능을 나타냈다. 이는 남조류 세포수가 극단적인 피크값과 작은 값이 혼재된 데이터 특성을 가지고 있기 때문으로 분석된다.

클로로필-a 농도의 경우, 2주의 짧은 결측 구간에서는 k-NN과 BRITS가 RMSE와 MAPE 두 지표 모두에서 낮은 값을 기록하였다. 그러나 결측 구간이 길어짐에 따라 BRITS의 대체 성능은 저하되었으며, k-NN 기법이 가장 우수한 성능을 나타냈다. NAOMI 역시 장기 결측

대체에서 강점을 보였으나, 클로로필-a의 안정적인 시계열 변동성으로 인해 k-NN 기법이 상대적으로 더 높은 성능을 기록하였다.

수온 데이터는 계절적 변동성이 뚜렷하며 선형적인 패턴이 강하게 나타난다. 이러한 특성으로 인해 선형 보간법은 결측 길이에 관계없이 RMSE와 MAPE 두 지표 모두에서 가장 우수한 성능을 보였다. BRITS는 2주의 짧은 결측 구간에서 선형 보간법과 유사한 성능을 나타냈으나, 결측 구간이 길어질수록 선형 보간법에 비해 성능이 저하되었다. 총인의 경우, 2주 결측 구간에서는 BRITS가 RMSE 기준으로 가장 우수한 성능을 보였으나, MAPE 기준으로는 선형 보간이 가장 우수했다. 4주 및 8주 결측 구간에서는 RMSE와 MAPE 두 지표 모두에서 선형 보간법이 가장 우수한 성능을 나타냈다. 이는 총인이 극단적인 값이 거의 나타나지 않으며, 변동 폭이 작고 단조로운 경향을 보이는 데이터 특성 때문으로 판단된다.

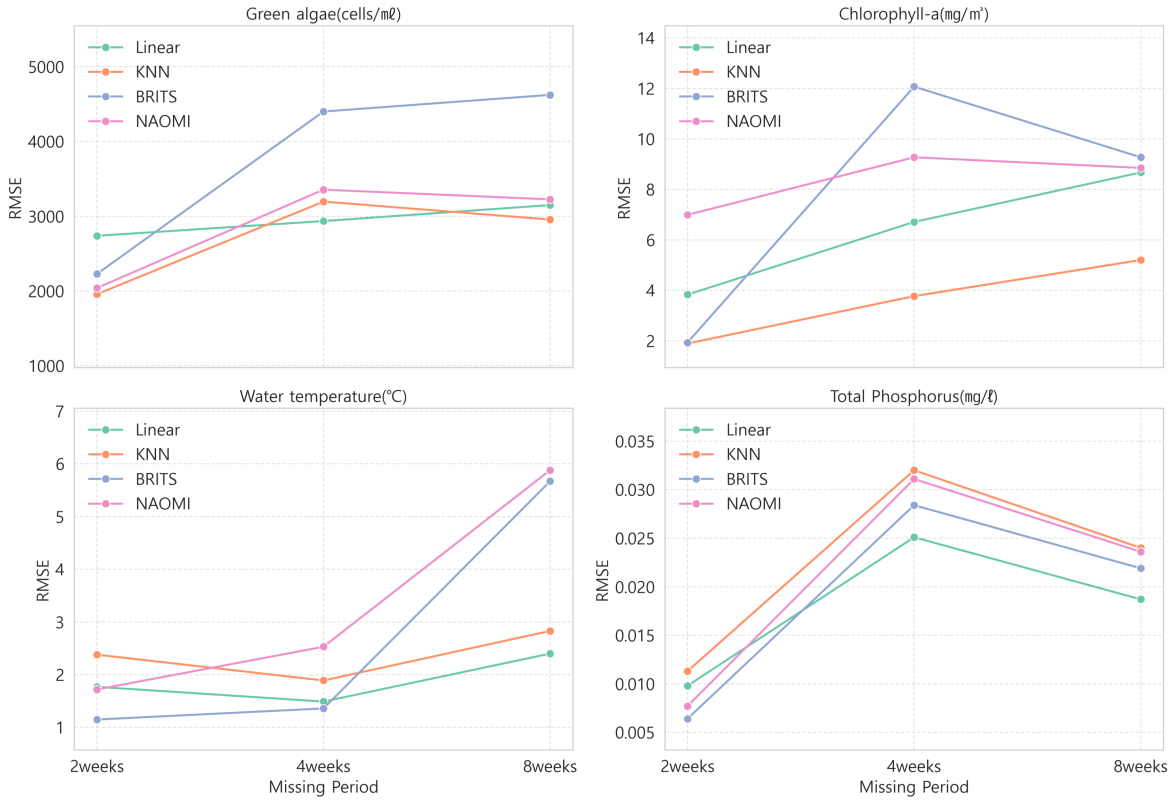

<그림 2.29> 결측 기간에 따른 결측값 대체 모델별 성능 비교(RMSE 기준)

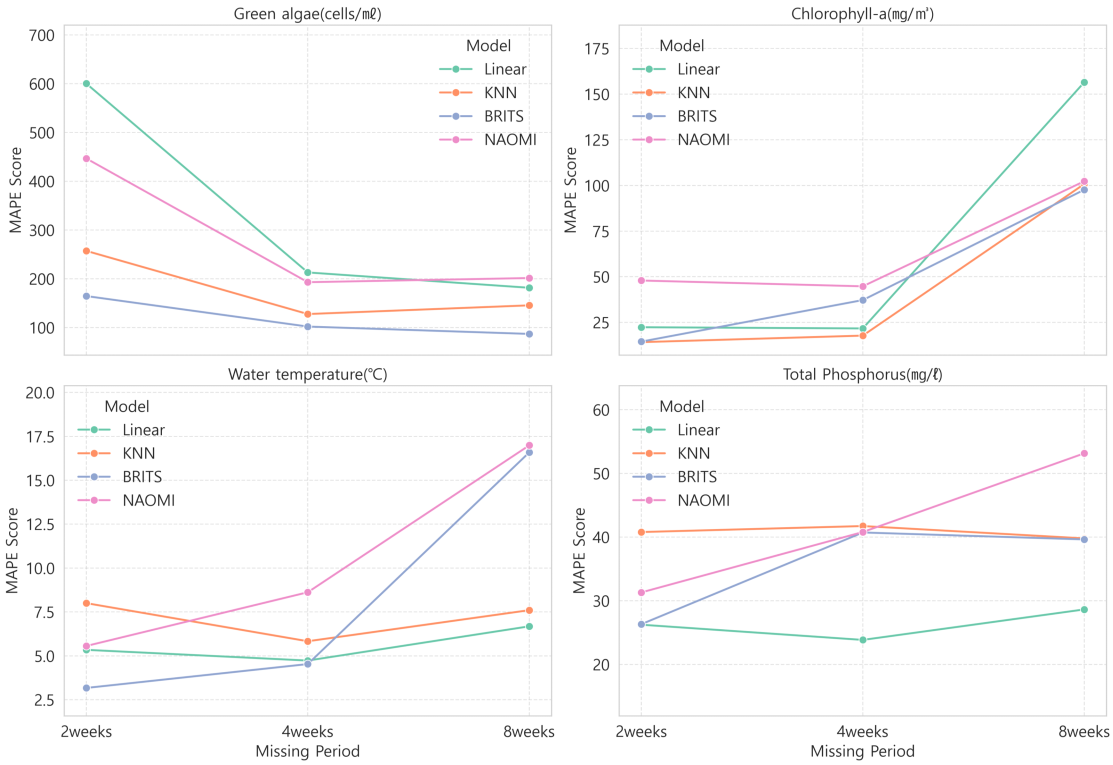

<그림 2.30> 결측 기간에 따른 결측값 대체 모델별 성능 비교(MAPE 기준)

나. 변수에 따른 대체 알고리즘 성능 비교

변수의 특성에 따라 대체 알고리즘의 성능이 다르게 나타나는 경향을 확인할 수 있었다. 이는 각 변수의 데이터 특성과 결측 양상이 대체 성능에 직접적인 영향을 미친 것으로 분석된다. 남조류 세포수는 여름철 극단적인 피크값과 작은 값이 혼재된 데이터로, 시계열적 변동성이 크고 복잡한 패턴을 가진다. RMSE 기준으로는 짧은 결측 구간(2주)에서는 KNN, BRITS, NAOMI 순으로 우수한 성능을 보였으나, 결측 구간이 길어질수록 NAOMI가 가장 낮은 RMSE를 기록하며 장기 결측 처리에 강점을 보였다. 반면, MAPE 기준으로는 BRITS와 NAOMI가 극단적인 값의 비율적 오차를 효과적으로 줄이며 더 우수한 성능을 나타냈다. 이는 MAPE가 작은 값의 변화를 민감하게 평가하며, BRITS와 NAOMI가 피크값과 작은 값을 잘 포착했기 때문으로 분석된다.

클로로필-a는 남조류 세포수와 밀접한 상관성을 가지지만 변동성은 상대적으로 낮고 안정적이다. 2주의 짧은 결측 구간에서는 KNN과 BRITS가 모두 우수한 성능을 보였으나, 결측 구간이 길어질수록 KNN이 RMSE와 MAPE 두 지표 모두에서 가장 낮은 값을 기록하며 성능이 우수했다. NAOMI는 장기 결측 처리 강점에도 불구하고, 상대적으로 단순한 데이터 특성에서는 KNN에 비해 성능이 낮게 평가되었다. 수온 데이터는 계절적 패턴이 뚜렷하며, 값이 선형적으로 변화하는 특성을 보인다. 모든 결측 구간에서 선형 보간법이 RMSE와 MAPE 두 지표 모두에서 가장 우수한 성능을 나타냈다. BRITS와 NAOMI는 2주의 짧은 결측 구간에서는 선형 보간법과 유사한 성능을 보였으나, 결측 구간이 길어질수록 상대적으로

복잡한 대체값을 생성하여 성능이 저하되었다.

총인은 값의 변동폭이 작고 극단적인 값이 거의 나타나지 않는 안정적인 데이터를 보인다. 2주 결측 구간에서 BRITS는 RMSE 기준으로 우수한 성능을 보였으나, MAPE 기준에서는 선형 보간법이 더 우수한 결과를 보였다. 4주 및 8주 결측 구간에서는 RMSE와 MAPE 두 지표 모두 가장 낮은 값을 기록한 선형 보간법을 가장 효과적인 대체 방법으로 판단할 수 있다. 이는 변동이 크지 않은 데이터 특성상 간단한 보간법이 실제값과 근접한 대체값을 생성했기 때문으로 판단된다.

5) 결론

본 연구는 수질 관리에서 중요한 문제인 녹조 현상의 관리와 관련하여, 수집 및 관리되는 수질 데이터를 기반으로 다양한 결측 대체 알고리즘을 적용하였다. 특히, 최근 여러 분야에서 뛰어난 성능을 보이고 있는 딥러닝 기반 대체 알고리즘을 적용하고, 기존의 전통적인 방법들과 대체 성능을 비교하였다. 딥러닝 기반 대체 알고리즘은 우수한 대체 성능을 보였으나, 여전히 데이터의 특성과 결측 패턴 등 여러 요소를 고려할 필요가 있다.

대청댐 일대의 남조류 세포 수, 클로로필-a, 수온, 총인 데이터를 대상으로 선형 보간법, KNN, BRITS, NAOMI 대체 알고리즘을 적용한 결과 결측 구간의 길이 및 데이터 특성에 따라 각 알고리즘의 성능이 달라지는 것을 확인하였다. 남조류 세포수, 클로로필-a 농도와 같이 변동폭 및 낮은 값과 높은 값 간의 차이가 큰 경우 BRITS, NAOMI와 같은 딥러닝 기반 알고리즘이 효과적이었다. 다만, 결측 길이와 성능 지표의 특성에 따라 KNN이 더 우수한 성능을 보이기도 한다. 수온과 같이 주기성 및 선형적 패턴이 뚜렷한 변수와 총인과 같이 변동폭이 작은 데이터에서는 KNN이나 선형 보간법이 더 적합했다.

결론적으로, 주기성 변수의 경우 긴 결측 구간에서는 선형 보간법 및 KNN을 적용할 수 있고, 그 외 주기성 변수의 짧은 결측 및 비주기성 변수의 경우 BRITS 알고리즘을 적용할 수 있다. 이는 각 변수의 특성과 결측 구간의 길이에 따라 대체 알고리즘을 최적화할 수 있음을 보여준다. 따라서 변수 특성에 따라 다양한 대체 알고리즘을 순차적으로 적용하는 복합적인 대체 프레임워크 개발 연구를 후속 연구로 고려할 수 있다. 예를 들어, 짧은 결측 구간을 선형 보간으로 채운 뒤 참값으로 가정하고 학습에 활용하는 방법도 하나의 접근법이 될 수 있다. 또한 향후 녹조 및 수질 관련 자료의 추가적인 수집과 품질 개선에 따라 딥러닝 기반 대체 알고리즘의 성능이 향상될 여지가 있다. 특히, 데이터 측정 빈도를 늘리거나 장기적인 수집을 통해 충분한 학습 데이터를 확보할 수 있다면, 딥러닝 기반 모델이 단기적인 변화 패턴을 잘 예측할 수 있을 것으로 기대된다.

마지막으로, 본 연구에서는 조류경보제의 기준이 되는 남조류 세포수에 시간해상도를 맞추었지만, 시간 단위로 제공되는 자동측정망 데이터에서는 대체 알고리즘의 성능 비교 결과가 상이할 수 있다. 시간 단위의 낮은 시간해상도에서 발견할 수 있는 비선형적 변화 양상을 딥러닝 기반 대체 알고리즘이 효과적으로 학습할 것으로 기대된다.

제 3장 탐색적 데이터 분석(EDA) 표준운영절차(SOP) 개발

4차 산업혁명의 핵심 기술인 빅데이터 분석은 인공지능(AI), 사물인터넷(IoT), 증강현실(AR), 가상현실(VR) 등과 함께 필수적인 요소이다. 빅데이터를 이용하면 매우 다양한 요인들 간 복잡한 상호작용의 결과로 나타나는 현상에서 의미 있는 패턴을 찾을 수 있고, 이를 통해 의사결정에 필요한 정보와 통찰(insight)을 얻기가 쉬워진다.

그러나 데이터 분석을 위해 아무리 좋은 도구나 분석 기법을 적용하더라도 품질이 낮은 데이터로 좋은 결과를 기대할 수는 없다. GIGO(Garbage-In, Garbage-Out)란 불완전한 데이터를 입력하면 불완전한 답이 나올 수밖에 없음을 일컫는 데이터 분석 분야의 격언과도 같다. 그만큼 데이터 분석에서 데이터 품질의 중요성을 일깨우는 말이다. 포브스에서 인용한, 2016년 CrowdFlower가 80명의 데이터 과학자를 대상으로 벌인 설문조사 결과에 따르면 데이터 수집에 19%, 수집된 데이터를 정리하고 구성하는 데 60%의 시간을 사용하는 등 전체 데이터 분석에 필요한 시간 중 약 80%를 데이터를 준비하고 전처리하는 데 소비하는 것으로 나타났다.

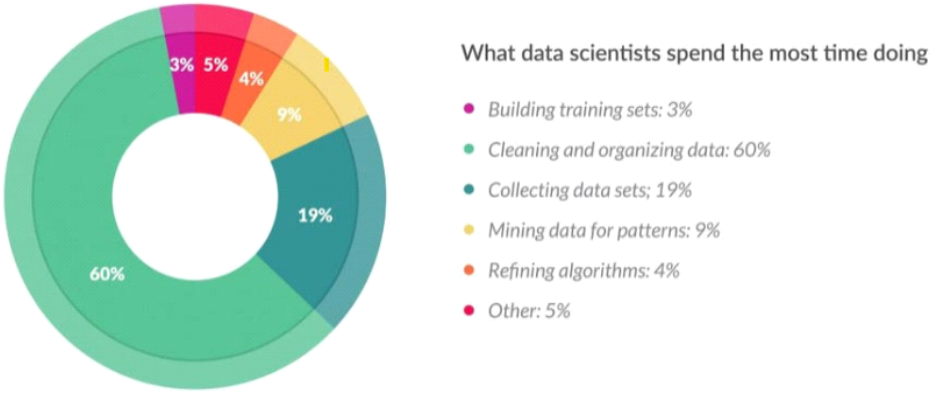

<그림 3.1> 데이터 과학자들의 데이터 분석 단계별 소비 시간

출처: https://www.forbes.com/sites/gilpress/2016/03/23/data-preparation-most-time-consuming-least-enjoyable-data-science-task-survey-says/?sh=4321b9186f63

데이터 분석에 있어 정해진 과정과 순서는 없지만, 대부분 "자료수집→데이터 전처리 및 탐색적 데이터 분석(EDA)→피처엔지니어링(Feature engineering)→기계학습 모델 적용"의 과정을 거친다. 기계학습의 관점에서는 탐색적 데이터 분석과 피처엔지니어링을 합쳐 데이터 전처리로 볼 수도 있다. 데이터 분석은 분석자 주관의 개입 정도에 따라 크게 확증적 데이터 분석(CDA)과 탐색적 데이터 분석(EDA)의 두 가지 접근방법으로 나누어 볼 수 있다.

확증적 데이터 분석(CDA: Confirmatory Data Analysis)은 전통 통계학에서 발전해온 통계적 추론(statistical inference) 방법이다. 분석자는 가설을 설정한 후, 수집한 데이터를 대상으로

관측된 형태나 효과의 재현성 평가, 신뢰구간 추정, 유의성 검정 기법 등을 적용하여 가설을 평가하고 가설의 기각 또는 채택 결과를 근거로 추론 예측한다. 확증적 데이터 분석은 다양한 학문 분야에서 연구목적의 설문조사나 실험의 결과를 실증분석 하는 데 사용한다.

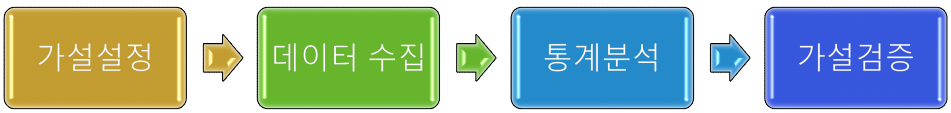

<그림 3.2> 확증적 데이터 분석 과정

탐색적 데이터 분석(EDA: Exploratory Data Analysis)은 원시 데이터(raw data)를 가지고 유연하게 데이터를 탐색하고, 데이터의 특징과 구조로부터 얻은 정보를 바탕으로 통계모델을 만드는 분석 방법으로 주로 빅데이터 분석에 사용된다. 분석자는 수집한 데이터를 요약, 묘사, 설명하기 위해 평균, 표준편차, 중앙값, 최빈값 등의 통계량뿐 아니라 확률밀도 등의 분포와 다양한 도표를 이용한 시각화된 방법을 이용한다. 통계학적 분류로 보면 확증적 데이터 분석이 추론통계라면 탐색적 데이터 분석은 기술통계라 할 수 있다.

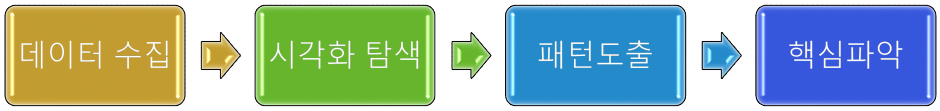

<그림 3.3> 탐색적 데이터 분석 과정

3.1 EDA 개요

탐색적 데이터 분석, EDA(Exploratory Data Analysis)는 벨연구소의 수학자 존 튜키(John Tukey)가 제안한 데이터 분석 방법론으로 통계적 가설 검정 등에 의존한 기존 통계학으로는 새롭게 나오는 많은 양의 데이터의 핵심 의미를 파악하는 데 어려움이 있다고 생각하여 이를 보완하기 위해 도입한 일종의 데이터 분석 체계이다. 존 튜키는 탐색적 데이터 분석을 “우리가 존재한다고 믿는 것들은 물론이고 존재하지 않는다고 믿는 것들을 발견하려는 태도, 유연성, 그리고 자발성”이라고 했다. 즉 데이터를 다양한 각도에서 편견 없이 관찰할 것을 강조하였다.

1) EDA 목적

데이터를 분석하고 결과를 내는 과정에서 해당 데이터에 대한 “탐색과 이해”는 기본적으로 중요하다. 데이터의 분포와 값을 다양한 기준에서 관찰하면 데이터에서 나타나는 현상을 더 잘 이해할 수 있을 뿐 아니라, 문제 정의 단계에서 미처 발견하지 못한 패턴을 발견하여 지식을 수정하거나 추가할 수도 있기 때문이다.

EDA의 목적은 여러 가지 시각화 도구 및 통계 기법을 사용하여 데이터를 다양한 각도에서 관찰함으로써 ① 변수들의 인과관계에 대한 새로운 가설을 제시하고, ② 예측 모델을 위한 적

합한 데이터 분석 도구 선택 및 추가 자료수집을 위한 가이드가 되며, ③ 도출하고자 하는 결과의 기본이 되는 가설의 평가 및 검증 등이다.

이처럼 데이터에 대한 관찰과 지식이 이후의 통계적 추론이나 예측 모델 구축 시에도 사용되므로 EDA는 전체 데이터 분석 과정에서 중요한 단계라고 할 수 있다. 데이터 분석 과정에서 EDA 목적에 따른 분석 방법을 정리하면 <그림 3.4>와 같다.

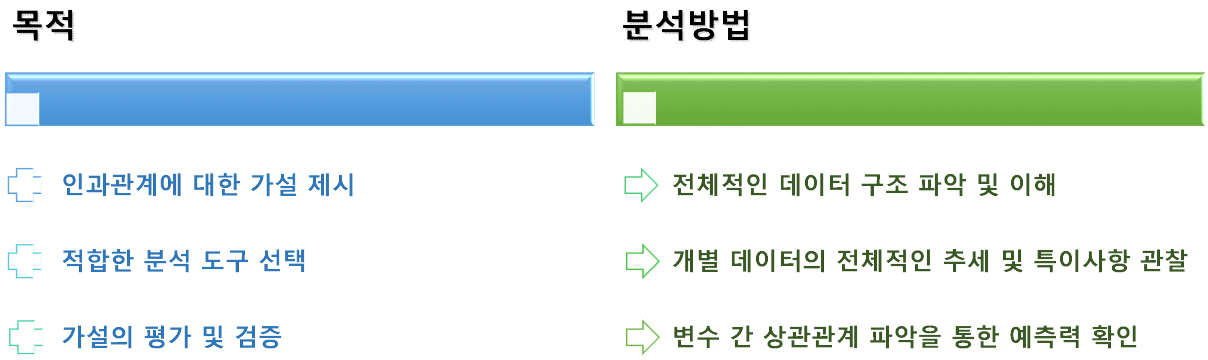

<그림 3.4> 데이터 분석 과정에서 EDA의 목적에 따른 분석 방법

2) EDA 분석 방법

EDA는 데이터를 다양한 측면에서 바라보고 이해하는 과정으로서 데이터가 나타내는 현상을 이해하고 다양한 패턴 발견하기 위해 통계적 요약, 분포 파악 및 시각화 등의 기법을 사용해 직관적으로 데이터의 특성을 파악한다. EDA가 데이터의 특성을 파악하는 방식은 크게 속성과 관계로 나눌 수 있다. 속성 파악이란 전체적인 데이터 구조 및 개별 변수의 고유한 속성을 파악하는 것으로 보통 변수 1개에 대해 분석하므로 일변량(Univariate) 분석이라고 한다. 반면 관계 파악은 변수 간의 상관성(corelation) 또는 인과성(causality)을 파악하는 것으로 2개 이상의 변수에 대해 분석하므로 다변량(Multi-variate) 분석이라고 한다.

가. EDA 분석 대상

① 일변량 분석(Univariate analysis)

EDA를 통해 파악하려는 변수가 1개인 경우이다. 즉, 독립변수 하나에 종속변수가 있는 것으로 데이터를 설명하고 패턴을 찾는 것이 목적이다. 일변량 분석은 어떤 대상의 성격을 규명하기 위하여 한 가지 측면에서 그 대상을 관찰하고 분석하는 것에 유용하다.

② 다변량 분석(Multi-variate analysis)

EDA를 통해 파악하려는 변수가 여러 개인 경우이다. 즉, 여러 개의 독립변수에 여러 개의 종속변수를 동시에 분석하는 것으로 분석 대상의 변동성을 이해하고 가설을 검증하는 것이 목적이다. 다변량 분석은 여러 각도와 측면에서 변수 간의 복잡한 관계성을 분석하는 것에 유용하다.

나. EDA 분석 종류

① 비시각화(Non-Graphic) 분석

통계학의 기술통계(descriptive statistics)를 이용해 요약된 통계량으로 데이터의 성격을 파악하는 방법이다. 다변량 분석이나 여러 개의 변수가 범주화된 데이터의 경우 시각적인 표현이 더 복잡해 보일 수도 있으므로 단일 지표를 이용해 더욱 명확한 의미를 파악할 수 있다.

② 시각화(Graphic) 분석

도표, 그림 등을 이용해 데이터를 전체적으로 파악하기 쉬운 방법이다. 데이터에 대한 직관적 이해를 추구하므로 정보전달 시간을 단축하고 새로운 영감(insight)을 얻는 데에 유리하다.

다. EDA 분석 유형

EDA의 분석 유형은 분석 대상과 종류를 연결한 것으로, 4가지 유형으로 구분할 수 있다.

- ○ **일변량 비시각화**(Univariate Non Graphic): 데이터의 분포를 확인하는 것이 주목적
- ○ **일변량 시각화**(Univariate Graphic): 데이터를 전체적으로 살펴보는 것이 주목적
- ○ **다변량 비시각화**(Multi-variate Non Graphic): 변수간 관계를 확인하는 것이 주목적
- ○ **다변량 시각화**(Multi-variate Graphic): 변수간 관계를 전체적으로 살펴보는 것이 주목적

3) EDA 분석 절차

탐색적 데이터 분석은 본격적인 데이터 분석 전에 데이터의 특성을 관찰하고 이해하는 단계로서, 한 번의 분석으로 결론에 도달하는 것이 아니라 <그림 3.5>와 같이 반복적 질문과 답을 이어가며 데이터에 내재한 현상을 이해하는 과정이다. 즉, 데이터에서 문제 해결을 위한 유의미한 패턴이 발견될 때까지 ① 전체적으로 데이터를 살펴보고, ② 이상값과 결측값 확인 등 전처리를 통해 데이터의 정합성을 유지하고, ③ 데이터의 개별 변수를 분석하며, ④ 변수 간에 존재하는 상관관계를 분석하는 등 특징적인 패턴을 발견하는 절차를 반복하게 된다.

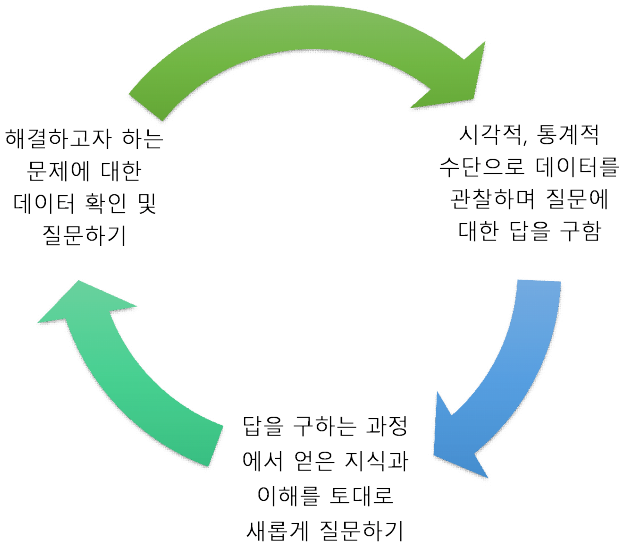

<그림 3.5> EDA의 반복적 분석단계

① 전체적인 데이터 확인

- 해결하고자 하는 목표와 변수를 파악(독립변수와 종속변수 구분)
- 데이터셋(Dataset)의 전체적인 구조 확인
- 수치형 자료, 범주형 자료 등 데이터 속성값의 고유한 성질에 따라 자료의 형태 구분

② 데이터 전처리 (Data Processing)

- 데이터에 이상값(anomaly)이나 결측값(오류값 포함)이 있는지 확인 후 제거 및 대체
- 여러 개로 나뉘어 수집된 데이터를 병합하거나, 중복 또는 불필요한 데이터를 제거
- 날짜, 문자, 숫자 등 자료의 형식이 잘못 정의되었을 경우 원래에 맞게 변환

③ 개별 변수의 분석: 일변량 분석 (Univariate Analysis)

- 개별 변수의 분포, 추세 및 주기성(시계열), 특이사항 등을 관찰하며 평균, 중앙값, 분산 등 적절한 요약통계로 나타냄
- 시각화를 통해 개별 변수의 분포, 추세 및 주기성, 특이사항 등을 직관적으로 파악

④ 변수 간의 관계 분석: 이변량 / 다변량 분석 (Bivariate / Multivariate Analysis)

- 둘 이상의 변수를 범주(Category)에 따라 그룹화해 변수별 데이터의 분포를 파악
- 둘 이상의 변수 간 교차 상관관계(Cross-correlation)를 상관계수 등을 통해 확인

위의 절차를 요약하면 EDA는 데이터의 전체적인 부분을 파악하고 개별 변수를 관찰한 후, 마지막으로 변수 간의 관계를 분석해보며 데이터를 탐색적으로 분석해보는 과정이다.

3.2 일변량 분석 (Uni-variate Analysis)

EDA에서 변수의 개별적 변동성을 파악할 목적으로 해당 데이터의 범위 및 형상, 패턴 등을 분석하는 것을 일변량 분석(Univariate Analysis)이라고 한다. 일변량 분석을 통해 분석자는 평균, 중앙값, 분산 등 적절한 요약통계를 활용하거나 시각화하여 데이터셋에 포함된 개별 변수의 분포, 추세 및 주기성, 그 외 특이사항 등을 직관적으로 파악할 수 있다. 따라서 분석에 활용할 요약통계와 시각화 기법은 수치형, 범주형 등 자료 형태에 따라 해당 변수의 특성을 잘 나타낼 수 있는 기법을 선택해야 한다.

3.2.1 일변량 비시각화 (Univariate Non Graphic)

일변량 비시각화 분석 방법으로는 자료 형태에 따라 표본의 요약통계(summary statistics)와 빈도표(tabulation) 등을 활용한다. 요약통계는 기술통계(descriptive statistics)의 요약된 통계량으로 수치형 변수에 활용한다. 개별 변수의 데이터 분포를 간단히 나타낼 수 있으나, 일정 수준의 도메인 지식이 뒷받침되어야 통계량이 나타내는 의미를 쉽게 파악할 수 있다. 빈도표는 범주형 변수의 구성을 파악하기 위한 것으로 범주별 빈도와 그 빈도가 전체에서 차지하는 비율을 나타내어 범주별 분포를 파악할 수 있다. 또한 결측값 처리를 위한 결측값 빈도와 비율을 파악하는 데에 활용할 수도 있다.

1) 수치형 변수

가. 중심 경향성(central tendency)

데이터의 중심이 어디에 위치하는지 파악하는 통계량으로 평균(mean), 중앙값(median), 최빈값(mode) 등이 해당한다. 중심 경향성을 알면 분포의 중앙을 알 수 있어 데이터의 특성을 파악하기 쉬워진다.

평균 (mean)	전체 주어진 자료의 값을 모두 더한 후 자료의 개수로 나눈 값으로, 데이터 한 개가 바뀌어도 값의 변화가 급격하지 않지만, 이상값(outlier)에 민감한 특성이 있다.
중앙값 (median)	전체 데이터의 정중앙에 있는 값을 의미한다. 데이터의 개수가 짝수라면 중앙값은 중앙에 있는 두 값의 평균으로 정한다. 중앙값은 크기 순서에 따라 정해지는 값이므로 평균에 비해 다른 값들의 변화나 이상값 등에 덜 민감한 특성이 있다.
최빈값 (mode)	전체 데이터에서 가장 자주 나오는 값(빈도수가 많은)을 의미한다. 수치형 변수에서는 평균이나 중앙값에 비해 덜 사용된다.

나. 산포도(dispersion)

데이터가 중심위치로부터 흩어진 정도를 나타내는 통계량으로 값이 클수록 데이터의 변동성(variation)이 큰 것을 의미한다. 범위(range), 사분위수 범위(IQR: Inter Quartile Range), 표준편차(standard deviation), 분산(variance) 등을 사용한다.

분산 (variance)	데이터의 분포가 평균으로부터 얼마나 흩어져 있는지를 나타내는 통계량으로 개별 데이터와 평균과의 차를 제곱한 것의 평균을 의미한다. $$s^2 = \frac{1}{n-1}\sum_{i-1}^{n}\left(x_i - \bar{x}\right)^2$$ 식(3.1)
표준편차 (standard deviation)	분산이 제곱 값을 취했기 때문에 직관적으로 이해하기 어려운 데 반해, 표준편차는 분산에 제곱근을 씌워 데이터의 실제 값과 같은 단위로 산포도를 나타낼 수 있는 장점이 있다. $$s = \sqrt{\frac{1}{n-1}\sum_{i-1}^{n}\left(x_i - \bar{x}\right)^2}$$ 식(3.2)
범위 (range)	데이터의 최대값과 최소값의 차로서 자료의 흩어짐 정도를 가장 쉽게 나타낼 수 있는 통계량이다. 계산하기 쉽지만, 희귀값 또는 이상값에 지나치게 좌우되는 단점이 있다.
사분위수 범위(IRQ)	전체 데이터를 작은 값부터 오름차순으로 정렬하여 동일 비율로 4등분 하였을 때 경계가 되는 25%, 50%, 75% 등 세 위치의 점을 사분위수(Quartile)라 하고, 1분위수(25%)과 3분위수(75%)의 차(Q_1 - Q_3)로 계산한다.

다. 분포 형태(shape of distribution)

데이터 분포의 모양을 나타내는 통계량으로 평균을 기준으로 한 데이터의 좌우 비대칭도를 나타내는 왜도(skewness), 데이터의 중심부 집중도를 나타내는 첨도(Kurtosis) 등이 있다.

왜도 (skewness)	데이터 분포의 좌우 비대칭도를 나타내는 통계량이다. 즉 데이터의 분포가 얼마나 대칭이 아닌지를 나타내며 0에 가까울수록 분포의 형태가 대칭을 이룬다. 왜도가 큰 데이터의 경우 로그 변환을 해주기도 한다. $$g_1 = \frac{n}{(n-1)(n-2)}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s}\right)^3$$ 식(3.3)
첨도 (Kurtosis)	데이터 분포가 첨도 0인 정규분포에 비해 얼마나 뾰족한지를 나타내는 통계량이다. 즉, 첨도가 높다는 것은 데이터가 중심에 많이 몰려 있어 정규분포보다 뾰족한 모양이라는 것이다. 분산과 표준편차가 데이터의 전반적인 산포도를 나타낸다면, 첨도는 중심에 얼마나 집중적으로 쏠려 있는가를 나타낸다고 하겠다. $$g_2 = \left\{\frac{n(n+1)}{(n-1)(n-2)(n-3)}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s}\right)^4\right\} - \frac{3(n-1)^2}{(n-2)(n-3)}$$ 식(3.4)

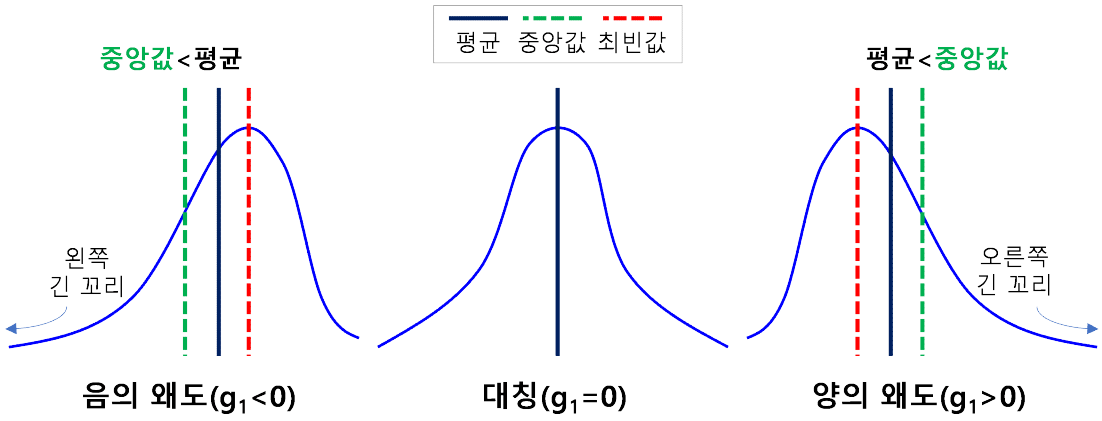

<그림 3.6> 왜도(Skewness)의 개념

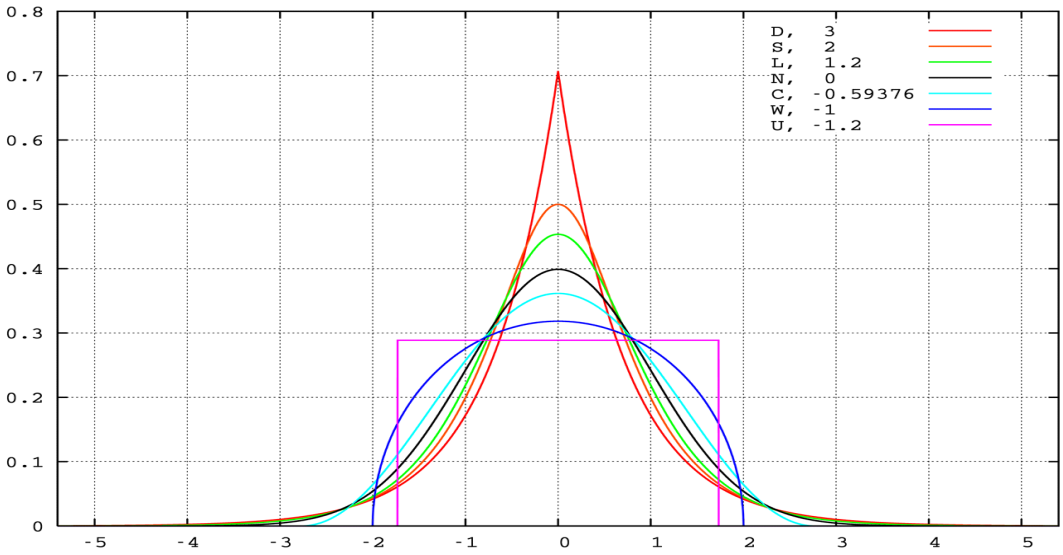

<그림 3.7> 정규분포와 동일한 분산을 갖는 분포들의 첨도(kurtosis) 비교

출처: 위키피디아(https://ko.wikipedia.org/wiki/첨도)

라. 정규성 검정(normality test)

정규성 검정은 주어진 데이터가 정규분포를 따른다는 가설을 통계적으로 확인하기 위한 절차이다. 정규분포는 평균을 중심으로 좌우대칭인 종(鐘) 모양의 분포로, 회귀분석, 분산분석(ANOVA), t-검정 등 다양한 통계적 추론 방법에서 기본 가정으로 활용된다. 정규성 가정이 충족되지 않을 경우, 분석 결과의 신뢰성에 영향을 미칠 수 있으므로, 데이터 전처리 및 통계 분석 단계에서 정규성 검정을 체계적으로 수행할 필요가 있다. 정규성 검정의 귀무가설(H_1)은 "데이터가 정규분포를 따른다"이며, 대립가설(H_1)은 "정규분포를 따르지 않는다"이다. 일반적으로 유의수준 α=0.05를 기준으로 p-value가 α 이하일 경우 귀무가설을 기각하여 정규성 위반으로 판단한다.

① Shapiro - Wilk 검정

Shapiro - Wilk 검정은 작은 표본(대략 50 이하)에서 높은 검정력을 보이며, 최대 약

5,000개 표본까지 적용 가능한 대표적인 정규성 검정 방법이다. 이 방법은 표본 순위값과 정규분포 이론값 간의 선형 결합을 이용하여 정규성 적합도를 평가하며, 검정통계량 W는 다음과 같이 정의된다.

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \qquad \text{식(3.5)}$$

여기서 $x(i)$는 오름차순 정렬된 표본값, α_i는 표본 크기에 따라 계산되는 가중계수, $\bar{x}$는 표본평균이다. W값이 작을수록 정규성에서 벗어난 것으로 해석되며, 대응되는 p-value를 통해 귀무가설 채택 여부를 판단한다.

② Kolmogorov - Smirnov (K-S) 검정

Kolmogorov - Smirnov 검정은 표본의 경험누적분포함수(ECDF)와 비교 대상 분포(본 연구에서는 정규분포)의 누적분포함수(CDF) 간 최대 차이를 이용하여 정규성을 평가한다. 검정통계량 D는 다음과 같다.

$$D = \max_x \left| F_{n(x)} - F(x) \right| \qquad \text{식(3.6)}$$

여기서 $Fn(x)$는 표본의 ECDF, $F(x)$는 정규분포 CDF이다. 표본 크기가 커질수록 미세한 차이에도 민감하게 반응하므로, 큰 데이터셋에서는 정규성 위반을 과도하게 판단할 가능성이 있다. 또한 K-S 검정은 정규분포 전용 방법이 아니라, 임의의 연속분포 비교에 사용될 수 있다는 점에서 해석 시 주의가 필요하다.

③ Anderson - Darling 검정

Anderson - Darling 검정은 K-S 검정을 확장하여 분포의 꼬리(tail) 영역에 더 큰 가중치를 부여함으로써 정규성 검정의 민감도를 강화한 방법이다. 검정통계량 A^2은 다음과 같이 정의된다.

$$A^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\left(\ln F(x_{(i)}) + \ln\left(1 - F(x_{(n+1-i)})\right)\right) \qquad \text{식(3.7)}$$

여기서 $F(x)$는 정규분포 CDF이며, $x(i)$는 표본의 순위값이다. 본 검정은 p-value 대신 유의수준별 임계값(Critical Value)을 제시하며, $A^2 > CV$일 경우 귀무가설을 기각한다. 본 방법은 극단값에 민감하게 반응하고, 표본 크기 제한이 없다는 점에서 대규모 자료 분석에도 적합하다.

④ Z-score 기반 정규성 점검

Z-score 분석은 정규성의 간접적 점검 방법으로, 각 관측값이 평균으로부터 얼마나 떨어져 있는지를 표준편차 단위로 환산하여 극단값 존재 여부를 평가한다.

$$z_i = \frac{x_i - \mu}{\sigma} \qquad \text{식(3.8)}$$

정규분포를 가정할 경우 $|z_i| > 3$ 구간의 비율은 매우 작아야 하므로, 해당 영역에 다수의 값이 존재한다면 정규성 위반 가능성을 시사한다. 다만 이는 정규성의 공식적 통계검정이라기보다 탐색적 진단 도구에 가깝다.

⑤ 정규성 검정 결과 해석

정규성 검정 결과는 다음 기준에 따라 해석한다.

○ 귀무가설(H_0): 데이터는 정규분포를 따른다.

○ 대립가설(H_1): 데이터는 정규분포를 따르지 않는다.

○ $p \leqq \alpha\,(=0.05)$ → 귀무가설 기각 → 정규성 미충족

○ $p > \alpha$ → 귀무가설 채택(정규성 위반 근거 없음)

정규성이 충족되지 않는 경우, 로그 변환, Box-Cox/Yeo-Johnson 변환, 이상값 처리, 비모수 검정 대체 등의 추가 조치를 함께 고려할 수 있다.

2) 범주형 변수

가. 빈도표(Tabulation)

빈도(frequency)란 특정 값을 갖는 점수의 수이며, 빈도표란 모든 가능한 점수들에 걸쳐 빈도의 패턴을 보여주는 표이다. 즉, 빈도표는 통계 및 데이터분석에서 특정 범위에 포함되는 데이터 값의 발생 빈도와 전체 데이터에서 차지하는 비중(%)을 표 형태로 요약해 놓은 것이다. 범주형 변수의 일변량 분석에서 주된 관심사는 변수가 가지는 분포상의 특징을 이해하는 것이다. 빈도표는 각 범주에 포함된 값이 얼마나 자주 나타나는지를 보여줌으로써 해당 변수의 데이터 분포와 특성을 파악하데 유용하다. 또한 이 과 정에서 추가 정보로 결측값(missing value)도 파악할 수 있다. 즉, 결측값이 있으면 percent의 합이 100%가 되지 않게 된다. 빈도표의 구성 요소는 다음과 같다.

나. 빈도표의 구성 요소

○ (변수) 빈도를 분석할 대상이 되는 변수를 나타낸다.

○ (범주) 변수가 가질 수 있는 값들을 그룹화한 범위를 나타낸다. 범주는 수치적 범위

또는 질적 구분 기준으로 설정할 수 있다.

- ○ (빈도) 각 범주에 속하는 데이터 개수를 나타낸다.
- ○ (백분율) 전체 데이터 개수 대비 각 범주에 속하는 데이터 비율을 나타낸다.
- ○ (누적빈도) 범주 순서대로 누적된 데이터 개수를 나타낸다.
- ○ (누적 백분율) 범주 순서대로 누적된 데이터 비율을 나타낸다.

다. 빈도표의 종류

- ○ (단순 빈도표) 하나의 변수에 대한 빈도만을 나타낸다.
- ○ (누적 빈도표) 누적빈도와 누적 백분율을 추가하여 데이터 분포의 변화 추이를 보여준다.
- ○ (교차 빈도표; Corss-tabulation) 두 개 이상의 변수 간의 빈도를 함께 나타냅니다. 두 변수의 상호 연관관계를 파악하는 데 유용하다.

<표 3.1> 단순 및 누적 빈도표 예시

범주	빈도	백분율	누적빈도	누적 백분율
A	29	27.36	29	27.36
B	35	33.02	64	60.38
C	27	25.47	91	85.85
D	15	14.15	106	100.00

라. 빈도표 활용

다양한 정보를 제공하여 데이터분석의 핵심 정보 파악에 활용할 수 있다.

- ○ 중심 경향: 데이터가 어느 값에 집중되어 있는지 파악
- ○ 분포 형태: 데이터 분포가 대칭인지 왜곡인지, 첨도가 높은지 낮은지 등을 파악
- ○ 변수 간 관계: 교차 빈도표를 통해 두 변수 간 상관성을 확인하고, 상호 작용을 이해
- ○ 이상값: 데이터 분포에서 벗어난 이상값을 발견
- ○ 결측값: 데이터 누락 여부를 파악하고, 결측값 처리 방안을 결정

마. 빈도표 활용 시 주의점

- ○ 범주 설정: 범주의 설정 방식은 빈도표 분석 결과에 영향을 미칠 수 있다. 적절한 범주 설정을 위해 데이터 특성을 고려하고, 필요에 따라 병합, 추가 등이 필요할 수 있다.
- ○ 데이터 해석: 빈도표를 통해 얻은 결과는 데이터의 특성을 이해하는 데 도움이 되는 정보이지만, 단순히 빈도나 백분율만으로 데이터를 판단해서는 안 된다. 추가적인 분석과 시각화를 통해 데이터를 심층적으로 이해해야 한다.

3.2.2 일변량 시각화 (Univariate Graphic)

일변량 시각화 분석 방법은 하나의 변수로 구성된 데이터를 전체적인 관점으로 파악할 수 있는 데이터 탐색 유형으로 단일 변수 데이터를 다양한 그래프로 시각화하여 관찰한다. 비시각화 분석의 장점이 요약된 데이터를 통해 변수의 개략적 특성을 빠르게 파악하는 데에 있다면, 시각화 분석은 그래프를 통해 직관적 이해를 추구하여 정보전달 시간을 단축하면서 분석 대상에 대한 통찰력을 끌어낼 수 있는 장점이 있다. 시각화에 Python을 활용하면 Matplotlib, Seaborn, Plotly, Cufflinks 등 다양한 패키지 함수를 활용할 수 있다. <표 3.2>는 데이터 특성과 분석 목적에 따른 시각화 방법을 나타낸 것이다.

<표 3.2> 데이터 특성과 분석 목적에 따른 시각화 방법

구분	시각화
시간	막대그래프(Bar Plot), 누적막대그래프(Stacked Bar Plot), 점그래프(Point Plot)
비중	파이차트(Pie Chart), 도넛차트(Donut Chart), 트리맵(Tree Map), 누적연속 그래프(Cumulative Continuous Plot)
분포	산점도(Scatter Plot), 상자 그래프(Box Plot), 버블차트(Bubble Chart), 히스토그램(Histogram), Q-Q plot
비교	히트맵(Heat Map), 체르노프 페이스(Chernoff Face), 별 그래프(Star Graph), 평행좌표계(Parallel Coordinate System), 다차원 척도법(Multi-dimensional Scaling)
지리	지도매핑(Dataviz on Map)

1) 수치형 변수

가. 히스토그램(Histogram)

관측된 연속형 데이터값들의 분포 파악이 가능하고, 구간별 분포 상태를 쉽게 알아볼 수 있는 그래프로서 구간 내 속하는 자료의 수가 많고 적음을 쉽게 파악할 수 있다. 막대그래프(Bar Plot)와 형태가 유사하지만, 막대그래프가 범주형(이산형 포함) 변수의 빈도표를 시각화하는 반면, 히스토그램은 연속형 변수의 빈도 분포를 나타낸다.

그러나 각 데이터에 대응되는 연속 구간의 경계면에서 이산적(discrete)으로 값을 증가시킴으로써 불연속성이 발생하며, 히스토그램의 구간 크기 및 시작 위치 등을 어떻게 설정하느냐에 따라 분포가 다르게 나타나는 한계가 존재한다.

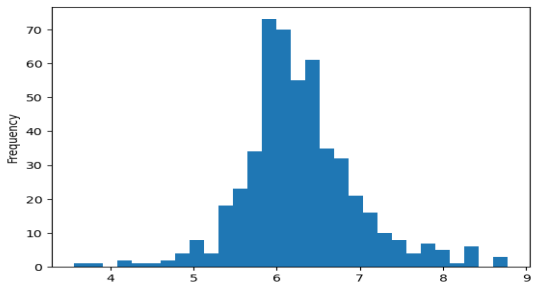

<그림 3.8> 히스토그램 시각화

나. 커널밀도추정(KDE: Kernel Density Estimation)

히스토그램의 한계를 개선하기 위해 분포를 완만한 곡선으로 나타낸 것이다. 커널함수(kernel function)를 이용하여 변수의 연속성 있는 확률밀도함수를 추정하는 비모수적(non-parametric) 방법이다. 커널함수는 원점을 중심으로 좌우 대칭이면서 적분값이 1인(식 3.9) 비음(non-negative) 함수(식3.10)로 정의되며, 커널함수를 이용한 확률변수(random variable) x에 대한 확률밀도함수(probability density function)는 식(3.11)과 같이 추정한다.

$$\int_{-\infty}^{\infty} K(u)du = 1 \qquad \text{식(3.9)}$$

$$K(u) = K(-u), \quad K(u) \geq 0, \quad \forall u \qquad \text{식(3.10)}$$

$$\hat{f}_h(x) = \frac{1}{n}\sum_{i=1}^{n} K_h(x - x_i) = \frac{1}{nh}\sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right), \quad K_h(u) = \frac{1}{h}K\left(\frac{x}{h}\right), \quad h > 0 \qquad \text{식(3.11)}$$

여기서, K_h는 scaled 커널, K는 커널함수, h는 대역폭(bandwidth)으로 h의 크기에 따라 커널의 smoothing 형태가 조절되는 매개변수, $x_i (i = 1, 2, \cdots, n)$는 변수 x의 표본 데이터셋이다.

식(3.11)에서 h값이 작을수록 커널은 뾰족한 형태가 되고 h값이 클수록 완만한 형태로 변한다. 식(3.11)의 커널함수를 적용하여 커널밀도를 추정하는 방법은 관측된 데이터 각각마다 해당 데이터값을 중심으로 하는 커널함수($K(x - x_i)$)를 생성한 후, 이렇게 만들어진 커널함수들을 모두 더하여 전체 데이터 개수로 나누는 것이다. <표 3.3>은 일반적으로 사용되는 커널함수의 종류를 나타내고 있으며, 특히 가우시안(Gaussian), Epanechnikov, uniform 함수 등이 대표적으로 사용되는 커널함수들이다.

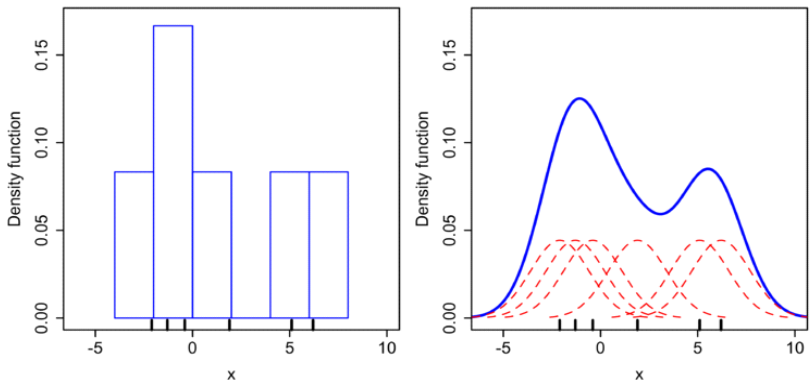

<그림 3.9> 히스토그램과 커널밀도추정(KDE) 비교

<표 3.3> 일반적으로 사용되는 커널함수

Kernel Functions, $K(u)$			$\int u^2 K(u)du$	$\int K(u)^2 du$
Cosine	$K(u)=\frac{\pi}{4}\cos\left(\frac{\pi}{2}u\right)$ Support: $\lvert u\rvert \le 1$	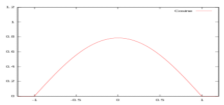	$1-\frac{8}{\pi^2}$	$\frac{\pi^2}{16}$
Epanechnikov (parabolic)	$K(u)=\frac{3}{4}(1-u^2)$ Support: $\lvert u\rvert \le 1$	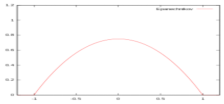	$\frac{1}{5}$	$\frac{3}{5}$
Gaussian	$K(u)=\frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}u^2}$	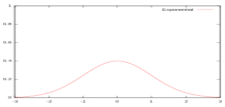	1	$\frac{1}{2\sqrt{\pi}}$
Logistic	$K(u)=\frac{1}{e^u+2+e^{-u}}$	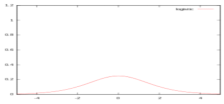	$\frac{\pi^2}{3}$	$\frac{1}{6}$
Quartic (biweight)	$K(u)=\frac{15}{16}(1-u^2)^2$ Support: $\lvert u\rvert \le 1$	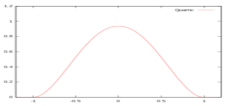	$\frac{1}{7}$	$\frac{5}{7}$
Sigmoid function	$K(u)=\frac{2}{\pi}\frac{1}{e^u+e^{-u}}$	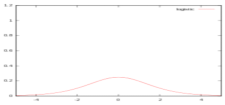	$\frac{\pi^2}{4}$	$\frac{2}{\pi^2}$
Silverman kernel	$K(u)=\frac{1}{2}e^{-\frac{\lvert u\rvert}{\sqrt{2}}}\cdot\sin\left(\frac{\lvert u\rvert}{\sqrt{2}}+\frac{\pi}{4}\right)$	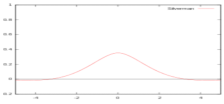	0	$\frac{3\sqrt{2}}{16}$
Triangular	$K(u)=(1-\lvert u\rvert)$ Support: $\lvert u\rvert \le 1$	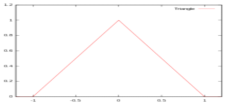	$\frac{1}{6}$	$\frac{2}{3}$
Tricube	$K(u)=\frac{70}{81}(1-\lvert u\rvert^3)^3$ Support: $\lvert u\rvert \le 1$	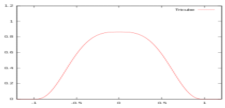	$\frac{35}{243}$	$\frac{175}{247}$
Triweight	$K(u)=\frac{35}{32}(1-\lvert u\rvert^2)^3$ Support: $\lvert u\rvert \le 1$	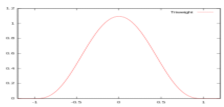	$\frac{1}{9}$	$\frac{350}{429}$
Uniform	$K(u)=\frac{1}{2}$ Support: $\lvert u\rvert \le 1$	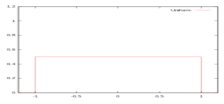	$\frac{1}{3}$	$\frac{1}{2}$

출처: 위키피디아(https://en.wikipedia.org/wiki/Kernel_(statistics)#Kernel_functions_in_common_use)

다. Q-Q 플롯(분위수 대조도)

Q-Q 플롯(Quantile-Quantile Plot)은 표준정규분포의 분위수(quantile)와 이에 대응하는 실제 데이터의 분위수를 x, y 좌표평면에 도시하는 시각화 방법이다. 분위수란 확률분포를 동일한 확률 간격으로 나누는 절단점을 의미한다. Q-Q 플롯은 주어진 데이터가 정규분포를 따르는지 판단(Normal Q-Q Plot)하기 위해 자주 이용되지만, 주어진 두 개의 데이터가 같은 형태의 확률분포인지 확인하거나, 또는 회귀분석 등에서 관측값과 예측값의 잔차의 정규성을 판단할 목적으로도 활용할 수 있다. EDA의 일변량 시각화 분석에서는 데이터의 분포 형태 즉, 왜도(Skewness)와 첨도(Kurtosis)를 파악할 때 주로 사용한다.

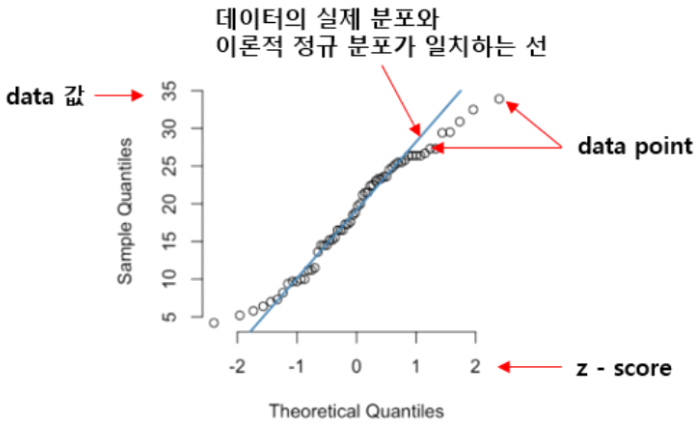

<그림 3.10> Normal Q-Q 플롯의 개념

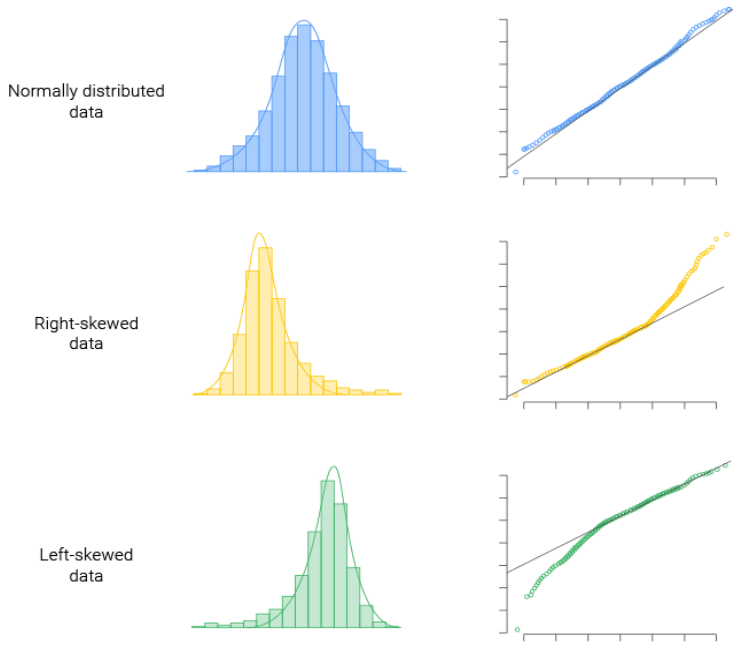

<그림 3.11> Q-Q 플롯을 이용한 데이터 분포 파악

라. 상자 그래프(Box Plot)

상자 그래프는 수치형 데이터의 양상을 직관적으로 파악할 수 있는 시각화 방법으로 평균, 중앙값, 사분위수 등과 같은 주요 요약통계 측정치를 나타내는 데 유용한 도구이다. 특히, 이상값(Outlier)을 파악하거나 데이터의 치우침 정도(symmetry)를 파악할 때 효과적이다. 상자 그래프는 데이터를 가장 작은 값에서부터 큰 값까지 정렬했을 때, 1분위수, 2분위수(중앙값), 3분위수, 최대값, 최소값 등 다섯숫자요약(Five-Number Summary)이라는 요약통계를 기반으로 데이터를 가공하여 생성하며, 때에 따라서 평균값도 함께 나타내기도 한다. <그림 3.10>은 상자 그래프의 구성 요소를 나타낸 것으로 각 부분의 의미는 다음과 같다.

○ 1분위수(lower quartile): 가장 작은 값으로부터 25% 위치, 중앙값을 기준으로 하위 25%

* $Q_1 = \frac{1}{4}(n-1)$번째 데이터값

○ 2분위수(median): 가장 작은 값으로부터 50% 위치, 상자 그래프에서 가장 중요한 수치로서 2분위수를 기준으로 데이터의 50%가 상위에, 나머지 50%가 하위에 분포되어 있음

* $Q_2 = \frac{2}{4}(n-1)$번째 데이터값

○ 3분위수(upper quartile): 가장 작은 값으로부터 75% 위치, 중앙값을 기준으로 상위 25%

* $Q_2 = \frac{3}{4}(n-1)$번째 데이터값

○ 최솟값(minium value): 1분위수에서 IQR의 1.5배를 뺀 위치

* $Q_1 - 1.5 \times IQR$번째 데이터값 * IQR(Inter Quartile Range) = $Q_3 - Q_1$

○ 최댓값(maximum value): 3분위수에서 IQR의 1.5배를 더한 위치

* $Q_3 + 1.5 \times IQR$번째 데이터값

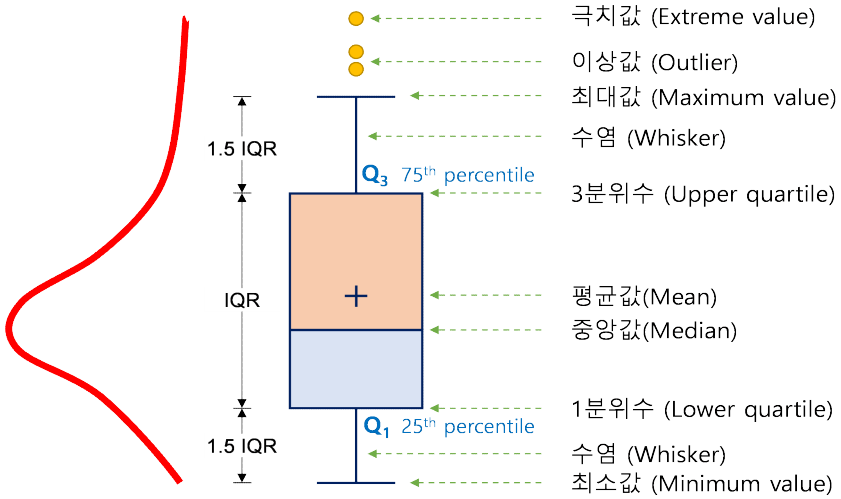

<그림 3.12> 상자 그래프(Box Plot)의 구성 요소

2) 범주형 변수

가. 막대그래프 (Bar Chart)

가장 일반적으로 사용하는 데이터 시각화 방법 중 하나로, 높이나 길이가 나타내는 값에 비례한 직사각형의 막대로 범주형 데이터를 수직이나 수평으로 표시하는 차트다. 이산형 자료를 대상으로 여러 항목을 비교하고 주어진 값들의 상대적인 차이를 시각화하는 데 유용하며 각각의 축은 관측값과 특정 범주를 나타낸다. 대표적으로 막대그래프(Bar Charts), 세로막대그래프(Column Charts), 누적막대그래프(Stacked Bar Charts), 누적세로막대그래프(Stacked Column Charts) 등이 있다.

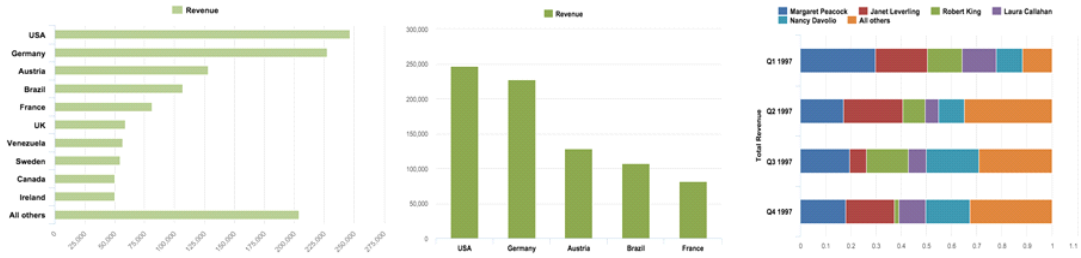

<그림 3.13> 다양한 형태의 막대그래프

나. 파이차트 (Pie Chart)

1801년 William Playfair의 The Statistical Breviary에서 처음 등장한 파이차트는 전체(100%)에서 범주형 데이터가 차지하는 비율을 각도 또는 면적으로 표현한 차트로 그룹 간의 비중을 시각화해 상대도수를 알아보는 데 유용하다. 전체 데이터에서 각 구성 항목별로 차지하는 부분을 알 수 있어 직관적으로 이해할 수 있으며, 세부 항목의 구성 비율을 비교하기 위해 최대한 구성요소를 제한하는 것이 가독성에 좋다.

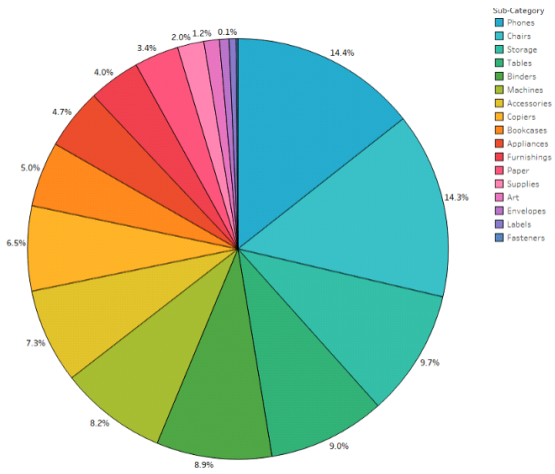

<그림 3.14> 원그래프(Pie Chart) 구성 요소

다. 점도표 (Dot Plot)

자료를 수직선 위에 점으로 표시하여 자료의 분포를 시각적으로 나타내는 그래프로 히스

토그램과 유사하지만, 각 범주에 속한 개발 관측치를 하나하나 보여줘 개별 데이터 표현에 뛰어난 시각화 방법이다. 점으로 표현되는 방식은 산점도(scatter plot)와 유사하나, 데이터 수가 많으면 점이 겹치고 복잡해지는 단점이 있다. 성격이 다른 항목의 관계성을 파악하기에 유용하며 선형이나 비선형의 형태로 확인해 방향성, 강도, 이상값 등을 확인할 수 있다.

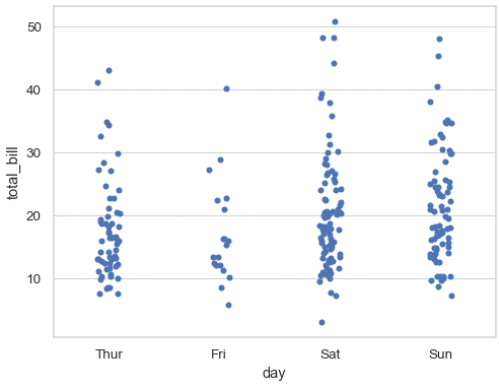

<그림 3.15> 점도표(Dot plot)

3.3 다변량 분석 (Multi-variate Analysis)

EDA에서 광범위한 데이터셋을 다룰 때 마주치는 어려움 중 하나는 많은 수의 변수를 동시에 분석하는 것이다. 일변량 분석(Univariate Analysis)도 단일변수의 고유한 특성에 대해 유용한 정보를 제공할 수 있지만, 여러 변수로 구성된 데이터 셋을 종합적으로 조사하기에는 부적합한 경우가 많다. 둘 이상 변수 간의 관계가 전체 변동성에 미치는 영향을 여러 각도와 측면에서 파악하는 것을 다변량 분석(Multivariate Analysis)이라고 하며, 변수 간의 상관성(correlation) 및 인과성(correlation), 패턴, 경향성(trend) 등을 파악하는 데 유용하다. 다변량 분석 중 두 개의 변수 간 관계를 분석하는 경우를 이변량 분석(Bivariate Analysis) 분석이라고 한다. 이러한 방법을 통해 연구자는 각 변수가 결과에 미치는 영향을 이해하고 학습과 예측에 사용할 변수 선정에 참고할 수 있다. <표 3.4>는 변수의 형태별로 다변량 분석 방법을 정리한 것이다.

<표 3.4> 변수의 자료형태에 따른 다면량 분석 방법

구 분	비시각화	시각화
수치형 변수	○ 상관분석(Correlation Analysis) - 피어슨 상관계수	○ 산점도(Scatter Plot)
범주형 변수	○ 교차 빈도표(Cross-tabulation) ○ Phi Correlation(이변량) ○ Cramer's V(다변량) ○ Lambda ○ Chi-Square분석(두 변수가 독립적인지 여부) ○범주별 통계값: 범주의 종류에 따라 - 2개: T-test/Z-test - 3개 이상: ANOVA (집단별 평균차가 유의한지 여부)	○ 범주별 시각화 - 파이 차트, 막대그래프, 점 차트 ○ 모자이크 플롯(Mosaic Plot)
수치형/ 범주형 변수 혼합	○ 범주별 요약통계 ○ 범주별 상관분석 ○ Logistic Regression ○ Point Biserial Correlation	○ 범주별 시각화 - 히스토그램, 상자 그래프, 산점도 ○ 히트맵(Heat Map)

3.3.1 상관성과 인과성

변수 간의 관계 분석을 통해 서로 의미 있는 상관성(correlation)을 갖는 변수의 조합을 찾을 수 있다. 상관성이란 두 변수의 공변성(co-variation)의 정도를 의미하는데, 한 변수의 변화가 다른 변수의 변화와 어떤 정도로 연관되어 있는지를 양적으로 나타낸다. 그러나 상관성이 높다고 해서 두 변수가 서로 영향을 주고받는 관계로 단정할 수는 없다. 즉 제3의 변수로부터 두 변수가 독립적으로 같은 영향을 받고 있어도 상관성은 높게 나타날 수 있기 때문이다.

한 변수가 다른 변수에 영향을 주고 있는지 판단하기 위해서는 인과성(causality)을 입증해

야 한다. 인과성은 상관성에 비해 더 엄밀한 정의가 필요한데, 즉 한 변수의 변동성이 다른 변수의 변동성의 원인이 되고 있어 두 변수 간 상관성을 나타내는 경우를 의미한다. 따라서 상관성은 인과성이 성립하기 위한 하나의 필요조건이므로 변수 간 상관성이 입증되었다 하더라도 인과성 여부를 판단하려면 좀 더 주의 깊은 고찰이 필요하다. 변수 간의 인과성을 판단하기 위해서는 일반적으로 다음의 세 가지 조건들이 성립해야 한다.

(1) 공변성(co-variation): 한 변수가 변할 때 다른 변수도 함께 변해야 한다. 공변성이 나타나도 여전히 인과관계가 없을 가능성이 있지만, 일단은 인과관계를 의심할 수 있다.
(2) 선후관계(time order): 시간상으로 하나의 변수가 변화했을 때 다른 하나가 뒤따라 변화하는 관계여야 한다. 이 경우 먼저 변화한 변수가 인과관계의 원인이 되고, 나중에 변화한 변수가 결과가 될 수 있다.
(3) 비허위성(non-spuriousness): 공변성과 선후관계와 더불어, 이러한 변화의 양상이 제3의 다른 변수로는 설명될 수 없어야 한다. 즉, 다른 외생변수로 인해 거짓 인과관계를 형성했다는 대안적 설명이 불가능해야만 한다.

상관성을 분석하는 방법은 분석의 대상이 되는 변수가 갖는 자료의 형태에 따라 달라지므로 먼저 그 형태에 따라 구분해야 한다.

3.3.2 다변량 비시각화 (Multi-variate Non Graphic)

1) 수치형 변수

수치형 변수들 간의 다변량 비시각화는 상관 구조나 종속성 파악을 위해 피어슨/스피어만 상관계수 행렬, 다중공선성 분석(VIF) 등의 수치 기반 통계 지표를 많이 활용한다.

가. 피어슨 상관계수 (Pearson Correlation Coefficient)

가장 흔히 쓰이는 상관관계로, 두 연속형 변수가 선형적으로 얼마나 관계가 있는지 -1~1 사이의 값으로 표현된다. 양의 상관 관계면 한 변수가 증가하면 다른 한 변수도 증가하고, 음의 상관 관계면 한 변수가 감소하면 다른 한 변수도 감소하는 모습을 보인다. 상관 계수의 절댓값이 클 수록 높은 (선형) 관계가 있고, 작을 수록 (선형) 관계가 거의 없다. 또한 두 변수 모두 정규분포를 이룬다는 조건이 만족해야 정확한 결과로 사용할 수 있다.

변수가 비선형 상관관계(nonlinear relationship), 이상값(outlier), 비대칭분포(skewed distribution)를 가지거나, 데이터가 범주형 변수(categorical variable)인 경우 피어슨 상관계수는 상관관계를 측정하는 데 적합하지 않다. 이러한 가정 (assumption) 중 하나라도 위반된다면 순위 상관계수(rank correlation coefficient)를 고려해야 하며 아래의 수식을 활용하여 계산한다.

$$\gamma_{XY} = \frac{\sum_{i=1}^{n}\left(X_i - \overline{X}\right)\left(Y_i - \overline{Y}\right)}{\sqrt{\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2}\sqrt{\sum_{i=1}^{n}\left(Y_i - \overline{Y}\right)^2}} \qquad \text{식(3.12)}$$

여기서, X_i와 Y_i는 각 변수 표본, $\overline{X}$와 $\overline{Y}$는 각 변수의 평균값, n은 관측값의 수를 의미한다.

피어슨 상관계수는 선형성(linearity)과 정규성(normality)을 전제조건으로 만족해야 하며, 그 중에서도 선형성은 필수 전제로 공분산 기반의 선형 상관을 측정하므로 두 변수가 일정한 비율로 함께 증가하거나 감소해야 한다. 선형성은 <그림 3.16>에 나타난 것과 같이 산점도의 형태가 직선으로 분포하면 선형성이 있는 것으로 판단할 수 있다. 정규성은 엄격한 전제는 아니지만, 피어슨 상관계수 결과값의 통계적 유의성 검정(t-test 기반)에서 p-value 계산의 정확성은 정규분포일 때 가장 정확하다. 정규성의 검정은 Shapiro-Wilk Test(소표본에 적합), Kolmogorov-Smirnov Test(중대 표본에 적합), Anderson-Darling Test(엄격한 꼬리 검정) 등이 많이 사용된다. 만일 두 변수가 비선형 상관관계(nonlinear relationship), 비대칭분포(skewed distribution), 이상값(outlier) 영향이 큰 경우이거나, 범주형 변수(categorical variable)인 경우에는 스피어만 상관계수나 켄달 상관계수 등 순위 상관계수(rank correlation coefficient)를 고려해야 한다.

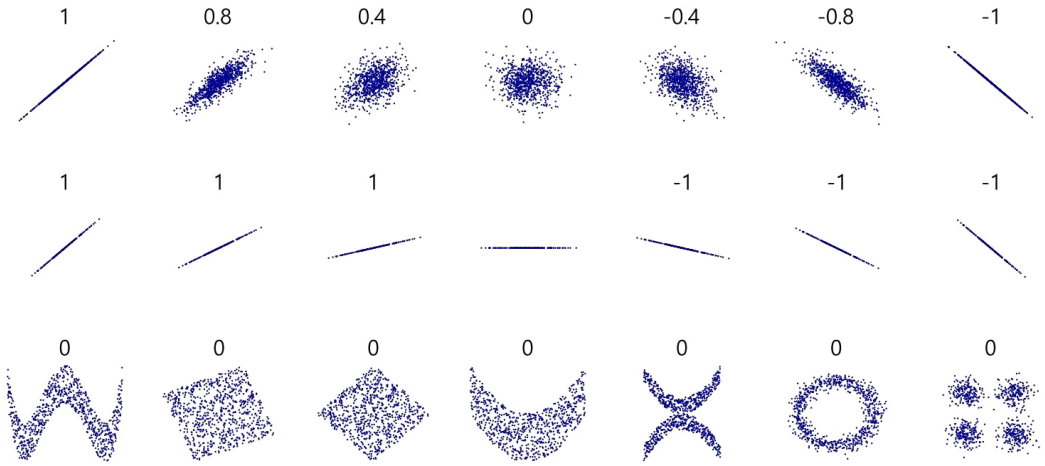

<그림 3.16> 상관계수 값에 따른 데이터 분포 형태

나. 편상관계수 (Partial Correlation Coefficient)

통계학에서 두 변수 간 상관관계를 측정할 때 다른 변수의 영향을 제거하여 변수 간 상관성을 평가하는 방법으로, 특정 변수가 다른 변수들 간 관계에 미치는 영향을 완전히 제거하여 두 변수 간의 직접적인 관계를 파악하는 데 유용하다. 편상관계수는 두 변수 X와 Y

사이의 편상관관계를 측정할 때 제3의 변수 Z(통제변수)의 영향을 제거하는 방식으로 계산한다. 즉, X와 Z, Y와 Z 간의 선형회귀를 통해 잔차(residual) e_X와 e_Y를 계산한 후, 잔차 간의 피어슨상관계수를 계산함으로써 산정할 수 있다.

편상관계수는 기본적으로 피어슨 상관계수와 유사한 개념으로 -1 ~ 1 사이의 값을 가지며 편 상관관계는 선형 관계를 가정하기 때문에 비선형 관계를 가진 변수들 간의 상관성을 평가할 경우에는 부적합할 수 있다. 또한 데이터에 다중공선성이 존재할 경우, 편 상관관계의 신뢰성이 떨어지는 경우도 있다.

녹조와 기상인자의 관계로 예를 들면, 녹조 현상의 주 원인인자인 남조류의 경우 수온에 직접적인 영향을 주는 기온이 높을수록 생장에 유리하여 기온이 높은 여름철에 남조류 세포수가 대량 발생하는 경향이 있다. 기압의 경우, 기온과의 반비례 관계를 갖기 때문에 기온이 높은 여름철에 기압이 낮고, 겨울철에 기압이 높다. 이러한 이유로 결과적으로는 남조류 세포수 생장에 직접적인 상관관계가 규명되지 않은 기압과 남조류 세포수 간의 상관관계가 높게 산정된다. 이러한 문제를 해소하기 위한 방법으로 편 상관관계 분석은 이러한 두 변수 사이의 상관관계 평가 시 두 개의 다른 변수에 대한 한 변수의 효과를 제거할 때 사용한다.

다. 부분상관계수 (Semi-partial Correlation Coefficient)

편상관관계와 유사한 개념으로, 통계 분석에서 특정 독립변수의 종속 변수에 대한 고유한 기여도를 평가하는데 사용되는 지표이다. 다른 독립변수들의 영향을 제거한 상태에서 주요한 독립변수와 종속변수 간 상관관계를 측정하며 회귀분석에서 각 독립변수가 종속변수에 미치는 독립적인 영향을 파악하는데 유용하다. 특정 독립변수에서 다른 독립변수들의 영향을 제거한 후 해당 독립변수와 종속변수 간 상관관계를 계산하며, 상관관계를 해석하고자 하는 두 표본에 대하여 다른 독립변수의 영향을 완전히 제거하는 편 상관관계와 달리 부분 상관관계는 다른 독립변수의 영향을 일부 표본에 대해서만 제거한다는 점이 다르다.

예시로 녹조 발생에 영향을 미치는 요인을 분석하는 경우 수온, 염류 농도, 일조량 등 여러 변수가 고려됨. 이러한 변수들 중 특정 변수의 고유한 영향을 평가할 때 부분 상관관계를 활용하는 것이 가능하다.

라. 교차상관계수(Cross Correlation Coefficient)

두 시계열 간의 상관성을 분석하는 통계적 기법으로, 한 시계열이 다른 시계열에 대해 지연 또는 선행 시간을 가질 때 그 관계를 평가하는데 활용한다. 교차상관함수는 두 시계열 $X(t)$와 $Y(t)$의 지연시간 τ에 따른 상관성을 나타내며 교차 상관관계는 수질 환경에서 녹조 발생과 환경 요인 간의 관계를 분석하는데 활용 가능하다. 과거의 연구에서는 남한의 4대강 보에서 클로로필-a 농도와 다른 환경 요인 간의 교차 상관관계를 분석하여 조류 발생과 환경 요인 간의 상관성을 평가한 사례가 있다.

교차상관분석 기법은 여러 분야에서 다양한 알고리즘과 모델에 적용되어 데이터 분석의 효율성을 높일 수 있다. 대표적으로 통신 분야에서는 신호 처리와 패턴 인식 등에 널리 활용되어 왔으며, 교차상관분석 기법을 기반으로 개발된 여러 알고리즘이 존재한다. 이러한 데이터 처리 방식은 녹조 시계열 변수의 시간 지연을 고려한 상관관계 파악과 데이터에 대한 패턴 인식 및 처리에도 활용이 가능하다. <그림 3.17>은 교차상관분석을 수행한 결과를 나타내고 있다.

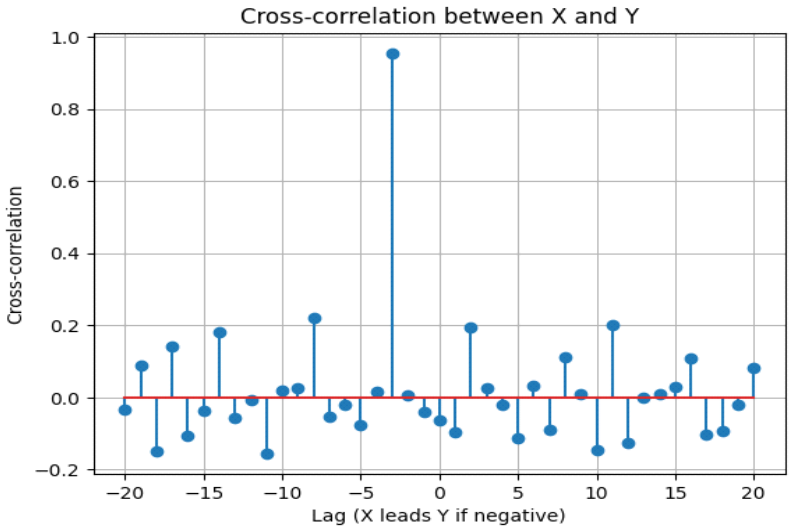

<그림 3.17> 두 변수의 지연시간(lag)에 따른 교차상관계수

마. 분산팽창지수 (Variance Inflation Factor, VIF)

분산팽창지수는 특정 변수가 다른 독립변수들과 얼마나 상관되어 있는지를 정량적으로 표현하는 지표이다. 상관계수와 유사한 개념을 가지고 있으나, 변수들의 공분산과 각 변수의 표준편차를 활용하는 상관계수와 달리 상관계수에서 파생되는 결정계수(R^2)를 활용하여 아래의 수식에 따라 계산한다. 일반적으로 VIF 값이 10을 초과할 경우 다중공선성이 높다고 판단하나, 드물게 VIF 값의 임계값을 5로 설정하는 경우도 있고 VIF 값이 높을수록 해당 독립변수의 분산이 다른 변수들과의 상관관계로 인해 팽창되었음을 의미한다. VIF 계산은 식(3.13)과 같으며, <표 3.5>는 VIF 값에 따른 해석 기준을 나타내고 있다.

$$VIF_j = \frac{1}{1 - R_j^2} \qquad \text{식(3.13)}$$

여기서, R^2은 변수 X_j를 나머지 변수들에 회귀했을 때의 결정계수를 의미한다.

<표 3.5> VIF 값의 해석 기준

VIF 값	해 석
1~2	다중공선성 거의 없음
2~5	다중공선성이 약간 있음 (보통 허용 가능)
5 ≤ VIF < 10	다중공선성 존재, 해석에 주의 필요
VIF ≥ 10	심각한 다중공선성 문제 있음, 변수 제거나 변환 고려 필요

VIF는 머신러닝에서도 전처리 단계에서 변수 다중공선성 제거 도구로 활용하면 모델의 안정성과 성능 향상을 기대할 수 있다. 다만, 트리 기반 모델이나 딥러닝 모델처럼 변수 간의 공선성에 덜 민감한 구조라면 VIF 계산이 필수는 아니다.

2) 범주형 변수

가. 교차 빈도표(Cross Tabulation/Contingency Table)

서로 다른 범주형 변수들이 결합될 때 각 범주 조합이 얼마나 자주 발생하는지를 행과 열의 형태로 정리하여 제시하는 비시각화 기반의 기술통계 기법이다. 교차빈도표는 한 변수를 행으로, 다른 변수를 열로 배치하고, 각 셀에 해당 범주 조합의 관측 빈도를 기록함으로써 변수 간 분포 구조와 상호 연관성을 체계적으로 파악할 수 있도록 한다. 또한, 각 범주 조합의 단순 빈도뿐 아니라 전체 대비 비율, 행 기준 또는 열 기준의 조건부 비율로 확장하여 해석할 수 있어, 특정 범주 내에서 다른 변수의 분포가 어떻게 달라지는지, 또는 변수 간 특정 조합이 과소·과대 발생하고 있는지 등을 정량적으로 비교·진단하는 데 유용하다. 이러한 특성 때문에 교차빈도표는 시각화 이전 단계에서 데이터의 구조적 특성을 명확히 이해하고, 이후 수행되는 통계적 가설검정과 모델 분석의 기초자료로 기능한다.

특히 교차빈도표는 범주형 변수 간 독립성 여부를 탐색하는 사전 분석 도구로서 중요한 역할을 한다. 예를 들어, 행·열의 주변빈도만으로 기대되는 발생 수준에 비해 특정 셀의 빈도가 두드러지게 크거나 작은 경우, 이는 변수 간 잠재적 연관성 또는 구조적 차이를 시사하는 신호로 해석될 수 있다. 나아가 분석 차원을 확장하여 세 개 이상의 범주형 변수를 동시에 고려하는 다차원 교차표로 확장할 경우, 제3의 변수에 따른 조건부 관계나 상호작용 양상을 계층적으로 비교·분석할 수 있다. 이와 같이 교차빈도표는 단순 요약 통계를 넘어, 카이제곱 독립성 검정, Cramer's V와 같은 연관성 지수 산출, 로지스틱 회귀 및 로그선형 모델과 같은 후속 분석 단계로 자연스럽게 연결되는 기반 자료 역할을 수행한다.

<표 3.6>은 조류 발생 여부에 대한 교차빈도표 예시를 나타낸다. 표에서 나타내듯이 각 셀값은 두 범주 조합에서 관측된 빈도 수(n_{ij})를 의미하고, 행 합계로 해당 수질 등급의 전체 발생 건수(주변빈도)를, 열 합계는 조류 발생 여부별 전체 건수를 쉽게 파악할 수 있다.

<표 3.6> 교차빈도표 예시 (빈도기준)

조류 발생 여부	발생	미발생	합계
수질 등급 A	12	38	50
수질 등급 B	25	30	55
수질 등급 C	33	12	45
합계	70	80	150

* 카이제곱 독립성 검정 등을 통해 통계적으로 유의한 관계인지 확인할 수 있음

<표 3.7>은 <표 3.6>의 빈도표를 이용해 행별 비율(왼쪽 표)과 전체 비율(오른쪽 표)로 나타낸 것이다. 행별 비율은 각 행의 합이 100%가 되도록 하여 특정 등급 내에서 조류 발생 비율이 얼마나 되는지 비교하는데 유용하며, 전체 비율은 전체 데이터 내에서 조합별 상대적 비중을 확인 가능하게 한 것이다.

<표 3.7> 교차비율표 예시 (왼쪽: 행 기준, 오른쪽: 전체 기준)

조류 발생 여부	발생(%)	미발생(%)
수질 등급 A	24.0	76.0
수질 등급 B	45.5	54.5
수질 등급 C	73.3	26.7

조류 발생 여부	발생(%)	미발생(%)	합계(%)
수질 등급 A	8.0	25.3	33.3
수질 등급 B	16.7	20.0	36.7
수질 등급 C	22.0	8.0	30.0
합계	46.7	53.3	100.0

다만 교차빈도표를 해석할 때에는 몇 가지 유의점이 요구된다. 표본 수가 매우 적은 셀이 과도하게 많을 경우 해석의 안정성이 저하될 수 있으며, 범주 수가 지나치게 세분화된 경우에는 해석 복잡도가 증가하므로 사전에 범주 통합 또는 군집화와 같은 전처리를 병행하는 것이 바람직하다. 또한 단순 빈도 차이만으로 인과관계를 단정하여 해석하기보다는, 조건부 분포 비교와 통계적 검정을 함께 수행하여 해석의 타당성을 보완하는 접근이 요구된다. 이러한 점을 종합하면, 교차빈도표는 다변량 범주형 데이터의 구조와 관계를 체계적으로 이해하기 위한 핵심적 분석 도구로서, 탐색적 자료 분석과 추론 통계 분석을 연결하는 중요한 중간 단계라 할 수 있다.

나. 파이 상관계수 (Phi Correlation Coefficient)

파이 계수는 2×2 교차표에서 두 범주형 변수 간 상관성을 측정하는 지표로 피어슨의 카이제곱 통계량을 기반으로 하며, 다음의 수식을 활용하여 계산한다. 피어슨 상관계수와 유사하지만, 독립변수와 종속변수가 모두 이분형 변수일 때 두 변수의 상관관계를 파악하기 위해 쓰이는 계수로, 비교 범주 대상이 2개인 경우 사용한다. 아래의 식(3.14)를 활용하여 계산한다.

$$\Phi = \sqrt{\frac{x^2}{n}}$$ 식(3.14)

여기서, x^2은 카이제곱 통계량, n은 총 표본 개수를 의미한다.

다. 크라머 V 계수 (Cramer's V coefficient)

파이 계수를 정규화한 형태로, 2×2 이상의 교차표에서 두 범주형 변수 간 상관성을 측정하며, 다음과 같은 수식을 활용하여 산정한다. 크래머 V 계수는 0 ~ 1 사이의 값을 가지며, 0은 두 변수 간 상관성이 없음을 의미하며 아래의 식(3.15)를 활용하여 계산한다.

$$V = \sqrt{\frac{x^2}{n \cdot min(c-1, r-1)}}$$ 식(3.15)

여기서, c는 데이터 행의 개수, r은 데이터 열의 개수, 나머지 변수는 파이 계수와 동일

라. 추프로프 T 계수 (Tschuprow's T coefficient)

추프로프 T 계수는 크라머 V 계수와 유사하나, 교차표의 행과 열의 수가 크게 다를 때 주로 활용하며, 아래의 식(3.16)을 활용하여 계산한다. 크래머 V 계수와 마찬가지로 0 ~ 1 사이의 값을 가지며, 0은 두 변수 간 상관성이 없음을 의미한다.

$$T = \sqrt{\frac{x^2}{n\sqrt{(c-1)(r-1)}}}$$ 식(3.16)

여기서, 사용되는 변수들은 크래머 V 계수와 동일하다.

3) 수치형, 범주형 변수

가. 범주별 요약통계

Summary Statistics는 요약통계량으로 .describe() 함수를 사용하면 평균, 중앙값, 최대/최소값 등 데이터의 컬럼별 요약 통계량을 볼 수 있다. 그래서 비시각화의 경우, 시각적인 지표 없이도 요약통계량을 통해 대략적인 데이터의 분포를 유추하고 정확한 값을 파악하기 용이하다. 데이터의 중심을 알기 위해서는 평균, 중앙값, 최빈값을 사용하고, 데이터의 분산도를 알기 위해서는 범위, 분산 등을 이용한다. 통계 지표를 이용할 때에는 평균과 중앙값의 차이처럼 데이터의 특성에 주의해서 이용해야 한다.

나. 스피어만 상관계수 (Spearman's rho/Spearman Rank Correlation Coefficient)

스피어만 상관계수는 두 변수 간의 순위 관계를 측정하는 비모수적 방법으로, 피어슨 상관계수는 관계의 선형도(linearity)를 측정하는 반면, 스피어만 상관계수는 관계의 단조성(monotonicity)을 측정한다. 이는 피어슨 상관계수에 비해 이상치에 덜 민감하며, 비선형적이지만 순위적인 관계를 파악하는데 유리하다. 데이터가 정규분포를 따르지 않거나 순위형 데이터일 때 사용하며, 각 데이터 값을 순위로 변환한 후 피어슨 상관계수를 계산하는 방식으로 계산한다. 데이터 내 편차와 에러에 민감하며, 일반적으로 켄달 상관계수보다 높은 값을 가진다. <표 3.8>은 스피어만 상관계수의 활용 사례를 나타내고 있다.

$$\rho = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \qquad \text{식(3.17)}$$

여기서, d_i는 각 관측값의 순위 차이($d_i = R(X_i) - R(Y_i)$), n은 표본의 개수를 의미한다.

<표 3.8> 스피어만 상관계수 (Spearman's ρ) 활용 사례

상 황	설 명
비선형 관계	변수 간 관계가 선형이 아니더라도 순위 기반의 단조(monotonic) 관계라면 유의미한 상관성을 잡아낼 수 있음
이상값 민감도 완화	피어슨은 이상값에 매우 민감하지만, 스피어만은 순위를 기준으로 하므로 이상값의 영향을 덜 받음
자료의 정규성이 부족	남조류세포수처럼 정규분포를 따르지 않는 데이터의 경우 스피어만을 선호하기도 함
환경/생태계 변수	수질·기상·유량 등과 같은 환경계열 변수들은 분포 왜곡이 심해 스피어만이 자주 사용됨

다. 켄달 상관계수 (Kendall Rank Correlation Coefficient)

켄달 상관계수는 두 변수 간 순위 일치 정도를 측정하는 비모수적 방법으로, 두 데이터 쌍의 순위 일치 여부를 통해 계산되며, 순위형 데이터나 비선형적 관계를 분석할 때 사용한다. 스피어만 상관계수와 켄달 상관계수는 사용 조건이 같지만, 켄달 타우는 일반적으로 더 작은 표본에 선호되는 반면, 스피어만 상관계수는 더 널리 사용된다. 켄달과 스피어만은 순위 일치 정도를 검사한다는 점에서 유사한 분석이다. 따라서, 동일 데이터로 상관분석으로 진행한다면 상관계수 값이 약간 다를지라도 비슷한 추론을 내린다.

$$\tau = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}} \qquad \text{식(3.18)}$$

여기서, C는 일치하는 쌍의 수, D는 불일치하는 쌍의 수, T_x와 T_y는 각각 X와 Y에서 동순위를 가진 쌍의 수를 의미한다.

<표 3.9> 켄달 상관계수 (Kendall's Tau) 활용 사례

상 황	설 명
샘플 수가 작을 때	Kendall은 작은 샘플에서도 비교적 안정적이며, 불일치쌍을 기반으로 계산하므로 순위 일관성에 더 민감
변수 간 순위 일관성이 중요할 때	변화 방향이 일관되게 유지되는지(동일 방향 증가 등)를 평가할 때 유용
해양, 기상, 생태학 분야	Kendall은 기상기후학에서 변수 간의 동조성(synchrony) 분석에도 사용됨

라. 점이연 상관계수 (Point Biserial Correlation Coefficient)

하나의 변수가 연속형이고 다른 변수가 자연적으로 이분화된 범주형일 때 사용되는 상관계수이다. 한 변수가 명명척도(nominal scale)에 의하여 이분화 (dichotomous, binary)된 질적 변수이고 다른 변수는 연속성을 지닌 양적 변수 (quantitative)일 때 두 변수의 상관 정도를 추정하기 위해 쓰이는 상관계수이다. 수학적으로는 식(3.19)와 같이 피어슨 상관계수와 동일하며, 범주형 변수를 0과 1로 환산하여 계산한다.

$$\gamma_{pb} = \frac{M_1 - M_0}{s_n}\sqrt{\frac{n_1 n_0}{n^2}} \qquad \text{식(3.19)}$$

여기서, M_i은 범주형 변수가 i인 표본의 연속형 변수 평균, s는 전체 연속형 범주의 표준편차, n_i는 범주형 변수가 i인 표본의 크기, n은 전체 표본 크기를 의미한다.

마. 이연 상관계수 (Biserial Correlation Coefficient)

연속형 변수를 인위적으로 이분화하여 범주형 변수로 변환했을 때 원래의 연속형 데이터의 특성을 고려하여 상관관계를 추정하는 방법이다. 점이연 상관계수와 달리 범주형 변수가 인위적으로 이분화된 경우에 사용되며, 연속형 변수의 원래 분포를 고려하여 상관관계를 추정한다. 이연 상관계수는 식(3.20)과 같이 계산한다.

$$r_b = \frac{M_1 - M_0}{s}\frac{n_1 n_0}{n^2 u} \qquad \text{식(3.20)}$$

여기서, u는 표준 정규분포에서 누적확률이 n_1/n인 지점의 밀도 함수 값, 나머지 변수들은 점이연 상관계수의 산정식과 동일하다.

바. 다연 상관계수(Polyserial correlation coefficient)

연속형 변수와 다단계 범주형 변수(순서형) 간의 상관관계를 추정하는 방법으로 다연 상관계수는 연속형 변수와 잠재적인 연속형 변수가 존재한다고 가정하여 범주형 변수를 연속형 변수로 변환하여 상관관계를 추정한다. 다연 상관계수는 범주형 변수가 순서형일 때 특히 유용하며, 범주형 변수를 연속형으로 간주하여 상관관계를 추정한다.

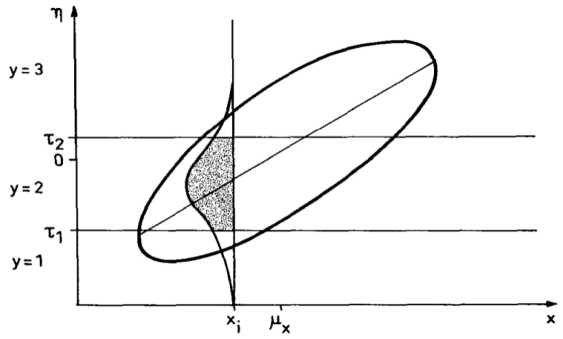

<그림 3.18> 연속형 변수 η와 범주형 변수 Y

출처: Olsson et al.(1982)

3.3.3 다변량 시각화 (Multi-variate Graphic)

다변량 데이터는 그래픽을 사용하여 둘 이상의 데이터 집합 간의 관계를 표시한다. 가장 많이 사용되는 그래픽은 그룹화된 막대 그림 또는 막대 차트로, 각 그룹은 변수 중 하나의 한 수준을 나타내고 그룹 내의 각 막대는 다른 변수의 수준을 나타낸다. 다변량 시각화의 일반적인 유형은 다음과 같다.

1) 수치형 변수

가. 산점도 (Scatter Plot)

산점도는 두 개의 수치형 변수 간 관계를 분석하기 위해 x-y 좌표평면 위에 관측값을 점으로 표현하는 시각화 기법으로, 변수 간 산점 분포를 통해 상관성, 패턴, 이상치의 존재 여부를 탐지하는 데 활용되는 핵심 도구이다. 이를 통해 변수 간 관계의 형태가 선형적인지 비선형적인지 직관적으로 파악할 수 있으며, 회귀선이나 밀도추정 기법과 결합할 경우 잠재적인 선형관계의 존재 여부를 시각적으로 확인할 수 있다. 일반적으로 두 변수가 양적 변수일 때 종속변수를 y축에 배치하고 독립변수를 x축에 배치하여, 한 변수가 다른 변수의 영향을 얼마나 받는지 그 경향을 점 분포 형태로 탐색한다. 상관계수를 함께 해석할 경우 동일한 상관값을 가지더라도 분포 모양이 서로 다른 다양한 관계 패턴을 산점도를 통해 시각적으로 비교할 수 있다는 점에서 분석적 의의가 크다.

산점도는 기본적으로 이변량 분석 도구이지만, 색상, 점의 크기, 모양, 투명도 등을 추가 변수로 매핑함으로써 다변량 시각화로 확장할 수 있다. 나아가 필요에 따라 3차원 산점도로 확장하거나, 각 점에 텍스트 라벨을 부여하는 방식으로 속성 정보를 보다 풍부하게 표현할

수도 있다. 한편 Q-Q 플롯과 외형적으로 유사해 보일 수 있으나, Q-Q 플롯은 데이터의 분위수를 이론적 분포의 분위수와 비교하여 해당 데이터가 특정 이론적 분포(예: 정규분포)를 따르는지 여부를 검증하는 데 목적이 있다는 점에서 기능과 해석 목적이 명확히 구분된다. 이러한 특성을 종합할 때, 산점도는 요인과 반응 간 관계를 탐색적으로 시각화하고, 이후 통계적 분석 및 모델링 단계로 연계하기 위한 기초 분석 도구로서 중요한 역할을 수행한다.

<그림 3.19> 산점도의 다양한 활용

나. 히트맵 (Heat Map)

히트맵은 데이터 값을 색상으로 표현하여 2차원 행렬 형태로 시각화하는 기법으로, 각 행과 열은 변수 혹은 범주를 의미하고 셀의 색상은 해당 조합에 대응되는 수치값을 나타낸다. 이러한 표현방식은 특히 변수 간 상관관계(correlation) 행렬 또는 범주 간 빈도(frequency) 분포를 시각적으로 요약할 때 효과적이며, 수치형 변수 집합에서 계산된 상관계수 행렬을 직관적으로 해석하는 데 적합하다. 예를 들어, 피어슨 상관계수의 값이 -1에서 +1의 범위로 산출될 경우, 히트맵에서는 해당 값이 색상 스케일로 인코딩되어 음의 상관, 양의 상관, 관계가 미약한 구간을 시각적으로 구분할 수 있다.

히트맵의 가장 큰 장점은 색상 차이를 통해 다수의 변수 조합을 동시에 비교할 수 있다는 점이다. 수십 개 이상 변수로 구성된 데이터셋의 경우에도, 색상 패턴만으로 변수들 간 유사성, 군집적 구조, 강한 상관관계가 형성된 구간 등을 신속하게 식별할 수 있으며, 이는 데이터 구조를 이해하고 이후 분석 방향을 설정하는 데 중요한 기초 정보를 제공한다. 다만 히트맵은 개별 값의 정밀 해석보다는 상대적 크기와 전반적 패턴을 파악하는 데 유리한 도구로, 수치의 정확한 비교가 필요한 경우에는 표 형태의 통계 요약이나 추가적인 정량 분석과 병행하는 것이 바람직하다.

또한 히트맵은 단순한 상관계수 시각화를 넘어, 범주형 변수 간 교차빈도, 시간-공간 데이터의 변화 양상, 정상 구간과 이상 구간 간 대비 등 다양한 분석 맥락으로 확장 가능하다. 변수 그룹을 클러스터링하여 행·열 순서를 재배열하거나, 색상 팔레트를 적절히 설계하면 패턴 해석의 가시성을 더욱 향상할 수 있다. 이러한 특성을 고려할 때, 히트맵은 복잡한 다변량 자료를 요약·구조화하여 데이터 관계의 전반적 윤곽을 파악하는 탐색적 시각화 도구로서, EDA 과정에서 중요한 역할을 담당한다.

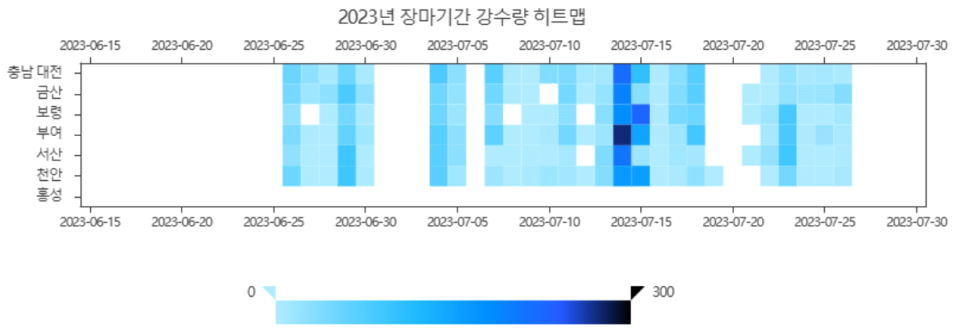

<그림 3.20> 히트맵 예시 * 출처: 기상청

2) 범주형 변수

가. 범주별 시각화

범주형 변수에 대한 다변량 시각화는 각 범주가 갖는 분포적 특성과 비교 관계를 직관적으로 파악하기 위해, 범주 단위로 데이터를 구분한 뒤 해당 범주 내에서 단변량 시각화를 적용하는 방식으로 구성할 수 있다. 이러한 접근은 범주 전체를 하나의 집합으로 처리하는 전통적 요약 통계 방식과 달리, 각 범주가 개별적으로 어떤 분포적 특징을 나타내는지, 그리고 범주 간 패턴 차이가 어떻게 드러나는지를 시각적으로 비교·해석할 수 있다는 점에서 분석적 의의가 크다. 구체적으로는 범주별로 파이차트, 막대그래프, 점차트와 같은 단변량 시각화 기법을 적용하되, 이를 단편적인 그래프 묶음이 아니라 하나의 일관된 시각화 프레임워크로 묶어 해석하는 방식으로 운영한다.

예를 들어, 범주형 변수의 수준(category)별로 자료를 분할한 뒤, 각 범주 내부에서 비율 구조를 표현하기 위해 파이차트를 적용하거나, 상대적 빈도와 비교 관계를 강조하기 위해 막대그래프를 활용할 수 있다. 또한 값의 크기 차이를 보다 정밀하게 비교해야 하는 경우에는 점차트를 사용하여 범주 간 위치 차이를 명확히 드러낼 수 있다. 이러한 시각화는 개별 차트가 독립적으로 제시되는 것이 아니라, 동일한 범주 체계에 기반하여 반복적·대응형 형태로 배치됨으로써, 범주 간 분포 특성의 차이를 체계적으로 대비할 수 있게 한다는 점에서 다변량 시각화의 성격을 지닌다.

나아가, 이러한 범주별 단변량 시각화 접근은 단일 차원의 빈도 비교를 넘어, 범주 간 이질성, 패턴의 비대칭성, 특정 범주에 집중된 분포 구조 등을 시각적으로 드러내는 탐색적 데이터 분석 단계로 확장될 수 있다. 즉, 수치 요약값만으로는 간과되기 쉬운 구조적 변동, 집중도, 분포형태의 차이를 시각적으로 확인할 수 있으며, 이를 기반으로 후속 통계 분석 및 모형화 과정에서 변수 선택, 그룹 통합 또는 세분화 판단 등 실질적인 의사결정에 기여할 수 있다.

결과적으로, 범주형 변수의 다변량 시각화를 범주 단위로 데이터를 분할하고, 각 범주 내에서 단변량 시각화를 체계적으로 적용·배치하여 범주 간 분포 특성을 비교·해석하는 통합적 시각화 카테고리로 정의할 수 있으며, 이는 범주형 데이터의 구조적 특성을 심층적으로 이해하기 위한 효과적인 분석 도구로 기능한다.

나. 모자이크 플롯 (Mosaic Plot)

모자이크 플롯은 두 개 이상 범주형 변수 간의 관계를 사각형 면적의 크기로 표현하는 시각화 기법으로, 교차표(Contingency Table)의 구조를 직관적으로 해석할 수 있도록 설계된 다변량 시각화 방법이다. 전체 패널을 하나의 큰 사각형으로 설정한 후, 해당 사각형의 넓이를 1(또는 전체 표본 수)에 대응시키고, 변수의 범주별 빈도에 비례하도록 영역을 순차적으로 분할한다. 먼저 행 변수의 빈도 크기에 비례하여 직사각형 영역을 구획한 다음, 각 행 영역 내부를 다시 열 변수의 빈도에 따라 세분화함으로써, 2원 또는 3원 교차표의 구조를 면적 기반으로 시각화할 수 있다. 각 사각형의 면적은 특정 범주 조합에 해당하는 관측빈도를 의미하므로, 데이터 내에서 어떤 조합이 상대적으로 크게 또는 작게 나타나는지를 한눈에 비교·판단할 수 있다는 점이 큰 장점이다.

모자이크 플롯은 단순 빈도 비교를 넘어, 통계적 해석과의 연계 측면에서도 유용하다. 교차표 기반의 카이제곱 독립성 검정과 결합할 경우, 기대빈도 대비 관측빈도의 차이를 의미하는 잔차(residual)를 색상으로 표현하여, 특정 범주 조합이 통계적으로 유의하게 과다 또는 과소 발생했는지를 동시에 시각화할 수 있다. 이러한 특성은 변수 간 독립성·연관성 구조를 탐색적으로 파악하고, 데이터 내 잠재적 패턴을 확인하는 데 효과적이다. 나아가 범주 수가 많거나 3개 이상의 변수를 포함하는 경우에도, 단계적 분할 방식을 통해 구조적 관계를 유지하면서 시각화가 가능하므로, 다차원 범주형 자료를 요약하는 데 적합한 도구로 평가된다.

한편, 모자이크 플롯은 면적 비교에 기반한 시각화이기 때문에, 세부 값의 정밀 비교보다는 범주 간 상대적 비중과 전반적인 분포 패턴을 파악하는 데 적합하다. 필요에 따라 범주 정렬, 색상 범례(잔차 크기 또는 그룹 구분), 비율표와의 병행 제시 등을 통해 해석의 가독성을 높일 수 있다. 이러한 특징을 종합하면, 모자이크 플롯은 범주형 데이터에서 변수 간 관계를 구조적으로 파악하고, 교차빈도 기반 분석과 통계적 가설검정을 연결하는 탐색적 시각화 도구로서 중요한 역할을 수행한다. <표 3.21>은 타이타닉 생존자 데이터에서 '객실 등급', '성별', '생존 여부'의 관계를 한눈에 파악 할 수 있게 모자이크 플롯으로 그린 것이다.

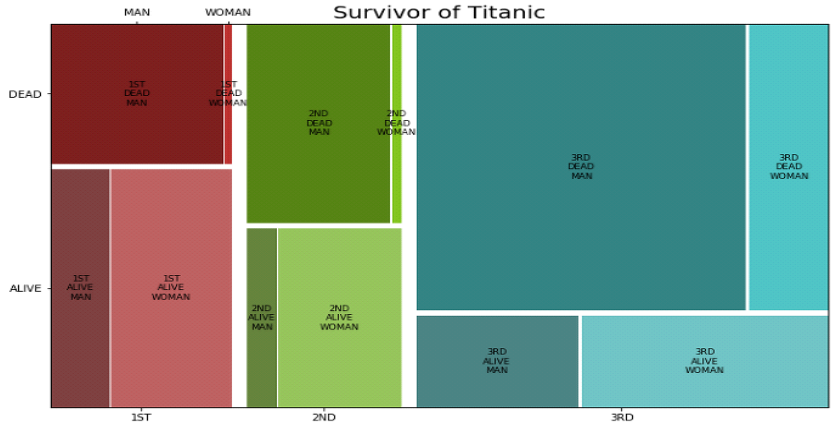

<그림 3.21> 모자이크 플롯 예시 (타이타닉 생존 데이터)

다. 생키 다이어그램 (Sankey Diagram)

생키 다이어그램은 화살표 또는 연결선의 굵기를 이용하여 데이터의 흐름(Flow)과 그 양을 직관적으로 표현하는 시각화 기법으로, 범주형 변수가 단계별로 어떻게 전이되거나 분포되는지를 보여주는 데 적합한 다변량 분석 도구이다. 도식은 일반적으로 여러 범주 또는 상태를 좌측에서 우측으로 순차적으로 배치하고, 각 단계 간을 연결하는 선의 너비를 해당 경로의 빈도 또는 비율에 비례하도록 구성한다. 이때 선의 굵기가 클수록 해당 전이 경로의 상대적 비중이 크다는 것을 의미하므로, 데이터가 어떤 경로를 중심으로 이동하거나 집중되는지 한눈에 식별할 수 있다.

생키 다이어그램의 가장 큰 장점은 복잡한 분기 구조를 시각적으로 단순화하여, 다수의 범주가 서로 다른 방향으로 전환되는 과정을 직관적으로 추적할 수 있다는 점이다. 예를 들어, 조사 대상 집단이 시간 경과, 정책 단계, 운영 상태, 고객 행동 단계 등 여러 단계에서 어떻게 세분화되고 재구성되는지를 흐름 구조로 표현함으로써, 단순 빈도표만으로는 파악하기 어려운 전이 패턴과 경로 의존성(Path Dependency)을 효과적으로 드러낼 수 있다. 또한 빈도 기반 표현뿐만 아니라, 비율, 비용, 자원량, 에너지 흐름 등 다양한 양적 지표를 동일한 구조에 적용할 수 있어, 의사결정·정책평가·프로세스 분석 등 다양한 분석 맥락에서 활용 가능하다.

다만 생키 다이어그램은 시각적 직관성이 뛰어난 반면, 단계 수와 범주 수가 지나치게 많아질 경우 선의 교차가 증가하고 해석이 복잡해질 수 있으므로, 주요 경로를 중심으로 요약하거나 범주를 통합하여 제시하는 것이 효과적이다. <표 3.22>는 웹사이트 방문자의 페이지 이동 경로를 생키 다이어그램으로 나타낸 사례이다.

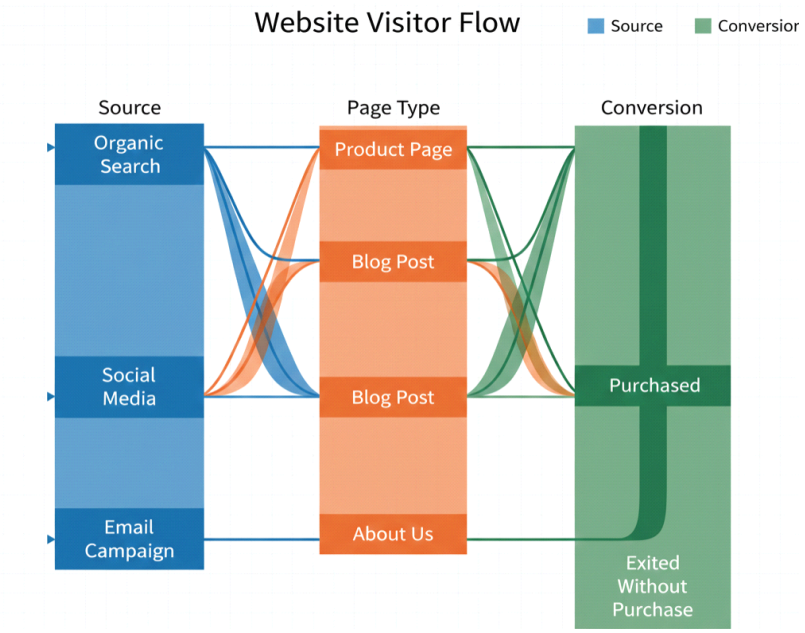

<그림 3.22> 생키 다이어그램 예시(웹사이트 방문자)

출처: Gemini 3(나노 바나나 프로)로 생성한 이미지

라. 트리맵 (Tree Map)

트리맵(Treemap)은 계층 구조를 가진 범주형 데이터를 중첩된 사각형 형태로 표현하는 시각화 기법으로, 상위 범주가 큰 사각형을 이루고 그 안에 하위 범주가 면적 비율에 따라 작은 사각형으로 배치된다. 각 사각형의 면적은 해당 범주의 크기(건수, 비율, 예산, 매출 등)에 비례하도록 설정되므로, 전체 대비 항목별 상대적 비중을 직관적으로 비교할 수 있다.

이 기법의 가장 큰 장점은 공간 효율성이 높다는 점으로, 화면을 빈틈없이 활용하여 많은 범주와 계층 정보를 한 번에 제시할 수 있다. 또한 색상 정보를 추가로 활용하면, 면적은 규모를, 색상은 성과·증감률 등 또 다른 수치형 지표를 동시에 표현할 수 있어, 구조와 지표를 함께 분석하는 데 유용하다. 트리맵은 기업 조직·부서별 예산 배분, 국가·산업·제품군별 시장 점유율 분석, 연구 분야별 투자 규모 분포 등과 같이, 계층형 범주 데이터의 구성 비중과 우선 영역을 한눈에 파악해야 하는 상황에서 효과적으로 활용된다. <그림 3.23>은 업종별 종목별 주가 변동을 트리맵으로 나타낸 사례이다.

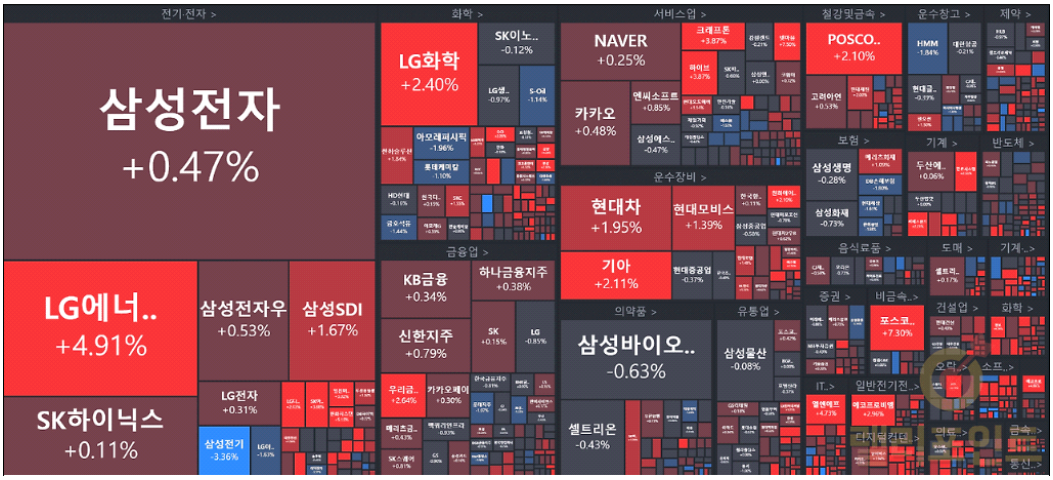

<그림 3.23> 트리맵 예시 (주가 변동)

제 4장 변수 선택 표준운영절차(SOP) 개발

변수 선택(Feature Selection)은 모델의 복잡도를 낮추고, 과적합(Overfitting)을 방지하며, 데이터 처리 속도와 해석력을 향상시키는 것을 목적으로 한다(Guyon & Elisseeff, 2003). 이를 통해 예측 성능의 개선, 모델의 비용 효율성 증대, 그리고 분석 결과의 해석 가능성 향상을 기대할 수 있다. 본 연구는 데이터의 특성과 모델링 목표에 따라 적용 가능한 변수 선택 방법론을 다섯 가지 주요 범주로 분류해 각 방법론에 대한 이론적 근거와 적용 절차를 상세히 기술하고, 녹조 예측 모델 구축을 위한 알맞은 변수선택 방법론을 제시하고자 한다.

4.1 변수 선택(Feature Selection) 방법론

변수 선택 방법론은 변수 탐색 전략과 모델 학습의 결합 방식에 따라 크게 필터(Filter), 래퍼(Wrapper), 임베디드(Embedded) 방식으로 구분되며, 고차원 데이터를 저차원으로 변환하는 차원 축소(Dimensionality Reduction)와 학습된 모델의 특성을 활용하는 모델 기반(Model-based) 선택법을 포함하기도 한다.

4.1.1 필터 기반(Filter-based) 선택법

필터 기반 선택법은 모델 학습 알고리즘과는 독립적으로, 변수와 타겟 변수 간의 통계적 연관성을 측정하거나 변수 자체의 통계적 특성을 분석하여 상위 변수를 선택하는 기법이다. 계산 속도가 매우 빠르며 모델의 편향(Bias)이 개입되지 않아 대용량 데이터의 1차 스크리닝 단계에서 필수적으로 수행한다.

1) 분산 임계값 (Variance Threshold) 기반 제거

변수 내 데이터의 변화가 거의 없는 경우, 즉 분산이 낮은 변수는 정보량이 낮다고 판단하여 제거하는 방법론이다. 해당 변수의 분산을 계산하여 설정된 임계값(예: 0.01) 미만인 변수는 모델 학습에서 제외한다. 특히 One-Hot Encoding 등으로 생성되어 값이 0 또는 1에 극단적으로 치우친 희소한(Sparse) 범주형 변수의 초기 필터링에 효과적으로 적용한다.

2) 단변량 통계 기반 타겟 변수 연관성 분석

각 독립 변수와 타겟 변수 간의 통계적 관계를 단독으로 분석하여 모델 예측에 기여할 가능성이 높은 변수를 선별하며, 타겟 변수의 유형에 따라 적용 기법을 달리한다. 연속형 타겟의 경우 피어슨 상관계수(Pearson Correlation)를 계산하여 절댓값이 높은 변수를 선택하거나, 분

산 분석(ANOVA)의 F-검정을 통해 타겟 그룹 간 평균 차이가 유의미한 변수를 선별한다. 범주형 타겟의 경우 카이제곱 독립성 검정(Chi-Square Test)을 수행하여 타겟 클래스와 독립 변수 간의 연관성(Association)이 유의한 변수를 선택하며, p-value가 유의수준(예: 0.05)보다 낮은 변수를 선택한다. 또한 상호 정보량(Mutual Information)도 비선형 관계를 파악하는 데 유용하게 활용하며, 일반적으로 통계량 순위나 p-value를 기준으로 필터링을 수행한다.

3) 다중공선성 (Multicollinearity) 검토 및 제거

독립 변수들 간의 높은 선형 상관관계는 회귀 모델의 계수 추정치 분산을 증가시켜 해석을 어렵게 하고 모델의 불안정성을 초래하므로, 이를 사전에 제거한다. 각 독립 변수의 분산 팽창 계수(VIF; Variance Inflation Factor) 값을 계산하여 설정된 임계값(일반적으로 5 또는 10)을 초과하는 변수를 식별하며, VIF가 가장 높은 변수부터 타겟 변수와의 상관관계가 낮은 순서대로 제거한다. 또한 독립 변수들 간의 상관 계수 행렬을 시각화하여 절댓값이 높은(예: 0.8 이상) 쌍을 찾아 타겟 변수와의 상관관계가 더 낮은 변수를 제거하는 방식으로 다중공선성을 완화한다.

4) 최종 선택 및 적용 기준

필터 기반 방법은 다중변수 간의 상호작용을 고려하기가 까다로우므로, 1차적으로 변수 후보군을 축소하는 데 활용하는 것이 바람직하다. 많은 변수가 존재하는 고차원 대용량 데이터셋에서 노이즈 변수를 빠르게 제거하여 차원을 축소해야 할 때 효과적으로 적용한다.

4.1.2 래퍼 기반 (Wrapper-based) 선택법

래퍼 기반 선택법은 실제 예측모델을 학습시키며 변수의 하위 집합(Subset)에 대한 모델 성능을 평가하여 최적의 조합을 찾는 방식이다(Kohavi & John, 1997). 변수 간의 상호작용을 반영할 수 있어 예측 정확도는 높으나, 모델 학습을 반복해야 하므로 계산 비용이 크고 과적합의 위험이 존재한다.

1) 전진 선택법(Forward selection)

전진 선택법은 변수가 하나도 없는 가장 간단한 모델(Null Model)에서 시작하여, 각 단계마다 현재 모델에 포함되지 않은 변수들 중에서 모델 성능 지표(예: AIC, BIC, Adjusted R-squared)를 가장 크게 향상시키는 변수를 하나씩 순차적으로 추가하는 방식으로 작동한다. 이 과정은 추가되는 변수의 기여도가 통계적으로 유의미한 임계값을 넘지 못할 때까지 반복된다. 변수 추가 시 통계적 유의수준(p-value)을 기준으로 판단하며, 더 이상 성능 향상이 없을 때 절차를 중단한다. 이 방법은 변수의 상호작용을 초기 단계에서는 충분히 고려하지 못한다는 단점이 존재한다.

2) 후방 소거법(Backward selection)

후방 소거법은 모든 변수가 포함된 풀 모델(Full Model)에서 시작하여, 각 단계마다 현재 모델 내 변수들 중에서 통계적 유의성이 가장 낮거나 모델 성능에 가장 적게 기여하는 변수 하나를 제거한다. 이 방법은 모든 변수가 포함된 상태에서 시작하기 때문에 변수 간의 복잡한 상호작용 효과를 초기에 인지할 수 있다는 장점이 있으나, 변수의 개수가 관측치 수보다 많은 경우($p > n$) 적용이 어렵다는 한계가 있다.

3) 단계적 선택법(Stepwise selection)

단계적 선택법은 전진 선택법과 후방 소거법을 결합한 하이브리드 방식이다. 각 단계에서 새로운 변수를 추가하는 전진 단계와 기존 변수 중 유의성이 떨어진 변수를 제거하는 후진 단계를 모두 수행한다. 예를 들어, 변수를 하나 추가하여 성능이 개선되었더라도, 이로 인해 기존에 포함된 변수의 유의성이 현저히 낮아졌다면 그 변수를 제거한다. 이 유연한 접근 방식은 탐색 과정이 국소 최적해(Local optima)에 빠지는 문제를 보완하고 최적의 변수 집합을 찾는다. 이로 인해 더 넓은 탐색 공간을 확보하고, 변수 선택 결과의 안정성을 높이는 데 기여한다.

래퍼 방법론 적용 시, 변수의 추가/제거 기준은 단순히 R^2나 개별 p-값에 의존해서는 안 된다. R^2는 변수가 많아질수록 필연적으로 증가하므로 과적합을 유도할 위험이 있다. 반드시 AIC(Akaike Information Criterion)나 BIC(Bayesian Information Criterion)와 같이 모델 복잡도에 패널티를 부여하는 통계량, 혹은 k-fold 교차 검증을 통해 측정된 일반화 성능 지표(예: 교차 검증 평균 제곱 오차 R^2_{CV}, AUC)를 최적화 기준으로 사용하여, 선택된 변수 집합이 새로운 데이터에 대해서도 견고한 예측 성능을 보이도록 보장한다.

4.1.3 임베디드 (Embedded) 선택법

임베디드 방식은 모델 학습 과정 자체에 변수 선택을 위한 페널티(Penalty) 항을 포함시켜, 최적화 과정에서 자동으로 변수가 선택되도록 하는 기법이다. 래퍼 방식보다 계산 효율이 높고 필터 방식보다 상호작용을 잘 반영하여 실무적으로 널리 사용된다.

1) LASSO (Least Absolute Shrinkage and Selection Operator)

LASSO는 선형 회귀의 손실 함수(Residual Sum of Squares, RSS)에 회귀 계수의 L1 norm, 즉 절댓값의 합을 규제항으로 추가하는 기법이다(Tibshirani, 1996). 이는 식(4.1)과 같은 최소화 문제로 나타낼 수 있다.

$$argmin_{\beta}\left\{RSS + \lambda_1 \sum_{j=1}^{p} |\beta_j|\right\} \quad \text{식(4.1)}$$

여기서 λ_1은 규제의 강도를 조절하는 하이퍼파라미터이다. L1 규제는 규제항에 절댓값을 취하는 형태이기 때문에, 회귀 계수가 추정되는 제약 조건 영역을 축을 중심으로 뾰족한 마름모꼴 형태로 만든다. 이 기하학적 특성으로 인해, 최적화 과정에서 많은 계수가 정확히 0이 되도록 강제되는 희소성(Sparsity)이 유발된다. 이로 인해 덜 중요한 변수들은 모델에서 효과적으로 제거되며, LASSO는 모델의 예측력 향상과 동시에 효율적인 변수 선택을 수행한다.

2) Ridge

Ridge 회귀는 선형 회귀의 손실 함수에 회귀 계수의 L2 norm, 즉 제곱의 합을 규제항으로 추가하는 기법이다(Hoerl & Kennard, 1970)으로, 식(4.2)와 같은 형태로 나타낼 수 있다.

$$argmin_{\beta}\left\{RSS+\lambda_2\sum_{j=1}^{p}\beta_j^{\,2}\right\} \qquad \text{식(4.2)}$$

Ridge 회귀는 계수를 0에 가깝게 수축(Shrinkage)시키지만, LASSO와 달리 계수를 완전히 0으로 만들지는 않는다. L2 규제는 계수 추정치의 분산이 커지는 다중공선성 문제를 효과적으로 완화하여, 계수 추정의 안정성(Stability)을 높이는 데 중점을 둔다. 이는 모든 변수가 어느 정도 중요성을 가지며, 계수의 안정성이 중요한 경우에 적합하다.

3) Elastic Net

Elastic Net은 LASSO의 L1 규제와 Ridge의 L2 규제를 모두 혼합하여 사용하는 정규화 기법이다(Zou & Hastie, 2005). 이는 L1 규제항과 L2 규제항을 동시에 사용하여 두 규제의 장점을 결합한다. Elastic Net은 아래의 식(4.3)과 같이 나타낼 수 있다.

$$argmin_{\beta}\left\{RSS+\lambda_1\sum_{j=1}^{p}|\beta_j|+\lambda_2\sum_{j=1}^{p}\beta_j^{\,2}\right\} \qquad \text{식(4.3)}$$

이 결합은 LASSO의 강력한 변수 선택 능력과 Ridge의 계수 안정화 능력을 동시에 활용한다. 특히, 데이터에 강한 상관성을 가진 변수들이 그룹으로 존재할 때, LASSO는 종종 그중 임의의 변수 하나만 선택하는 경향이 있는 반면, Elastic Net은 상관성이 높은 변수들을 그룹으로 묶어 선택하거나 배제하는 그룹화 효과(Grouping Effect)가 있어, 더 견고하고 예측력이 높은 변수 집합을 도출한다.

임베디드 기법의 통계학적 근거는 깊은 의미를 갖는다. 베이지안 통계학적 관점에서 볼 때, LASSO의 L1 규제는 계수에 대한 이중 지수(Laplace) 사전 분포를, Ridge의 L2 규제는 정규 분포(Normal) 사전 분포를 사용하는 것과 수학적으로 동등하다. 이중 지수 분포는 0 근처에서 뾰족하여 작은 계수를 강력하게 0으로 수축시키는 반면, 정규 분포는 상대적으로 완만한 수축

을 유도한다. 이러한 관점은 SOP가 확률 기반 모델과 임베디드 기법 간의 방법론적 연관성을 이해하고 일관된 변수 선택 전략을 수립하는 데 필수적인 근거를 제공한다.

4.1.4 차원 축소 (Dimensionality Reduction)

차원 축소는 기존 변수들의 부분 집합을 선택하는 것과 달리, 원본 변수들의 정보를 보존하면서 더 낮은 차원의 새로운 잠재 공간(Latent Space)으로 데이터를 투영하는 기법이다. 이는 특징 추출(Feature Extraction)의 한 형태로, 과적합 방지, 계산 효율 증대, 그리고 잠재 변수(Latent Variable) 발견이라는 목표를 달성하는 데 기여한다. 또한, 모델의 계산 효율을 높이고 데이터의 시각화를 용이하게 한다.

1) 선형 차원 축소 기법 (Linear Method)

선형 차원 축소 기법으로는 주성분 분석(PCA)과 선형 판별분석(LDA)이 대표적이다.

가. 주성분 분석 (PCA, Principal Component Analysis)

PCA는 고차원 데이터의 총 분산을 최대화하는 방향으로 직교 기저(Eigenvector)를 찾아 정보를 손실을 최소화하면서 차원을 축소하는 대표적인 비지도 학습 기법이다. PCA는 데이터의 분산이 가장 큰 방향을 첫 번째 주성분으로 설정하고, 이 축에 직각이 되는(직교하는) 방향 중 잔여 분산이 가장 큰 방향을 두 번째 주성분으로 설정하는 방식으로 축을 생성한다. 분석 과정은 입력 데이터의 공분산 행렬을 고유벡터와 고유값으로 분해하는 과정을 포함하며, 고유값이 클수록 해당 고유벡터가 정의하는 주성분 축이 더 많은 원본 데이터의 정보를 포함한다. 이렇게 추출된 주성분은 원본 변수의 선형 조합으로 표현되며, 새로운 저차원 특징 벡터로 사용된다. 주성분은 서로 직교하기 때문에 다중공선성 문제를 완전히 제거한다는 장점이 있다. <그림 4.1>은 PCA의 기본 원리를 나타내고 있다.

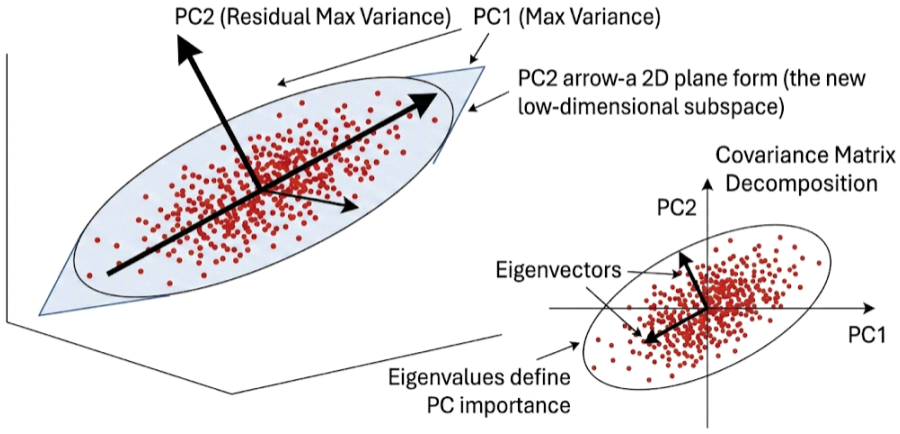

<그림 4.1> 주성분 분석(PCA)의 기본 원리

출처: Gemini 3(나노 바나나 프로)으로 생성한 이미지임

나. 선형 판별분석 (LDA, Linear Discriminant Analysis)

LDA는 분류 문제에 특화된 지도 학습 기반 차원 축소 기법이다. PCA가 데이터의 전체 분산 보존에 초점을 맞춘다면, LDA는 클래스 간 분산을 최대화하고 클래스 내 분산을 최소화하는 사영 축을 찾아 분류 성능을 최적화하는 것을 목표로 한다. LDA의 분석 과정은 클래스 내부 분산 행렬과 클래스 간 분산 행렬을 계산하고, 이 행렬들의 곱을 분해하여 고유벡터와 고유값을 계산하는 방식으로 이루어진다. 고유값이 가장 큰 순서로 K개의 축을 추출하여 입력 데이터를 선형 변환하면, 분류 경계면을 형성하는 데 가장 효과적인 잠재 변수가 생성된다. LDA를 통해 추출할 수 있는 최대 차원 수는 (클래스 개수-1)로 제한된다. <그림 4.2>는 LDA의 기본 원리를 나타내고 있다.

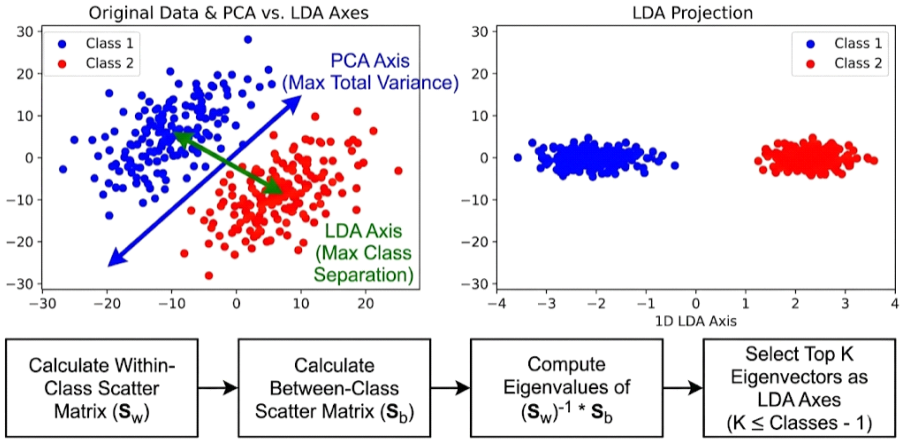

<그림 4.2> 선형 판별분석(LDA)의 기본 원리

출처: Gemini 3(나노 바나나 프로)으로 생성한 이미지임

차원 축소 기법을 통해 새로운 차원의 변수들을 생성하면, 이 변수들은 서로 직교하므로 다중공선성 문제가 원천적으로 제거된다. 이는 선형 모델의 안정성을 극대화하지만, 새로운 특징 벡터(주성분 또는 판별 벡터)가 원본 변수들의 복잡한 선형 조합이라는 점 때문에 최종 모델의 결과를 해석하는 데 어려움이 발생할 수 있음을 SOP에 명시하고, 해석을 위한 추가적인 노력이 필요함을 강조한다. <표 4.1>은 대표적 선형 차원 축소 기법인 PCA와 LDA를 비교해 나타낸 것이다.

<표 4.1> 주성분 분석(PCA)과 선형 판별분석(LDA)의 비교

구분	주성분 분석(PCA)	선형 판별분석(LDA)
학습 유형 (Learning Type)	비지도 학습(Unsupervised)	지도 학습(Supervised)
목적 함수 (Objective Function)	데이터의 총 분산 최대화 (정보 보존)	클래스 간 분산 최대화 및 클래스 내 분산 최소화
적합성	데이터 일반화, 잡음 제거, 다중공선성 해소	분류 성능 최적화를 위한 특징 추출

2) 비선형 차원 축소 기법 (Nonlinear/Manifold Learning)

고차원 데이터가 선형적인 구조가 아닌 복잡한 곡면(Manifold) 상에 내재되어 있을 때, PCA나 LDA와 같은 선형 기법은 정보 손실을 야기할 수 있다. 비선형 차원 축소 기법(Manifold Learning)은 데이터의 국소적 구조(Local Structure)를 보존하는 데 중점을 두며, 고차원 공간에서의 복잡한 근접성 관계를 저차원 잠재 공간에서도 유지하도록 설계된다. 복잡한 데이터 구조 탐색을 위해 Isomap (Isometrically Feature Mapping), LLE (Locally Linear Embedding), UMAP(Uniform Manifold Approximation and Projection), 또는 시각화에 특화된 t-SNE (t-distributed Stochastic Neighbor Embedding) 등의 기법이 대표적이다(McInnes et al., 2018). 이 기법들은 고차원 데이터의 국소적 거리 관계(Local Structure)를 보존하여 저차원 공간에서 데이터의 군집 구조를 효과적으로 시각화하는 데 주로 활용된다.

3) 딥러닝 기반 비선형 차원 축소 기법

딥러닝 기반 차원 축소 기법은 고차원·비정형 데이터에 내재된 비선형 구조(non-linear manifold)를 학습함으로써, 기존의 선형 차원 축소 기법(PCA 등)으로는 포착하기 어려운 복잡한 표현 구조와 잠재 패턴(latent structure)을 효과적으로 추출할 수 있다는 점에서 중요한 의미를 갖는다. 대표적인 기법으로는 오토인코더(Autoencoder)와 트랜스포머 임베딩(Transformer Embedding)이 있으며, 두 기법은 각각 신경망을 활용한 재구성 기반 표현 학습과, Attention 반의 문맥적 의미 표현 학습이라는 상이한 원리를 통해 차원 축소를 달성한다.

이들은 단순히 차원을 줄이는 것이 아니라, 고차원 데이터에서 정보 손실을 최소화한 잠재 표현(latent representation)을 생성하여 후속 분석·예측 모델의 성능과 안정성을 향상시키는 데 활용된다는 점에서 의의가 있다. 아래에서는 두 기법의 구조적 특성, 수식적 의미, 적용 관점에서의 비교 및 활용방안을 더욱 상세하게 기술한다.

가. 오토인코더(Autoencoder)를 활용한 비선형 차원 축소

오토인코더는 입력 데이터를 보다 낮은 차원의 잠재 공간으로 압축한 후, 다시 이를 통해 입력을 복원하도록 학습되는 인공 신경망 구조로, 차원 축소와 표현 학습을 동시에 수행하는 비지도 학습 기반 모델로 이해할 수 있다. 이때 오토인코더의 학습 목적은 단순히 입력 차원을 줄이는 데 있지 않고, 디코더가 원본 데이터를 가능한 한 정확하게 복원할 수 있도록, 입력 데이터가 내포하고 있는 핵심적인 구조적·통계적 특성을 유지한 상태에서 정보를 효율적으로 압축하는 잠재 표현(latent representation)을 도출하는 데 있다.

모형은 보통 인코더와 디코더라는 두 개의 연속적인 함수로 표현되며, 인코더는 입력값 x를 저차원 잠재 벡터 z로 변환하는 함수 $f_\theta(\cdot)$로 정의된다. 반면 디코더는 잠재 벡터로부터 복원된 출력 $\hat{x}$를 생성하는 함수 $g_\phi(\cdot)$로 구성된다. 이를 수식으로 나타내면 식(4.4)와 같이 표현할 수 있으며, 학습 과정은 원본 입력 x와 복원된 출력 $\hat{x}$간의 차이를 최소화하는 방향으로 파라미터 θ, ϕ를 최적화하는 문제로 정식화된다.

$$z = f_\theta(x), \quad \hat{x} = g_\phi(z) \qquad \text{식(4.4)}$$

일반적으로 손실 함수는 평균제곱오차(MSE) 식(4.5)와 같은 형태로 정의되는 목적함수를 통해 최적화가 수행된다.

$$\min_{\theta,\,\phi} E\left[\, L(x,\, \hat{x}) \,\right] \qquad \text{식(4.5)}$$

이 과정에서 <그림 4.3>에 나타낸 것과 같이 오토인코더의 중앙에 위치한 병목층(bottleneck layer)은 입력 차원보다 작도록 설계되며, 이는 네트워크가 불필요한 정보를 제거하고 중요한 구조적 특징만을 보존하도록 하는 압축 장치로 기능한다. 이러한 병목 구조를 통해 모델은 고차원 데이터가 놓여 있는 비선형 매니폴드 구조를 잠재 공간에서 학습하게 되며, 결과적으로 잠재 벡터 z는 단순한 저차원 요약값이 아니라, 원본 데이터의 의미 있는 패턴을 응축하여 표현한 차원 축소 특징으로 해석된다.

개념적으로 보면, 입력 공간에서 고차원 데이터가 분포하는 영역을 인코더가 점차 축소된 표현 공간으로 사상하고, 병목층에서는 가장 압축된 형태의 잠재 벡터가 형성된다. 이후 디코더는 동일 구조를 역방향으로 확장하면서 원본을 복원하려고 시도한다. 이러한 구조는 좌우가 대칭적인 모래시계 형태의 신경망으로 묘사될 수 있다. 즉, 전방 경로는 정보 압축, 후방 경로는 정보 복원이라는 상호보완적 기능을 수행한다.

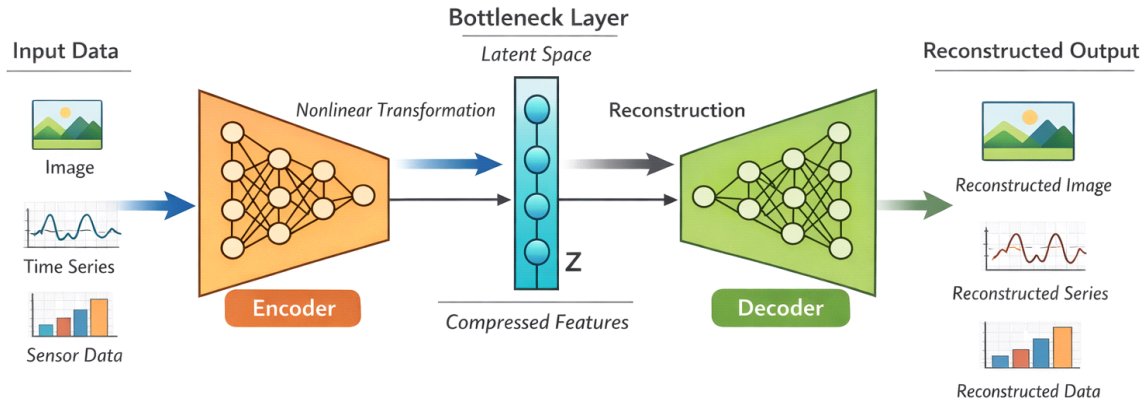

<그림 4.3> 오토인코더에 의한 비선형 차원축소 개념

출처: ChatGPT 5.2(GPT Image 1.5)로 생성한 이미지임

오토인코더 계열 모형은 목적 및 제약 조건에 따라 다양한 변형 모델로 확장될 수 있으며, 각 변형은 차원 축소 성능과 표현의 성질에 서로 다른 영향을 미친다. 예를 들어, Denoising Autoencoder는 학습 과정에서 입력에 인위적인 노이즈를 추가한 뒤 이를 복원하도록 학습함으로써, 노이즈에 강건한(latent) 표현을 학습하도록 유도한다. Sparse Autoencoder는 잠재 표현에 희소성 제약을 부과하여 보다 해석 가능한 특징을 도출하도록 설계되며, Variational Autoencoder는 잠재 공간을 확률분포 형태로 모델링함으로써 데이터

생성과 분포 보존이라는 관점까지 확장된 표현 학습을 수행한다. 이러한 변형들은 고차원 센서 데이터, 환경·수질 시계열, 이미지 및 복잡 신호 데이터 등에서 잡음이 포함된 데이터를 정제하면서 동시에 차원을 축소하는 데 매우 효과적으로 활용될 수 있다.

결과적으로, 오토인코더를 통해 얻어진 잠재 벡터는 이후 예측 모델의 입력 변수, 이상치 탐지, 클러스터링, 시각화 등 다양한 다운스트림 분석 단계에서 차원 축소된 특징 공간으로 활용될 수 있으며, 이는 오토인코더가 단순 압축기(compressor)가 아니라 학습된 비선형 차원 축소기(learned non-linear projector)로 기능한다는 점을 의미한다.

나. 트랜스포머 임베딩을 활용한 비선형 차원 축소

트랜스포머 임베딩은 텍스트·시퀀스·로그 데이터와 같이 순차적 구조를 갖는 데이터에 대해, 해당 시퀀스에 포함된 요소들 간의 맥락적 관계(contextual dependency)를 학습하여 이를 고밀도 의미 벡터(dense semantic vector)로 변환하는 표현 학습 기법으로 이해할 수 있다. 트랜스포머는 Self-Attention 메커니즘을 통해 입력 시퀀스의 각 위치가 다른 모든 위치와 맺는 관계 강도를 동시에 고려하며, 이를 통해 단일 요소가 문맥 내에서 어떤 의미적 역할을 수행하는지를 벡터 공간 상에서 정량적으로 표현한다.

모형 내부에서는 시퀀스의 각 입력 벡터가 Query, Key, Value 행렬로 변환되며, Self-Attention 연산은 식(4.6)과 같이 정의된다.

$$Attention(Q, K, V) = softmax\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V \qquad \text{식(4.6)}$$

이 과정에서 한 토큰이 다른 토큰과 갖는 의존성은 가중합 형태로 반영되며, 그 결과 생성되는 은닉 벡터는 단일 토큰의 고립된 속성뿐 아니라, 문맥 전반에서의 의미적 위치와 역할을 동시에 반영한 표현이 된다. 이러한 임베딩은 전통적인 희소 표현(예: one-hot vector, TF-IDF 표현)과 비교할 때 차원이 상대적으로 낮으면서도, 의미 정보를 훨씬 풍부하게 보존한다는 점에서 차원 축소 기법의 성격을 동시에 내포하고 있다. 즉, 트랜스포머 임베딩은 고차원·희소 표현 → 저차원·밀집 표현(Dense Vector)으로의 변환을 수행하는 과정에서, 단순한 차원 축약이 아니라 의미 구조와 관계성을 유지한 상태에서의 압축 표현을 제공한다.

특히 BERT와 같은 사전학습(Pre-trained) 인코더 기반 모델에서는, 인코더 출력층에서 생성되는 은닉 벡터가 단어, 문장, 또는 문단 수준의 의미를 내포한 임베딩으로 사용되며, 이 임베딩은 후속 분류·회귀·군집 알고리즘의 입력 변수로 직접 활용될 수 있다. 이러한 구조는 자연어 처리 영역뿐 아니라, 시계열 이벤트 데이터, 센서 로그 데이터, 이상동작 탐지 데이터 등에서도 응용이 가능하며, 시계열을 토큰화하여 입력 시퀀스로 변환할 경우, 패턴 간 유사도와 순서 의존 구조를 동시에 반영하는 차원 축소 표현을 얻을 수 있다.

개념적으로, 입력 시퀀스는 임베딩 계층과 위치 인코딩을 거친 후, 여러 개의 트랜스포머

인코더 블록을 통과하면서 단계적으로 문맥 정보가 통합된다. 최종 은닉층에서 산출되는 벡터는 전체 시퀀스가 내포한 의미적 구조가 응축된 표현으로 이해할 수 있으며, 이는 이후 분석 단계에서 고차원 시퀀스 데이터를 대체하는 의미 기반 저차원 표현 공간으로 활용될 수 있다. <그림 4.4>는 트랜스포머 임베딩의 차원 축소 체계 및 과정을 나타낸 것이다.

이와 같은 관점에서 보면, 트랜스포머 임베딩은 오토인코더와 마찬가지로 차원 축소 기능을 수행하지만, 오토인코더가 주로 재구성 가능성을 기준으로 특징을 압축하는 반면, 트랜스포머 임베딩은 맥락적 의미 구조의 보존을 목표로 특징을 압축한다는 점에서 서로 다른 역할과 해석적 가치를 갖는다.

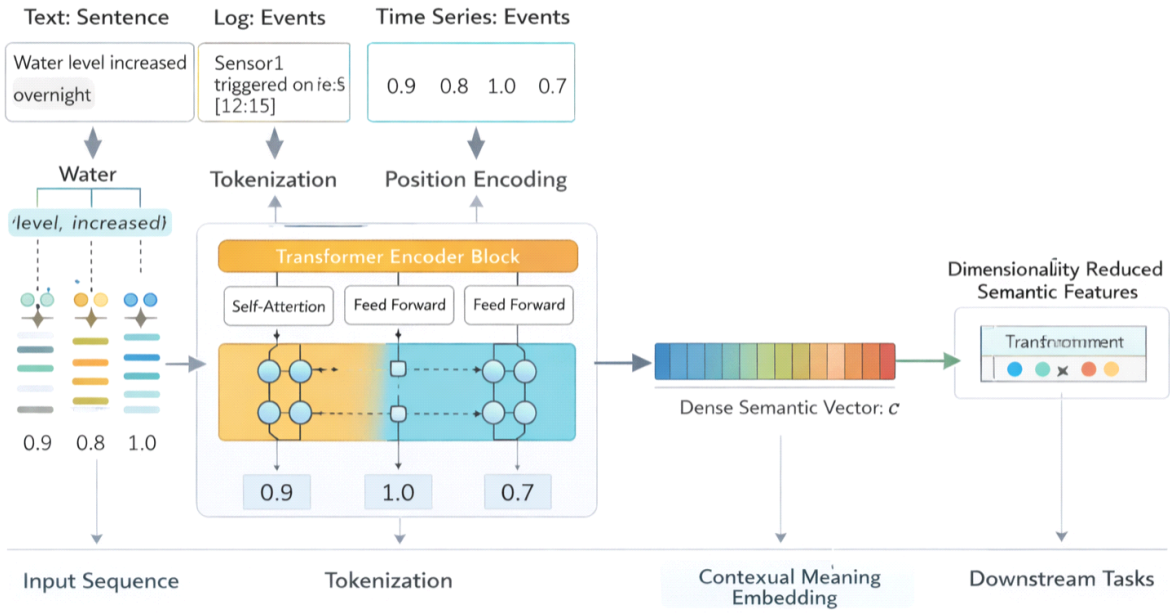

<그림 4.4> 트랜스포머 임베딩 기반 비선형 차원 축소 모델 아키텍쳐

출처: ChatGPT 5.2(GPT Image 1.5)로 생성한 이미지임

다. 오토인코더와 트랜스포머 임베딩 활용 방식의 비교

오토인코더는 입력 데이터를 복원하는 과정을 통해 구조적·형태적 특징을 응축한 비선형 잠재 표현을 학습하는 차원 축소 기법이며, 트랜스포머 임베딩은 Self-Attention 메커니즘을 통해 문맥·관계·의존 구조를 반영한 의미 중심의 압축 표현을 생성한다. <표 4.2>는 두 방식의 차이를 여러 관점에서 비교해 본 것이다.

<표 4.2> 오토인코더와 트랜스포머 인베딩을 활용한 비선형 차원축소 방식의 비교

구 분	오토인코더	트랜스포머 임베딩
핵심 원리	재구성 오차 최소화 기반 표현 학습	문맥 의존성 학습 기반 의미 표현
보존 정보	데이터 구조·패턴·형태	관계성·순서·문맥 의존
차원 축소 특성	비선형 매니폴드 압축	저차원 밀집 의미 표현
적용 데이터	이미지·센서·다변량 시계열	텍스트·로그·토큰화 시계열
강점	노이즈 제거·압축 안정성	의미 정보 보존·해석력
활용 목적	특징 생성·이상값 탐지·전처리	분류·군집·검색·표현학습 입력

두 방법은 서로 대체 관계라기보다는 분석 목적에 따라 상호보완적으로 결합될 수 있는 관계로 이해하는 것이 바람직하다. 예를 들어, 비선형 물리·환경 신호에서 AE 기반 잠재 특징을 도출한 뒤, 시퀀스적 의미 구조를 반영하기 위해 트랜스포머 임베딩을 추가적으로 결합하는 복합형 접근도 가능하다.

4.1.5 모델 기반 (Model based) 선택법

모델 기반 선택법은 학습이 완료된 모델이 제공하는 변수 중요도(Feature Importance)를 활용하여 사후적으로 핵심 변수를 선별하는 방식이며, 모델의 종류와 XAI 기법의 적용 여부에 따라 접근 방식이 달라진다.

1) 트리 기반 모델의 변수 기여도

트리 기반 모델에서는 변수의 기여도를 측정하는 방식으로 Bagging 방식(Random Forest 등)과 Boosting 방식(GBM, XGBoost, Light GBM 등)이 사용되는데, Bagging 방식은 다수의 트리에서 각 변수가 분기(Split)에 사용될 때 불순도(Gini Impurity 등)를 얼마나 감소시켰는지 평균 내어 중요도를 산출하는 반면(Breiman, 2001), Boosting 방식은 순차적으로 학습되는 약한 학습기들에서 변수가 사용된 횟수(Frequency), 분기 시 얻은 정보 이득(Gain) 등을 종합적으로 평가하여 변수의 기여도를 산출한다.

가. Bagging 방식의 변수 기여도 산정

트리 기반 모델의 Bagging 계열(Random Forest 등)은 복원추출(bootstrap sampling)을 통해 생성된 다수의 학습 표본에 대해 개별 결정트리를 독립적으로 학습한 후, 이들 트리를 평균 또는 다수결 방식으로 결합하여 최종 예측값을 도출한다. <그림 4.5>에 나타낸 이러한 구조적 특성 때문에 변수 기여도는 각 트리 내에서 해당 변수가 분기(split) 시 노드 불순도(impurity) 감소에 기여한 정도를 정량화하여 산출된다.

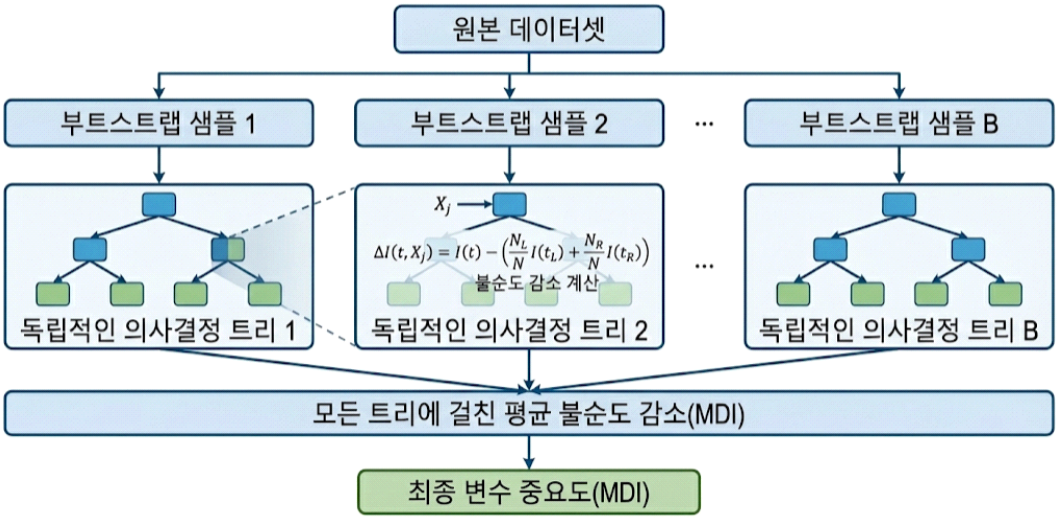

<그림 4.5> Bagging 기반 앙상블 모델에 의한 변수 기여도 산정 구조

출처: Gemini 3(나노 바나나 프로)으로 생성한 이미지임

분류 문제에서 노드 t의 Gini 불순도는 식(4.7)과 같이 정의된다.

$$G(t) = \sum_k p_k(1-p_k) \qquad \text{식(4.7)}$$

여기서 p_k는 노드 t에 속한 표본 중 클래스 k가 차지하는 비율이다. 변수 X_j가 노드 t를 좌·우 자식노드 t_L, t_R로 분할할 때의 불순도 감소량은 다음의 식(4.8)과 같다.

$$\Delta I(t, X_j) = I(t) - \left(\frac{N_L}{N} I(t_L) + \frac{N_R}{N} I(t_R)\right) \qquad \text{식(4.8)}$$

여기서 N은 부모 노드의 표본 수이며, N_L과 N_R은 각각 좌·우 자식노드의 표본 수를 의미한다.

특정 변수 X_j의 중요도는 하나의 트리 b에서 해당 변수가 사용된 모든 분기 노드 집합 $T_b(X_j)$에 대해 불순도 감소량을 합산하고, 이를 전체 트리 집합 B에 대해 평균함으로써 식(4.9)와 같이 산정된다.

$$Imp(X_j) = \frac{1}{B} \sum_{b=1}^{B} \sum_{t \in T_{b(X_j)}} \Delta I(t, X_j) \qquad \text{식(4.9)}$$

최종적으로는 모든 변수의 중요도 합이 1이 되도록 정규화하여 비교·해석에 활용하는 것이 일반적이다.

이와 같은 방식은 Breiman(2001)이 제안한 Mean Decrease Impurity(MDI) 개념에 근거

하며, 하나의 변수에 대해 다수의 독립된 트리 전반에서 반복적으로 관측된 불순도 감소 기여를 집계함으로써 전반적 패턴 형성 능력을 안정적으로 반영한다는 장점이 있다. 특히 Random Forest의 무작위 변수 선택(mtry)과 결합할 경우, 특정 소수 변수에 대한 의존도를 완화하고 변수 기여도의 편차를 완곡하게 만드는 효과를 제공한다.

다만, 이러한 방식은 다중 범주를 가진 변수나 값의 분산이 큰 변수에 대해 분할 가능성이 상대적으로 높아져 중요도가 과대 추정될 수 있으며, 하위 노드에서 발생하는 작은 분기 효과가 누적되면서 실질적 예측 기여도 대비 중요도가 과대 평가되는 통계적 편향이 존재할 수 있다. 이러한 한계로 인해, Bagging 방식의 변수 중요도는 모델 전반의 구조적 분기 기여를 중점적으로 반영하지만, 반드시 최종 예측오차 감소에 대한 직접적 기여와 일대일로 대응된다고 보기는 어렵다.

나. Boosting 방식의 변수 기여도 산정

Boosting 계열 모델(GBM, XGBoost, LightGBM 등)은 <그림 4.6>에 나타난 바와 같이 다수의 약한 학습기(weak learner)를 순차적으로 결합함으로써 점진적으로 예측성능을 개선하는 구조를 가진다. 각 단계의 트리는 이전 단계에서 충분히 설명되지 못한 오차(혹은 손실함수의 기울기)를 보정하는 방향으로 학습되며, 이에 따라 변수 기여도 또한 손실 함수 감소(loss reduction)에 대한 누적 기여량을 중심으로 평가된다. 일례로 XGBoost 모델에서 변수 분기로 발생하는 이득(Gain)은 다음의 식(4.10)과 같이 정의된다.

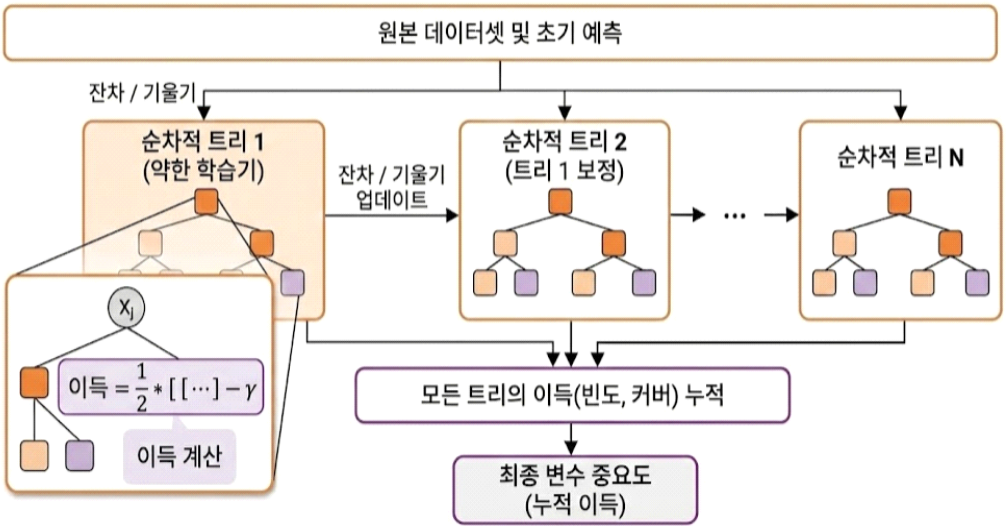

<그림 4.6> Boosting 기반 앙상블 모델에 의한 변수 기여도 산정 구조

출처: Gemini 3(나노 바나나 프로)으로 생성한 이미지임

$$Gain = \frac{1}{2}\left(\frac{G_L^2}{H_L+\lambda}+\frac{G_R^2}{H_R+\lambda}-\frac{(G_L+G_R)^2}{H_L+H_R+\lambda}\right)-\gamma \qquad \text{식(4.10)}$$

여기서, G_L, G_R은 좌·우 자식노드의 gradient 합, H_L, H_R은 Hessian 합이며, λ와 γ는 각각 정규화 항 및 트리 복잡도 패널티에 해당한다.

Boosting 모델에서 변수 중요도는 일반적으로 (1) 해당 변수가 분기에 사용된 횟수(Frequency), (2) 분기에서 처리된 표본 가중치 규모(Cover), (3) 분기별 손실 감소량의 누적합(Gain)을 종합적으로 고려하여 산출되며, 이 중 Gain은 실제 성능 개선과의 인과적 연계성이 가장 명확한 지표로 간주한다. 이 방식은 순차적 학습 과정에서 초기 트리에서 데이터 전반의 큰 패턴을 설명한 기여, 후속 트리에서 잔차를 정밀하게 보정한 기여를 모두 반영함으로써, 변수 기여도를 동태적(dynamic) 관점에서 평가한다는 점에 특징이 있다. 따라서 Boosting 방식의 변수 중요도는 단순 구조적 분기 기여도가 아니라, 모델의 목적 함수 최적화 과정에서 실질적으로 성능 향상에 기여한 정도를 보다 직접적으로 반영한다고 해석할 수 있다.

다. Bagging 방식과 Boosting 방식의 비교

Bagging 방식의 변수 중요도는 다수의 독립된 트리에서 관측된 불순도 감소 효과의 평균적 기여를 반영하는 반면, Boosting 방식의 변수 중요도는 순차적 학습 과정 전반에서 손실 함수 감소에 기여한 누적효과를 중심으로 산정된다는 점에서 본질적 차이가 있다. 따라서, 탐색적 단계에서는 Bagging 방식이 변수 후보 발굴에 유리하며, Boosting 방식의 Gain 기반 중요도는 최종 채택된 Boosting 모델을 해석하는 것에 더 합리적이라 할 수 있다. 결론적으로 두 방식은 상호 대체적 관계가 아니라 보완적 관계로 이해하는 것이 바람직하며, 필요 시 SHAP 등 후처리 설명기법과 함께 활용할 때 변수 기여 해석의 신뢰도를 더욱 높일 수 있다. <표 4.3>은 두 산정 방식의 구조적 차이와 해석적 특징을 대비하여 정리한 것이다.

<표 4.3> Bagging과 Boosting의 변수 중요도 산정 방식 비교

구 분	Bagging 방식	Boosting 방식
학습 방식	독립적·병렬적 트리 학습	순차적·누적적 트리 학습
변수 기여도 기준	노드 불순도 감소량(MDI)	손실 감소량(Gain) 중심
계산 단위	트리별 분기 노드의 지역(local) 기준을 합산	전체 학습 단계의 글로벌 최적화 과정에 대한 누적 기여
주요 보조 지표	없음(불순도 감소 중심)	Frequency, Cover 등 추가 제공
해석 관점	데이터 전반의 분류·분기 구조 형성 기여	예측오차 감소에 대한 직접적 성능 기여
장점	안정적, 직관적, 탐색적 분석에 유용	성능 개선 기여도를 정밀하게 반영
한계	범주 수가 많은 변수에 편향 발생 가능	초기 단계 편향·학습률 설정에 영향 가능
활용 적합성	변수 후보군 스크리닝, 탐색 분석	최종 모델 해석, 성능 기여 분석

2) XAI 기반 모델의 변수 기여도

설명 가능한 인공지능(XAI: Explainable Artificial Intelligence) 접근법은 복잡한 예측 모델의 내부 작동 원리를 해석 가능하게 표현함으로써, 모델의 신뢰성·책임성·투명성을 강화하는 데 중요한 역할을 수행한다. 특히 변수 기여도 산정 관점에서 SHAP(SHapley Additive exPlanations)과 LIME(Local Interpretable Model-agnostic Explanations)은 모델 비의존성(model-agnostic)과 직관적 해석성을 동시에 제공하는 대표적 방법론으로, 고성능 예측 모델이 생성한 결과를 정량적이고 체계적인 방식으로 설명할 수 있게 한다. 이러한 기법들은 단순히 변수의 중요도를 순위화하는 수준을 넘어, 변수가 예측 결과에 미치는 긍·부정 방향의 기여, 상호작용 효과, 국소·전역적 영향 구조까지 함께 파악할 수 있다는 점에서 실무적·정책적 의미가 크다.

가. SHAP을 활용한 변수 기여도 산정

SHAP은 협동 게임 이론의 핵심 개념인 샤플리 값(Shapley Value)을 적용하여, 각 변수가 모델 예측값에 기여한 정도를 공정하고 일관된 규칙에 따라 계산하는 방법이다. 여기서 예측 모델은 하나의 "게임", 변수(feature)는 "참여 플레이어", 예측값의 증가분은 "성과 분배"로 간주하며, 각 변수가 없을 때 와 있을 때의 기여 차이(한계 기여도, marginal contribution)를 모든 가능한 변수 조합(coalition)에 대해 평균함으로써 기여도를 정의한다.

모델 $f(\cdot)$와 변수 집합 N, 특정 변수 i에 대해, 변수 i의 SHAP 값 ϕ_i는 다음과 같은 식으로 표현된다.

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!,\ (|N|-|S|-1)!}{|N|!} \left(f(S \cup \{i\}) - f(S)\right) \qquad \text{식(4.11)}$$

여기에서, S는 변수 i를 제외한 임의의 부분집합(coalition), $f(S)$는 변수 S만을 사용하여 계산된 예측값, $f(S \cup \{i\}) - f(S)$는 변수 i의 한계 기여도(marginal contribution)를 의미한다.

이 식은 모든 가능한 변수 조합에서 변수 i가 추가됨으로써 발생하는 성과 변화량을 평균한 값이며, 이를 통해 SHAP은 다음과 같은 수학적 성질을 동시에 만족한다.

- ○ 효율성(Efficiency): 모든 변수 기여도의 합은 전체 예측값 변화와 정확히 일치
- ○ 대칭성(Symmetry): 동일 기여 변수를 동일하게 평가
- ○ 가산성(Additivity): 모델이 합성될 경우 기여도 역시 선형 결합 가능
- ○ 공정성(Fairness): 임의적인 가중 또는 순서 기반 편향 배제

이러한 성질은 기존 변수 중요도 방법과 달리, SHAP이 변수 간 상호작용을 체계적으로 반영하면서도 해석적 일관성을 유지할 수 있게 하는 이론적 근거가 된다. SHAP 기반 분석은 전역 수준에서는 변수 전체의 상대적 중요도 구조 및 영향 방향을 파악할 수 있으며, 국

소 수준에서는 특정 관측값의 예측 결과가 형성된 세부 원인을 정량적으로 설명할 수 있다. 따라서 금융, 의료, 보험, 공공 의사결정과 같이 설명 가능성과 규제 정당성이 요구되는 영역에서는, SHAP 기반 변수 설명이 의사결정 책임성 확보 및 변수 선택의 윤리·법적 합리성 제시에 중요한 근거로 활용될 수 있다.

나. LIME을 활용한 변수 기여도 산정

LIME은 복잡한 비선형 예측 모델을 직접 해석하기 어려운 상황에서, 특정 관측값 주변 국소 영역(Local Neighborhood)을 대상으로 단순하고 해석 가능한 대체 모델(surrogate model)을 학습시켜 변수 기여도를 도출하는 방법이다. 이는 전체 모델을 설명하기보다는, 특정 예측이 왜 그러한 결과를 생성했는지를 이해한다는 실용적 철학에 기반하고 있으며, 모델 디버깅·사례 해석·국소적 의사결정 검증에 특히 적합하다. LIME의 기본 절차는 다음의 식(4.12)와 같이 정식화된다.

① 관심 대상 관측치 (x_0) 주변에서 유사한 샘플을 다수 생성
② 원래 모델 $f(\cdot)$로부터 각 샘플의 예측값을 계산
③ 거리 기반 가중치 $\pi(x_{0,}\, x)$를 적용하여 국소 영역 중요도를 반영
④ 해석 가능한 단순 모델 $g(\cdot)$을 학습
⑤ 가중 최소제곱 형태의 목적함수를 최소화

$$\min_{g \in G} \sum_{x} \pi(x_0,\, x)(f(x) - g(x))^2 \qquad \text{식(4.12)}$$

여기서 G는 선형 회귀, 의사결정 규칙 등 단순 모델의 집합을 의미하며, $g(x)$의 회귀 계수는 국소 영역에서의 변수 기여도(local importance)로 해석된다. 즉, LIME은 국소적 선형 근사 모델을 통해 어떤 변수들이, 어떤 방향으로, 어느 정도 크기로 해당 예측 결과에 기여했는지를 직관적으로 설명하게 한다. 이 방법은 전역적 변수 중요도보다는, 특정 사례의 해석 가능성·투명성 확보에 초점을 두기 때문에, 모델 이상 탐지, 예측 오류 원인 분석, 정책적 민감 사례 검증 등에서 중요한 분석 도구로 활용될 수 있다.

정리하면, SHAP은 수학적 공정성과 설명 일관성을 기반으로 변수 기여도를 정량 산출하는 방법이며, LIME은 국소적 근사 모델을 통해 개별 사례 수준에서 직관적인 설명을 제공하는 방법으로 이해할 수 있다. 두 기법은 상호 대체적인 것이 아니라, 전역 구조 파악과 국소 사례 해석을 결합하는 보완적 도구로 활용될 때 모델 신뢰성과 해석력은 한층 강화될 수 있다. 또한, 이러한 XAI 기반 변수 기여도 분석은 단순히 해석 보조 수단을 넘어, 변수 선택 정책 수립, 위험 요인 점검, 데이터 거버넌스 및 알고리즘 책임성 체계 구축 등 기술 보고서 수준의 의사결정 지원 체계와 직접적으로 연계될 수 있다는 점에서 중요한 의미를 가진다. <표 4.4>는 SHAP과 LIME의 특징을 비교하여 정리한 것이다.

<표 4.4> SHAP과 LIME의 특징 비교

구분	SHAP	LIME
이론 기반	협동 게임 이론	국소적 선형 근사
분석 범위	전역 + 국소	주로 국소
상호작용 반영	체계적으로 반영	제한적
기여도 정의	한계 기여 평균	국소 회귀 계수
해석 초점	공정·일관·정량 설명	사례 중심 설명
적용 적합성	규제·감사·책임 분야	디버깅·사례 검증

3) 확률 기반 모델

확률 기반 모델은 파라미터에 대한 사전 분포(Prior)를 가정하고 베이즈 정리를 통해 사후 분포(Posterior)를 추론하며, 이 범주에는 Bayesian LASSO와 Bayesian Ridge가 포함되어 라플라스 사전 분포 등을 사용하여 변수 선택 효과를 얻거나, 가우시안 프로세스(Gaussian Process)의 커널 자동 관련성 결정(ARD)을 활용하여 변수의 관련성을 파악함으로써 불확실성을 고려한 변수 선택을 수행한다.

가. Bayesian LASSO, Bayesian Ridge

베이지안 관점에서 변수 선택은 계수(β)에 대한 사전 분포(Prior Distribution)를 설정함으로써 이루어진다. Bayesian LASSO는 계수 벡터에 이중 지수(Laplace) 분포를 사전 분포로 적용하여 L1 규제와 동일한 희소성 효과를 유발함으로써 변수 선택을 수행한다. 이중 지수 분포는 0 주변에서 첨예한 형태를 가지므로 작은 계수를 강력하게 0으로 수축시킨다. 반면, Bayesian Ridge는 정규 분포(Normal Distribution)를 사전 분포로 사용하여 L2 규제와 유사한 계수 안정화 효과를 유도한다. 이 베이지안 접근법은 계수 값이 0일 확률 분포를 명확하게 제공함으로써, 빈도론적 접근법보다 변수 선택의 통계적 확실성을 더 높게 평가할 수 있도록 한다.

나. Gaussian Process Regression (GPR)

가우시안 프로세스 회귀(GPR)는 비모수적(Non-parametric) 회귀 방법으로, 명시적인 회귀 계수를 추정하지 않고 함수에 대한 분포를 모델링한다. GPR에서 변수 선택은 주로 ARD (Automatic Relevance Determination) 커널을 통해 간접적으로 수행된다. ARD 커널은 각 입력 변수 X_j에 연결된 길이 척도(Length scale, l_j)를 학습하며, l_j 값이 클수록 해당 변수의 관련성이 낮다고 해석하여 변수 중요도를 측정할 수 있다. 이는 복잡한 비선형 관계에서 변수 중요도를 정량화하는 유연한 방법을 제공한다.

4.2 시계열 전처리 (Time Series Preprocessing)

4.2.1 정상성 진단 (Stationarity test)

시계열 데이터 분석의 성공은 정상성(Stationarity) 확보에 달려있다. 정상성이란 시계열 데이터의 평균과 분산이 시간에 따라 일정하며, 같은 시차(time lag)의 자기공분산이 변하지 않는 특별한 성질을 의미한다. 이러한 정상성을 확보하기 위한 진단 및 변환 과정은 시계열 분석의 핵심 단계가 된다. 정상성을 진단하는 방법은 시각적 분석, 통계적 가설검정, 그리고 자기상관성 패턴 확인으로 나눌 수 있다.

1) 시각적 검사 (Visual Inspection)

시계열 데이터 플롯을 통해 데이터의 시각적 특징을 직관적으로 확인하는 단계이다. 데이터의 평균이 특정 값을 중심으로 일정하게 유지되는지(평균 불변성), 변동 폭이 시간에 따라 폭발적으로 증가하거나 감소하지 않고 일정한지(분산 불변성), 그리고 뚜렷한 추세(Trend)나 계절성(Seasonality)이 존재하는지를 확인한다. 평균이 변하지 않는다면 평균 회귀(Mean Reversion) 경향을 보이며, 분산이 일정하지 않고 시간에 따라 변하면 이분산성(Hetero-scedasticity)이 있다고 판단한다.

2) 통계적 가설검정

객관적인 통계적 판단을 위해 ADF, PP, KPSS 등 단위근(Unit Root) 검정을 수행한다. 단위근은 시계열 모델의 특성 방정식 해가 1인 경우를 말하며, 단위근이 존재하면 시계열은 시간에 따라 평균과 분산이 변하는 비정상적 특성을 보이게 된다.

가. ADF (Augmented Dickey-Fuller) 검정

ADF 검정은 Dickey와 Fuller(1979)이 제안한 단위근 검정에 lagged difference를 추가하여 자기상관을 보정한 확장형이다 (Dickey & Fuller, 1979; Said & Dickey, 1984). 귀무가설은 “단위근이 존재한다(비정상적)”이고, 대립가설은 “단위근이 존재하지 않는다(정상적)”이다. 검정통계량이 임계치보다 작고 p값이 0.05보다 작으면 귀무가설을 기각하여 단위근이 없다(정상 시계열이다)고 판단한다. ADF 검정은 작은 표본에서도 검정력이 우수하지만, 계절성이 강하거나 구조가 복잡한 경우에는 한계가 있을 수 있다. ADF의 검정식은 식(4.13)과 같으며,

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^{p} \delta_i \Delta y_{t-i} + \varepsilon_t \qquad \text{식(4.13)}$$

여기에서, $\Delta y_t = y_t - y_{t-1}$는 데이터의 차분(1차 차분), α는 상수항(intercept, 필요시 포

함), β는 시간 추세(Term, 필요시 포함), γ는 단위근의 존재 여부를 검정하는 계수, δ_i는 추가적인 지연 차분(lagged differences)을 고려하여 자기상관을 보정하는 계수, p는 최적 레그 수, ε_i는 백색잡음(white noise)을 의미한다. ADF 검정의 해석기준은 <표 4.5>와 같다.

<표 4.5> Augmented Dickey-Fuller test 해석 기준

지표값	해석	정상성 여부
p-value < 0.05	귀무가설 기각 → 단위근 없음	정 상
p-value ≥ 0.05	귀무가설 채택 → 단위근 있ㅇ,ㅁ	비정상

나. PP (Phillips-Perron) 검정

Phillips와 Perron(1988)이 제안한 PP 검정은 ADF 검정과 유사하게 단위근 여부를 검정하지만, 잔차의 이분산성과 자기상관을 비모수 방식으로 수정하여 보다 강건하게 단위근 존재 여부를 평가한다. PP 검정식은 ADF 검정식과 동일하지만, 오차항의 특성을 고려하여 검정 통계를 수정한 것으로 식(4.14)와 같이 나타낼 수 있다.

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \varepsilon_t \qquad \hat{\gamma} = \frac{\sum_{t=1}^{T} y_{t-1}\,\Delta y_t}{\sum_{t=1}^{T} y_{t-1}^2} \qquad \text{식(4.14)}$$

여기에서, $\Delta y_t = y_t - y_{t-1}$는 데이터의 차분(1차 차분), α는 상수항(intercept, 필요시 포함), β는 시간 추세(Term, 필요시 포함), γ는 단위근의 존재 여부를 검정하는 계수, ε_i는 백색잡음(white noise)을 의미한다.

ADF가 lag 항을 추가해 자기상관을 제거하는 데 반해, PP는 잔차의 장기분산(long run variance)을 추정하여 검정통계량을 보정한다. 이러한 비모수적 보정 덕분에 잔차가 이분산성을 보이거나 오차 구조가 복잡한 경우 PP 검정이 유리하지만, 작은 표본에서는 검정력이 약할 수 있다. <표 4.6>은 PP 검정의 해석 기준을 나타낸 것이다.

<표 4.6> Phillips-Perron test 해석 기준

지표값	해석	정상성 여부
p-value < 0.05	귀무가설 기각 → 단위근 없음	정 상
p-value ≥ 0.05	귀무가설 채택 → 단위근 있음	비정상

다. KPSS (Kwiatkowski-Phillips-Schmidt-Shin) 검정

KPSS 검정(Kwiatkowski et al., 1992)은 데이터가 추세-정상성(Trend-Stationary)인지 여부를 검사한다. ADF 등 다른 단위근 검정과 반대로 정상성을 귀무가설로 설정하여 대립가설은 단위근이 존재하여 비정상적인 것으로 설정된다. p값이 0.05보다 작고 검정통계량이 임계치보다 크면 귀무가설을 기각하여 비정상성을 의미한다. KPSS 검정은 ADF와 PP 검정의 결과를 보완하는 데 사용되며, 두 검정이 상충할 때에는 추세 제거나 차분을 통해 정상성을 확보해야 한다. KPSS의 검정식은 식(4.15)와 같이 나타낼 수 있으며, 검정 결과의 해석 기준은 <표 4.7>과 같다.

$$y_t = \tau_t + \gamma_t + \varepsilon_t \qquad \text{식(4.15)}$$

여기서, τ_t는 결정적 추세(deterministic trend) γ_t는 단위근이 존재할 가능성이 있는 랜덤 워크(random walk) 항, ϵ_t는 백색잡음(white noise)를 의미한다.

<표 4.7> Kwiatkowski-Phillips-Schmidt-Shin test 해석 기준

지표값	해석	정상성 여부
p-value < 0.05	귀무가설 기각 → 단위근 포함	비정상
p-value ≥ 0.05	귀무가설 채택 → 정상성 있음	정 상

3) 자기상관성 확인

자기상관성 확인은 ACF(Auto-Correlation Function)와 PACF(Partial Auto-Correlation Function) 패턴을 분석하여 비정상성의 원인과 ARIMA 모델 식별에 필요한 정보를 파악하는 과정이다. ACF(자기상관 함수)는 특정 시차 k에서 관측값과 이전 관측값 간의 모든 시차를 포함한 총체적인 상관관계를 측정한다. 비정상적 시계열(단위근 존재)은 과거 값이 현재 값에 지속적으로 영향을 주어 ACF 값이 시간 지연(lag)에 따라 천천히 감소(decaying)하거나 높은 값을 유지하며 서서히 감소하는 패턴을 보이는 반면, 정상 시계열은 ACF 값이 몇 개의 lag 이후 급격히 0으로 수렴한다. 이에 반해 PACF(편자기상관 함수)는 특정 시차에서 다른 중간 시차의 영향을 제거한 후의 순수한 상관관계를 측정한다. 비정상 시계열은 일반적으로 1차 래그에서만 유의미하고, 이후 빠르게 감소하는 패턴을 보인다. 이러한 ACF와 PACF 패턴은 데이터가 1차 차분(Differencing)이 필요한 비정상적 상태에 있음을 판단하고, 시계열 모델의 차수(p, q)를 결정하는 중요한 근거가 된다.

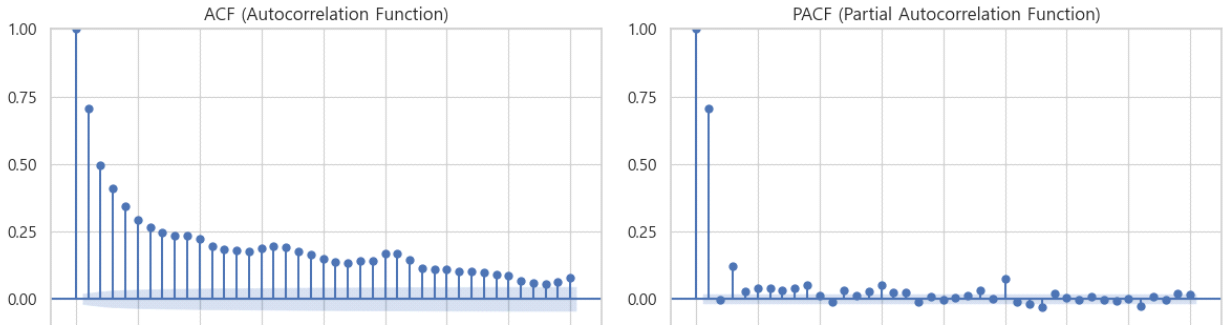

<그림 4.7> 대청댐 유입량 대상 자기 상관함수 분석 결과 (2000~2023)

4.2.2 정상성 변환 (Stationarity Transformation)

데이터가 진단 결과 비정상성 시계열(Non-stationary time series)로 확인되면, 통계적 모델 적용을 위해 데이터를 정상 시계열(Stationary time series)로 변환해야 하며, 이 과정을 정성성 변환이라고 한다.

1) 분산 안정화 변환(VST: Variance Stabilizing Transformation)

시계열의 진폭(변동 폭)이 시간에 따라 커지거나 작아지는 등 분산에 추세(증가 또는 감소)가 있는 경우, 추세(trend) 제거를 위해 차분 시행 시 음수(-) 발생 위험이 있는 등으로 추세 제거에 앞서 분산 안정화가 필요하다.

가. 로그 변환

분산이 시간에 따라 증가하는 경우 데이터의 변동 폭을 줄여 분산을 안정화한다. 로그함수의 특성상 0 또는 음수 데이터에는 적용할 수 없으므로, 이러한 값이 포함된 경우, 모든 값이 0 이상이 되도록 상수 추가(Shift Transformation) 후 변환해야 한다. 상수 추가는 일반적으로 1에 x를 더한 값의 자연로그인 log(1+x)를 계산한다.

나. Box-Cox 변환

Box-Cox 변환은 데이터의 분포를 정규 분포에 가깝게 만드는 정규화 기법으로 시작하였으나, 분산이 큰 값과 작은 값의 차이를 줄이므로 정상화에도 활용될 수 있는 유연한 변환 기법이다. 데이터가 양수(positive)일 때만 적용 가능하며, 최우추정법(MLE)을 통해 최적의 λ 값을 찾아 적용하는 멱 변환(power transformation)의 한 형태이다. 일반적으로 Box-Cox 변환은 식(4.16)와 같이 나타낼 수 있다.

$$y(\lambda) = \begin{cases} \dfrac{x^{\lambda}-1}{\lambda}, & \lambda \neq 0 \\ \log(x), & \lambda = 0 \end{cases} \qquad \text{식(4.16)}$$

여기에서, λ=1.0→x(변환 없음), λ=0.5→$\sqrt{x}$(제곱근 변환), λ=0.0→log$x$(로그 변환), λ=-0.5 →$\frac{1}{\sqrt{x}}$(역제곱근 변환), λ=-1.0→$\frac{1}{x}$(역수 변환)이 된다.

다. Yeo-Johnson 변환

Yeo-Johnson 변환은 Box-Cox 변환과 달리 0과 음수 값도 변환할 수 있도록 조정된 형태의 확장된 멱 변환이다. 변환식은 다음의 식(4.17)과 같다.

$$y(\lambda) = \begin{cases} \frac{(x+1)^{\lambda}-1}{\lambda}, & x \geqq 0,\ \lambda \neq 0 \\ \log(x+1), & x \geqq 0,\ \lambda = 0 \\ -\frac{(-x+1)^{2-\lambda}-1}{2-\lambda}, & x < 0,\ \lambda \neq 2 \\ -\log(-x+1), & x < 0,\ \lambda = 2 \end{cases} \quad \text{식(4.17)}$$

2) 차분 (Differencing)

데이터의 평균이 시간에 따라 변하는 비정상적인 평균을 가진 경우, 즉 추세(Trend) 성분을 제거하기 위해 사용되는 가장 기본적인 정상화 기법이다.

가. 일반 차분(Ordinary differencing)

현재 시점의 값(y_t)에서 바로 이전 시점의 값(y_{t-1})을 빼는 것으로, 추세 제거(De-trend)에 효과적이다. 1차 차분을 수행한 결과가 여전히 비정상적일 경우 2차 차분 등을 수행할 수 있지만, 차분 차수가 너무 높을 경우 데이터의 정보 손실 및 인위적인 자기상관(과적합)이 발생할 수 있으므로 주의해야 한다. 1차 차분은 식(4.18)과 같이 표현된다.

$$\nabla T_t = T_t - T_{t-1} \quad \text{식(4.18)}$$

나. 계절 차분(Seasonal differencing)

현재 시점의 값(y_t)에서 이전 계절주기(s)의 값(y_{t-s})을 뺀 결과로, 데이터에 내재된 계절성(De-seasonality)을 제거하는 데 사용된다. 식(4.19)와 같이 계절주기 m을 기준으로 한 계절 차분(seasonal differencing)을 적용한다.

$$\nabla_m Y_t = Y_t - Y_{t-m} \quad \text{식(4.19)}$$

3) 시계열 분해 (Time Series Decomposition)

시계열 자료는 시간 경과에 따라 관측값이 순차적으로 누적되는 데이터로서, 추세 변화, 계

절적 주기, 불규칙 변동 등 다양한 패턴이 동시에 존재하는 경우가 많다. 이러한 복합적 구조를 갖는 시계열은 비정상성을 내포하는 경우가 많으며, 이는 통계적 예측모형이나 ARIMA 계열 모형과 같이 정상성을 전제로 하는 방법론의 적용을 어렵게 만든다. 이에 따라 시계열을 구성 요소별로 분리한 후, 비정상적 요소를 개별적으로 변환·정상화하는 시계열 분해(Decomposition) 기반 정상성 변환 기법이 활용된다. 이 방법은 시계열 구조를 해석적으로 이해하고, 각 구성 요소의 통계적 성질을 구분하여 적절히 처리할 수 있다는 점에서 실무적 유용성이 크다.

가. 시계열의 구성요소 분해 (Trend - Seasonality - Residual)

시계열 분해(Decomposition)는 시계열 자료가 가지고 있는 장기적 추세, 주기적 변동, 불규칙 변동을 상호 분리하여 각각의 통계적 특성을 개별적으로 분석하기 위한 절차로 이해된다. 하나의 시계열 Y_t는 일반적으로 추세(Trend) 성분 T_t, 계절성(Seasonality) 성분 S_t, 잔차(Residual) 성분 R_t로 구성된다고 가정할 수 있으며, 데이터의 변동 특성에 따라서 가산적 분해(Additive Decomposition) 또는 승법적 분해(Multiplicative Decomposition)로 표현된다.

가산적 분해 모형에서는 시계열이 다음의 식(4.20)과 같이 같이 나타나며, 이는 시계열의 변동폭이 시간에 따라 크게 변하지 않고 일정하게 유지되는 경우에 적합하다.

$$Y_t = T_t + S_t + R_t \qquad \text{식(4.20)}$$

반면, 시계열 수준이 커질수록 변동폭 역시 함께 증가하는 특성을 보이는 경우에는 승법적 구조가 더 적합하며, 식(4.21)과 같이 표현된다. 승법 모형은 로그 변환을 통해 식(4.22)와 같은 형태의 가산 모델로 변환될 수 있으므로, 급격한 수준 변화나 이분산적 성격을 갖는 시계열에서도 안정적인 분석을 가능하게 한다. 이러한 분해 과정은 시계열의 구조적 성질을 직관적으로 이해할 수 있게 해 줄 뿐 아니라, 이후 단계에서 정상성 변환을 보다 체계적으로 수행할 수 있는 기반을 제공한다.

$$Y_t = T_t \times S_t \times R_t \qquad \text{식(4.21)}$$

$$\log(Y_t) = \log(T_t) + \log(S_t) + \log(R_t) \qquad \text{식(4.22)}$$

나. 분해 성분의 정상성 진단 및 변환

시계열이 구성요소별로 분해된 이후에는 각 성분의 정상성 여부를 개별적으로 평가하고, 필요할 경우 적절한 변환을 적용하여 정상성을 확보한다. 추세 성분 T_t는 장기간에 걸친 증가·감소 경향을 포함하는 경우가 많으므로, 이러한 비정상성을 제거하기 위해 일반적으로 차분 변환이 적용된다. 계절성 성분 S_t의 경우, 일정 주기를 갖는 반복 구조가 존재하면, 식(4.19)와 같이 계절 차분을 적용한다.

잔차 성분 R_t는 이상적으로는 정상성을 만족하는 것이 바람직하지만, 일부 시계열에서는 분산 불안정성 또는 비정상적 변동이 잔존 할 수 있다. 이때 로그 변환, Box - Cox 변환 등 분산 안정화 변환을 함께 적용함으로써, 모형 적합성을 높일 수 있다. 이와 같은 성분별 접근은 전체 시계열에 일괄적인 차분을 적용하는 방식보다, 비정상성의 원인을 구조적으로 구분하여 처리할 수 있다는 점에서 분석적 유리함을 제공한다.

다. 정상화된 성분의 재조합

성분별 정상성 확보가 완료되면, 변환된 추세·계절·잔차 성분을 다시 결합하는 과정을 통해 정상화된 시계열을 재구성한다. 이 과정은 단순한 수학적 재결합을 넘어, 구성요소 단위에서 수행된 통계적 변환이 전체 시계열 수준에서 어떻게 반영되는지를 정합적으로 복원하는 단계로 이해될 수 있다. 이와 같은 시계열 분해 기반 정상성 변환 절차는 단순한 전처리 과정을 넘어, 시계열의 구조적 특성을 체계적으로 해석하고 구성 요소별 변동 요인을 구분하여 분석할 수 있게 한다는 점에서 의미가 크다. 특히 예측모형 구축 단계에서 이러한 접근을 적용하면, 모형의 적합성·안정성·설명력이 개선되며, 장기적 추세와 주기적 변동의 구분을 통해 운영·정책적 의사결정에서도 해석 가능성이 강화된다는 점에서 실무적 활용 가치가 높다.

4.3 녹조 예측을 위한 변수 선택 알고리즘 개발

녹조 발생 예측을 위한 시계열 분석 기반 변수 선택 알고리즘은 1) 시계열 전처리를 통해 정상성을 확보하고, 2) 독립변수들 간 중복성과 다중공선성을 제거해 변수간 최소 중복성(Minimum Redundancy)을 확보한 뒤, 3) 종속변수와의 상관성이 높은 변수를 선정해 최대 관련성(Maximum Relevance)을 확보해 최종 변수를 선정하는 3단계로 구성된다. 구체적으로 시계열 전처리 단계에서는 예측 변수들의 정상성(stationarity)을 진단하고 필요시 분산 안정화 변환을 적용하며, 독립변수 간 중복성 제거 단계에서는 상관관계 필터링과 다중공선성 진단을 통해 불필요한 변수를 제거한다. 마지막으로 종속변수와의 상관성 및 편상관성 분석을 통해 남은 변수들의 예측 기여도를 평가함으로써 직접효과, 간접효과(매개효과), 억제효과 등을 해석하고 최종 모델에 사용할 변수를 확정한다.

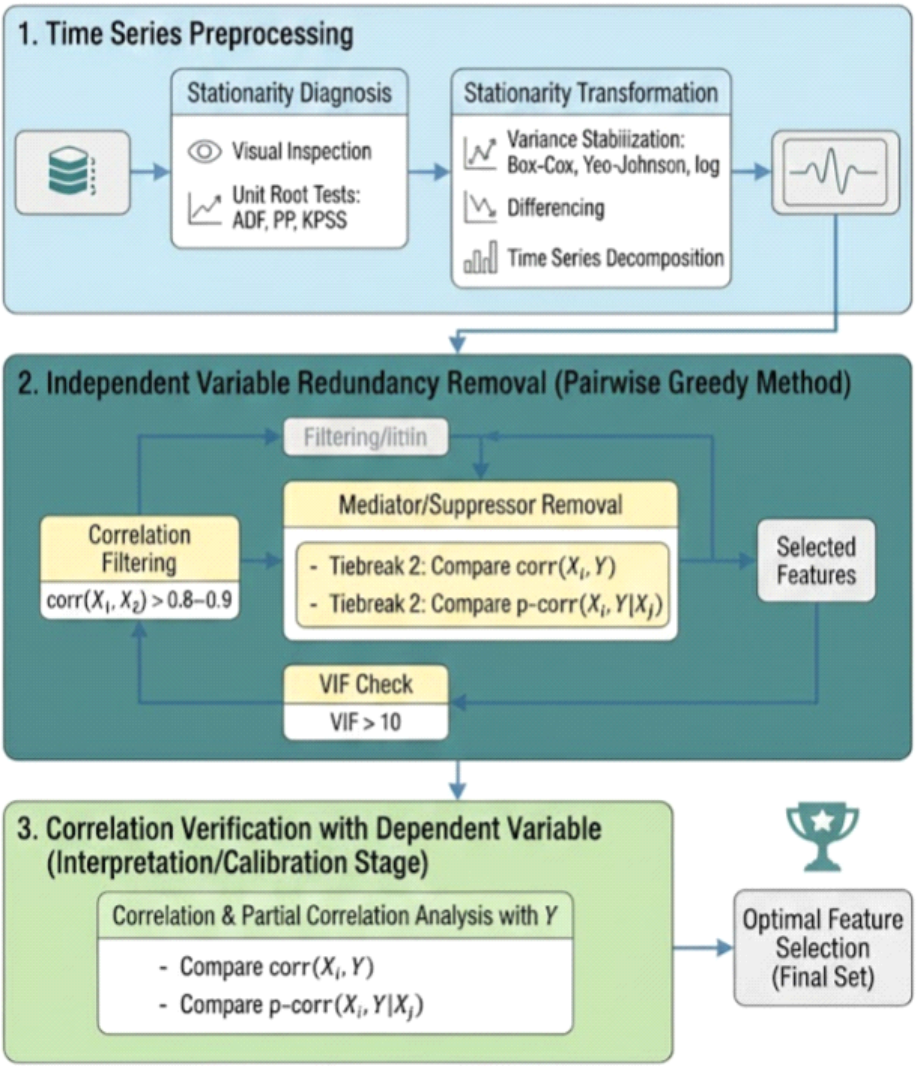

<그림 4.8> 녹조 예측 모델의 변수 선택 알고리즘

출처: ChatGPT 5.2(GPT Image 1.5)로 생성한 이미지임

4.3.1 시계열 전처리

1) 시계열 정상성 진단

시계열 데이터를 올바르게 분석하려면 우선 정상성(stationarity)을 확보해야 한다. 정상성이란 시간에 따라 평균과 분산이 일정하고, 동일한 시차의 자기공분산이 변하지 않는 성질을 말한다. 일반적으로 시계열이 정상성을 만족하는지 확인하기 위해 단위근(Unit Root) 검정을 수행하는데, 본 연구에서는 ADF (Augmented Dickey-Fuller), PP (Phillips-Perron), KPSS (Kwiatkowski-Phillips-Schmidt-Shin) 세 가지 검정을 활용하였다. ADF와 PP 검정은 귀무가설을 "단위근이 존재한다(비정상 시계열)"로 설정하여 검정 통계량의 유의확률을 평가하며, p값이 0.05 미만일 때 귀무가설을 기각함으로써 시계열에 단위근이 없다고 판단한다.

ADF 검정은 작은 표본에서도 검정력이 뛰어나 널리 사용되는 방법으로, 시계열에 단위근이 존재하는지를 회귀분석 모형을 통해 검정한다. 한편 PP 검정은 ADF와 동일한 귀무가설 하에 잔차의 자기상관과 이분산성을 비모수적으로 보정한 방법으로, 충분한 표본에서는 ADF보다 더 강건한 단위근 검정 결과를 제공한다. 마지막으로 KPSS 검정은 앞의 두 검정과는 반대로 귀무가설을 "시계열이 정상적(추세-정상성 보유)"으로 설정하며, p값이 0.05 이상이면 정상성을 만족하는 것으로 본다.

세 가지 검정을 상호 보완적으로 활용하여 시계열의 정상성을 진단하는데, 예를 들어 ADF/PP 검정 결과 귀무가설을 기각해 정상성이 있는 것으로 나오더라도 KPSS 검정이 귀무가설을 기각(비정상)하는 경우 추세 요인이 존재할 수 있으므로 추가적인 변환이 필요하다. 일반적으로 ADF와 PP, KPSS 모두 정상성을 판정하면 해당 시계열은 정상 시계열로 판단되어 변환이 불필요하다. 반면 ADF와 PP가 비정상을 판정하거나 세 검정 방법의 결과가 서로 모순될 경우, 비정상 시계열로 간주하여 추세 제거나 차분(differencing) 등의 변환을 통해 정상성을 확보해야 한다.

2) 분산 안정화 및 변환 기법

단위근 검정 결과, 비정상으로 판정된 시계열에 대해서는 정상성을 달성하기 위한 정상성 변환을 실시한다. 정상성 변환에는 크게 분산 안정화와 추세 제거의 두 가지 접근이 있으며, 이는 시계열 분포의 특성과 비정상성의 원인에 따라 적용된다. 분산 안정화 변환(Variance Stabilizing Transformation)은 시간에 따라 분산이 변화하거나 데이터 분포가 비대칭적인 경우 분포를 정규분포에 가깝게 변환하여 분산의 시간 의존성을 줄이는 방법이다. 대표적으로 로그 변환과 박스콕스(Box-Cox) 변환이 사용된다. 로그 변환은 양수 데이터에 적용되어 데이터 분포의 왜도를 감소시킴으로써 정규성 및 분산 안정성을 향상시키는 효과가 있다. 박스콕스 변환은 데이터 분포를 정규화하면서 큰 값과 작은 값의 분산 차이를 축소하여 시계열을 정상화(Stationarization)하는 데 활용될 수 있는 유연한 멱변환(power transformation) 기법이다.

박스콕스 변환은 0 또는 음수 값에 적용할 수 없다는 한계가 있으나, 이를 보완한 Yeo-Johnson 변환을 이용하면 데이터에 0이나 음수가 포함된 경우에도 유사한 효과로 분산을

안정화할 수 있다. 한편 시계열의 평균이 시간에 따라 변화하는 추세 비정상성에 대해서는 1차 차분 등의 차분 기법을 적용하여 평균 수준의 변동을 제거한다. 예를 들어 시계열에 단위근이 존재하여 비정상적이라면 한 번의 차분을 통해 추세 또는 누적 효과를 제거하면 대체로 정상성이 확보된다. 이상과 같이 분산 안정화 변환(로그, 박스콕스 등)과 차분을 적절히 조합하여 시계열 데이터를 정상성 요건에 부합하도록 변환함으로써 후속 분석의 신뢰성을 높일 수 있다.

4.3.2 독립변수간 중복성 제거

1) 목적 및 문제 정의

녹조 예측 모델에서 독립변수 후보 집합 $X = \{x_1, \cdots, x_p\}$는 녹조·수질·댐운영·기상 자료의 상호 연동성으로 인해 유사한 관측 메커니즘(예: 동일 계열 센서, 동일 물리량의 근접 정의, 누적/최대/평균 등 통계량)으로부터 파생된 변수가 동시에 포함되는 경우가 빈번하다. 이러한 조건은 동일·유사 정보의 중복 투입에 따른 모델 복잡도 증가, 회귀 계수의 불안정성과 유의성 왜곡을 초래하는 다중공선성(multicollinearity) 심화, 변수 중요도 및 인과적 해석 가능성 저하로 이어질 수 있다. 따라서 본 연구는 독립변수들간 중복성과 다중공선성을 제거하여 모델의 안정성과 해석력을 제고하는 것을 1차 목표로 하며, 동시에 종속변수 y에 대한 직접효과(직접 기여)가 있는 변수의 보존을 통해 예측 성능의 저하를 방지하고자 한다. 본 연구에서 독립변수간 중복성(redundancy)이란, 서로 다른 독립변수들이 동일하거나 유사한 정보를 포함하여 종속변수를 설명하는 데 있어 중복된 기여를 하는 현상을 의미한다.

본 절에서 사용되는 기호는 다음과 같다. Y는 종속변수(남조류 세포수)이며, X_i와 X_j는 높은 상관을 보이는 두 독립변수(쌍별 비교 대상)이다. $r_{X_iX_j}$와 r_{YX}는 각각 X_i와 X_j 및 의 Y와 X의 Pearson 상관계수(단순 상관), $r_{YX_i \mid X_j}$는 X_j를 통제한 Y와 X_i의 편상관계수를 의미한다. 판정에 사용되는 유의수준 α는 0.05로 두며, 쌍별 상관 필터링 임계값은 $\left|r_{X_i, X_j}\right| \geq \tau_{corr}$ ($\tau_{corr} \in [0.8, 0.9]$), 허위상관(spurious correlation) 판별을 위한 "편상관이 거의 0"인 실무적 임계값은 $\left|r_{YX_i \mid X_j}\right| < \tau_{pcorr}$($\tau_{pcorr} \approx 0.1$ and $p > 0.05$)로 설정한다. 다중공선성 제거를 위한 VIF 임계값은 $VIF \geq \tau_{VIF}$($\tau_{VIF} \approx 10$)로 설정한다.

2) 이론적 배경

가. 상관성 기반 중복성(redundancy)의 의미

독립변수 X_i와 X_j가 $\left|r_{X_iX_j}\right| \geq \tau_{corr}$를 만족하는 경우, 두 변수는 강한 선형 관계로 같거나 매우 유사한 정보를 담고 있을 가능성이 크다. 이때 두 변수를 동시에 모델에 포함하면 예측력 증대보다 복잡도 증가 및 추정 불안정성이 커질 수 있으며, 특히 선형·준선형 모형에서는 계수 추정의 분산이 증가하여 부호가 변동하거나 유의성이 왜곡되는 문제가 발생한다. 그러나 상관관계가 높다는 사실만으로 두 변수 중 하나를 기계적으로 제거하면 중요한 변

수를 잘못 제거할 위험도 존재한다.

통계 분석에서 변수 간 관계를 해석할 때 가장 주의해야 할 문제 중 하나는 이른바 제3의 변수(third-variable) 문제이다. 제3의 변수 문제란 두 변수 간에 관측되는 상관관계가 실제 인과적 관계를 반영하지 않거나, 혹은 제3의 변수의 개입으로 인해 그 관계가 왜곡되거나 은폐되는 현상을 포괄적으로 지칭한다. 대표적인 유형으로는 허위상관(spurious correlation), 매개효과(mediation), 억제효과(suppression) 등이 있으며, 이들은 모두 제3의 변수가 개입한다는 공통점을 가지나, 그 구조적 특성과 해석상의 의미는 서로 명확히 구분된다.

먼저, 허위상관(spurious correlation)은 두 변수 X와 Y 사이에 직접적인 인과관계가 존재하지 않음에도 불구하고, 공통된 원인이 되는 제3의 변수 Z로 인해 통계적으로 유의한 상관관계가 관측되는 현상을 의미한다. 이 경우의 구조는 Z→X 및 Z→Y로 표현되며, Z가 X와 Y의 동시 변화를 유발하는 공통 원인으로 작용한다. 허위상관의 핵심적 특징은 제3의 변수 Z를 통제한 이후에는 X와 Y 사이의 상관관계가 0에 가깝게 소멸하거나 통계적으로 유의하지 않게 된다는 점이다. 극단적인 예를 들어보면, 아이스크림 판매량과 녹조 발생 사이에서 관측되는 양의 상관관계는 두 변수 간의 직접적 인과관계를 의미하지 않으며, 실제로는 기온이라는 외생변수가 두 변수 모두에 영향을 미친 결과로 해석된다. 이 경우, 허위상관을 인과관계로 오인하면 잘못된 정책적·과학적 결론에 도달할 위험이 크다.

둘째, 매개효과(mediation)는 허위상관과 달리 실제적인 인과적 연결 고리가 존재하는 경우로, 독립변수 X가 종속변수 Y에 영향을 미치는 과정에서 제3의 변수 M이 중간 단계로 작용하는 구조를 의미한다. 이는 X→M→Y의 형태로 표현되며, X의 효과가 직접적으로 Y에 전달되기보다는, 매개변수 M을 통해 간접적으로 전달된다. 매개효과 분석의 핵심적인 의의는 단순히 “영향이 존재하는가”를 넘어서, 그 영향이 “어떤 경로를 통해” 발생하는지를 설명할 수 있다는 점에 있다. 예컨대, 기온이 녹조 발생에 미치는 영향을 분석할 때, 수온 상승(1차 매개)→조류의 세포 대사 속도 증가(2차 매개) 등은 생화학적 매개변수로 작용하는 인과적 연쇄 구조로 해석할 수 있다. 이 경우 독립변수인 기온은 허위상관이 아니라, ‘수온’이라는 경로로 영향력을 전달하는 원천적 원인으로 기능한다. 다만 통계적으로는 수온이 녹조 발생에 더 직접적이고 지배적 영향으로 작동할 수 있으므로 기온 변수는 제거하는 것이 효과적이다. 반면 원천적 원인인 기온은 우리가 조절할 수 있는 정책적 지렛대(탄소저감 정책 등)로서 여전히 중요한 의미를 갖는다.

마지막으로, 억제효과(suppression)는 허위상관이나 매개효과와 달리 두 변수 간에 실제로 존재하는 관계가 제3의 변수를 통제하지 않은 상태에서는 약화하거나 가려져 관측되며 해당 제3의 변수를 통제할 경우 오히려 관계가 더 명확해지는 현상을 의미한다. 다시 말하면, 억제변수는 독립변수 또는 종속변수에 포함된 불필요한 변산성이나 잡음 성분을 제거함으로써, 핵심적인 관계를 더욱 선명하게 드러내는 역할을 한다. 이 경우의 특징적인 현상은 억제변수를 통제한 이후 X와 Y 사이의 상관계수 또는 회귀계수가 오히려 증가한다는 점이

다. 즉, 억제효과는 “실제로는 강한 관계가 존재하지만, 단순 상관분석에서는 그 관계가 과소평가되던 상황”을 교정해 주는 역할을 한다. 따라서 제3의 변수가 억제변수로 판명되면 두 독립변수를 모두 유지하는 것이 옳은 선택이 된다. 만일 단순 상관관계만 고려해 억제변수 또는 억제 효과가 나타나는 변수 쌍 중 일부를 제거하면 예측 성능이나 설명력을 크게 저해할 위험이 있다.

종합하면, 허위상관, 매개효과, 억제효과는 모두 제3의 변수가 변수 간 관계에 개입한다는 점에서는 공통적이지만, 허위상관은 인과적 착시를 제거해야 할 대상인 반면, 매개효과와 억제효과는 변수의 역할과 경로에 대한 정교한 이해를 바탕으로 제거 및 유지 결정을 신중히 해야 한다. 본 연구는 이러한 위험을 줄이기 위해 단순 상관과 함께 편상관 분석을 병행하여 “직접 효과의 보존” 관점에서 중복 제거를 수행한다.

나. 편상관계수를 통한 허위상관(spurious correlation) 판정

편상관(partial correlation)은 다른 변수의 영향을 제거한 후 두 변수 간에 남는 순수한 선형 관계를 의미한다. 본 연구에서는 X_j를 통제한 X_i와 Y의 편상관계수 $r_{YX_i|X_j}$을 식(4.23)과 같은 잔차 상관 방식으로 계산한다. 구체적으로, 먼저 Y를 X_j에 회귀하여 잔차 e_Y를 얻고, 동일하게 X_i를 X_j에 회귀하여 잔차 e_{X_i}를 얻은 후, e_Y와 e_{X_i}의 상관을 통해 $r_{YX_i|X_j}$을 산출한다.

$$
\begin{aligned}
&① \ Y\text{를 } X_j\text{에 회귀} && Y = a_0 + a_1 X_j + \epsilon_{Y,} \quad e_Y = \widehat{\varepsilon_Y} \\
&② \ X_i\text{를 } X_j\text{에 회귀} && X_i = b_0 + b_1 X_j + \epsilon_{X_i,} \quad e_{X_i} = \widehat{\varepsilon_{X_i}} \\
&③ \ \text{잔차 간 상관} && r_{YX_i|X_j} = r_{e_Y e_{X_i}}
\end{aligned}
\qquad \text{식(4.23)}
$$

이때, 상관계수 $r_{X_iX_j}$, r_{YX_i}, 는 높으나, X_j를 통제한 편상관계수 $r_{YX_i|X_j}$가 0에 가까우면 ($r_{YX_i|X_j} \approx 0$), Y와 X_i 사이의 관계는 X_j를 매개로 발생한 간접효과로 해석될 수 있으며, X_i의 직접효과는 미미한 것으로 판단된다. 반대로 X_j를 통제한 이후에도 $r_{YX_i|X_j}$이 충분히 크고 유의하면, X_i는 X_j와 무관하게 Y에 대한 직접효과를 보유한다고 해석할 수 있다. 편상관의 유의성은 표본크기 n, 통제변수 개수 k(본 절에서는 $k=1$일 때 식(4.24)의 t-통계량을 사용하여 검정한다.

$$
t = r_{Y,X_i|X_j} \frac{n-k-2}{1-r^2_{Y,X_i|X_j}} \qquad \text{식(4.24)}
$$

이에 따라 본 연구는 실무적 판정 기준으로 $\left|r_{Y,|X_j}\right| < 0.1$이면서 $p > \alpha$인 경우를 “직접

효과가 거의 없음(매개 가능성 높음)"으로 간주한다. 다만 $\left|r_{Y,X_i|X_j}\right|$가 작더라도 $p \le \alpha$이면 약하지만 독립적인 직접효과가 잔존할 가능성을 배제할 수 없으므로, 해당 변수의 제거는 보수적으로 판단하며 추가 근거(도메인 지식 또는 성능 검증)를 병행하도록 한다.

<표 4.8> 변수쌍 (X_i , X_j)에서 단순상관과 편상관 비교를 통한 변수 제거 규칙

구 분	단순상관		편상관		변수구조	제거/유지 결정
	r_{YX_i}	r_{YX_j}	$r_{YX_i \mid X_j}$	$r_{YX_j \mid X_i}$		
허위상관	높음	r_{YX_i} <	거의 0	$r_{YX_i \mid X_j}$ <	$X_i \leftarrow X_j \rightarrow Y$	X_i 제거 (X_j가 진짜 원인)
완전매개	보통~높음	r_{YX_i} <	거의 0	$r_{YX_i \mid X_j}$ <	$X_i \rightarrow X_j \rightarrow Y$	X_i 제거 (X_j가 효과 대변)
부분매개	높음	r_{YX_i} <	r_{YX_1} >, > 0	$r_{YX_i \mid X_j}$ <	$X_i \rightarrow Y$, $X_i \rightarrow X_j \rightarrow Y$	단순상관 낮은 변수 제거
억제효과	중간	r_{YX_i} >	r_{YX_i} <	$r_{YX_i \mid X_j} \ge$	X_i-($X_i \cap X_j$)$\rightarrow Y$	둘 다 유지 (시너지)
단순중복	$r_{YX_i} \approx r_{YX_j}$		거의 0		단순 중복 (공선성)	단순상관 낮은 변수 제거

다. VIF와 다중공선성의 정량화

VIF(Variance Inflation Factor)는 특정 독립변수가 다른 독립변수들에 의해 설명되는 정도를 바탕으로 회귀계수 분산이 얼마나 팽창하는지를 계량화한다. 변수 X_i를 나머지 변수들로 회귀했을 때의 결정계수를 R_i^2라 하면, VIF는 다음의 식(4.25)와 같이 정의된다.

$$VIF_i = \frac{1}{1 - R_i^2} \qquad \text{식(4.25)}$$

VIF는 선형회귀에서 회귀계수의 분산이 $1/(1 - R_i^2)$에 비례한다는 사실을 직접 반영하므로, VIF가 높을수록 계수 추정이 불안정하고 해석이 취약해진다. 일반적으로 VIF = 10은 표준오차가 $\sqrt{10} \approx 3.16$배까지 커질 수 있음을 의미한다. 본 연구에서는 쌍별 상관 기반으로 중복 변수를 선제적으로 제거한 뒤 VIF를 적용하는데, 이는 쌍별 중복 제거만으로도 R_i^2가 감소하여 VIF가 자연스럽게 낮아지는 사례가 많아, 후속 VIF 제거 과정의 반복 횟수와 과도한 변수 탈락 위험을 동시에 줄일 수 있기 때문이다.

3) Greedy 방식 상관 + VIF 필터링 알고리즘 (수행 절차)

본 알고리즘은 먼저 독립변수간 쌍별 상관계수를 활용해 Greedy 방식 제거로 강한 선형 중복을 빠르게 정리하고, 그 이후에도 남아있는 다변량 다중공선성을 VIF 기반으로 추가 정리하

는 2단계 절차로 구성된다. 핵심은 1단계의 “제거 대상 결정”에서 단순 상관뿐 아니라 편상관을 활용하여 매개·억제 구조에서의 오판을 줄이고, 결과적으로 직접효과가 있는 변수를 보존하도록 설계한 점이다.

가. 단계 1: Greedy 상관 기반 중복 제거 (쌍별 제거)

① 후보 쌍 정의 및 Greedy 선택 규칙

현재 변수 집합을 $S \subset X$라 하면, 본 연구는 식(4.26)과 같이 S 내 모든 변수쌍에 대한 상관계수 행렬을 계산하고, $\left|r_{X_i, X_j}\right| \geq \tau_{corr}$를 만족하는 쌍만을 중복 후보로 지정한다.

$$P = \left\{ (i, j) : \left|r_{X_i, X_j}\right| \geq \tau_{corr} \right\} \quad \text{식(4.26)}$$

이후 Greedy 방식에 따라 P 중 $\left|r_{X_i, X_j}\right|$가 최대인 변수쌍 (X_i, X_j)를 선택하고, 두 변수 중 하나를 제거한 뒤 상관행렬과 P를 갱신한다. 이러한 반복은 $P = \varnothing$, 즉 모든 변수쌍이 $|r| < \tau_{corr}$를 만족할 때까지 수행된다. 이와 같은 Greedy 설계는 계산 효율성과 구현 용이성을 확보하는 동시에, “가장 큰 중복”부터 제거함으로써 모델 단순화를 단계적으로 달성하도록 한다.

② 1차 Tie-break: 종속변수와의 단순상관 비교(예측 관련성 보존)

변수쌍 (X_i, X_j)가 강한 중복 관계에 있을 때, 예측 관점에서 기본 원칙은 종속변수 Y와의 관련성이 더 큰 변수를 보존하는 것이다. 따라서 두 변수의 종속변수와의 단순상관 $\left|r_{Y, X_i}\right|$와 $\left|r_{Y, X_j}\right|$를 비교하고, 상대적으로 절댓값이 작은 변수를 우선 제거 후보로 둔다. 다만 이 규칙은 X_i 또는 X_j가 Y와의 단순상관이 커도 직접효과는 없거나 작을 수 있다는 한계를 갖는다. 그러므로 본 연구는 단순상관 비교를 “1차 Tie-break”로만 사용하고, 최종 제거 결정은 편상관 기반 판정으로 보정한다.

③ 2차 Tie-break: 매개변수(mediator) 판정 및 허위상관 방지(편상관 규칙)

본 연구는 (X_i, X_j) 상관이 높을 때 X_i의 Y에 대한 예측 기여가 실제로 직접효과인지, 또는 X_j에 의해 매개된 간접효과인지 판단하기 위해 $\left|r_{Y, X_i | X_j}\right|$를 산출한다. 먼저 $\left|r_{Y, X_i}\right|$가 큰데도 불구하고 $\left|r_{Y, X_i | X_j}\right| < \tau_{pcorr}$이거나 값의 신뢰도가 높지 않으면($p > \alpha$), X_i의 직접효과는 거의 없고 X_j를 통한 간접효과로 설명될 가능성이 높다. 이 경우 X_j를 제거하면 Y 예측에 필요한 핵심 경로가 손실될 수 있으므로, 원칙적으로 X_i를 제거하고 X_j를 보존한다. 반대로 X_j를 통제한 이후에도 $\left|r_{Y, X_i | X_j}\right|$가 충분히 크고 신뢰도가 높으면($p \leq \alpha$), X_i의 직접효과가 남아있다고 해석되므로, X_j는 중복 변수일 가능성이 커져 제거가 허용된다.

더욱 엄밀한 결정을 위해 본 연구는 쌍방향 편상관을 병행하는 것을 권장한다. 즉, 식(4.27)과 같이 $r_{Y,X_j|X_i}$는 높고 유의한 반면 $\left|r_{Y,X_i|X_j}\right|$는 낮고 신뢰도가 낮으면($p > \alpha$), X_i는 허위상관일 가능성이 더욱 커져 제거의 타당성이 강화된다.

$$\left|r_{Y,X_j|X_i}\right| \text{ 높음} \ \wedge \ \left|r_{Y,X_i|X_j}\right| \text{ 낮음} \qquad \text{식(4.27)}$$

④ 억제변수(suppressor) 고려

억제변수(suppressor)는 단순상관만으로 판단할 경우 제거되기 쉬우나, 실제로는 다른 변수의 잡음 성분을 제거하여 예측력을 높일 수 있다. 따라서 본 연구는 $\left|r_{Y,X_j}\right|$가 낮더라도 $\left|r_{Y,X_j|X_i}\right|$가 증가(↑)하고 유의한 경우, X_j를 억제변수로 의심하여 제거를 보류하거나, 제거가 불가피할 때는 직접효과가 더 약한 변수를 제거하도록 규칙을 설정한다. 이를 구조적으로 요약하면 다음과 같다.

즉, 억제 구조가 의심되는 쌍에서는 단순상관의 크기만으로 제거 결정을 내리지 않으며, 편상관 기반의 정보 증대 여부를 확인한 뒤 보수적으로 의사결정을 수행한다.

나. 2단계: VIF 기반 다변량 중복 제거(다중공선성 정리)

쌍별 상관 필터링을 통과한 변수 집합 S에 대해, 각 변수 $X_i \in S$의 VIF_i를 계산한다. 계산은 X_i를 나머지 변수들 $S \setminus \{X_i\}$로 회귀하여 R_i^2를 구한 후, $VIF_j = 1/(1-R_i^2)$로 산출한다. 이후 $\max_i VIF_i \geq \tau_{VIF}$이면 가장 큰 VIF를 갖는 변수를 제거 후보로 지정하고, 제거 후 VIF를 재계산한다. 이 과정은 모든 변수에 대해 $VIF_i < \tau_{VIF}$가 만족될 때까지 반복된다. 또한 본 연구는 VIF 제거 과정에서도 종속변수 관련성이 매우 큰 변수의 오제거를 방지하기 위해, 필요 시 $\left|r_{Y,X_i}\right|$ 또는 "통제 후 직접효과" 관점의 추가 근거를 참고하여 제거 대상을 보정하도록 한다.

상관 기반 필터링은 쌍별 선형 중복을 빠르게 제거할 수 있어 계산 효율성이 높고, VIF는 다변량 조합에 의해 유발되는 공선성까지 반영한다는 점에서 상호 보완적이다. 특히 쌍별 상관이 낮더라도 여러 변수가 결합해 특정 변수를 거의 완벽히 설명하는 경우 VIF가 높아질 수 있으므로, VIF 단계는 상관 필터링만으로 제거되지 않는 다변량 중복을 정리하는 역할을 한다. 또한 상관 기반 중복 제거를 선행하면 R_i^2가 감소하여 VIF가 자연스럽게 낮아지는 경향이 있어, VIF 기반 반복 제거의 횟수와 과도한 변수 탈락 위험을 동시에 줄일 수 있다. 따라서 "상관 → VIF"의 순차 적용은 계산 효율성과 통계적 안정성을 균형 있게 달성하는 합리적 설계로 해석된다.

4.3.3. 종속변수와의 상관성 분석

1) 목적과 기본 개념: 총효과와 직접효과의 분리

녹조 예측 문제에서 설명변수 X_i가 종속변수 Y에 영향을 미치는 경로는 단일하지 않으며, 다수의 수질·수문·기상·운영 변수가 복합적으로 얽힌 시스템에서는 특정 변수가 다른 변수를 매개로 하여 간접적으로 영향을 미치는 경우가 빈번하다. 이러한 상황에서 상관계수 r_{Y,X_i}는 X_i와 Y의 선형적 결합 정도를 나타내지만, 그 값에는 X_i의 직접효과(Direct Effect) 뿐 아니라 다른 변수들을 경유하는 간접효과(Indirect Effect)가 함께 포함된다. 즉 상관계수는 "총효과"를 반영하므로, 상관이 높다는 사실만으로 해당 변수가 독자적으로 X_i를 설명한다고 결론짓기 어렵다.

이를 보완하기 위해 본 연구는 편상관계수 $r_{Y,X_i|X_{-i}}$를 함께 사용한다. 여기서 $X_{-i} = \boldsymbol{X}\{X_i\}$는 X_i를 제외한 나머지 설명변수(또는 분석 목적에 따라 선택한 통제변수 집합)이다. 편상관계수는 X_{-i}의 영향을 통제한 상태에서 X_i와 Y 사이에 남는 순수한 선형 관계를 의미하므로, 결과적으로 X_i가 Y에 제공하는 독립적·직접적 정보(직접효과)를 정량화하는 지표로 해석할 수 있다. 따라서 상관과 편상관을 병행하면, 변수가 Y에 미치는 영향이 주로 직접효과인지, 다른 변수에 의해 매개된 간접효과인지, 또는 억제효과(suppression)를 통해 숨은 기여를 하는지 구분할 수 있다.

2) 실행 효과: 종속변수와의 관계 해석 정교화 및 Maximum Relevance 확보

상관 - 편상관 비교 기반의 변수 선택은 단순히 "상관이 큰 변수만 유지"하는 접근을 넘어, 각 변수가 Y를 설명하는 방식과 역할을 해석함으로써 변수 선택의 타당성을 강화한다. 첫째, 특정 변수가 Y와 높은 상관을 보이더라도 편상관이 낮다면, 이는 해당 변수가 Y에 독자적으로 기여한다기보다 다른 변수(또는 변수군)를 통해 간접적으로 연관되어 있음을 시사한다. 이 경우 해당 변수는 매개변수(mediator) 또는 중복 정보 제공 변수로 해석될 수 있으며, 최종 모델에서 제거하더라도 설명력 손실이 제한적일 가능성이 높다.

둘째, 반대로 단순 상관은 낮지만 편상관이 높은 변수는, 단독으로는 Y와의 관계가 약해 보이나 다른 변수들을 통제했을 때 Y와의 순수 관계가 강화되는 경우로서 억제변수(suppressor) 가능성이 있다. 억제변수는 다른 변수와 공유하는 불필요한 변동(잡음 또는 공통성분)을 제거함으로써 핵심 예측 신호를 부각시키는 역할을 할 수 있으며, 제거 시 오히려 모델 설명력이 감소할 수 있다. 이러한 구조를 상관만으로는 포착하기 어렵기 때문에, 편상관 비교는 억제효과로 인한 "숨은 기여자"를 식별하고 유지 여부를 판단하는 데 중요한 근거를 제공한다.

종합하면, 상관계수 기반의 총효과 정보와 편상관계수 기반의 직접효과 정보를 함께 고려하면, 종속변수 Y에 대한 유효한 직접적 정보량을 극대화하는 방향으로 변수 집합을 정제할 수 있다. 이는 변수 수를 단순히 줄이는 차원을 넘어, 최종 변수 집합이 Y와의 관계 측면에서 최대 관련성(Maximum Relevance)을 갖도록 하는 목적함수에 부합한다.

제 5장 수리특성을 고려한 적정 AI 알고리즘 개발

5.1 AI 알고리즘 검토 및 적정 모델 선정

5.1.1 다양한 AI 알고리즘 특성 검토

1) 시계열 분석 특화 모델

가. LSTM

Long Short-Term Memory (LSTM)은 시계열 데이터에서 장기 의존성을 효과적으로 학습할 수 있도록 설계된 순환 신경망(RNN)의 한 유형이다. 전통적인 RNN은 긴 시퀀스를 처리할 때 기울기 소멸 문제로 인해 학습이 어려운 반면, LSTM은 셀 상태와 게이트 메커니즘을 통해 이러한 문제를 완화한다. 이러한 특성 덕분에 LSTM은 흐름 특성이나 과거 관측값이 현재 상태에 영향을 미치는 복잡한 데이터 관계를 학습하는 데 매우 유리하다. 특히, 계절적 변화와 같은 시계열 데이터에서 중요한 패턴을 학습하는 데 강점을 보인다.

LSTM의 아키텍처는 입력, 은닉 상태(hidden state), 셀 상태(cell state)로 구성되며, 세 가지 게이트(입력 게이트, 망각 게이트, 출력 게이트)를 포함한다. 입력 게이트는 새로운 정보를 셀 상태에 추가할지 결정하고, 망각 게이트는 불필요한 정보를 제거하며, 출력 게이트는 은닉 상태를 기반으로 최종 출력을 생성한다. 이러한 구조는 데이터의 시간적 변화를 효율적으로 학습할 수 있도록 돕는다. 동시에 셀 상태는 장기적인 의존성을 유지하며 중요한 정보를 잃지 않도록 한다. LSTM은 데이터를 단계적으로 처리하며, 각 단계에서 입력 데이터와 이전 단계의 정보를 결합해 새로운 셀 상태와 은닉 상태를 계산한다. 이를 통해 이전 데이터의 영향을 반영하면서도 새로운 데이터를 학습할 수 있다. 예를 들어, 녹조 예측과 같은 환경 모니터링에서 LSTM은 과거 수질 데이터와 기상 데이터를 활용해 미래의 녹조 농도를 예측할 수 있다.

그러나 LSTM은 계산 복잡도가 높은 모델로, 대규모 데이터나 긴 시퀀스를 처리할 때 학습 속도가 느리고 메모리 소모가 클 수 있다. 또한, 매우 긴 시퀀스에서는 성능 저하가 발생할 가능성도 있다. 하지만 적절한 하이퍼파라미터 튜닝과 모델 최적화를 통해 이러한 단점을 보완할 수 있다. LSTM은 특히 소규모 시계열 데이터에서도 뛰어난 성능을 발휘하므로 다양한 도메인에서 널리 활용된다.

나. GRU

Gated Recurrent Unit (GRU)는 LSTM의 단순화된 변형으로, 시계열 데이터를 처리할 때 유사한 성능을 제공하면서도 더 간결한 구조를 가진다. GRU는 셀 상태를 따로 유지하지 않고 은닉 상태만을 사용하므로 계산 자원이 적게 소모된다. 이로 인해 LSTM보다 학습 속

도가 빠르고 메모리 효율성이 높아 대규모 데이터 처리에 적합하다.

GRU는 두 가지 주요 게이트인 업데이트 게이트와 리셋 게이트로 구성된다. 업데이트 게이트는 이전 은닉 상태와 현재 입력 간의 가중치를 결정하며, 리셋 게이트는 이전 은닉 상태를 무효화할지를 판단한다. 이를 통해 GRU는 필요한 정보를 유지하거나 새로운 정보를 추가하며 데이터를 처리한다. 이러한 구조는 단순하지만 강력한 학습 능력을 제공한다.

GRU는 입력 데이터를 처리하면서 단계별로 새로운 은닉 상태를 생성한다. 이전 은닉 상태와 현재 입력 데이터를 결합하여 업데이트 및 리셋 게이트를 계산한 후 이를 기반으로 최종 은닉 상태를 업데이트한다. GRU는 복잡한 데이터 패턴을 학습할 수 있으면서도 계산 비용이 적게 들어 다변량 시계열 데이터에도 적합하다. 또한, LSTM과 비슷한 수준의 성능을 제공하면서도 더 단순한 구조를 통해 빠른 학습 속도를 유지한다. 그러나 데이터의 복잡성에 따라 LSTM보다 성능이 낮을 수도 있으며, 복잡한 장기 의존성을 다루는 데는 LSTM만큼 효과적이지 않을 수 있다.

2) 시공간적 분석 특화 모델

가. ConvLSTM

Convolutional LSTM(ConvLSTM)은 시공간 데이터를 처리하기 위해 LSTM과 CNN(Convolutional Neural Network)을 결합한 모델로, 복잡한 시공간 의존성을 학습하는 데 적합하다. 이 모델은 특히 공간적 패턴(물 흐름 분포 등)과 시간적 패턴(계절적 변화 등)이 모두 중요한 문제에서 뛰어난 성능을 발휘한다. ConvLSTM은 LSTM의 게이트 연산을 수행할 때 Fully Connected 레이어 대신 Convolutional 레이어를 사용한다는 점에서 차별화된다. 입력 데이터는 3D 텐서(시간, 공간 X, 공간 Y) 형태로 전달되며, Convolutional 연산을 통해 공간적 특성을 추출한다. 이러한 공간적 특성을 LSTM의 게이트 메커니즘과 결합하여 시간적 종속성과 공간적 구조를 동시에 학습한다. 이는 복잡한 수리 및 환경 데이터를 처리하는 데 매우 유용하다.

ConvLSTM은 데이터를 시퀀스 형태로 처리하며, 각 시퀀스에서 CNN을 통해 공간적 특성을 추출하고, LSTM 셀 상태와 은닉 상태를 통해 시간적 의존성을 학습한다. 이러한 처리 방식은 특히 강이나 호수의 수질 데이터를 기반으로 한 녹조 예측에서 공간적 상호작용과 시간적 변화를 동시에 고려할 수 있도록 한다. 결과적으로 ConvLSTM은 데이터의 시공간적 특성을 통합적으로 이해하여 높은 예측 정확도를 제공한다.

이 모델의 주요 장점은 공간 및 시간적 의존성을 모두 처리할 수 있다는 것이다. 이는 환경 데이터 분석과 같은 복잡한 도메인에서 매우 중요하다. 그러나 ConvLSTM은 입력 데이터의 공간 구조가 명확하지 않거나 비정형 데이터인 경우 성능이 저하될 수 있다. 또한, 계산 비용이 높아 대규모 데이터셋을 처리할 때 학습 속도가 느릴 수 있다는 단점이 있다. 하지만 적절한 하드웨어 및 최적화 기법을 활용하면 이러한 한계를 극복할 수 있다. ConvLSTM은 공간 및 시간적 상호작용을 통합적으로 분석할 수 있는 도구로, 녹조 예측과

같은 문제에 적합한 모델이다. 특히 수질 및 기상 데이터의 상관관계를 명확히 이해하고 이를 기반으로 예측을 수행할 수 있어 정책 결정과 환경 관리에 중요한 정보를 제공할 수 있다.

나. ST-GCN

ST-GCN(Spatio-Temporal Graph Convolutional Network)은 시공간 데이터의 구조적 특성을 동시에 반영하기 위해 그래프 신경망(GNN)과 시간 축 기반 합성곱(Temporal Convolution)을 결합한 모델로, 공간적 상호작용이 명확히 정의된 네트워크형 데이터에 적합하다. 이 모델은 관측 지점 간의 연결 관계(예: 하천 지점 간 상·하류 관계, 저수지-지천 연결 구조)와 시간적 변화 패턴을 통합적으로 학습함으로써, 전통적인 CNN이나 RNN 기반 모델이 충분히 반영하지 못하는 비정형 공간 구조와 시계열 의존성을 동시에 처리할 수 있다는 점에서 차별화된다.

ST-GCN은 먼저 그래프 구조를 기반으로 공간적 의존성을 학습한다. 각 관측 지점은 그래프의 노드로 표현되며, 유역 연결성·수리적 영향권·지리적 인접성 등의 기준에 따라 에지(edge)가 정의된다. 모델은 그래프 합성곱(Graph Convolution)을 통해 인접 노드의 특성을 통합하여 공간적 상호작용을 학습하고, 이를 통해 개별 지점의 값뿐 아니라 주변 지점의 영향까지 반영된 표현을 생성한다. 이후 시간 축 합성곱(Temporal Convolution)을 적용하여 시계열 흐름과 추세 변화를 학습하며, 이 과정을 통해 공간 구조와 시간 변동성을 결합한 시공간 표현을 효과적으로 추출한다.

이와 같은 구조는 수질 및 수문 데이터와 같이 지점 간 상호작용이 존재하는 네트워크 환경에서 특히 유용하다. 예를 들어, 강·저수지에서의 녹조 발생은 특정 지점의 수질 조건뿐 아니라 상류 유입수, 인근 지점의 영양염 변화, 수리적 체류시간 등 주변 공간 요인의 영향을 함께 받는다. ST-GCN은 이러한 영향 전파를 그래프 구조로 표현하고, 시간적 누적효과를 함께 학습함으로써 녹조 확산 패턴과 시공간 상관관계를 정교하게 모델링할 수 있다. 결과적으로 ST-GCN은 단일 지점 기반 시계열 모델보다 네트워크 전반의 동태적 변화를 반영한 예측 성능을 제공한다.

ST-GCN의 장점은 비정형 공간 구조를 가진 데이터에서도 적용 가능하다는 점이다. 규칙 격자 형태를 가정하는 CNN과 달리, 그래프 구조를 활용함으로써 관측망 간격이 불규칙하거나 지점 간 영향 경로가 비선형적인 경우에도 적합하게 활용될 수 있다. 또한 공간적 의존성과 시간적 의존성을 분리-결합하여 학습하기 때문에, 고차원 시공간 데이터에서도 비교적 효율적인 표현 학습이 가능하다. 다만 그래프 구조 정의(에지 가중치, 연결 기준 등)에 따라 성능이 민감하게 달라질 수 있으며, 대규모 그래프에 대해 학습 시 계산 비용이 증가하는 한계가 존재한다. 이러한 점을 보완하기 위해 인접행렬 학습, 노드 군집화, 샘플링 기반 학습 등의 기법을 병행할 수 있다.

종합적으로 ST-GCN은 시공간 상호작용이 지점 간 네트워크 구조로 전파되는 환경 데이터 분석에 적합한 모델이며, 수질-기상-수문 변수 간 복합적 영향관계를 체계적으로 반영할

수 있다. 특히 녹조 예측, 수질 오염 확산, 유역-저수지 상호작용 분석과 같은 문제에서 의사결정 지원을 위한 정밀 예측과 패턴 이해에 중요한 도구로 활용될 수 있다.

3) 어텐션 기반 트랜스포머

가. Temporal Fusion Transformer

Temporal Fusion Transformer (TFT)는 복잡한 다변량 시계열 데이터 예측을 위해 설계된 트랜스포머 기반 모델로, 성능뿐만 아니라 해석 가능성까지 제공할 수 있다. 이 모델은 시간적 및 정적 특성을 통합하여 단기 및 장기 예측 문제를 다룰 수 있다. 특히, 다양한 입력 변수 간의 상호작용과 중요도를 파악할 수 있는 어텐션 메커니즘을 통해 데이터의 유용성을 극대화한다.

TFT는 변수 선택 네트워크, LSTM 기반의 시계열 특성 인코더, 그리고 시점 및 변수 간 상관관계를 학습하는 어텐션 계층으로 구성되어 있다. 변수 선택 네트워크는 중요하지 않은 입력 데이터를 걸러내어 모델 효율성을 높이며, LSTM 계층은 시간 의존적 데이터를 처리한다. 마지막으로 어텐션 계층은 특정 시점과 변수에 가중치를 부여하여 중요한 정보를 강조한다. 이러한 구조는 데이터에서 중요한 패턴과 변수를 효율적으로 학습할 수 있도록 돕는다.

이 모델은 시계열 데이터의 복잡한 의존성을 다루는 것뿐만 아니라 정적 변수와의 관계를 분석하는 데 강점을 가진다. TFT는 단순히 높은 예측 성능을 제공할 뿐 아니라, 모델이 예측 결과에 어떤 변수가 어떻게 기여했는지에 대한 명확한 해석도 가능하게 한다. 예를 들어, 녹조 농도 예측 시, 기온, 강수량, 유속 등 여러 요인이 각기 어떤 영향을 미쳤는지 확인할 수 있다. 이는 환경 데이터 분석에서 데이터 기반 의사결정에 중요한 통찰을 제공한다.

TFT의 장점은 유연성과 해석 가능성이다. 다양한 시계열 데이터와 정적 변수의 조합을 효과적으로 처리할 수 있으며, 다변량 데이터에서 중요한 특성과 시점을 학습하는 능력이 탁월하다. 그러나 모델의 복잡성으로 인해 대규모 데이터셋에서 훈련 시간이 길어질 수 있으며, 최적화를 위해 높은 계산 리소스가 필요할 수 있다. 그럼에도 불구하고, TFT는 복잡한 시계열 데이터를 다룰 때 강력하고 실용적인 도구로 평가받는다.

나. Autoformer

Autoformer는 장기 시계열 예측을 위해 설계된 트랜스포머 기반 모델로, 특히 시간적으로 먼 미래의 값을 예측하는 데 초점을 맞추고 있다. Autoformer는 기존 트랜스포머 구조에서 발생하는 계산 복잡도를 완화하고, 긴 시계열 데이터에서도 효율적으로 동작하도록 설계되었다. 이 모델은 입력 데이터의 시간적 패턴을 학습하기 위해 decomposition block과 patch attention 메커니즘을 활용한다.

Autoformer의 핵심 구성 요소인 decomposition block은 시계열 데이터를 추세와 계절적

성분으로 분해한다. 이를 통해 모델은 시간적 변동성을 효율적으로 학습할 수 있으며, 특히 예측 안정성을 높인다. 또한, patch attention 메커니즘은 데이터의 세그먼트를 학습하여 복잡한 시간적 관계를 간결하게 표현한다. 이러한 설계는 기존 트랜스포머의 단점을 보완하면서도 성능을 향상시키는 데 기여한다.

Autoformer는 긴 시계열 예측에서 특히 효과적이다. 이는 녹조 농도의 장기적인 변화 예측과 같은 환경 모델링 작업에서 중요한 이점을 제공한다. decompostion block을 통해 데이터의 주요 추세를 학습하고, patch attention을 활용하여 세부적인 패턴을 정확히 예측할 수 있다. 결과적으로 Autoformer는 장기 예측 작업에서 높은 성능과 예측 신뢰성을 보장한다.

다. Informer

Informer는 효율성과 확장성에 중점을 둔 트랜스포머 모델로, 특히 긴 시계열 데이터를 다룰 때 효과적이다. Informer는 기존 트랜스포머의 단점을 개선하기 위해 probabilistic sparse attention과 병렬 예측 메커니즘을 도입하였다. 이를 통해 긴 시계열 데이터에서도 높은 예측 성능과 계산 효율성을 제공한다.

Informer의 probabilistic sparse attention은 입력 데이터 중 중요한 정보에만 집중하여 계산량을 줄인다. 이는 기존의 트랜스포머가 모든 입력 데이터에 동일한 가중치를 부여하는 것과 달리, 중요도가 낮은 데이터를 제외함으로써 효율성을 높인다. 병렬 예측 메커니즘은 모델이 여러 시점의 출력을 동시에 계산할 수 있도록 하여 예측 속도를 더욱 향상시킨다.

이 모델은 대규모 데이터셋에서도 안정적으로 작동하며, 다양한 시계열 데이터에서 우수한 성능을 발휘한다. 예를 들어, 녹조 농도 예측 작업에서 Informer는 장기적인 데이터 패턴과 단기적인 이상치를 동시에 학습할 수 있다. 이는 수질 관리와 같은 실제 응용에서 매우 유용하다.

Informer의 주요 장점은 계산 효율성과 확장성이다. 긴 시계열 데이터를 다룰 때 기존 트랜스포머보다 메모리 사용량과 계산 비용이 적으며, 대규모 데이터셋에서도 빠르게 학습할 수 있다. 그러나 중요하지 않은 데이터를 무시하는 스파스 어텐션의 특성상, 일부 세부 패턴이 손실될 가능성이 있다. 그럼에도 불구하고 Informer는 대규모 시계열 데이터와 빠른 예측 속도가 요구되는 응용에서 매우 효과적인 도구로 평가받는다.

4) 트리 기반 앙상블 모델

가. 의사결정나무(Decision Tree, DT)

의사결정나무는 자료를 분석하여 이들 사이에 존재하는 패턴을 예측 가능한 규칙들의 조합으로 나타내며, 그 모양이 나무와 같아 의사결정나무로 지칭한다. 분류 규칙을 기반으로 자료를 분할하여 예측 및 분류를 수행하는 방법론 중 하나다. 분석 과정을 나무구조로 표현하는 것이 가능하기 때문에 판별분석(discriminant analysis), 회귀분석(regression analysis),

신경망(neural networks) 등과 같은 방법들에 비해 분석 과정을 쉽게 이해하고 설명할 수 있다는 장점이 있으나, 로지스틱 회귀(logistic regression)와 같이 각 예측 변수의 효과를 파악하기 어렵고 새로운 자료에 대한 예측이 불안정할 수 있다는 한계가 있다. 의사결정나무에 포함되는 기본 알고리즘은 CHAID, CART, ID3, C4.5, C5.0 등이 있으며 이들의 장점을 결합한 다양한 알고리즘이 존재한다. 시스템에서 구현할 때 R 언어에서는 rpart 패키지를, python에서는 scikit-learn 라이브러리를 활용하며 분석을 위한 초매개변수(hyper parameter)로는 가지치기의 복잡성을 의미하는 CP가 있다.

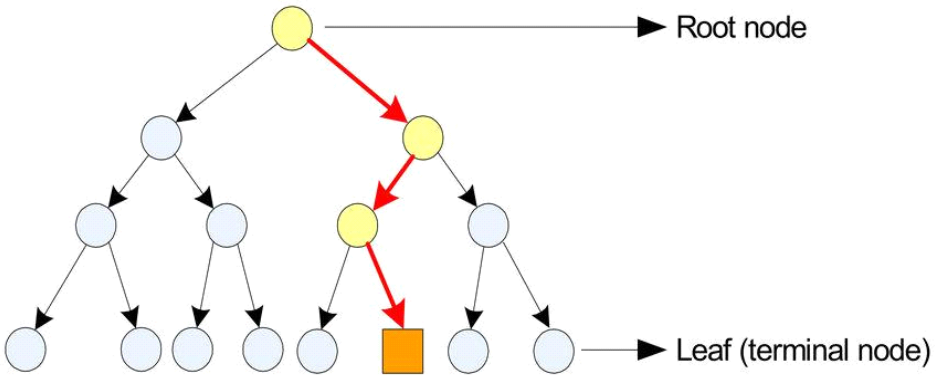

<그림 5.1> 의사결정나무의 개념도

나. 랜덤 포레스트(Random Forest, RF)

정확성, 단순성 및 유연성으로 인해 가장 많이 사용되는 알고리즘 중 하나로, 무작위로 특징을 선정해 나무의 마디로 지정하고 분기할 때마다 의사결정나무와 같은 방식으로 불순도를 파악하여 분기해 나가는 가지를 여러개 만들어 비교해 최적의 분류 및 예측을 하는 모델이다. 다수의 의사결정나무를 통합한 앙상블 형태로, 전체 자료에서 무작위 자료의 추출을 통해 여러개의 학습 자료 표본을 추출(bootstraping)하여 표본들의 특성을 무작위로 선정하고 다수의 분류기를 일괄적으로 배깅(bagging)하는 알고리즘이다. 이 방법을 통해 각 트리가 선택하는 변수를 무작위로 설정하여 트리간의 상관성을 줄여 모델의 과적합을 방지할 수 있고 모델의 특성상 자료의 크기가 방대할수록 예측에 소요되는 시간이 길어지나, 분류 및 회귀분석에 모두 사용이 가능하다. 대용량 자료를 효과적으로 처리할 수 있으며, 과적합 문제를 최소화하여 모델의 정확도가 높다는 장점이 있다. 시스템에서 구현할 때 R 언어에서는 randonForest 패키지를, python에서는 scikit-learn 라이브러리를 활용하며 대표적인 초매개변수는 무작위 분류기의 개수를 나타내는 mtry가 있다.

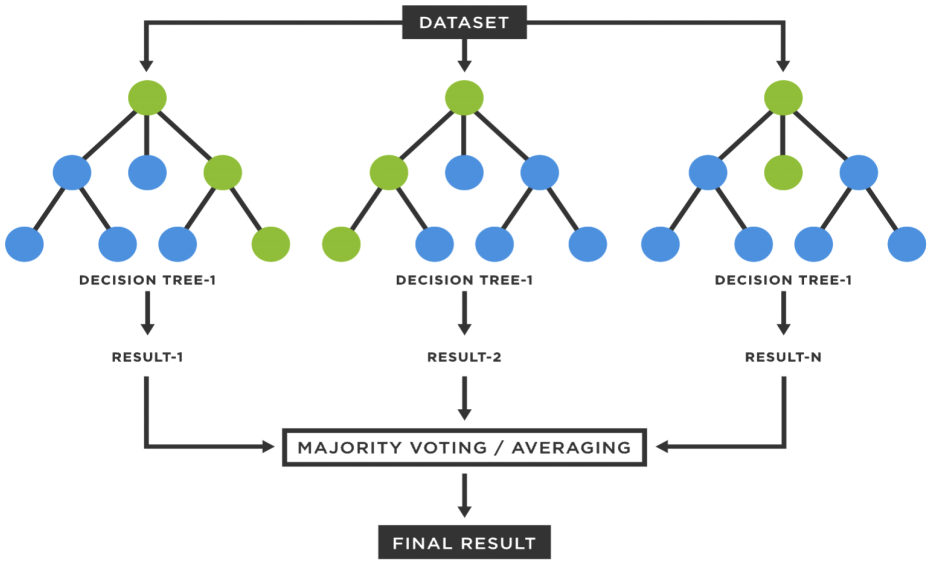

<그림 5.2> 랜덤 포레스트의 개념도

다. XGBoost

다수의 약한 분류기(weak classifier)를 순차적으로 학습하여 잘못된 자료에 가중치를 부여하는 방식으로 오류를 개선하는 Gradient Boost 모델이 있다. XGBoost는 Gradient Boost 모델이 가진 단점을 잔차를 이용하여 보완하는 새로운 모델을 순차적으로 선형 결합하여 만든 모델을 생성하는 지도학습 알고리즘인 Gradient Tree Bossting 모델에 과적합 방지를 위한 여러 기법이 추가된 지도학습 알고리즘이다. 실제값과 예측값의 오차를 학습자료에 투입하고 잔차(gradient)를 이용하여 오류를 보완하는 방식으로 구동된다. 적은 자료를 활용할 시 과적합 가능성이 높고 모델의 정확도가 낮다는 단점이 있으나, 충분한 양의 자료가 있을 때 과적합이 잘 일어나지 않아 예측 성능이 좋다는 장점이 있다. 시스템에서 구현할 때 R 언어에서는 xgboost 패키지를, python에서는 XGBoost 라이브러리를 활용하며 대표적인 초매개변수로는 부스팅 반복횟수를 의미하는 nrounds, 패널티 비율을 의미하는 lambda와 alpha, 학습률을 의미하는 eta가 있다.

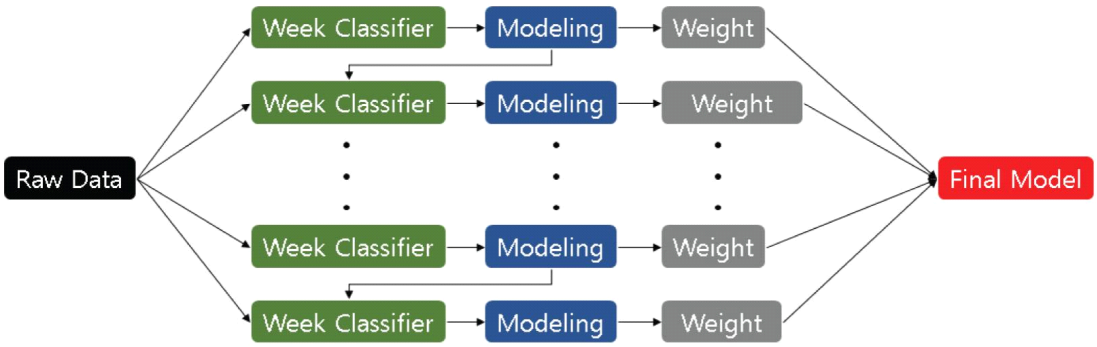

<그림 5.3> XGBoost의 개념도

5.1.2 녹조 예측에 적합한 모델 선정

녹조 현상(특히 남조류 대발생)은 수생 생태계와 상수원에 큰 위협으로, 이를 사전에 예측하는 것은 효과적인 수질관리에 필수적이다. 기존에는 생물학적·물리적 과정을 수식화한 수치모델이 주로 사용되었으나, 복잡한 비생성(非線性) 상호작용을 완전하게 기술하지 못해 한계가 있었다. 최근 들어 데이터 기반 머신러닝 기법들이 이러한 복잡한 패턴을 식별하고 예측하는 대안으로 부상하였다(Lin et al., 2023). 그러나 수질 및 남조류 예측에 사용되는 데이터는 시간 해상도가 낮고 관측 간격이 불규칙하며, 표본 크기가 작고 불균형한 데다가 이상치와 결측치도 빈번하게 포함하는 경향이 있다. 이러한 특성 때문에 매우 많은 데이터를 필요로 하면서 과적합 우려도 큰 딥러닝 모형보다, 트리 기반 앙상블 기법들이 보다 실용적이고 안정적인 대안으로 주목받고 있다(Emami et al., 2025).

1) 수질 예측 데이터 특성과 트리 기반 모델의 적합성

환경부 물환경정보시스템, K-water 댐운영자료, 기상청 등에서 수집되는 수질 및 남조류 예측 자료는 소규모 표본의 정형 데이터(tabular data)인 경우가 많다. 딥러닝은 영상이나 음성처럼 대규모 연속 데이터에서 뛰어난 성능을 보이지만, 이와 달리 이종 변수로 이루어진 소규모 표본 데이터에서는 성능 우위가 불확실하다. 실제로 Grinsztajn et al. (2022)의 광범위한 벤치마크에 따르면 표본 크기가 중간 정도(예: 1만 행 내외)인 탐지/예측 문제에서는 트리 기반 모델이 여전히 최고 성능을 유지하며, 이는 딥러닝이 이러한 이질적 특성과 작은 데이터에서 적절한 규칙성을 학습하기 어려운 데 기인한다고 보고된다(Grinsztajn et al., 2022).

한편 트리 앙상블 기법인 GBDT(Gradient Boosting Decision Tree)는 데이터가 작을 때도 안정적인 예측력을 보여주는데, 작은 데이터셋에서는 GBDT 계열이 일반적으로 최적의 성능을 내고, 딥러닝은 충분히 큰 데이터 수가 확보되어야 우수성이 나타난다고도 알려져 있다(Emami et al., 2025). 이러한 결과는 대청댐 녹조 예측과 같이 이용 가능한 학습데이터가 제한적인 문제에 트리 기반 모델이 적합한 이유를 뒷받침한다. 또한 트리 모델은 데이터의 분포나 형태에 대한 가정이 거의 없고 순전히 관측된 패턴에 따라 학습하므로, 복잡한 수질 생태 시스템에서도 높은 적응성을 가지고 작은 규모의 문제에도 적용 가능하다는 장점이 있다(Derot et al., 2020).

2) 결측치, 이상치 및 데이터 불균형에 대한 강건성

수질 환경 데이터에는 종종 센서 고장이나 채수 간격 차이로 결측치가 발생하고, 극한 강우나 오염 사고 등으로 이상치가 포함되며, 남조류 대발생 현상처럼 관심 대상 현상은 드물게 나타나 레이블 불균형이 심한 경우가 많다. 트리 기반 모델은 이러한 문제에 대하여 비교적 견고한 내성을 갖는다. 예를 들어, XGBoost 모델은 학습 과정에서 자동으로 분할 노드별 결측치 처리 방향을 학습하여 결측값을 효과적으로 처리할 수 있고, LightGBM이나 CatBoost 등도 별도의 전처리 없이 결측치를 다룰 수 있는 기능을 제공한다. 반면 딥러닝 모델은 결측치에 직접

대응하지 못해 사전에 보간이나 대체 등의 추가 조치가 필요하다. 이상치와 노이즈에 대해서도 트리 앙상블은 강건성을 보이는데, 노드 분할을 통해 국소적인 임계치 기준으로 학습하므로 극단값에 크게 영향을 받지 않는다(Molares-Ulloa et al., 2024). 실제 연구에서도 XGBoost 모델이 LSTM보다 노이즈에 대한 민감도가 낮아 예측 안정성이 높았다는 보고가 있으며, 랜덤 포레스트는 부스팅 계열 기법보다도 노이즈에 강인하고 과적합을 잘 피하는 안정적인 성능을 보여주는 것으로 나타났다. 또한 트리 모델은 불균형한 데이터셋에서도 클래스 가중치 부여나 앙상블 기법(Bagging, Boosting 등)으로 개별 약한 모델의 편향을 상쇄함으로써 비교적 우수한 성능을 발휘할 수 있다(Ahn et al., 2023). 전반적으로 트리 기반 방법은 결측 데이터나 이상치에 크게 성능 저하를 보이지 않고, 데이터 분포가 한쪽으로 치우친 상황에서도 강건한 예측을 제공하는 것으로 문헌에서 반복 확인되고 있다.

3) 변수 간 비선형 관계 및 상호작용 탐지

녹조 발생에는 수온, 영양염류(TN, TP), 일사량, 강우량 등 다양한 인자가 복합적으로 작용하며 이들의 관계는 명백한 선형성이 없고 고차원의 비선형 상호작용을 띨 가능성이 높다(Lin et al., 2023). 트리 기반 모델은 이러한 비선형 패턴과 변수 상호작용을 효과적으로 포착하는 강점을 갖는다. 의사결정나무는 특징 공간을 반복적으로 분할하여 국지적인 규칙을 학습하므로, 변수들 간의 곱이나 비 등 복잡한 조합 효과도 트리 분기 구조 속에서 자연스럽게 표현된다. 예를 들어, 랜덤 포레스트는 변수들 사이의 상관관계나 상호작용을 자동으로 고려하면서 학습하며, 남조류와 환경인자 간 비선형 관계를 모형에 잘 반영하는 것으로 보고되었다. Derot et al. (2020)은 RF를 활용한 연구에서 “RF 모델은 선행 가정이 없어 복잡한 비선형 과정을 잘 모사하고, 변수들 간의 상호작용도 반영할 수 있다”고 강조하였으며, 실제로 다양한 수질 예측 연구에서 RF와 GBM 계열 모델이 남조류 농도나 Chlorophyll-a 변동의 고차 상관성을 성공적으로 학습하여 높은 예측 정확도를 달성했다(Derot et al., 2020). 반면 딥러닝 신경망은 이론적으로 복잡한 함수를 근사할 수 있지만, 충분한 데이터가 없는 상황에서는 이러한 비선형 상호작용을 학습시키기 어려워 성능이 불안정해질 수 있다. 요컨대, 트리 기반 모델은 남조류 예측에 내재한 복잡한 비선형 인과관계 탐지에 유리한 것으로 알려져 있다(Prokhorenkova et al., 2018).

4) 트리 모델의 실용성과 해석 용이성

트리 기반 예측 모델을 현장에 적용할 때의 실용적인 이점도 무시할 수 없다. 첫째, 모델 튜닝과 학습 효율 측면에서 트리 앙상블이 우위에 있다. 딥러닝은 신경망 구조 설계, 층수 및 뉴런 수 결정, 학습률 및 최적화 기법 등 조율해야 할 하이퍼파라미터가 매우 많고 최적값 탐색에 많은 시간과 자원이 소요된다. 반면 랜덤 포레스트나 XGBoost는 트리 깊이, 학습률, 트리 개수 등 몇 가지 핵심 파라미터만으로도 성능을 조절할 수 있고, 기본 설정만으로도 비교적 안정된 결과를 얻는 경우가 많다. 예를 들어 CatBoost는 특별한 카테고리형 처리와 Ordered

Boosting 기법으로 과적합을 억제하여, 복잡한 튜닝 없이도 다양한 데이터셋에서 최상급 성능을 보이는 것으로 보고되었다(Prokhorenkova et al., 2018). 둘째, 학습 및 예측 속도 측면에서 트리 모델이 유리하다. Ahn et al.(2023)의 연구에서 XGBoost 모델이 동일한 데이터를 학습할 때 LSTM보다 훨씬 짧은 시간 내에 훈련을 완료하면서도 예측 정확도는 더 높게 나타났으며, Trizoglou 등(2021) 역시 트리 기반 모델이 신경망 대비 학습 속도가 빠르고 대규모 연산 자원이 없어도 동작 가능함을 보여주었다. 셋째, 모델 해석 가능성에서 트리 기반 방법이 상대적으로 장점을 가진다. 딥러닝은 높은 복잡성으로 결과에 대한 원인 해석이 어려운 블랙박스인 반면(Mermer et al., 2024), 트리 모델은 변수 중요도(feature importance), 분할 조건 등을 통해 어느 변수가 예측에 얼마나 기여했는지 직관적으로 파악하기 쉽다. 예를 들어, Jeong et al. (2022)은 한국의 8개 저수지를 대상으로 RF와 XGBoost로 남조류 발생을 예측하면서 SHAP 값으로 각 수질 변수의 중요도를 산정하여 수온, 총질소, 총인 등이 남조류 증식에 가장 영향을 미치는 요인임을 확인하였다 . 이처럼 트리 앙상블은 모델 결과에 대한 해석을 제공함으로써 관리 의사결정에 신뢰도를 부여할 수 있다는 실용적 장점이 있다(Mermer et al., 2024). 마지막으로, 트리 기반 모델은 구현과 배포가 비교적 간편하다. 딥러닝 모델은 복잡한 연산으로 인한 유지보수 부담과 재현성 문제가 있지만, 트리 모델은 구조가 비교적 단순하고 다양한 라이브러리 지원이 잘 되어 있어 예측 시스템에 쉽게 통합할 수 있다.

5.1.3 트리 기반 예측모델의 한계와 시계열 구조 보완 전략

1) 트리 기반 머신러닝 모델의 구조적 한계

Random Forest, GBM(Gradient Boosting Machine), XGBoost와 같은 트리 기반 머신러닝 모델은 다수의 입력 변수 간 비선형 관계와 상호작용을 효과적으로 학습할 수 있어 수질·기상·운영 변수들이 복합적으로 작용하는 녹조 예측 문제에 적합한 예측기로 널리 활용되고 있다. 그러나 이러한 모델은 기본적으로 각 관측 시점의 입력 벡터가 서로 독립적으로 주어졌다는 가정에 따라 학습되므로, 시계열 데이터가 내재적으로 갖는 시간적 연속성(time continuity)과 자기상관(auto-correlation) 구조를 명시적으로 반영하지 못한다는 한계를 가진다.

특히 녹조와 같은 수질 시계열은 단일 시점의 외생 조건보다는 과거 상태의 누적 효과와 관성에 의해 현재 상태가 결정되는 경우가 많다. 그럼에도 불구하고 원시 시계열을 그대로 트리 모델에 입력할 경우, 모델은 이러한 시간 의존성을 “서로 다른 시점의 독립 관측치”로 해석하게 되어, 예측 성능과 일반화 능력에 제약이 발생할 수 있다. 또한 공간적으로 분산된 관측 지점(예: 상류~하류, 인접 호소 또는 취·정수 지점) 간의 상호작용 역시 트리 모델이 직접적으로 학습하기 어렵다. 그래프 신경망(GNN)과 같은 시공간 특화 모델을 적용할 수도 있으나, 본 연구 대상과 같이 관측 지점 수가 제한적이고 관측자료의 시간해상도가 낮은 경우에는 오히려 모델 학습의 불안정성과 과적합 문제가 발생할 가능성이 있다. 이에 따라 본 연구에서는 복잡한 그래프 구조를 도입하지 않고도, 피처엔지니어링을 통해 시공간 의존성을 일부 반영하는 실용적 대안을 채택하였다.

2) Lag 변수 도입을 통한 시·공간적 의존성 반영

트리 모델의 시간적 한계를 보완하기 위해, 본 연구에서는 자기회귀 변수(LDV: Lagged Dependent Variable)와 외생변수의 시간 지연(lag-k) 변수(Lagged Exogenous Variable)를 입력변수로 포함하였다. 이는 전통적인 ARX/ARIMAX 모델의 개념을 머신러닝 환경에서 피처엔지니어링 형태로 구현한 것으로, 예측 문제를 식(5.1)과 같은 NARX(Nonlinear Autoregressive with Exogenous Inputs) 구조로 확장한다.

$$y_{t+h} = F\left(y_t, y_{t-1}, \cdots, y_{t-p}, \mathrm{X_t}, \mathrm{X_{t-1}}, \cdots, \mathrm{X_{t-q}}\right) + \varepsilon_{t+h} \qquad \text{식(5.1)}$$

여기서, y_{t+h}는 h-step ahead 예측 대상(남조류 세포수), y_{t-p}는 종속변수의 과거값(LDV), $\mathrm{X_{t-q}}$는 기상·수질·유량·운영량 등 외생변수의 시간 지연 값, $F(\cdot)$는 트리 기반 머신러닝 모델이 근사하는 비선형 함수이다.

이와 같은 구조에서 LDV는 녹조 시계열의 관성, 추세, 계절성을 직접적으로 반영하는 핵심 변수로 작용하며, 외생변수 lag는 외부 요인의 지연 효과(delay effect)를 모델 입력에 명시적으로 포함시키는 역할을 한다. 특히 상류 관측지점의 수질·유량 정보나 과거 강우·방류 이력은 일정한 시간 지연 후 하류 지점의 녹조 상태에 영향을 미칠 수 있으므로, 이를 lag 변수 형태로 포함함으로써 공간적 의존성을 시간 지연으로 치환하여 간접적으로 반영할 수 있다. <그림 5.4>는 lag 변수 도입에 따라 동일 지점의 과거 상태는 시간적 의존성을, 상·하류 또는 인접 지점의 과거 상태는 공간적 의존성을 간접 반영하는 개념을 나타내고 있다.

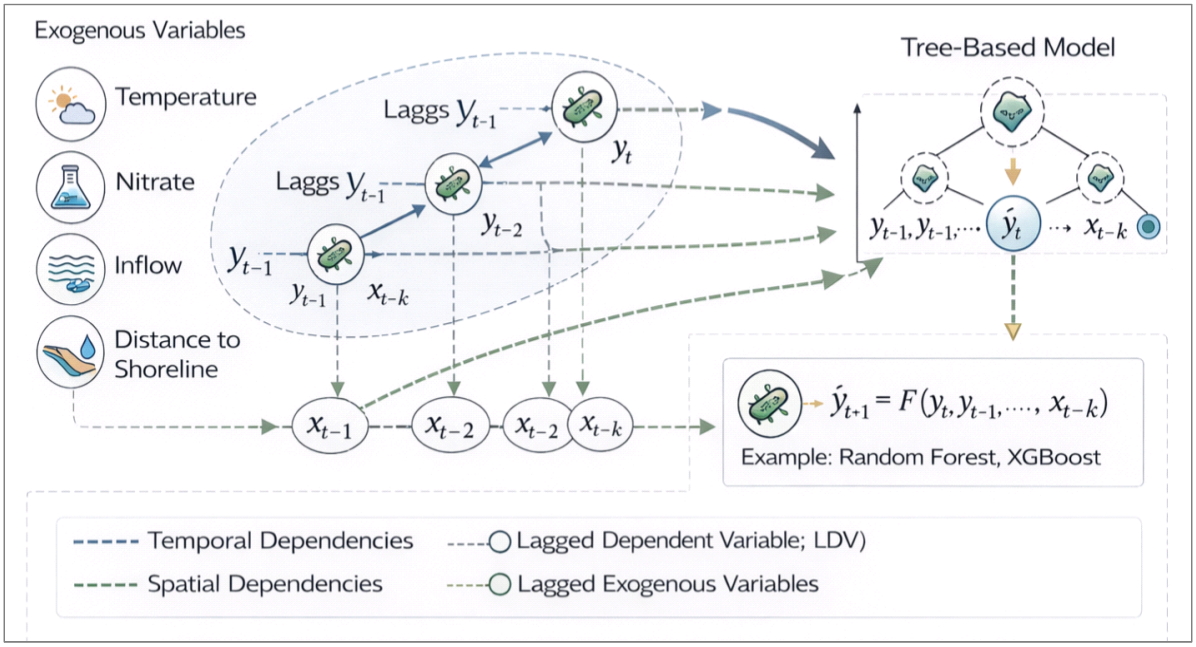

<그림 5.4> 지연변수 도입에 따른 시·공간적 의존성 반영 개념

출처: ChatGPT 5.2(GPT Image 1.5)로 생성한 이미지임

이러한 접근은 그래프 구조를 명시적으로 정의하지 않아도 되므로 계산 비용이 낮고, 자료 해상도가 낮은 환경에서도 안정적으로 적용 가능하다는 장점이 있다. 또한 트리 모델의 특성상 변수 기여도(feature importance)를 통해 어떤 지점의 어떤 lag가 예측에 기여하는지 해석 가능하다는 점도 실무적인 활용성을 높일 수 있다.

3) LDV 도입의 효과와 첨두값 예측 지연(lagging) 문제

가. LDV 도입에 따른 예측 성능 향상 메커니즘

LDV를 포함한 예측 구조는 일반적으로 단기 예측성능을 크게 향상시키는 것으로 알려져 있다. 실제로 남조류 세포수와 같은 수질 시계열은 강한 자기상관 구조를 가지므로, 전 시점 또는 수 주 전의 관측값은 현재 상태를 설명하는 데 매우 높은 정보량을 제공한다. 이에 따라 LDV는 다수의 예측 사례에서 가장 높은 변수 기여도를 차지하는 핵심 변수로 나타난다. 수식적으로 볼 때, LDV가 포함되지 않은 모델은 식(5.2)와 같은 형태로 표현된다.

$$y_{t+h} = F(\mathrm{X_t}, \mathrm{X_{t-1}}, \cdots) + \varepsilon_{\mathrm{t+h}} \qquad \text{식(5.2)}$$

반면 LDV를 포함할 경우는 식(5.3)과 같이 확장되며, 이는 시계열을 감독학습(supervised learning) 문제로 변환하는 핵심 단계로 해석할 수 있다. 이 과정에서 모델은 별도의 시계열 구조를 학습하지 않더라도, 입력 변수를 통해 시계열의 관성과 누적효과를 직접 활용할 수 있게 된다.

$$y_{t+h} = F(y_t, y_{t-1}, \cdots, X_t, X_{t-1}, \cdots) + \varepsilon_{t+h} \qquad \text{식(5.3)}$$

나. 첨두값 예측에서의 lagging 현상

그러나 LDV에 대한 높은 의존성은 특정 상황에서 예측의 한계를 초래할 수 있다. 특히 녹조 대발생과 같은 첨두값(peak) 또는 급격한 상태 전이 구간에서는, 모델이 과거의 비교적 완만한 값에 기반하여 미래를 예측함으로써 실제 발생 시점보다 늦게 반응하는 예측 지연(lagging) 현상이 나타날 수 있다. 이는 트리 모델이 손실함수(RMSE 등)를 최소화하는 과정에서 평균적 패턴을 우선적으로 학습하는 경향과, LDV가 강한 관성 신호로 작용하여 급격한 변화보다는 직전 상태를 지속적으로 추종하도록 모델을 유도하는 특성이 결합된 결과로 해석할 수 있다.

이러한 한계에도 불구하고, 본 연구의 대상 자료 특성(관측지점 수 제한, 주간 단위 시간해상도, 장기간 시계열)을 고려할 때, lag 기반 피처엔지니어링은 시·공간 의존성을 반영하는 가장 현실적이고 재현성 높은 접근으로 판단된다. <표 5.1>은 본 연구에서 적용한 lag 기반 피처엔지니어링 전략의 장점과 한계를 요약한 것이다.

<표 5.1> Lag 기반 피처엔지니어링을 통한 시공간 의존성 반영의 장점과 한계

구 분	내 용
장점	▸ 그래프 모델 없이도 시간·공간 의존성 일부 반영 가능 ▸ 계산량이 적고 저해상도·불규칙 시계열 자료에 적용 용이 ▸ 변수 중요도 분석을 통한 설명력 확보
한계	▸ 모든 지점 간 관계를 고정된 lag로 정의해야 함 ▸ lag 범위 확장 시 변수 수 급증으로 과적합 위험 증가 ▸ 유속·거리·연결성 등 물리적 네트워크 구조를 직접 반영하기 어려움
해석적 제약	시간 변수와 공간 변수가 결합된 고차 상호작용 패턴을 고려하기 어려움 ※ 예: 상류 이틀 전 강우 × 현재 수온을 제한적으로만 학습

다. Lagging 문제의 구조적 해석

중요한 점은 이러한 lagging 현상이 LDV 자체의 오류라기보다는, LDV가 제공하는 정보의 성격(level information)에서 기인한다는 점이다. LDV는 시계열의 절대 수준과 상태를 잘 설명하지만, 변화의 속도나 방향에 대한 정보는 제한적으로만 제공한다. 따라서 첨두값 예측에서의 lagging 문제는 단순히 LDV의 개수를 줄이거나 제거하는 방식으로 해결하기보다는, LDV가 제공하는 수준(level) 정보와는 다른 차원의 정보를 추가적으로 제공함으로써 완화하는 것이 바람직하다.

4) 차분 변수를 활용한 첨두값 예측 지연 문제의 개선

가. LDV 기반 예측에서 첨두값 지연 현상의 원인

앞선 장에서 논의한 바와 같이, 종속변수의 자기회귀 변수(LDV)를 포함하는 NARX형 트리 모델은 녹조 시계열의 관성(inertia)과 누적효과를 효과적으로 학습할 수 있으나, 급격한 상태 변화가 발생하는 구간에서는 예측 결과가 실제 관측값을 후행(lagging) 하는 문제가 관찰될 수 있다. 이를 수식적으로 단순화하면, LDV 중심의 예측 구조는 식(5.4)와 같은 형태로 이해할 수 있다.

$$\widehat{y_{t+1}} \approx f\left(y_{t,}\, y_{t-1},\, \cdots\right) \qquad \text{식(5.4)}$$

이때 $y_t \approx y_{t-1} \approx \cdots$ 인 정상 상태 구간에서는 높은 예측 정확도를 보이지만, $y_t \gg y_{t-1}$과 같은 급격한 증가 국면에서는 모델이 수준(level) 정보에 과도하게 의존하여 변화 속도를 충분히 반영하지 못하게 된다. 즉, LDV는 “현재 상태가 어디에 있는가”에 대한 정보는 풍부하게 제공하지만, “상태가 얼마나 빠르게 변화하고 있는가”에 대한 정보는 상대적으로 부족하므로 녹조 대발생과 같은 첨두 구간에서 예측 시점이 실제 발생 시점보다 지연되는 구조적 한계가 발생한다.

나. 차분 변수의 개념과 도입 원칙

본 연구에서는 LDV 기반 예측에서 발생할 수 있는 첨두값 예측 지연 문제를 완화하려는 방안으로 차분(differencing) 변수를 선택적으로 도입하였다. 차분 변수는 시계열의 절대 수준이 아닌 변화량(increment) 또는 기울기(slope) 정보를 반영하므로, 급격한 증가 또는 감소 국면을 조기에 포착하는 데 유리하다. 종속변수와 외생변수에 대한 차분은 식(5.5)과 같이 정의된다.

(종속변수 차분, ΔLDV) $\Delta y_{t-1} = y_{t-1} - y_{t-2}$ 식(5.5a)

(외생변수 차분, ΔX) $\Delta x_{t-k} = x_{t-k} - x_{t-k-1}$ 식(5.5b)

식(5.5a)는 시점 t-1에서의 증가 또는 감소 방향과 크기를 나타내며, LDV가 제공하지 못하는 변화 속도 정보를 모델에 명시적으로 전달한다. 필요에 따라 고차 차분도 정의할 수 있으나, 본 연구에서는 해석 가능성과 안정성을 고려하여 종속변수(LDV)에 대해서는 1차 차분을 기본으로 사용하고 최근 시점(lag-0~1)의 차분변수만 도입하여, 녹조 증식의 초기 가속 구간을 민감하게 반영하도록 하였다.

반면 외생변수의 경우는 식(5.5b)과 같이 기본적으로 종속변수 y와의 공간적 의존성에 따라 연관성이 높은 특정 lag가 존재할 경우 해당 차분할 변수 및 lag를 선택적으로 적용할 수 있다. 다만 과도하게 많은 변수 설정으로 정보 중복과 노이즈 증폭을 초래할 위험이 있으므로, 외생변수의 물리적·생태학적 성격에 따라 차분 변수(Δx)의 적용 적합성을 고려해 lag-0에 한해 차분 변수를 반영하도록 하였다.

<표 5.2> 외생변수 유형별 차분 적용의 적합성 및 물리적 의미

변수 유형	대표 변수 예시	적용성	물리적 의미
변화 자체가 중요한 동적 변수	강우량, 유입량, 방류량, 수위, 유속	매우 높음	절대 수준보다 증가·감소의 발생과 크기가 시스템 반응을 유발함. 급격한 변화가 녹조·홍수·수질 악화의 직접적 트리거로 작용
수준(level)이 본질적으로 중요한 화학·수질 변수	수온, 풍속, 일사량, 탁도	높음	단기 변동이 생물학적 반응 속도(성장·혼합·확산)에 직접적 영향. Δx는 변화율(gradient) 정보를 제공
	TP, TN, DTN, DTP	중간	농도 자체가 제한요인으로 작용. 다만 Δx는 축적/소모 국면 전환 신호를 보완적으로 제공
완만한 변화 또는 누적 반응 변수	pH, DO	중간	생태계 임계값과 직접 연결. 단기 차분은 노이즈가 될 수 있으나, 급변 시 조기경보 신호로 활용 가능
	COD, BOD	중간	장기 추세는 수준 정보가 핵심이나, 오염 유입 시 Δx가 사건(event) 탐지에 기여
	염분, 전기전도도(EC)	낮음~중간	비교적 안정적이며 누적 특성이 강함. Δx는 미세 변화 감지에는 유용하나 필수는 아님
	클로로필-a	낮음~중간	단기 변동은 관측 노이즈 성격이 강하나, 증식 초기 국면에서는 Δx가 보조지표로 작동 가능

<표 5.2>는 녹조 예측의 주요 외생변수별 차분 적용의 적합성을 정리하여 나타낸 것으로, 강우량, 유입량, 수위와 같이 변화 자체가 시스템 반응을 유발하는 변수들에 대해서는 차분 변수가 필수적인 입력으로 작동하는 반면, 영양염 농도나 pH와 같은 수준(level)이 본질적으로 중요한 변수들에 대해서는 차분 변수를 보조적 피처로 활용하였다.

다. 차분 변수 활용과 효과

차분 변수를 도입과 관련하여 한 가지 중요한 점은 첨두값 지연이 문제가 되었던 원래의 LDV 또는 외생변수의 lag 변수를 차분 변수로 대체하지 않는다는 점이다. 차분 변수는 원래 변수의 수준(level) 정보를 제거하기 위한 것이 아니라, 수준 정보로는 포착하기 어려운 변화율 정보를 추가하기 위한 보완적 목적이기 때문이다. 즉, 모델 입력은 식(5.6)과 같이 구성되며, 이를 통해 <표 5.3>과 <그림 5.5>에 나타낸 것과 같이 LDV와 외생변수의 Lag 변수로 현재 상태의 수준(level) 정보를, 차분 변수로는 상태 변화의 방향과 속도(trend acceleration) 정보를 동시에 활용할 수 있게 된다.

$$Z_t = \left(y_t, y_{t-1}, \ \ldots\ , \Delta y_{t-1}, \boldsymbol{X_t}, \boldsymbol{X_{t-1}}, \ \ldots, \boldsymbol{\Delta X_{t-k}}\right) \qquad \text{식(5.6)}$$

<표 5.3> 지연 변수와 차분 변수의 역할과 보완적 특징

변 수	역 할	특 징	급변/피크 탐지	레벨 안정성
Lag변수	물리·화학적 절대 상태	자기상관, 평상시 예측 우수	둔감	강함
차분 변수	변화 속도, 급변 신호	급변 초기 신호 포착	민감	약함

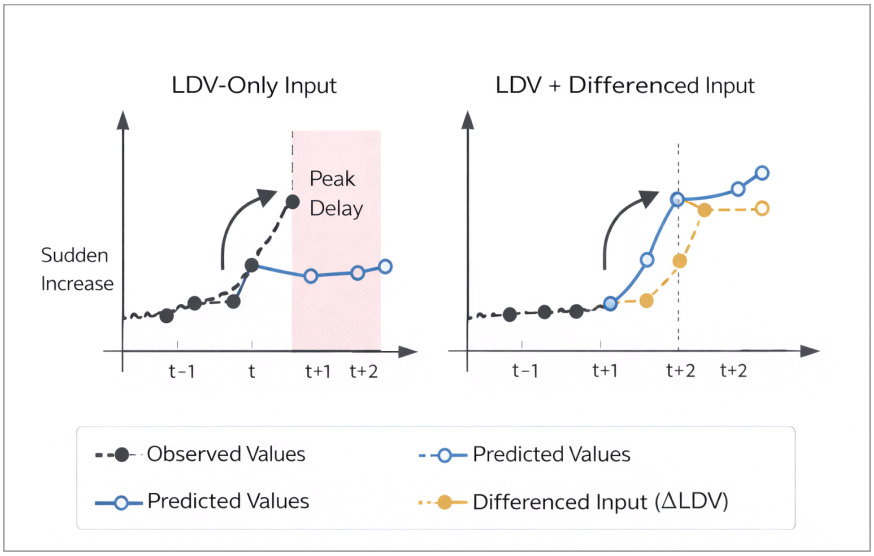

<그림 5.5> LDV 및 LDV+차분 변수 입력 시 예측 반응의 차이

출처: ChatGPT 5.2(GPT Image 1.5)로 생성한 이미지임

위에서 논의한 바에 따라 녹조 예측 트리 기반 머신러닝 모델의 시계열 구조 보완을 위한 피처엔지니어링 적용 절차를 나타내면 <그림 5.6>과 같다.

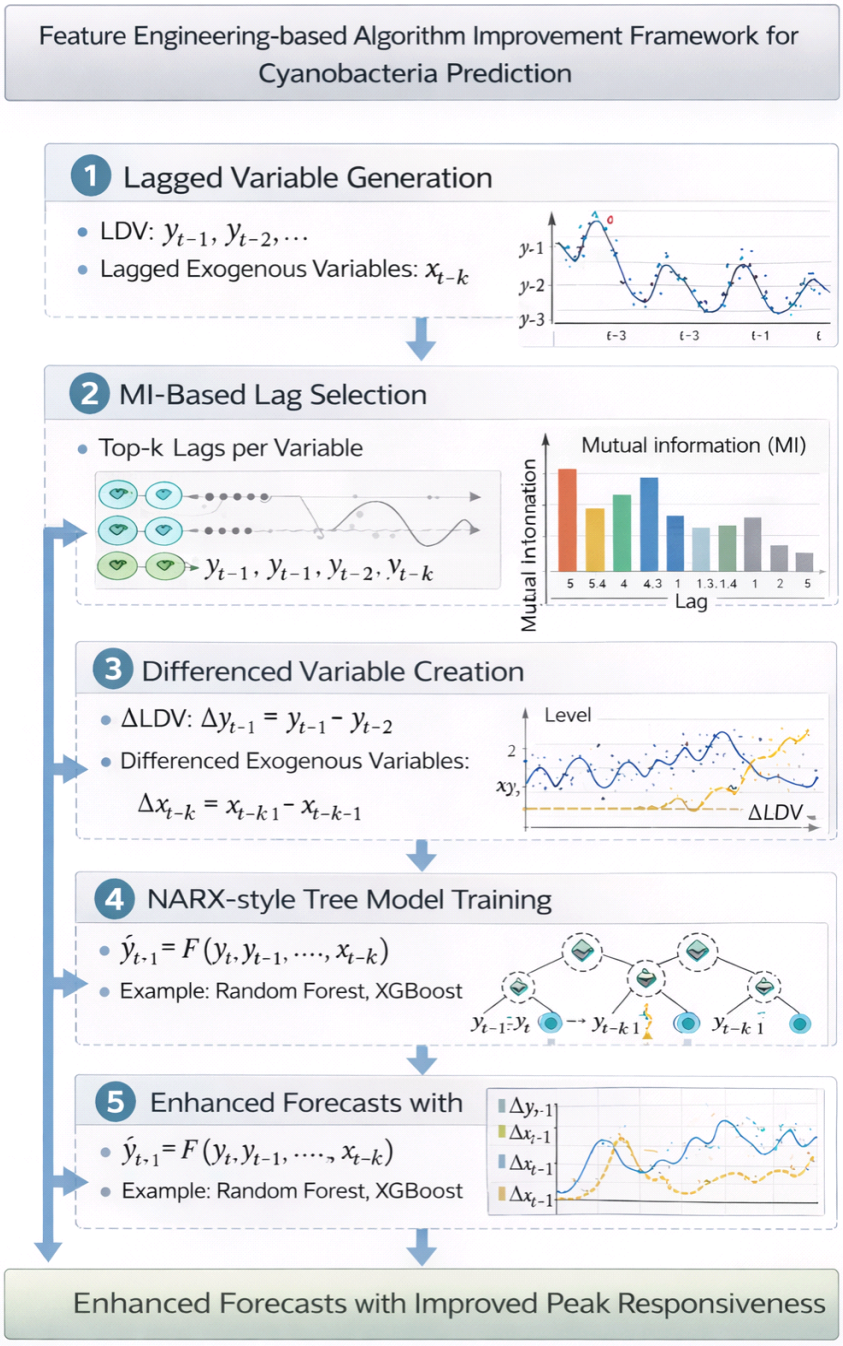

<그림 5.6> 녹조 예측 머신러닝 알고리즘 개선을 위한 피처엔지니어링 적용 절차

출처: ChatGPT 5.2(GPT Image 1.5)로 생성한 이미지임

5.2 관측자료 불균형 해소를 위한 데이터 증강기법

5.2.1 배경 및 필요성

남조류 세포수 데이터셋은 연중 대부분이 저농도 구간으로 고농도 구간의 샘플 비중이 매우 낮은 극단적 불균형 분포를 나타낸다. 일반적인 분류 및 회귀 기반 지도학습 알고리즘은 전체 손실(loss)을 최소화하는 방식으로 학습되므로 불균형한 데이터에서는 다수 구간(majority region)인 저농도 자료의 오차를 줄이는 방향으로 학습하게 되고, 결과적으로 수원 관리상 중요성이 높은 고농도 시점에 대한 예측성능이 낮아지게 된다. 이러한 데이터 불균형(data imbalance)을 완화하기 위해서는 고농도 구간의 샘플 밀도를 보강하는 오버샘플링(oversampling) 기법을 적용하여 모델 학습 시 해당 구간의 기여도를 높이는 접근이 필요하다.

분류형 모델에서는 SMOTE(Synthetic Minority Oversampling Technique), ADASYN(Adaptive Synthetic Sampling)과 같은 오버샘플링 기법이 많이 활용되며, 영상자료 합성에 널리 사용되는 GAN(Generative Adversarial Networks)도 활용되고 있다. 일례로 Jeong et al. (2022)은 XGBoost 모델에 SMOTE를 적용한 오버샘플링을 통해 저수지 남조류 발생 여부를 예측하였으며, Kim et al. (2021)은 ANN 및 SVM 모델에 ADASYN을 적용해 조류 대발생 경보 수준을 예측한 바 있다.

본 연구의 목적은 회귀 기반 머신러닝 모델을 활용하여 남조류 세포수 예측의 연속적, 정량적 변동 특성을 고려하고, 오버샘플링을 통해 고농도 희소 구간의 샘플을 보강하는 것이 예측성능 개선에 효과적인지를 정량적으로 분석하는 데 있다. 이를 위해 환경부의 대청호 조류경보 지점 남조류 세포수 데이터에 SMOGN(SMOT for regression using Gaussian Noise), GAN 및 TimeGAN(Time-series GAN) 등 회귀형 오버샘플링 기법들을 적용해 불균형을 완화하고, 오버샘플링 전후 모델 예측성능이 개선된 결과를 비교하였다. 모델 입력 데이터셋은 남조류 세포수와 주요 영향 인자들에 대해 최대 3주의 지연시간(lag time) 변수를 도입함으로써 녹조 증식 시퀀스가 하나의 데이터 샘플이 되도록 하고, 이를 통해 희소데이터를 합성할 때 시간 의존적 특성을 일부 반영하였다. 오버샘플링에 따른 남조류 세포수 예측모델의 학습력 강화 효과 분석은 트리 기반 앙상블 학습 모델로 대표적인 랜덤포레스트(Random Forest) 모델을 활용하였다.

5.2.2 이론적 배경

1) 데이터 불균형 완화

오버샘플링은 구간별 샘플 수가 불균형한 데이터셋에서 소수 구간(minority region)의 샘플 수를 인위적으로 증가시켜 데이터 분포를 균형 있게 맞추는 통계적 기법이다. 가장 단순한 형태인 무작위 오버샘플링(random oversampling)은 소수 구간 샘플들을 단순 복제하여 그 수를 늘리는 방법으로 구현이 간단하다는 장점이 있지만, 모델이 특정 샘플에 과적합 되기 쉬운 한계가 있다. 이러한 한계를 극복하기 위해 단순 복제 대신 합성 데이터(Synthetic Data)를 생성하는 혁신적인 접근법들이 다수 등장했다(Chawla et al., 2002).

가. SMOGN

대부분의 오버샘플링 기법이 불균형 분류 문제를 다루지만, SMOTE-R(SMOTE for Regression)은 불균형 회귀 문제에 특화된 오버샘플링 기법이다. 분류 문제의 불균형이 불연속적인 클래스 간의 샘플 수 차이를 의미한다면, 회귀 문제의 불균형은 연속적인 목표변수(Y)의 값 분포가 특정 희소 구간(rare region)에 치우쳐져 있는 상태를 의미한다. 희소하지만 예측이 매우 중요한 의미가 있는 문제에서 SMOTE-R과 같이 불균형 회귀 문제에 특화된 방법론의 효용성은 매우 높다.

SMOGN(SMOTE for regression with Gaussian Noise)은 SMOTE-R에 가우시안 노이즈를 결합한 하이브리드 알고리즘이다(Branco et al., 2017). 이 기법은 원본 데이터에서 선택된 두 샘플 간의 거리를 기준으로 데이터 합성 방식을 결정한다. 만약 두 샘플 간의 거리가 가까워 보간이 적절하다고 판단되면 SMOTE-R을 사용하여 선형 보간을 수행한다. 반면, 거리가 멀어 단순 보간이 부적절하다고 판단되면 가우시안 노이즈를 추가하여 새로운 샘플을 생성한다. 이는 단순히 보간하는 것을 넘어 데이터 분포의 희소 구간을 효과적으로 채우려는 시도로, 회귀 문제의 연속적인 특성을 고려한 독창적인 접근법이다(Branco et al., 2017).

나. GAN

GAN은 생성자(generator)와 판별자(discriminator)라는 두 개의 신경망이 서로 경쟁하며 학습하는 적대적 학습 체계를 갖추고 있다(Goodfellow, 2020). 생성자는 무작위 노이즈 벡터를 입력받아 실제 데이터와 구별할 수 없을 만큼 현실적인 가짜 데이터를 생성하려고 시도하며, 판별자는 실제 데이터와 생성자가 만든 가짜 데이터를 입력받아 어떤 것이 진짜인지 판별한다. 이 경쟁적인 학습 과정에서 생성자는 판별자를 속이려 하고, 판별자는 속지 않으려 하는 상호작용이 반복된다. 이러한 적대적 관계를 통해 두 신경망은 점진적으로 발전한다. 생성자는 실제 데이터의 복잡한 분포를 충실히 모방하는 데이터를 만들어내고, 판별자는 가짜와 진짜를 더욱 정교하게 식별하는 능력을 갖추게 된다. 이러한 분석체계는 고품질의 현실적인 데이터를 대량 생성할 수 있어, 데이터 희소성 및 불균형 문제 완화 등 강력한 데이터 증강(Data Augmentation) 도구로 활용되고 있다.

다. TimeGAN

시계열 데이터는 이미지 같은 정적 데이터와 달리 시간 의존성(temporal dependency)과 동역학(dynamics)이라는 고유한 특성이 있다. 단순히 통계적 특성만 유사하게 만드는 것을 넘어, 시간 흐름에 따른 데이터의 인과관계와 패턴을 보존하는 것이 시계열 데이터 오버샘플링의 핵심 과제이다. 기존의 GAN은 합성 데이터를 생성할 때 이러한 시간적 동역학을 고려하지 않는 문제가 있었다. 이러한 문제를 해결하기 위해 TimeGAN(Time series GAN)은 지도 학습 손실(Supervised Loss)과 비지도 학습 손실(Unsupervised Loss)을 결합한 분석체계를 제안했다(Yoon et al., 2019).

TimeGAN은 GAN과 마찬가지로 비지도 학습 손실을 통해 잠재공간 상에서 실제 데이터 분포의 유사성을 보존함으로써 합성된 시퀀스와 실제 시퀀스를 구별할 수 없도록 만들지만, 지도 학습 손실까지 포함해 시계열의 시간 의존성과 동역학적 구조를 보존한다. 즉, 생성자는 모델이 각 시간 단계에서 다음 단계의 조건부 분포(conditional distribution)를 명시적으로 학습하도록 지도한다. 이는 단순히 '진짜처럼 보이는' 시퀀스를 만드는 것을 넘어 현실의 데이터가 시간에 따라 변화하는 규칙을 내재화해, 단순히 노이즈 주입이나 시간 축 이동(time shift) 같은 기법으로는 불가능한 복잡한 시계열 데이터도 합성할 수 있도록 훈련하는 것이다.

2) 학습력 강화 효과 분석 모델

오버샘플링에 따른 머신러닝 모델의 학습력 강화 효과 분석을 위해서는 다양한 분류 및 회귀 문제에서 널리 활용되는 랜덤포레스트 모델을 선정하였다. 대표적 트리 기반 모델인 랜덤포레스트는 강건성(robustness)이 높아 안정적인 예측 성능을 발휘하는 것으로 알려져 있으며(Sun et al., 2025), 변수 중요도(feature importance)를 통해 결과에 대한 설명력을 제공한다. 특히, 변수 간 상호작용이 복잡하고 비선형성이 강한 녹조 발생 특성을 고려하면 랜덤포레스트는 부트스트랩(Bootstrap) 샘플링과 무작위 변수 선택을 통해 트리 간 상관성을 낮추므로(Breiman, L., 2001) 트리 기반 앙상블 모델 중에서도 과적합 위험이 적은 장점이 있다. 랜덤포레스트 모델의 회귀 문제 예측은 식(5.7)과 같이 주어진다.

$$\hat{y}(x) = \frac{1}{B}\sum_{b=1}^{B} T_b(x) \qquad \text{식(5.7)}$$

여기서, B는 트리 개수, T_b는 서로 다른 부트스트랩 표본과 무작위 변수 선택으로 학습된 트리이다. 또한, x는 녹조 발생에 영향을 미치는 환경요인으로 구성된 입력 벡터를 의미하며, $\hat{y}$는 해당 입력 조건에 대해 모델이 최종적으로 예측한 남조류 세포수를 의미한다.

3) 성능 평가 지표

본 연구에서는 오버샘플링에 따른 랜덤포레스트 모델의 성능 개선을 다각적으로 평가하기 위해 식(5.2)~(5.5)와 같이 수문·수질 분야에서 널리 사용하는 네 개의 성능 지표를 병행 산정하였다. 여기서, n은 전체 샘플의 수를 의미한다. 각 지표는 예측 정확도 및 모형 특성을 다른 관점에서 설명하므로, 단일 지표로만 평가할 때 나타날 수 있는 편향적인 해석을 방지할 수 있다.

RMSE(Root Mean Squared Error)는 관측값과 예측값의 절대적 오차의 크기를 원자료와 동일한 단위로 나타내므로 모델의 평균적 오차 규모를 설명할 수 있으나, 제곱을 취함에 따라 오차의 크기에 민감하고, 값 자체만으로는 단위가 다른 데이터 간 비교에 한계가 있다. 이에 반

해 NSE(Nash-Sutcliffe Efficiency)는 관측값의 변동성을 기준으로 모델의 설명력을 비율 형태로 제시함으로써 단순히 평균값으로 예측하는 것보다 어느 정도 효율적인지를 정량적으로 판단할 수 있게 한다(Moriasi et al., 2007). NSE 값이 크면 모형이 시간적 변동 패턴을 적절히 재현하고 있음을 의미하므로, 시계열적 구조를 갖는 수문·수질 예측에서 특히 중요한 평가 기준이다.

한편, PBIAS(Percent Bias)는 관측값과 예측값의 오차의 합을 관측값의 합에 대한 백분율로 나타낸 것으로 부호에 따라 전반적 과대(+) 또는 과소(-) 추정도 알 수 있어 모델의 전반적인 편향성을 파악하기 쉽다. MAPE (Mean Absolute Percentage Error)는 PBIAS와 비슷해 보이지만, PBIAS가 오차 합의 백분율을 계산해 과대/과소가 상쇄되어 개별 샘플의 변동성을 설명하지 못하는 데 반해 각 샘플별 오차 백분율의 절댓값을 평균하므로 샘플별 예측 정확도 자체를 평가할 수 있는 장점이 있다. 그러나 관측값이 0에 근접할 정도로 작은 경우 비율이 무한대로 폭증하는 단점이 있다(Hyndman and Athanasopoulos, 2018). PBIAS도 겨울철 남조류 또는 갈수기 강우량과 같이 관측값 전체 수준이 매우 작다면 비슷한 문제가 나타날 수 있으나, MAPE처럼 단일 샘플 만으로 문제가 발생하지는 않는다.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \quad \text{식(5.8)}$$

$$NSE = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \quad \text{식(5.9)}$$

$$PBIAS = 100 \times \sum_{i=1}^{n}\frac{(\hat{y}_i - y_i)}{\sum_{i=1}^{n} y_i} \quad \text{식(5.10)}$$

$$MAPE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \quad \text{식(5.11)}$$

제 6장 녹조·수질 예측 AI 모델 개발 및 적용

6.1 녹조 영향인자의 특성 및 영향과 상호작용

여름철 호수 및 댐과 같은 정수역에서 Microcystis속 남조류(남조류: cyanobacteria)는 수온 상승과 영양염 증가로 대규모 증식(일명 녹조현상)을 일으키기 쉽다. 이러한 Microcystis 대발생(bloom)에는 수질 및 기상 인자의 복합적인 영향이 작용하며, 각 변수들은 상호작용을 통해 남조류의 성장과 독소 생산을 좌우한다. 아래에서는 여름철 Microcystis 증식에 영향을 주는 주요 물리·화학·기상학적 변수 각각에 대해, (1) Microcystis 생장에 미치는 영향 및 민감도, (2) 다른 변수와의 상호작용 및 해당 변수의 변동 요인, (3) 머신러닝 기반 예측모델 입력변수로서의 중요성(비선형성, 계절성, 상호작용)을 정리하였다.

농업·도시로부터 유입되는 질소(N)와 인(P) 등 영양염 및 유기물은 남조류 생장을 촉진하며, 기후 변화로 인한 고온·강한 일사와 가뭄은 수체의 증발을 증가시키고 층상을 강화하여 남조류에 유리한 환경을 조성한다. 그 결과 조류 증식으로 클로로필-a가 증가하고, 남조류 폐사로 유기물 부하 및 BOD가 증가하여 용존산소 고갈(저산소) 등의 2차 영향이 나타날 수 있다. <그림 6.1>은 이러한 호소의 부영양화와 기후 요인이 남조류 번성에 미치는 영향을 나타낸 것이다.

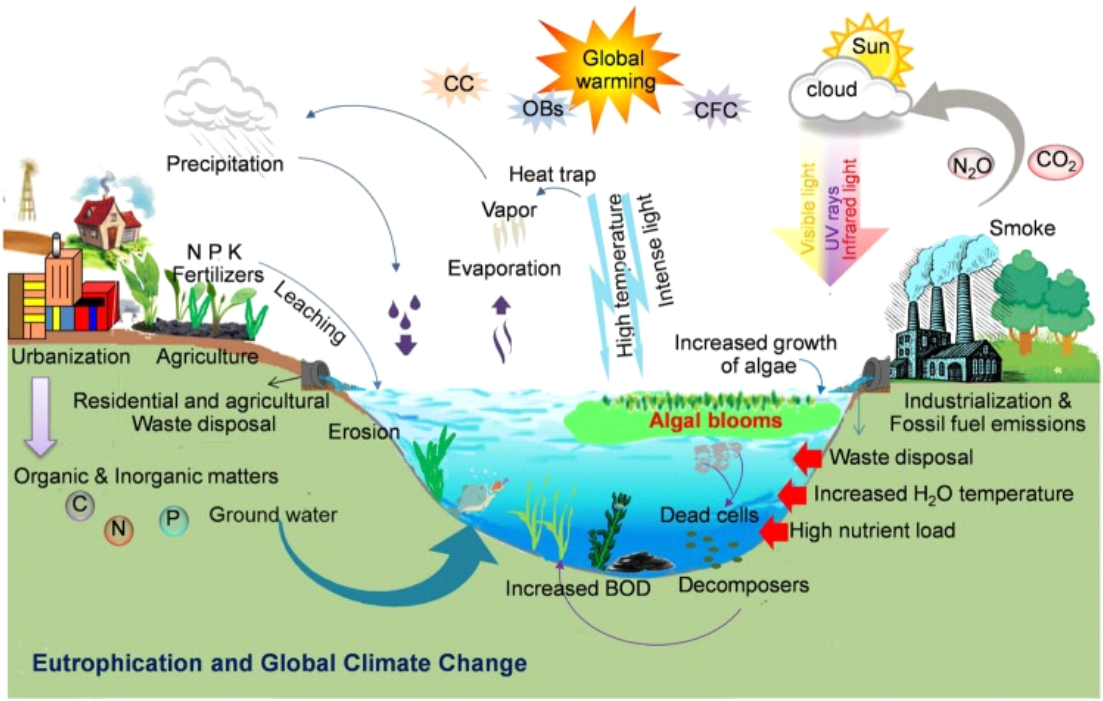

<그림 6.1> 호소의 부영양화와 기후 요인이 남조류 번성에 미치는 영향

6.1.1 수질 인자

1) 클로로필-a (Chl-a)

클로로필-a는 식물플랑크톤, 특히 Microcystis를 포함한 조류의 생물량을 대표하는 지표로서, 농도가 높을수록 조류 증식과 남조류 세포밀도가 큰 것으로 해석된다. 클로로필-a는 마이크로시스틴과 양의 상관관계를 보여 독성위험 평가 및 Microcystis 우점 여부 판단에 간접 지표로 활용되며, 영양염, 일사, 수온 등 다양한 환경조건의 결과를 집약적으로 반영하는 변 수이다. 다만 클로로필-a는 남조류 생장의 원인보다는 결과에 가까운 상태변수로서 인과해석 시 주의가 필요하며, 머신러닝 모델에서는 독립변수로 사용될 경우 남조류 현존량과 계절성을 잘 포착하나, 클로로필-a 자체를 목표변수로 삼을 경우에는 입력변수에서 제외하는 것이 바람직하다.

2) 수온

수온은 Microcystis 생장에 가장 중요한 물리적 요인 중 하나로, 대체로 20℃ 이상에서 성장률이 증가하고 25~30℃ 부근에서 최대 증식이 나타나는 것으로 알려져 있다. 고수온은 광합성과 효소활성을 촉진할 뿐 아니라 규조류 등 경쟁종의 쇠퇴를 유발하여 Microcystis의 상대적 우점을 강화하고, 층상 형성 및 체류시간 증가를 통해 표층 남조류에 유리한 환경을 조성한다. 그러나 수온만으로는 폭발적 증식이 유도되지 않으며, 충분한 질소·인 공급과 결합될 때 고수온 조건이 bloom 발생의 필수 조건으로 작용하고, 예측모형에서는 비선형 임계온도(예: 20℃ 이상) 부근에서 남조류 발생 확률이 급격히 증가하는 형태로 반영된다.

3) 용존산소(DO)

용존산소는 남조류의 직접적인 성장 인자라기보다는 광합성과 호흡에 따른 수체의 대사상태를 나타내는 지표로, 남조류 대발생 시 주간 과포화와 야간 저산소가 반복되는 특성을 보인다. Microcystis는 광합성을 통해 필요한 산소를 자체 생산하므로 DO 농도에 비교적 내성이 높지만, bloom이 지속되면 저층 저산소 및 무산소 상태를 유발하여 내부부영양화(퇴적물로부터 인 용출)를 촉진하고, 이는 다시 영양염 공급 증가라는 간접 경로를 통해 남조류에 유리하게 작용한다. 예측모델에서 DO는 극단구간(과포화 또는 심각한 저산소)에서 남조류 상태를 시사하는 보조지표로 활용될 수 있으나, 시간대·일사 조건에 따라 변동폭이 크므로 측정시점 통일이나 적절한 전처리가 수반될 필요가 있다.

4) 생화학적 산소요구량(BOD)

BOD는 수중 유기물이 미생물 분해 과정에서 소비하는 산소량을 나타내며, Microcystis 자체보다는 남조류 사체 및 기타 유기물 축적 이후 분해과정에서 사후적으로 상승하는 특성이 강하다. 남조류 대발생 후 사멸·침강된 조류 및 외부 유기오염원이 많을수록 BOD가 상승하여 저층 DO 고갈과 내부 인 용출을 심화시켜 부영양화 악순환을 유발할 수 있다. 예측모델에서는 BOD가 필수 변수는 아니나, 예외적으로 높은 BOD 값은 최근 대량 조류 분해나 외부 유기오

염 사건을 시사하는 보조지표로 활용될 수 있으며, 다만 측정의 번거로움과 영양염 변수와의 중복성 때문에 변수선택 시 정보 이득을 신중히 판단해야 한다.

5) 화학적 산소요구량(COD)

COD는 수중 유기물과 일부 무기 환원성 물질을 화학적으로 산화할 때 필요한 산소량으로, 일반적으로 유기오염 및 부영양화 정도를 나타내는 지표이다. Microcystis bloom 수역에서는 조류 세포 및 분비물에 의해 COD가 상승하나, 강우 유입 토사 등 비조류성 부유물 증가에 따른 COD 상승은 탁도 증가와 광감소를 통해 오히려 남조류 성장에 부정적 영향을 줄 수 있다. COD는 TOC, BOD 등과 상관성이 높고 난분해성 유기물(cDOM) 등에 대한 정보도 포함하므로, 모델에서는 비선형·임계특성을 가진 간접 수질지표로 활용될 수 있으나 단독 영향력은 제한적이며, 다른 핵심 변수와의 조합을 통해 해석력을 보완하는 수준에서 이용하는 것이 적절하다.

6) 총유기탄소(TOC)

TOC는 용존 및 입자 유기탄소의 총량으로, 부영양화 및 유기물 부하 수준을 나타내는 지표이다. Microcystis bloom 시기에는 조류 세포 및 분비물에 의해 TOC가 증가하며, 유기물 분해 과정을 통해 장기적으로 질소·인 등의 무기 영양염이 재생되어 남조류에 간접적으로 유리한 조건을 조성할 수 있다. 반면 유기물이 과다하여 수체가 착색·탁해질 경우 광투과가 제한되어 Microcystis 성장에 제약 요소로 작용할 수 있어, TOC는 농도 수준에 따라 양·음의 효과가 공존하는 변수이며, 예측모델에서는 수체 상태를 나타내는 보조 피처로 제한적으로 활용될 수 있다.

7) 전기전도도(EC)

EC는 수중 용존 이온의 총농도를 나타내며, 담수에서 영양염 및 무기염류 농도와 밀접히 연관된 지표이다. Microcystis는 낮은 염분에서는 영양염 부족과, 지나치게 높은 염분에서는 삼투 스트레스로 인해 성장이 제한되며, 일반적인 담수 호소의 EC 범위에서는 직접적인 제한 요인이기보다는 비료성분 유입, 증발 농축, 가뭄·홍수 등 수문·수질 조건 변화를 반영하는 간접지표로 기능한다. 모델에서는 EC가 수온·유량·강수와 함께 환경 맥락을 설명해주는 입력변수로 활용되며, 다른 질소·인 변수와의 상호관계 및 역치 범위를 고려하여 해석할 필요가 있다.

8) 총질소(TN)

TN은 모든 무기·유기 질소 형태의 합으로, 담수 부영양화 및 질소 공급능을 대표하는 핵심 영양염 지표이다. Microcystis는 N_2 고정능이 없어 외부 공급 또는 내부 재순환 질소에 의존하므로, TN 농도가 충분할수록 성장 잠재력이 증가하며, 특히 인이 충분한 조건에서 TN 증가는 남조류 세포량 및 독소 생산 증가로 이어지는 경향을 보인다. 예측모델에서 TN은 TP와 함

께 가장 중요한 설명변수로 작용하며, N:P 비와의 상호작용, 저농도 구간에서의 포화곡선 형태 등 비선형 효과를 통해 남조류 성장 잠재력을 결정하는 핵심 인자로 평가된다.

9) 총인(TP)

TP는 수체의 모든 형태의 인을 포함하는 지표로, 정체성 담수 환경에서 가장 중요한 제한영양염으로 인식된다. TP 농도 증가는 Microcystis 최대 생물량과 클로로필-a 첨두를 상향시키며, 인 저감이 남조류 발생 억제에 가장 효과적이라는 다수 연구 결과와 부합한다. 모델링 관점에서 TP는 장기 부영양화 수준을 대표하는 지수로서 남조류 발생 수용력을 규정하며, 낮은 TP 구간에서 극히 민감한 반응을, 일정 농도 이상에서 포화 경향을 보이는 비선형 관계와 TN과의 상호작용을 함께 반영하는 핵심 입력변수로 활용된다.

10) 용존총질소(DTN)

DTN은 여과 후 용존 상태의 모든 질소를 포함하는 지표로, 실질적으로 남조류가 단기적으로 이용 가능한 질소 가용도를 나타낸다. DTN 중 질산·암모늄 등 용존무기질소(DIN)는 Microcystis 성장률과 가장 직접적인 관련을 가지며, 용존유기질소(DON)는 분해 후 지연된 공급원으로 작용한다. 충분한 DTN 자료가 확보될 경우, 예측모델은 질소의 형태별·시간별 가용성을 정교하게 반영할 수 있어 단기 bloom 예측 성능을 크게 향상시킬 수 있으나, 실측 빈도와 중복성 문제로 실무 적용은 제한적이며, TN과의 보완적 활용이 요구된다.

11) 용존총인(DTP)

DTP는 여과된 용존 상태의 인 총량으로, 대부분 용존무기인(DIP)과 일부 용존유기인(DOP)으로 구성되며, Microcystis에 즉시 또는 단기간 내 이용 가능한 인 공급량을 나타낸다. bloom 시기에는 DIP가 급속히 고갈되어 DTP가 낮은 인 제한 상태가 나타나고, 퇴적물 용출·외부 유입 또는 혼합 등에 의해 DTP가 재상승하면 다시 급격한 증식이 가능해지는 등, DTP는 남조류 성장의 “실효 인 스위치” 역할을 한다. 모델에서 DTP(특히 DIP)를 포함할 수 있다면 인 제한·비제한 상태를 직접적으로 구분할 수 있어 예측 및 인과 해석 측면에서 매우 유리하나, 자료 제약으로 TP 기반 간접 추정이 병행되는 경우가 많다.

12) 수소이온농도(pH)

pH는 담수 중 탄산계 평형, 금속 및 인산의 용해도, 이산화탄소 이용형태 등에 영향을 미쳐 Microcystis 성장에 간접적으로 작용한다. Microcystis는 중성~알칼리성(pH 7~10) 환경을 선호하며, 높은 pH에서는 CO_2 가 감소하고 HCO_3^- 비중이 커지지만 탄소농축기작을 통해 이를 활용할 수 있어 경쟁종 대비 우위를 갖는다. 남조류 대발생 시 낮 시간 pH가 9~10까지 상승하여 타 조류군 및 수생생물에 스트레스를 주고, 인·금속의 화학형 변화를 통해 DIP 가용성을 변화시키는 등 복합적 피드백을 유발하므로, 예측모델에서는 bloom 진행 정도를 나타내는 결

과지표이자 비선형 임계특성을 가진 환경변수로 활용된다.

13) 암모니아성 질소(NH3-N)

암모니아성 질소는 NH4+ 및 NH3 형태로 존재하며, Microcystis가 가장 선호하는 질소원 중 하나이다. 암모늄은 질산에 비해 환원 과정이 필요 없으므로 세포 동화에 에너지 효율이 높아, 적정 농도 범위에서는 Microcystis 초기 성장률과 우점 형성에 강한 양(+)의 영향을 준다. 다만 pH와 온도가 높은 조건에서 NH3 비율이 커질 경우 독성 위험이 증가할 수 있어, 모델에서는 농도 수준에 따라 성장 촉진과 억제를 동시에 보이는 농도 의존적 비선형 변수를로 취급되며, NO3-N과 함께 질소 형태별 기여도를 분리·해석하는 데 중요하다.

14) 질산성 질소(NO3-N)

NO3-N은 수계에서 가장 흔한 무기질소 형태로, 농업·생활오수 유입에 의해 축적되는 주요 질소원이며, Microcystis에게 암모니아 다음으로 중요한 질소 공급원이다. 질산만으로도 남조류 성장은 충분히 유지될 수 있으나, 세포 내 환원 과정이 필요해 암모니아성 질소에 비해서는 다소 완만한 성장효과를 보인다. 예측모델에서는 NO3-N이 남조류 기본 성장 잠재력과 외부 부영양화 수준을 나타내는 기저 변수로 활용되며, NH3-N 및 TN과의 조합을 통해 질소 제한 여부 및 형태별 상호작용을 반영하는 것이 중요하다.

15) 인산염인(PO4-P)

PO4-P는 남조류가 직접 흡수하는 무기태 인(orthophosphate)을 의미하며, Microcystis 순간 성장률을 결정하는 가장 핵심적인 제한영양염이다. PO4-P 농도가 임계농도 이상일 경우 남조류는 인 제한 없이 최대 성장과 세포 내 인 저장(luxury uptake)을 지속할 수 있으나, 고갈 시 단기간 내 성장 정체 및 쇠퇴가 발생하므로, 실질적으로 bloom 발생·소멸을 제어하는 “스위치” 역할을 수행한다. 데이터 확보가 가능한 경우 예측모델에서 PO4-P는 대개 가장 높은 변수 중요도를 보이며, 임계치를 중심으로 한 문턱효과(threshold)를 통해 남조류 발생 여부를 강하게 규정하는 핵심 인자로 활용된다.

16) 부유물질(SS)

SS는 토사·점토·유기물·플랑크톤 등 수중 부유입자 농도를 나타내며, 비조류성 탁질이 많은 경우 광투과 저하를 통해 Microcystis 성장에 음(-)의 영향을 미친다. 강우나 유량 증가로 유입 탁수가 유입될 때 SS가 높아지고 남조류가 희석·유출되거나 침강 손실을 겪어 bloom이 붕괴되는 경향이 있으나, 한편 bloom 자체가 SS를 증가시키는 경우도 있어 외부 기인 SS와 조류 기인 SS를 구분한 해석이 필요하다. 예측모델에서는 SS(또는 탁도)가 강우·유량과 함께 교란 이벤트를 나타내는 변수로 활용되며, 일정 SS 이상에서 조류 농도가 급감하는 임계값을 반영함으로써, 호우 후 일시적 감소 및 회복 패턴을 설명하는 데 기여한다.

6.1.2 수문·기상 인자

1) 강수량(precipitation)

강수량은 유역으로부터 질소·인·유기물 등을 공급하여 남조류 성장에 필요한 영양염을 보충하는 한편, 강우 강도가 클 경우 수체 희석·유출, 수온 저하, 혼합·탁도 증가를 통해 기존 bloom을 붕괴시키는 양면적 역할을 한다. 소규모·빈발 강우는 체류시간을 크게 줄이지 않으면서 영양염을 누적 공급하여 이후 맑고 안정된 기간의 Microcystis 폭증을 준비시키는 반면, 장기간 집중호우나 장마는 유출과 저광 조건으로 남조류 번성을 억제하는 경향이 있다. 예측모델에서는 일강수량과 누적강수량, 선행 강우일수 등의 파생변수를 통해 영양염 공급과 희석·혼합 효과를 동시에 반영하며, 특정 강우량 이상에서 영향 방향이 반전되는 비선형·임계 특성을 학습하는 것이 중요하다.

2) 기온(air temperature)

기온은 수온, 층상 형성, 증발 및 기상 패턴과 밀접히 연관되어 남조류에 간접 영향을 미치는 변수이다. 고온 조건에서는 수온 상승과 수체 안정화, 일사 증가, 증발 농축, 무풍·정체 패턴이 동반되어 Microcystis에 유리한 환경을 제공하는 반면, 저온·큰 일교차·겨울철 overturn 등은 남조류 서식환경을 붕괴시키고 휴지·월동 상태로 전환시킨다. 예측모델에서 기온은 수온의 대용 또는 보조변수로 활용되며, 특히 기상예보와 연계한 중장기 예측 시 향후 수온과 남조류 변동을 간접 추정하는 데 중요한 역할을 하며, 고온+무풍 등 위험 조합 파악에 유용하다.

3) 풍속(wind speed)

풍속은 수면 및 수층 혼합을 통해 Microcystis 집적·분산을 직접 제어하는 물리적 요인이다. 약한 바람 또는 무풍상태가 지속되면 층상이 강화되고 표층에 남조류가 집중되어 스컴 형성과 bloom 발달에 유리해지는 반면, 일정 수준 이상의 강풍은 수체 혼합과 파랑을 통해 표층 집적을 해체하고 남조류를 광이 부족한 하부로 이동시켜 성장률을 저하시킨다. 예측모델에서는 선행 풍속 평균 및 최대풍속 등을 고려하여 풍속이 특정 임계값 이상일 때 음(-)의 효과를, 그 이하에서는 영향 미미 또는 약한 양(+)의 효과를 반영하며, 특히 수온·강수와 함께 단기 bloom 상태 변화를 설명하는 데 핵심 기상변수로 활용된다.

4) 상대습도(humidity)

상대습도는 남조류에 대한 직접 영향은 크지 않으나, 맑음/흐림, 일사량, 증발량 등 기상 상태와 밀접하게 연관된 간접 변수이다. 저습·건조 조건은 대체로 맑은 하늘과 높은 일사를 동반하여 증발과 농축, 광합성 촉진을 통해 Microcystis에 유리하게 작용하는 반면, 고습·습윤 조건은 흐림·강수와 동반되어 일조 부족·희석 효과를 통해 남조류 성장에 불리하게 작용하는 경향이 있다. 모델에서는 상대습도가 기온·일사·강수와 높은 상관을 가지므로 단독 중요도는 낮더라도, 동일 고온 조건에서 맑은 폭염과 흐린 폭염을 구분하는 등 기상 패턴 해석의 보조 변수

로 활용될 수 있다.

5) 일조시간

일조시간은 하루 중 남조류가 광합성을 수행할 수 있는 시간의 길이를 나타내며, 길수록 하루 순생산량과 성장률이 증가하는 경향을 보인다. 여름철 긴 일조시간은 짧은 야간과 결합되어 남조류 순생산을 극대화시키는 계절적 조건을 제공하는 반면, 가을·겨울로 갈수록 일조시간 감소로 인해 같은 광세기라도 하루 총 광량이 줄어 남조류 성장 속도가 둔화된다. 예측모델에서는 일사량 자료가 없을 경우 일조시간이 광환경을 요약하는 지표로 활용되며, 장마철과 같은 고온·저일조 상황에서 bloom 억제, 맑은 계절의 bloom 촉진 등 계절·기상 효과를 교정하는 데 기여한다.

6) 일사량(solar radiation)

일사량은 남조류 광합성에 직접 이용되는 태양복사 에너지의 총량을 나타내며, 높을수록 DO 과포화, pH 상승, 수온 상승 등 남조류에 유리한 일련의 피드백을 유발한다. 흐린 날이나 겨울철처럼 일사량이 낮을 경우 Microcystis 성장률이 감소하고, 장기간 저조도 조건에서는 경쟁종인 규조류 등 저광 적응종이 우위에 설 수 있다. 예측모델에서는 일사량이 광환경을 가장 직접적으로 나타내는 변수로서, 비선형 포화 특성을 고려하여 극저 일사 시 음(-)의 효과, 임계량 이상에서는 추가 증가 효과가 제한적인 양상을 반영하며, 기상예보와 결합해 향후 bloom 강도 변동을 예측하는 데 핵심 입력으로 사용된다.

7) 증발량(evaporation)

증발량은 수면으로부터의 수분 손실을 의미하며, 수위 저하 및 체류시간 증가, 영양염·조류 농도의 농축 등 가뭄 조건을 반영하는 지표이다. 증발이 많은 시기에는 일반적으로 고온·건조·고일사·저강수 상태가 동반되어 Microcystis에 유리한 환경이 조성되며, 수위 저하에 따른 체적 감소로 겉보기 bloom 강도가 심화되는 효과도 나타난다. 모델 차원에서 증발량은 기온·습도·풍속·일사량의 결합 효과를 대표하는 파생변수로, 가뭄·건기 패턴과 남조류 고농도 지속 위험을 포착하는 데 활용될 수 있으나, 원천 기상변수와의 높은 공선성을 고려하여 변수 선택과 해석에 주의가 필요하다.

6.2 대상지역 수질 환경 자료 조사·분석

6.2.1 물관리 기관별 자료 관리 및 서비스 현황 조사

1) 수질 자료 생성 및 관리 현황

환경부는 물환경보전법 제21조(수질오염 경보제)에 의거해 수질측정망, 총량측정망, 자동측정망을 포함한 물환경측정망을 운영하고 있다. 조류경보제를 통해 조류발생 상황을 주기적으로 모니터링하여 일정 수준 이상의 조류가 발생할 경우에 필요한 조치를 취함으로써 수돗물을 안정적으로 공급하고, 친수활동시 조류 독소로부터 국민의 안전을 도모하고 있다. 전국의 29개소(상수원 호소 22개소, 상수원 하천 6개소, 친수활동 구간 1개소)를 대상으로 실시(그림 6.2와 표 6.1)하며 매년 연중 녹조가 발생할 우려가 높은 5월부터 10월까지 매주 유해 남조류세포수, Chl-a 등의 측정을 수행하여 단계별 남조류세포수 발령기준(표 6.2)에 따라 경보를 발령한다.

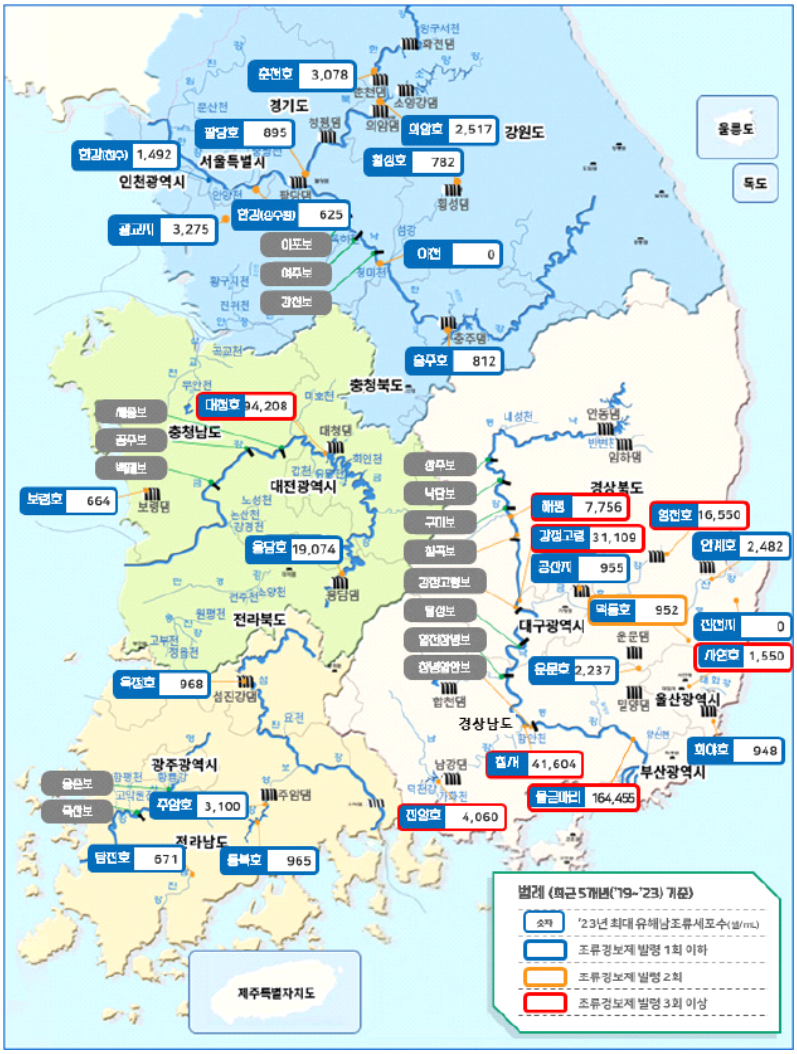

<그림 6.2> 조류경보제 발령지점

<표 6.1> 환경부 조류경보제 개요

구분	조류경보제	수질예보제* ('20년 조류경보제와 통합)
도입 목적	경보 단계별 필요한 조치를 취함으로써 수돗물을 안정적으로 공급	4대강 보구간 수생태계 건강성과 수질관리
도입 시기	1998년	2012년
대상	상수원 호소·하천 28개, 친수 1개 - 호소 22개소(K-water댐 13개) - 상수원 하천 6개소 - 친수활동 1개소	4대강 본류(12개 보) ※ 전체 16개 보 중 조류경보제 중복 4개소 제외
발령권자	하천·호소별 관리기관 (유역·지방환경청장/시도지사)	국립환경과학원
분석 주기	주 1회 이상 ('경계' 이상 발령시 주 2회 이상)	향후 7일간 수질변화를 예측하여 주 2회(월, 목) 예보
측정항목	수온, ph, DO, 클로로필-a, 유해남조류 세포수 등	남조류 세포수(실측),클로로필-a, 농도(예측), 수온, 총인, 총질소 등 예측
발령 단계	관심 / 경계 / 대발생	관심 / 주의 / 경계 / 심각

* 2020년부터 수질예보 지점을 조류경보제에 편입시키고 조류관찰지점(조류경보 발령 미실시)으로 명칭을 바꿔서 운영

<표 6.2> 조류경보단계에 따른 남조류세포수 발령기준

조류경보단계	발령기준
미발령	유해 남조류 세포수 1,000 cell/ml 미만
관심	유해 남조류 세포수 1,000 cell/ml 이상 10,000 cell/ml 미만
경계	유해 남조류 세포수 10,000 cell/ml 이상 1,000,000 cell/ml 미만
대발생	유해 남조류 세포수 1,000,000 cell/ml 이상

하천·호소별 관리기관(유역·지방환경청장 또는 시·도지사)에서 발령을 내린다. 경계 이상의 경보가 발령될 시 해당 지점의 관측 횟수를 주 2회 이상으로 늘리고 1,000 cell/ml 미만으로 떨어질 때까지 지속적인 관측이 이루어지고 있다. 조류경보제 시행을 위하여 환경부 산하 국립환경과학원은 2012년부터 조류측정망을 운영 시작 및 관측지점 점차 확대하고 있다. 기 운영 수질측정망의 수질 항목 일부와 녹조 현상 관련된 추가 측정 인자는 (표 6.4)와 같다. 2022년까지 환경부 조류경보제 대상 댐 22개소 중 K-water 관리 댐은 13개소(다목적댐 충주, 대청, 남강 3개소)이며, 대청댐가 남강댐 경보발령은 빈번하게 이루어지며 총 발령일수 현황은 (표 6.5)와 같다.

<표 6.3> 조류경보 단계별 조치사항

단계	조치사항
평시	· 주 1회 이상 시료채취 및 분석(유해남조류 세포수, 클로로필-a) · 오염원 점검 및 예찰활동 전개
관심	· "관심" 단계 발령, 오염원 단속 · 주 1회 이상 시료채취 및 분석(유해남조류 세포수, 클로로필-a) · 취수구와 조류 심한지역 차단막 설치 및 조류 제거 조치 실시 · 정수 처리 강화
경계	· "경계" 단계 발령 및 대국민 홍보(친수 활동, 어패류섭취 자제) · 주 2회 이상 시료채취 및 분석(유해남조류 세포수, 클로로필-a, 냄새물질, 조류독소) · 취수구와 조류가 심한 지역에 대한 차단막 설치 등 조류 제거 조치 실시 · 취수구 이동, 정수처리 강화(활성탄처리, 오존처리 등), 정수의 독소 분석 · 기상상황, 하천수문 등을 고려한 방류량 산정(필요시 방류량 조정)
대발생	· 주 2회 이상 시료채취 및 분석(유해남조류 세포수, 클로로필-a, 냄새물질, 조류독소) · 취수구와 조류가 심한 지역에 대한 차단막 설치, 조류제거물질 살포, 조류제거선 운영 등 조류 제거 조치 실시 · 취수구 이동, 정수처리 강화(활성탄처리, 오존처리 등), 정수의 독소 분석 실시 · 댐·보 방류량 조정

<표 6.4> 조류측정망 수질인자 측정항목

수질인자		조류 세포수 및 우점종	
수온	투명도	유해 남조류 세포수	Microsystis
pH	탁도		Anabaena
DO	SS		Oscillatoria
BOD	T-N		Aphanizomenon
COD	DTN	총조류	
Chlorophyll-A	NO3-N	총남조류	
지오스민	NH3-N	총규조류	
2-MIB	T-P	총녹조류	
전기전도도	DTP	총기타조류	
TOC	PO4-P	-	

<표 6.5> 조류경보제 대상 댐 중 K-water 관리 13개 댐의 총 발령일수 현황

연도	대청댐(호)			주암댐(호)		용담댐(호)	장흥댐(호)	섬진강댐(호)	영천댐(호)	남강댐(진양호)		안계댐(호)	보령댐(호)	횡성댐(호)	운문댐(호)		사연댐(호)		충주댐(호)	
	회남	문의	추동	댐앞	신평교					판문	내동				댐앞	취수탑2	취수탑	반연리	댐앞	청풍교
1998	31			-		미시행	미시행	미시행	미시행	미시행		미시행	미시행	미시행	미시행		미시행		미시행	
1999	-			-											-					
2000	46			-											-					
2001	84	-	-	-											-					
2002	-	16	-	57											-					
2003	61	78	78	76		-									-					
2004	-	14	-	14		-			40						-					
2005	67	30	30	-		80			86	17		53			-					
2006	62	59	64	-		39		-	100	-		43			-					
2007	14	-	14	19		-		-	139	-		-			-		-		-	
2008	15	-	-	-		-	-	-	37	15		-			-		-		-	
2009	47	-	-	39	35	-	-	-	-	51		-			-		-		-	
2010	59	29	43	-	37	20	-	-	-	-		-	19	-	-		-		-	
2011	57	48	29	-	-	-	-	-	36	-		-	-	-	16		-		-	
2012	83	48	62	-	-	-	-	-	-	-		-	-	-	-		-		-	
2013	33	-	47	-	-	-	-	-	-	-		-	-	35	-		-		-	
2014	-	-	-	-	-	-	-	-	-	-		-	-	-	-		-		-	
2015	14	14	40	-	-	-	-	-	-	-		-	-	-	-		-		-	
2016	63	91	84	-	-	-	-	-	-	26		15	-	-	-		20	29	-	-
2017	84	64	91	-	-	-	-	-	-	154	151	-	42	-	-		-	-	-	-
2018	69	77	63	-	-	-	-	-	59	48	30	40	-	-	42	42	-	-	13	
2019	42	13	83	-	-	-	-	-	13	21	35	-	-	-	-	-	-	-	-	
2020	83	82	62	-	-	-	-	-	21	-	35	-	-	-	-	-	39	39	-	
2021	-	69	22	-	-	-	-	-	21	84	84	42	-	-	-	-	14	83	-	
2022	42	14	21	-	-	-	-	-	-	63	49	-	-	15	-	-	-	21	14	-

2) 물관리 기관별 모니터링 및 정보 공유체계 현황

환경부는 기존 수질예보제와 같이 조류발생 상황을 미리 예측하는데, 2020년 수질예보제와

조류경보제가 통합되면서 조류예측 기능을 조류경보제 상수원 지점을 대상으로 실시하고 있다. 이는 단기 조류발생량 예측정보 제공으로 선제 대응을 강화하기 위해 '조류예측 및 수질관리협의회에 관한 규정'에서 조류예측에 대해 규정하고 시행한다. 또한 HSPF와 EFDC-NIER 모델을 연계 이용하여 기상 및 오염원의 변화에 따른 장래의 조류 발생 및 변화를 예측하고 발표한다. 이러한 수치모델링을 이용한 조류예측 정보는 환경부 물환경정보시스템(http://water.nier.go.kr)을 통해 공개하고 있다. 2020년 총 6개 지점(한강 이천, 낙동강 해평, 강정고령, 칠서, 물금매리, 금강 대청호) 운영을 시작으로 2021년 총 8개지점(팔당호, 진양호 추가)에 대하여 유해남조류 세포수 농도(구간 범위) 및 수온에 대한 향후 7일간의 예측정보를 제공하고 있다. 취·정수장 녹조 대비(환경부 정수장 조류대응 가이드라인)를 위해서 원수에 대한 주기적인 수질모니터링(pH, 조류, 맛·냄새물질 등) 및 조류경보가 발령하는 때에 조류독소인 마이크로시스틴-LR 농도를 측정하고 있으며, 2017년 10월부터 그 검사 결과는 국가상수도정보시스템(www.waternow.go.kr, 한국수자원공사 운영)에 공개하고 있다.

K-water는 데이터를 수집하고 내부 시스템(WQE 녹조, 디지털트윈, 상황실빅보드), 외부 시스템(모니터링데이터 허브)을 통해 녹조 DB 관리, GIS 기반 데이터 표출, 녹조 위기대응 의사결정 지원, 무인선박 모니터링 DB 관리를 유통하고 공유하고 있다.

<표 6.6> K-water 녹조 관련 정보 유통 및 공유체계

구 분	조류경보제 수질예보	취수원 예측	일일수질예측 (SURIAN)
제공대상	대국민	사내, 지자체	원격제어
제공횟수	2회/주	1회/주	일일
지 점	대청댐, 남강댐	서화천, 팔당호	15개 댐, 4대강 보
주요내용	조류경보제지점 남조류세포수 예보	녹조, 이취미 등 맞춤형 수질예측	일일(7일간) 수질예측
공개장소	물환경정보시스템	WQE/어플리케이션	SURIAN/주간레포트

* (SURIAN 댐) 13/20개 다목적댐(임하·안동·합천·남강·충주·횡성·용담·대청·보령·부안·주암·보현산·섬진강댐), 2/14개 용수댐(영천·운문댐), 3개 북한강댐(의암·청평·팔당댐) 구축·운영

기상청의 지상기상관측은 지면 부근 및 지상에서의 기상요소와 현상에 대한 관측을 말하며(관측업무규정 제2조), 자연과학적인 측정의 한 부분으로 시시각각 변하는 기상현상에 대해 눈(目) 또는 장비를 사용한 관측한다. 종관기상관측은 정해진 시각의 대기 상태를 파악하기 위해 모든 관측소에서 같은 시간에 실시하는 지상관측으로서 시정, 구름, 증발량, 일기현상 등 일부 목측 요소를 제외하고 종관기상관측장비(ASOS, Automated Synoptic Observing System)를 이용해 자동으로 관측한다.

<표 6.7> 지상기상관측(종관) 개요

요 소	기온, 강수, 바람, 기압, 습도, 일사, 일조, 눈, 구름, 시정, 지면상태, 지면·초상온도, 일기현상, 증발량 등
지 점	102지점 ※ 기상자료개방포털 제공 기준(18. 07. 01), 폐쇄 지점 포함으로 현행 지점 수와 차이 있음
보유기간	1904년 4월 ~ 현재 (지점별 상이함)
생산주기	분, 시간, 일, 월, 연 자료
제공형식	CSV, XML(Open API)
이용방법	CSV 형식은 EXCEL 프로그램 활용하거나 쉼표를 구분자로 하여 Text로 Read하여 사용하고, XML포맷은 오픈API 서버를 통해 자료를 제공
간행물	기상월보, 기상연보를 각각 매월 · 년에 대해 정기적으로 발간, 매 10년마다 지난 30년에 대해 한국기후표, 한국기후도를 발간

6.2.2 대상 지역 조류 발생 특성

1) 대청댐

대청댐은 지형적, 사회경제적으로 조류 발생에 취약하고 대청호는 길고 구불구불한 사행천과 만입부 형태를 가지고 있어 평균 체류시간이 199일이나 되는 등 지형적으로 조류 발생에 취약하다. 특히, 유역 내 농·축산 오염원으로 강우 시 오염물질이 다량 유입되어 여름철 호내에 장기간 체류하며 조류 발생 요인으로 작용한다. 중부지역 대표 상수원인 만큼 조류경보제 3개 운영지점인 추동과 문의는 취수탑 1km 상류에, 회남은 취수탑 14km 상류에 위치하고 있다.

중부권의 대표적인 식수원인 대청호는 1998년 조류경보제를 시행한 이후 1999년과 2014년 제외 매년 조류경보 발령('19년 117일→'20년 90일, '21년 69일, '22일 49일 발령으로 감소추세), 2020년 이후부터 '경계' 단계 발령은 없었다. 2022년 3개 지점에서 '관심' 단계 발령(회남 42일, 추동21일, 문의14일)되었고 '22년은 '21년과 비교시 발령일수는 감소했으나 평균유해남조류 세포수는 증가(510→1,328 cells/mL)했다. 2023년에는 7월 집중호우로 다량의 영양염류가 유입된 후 8월 폭염이 이어지면서 유해남조류가 급증하였다. 이에 따라 전년(2022년 49일) 대비 발령일수가 대폭 증가하여 총 112일간 경보가 발령되었다. 문의 지점은 최대 94,208 cells/mL(9월 4일)를 기록하며 '경계' 단계가 34일간 지속되었고, 추동 지점 또한 '경계' 단계가 12일간 발령되는 등 전년 대비 발생 강도가 높았다.

<표 6.8> 금강 수계 최근 5년간 조류경보 발령일수 **(단위: 일)**

구분		용담호	대청호	보령호	합계
2019	관 심	-	117	-	117
	경 계	-	-	-	
	대발생	-	-	-	
2020	관 심	-	90	-	90
	경 계	-	11	-	
	대발생	-	-	-	
2021	관 심	-	69	-	69
	경 계	-	-	-	
	대발생	-	-	-	
2022	관 심	-	49	-	49
	경 계	-	-	-	
	대발생	-	-	-	
2023	관 심	58	78	-	181
	경 계	11	34	-	
	대발생	-	-	-	

출처 : 2023 조류(녹조)발생과 대응 연차보고서(환경부, 2024.6)

2) 주암댐

주암호는 조류경보제 운영 지점이 댐앞, 신평교 지점으로 2개가 존재하며, 최근 5년간 조류경보 발령이 없었다. 2022년 주암댐 앞의 평균 수온은 2019~2021년 평균수온 보다 0.7℃ 증가하고, 클로로필-a 농도는 1.0mg/㎥ 감소한 것으로 나타났다. 총질소는 0.146mg/L 만큼 감소하였고, 총인은 0.004mg/L만큼 증가하였다.

2023년 주암호의 댐 유역 평균 강수량은 예년 대비 약 151% 수준으로 크게 증가하였다. 이러한 기상 조건 속에서 댐앞 평균 수온은 14.2℃로 전년 대비 상승하였으나, 클로로필-a 농도는 감소하였다. 2023년 8월 말, 댐앞 지점에서 유해남조류 세포수가 일시적으로 3,100 cells/mL까지 증가하였으나, 2회 연속 발령 기준(1,000 cells/mL)을 초과하지 않아 조류경보는 발령되지 않았다.

<표 6.9> 영산강 수계 최근 5년간 조류경보 발령일수 **(단위: 일)**

구분		옥정호	동복호	주암호	탐진호	합계
2019	관 심	-	-	-	-	0
	경 계	-	-	-	-	
	대발생	-	-	-	-	
2020	관 심	-	-	-	-	0
	경 계	-	-	-	-	
	대발생	-	-	-	-	
2021	관 심	-	-	-	-	0
	경 계	-	-	-	-	
	대발생	-	-	-	-	
2022	관 심	-	-	-	-	0
	경 계	-	-	-	-	
	대발생	-	-	-	-	
2023	관 심	-	-	-	-	0
	경 계	-	-	-	-	
	대발생	-	-	-	-	

출처: 2023 조류(녹조)발생과 대응 연차보고서(환경부, 2024.6)

6.2.3 녹조 예측 관련 자료 수집

본 연구에서는 AI모델 기반 녹조 예측을 위해 물리적 기작(수치모델 매개변수 참조) 등 남조류 생장과 관련한 다양한 변수를 고려하고자 했다. 여기서, 물리적 변수는 녹조 및 맛·냄새 물질의 자체적 물성과 지형, 유속(체류시간), 기상(기온, 수온, 강우량 등), 화학적 변수는 TOC, TP, TN, DO, 영양염 용출율(NH3-N, PO4-P)을 나타낸다. 광학적 변수는 일사량, 일조시간(운량), 탁도(투명도), SS, 파생 및 2차변수는 체류시간에 기반한 조류의 Mixing 정도, 부정기적 또는 정기적으로 취득 가능한 원격탐사(드론, 위성) 자료에 의한 수표면 녹조 분포(타과제 등 연계)를 의미한다.

자료는 녹조, 일반수질, 수리·수문(댐 운영자료), 기상자료로 구분하여 수집하였다. 녹조자료는 조류경보제 측정자료를 환경부 물환경정보시스템 및 K-water 수리안을 통해 취득 가능하며, 수온(℃), pH, DO(㎎/L), 클로로필-a 평균(㎎/㎥), 클로로필-a 표층(㎎/㎥), 투명도, 탁도, 남조류 우점종 등을 측정한다. 종속변수는 남조류 세포수(cells/mL), 지오스민(ng/L), 2-MIB(ng/L)이며, 조류경보제 자료 현황은 3개 지점, 8개 측정 위치에서 12~24년간의 남조류 발생 및 관련 자료를 확보 가능하다.

일반수질 자료는 환경부에서 운영하는 국가수질측정망, 국가자동측정망 등의 일반수질 자료를 물환경정보시스템에서 수집 가능하며 측정항목은 BOD(㎎/L), COD(㎎/L), TN(㎎/L), TP(㎎/L), SS(㎎/L), Cond(μS/㎝) 등이 있다. 수리·수문 자료는 K-water 운영통합정보시스템(WRO) 및 실시간수자원정보시스템(HDAPS)에서 댐 운영 관련 유입량(㎥/s), 최대유입량(㎥/s), 방류량(㎥/day), 최대방류량(㎥/day), 댐유역 평균강우량(mm), 저수량, 저수위 등의 자료를 확보할 수 있다. 기상자료는 기상청 기상자료개방 포털에서 종관기상관측 자료에서 평균기온(℃), 최고기온(℃), 강수량(mm), 평균풍속(m/s), 상대습도(%), 일조시간(hr), 일사량(MJ/m2), 최다일사량(MJ/m2), 전운량(1/10), 증발량(mm) 등을 수집할 수 있다. 환경부 조류경보제·수질측정망, K-water 댐 운영, 기상청 기상자료 등 총 40개 항목에 대한 자료수집('00~'23) 결과는 <표 6.11>과 같다.

<표 6.10> 원시자료 수집 목록

분류	측정항목	분류	측정항목	
조류경보제 (물환경정보시스템)	수온(℃)		질산성 질소(mg/L)	
	수소이온농도(pH)		인산염인(mg/L)	
	DO(mg/L)		SS(mg/L)	
	투명도	댐 운영 (K-water 운영통합)	저수지수위(당년)	
	탁도		저수량	체류시간
	클로로필-a 평균(㎎/㎥)		유입량	
	남조류 세포수(cells/mL)		최대유입량	
국가수질측정망 (물환경정보시스템) (상층/중층/하층)	수온(℃)		총방류량	
	수소이온농도(pH)		최대방류량	
	DO(mg/L)		댐유역평균강우량(당년)	
	BOD(mg/L)	기상 (기상청 날씨정보)	평균기온(℃)	
	COD(mg/L)		최고기온(℃)	
	클로로필-a		일강수량(mm)	
	TP(mg/L)		평균풍속(m/s)	
	TN(mg/L)		평균 상대습도(%)	
	TOC(mg/L)		합계 일조시간(hr)	
	전기전도도(㎲/cm)		합계 일사량(MJ/㎡)	
	DTN(mg/L)		시간별 최다일사량(MJ/㎡)	
	DTP(mg/L)		평균 전운량(1/10)	
	암모니아성 질소(mg/L)		합계 소형증발량(mm)	

1) 대청댐

대청댐 국가수질측정망(일반) 지점은 2004년 4월 이전에는 1회씩 측정하여 상층부에 입력하였으나, 이후에는 채수를 3번(상층부/중층부/하층부)에 거쳐 수행하였다. 특히 대청댐3 자료 중 2007년 3월~2007년 10월에는 1회차, 상층부/중층부/하층부로 동일 일자에 총 4개의 계측값이 존재하는데, 자료 수집 시 1회차는 생략하였다. 대청댐1 자료 중에서는 중상 및 중하층부에서 채수(2007년 10월 9일, 2014년 5월 13일, 2015년 11월 25일, 2021년 1월 25일)한 내역은 포함하지 않았고 대청댐1 상층부, 중층부, 하층부 자료 중 2023년 6월 12일부터 암모니아질소, 인산염인에서 '정량한계미만'이 나타나는 것으로 확인되었다.

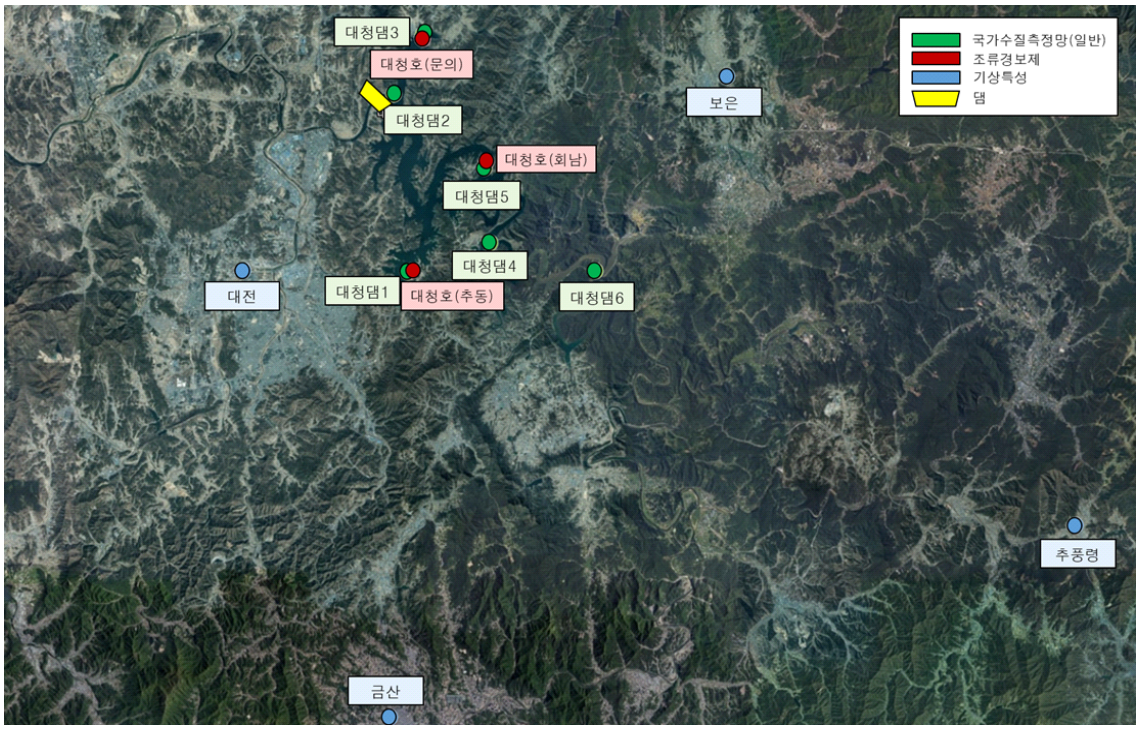

<그림 6.3> 대청댐 관련 지점 위치

<표 6.11> 대청댐 조류경보제 및 국가수질측정망(일반) 지점 비교

조류경보제 지점	국가수질측정망(일반) 지점
대청호(문의)	대청댐3
대청호(추동)	대청댐1
대청호(회남)	대청댐5

<표 6.12> 대청댐3 일부 발췌 자료

년/월/일	회차	수온	DO	…	용존총인	인산염인	SS
2007/03/06	1회차	7	12.5		0.005	0.001	1.5
2007/03/06	상층부	7	12.5		0.007	0	1.3
2007/03/06	중층부	7	12.5		0.005	0.001	1.7
2007/03/06	하층부	7	12.4		0.003	0	1.3

<표 6.13> 대청댐 관련 지점별 자료 제원

분류	지점명	자료수	관측개시	관측간격
조류경보제	회남 (3008G30)	396~928	2003.3.5	1~2회/주 (1~2회/일)
	추동 (3008G40)	398~930	2003.3.5	1~2회/주 (1~2회/일)
	문의 (3008G50)	403~935	2003.3.5	1~2회/주 (1~2회/일)
국가 수질측정망 (일반수질)	대청댐3 (3008B50)	(상층) 138~252	1997.1.6	1회/월 3회/일(2004.4~2023.12)
		(전체) 132~193		
	대청댐1 (3008B40)	(상층) 759~1026	1997.1.6	1~2회/주 3회/일(2004.4~2023.12)
		(전체) 714~917		
	대청댐5 (3008B30)	(상층) 138~288	1997.1.6	1회/월 3회/일(2004.4~2023.12)
		(전체) 132~237		
댐 운영	대청	8766	1981.1.1	1회/1일
기상	보은	8766	1972.1.9	1회/1일
	금산	8766	1972.1.9	1회/1일
	추풍령	8766	1940.8.27	1회/1일
	대전	8766	1969.1.1	1회/1일

2) 주암댐

주암댐 기상자료 중 주암은 2000.1.1.~2012.7.2., 순천은 2011.4.1.~2023.12.31. 구간에만 존재하며, 그 외 특이사항은 존재하지 않았다.

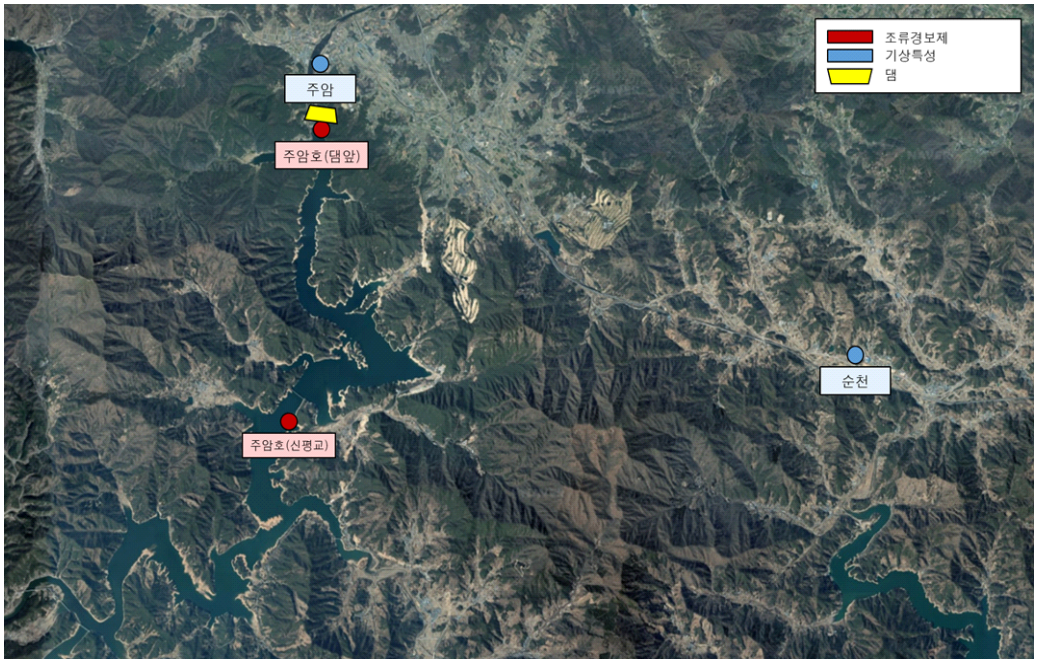

<그림 6.4> 주암댐 관련 지점 위치

<표 6.14> 주암댐 관련 지점별 자료 제원

분류	지점명	자료수	관측개시	관측간격
조류경보제	주암호 (댐앞)	399~1012	2022.5.6	1~2회/주 1~2회/일
	주암호 (신평교)	399~1012	2022.5.6	1~2회/주 1~2회/일
국가 수질측정망 (일반수질)	주암댐1 (댐앞)	1102	1992	1회/주
	주암댐2 (신평교)	1102	1992	1회/주
댐 운영	주암	8766	1991.1.1	1회/1일
기상	주암	8766	1972.1.21	1회/1일
	순천	8766	2011.4.1	1회/1일

6.3 녹조·수질 예측 모델 구축

6.3.1 대상지점 개요

본 연구는 남조류 세포수 예측을 위한 머신러닝 모델 구축과 예측성능 검증을 위해 조류경보제 지점으로 대표적 광역취수원 중 하나인 대청댐과 주암댐을 선정하였다.

1) 대청댐

금강 유역의 대표적 취수원인 대청호는 길고 구불구불한 사행천과 만입부 형태를 가지고 있어 평균 체류시간이 199일이나 되는 등 지형적으로 조류 발생에 취약하고, 강우 시 유역 내 농·축산 오염물질이 다량 유입되어 여름철 호 내에 장기간 체류하며 조류 발생 요인으로 작용하고 있다. 대청호는 1998년 조류경보제를 시행한 이후 현재까지 1999년과 2014년을 제외하고 매년 조류경보가 발령되고 있다(MOE, 2024). 대청호 조류경보제는 회남, 추동, 문의 등 3개 지점이 운영 중인데, 본 연구는 취수장 상류 1km에 위치하고, 인근에 국가수질관측망 지점(대청댐1)이 있어 상관성 높은 일반수질 자료 취득이 용이한 추동 지점을 연구 대상으로 선정하였다(그림 6.5).

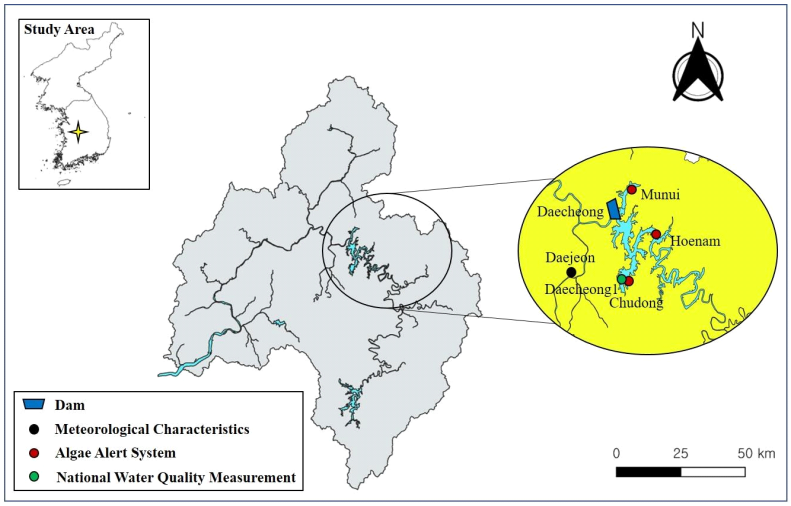

<그림 6.5> 대상 지점 현황(대청댐)

2) 주암댐

주암호는 조류경보제 운영 지점이 댐앞, 신평교 지점으로 2개가 존재하며, 최근 5년간 조류경보 발령이 없었지만(MOE, 2024), 2025년 8월부터 14년만에 조류경보(관심)가 발령되었다. 2025년 광주·전남지역의 폭염일수는 29.6일로 평년 22.3일 대비 크게 늘었고, 국지성 호우 또한 빈번히 발생하며 수온이 상승하는 시기에 질소·인 등 오염원 유입이 녹조 발생의 주요 원인인 것으로 파악된다. 본 연구는 댐 바로 직상류에 주간 단위 관측 시간해상도를 가지고 있는 국가수질관측망 지점(주암댐1)이 위치하고 있어 상관성 높은 일반수질 자료 취득이 용이한 댐앞 지

점을 적용 대상으로 선정하였으며(그림 6.6), 근처에 국가수질관측망이 없는 신평교 지점의 경우 댐앞 지점과 동일한 설명변수들을 적용하여 시험적 예측을 수행했다.

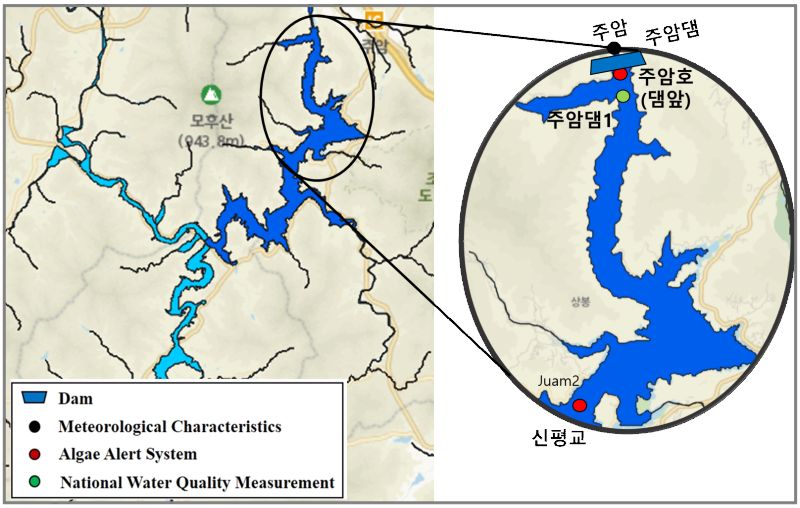

<그림 6.6> 대상 지점 현황(주암댐)

6.3.2 데이터 수집

머신러닝 모델 구축을 위한 데이터셋은 남조류, 일반수질, 수리·수문, 기상 데이터를 각각 수집하여 관측일 기준으로 결합하였다. 각 조류경보지점은 대청호 추동 지점이 2003년, 주암호 댐앞 지점이 2000년 관측을 개시하여 주 1~2회 간격으로 남조류 세포수를 측정(12~3월 제외)하고 있으며, 일반수질의 경우 2016년부터 클로로필-a(Chl-a), 수온, 수소이온농도(pH), 용존산소(DO) 등을 측정하고 있다. 다만, 일반수질의 경우 남조류 세포수에 비해 자료 연한이 매우 짧은 문제로 국가수질측정망 측정값으로 대신하였다. 국가수질측정망은 2004년부터는 상층, 중층, 하층 3개 수심별 측정값을 제공하고 있어 이를 별도로 정리했다.

관련 자료들은 환경부 물환경정보시스템을 통해 수집하였다. 수질·녹조 자료 외 수리·수문 특성 반영을 위해서는 유입량 및 방류량 등 K-water의 댐 운영 자료를 수집했으며, 기온, 강우량, 일사량 등 기상자료는 기상청 기상자료개방포털의 종간기상관측(ASOS) 자료 일 단위로 수집하였다. 수집된 자료 중 남조류 및 일반수질은 주 단위, 댐 운영 및 기상자료는 일 단위인 등 자료 분류별로 시간 해상도가 다르고, 주 자료의 경우 관측일도 규칙적이지 않았다. 따라서 기본 데이터셋은 일 단위를 기준으로 미측정 데이터를 결측 처리하는 방식으로 구축해 데이터 손실을 방지하였다. 수집한 데이터셋의 세부 내용은 <표 6.15>와 같다.

<표 6.15> 수집한 관측 데이터 현황

구 분	출 처	Measured Variables(Units)
남조류	조류경보제	남조류세포수(cells/mL)
일반수질	기후부 물환경정보시스템	수온(℃), DO(mg/L), BOD(mg/L), COD(mg/L), 클로로필-a(Chl-a, mg/㎥), TN(mg/L), TP(mg/L), TOC(mg/L), 용존성질소(DTN, mg/L), 암모니아성질소(NH3-N, mg/L), 질산성질소(NO3-N, mg/L), 용존성인(DTP, mg/L), 인산염인(PO4-Pmg/L)
댐운영	K-water 댐 운영자료	일평균유입량(㎥/s), 일최대유입량(㎥/s), 일평균방류량(㎥/s), 일최대방류량(㎥/s)
기상	기상청 종관관측소	일평균기온(℃), 일최대기온(℃), 일강수량(mm), 총일조시간(hr), 일사량(MJ/m^2), 최대일사량(MJ/m^2)

1) 대청호

대청댐 유역은 조류경보제 운영 지점인 추동 지점과 이에 대응하는 국가수질측정망 지점(대청댐1)의 일반수질 데이터를 수집하였다. 조류 데이터는 3개 지점 모두 2003년 3월부터 관측을 시작하여 약 20년 이상의 주간 단위 시계열을 확보하였다. 수질측정망 자료는 1997년부터 관측되었으며, 특히 2004년 이후부터는 일 3회의 고빈도 측정 자료가 존재하여 정밀한 수질 변동 분석이 가능하다. 댐 운영 자료는 1981년 이후의 대청댐 일별 데이터를 활용하였으며, 기상 자료는 댐 유역의 광범위한 범위를 고려하여 보은, 금산, 추풍령, 대전 등 4개 기상관측소의 1970년대 이후 관측 자료를 수집하여 공간적 대표성을 확보하였다.

2) 주암호

주암댐 유역은 조류경보제 운영 지점인 주암호 댐앞 지점과 이에 대응하는 국가수질측정망 지점(주암댐1)의 일반수질 데이터를 수집하였다. 해당 지점의 조류 관측 자료는 2000년 5월부터 본격적으로 수집되기 시작하여 주 1~2회의 조밀한 관측 간격을 유지하고 있다. 댐 운영 자료는 1991년부터 축적된 주암댐의 일별 데이터를 활용하였으며, 기상 자료는 댐 직하류에 위치한 주암(1972년~2012) 종관기상관측(ASOS) 지점 자료를 수집했으나, 2012년 7월부터 관측이 중단되어, 부득이하게 2012년 부터는 가장 가까운 순천(2011년~) 기상관측소의 데이터를 수집하였다.

6.3.3 데이터 전처리

데이터 전처리는 머신러닝 모델의 성능을 극대화하기 위한 필수 과정으로, 불완전하거나 부정확한 데이터를 정제해 모델이 효과적으로 학습할 수 있도록 변환하는 역할을 한다. 본 연구에서는 일 단위 샘플에 대한 전처리 첫 단계로 이상값 탐지(anomaly detection)를 수행하였고, 다음으로 자료별로 다른 시간 해상도를 일치시키기 위해 일 단위로 구축된 원시 데이터셋을

주 단위로 재표집(resampling) 하여 주 단위 샘플로 줄였으며, 마지막으로 결측값 대체(missing value imputation)를 수행하였다.

이상값 탐지를 위해 Z-score, 사분위범위법(IQR)과 같은 단순 통계 기반 기법과, 지수평활(Exponential Smoothing), STL(Seasonal-Trend decomposition using Loess) 등 평활 기반 시계열 기법을 변수별로 비교·평가하였다. 평가 결과, 계절성, 추세, 단기 변동성을 함께 반영하여 국소적 시계열 맥락을 기준으로 이상 여부를 판단할 수 있는 평활 기반 기법이 녹조 특성에서 자주 나타나는 급격한 고농도 증가 구간에서 안정적인 탐지 성능을 보였다. 반면, 단순 통계 기반 기법은 전역 통계량을 기준으로 임계값을 설정하여 점 이상값(point anomaly)을 탐지하는 특성이 있어, 생태계 반응의 연속적 증가 과정에서 발생하는 희소하지만, 정상적인 고농도 값을 이상값으로 오탐지할 가능성이 상대적으로 높게 나타났다. 이에 본 연구에서는 시계열적 문맥을 고려한 평활 기반 이상값 탐지기법을 최종적으로 적용하였다.

시간 해상도 일치를 위한 재표집 시 일주일 내 2개 이상의 측정값이 있으면 변수의 특성을 고려해 평균, 합계, 최댓값, 최솟값 등의 대푯값으로 대체하였다(<그림6.7>. 시간 해상도를 주 단위로 일치시킨 후 남아있는 결측값은 거리 기반 알고리즘인 k-NN을 활용하여 대체하였다. k-NN은 결측 시점과 유사한 이웃 관측치의 값을 가중 평균하는 방식으로 보간하므로, 원자료에 존재하지 않는 급격한 변동이나 인위적인 피크를 새로 생성하지 않는다는 방법론적 특성을 가진다. <그림 6.8>과 <그림 6.9>는 재표집한 데이터에 대해 이상치 탐색과 결측값 대체를 수행한 결과 중 일부를 나타낸 것이다. <그림 6.10>은 모든 전처리 절차를 마친 후 남조류 세포수 시계열을 나타내고 있다.

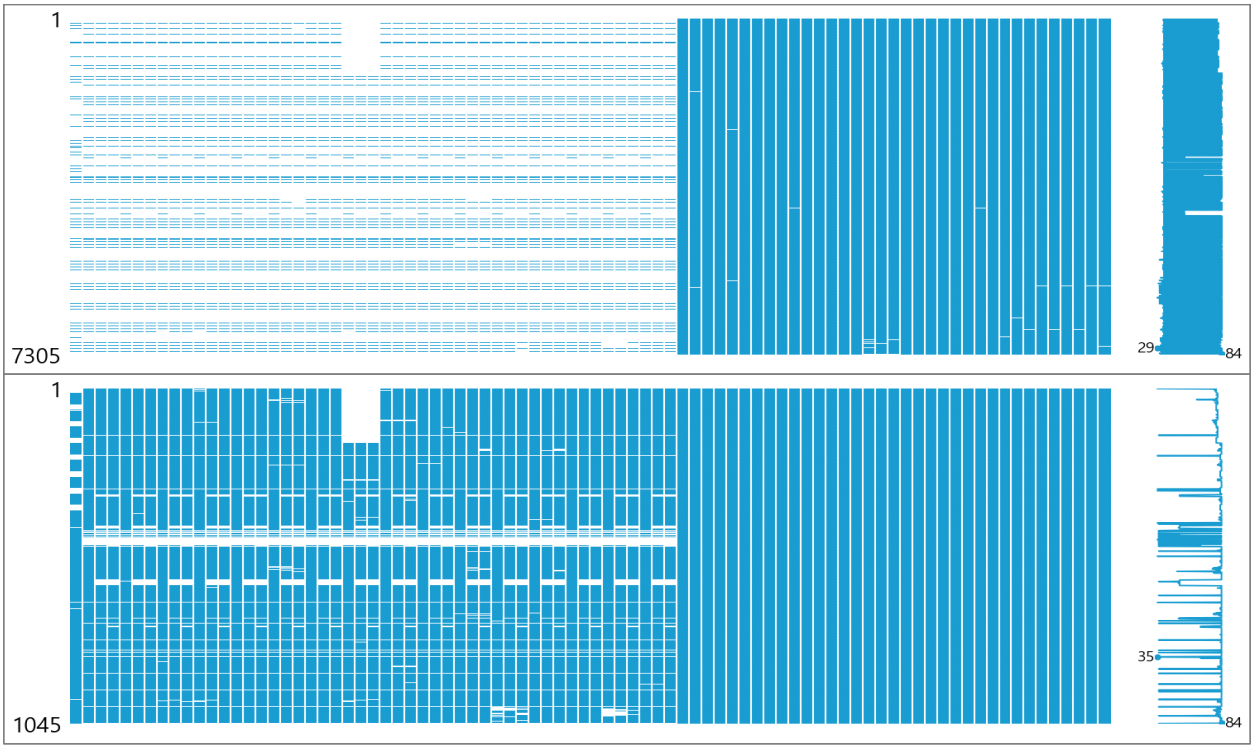

<그림 6.7> 자료별 시간해상도 불일치(위)와 일주일 단위 재표집 결과(아래) (대청호 예시)

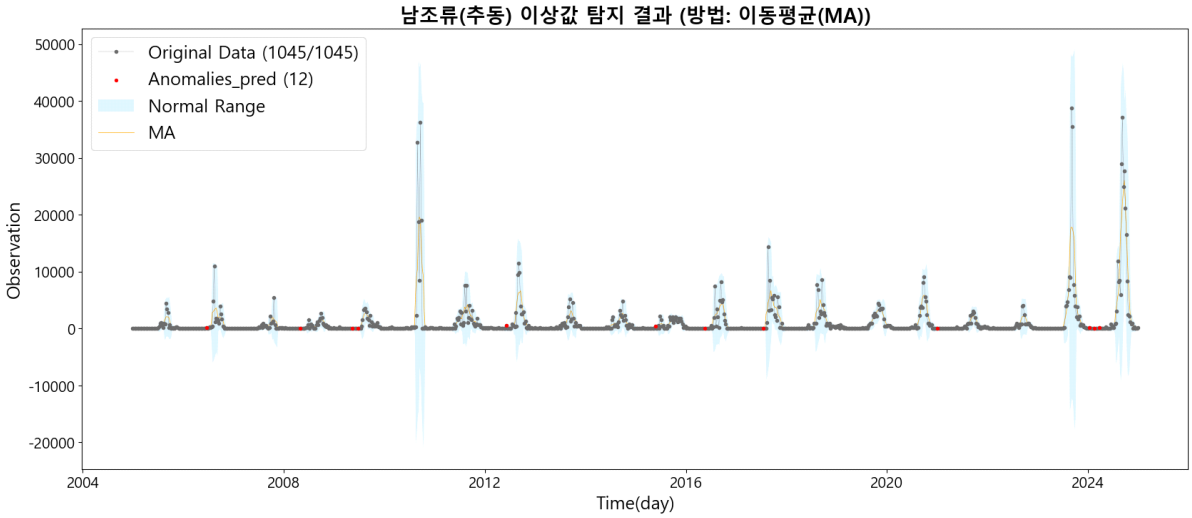

<그림 6.8> 이상값 처리 완료된 남조류세포수 데이터 (2005 ~ 2024, 대청호 예시)

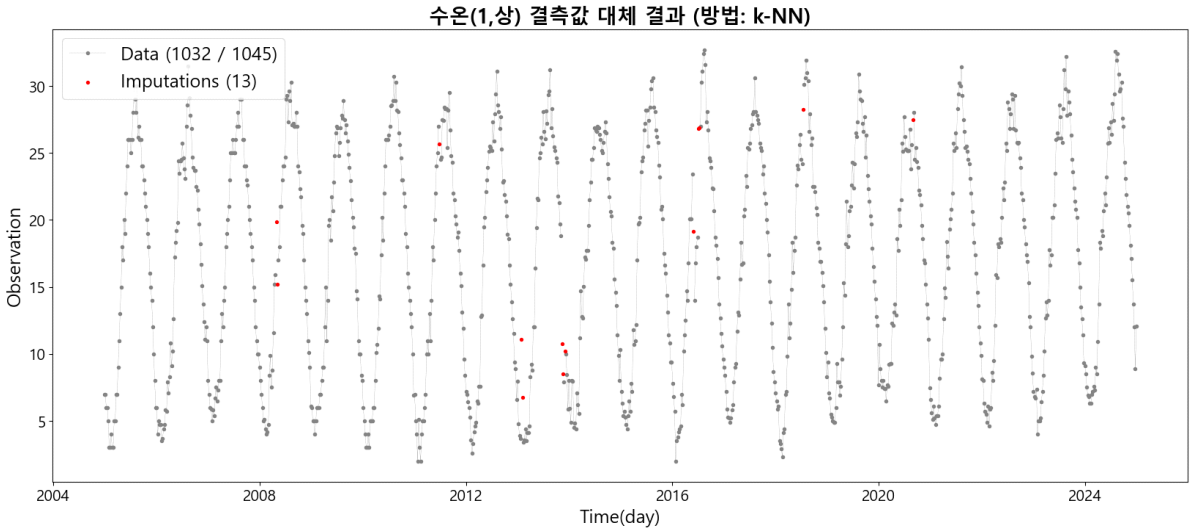

<그림 6.9> 결측값 대체 완료된 수온 데이터 (2005 ~ 2024, 대청호 예시)

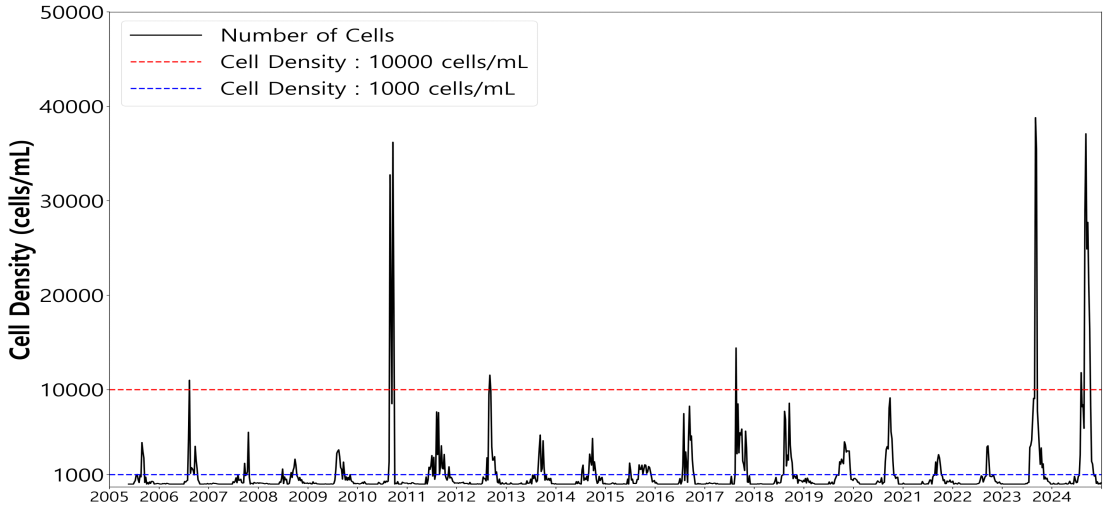

<그림 6.10> 전처리 완료된 남조류세포수 데이터 (2005 ~ 2024, 대청호 예시)

6.3.4 EDA

EDA의 목적은 각 변수의 분포·스케일·왜도 등 기초 특성을 정량적으로 파악하고, 변수들 간 상호관계(상관·부분상관)를 통해 정보 중복, 잠재적 다중공선성, 해석상의 혼선을 사전에 점검함으로써, 이후 단계의 변수선정·변환·모델링 전략(정규화/변환, 상관 기반 필터링, 구조적 해석 등)에 근거를 제공하는 데 있다. 본 연구에서는 변수 선택 전 단계에서 EDA를 수행함으로써 변수 선택시 필터링할 데이터 및 변수에 대한 사전 정보를 학습하는 과정을 거쳤다. 본 절에서 제시하는 도표들은 분량이 많아 대청댐 모델 구축만을 예시로 제시하였으며, 다른 대상 지역들도 유사한 과정을 거쳐 EDA를 수행하였다.

1) 일변량 분석을 통한 변수특성 파악

가. 수치형 변수의 일변량 통계분석(요약통계 산출)

전처리된 84개 변수는 수질·수문·기상·운영 등 서로 다른 물리적 의미와 계측 체계를 갖는 수치형 변수들로 구성되므로, 모델 학습 이전에 각 변수의 규모(scale), 산포(spread), 분포 형태(distribution shape)를 먼저 확인하는 과정이 필수적이다. 이를 위해 <그림 6.11>과 같이 각 변수에 대해 기술통계(descriptive statistics)의 요약된 형태인 요약통계(summary statistics)를 산출하였다. 구체적으로 평균, 표준편차 최솟값/최댓값, 사분위수, 변동계수(CV), 왜도(skewness), 첨도(kurtosis) 등을 계산하여 다음의 사항을 점검하였다.

	# Mean	# Median	# Mode	# Range	# IQR	# Std Dev
	누락: 0 (0%) 고유: 42 (100%)	누락: 0 (0%) 고유: 42 (100%)	누락: 0 (0%) 고유: 38 (90%)	누락: 0 (0%) 고유: 42 (100%)	누락: 0 (0%) 고유: 42 (100%)	누락: 0 (0%) 고유: 42 (100%)
	최소 0.0176429286… 최대 903.103109…	최소 0.0140208150… 최대 878.258428…	최소 0.0 최대 491.56042857142 86	최소 0.095 최대 3812.0	최소 0.011999999999999 9 최대 618.0	최소 0.0114709826… 최대 2870.94168…
남조류(추등)	903.1031091132501	88.40443944636243	0.0	38812.0	618.0	2870.9416803572576
수온(1,상)	17.26492967157377	18.2	5.0	30.700000000000003	15.7	8.374870287349317
DO(1,상)	10.694118171800165	10.6	10.6	10.8	2.799999999999999	1.8549001794386557
BOD(1,상)	1.0296168238952141	1.0	0.8	1.6	0.4582000639021213	0.342149599540133
COD(1,상)	4.1926635397138	4.1	3.9	4.800000000000001	1.1	0.8524140053875301
Chl-a(1,상)	8.896193980678136	5.7043323986231425	3.2	110.0	8.600000000000001	8.902816762785163
TN(1,상)	1.3943334213778658	1.387	1.22	1.8940000000000001	0.3074999999999999	0.2840203819064268
TP(1,상)	0.017642928619094153	0.014020815092669017	0.011	0.095	0.011999999999999999	0.011470982699460423
TOC(1,상)	2.8027195375102227	2.7038903457253127	2.7	3.8	0.6494695536482893	0.5412445279595853
pH(1,상)	8.077692526901211	7.9	7.9	3.8000000000000007	0.858270295627765	0.5858113738350967
EC(1,상)	140.213790680157	141.0	157.0	164.0	29.0	21.565375826031037
SS(1,상)	2.4636447181578 61	2.0	1.4	14.0	1.6	1.6084192287055574
평균강우량	22.728146974358946	8.657200000000001	0.0	303.07599999999996	25.7759	38.526515108617424
유입량	506.7444348717946	187.62	30.509999999999998	13023.237	246.28999999999996	1115.9926993765007

<그림 6.11> 수치형 변수의 요약통계량 계산 (대청호 예시)

첫째, 중심경향치(평균·중앙값·최빈값)의 불일치는 분포 비대칭 또는 극단값(outlier) 존재 가능성을 시사한다. 예컨대 평균이 중앙값보다 과도하게 큰 경우(우측 꼬리, positive skew)는 강우·유입량·방류량·조류세포수 등에서 흔히 관찰되는 전형적 패턴이며, 이러한 변수는 그대로 투입할 경우 모델이 평상시 구간보다 피크 구간에 민감하게 반응하거나 반대로 피크를 과소적합할 수 있다. 따라서 일변량 수준에서 왜도·첨도와 함께 확인함으로써, 이후 로그/Box‑Cox/Yeo‑Johnson 변환, 로버스트 스케일링 등 변환 필요성을 판단할 수 있다.

둘째, 산포의 상대 비교는 변수 간 스케일 차이를 정량적으로 드러내어, 정규화/표준화

여부와 방식(표준화 vs 로버스트 스케일링)을 결정하는 근거가 된다. 특히 동일한 물리 단위라도 관측 지점·계절에 따라 분산이 크게 달라지는 수질 변수가 존재할 수 있으므로, 요약통계는 단순한 요약을 넘어 학습 안정성(수치 안정성)과 손실함수 민감도를 점검하는 역할을 수행한다.

셋째, 사분위수 기반의 범위(IQR)와 최소–최대 범위를 함께 확인함으로써, 단순 평균·표준편차만으로는 드러나지 않는 두꺼운 꼬리(heavy tail), 비정상적 극단 관측치 가능성을 조기에 식별하였다. 본 연구는 녹조 예측이라는 목적상 "극단값"이 반드시 오류라고 단정할 수 없고, 오히려 고농도 사건이 중요한 예측 대상이므로, 요약통계는 극단값을 제거하기 위한 근거가 아니라 극단값이 '자연현상'인지 '계측/처리 오류'인지를 후속 단계에서 재검토하기 위한 1차 진단 정보로 활용하였다.

나. 정규성 검정(Normality tests)을 통한 분포 가정 점검

녹조 예측에 사용되는 다수의 환경·수질 변수는 경험적으로 정규분포를 따르지 않는 경우가 많다(예: 강우·유입량, 영양염, 클로로필-a, 조류세포수 등). 그럼에도 정규성 점검은 (i) 변수 변환 필요성 판단, (ii) 일부 통계적 해석(상관의 신뢰성, 특정 가정 기반 분석)에서의 주의점 명시, (iii) 모델 입력 분포의 비선형성/비대칭성이 학습에 미치는 영향 평가라는 측면에서 의미가 있다. 이에 따라 각 변수별로 다음의 정규성 검정을 수행하였다.

① **Shapiro–Wilk 검정**: 표본이 정규분포에서 왔다는 귀무가설 H_0를 검정하는 방법으로, 비교적 강력한 정규성 검정으로 알려져 있다.
② **Kolmogorov–Smirnov(K–S) 검정**: 경험적 누적분포함수(ECDF)와 이론분포(CDF) 간 최대 차이를 기반으로 정규성을 점검한다.
③ **Anderson–Darling(A–D) 검정**: K–S 계열과 유사하나 꼬리 부분에 더 큰 가중을 부여하여, 극단부 적합도를 보다 민감하게 반영한다.

정규성 검정 결과는 단순히 "정규/비정규"의 이분법적 판정으로 끝나지 않는다. 환경 시계열 데이터에서는 표본 수가 큰 경우 작은 왜곡에도 p-value가 매우 작아져 정규성이 쉽게 기각될 수 있으므로, 본 연구에서는 검정 결과를 분포 시각화(Q–Q plot 등) 및 왜도·첨도와 함께 해석하였다. 즉, 통계적 유의성(p-value)만으로 변환 여부를 결정하기보다, 비대칭성 정도, 극단부의 두꺼운 꼬리, 모델링 목표(피크 예측 중시 여부)를 종합하여 변환·스케일링 전략을 수립하는 근거 자료로 사용하였다.

다. 수치형 변수의 일변량 시각화(히스토그램·KDE·Q-Q plot·상자그림)

위에서 요약통계와 정규성 검정은 분포를 압축해 보여준다는 장점이 있으나, 실제 데이터의 구조(다봉분포, 꼬리 두터움, 구간별 밀도 차이 등)를 직관적으로 파악하는 데에는 한계가 있다. 이에 따라 각 변수에 대해 <그림 6.12>와 같이 일변량 시각화를 수행하였다.

① 히스토그램 및 커널밀도추정(KDE)

히스토그램은 데이터 분포의 거친 형태를, KDE는 연속적인 밀도 추정치를 제공하여 분포를 더 매끄럽게 해석할 수 있게 한다. 이를 통해 단봉형/다봉형 여부, 비대칭성(좌/우 꼬리), 특정 구간의 밀집, 희소하지만 중요한 고값 영역(피크)의 존재 등을 파악하였다.

② Q - Q(Quantile - Quantile) 플롯

Q - Q 플롯은 표본 분위수와 이론 정규분포 분위수의 대응을 시각화하여 정규성 위반의 형태를 구체적으로 드러낸다. 직선에서의 체계적 이탈 패턴은 꼬리 두터움(양쪽 끝에서 벌어짐), 비대칭(한쪽 끝에서만 크게 이탈), 절단/포화(센서 한계로 상한 또는 하한에서 꺾임) 등을 시사한다. 이는 특히 수질 센서 데이터에서 발생할 수 있는 측정 한계, 검출한계(LOD), 상·하한 클리핑 등 품질 이슈를 점검하는 데 유용하다.

③ 분포 요약 지표의 시각적 표기

각 그래프에는 평균, 중앙값, 최빈값(추정), 왜도, 첨도 등을 함께 표시하고(또는 동일 화면에서 병렬 제시), 정규성(Z-test 등) 관련 지표를 병기함으로써 "수치적 결과 - 시각적 근거"가 일관되게 연결되도록 구성하였다. 이러한 방식은 단순히 분포를 보여주는 것을 넘어, 특정 변수의 변환 필요성(로그 변환, 분포 안정화), 이상치 처리 방향(삭제가 아닌 보존·강건화), 스케일링 전략 수립 등 모델링 의사결정에 직접적으로 기여한다.

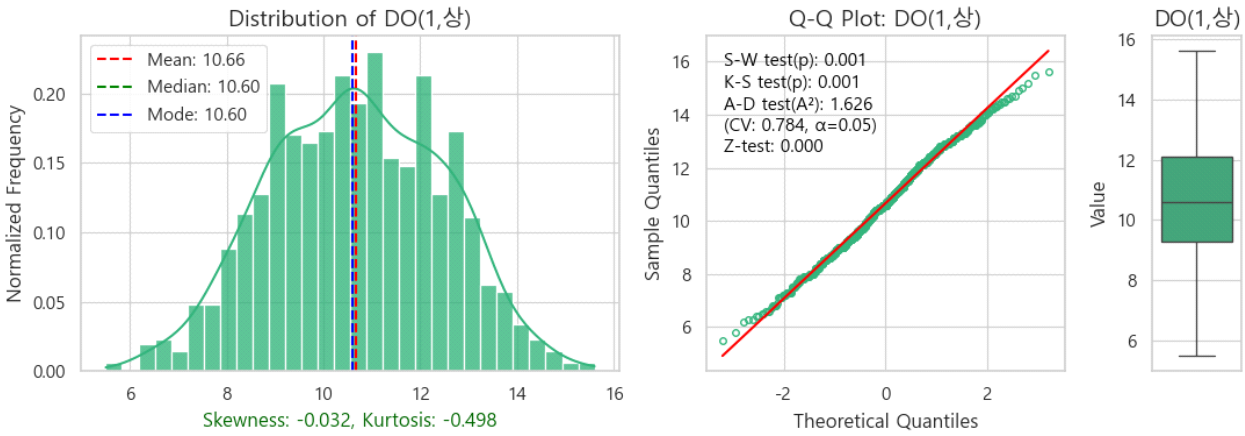

<그림 6.12> 히스토그램과 Q-Q플롯, 상자그림을 이용한 DO의 일변량 시각화(대청호 예시)

2) 다변량 분석을 통한 변수 간 관계 분석

가. 다변량 분석의 목적과 본 연구에서의 활용 맥락

다변량 분석(multivariate analysis)은 둘 이상의 변수가 동시에 존재할 때, 변수 간의 상호관계가 전체 변동성 및 관측 패턴에 미치는 영향을 다각도로 파악하는 접근이다. 특히 녹조 예측 문제에서는 수온, 영양염, 유입·체류, 광조건, 운영 조건 등 여러 요인이 복합적으로 작용하므로, 단일 변수의 분포 특성만으로는 예측에 중요한 구조를 충분히 설명하기 어렵

다. 따라서 다변량 분석을 통해 변수 간 상관성 구조, 정보 중복(redundancy) 및 잠재적 다중공선성, 특정 변수 집합 간 결합 패턴과 경향성을 파악하고, 모델 입력 구성과 해석 체계를 정교화할 수 있다.

한편, 두 변수 간 관계만을 집중적으로 살펴보는 경우는 이변량 분석(bivariate analysis)으로 구분할 수 있으며, 본 연구의 다변량 분석은 이변량 관계(상관·부분상관)를 기반으로 확장하여 전체 변수 집합의 상호연결 구조를 점검하는 방식으로 수행되었다.

나. 수치형 변수의 다변량 비시각화: 상관계수 기반 관계 진단

① 피어슨 상관계수와 상관행렬 산출

수치형 변수 간 선형관계를 가장 일반적으로 요약하는 지표로 피어슨 상관계수(Pearson's r)를 사용하였다. 피어슨 상관계수는 해석이 직관적이며, 전체 변수 집합에 대해 계산하면 상관행렬(correlation matrix) 형태로 변수 간 관계를 일괄적으로 점검할 수 있다. 본 연구에서는 상관행렬을 통해 동일 계열 변수(예: 유입량과 최대유입량, 방류량과 최대방류량 등) 간 매우 높은 상관이 존재하는지, 수질 변수군(영양염, 유기물 지표, DO, Chl-a 등) 내부에서 강한 동행관계가 나타나는지, 운영·수문 변수와 수질 변수 간에 구조적으로 설명 가능한 상관 패턴이 형성되는지 등을 점검했다(<그림 6.13>). 이러한 점검은 단순히 상관계수가 크거나 작은 수치를 넘어, 모델 입력에서의 정보 중복 제거, 해석 시 혼선 방지, 모델이 특정 변수군에 과도하게 의존하는지 여부를 점검하는 기반이 된다.

	남조류(추동)	수온(1,상)	DO(1,상)	BOD(1,상)	COD(1,상)	Chl-a(1,상)	TN(1,상)	TP(1,상)	TOC(1,상)	pH(1,상)	EC(1,상)	SS(1,상)	평균강우량	유입량	최대유입량	방류량	최대방류량	저수량
남조류(추동)	1.000000	0.299907	-0.086310	0.309651	0.396019	0.485115	-0.132927	0.327820	0.310749	0.200523	-0.042210	0.390981	0.110131	0.114987	0.100543	0.118064	0.084127	0.227230
수온(1,상)	0.299907	1.000000	-0.583491	0.680697	0.468618	0.495937	-0.083164	0.427388	0.455663	0.599947	0.160086	0.483679	0.391144	0.296629	0.291202	0.259626	0.211431	-0.033095
DO(1,상)	-0.086310	-0.583491	1.000000	-0.283547	-0.319030	-0.196711	0.056821	-0.271132	-0.209101	-0.000600	0.027508	-0.224565	-0.225981	-0.191689	-0.189302	-0.116375	-0.107248	-0.164611
BOD(1,상)	0.309651	0.680697	-0.283547	1.000000	0.448948	0.513762	-0.071812	0.408210	0.424028	0.549744	0.043766	0.517811	0.362776	0.327591	0.297982	0.301326	0.280305	-0.029536
COD(1,상)	0.396019	0.468618	-0.319030	0.448948	1.000000	0.531070	-0.192008	0.379601	0.625691	0.276510	0.193971	0.461533	0.167076	0.172607	0.105066	0.187839	0.114748	0.455321
Chl-a(1,상)	0.485115	0.495937	-0.196711	0.513762	0.531070	1.000000	-0.083512	0.403683	0.520701	0.337087	-0.048487	0.753614	0.199237	0.218796	0.191218	0.216954	0.180654	0.247428
TN(1,상)	-0.132927	-0.083164	0.056821	-0.071812	-0.192008	-0.083512	1.000000	0.093749	0.004944	-0.102745	-0.244295	0.015434	-0.001746	0.052171	0.076857	0.092342	0.099371	0.052025
TP(1,상)	0.327820	0.427388	-0.271132	0.408210	0.379601	0.403683	0.093749	1.000000	0.353783	0.227344	-0.051499	0.416251	0.227419	0.267089	0.286755	0.268296	0.209919	0.264438
TOC(1,상)	0.310749	0.455663	-0.209101	0.424028	0.625691	0.520701	0.004944	0.353783	1.000000	0.301397	-0.015893	0.469902	0.206283	0.217376	0.175943	0.219502	0.140526	0.380765
pH(1,상)	0.200523	0.599947	-0.000600	0.549744	0.276510	0.337087	-0.102745	0.227344	0.301397	1.000000	0.231921	0.299637	0.231138	0.108153	0.117454	0.117378	0.098612	-0.199657
EC(1,상)	-0.042210	0.160086	0.027508	0.043766	0.193971	-0.048487	-0.244295	-0.051499	-0.015893	0.231921	1.000000	-0.118776	0.123316	0.038135	-0.025205	0.000242	-0.068985	-0.183073

<그림 6.13> 피어슨 상관계수로 상관행렬 및 편상관행렬 산출(대청호 예시)

② 단순 상관의 한계와 편상관계수의 도입

다만 다수의 변수가 동시에 상호작용하는 환경 시스템에서는, 두 변수 간 단순 상관만으로는 "순수한 관계"를 파악하기 어렵다. 예를 들어 수온과 조류 지표가 강한 상관을 보이더라도, 실제로는 일사량, 체류시간, 영양염 상태 등 제3의 요인이 함께 움직이면서 겉보기 상관을 강화했을 가능성이 있다. 이러한 문제를 완화하기 위해, 본 연구에서는 편상관계수(partial correlation coefficient)를 함께 활용하였다. 본 연구에서 편상관을 병행한 이유는 단순 상관이 포함하는 총효과(직접+간접)와 달리, 편상관은 다른 변수들의 영향을 제거한 후

의 직접적 연관성에 가까운 정보를 제공하며, 변수 선택 과정에서 단순 상관이 큰 변수라도 편상관이 매우 작거나 부호가 바뀌는 경우가 있으며(매개·억제·공선 구조), 이는 해석과 일반화 성능 측면에서 중요한 신호가 되기 때문이다.

다. 수치형 변수의 다변량 시각화: 관계 구조의 직관적 해석

다변량 데이터는 수치 요약만으로는 관계 구조를 직관적으로 파악하기 어렵기 때문에, 본 연구에서는 그래픽 기반 시각화를 통해 변수 집합의 상호관계를 명확히 제시하였다.

① 상관행렬 히트맵(heatmap)

상관행렬을 색상으로 표현한 히트맵(heatmap)은 변수 간 관계의 강도와 방향(양/음)을 한 눈에 보여주는 대표적 도구이다. 히트맵을 통해 강한 상관의 블록 구조(변수군 단위의 묶음), 특정 변수의 광범위한 동행 패턴(허브 변수), 음의 상관이 체계적으로 나타나는 쌍(상반된 물리 메커니즘 가능)을 식별할 수 있었다. 이는 이후 단계에서 변수군을 통합하거나 대표 변수를 선택하는 등 차원 축소적 의사결정의 정성적 근거를 제공한다.

② 상관행렬과 히스토그램, 산점도

산점도를 함께 제시하는 상관계수 행렬은, 단일 상관계수 표가 제공하는 선형 요약을 넘어 변수 관계의 구조적 특성을 동시에 진단할 수 있다는 점에서 탐색적 데이터 분석(EDA) 단계에서 중요한 의미를 갖는다. 일반적인 상관행렬은 변수쌍의 연관성을 하나의 수치로 압축하여 제시하므로 전체 변수 집합의 관계 구조를 신속히 조망할 수 있으나, 상관계수의 크기만으로는 관계의 형태(비선형성, 문턱효과), 데이터 품질(이상치·레버리지), 집단 혼합(계절·수문상태·운영모드) 등 예측모델 구축에 직접적인 영향을 미치는 핵심 특성을 충분히 파악하기 어렵다. 이에 따라 본 연구에서는 상관계수 행렬을 산점도와 결합하여 변수쌍별 분포와 관계 양상을 시각적으로 확인함으로써, 수치 요약과 구조 진단을 결합한 인사이트를 얻고자 하였다.

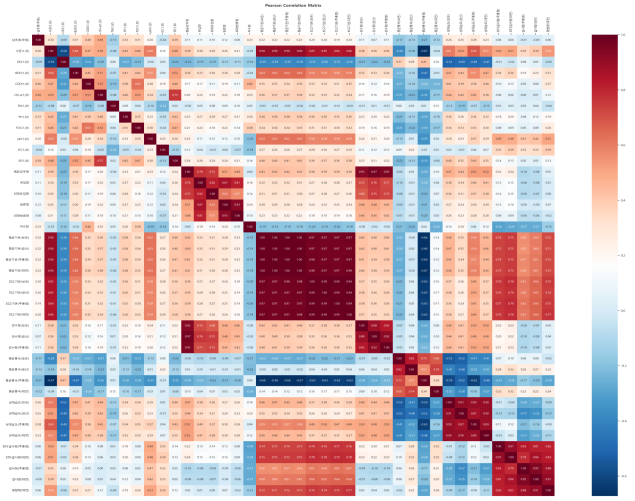

<그림 6.14> 상관행렬 히트맵(대청호 예시)

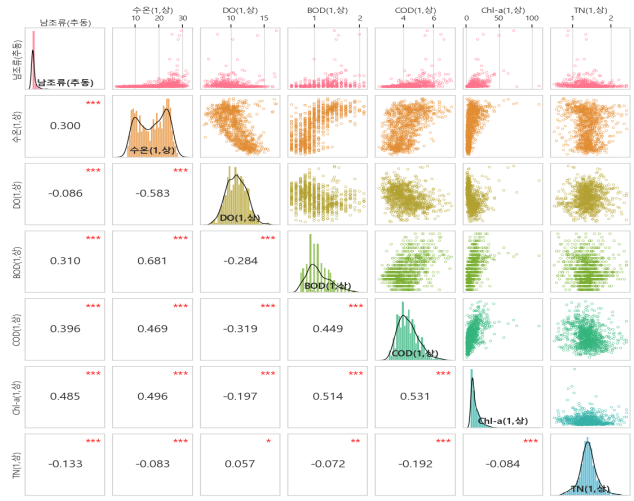

<그림 6.15> 상관행렬 산점도(대청호 예시)

6.3.5 모델 설정

본 연구에서는 대청댐에서 수집된 총 84개의 녹조, 일반수질, 댐 운영, 기상 관련 변수를 대상으로 종속변수 및 다른 설명변수와의 상관성, 녹조발생 특성에 대한 도메인 지식을 종합적으로 고려하여 최종적으로 40개의 설명변수를 선정하였다. <그림 6.16>은 독립변수 간 중복성 제거에 따른 단계적 변수 선택(Greedy) 방식에 따라 변수 선택을 수행하는 과정을 나타내고 있다.

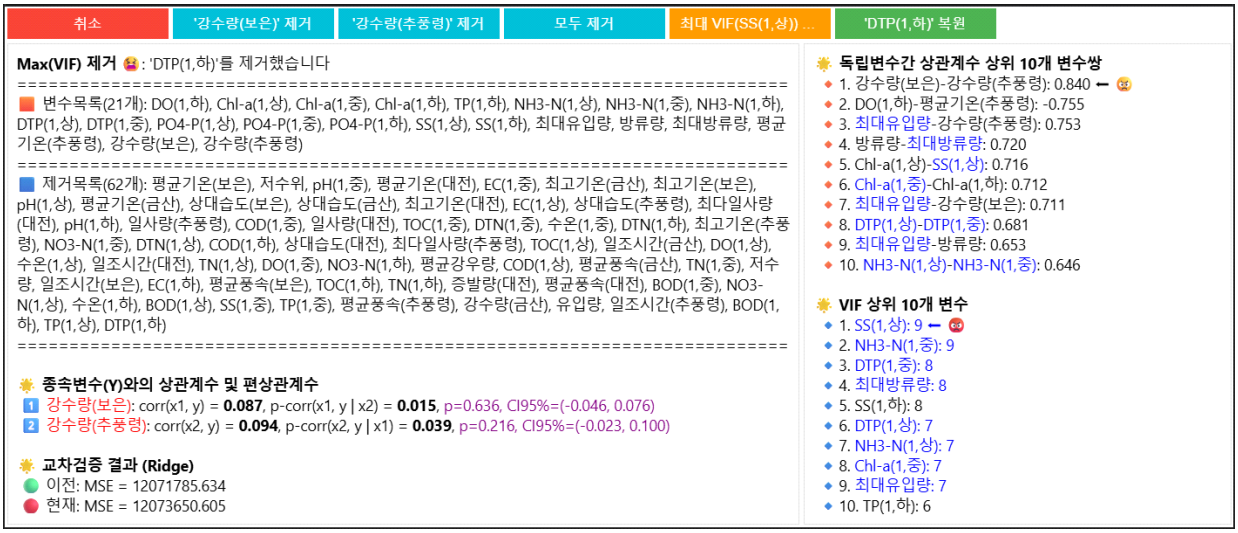

<그림 6.16> 독립변수 간 중복성 제거에 따른 단계적 변수 선택(Greedy 방식)

또한, 본 연구는 남조류 세포수의 시간적 의존성과 계절적 변화 양상을 반영하기 위하여 각 변수에 대해 현재 시점(t)을 포함하여 최대 3주 전 시점($t-3$)까지의 시차 변수(lag variable)를 추가하였다. 아울러, 단기 예측과 중기 예측의 성능 차이를 비교·분석하기 위해 리드타임(lead time), 즉 예측 선행시간을 1주($t+1$)에서 최대 3주($t+3$)까지 설정하였다. 이에 따라 모델 입력 데이터셋은 리드타임별로 개별 구축되었으며, 데이터 불균형 문제가 모델 학습에 영향을 미치는 것을 최소화하기 위해 오버샘플링 절차 또한 리드타임별로 독립적으로 수행하였다. 동일한 방식으로 모델 학습 및 검증 역시 리드타임별로 분리하여 수행함으로써, 리드타임 증가에 따른 예측 정확도 변화 및 민감도를 체계적으로 평가할 수 있도록 하였다. 식 (6.1)은 모델 입력 데이터셋의 구성을 나타낸 것이다.

$$Y_{t+lead} = \left\{ \left(X_t^k,\ X_{t-lag}^k \right) \mid k, lag, lead \right\} \qquad \text{식(6.1)}$$

$$k \in \{1, \cdots, 40\},\ lag \in \{1, 2, 3\},\ lead \in \{1, 2, 3\}$$

오버샘플링 적용을 위해서 입력 데이터셋은 훈련/시험용으로 먼저 분할하였으며, 오버샘플링은 훈련용(training set)에 대해서만 수행하고, 생성된 합성 샘플 역시 훈련 데이터에만 추가하였다. 이는 오버샘플링 과정에서 시험 데이터셋의 정보가 모델 학습에 유입되어 발생할 수

있는 데이터 누수(data leakage)에 따른 과적합을 방지하기 위함이다. 데이터 분할 기준은 녹조 시계열의 시간 연속성과 계절성, 그리고 고농도 희소 구간인 경계단계(≥10,000 cells/mL)의 샘플 확보 등을 고려하여 연도 단위로 설정하였다. 구체적으로 2005～2023년 자료를 훈련용으로, 2024년 자료를 시험용(test set)으로 구성하였다. 또한, 녹조가 거의 발생하지 않는 기간의 저농도 패턴을 제거함으로써 오버샘플링의 실효성을 높이기 위해 실제 대청댐에서 조류 증식이 집중적으로 나타나는 7～10월까지의 시계열만을 훈련용 데이터셋에 포함하였다.

<표 6.16> 오버샘플링 모델별 하이퍼파라미터 설정

SMOGN	GAN	TimeGAN	Random Forest
k = 4, samp_method = 'extreme', under_samp = False, rel_method = 'auto', rel_coef = 4, rel_xtrm_type = 'high'	latent_dim = 32, batch_size = 128, epochs = 2000, learning_rate = 0.0002, n_generate = 200	seq_len = 80(weeks), input_dim = 40, hidden_dim = 48, z_dim = 32, num_layers = 3, lr = 1e-3 batch_size = 64	n_estimators=150, max_depth=None, bootstrap=True, oob_score=True, n_jobs=-1

<표 6.16>은 각 오버샘플링 기법들의 하이퍼파라미터 설정값을 정리한 것이다. SMOGN의 오버샘플링은 반응변수 y(남조류 세포수)에서 "희소하지만 중요한 구간"을 relevance function ϕ로 정의한 뒤, $\phi(y)$가 임계값 t_R 이상인 관측치를 희소(rare) 사례로 간주하여 해당 구간을 중심으로 합성 데이터를 생성하는 방식이다. 구체적으로 $\phi : y \rightarrow [0,1]$는 목표변수 값을 0～1의 중요도(relevance)로 설정하며, $\phi(y) \geq t_R$이면 희소·관심 구간, $\phi(y) < t_R$이면 일반(다수) 구간으로 분리한다. 본 연구는 관련 하이퍼파라미터를 rel_method=auto, rel_xtrm_type=high로 설정하였다. 일반적으로 목표변수의 표본분포로부터 $\phi(y)$를 추정하기 위해 rel_method= auto로 설정하는데, IQR(Inter Quantile Range)을 이용해 극단 구간을 희소구간(el_xtrm_type=high로 상위 꼬리로 한정)으로 간주한다(Branco et al., 2017). rel_method를 수동(manual)으로 설정하면 중요도 함수의 구간 분할을 사용자가 이산적으로 입력해야 한다.

희소 구간의 threshold(t_R)는 rel_thres를 이용해 중요도 함수 ϕ의 0～1 값 범위에서 설정 하거나, IQR 기반 희소구간 경계인 rel_coef로 설정할 수 있는데, 본 연구는 rel_coef=4로 설정하여 해당 구간의 샘플 밀도를 집중적으로 보강하였다. 실제 합성샘플은 근접 이웃 방식인 k-NN 기반으로 생성(k=4)하게 되며, 전반적인 오버샘플링 분포는 samp_method='extreme'을 적용해 희소 구간에서 상대적으로 더 높은 오버샘플링이 이루어지도록 설정하였다. 또한 다수 구간의 정보 손실을 최소화하기 위해 under_samp=False로 언더샘플링은 수행하지 않았다.

GAN과 TimeGAN의 경우 오버샘플링으로 합성하는 데이터의 스케일 일관성과 수치적 안정성을 확보하기 위해 입력변수에 대해 Min‑Max 정규화를 적용하였다. 이는 변수 간 범위를 통일함으로써 생성자가 상대적 분포 구조를 안정적으로 학습하고, 학습 초기에 특정 변수 스케일이 기울기 업데이트를 지배하는 현상을 완화하기 위한 전처리 전략이다. 생성자와 판별자의

네트워크 구조는 Radford et al. (2015)이 제시한 안정적 GAN 학습 설계 원칙을 참고하여, 생성자는 저차원 특징 벡터를 점진적으로 확장(64 – 128 – 256)해 다변량 분포를 복원하고, 판별자는 반대로 축소(256 – 128 – 64)하여 진위 판별에 유효한 핵심 특징을 추출하도록 구성하였다. 활성 함수는 은닉층에 ReLU를 적용해 비선형 표현력을 확보하였으며, 판별출력층에는 시그모이드를 배치해 입력 샘플의 진위 여부를 확률값으로 산출하도록 하였다. 또한 학습 과정의 불안정성을 완화하기 위해 Radford et al. (2015)에서 경험적으로 안정성이 보고된 Adam 설정(learning rate=0.0002, β=0.5)을 채택하여, 진동 및 발산 가능성을 낮추는 방향으로 훈련 파라미터를 선택하였다.

기본 GAN 구조를 기준선으로 선택한 이유는 그 구현의 단순성과 검증된 안정성 때문이다. GAN의 대표적인 구조로, 비교적 적은 파라미터 튜닝만으로도 확실한 학습 과정을 거칠 수 있으며, 이는 다양한 변형 모델들이나 대체 구조들의 성능을 검증하기 위한 출발점으로서 유용하다. 다만 본 연구에서 채택한 GAN 학습은 판별기가 상대적으로 빠르게 최적화될 경우 생성자로 전달되는 유효 기울기가 약화하여 학습이 정체될 수 있으며, 특히 데이터가 여러 개의 떨어진 값 범위에 나뉘어 분포하는 경우 이러한 문제가 두드러질 수 있다(Arjovsky and Bottou, 2017). 따라서 향후 연구에서는 Wasserstein 거리를 도입한 WGAN 또는 기울기 페널티를 추가한 WGAN-GP와 같은 대안적 손실/구조를 적용함으로써, 희소구간에서의 분포 보존 성능과 수렴 안정성을 개선할 가능성을 추가 검토할 필요가 있다(Arjovsky and Bottou, 2017).

6.4 대청호 적용 결과 및 분석

6.4.1 오버샘플링

본 연구는 데이터 불균형을 완화해 모델의 예측성능을 개선하기 위하여 SMOGN, GAN, TimeGAN 등 다양한 오버샘플링 기법을 적용하였으며, <그림 6.17~19>는 오버샘플링 전·후의 구간분포 변화를 조류경보제 등급으로 재분류해 나타낸 것이다. 리드타임별로 구축된 원본 훈련 데이터셋은 정상(1,000셀 미만)과 관심(1,000셀 이상) 등급 샘플이 각각 180여 개, 150여 개로 상대적으로 많고, 경계(10,000셀 이상) 등급은 9개에 불과한 전형적인 불균형 구조를 보였다. 오버샘플링 적용 결과 모든 기법에서 소수 구간의 샘플 비중이 증가하였지만, 등급별 재분류 기준으로 살펴보면 기법 간 결과 차이가 컸다.

SMOGN은 관심등급과 경계등급에 해당하는 합성 샘플을 유사한 수로 생성하였는데, 희소성이 클수록 중요도를 더 높게 설정해 집중적으로 오버샘플링 하였음을 나타내는 것이다. 이는 SMOGN이 다수 구간과 소수 구간의 국소적 밀도(local density) 차이를 보정(balancing)하는 방식으로 구간 간 비율을 중요도 기반(relevance-aware) 으로 균형 있게 조정하기 때문이다. 즉, 다수와 소수 구간을 강제로 균등화하는 것이 아니라, 목표변수의 연속형 분포를 유지하면서 소수 구간의 밀도만 강화하는 방식이다. 결국 SMOGN은 중·고농도 구간의 샘플 수를 전반적으로 강화하는 데 유리한 것으로 볼 수 있다.

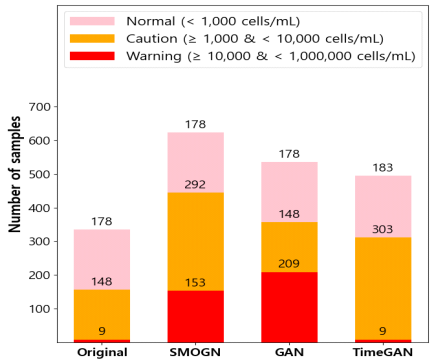

Alert System	원본 데이터	SMOGN	GAN	Time-GAN
평상시	178 (53.13%)	178 (28.57%)	178 (33.27%)	183 (36.97%)
관심	148 (44.18%)	292 (46.87%)	148 (27.66%)	303 (61.21%)
경계	9 (2.69%)	153 (24.56%)	209 (39.07%)	9 (1.82%)

<그림 6.17> 리드타임 1주 후 오버샘플링 결과

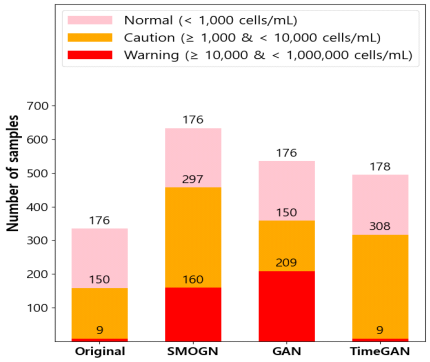

Alert System	원본 데이터	SMOGN	GAN	Time-GAN
평상시	176 (52.54%)	176 (27.80%)	176 (32.90%)	178 (35.96%)
관심	150 (44.78%)	297 (46.92%)	150 (28.04%)	308 (62.22%)
경계	9 (2.69%)	160 (25.28%)	209 (39.07%)	9 (1.82%)

<그림 6.18> 리드타임 2주 후 오버샘플링 결과

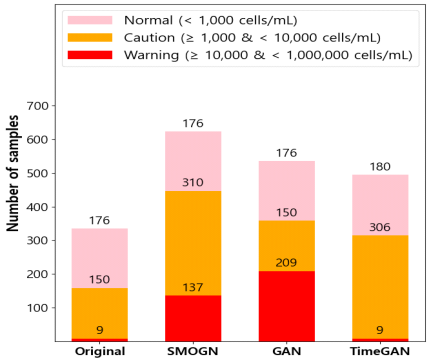

Alert System	원본 데이터	SMOGN	GAN	Time-GAN
평상시	176 (52.54%)	176 (28.25%)	176 (32.90%)	180 (36.36%)
관심	150 (44.78%)	310 (49.76%)	150 (28.04%)	306 (61.82%)
경계	9 (2.69%)	137 (21.99%)	209 (39.07%)	9 (1.82%)

<그림 6.19> 리드타임 3주 후 오버샘플링 결과

반면, GAN은 학습 과정에서 원본 데이터의 분포를 최대한 모사하도록 설계되어 희소 구간의 비중을 의도적으로 조정하지 않으므로, SMOGN과 달리 생성된 데이터에서도 고농도 샘플의 희소성은 그대로이다. 따라서 본 연구는 경계등급을 조건부 희소 구간으로 지정해 합성 샘플을 생성한 후, 이를 원본 데이터와 결합하는 conditional GAN(cGAN) 방식으로 오버샘플링을 수행하였다. 결과적으로 GAN은 원본 데이터의 통계적 특성을 충실히 재현하면서도 데이터의 다양성 확보 및 일반성을 강화하므로 과적합 가능성을 줄이면서 새로운 데이터셋을 생성하는 데에는 효과적이나, 구간 간 분포를 자연스럽게 재조정하는 데에는 한계가 있는 것으로 판단된다.

TimeGAN은 설계상 시간 의존성 보존에 특화되어 시간적 구조를 가진 시퀀스를 통합된 형태로 재현하는 데 초점을 두고 있다. 따라서 각 샘플을 시계열적 맥락 없이 독립적으로 생성하는 일반 GAN처럼 희소 구간에 대한 명시적 조건을 통해 원하는 고농도 샘플만 증강하는 방식을 적용하기는 어렵다. 결과적으로 <그림 6.17~19>에서 나타나듯이 극도로 희소한 경계등급 샘플의 밀도는 전혀 개선하지 못하고 오히려 샘플이 풍부한 관심등급만 추가로 증강하는 현상이 나타났다. 이러한 점을 종합하면, TimeGAN은 시계열 구조 보존과 분포 재현 측면에서는 유용하지만, 본 연구와 같이 원자료에서 극히 일부만 존재하는 고농도 경계등급을 선택적으로 강화해야 하는 오버샘플링 목적에는 적합하지 않은 방법으로 판단된다.

6.4.2 예측성능 개선 효과

오버샘플링 기법별로 증강된 훈련용 데이터는 랜덤포레스트 모델로 학습시킨 후, 사전 분할된 2024년 관측치로 이루어진 시험 데이터셋에 적용하여 원본 데이터셋 대비 오버샘플링의 예측성능 개선 효과를 분석하였다. <그림 6.20>은 오버샘플링 기법별 남조류 세포수 예측 결과를 리드타임에 따라 나타낸 것이다. 전반적으로 오버샘플링을 적용했을 때의 결과가 적용하지 않은 원본 데이터(original data)의 결과보다 상대적으로 관측 데이터의 고농도 구간 주변 패턴을 유사하게 재현하는 경향을 보였다. 특히, SMOGN이 다른 기법보다 남조류 세포수가 급증하는 첨두 구간에서 관측 데이터의 형태와 높이를 가장 근접하게 예측한 것으로 나타났다.

한편, 모델의 리드타임이 길어질수록 예측성능은 불안정해지고 관측값과의 오차가 커지는

것이 일반적이나, SMOGN은 전반적인 성능이 안정적으로 유지되는 것을 확인할 수 있다. 반면 GAN은 첨두의 크기는 SMOGN과 비슷한 수준이었으나, 리드타임이 길어짐에 따라 발생 시점의 정확도가 크게 낮아졌다. TimeGAN의 예측성능은 전반적으로 원본 데이터셋에 비해 개선된 점이 없었으며, 이는 희소 구간에서 오버샘플링이 전혀 이루어지지 않았기 때문으로 판단된다.

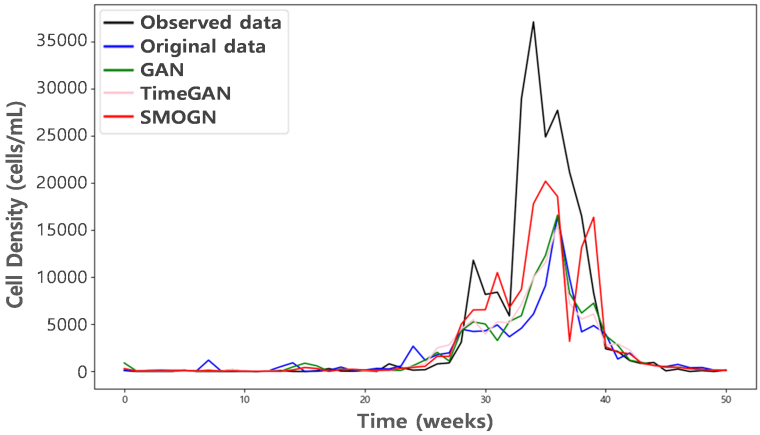

(a) 1주 후 예측

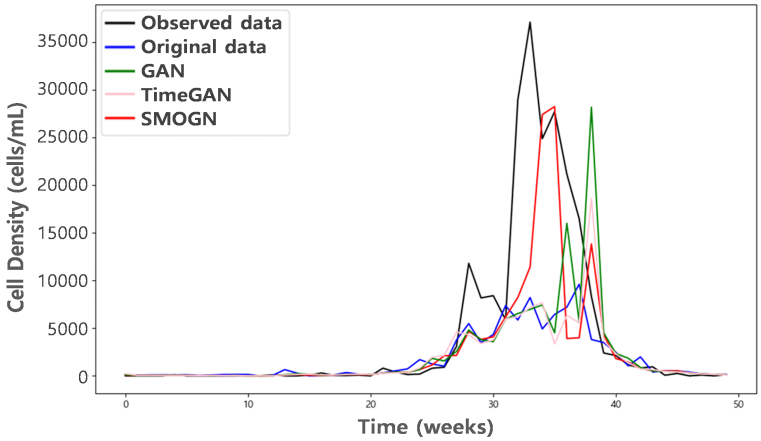

(b) 2주 후 예측

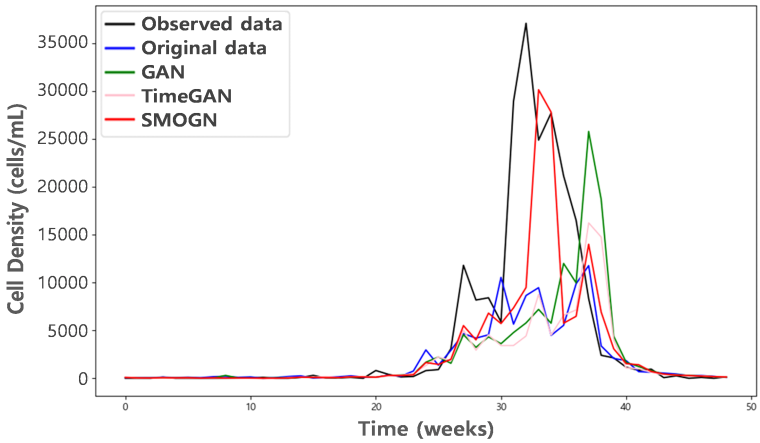

(c) 3주 후 예측

<그림 6.20> 랜덤포레스트 모델의 예측 결과

예측성능 개선 효과를 더욱 엄밀하게 분석하기 위해 성능 평가 지표를 산정하였다. <표 6.17>은 시험 데이터셋에 대한 랜덤포레스트 모델의 성능 평가 지표 값을 오버샘플링 기법과 리드타임별로 나타낸 것이고, <그림 6.21>은 를 리드타임에 따른 성능 변화 양상으로 나타낸 것이다. 전체적으로 오버샘플링을 적용한 모든 경우가 원본 데이터 대비 일정 수준의 개선을 보이는 가운데, 그 정도와 양상은 오버샘플링 기법과 리드타임에 따라 뚜렷한 차이가 있음을 알 수 있다.

<표 6.17> 오버샘플링 기법별 예측 성능지표 비교

리드타임	성능지표	원본데이터	SMOGN	GAN	Time-GAN
1주	RMSE(cells/mL)	6756	5104	6120	6166
	NSE(<1.0)	0.39	0.65	0.50	0.49
	PBIAS(%)	-52.6	-29.8	-51.3	-49.3
	MAPE(%)	780.7	204.6	229.9	264.3
2주	RMSE(cells/mL)	7169	5790	7604	7558
	NSE(<1.0)	0.33	0.56	0.24	0.25
	PBIAS(%)	-57.7	-36.9	-47.0	-55.6
	MAPE(%)	630.8	161.8	198.2	161.4
3주	RMSE(cells/mL)	7202	5910	8041	8001
	NSE(<1.0)	0.33	0.55	0.17	0.17
	PBIAS(%)	-52.9	-32.0	-42.3	-54.3
	MAPE(%)	232.1	84.8	230.1	104.7

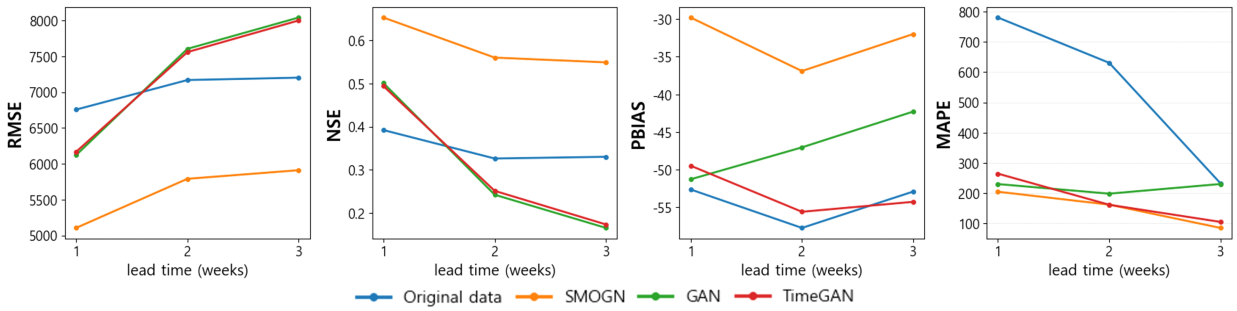

<그림 6.21> 리드타임에 따른 모델 성능

RMSE는 모든 리드타임에서 SMOGN이 가장 낮은 값을 보여 모델의 평균 오차 규모 측면에서 가장 일관된 개선 효과를 나타냈다. 특히 1주 예측에서는 원본보다 약 20% 이상 감소하였고(6756→5104), 2·3주 예측에서도 약 18 - 20% 수준의 감소가 유지되어 첨두 시점이나 고농도 구간의 오차를 효과적으로 억제한 것으로 해석된다. 반면 GAN과 TimeGAN은 1주 예측에서는 원본보다 다소 작지만, 2·3주 예측에서는 오히려 오차가 커진 것을 알 수 있다. 이는 중·고농도 구간의 샘플 수를 균형 있게 조정한 SMOGN에 비해 GAN과 TimeGAN 처럼 특정 구

간의 샘플만 중점 생성해 학습함으로써, 전체 평균 오차 구조를 악화시켰기 때문으로 판단된다.

NSE는 모델이 관측값의 변동성을 얼마나 잘 설명하는지를 비율로 나타내는 지표로, 시계열 구조 재현 성능을 평가하는 데 핵심적이다. SMOGN은 1주 예측에서 0.65, 2·3주 예측에서 각각 0.56, 0.55로 원본의 성능을 효과적으로 개선한 것으로 나타났다. GAN과 TimeGAN도 1주 예측에서는 NSE 0.50, 0.49로 원본보다 개선되지만, 리드타임이 길어질수록 0.25 이하로 급격히 저하되어 변동성 재현 능력이 크게 떨어지는 것으로 나타났다.

PBIAS는 모형의 전반적 편향성을 진단하는 지표로, 부호와 크기를 통해 과대(+)·과소(-) 추정을 구분할 수 있다. 전체적으로 원본을 포함 네 가지 데이터셋 모두 음(-)의 PBIAS를 보여 남조류 세포수를 전반적으로 과소 추정하는 경향이 유지되고 있으나, SMOGN은 모든 리드타임에서 PBIAS의 절댓값이 뚜렷이 감소하여 전반적인 편향 규모가 유의미하게 완화된 것으로 해석된다. GAN의 경우도 원본 대비 과소추정 완화 효과를 보이지만, 그 개선 폭은 SMOGN에 비해서는 매우 제한적이며, TimeGAN은 PBIAS 절댓값이 거의 감소하지 않거나 오히려 커지는 구간도 나타나 비효율적인 것으로 나타났다.

MAPE는 각 관측치별 상대 오차의 절댓값을 평균한 지표로, 개별 샘플 수준의 예측 정확도를 평가하는 데 유용하다. 오버샘플링을 적용한 세 가지 데이터셋의 MAPE는 동일 리드타임에서 원본에 비해 매우 감소하여, 상대오차 관점에서의 예측 안정성이 크게 향상된 것을 확인할 수 있다. 오버샘플링 기법 간 비교에서는 SMOGN이 가장 낮은 오차를 나타냈다.

<그림 6.21>에서 리드타임에 따른 성능 변화를 살펴보면, 모든 데이터셋에서 리드타임이 길어질수록 RMSE 증가와 NSE 감소가 나타나 남조류 세포수 예측의 불확실성이 예측시간 선행이 길어질수록 커지는 일반적 경향을 확인할 수 있다. 반면 PBIAS와 MAPE는 리드타임 증가에 따른 단조적 경향을 보이지 않았는데, 이는 RMSE와 NSE와 같이 오차 분산의 크기에만 반응하는 것이 아니라 과대· 과소추정의 상쇄 효과, 관측값의 크기, 구간별 샘플 분포 등 데이터셋의 구조 변화에 더욱 민감하게 반응하기 때문으로 판단된다.

6.4.3 모델의 일반화 성능 검증

본 연구는 오버샘플링 기법을 적용한 녹조예측 모델의 일반화 성능을 검증하기 위해, 앞서 예측성능 개선 효과가 가장 큰 것으로 나타난 SMOGN에 대해 연도 기반 Rolling Cross-Validation을 수행하였다. 실험은 20개년(2005- 2024년)의 데이터셋을 순차적으로 과거 5년 데이터로 훈련하고, 미래 1년 데이터에 검증하는 방식으로 전진시켜 총 15개 rolling 분할(splits)로 이루어졌다. Table 4는 오버샘플링 수행 유/무에 따른 Original 모델과 SMOGN 수행 모델의 연도별 RMSE 기준 성능 변동성을 나타내고 있으며, 95% 신뢰구간은 15개 rolling 분할 결과를 표본 단위로 하여 부트스트랩(percentile, 반복횟수=2000) 방법을 적용해 산출하였다. 그 결과, Original 모델의 평균 RMSE는 3581.35(95% CI: 2736.91 – 4542.76)이며, SMOGN의 평균 RMSE는 3273.00(95% CI: 2603.07 – 4069.07)으로 나타났다. 이는 SMOGN으로 오버샘플링을 수행하는 것이 수행하지 않는 것에 비해 평균적으로 낮은 오차를 발생시키고 있음을 확인

하는 결과이나, 두 방법 모두 신뢰구간의 폭이 크게 나타나고 상당부분 중첩되는 등 변동성이 커서 평균적 성능 차이가 통계적으로 유의하다고 단정 짓기는 어려움을 의미한다.

이러한 결과의 근본적 원인은 SMOGN과 같은 오버샘플링 기법들이 모델이라기보다 데이터 변환 연산자에 가깝기 때문이다. 즉, 모델 파라미터보다 훈련 데이터의 분포(불균형 정도)에 민감하게 반응하기 때문에 각 분할의 데이터 불균형 정도가 다를 경우 CV 평균 성능이 SMOGN의 본질적 효과를 대표하지 못할 수 있다. <표 6.18>에서 방법 간 성능 차이인 $\Delta RMSE_i$ $(SMOGN_i - Orig_i)$의 결과를 살펴보면 이러한 점이 명확해진다. $\Delta RMSE_i$가 음수이면 성능 개선, 양수인 경우 성능 악화를 나타내는데, 15개 분할 중 9개 연도에서 SMOGN 수행이 모델 성능을 개선하였으나, 6개 연도에서는 오히려 성능을 악화시킨 것으로 나타났다. <그림 6.22>에서는 더욱 직관적인 해석이 가능한데, 분할 6(2010-2014년 훈련, 2015년 검증)이 매우 큰 음의 $\Delta RMSE$를 나타낸 것은 훈련 데이터의 데이터 불균형이 심각해 SMOGN 오버샘플링 후 극단적 개선이 이루어진 것으로 추정할 수 있으며, $\Delta RMSE$>0인 분할들은 훈련 데이터의 분포가 비교적 안정적이어서(극단값 비중 낮음) SMOGN 합성 샘플들이 오히려 노이즈를 증가시키거나 원본 분포를 왜곡했을 가능성이 있다.

<표 6.18> Rolling Cross-Validation 수행 결과

분할	훈련 연도	RMSE (cells/mL)		
		원본 데이터	SMOGN	Δ RMSE
1	2005-2009	7362.587	7241.867	-120.72
2	2006-2010	2589.27	3205.931	616.661
3	2007-2011	3577.18	4219.435	642.255
4	2008-2012	3163.83	2893.736	-270.094
5	2009-2013	3462	3034.546	-427.454
6	2010-2014	7160.614	2665.566	-4495.05
7	2011-2015	2040.463	1991.621	-48.842
8	2012-2016	2567.206	2274.506	-292.7
9	2013-2017	2683.887	3123.496	439.609
10	2014-2018	1907.733	2285.34	377.607
11	2015-2019	1886.834	2226.877	340.043
12	2016-2020	1781.431	2468.498	687.067
13	2017-2021	2710.615	1866.255	-844.36
14	2018-2022	6766.312	6219.934	-546.378
15	2019-2023	4060.219	3377.326	-682.893
RMSE 평균		3581.35	3273.00	-308.35
95% 신뢰구간(CI)		[2736.91, 4542.76]	[2603.07, 4069.07]	[−992.47, 177.52]

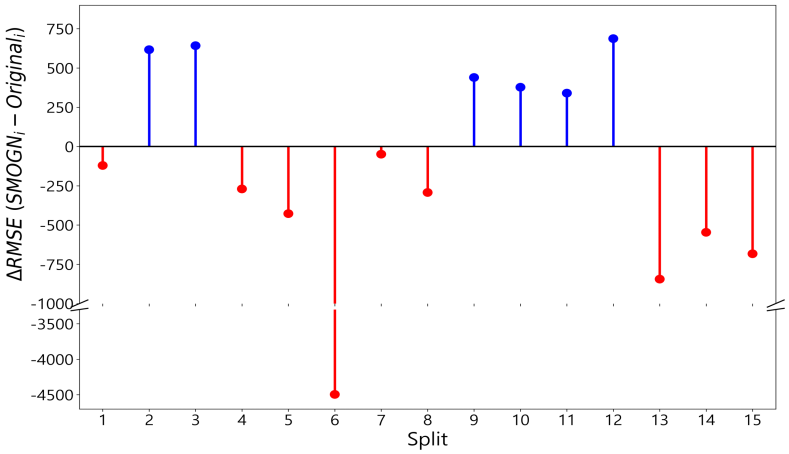

<그림 6.22> SMOGN 적용과 미적용의 RMSE 차이

결론적으로 연도 기반 Rolling CV에서 분할마다 불균형 구조가 다를 경우, 동일 파라미터의 SMOGN 적용이 항상 성능 향상으로 이어지지 않을 수 있다. 따라서 오버샘플링 기법이 적용된 모델의 교차검증은 평균 성능 우위 증명을 목표로 하기보다 원본 자료 대비 성능 민감도를 확인하여 파라미터의 강건성을 평가하는데 맞춰져야 할 것이다.

6.5 주암호 시험적용 결과

본 연구는 대청댐 추동 지점의 조류경보제 관련 데이터를 이용해 트리 모형(random forest)에 오버샘플링을 적용한 녹조 예측모델을 정밀하게 구축했다. 구축된 모델 아키텍처는 주암댐 저수구역에 위치한 댐앞 조류경보 지점과 신평교 조류경보 지점의 2004년~2024년 녹조데이터에 적용해 훈련(2004~2023) 및 시험(2024)을 수행하였다. 근처에 국가수질관측소가 없어 일반수질 자료 획득이 여의치 않은 신평교 지점의 경우 댐앞 지점에서 활용한 주암댐1 국가수질관측소 자료를 활용해 동일한 설명변수들로 시험적인 예측을 수행하였다.

6.5.1 주암호 댐앞 지점 적용 결과

<그림 6.23>은 주암댐 댐 앞 지점의 학습데이터 및 훈련/시험 조건을 나타낸 것이다. 대청댐 모델가 동일하게 시차변수는 lag0~3으로 설정하고, 녹조 발생 기간을 7월~10월로 한정해 훈련을 수행했다(시험은 2024년 전체에 적용).

<그림 6.24~26>에 나타난 결과를 보면 주암댐의 경우 RMSE, NSE, PBIAS 성능지표 모두에서 모델이 목표변수인 남조류세포수의 변동에 전혀 반응하지 못하고 있음을 알 수 있다. 특히 회귀모델의 시계열적 효율성을 나타내는 NSE의 경우 오버샘플링 모델과 리드타임에 따라서 음수도 나타나고 있어, 평균값으로 추정시 보다 예측력이 낮음을 알 수 있다. 대청호와 동일한 모델 아키텍처를 활용했음에도 이처럼 좋지 않은 예측력을 보이는 이유로 본 연구는 주암호의 녹조 및 기상 데이터의 일관성 문제가 있는 것으로 판단했다.

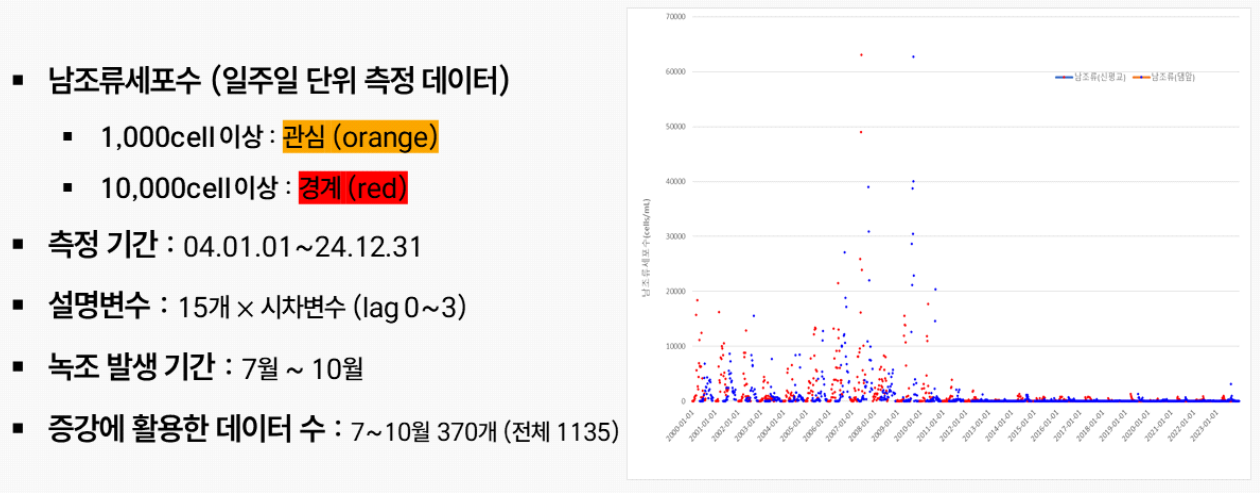

<그림 6.23> 주암호 댐앞 지점 학습데이터 및 훈련/시험 조건

<그림 6.23>에도 나타나듯이 주암호는 2011년까지 관심단계 이상 경보발령이 거의 매해 발생했고, 경계단계도 자주 발생한 것을 알 수 있다. 그러나 2011년 이후로는 특별한 유역내 오염원 변화나 기상변화가 없었음에도 조류경보가 2024년까지 14년간 전혀 발령되지 않았다. 이로부터 제기될 수 있는 가설은 2010~2012년부터 표층채수에서 혼합채수로 변경된 조류검사 채

수 기준으로 인해 데이터 드리프트가 발생했을 가능성이다. 목표변수와 설명변수 간의 물리적 관계가 변하지 않았는데 시계열 데이터에 큰 폭의 시프트나 추세 변화가 발생했다면 데이터 드리프트를 의심해 볼 수 있다. 또 한가지는 본 연구에서 입력데이터셋 구성 시 기상자료는 이 주암댐 인근인 주암관측소가 2011년 폐쇄되면서 2012년부터 순천관측소 자료를 활용한 부분이다. 순천관측소와 주암관측소간 거리와 유역내 지형적 차이가 적지 않으므로 이 또한 데이터 드리프트를 의심해 볼 수 있다.

① 1주 예측 $(Y_{t+1} \sim X_t,\ X_{t-1},\ X_{t-2},\ X_{t-3})$

Model	Performance	Original	SMOGN	GAN	TimeGAN
$Y_{t+1} \sim X$	RMSE	1312.221	1913.362	850.552	843.097
	NSE	-8.117	-18.382	-2.830	-2.763
	PBIAS	-85.369	-335.700	-97.460	-104.228
F1-score	경계	-	-	-	-
	관심	0.00	0.44	0.57	0.33
	평시	0.93	0.94	0.95	0.94
	전체	0.86	0.86	0.92	0.89

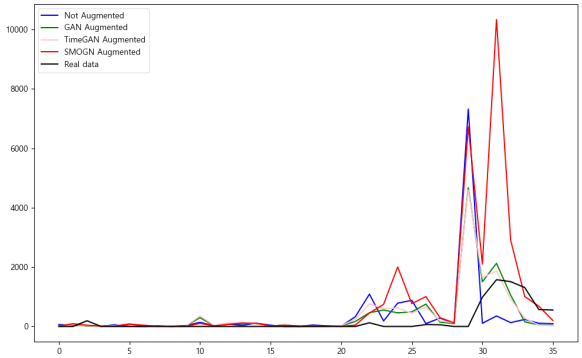

<그림 6.24> 주암호 댐앞 지점 랜덤포레스트 모델 예측 결과 (1주 후 예측)

② 2주 예측 $(Y_{t+2} \sim X_t,\ X_{t-1},\ X_{t-2},\ X_{t-3})$

Model	Performance	Original	SMOGN	GAN	TimeGAN
$Y_{t+2} \sim X$	RMSE	993.260	744.490	365.535	356.052
	NSE	-4.107	-1.869	0.308	0.344
	PBIAS	-83.382	-161.992	-53.263	-37.176
F1-score	경계	-	-	-	-
	관심	0.00	0.44	0.57	0.33
	평시	0.92	0.92	0.95	0.94
	전체	0.86	0.86	0.91	0.89

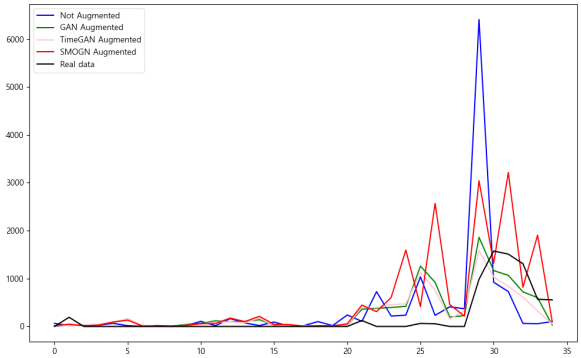

<그림 6.25> 주암호 댐앞 지점 랜덤포레스트 모델 예측 결과 (2주 후 예측)

③ 3주 예측 $(Y_{t+3} \sim X_t,\ X_{t-1},\ X_{t-2},\ X_{t-3})$

Model	Performance	Original	SMOGN	GAN	TimeGAN
$Y_{t+3} \sim X$	RMSE	366.445	462.532	300.368	312.786
	NSE	0.321	-0.082	0.544	0.505
	PBIAS	-22.730	-106.448	-20.810	-24.375
F1-score	경계	-	-	-	-
	관심	0.50	0.50	0.67	0.40
	평시	0.97	0.93	0.97	0.95
	전체	0.94	0.88	0.94	0.91

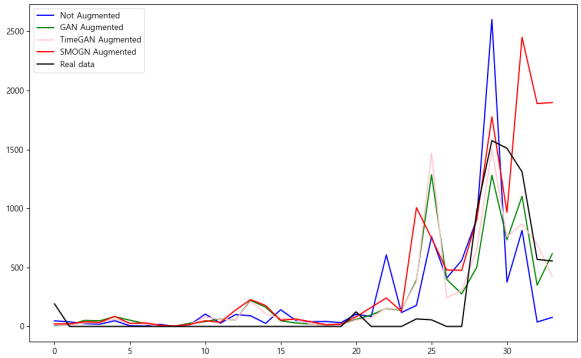

<그림 6.26> 주암호 댐앞 지점 랜덤포레스트 모델 예측 결과 (3주 후 예측)

6.5.2 주암호 신평교 지점 적용 결과

- 남조류세포수 (일주일 단위 측정 데이터)
  - 1,000cell 이상 : 관심 (orange)
  - 10,000cell 이상 : 경계 (red)
- 측정 기간 : 04.01.01~24.12.31
- 설명변수 : 15개 × 시차변수 (lag 0~3)
- 녹조 발생 기간 : 7월 ~ 10월
- 증강에 활용한 데이터 수 : 7~10월 370개 (전체 1135)

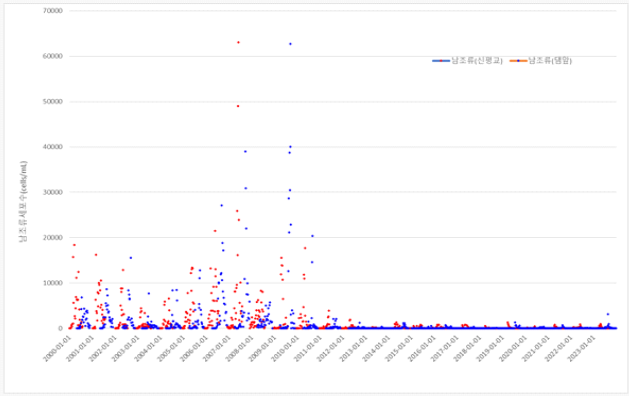

<그림 6.27> 주암호 신평교 지점 학습데이터 및 훈련/시험 조건

① 1주 예측 $(Y_{t+1} \sim X_t,\ X_{t-1},\ X_{t-2},\ X_{t-3})$

Model	Performance	Original	SMOGN	GAN	TimeGAN
$Y_{t+1} \sim X$	RMSE	725.901	775.156	714.407	1000.824
	NSE	-0.243	-0.418	-0.204	-1.363
	PBIAS	24.345	-36.643	-77.791	-122.267
F1-score	경계	-	-	-	-
	관심	0.00	0.40	0.67	0.60
	평시	0.94	0.96	0.95	0.94
	전체	0.89	0.92	0.92	0.89

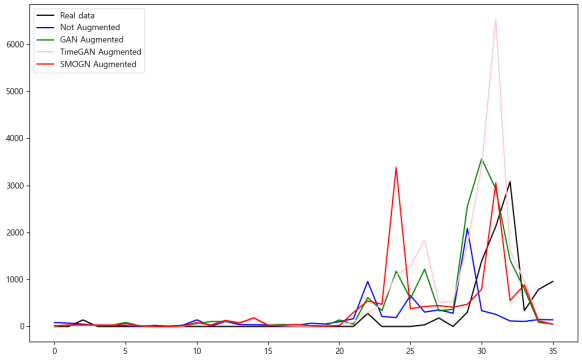

<그림 6.28> 주암호 신평교 지점 랜덤포레스트 모델 예측 결과 (1주 후 예측)

② 2주 예측 $(Y_{t+2} \sim X_t,\ X_{t-1},\ X_{t-2},\ X_{t-3})$

Model	Performance	Original	SMOGN	GAN	TimeGAN
$Y_{t+2} \sim X$	RMSE	1976.832	987.272	508.858	581.246
	NSE	-8.008	-1.247	0.403	0.221
	PBIAS	-103.267	-78.260	-60.910	-85.647
F1-score	경계	-	-	-	-
	관심	0.00	0.86	1.00	0.86
	평시	0.97	0.98	1.00	0.98
	전체	0.91	0.97	1.00	0.97

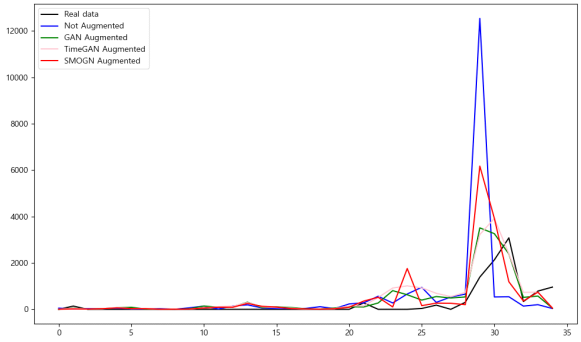

<그림 6.29> 주암호 신평교 지점 랜덤포레스트 모델 예측 결과 (2주 후 예측)

③ 3주 예측 $(Y_{t+3} \sim X_t,\ X_{t-1},\ X_{t-2},\ X_{t-3})$

Model	Performance	Original	SMOGN	GAN	TimeGAN
$Y_{t+3} \sim X$	RMSE	1436.439	529.113	580.440	392.003
	NSE	-3.644	0.370	0.242	0.654
	PBIAS	-91.453	7.534	-25.887	-29.284
F1-score	경계	-	-	-	-
	관심	0.80	0.40	0.50	0.86
	평시	0.98	0.95	0.97	0.98
	전체	0.97	0.91	0.94	0.97

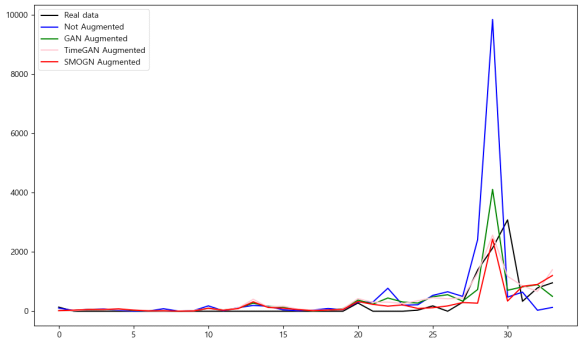

<그림 6.30> 주암호 신평교 지점 랜덤포레스트 모델 예측 결과 (3주 후 예측)

제 7장 기존 플랫폼 기반 하이브리드 AI 연계 방안

국내 주요 다목적댐 및 하천·호소 수계에서 녹조(남조류) 발생은 수돗물 안전성에 대한 사회적 우려를 증대시키고, 취·정수 운영의 부담(약품 사용량 증가, 역세·슬러지 처리, 취수원 변경 등)을 유발한다. 특히 녹조 발생은 기상(고온, 무강우, 약풍), 수문(체류시간 증가), 영양염(인·질소), 광환경 및 수체 안정도 등 복합 요인의 비선형 상호작용으로 좌우되어, 단일 모델 접근으로는 예측 성능과 운영 활용성을 동시에 충족하기 어렵다.

K-water는 HSPF(유역)-AEM3D(저수지)-CE-QUAL-W2(하천) 기반 수질모델을 사내 시스템으로 구현한 수리안(SURIAN)을 통해 현장자료 및 내부 DB와 연계된 시뮬레이션 운영체계를 보유하고 있다. 또한 다지점 모니터링 정보를 집약·제공하는 WQE를 운영 중이다. 본 장에서는 (1) AI 기반 녹조 예측모델을 WQE 내부에 탑재하고, (2) 수리안의 물리기반 예측 결과와 AI 모델의 데이터 기반 학습능력을 결합한 하이브리드 예측체계를 구축함으로써, (3) 현장 의사결정(조기경보, 운영대응, 시나리오 평가)에 직접 활용 가능한 수준의 예측 정확도·설명력·운영성을 확보하는 개발 방향을 제시하는 데 있다.

7.1 하이브리드 예측 기술의 개요

1) 기존 수질모델링 한계와 AI 접목의 필요성

물리기반 수질모델은 지배방정식과 계수(반응속도, 침강·재부유, 광제한, 온도 의존성 등)를 기반으로 수체 거동을 모사하므로 물리적 일관성과 설명 가능성이 강점이다. 반면 녹조예측은 임계값(Threshold) 기반 급증, 지점·수층별 국지적 현상, 관측 불확실성 및 입력자료 누락, 단기 기상 변동에 대한 민감도 등으로 인해 물리모델 단독으로는 오차가 확대될 수 있다. 특히, 운영현장에서는 정확도뿐 아니라 언제, 왜 위험이 커지는지에 대한 해석 가능한 경보정보와 신속하게 활용 가능한 산출물이 중요하므로, 물리 모델의 장점인 일관성·설명력과 AI 모델의 장점인 비선형 패턴 학습·실시간 보정·데이터 융합을 결합한 하이브리드적 접근이 요구된다.

AI 모델은 관측데이터 기반으로 복잡한 상호작용을 학습하여 단기 예측에서 강점을 보이나, 물리법칙을 위배하는 비현실적 예측, 데이터 분포 밖의 극한 현상의 일반화에 한계, 모델 드리프트 및 책임성 논란 등의 문제가 존재한다. 따라서 정책·운영적 관점에서 바람직한 방향은 물리모델을 예측의 기준선(baseline)으로 유지하되, AI 모델을 통해 물리 모델의 체계적 오차를 보정하고, 핵심 상태변수의 추정치를 보완하며, 빠른 의사결정용 대체모델(surrogate)을 제공하는 역할 분담형 결합 구조를 채택하는 것이다.

2) AI 모델과 물리모델의 특성 비교

수질 예측을 위한 모델링 접근법은 크게 물리 기반 모델과 데이터 기반 모델로 구분된다. 두 접근법은 상반된 강점과 약점을 지니고 있으며, 이를 이해하는 것은 하이브리드 모델의 필요성을 설명하는 근거가 된다.

기계학습·딥러닝 등 데이터 기반 모델은 과거 관측데이터로부터 입력-출력 간 상관관계를 학습하는 블랙박스 모델이다. 충분한 자료만 확보된다면 비선형적이고 복잡한 패턴도 모형이 스스로 찾아내므로 예측 정확도가 높고 개발 및 계산 속도가 빠른 경향이 있다. 실제로 최근 10여 년간 대용량의 수질 모니터링 자료가 축적되면서 이러한 데이터 기반 모델의 활용이 늘어나고 있으며, 유연한 구조와 모의 효율성, 뛰어난 비용효과 등으로 조류 조기경보 등 현장에서 많이 도입되고 있다. 예를 들어 단일 파라미터에 대한 조류 예측부터 딥러닝 기반 클로로필-a 농도 예측까지 다양한 AI 모델들이 연구되고 있다. 그러나, AI 모델은 물리적 인과관계에 대한 해석력이 부족하고 모델 내부 작동이 불투명하여 결과에 대한 원인분석이 어렵다는 단점이 있다. 또한, 개발에 사용된 특정 수체의 데이터 패턴에 최적화되기 때문에 적용 대상 수체가 바뀌거나 학습 범위를 벗어난 상황에서는 예측성능이 급격히 저하되고 일반화에 한계가 있다는 약점이 지적된다. 요컨대 범용성과 신뢰성 측면에서 순수 데이터 기반 접근은 단독으로는 한계를 가질 수 있다.

물리 기반 수치 모델(process-based model)은 유역과 수체의 물리·화학·생물학적 과정을 수식으로 구현한 것으로, 인위적 보정 없이도 다양한 시나리오에 대해 물리적으로 일관된 결과를 산출할 수 있고 해석 가능성이 높다는 이점이 있다. 예를 들어 CE-QUAL-W2, EFDC, WASP 등의 수질모델은 수온, 영양염, 조류 등 물질의 거동을 지배방정식으로 풀어내므로, 모델 결과를 통해 어떤 인자가 조류 증식에 기여했는지 등에 대한 원인분석과 설명이 가능하다. 또한 매개변수를 조정하면 다른 수계에도 적용할 수 있어 일반화 및 예측 범용성이 상대적으로 높다. 반면, 그 구조가 복잡하고 요구되는 입력자료 종류가 많으며, 수십~수백 개에 이르는 매개변수를 보정해야 하는 어려움이 있다. 특히 녹조와 같은 생태 현상을 정확히 모사하려면 조류 종별 동태, 영양염 순환 등 복잡한 생물화학적 상호작용을 포함해야 하므로 모델 개발과 적용이 더욱 복잡해진다. 이로 인해 충분한 현장 자료와 전문지식이 없으면 물리모델의 실무 적용에 시간과 비용 부담이 크고, 모델 불확실성이 존재하면 예측 결과에 대한 현장 신뢰도가 낮아질 수 있다. 이상의 내용을 정리하면 <표 7.1>과 같다.

<표 7.1> 물리 기반 모델과 AI 데이터 기반 모델의 주요 특성 비교

구분	장점	단점
물리 모델	- 현상의 원인과 인과관계 파악 용이 - 새로운 조건에도 비교적 일관된 예측	- 모형 구조 복잡, 매개변수 다수 - 방대한 입력데이터 및 높은 계산자원 필요 - 모델 보정에 많은 시간·노력 소요
AI 모델	- 관측데이터의 패턴 학습으로 높은 예측 정확도 - 비교적 개발·계산 시간 짧음, 자동화 용이	- 모델 구조가 불투명하여 해석 어려움 - 학습 데이터 범위 밖에서는 오차 급증 (일반화 제한)

<표 7.1>에서 보듯이 두 접근법의 장단점은 상호 보완적이다. 물리 모델은 신뢰성과 해석력을 제공하지만 구축과 운영이 복잡하고, AI 모델은 실용성과 정확도를 제공하지만 물리적 타당성 측면에서 약점을 가진다. 따라서 수질 예측의 정확도와 신뢰성을 동시에 향상하기 위해서는 두 접근법의 강점을 결합하는 새로운 방법론이 요구된다.

3) 하이브리드 모델의 개념 및 필요성

하이브리드 모델이란 상기한 물리 기반 모델과 AI 기반 모델을 적절히 통합함으로써, 개별 모델 단독보다 향상된 예측 성능과 실용성을 얻고자 하는 접근을 말한다. 전통적인 물리 모델은 불가피하게 현실을 단순화하여 복잡한 수환경의 일부 특성만을 모사하기 때문에 한계가 있고, 데이터 기반 모델은 충분한 데이터를 확보하지 못하거나 모델 내부를 해석해야 하는 경우 한계가 있다. 하이브리드 기법은 이러한 상호 보완을 통해 한계를 극복하고자 한다. 실제로 물리학적 전문지식과 데이터 마이닝 기법을 결합하는 것이 수질 예측모델의 적용성 및 효용성을 높이는 전 세계적 추세로 보고되고 있다. 국내에서도 환경부·K-water 등이 물리 모델 기반 예측에 AI를 접목하려는 시도를 진행하고 있다. 이처럼 하이브리드 모델은 녹조 예측의 정확도와 신뢰도를 향상시킬 수 있음을 시사하며, 물관리 분야에 혁신적 도구로 부상하고 있다. 특히 K-water와 같이 다양한 수계의 방대한 관측자료(WQE 시스템 자료)를 확보한 기관에서는 이러한 하이브리드 접근이 현실적으로 구현 가능하며, 향후 스마트 물관리의 일환으로 중요한 역할을 할 것으로 기대된다.

7.2 하이브리드 모델 구축 방안

1) 적용 가능한 결합 전략

하이브리드 모델을 구축하는 방법은 여러 가지 전략으로 나눌 수 있으며, 예측 목표와 데이터 여건에 따라 적합한 방식을 선택하거나 복합 적용할 수 있다. 본 장에서는 대표적으로 고려되는 네 가지 하이브리드 접근 전략을 소개한다.

가. 물리정보 신경망 (PINN, Physics-Informed Neural Network)

물리법칙을 손실함수 등에 제약 조건으로 통합함으로써, AI 모델이 학습 과정에서 물리방정식이나 보존 법칙을 자동으로 만족하도록 만드는 기법이다. 예를 들어 수질 모델의 미분방정식을 신경망 학습에 포함시키면, 데이터가 부족한 구간에서도 물리적 거동을 따르는 예측값을 생성할 수 있다. PINN은 불완전한 물리모델과 부분적인 관측 데이터가 있을 때도 좋은 성능을 내며, 학습 데이터에 없던 조건에서도 일정 수준의 예측 정확도를 유지할 수 있는 것으로 보고되고 있다. 녹조 예측의 경우, 조류 증식에 관한 미분방정식(예: Monod 식이나 Logistic 성장식 등)을 신경망에 녹여 넣어 모델이 물리적으로 일관된 범위에서 학습·예측하도록 설계할 수 있다. PINN 접근은 초기 연구 단계이지만 수리학, 수문학 등 분야에서 점차 응용이 늘고 있으며, 물리모델의 보편성과 AI의 유연성을 함께 취할 수 있는 유망한 방법이다.

나. 대리모델 (Surrogate Model)

복잡한 물리모델을 대신하여 근사하는 AI 모델을 의미한다. 즉, 물리모델을 여러 시나리오로 실행하여 얻은 학습데이터(입출력)를 활용해, 그 입출력 관계를 모사하는 메타모델을 만드는 것이다. 이렇게 하면 원래 물리모델을 직접 돌리지 않고도 유사한 결과를 훨씬 빠르게 얻을 수 있어 실시간 예측이나 다중 시나리오 평가에 유리하다. 예를 들어 수리안(AEM3D) 모델이 1회 실행에 몇 시간 걸린다면, 동일 입력에 대한 대리모델(예: 딥러닝 회귀모델)은 거의 실시간에 가까운 응답을 줄 수 있다. 대리모델은 주로 모델 연산 속도 향상을 위해 도입되지만, 충분한 데이터로 잘 훈련되면 원 모형의 복잡한 거동까지 학습하여 어느 정도의 보정 기능도 수행할 수 있다. 예를 들어 수리안 모형으로 과거 수년간 다양한 기상·운영 조건에서 조류 농도를 모의하고, 그 결과를 학습한 대리 AI모델을 개발해 놓으면 향후 새로운 입력 조건에서 신속히 조류예측을 산출할 수 있다. 이는 실시간 의사결정 지원에 큰 이점을 제공한다.

다. 잔차 보정형 하이브리드 (Residual Correction)

물리모델이 산출한 1차 예측값과 실제 관측값 간의 오차(잔차)를 학습하여, 향후 물리모델 예측에 보정 값을 추가해주는 전략이다. 이 접근은 물리모델의 구조적 한계나 불완전한

인자 때문에 발생하는 계통 오차(bias)를 AI로 보완하는 개념이다. 예를 들어 특정 저수지에서 수리안 모형이 매번 조류 농도를 과소추정하는 경향이 있다면, AI 모델이 과거에 그 과소추정량(오차)을 학습하여 다음 예측 시 보정값을 더해주는 식이다. 이렇게 하면 순수 물리 모델에 비해 평균 오차와 패턴 재현력이 향상될 수 있다. 잔차 보정용 AI로는 주로 회귀분석이나 신경망이 사용되며, 시계열 예측 맥락에서는 LSTM 기반 모델이 물리 모델 결과의 잔차 시계열을 학습하는 사례도 있다. 이 방식의 장점은 물리모델과 AI모델이 각자 잘하는 부분만 담당하도록 역할을 분담하는 것으로, 물리 모델이 대세 추이를 예측하고 AI가 미세 조정을 하는 구조다. 다만 물리 모델의 예측이 크게 빗나가는 상황에서는 잔차 보정만으로 한계가 있을 수 있으므로, 물리 모델의 기본적 품질이 담보된 상태에서 적용하는 것이 효과적이다.

라. 입력 연계형 하이브리드 (Input Fusion)

물리모델과 AI모델을 직렬로 연결하여, 한쪽의 출력을 다른 쪽의 입력으로 활용하는 전략이다. 두 가지 방향이 가능하다. 첫째는 물리모델 → AI모델 연계로서, 물리모델이 생성한 중간 결과(예: 수체의 유동, 수온, 영양염 농도 등)를 AI 모델의 추가 입력 변수로 제공하여 AI 예측의 풍부한 맥락 정보를 부여하는 것이다. 예를 들어 상류 유역에서의 강우-유출을 HSPF로 계산하고, 그 결과로 도출된 영양염 부하량 시계열을 AI 모델의 입력으로 넣어 조류 농도를 예측하면 순수하게 기상 데이터만 활용한 AI보다 예측 성능이 향상될 수 있다.

둘째는 AI모델 → 물리모델 방향으로, AI가 예측한 값을 물리모델의 입력 조건으로 사용하는 경우이다. 예를 들어 단기 기상예보 자료와 과거 데이터를 활용해 AI가 단기 영양염 농도를 예측하고, 이를 물리 모델의 경계조건으로 넣어 조류 분포를 모의하면 물리모델 단독 실행 대비 현실 반영도가 높아질 수 있다. 이러한 입력 연계형 접근은 기존 운영 시스템에 AI 모듈만 삽입하면 되므로 구현이 비교적 쉬우며, 모델 간 인터페이스만 정의하면 단계적으로 적용할 수 있다는 장점이 있다. 다만 한 모델의 오류가 다음 단계로 전파(propagation)될 수 있으므로, 초기 적용 시 면밀한 검증이 필요하다.

이상의 전략들은 상호 배타적이지 않으며, 필요에 따라 복합 구성도 가능하다. 예를 들어 잔차보정형과 입력연계형을 접목하여, 1단계로 물리모델+AI 잔차보정으로 대략의 예측을 하고 2단계로 그 결과를 다시 AI가 후처리하는 다중 단계 하이브리드도 구상할 수 있다. K-water의 과업 여건과 목표에 비추어볼 때, 대리모델이나 잔차 보정형 및 입력 연계형은 현 수리안 시스템을 크게 변경하지 않고도 도입하기 쉬운 방식이며, PINN은 중장기적으로 데이터가 축적되고 알고리즘 검증이 완료되면 도입할 수 있을 것이다. <표 7.2>는 대표적인 하이브리드 모델 유형을 비교한 것이다.

<표 7.2> 하이브리드 모델 유형 비교표

분류	결합 방식	목적	장점	예시
PINNs	손실함수에 물리 방정식 삽입	물리 법칙 내재화	일반화 성능 우수, 소량 데이터 가능	Poisson Eq 기반 PINN
Surrogate	물리모델 결과로 AI 학습	계산속도 향상, 간접 예측	다양한 시나리오 학습 가능, 시뮬레이션 대체 가능	EFDC → XGBoost
잔차 보정형	AI가 물리모델 오차를 예측하여 보정	정확도 향상	물리 일관성 + 정밀 예측 가능	예측값 + AI 잔차
입력 연계형	물리모델 출력값 → AI 입력	예측 변수 정보 확장	물리기반 특징 포함 가능	체류시간, 유속 등
파라미터 최적화형	AI가 물리모델 파라미터 조정	물리모델 보정	해석력 + 데이터기반 최적화	유전자알고리즘 활용 보정
디지털트윈 통합형	실시간 센서 기반 모델 융합	실시간 대응, 운영지원	시각화·조기경보 통합, 실무 적용성 높음	예측 대시보드 구축

2) 수리안과 AI모델의 결합 구조 및 역할 분담

하이브리드 모델을 설계할 때에는 물리모델(수리안)과 AI 예측모델이 어떤 형태로 상호작용할지 구조를 정하고, 각자의 역할 분담을 명확히 하는 것이 중요하다. 본 연구에서는 수리안(AEM3D · CE-QUAL-W2)이 기본적인 수리·수질 거동을 시뮬레이션하는 역할을 담당하고, AI 모델은 수리안으로부터 얻기 어려운 부분을 예측 보완하거나 실시간성을 확보하는 역할을 담당하도록 설정한다. 우선 전체 하이브리드 시스템의 개념도를 살펴보면 <그림 7.1>과 같다.

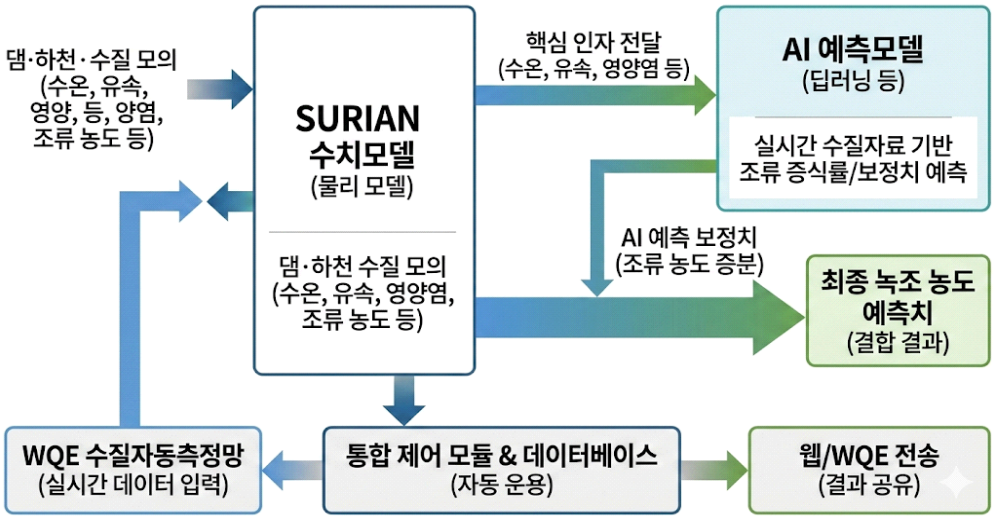

<그림 7.1> 수리안과 AI 예측모델을 통합한 하이브리드 예측 구조 예시

출처: Gemini 3(나노 바나나 프로)로 생성한 이미지

위의 예시 개념에서 볼 수 있듯, 수리안과 AI 모델은 병렬적이면서도 직렬적인 결합 형태를 모두 가진다. 수리안은 물리 기반 1차 예측을 수행하고, AI는 그 결과와 실측 데이터 기반으로

2차 예측 또는 보정을 수행한 뒤, 필요한 경우 물리모델의 결과를 갱신한다. 보다 구체적으로 역할을 정리하면 다음과 같다.

가. 수리안 물리 모델

댐 및 하천 구간의 수리동역학(유량, 체류시간 등)과 수질 물질순환(수온, 영양염, 조류 성장/사멸 등)을 모사한다. 공간적으로는 3차원(AEM3D) 및 2차원 종단(CE-AUL-W2) 방향의 격자망을, 시간적으로는 시간단위 이하로 연속 모의를 수행하여 공간 분포를 가지는 예측 결과(예: 조류 농도의 수역 및 수심별 분포)를 산출한다. 즉, 시공간 해상도가 있는 기본 예측을 제공하는 역할이다. 또한 수리안은 예측 과정에서 수문학적 일관성을 보장하므로, AI가 예측하기 어려운 물리적 경계 조건이나 상황별 시나리오(예: 댐 방류 증감에 따른 변화) 분석에 활용될 수 있다.

나. AI 예측모델

시계열 예측에 특화된 머신러닝/딥러닝 모델로서, 조류 농도 또는 관련 수질 파라미터를 예측한다. 이 모델은 WQE에서 수집되는 실시간 자료를 주요 학습 및 입력 데이터로 활용하며, 필요에 따라 수리안으로부터 전달받은 변수(수온, 유량 등)를 추가 입력으로 받는다. AI 모델의 구조는 LSTM, GRU와 같은 순환신경망이나 XGBoost와 같은 앙상블 트리 모형 등을 고려할 수 있다. 이 모듈은 수리안의 예측값과 과거 관측값의 오차를 학습하여 수리안 출력에 대한 보정값을 산정하거나, 혹은 수리안이 모의하지 않는 새로운 목표변수(예: 남조류 세포수, toxics 등)를 직접 예측하는 역할을 맡는다. 요약하면, AI 모듈은 수리안 결과를 후처리하여 예측 정밀도를 높이고 예측 변수의 범위를 확장하는 역할을 수행한다.

다. 자료 연계 및 통합 모듈

수리안과 AI 사이의 데이터 흐름을 조정하고 WQE 및 외부 시스템과의 인터페이스를 담당한다. 예컨대, WRO 및 WQE에서 최신 기상정보, 유입량, 수질 측정값 등을 자동으로 불러와 수리안과 AI의 입력파일을 생성해주고, 수리안을 실행하며, 수리안 출력값을 가공해 AI 모델에 전달하고, 최종적으로 AI 예측결과를 WQE 데이터베이스와 웹서비스에 등록하는 일련의 과정을 관리한다. 이 부분은 기존 수리안 시스템의 자동화 모듈을 확장하여 구현할 수 있다. 특히 실시간 운영을 위해서는 스케줄러와 데이터 동기화 장치가 필요하며, 예측 과정 전체가 하나의 파이프라인으로 매일 또는 필요시 자동 수행되도록 구성한다.

이러한 결합 구조에서 물리 모델과 AI 모델의 역할 분담은 상호 보완적이다. 물리 모델이 공간분포와 물질 균형을 책임진다면, AI 모델은 최신 데이터를 반영한 시계열 추세와 오차 보정을 책임지는 식이다. 예를 들어 수리안이 “기본 시나리오에서 5일 후 조류농도 50 mg/㎥”로 예측한 것을 AI가 “최근 경향으로 보아 +5 mg/㎥ 상향 조정이 필요”하다고 판단하여 최종 예측을 55 mg/㎥로 보정하는 형태이다. 또는 수리안은 Chl-a 농도까지 예측하고, AI는 거기서

한 걸음 더 나아가 남조류 세포수나 2-MIB 같은 맛·냄새물질 농도를 추가 예측하여 제공할 수도 있다(현재 수리안에서도 경험식 등을 활용해 남조류세포수, 맛냄새물질 예측은 가능). 이렇게 함으로써 사용자는 물리적 일관성이 담보된 공간분포 예측과 최신 데이터가 반영된 보정 예측을 한꺼번에 얻을 수 있어 의사결정에 활용하게 된다.

3) WQE 기반 실시간 운영 연계 방안

하이브리드 예측모델을 실제 현장에 적용하려면, 기존 운영 시스템과의 연계 및 실시간 서비스화 전략이 필요하다. K-water의 WQE와 수리안 시스템은 이미 자동화된 운영체계를 일부 갖추고 있으므로, 여기에 AI 모듈을 추가하는 통합이 이루어져야 한다. 구체적인 연계 방안을 몇 가지 측면에서 제안한다.

가. 데이터 수집 및 전송 자동화

WQE로부터 예측에 필요한 모든 데이터를 자동 추출(Extract), 변환(Transform), 적재(Load)하여 하이브리드 모델의 입력으로 사용한다. 예컨대, 전일의 댐 유입량, 방류량, 수위, 수온, 영양염농도, 조류농도 계측값 등을 매일 자정에 WQE DB에서 불러와서 수리안 초기조건 및 AI 입력 데이터로 변환한다. 이런 데이터 연계는 웹의 장점을 최대한 활용하기 위해 만들어진 REST API 또는 DB 뷰어를 활용하여 구현하고, 데이터 누락이나 이상치 발생 시 알람을 주어 데이터 수집 신뢰성을 확보한다.

나. 예측 실행 스케줄링

수리안 물리 모델은 현재 일일 모드로 정규 실행되고 있으므로, AI 보정 모듈이 이를 받아 처리하는 일정을 동기화해야 한다. 예를 들어 매일 새벽에 수리안이 5일 예측을 완료하면, 곧바로 AI 모듈이 구동되어 수리안 출력과 최신 WQE 자료를 결합한 하이브리드 보정 결과를 산출하도록 일괄 배치작업(batch job)을 편성한다. 이때 AI 모듈은 사전에 학습된 모델을 활용하므로 예측 계산은 수 분 내로 완료될 것이며, 전체 예측 파이프라인이 아침 업무 시작 전에 끝나도록 조정할 수 있다. 또한 녹조 상황이 심각한 기간에는 예측 빈도를 증가시켜, 필요시 하루 2회(예: 새벽+정오) 혹은 3시간 간격 등으로 운영하는 방안도 고려할 수 있다. WQE와 수리안 간 인터페이스를 표준화하고, AI 모듈 실행 트리거를 유연하게 설정함으로써 운영 일정을 탄력적으로 가져가는 것이 중요하다.

다. 결과 통합 및 시각화

예측이 완료된 후에는 결과 데이터를 WQE에 등록하고 관련 부서에 전파해야 한다. 이를 위해 하이브리드 모델 결과를 WQE 대시보드에 시각화하는 방안을 마련한다. 구체적으로, 수리안의 예측 결과(예: 조류 농도의 종단 분포 그래프)와 AI 보정 후 최종 예측 결과를 겹쳐서 표시함으로써, 사용자들이 두 결과를 직관적으로 비교할 수 있게 한다. 또한 예측치에 신뢰구간 또는 불확실성 수준을 AI 모듈이 산출하도록 하여, WQE 화면에 예측값과 함

께 표출하면 현장 담당자들이 위험도를 판단하는데 도움을 줄 수 있다. 예측 결과는 실시간으로 K-water 내부 업무망 또는 모바일 앱을 통해서도 확인할 수 있도록 하여 정보 접근성을 높이고, 필요시 지자체·환경부 등 유관기관과 공유 체계를 갖춘다.

라. 운영자 개입 및 피드백 루프

완전 자동화된 시스템이라도 운영자의 판단이 필요할 수 있으므로, WQE 상에서 운영자가 예측 결과에 대한 피드백을 제공하거나 매개변수를 조정할 수 있는 기능을 둔다. 예를 들어 예측 결과가 현장 상황과 맞지 않는 경우 운영자가 코멘트를 달거나, AI 모델이 참고할 수 있도록 사건 정보(비상 방류 실시 등)를 입력하면 다음 학습 시 반영되도록 한다. 또한 일정 기간마다(예: 월간) 예측 성능 리포트를 자동 생성하여, 오차 분석과 원인 진단을 실시하고 이를 바탕으로 모델을 개선하거나 재학습하는 피드백 루프를 구축한다. 이 피드백 정보 역시 WQE에 연계하여 관리함으로써, 예측 시스템의 지속적인 학습효과를 높인다.

마. 비상상황 대비 이중화

예측 시스템의 장애나 오류에 대비하여, 물리 모델 단독 예측 또는 AI 단독 예측으로도 운영을 유지할 수 있는 플랜 B를 마련한다. 예를 들어 AI 모듈에 결함이 생긴 경우에는 WQE에 물리모델 결과만이라도 제공하고, 물리 모델 쪽 입력 데이터에 문제 발생 시에는 AI모델이 순수 데이터 기반으로라도 예측을 내놓는 식이다. 이러한 이중화 운영은 WQE 플랫폼 내에서 상태 모니터링을 통해 자동 전환되도록 설계한다.

제 8장 결론

본 연구는 고농도 남조류 세포수 데이터의 희소성으로 인한 녹조 데이터셋의 불균형 문제를 오버샘플링을 통해 완화하면 고농도 희소 구간에 대한 모델 예측성능이 개선되는지를 정량적으로 분석하는 것을 목표로 하였다. 이를 위해 SMOGN, GAN, TimeGAN 등 세 가지 오버샘플링 기법을 적용하여 훈련 데이터셋에서 희소한 고농도 구간 샘플을 증강하고, 작은 표본 크기에도 안정적인 성능을 보이는 랜덤포레스트 모델을 활용하여 남조류 세포수의 1~3주 후 예측성능을 비교 분석하였다.

연구 결과, SMOGN 기반 오버샘플링으로 구축한 훈련 데이터셋으로 학습한 모델이 원본 데이터 및 GAN, TimeGAN 적용 모델에 비해 우수한 예측성능 개선 효과를 나타냈다. SMOGN은 원본 데이터 대비 평균 오차 규모(RMSE) 감소, 시간적 변동성 재현(NSE) 증가를 동시에 달성하면서, 전반적 편향(PBIAS)을 축소하고, 개별 샘플 정확도(MAPE)를 개선하여 다양한 평가 관점에서 우수한 예측성능 개선 효과를 보였다.

원본 데이터와 다른 기법에 비교해 SMOGN이 고농도 구간의 오차를 유의미하게 줄이면서도 전반적인 예측성능 개선 폭이 가장 크게 나타난 이유는 목표변수의 연속형 분포를 유지한 채 국소적 밀도(local density)에 따라 다수/소수 구간의 중요도를 균형 있게 조정하는 중요도 기반 오버샘플링 전략에 있다. 이를 통해 중·고농도 구간의 샘플 밀도를 효과적으로 보강하면서 회귀형 불균형 문제를 완화할 수 있었다. 반면 GAN은 원본 분포 재현을 우선하는 구조적 특성으로 인해 극히 희소한 경계등급의 비중을 충분히 조정하지 못하였고, TimeGAN 역시 시계열의 시간적 의존성 보존에 초점을 둔 설계로 인해 희소 구간을 조건적으로 확대하는 기능이 제한되었다. 이러한 결과는 시계열 기반 예측에서 극히 희소한 고농도 구간을 다룰 때 합성 데이터의 '질적 유사성'과 '양적 확보 전략'이 동시에 충족될 때에만 예측성능 향상이 실질적으로 나타날 수 있음을 시사한다.

더 나아가 본 연구의 결과는 남조류 세포수 예측에 국한되지 않고, 극단값이 드물고 불균형이 심한 연속형 수문·환경 시계열 전반에 적용 가능한 시사점을 제공한다. 특히 시계열적 연속성을 지닌 회귀 문제에서는 분포를 보존하면서 국소 밀도에 따라 희소 구간을 선택적으로 증강하는 오버샘플링 전략이 모델의 안정성과 일반화 성능을 높이는 데 유효한 대안이 될 수 있음을 보여준다.

다만 본 연구는 특정 수역의 장기 시계열과 랜덤포레스트 중심의 단일 모델링에 기반하고 있어, 기상·수문 조건이 다른 수계나 딥러닝 기반 예측모형으로의 확장 가능성은 추가 검증이 필요하다. 그럼에도 불구하고, 본 연구는 비정상(non-stationary)성과 극단값 특성이 강한 수문·환경 시계열에서 오버샘플링에 의한 예측모형 성능 향상을 모색하는 데 참고할 수 있는 기초적 근거로 활용될 것으로 기대된다.

참 고 문 헌

1. 김동현, 황준화, 홍건교, & 서동준. (2023). 리튬이온 배터리 예측 성능 향상을 위한 시계열 데이터 증강 기법 유효성 연구. 한국통신학회 학술대회논문집, 1382-1383.

2. 김진휘. (2020). 이상치 탐색을 위한 통계적 방법.

3. 백성기, “응집에 대한 속도구배 및 지체시간의 영향”, 석사학위논문, 1994.

4. 선정연, 김기영, & 김진휘. (2019). 이상치 탐색을 위한 통계적 방법과 활용 방안.

5. 진세종, & 조형준. (2020). 머신러닝을 활용한 계절 시계열 예측. Journal of The Korean Data Analysis Society, 22(5), 1779-1791.

6. 차윤경, 신지훈, 김영우. (2020). 자료기반 물환경모델의 현황 및 발전 방향. 한국물환경학회지, 36(6), 611-620.

7. 최희원, & 김한준. (2019). 머신러닝 기반 자동 데이터 시각화를 위한 특징공학. 한국통신학회논문지, 44(9), 1788-1797.

8. Ahn, J. M., Kim, J. W. and Kim, K. H. (2023). Ensemble Machine Learning of Gradient Boosting (XGBoost, LightGBM, CatBoost) and Attention-Based CNN-LSTM for Harmful Algal Blooms Forecasting. Toxins, 15(10), 608.

9. Ali, S., Abuhmed, T., El-Sappagh, S., Muhammad, K., Alonso-Moral, J. M., Confalonieri, R., ... & Herrera, F. (2023). Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. Information Fusion, 99, 101805.

10. Arjovsky, M. and Bottou, L. (2017). Towards principled methods for training generative adversarial networks. International Conference on Learning Representations 2017, Toulon, France.

11. Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., ... & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. Information Fusion, 58, 82-115.

12. Backer, L. C., Manassaram-Baptiste, D., LePrell R. and Bolton, B. (2015). Cyanobacteria and algae blooms: review of health and environmental data from the harmful algal bloom-related illness surveillance system (HABISS) 2007–2011. Toxins, 7(4), 1048-1064.

13. Baur, Christoph & Denner, Stefan & Wiestler, Benedikt & Albarqouni, Shadi & Navab, Nassir. (2020). Autoencoders for Unsupervised Anomaly Segmentation in Brain MR Images: A Comparative Study. 10.48550/arXiv.2004.03271.

14. Branco, P., Torgo, L., and Ribeiro, R. P. (2017). SMOGN: A pre-processing approach for imbalanced regression. Proceedings of the Machine Learning Research, 74, 36-50.

15. Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.

16. Briand, J. F., Jacquet, S., Bernard, C. and Humbert, J. F. (2003). Health hazards for terrestrial vertebrates from toxic cyanobacteria in surface water ecosystems. Veterinary Research, 34(4), 361-377.

17. Busari, I., Sahoo, D., Harmel, R. D. and Haggard, B. E. (2023). A Review of Machine Learning Models for Harmful Algal Bloom Monitoring in Freshwater Systems. Journal of Natural Resources and Agricultural Ecosystems, 1(2), 63-76.

18. Cao, W., Wang, D., Li, J., Zhou, H., Li, L., & Li, Y. (2018). BRITS: Bidirectional recurrent imputation for time series. Advances in Neural Information Processing Systems, 31.

19. Carmichael, W. W. and Boyer, G. L. (2016). Health impacts from cyanobacteria harmful algae blooms: Implications for the North American Great Lakes. Harmful Algae, 54, 194-212.

20. Cascallares, G. and Gleiser, P. M. (2015). What season suits you best? Seasonal light changes and cyanobacterial competition. Papers in Physics, 7(1), 070005.

21. Cha, Y., Shin, J., Go, B., Lee, D. S., Kim, Y., Kim, T., & Park, Y. S. (2021). An interpretable machine learning method for supporting ecosystem management: Application to species distribution models of freshwater macroinvertebrates. Journal of Environmental Management, 291, 112719.

22. Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321-357.

23. Che, Z., Purushotham, S., Cho, K., Sontag, D., & Liu, Y. (2018). Recurrent neural networks for multivariate time series with missing values. Scientific Reports, 8(1), 6085.

24. Cho, K., Van Merrienboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv:1406.1078.

25. Choi, E., Bahadori, M. T., Sun, J., Kulas, J., Schuetz, A., & Stewart, W. (2016). RETAIN: An interpretable predictive model for healthcare using reverse time attention mechanism. Advances in Neural Information Processing Systems, 29.

26. Chorus, I. and Welker, M. (2021). Toxic Cyanobacteria in Water: A Guide to Their Public Health Consequences, Monitoring and Management. 2nd Edition. WHO.

27. Cruz, R. C., Costa, P. R., Vinga, S., Krippahl, L. and Lopes, M. B. (2021). A Review of Recent Machine Learning Advances for Forecasting Harmful Algal

Blooms and Shellfish Contamination. Journal of Marine Science and Engineering, 9(3), 283.

28. Derot J., Yajima H. and Jacquet S. (2020). Advances in forecasting harmful algal blooms using machine learning models: a case study with Planktothrix rubescens in Lake Geneva. Harmful Algae, 99, 101906.

29. Derot, J. Yajima, H. Jacquet, S. (2020) Advances in forecasting harmful algal blooms using machine learning models: A case study with Planktothrix rubescens in Lake Geneva. Harmful Algae, 99(3), 101906.

30. Elith, J., Leathwick, J. R., & Hastie, T. (2008). A working guide to boosted regression trees. Journal of Animal Ecology, 77(4), 802-813.

31. Emami, S., Gonzalo Martínez-Mu Noz, G.M., Hernández-Lobato, D. (2025). Robust-Multi-Task Gradient Boosting. Neurocomputing.

32. Few, S., & Edge, P. (2007). Save the pies for dessert. Visual Business Intelligence Newsletter, 1(1), 1 – 14.

33. Goeman, J. J. (2010). L1 penalized estimation in the Cox proportional hazards model. Biometrical Journal, 52(1), 70 – 84.

34. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. (2020). Generative adversarial networks. Communications of the ACM, 63(11), 139-144.

35. Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS 36.

36. Haffar, M. A., Fajloun, Z., Azar, S., Sabatier, J. M. and Khattar, Z. A. (2024). Lesser-Known Cyanotoxins: A Comprehensive Review of Their Health and Environmental Impacts. Toxins, 16(12), 551.

37. Han, J. W., Kim, T., Lee, S., Kang, T., & Im, J. K. (2024). Machine learning and explainable AI for chlorophyll-a prediction in Namhan River Watershed, South Korea. Ecological Indicators, 166, 112361.

38. Hunter, J. S. (1986). The Exponentially Weighted Moving Average. Journal of Quality Technology, 18, 203-210.

39. Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: principles and practice (3rd ed.). OTexts.

40. Jeong, B., Chapeta, M. R., Kim, M., Kim, J., Shin, J., & Cha, Y. (2022). Machine learning-based prediction of harmful algal blooms in water supply reservoirs. Water Quality Research Journal, 57(4), 304-318.

41. Jeong, B. S, Chapeta, M. R., Kim, M. G., Kim, J. H., Shin, J. H. and Cha, Y. K. (2022). Machine learning-based prediction of harmful algal blooms in water supply reservoirs. Water Quality Research Journal, 57(4), 304-318.

42. Kaplan, D. (2024). Bayesian statistics for the social sciences. The Guilford Press.

43. Kim, J., & Park, Y. (2015). Analysis of Work Load for Developing the Control Strategy of Hybrid Agricultural Tractor. Transactions of the Korean Society of Automotive Engineers, 23(2), 239-245.

44. Kim, J. H., Shin, J. K., Lee, H. K., Lee, D. H., Kang, J. H., Cho, K. H., Lee, Y. G., Chon, K. M., Baek, S. S. and Park, Y. G. (2021). Improving the performance of machine learning models for early warning of harmful algal blooms using an adaptive synthetic sampling method. Water Research, 207, 117821.

45. Kim, T., Shin, J., & Cha, Y. (2023). Incorporation of feature engineering and attention mechanisms into deep learning models to develop an early warning system for harmful algal blooms. Journal of Cleaner Production, 414, 137564.

46. Kim, T., Shin, J., Lee, D., Kim, Y., Na, E., Park, J. H., ... & Cha, Y. (2022). Simultaneous feature engineering and interpretation: Forecasting harmful algal blooms using a deep learning approach. Water Research, 215, 118289.

47. Kim, Y. W., Kim, T., Shin, J., Go, B., Lee, M., Lee, J., ... & Cha, Y. (2021). Forecasting abrupt depletion of dissolved oxygen in urban streams using discontinuously measured hourly time series data. Water Resources Research, 57(4), e2020WR029188.

48. Kwon, D. H., Hong, S. M., Abbas, A., Pyo, J., Lee, H. K., Baek, S. S., & Cho, K. H. (2023). Inland harmful algal blooms (HABs) modeling using internet of things (IoT) system and deep learning. Environmental Engineering Research, 28(1).

49. Larsen, M. L., Baulch, H. M., Schiff, S. L., Simon, D. F., Sauvé, S., & Venkiteswaran, J. J. (2020). Extreme rainfall drives early onset cyanobacterial bloom. FACETS, 5(1), 899-920.

50. Lee, D., Kim, M., Lee, B., Chae, S., Kwon, S., & Kang, S. (2022). Integrated explainable deep learning prediction of harmful algal blooms. Technological Forecasting and Social Change, 185, 122046.

51. Lee, J. S., & Jeon, B. J. (2008). A study on the balance ability and obesity of rural elderly persons in Nonsan. Culinary Science & Hospitality Research, 16(1), 55 - 66.

52. Lin, S., Pierson, D. C., & Mesman, J. P. (2023). Prediction of algal blooms via data-driven machine learning models… Geoscientific Model Development, 16(1), 35 - 46.

53. Liu, Y., Yu, R., Zheng, S., Zhan, E., & Yue, Y. (2019). NAOMI: Non-autoregressive multiresolution sequence imputation. Advances in Neural Information Processing Systems, 32.

54. Lucas, J.M. and Saccucci, M.S. (1990). Exponentially Weighted Moving Average Control Schemes: Properties and Enhancements. Technometrics, 32, 1-29.

55. Lundberg, S. (2017). A unified approach to interpreting model predictions.

arXiv:1705.07874.

56. Lundberg, S. M., Erion, G. G., & Lee, S. I. (2018). Consistent individualized feature attribution for tree ensembles. arXiv:1802.03888.

57. Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., ... & Lee, S. I. (2020). From local explanations to global understanding… Nature Machine Intelligence, 2(1), 56–67.

58. McElfresh, D., Khandagale, S., Valverde, J., Prasad, C. V., Ramakrishnan, G., Goldblum, M. and White, C. (2023). When do neural nets outperform boosted trees on tabular data? NeurIPS 37, 3337, 76336-76369.

59. Mermer, O., Zhang, E. and Demir, I. (2024). Predicting Harmful Algal Blooms Using Ensemble Machine Learning Models and Explainable AI Technique. Advancing Global Resilience to Climate Change.

60. Molares-Ulloa, A., Rivero, D., Fernandez-Blanco, E., Padin, X.A., Rocruz, E., Nolasco, R., & Dubert. (2024). Harmful algal bloom forecasting. A comparison between stream and batch learning.

61. Molnar, C. (2020). Interpretable machine learning. Lulu.com.

62. Montgomery, D. C. (2005). Introduction to Statistical Quality Control. John Wiley & Sons.

63. MOE (2024). Annual Report on Algal Bloom Occurrence and Response 2023. Korean Ministry of Environment.

64. Moriasi, D. N., Arnold, J. G., Van Liew, M. W., Bingner, R. L., Harmel, R. D., & Veith, T. L. (2007). Model evaluation guidelines for systematic quantification… Transactions of the ASABE, 50(3), 885-900.

65. Niu, Z., Zhong, G., & Yu, H. (2021). A review on the attention mechanism of deep learning. Neurocomputing, 452, 48-62.

66. Park, J., Lee, W. H., Kim, K. T., Park, C. Y., Lee, S., & Heo, T. Y. (2022). Interpretation of ensemble learning to predict water quality using explainable artificial intelligence. Science of the Total Environment, 832, 155070.

67. Park, J. S., Patel, K. and Lee, W. H. (2024). Recent advances in algal bloom detection and prediction technology using machine learning. Science of The Total Environment, 938, 173546.

68. Preece, E. P., Paerl, H. W., Plaas, H. E. and Cooke, J. (2025). From drought to deluge… Environmental Pollution, 382, 126731.

69. Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. and Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. NeurIPS 32.

70. Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A.V., and Gulin, A. (2018).

CatBoost… NIPS, 6639 – 6649.

71. Radford, A., Metz, L. and Chintala, S. (2015). Unsupervised Representation Learning with Deep Convolutional GANs. ICLR 2016.

72. Rastogi, R. P., Madamwar, D. and Incharoensakdi, A. (2015). Bloom Dynamics of Cyanobacteria… Frontiers in Microbiology, 6, 1254.

73. Reichwaldt, E. S. and Ghadouani, A. (2012). Effects of rainfall patterns on toxic cyanobacterial blooms… Water Research, 46(5), 1372-1393.

74. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). Model-agnostic interpretability of machine learning. arXiv:1606.05386.

75. Rousso, B. Z., Bertone, E., Stewart, R., & Hamilton, D. P. (2020). A systematic literature review… Water Research, 182, 115959.

76. Rousso, B. Z., Bertone, E., Stewart, R. A., Hughes, S. P., Hobson, P. and Hamilton, D. P. (2022). Cyanobacteria species dominance… Hydrobiologia, 849, 1453-1469.

77. Shan, K., Song, L., Chen, W., Li, L., Liu, L., Wu, Y., Jia, Y., Zhou, Q. and Peng, L. (2019). Analysis of environmental drivers… Harmful Algae, 84, 84-94.

78. Shin, J., & Cha, Y. (2024). Development of a deep learning – based feature stream network… Water Research, 122751.

79. Shin, J., Lee, G., Kim, T., Cho, K. H., Hong, S. M., Kwon, D. H., ... & Cha, Y. (2024). Deep learning-based efficient drone-borne sensing… Science of The Total Environment, 912, 169540.

80. Spence, I. (2005). No humble pie: The origins and usage of a statistical chart. Journal of Educational and Behavioral Statistics, 30(4), 353-368.

81. Sun, G., Zhu, W., Qian, X., Wei, C., Xie, P., Shi, Y., Cao, X. and He, Y. (2025). Machine Learning Models for Chlorophyll-a Forecasting… Water, 17(8), 1219.

82. Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. JRSS-B, 58(1), 267 – 288.

83. Tibshirani, R., Rosset, S., Zhu, J., & Hastie, T. (2005). Sparsity and smoothness via the fused lasso. JRSS-B, 67, 91 – 108.

84. Tibshirani, R., & Wang, P. (2007). Spatial smoothing and hot spot detection… Biostatistics Journal, 9, 18 – 29.

85. USGS (2025). Science Needs for Determining the Effects of Climate Change on Harmful Algal Blooms… Open-File Report 2025 – 1004.

86. Wai, K. P., Chia, M. Y., Koo, C. H., Huang, Y. F., & Chong, W. C. (2022). Applications of deep learning in water quality management. Journal of Hydrology, 128332.

87. White, I. R., Royston, P., & Wood, A. M. (2011). Multiple imputation using chained equations… Statistics in Medicine, 30(4), 377–399.

88. Yoon, J., Jordon, J., & Schaar, M. (2018). GAIN: Missing data imputation using generative adversarial nets. ICML, 5689–5698.

89. Yoon, J., Jarrett, D., and van der Schaar, M. (2019). Time-series generative adversarial networks. NeurIPS 33.

90. Yuan, J., Cao, Z., Ma, J., Li, Y., Qiu, Y., and Duan, H. (2024). Influence of climate extremes… Science of The Total Environment, 939, 173601.

부록 A 자문보고서

A-1 녹조 영향 시계열 변수들의 상관성 분석 기법

작성자: 인하대학교 김수전 교수

□ 주요 목적

- 시간의 흐름에 따라 관측된 시계열 다변량 자료의 상관성 분석 방안, 변수 간 상호작용을 최소화하면서 설명력 높은 변수를 선택해 모델의 예측성능을 높이는 방안을 검토하고자 함

□ 녹조현상과 조류경보제

○ 녹조 현상(Algal bloom)

- 조류(Algae)는 물속에서 광합성을 하는 식물 플랑크톤으로 수생태계 먹이사슬의 생산자이며, 산소를 공급하고 동물플랑크톤의 먹이가 되는 등 육상의 식물과 같은 중요한 역할 수행
- 조류는 크게 규조류, 녹조류, 남조류, 기타조류로 구분
- 녹조현상과 관련된 종은 남조류(Cyanobacteria)이며, 남조류 중 일부 종은 냄새물질(Geosmin, 2-MIB)과 독소(간 독소, 신경독소) 등의 배출에 따라 물의 심미적 가치 및 안정성 저하
- 녹조 현상(Algal bloom)이란 수온이 높은 여름~가을철에 조류의 종 중 남조류가 우점하여 하천과 호소의 물빛이 진한 녹색을 띠는 현상
- 이취미와 독성으로 인하여 인근 생태계와 상수원 수질에 악영향을 미치고 이수 및 친수 활동 안전에 대한 부정적 인식 각인
- 높은 수온 및 일사량, 긴 체류시간(낮은 유량), 인, 질소 등의 영양염류 과도한 유입이 녹조 현상이 발생하기 쉬운 조건으로 주로 언급됨

○ 조류경보제

- 조류발생 상황을 주기적으로 모니터링하여 일정 수준 이상의 조류가 발생할 경우 경보를 발령하여 필요한 조치를 취함으로써 수돗물을 안정적으로 공급

하고, 친수활동시 조류 독소로부터 국민의 안전을 도모하기 위하여 물환경보전법 제21조(수질오염 경보제)에 의거 조류경보제 운영 중

- 전국의 29개소(상수원 호소 22개소, 상수원 하천 6개소, 친수활동 구간 1개소)를 대상으로 실시(그림 1)
- 연중 녹조가 발생할 우려가 높은 5월부터 10월까지 매주 유해 남조류세포수, Chl-a 등의 수질인자 측정을 수행하여 단계별 남조류세포수 발령기준(표 1)에 따른 경보 발령

<표 1> 조류경보단계에 따른 남조류세포수 발령기준

조류경보단계	발령기준
미발령	유해 남조류 세포수 1,000 cell/ml 미만
관심	유해 남조류 세포수 1,000 cell/ml 이상 10,000 cell/ml 미만
경계	유해 남조류 세포수 10,000 cell/ml 이상 1,000,000 cell/ml 미만
대발생	유해 남조류 세포수 1,000,000 cell/ml 이상

- 경계 이상의 경보가 발령될 시 해당 지점의 관측회수를 주 2회 이상으로 늘리고 1,000 cell/ml 미만으로 떨어질 때까지 지속적 관측
- 조류경보제 시행을 위하여 환경부 산하 국립환경과학원은 2012년부터 조류측정망을 운영 시작 및 관측지점 점차 확대중
- 기 운영 수질측정망의 수질 항목 일부 및 녹조 현상 관련 인자 추가 측정(표 2)
- 국립환경과학원에서 물환경정보포털(http://211.114.21.27)를 통해 관측자료 제공 중

<표 2> 조류측정망 수질인자 측정항목

수질인자		조류 세포수 및 우점종	
수온	투명도	유해 남조류 세포수	Microsystis
pH	탁도		Anabaena
DO	SS		Oscillatoria
BOD	T-N		Aphanizomenon
COD	DTN	총조류	
Chlorophyll-A	NO3-N	총남조류	
지오스민	NH3-N	총규조류	
2-MIB	T-P	총녹조류	
전기전도도	DTP	총기타조류	
TOC	PO4-P	-	

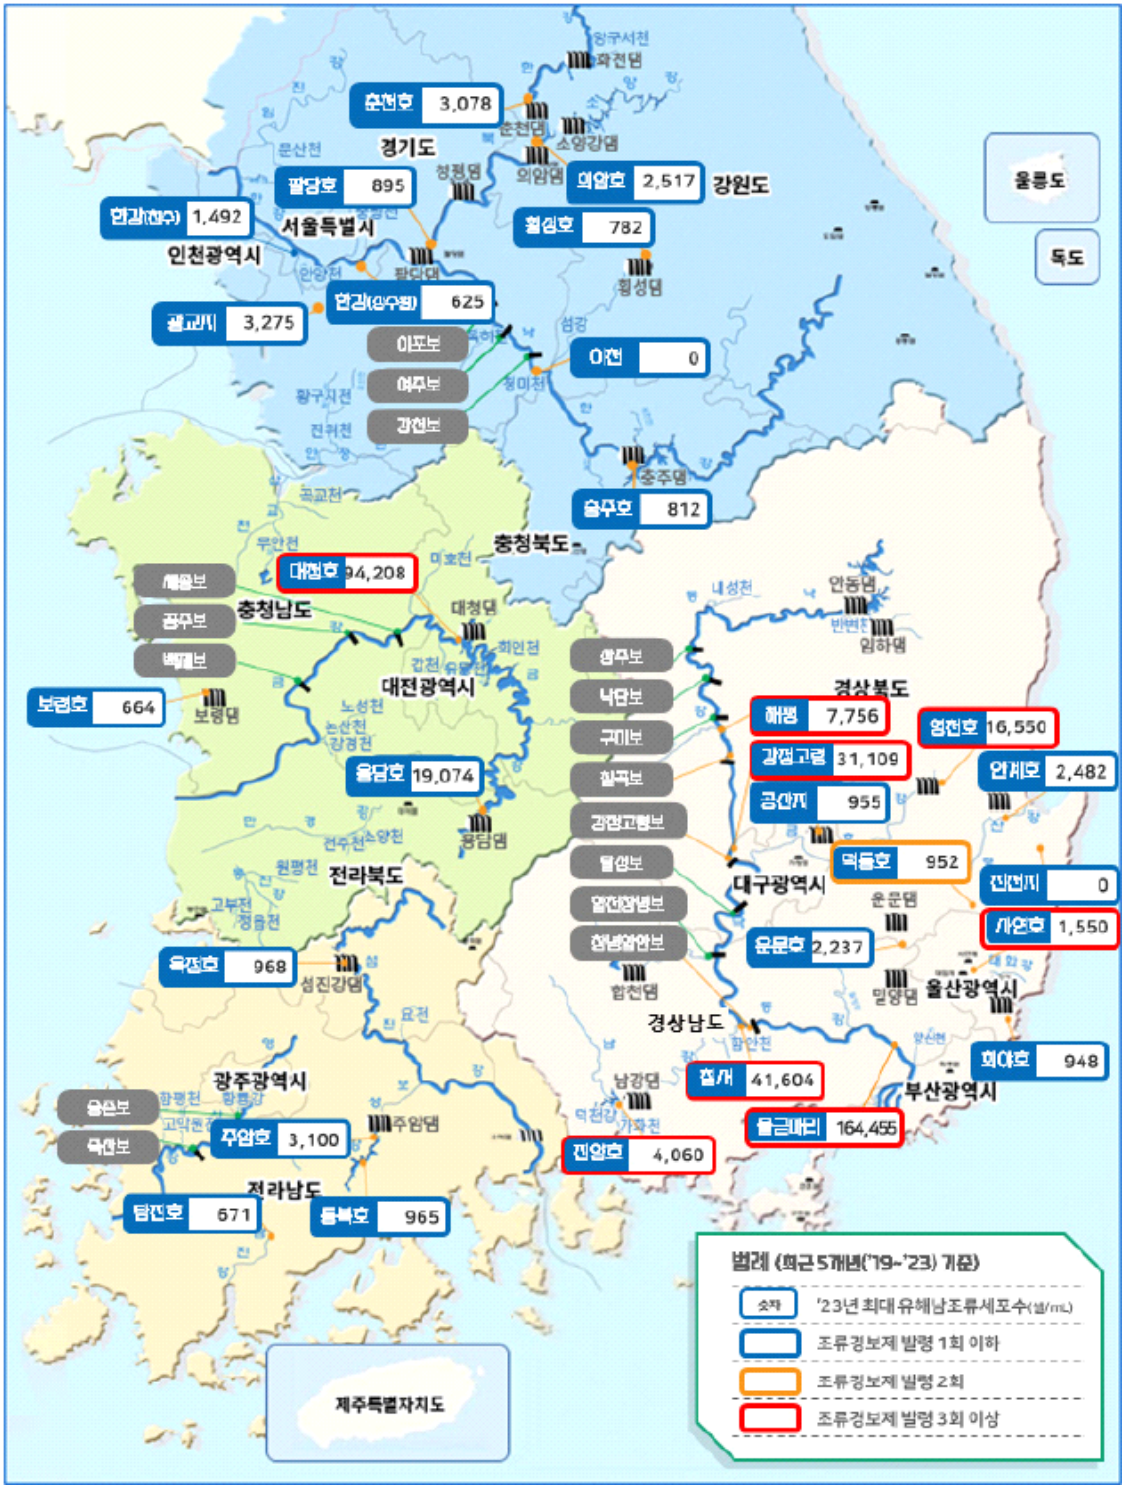

<그림 1> 조류경보제 발령지점

□ 남조류세포수의 시계열 분석

○ 남조류세포수 영향인자 자료 수집 방안

- 남조류 생장 조건으로 유력하게 밝혀진 주 요인 : 높은 수온과 일사량, 저유량으로 인한 수체 내 긴 체류시간, 과다한 영양염류 유입
- 하천 및 호소의 수온은 기온과 매우 밀접한 관계(상관계수 0.95 이상)가 있으므로 시계열 분석시 기온 자료로 대체 가능할 것으로 판단
- 기온, 일사량, 강수량 : 기상청 기상자료개방포털(https://data.kma.go.kr)의 종관기상관측자료(ASOS) 또는 방재기상관측자료(AWS)로부터 확보 가능
- 수위, 유량 : 환경부 홍수통제소로부터 확보 가능
- 수질인자(영양염류) : 환경부 물환경정보포털에서 제공하는 조류관측소 자료 활용, 결측인자 보간 또는 추가 다른 수질인자 자료 필요 시 인근 수질측정망 자료 활용

○ 남조류세포수와 시계열 분석의 주의점 및 한계점

① 짧은 관측기간으로 인한 자료 수 부족

- 13년 미만의 다소 짧은 조류측정망 관측기간 및 주 단위의 다소 긴 관측간격으로 인해 단일 관측소에서의 현 시점(2024년 11월 기준) 남조류세포수 최대 약 670여 개의 시계열 관측자료 확보 가능
- 시계열 분석 및 기계학습을 위한 충분한 데이터가 축적되어있지 않은 실정

② 긴 관측주기로 인한 계열 간 낮은 연속성

- 남조류세포수 및 수질인자의 일반적인 측정 주기가 1주일으로 다소 길기 때문에 시계열 자료가 온전히 연속형이라 가정하기 어려움. 측정 간격 사이에 수질인자의 유입 또는 강우가 발생할 경우 남조류세포수의 변동이 있을 우려가 있기 때문에 남조류세포수 시계열 분석시 이러한 불확실성을 고려해야 함.
- 또한 기상자료(기온, 일사량, 강수량)와 수문자료(수위, 유량)의 경우 시간 단위로 관측하여 시간, 일, 월, 년 단위 평균, 누계 등의 통계치를 제공하고 있으므로 연속성을 보유하고 있음. 이에 남조류세포수와 기상·수문인자 간 시계열 분석시 동일 관측일시의 자료뿐만 아니라 기상·수문인자의 경우 연속성을 고려한 주 단위 통계치와의 분석 또한 고려해야할 것으로 판단됨.

③ 광범위한 발생 범위로 인한 선형관계 규명 난해

- 남조류세포수는 하천 및 호소에서의 생장 조건이 만족할 시 기하급수적으로 증가하기 때문에 0부터 1,000,000 cell/ml 또는 그 이상으로 매우 넓은 범위로 발생하며, 이에 각 계열 간 격차가 매우 클 수 있음. 따라서 남조류세포수 시계열을 데이터의 가공 없이 상관분석을 수행할 경우 선형관계가 규명이 어려울 수 있음.
- 따라서 남조류세포수 시계열 분석 시 남조류세포수에 상용로그를 취하거나 표 3과 같이 남조류세포수 발생 범위에 따른 범주형 변수로 변환할 시 보다 선형관계 규명에 유리할 수 있음.
- 표 3의 기준은 현행 조류경보제 발령단계 구분기준과 유사하며, 물환경정보시스템에서 운영하는 조류예측정보 단계별 범례임.

<표 3> 남조류세포수에 따른 단계 구분

단계	발령기준
0	유해 남조류 세포수 1,000 cell/ml 미만
1	유해 남조류 세포수 1,000 cell/ml 이상 10,000 cell/ml 미만
2	유해 남조류 세포수 10,000 cell/ml 이상 100,000 cell/ml 미만
3	유해 남조류 세포수 100,000 cell/ml 이상 1,000,000 cell/ml 미만
4	유해 남조류 세포수 1,000,000 cell/ml 이상

□ 상관관계 분석 유형 분류 (연속 & 범주)

- 데이터 분석에서 두 변수 간 상관관계는 다양한 상관계수를 통해 파악하는 것이 가능
- 상관분석에서는 데이터의 형태를 크게 연속형과 범주형으로 분류
- 연속형은 수치로 표현되며, 특정 범위 내에서 무한히 많은 값을 가질 수 있는 데이터로, 온도나 시간, 수질관측치 등이 여기에 해당됨
- 범주형은 사전에 정의된 범주로 데이터가 구분되는 경우를 의미. 즉, 범주는 명칭(nominal) 또는 순서(ordinal)를 나타내며, 성별이나 직업, 또는 재난 분야에서의 위기경보 단계 등을 의미

○ 연속형-연속형 데이터 간 상관관계 분석 방법

• 피어슨 상관계수(Pearson‘s correlation coefficient)

- 피어슨 상관계수는 두 연속형 변수 간 산형적 관계의 강도와 방향을 측정하는 지표
- -1~1 사이의 값을 가지며, 1에 가까울수록 강한 양의 선형관계, -1에 가까울수록 강한 음의 선형관계를 의미하며 0에 가까운 값은 선형관계가 없다는 것을 의미
- 피어슨 상관계수는 아래의 수식에 따라 계산

$$r = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}} \qquad (1)$$

- 여기서 X_i와 Y_i는 각 변수 표본, $\overline{X}$와 $\overline{Y}$는 각 변수의 평균값, n은 관측값의 수를 의미
- 피어슨 상관계수는 두 변수가 정규분포를 따르고, 선형적 관계를 가질 경우 유용. 그러나 이상치에 민감하며, 비선형적 관계의 데이터에서는 적절하지 않을 수 있음

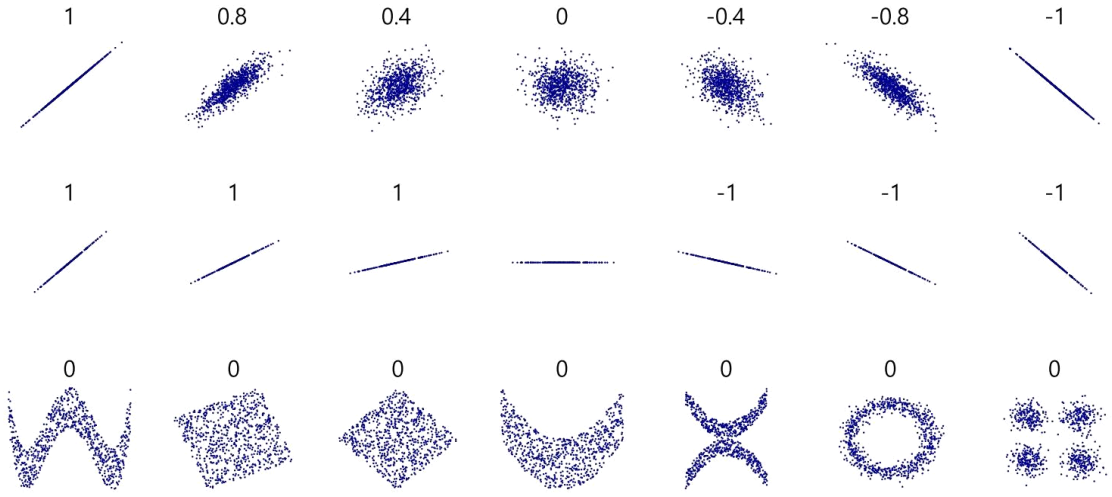

<그림 2> 상관계수 값에 따른 데이터 분포 형태

• 스피어만 순위 상관계수(Spearman's rank correlation coefficient)
- 스피어만 순위 상관계수는 두 변수 간의 순위 관계를 측정하는 비모수적 방법
- 데이터가 정규분포를 따르지 않거나 순위형 데이터일 때 사용하며, 각 데이터 값을 순위로 변환한 후 피어슨 상관계수를 계산하는 방식으로 계산
- 스피어만 순위 상관계수는 다음의 수식을 활용하여 계산

$$\rho = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \quad (2)$$

- 여기서 d_i는 각 관측값의 순위 차이($d_i = R(X_i) - R(Y_i)$), n은 표본의 개수를 의미
- 스피어만 순위 상관계수는 피어슨 상관계수에 비해 이상치에 덜 민감하며, 비선형적이지만 순위적인 관계를 파악하는데 유리

• 켄달 타우(Kendall's Tau)

- 켄달 타우는 두 변수 간 순위 일치 정도를 측정하는 비모수적 방법
- 두 데이터 쌍의 순위 일치 여부를 통해 계산되며, 순위형 데이터나 비선형적 관계를 분석할 때 사용
- 켄달 타우는 아래의 수식을 통해 산정

$$\tau = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}} \quad (3)$$

- 여기서 C는 일치하는 쌍의 수, D는 불일치하는 쌍의 수, T_x와 T_y는 각각 X와 Y에서 동순위를 가진 쌍의 수를 의미
- 켄달 타우는 스피어만 순위 상관계수에 비해 더 보수적인 해석을 할 수 있으며, 순위가 동등한 데이터가 많을 경우 주로 사용

○ 연속형-범주형 데이터 간 상관관계 분석 방법

• 점이연 상관계수(Point-biserial correlation coefficient)

- 하나의 변수가 연속형이고 다른 변수가 자연적으로 이분화된 범주형일 때 사용되는 상관계수
- 점이연 상관계수는 아래의 수식을 통해 계산
- 켄달 타우는 아래의 수식을 통해 산정

$$r_{pb} = \frac{M_1 - M_0}{s}\sqrt{\frac{n_1 n_0}{n^2}} \quad (4)$$

- 여기서 M_i은 범주형 변수가 i인 표본의 연속형 변수 평균, s는 전체 연속형

범주의 표준편차, n_i는 범주형 변수가 i인 표본의 크기, n은 전체 표본 크기를 의미

- 수학적으로는 피어슨 상관계수화 동일하며, 범주형 변수를 0과 1로 환산하여 계산

• 이연 상관계수(Biserial correlation coefficient)

- 연속형 변수를 인위적으로 이분화하여 범주형 변수로 변환했을 때 원래의 연속형 데이터의 특성을 고려하여 상관관계를 추정하는 방법
- 이연 상관계수는 아래의 수식을 통해 산정

$$r_b = \frac{M_1 - M_0}{s} \frac{n_1 n_0}{n^2 u} \tag{5}$$

- 여기서 u는 표준 정규분포에서 누적확률이 n_1/n인 지점의 밀도 함수 값, 나머지 변수들은 점이연 상관계수의 산정식과 동일
- 점이연 상관계수와 달리 범주형 변수가 인위적으로 이분화된 경우에 사용되며, 연속형 변수의 원래 분포를 고려하여 상관관계를 추정

• 다연 상관계수(Polyserial correlation coefficient)

- 연속형 변수와 다단계 범주형 변수(순서형) 간의 상관관계를 추정하는 방법. 예를 들어, 재난 위기경보단계에 따른 4점 척도로 측정된 표본과 강수량, 수위, 유량 등과 같은 연속형 변수 간의 상관관계를 분석할 때 사용
- 다연상관계수는 연속형 변수와 잠재적인 연속형 변수가 존재한다고 가정하여 범주형 변수를 연속형 변수로 변환하여 상관관계를 추정
- 다연 상관계수는 범주형 변수가 순서형일 때 특히 유용하며, 범주형 변수를 연속형으로 간주하여 상관관계를 추정

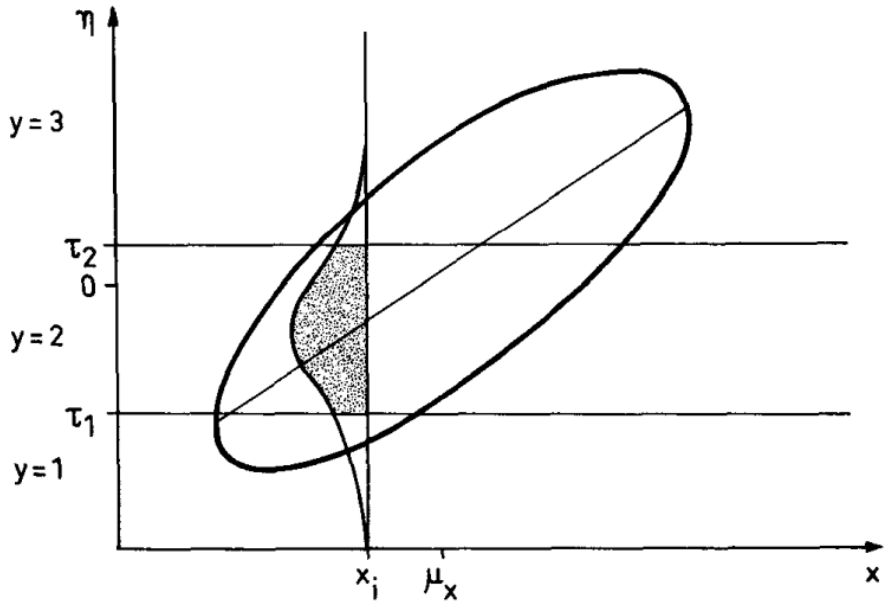

<그림 3> 기본 연속형 변수 η과 범주형 변수 Y 예시
(Olsson et al., 1982)

○ 범주형-범주형 데이터 간 상관관계 분석 방법

• 파이 계수(Phi coefficient)

- 파이 계수는 2×2 교차표에서 두 범주형 변수 간 상관성을 측정하는 지표
- 이는 피어슨의 카이제곱 통계량을 기반으로 하며, 다음의 수식을 활용하여 계산

$$\Phi = \sqrt{\frac{x^2}{n}} \qquad (6)$$

- 여기서 x^2은 카이제곱 통계량, n은 총 표본 개수를 의미
- 파이 계수는 피어슨 상관계수와 같이 $-1 \sim 1$ 사이의 값을 가지며, 0은 두 변수 간 상관성이 없음을 의미. 해당 계수는 2×2 교차표에서만 적용 가능

• 크래머 V 계수(Cramer's V coefficient)

- 파이 계수를 정규화한 형태로, 2×2 이상의 교차표에서 두 범주형 변수 간 상관성을 측정하며, 다음과 같은 수식을 활용하여 산정

$$V = \sqrt{\frac{x^2}{n \cdot min(c-1, r-1)}} \qquad (7)$$

- 여기서 c는 데이터 행의 개수, r은 데이터 열의 개수, 나머지 변수는 파이

계수와 동일

- 크래머 V 계수는 0 ~ 1 사이의 값을 가지며, 0은 두 변수 간 상관성이 없음을 의미

• Tschuprow T 계수(Tschuprow's T coefficient)

- 크래머 V 계수와 유사하나, 교차표의 행과 열의 수가 크게 다를 때 주로 활용하며, 아래의 수식을 활용하여 계산

$$T = \sqrt{\frac{x^2}{n\sqrt{(c-1)(r-1)}}} \qquad (8)$$

- 여기서 사용되는 변수들은 크래머 V 계수와 동일
- 크래머 V 계수와 마찬가지로 0 ~ 1 사이의 값을 가지며, 0은 두 변수 간 상관성이 없음을 의미

□ 편 상관관계, 부분 상관관계, 교차상관관계

○ 편 상관관계(Partial correlation)

- 통계학에서 두 변수 간 상관관계를 측정할 때 다른 변수의 영향을 제거하여 변수 간 상관성을 평가하는 방법
- 이는 특정 변수가 다른 변수들 간 관계에 미치는 영향을 완전히 제거하여 두 변수 간의 직접적인 관계를 파악하는 데 유용
- 두 변수 X와 Y 사이의 상관관계를 측정할 때제3의 변수 Z의 영향을 제거하는 방식으로 계산. 이는 X와 Z, Y와 Z 간의 선형회귀를 통해 잔차(residual)를 계산하여 해당 잔차 간의 상관관계를 계산하여 산정
- 기본적으로 피어슨 상관계수와 유사한 개념으로 -1 ~ 1 사이의 값을 가짐
- 편 상관관계는 선형 관계를 가정하기 때문에 비선형 관계를 가진 변수들 간의 상관성을 평가할 경우에는 부적합할 수 있음. 또한, 데이터에 다중공선성이 존재할 경우 편 상관관계의 신뢰성이 떨어지는 경우도 있음
- 녹조와 기상인자의 관계를 예를 들면, 녹조 현상의 주 원인인자인 남조류의 경우 수온에 직접적인 영향을 주는 기온이 높을수록 생장에 유리하여 기온이 높은 여름철에 남조류 세포수가 대량 발생하는 경향이 있음

- 기압의 경우 기온과의 반비례 관계를 갖기 때문에 기온이 높은 여름철에 기압이 낮고, 겨울철에 기압이 높음. 이러한 이유로 결과적으로는 남조류 세포수 생장에 직접적인 상관관계가 규명되지 않은 기압과 남조류 세포수 간의 상관관계가 높게 산정됨
- 이러한 문제를 해소하기 위한 방법으로써 편 상관관계 분석은 이러한 두 변수 사이의 상관관계 평가 시 두 개의 다른 변수에 대한 한 변수의 효과를 제거할 때 사용

○ 부분 상관관계(Semi-partial correlation)
- 편 상관관계와 유사한 개념으로, 통계 분석에서 특정 독립변수의 종속 변수에 대한 고유한 기여도를 평가하는데 사용되는 지표
- 다른 독립변수들의 영향을 제거한 상태에서 주요한 독립변수와 종속변수 간 상관관계를 측정
- 부분 상관관계는 회귀분석에서 각 독립변수가 종속변수에 미치는 독립적인 영향을 파악하는데 유용
- 특정 독립변수에서 다른 독립변수들의 영향을 제거한 후 해당 독립변수와 종속변수 간 상관관계를 계산하며, 상관관계를 해석하고자 하는 두 표본에 대하여 다른 독립변수의 영향을 완전히 제거하는 편 상관관계와 달리 부분 상관관계는 다른 독립변수의 영향을 일부 표본에 대해서만 제거하는 것이 주요 차이
- 예시로 녹조 발생에 영향을 미치는 요인을 분석하는 경우 수온, 염류 농도, 일조량 등 여러 변수가 고려됨. 이러한 변수들 중 특정 변수의 고유한 영향을 평가할 때 부분 상관관계를 활용하는 것이 가능

○ 교차 상관관계(Cross correlation)
- 두 시계열 간의 상관성을 분석하는 통계적 기법으로, 한 시계열이 다른 시계열에 대해 지연 또는 선행 시간을 가질 때 그 관계를 평가하는데 활용
- 교차 상관관계 함수는 두 시계열 $X(t)$와 $Y(t)$의 지연시간 τ에 따른 상관성을 나타냄
- 교차 상관관계는 수질 환경에서 녹조 발생과 환경 요인 간의 관계를 분석하는데 활용 가능. 과거의 연구에서는 남한의 4대강 보에서 클로로필-a 농도와

다른 환경 요인 간의 교차 상관관계를 분석하여 조류 발생과 환경 요인 간의 상관성을 평가한 사례가 있음

□ 교차상관 분석 기법의 적용 사례

- 교차상관 분석 기법은 여러 분야에서 다양한 알고리즘과 모델에 적용되어 데이터 분석의 효율성을 높일 수 있음
- 대표적으로 통신 분야에서는 신호 처리와 패턴 인식 등에 널리 활용되어 왔으며, 교차상관 분석 기법을 기반으로 개발된 여러 알고리즘이 존재
- 이러한 데이터 처리 방식은 녹조 시계열 변수의 시간 지연을 고려한 상관관계 파악과 데이터에 대한 패턴 인식 및 처리에도 활용이 가능
- 대표적인 방법으로는 웨이블렛 교차상관분석 기법이 있음

○ 웨이블릿 교차상관(Wavelet Cross correlation) 분석

- 웨이블릿 교차상관 분석은 ① 연속 웨이블릿 변환(Continuous Wavelet Transform, CWT), ② 교차 웨이블릿 스펙트럼 계산, ③ 웨이블릿 코히어런스(Wavelet Coherence) 분석 순서로 진행
- 시간에 따라 주파수 성분이 변하는 비정상 신호의 특성을 효과적으로 분석하며, 신호의 시간적 변화와 주파수 특성을 동시에 파악할 수 있어 복잡한 신호 분석에 유리하다는 강점이 있음
- 그러나 연속 웨이블릿 변환과 교차상관 계산은 높은 연산능력을 요구하기 때문에 긴 시계열 데이터나 실시간 데이터 처리에는 부적합할 수 있음
- 통신분야에서 개발된 웨이블릿 방법에서 신호로 녹조 시계열 데이터를 적용하는 것이 가능하며, 이러한 방법론은 녹조 관련 시계열 중 수온, 영양염류 농도, 일사량 등 다양한 환경 변수와 녹조 발생 간의 시간-주파수 영역에서의 상관관계를 파악하여 녹조 발생의 주요 원인을 파악하는 것이 가능
- 또한, 관련 변수들의 주기적인 변동성을 분석하여 향후 녹조 발생 시점 및 여부를 예측하는 모델을 구축하는데 큰 기여를 할 수 있음
- 사례 연구
  - Bingfen Cheng et al., Characterization and causes analysis for algae blooms in large river system,Sustainable Cities and Society, 2019

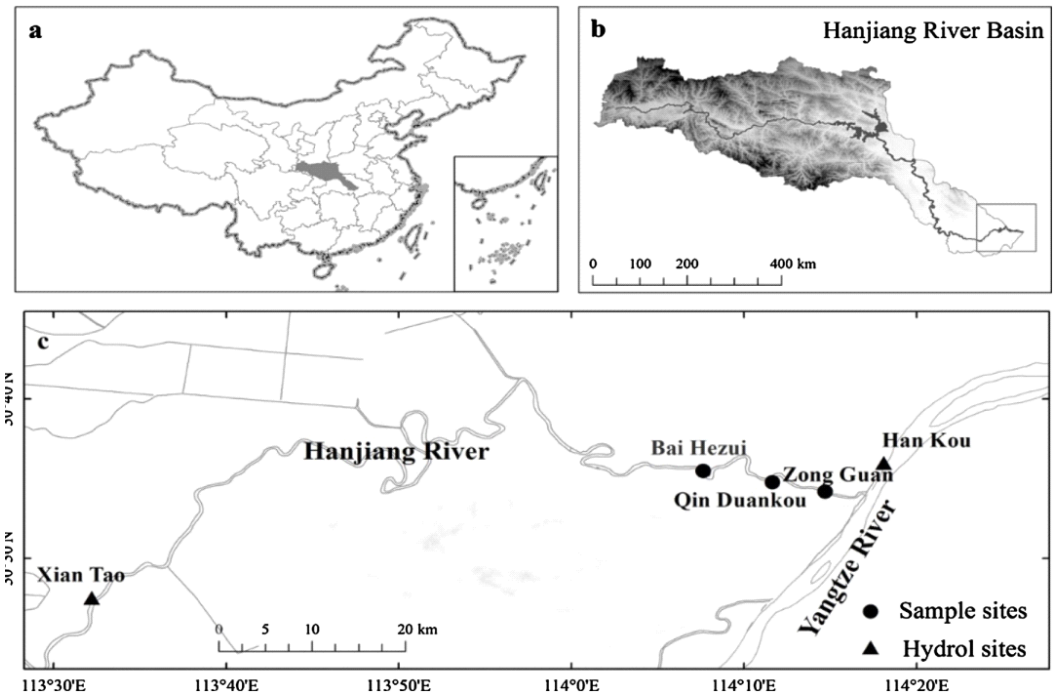

<그림 4> Study areas and the sampling sties,
(a) Hanjiang River Basin in China;

(b) the downstream of Hanjiang River Basin outlined in the box;
(c) three sampling sites(Zong Guan, Bai Hezui and Qin Duankou)

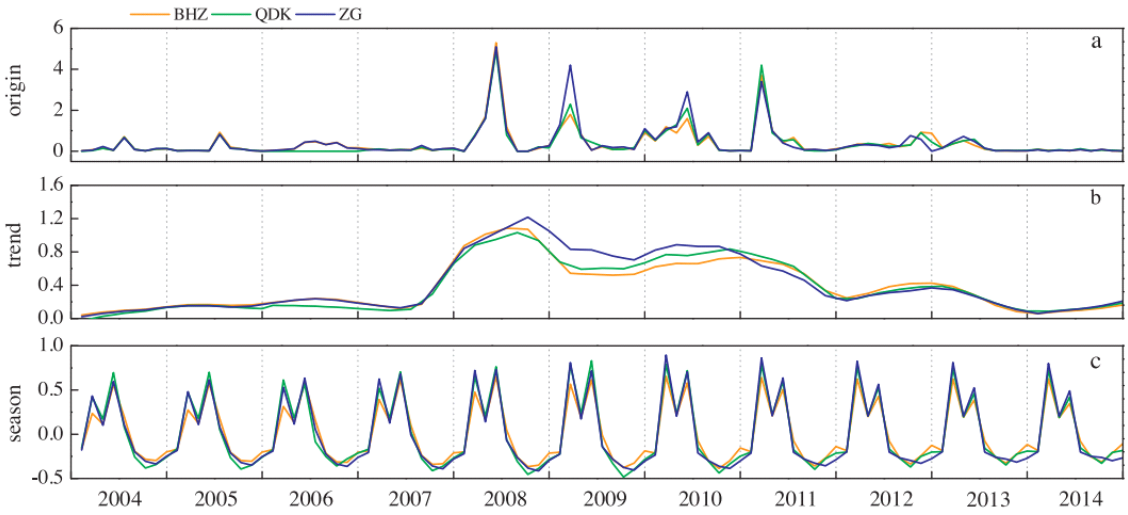

<그림 5> Decomposed plot of algal density at three sites (2004-2014) in Hanjiang River. STL method was used to assist in the evaluation of the trend and seasonality against the original data;

(a) the changes of original algal density;
(b) trend-diagnostic plots of algal density;
(c) seasonal-diagnostic plot of algal density.

• 녹조에 영향을 미치는 요인간 상관성 평가

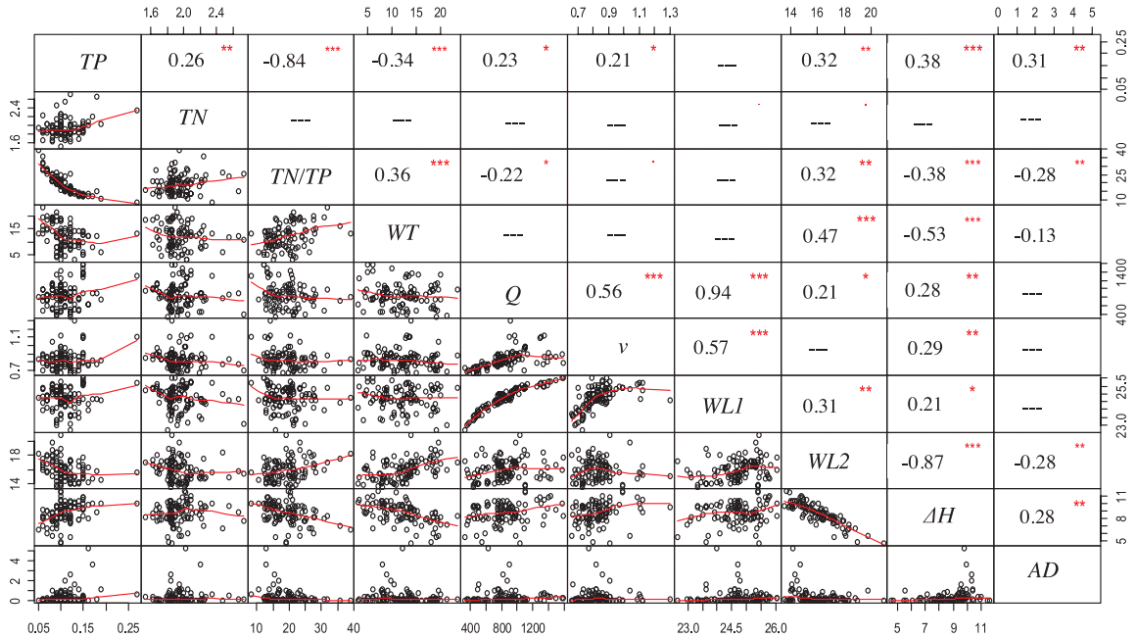

<그림 6> Scatter plots between algal density and TN, TP, TN/TP, WT, Q, v, WL1, WL2, and ΔH (WL2-WL1) downstream of Hanjiang River, China (* p < 0.1; **p < 0.05; *** p < 0.01).

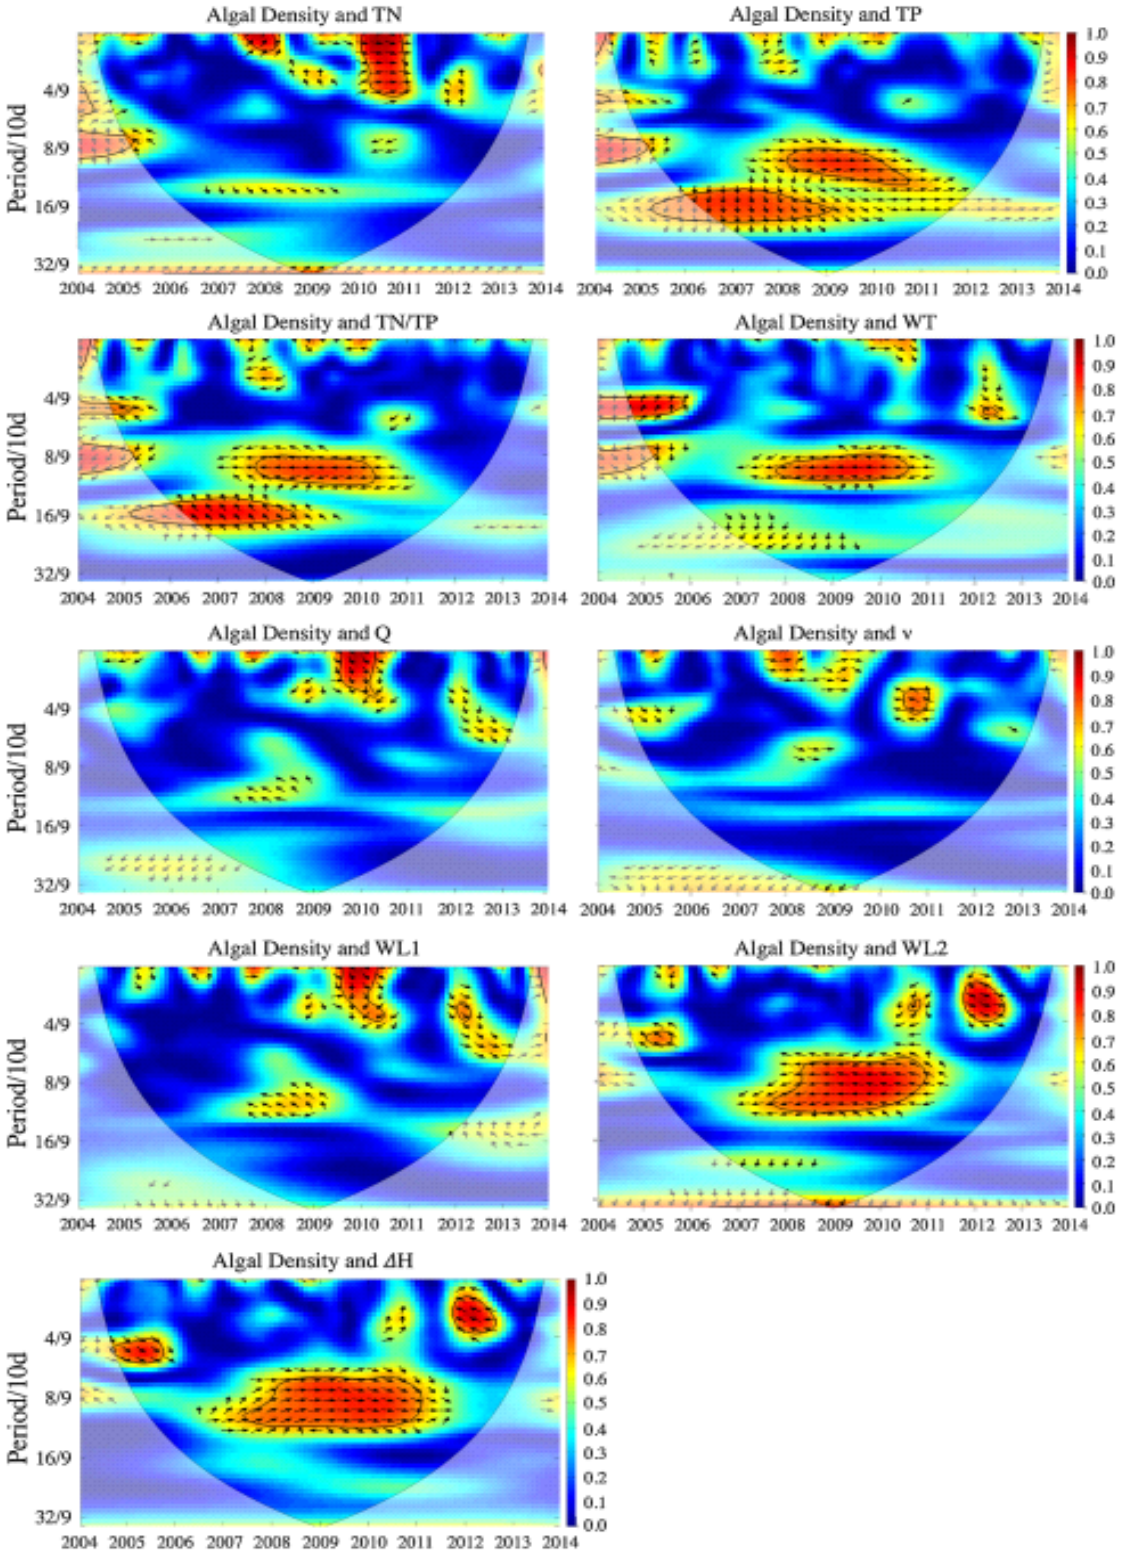

<그림 7> Cross wavelet analysis of relationship between algal density and influencing factors (a. TN; b. TP; c. TN/TP; d. WT; e. Q; f. v; g. WL1; h. WL2; i. ΔH) downstream of Hanjiang River, China. The 5% significance level against red noise is shown as a thick contour

□ 시계열 변수를 활용한 분석에서의 다중공선성

- 다중공선성(multicolinearity)은 데이터 처리에서 각 변수의 개별적인 효과를 정확하게 추정하기 어려운 현상을 의미
- 대표적인 다중공선성의 발생 원인으로는 ① 독립변수들 간에 높은 상관관계가 존재하거나 ② 표본의 크기(개수)가 적을 경우, ③ 데이터 분석에 불필요한 변수가 많이 포함될 경우 발생
- 다중공선성이 발생하면 다중회귀분석에서 회귀계수나 머신러닝, 딥러닝 모델 내부의 가중치 추정에 불확실성이 증가
- 이에 따라 표준 오차 및 분산이 증가하고, 통계적 유의성 등이 왜곡되거나 모델의 신뢰성을 저하시키는 문제가 발생
- 다중공선성의 명확한 판단 기준은 없으나, 다중공선성의 발생 가능성을 추정할 때 사용하는 지표로 변수 간 상관계수나 분산팽창지수 등을 활용

○ 변수 간 상관계수를 통한 다중공선성 판단

- 상관계수를 산정하기 위한 분석 방법은 여러 가지가 있으나, 다중공선성을 판단하기 위한 상관계수는 대표적으로 피어슨 상관계수(Pearson Correlation Coefficient)를 활용
- 상관계수는 일반적으로 -1 ~ +1의 범위를 가지며, 다중공선성의 가능성을 판단할 수 있는 기준은 데이터에 따라 다르나 일반적으로 절대값 0.7 ~ 0.8을 기준으로 판단
- 각 변수 간 상관계수의 절대값이 0.9를 초과할 경우에는 다중공선성 문제가 발생할 확률이 상당히 높으며, 해당 상황에서는 추가적인 데이터 처리를 통해 문제를 해결하는 것이 필요

○ 분산팽창지수(Variance Inflation Factor, VIF)를 활용한 다중공선성 판단

- 분산팽창지수는 특정 변수가 다른 독립변수들과 얼마나 상관되어 있는지를 정량적으로 표현하는 지표
- 상관계수와 유사한 개념을 가지고 있으나, 변수들의 공분산과 각 변수의 표준편차를 활용하는 상관계수와 달리 상관계수에서 파생되는 결정계수(R^2)를 활용하여 아래의 수식에 따라 계산

$$VIF = \frac{1}{1-R^2} \quad (9)$$

- 여기서 VIF는 분산팽창지수, R^2은 결정계수를 의미
- 일반적으로 VIF 값이 10을 초과할 경우 다중공선성이 높다고 판단하나, 드물게 VIF 값의 임계값을 5로 설정하는 경우도 있음
- VIF 값이 높을수록 해당 독립변수의 분산이 다른 변수들과의 상관관계로 인해 팽창되었음을 의미

□ 녹조영향 시계열 변수들을 활용한 예측 및 분류 기법

- 시계열 변수의 상관성 분석을 통해 데이터의 특성을 파악하면, 그 다음 적용 가능한 분석기법으로는 AI 기법을 활용한 시계열의 예측·분류가 있음
- AI 기법에는 머신러닝과 딥러닝 기법이 포함되며, 시계열 분석에 활용 가능한 대표 모델들을 다음과 같이 제시

○ 의사결정나무(Decision Tree, DT)

- 의사결정나무는 자료를 분석하여 이들 사이에 존재하는 패턴을 예측 가능한 규칙들의 조합으로 나타내며, 그 모양이 나무와 같아 의사결정나무로 지칭
- 분류 규칙을 기반으로 자료를 분할하여 예측 및 분류를 수행하는 방법론 중 하나
- 분석 과정을 나무구조로 표현하는 것이 가능하기 때문에 판별분석(discriminant analysis), 회귀분석(regression analysis), 신경망(neural networks) 등과 같은 방법들에 비해 분석 과정을 쉽게 이해하고 설명할 수 있다는 장점이 있으나, 로지스틱 회귀(logistic regression)와 같이 각 예측 변수의 효과를 파악하기 어렵고 새로운 자료에 대한 예측이 불안정할 수 있다는 한계가 있음
- 의사결정나무에 포함되는 기본 알고리즘은 CHAID, CART, ID3, C4.5, C5.0 등이 있으며 이들의 장점을 결합한 다양한 알고리즘이 존재
- 시스템에서 구현할 때 R 언어에서는 rpart 패키지를, python에서는 scikit-learn 라이브러리를 활용하며 분석을 위한 초매개변수(hyper parameter)로는 가지치기의 복잡성을 의미하는 CP가 있음

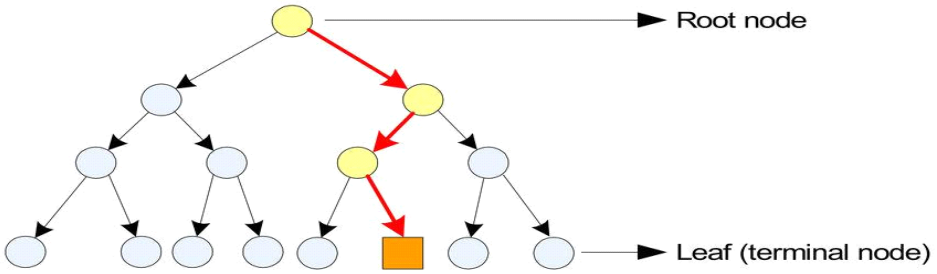

<그림 8> 의사결정나무의 개념도

○ 서포트 벡터 머신(Support Vector Machine, SVM)

- 패턴 인식, 자료 분석을 위한 지도 학습 모델로 주로 분류 및 회귀분석에 사용
- 신경망보다 사용이 간결하며, 회귀분석에서 사용이 가능하나 분류에서 주로 사용하고 있는 기법
- 다양한 연산이 필요하고 입력 자료가 많을 경우에 학습 속도가 크게 느려진다는 단점이 있으나 가중치 벡터 범주, 수치예측 문제에 사용이 가능하며 오류 자료에 대한 영향을 적게 받는다는 장점이 있음
- 서포트 벡터 머신은 비확률적 선형분류모델로 서로 다른 특성을 가진 데이터들이 하나의 집합에 있을 때 최적의 경계 기준을 찾아 마진(margin)의 폭이 최대화가 되도록 범주를 구분하는 방법
- 시스템에서 구현할 때 R 언어에서는 e1071 패키지를, python에서는 scikit-learn 라이브러리를 활용하며 대표적인 초매개변수로는 자료 표본의 영향력을 의미하는 sigma, 분류 경계를 의미하는 C가 있음

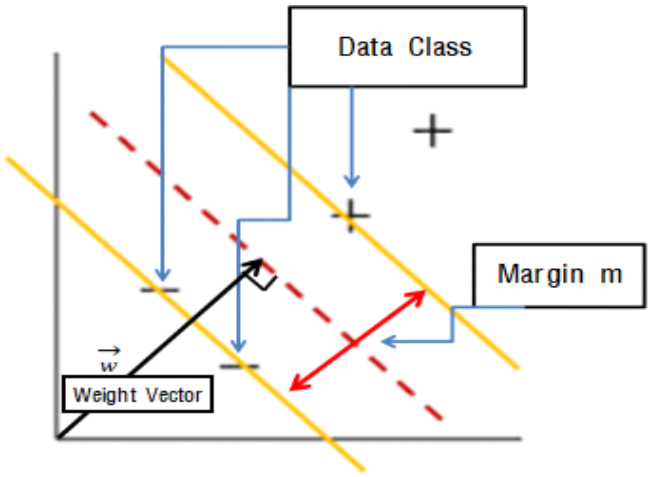

<그림 9> 서포트 벡터 머신의 개념도

○ 랜덤 포레스트(Random Forest, RF)

- 정확성, 단순성 및 유연성으로 인해 가장 많이 사용되는 알고리즘 중 하나로, 분류 및 회귀분석 등에 사용되는 앙상블(ensemble) 학습 방법 중 하나
- 무작위로 특징을 선정해 나무의 마디로 지정하고, 분기할 때마다 의사결정나무와 같은 방식으로 불순도를 파악하여 분기해 나가는 가지를 여러개 만들어 비교하여 최적의 분류 및 예측을 하는 모델
- 다수의 의사결정나무를 통합한 앙상블 형태의 모델로, 전체 자료에서 무작위 자료의 추출을 통해 여러개의 학습 자료 표본을 추출(bootstraping)하여 표본들의 특성을 무작위로 선정하고 다수의 분류기를 일괄적으로 배깅(bagging)하는 알고리즘
- 이 방법을 통해 각 트리가 선택하는 변수를 무작위로 설정하여 트리간의 상관성을 줄여 모델의 과적합을 방지
- 모델의 특성상 자료의 크기가 방대할수록 예측에 소요되는 시간이 길어지나, 분류 및 회귀분석에 모두 사용이 가능
- 대용량 자료를 효과적으로 처리할 수 있으며, 과적합 문제를 최소화하여 모델의 정확도가 높다는 장점이 있음
- 시스템에서 구현할 때 R 언어에서는 randonForest 패키지를, python에서는 scikit-learn 라이브러리를 활용하며 대표적인 초매개변수는 무작위 분류기의 개수를 나타내는 mtry가 있음

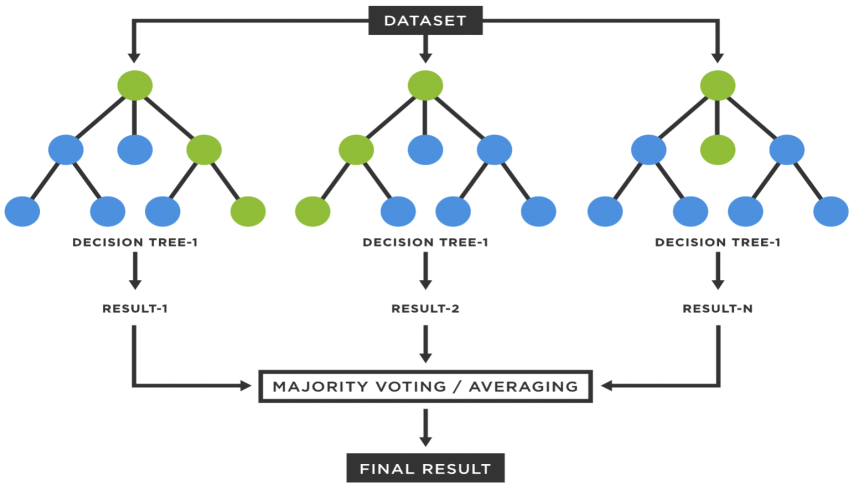

<그림 10> 랜덤 포레스트의 개념도

○ XGBoost

- 여러개의 약한 분류기(weak classifier)를 순차적으로 학습하여 잘못된 자료에

가중치를 부여하는 방식으로 오류를 개선하는 Gradient Boost 모델이 있음

- XGBoost는 Gradient Boost 모델이 가진 단점을 잔차를 이용하여 보완하는 새로운 모델을 순차적으로 선형 결합하여 만든 모델을 생성하는 지도학습 알고리즘인 Gradient Tree Bossting 모델에 과적합 방지를 위한 여러 기법이 추가된 지도학습 알고리즘
- 실제값과 예측값의 오차를 학습자료에 투입하고 잔차(gradient)를 이용하여 오류를 보완하는 방식으로 구동
- 적은 자료를 확용할 시 과적합 가능성이 높고 모델의 정확도가 낮다는 단점이 있으나, 충분한 양의 자료가 있을 때 과적합이 잘 일어나지 않아 예측 성능이 좋다는 장점이 있음
- 시스템에서 구현할 때 R 언어에서는 xgboost 패키지를, python에서는 XGBoost 라이브러리를 활용하며 대표적인 초매개변수로는 부스팅 반복횟수를 의미하는 nrounds, 패널티 비율을 의미하는 lambda와 alpha, 학습율을 의미하는 eta가 있음

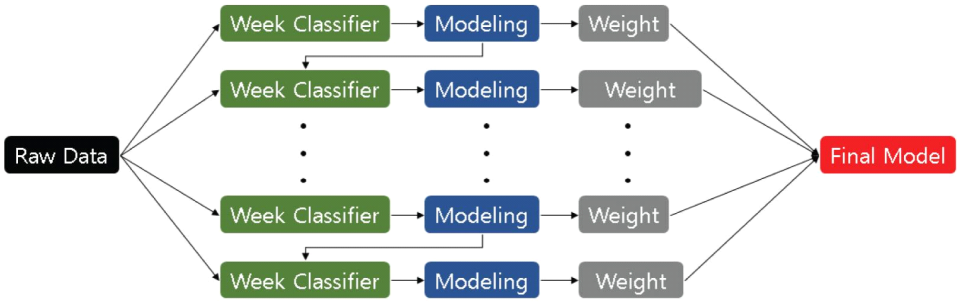

<그림 11> XGBoost의 개념도

○ 장단기 메모리 (Long Short-Term Memory, LSTM)

- 순환신경망(Recurrent Neural Network, RNN)에서 파생된 모델로, 셀(cell) 및 입력, 출력, 망강 게이트를 활용하여 기존 순환신경망의 기울기 소멸 문제를 해결하기 위한 방안으로 개발된 모델
- 일반적인 순환신경망이 과거 자료에 대한 은닉층의 결과만을 업데이트하는 한계를 가진 반면, LSTM은 이를 개선하여 장기적인 데이터 저장을 가능하게 하는 추가적인 셀의 구조를 은닉층에 추가하여 구성
- 시스템에서 구현할 때 R 언어에서는 keras 패키지를 활용하여 모델링이 가능하나 불완전하여 python의 TensorFlow 라이브러리와 연계가 필요하고, python

에서는 TensorFlow 및 Keras 라이브러리를 활용

- 대표적인 초매개변수로는 레이어(layer)의 뉴런 수를 의미하는 units, 학습 시 한번에 처리되는 데이터 샘플의 수를 의미하는 batch size가 있음

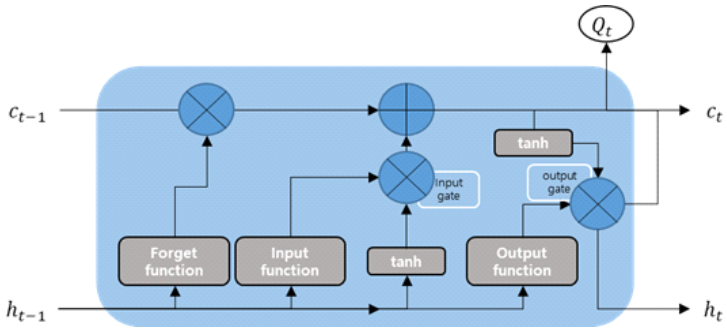

<그림 12> LSTM의 개념도

□ 상관분석을 통한 녹조의 기온-유량 선행 영향기간 탐색

○ 다연상관(Polyserial correlation) 분석을 통한 기온·유량-녹조 단계 상관관계 분석

- 본 연구에서는 녹조 현상과 밀접한 기상·수문인자인 기온과 유량을 선정하여 녹조 발생간 상관분석 수행
- 녹조 예보 단계의 기준이 되는 남조류세포수는 0부터 1,000,000 cell/ml까지 그 발생 범위가 매우 광범위함
- 이에 본 연구에서는 <표 3>의 남조류세포수에 따른 조류 예측단계 활용

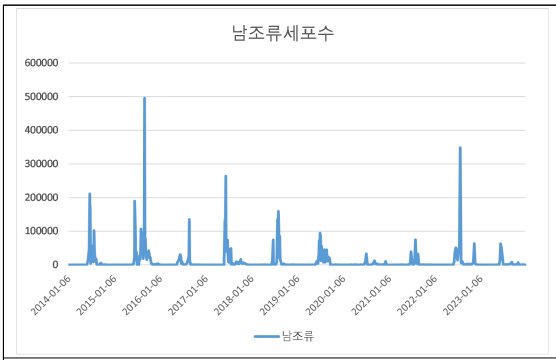

(a) 2014.01 - 2023.12 남조류세포수

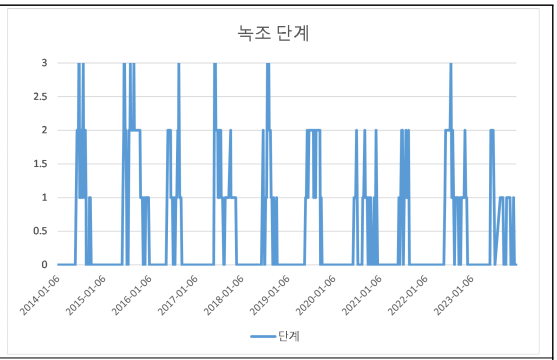

(b) 2014.01 - 2023.12 녹조 단계

<그림 13> 남조류세포수 - 녹조 단계 시계열 비교 (달성보 예시)

- 녹조 예측단계의 경우 총 5단계로 구분된 범주형 변수이고 기온·유량의 경우 연속형 변수

- 범주형 변수-연속형 변수 유형에 가장 적합한 상관관계 분석인 다연상관 분석 채택
- R의 'polycor' 라이브러리를 통하여 다연상관 분석 가능

○ 선행 영향기간별 기온·유량-녹조 단계 상관관계 분석

- 선제적 녹조 대응을 위한 녹조현상 발생 이전의 기온·유량 조건 파악 필요
- 남조류세포수 관측일자와 동일 일자(1 day)부터 1주일(1 week), 2주일(2 week), 3주일(3 week), 4주일(4 week) 전까지의 각 선행기간별 평균 기온 및 평균 유량간 다연상관계수 산정(그림 14)
- 낙동강 본류에 위치한 달성보를 시범지역으로 선정하여 수행

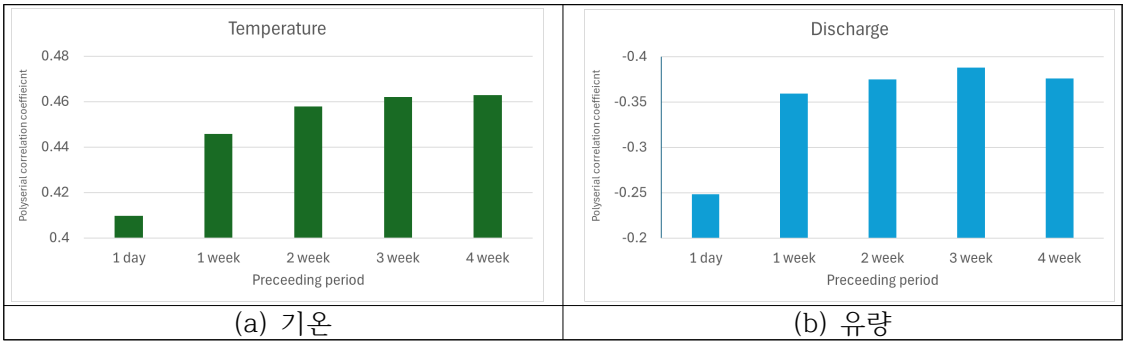

(a) 기온 (b) 유량

<그림 14> 선행기간별 평균 기온·유량-녹조 단계 다연상관계수 산정결과

- 예를 들어, 1 day의 경우 남조류세포수 관측일자와 동일한 일자에 관측된 기온 및 유량인자와 녹조 단계간 상관계수를 도출하였고, 1 week의 경우 남조류세포수 관측일자와 동일한 일자부터 1주일 전 동안의 기온 및 유량 관측치의 평균값과 녹조 단계간 상관계수를 도출
- 동일 관측일자간의 상관관계는 비교적 낮게 산정되었으나 1주일 이상의 영향기간을 고려하였을 경우 상관관계가 높아짐을 확인할 수 있음
- 다연상관 분석 결과, 기온의 경우 **4주(0.463)**, 유량의 경우 **3주(-0.388)**가 가장 상관관계가 높은 선행 영향기간으로 선정됨
- 도출한 각 인자의 선행 영향기간을 토대로 머신러닝 분석 및 녹조 예보체계 제시

□ 머신러닝을 활용한 기온·유량 기반 녹조 예보체계 제시

○ 의사결정나무 분석을 통한 녹조 단계별 기온·유량 분리기준 도출

- 기온-유량 기반 녹조 예보체계를 제시하기 위해 본 연구에서는 머신러닝 기법 중 의사결정나무(Decision tree) 분석 결과를 활용

- 남조류세포수 관측자료 보유기간(2014.01 ~ 2023.12) 동안의 녹조 예보단계와 기온·유량간 의사결정나무 분석 수행(그림 15)

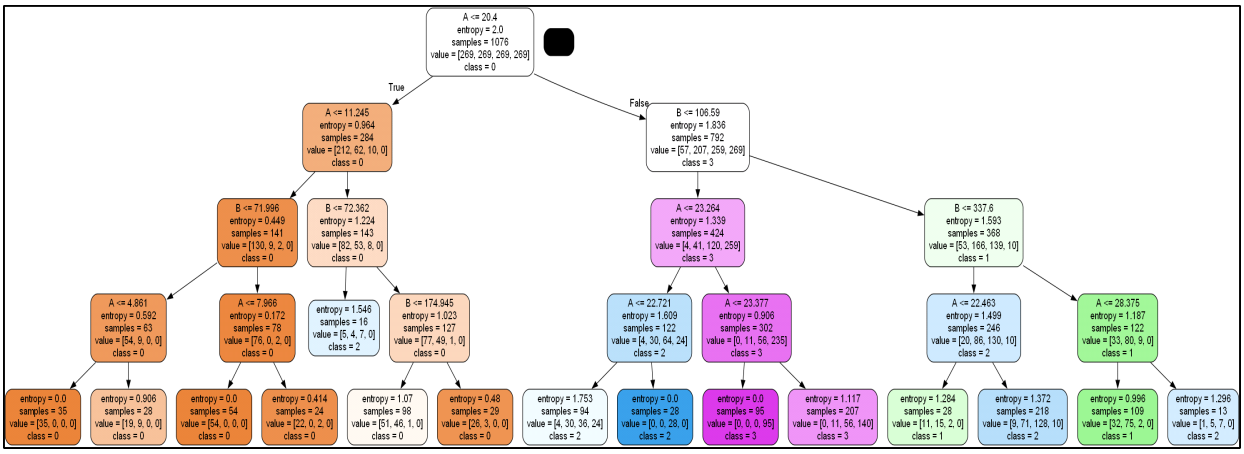

<그림 15> 의사결정나무 분석결과 (달성보 예시)

- 학습구간과 검증구간을 다르게 하여 10회 반복 수행하였으며, 각 도출한 의사결정나무의 결정노드(Decision node)에 도출된 녹조 단계를 구분하는 기온 및 유량 기준값을 추출
- 그림 16을 예시로, 의사결정나무에서 표출되는 각 cell을 결정노드(Decision node)라 하며, 결정노드가 포함하는 정보는 다음과 같음

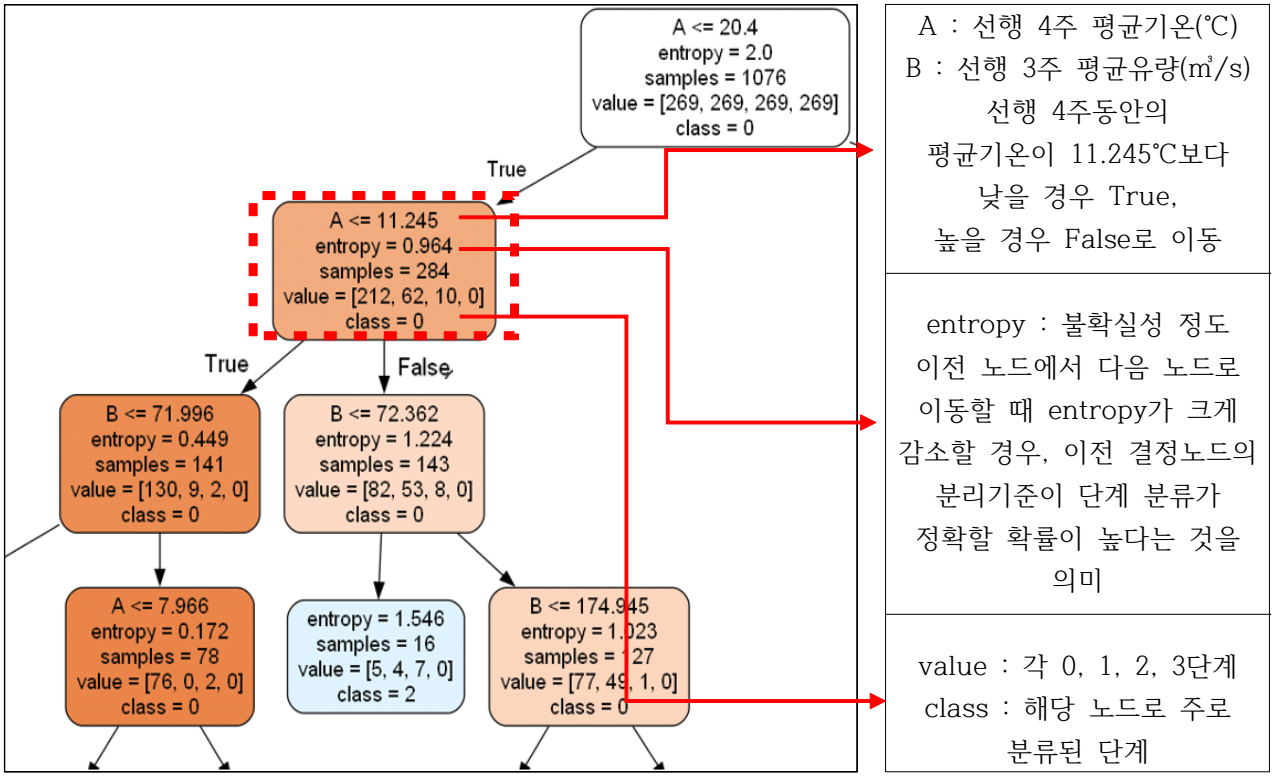

<그림 16> 의사결정나무를 통한 분리기준 도출 예시

- 의사결정나무 분석 10회 반복을 통하여 entropy를 비교적 크게 감소시키고, 출현하는 빈도가 높은 결정노드의 기온 및 유량 기준값 선정(표 4)

<표 4> 남조류세포수에 따른 단계 구분

요소	녹조 단계별 기준				
	0단계	1단계		2단계	3단계
4주 선행평균 기온(℃)	-	20.4	22.5	23.3	-
3주 선행평균 유량(㎥/s)	-	633.7	138.3	106.6	-

- 달성보의 경우 4단계 이상(남조류세포수 1,000,000 cell/ml 이상) 발령된 이력이 없으므로 0단계부터 3단계까지 총 4개의 단계에 따른 기온과 유량 분리 기준 도출
- python 언어를 통하여 의사결정나무 분석을 수행하였으며, 표 5에 의사결정나무 분석에 사용된 라이브러리, 패키지 및 모듈을 요약하였음

<표 5> 의사결정나무 분석을 위한 python 패키지

라이브러리	패키지	모듈	설명
–	pandas	–	테이블 형태의 데이터를 다루는 데이터프레임(DataFrame) 자료형을 제공하며, 자료 탐색과 정리에 유용한 기능 제공
		read_excel	엑셀 파일(.xlsx) 불러오기
sklearn	–	–	다양한 머신러닝 모형 제공
	model_selection	train_test_split	머신러닝을 위하여 시계열 데이터의 학습기간과 검증기간을 분리
		GridSearchCV	최적 파라미터 값 탐색 등 머신러닝 모델의 성능 향상
	tree	DecisionTree Classifier	의사결정나무 분류모형
	pipeline	make_pipeline	데이터 전처리에서 학습까지의 과정을 하나로 연결
	metrics	accuracy_	분류 성능 평가
imblearn	over_sampling	SMOTENC	불균형 데이터를 다루기 위한 패키지 및 모듈
matplotlib	–	–	각종 그래프나 차트 등의 시각화 기능 제공
seaborn	–	–	matplotlib에서 제공하지 않는 고급 통계 차트의 시각과 기능 제공
os	–	–	파일 및 디렉터리 관리, 시스템 명령어 실행, 경로 관련 작업 등 운영체제와 상호작용하는 다양한 기능 제공
pydotplus	–	–	sklearn으로부터 생성된 dot data를 의사결정나무 이미지 파일로 변환하는 기능 제공
IPython	display	Image	python 편집기 결과화면에 이미지, 영상 등 출력

○ 선행기간 평균 기온-유량 기반 녹조 예보체계 제시

- 도출한 녹조 단계별 선행기간 평균 기온-유량 분리기준을 통하여 녹조 예보체계 제시(그림 17)

요소			4주 평균기온 (℃)			
			20.4	22.5	23.3	
			0단계	1단계	2단계	3단계
3주 평균유량 (㎥/s)	633.7	0단계	0단계	0단계	1단계	1단계
	138.3	1단계	0단계	1단계	1단계	2단계
	106.6	2단계	1단계	1단계	2단계	3단계
		3단계	1단계	2단계	3단계	3단계

<그림 17> 기온·유량 기반 녹조 예보체계 (달성보)

- 예보체계의 사용 예시로, 달성보의 지난 4주간의 평균기온이 22.5℃, 지난 3주간의 평균 유량이 106.6㎥/s 미만일 경우 녹조 3단계(남조류세포수 100,000 cell/ml 이상, 1,000,000 cell/ml 미만)로 예측
- 도출한 녹조 예보체계의 검증을 수행하였으며, 학습구간(2014년부터 2022년의 녹조 주 발생기간인 5월부터 10월까지)에 적용한 결과 실제 경보 발령기록 대비 정확도 50.24%로 산정되었으며, 검증구간(2023년 5월~10월)에 적용한 결과 실제 경보 발령기록 대비 정확도 62.50%로 산정됨
- 정확도 보완을 위하여 수질인자 등 보다 다양한 요인을 고려할 필요가 있을 것으로 판단됨

A-2 녹조·수질 영향 독립변수들의 설명력 검정을 위한 설명가능한 AI(XAI: eXplainable AI) 기술 알고리즘 및 활용방안 제시

작성자: 서울시립대학교 신지훈 박사

제 1 장 서 론

1.1 자문내용 및 범위

기후변화의 가속화는 물환경 전반에 걸쳐 이전과는 다른 형태로의 변화를 촉진하고 있다. 기후위기 시대, 빈번해진 이상 수질에 대응하여 안전하고 지속가능한 수자원의 활용을 영위하기 위해서는 지속적인 모니터링과 더불어 정확한 예측을 기반으로 하는 사전적 관리체계를 마련할 필요가 있다. 이러한 상황에서 수질사고(이상 수질, 녹조현상 등)의 발생에 앞서 정확한 예측이 가능한 모델은 예방적 조치를 적시에 시행하기 위한 유용한 의사결정 지원도구로 활용될 수 있다.

전통적으로 물환경 분야에서는 시스템에 대한 통찰과 인과해석이 가능한 기작기반 모델(process-based models)의 활용이 선호되어왔으나, 최근 빅데이터의 등장, 컴퓨팅 능력의 발전 등으로 인해 물환경 분야에서도 인공지능(Artificial Intelligence, AI) 기술의 활용이 지속적으로 증가하고 있다(차윤경 외 2020). 특히 2010년을 기점으로 AI 기술을 비롯한 자료기반 모델의 활용 증가율이 기작기반 모델을 앞선 것을 확인할 수 있다<그림 1.1>. AI 기술은 통계기법이나 ML, 또는 딥러닝(Deep Learning, DL) 알고리즘을 통해 시스템에 대한 사전지식(Domain knowledge)를 요구하지 않고 가용 데이터에 내재된 정보를 학습함으로써 수질변화에 대한 예측을 수행 가능하며, 다수의 연구에서 우수한 예측정확도를 보고하고 있다(Wai et al., 2022). 그러나 우수한 예측 정확도를 확보하더라도 출력값에 대한 결정근거를 파악하지 못한다면, 수자원 관리에 있어 AI 기술 실질적인 활용도를 극대화하는 데 있어 제한점으로 작용한다.

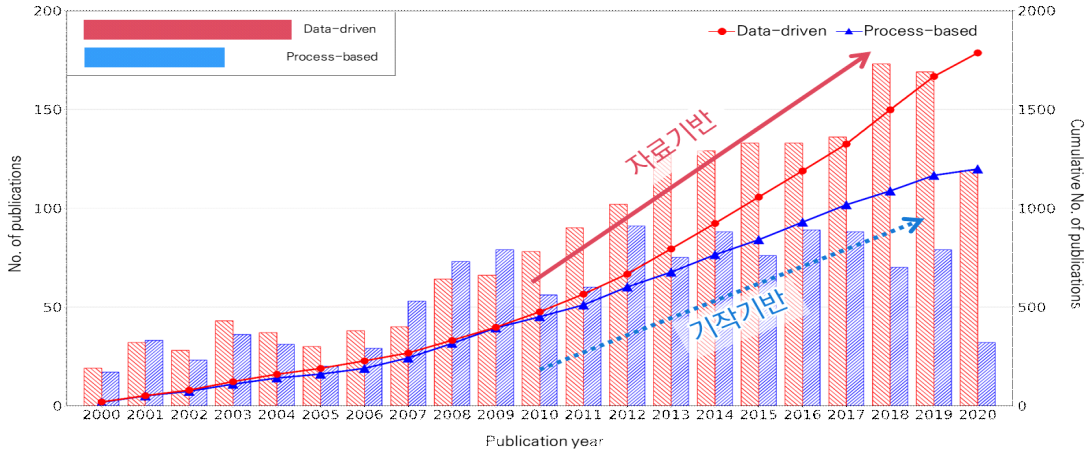

<그림 1.1> 자료기반 및 기작기반 모델 활용 출판 현황(차윤경 외, 2020)

인공지능 모델의 출력값에 대한 결정근거(변수 중요도 등)을 파악할 수 있다면, 사용자는 수질변화와 그 영향인자 간의 관계를 정량화하고 관리전략 수립 및 시행을 위한 의사결정 지원 자료로서 활용 가능하다. 일부 간단한 형태의 AI 모델(선형 회귀모델, 결정나무 모델 등)들은 자체적으로 해석가능한 구조를 지녀 별도의 알고리즘을 적용하지 않고도 예측결과에 대한 결정근거를 사용자가 확인가능하다(Arrieta et al., 2020; Ali et al., 2023). 그러나 간단한 구조의 AI 모델은 복잡한 형태의 입력자료에 대한 학습능력이 부족하여 예측의 정확도를 확보하기 어렵다. 반면 복잡한 형태의 AI 모델은 향상된 예측 정확도를 확보할 수 있으나 내부 구조에 대한 접근이 어려워져 모델의 블랙박스적 특성이 강해진다<그림 1.2>. 최근 복잡한 AI 모델의 출력값에 대한 결정근거를 사용자가 이해할 수 있는 형태로 가공하여 제시할 수 있도록 하는 설명가능한 인공지능(eXplainable AI, XAI)에 대한 연구가 점차 증가하고 있다(Ali et al., 2023). 이에 본 자문에서는 효율적인 수자원 관리를 위한 수질예측 시스템의 개발에 기여하기 위해 녹조, 수질 예측을 대상으로 활용 가능한 XAI 기술 알고리즘에 대한 소개 및 활용방안 등을 제시하고자 한다.

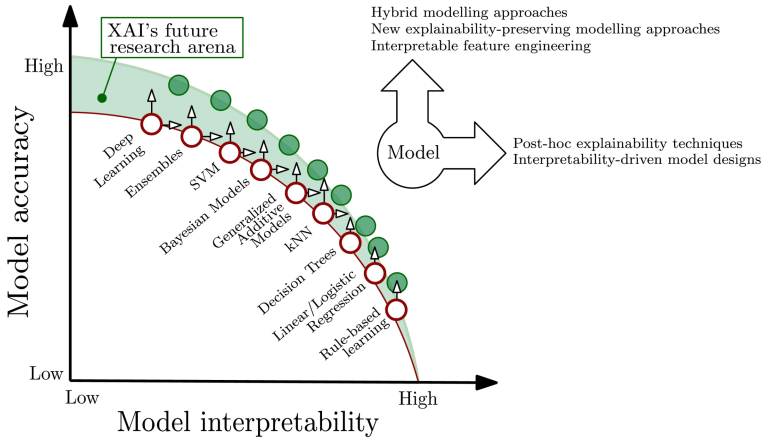

<그림 1.2> AI 기반 모델의 정확도와 해석력 간 관계(Arrieta et al., 2020)

1.1.1 주요 자문내용

본 자문은 i) 녹조·수질에 영향을 미치는 독립변수들의 설명력 검정을 위해 활용 가능한 XAI 기술 알고리즘 및 활용방안을 제시하며, ii) 가용 기술 중 다중공선성 문제를 회피하며 설명력을 높이는 방법론과 그 활용방안의 제안하는 것을 목적으로 한다. 이를 위해 a) 테이블형 자료(Tabular data)에 적용성이 높은 기술 및 적용 사례 등을 제시하고, b) 이를 기반으로 녹조·수질 예측에 대한 적용 방향(안)을 제안하며, c) 대표적인 XAI 기술 시험적용을 위한 예시 코드를 제공했다.

제 2 장 XAI 기술 및 활용방안

2.1 XAI 기술 알고리즘

본 절에서는 XAI의 개요(Section 2.1.1)와 함께 대표적인 방법론(Section 2.1.2)들을 제시한다.

2.1.1 XAI 개요

XAI 기술이란, AI 기반 모델의 출력값이 도출되는 결정근거를 사용자가 이해할 수 있는 형태로 제공하는 일련의 알고리즘 및 방법론들을 의미한다<그림 2.1>. XAI 기술들은 예측 성능과 모델의 해석력 간의 trade-off를 완화하는 데 목적을 두며, 이를 통해 사용자는 블랙박스 모델 내부에서 학습되는 입력변수와 출력값 간의 관계를 파악할 수 있다. 이와 관련된 모델의 특성으로는 대표적으로 설명력/설명가능성(Explainability)과 해석력/해석가능성(Interpretability)이 있으며, 각 특성(용어)의 정의는 아래와 같다.

- **설명력/설명가능성(Explainability)**: 모델 내부의 작동 방식을 사용자가 이해할 수 있는 형태로 제시할 수 있는 능력 또는 정도를 지칭하며, 이와 관련하여 사후 설명(Post-hoc explainability) 방법론들은 입력데이터가 출력값에 기여하는 정도 등을 사용자에게 제공한다.
- **해석력/해석가능성(Interpretability)**: 모델 내부의 작동 방식 자체를 사용자에게 제시할 수 있는 능력 또는 정도를 지칭하며, 완전히 투명한 모델(e.g., 단일 결정나무)의 경우 출력값이 도출되기 위한 모든 결정 근거(e.g., 결정나무 모델의 decision criteria, 회귀모델의 coefficient 등)가 해석 가능함을 의미한다.

<그림 2.1> XAI의 개요

2.1.2 XAI 방법론

본 자문에서는 입력 데이터의 특성 XAI 기술의 적용성 등을 고려하여, XAI 기술 중 모델에 구애받지 않고 적용 가능한 model-agnostic explanation techniques와 딥러닝 모델의 구조 수정 등을 통해 interpretability을 향상시키는 model-specific 방법론들을 소개한다.

1) Model-agnostic techniques

Model-agnostic 방법론들은 모델의 종류에 구애받지 않고 활용 가능하며, 학습된 모델에 적용함으로써 설명력의 향상을 도모하는 사후 설명(post-hoc explanations) 방법론들로 구성된다.

① Partial dependence plot

Parital dependence plot(PDP)은 AI모델의 1개 또는 2개 입력변수 변화에 따른 출력값의 선형(linear), 비선형(non-linear) 또는 비단조적(non-monotonous) 반응을 시각화하는 도표이다(Ellith et al., 2008). 이때 2개 입력변수에 대한 PDP를 도시하면 변수 간의 상호작용 효과를 시각적으로 제시할 수 있다<그림 2.2>.

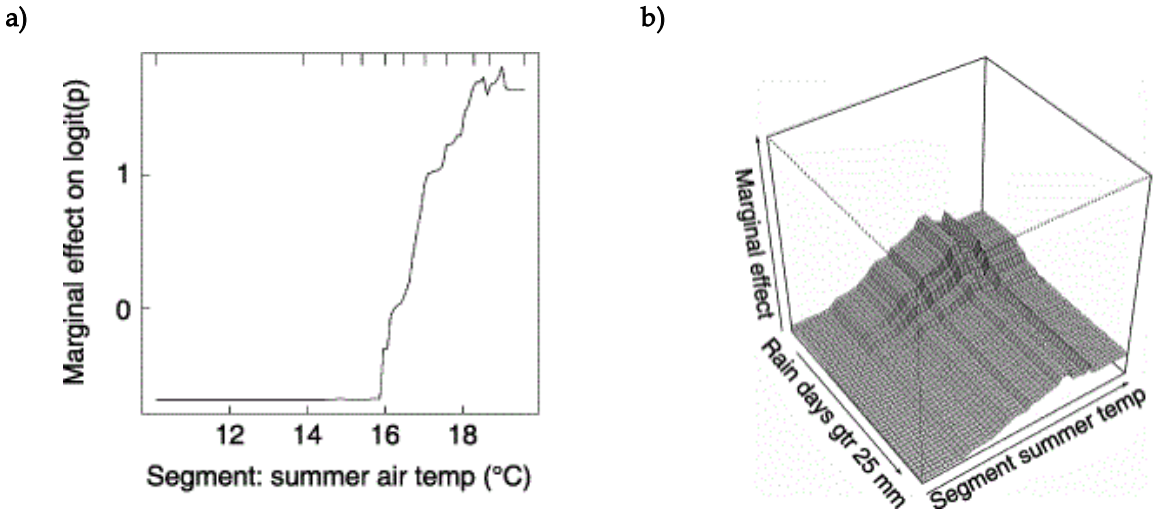

<그림 2.2> a) 단일 입력변수, b) 2개 입력변수에 대한 PDP 예시(Ellith et al., 2008)

이때 특정 입력변수의 partial dependence는 데이터를 구성하는 특정 샘플에 대해 타 입력변수(x_c^i)의 값을 고정한 상태에서 분석 대상 입력변수의 값(x_s)을 전체 샘플 내 존재하는 값들로 변화시켜가며 산정한 모델(f)의 평균 예측값을 의미한다<식 2.1>.

$$Partial\ dependence\ (x_s) = \frac{1}{N}\sum_{i}^{N} f(x_s, x_c^i)$$ **<식 2.1>**

이를 모든 샘플(N)에 대해 도시하면 PDP를 얻을 수 있다. 이때 분류 모델의 경우 각 범주별 확률에 대해 PDP를 도시함으로써 입력변수와 출력값의 관계를 제시할 수 있다.

PDP는 모델의 종류에 구애받지 않고 간단하게 적용할 수 있으며, 변수의 전역적인 중요도(Global importance)와 방향을 직관적으로 제공할 수 있다는 장점이 있다. 그러나 모든 입력변수가 서로 독립이라는 가정이 요구되어 다중공선성 문제 하에서 분석 결과의 신뢰도를 확보하기 어려우며, 전체 데이터 내 국소적인(Local) 구간에 대해 해당 변수의 이질적 영향(Heterogeneous effect)이 무시되는 단점이 있다.

② Permutation importance

Permutation importance(PI)는 입력변수의 값을 무작위로 섞었을 때 발생하는 모델 오차의 변화 정도를 기반으로 변수의 중요도를 정량화한다. 중요한 변수를 무작위로 섞는(permuting) 경우 모델의 오차는 크게 증가하는 반면, 중요도가 낮은 변수를 섞는 경우 모델의 오차는 큰 변화를 나타내지 않는다(Kim et al., 2021). PI의 산정은 아래 절차를 통해 이루어진다<식 2.2 ~ 식 2.4>.

$$\epsilon^o = L(y, f(X))$$ **<식 2.2>**

$$\epsilon_j^p = L(y, f(X_j^p))$$ **<식 2.3>**

$$PI_j = \epsilon^o - \epsilon_j^p$$ **<식 2.4>**

즉, j번째 변수에 대한 중요도 PI_j는 해당 변수의 값을 무작위로 섞은 입력변수(X_j^p)를 활용했을 때의 모델 오차(ϵ_j^p)와 기존 모델의 오차(ϵ^o) 간의 차로써 표현된다.

PI는 모델을 재학습시킬 필요 없이 간단하게 적용할 수 있으며, 서로 다른 입력변수 간의 상호작용이 고려된 변수 중요도를 제시할 수 있다. 그러나 모델의 예측 정확도에 큰 영향을 받으며, 데이터의 변화에 따라 분석 결과 크게 달라질 수 있으므로 안정적인 결과를 확보하기 어렵다. 또한 출력값에 대해 입력변수가 기여하는 방향(음/양)을 알 수 없다.

③ Individual conditional expectation

Individual conditional expectation(ICE)는 개별 예측 결과(즉, 샘플)에 대한 국소적인 설명(Local explanation)을 위한 partial dependence로 아래 수식을 통해 산정된다<식 2.5>.

$$ICE^i = f(x_s, x_c^i) \qquad \text{<식 2.5>}$$

이후 모든 샘플에 대해 산정된 ICE 값들을 개별 선으로 도시함으로써 특정 입력변수의 기여도를 세부적으로 파악 가능하다<그림 2.3>.

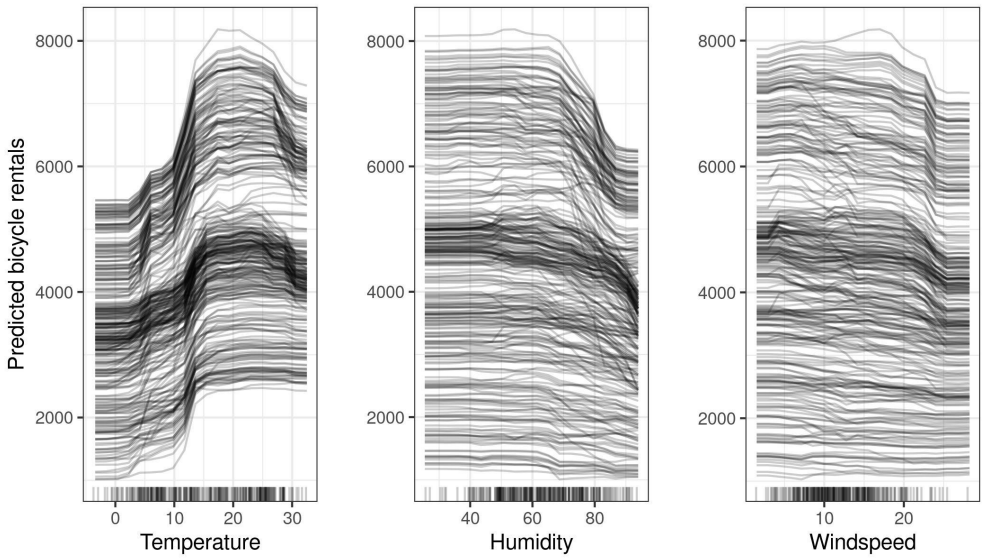

<그림 2.3> ICE 적용 예시(Molnar et al., 2020)

ICE 또한 모델에 구애받지 않고 간단하게 적용 가능하며 PDP보다 더욱 직관적으로 입력변수의 기여도를 제공할 수 있다. 또한 국소적인 해석을 제공할 수 있으므로 변수의 이질적 영향을 분석 가능하다. 그러나

④ Local Interpretable Model-agnostic Explanations (LIME)

LIME은 복잡한 블랙박스 모델도 부분적으로는 해석가능한 모델로 적합 시킬 수 있다는 전제를 기반으로 부분적으로 AI 모델을 선형회귀모델로 근시 시킴으로써 모델의 설명력을 향상시킨다(Ribeiro et al., 2016). 즉 LIME의 목적은 AI 모델(f)로부터 얻어진 개별 예측 결과(x)에 대한 해석을 위해 local surrogate model을 적합하는 것으로 local surrogate model(g)은 다음의 <식 2.6>과 같이 표현 가능하다.

$$interpretation(x) = argmin_{g \in G} L(f, g, \pi_x) + \Omega(g)$$ **<식 2.6>**

이때 L은 손실함수, π_x는 proximity measure (Kernel function), $\Omega(g)$는 복잡도를 나타낸다. 즉 local surrogate model은 모델(g)의 추정값과 기존 모델(f)의 예측 결과와의 손실함수 값을 최소화하는 동시에 복잡도를 낮게 유지하도록 적합된다<그림 2.4>. 이때 proximity measure는 개별 예측 결과(x) 주변의 얼마나 많은 perturbed instance를 local surrogate model의 적합 시 고려할지를 설정하는 파라미터이다.

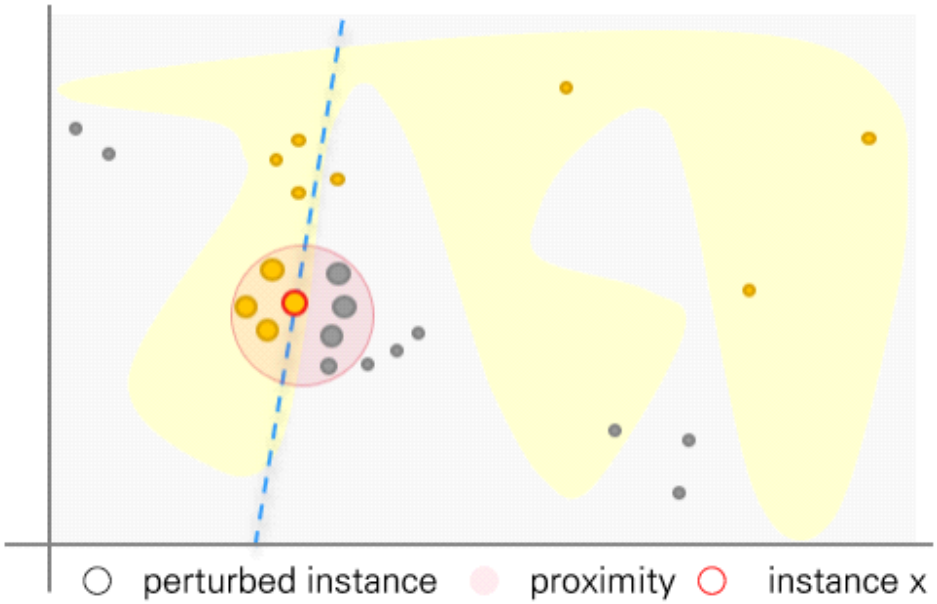

<그림 2.4> LIME을 통한 블랙박스 모델의 국소적합 예시

이를 기반으로 LIME의 동작은 아래와 같이 같이 이루어진다<그림 2.5>.

1) 기존 모델(f)의 예측 결과에서 해석을 원하는 샘플(x)을 선택
2) x에 대해 가상의 샘플인 perturbed instance를 생성
3) 설정한 proximity(π_x)에 따라 x 주위의 perturbed instance에 가중치를 설정
4) 상기 절차를 통해 얻어진 데이터를 통해 local surrogate model을 적합
5) 적합 결과를 바탕으로 x에 대한 각 변수의 상대적 중요도를 설명

LIME은 개별 예측 결과에 대해 다수의 입력변수를 대상으로 상대적 중요도를 기여의 방향과 함께 제시할 수 있으며, 활용을 위한 별도의 가정을 요구하지 않는다. 그러나 매 구동 시 해석 결과(변수 중요도의 크기)에 변화가 발생하며, 개별 예측 결과에 대한 설명만을 제공하므로 출력값에 대한 입력변수의 전역적인 중요도를 파악하는 데는 한계가 있다.

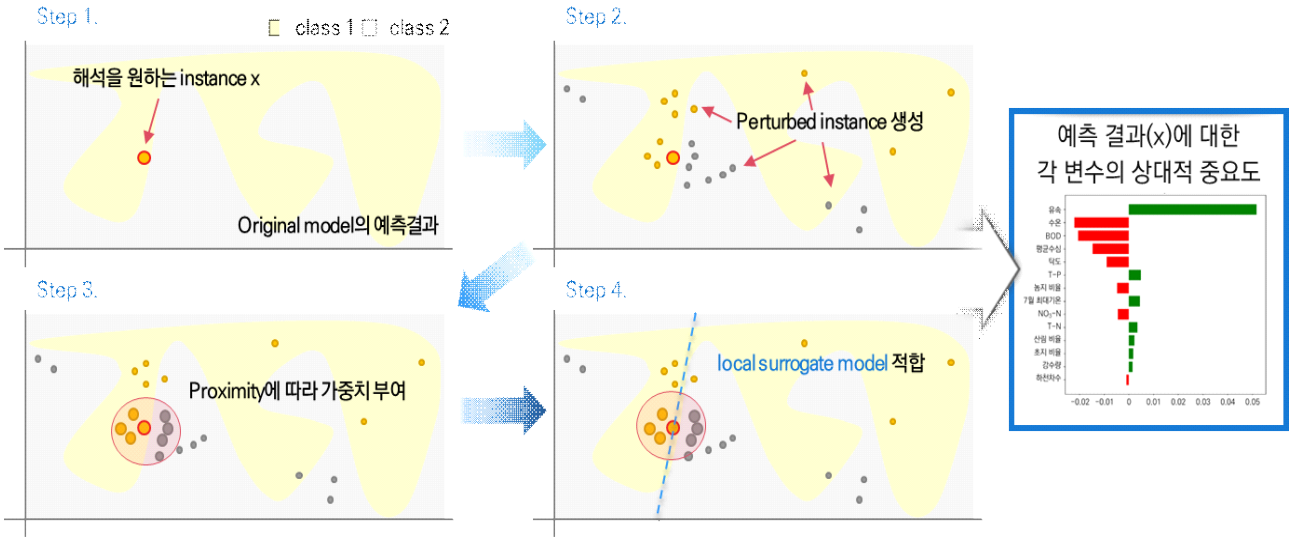

<그림 2.5> LIME의 동작 단계 및 적용 예시

LIME의 적용성을 향상시키기 위한 방법론 중 Submodular Pick for LIME (SP-LIME)은 AI 모델의 출력값을 대표할 수 있는 해석들을 선택해주는 알고리즘이다. SP-LIME은 coverage function을 기반으로 각 입력변수의 global importance를 고려하여 모든 샘플에 대한 설명 중 예측 결과를 가장 잘 대표할 수 있는 설명들을 선택한다<그림 2.6>.

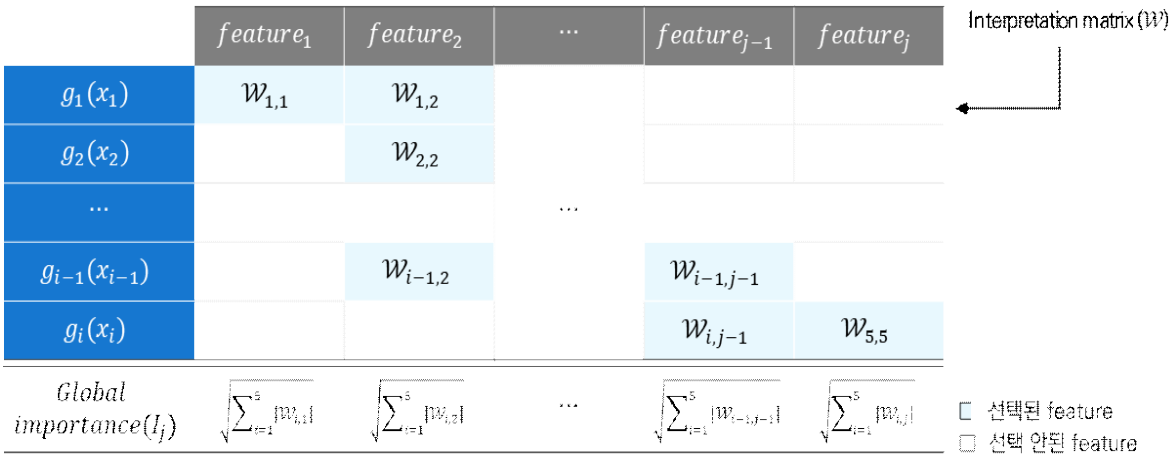

<그림 2.6> SP-LIME 알고리즘 예시

이때 선택된 g_i들의 집합을 V라 하며, $V=\{g_1, g_{i-1}\}$라면, coverage function인 $c(V, W, I)$는 다음과 같이 표현 가능하다<수식 2.7>. 즉 coverage function은 선택된 V에 대해 한번이라도 나타난 모든 입력변수의 global importance를 더한 값이다. 따라서 SP-LIME은 이를 최대화하는 설명의 집합(pick)을 제공한다<식 2.8>.

$$c(V, W, I) = I_1 + I_2 + \ldots + I_{j-1} \qquad \textbf{<식 2.7>}$$

$$\Pi ck = \arg max\, c(V, W, I) \qquad \textbf{<식 2.8>}$$

⑤ Shapley Additive Explanations (SHAP)

SHAP은 Shapley value의 원리를 기반으로 모델의 설명력을 향상시키는 방법론으로 견고한 이론적 기반을 바탕으로 모델 종류에 구애받지 않고 적용이 가능하다(Lundberg and Lee, 2017). 특히 예측결과에 대한 전역적인 해석과 더불어 각각의 예측값에 대한 국소적 해석이 모두 가능해 물환경을 비롯해 AI를 활용하는 다양한 분야에서 활용성을 입증받고 있다. 이때 Shapely value는 <식 2.9>와 같이 표현된다(Shapely, 1953).

$$\Phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F|!-|S|!-1)}{|F|!}(f_{S\cup\{i\}}(x_j) - f_S(x_j)) \quad \text{<식 2.9>}$$

F: 모델 입력변수 전체

S: 기여도를 구할 i번째 변수를 제외한 나머지 변수 $F\setminus\{i\}$의 부분 집합

x_j: 전체 샘플 중 j번째 샘플

Φ_i: i번째 변수에 대한 Shapley value

이때 $f_{S\cup\{i\}}(x_j) - f_S(x_j)$는 j번째 샘플의 모델 예측결과에 대한 i번째 변수의 marginalized contribution을 의미한다. 따라서 Shapley value는 j번째 모델 예측결과에 대한 i번째 변수를 제외하고 형성할 수 있는 모든 경우의 수에 대한 모델 예측결과의 차이에 대한 가중평균이며, 이를 활용하여 각각 변수의 기여도를 계산할 수 있게 된다.

Shapley value는 efficiency, symmetry, dummy, additivity의 특성을 모두 만족한다는 장점이 있다(Molnar, 2020). Efficiency 특성은 특정 샘플에 대한 모델의 예측값과 전체 샘플에 대한 예측값의 평균의 차이가 해당 샘플에 대한 각 변수의 기여도의 합과 같다는 것을 의미하며, 아래와 같이 표현할 수 있다.

$$\sum_{j=1}^{p} \Phi_j = \hat{f}(x) - E_X(\hat{f}(x)) \quad \text{<식 2.10>}$$

Φ_j: j번째 변수의 shapley value

p: 변수의 전체 개수

$\hat{f}$: 모델 예측값

Efficiency 특성을 통해 Shapley value는 해당 샘플에 대해 각 변수에 대한 기여도가 평균 예측에 비해 어느정도의 영향을 주었는지를 수치적으로 판단할 수 있도록 한다.

Symmetry 특성은 변수의 전체집합인 S와 각각 j변수, k변수의 합집합에 대해 모두 결과값이 같다면 같은 shapley value값을 갖는다는 특성으로 아래와 같이 표현할 수 있다<식 2.11>.

$$
\begin{aligned}
&if, \\
&val(S \cup \{x_j\}) = val(S \cup \{x_k\}) \\
&for\ all \\
&S \subseteq \{x_1,...,x_p\} \setminus \{x_j, x_k\} \\
&then \\
&\Phi_j = \Phi_k
\end{aligned}
$$

<식 2.11>

Φ_j: j번째 변수의 shapley value

val: 모델 출력값

S: 변수 전체집합과 j,k변수에 대한 차집합의 부분집합

Symmetry 특성으로 인해 Shapley value를 통해 얻어진 변수 기여도는 같은 모델인 경우 다른 샘플, 다른 변수에 대해서 모든 Shapley value값의 비교를 통해 기여도의 크기를 직접적으로 비교할 수 있다.

Dummy 특성은 해당 변수의 유무가 예측값에 영향을 주지 못한다면 Shapely value가 0인 것을 의미하며 아래와 같이 표현할 수 있다<식 2.12>.

$$
\begin{aligned}
&if, \\
&val(S \cup \{x_j\}) = val(S) \\
&for\ all \\
&S \subseteq \{x_1,...,x_p\} \\
&then \\
&\Phi_j = 0
\end{aligned}
$$

<식 2.12>

마지막으로 Additivity 특성은 모델이 혼합모델인 경우 각 개별모델에서의 j번째 변수에 대해 Shapley value를 더한 값이 최종 모델의 Shapley value와 동일하다는 것을 의미하며 아래와 같이 표현할 수 있다<식 2.13>.

$$
\begin{aligned}
&if, \\
&val = val_1 + val_2 \\
&then \\
&\Phi_j = \Phi_j^1 + \Phi_j^2
\end{aligned}
$$

<식 2.13>

Φ_j^1: val_1모델에서 예측에 대한 j번째 변수의 shapley value

Φ_j^2: val_2모델에서 예측에 대한 j번째 변수의 shapley value

변수 기여도를 분석하는 기법 중 위의 efficiency, symmetry, dummy, additivity의 4가지 특성을 만족하는 방법론은 Shapley value가 유일하다. 따라서 Shapely value는 변수간 기여도 비교, 기여도 수치 자체에 대한 분석 등을 수행하는 데 있어 이론적으로 안정성이 보장되므로 그

에 따른 해석의 신뢰성을 향상시킨다. 하지만 Shapley value의 계산을 위해서는 모든 가능한 부분 집합에 대해 모델을 학습시켜야 하므로 계산 복잡도는 입력변수의 개수에 따라 기하급수적으로 증가한다. 또한 기계학습 모델이나 딥러닝 모델의 특성상 모델을 한 번 학습시키기 위해 필요한 계산비용이 크기 때문에 사실상 실제 Shapley value를 계산하여 사용하는 것은 현실적으로 어렵다(Molnar, 2020; Lundberg et al., 2020).

SHAP은 Shapely value의 추정값인 SHAP value를 추정하는 기법으로 대표적으로 kernelSHAP, TreeSHAP, DeepSHAP 등의 알고리즘을 통해 모델의 해석력을 확보한다. KernelSHAP은 가중 선형 회귀분석을 통해 SHAP value를 산정하는 방법으로 실제 Shapely value를 계산하는 데 비해 연산량을 크게 감소시킬 수 있으며, 이때 kernel SHAP 계산을 위한 가중 선형 회귀식은 아래와 같이 표현할 수 있다.

$$g(z') = \Phi_0 + \sum_{j=1}^{M} \Phi_j z_j' \qquad \text{<식 2.14>}$$
$$z_k' \in \{0,1\}^M, (k \in \{1,...,K\})$$

g: 설명모델, 즉 가중 선형 회귀모델

M: 최대 coalition 크기(총 변수의 개수보다 클 수 없음)

K: 랜덤 샘플링한 샘플의 개수

z_k': 연합벡터(coalition vector)

Φ_j: j번째 변수의 shapley value 추정치

이때 가중 선형 회귀식의 손실함수는 아래와 같이 표현할 수 있다.

$$L(f, g, \pi_x) = \sum_{z' \in Z} [\, f(h_x(z')) - g(z') \,]^2 \pi_x(z') \qquad \text{<식 2.15>}$$

f: 변수 기여도를 분석하고자하는 원래 모델

h_x: kernel 함수

z': 샘플링한 연합벡터

π_x: 샘플링한 연합벡터에 대한 가중치

여기서 h_x는 연합벡터(z')를 원래 변수 x의 차원으로 사상하는 kernel 함수이며, 연합벡터는 M의 크기만큼 0 또는 1의 값을 갖는 벡터로 1인 경우 기존 x와 동일한 값이 출력되고, 0인 경우 marginal distribution에서 랜덤한 값을 출력한다. 결과적으로 <식 2.15>는 0과 1의 값을 갖는 연합벡터(z')를 가중치를 갖는 가중 선형 회귀식으로 학습한 모델의 각 변수의 가중치가

SHAP value가 된다. 여기서 가중치인 π_x은 다음과 같이 표현할 수 있다.

$$\pi_x(z') = \frac{(M-1)}{\binom{M}{|z'|}|z'|(M-|z'|)}$$ <식 2.16>

TreeSHAP은 결정나무 기반 모델을 대상으로 적용 가능한 알고리즘이다. TreeSHAP은 결정나무 모델의 구조를 활용하여 정확한 Shapely value를 계산 가능하며, 계산복잡도를 감소시키기 위해 입력변수의 어떤 부분집합이 어떠한 노드(leaf node)로 흘러가는지를 재귀적으로 추적한다(Lundberg et al., 2018; 2020). DeepSHAP은 딥러닝 기반 모델에 대한 SHAP value의 추정 효율화를 위해 등장했다. DeepSHAP은 학습된 딥러닝 기반 모델의 각 층(layer)의 가중치(trainable weights)를 역산하는 형태로 SHAP value를 추정한다.

결과적으로 SHAP value는 출력값에 대한 입력변수의 기여도의 크기와 함께 방향을 제시할 수 있으며, 개별 샘플에 대한 국소적인 해석결과를 종합함으로써 전역적인 해석결과를 동시에 제공 가능하다<그림 2.7>, <그림 2.8>.

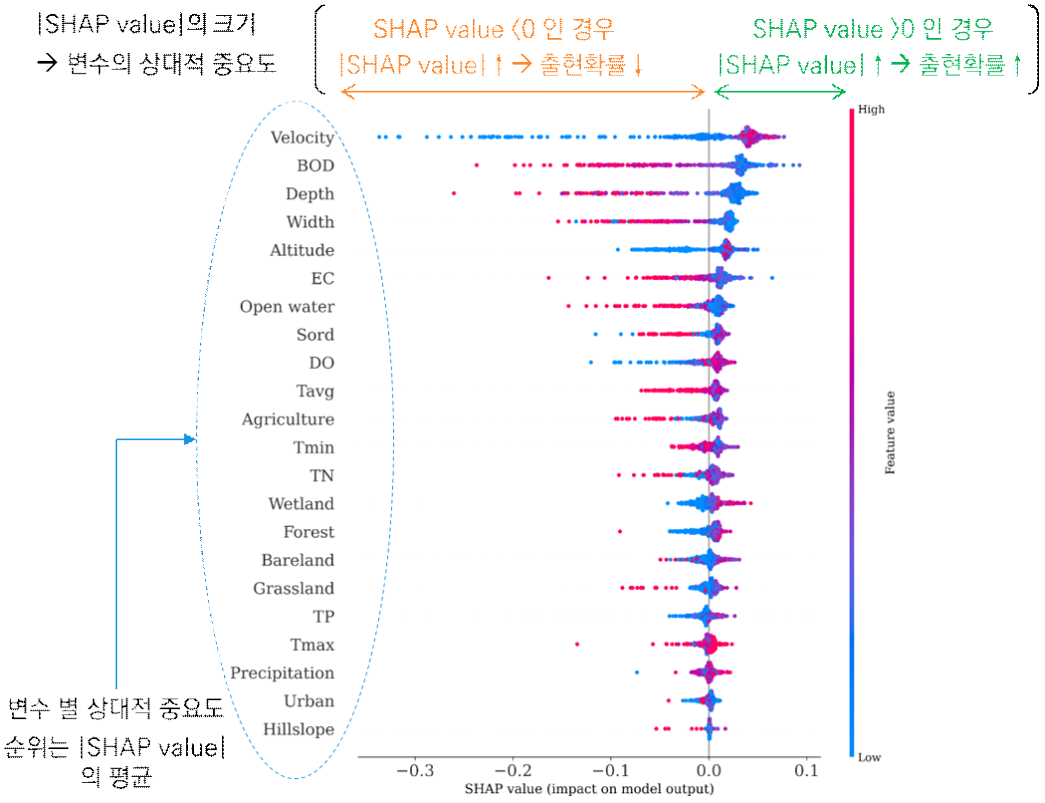

<그림 2.7> SHAP을 활용한 전역적 해석 예시(Cha et al., 2021)

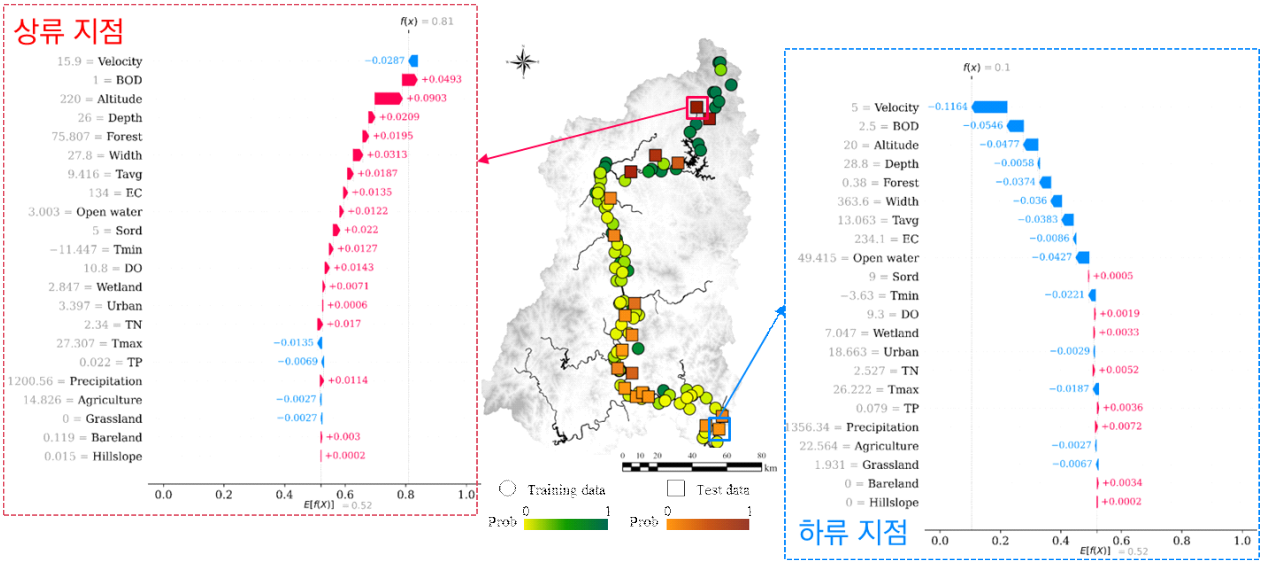

<그림 2.8> SHAP을 활용한 국소적 해석 예시(Cha et al., 2021)

더 나아가 SHAP은 입력변수 간의 상호작용 효과(interaction effect)를 정량화할 수 있으며, 이를 통해 변수 간 상호작용이 모두 제거된 주 영향(main effect)를 정량화할 수 있다. 따라서 SHAP은 다중공선성 문제를 완화하면서 출력값에 대한 입력변수의 기여도의 크기를 기여의 방향과 함께 제공할 수 있다(Lundberg et al., 2020). 입력변수 각 쌍(i,j)에 대한 상호작용 효과는 아래와 같이 산정 가능하다<식 2.17, 식 2.18>.

$$\Phi_{i,j} = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|M|!-|S|!-2)}{2(M-1)!} \nabla ij(S) \qquad \text{<식 2.17>}$$

이때, $i \neq j$인 경우

$$\begin{aligned} \nabla ij(S) &= f_x(S \cup \{i,j\}) - f_x(S \cup \{i\}) - f_x(S \cup \{j\}) + f_x(S) \\ &= f_x(S \cup \{i,j\}) - f_x(S \cup \{j\}) - [f_x(S \cup \{i\}) - f_x(S)] \end{aligned} \qquad \text{<식 2.18>}$$

이때 입력변수 i 와 j 간의 상호작용 효과는 동일하며 $(\Phi_{i,j} = \Phi_{j,i})$ 이는 전체 상호작용 효과를 나타낸다. 따라서 상호작용 효과를 제외한 단일 입력변수의 주영향은 다음과 같이 산정할 수 있<식 2.19>. 이를 시각화하여 표현하면 <그림 2.9>와 같다.

$$\Phi_{i,i} = \Phi_i - \sum_{j \neq i} \Phi_{i,j} \qquad \text{<식 2.19>}$$

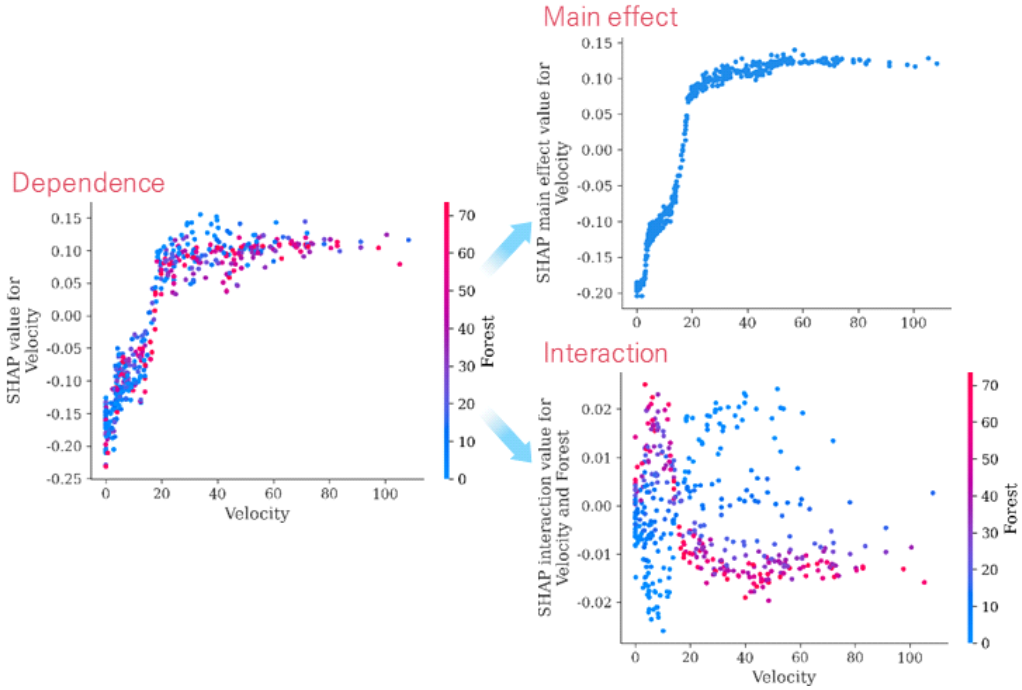

<그림 2.9> SHAP을 활용한 국소적 해석 예시(Cha et al., 2021)

SHAP의 활용은 AI 모델의 출력값에 대한 입력변수의 기여도를 분석하는 데 있어 매우 높은 적합도를 보인다. 국소적 해석, 전역적 해석은 물론 입력변수 간의 상호작용 효과와 해당 효과가 제거된 주 영향을 모두 제공할 수 있어 다중공선성 문제를 완화하면서도 녹조·수질 영향인자의 설명력을 검정하는 데 효과적일 것으로 판단된다. 그러나 모델의 복잡도, 입력데이터의 양 등에 따라 연산 부하량이 크게 증가할 수 있다는 단점이 있다.

2) Model-specific techniques

Model-specific 방법론들은 특정 모델을 대상으로만 적용할 수 있다. 본 자문에서는 딥러닝 모델의 해석가능성을 향상시킬 수 있는 방법론으로 attention mechanism을 소개한다.

① Attention mechanism 개요

Attention mechanism의 기본 아이디어는 출력값을 도출하는 데 있어 입력자료를 전체적으로 다시 한번 참고하는 것이다(Niu et al., 2021). Attention mechanism을 딥러닝 구조에 포함하면, 출력값을 도출하는 데 있어서 중요한 부분에 집중하여 학습을 진행할 수 있다. attention mechanism의 적용은 다양한 형태로 이루어지나, 공통적으로 1) 입력자료를 활용한 attention weight의 산정, 2) 산정된 가중치를 기반으로 하는 context vector의 생성으로 이루어지며 아래와 같이 표현 가능하다<그림 2.10>.

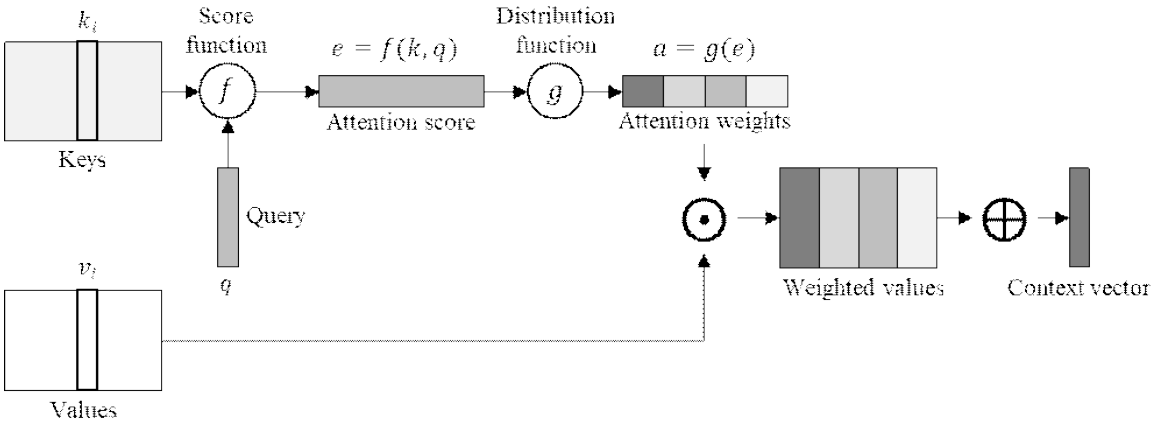

<그림 2.10> Attention mechanism의 적용 절차(Niu et al., 2021)

이때 키(k)와 쿼리(q)는 attention weight의 산정을 위해 활용되며, 키는 입력자료로부터 추출된 은닉 상태 등 가중치 산정에 활용될 특징값들을 나타내며 쿼리는 가중치 산정의 기준이 되는 값을 의미한다. 값(v)는 입력자료 중 가중치를 부여할 부분을 나타낸다. 이때 각 요소들은 attention mechanism의 종류와 적용 목적에 따라 다양하게 설정된다. attention mechanism은 스코어 함수를 통해 키와 쿼리 간의 유사도를 학습하여 어텐션 스코어를 산정한 뒤<식 2.20>, 분포 함수를 적용하여 attention weight를 확보한다<식 2.21>. 이후 산정된 attention weight와 가중치를 부여할 값을 가중합(z_i) 한 뒤, 이를 종합하여 context vector를 얻는다<식 2.22>. 이때 분포 함수로는 어텐션 스코어 값 간의 비교를 용이하게 하기 위해 대체로 Softmax 함수를 적용하며, 이를 통해 attention weight는 합계가 1인 0에서 1 사이의 값을 지니게 된다<식. 2.23>.

$$e = f(q, K) \quad \text{<식 2.20>}$$

$$\alpha = g(e) \quad \text{<식 2.21>}$$

$$c = \sum_{i=1}^{n} z_i = \alpha_i v_i \quad \text{<식 2.22>}$$

$$Softmax(z) = \frac{e^{z_i}}{\Sigma_{k=1}^{K} e^{z_k}} \quad \text{for } i = 1, 2, ..., K \quad \text{<식 2.23>}$$

k : 키(Keys), q : 쿼리(Query), v : 값(Values)

f : 스코어 함수, e : 어텐션 스코어, g : 분포 함수, α : attention weight

c : context vector

이후 context vector를 활용하여 모델링 목적에 맞는 출력값을 도출한다. 이때 스코어 함수는 다양한 형태를 나타내며 대표적인 함수들은 <표 2.1>과 같다(Niu et al., 2021).

<표 2.1> 대표적인 attention 함수

Name	Formula	Reference
Bahdanau attention	$f(q,k) = v_a^\top \tanh(W_a[q_t;k_i])$	Bahdanau et al., 2014
Dot-product attention	$f(q,k) = q_t^\top k_i$	Luong et al., 2015
Scaled dot-product attention	$f(q,k) = \frac{q_t^\top k_i}{\sqrt{n}}$	Vasawani et al., 2017
Location base attention	$\alpha = softmax(W_a q)$	Luong et al., 2015
General attention	$f(q,k) = q_t^\top W_a k_i$	Luong et al., 2015

즉 딥러닝 모델 내부에 attention mechanism을 포함하면, 예측값을 도출함에 있어 입력 데이터 중 중요한 부분에 집중할 수 있도록 하며, 학습된 attention weight를 기반으로 출력값에 대한 설명력(모델 구조에 따라 해석력)을 확보할 수 있다.

② Reverse time attention mechanism (RETAIN)

RETAIN은 시퀀스 데이터를 구성하는 시점(time)과 변수(feature) 각각을 위한 두 개의 attention mechanism을 학습 과정에서 출력값을 도출하는 데 있어 입력변수에 더해 시점에 대해서도 중요한 부분에 집중할 수 있다<그림 2.11>. 즉 RETAIN은 두 개의 attention mechanism을 이용하여 입력변수의 시점별, 중요도를 정량화하여 제공할 수 있다. 게다가 RETAIN은 예측에 있어 최근 관측치를 과거의 관측치보다 주목할 필요가 있다는 가정하에 학습 과정 시 시간 역순으로 시퀀스를 탐색하며, attention weight 생성의 안정성을 확보한다 (Choi et al., 2017).

RETAIN의 연산 과정은 크게 ⅰ) 선형 임베딩(Embedding), ⅱ) time-level attention weight 산정, ⅲ) feature-level attention weight 산정, ⅳ) context vector) 생성, ⅴ) 예측 수행의 다섯 단계로 구분된다. 이때 시점 및 변수에 대한 attention weight의 생성은 병렬로 이루어진다. 입력변수를 D 변수들과 T 시점들(time steps)로 이루어진 다변량 시계열 $X = (x_1, x_2, \ldots x_T)' \in \mathbb{R}^{T \times D}$ 이며, $t \in 1,2,\ldots T$ 에서 $x_t \in \mathbb{R}^D$라 할 때, 첫 번째 단계인 선형 임베딩은 다음과 같이 수행된다<식 2.24>.

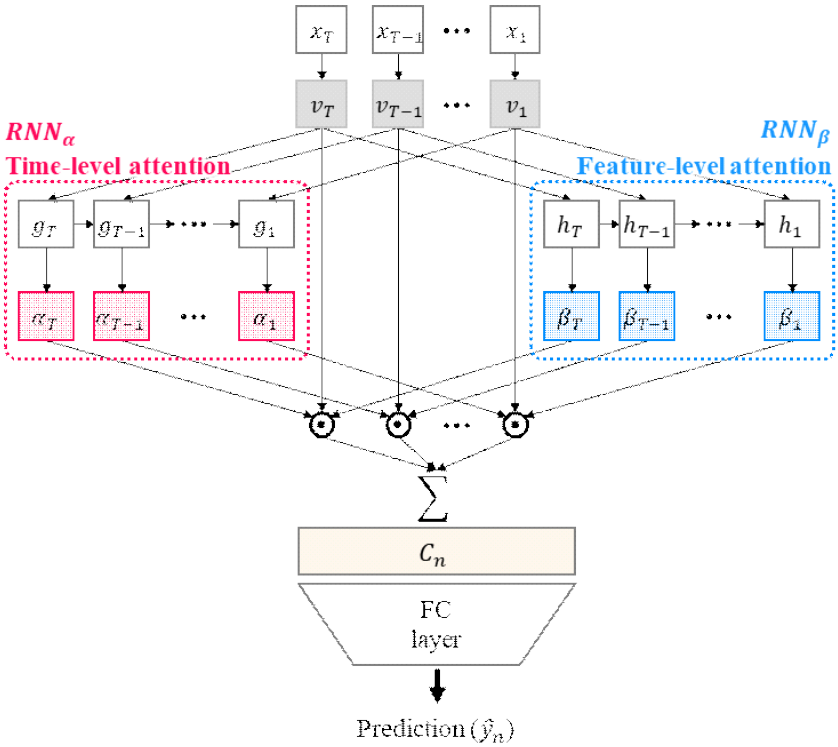

<그림 2.11> RETAIN 모델의 구조

$$v_t = W_{emb} x_t \qquad \text{<식 2.24>}$$

이후 RETAIN은 생성된 임베딩과 두 개의 RNN(즉, RNN_α와 RNN_β) 를 활용하여 시점에 대한 attention weight인 $\alpha = \{\alpha_1, \alpha_2, ..., \alpha_T\}$와 변수에 대한 attention weight인 $\beta = \{\beta_1, \beta_2, ..., \beta_T\}$를 생성한다. 이때 attention weight 산정을 위한 각각의 RNN은 GRU가 활용된다(Cho et al., 2014). 각각의 가중치는 각각 시점별 임베딩 $\{v_1, v_2, ..., v_T\}$과 시점별 임베딩 내 각 차원 $\{v_{1,1}, v_{1,2}, ..., v_{1,T}, ..., v_{T,1}, v_{T,2}, ..., v_{T,V}\}$에 대응하는 값을 활용하여 산정된다.

$$\begin{aligned} &g_T, g_{T-1}, ..., g_1 = RNN_\alpha(v_T, v_{T-1}, ..., v_1), \\ &e_t = w_\alpha^\top g_t + b_\alpha \quad \text{for } t = 1, ..., T, \\ &\alpha_1, \alpha_2, ..., \alpha_T = Softmax(e_1, e_2, ..., e_T) \end{aligned} \qquad \text{<식 2.25>}$$

$$\begin{aligned} &h_T, h_{T-1}, ..., h_1 = RNN_\beta(v_T, v_{T-1}, ..., v_1), \\ &\beta_t = \tanh(W_\beta h_t + b_\beta) \quad \text{for } t = 1, ..., T \end{aligned} \qquad \text{<식 2.26>}$$

이때 $w_\alpha \in \mathbb{R}^p$, $W_\beta \in \mathbb{R}^{V \times q}$, $b_\alpha \in \mathbb{R}$, $b_\beta \in \mathbb{R}^V$ 이다. 이때 시점별 attention weight(α)는 Softmax 함수를 통해 합계가 1인 0에서 1 사이의 값을 지니게 되며, 변수별 attention weight(β)는 tanh를

통해 [-1, 1] 범위의 값을 지니게 된다. 다음으로 임베딩과 시점 및 변수별 attention weight를 활용하여 context vector($c \in \mathbb{R}^V$)를 아래와 같이 산정한다.

$$c = \sum_{t=1}^{T} \alpha_t \beta_t \odot v_t \qquad \text{<식 2.27>}$$

이를 RETAIN 모델 최후단의 완전연결층(fully-connected layer, FC layer)에 입력함으로써 입력자료에 대응되는 예측값을 얻는다.

$$\hat{y} = FC(c) = ReLU(W_{FC} c) \qquad \text{<식 2.28>}$$

RETAIN은 시점 및 변수에 대한 attention weight(α, β)와 임베딩을 종합하여 최종 예측값을 도출한다. 따라서 각 예측값에 대한 입력변수의 상대적 기여도(contribution)를 전술한 항들로 직접적으로 표현이 가능하다. 입력 다변량 시계열(X)에 대한 모델의 예측값은 각각의 attention weight와 임베딩을 활용하여 <식 2.29>와 같이 표현할 수 있다.

$$w(y, x_{t,d}) = \alpha_t W_{FC}(\beta_t \odot W_{emb}[:, d]) x_{t,d} \qquad \text{<식 2.29>}$$

이때 $x_{t,d}$는 t 시점에 대한 입력 벡터 x_t를 의미한다. 따라서 기여도(w)는 시점별로 구분할 수 있으며, 이는 관측치(y)에 대응되는 예측값($\hat{y}$)에 대한 입력변수의 시점별 기여도를 의미한다. RETAIN 모델은 별도의 사후 분석 기법의 적용 없이 입력변수의 국소적 해석, 전역적 해석에 더해 시점별 해석이 가능하다. 그러나 입력변수의 설명럭 분석을 위해서는 위해서는 시퀀스 데이터(녹조·수질 예측의 경우 시계열 데이터)의 형태로 입력자료를 가공, 녹조예측을 위한 RETAIN을 최적화 과정이 요구된다.

2.2 XAI 기술 활용방안

본 절에서는 녹조·수질예측에 대한 XAI 적용사례(Section 2.2.1), 녹조·수질 영향인자 검정을 위한 XAI 적용방안(안)(Section 2.2.2), 그리고 녹조·수질예측 대상 XAI 적용 예시 코드(Section 2.2.3)을 제시한다.

2.2.1 녹조·수질예측 대상 XAI 적용 사례

최근 녹조·수질예측을 대상으로 XAI를 적용한 선행연구에서는 대부분 SHAP을 활용하여 예측결과에 대한 설명력 확보를 도모했다. 일부 센서 모니터링 데이터(조류 색소 농도 등) 등을 활용한 사례에서는 attention mechanism 등의 적용을 통해 해석가능한 딥러닝 모델의 개발을 도모했다.

1) 녹조·수질예측 대상 SHAP 적용 사례

Jeong et al. (2022)은 국내 상수원 대상으로 일주 후 조류경보발령 단계를 예측하는 데 결정나무 기반 ML 모델(XGBoost 및 Random forest)을 적용한 바 있다. 해당 연구에서는 SHAP을 활용하여 예측결과에 대한 입력변수 중요도 분석을 수행했다<그림 2.12>.

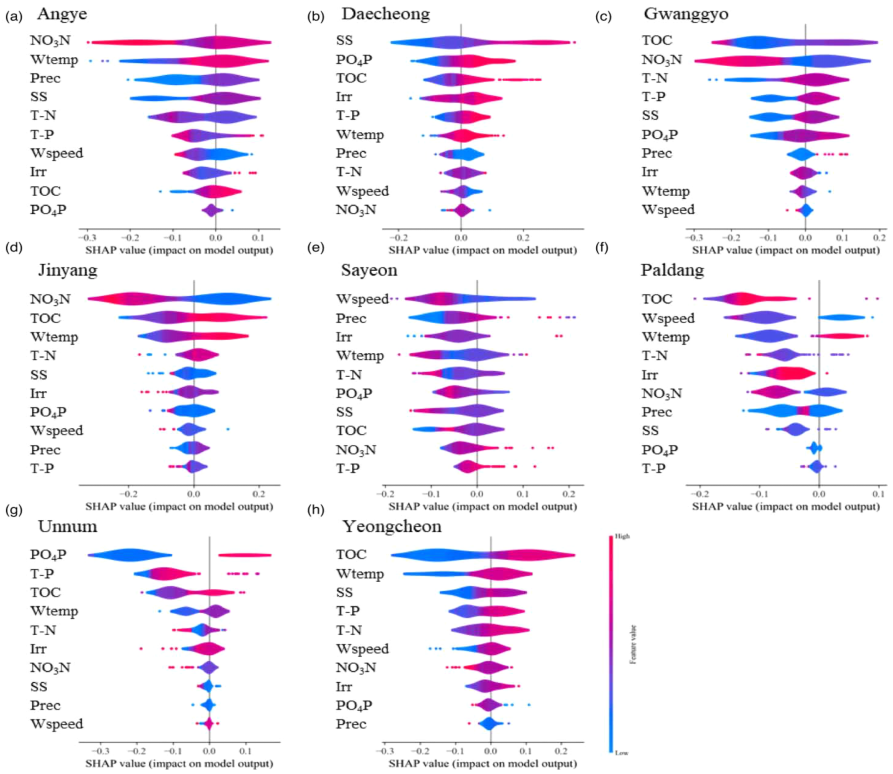

<그림 2.12> 국내 상수원 호소 녹조 발생에 대한 SHAP 적용 결과 (Jeong et al., 2022)

Lee et al. (2022) 전국 조류 모니터링 지점(조류경보제 및 관찰지점)을 대상으로 CNN (Convolutional neural network) 기반 다지점 동시 chlorophyll-a 예측 모델을 개발하였으며, 모델의 성능평가에 더해 DeepSHAP을 활용한 변수 중요도 결과를 제시한 바 있다.

Park et al. (2022)은 XGBoost를 활용하여 대청호 내 수질측정망 지점의 chlorophyll-a 예측 모델을 개발하였으며, SHAP을 통해 변수 중요도를 제시한 바 있다. 해당 연구에서는 모델 개발 과정에서 변수 중요도를 정량화하는 SHAP, feature importance와 변수 선택 시 다중공선성을 고려할 수 있는 variance inflation factor (VIF)를 활용하여 각각 변수 선택을 진행, 예측 성능을 비교했다. 결과적으로 SHAP을 통해 선택한 입력변수 조합이 가장 안정적인 예측 정확도를 제공함을 보고했다<그림 2.13>.

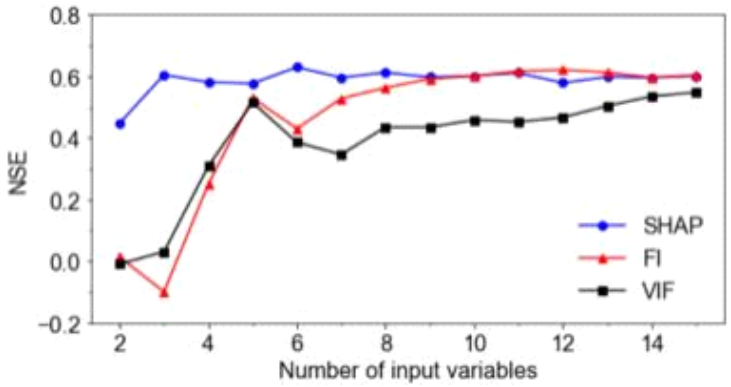

<그림 2.13> 변수 선택 방법에 따른 예측 정확도 변화 (Park et al., 2022)

Han et al. (2024)은 남한강을 대상으로 XGBoost 모델을 개발하였으며, SHAP을 활용하여 예측결과에 대한 입력변수의 설명력을 분석했다. 특히 해당 연구에서는 입력변수의 상호작용 효과 및 주 영향 등을 함께 분석하였으며, 이를 통해 chlorophyll-a 예측에 대한 입력변수의 중요도를 다각적인 검토했다<그림 2.14>.

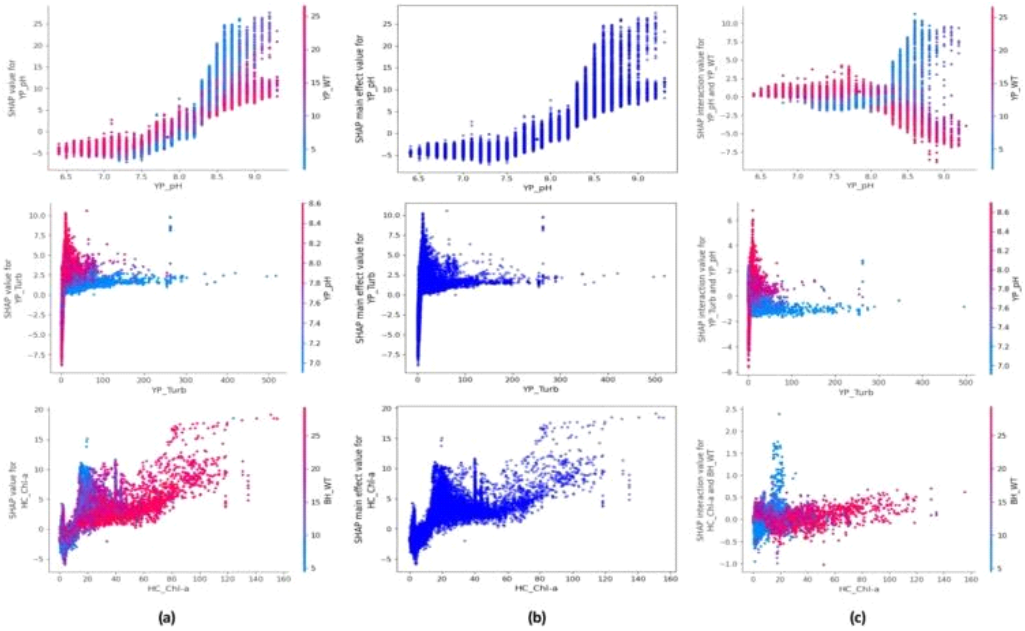

<그림 2.14> Chlorophyll-a 예측 결과에 대한 SHAP 적용 결과 (Han et al., 2024)

Shin et al. (2024)은 다변량 데이터의 활용 효율성 향상을 위해 계층구조의 딥러닝 모델인 hierarchical concatenated variational autoencoder (HCVAE) 개발했으며<그림 2.15>, SHAP을 통해 각 계층별 해석결과를 제공했다.

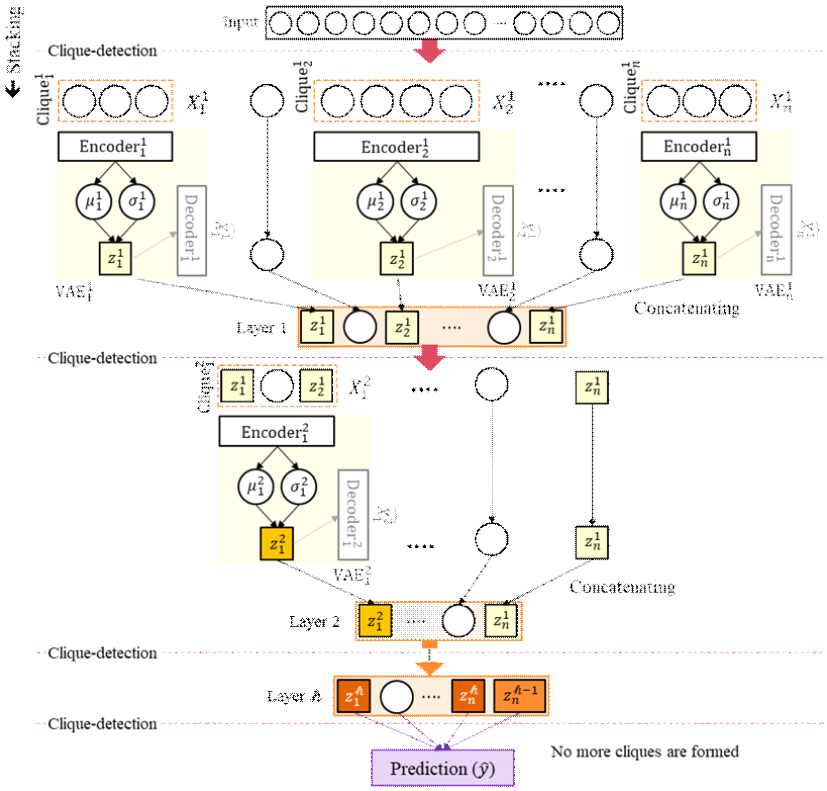

<그림 2.15> HCVAE 모델의 구조 (Shin et al., 2024)

해당 연구에서 개발된 HCVAE는 유사한 특성을 지닌 입력변수를 그룹화하고 이를 순차적으로 적층하여 개별 입력변수에 더해 각 그룹별로 설명력을 제공할 수 있는 구조를 지녀 SHAP의 적용을 통해 주요 변수 그룹의 식별, 나아가 각 그룹별 중요 변수의 식별을 수행했다 <그림 2.16>.

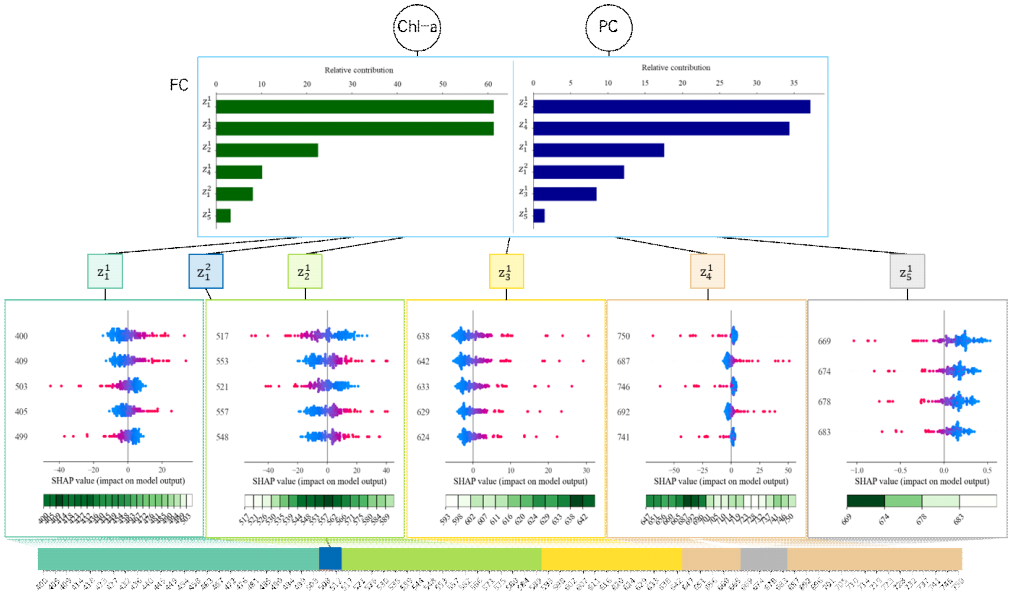

<그림 2.16> SHAP을 활용한 계층별 해석 결과 (Shin et al., 2024)

2) 녹조·수질예측 대상 해석가능한 딥러닝 개발 사례

Kwon et al. (2023)은 대청호에서 IoT 모니터링을 기반으로 수집된 수질항목을 입력변수로 활용하여 chlorophyll-a와 유해남조류의 고유 색소 물질인 phycocyanin을 예측하는 데 있어 어텐션 기반 LSTM을 활용했다. 해당 연구에서는 기존 LSTM보다 어텐션 기반 LSTM의 향상된 성능을 보고했다. 추가적으로 모델로부터 얻어진 어텐션 가중치를 활용하여 예측에 있어 입력자료의 시점(Time step) 간 상대적 중요도를 제시했다<그림 2.17>.

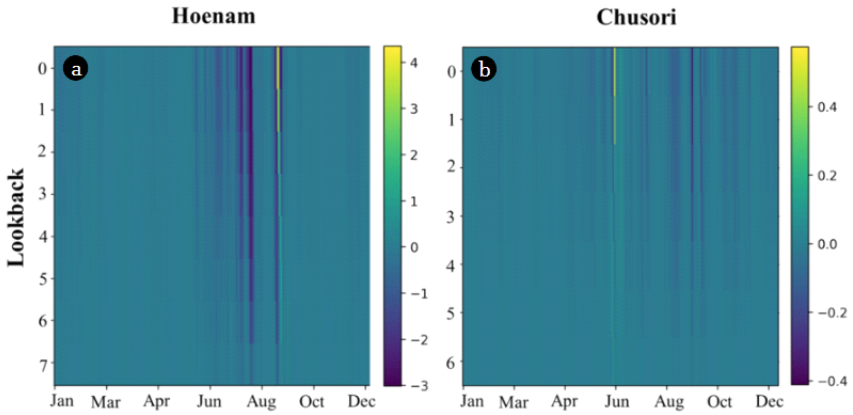

<그림 2.17> 시점에 대한 attention score 매핑 결과 (Kwon et al., 2023)

Kim et al. (2022) 및 Kim et al. (2023)은 조류 모니터링 데이터의 불충분한 시간해상도를

개선함과 동시에 해석이 가능한 RETAIN-Hybrid 모델을 개발했다. RETAIN-Hybrid는 시간해상도의 향상을 위한 feature engineering module을 모델 전반에 배치함으로써 입력변수 중 가장 고빈도로 측정되는 항목의 시간해상도에 맞춰 완전 시계열을 생성하며, 후단의 RETAIN 구조를 활용하여 녹조 예측 결과에 대한 입력변수의 변수별, 시점별 설명 결과를 제공 가능하다. 이때 향상된 시간해상도로 예측이 이루어지므로 설명 결과 또한 향상된 시간해상도로 제공 시행했다<그림 2.18>.

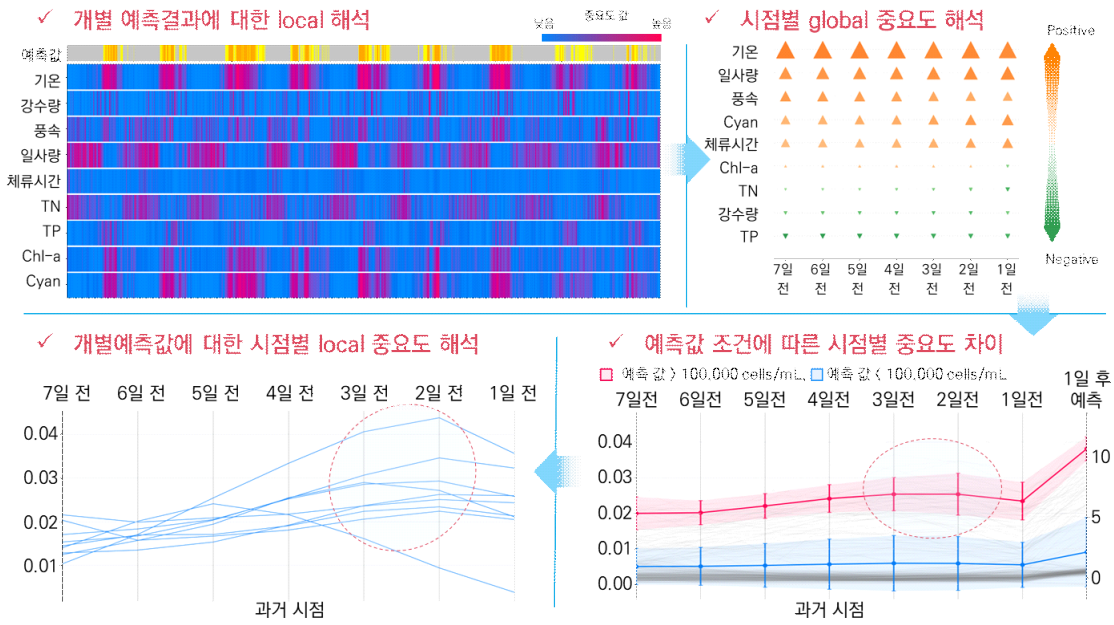

<그림 2.18> RETAIN-Hybrid 모델의 설명 결과 (Kim et al., 2022; 2023)

Shin et al. (2024)는 물환경 네트워크의 상·하류 연계성을 반영할 수 있는 feature stream network를 개발했다. 해당 모델은 네트워크 구조를 지니고 있으며, 물환경 측정망 지점을 노드, 지점 간의 연결성을 엣지(edge)로 표현한다. 이때 지점 간 모니터링 체계의 차이를 극복하기 위해 각 노드로부터 동일한 차원을 지닌 잠재변수를 추출하여 네트워크 구조로 전달한다. 해당 연구에서는 잠재변수 추출을 위한 모듈로써 RETAIN을 활용했다<그림 2.19>.

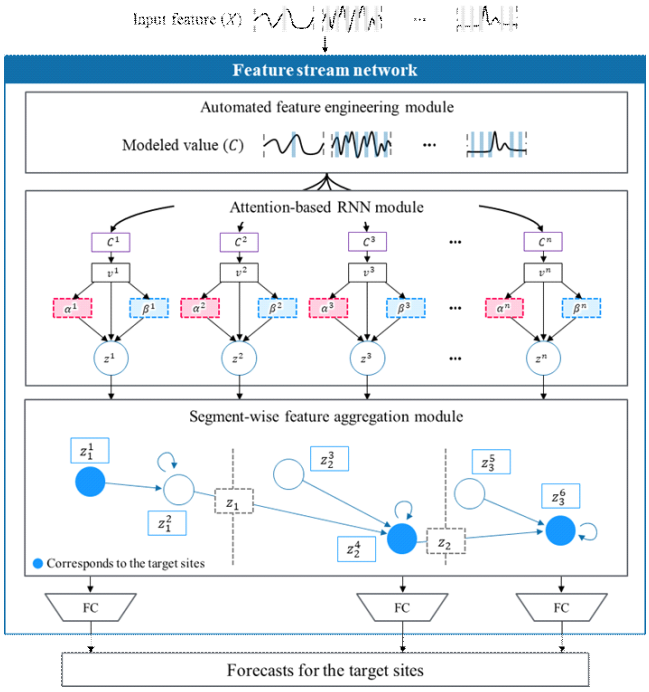

<그림 2.19> Feature stream network 구조 (Shin et al., 2024)

결과적으로 개발된 모델은 다수 모니터링 지점에 대한 유해남조류 세포 수 동시 예보가 가능하며, RETAIN의 변수 및 시점별 attention weight와 네트워크를 구성하는 공간 단계의 attention weight를 종합하여 각 예보 결과에 대해 지점 간의 연계성이 반영된 설명 결과를 제공 가능하다<그림 2.20>.

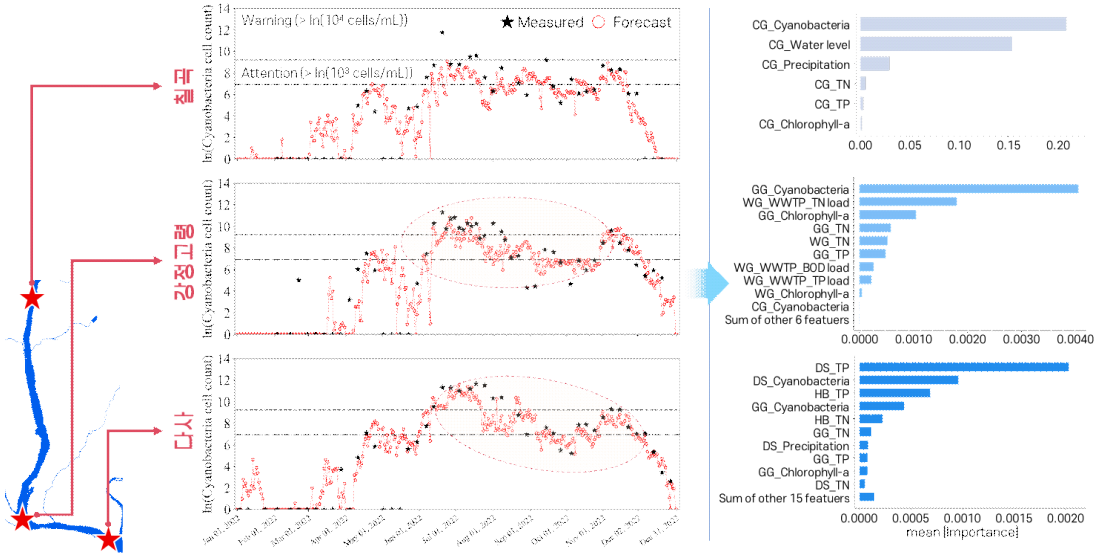

<그림 2.20> Feature stream network 모델의 설명 결과 (Shin et al., 2024)

2.2.2 녹조·수질 영향인자 검정을 위한 XAI 적용방안(안)

본 자문 대상 연구의 경우 녹조·수질 예측을 위한 표준 AI 모델의 개발을 목적으로 하므로, model-agnostic 방법론의 활용이 효과적일 것으로 판단된다. 앞서 검토된 model-agnostic 방법론 중 다중공선성 문제를 회피할 수 있으며, 선행연구 결과를 통해 주요 환경인자 선택에도 높은 잠재력을 보이는 SHAP의 활용을 제안하고자 한다.

SHAP은 사후설명 기법이므로 구축된 입력자료에 대한 AI 알고리즘의 적합(최적화)을 선행한 뒤, 최적화된 모델에 대해 SHAP value를 산정함으로써 예측대상에 대한 입력변수의 설명력을 다각도로 분석 가능하다<그림 2.21>. 예측대상에 대한 입력변수의 전역적인 기여도의 크기 및 방향은 녹조현상 및 수질 이상에 대한 영향인자의 전반적인 설명력을 반영할 수 있으며, 이는 최종 모델 개발을 위한 입력변수 선택, 관리가 요구되는 주요 영향인자의 선정, 게다가 이는 모델의 신뢰도(credibility)를 검토하는 데도 활용 가능하다. 더 나아가 입력변수의 상호작용 효과를 산정함으로써 상호연관성의 정도를 정량화할 수 있고, 주 영향을 통해 다중공선성의 문제를 최소화할 수 있으므로 개별 영향인자의 설명력을 심층적으로 분석 가능할 것으로 판단된다.

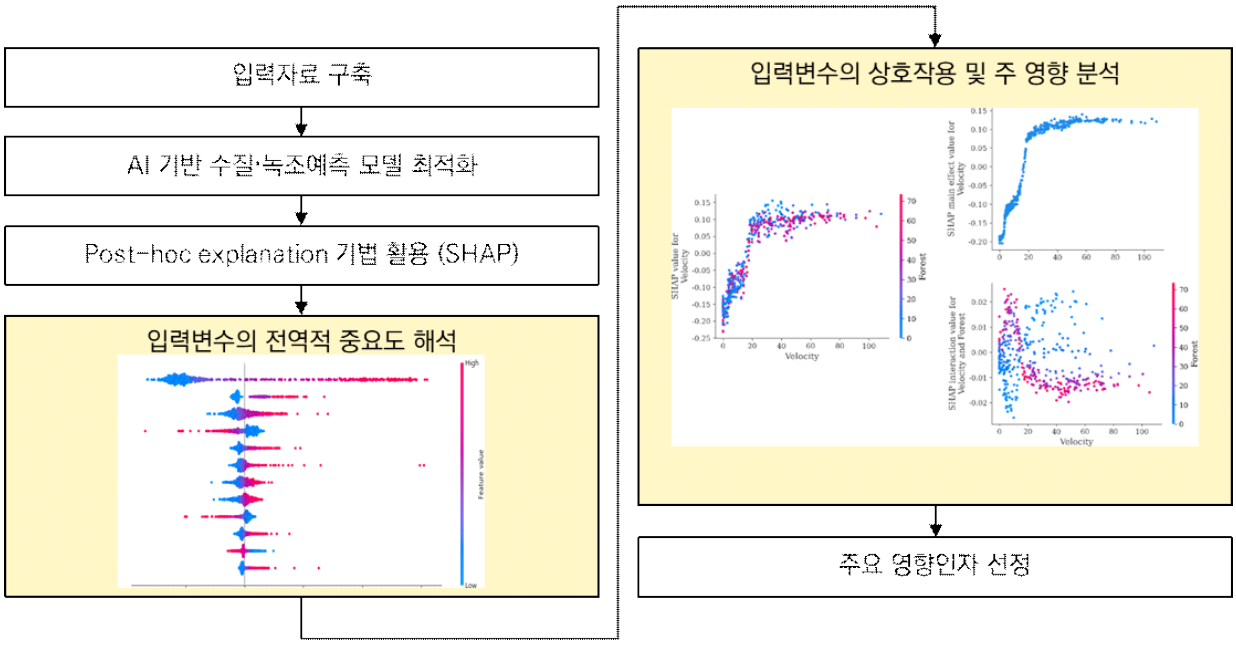

<그림 2.21> 녹조·수질 영향인자 검정을 위한 XAI 적용절차(안)

향후 AI 모델 고도화 시에는 가용 데이터 및 현장 적용성 등을 고려하여 예측 정확도와 함께 해석력을 향상시킬 수 있는 맞춤형 AI 구조를 개발하고 사용자의 접근성을 고려하여 이를 시스템화할 필요가 있을 것으로 판단된다.

2.2.3 녹조·수질예측 대상 XAI 적용 예시 코드

녹조·수질예측에 대한 SHAP 적용을 위한 예시 코드를 제시한다. 예시 코드는 크게 라이브러리 호출, AI 모델 학습, SHAP value 및 SHAP interaction value 산정, 시각화로 구성했다. 이때 예시 코드는 재현성 등을 고려하여 Google Colab을 활용해 python 언어로 작성했다.

1) 라이브러리 호출

본 예시 코드에서 활용된 주요 라이브러리 정보는 <표 2.2>와 같다.

```
import shap
import numpy as np
import pandas as pd

from sklearn.ensemble import RandomForestRegressor
from xgboost import XGBRegressor

from sklearn.model_selection import RandomizedSearchCV
```

<표 2.2> 예시 코드 내 주요 라이브러리 정보

라이브러리 명	버전	설명
shap	0.46.0	• SHAP 구현 및 적용을 위한 라이브러리
sklearn	1.5.2	• 기계학습 모델 구현 및 개발을 위한 라이브러리
xgboost	2.1.2	• XGBoost 모델 구현 및 개발을 위한 라이브러리
pandas	2.2.2	• 데이터 분석, 가공 등을 위한 라이브러리
numpy	1.26.4	• 다차원 데이터 분석, 가공 등을 위한 라이브러리

2) AI 모델 최적화

예시 코드의 입력자료는 8766개 샘플(24년 1일 단위), 40개 설명변수로 구성하였으며, 향후 실 모니터링 데이터 활용 시 아래 코드의 sample_data를 수정함으로써 후단의 코드를 구동 가능하다. 본 샘플 코드에서는 random forest와 XGBoost 모델을 활용했다. 이때 모델의 하이퍼

파라미터 최적화는 random search를 통해 수행했으며, 반복 수는 10회, 그리고 손실함수는 MSE(mean squared error) 값을 활용했다.

```
## Data split
sample_x, sample_y = sample_data.iloc[:, :-1], sample_data.iloc[:, -1]

## Model hyperparameter optimization
iters = 10
score_fun = "neg_mean_squared_error"

## Random Forest
RF_model = RandomForestRegressor(random_state = 42)
RF_grid = {'n_estimators': np.arange(100, 500, 10),
           'max_depth': np.arange(5, 15, 1),
           'min_samples_split': np.arange(2, 6, 1),
           'min_samples_leaf': np.arange(1, 6, 1)
}

RF_search = RandomizedSearchCV(RF_model,
                               RF_grid,
                               n_iter = iters,
                               scoring = score_fun
                               )

RF_opt_ = RF_search.fit(sample_x, sample_y)

## XGBoost
XGB_model = XGBRegressor(random_state = 42)

XGB_grid = {'n_estimators': np.arange(100, 500, 10),
            'max_depth': np.arange(5, 15, 1),
            'min_child_weight': np.arange(1, 10, 1),
            'gamma': np.arange(0.1, 3, 0.05),
            'learning_rate': np.arange(0.05, 0.3, 0.05),
            'colsample_bytree': np.arange(0.6, 0.9, 0.05)
}

XGB_search = RandomizedSearchCV(XGB_model,
                                XGB_grid,
                                n_iter = iters,
                                scoring = score_fun
                                )

XGB_opt_ = XGB_search.fit(sample_x, sample_y)
```

3) SHAP value 및 SHAP interaction value 산정

SHAP value 및 SHAP interaction value의 산정은 TreeSHAP을 활용하여 수행했다. 이때 산정을 위한 입력데이터인 sample_x를 학습 혹은 테스트 데이터 등으로 수정함으로써 SHAP value 산정을 위한 샘플을 조정할 수 있다. 본 예시에서는 별도의 테스트 데이터 없이 학습 데이터를 대상으로 SHAP을 적용했다.

```
## Random Forest
RF_shap_explainer = shap.TreeExplainer(RF_opt_.best_estimator_)
RF_shap_value = RF_shap_explainer.shap_values(sample_x)
RF_int_values = RF_shap_explainer.shap_interaction_values(sample_x)

## XGBoost
XGB_shap_explainer = shap.TreeExplainer(XGB_opt_.best_estimator_)
XGB_shap_value = XGB_shap_explainer.shap_values(sample_x)
XGB_int_values = XGB_shap_explainer.shap_interaction_values(sample_x)
```

4) 시각화

산정된 SHAP value 및 SHAP interaction value에 대한 시각화 코드는 아래와 같으며, 전역적 설명결과를 도시하는 SHAP summary plot, 입력변수 값 변화에 따른 SHAP value의 변화를 도시하는 SHAP dependence plot, 각각 상호작용과 주 영향을 도시하는 SHAP interaction plot과 SHAP main effect plot에 대한 코드를 포함한다.

```
## Random forest
## SHAP summary plot
shap.summary_plot(RF_shap_value, sample_x,  max_display= sample_x.shape[1])

## SHAP dependence plot
shap.dependence_plot('X1', RF_shap_value, sample_x, interaction_index = 1,
display_features = sample_x)

## SHAP interaction plot
shap.dependence_plot(('X1', 'X2'), RF_int_values, sample_x, display_features =
sample_x)

## SHAP main effect plot
shap.dependence_plot(('X1', 'X1'), RF_int_values, sample_x, display_features =
sample_x)


## XGBoost
## SHAP summary plot
```

```
shap.summary_plot(XGB_shap_value, sample_x,  max_display= sample_x.shape[1])

## SHAP dependence plot
shap.dependence_plot('X1', XGB_shap_value, sample_x, interaction_index = 1,
display_features = sample_x)

## SHAP interaction plot
shap.dependence_plot(('X1', 'X2'), XGB_int_values, sample_x, display_features =
sample_x)

## SHAP main effect plot
shap.dependence_plot(('X1', 'X1'), XGB_int_values, sample_x, display_features =
sample_x)
```

5) SHAP value 시각화 방법론

① SHAP summary plot

SHAP summary plot은 모델의 전반적인 예측결과에 대한 모든 입력변수별 전역적인 기여도(SHAP value)의 크기 및 방향을 나타낸다<그림 2.22a>. 이때 도표의 x축은 입력변수별 기여도의 크기를 나타내며 음수(-)인 경우 예측값을 감소시키는 방향, 양수(+)인 경우 예측값을 증가시키는 방향으로 모델의 예측결과에 기여한다. 도표를 이루는 각 점의 색상은 해당 입력변수의 크기를 나타내며, 파란색에서 붉은색으로 갈수록 변수 값이 큼을 의미한다. 추가로 y축의 각 입력변수는 상대적 기여도 순위에 따라 내림차순으로 제시된다.

② SHAP dependence plot

SHAP dependence plot은 기존의 PDP와 유사한 역할을 수행하며, 특정 입력변수 값(코드상 'X1')의 변화에 따른 해당 변수의 연속적인 기여도 변화를 나타낸다<그림 2.23b>. 이때 도표 내 각 점은 개별 샘플을 의미하며, 점의 색상은 해당 변수 외 타 변수(코드상 interaction_index = 1이므로, 변수 'X2')의 크기를 의미한다. 즉 점의 색상을 통해 서로 다른 두 변수 간의 상호작용을 개략적으로 파악할 수 있다.

③ SHAP interaction plot

SHAP interaction plot은 서로 다른 두 변수('X1', 'X2') 간의 정량화된 상호작용 효과를 나타낸다<그림 2.23c>. 이때 점의 색상은 분석 상호작용 효과 산정 대상 입력변수('X2')의 크기를 나타낸다. 이를 통해 분석 대상 변수('X1')와 타 변수('X2') 값의 변화에 따른 상호작용 효과의 크기 및 방향을 파악할 수 있다.

④ SHAP main effect plot

SHAP main effect plot은 분석 대상 변수('X1')에 대한 모든 상호작용 효과를 제거한 해당 변수만의 주 영향을 나타낸다<그림 2.22d>. 이를 통해 다중공선성의 영향을 최소화하면서도 특

정 입력변수의 기여도를 크기 및 방향의 측면에서 정량적으로 파악할 수 있다.

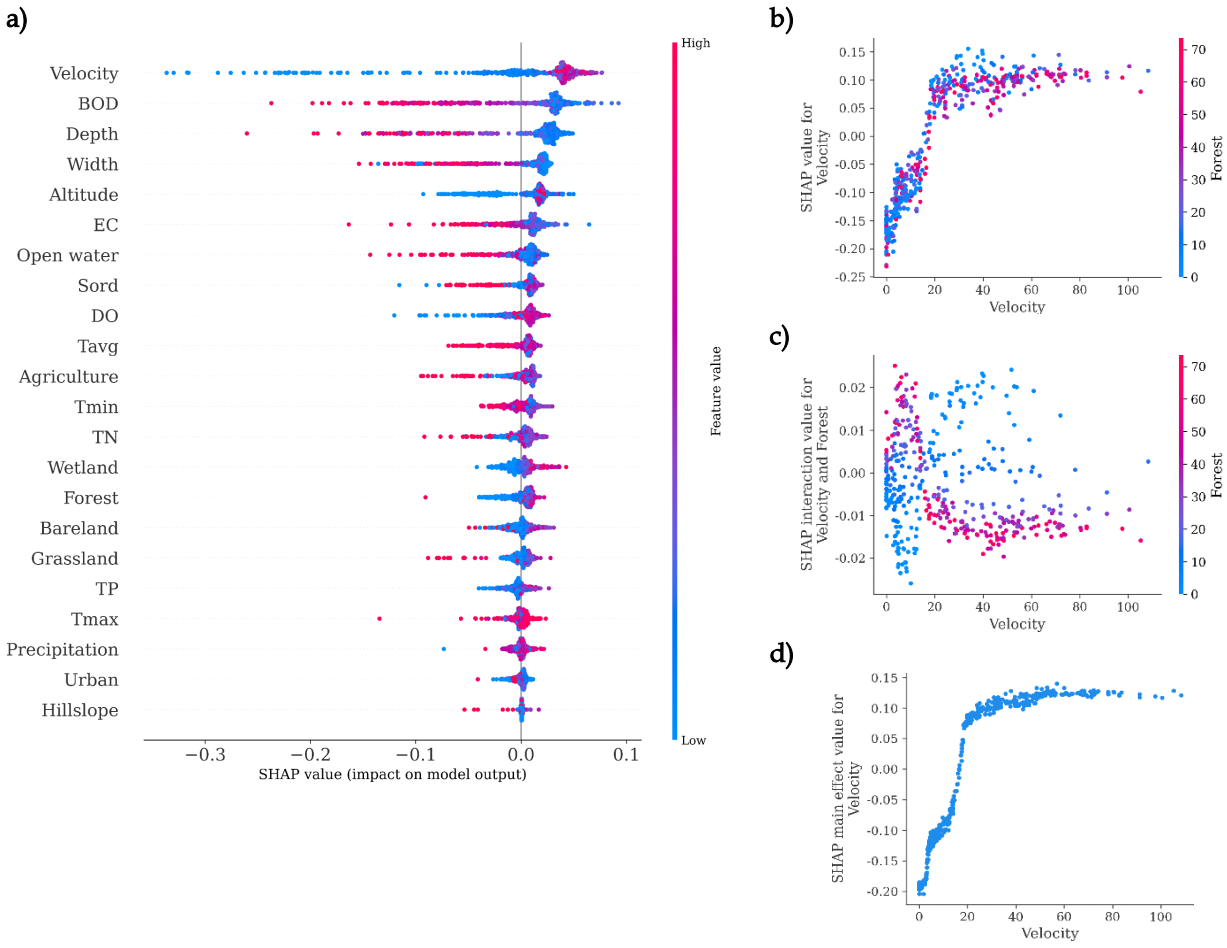

<그림 2.22> SHAP value의 시각화 방안, a) summary plot, b) dependence plot, c) interaction plot, d) main effect plot (Cha et al., 2021)

참고문헌

- 차윤경, 신지훈, 김영우. (2020). 자료기반 물환경모델의 현황 및 발전 방향. 한국물환경학회지, 36(6), 611-620.
- Ali, S., Abuhmed, T., El-Sappagh, S., Muhammad, K., Alonso-Moral, J. M., Confalonieri, R., ... & Herrera, F. (2023). Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. Information fusion, 99, 101805.
- Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., ... & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. Information fusion, 58, 82-115.
- Cha, Y., Shin, J., Go, B., Lee, D. S., Kim, Y., Kim, T., & Park, Y. S. (2021). An interpretable machine learning method for supporting ecosystem management: Application to species distribution models of freshwater macroinvertebrates. Journal of Environmental Management, 291, 112719.
- Cho, K., Van Merrienboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv preprint arXiv:1406.1078.
- Choi, E., Bahadori, M. T., Sun, J., Kulas, J., Schuetz, A., & Stewart, W. (2016). Retain: An interpretable predictive model for healthcare using reverse time attention mechanism. Advances in neural information processing systems, 29.
- Elith, J., Leathwick, J. R., & Hastie, T. (2008). A working guide to boosted regression trees. Journal of animal ecology, 77(4), 802-813.
- Han, J. W., Kim, T., Lee, S., Kang, T., & Im, J. K. (2024). Machine learning and explainable AI for chlorophyll-a prediction in Namhan River Watershed, South Korea. Ecological Indicators, 166, 112361.
- Jeong, B., Chapeta, M. R., Kim, M., Kim, J., Shin, J., & Cha, Y. (2022). Machine learning-based prediction of harmful algal blooms in water supply reservoirs. Water Quality Research Journal, 57(4), 304-318.
- Kim, T., Shin, J., & Cha, Y. (2023). Incorporation of feature engineering and attention mechanisms into deep learning models to develop an early warning system for harmful algal blooms. Journal of Cleaner Production, 414, 137564.
- Kim, T., Shin, J., Lee, D., Kim, Y., Na, E., Park, J. H., ... & Cha, Y. (2022). Simultaneous feature engineering and interpretation: Forecasting harmful algal blooms using a deep learning approach. Water Research, 215, 118289.
- Kim, Y. W., Kim, T., Shin, J., Go, B., Lee, M., Lee, J., ... & Cha, Y. (2021). Forecasting

abrupt depletion of dissolved oxygen in urban streams using discontinuously measured hourly time series data. Water Resources Research, 57(4), e2020WR029188.

- Kwon, D. H., Hong, S. M., Abbas, A., Pyo, J., Lee, H. K., Baek, S. S., & Cho, K. H. (2023). Inland harmful algal blooms (HABs) modeling using internet of things (IoT) system and deep learning. Environmental Engineering Research, 28(1).
- Lee, D., Kim, M., Lee, B., Chae, S., Kwon, S., & Kang, S. (2022). Integrated explainable deep learning prediction of harmful algal blooms. Technological Forecasting and Social Change, 185, 122046.
- Lundberg, S. (2017). A unified approach to interpreting model predictions. arXiv preprint arXiv:1705.07874.
- Lundberg, S. M., Erion, G. G., & Lee, S. I. (2018). Consistent individualized feature attribution for tree ensembles. arXiv preprint arXiv:1802.03888.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., ... & Lee, S. I. (2020). From local explanations to global understanding with explainable AI for trees. Nature machine intelligence, 2(1), 56-67.
- Molnar, C. (2020). Interpretable machine learning. Lulu. com.
- Niu, Z., Zhong, G., & Yu, H. (2021). A review on the attention mechanism of deep learning. Neurocomputing, 452, 48-62.
- Park, J., Lee, W. H., Kim, K. T., Park, C. Y., Lee, S., & Heo, T. Y. (2022). Interpretation of ensemble learning to predict water quality using explainable artificial intelligence. Science of the Total Environment, 832, 155070.
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). Model-agnostic interpretability of machine learning. arXiv preprint arXiv:1606.05386.
- Rousso, B. Z., Bertone, E., Stewart, R., & Hamilton, D. P. (2020). A systematic literature review of forecasting and predictive models for cyanobacteria blooms in freshwater lakes. Water Research, 182, 115959.
- Shin, J., & Cha, Y. (2024). Development of a deep learning‐based feature stream network for forecasting riverine harmful algal blooms from a network perspective. Water Research, 122751.
- Shin, J., Lee, G., Kim, T., Cho, K. H., Hong, S. M., Kwon, D. H., ... & Cha, Y. (2024). Deep learning-based efficient drone-borne sensing of cyanobacterial blooms using a clique-based feature extraction approach. Science of The Total Environment, 912, 169540.
- Wai, K. P., Chia, M. Y., Koo, C. H., Huang, Y. F., & Chong, W. C. (2022). Applications of deep learning in water quality management: A state-of-the-art review. Journal of Hydrology, 128332.

작성자: ㈜지오시스템리서치 송용식 부사장

제 1 장 녹조 예측 문제에서 영향변수 간 데이터 불균형에 따른 문제점, 대표적 사례 및 해소방안

1.1 기존 사례 개요

1.1.1 사업명

- 기작 및 자료 기반 통합 수질(조류) 예측 체계 개발(국립환경과학원, 2023)
- 과업 수행 기간 : 2022.07.20. ~ 2023.04.16.

1.1.2 수행배경 및 목적

기존 기작 기반 예측모델은 높은 정확도를 보이지만 다량의 입력 자료와 긴 계산 시간으로 실시간 운용에 제약이 있어 인공지능 모델을 구축하고 병행 운용을 검토하였다. 국립환경과학원이 축적한 데이터를 기반으로 딥-러닝 알고리즘을 적용한 모델을 개발하고 조류 대발생 예측 정확도 및 효율성을 개선하는 것이 이 연구의 목표이다.

<표 1.1> 녹조예측을 위한 기작 기반 모델과 자료 기반 모델 비교

항목	기작 기반	자료 기반
장점	유체역학 모델과 연계	제공 데이터로 예측 결과 직접 생산
	조건별 미래의 조류예측 역학적 계산	다양한 기술 적용
	공간적인 예측 가능	상대적으로 적은 입력 데이터 필요
	생태학·생화학·물리학 원리, 이론 및 경험적 지식 정량화	빠른 계산 시간
	개선 및 업데이트 활발, 개발자의 유지보수 제공 활성화	-
단점	많은 입력데이터 필요	기본 프로세스 미 고려
	느린 계산시간	검증영역 외부조건에서 사용이 어려움

1.2 모델 개발

1.2.1 데이터 수집 및 전처리

1) 변수구성

<표 1.2>에 인공지능 예측모델 입력 변수를 제시하였다. 그리고 사용된 자료의 종류와 예측 대상은 변수는 아래와 같다.

- 사용자료 : 2012.01.01. ~ 2022.12.31. 기간 낙동강 보 및 상수원 8개 지점 데이터
- 예측대상 : 유해남조류 세포수 (Microcystis, Anabaena, Aphanizomenon, Oscillatoria 속의 세포수 합)

<표 1.2> 인공지능 예측모델 독립변수

구 분	변수 구성	데이터 수집
기상 자료	평균기온, 최저기온, 최고기온, 일강수량, 최대풍속	기상자료개방포털 (data.kma.go.kr)
수문 자료	수위, 유량, 보 방류량/유입량, 저수량, 저수위	WAMIS (wamis.go.kr)
수질 자료	수온, 용존산소(DO), 총유기탄소(TOC), 클로로필-a, 유해 남조류 세포수	물환경정보시스템 (water.nier.go.kr)

2) 데이터 전처리

인공지능 모델을 구축을 위한 가용 유해남조류 세포수 자료는 지점별 153~584회로 매우 적다. 따라서 언더피팅 방지를 위해 지점 데이터를 통합하여 단일 학습 세트 생성하였다. 그리고 결측치를 <표 1.3>과 같이 처리하였다. 주 단위 자료(세포수 제외)는 일 단위로 보간(Interpolation) 변환 후 입력하였다. 변수 간 단위 차이를 제거하기 위해 표준화(Standardization)를 적용하였다.

<표 1.3> 녹조 인공지능 예측모델 입력자료 전처리

데이터 구분(시간)	방 법
주 단위 자료	연속 2주 미만 결측 시 보간, 2주 이상 결측 시 제거
일 단위 자료	결측률 30% 이상 변수는 제거, 그 미만은 보간

1.2.2 모델 입력·출력 구성 및 설계

1) 데이터 셋 구성

녹조예측 인공지능 모델의 입력자료, 종속변수 그리고 학습구성 내용을 <표 1.4>에 제시하였다.

<표 1.4> 녹조 인공지능 예측모델 구성

구분	내용
입력 데이터	유해 남조류 세포수 관측일 기준 1일 전 ~ 7일 전(총 7일)의 다변량 시계열 . 각 보별 최근접 정점 기온, 일강수량, 최대풍속, 수위, 유량, 보 방류량·유입량, 저수량, 저수위, 수온, DO, Chl-*a*
종속변수	해당 관측일의 (+1일) 유해 남조류 세포수 (모델은 +1일 예측 구조로 설계됨)
학습 구성	여러 지점 데이터를 통합하여 단일 학습 세트 생성. row shuffling 적용 > 학습/검증 세트에 지점별 데이터가 고르게 학습 되도록 구성

2) 모델 설계

녹조예측을 위하여 Attention-LSTM 알고리즘을 사용하였다. Attention 메커니즘을 적용하여 특정 시점의 환경 변화가 전체 조류 번성에 미치는 영향 강화하였다. Attention 알고리즘은 자연어 처리 분야에서 개발되었다(Vaswani et al., 2017). 서로 멀리 떨어진 입력 요소 간 상호작용을 고려한 구조로 기존 RNN-LSTM 대비 장기 의존성(Long-term dependency) 문제를 해결할 수 있다.

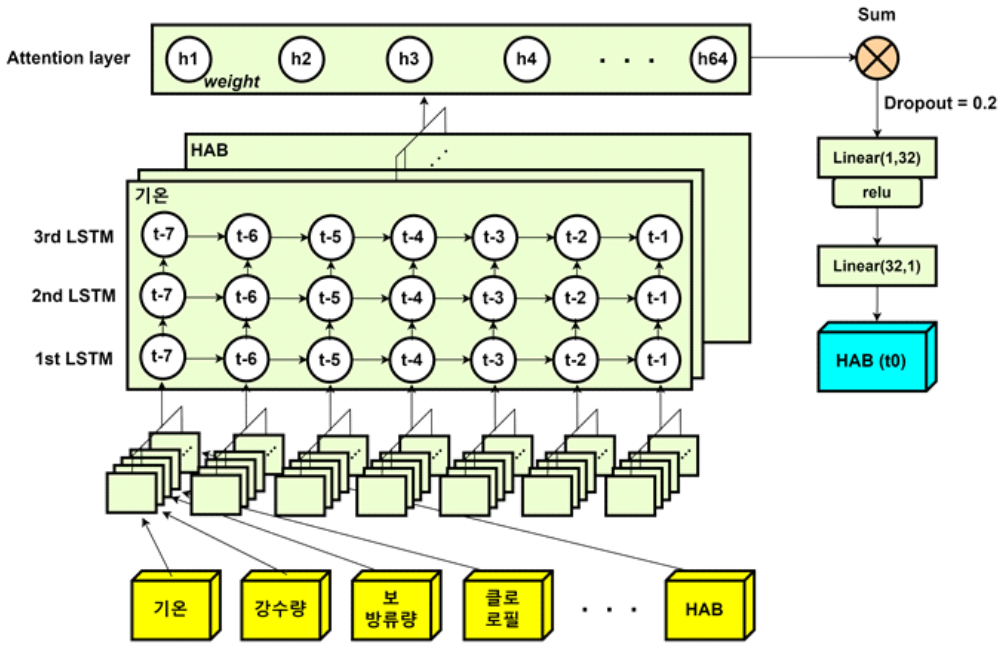

<그림 1.1> 녹조예측을 위한 인공지능 모델 구조.

1.3 재현 결과

모델 검증기간인 2019.01.01 ~ 2021.12.31 동안의 유해남조류 세포수 재현결과를 <그림 1.2>에 제시하였다. 그리고 결정계수, 평균제곱근오차, 코사인유사도를 <표 1.5>에 제시하였다.

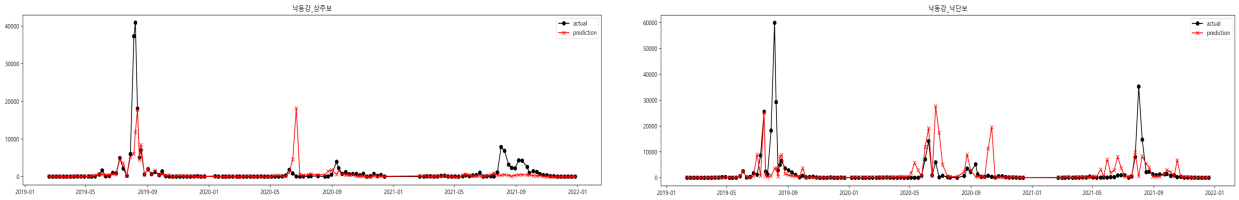

상주보 낙단보

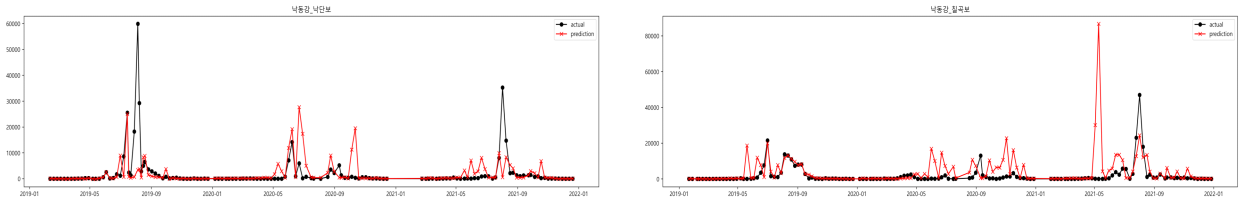

구미보 칠곡보

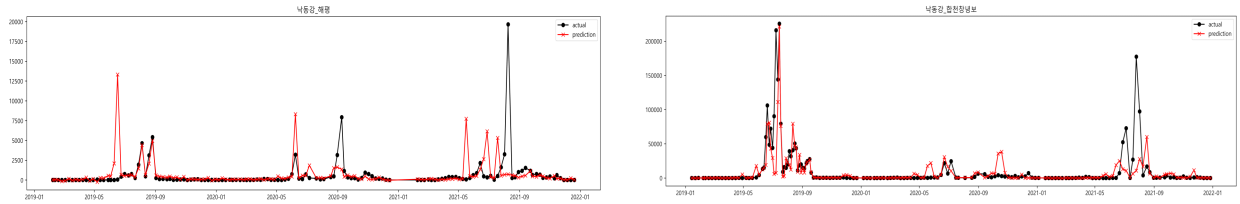

해평 합천창녕보

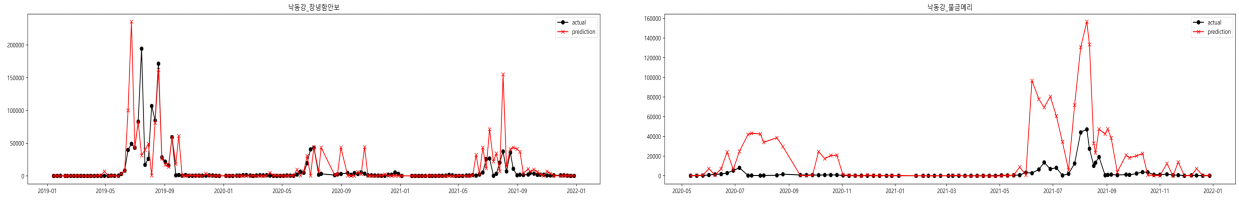

창녕함안보 물금매리

<그림 1.2> 녹조 인공지능 예측모델 재현 결과.

<표 1.5> 녹조 인공지능 예측모델 검증 결과

알고리즘	지점	단위 : log cells/mL		
		R^2	RMSE	Cosine Similarity
AttentionLSTM	상주보	0.77	3.59	0.82
	낙단보	0.19	16.66	0.92
	구미보	0.41	8.12	0.84
	칠곡보	0.71	1.30	0.89
	해평	0.27	13.62	0.83
	합천창녕보	0.78	14.52	0.88
	창녕함안보	0.33	9.14	0.83
	물금매리	0.16	8.10	0.91

1.4 한계점

1.4.1 관측소별 데이터 부족 문제

유해 남조류 세포수 자료는 주간 단위로 수집되며, 지점별로 최소 150여 회에서 최대 500여 회 수준에 불과하여, 관측소 단독 학습으로는 충분한 데이터 확보가 어렵다. 이로 인해 각 보·지점별 맞춤형 모델을 구축하기 어렵고, 데이터 희소성에 따른 언더피팅(underfitting) 문제가 발생하였다.

1.4.2 전국 표준화 모델 구축의 한계

데이터 부족을 보완하기 위해, 전국 관측소 데이터를 통합하고 주변 최근접 자료를 활용하여 표준화된 단일 모델을 개발하였다. 그러나 이러한 접근은 지점별 고유 특성(지형적 조건, 하천 폭·수심, 체류시간, 보 운영방식 등)을 반영하지 못하였다. 특히 동일한 입력 변수(강수·유량·수온 등)라도 하천형상·유역특성에 따라 반응 메커니즘이 다르지만 일반화 모델의 경우 반영하지 못한 문제점이 있다. 일례로, f(x)=ax+1 는 강우량에 따른 남조류 세포수 증가량이라 가정하고, 이때 a는 체류시간, x는 강수량을 의미한다고 할 때, 체류시간이 각 보에서는 서로 다른 a를 나타낸다. 그러나 동일한 강수량을 입력하여도 f(x)는 다른 결과로 보에 대한 적합한 관계식 성립이 어렵다. 결과적으로 딥-러닝 모델은 '평균적인 기울기'만을 학습하게 되어 체류시간이 긴 보에서는 실제보다 낮게, 체류시간이 짧은 보에서는 실제보다 높게 예측하는 오류를 가지게 된다.

1.4.3 지리적·수문학적 이질성 미반영

관측소 간 거리가 멀거나, 상·하류 연결이 약한 지점까지 단순 병합하여 사용함으로써

수리·수문 **연계성이 모델에 충분히 반영되지 못하였다.** 강우 시 발생하는 지표 유출수(영양염, 오염물질 부하)의 시차적 영향이 지점별로 다르게 나타나지만, 표준화 모델에서는 이를 구체적으로 반영하기 어려웠다.

1.4.4 환경 인자 반영의 제한성

실제 남조류 대발생은 강우·체류시간·성층(수층안정성)·영양염부하 등 다양한 인자의 복합작용으로 발생하나, **기상·수문·수질의 제한된 변수만 사용**하여 다차원적 인자들의 비선형 상호작용을 충분히 학습하지 못하였다.

1.5 남조류 예측을 위한 개선 방안

1.5.1 해외 및 최신 연구동향

1) NOAA Lake Erie HAB-OFS

미국 NOAA는 Lake Erie를 대상으로 Harmful Algal Bloom Operational Forecast System (HAB OFS)을 운영중이다. **Sentinel-3 OLCI 위성 영상에서 추출한 해양 색상 자료와 현장 관측치**(세포 수, 클로로필 농도, 마이크로시스틴 독소 등), 그리고 **LEOFS(3차원 순환모델) 기반 유동·수온·풍속·강우 자료를 통합**하여 조류 발생 현황을 탐지하고 **미래 분포를 예측**하는 시스템임.

본 시스템은 위성 기반 탐지(nowcasting)와 수치모델 기반 예측(forecasting)을 결합하여 향후 **96-120시간 이내 조류의 이동·확산, 표면 스컴(scum) 형성 가능성 등을 제시**하며, 추가적으로 Bloom Severity Index(SI)와 독성 예측(실험 단계)도 제공한다. NOAA는 매년 7-10월 Bloom 시즌 동안 주 2회(월·목) 예보를 발행하고 있으며, 이 예측 결과는 정수처리장·보건기관의 선제적 대응, 해변 관리 및 수질 채취, 수상 레저 활동 안전 확보 등 현장 운영에 직접 활용되고 있다.

2) 하이브리드 모델(Process-Based + Data-Driven) (Lin et al. 2025)

기작모델(PBM)인 수치모델에 데이터 기반 예측(딥-러닝)을 결합한 하이브리드 모델 예측체계로, PBM에서 출력된 지표(유속, 체류시간 등)를 데이터 기반 모델의 입력 변수로 사용하였다. 예측모델은 LSTM모델로 하이브리드 모델이 단순 ML 또는 PBM 단독보다 조류 번성의 시기와 강도 예측에서 TPR 등 정확도가 유의미하게 향상되었다.

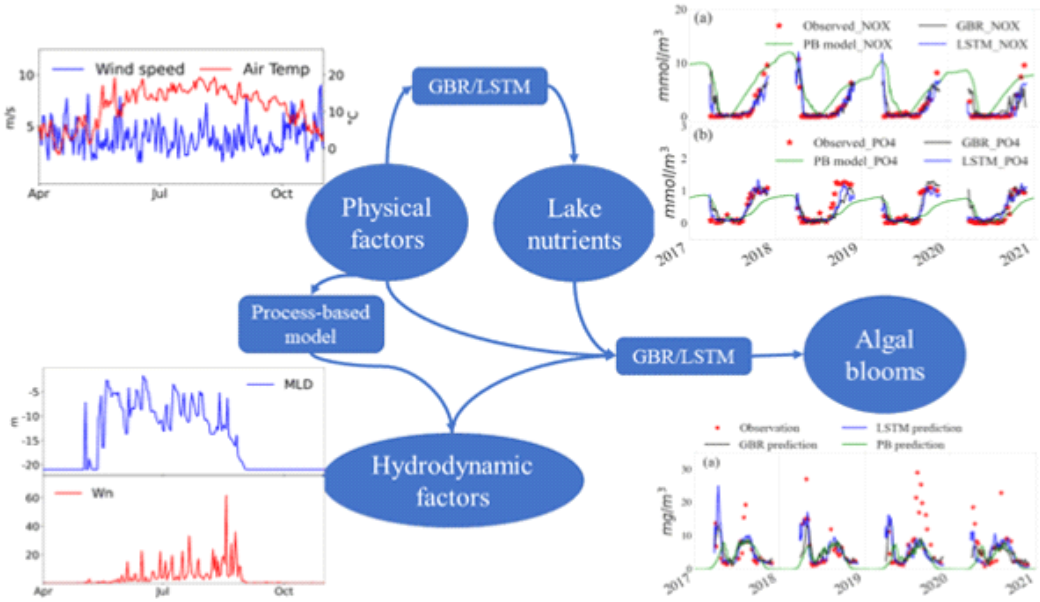

<그림 1.3> 기상 및 수치모델 데이터를 접목한 조류예측 구성 사례(Lin et al. 2025)

3) 공간-시간 모델 (Wan et al. 2025)

Wan et al.(2025)은 Spatio Temporal Feature Graph Neural Network(STF GNN) 개발하였다. **여러 지점의 시공간 특성을 노드(딥러닝 레이어 구조) 형태로 표현**하고 이웃 지점 간 가중치를 포함해서 주요 수질항목을 예측하였다. 공간 및 시간 모듈을 제거할 경우 정확도가 12~19% 큰 폭으로 저하됨을 밝히고 공간-시간 구조적 연계 노드 구조의 예측 우수성을 제시하였다.

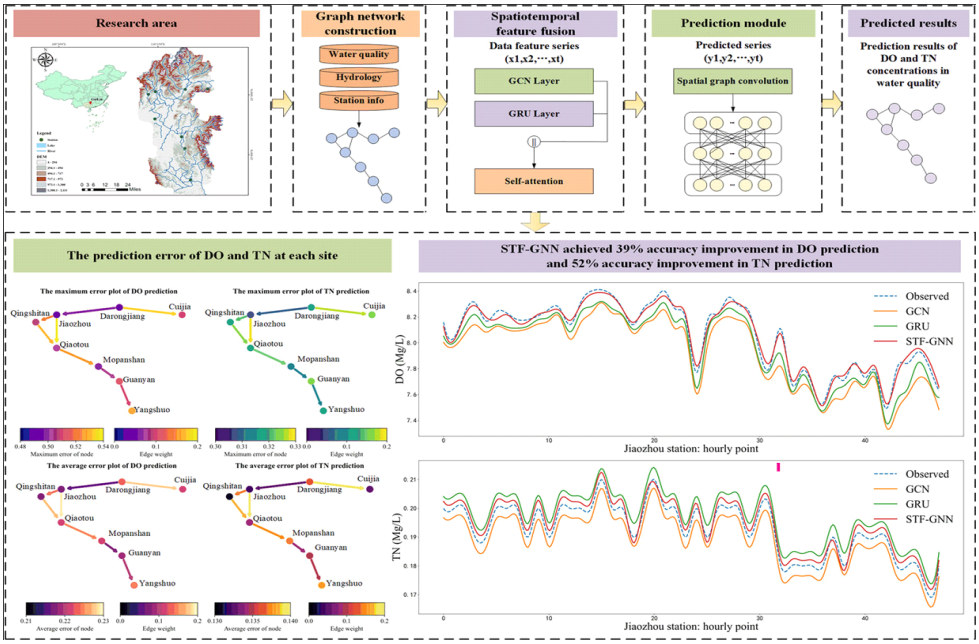

<그림 1.4> STF-GNN – 하천의 형상 및 관측지점간 관계의 노드 구현사례(Wan et al. 2025)

4) 원격탐사

• Monitoring harmful algae blooms in Darlings Lake, New Brunswick, using K−means clustering of multi−spectral imagery (Evans et al. 2025)

Evans et al.(2025)은캐나다 뉴브런즈윅 Darlings Lake에서 Sentinel-2 다중분광 영상을 활용하여 NDCI(Chloro phyll Index)를 계산하고, K-means 클러스터링을 적용하여 유해 남조류의 공간적 발생 패턴을 모니터링하였다. 본 연구는 "위성 기반 탐지"를 통해 현장 관측이 어려운 구간의 조류 분포를 효율적으로 파악할 수 있음을 보여주었으며, 이는 향후 시계열 예측 모델의 입력자료로 확장될 가능성을 시사하고 있다.

• Florida Department of Environmental Protection(DEP)

Sentinel-3 OLCI에서 산출한 사이아노박테리아 지수(2BDA-PC, NDPCI 등)를 현장 관측값과 교정하여 주·일 단위 시계열을 구축하고, 이를 위성 산출물(Chl-a/CB 지수)과 기상자료(강우, 풍속, 수온 등)와 결합하여 단기 예측 모델(Machine Learning 및 Deep Learning)의 입력자료로 활용하였다.

Florida DEP 보고서에서는 Sentinel-3 기반 CB 지수와 현장 관측값 간 교정 성능($R^2 \approx 0.65$, RMSE≈11–12%)을 제시하였으나, 이는 탐지(nowcasting) 중심 결과일 뿐 미래 예측 성능은 포함되어 있지 않다. 다만 보고서에서도 위성자료 단독 사용 시 구름·강우 등 외부 요인으로 변동성이 커 안정성이 낮아질 수 있음을 지적하며, 예측 정확도 향상을 위해 기상·수문 입력과의 결합이 필요함을 언급하였다.

1.5.2 데이터 확충 및 개선

1) 데이터 확충

기존 예측 연구는 주로 수질·수문·기상 관측소에서 확보되는 제한적 변수(수온, 용존산소, 총유기탄소, 강수, 유량 등)에 의존하고 있다. 지점 자료만으로는 공간적 확장성이 부족하여, 수계 전체의 조류 발생 양상을 반영하는 데 한계가 있다.

향후에는 **위성 원격탐사(Sentinel-2β, Landsat, hyperspectral 등)를 통해 넓은 수역의 공간 분포를 확보**하고, 실시간 센서 관측을 통해 고빈도 자료를 수집하며, 수문 운영 데이터(댐·보 방류량, 저수위 등)를 함께 통합하여 시·공간적 커버리지를 확대할 필요가 있다. 이를 위해 수계 전반의 공간적 변동성을 설명할 수 있는 자료 확보 필요하다.

2) 데이터 해상도 보완

현재는 주 단위, 일부 수질 변수는 일 단위로 불균질하게 수집되고 있다. 이러한 한계로 인해 단기 변동성이나 집중강우 후 영양염 유입과 같은 급격한 환경 변화를 포착하기 어렵다. **향후에는 고해상도(일 단위, 가능 시 시간 단위) 관측 체계 확충이 요구된다.** 또한 **불균질한**

시계열은 보간(interpolation)·재표본화(resampling) 기법을 개선(과거에는 단순 내삽)하여 균질한 시계열 데이터셋으로 변환할 필요가 있다. 이를 통해 학습 과정에서 시간 스케일 불일치로 인한 학습 데이터 결측을 줄이고, 단기 예측 성능을 향상시킬 수 있다.

3) 다차원 환경 인자 확보

조류 발생은 단순한 영양염 농도뿐 아니라 체류시간(HRT), 성층, 영양염 부하, 기상조건(풍속·강수·기온) 등 다양한 요인의 상호작용으로 결정된다. 기존 관측 변수만으로는 이러한 복합적 과정을 충분히 반영하기 어렵다. 따라서 유역 유출모델 및 수치모델을 활용하여 수리학적 특성을 산출하고 이를 예측 모델의 입력 변수로 포함해야 한다. 이를 통해 단순 상관관계 수준을 넘어, 원인 기반 예측으로 확장할 수 있다.

4) 데이터 품질 관리

남조류 예측 자료는 지점별·유역별 관측 환경과 지형적 조건이 상이하여, **동일 변수라 하더라도 분포 특성이 달라지는 Domain Shift 문제가 발생한다.** 이러한 분포 차이를 고려하지 않을 경우, 전국 단일 모델은 개별 지점의 특성을 제대로 반영하지 못해 예측 성능이 저하된다. 이를 해결하기 위해서는 자료 표준화·정규화를 정립하고, 모델 학습 과정에서 지점별 보정 계층(adaptive layer)을 적용할 필요가 있다. 이를 통해 지역별 환경 차이를 보정하면서도, 공통 모델의 일반화 성능을 유지할 수 있다.

1.5.3 개선 방향(설계·학습·검증)

1) 하이브리드 접근(PBM + Data-Driven)

기작 기반 수치모델(PBM)에서 계산된 수문·수리 지표(유속, 체류시간, 성층 안정도 등)를 딥러닝 입력 변수로 활용하는 하이브리드 모델을 개발하여, 단순 자료 기반 모델의 한계를 보완하고 물리적 해석성과 예측력을 동시에 확보해야 한다.

2) 하천 및 보에서 예측 최적화된 모델 알고리즘 개발 및 적용

기존 LSTM 기반 모델은 단기 예측에는 효과적이나, 장기 의존성(Long-term dependency) 문제로 복잡한 환경 요인 반영이 제한된다. Transformer 기반 시계열 모델, ST-GNN(Spatio-Temporal Graph Neural Network) 등 공간-시간 상호작용을 학습하는 최신 구조를 적용하여, 다지점 간 상관성을 반영한 예측 성능을 확보할 필요가 있다.

제 2 장 머신러닝을 활용한 저수지 녹조예측 모델 구축시 적정변수 선택을 위해 도메인 관점에서 고려할 주요 사항

녹조(綠潮, algal bloom)란 강이나 호수에 남조류(藍藻類)가 과도하게 성장하는 현상을 말한다. 환경부는 여러 남조류 중 'Anabaena, Aphanizomenon, Microcystis, Oscillatoria' 4개 속을 유해남조류로 지정하고 조류측정망 및 조류관찰지점에서 수온, pH, DO, 투명도, 탁도, 클로로필 a, 유해남조류 세포수, 유해남조류 우점종 및 세포수(속별)를 주기적으로 측정하고 있다. 인공지능을 활용한 녹조 예측은 장기 측정자료를 확보할 수 있음을 전제로 하기 때문에 환경부 조류측정망 및 조류관찰지점 측정자료를 기반으로 녹조 예측 모델 구축 시 적정 변수 선택을 위해 도메인 관점에서 고려할 주요 사항을 제안하였다.

2.1 연구사례

녹조 발생에 영향을 주는 환경변수에 대한 연구들을 아래와 같이 제시하였다.

■Salmaso과 Braioni(2008)

영양염 농도는 조류의 성장을 제한하지 않는 것으로 보이며, 가장 중요한 강제력 요소는 물리적 변수 (주로 하천 유량)와 수문 관련 변수 (조류 세포를 희석시키고 광합성을 저해하는 부유 고형물 및 탁도)임을 주장하였다.

■Mitrovic et al.(2003)

Anabaena circinalis 성장과 우점이 성층의 형성·유지와 밀접한 관련이 있으며, 성층 발달은 하천유량과 관계가 있음을 제시하였다. 하천유량을 단면적으로 나누어 평균유속을 산출한 결과, 하계에 발달하는 성층을 억제하기 위한 임계 유속은 5 cm/s이며, 이는 Anabaena circinalis 번식을 억제하기에 충분하고 유사한 기후대의 다른 하천에도 적용이 가능함 제시하였다.

■Long et al.(2011)

다양한 2차원 수치모델 실험을 통하여 조류성장에 영향을 미치는 수리조건을 분석한 결과 조류성장을 위한 최적 유속이 0.04 m/s임을 제시하였다.

■Li et al.(2013)

조류 대발생은 유속과 영양염, 지형에 영향을 받으며, 유속과 클로로필-a 농도는 강한 음의 상관관계 (R2= -0.618)가 있음을 보였다. 또한, 유속, 강수 및 기온과 같은 수문기상 요소의 변화는 조류의 시공간적인 변동과 밀접한 관련이 있으며, 수역의 크기, 지형, 흐름의 특성, 퇴적물 상태, 영양염, 수온, 빛 및 종 구성 등 많은 영향 인자의 차이로 인하여 일반적인 임계유속 값이 존재하지 않을 수 있음을 주장하였다.

<표 2.1> 남조류 현존량 감소와 수온과의 관계 관련 연구

대상종	수역	반응	출처
Anabaena spiroides	북한강 수계	4°C 이하에서 현존량 급격히 감소	유 등, 2013.
Anabaena circinalis	북한강 수계	15℃ 이하에서 성장 지체, 15℃를 기준으로 부유특성이 달라짐	권대률, 2015
Microcystis eruginosa	Lake Kasumigaura, Japan	11℃ 이하에서 광합성 현저히 감소, 4℃ 이하에서 광합성 일어나지 않음	Takamura et al.,1985

■ Vidal et al.(2012)

인과 질소 농도가 높고, 수온의 일변동이 큰 경우, 강한 성층조건에서 낮 동안 표층으로 유입된 영양염이 풍부한 지천수는 정체된 물과 혼합하여 국지적으로 조류 대발생을 촉진시키는 주요 강제력임을 제시하였다.

■ Li et al.(2016)

Microcystis 군집 (Microcystis ichthyoblabe, Microcystis wesenbergii, Microcystis aeruginosa)을 대상으로 기낭을 파괴한 그룹과 처리를 하지 않은 그룹으로 구분하고 스톡스 법칙 (Stokes Law)에 기반한 군집의 밀도, 크기, 형태와 부유 및 침강 속도를 산정하여 Microcystis 군집의 계절적 부력변화에 대한 연구를 수행하였다.

■ Horne & Goldman(1994)

조류는 수체 내에서 엽록소에 의한 광합성을 위해 태양 에너지를 이용한다. 수심이 깊어질수록 낮아지는 광 흡수율 때문에 조류가 제한적으로 생육하게 되므로 조류는 부유기작이나 운동성을 이용하여 유광층 상부에 오래 머물 수 있는 능력이 있어야 함을 발견하였다.

2.2 종속변수 구성

상기 제시한 바와 같이 환경부는 녹조(綠潮, algal bloom)를 강이나 호수에 남조류(藍藻類)가 과도하게 성장하는 현상으로 제시하고 유해남조류 총 세포수 기준으로 조류경보제를 발령하고 있다. 김 등(2020), Kim et al(2024) 등 대부분 인공지능 모델에서 연구에서도 유해남조류 총 세포수를 종속변수로 설정하고 있는데 이에 대한 적절성을 검토하였다.

2.2.1 유해남조류 속 구분

녹조 예측 정확도 측면에서 중요하게 고려되어야 할 점은 발생시기, 대발생 여부, 소멸시기이다. 이러한 기작들은 남조류 속별 고유한 특성을 갖는다. 마이크로시스티스는 최적성장 수온이 25℃ 이상인 고온성 남조류인 반면 아나베나는 20~25℃, 오실라토리아는 20℃ 이하이다 <표 2.2>. 따라서 각 속별 발생시기도 각각 다르다. 생활상, 성장속도 등의 특성도 각기 다르다. 조류측정망에서 제공되는 공식 자료는 속별 세포수가 아닌 4종 유해남조류 세포수의 합이

다. 녹조를 대상으로 하는 많은 인공지능 모델 연구에서는 유해남조류 속별 세포수가 아닌 4개 유해남조류 세포수의 합, 즉 유해남조류 총 세포수를 종속변수로 설정한다. 하계에 Microcystis가 우점종인 경우가 많지만 시기별, 대상 수체별 변동성이 크다. 대청호에서 수온이 높은 여름철에는 Microcystis의 발생이 높았고 상대적으로 수온이 낮은 계절에는 Aphanizomenon이 우점하는 비율이 높았으나 2002년까지는 우점종이 구형 남조류인 Microcystis 속이었고 2005년부터 선상남조류인 Anabaena, Aphanizomenon 등으로 변화되었다(노 등, 2014). 따라서 대상 수체별, 계절별, 연도별 우점종은 변화할 수 있다. 유해남조류 총 세포수를 종속변수로 설정하는 경우 연중 나타나는 남조류 세포수의 다중 peak 특성의 재현·예측에 한계가 있다. 모든 peak에서 동일한 종이 우점하는 경우 합리적인 재현성능을 기대할 수 있으나 그렇지 않은 경우 모델 재현성은 낮을 수밖에 없다. 종속변수(dependent variable)는 어떤 사건의 원인이 되는 독립변수의 영향을 받아 나타나는 결과로서 시공간적으로 그 정의와 성격이 바뀔 수 없다. 그러나 수체와 시기별 우점종은 다를 수 있고 그 우점종들의 생리·생태 특성이 서로 다를 수 있어 동일한 종속변수라고 보기 어려울 수 있다. 예를 들어 낙동강 특정 보 구간에 올해 8월 발생한 녹조 이벤트에서 우점한 남조류는 Microcystis이고 9월 녹조 이벤트에서 우점한 남조류는 Anabaena라고 가정하자. 각 월별 수온, 광량, 영양염, 체류시간 등의 환경조건 즉 독립변수에 영향을 받아 그 결과로 나타나는 결과인 종속변수가 각 월별로 달라지는데 이는 종속변수의 공리를 위배하는 것이다.

그러나 유해남조류 세포수를 대상으로 하는 인공지능 모델 구축은 다른 분야에 비하여 학습자료가 매우 적기 때문에 위와 같은 유해남조류 속별 고유한 특성이 올바로 반영되지 않을 경우의 오차가 자료수 부족으로 발생하는 오차에 묻혀 제대로 구분되지 못할 수 있다. **따라서 유해남조류 4개 속을 각각 종속변수로 설정하고 각 속별 예측된 세포수의 합을 유해남조류 세포수로 사용하는 경우와 유해남조류 총세포수를 단일 종속변수로 사용하는 경우의 재현성능을 비교·분석하여 바람직한 방법을 사용할 필요가 있다.**

<표 2.2> 유해남조류 4종의 특성 (국립환경과학원 물환경정보시스템)

구분	Microcystis	Anabaena	Oscillatoria	Aphanizomenon
생활상	세포내에 공기주머니가 있어 수표면에 부유하면서 성장	세포내에 공기주머니가 있어 수표면에 부유하면서 성장	세포내에 공기주머니가 있어 수표면 혹은 수중에 부유	세포내에 공기주머니가 있어 수표면에 부유
최적 성장온도	25℃~35℃ (고온성)	20℃~25℃	20℃이하	20℃전후
발생시기	늦봄 ~ 늦가을	봄, 초여름, 가을	봄 ~ 가을	봄, 가을, 초겨울

2.2.3 남조류 생활사

Kong and Gao(2005)의 연구에서 남조류 생활사를 '1) 봄철에 퇴적물로부터 수층으로의 회귀, 2) 생체량 증가, 3) 성장, 4) 가을철 침강, 5) 퇴적물 표면에서의 월동'의 다섯 단계로 구분하여 제시하였다. 녹조를 재현·예측한다는 것은 특정 수체에서 남조류 발생, 대량증식, 소멸을 재현한다는 의미이다. 남조류는 겨울철에 휴면포자 형태로 바닥 퇴적층에서 존재하다 적합한 환경조건이 되었을 때 발아한다. 이렇게 발아한 남조류 세포는 성장에 적합한 환경이 되었을 때 대량 증식하여 녹조를 발생시킨다. 남조류 포자가 남조류 영양세포로 발아하는 특성은 수중의 남조류 세포가 대량 증식하는 것과 다른 기작의 결과이다. 즉 모의하고자 하는 대상이 다르다. 그러나 남조류 포자와 수중의 영양세포를 구분하여 모의할 수는 없으므로 이를 합리적으로 반영할 필요가 있다. 이를 위해서 남조류 포자가 발아하는데 영향을 주는 환경조건들을 독립변수로 고려해야 한다. 또한 발아한 남조류 세포가 적절한 환경이 아닌 조건에서 포자를 형성한 후 침강하여 바닥으로 퇴적되는 조건도 고려할 필요가 있다. 즉, **남조류를 포자 단계와 영양세포 단계로 구분하여 모의할 수는 없어도 남조류 생활사별 영향요인을 고려할 수 있도록 독립변수를 구성할 필요가 있다.**

<표 2.3> 남조류 생활사별 관련 기작 및 영향인자

생활사	관련 기작	영향인자
침강	침강 임계 유속	유속
	일주기 수직 이동	광합성
월동	포자형성	DO, 빛, 포식자 영향
회귀	회귀 시점, 회귀량	수온, 빛, 수심(수위), 재부유, 생물교란, 영양염, DO
성장, 감쇄	성장	수온, 광, 영양염 영향, 유속 영향
	감쇄	염분 독성 영향(기수호), 대사, 포식

<표 2.4> 수온이 남조류 회귀에 미치는 영향

대상종	수온	내용	출처
Anabaena circinalis	22~24℃ <15℃, 30℃<	회귀 최적수온, 발아율 감소	Fay, 1988
Anabaena	10-15℃	회귀 제한수온 임계치	Baker and Bellifemine, 2000
Anabaena ucrainica	11℃	휴면포자 발아율 높음	Tsujimura and Okubo, 2003
Microcystis aeruginosa	11℃	생리적 상태 변화 큼	Takamura et al., 1985
Microcystis	15-20℃	회귀시발 및 최적수온	Li et al., 2004
Microcystis	14℃	회귀시작, 최대 회귀	Tao et al., 2005
Microcystis	15℃	회귀량 증가 임계수온	Yamamoto, 2009

2.3 독립변수 구성

2.3.1 남조류 거동 기작별 환경 영향 인자

남조류 영양세포는 수중에서 물리적 기작인 이류·확산에 의하여 이동하고 성장과 감쇄에 의하여 변동한다. EFDC, CE-QUAL-ICM 등 조류를 고려하는 수질모델에서 일반적으로 남조류를 포함한 조류에 대한 질량보존 방정식은 다음과 같이 표현한다 <식 2.1>.

$$\frac{\triangle \mathrm{Alg}ae}{\triangle \mathrm{t}} = loads + transport + settling + resuspension + gross\ primary\ produduction - \mathrm{respiration} - \mathrm{mortality} \quad \text{<식 2.1>}$$

조류는 총1차 생산, 호흡(대사 포함), 배설(excretion), 사멸, 섭식(grazing), 재부유 및 침강에 의해 영향을 받고 순 성장 (생체량 증가)이 그 결과이다. 순1차 생산은 총 1차 생산에서 호흡을 뺀 것으로 정의된다. 즉, **조류의 성장과 감쇄에 영향을 미치는 기작은 광합성에 의한 1차 생산(성장), 호흡, 배설(excretion), 사멸, 섭식(grazing), 재부유 및 침강 그리고 호흡이다.** 각 기작들에 미치는 환경요인을 검토하고 독립변수 구성 시 유의할 점을 제시하였다.

1) 조류 성장

대부분 결정론적 수질모델은 최고성장율에 광, 수온, 영양염 제한을 복합적으로 고려하는 multiplicative formulation을 사용하여 성장률(생산율)을 산정한다. 즉, 조류 성장은 광, 수온, 영양염에 영향을 받으며 각 조건들이 제한되는 경우 성장이 저하된다 <식 2.2>.

$$P = PM \bullet f(N) \bullet f(I) \bullet f(T) \quad \text{<식 2.2>}$$

여기서,

P	: growth rate [day^{-1}]
PM	: maximum growth rate [day^{-1}]
N	: nutrient concentration [mg/L^{-1}]
I	: light intensity [ly]
T	: temperature [degree C]
$f(N), f(I), f(T)$	: effect of suboptimal nutrient, light and temperature (0<f<1)

① 영양염 영향

조류의 영양염 제한 특성은 일반적으로 질소, 인, 규소(규조류의 경우) 중 최소의 제한요인만을 적용하는 minimum formulation으로 표현된다 <식 2.3>.

$$f(N) = \min\left[\frac{DIN}{KHN+DIN}, \frac{PO_4}{KHP+PO_4}, \frac{Si}{KHS+Si}\right] \quad \text{<식 2.3>}$$

여기서,

DIN, PO_4, Si : 용존무기질소, 인산염 및 규산염 농도

KHN, KHP, KHS : 질소, 인, 규소의 영양염 반포화 상수

규조류는 인, 질소 그리고 규소에 영향을 받으며 남조류를 포함한 이외 조류는 인산염과 질산염에 영향을 받는다. 남조류와 수질항목간 관계를 분석하는 연구에서 많은 경우 남조류와 총질소(TN), 총인(TP)의 관계를 분석한다. 인은 수중에서 용존성무기인(phosphate, 인산염), 용존성유기인(DOP), 입자성유기인(POP) 형태로 존재하며 그 합을 총인(TP)으로 명명한다. 이 중 입자성유기인은 조류생체 내의 인도 포함된 개념이다. 따라서 조류를 포함한 총인과 조류간의 관계는 상관관계가 높아 보일 수 있지만 향후 조류 대발생을 예측하기 위한 선행 지표로 사용하기에는 무리가 있을 수 있다. 즉, 조류가 대발생한 경우 총인이 증가하기 때문에 이 둘의 관계는 경우에 따라서 인과관계가 아니라 상관관계로 해석해야 한다. 조류는 수중의 용존성무기인, 즉 인산염을 영양염으로 흡수하므로 조류의 성장을 예측하기 위해서는 총인보다 인산염 농도가 중요하다. 입자성유기인이나 용존성유기인이 분해되어 영양염인 인산염이 증가할 수는 있지만 이를 직접 이용할 수는 없고 난분해성 유기인의 경우 분해에 소요되는 시간이 길기 때문에 조류 성장에 주요한 영향을 주지 못할 수도 있다. 이는 질소의 경우에도 마찬가지이다. **따라서 총인과 총질소를 독립변수로 사용하기보다는 ① 영양염인 인산염, 질산염, 암모늄을 사용하거나 ② 영양염과 총인/총질소를 함께 사용하는 것을 모두 검토하고 결과가 합리적인 것을 선택하는 것이 바람직해 보이며, 적어도 영양염 항목들은 반드시 반영할 필요가 있다.**

남조류는 영양염 변동이 심한 환경에서 생존하고 번성하기 위해 '사치성 인 섭취(Luxury Phosphorus Uptake, LPU)'라는 독특한 생리적 적응전략을 사용한다. 이 메커니즘을 통해 남조류는 현재의 대사 요구량을 훨씬 초과하는 양의 인산염(Pi)을 세포 내로 흡수한다. 과도하게 흡수된 인산염은 삼투압에 영향을 미치지 않는 폴리인산염(Polyphosphate, PolyP) 과립 형태로 전환되어 세포 내에 저장된다. 이 저장된 폴리인산염은 외부 인 농도가 고갈된 환경에서도 최대 20회의 세포 분열에 필요한 에너지를 공급할 수 있는 강력한 영양분 저장고 역할을 한다(Alexei et al., 2020). 인 농도가 낮은 낙동강에서 남조류가 성장할 수 있는 이유이다. 따라서 대부분 환경에서 인이 제한영양염으로 작용하지만 위와 같은 '사치성 인 섭취(Luxury Phosphorus Uptake, LPU)' 기작으로 인하여 인과의 관계가 복잡하게 나타날 수 있다. 환경기초시설 고도처리를 통해 인 농도가 낮게 유지되는 낙동강에서 녹조가 발생한 경우에도 인산염 농도가 낮게 유지되어 인산염과 녹조간 상관관계가 낮아 보이는 경우는 이와 같은 이유이다. 또한 지류를 통한 낮은 농도의 인 유입, 수중에서의 유기물 분해, 바닥용출 등을 통해 인산염이 공급될 수 있으나 대량 발생한 녹조로 인하여 즉시 흡수된다. 즉, 실제는 인산염이 영양염으로 사용되고 있으나 수중에는 고갈된 것처럼 보일 수 있다.

위와 같은 이유들로 인하여 수중에서 인산염이 고갈된 것처럼 보일 경우에도 녹조가 대량발생하거나 이미 대량 발생한 녹조가 인산염이 고갈되어도 지속될 수 있다. 그러나 인산염 영향이 없는 것이 아니며 시스템이 갖는 특성에 따라 달리 반응할 수 있어 녹조 예측시 유의해야한다.

수중에 용해된 질소는 주로 질산염(NO^{3-})과 암모늄(NH^{4+}) 형태로 존재하며, 조류가 이러한 질소형태를 얼마나 효율적으로 흡수하고 이용하는지가 생존과 번식에 결정적인 영향을 미친다. 남조류를 포함한 조류는 질소원 흡수 과정에서 암모늄(NH^{4+})을 질산염(NO^{3-})보다 훨씬 선호하며 선택적으로 흡수한다. 질산염은 세포 내로 흡수된 후 조류가 아미노산과 단백질 합성에 이용되기 위해 먼저 아질산염(NO^{2-})으로, 그리고 다시 암모늄으로 환원되는 과정을 거쳐야 한다. 이 환원 과정은 질산염 환원 효소(nitrate reductase)의 작용을 통해 일어난다. 반면, 암모늄은 이미 환원된 형태이므로 이러한 중간 과정을 거치지 않고 대사에 직접 사용될 수 있다. 따라서 암모늄 흡수는 질산염 흡수에 비해 적은 에너지를 소모하며, 이는 한정된 자원 속에서 생존하는 조류에게 유리하게 작용한다. 드물지만 질소 부족 환경이나 N/P 비가 작은 환경에서 암모늄이 지배적인 질소원으로 작용하는 현상은 이러한 에너지 효율성의 중요성을 강조한다. 이는 조류가 에너지를 절약하여 성장률을 극대화하려는 최적화된 생존 전략을 구사함을 의미한다. 광합성을 통해 에너지를 얻는 식물플랑크톤은 빛이 제한적인 환경(예: 수심이 깊거나 혼탁한 수층)에서는 에너지 생산량이 줄어들기 때문에, 질소 동화에 필요한 에너지 소비를 최소화하기 위해 암모늄을 우선적으로 이용하는 것이 훨씬 유리하다. **따라서 암모늄과 질산염을 각각 상태변수로 사용하는 것이 바람직 할 수 있다.**

② 수온 영향

종간에 나타나는 성장률 차이는 제한 영양염에 대한 식물플랑크톤 종간 생리적 특성에 영향을 받지만, 수온에 특히 민감하게 반응한다. 수생태계에서 식물플랑크톤 천이는 영양염외에도 수온과 광도 등에 야기될 수 있다 (Carpenter and Kitchell, 1993; Lathrop and Carpenter, 1990; Sterner and Grover, 1998). 일반적으로 부영양 정체수역에서 일조시간이 짧고 수온이 낮은 봄과 가을에는 규조류가, 수온이 높은 시기에는 남조류가 우점하는 식물플랑크톤 천이가 일반적인 현상으로 알려져 있다(Sommer et al., 1986). 따라서 남조류의 우점기간은 영양상태와 수온에 의존하여 결정될 수 있으며, 동절기의 낮은 수온은 남조류 소멸의 중요한 원인으로 지적되고 있다(Reynolds, 1984; Romo and Miracle, 1994; Sommer et al., 1986). 수온이 4℃ 이하로 유지되는 기간 중 인이 부족한 상태에서는 남조류보다 규조류의 경쟁적 우위를 예상할 수 있다(Sommer, 1989; Sommer et al., 1986). 겨울철 결빙 동안에 Microcystis sp.에서 낮은 수온에 내성이 강한 것으로 알려진 Oscillatoria sp.와 Aphanizomenon sp.와 같은 사상성 남조류로 천이된다.

수온은 남조류를 포함한 조류에 성장, 호흡, 배설(excretion), 섭식(grazing)에 영향을 미친다. 조류는 적정 수온 범위 내에서는 성장에 제한을 받지 않으며 그 이하 또는 이상 수온에서는

성장률이 감소하며 일반적으로 아래와 같이 표현된다 <식 2.4>.

$$f_3(T) = \exp(-KTG1[T - TM]^2 \quad \text{if} \quad T \leq TM$$
$$= \exp(-KTG2[TM - T]^2 \quad \text{if} \quad T > TM \qquad \text{<식 2.4>}$$

여기서,

T	: temperature(℃) provided from the hydrodynamic model
TM	: optimal temperature for algal growth (℃)
KTG1	: effect of temperature below TM_x on growth ($℃^{-2}$)
KTG2	: effect of temperature above TM_x on growth ($℃^{-2}$)

대사, 호흡, 배설, 섭식은 기준 수온 이상에서 반응속도가 증가하고 그 이하에서는 감소하는 특성을 갖는다. 그 중 대사는 아래와 같이 표현할 수 있으며 나머지 기작도 동일한 유형으로 표현할 수 있다 <식 2.5>.

$$BM = BMR \cdot exp(KTB[T - TR]) \qquad \text{<식 2.5>}$$

여기서,

BM	: metabolism rate (day^{-1})
BMR	: basal metabolism rate at TR (day^{-1})
TR	: reference temperature for basal metabolism (℃)
KTB	: effect of temperature on metabolism ($℃^{-1}$)

녹조가 발생하는 하계에는 표층과 중·저층 간 수온차가 커지며 성층이 강화된다. 강화된 성층은 상부에 위치하는 표면 혼합층과 그 하부와의 연직 혼합을 억제한다. 따라서 표층에서 대발생한 녹조의 연직혼합이 제한되고 녹조가 가속된다. 낙동강에서 상부 혼합층과 성층은 수면하 5~7 m까지 발달하며 그 아래에는 비교적 저온수가 위치한다 <그림 2.1> (국립환경과학원, 2019). 수온의 연직적인 구조는 시스템별로 차이가 크며 영산강 죽산보의 경우 4 m 내외의 수심에서도 성층이 발달한다 <그림 2.2>. 성층이 약화되어 연직혼합이 활발해지고 표층 녹조가 저층으로 확산되는 경우 광제한으로 인하여 성장이 제한될 수 있다. 즉 수온은 조류의 생리작용에 영향을 미치는 동시에 물리적인 수송작용에도 영향을 미치며 성장을 제한시킬 수 있다.

표층에 분포하는 녹조는 표층 수온에 영향을 받지만 녹조의 연직혼합은 표층과 중·저층 수온간의 차이, 즉 성층강도에 영향을 받으며 연직혼합이 제한되므로 표층과 중층 또는 저층 수온자료를 모두 독립변수로 사용할 필요가 있다.

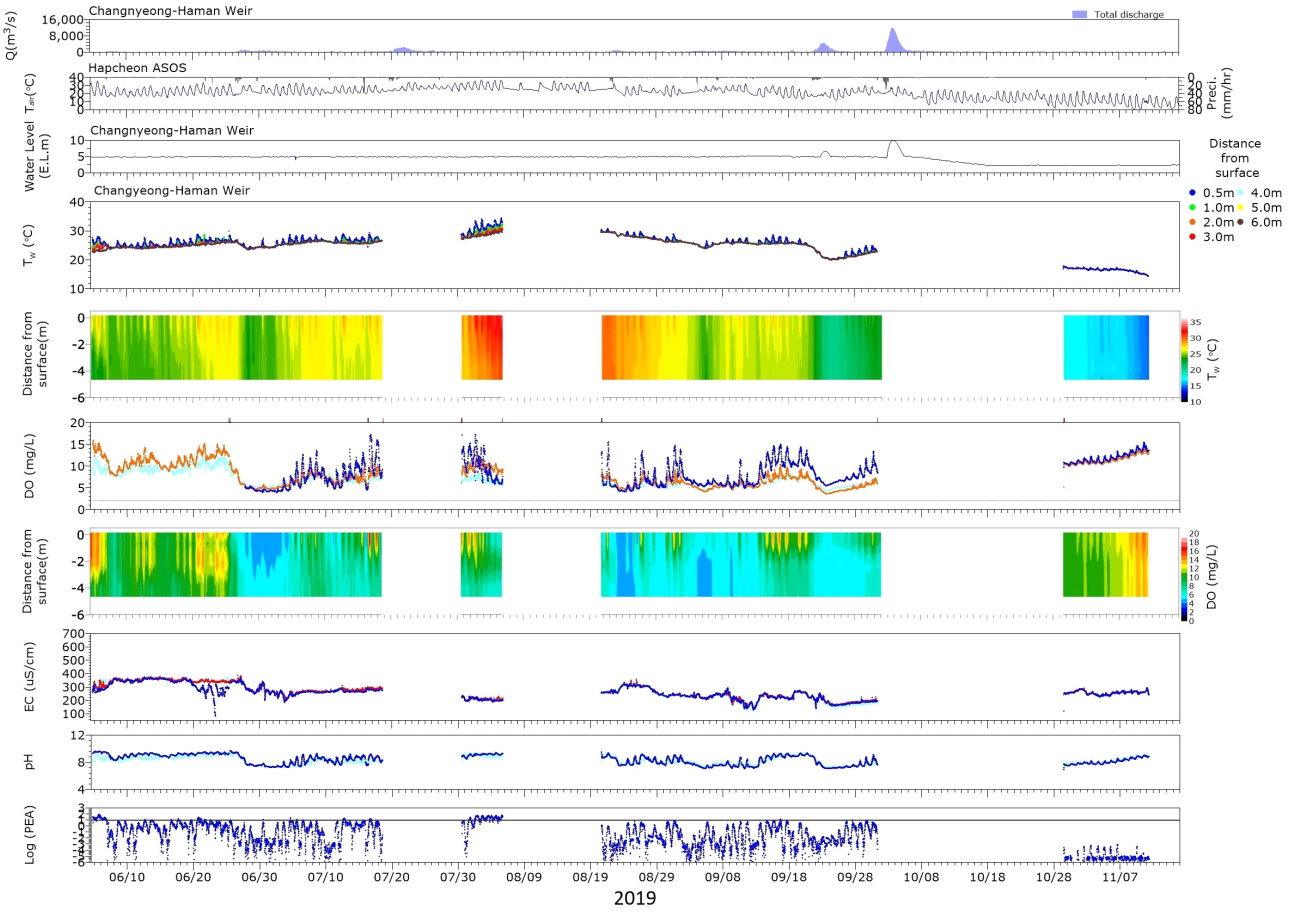

<그림 2.1> 수층별 수질항목별 시계열 (창녕함안보 대표지점) (국립환경과학원, 2019).

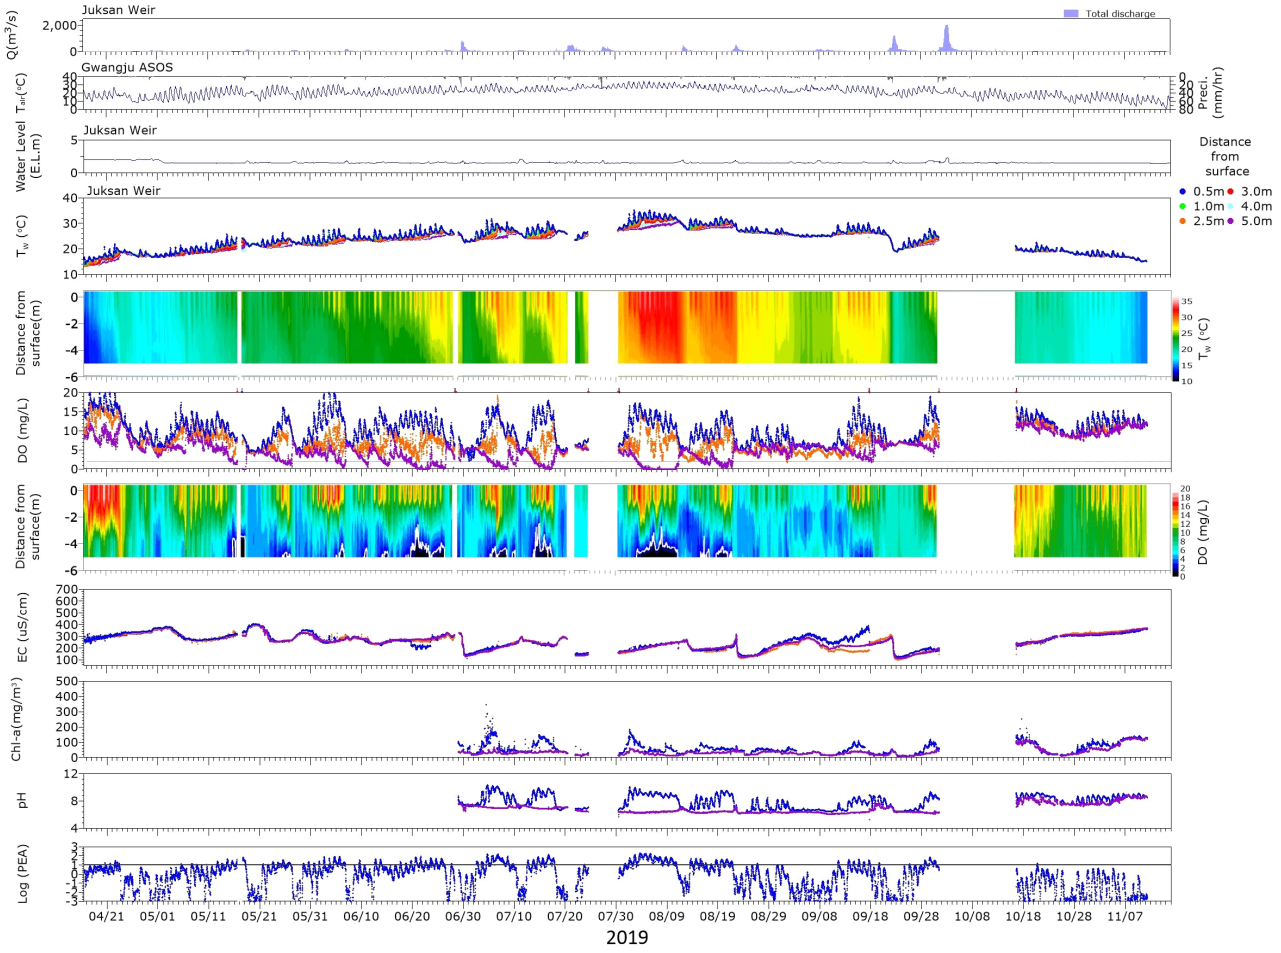

<그림 2.2> 수층별 수질항목별 시계열 (죽산보 대표지점) (국립환경과학원, 2019).

③ 광 영향

영양염 흡수와 동화는 광합성을 통해 생성되는 에너지를 소모하므로 광도에 따라 흡수율이 변동한다. 조류 군집은 보통 밤보다 낮에, 특히 정오 무렵에 질산염을 최고로 흡수하는 주기적인 패턴을 보인다. 반면 암모늄 흡수율은 광도에 대한 의존성이 질산염보다 상대적으로 약하다.

유해남조류 중 Microcystis, Anabaena, Aphanizomenon는 주로 수표면 인근에 위치하지만 Oscillatoria는 수표면을 포함한 수중에 분포한다. 수표면에 도달한 태양광은 수중에서 급격히 감쇄하며 이를 광합성에 이용하는 조류에도 중요한 영향을 미친다. 소광은 수립자의 산란, 수중 부유사, 입자성유기물 등에 의한 소광, 조류에 의한 자체소광으로 구분된다.

홍수직후 부유사 농도가 크게 증가하고 다량의 인이 하천으로 유입된다. 외부에서 다량의 인산염이 유입될 때 부유사는 이를 흡착하여 용존 농도를 낮추는 완충 작용을 하지만, 부유사가 침전되거나 환경 변화로 인해 흡착된 인산염을 다시 용출할 경우, 용존 인 농도가 증가하여 조류 번식의 직접적인 원인이 될 수 있다. 이후 유량이 감소하고 수온과 일사량이 호조건으로 유지되는 경우 녹조발생에 호조건이 형성되는데 홍수 직후에는 부유사 농도가 일정 기간 동안 높은 농도로 유지되므로 녹조 대발생을 억제한다 <그림 2.3>. 또한 녹조가 대량 발생하는 경우에도 소광이 증가하므로 chl-a, 남조류 세포수 현황 등을 고려하여 자체소광(self-shading)을 반

영할 수 있도록 해야한다 <그림 2.4>.

소광은 표층부터 바닥층까지의 누적 현상이다. 소광에 영향을 미치는 부유사농도(탁도), 입자성유기물 농도, 조류 농도는 수표면으로부터의 거리 (수심)에 따라 크게 달라지는 연직분포 특성을 갖는다. 조류는 표층, 부유사 농도는 저층으로 갈수록 농도가 증가한다. 따라서 소광에 미치는 영향을 합리적으로 고려하기 위해서는 표층뿐만 아니라 연직적인 분포를 반영할 필요가 있다.

녹조를 예측하기 위한 인공지능 모델에서 소광은 남조류의 과도한 증가를 억제할 수 있는 요인이며 녹조발생과 소멸시기를 정도 높게 예측할 수 있는 중요 제어요인이다. 따라서 소광에 영향을 미치는 부유사농도(탁도), 입자성유기물 농도, 조류 농도(chl-a, 남조류 세포수)를 반영할 필요가 있다.

<표 2.5> 조류농도에 영향을 미치는 환경인자와 조류농도의 관계

영향인자		관계	강우시 특성	내용
영양염 농도		+	N (-), P(+)	-
수온		+	수역마다 계절마다 다름	최적수온 이하/이상에서는 (-)
광	일사량	+	-	최적 광량 이상에서는 (-)
	부유사농도(탁도)	-	+	-
	입자성유기물 농도	-	+	-
	조류 농도	-	-	자체소광
유속		-	+	4 (또는 5) cm/s 이하에서는 (+)
제류시간		+	-	-

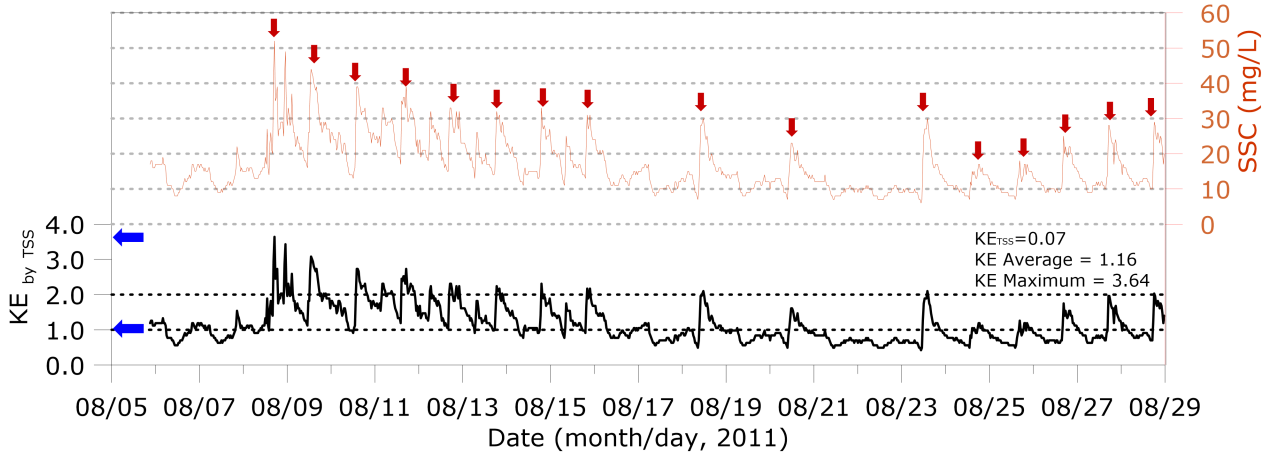

<그림 2.3> 부유사 농도에 의한 소광 변화 예시

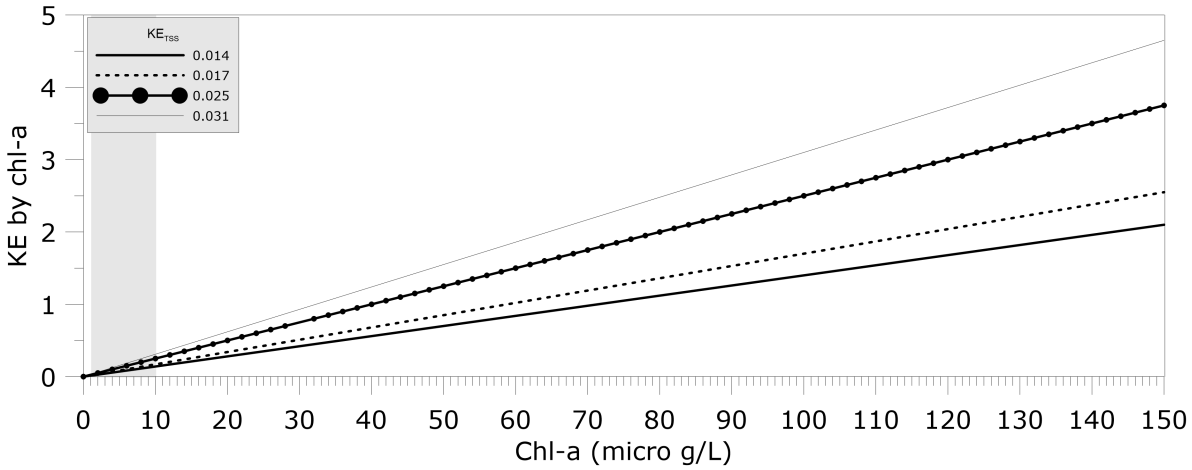

<그림 2.4> Chl-a 농도에 의한 소광 변화

④ 유속 영향

조류 성장률과 유속간의 관계와 관련된 선행 연구에 따르면 유속은 조류 성장률에 영향을 미치며, 최적 성장 유속은 4 cm/s로 제시된 바 있다 (Long et al., 2011). 이는 연구지역에 따라 변화하며 임계 유속은 4.1 ~ 5.3 cm/s의 범위를 보인다 (Mitrovic, 2003).

흐름조건은 성층의 형성·파괴와 수온 변화, 체류시간 변화 등 수리적인 조건에 영향을 미쳐 조류성장에 간접적인 영향을 준다. 대형 부착조류가 강한 흐름에서 탈리되어 하류로 제거되는 직접적인 영향을 미치는 경우도 있으나 부유성 조류의 경우 유속에 따른 수리환경 변화에 의한 간접적인 영향을 받는다. 따라서 수리적인 특성들을 합리적으로 반영한다면 이에 영향을 받는 조류도 합리적으로 재현 및 예측될 수 있다.

⑤ 체류시간 영향

임계유속 연구가 수행된바 있는 호주도 우리나라와 같이 강수량의 계절변화가 있으나 변화정도는 우리나라와 달리 크지 않아 건기와 우기의 월강수량 차이가 3배 미만이므로 국내와는 다른 수리적 환경이 형성된다. 따라서 국내 하천환경에서는'유속증가→성층파괴→세포수 감소→임계유속 산정'일련의 과정을 호주와 동일하게 적용하기 어렵다. 기존 호주 연구사례에서도 기후특성을 고려해야 한다고 제시된 바 있다.

과거 남조류 세포수 모니터링 자료에서도 알 수 있듯이 홍수에 의한 flushing 직후 남조류 세포수가 감소한 상태에서는 약한 유속에서도 적은 남조류 세포수가 나타나고, 낙동강 전 구간에 걸쳐 남조류 세포수가 높아진 상황에서는 유속이 다소 강해지더라도 홍수량에 해당하는 유속이 아닐 경우 남조류 세포수는 높게 유지되어 성층 유무에 의한 영향은 적다. 남조류가 성장하기 시작하는 시기에는 성층강도, 수온 등 수리적 특성에 영향을 크게 받지만 이미 대상 하천에 남조류 세포수가 전반적으로 크게 증가한 상태에서는 성층이 약해져도 남조류 세포수가 일정수준 이상으로 유지될 수 있기 때문이다.

또한 동일한 보 구간에서도 유속은 하폭에 따라 다르고 동일한 단면에서도 중심부와 가장

자리가 다르며 표층과 저층이 달라 구간별 대표유속을 정의하기가 어렵다.

하계 성층이 거의 나타나지 않은 2017년은 강우량이 많았던 8월을 제외하면 남조류세포수가 6,7,9,10월 모두 월평균 10,000 cell/mL 이상이며 성층이 강했던 2016년보다도 많이 나타났다 <그림 2.5, 2.6> (국립환경과학원, 2017). 국립환경과학원(2019)은 죽산보와 달성보에서 센서로 측정된 Chl-*a* 농도와 체류시간을 비교하였다. 죽산보에서는 체류시간이 16일 이상일 때 Chl-*a* 최고농도가 가장 높았으며, 달성보의 경우 체류시간 5일 이상일 때 Chl-*a* 최고농도가 가장 높았다. 체류시간과 Chl-*a* 농도 비교결과 체류시간이 길수록 표층 Chl-*a* 최고 농도가 증가하며, 달성보보다 죽산보에서 체류시간 영향이 더 크게 나타났다 <그림 2.7>.

성층파괴를 통한 남조류 세포수 감소의 효과는 뚜렷하지 않고, 유속은 공간적 변동특성이 크기 때문에 남조류 침강 임계유속을 정의하는 것은 쉽지 않다. 따라서 유속이 아닌 체류시간 개념을 적용할 필요가 있다. 유속은 점 개념이지만 체류시간은 3차원 공간개념으로 보 구간 대표성이 있고 남조류 세포수 제어를 위해 보구간 유속을 제어하는 것보다 체류시간을 제어하는 것이 더 현실적이므로 향후 이에 대한 검토가 필요하다. **유속 증가에 의한 성층파괴와 그로 인한 남조류 수직혼합은 수리적인 개념이지만 체류시간 제어는 남조류 성장에 필요한 시간을 짧게 단축시키는 것으로 생지화학적 반응에 대한 개념이다. 또한 보 구간별 체류시간은 수자원공사에서 제공하는 보별 수용적과 방류량 자료를 사용하여 산정 가능하다.**

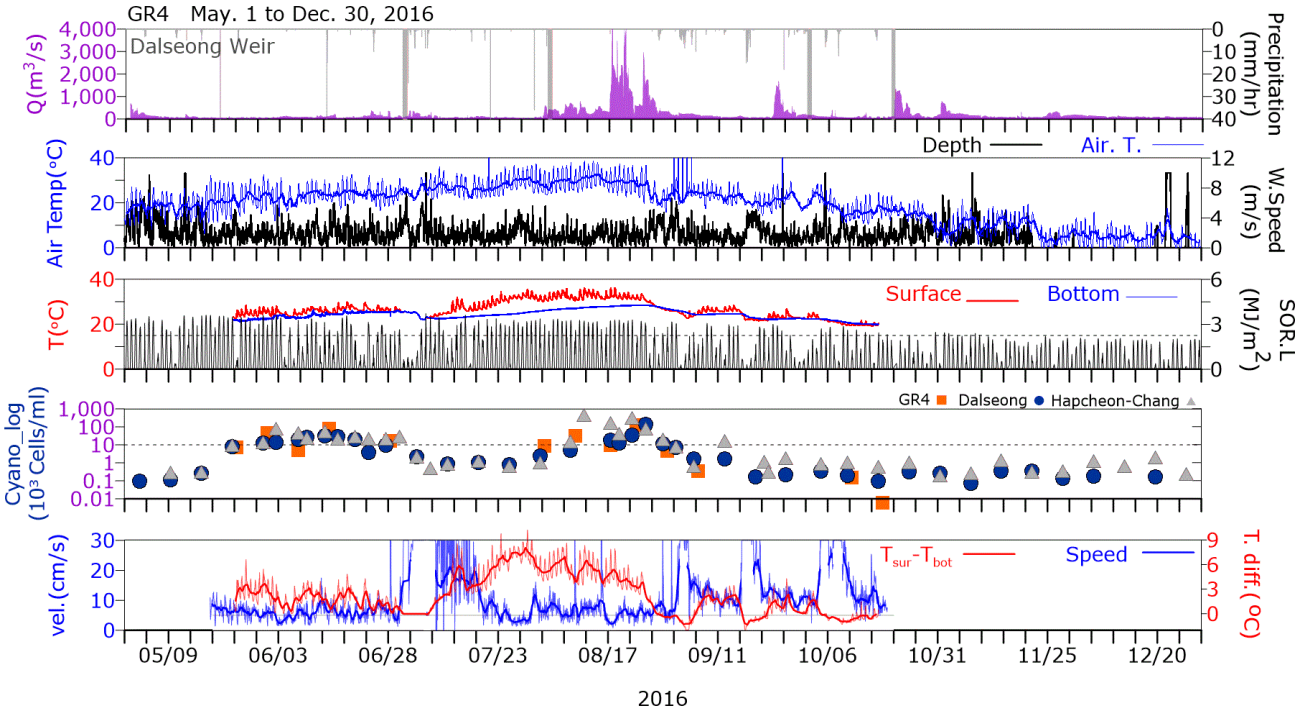

<그림 2.5> 남조류 세포수와 수리환경인자 시계열 (국립환경과학원, 2017).

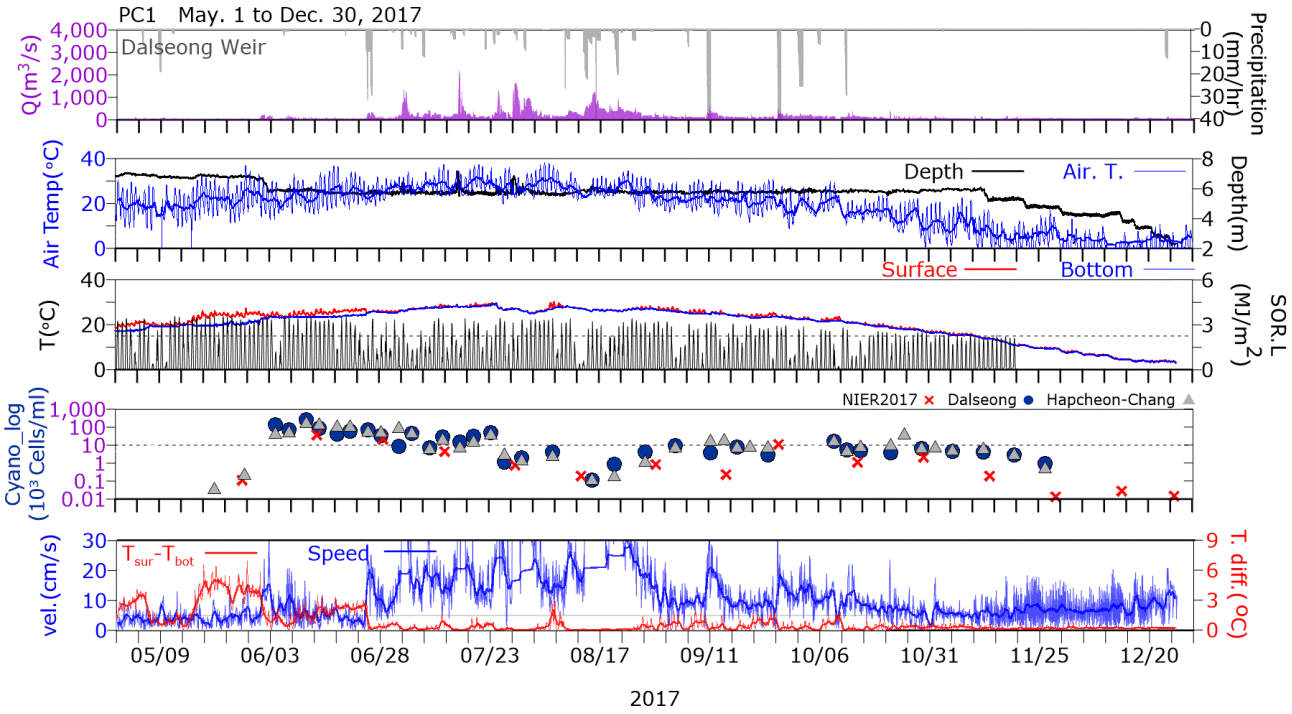

<그림 2.6> 남조류 세포수와 수리환경인자 시계열 (국립환경과학원, 2017).

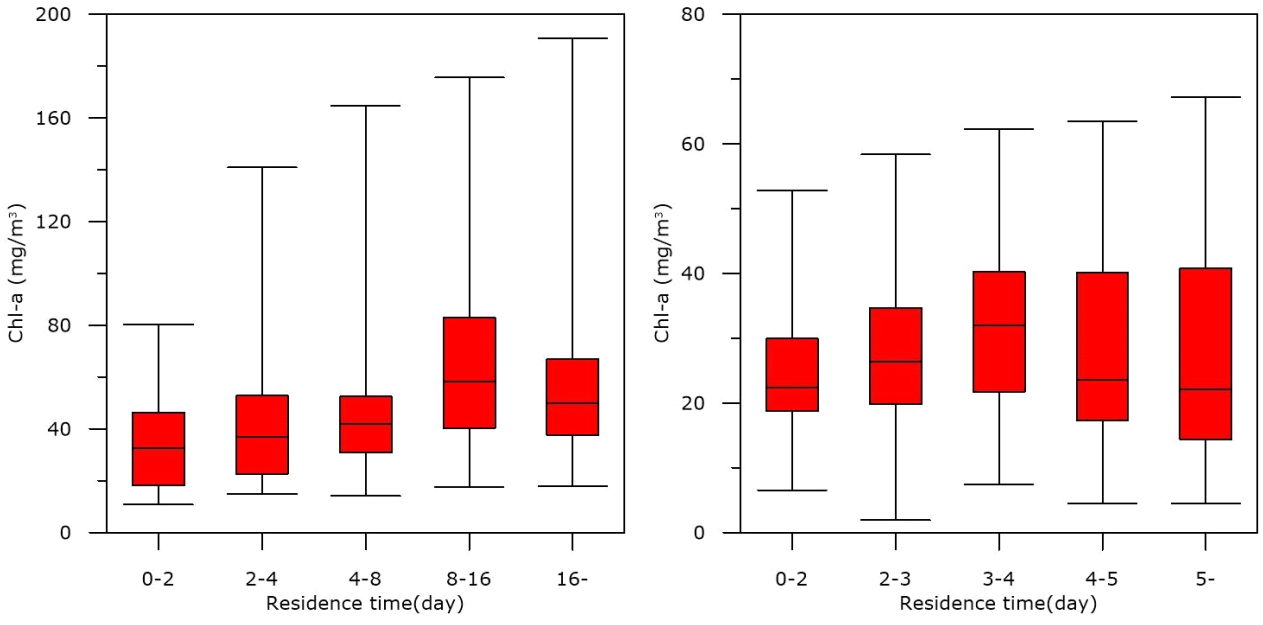

(a) 죽산보 (b) 달성보

<그림 2.7> 체류시간별 Chl-*a* 농도 (국립환경과학원, 2019).

⑥ 염분 영향

담수성 조류가 염분 변화에 노출되는 경우 세포 수준에서의 삼투압 스트레스와 이온 불균형이 발생한다. 담수종은 세포 내 이온 농도가 주변 환경보다 높기 때문에, 염분이 증가하면 물이 세포 밖으로 유출되고 세포의 삼투압 균형이 깨지게 된다. 이러한 삼투압 스트레스를 극복하기 위해 플랑크톤은 에너지 소모를 늘려 세포 내 이온 농도를 조절해야 한다. 이는 호흡률 증가로 이어져, 결과적으로 광합성이나 성장을 위한 에너지 사용을 제한하는 '에너지 예산(energy budget)'의 교란을 유발한다(Parthasarathi, et al., 2011). 염분이 특정 농도 이상으로 증가하는 경우 더 이상 유지되지 못하고 사멸한다 <그림 2.8>. 해양성 조류도 적정염분보다 낮은 염분환경에 노출되는 경우 마찬가지 특성을 갖는다.

조류에 대한 염분 영향은 최근 하굿둑 개방 이슈에 대한 기술적 대비를 위해서 검토할 필요가 있다. 하굿둑 개방시 예상되는 염수유입으로 인하여 하구호 수역이 기수역으로 변화하는 경우 담수성 남조류를 비롯한 조류들이 영향을 받게 된다. 해수를 따라 유입되는 해수성 조류도 저염 또는 담수환경에서 성장에 영향을 받는다. 그러나 국내에서 담수호가 기수호로 변경된 사례가 많지 않고 인공지능 모델을 구축할 정도로 충분한 양의 자료가 축적된 사례는 더욱 적다.

(a) 담수 조류 종

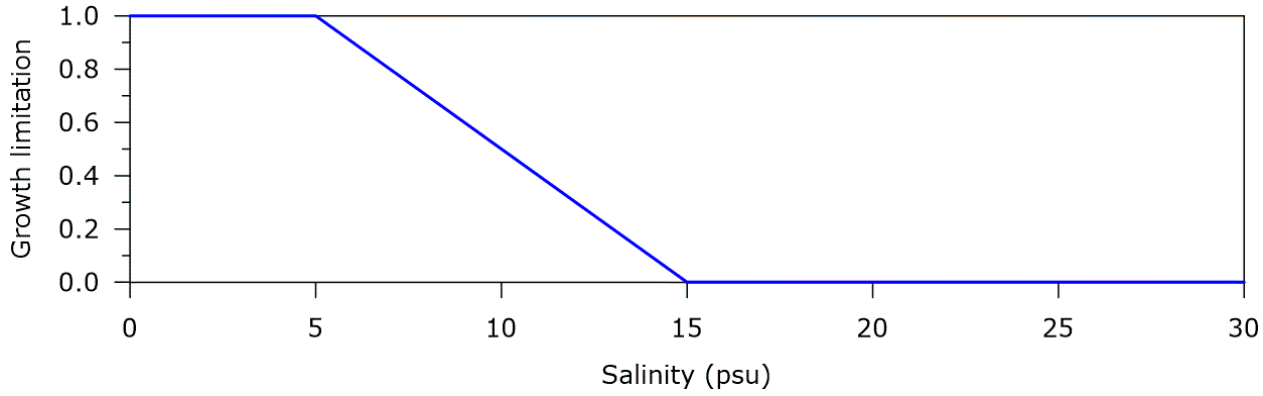

(b) 해수 조류 종

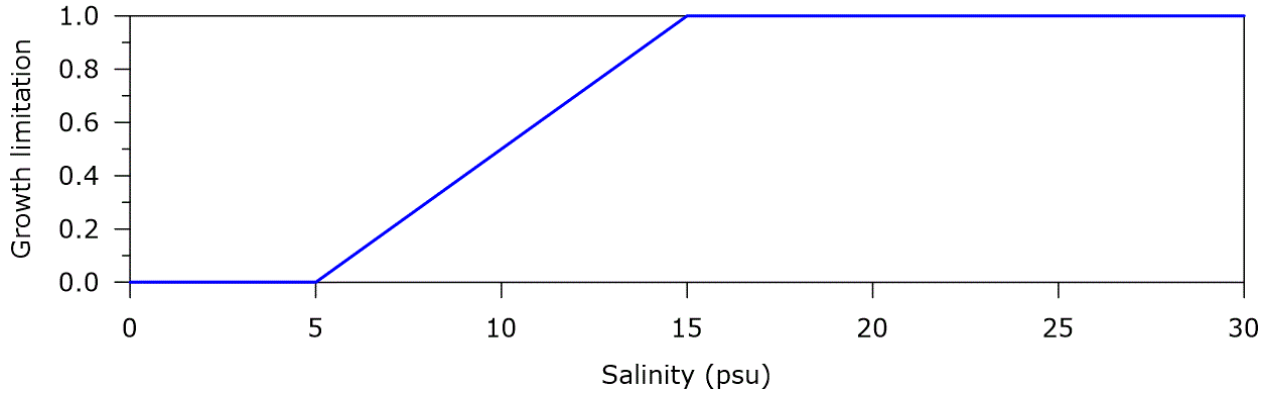

<그림 2.8> 염분에 따른 성장률 제한 (국립환경과학원, 2020).

참고문헌

- 국립환경과학원, 2017. 남조류 거동 해석을 위한 하천 수리학적 특성 조사 연구.
- 국립환경과학원, 2019. 보구간 센서기반 연속 수질 모니터링(Ⅱ).
- 국립환경과학원, 2020.새만금유역 2단계('11~'20) 수질개선종합대책 종합평가 최종보고서.
- 권대률, 2015. 온도와 광도에 따른 남조류 성장과 부력 및 지오스민 생산 특성. 건국대학교.
- 김진휘, 이한규, 이정원, 박용은, 신재기, 2020. 기계학습을 활용한 하천에서의 유해조류 대발생 예측 및 합성 데이터를 통한 모델 정확도 개선. 대한상하수도학회·한국물환경학회 공동학술발표회 발표논문 2020권 1-1.
- 유경아, 변명섭, 윤석제, 황순진, 류덕희. 2013. 북한강 수계에서 이취미를 유발하는 남조류 (Anabaena spiroides)의 증식 특성. 한국하천호수학회지. 46.1:135-144.
- Alexei Solovchenko, Olga Gorelova, Olga Karpova, Irina Selyakh, Larisa Semenova, Olga Chivkunova, Olga Baulina, Elizaveta Vinogradova, Tatiana Pugacheva, Pavel Scherbakov, Svetlana Vasilieva, Alexandr Lukyanov, Elena Lobakova, 2020. Phosphorus Feast and Famine in Cyanobacteria: Is Luxury Uptake of the Nutrient Just a Consequence of Acclimation to Its Shortage?. Cells. 2020 Aug 21;9(9):1933. doi: 10.3390
- Horne A.J. and Goldman C.R. 1994. Limnology. McGraw-Hill, Inc., New York. 576.
- Kong F. X., Gao G., 2005. Hypothesis on cyanobacteria bloom-forming mechanism in large shallow lakes, allelopathy. Acta Ecol. Sin. 25: 589-595.
- Kim, JW., Kim, HT., Kim KH., Ahn JM., 2024. Assessing the Applicability of Deep-Learning Method for Predicting Cyanobacteria in a Regulated River. Journal of Environmental Engineering. Volume 150, No.5.
- Li, F., Zhang, H., Zhu, Y., Xiao, Y., Chen, L., 2013. Effect of flow velocity on phytoplankton biomass and composition in a freshwater lake. Science of The Total Environment 447, 64–71.
- Li, M., Zhu W., Guo, L., Hu, J., Chen, H., Xiao, M., 2016. To increase size or decrease density? Different Microcystis species has different choice to form blooms. Scientific Reports 6, 37056.
- Long, T., Wu L., Meng, G., Guo, W., 2011. Numerical simulation for impacts of hydrodynamic conditions on algae growth in Chongqing Section of Jialing River, China. Ecological Modelling, 222:112–119.
- Mitrovic, S.M., Oliver, R.L., Rees, C., Bowling, L.C., Buckney, R.T., 2003. Critical flow velocities for the growth and dominance of Anabaena circinalis in some turbid freshwater rivers. Freshwater Biology, 48:164–174.

- Parthasarathi Chakraborty, Tamoghna Acharyya, P. V. Raghunadh Babua and Debasmita Bandyopadhyaya, 2011. Impact of salinity and pH on phytoplankton communities in a tropical freshwater system: An investigation with pigment analysis by HPLC. Journal of Environmental Monitoring 13(3). 614-20.
- Salmaso, N., Braioni, M.G., 2008. Factors controlling the seasonal development and distribution of the phytoplankton community in the lowland course of a large river in Northern Italy (River Adige). Aquat, Ecol, 42:533–545.
- Takamura, N., Iwakuma, T., and Yasuno, M., 1985. Photosynthesis and primary production of Microcystis aeruginosa Kütz in Lake Kasumigaura. J. Plankton. Res. 7: 303-312.
- Vidal, J., Marce, R., Serra, T., Colomer, J., Rueda, F., Casamitjana, X., 2012. Localized algal blooms induced by river inflows in a canyon type reservoir. Aquat Sci., 74:315–327.

A-4. 수질·녹조 예측 AI 알고리즘 개량 검토·제언

작성자: 국립공주대학교 안국현 교수

제 1 장 서 론

1.1 자문내용 및 범위

본 자문보고서는 수질 및 녹조 예측을 위한 AI 알고리즘의 개량 가능성을 검토하고, 시계열 예측 성능 향상을 위한 학습 알고리즘 개선 방안을 제언하는 것을 목적으로 한다. 이를 통해 홍수, 가뭄, 녹조 등 극한 사상 예측에서 발생하는 첨두값 과소평가 문제의 원인과 해결 방안을 제시하고자 한다.

1.1.1 주요 자문내용

본 자문에서 다루는 주요 내용은 다음과 같다.

1. Curriculum learning 기반 알고리즘 필요성 논의
- 기존 시계열 예측 모델의 한계와 극한 사상 예측에서 발생하는 문제점 분석
- Curriculum Learning 도입의 필요성 및 기대 효과 설명

2. Curriculum learning 기반 알고리즘 방법론 설명
- 학습 난이도 조절을 통한 점진적 학습 구조 제안
- 시계열 데이터 특성에 맞는 커리큘럼 설계

3. Curriculum learning 기반 알고리즘 적용 사례 및 평가
- 적용 사례 소개
- 예측 정확도 및 첨두값 재현성 개선 효과 분석

4. Curriculum learning 기반 알고리즘 예시 코드 제시
- 구현 예시 코드 제공

제 2 장 Curriculum learning 기반 기술 및 활용방안

2.1 Curriculum learning 기반 알고리즘

본 절에서는 Curriculum learning 기반 알고리즘의 개요(Section 2.1.1)와 함께 대표적인 방법론(Section 2.1.2)들을 제시한다.

2.1.1 Curriculum learning 개요

1) 서론

최근 딥러닝(DL)과 머신러닝(ML)을 포함한 데이터 기반 모델은 다양한 과학 분야에서 빠르게 확산되고 있다(Bengio et al., 2017; Mont´ans et al., 2019; Shen, 2018). 수문학 분야에서도 시계열 모델은 강우-유출 모형(Herath et al., 2021; Kratzert et al., 2019b; Lee and Ahn, 2021), 토양 수분 예측(Fang and Shen, 2020; Li et al., 2021), 수질 평가(Wan et al., 2022), 지하수 관리(Vu et al., 2021; Zhan et al., 2024), 강수 예측(Liu et al., 2022; Xiong et al., 2021) 등 다양한 연구 과제에 활용되고 있다.

특히, 순환 신경망(RNNs)(Cai et al., 2024; Jiang et al., 2022; Yoon and Ahn, 2024), 합성곱 신경망(CNNs)(Dehghani et al., 2023; Shu et al., 2022), 인코더-디코더 네트워크(Lin et al., 2020), 트랜스포머(Lee and Ahn, 2024; Yin et al., 2023) 등 여러 DL 구조가 도입되었으며, 이 외에도 다양한 아키텍처가 연구되고 있다. 수문학은 DL 모델을 비교적 일찍 도입한 분야 중 하나이지만, 관련 기법은 현재까지도 빠르게 발전하고 있다(Shen and Lawson, 2021). 본 보고서는 이러한 배경 속에서 시계열 DL 모델의 학습 과정에 새로운 샘플링 전략을 도입하여, 수문학 분야에서 최첨단 기법으로 인정받는 DL 모델의 예측 성능 향상을 목표로 한다(Nearing et al., 2021).

2) 인간 학습과 커리큘럼 러닝

인간 학습의 중요한 특징 중 하나는 교육과정(curriculum)의 체계적 구성이다. 일반적으로

학습은 기초 개념에서 시작하여 점진적으로 복잡한 개념으로 확장된다. 예를 들어, 대학에서 미적분을 학습하기 전에는 초등학교에서 기본 산술을, 중학교에서 함수 개념을, 고등학교에서 미분 개념을 순차적으로 습득한다.

DL 모델 개발은 인간 학습에서 많은 영감을 받아왔으나, 기존 DL 알고리즘은 학습 샘플을 무작위로, 동일한 확률로 모델에 제공하는 방식을 주로 사용한다. 이러한 균등 샘플링 방식은 데이터 샘플 간의 난이도 차이나 복잡성을 고려하지 못하며, 모델의 현재 학습 상태를 반영하지 못한다는 한계를 가진다.

이러한 한계를 극복하기 위한 접근으로 커리큘럼 러닝(CL: Curriculum Learning) 기반 학습 전략이 제안되었다. 커리큘럼 러닝은 난이도가 낮은 데이터에서 시작하여 점차 복잡한 데이터를 학습하도록 설계함으로써 모델의 학습 효율성과 예측 성능을 동시에 향상시킬 수 있는 방법론이다.

3) 커리큘럼 러닝(CL) 개념 및 적용 필요성

커리큘럼 러닝(CL)의 개념은 Bengio et al.(2009)에 의해 처음 제안되었다. 간단히 요약하면, CL은 “보다 단순한 데이터로 학습을 시작하여 점진적으로 어려운 데이터로 나아가는 학습 과정”을 의미한다. 이 개념은 Elman(1993)이 언급한 “단순성에서 시작하기(beginning with simplicity)” 원리에 기반하며, 본 연구에서는 이를 easy-first mode라 지칭한다. 즉, 머신러닝 모델은 처음에는 비교적 난이도가 낮은 데이터 부분집합(또는 단순한 하위 과업)으로 학습을 시작하고, 이후 점차 데이터(또는 과업)의 난이도를 높여 최종적으로 전체 학습 데이터셋을 포함하도록 설계된다.

이와 같은 기초 연구는 다양한 연구자들에게 영감을 주었으며, 여러 응용 분야에서 CL 전략을 탐구하는 계기가 되었다(Graves et al., 2017; Hacohen and Weinshall, 2019; Platanios et al., 2019; Tang et al., 2018). 그러나 이러한 연구들에서 제시된 실증적 결과에 따르면, CL 기반 학습 전략은 일부 사례에서는 효과적이었으나 모든 경우에 일관되게 성공하지는 않았다. 이는 시계열 DL 모델에 CL을 적용할 때 그 효과가 과업 특성에 따라 달라진다는 점을 시사한다. 이러한 맥락에서 CL 전략은 의학 분야(Guo et al., 2022) 등 일부 과학 분야에서 적용되었으나, 수문학을 포함한 대부분의 분야에서는 아직 널리 도입되지 않았다. 따라서 수문학 연구에서 학습 샘플링 전략이 실제로 성과를 제공할 수 있는지 규명하는 것은 의미 있는 연구 과제이며, 본 연구의 주요 목적 중 하나이다. 또한, 학습 샘플링 전략은 수문학 분야에서 아직 공식적으로 도입된 바가 없다는 점에서 본 보고서의 학술적 가치가 더욱 크다.

4) 연구 범위 및 방법론

본 보고서에서는 시계열 DL 모델을 활용하여 수문학 과업에서 학습 샘플링 전략이 미치는 효과를 규명하는 것을 목적으로 한다. 구체적으로는, 유역 출구 지점에서 관측된 유량 자료를 이용하여 강우-유출 관계를 모델링하는 데 초점을 두었다(Emmanuel et al., 2015; Mohammadi, 2021).

2.1.2 학습 샘플링 전략의 정의적 진화에 대한 역사적 고찰

머신러닝 분야에서 학습 샘플링 전략은 상당한 진화를 거쳐 발전해 왔다. 이러한 발전 과정은 두 가지 주요한 단계로 구분할 수 있다.

1) 원래의 정의: 커리큘럼 러닝(CL)

Bengio et al.(2009)은 커리큘럼 러닝을 제안하면서, 학습 과정에서 데이터 샘플의 복잡성을 점진적으로 증가시키는 방법론을 정립하였다. 그 정의는 다음과 같다.

정의 1. 원래의 커리큘럼 러닝

모델 $f(\bullet)$는 전체 학습 과정에서 N 단계의 학습 샘플 시퀀스 $S = \langle S1, S2, \cdots, Sn, \cdots, SN \rangle$ 에 기반하여 학습된다. 각 단계 Sn은 목표 학습 분포 P(z)의 재가중(reweighting)으로 정의되며, 다음과 같은 조건을 만족한다.

(1) 학습 분포의 정보량 $I(\bullet)$ 은 점진적으로 증가한다. 즉, $I(Sn) < I(Sn+1)$.

(2) 모든 학습 샘플의 가중치는 점차 증가한다. 즉, $Wn(z) \leq Wn+1(z), \forall z \in D$.

(3) 최종적으로 $SN(z) = P(z)$.

위 정의에서 조건 (1)은 학습 집합의 다양성과 정보량이 점진적으로 확장되어야 함을 의미한다. 이는 이후 단계에서 약간 더 어려운 샘플을 추가하여 학습 분포를 조정함으로써 달성된다. 조건 (2)는 점진적으로 더 많은 관련 학습 샘플을 포함시켜 학습 집합의 크기를 확대함을 의미한다. 조건 (3)은 최종적으로 모든 학습 샘플이 균등하게 재가중되어 전체 학습 집합을 대상으로 학습이 이루어짐을 뜻한다.

이 정의는 비볼록 최적화에서 널리 알려진 연속법(continuation method)의 일환으로 볼 수 있다(Allgower and Georg, 2003). 즉, 최적화가 용이한 단순한(또는 평활한) 목적 함수를 먼저 설정한 후, 학습이 진행됨에 따라 가중치 Wn(z)를 조정하여 이진적 인스턴스 선택(Olvera-López et al., 2010) 또는 연속적 예제 재가중을 수행함으로써 학습의 수렴 속도를 높이거나 일반화 성능을 개선하는 접근이다. 이러한 관점은 연구자들로 하여금 원래의 CL 정의에서 제시된 세 가지 조건 중 하나 이상을 완화하여 새로운 개념을 도입하는 계기를 제공하였다.

2) 일반화된 정의: 샘플링 전략의 확장

정의 2. 일반화된 샘플링 전략

정의 1의 세 가지 조건을 모두 제거할 경우, 학습 전략은 N 단계에 걸쳐 목표 학습 분포의 일련의 재가중으로 전환된다. 이 정의는 각 학습 단계에서 동적으로 선택된 학습 기준 Sn을 포함하는 보다 일반화된 형태이다.

여기서 Sn은 단순한 샘플 가중치뿐만 아니라, 샘플, 과업, 모델 복잡성, 목적 함수 등 학습과 관련된 모든 요소를 포함한다.

흥미롭게도, 머신러닝 분야에서는 원래의 CL과 반대되는 방식의 샘플링 전략도 존재한다. 예를 들어, 난이도가 높은 샘플에 우선적으로 높은 가중치를 부여하는 “hard-first mode”에서는 성능 향상이 기대될 수 있다(Wang et al., 2019). 또한, Hard Example Mining (HEM)이라 불리는 연구 분야에서는 각 학습 반복에서 가장 어려운 샘플을 선택하여 과적합을 방지하는 전략이 제안되었다(Jesson et al., 2017; Zhou et al., 2020).

이러한 일반화된 정의는 손실 가중치 조정(Wu et al., 2018), 모델 용량 확장(Sinha et al., 2020)등과 같은 추가적 방법론을 통해 지속적으로 발전하고 있다.

2.1.3 강우-유출 모형 LSTM 모형 소개

시계열 모델링에서는 자기회귀(autoregressive) 모델이나 순환신경망(RNN)과 같은 순환 구조가 일반적으로 사용된다. 본 연구에서는 이러한 맥락에서 가장 널리 활용되는 장단기 메모리(Long Short-Term Memory, LSTM) 구조(Hochreiter and Schmidhuber, 1997)를 채택하였다. LSTM은 게이팅(gating) 메커니즘을 도입하여 정보 흐름을 효과적으로 제어하며, 장기 의존성 문제를 완화하고 장기간의 시간 구간에 걸쳐 정보를 유지할 수 있도록 한다.

1) LSTM 구조

LSTM 유닛은 메모리 셀(memory cell), 입력 게이트(input gate), 출력 게이트(output gate), 망각 게이트(forget gate)로 구성된다.

- 메모리 셀은 시간적 정보를 저장하며, 각 게이트는 입력, 유지, 출력 흐름을 조절한다.
- 입력 게이트는 새로운 데이터가 메모리 셀로 유입되는 정도를 제어한다.
- 망각 게이트는 기존 정보를 유지할지 삭제할지를 결정한다.
- 출력 게이트는 저장된 정보를 외부 네트워크로 전달하는 역할을 한다.

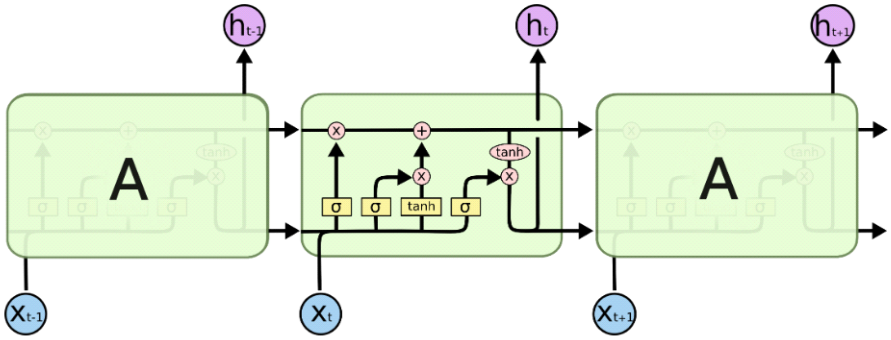

<그림 2.1> LSTM 모형의 모식도

본 연구에서 사용된 모델은 다음과 같이 구성된다.

1. 입력 임베딩 레이어(input embedding layer): 안정화된 드롭아웃(dropout) 적용
2. 1-계층 LSTM
3. 회귀(regression) 레이어

입력 데이터 $X \in R^{(T \times D)}$ 는 T 길이의 시퀀스로, 각 시점 t에서의 특징 벡터로 표현된다. 시간 t에서의 회귀 출력 y_t는 다음과 같이 계산된다.

$$
\begin{aligned}
e_t &= D(\mathrm{GELU}(W_e x_t + b_e)) \\
i_t &= \sigma(W_i e_t + U_i h_{t-1} + b_{ih}) \\
f_t &= \sigma(W_f e_t + U_f h_{t-1} + b_{fh}) \\
g_t &= \tanh(W_g e_t + U_g h_{t-1} + b_{gh}) \\
o_t &= \sigma(W_o e_t + U_o h_{t-1} + b_{oh}) \\
c_t &= f_t \odot c_{t-1} + i_t \odot g_t \\
h_t &= o_t \odot \tanh(c_t) \\
y_t &= w_y^T D(h_t) + b_y
\end{aligned}
$$

<식 1>

여기서 i_t, f_t, g_t, o_t 는 각각 입력, 망각, 셀, 출력 게이트를 의미하며, c_t, h_t는 셀 상태(cell state)와 은닉 상태(hidden state)를 나타낸다. D(·) 는 드롭아웃 연산자, GELU(·) 는 Gaussian Error Linear Units 함수(Hendrycks and Gimpel, 2016)를 의미한다.

모델 파라미터에는 W_e, b_e, We, Uh, bh, w_y, b_y*가 포함되며, 주요 하이퍼파라미터는 T = 270, D = 27, H = 256이다. 또한 순환 가중치는 직교(orthogonal) 초기화 되었으며, 망각 게이트의 바이어스는 1로 설정되었고, 드롭아웃은 0.4로 적용되었다. 각 입력 시퀀스 X에 대해 최종 출력은 마지막 시점 T에서의 회귀 결과 y_T로 산출된다.

2) 모델 최적화

모델 최적화에는 평균제곱오차(Mean Squared Error, MSE)를 손실 함수로 사용하였다. 손실 함수는 다음과 같이 정의된다.

$$
l_i = (y_i - \hat{y}_i)^2
$$

<식 2>

여기서 l_i는 i-번째 학습 샘플 시퀀스에 대한 손실이며, y_i는 모델의 예측값, $\hat{y}_i$는 해당 입력 시퀀스에 대한 실제 관측값(정답 레이블)을 의미한다.

2.1.4 Curriculum learning 방법론 소개

본 연구의 탐색은 SuperLoss에 기반하며, 이는 easy-first 가중치 모드를 적용한다. 즉, 상대

적으로 학습이 용이한 샘플에 더 높은 가중치를 부여하는 방식이다.

1) SuperLoss

SuperLoss(SL)는 학습 샘플에 대해 동적으로 가중치(신뢰도, confidence)를 부여하는 커리큘럼 러닝 기법으로, 과업(task) 비종속적이고 신뢰도 기반(confidence-aware)의 손실 함수이다. 이 방법은 기존의 과업 특화 손실 함수에 SL을 결합하여, 해당 샘플의 손실값으로부터 신뢰도를 산출하는 방식으로 동작한다.

본 연구에서 사용된 경우, i-번째 학습 샘플의 평균제곱오차(Mean Squared Error, MSE)를 l_i라 할 때, SL은 다음과 같이 정의된다.

$$M_{SL}(l_i) = (l_i - \tau)\sigma_i + \lambda(\log \sigma_i)^2 \qquad \text{<식 3>}$$

여기서,
- $\sigma_i > 0$: i-번째 학습 샘플의 신뢰도(가중치)
- τ : 손실 기준값(threshold)으로, 샘플을 쉬운 샘플($l_i < \tau$)과 어려운 샘플($l_i > \tau$)로 구분
- $\lambda > 0$: 정규화 하이퍼파라미터

본 연구에서는 τ를 지금까지 계산된 손실의 이동평균(running average)으로 설정하였다. 학습 반복 ϕ 단계에서 임계값 τ_ϕ는 다음과 같이 갱신된다.

$$\tau_\phi = \alpha\tau_{\phi-1} + (1-\alpha)\tau \qquad \text{<식 4>}$$

여기서 α는 평활화(smoothing) 하이퍼파라미터이며, τ는 ϕ-번째 반복에서의 샘플 손실 평균이다. 본 연구에서는 $\alpha = 0.9$, $\lambda = 0.25$, $\tau 0 = 0.5$로 설정하였다.

SL에서 i-번째 샘플의 신뢰도 σ_i는 샘플 손실 l_i로부터 직접 도출된다. 최적화의 목표는 $M_{SL}(l_i)$를 최소화하는 것이므로, 최적 신뢰도 σ^*i는 주어진 l_i에 대해 $M_{SL}(l_i)$를 최소화하는 값이다(이때 l_i는 상수로 간주). 이때, $-2e < \beta_i = (l_i - \tau)/\lambda$ 조건에서 닫힌 해(closed-form solution)가 존재하며, 다음과 같이 표현된다.

$$\sigma_i^*(l_i) = \arg\min_{\sigma_i} M_{SL}(l_i) = e^{-W\left(\frac{1}{2}\max(-2e,\beta_i)\right)} \qquad \text{<식 5>}$$

여기서 $W(\cdot)$는 Lambert W 함수이다. $\beta_i \in (-2e, \infty)$일 때, β_i는 $-W(\beta_i/2)$에 역비례하므로, SL은 손실값이 낮은 샘플(즉, 쉬운 샘플)에 더 높은 가중치를 부여하게 된다.

본 연구에서는 SL을 채택한 이유로, 1) 과업 비종속적 특성을 가져 다양한 분야에 적용 가능하며, 2) 추가 학습 파라미터가 불필요하고, 3) 기존의 과업 특화 손실 함수와의 결합이 용이하며, 4) 파라미터화된 신뢰도 추정 방식이 필요하지 않아 일관성과 수렴성이 보장된다는 점을 들 수 있다. 따라서 SL은 다양한 수문학적 과업에 적용하기에 적합한 방법론으로 평가된다.

2.2 Curriculum learning 기반 기술 활용방안

본 절에서는 Curriculum learning 기반 기술 활용방안(Section 2.2.1)와 함께 적용 예시 코드(Section 2.2.2)들을 제시한다.

2.2.1 유출량 예측 대상 Curriculum learning 적용 사례

1) 실험 설계 및 평가 지표

본 연구에서는 서론에서 제시한 연구 가설을 검증하기 위해 실험을 설계하였다. 실험에서는 원래의 커리큘럼 러닝(CL) 기반 샘플링 전략을 적용하여 강우-유출 모형에 미치는 영향을 평가하였다. 구체적으로, 단순한 데이터 부분집합으로 학습을 시작하여 점진적으로 학습 집합을 확장하는 M_{Easy}전략이, 무작위 샘플링을 적용하는 M_{Rand} 전략과 비교하여 성능상의 이점을 제공하는지 검증하였다.

이를 위해 전체 데이터셋을 활용하여 여러 유역에 걸친 풀링(pooled) 모델을 학습함으로써, 강우-유출 관계에서 보다 일반화된 패턴을 포착하고자 하였다(Gauch et al., 2021; Kratzert et al., 2019a).

또한, 본 실험에서 성능의 견고성을 확보하기 위해 M_{Rand}와 M_{Easy}모델을 동일한 학습 시나리오(4년 학습 시나리오)에서 비교하였다. 이 시나리오에서 학습은 1991년 10월 1일부터 1995년 9월 30일까지 4년간 수행되었으며, 이후 1995년 10월 1일부터 1998년 9월 30일까지 3년간 검증(validation)을 거쳤다. 최종적으로 1998년 10월 1일부터 2008년 9월 30일까지 10년간 평가(testing)를 진행하였다.

각 실험에서 학습된 모델의 성능을 평가하기 위해, 모든 모델은 5개의 무작위 시드(random seed)로 실행되었으며, 결과로 생성된 앙상블(ensemble) 멤버들의 평균 예측값을 사용하였다.

본 연구의 주요 성능 평가 지표는 Kling-Gupta Efficiency(KGE) 계수(Gupta et al., 2009)이다. 본 연구에서 보고된 평가지표는 평가 기간(testing period)을 기준으로 산출되었다.

2) 수문학 과업에서 Curriculum learning 전략 평가

본 절에서는 Curriculum learning 샘플링 전략이 하천유량(streamflow) 예측 성능 향상에 미치는 효과를 평가하였다. 그림 2.2는 평가 기간 동안 KGE의 공간 분포와, M_{Easy}와 M_{Rand}의 성능 차이를 보여준다. 지표 차이의 결과에서 빨간색과 노란색은 M_{Easy}가 M_{Rand}보다 우수한 성능을 나타내며, 파란색은 M_{Easy}가 M_{Rand}보다 열세임을 의미한다. 또한, 그림 2.3는 학습 과정에서 샘플별 난이도(역 신뢰도, $1/\sigma_i$)를 제시하였다. 특히 특정 유역(Gauge ID: 07208500)에 대해 3회, 15회, 60회 학습 시점에서의 난이도를 예시로 제시하였다.

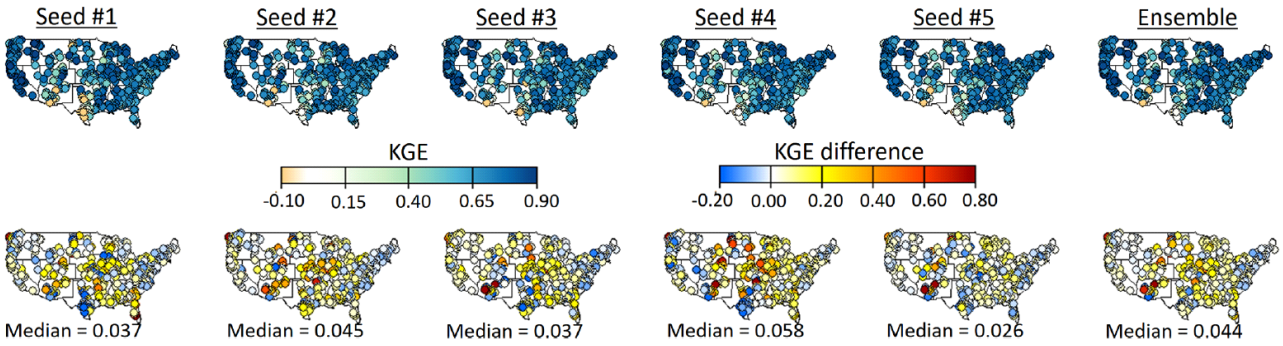

<그림 2.2> (상단) 5개의 무작위 시드 실험에서 M_{Easy}의 KGE 결과와, (우측 끝) 4년 학습 시나리오에서의 평균 모의 결과. (하단) M_{Rand}와 M_{Easy}의 KGE 결과 차이(M_{Easy} - M_{Rand}). 시각화를 용이하게 하기 위해 KGE 차이의 색상 범위는 [−0.2, 0.8]로 제한하였다. 또한, 각 실험별로 모든 유역의 중위수 KGE 차이를 함께 제시함.

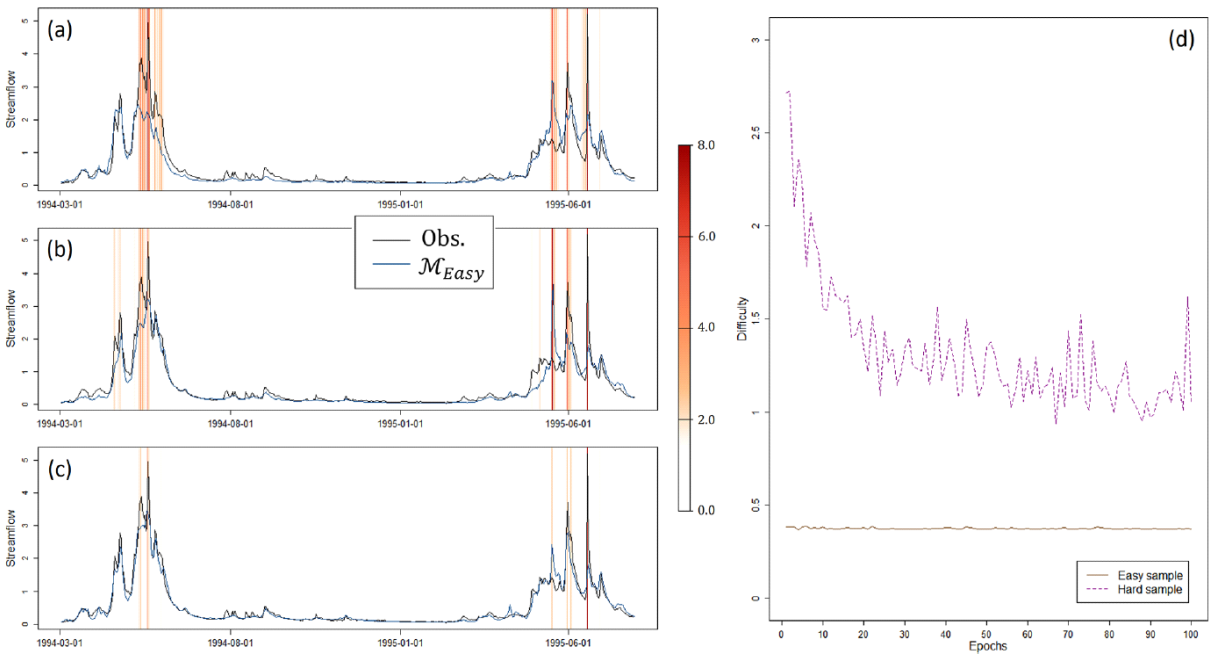

<그림 2.3> 학습 과정에서의 훈련 샘플에 대해 모의된 유출량(파란색 선)과 부여된 난이도(즉, $1/\sigma_i$; 빨간색 음영). 특히, 특정 유역(Gauge ID: 07208500)의 1994년 3월부터 1995년 7월까지 구간을 대상으로, 세 가지 학습 시점에서의 예시를 제시함: (a) 3회, (b) 15회, (c) 60회 학습 시점. 또한, (d)는 학습 과정에서 난이도의 변화 추이를 나타냄. 여기서 hard 샘플과 easy 샘플은 학습 초기 5회 이내에서 난이도가 높고 낮은 샘플로 구분되며, 임의의 기준값(threshold)을 활용하였음.

주목할 점은, 무작위 샘플링 전략과 비교했을 때 Curriculum learning 전략은 모든 무작위 시드와 세 가지 성능 지표에서 일관되게 개선 효과를 보였다는 것이다. 다만, 남부 지역 일부 유역에서는 특정 시드(#1, #4)에서 성능 저하가 두드러졌으나, 다른 시드의 모의 결과로 상쇄되어 앙상블 예측에서는 전반적으로 향상된 성능을 보였다. 이러한 남부 지역의 성능 저하는 해당 지역 유역의 강우-유출 지배 과정이 주요 원인으로 추정된다. 즉, 남부 지역은 여름철 집중 호우에 따른 단순한 유출 과정을 가지는 반면, 적설 해빙 과정을 포함하는 유역에서는 더 복잡한 특성이 반영되기 때문이다. 이는 Easy-First 전략의 효과가 대상 유역의 수문학적 특성에 따라 달라질 수 있음을 시사한다. 다만, 이는 본 연구의 범위를 넘어서는 부분으로, 향후 연구에서 심층적으로 다룰 예정이다.

다음으로, Curriculum learning 샘플링 전략이 학습 과정 전반에서 개별 샘플에 차등적 난이도를 부여하는 방식과 그에 따른 매개변수화(parameterization)에 미치는 영향을 살펴보았다. 그림 2.3a – c는 시간에 따라 변화하는 샘플 난이도와 이에 대응하는 모의 유량을 보여준다. 예를 들어, 그림 2.3a에서 M_{Easy}는 1994년 5월 19일의 유량 기록에 대해 세 시점 모두 난이도

7.31을 할당했는데, 이는 당시 기록이 가장 극단적일 뿐 아니라 모델 입장에서 가장 도전적인 샘플임을 의미한다. 이후 학습이 진행되면서 난이도는 점차 감소하였고, 15회 및 60회 학습 시점에서 모의 유량은 각각 3.21 mm, 3.44 mm로, 실제 관측값(4.06 mm)과의 차이는 줄어드는 경향을 보였다(그림 2.3b, 2.3c). 반대로, 1994년 4월 18일의 경우 초기 난이도는 0.36으로 낮았으나, 15회 학습 시점에서 모의값과 관측값의 차이가 0.93까지 증가하면서 난이도는 1.93으로 상승하였다. 이는 난이도가 학습 과정에서 동적으로 부여되며, 일부 샘플에서는 일시적으로 재상승(rebound)하는 경우도 있음을 보여준다.

그림 2.3d는 학습 전 과정에서 쉬운 샘플 그룹과 어려운 샘플 그룹 간의 난이도 변화를 비교한다. 쉬운 샘플은 초기 한 번의 학습만으로 난이도가 0.5 이하로 수렴한 후 이후에는 거의 변동이 없었다. 반면, 어려운 샘플은 초기 약 2.8에서 20회 학습까지 1.2로 감소한 후, 남은 구간 동안 [0.9, 1.6] 범위에서 변동하였다. 이는 학습이 진행될수록 어려운 샘플이 모델 학습에 더 큰 기여를 하게 되며, 이는 M_{Easy} 전략의 이론적 배경과 부합한다.

종합하면, M_{Easy}는 M_{Rand} 대비 각 샘플에 이질적인 신뢰도(heterogeneous confidence)를 부여함으로써 전반적인 성능 개선 효과를 보였다. 특히, M_{Easy}는 고유량(high flow) 구간에 집중적으로 가중치를 부여하는 특성을 보였는데, 이는 M_{Rand}가 큰 값에 의해 손실 함수가 왜곡되는 문제를 보완하면서 전체 강우-유출 관계를 더 잘 반영하도록 돕는다.

2.2.2 Curriculum learning 예시 코드

본 절에서는 Superloss와 LSTM을 파이썬으로 구현한 코드를 첨부한다.

```
################################## Superloss 예시 코드
import numpy
import torch
from typing import Any, Tuple
from scipy.special import lambertw


class SuperLoss(torch.nn.Module):
    def __init__(self, tau: float = 0.5, lam: float = 1., mom: float = 0.) -> None:
            super(SuperLoss, self).__init__()
```

```
            self.tau = float(tau) # threshold;  running average of input loss;
e.g., log(C) in classification
            self.lam = float(lam) # regulazization hparam;
            self.mom = float(mom) # e.g., 0.9

        def compute_sigma(self, loss: torch.Tensor) -> torch.Tensor:
            loss_numpy = loss.detach().cpu().numpy()

            if self.mom > 0:
                  self.tau  =  (1.  -  self.mom)  *  self.tau  +  self.mom  *
loss_numpy.mean()

            beta = (loss_numpy - self.tau) / self.lam
            z = 0.5 * numpy.maximum(-2. * numpy.exp(-1), beta)

            sig                                                                =
torch.from_numpy(numpy.exp(-lambertw(z).real)).to(device=loss.device)
            return sig

        def forward(self, loss: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor]:

            sigma = self.compute_sigma(loss)
            super_loss = (loss - self.tau) * sigma + self.lam * (torch.log(sigma) **
2)

            return super_loss, sigma




  def          train_rnn_superloss(network:          torch.nn.Module,          loader:
torch.utils.data.DataLoader,  optimizer:  torch.optim.Optimizer,  super_loss_computer:
SuperLoss, epoch: int, device: torch.device, **kwargs: Any) -> None:
        network.train()
```

```
    for batch_idx, (x, y) in enumerate(loader):
            assert x.ndim == 3 and y.ndim == 2
            x = x.to(device)  # (N, T, D)
            y = y.to(device)  # (N, 1)

            optimizer.zero_grad()
            pred = network(x)
            loss = torch.nn.functional.mse_loss(pred, y, reduction='none')

            sl, sig = super_loss_computer(loss)
            sl.mean().backward()

            optimizer.step()

            print(f'₩rEpoch      {epoch:3d}      {numpy.float32(batch_idx+1)      /
numpy.float32(len(loader))  *  100:3.2f}  loss  {loss.detach().mean().tolist():.4f}  sig
{sig.detach().mean().tolist():.4f}', end='')
```

```
############################ LSTM 예시 코드

import torch
import torch.nn as nn
import math
from typing import Any


class LSTM(nn.Module):
    def __init__(
            self,
            input_size: int,
            output_size: int,
            hidden_size: int = 256,
```

```
            num_layers: int = 1,
            input_dropout: float = 0,
            lstm_dropout: float = 0,
            num_regression_layers: int = 0,
            regression_dropout: float = 0,
            bidirectional: bool = False,
            input_proj_size: int = 0,
            lstm_proj_size: int = 0,
            **kwargs: Any
        ) -> None:

            super(LSTM, self).__init__()

            if input_proj_size > 0:
                self.input_proj = nn.Sequential(
                    nn.Linear(input_size, input_proj_size),
                    nn.GELU()
                )

            if 0 < input_dropout < 1:
                self.input_dropout = nn.Dropout(float(input_dropout))

            self.rnn = nn.LSTM(
                input_size=input_size if input_proj_size <= 0 else
input_proj_size,
                hidden_size=hidden_size,
                num_layers=num_layers,
                bias=True,
                batch_first=True,
                dropout=lstm_dropout,
                bidirectional=bidirectional,
                proj_size=lstm_proj_size
            )

            embedding_size = int(
```

```
                hidden_size) if lstm_proj_size <= 0 else int(lstm_proj_size)

        if bidirectional:
                embedding_size *= 2

        _regression = []

        if 0 < regression_dropout < 1:
                _regression.append(nn.Dropout(float(regression_dropout)))

        for i in range(num_regression_layers):
                _regression.append(nn.Linear(embedding_size,      embedding_size,
bias=True))
                _regression.append(nn.GELU())
                if 0 < regression_dropout < 1:
                        _regression.append(nn.Dropout(float(regression_dropout)))

        _regression.append(nn.Linear(embedding_size, output_size, bias=True))
        self.regression = nn.Sequential(*_regression)

        #
        self.init_params()
        self.rnn.flatten_parameters()

    def init_params(self) -> None:
        # rnn
        for m in self.modules():
                if isinstance(m, nn.LSTM):
                        for name, param in m.named_parameters():
                                if 'weight_ih' in name:
                                        nn.init.xavier_normal_(param)
                                elif 'weight_hh' in name or 'weight_hr' in name:
                                        fan_in,              fan_out              =
nn.init._calculate_fan_in_and_fan_out(param)
                                        gain  =  math.sqrt(2.0  /  float(fan_in  +
```

```
fan_out))
                                        nn.init.orthogonal_(param, gain=gain)
                                elif 'bias' in name:
                                        if 'bias_hh' in name:
                                                nn.init.zeros_(param[0])
                                                nn.init.ones_(param[1])
                                                nn.init.zeros_(param[2:])
                                        else:
                                                nn.init.zeros_(param)
                        elif isinstance(m, nn.Linear):
                                nn.init.xavier_normal_(m.weight)
                                if m.bias is not None:
                                        nn.init.zeros_(m.bias)

        def forward(self, input: torch.Tensor) -> torch.Tensor:
                # input: (N, T, D)
                if hasattr(self, 'input_proj'):
                        input = self.input_proj(input)
                if hasattr(self, 'input_drouput'):
                        input = self.input_dropout(input)
                x, _ = self.rnn(input)
                x = x[:, -1]
                x = self.regression(x)

                return x
```

참고문헌

- Allgower, E.L., Georg, K., 2003. Introduction to numerical continuation methods. SIAM.
- Bengio, Y., Louradour, J., Collobert, R., Weston, J., 2009. Curriculum learning. In: Proceedings of the 26th Annual International Conference on Machine Learning, pp. 41–48.
- Bengio, Y., Goodfellow, I., Courville, A., 2017. Deep learning. MIT press Cambridge, MA, USA.
- Cai, H., Shi, H., Zhou, Z., Liu, S., Babovic, V., 2024. Explaining the mechanism of multiscale groundwater drought events: A new perspective from interpretable deep learning model. Water Resour. Res. 60, e2023WR035139.
- Dehghani, A., Moazam, H.M.Z.H., Mortazavizadeh, F., Ranjbar, V., Mirzaei, M., Mortezavi, S., Ng, J.L., Dehghani, A., 2023. Comparative evaluation of LSTM, CNN, and ConvLSTM for hourly short-term streamflow forecasting using deep learning approaches. Ecol. Inform. 75, 102119.
- Elman, J.L., 1993. Learning and development in neural networks: The importance of starting small. Cognition 48, 71–99.
- Emmanuel, I., Andrieu, H., Leblois, E., Janey, N., Payrastre, O., 2015. Influence of rainfall spatial variability on rainfall–runoff modelling: Benefit of a simulation approach? J. Hydrol. 531, 337–348.
- Fang, K., Shen, C., 2020. Near-real-time forecast of satellite-based soil moisture using long short-term memory with an adaptive data integration kernel. J. Hydrometeorol. 21, 399–413.
- Gauch, M., Mai, J., Lin, J., 2021. The proper care and feeding of CAMELS: How limited training data affects streamflow prediction. Environ. Model. Softw. 135, 104926.
- Graves, A., Bellemare, M.G., Menick, J., Munos, R., Kavukcuoglu, K., 2017. Automated curriculum learning for neural networks. In: International Conference on Machine Learning. Pmlr, pp. 1311–1320
- Guo, J., Fialkov´a, V., Arango, J.D., Margreitter, C., Janet, J.P., Papadopoulos, K., Engkvist, O., Patronov, A., 2022. Improving de novo molecular design with curriculum learning. Nat. Mach. Intell. 4, 555–563.
- Gupta, H.V., Kling, H., Yilmaz, K.K., Martinez, G.F., 2009. Decomposition of the mean squared error and NSE performance criteria: Implications for improving hydrological modelling. J. Hydrol. 377, 80–91.
- Hacohen, G., Weinshall, D., 2019. On the power of curriculum learning in training deep

networks. In: International Conference on Machine Learning. PMLR, pp. 2535–2544.
- Herath, H.M.V.V., Chadalawada, J., Babovic, V., 2021. Hydrologically informed machine learning for rainfall–runoff modelling: towards distributed modelling. Hydrol. Earth Syst. Sci. 25, 4373–4401.
- Jesson, A., Guizard, N., Ghalehjegh, S.H., Goblot, D., Soudan, F., Chapados, N., 2017. CASED: curriculum adaptive sampling for extreme data imbalance. In: International Conference on Medical Image Computing and Computer-Assisted InterventionSpringer, pp. 639–646.
- Jiang, S., Zheng, Y., Wang, C., Babovic, V., 2022. Uncovering flooding mechanisms across the contiguous United States through interpretive deep learning on representative catchments. Water Resour. Res. e2021WR030185.
- Kratzert, F., Klotz, D., Herrnegger, M., Sampson, A.K., Hochreiter, S., Nearing, G.S., 2019a. Toward improved predictions in ungauged basins: Exploiting the power of machine learning. Water Resour. Res. 55, 11344–11354.
- Kratzert, F., Klotz, D., Shalev, G., Klambauer, G., Hochreiter, S., Nearing, G., 2019b. Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets. Hydrol. Earth Syst. Sci. 23, 5089–5110.
- Lee, D.-G., Ahn, K.-H., 2021. A stacking ensemble model for hydrological post-processing to improve streamflow forecasts at medium-range timescales over South Korea. J. Hydrol. 600, 126681.
- Lee, D.-G., Ahn, K.-H., 2024. Improving medium-range streamflow forecasts over South Korea with a dual-encoder transformer model. J. Environ. Manage. 368, 122114.
- Li, Q., Wang, Z., Shangguan, W., Li, L., Yao, Y., Yu, F., 2021. Improved daily SMAP satellite soil moisture prediction over China using deep learning model with transfer learning. J. Hydrol. 600, 126698.
- Lin, K., Sheng, S., Zhou, Y., Liu, F., Li, Z., Chen, H., Xu, C.-Y., Chen, J., Guo, S., 2020. The exploration of a temporal convolutional network combined with encoder-decoder framework for runoff forecasting. Hydrol. Res. 51, 1136–1149.
- Liu, J., Xu, L., Chen, N., 2022. A spatiotemporal deep learning model ST-LSTM-SA for hourly rainfall forecasting using radar echo images. J. Hydrol. 609, 127748.
- Mohammadi, B., 2021. A review on the applications of machine learning for runoff modeling. Sustain. Water Resour. Manag. 7, 98.
- Mont´ans, F.J., Chinesta, F., G´omez-Bombarelli, R., Kutz, J.N., 2019. Data-driven modeling and learning in science and engineering. Comptes Rendus M´ecanique 347, 845–855.

- Nearing, G.S., Kratzert, F., Sampson, A.K., Pelissier, C.S., Klotz, D., Frame, J.M., Prieto, C., Gupta, H.V., 2021. What role does hydrological science play in the age of machine learning? Water Resour. Res. 57, e2020WR028091.
- Olvera-L´opez, J.A., Carrasco-Ochoa, J.A., Martínez-Trinidad, J.F., Kittler, J., 2010. A review of instance selection methods. Artif. Intell. Rev. 34, 133–143.
- Platanios, E.A., Stretcu, O., Neubig, G., Poczos, B., Mitchell, T.M., 2019. Competencebased curriculum learning for neural machine translation. ArXiv Prepr. ArXiv190309848.
- Shen, C., 2018. A transdisciplinary review of deep learning research and its relevance for water resources scientists. Water Resour. Res. 54, 8558–8593.
- Shu, X., Peng, Y., Ding, W., Wang, Z., Wu, J., 2022. Multi-step-ahead monthly streamflow forecasting using convolutional neural networks. Water Resour. Manag. 36, 3949–3964.
- Sinha, S., Garg, A., Larochelle, H., 2020. Curriculum by smoothing. Adv. Neural Inf. Process. Syst. 33, 21653–21664.
- Tang, Y., Wang, X., Harrison, A.P., Lu, L., Xiao, J., Summers, R.M., 2018. Attentionguided curriculum learning for weakly supervised classification and localization of thoracic diseases on chest radiographs, in: Machine Learning in Medical Imaging: 9th International Workshop, MLMI 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 16, 2018, Proceedings 9. Springer, pp. 249–258.
- Vu, M., Jardani, A., Massei, N., Fournier, M., 2021. Reconstruction of missing groundwater level data by using long short-term memory (LSTM) deep neural network. J. Hydrol. 597, 125776.
- Wan, H., Xu, R., Zhang, M., Cai, Y., Li, J., Shen, X., 2022. A novel model for water quality prediction caused by non-point sources pollution based on deep learning and feature extraction methods. J. Hydrol. 612, 128081.
- Wang, W., Caswell, I., Chelba, C., 2019. Dynamically composing domain-data selection with clean-data selection by“ co-curricular learning” for neural machine translation. ArXiv Prepr. ArXiv190601130.
- Wu, L., Tian, F., Xia, Y., Fan, Y., Qin, T., Jian-Huang, L., Liu, T.-Y., 2018. Learning to teach with dynamic loss functions. Adv. Neural Inf. Process Syst 31.
- Xiong, T., He, J., Wang, H., Tang, X., Shi, Z., Zeng, Q., 2021. Contextual Sa-attention convolutional LSTM for precipitation nowcasting: A spatiotemporal sequence forecasting view. IEEE J Sel. Top. Appl. Earth Obs. Remote Sens. 14, 12479–12491.
- Yin, H., Zhu, W., Zhang, X., Xing, Y., Xia, R., Liu, J., Zhang, Y., 2023. Runoff predictions in new-gauged basins using two transformer-based models. J. Hydrol. 622,

129684.

- Yoon, S., Ahn, K.-H., 2024. Self-training approach to improve the predictability of datadriven rainfall-runoff model in hydrological data-sparse regions. J. Hydrol., 130862
- Zhan, Y., Guo, Z., Yan, B., Chen, K., Chang, Z., Babovic, V., Zheng, C., 2024. Physicsinformed identification of PDEs with LASSO regression, examples of groundwaterrelated equations. J. Hydrol., 131504
- Zhou, T., Wang, S., Bilmes, J., 2020. Curriculum learning by dynamic instance hardness. Adv. Neural Inf. Process. Syst. 33, 8602–8613.

부록 B 추진성과

<표 1> 전체 연도별 성과계획

성과구분	세부성과지표	계획내용	계획시기		계획건수	
			'24년	'25년	'24년	'25년
R&D 성과확산	학술지 게재 논문 건수	국내 등재 학술지에 논문 게재	12월	12월	1	1
R&D 성과확산	학술회의 발표 건수	국내학회 구두·포스터 발표	5월	5월	2	2
R&D 성과확산	연구개발 관련 홍보 건수	학술잡지 기술기사 기고	9월	-	1	-
R&D 성과확산	기술확산을 위한 상호 교류정도	닥터컨퍼런스/기술세미나/ 심포지움 등 개최	연중	연중	2	2
R&D 성과확산	학회 포상 건수, 학회 임원활동	인공지능 관련 학회 이사/ 연구분과 위원장	연중	-	1	-
지식재산 기술실용화	소프트웨어 등록 건수	인공지능 녹조수질 학습시험, 예측 프로그램 및 소스코드 저작권 등록	-	12월	-	1
경영지원 국제협력	내부 전문가 자문	성과물을 현업에 적용	-	연중	-	1
경영지원 국제협력	내부 및 외부 강의	성과물을 내·외부에 강연한 실적	-	연중	-	1

<표 2> 1차년도 상세 성과 실적

	성과구분	세부성과지표	실적내용	실적 시기	실적 건수
1-1	R&D 성과확산	학술지 게재 논문 건수	국가위기관리학회 Crisisonomy 제21권 2호 1건(게재 예정)	'24.12	1
1-2	R&D 성과확산	학술회의 발표 건수	한국수자원학회 구두발표 1건 대한토목학회 구두발표 1건	'24.05 '24.10	2
1-3	R&D 성과확산	연구개발 관련 홍보 건수	대전세종포럼 기획특집 기고 1건	'24.06	1
1-4	R&D 성과확산	기술확산을 위한 상호 교류정도	수질·녹조 자료 불균형 해소방안 기술세미나 1건 수자원학회 학술발표회 기획세션 개최 1건 K-water연구원-수자원학회 공동 세미나 1건	'24.04 '24.05 '24.10	3(▲1)
1-5	R&D 성과확산	학회 포상 건수, 학회 임원활동	한국수자원학회 분과위원장 활동	'24.01~ '24.12	1
1-6	경영지원 국제협력	내부 및 외부 강의	충남대학교 AI 데이터분석 강연 1건 경북대 대학원 AI 이해와 활용 강연 1건	'24.11	2(▲2)

※ ▲ : 초과실적

<표 3> 2차년도 상세 성과 실적

	성과구분	세부성과지표	실적내용	실적 시기	실적 건수
2-1	R&D 성과확산	학술지 게재 논문 건수	한국수자원학회 1건(게재 예정)	'25.12	1
2-2	R&D 성과확산	학술회의 발표 건수	한국수자원학회 구두발표 1건 한국수자원학회 포스터발표 1건 한국습지학회 구두발표 1건	'25.04 '25.04 '25.08	3(▲1)
2-3	R&D 성과확산	기술확산을 위한 상호 교류정도	수질·녹조 과제 통합 전문가 토론회 개최 1건 물관리 디지털·AI 기술세미나 개최 1건	'25.04 '25.12	2
2-4	지식재산 기술실용화	소프트웨어(S/W) 등록 건수	EDA SOP 프로그램 소프트웨어 등록 1건 Oversampling 프로그램 소프트웨어 등록 1건	'25.11 '25.11	2(▲1)
2-5	경영지원 국제협력	내부전문가 자문	가뭄 상황(영향·피해)조사 관련 상관성분석	'25.07~ '25.09	1
2-6	경영지원 국제협력	내부 및 외부 강의	국립환경과학원 외부 강연 1건 한국하천협회 외부 강연 1건	'25.09 '25.11	2(▲1)

※ ▲ : 초과실적

첨부 **추진성과 증빙자료**

1-1. 국가위기관리학회 Crisisonomy(제21권 2호) 논문 및 게재 확정 증명서 ('24. 12월)

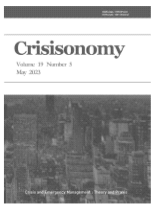

Crisisonomy Vol.19 No.5, 1-119 알맞게 변경
ISSN 2466-1198 (Print) ISSN 2466-1201 (Online) https://doi.org/10.14251/crisisonomy.2023.19.5.1 알맞게 변경
© 2023 Crisis and Emergency Management : Theory and Praxis. All rights reserved.

Crisisonomy

A Study on the Comparison for Deep-learning based Imputations for Green Algae and Water Quality Data

Jewan Ryu[1#,+], Seung Yeon Lee[1], Choong Sung Yi[1], Sung Hoon Kim[1]

[1] AI Research Laboratory, K-water Research Institute, Yuseong-daero, Yuseong-gu, Daejeon, Korea

Abstract

Body

This study investigates various imputation techniques for missing data in green algae and water quality data, comparing traditional and deep-learning methods. Utilizing data from the Daecheong Dam area, four variables—green algae cell count, chlorophyll-a, water temperature, and total phosphorus—were analyzed under artificially induced missing data scenarios. Performance evaluation revealed that for green algae cell counts, NAOMI achieved the lowest RMSE (2039.66) and MAPE (164.55) for short missing periods, while BRITS underperformed for longer gaps. For chlorophyll-a, KNN outperformed other methods with RMSE values as low as 1.89. Linear interpolation excelled for stable variables like water temperature and total phosphorus with RMSEs of 1.15 and 0.0064, respectively. These results underscore the adaptability of advanced models like BRITS and NAOMI in handling complex temporal patterns. Simpler models, such as KNN and linear interpolation, proved sufficient for variables with linear trends or minimal variability. The study emphasizes the importance of aligning imputation strategies with data characteristics to ensure robust water quality predictions.

Key Words: green algae, missing data imputation, BRITS, NAOMI

Ⅰ. Introduction

녹조 현상은 전 세계적으로 심각한 환경문제가 되고 있다. 기후변화로 인한 수온 상승과 산업화에 따른 오염 부하량의 증가로 인해 조류 발생의 빈도와 심도가 매년 확대되고 있으며, 이에 따른 수질 악화와 생태계 교란은 인류에게 지속 가능한 물 관리의 과제를 제기하고 있다(Paerl & Otten, 2013; Smith et al., 1999). 조류는 식물성 플랑크톤이 과다 증식하여 물이 짙은 녹색으로 변하는 현상으로, 이는 영양염류, 수온, 일사량, 체류시간 등 복합적인 요인에 의해 발생한다(Anderson et al., 2002). 조류는 일반적으로 특성에 따라 규조류, 녹조류, 남조류로 구분되며, 특히 남조류 중 독성물질

The 1st author: Je Wan Ryu, Tel. +82-42-870-7340, Fax. +82-42-870-7309, e-mail. ryujw@kwater.or.kr
+ Corresponding author: Je Wan Ryu, Tel. +82-42-870-7340, e-mail. ryujw@kwater.or.kr

1-1. <계속>

사단법인 위기관리 이론과 실천(CEM-TP)

Crisis and Emergency Management: Theory & Praxis

충청북도 청주시 서원구 성봉로 226-1 우리누리터3층 사단법인 위기관리이론과실천 (개신동)

3F Woorinooriter, 226-1, Seongbong-ro, Seowon-gu Cheongju-si, Chungcheongbuk-do, Korea

(TEL) 043-263-2197 (FAX) 043-264-2197

문서번호: CEM-TP 2024-316

시행일자: 2024. 12. 26

수　　신: 류제완박사님(K-water)

참　　조:

제　목 : 「Crisisonomy(한국연구재단 등재지)」제21권 2호 게재 확정 증명

---

1. 귀하의 무궁한 발전을 기원합니다.

2. 본 사단법인 위기관리 이론과 실천(CEM-TP)이 발행하는「 Crisisonomy(한국연구재단 등재지)」제21권 2호에 귀하께서 투고하신 원고가 다음과 같이 게재가 확정되었기에 확인 드립니다.

- 다　　음 -

1. 논집명(권호): Crisisonomy(제21권 2호)
2. 논 문 명: A Study on the Comparison for Deep-learning based Imputations for Green Algae and Water Quality Data
   (딥러닝 기반 녹조 및 수질 자료 결측치 대체 성능 비교 연구)
3. 저자사항 : 류제완(제1저자), 이승연(참여저자), 이충성(참여저자), 김성훈(참여저자)
4. 결과확정일 : 2024년 12월 26일
5. 게　재　일 : 2025년 2월 28일

(사) 위기관리 이론과 실천(CEM-TP) (인)

수치모델 기반 AI 하이브리드 하구 수리해석 기법 연구

Hybrid Approach Integrating Data and Numerical Models for Evaluating Hydraulic Analysis in Estuary

김성훈*, 이상욱**, 주경원***, 장현준****
Sung Hoon Kim, Sangwook Yi, Kyungwon Joo, Hyeonjune Jang

요 지

본 연구는 수자원 공급의 원천이 되는 다목적댐이나 하굿둑 인근의 수리영향에 따라서 사전적인 수질변동 등에 대응이 가능한 방법을 탐색하는 것을 기본 목적으로 하며, 방법론적으로는 AI/ML을 활용하여 데이터 기반으로 시뮬레이션 모사(Emulate)하는 다양한 방법을 적용하고 비교검토 하는 방식으로 수행하였다.

대상으로는 낙동강 하굿둑 인근의 취수원을 대상으로 수온과 염분을 AI로 모의하는 것으로 하였다. 하굿둑의 개방시 해수측의 염분이 상류측으로 크게 이동하게 되면 해당지역 정수장 취수원에 심각한 영향을 줄 수 있으므로 이에 대한 사전적인 시나리오 기반의 대응이 필요한 바, AI 대체모형을 적용함으로써 수문조건 및 하굿둑 문비의 운영, 기상조건의 변동에 따라 실시간 추론을 하는 모델을 구축하고 그 정확도를 파악하는 것이 목표가 된다.

먼저 3회에 걸쳐 현장의 실측자료로부터 보정을 수행한 2차원 수치모델(CE-QUAL-W2)을 구축하였다. 분석의 범위는 하구로부터 15km까지로 하였으며, 도메인 영역을 하천길이 방향으로 250m, 높이는 수심에 따라 변동되나 1m간격으로 최대 45m까지 설정하였다. 분석된 수온 및 염분 결과를 모의치 학습을 위한 결과값(Ground Truth)으로 하는 딥러닝 모델을 구축하였다. 경계조건은 상류(함안보)와 하류(해수)의 유입조건을 변동시키고, 일사, 강우, 기온 등의 기상조건을 적용하는 방식으로하여 총 108개의 시나리오를 구성하였으며, 그중 90개를 학습에 활용하고 나머지 18개를 테스트 셋으로 활용하는 방식으로 하였다. 적용된 딥러닝 모델은 1D-CNN, MLP-Mixer, bi-directional LSTM 기법 3가지를 고려하였으며, 현시점 예측을 위한 이전 시간 적용(sequence)은 최대 12시간까지로 하였다. 각 격자에 대해서 시간에 따른 수온 및 염분의 예측 정확성을 분석한 결과, 수온의 경우 결정계수 기준으로는 최소 0.981 이상, 염분의 경우에는 0.856 이상(LSTM)의 정확성(재현성)을 나타내었다. MLP-Mixer방식을 채택했을 경우에는 염분의 모의 경우에도 MAE 기준 0.04 수준(결정계수 기준으로는 0.99이상)으로 효과적인 모사성능을 나타내었다.

본 연구를 통해서 하류 하천의 비교적 복잡한 수리구조물 운영조건에 대한 2차원 시뮬레이션 결과를 기반으로 분석 목적에 맞게 AI로 모사하는 경우, 해당 예측성능을 보존하면서 기존대비 빠른 분석을 통해 다양한 운영 시나리오를 검토하는데 활용할 수 있음을 보였다.

핵심용어 : 하굿둑 모의, 수리·수질 모델, 딥러닝, 대체모형(Surrogate Model)

감사의 글

본 연구는 K-water 연구개발과제 “수리특성을 고려한 자료기반 인공지능 녹조·수질 예측 모형 개발”(과제번호: G230146)의 지원을 통해 수행되었습니다.

* 정회원·K-water연구원 AI연구센터장·E-mail : sunghoonkim@kwater.or.kr
** 정회원·K-water연구원 책임연구원·E-mail : lsu@kwater.or.kr
*** 정회원·KISTEP 부연구위원·E-mail : kyjoo@kistep.re.kr
**** 정회원·K-water연구원 위촉연구원·E-mail : gapple95@kwater.or.kr

1-2. ② 대한토목학회 학술발표회 구두발표 초록 (2024. 10월)

정수공정에서의 AI 기반 소독부산물(THMs) 예측 모델 개발

Development AI-based disinfection by product pediction model for water treatment process

정지영* · 이진희** · 전은주*** · 김성훈****
Jung, Jiyoung · Lee, Jinhee · Jun, Eunju · Kim, Sunghoon

수돗물 생산과정에서 수질 안정성 확보를 위해 투입되는 소독제(염소)와 천연 유기물의 반응으로 필연적으로 발생하는 소독부산물은 유해성을 가지고 있어 지속적 관리가 필요하나 실시간 수질 확인 불가하여 생산·공급과정에서 염소투입량, TOC, 체류시간, 온도, pH 등 특성적 항목을 반영한 통계 예측 모델을 활용하고 있으나 정확도 편차 발생 등 신뢰도 저하 등의 문제점 내포하고 있다. 이에 따라 본 연구에서는 소독부산물의 도메인적 요소와 트리 계열 딥러닝(Deep Learning) 기법 및 시계열 트랜드 반영 등 Case별로 수행한 최적의 모델 프로세스를 구축하여 도입 단계별(정수장 및 배수지로부터 관말까지) 향후 지속적 관리를 위한 MLOps로 연계될 수 있는 실용화 모델을 개발하였다.

핵심용어 : 소독부산물, 체류시간, 딥러닝(Deep Learning), MLOps

1. 서 론

수돗물을 정수 처리하는 생산부터 공급과정에서 수질 안정성 확보를 위한 소독 공정은 일정 농도를 유지하는 것이 좋으며 이를 유지하고는 있으나, 프로세스에서 소모되는 양의 변동이 밟깽하고, 특히, 염소 소독 방식의 경우에는 소독부산물(THMs)이 필연적으로 발생하고 있다. 정수 처리공정에서 가장 많이 사용하고 있는 염소와 원수에 포함된 유기물의 화학적 반응을 통해 발생하는 소독부산물은 인체 발암 가능성 물질(2B)로 체계적인 관리가 필요하며, 최근 사례에서는 대구·고령 수돗물 조사 결과 소독부산물 수질기준이 초과 되었다는 언론보도를 통해 그 심각성이 대두되고 있다. 지금까지 소독부산물 생성 특성에 대한 연구와 통계 예측 모델을 적용하여 운용중에 있으나 공급과정에서의 예측 정확도 편차 발생 및 신뢰도 저하 문제점을 가지고 있다. 본 연구에서는 정수 정수장~공급과정 프로세스 단계별 입력변수의 다양화 및 Deep Learning 기법의 적용성을 검토하고 지속적 모니터링 체계를 구축하고자 하였다.

2. 예측 기법

소독부산물 생성에 영향을 미치는 인자로 수온, pH, TOC, 체류시간 및 유기물의 농도의 상관도가 높아 해당 인자를 활용한 예측 모형을 적용한 예측이 주요한 목표이나, 사이트 특성과 데이터의 형상 등을 파악하기 위한 기초적 탐색을 통해 예측력을 높여가는 시나리오를 구축하여 진행하여 예측성능 정확도를 최대 80% 이상까지 달성 할 수 있도록 하는 것을 목표로 하고 있다. 특히 계절적 특성을 반영하여 단기 농도 예측과 더불어 장기 발생 시기를 고려하여 폭기 장치를 통해

* K-water연구원 수석위원 (E-mail: jyjung@kwater.or.kr) - 발표자
** K-water 수도관리처 차장 (E-mail: 785jjh@kwater.or.kr)
*** K-water 수도관리처 부장 (E-mail: jeonej@kwater.or.kr)
**** 종신회원, K-water연구원 수석위원, 공학박사 (E-mail: sunghoonkim@kwater.or.kr)

1-2. ② <계속>

소독부산물 처리를 효과적으로 수행할 수 있도록 실용적 측면의 연구를 검토하였다. 또한 체류시간의 영향 등으로 관말의 농도가 상승하는 것을 대비한 정수장에서부터 수용가 관말까지 단계별 분석기법을 적용하였으며 소독부산물의 수집 주기를(1회/월) 고려한 트리 계통(Random Forest, Gradient Boosting Regression, XGBoosting)의 농도 예측 알고리즘을 적용하였다.

3. 소독부산물(Trihalomethanes) 예측

정수장에서 염소처리에 따른 소독부산물 영향을 시나리오 Case별 분석과 데이터 증강과정 등 데이터 중심의 모델 분석과 모니터링 프로세스에 초점을 맞춰 딥러닝 모델의 재학습과 예측을 통해 데이터 희소 문제의 한계점을 개선하여 예측력을 높였다. 특히 결측값 보정과 과거 시계열 특성 반영을 통한 기법의 결과는 다음과 같다.

	X													Y
	수온	pH	EC	NTU	TOC	염소주입률	체류시간	잔류염소	혼화수	침전수	정수유입	정수유출	KMnO4	BOD	THMs
Case 1	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●
Case 2	●		●			●		●	●	●			●		●
Case 3	●	●	●	●	●	●	●	●							●

* (Case 1) 데이터 셋 전체 대상 독립변수와 종속변수 1:1 매칭 분석
* (Case 2) 입력변수 Feature Importances 분석 후 중요 변수 대상 분석
* (Case 3) THMs 발생 시계열 입력변수 사용 (T-1, T-2, ...)

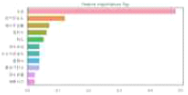

	1차			2차			3차			통계	
	Case 1	Case 2	Case 3	Case 1_1	Case 2_1	Case 3_1	Case 1_2	Case 2_2	Case 3_2	Min	Max
GBM	0.778	0.669	0.5	0.595	0.699	0.77	0.610	0.54	0.74	0.5	0.778
RF	0.748	0.711	0.61	0.707	0.657	0.76	0.674	0.58	0.75	0.58	0.76
XGB	0.716	0.604	0.58	0.492	0.663	0.75	0.676	0.51	0.81	0.51	0.81
	0.747	0.661	0.563	0.598	0.673	0.76	0.653	0.543	0.766		

4. 결 론

본 연구에서는 정수장내 계측된 정보와 소수의 데이터를 효과적으로 활용할 수 있는 트랜드 반영 프로세스를 도입한 딥러닝 기법을 통해 다음과 같은 결과를 도출하였다.

1. 도메인(수질) 영향인자와 시계열성 Sequence를 적용한 입력변수의 구성을 통한 분석 Case에서 Test Set에 대해서 결정계수 기준 0.8이상의 성능을 나타내었고,
2. 배수지에서의 영향도 추가로 분석한 결과 예측력이 증가(결정계수 기준 0.9이상)하여, 정수 소독부산물 예측 결과값에 대한 실용성 측면에서 유의미한 결과가 도출 되었으며, 향후 장·단기 예측을 통해 정수장(광역) 모니터링 체계를 구축함으로써 관리의 효율성이 제고가능 할 것으로 기대된다.

감사의 글

본 연구는 K-water 연구개발과제 "수리특성을 고려한 자료기반 인공지능 녹조·수질 예측 모형 개발"(과제번호: G230146)의 지원을 통해 수행되었습니다.

참고문헌

1. Stavroula Tsitsifli and Vailis Kanakoudi (2020). "Total and Specific THMs Prediction Models in Drinking Water Pipe Networks" , Environmental Sciences Proceedings
2. M. K. Nallakaruppan, E. Gangadevi and Shitharth Selvarajan (2024). "Reliable water quality prediction and parametric analysis using explainable AI Models" Scienrific reports

기 획 특 집 0 2

AI를 활용한 물 환경 관리 방안

김성훈 / K-water연구원 AI연구센터 센터장

Ⅰ 들어가며

기후변화를 넘어 기후위기가 현실화되고 있는 현 시기는 기술과 환경의 교차로에서 중대한 도전에 직면하고 있다. 물 안보와 관련한 물 환경관리의 중요성이 커지고 있는 시기에 대응하여 UN은 작년 3월 46년만 물 컨퍼런스(UN Water Conference)를 개최하였다. 여기서는 물 부족과 수질 오염, 기후변화에 따른 글로벌 가뭄의 장기화, 메가홍수의 빈발 등 물 위기 해결의 긴급성과 함께 기후변화 대응을 위해서는 물 자원의 관리가 핵심이라는 점을 강조했다. 또한, 모든 이해관계자가 참여할 수 있는 통합적이고 협력적인 물 거버넌스 체계 구축을 제안함과 동시에 물 인프라 구축, 물 효율성의 제고, 물 정보 시스템 구축 등을 위한 혁신과 투자의 필요성을 역설했다.

여전히 신도시에 해당하는 세종시와 도심의 재개발이나 리모델링의 요구가 있는 대전시는 도시화에 따른 필연적인 불투수 면적 증가 및 배수시설의 설계 빈도에 육박하는 집중호우 발생 등으로 일찍이 겪지 못한 도시홍수에 대한 취약성이 노출되고 있다. 또한, 작년 봄철 대청댐의 저수율 저하나 여름철 녹조 등 식원의 수질관리의 어려움 등으로 도시 물순환 전반에 걸쳐 지속가능한 물 환경 관리를 위한 정책적 대응과 이에 발맞춘 기술 확보가 요구된다.

한편, 최근 급속히 발달하여 다양한 분야에 적용되고 있는 인공지능(AI) 기술은 UN이 제시한 물 인프라와 운영관리, 정보 시스템 구축 등 도시 물 환경관리를 혁신적으로 전환할 수 있는 잠재적 방안이라고 할 수 있다.

물 환경관리와 이에 연관된 도시의 인프라는 사회간접자본으로 공공성이 높아 그간에는 시장의 경쟁 압력이나 비즈니스 모델 개발과는 연관성이 낮고, 결과적으로 디지털 혁신 기술과 정책적 변화에서는 다소 더딘 측면이 있었던 것으로 보인다 최근 정부에서 기존의 대한민국 디지털 전략을 보완 · 강화한 "AI · 디지털 혁신 성장 전략"을 발표하고 전 산업과 일상에 AI를 도입 · 추진하기로 한 만큼 도시 물 환경 관리 분야에서도 보다 다양한 AI의 기술적 적용과 정책적 변화가 가속화될 것으로 판단된다. 본고에서는 AI를 활용한 물 환경관리의 현황을 사계 중심으로 개괄하고 이를 바탕으로 도시 물 환경관리의 활용 제고를 위한 방안을 검토하고자 한다.

1-4. ①수질녹조 자료 불균형 해소 방안 기술세미나 개최 ('24. 4월)

물이 여는 미래, 물로 나누는 행복
국민 안전을 최우선으로 하는 '새로운 물의 시대'를 열어가겠습니다.

한국수자원공사

수신자 내부결재

(경유)

제목 수질녹조 자료 불균형 해소 방안 기술세미나 개최 결과 보고

1. 수질녹조 자료 불균형 해소 방안 기술세미나 개최 계획(K-water연구원-2727, 2024.04.15.)관련 입니다.

2. 계획에 따라 세미나를 개최하고, 그 결과를 붙임과 같이 보고합니다.

붙임 수질녹조 자료 불균형 해소 방안 기술세미나 개최 결과 보고 1부. 끝.

연구관리처장

★AI연구센터 수석위원	이충성	AI연구센터 센터장	김성훈	연구관리처 처장	04/25 김선웅

감 사

협조자

시행 K-water연구원-3018 (2024.04.25.) 접수 ( )

우 34045 대전광역시 유성구 유성대로 1689번길 125 K-water연구원 (전민동 462-1) / http://www.kwater.or.kr/

/ 공개

1-4. ② 2024년 수자원학회 학술발표회 기획세션 개최 ('24. 5월)

물이 여는 미래, 물로 나누는 행복
국민 안전을 최우선으로 하는 '새로운 물의 시대'를 열어가겠습니다.

한국수자원공사

수신자 내부결재

(경유)

제목 2024년 수자원학회 학술발표회 기획세션 개최 결과보고

1. 2024년 수자원학회 학술발표회 기획세션 추진계획(K-water연구원-2728호, 2024.04.15.) 관련입니다.

2. 추진계획에 따라 기획세션("수자원 AI 실용화를 위한 제도화 필요성")을 개최하였고, 그 결과를 붙임과 같이 보고드립니다.

붙임 2024년 수자원학회 학술발표회 기획세션 개최 결과보고(안) 1부. 끝.

연구관리처장

★AI연구센터 수석위원	**이충성**	AI연구센터 센터장	**김성훈**	연구관리처 처장	05/16 **김선웅**

감 사

협조자

시행 K-water연구원-3373 (2024.05.16.) 접수 ( )

우 34045 대전광역시 유성구 유성대로 1689번길 125 K-water연구원 (전민동 462-1) / http://www.kwater.or.kr/

/ 공개

1-4. ③ K-water연구원-한국수자원학회 공동 세미나 개최 ('24. 10월)

물이 여는 미래, 물로 나누는 행복
국민 안전을 최우선으로 하는 '새로운 물의 시대'를 열어가겠습니다.

한국수자원공사

세상에 행복을 水놓다

수신자 내부결재

(경유)

제목 K-water연구원-한국수자원학회 공동 세미나 개최 결과 보고

1. 「K-water연구원-한국수자원학회 공동 세미나 개최 계획(K-water연구원-7208, 2024.10.23.)」 관련입니다.

2. 위 관련, 공동 세미나를 개최한 결과를 붙임과 같이 보고합니다.

붙임 K-water연구원-한국수자원학회 공동 세미나 결과보고 1부. 끝.

연구관리처장

★AI연구센터 수석위원	**이충성**	AI연구센터 센터장	**김성훈**	연구관리처 처장	11/04 **김선웅**		
감 사							
협조자							

시행 K-water연구원-7500 (2024.11.04.) 접수 ( )

우 34045 대전광역시 유성구 유성대로 1689번길 125 K-water연구원 (전민동 462-1) / http://www.kwater.or.kr/

/ 공개

1-5. 한국수자원학회 분과위원장 위촉장

제23-079호

위 촉 장

K-water 연구원
김 성 훈

귀하를 한국수자원학회 'AI응용연구 분과위원회' 위원장으로 위촉하오니 학회발전에 적극 협조하여 주시기 바랍니다.

(임기: 2023. 2. 24. ~ 2024. 12. 31.)

2023. 2. 24.

사단법인 한국수자원학회
회 장 이 상 호

1-6. ①충남대학교 '디지털 물산업 분야 혁신인재 양성사업' 강연 초청 공문 ('24. 11월)

미래사회를 선도할 강한 대학

충남대학교

수 신 한국수자원공사사장

(경유)

제 목 「디지털 물산업 분야 혁신인재 양성사업」전문가 초청 세미나 참석 협조 요청

1. 귀 사의 무궁한 발전을 기원합니다.

2. 공학교육혁신센터에서는 「디지털 물산업 분야 혁신인재 양성사업」 일환으로 AI 융합 기본 및 실무과정 학습과 관련하여 "AI를 활용한 물관리 데이터 분석 실습" 을 주제로 한국수자원공사 정지영 박사님을 초청연사로 초대하여 세미나를 개최하고자 하오니 협조하여 주시기 바랍니다.

가. 일 시: 2024년 11월 13일(수) 15:00 ~ 18:00

나. 주 제: AI를 활용한 물관리 데이터 분석 실습

다. 장 소: 대전광역시 유성구 대학로 99, 충남대학교 공과대학 3호관 313호실

라. 초 청 자: 이용목 겸임교수

마. 초청연사

No	성 명	소 속	비 고
1	정지영	한국수자원공사 K-water연구원 AI연구센터	

끝.

공학교육혁신센터장

자체직원	조교	부장	공학교육혁신센터 부센터장
협조자			

시행 공학교육혁신센터-5176 (2024.11.12.) 접수 K-water연구원-@N (2024.12.04.)

우 대전광역시 유성구 대학로 99 (궁동, 충남대학교) / http://ceeca.cnu.ac.kr

/ 공개

1-6. ② 경북대학교 대학원 4단계 BK21사업 세미나 강연 초청 공문 ('24. 11월)

새로운 100년, 시대를 선도하는 KNU

경북대학교

다시뛰자! 다시자랑스럽게! RE:MAKE KNU

수 신 한국수자원공사사장

(경유)

제 목 경북대학교 대학원 미래과학기술융합학부 4단계 BK21사업 세미나 연사 초청

1. 귀 기관의 무궁한 발전을 기원합니다.

2. 우리 대학 대학원 미래과학기술융합학부에서 4단계 BK21사업 관련 「교육연구단 맞춤형 비교과 교육과정 프로그램」을 운영 중에 있는 바, 대학원생의 교육·연구 역량 향상을 위해 귀 기관의 전문가를 연사로 위촉하여 세미나를 개최하고자 하오니, 적극적인 협조를 부탁드립니다.

가. 위촉대상

성 명	소속	직급/직책
이충성	한국수자원공사	수석위원

나. 주 제: AI전환의 시대, 물 문제 해결을 위한 AI의 이해와 활용

다. 일 시: 2024. 11. 12.(화), 13:00 ~

라. 장 소: 경북대학교 상주캠퍼스 7호관 216호

마. 자 문 료: 금300,000원(금삼십만원)

붙임 관련 공문 1부. 끝.

경북대학교총장

주무관	신성환	팀장	조영미	실장	김경관	부학장	출장
학장	전결 11/06 오세욱						
협조자							

시행 과학기술대학생태환경대학통합행정실-13990 (2024.11.06.) 접수 K-water연구원-7618 (2024.11.07.)

우 경상북도 상주시 경상대로 2559 (가장동) 경북대학교 상주캠퍼스 / http://www.knu.ac.kr

: / 비공개(6)

2-1. 한국수자원학회 논문집(제59권 2호) 논문 및 게재 확정 증명서 ('25. 12월)

Impact of Oversampling on the Predictive Performance of Machine Learning Models: Empirical Analysis of Algal Bloom Prediction

Lee, Junhaeng[a] · Yi, Choongsung[b*] · Ryu, Jewan[c] · Kim, Sunghoon[d]

[a]Researcher, AI Research Lab., K-water Research Institute, Daejeon, Korea
[b]Head Researcher, AI Research Lab., K-water Research Institute, Daejeon, Korea
[c]Senior Researcher, AI Research Lab., K-water Research Institute, Daejeon, Korea
[d]Director, AI Research Lab., K-water Research Institute, Daejeon, Korea

Abstract

The aim of this study is to quantitatively evaluate how oversampling affects regression-based predictive performance in highly imbalanced time series, such as cyanobacterial cell density datasets with extremely rare high-concentration samples. Using Daecheong Reservoir as a case study, we compiled weekly data for 2005 - 2024 by integrating cyanobacterial, water quality, hydrologic, and meteorological variables, built random forest models with 1 - 3 week lead times, and compared SMOGN, GAN, and TimeGAN oversampled training sets against the original data using multiple performance metrics.

SMOGN, by preserving the continuous distribution while selectively reinforcing rare regions according to local density, reduced errors in high-concentration ranges and yielded consistent improvements across most metrics compared with the original data. In contrast, GAN and TimeGAN better preserved the original distribution and temporal structure but showed limited ability to rebalance toward extremely rare high-concentration regimes. These results suggest that, for hydrologic and environmental time series with rare extremes and severe imbalance, regression-oriented oversampling strategies that jointly preserve the target distribution and strengthen sparse regions can effectively enhance the predictive performance of forecasting models.

Keywords: Oversampling, Imbalanced time series, SMOGN, Random Forest, Cyanobacterial cell density

오버샘플링이 머신러닝 모델 예측성능에 미치는 영향: 녹조예측 실증분석

이준행[a] · 이충성[b*] · 류제완[c] · 김성훈[d]

[a]K-water연구원 AI연구소 연구원, [b]K-water연구원 AI연구소 수석위원, [c]K-water연구원 AI연구소 선임연구원, [d]K-water연구원 AI연구소 소장

요 지

본 연구의 목적은 남조류 세포수 데이터셋과 같이 고농도 샘플이 극히 희소한 불균형 시계열에서 오버샘플링이 회귀 기반 예측성능에 미치는 영향을 정량적으로 분석하는데 있다. 대청호를 대상으로 2005 - 2024년 주간 자료로 남조류, 일반수질, 수리·수문, 기상변수를 통합하고, 리드타임 1-3주별로 랜덤포레스트 예측모형을 구축한 뒤, SMOGN, GAN, TimeGAN을 적용한 혼련 데이터셋과 원본 데이터셋의 성능을 다양한 성능 평가 지표로 비교하였다. 그 결과 SMOGN은 연속형 분포를 유지하면서 국소 밀도에 따라 희소 구간을 선택적으로 강화함으로써 고농도 구간 오차를 줄이고, 오버샘플링 미실행 대비 대부분의 평가 지표에서 일관된 성능 개선을 보였다. 반면 GAN과 TimeGAN은 원본 분포 및 시계열 구조 보존에는 유리하나, 극히 희소한 고농도 구간을 목표로 분포를 재조정하는 데에는 한계를 나타냈다. 이러한 결과는 극단값이 드물고 불균형이 심한 수문·환경 시계열에서 단순 데이터 증대가 아닌 분포 보존과 선택적 밀도 강화를 결합한 회귀형 오버샘플링 전략이 예측모형 성능 향상에 유용함을 시사하는 기초적 근거로 활용될 것으로 기대된다.

핵심용어: 오버샘플링, 불균형 시계열, SMOGN, 랜덤포레스트, 남조류 세포수

---

*Corresponding Author. Tel: +82-42-870-7685
E-mail: sung@kwater.or.kr

2-1. <계속>

No. 25-098

게 재 예 정 증 명 서

제　　목: 오버샘플링이 머신러닝 모델 예측성능에 미치는 영향:
녹조예측 실증분석

연구 발표자: 1) 이준행 2) 이충성 3) 류제완 4) 김성훈

소속 및 직위: 1) K-water연구원 AI연구소 연구원
2) K-water연구원 AI연구소 수석위원
3) K-water연구원 AI연구소 선임연구원
4) K-water연구원 AI연구소 소장

게　재　지: 한국수자원학회 국문논문집 59권 2호 (2026년 2월호)
ISSN : 2799-8746(print), 2799-8754(online)

게재 예정일: 2026년 2월 28일

위의 내용과 같이 게재예정을 증명함

2025년 12월 29일

사단법인 한국수자원학회장

2-2. ① 한국수자원학회 학술발표회 구두발표 초록(2025. 4월)

저수지 녹조 관련 시계열자료에 대한 이상 탐지 기법 비교 분석

Comparative Analysis of Anomaly Detection Techniques for Time-Series Data on Algal Blooms in Reservoirs

이충성*, 류제완**, 김성훈***

Choong Sung Yi, Je Wan Ryu, Sung Hoon Kim

요 지

저수지의 녹조 발생은 수자원의 안정적 관리에 중대한 위협으로 이를 효과적으로 예측하기 위해서는 수질, 수리·수문, 기상 등 다양한 시계열자료 활용이 필수적이나 시간의 흐름에 따라 수집되는 특성상 계측·처리 단계에서의 오류 등 비자연적 요인과 극한사상 같은 자연적 요인 등으로 이상(anomaly)이 발생하기 쉽다. 이렇게 제한성이 매우 작은 값들은 예측 모형의 일반화 성능을 저하하고 과적합의 원인이 될 수 있으므로 사전에 적절한 탐지 및 처리 과정이 필수적이다.

수질과 같은 시계열자료의 이상 탐지 기법으로는 통계적 접근법, 기계학습 기반 방법, 신호 처리 기법 등이 다양하게 이용되었으나 자료의 시계열적 특성에 따라 탐지 성능은 상이할 수 있다. 그러나 성능 평가를 위한 참값(ground truth)을 얻기가 어렵고, 전문가의 도메인 지식에 의존하는 경우가 많아 자료의 특성별로 적합한 탐지 기법을 판별하기란 쉽지 않다. 본 연구는 합성 이상값 주입(Synthetic Anomaly Injection), 합의 기반 평가(Consensus based Evaluation), 이상값 제거 전후 모델 예측성능 평가(Relative Performance Evaluation) 등의 비교분석법을 통해 다양한 이상값 탐지 기법의 성능을 비교·평가하였다.

본 연구의 적용 대상은 대청댐으로 약 20년간(2005~2023년)의 환경부 조류경보제 및 국가수질측정망 자료, 수자원공사 댐 운영 자료, 기상청 자료 등에서 총 27종(남조류, 클로로필-a, 수온, pH, DO, BOD, COD, TN, TP, TOC, pH, EC, SS, 강우량, 유입량, 최대유입량, 최대방류량, 저수량, 저수위, 평균기온, 최고기온, 평균풍속, 상대습도, 일조시간, 최다일사량, 일사량, 증발량), 84개의 시계열자료를 수집하였다. 이상값 탐지 기법으로는 Z-score, 수정 Z-score, IQR, 수정 IQR, 이동평균법, 지수가중이동평균법, 지수평활법, STL분해 등을 활용하였다. 본 연구를 통해 수질, 수리·수문, 기상 등 저수지 녹조 발생과 관련된 시계열자료 각각의 특성을 고려하고, 다양한 이상값 탐지 기법의 성능을 비교 분석하여 가장 효과적인 방법을 제안함으로써 기계학습을 이용한 녹조 예측 모델 구축 시 자료의 전처리 과정에 중요한 정보를 제공할 수 있기를 기대한다.

핵심용어 : 시계열자료, 이상값, 녹조, 전처리

감사의 글

이 논문은 한국수자원공사의 재원을 지원받아 수행된 연구임(No. C240159).

* 정회원 · K-water연구원 AI연구센터 수석위원 · E-mail : sung@kwater.or.kr
** 정회원 · K-water연구원 AI연구센터 선임연구원 · E-mail : ryujw@kwater.or.kr
*** 정회원 · K-water연구원 AI연구센터 센터장 · E-mail : sunghoon.kim@kwater.or.kr

2-2. ② 한국수자원학회 학술발표회 포스터발표 초록(2025. 4월)

녹조 및 수질 시계열 자료의 결측치 대체 기법 성능 비교

A Comparative Analysis of Imputation Methods for Missing Data in Algal Bloom and Water Quality Time Series

류제완*, 이충성**, 김성훈***
Jewan Ryu, Choong Sung Yi, Sung Hoon Kim

요 지

기후변화로 인한 수온 상승 및 산업화에 따른 오염 부하량 증가로 조류 발생의 빈도 및 강도가 매년 확대되고 있다. 녹조 현상은 영양염류, 수온, 일사량, 체류시간 등 복합적인 요인에 의해 식물성 플랑크톤이 과다 증식하며 발생한다. 이에, 녹조 발생 메커니즘에 내재된 비선형 관계를 분석하고 조류경보제 등 제도의 기초자료로 활용하기 위하여 다양한 시계열 자료가 수집되고 있다. 그러나, 다양한 원인으로 발생하는 결측값은 자료의 신뢰성과 분석 정확도를 저해하는 요인이 되며, 따라서 적절한 결측치 처리가 수반되어야 한다.

본 연구는 녹조 및 관련 변수들을 대상으로 다양한 결측 대체 기법을 적용하고, 그 성능을 비교 및 분석하였다. 대청댐 지역을 대상으로 녹조 발생의 주요 영향 인자인 남조류 세포수, 클로로필-a 농도, 수온, 총인을 포함하여 2004년 4월부터 2023년 12월까지 총 27개 변수에 대해 83개의 주간 시계열 자료를 수집하고 분석에 활용하였다. 주요 영향 인자 각각에 다양한 기간의 결측치를 인위적으로 발생시킨 후 선형 보간법(Linear interpolation), 최근접이웃 기반 대체(k-Nearest Neighbors imputation), BRITS(Bidirectional Recurrent Imputation for Time Series), NAOMI(Non-autoregressive Multiresolution Sequence Imputation)를 활용하여 결측치를 대체하고 성능을 비교하였다.

대체 기법에 따른 성능 비교는 RMSE와 MAPE를 기준으로 이루어졌으며, 변수 특성과 결측 구간의 길이에 따라 최적 대체 기법이 달라지는 것을 확인하였다. 남조류 세포수와 클로로필-a 농도의 경우, 최근접이웃 기반 대체 기법이 결측 길이에 상관없이 전반적으로 우수한 성능을 보였다. 반면, 수온과 총인 등 상대적으로 변동성이 적거나 선형적 패턴이 뚜렷한 변수에서는 선형 보간법이 가장 효과적인 대체 기법으로 나타났다. 본 연구를 통해 녹조 및 수질 관련 다양한 시계열 자료 특성을 고려한 최적 결측치 대체 기법을 제안하고, 향후 예측 모형 개발 및 분석을 위한 기초 자료로써의 활용성을 기대할 수 있다.

핵심용어 : 녹조, 수질, 결측치 대체

감사의 글

본 연구는 K-water 연구개발과제 "수리특성을 고려한 자료기반 인공지능 녹조수질 예측 모형 개발"(과제번호: G230146)의 지원을 통해 수행되었습니다.

* 정회원 · K-water연구원 AI연구센터 선임연구원 · E-mail : ryujw@kwater.or.kr
** 정회원 · K-water연구원 AI연구센터 수석위원 · E-mail : sung@kwater.or.kr
*** 정회원 · K-water연구원 AI연구센터 센터장 · E-mail : sunghoonkim@kwater.or.kr

2-2. ③ 한국습지학회 학술발표회 구두발표 초록(2025. 8월)

머신러닝 기반 녹조 예측을 위한 데이터 증강 기법 분석 및 적용 전략

이준행[1] · 이충성[2]† · 류제완[3] · 김성훈[4]

Evaluating and Applying Data Augmentation Methods for Machine Learning Models in Algal Bloom Prediction

Jun Haeng Lee, Choong Sung Yi, Je Wan Ryu, Sung Hoon Kim

Abstract

녹조 현상의 지표인 남조류세포수는 하천과 호수의 수질관리와 생태계 건강성 평가에 매우 중요하나, 평상시에는 그 수가 매우 적거나 관측되지 않다가 녹조 우심기인 6~9월에 급증하는 특징이 있다. 특히, 환경부 조류경보제 경계 단계인 10,000 cells/mL을 초과하는 사례는 극히 제한적이다. 이렇게 데이터 분포가 불균형한 상황에서는 일반적인 머신러닝 회귀 모델의 예측 성능이 저하되고, 주로 빈도가 높은 값(적은 세포수) 위주로 학습되는 문제가 지적된다.

본 연구에서는 이러한 문제를 해결하고자 2005년 5월부터 2023년 12월까지 수집한 총 971개의 주 단위 시계열 데이터를 사용하여 데이터 증강 기법을 적용하였다. 특히 남조류세포수를 반응변수로 하고, 녹조 발생의 주요 영향 인자인 수온, 총인(TP), 용존산소(DO), 클로로필-a 등의 환경 인자를 설명변수로 포함하여 남조류 세포수의 예측 성능 향상을 도모하였다. 데이터 증강 기법으로 대표적인 SMOTE(Synthetic Minority Over-sampling Technique)와 GAN(Generative Adversarial Networks) 외에 이를 회귀 및 시계열 데이터에 적합하도록 확장한 SMOGN, T-SMOTE, TimeGAN 등 다섯 가지 방법을 선정하여 비교·분석하였으며, 남조류 세포수와 주요 영향 인자들의 지연시간(Lag time)을 최대 4주까지 고려함으로써 녹조 증식 이벤트 시퀀스 전체가 하나의 데이터 샘플이 되도록 학습용 데이터셋을 구축하였다. 데이터 증강에 따른 예측 성능 개선 평가는 Random Forest 모형을 활용하였다.

본 연구는 소수 클래스에 해당하는 희소한 수질 데이터 문제를 효과적으로 해결하기 위해 다양한 데이터 증강 기법을 비교론적으로 적용하였다는 것에 일차적인 의의가 있다. 또한 데이터 증강 시 녹조 현상의 시계열적 특성을 나타낼 수 있는 적용 전략 및 예측 성능 개선 여부를 종합적으로 검토함으로써 향후 수질 데이터 분석 분야에서 발생하는 유사한 문제에 대한 실질적 해결책 제시도 기대해 볼 수 있다.

keywords : 녹조, 데이터 증강(Data Augmentation), SMOTE, GAN

Acknowledgement : 이 논문은 한국수자원공사의 재원을 지원받아 수행된 연구임(No. G240159).

† Corresponding author : sung@kwater.or.kr

[1] K-water Research Institute, Korea(wngod48@partner.kwater.or.kr)

[2] K-water Research Institute, Korea(sung@kwater.or.kr)

[3] K-water Research Institute, Korea(ryujw@kwater.or.kr)

[4] K-water Research Institute, Korea(sunghoonkim@kwater.or.kr)

2-3. ① 수질·녹조 과제 통합 전문가 토론회 개최 (2025. 4월)

물이 여는 미래, 물로 나누는 행복
국민 안전을 최우선으로 하는 '새로운 물의 시대'를 열어가겠습니다.

한국수자원공사

수신자 내부결재

(경유)

제목 수질·녹조 과제 통합 전문가 토론회 개최 계획

1. 2025년도 물관리 디지털·AI 기술세미나 개최 계획(K-water연구원-1568, 2025.03.05.) 및 「수리특성을 고려한 자료기반 인공지능 녹조·수질 예측모형 개발」 연구과제 관련 입니다.

2. 녹조 예측과 관련한 연구과제들의 연계 및 상호보완 방안에 대한 전문가 토론회를 붙임과 같이 개최하고자 합니다.

붙임 수질·녹조 과제 통합 전문가 토론회 개최 계획(안) 1부. 끝.

연구관리처장

★AI연구센터 수석위원	이충성	AI연구센터 센터장	김성훈	연구관리처 처장	04/16 박기범
감 사					
협조자	미래물환경연구팀 팀장	이승윤			

시행 K-water연구원-2847 (2025.04.16.) 접수 ( )

우 34045 대전광역시 유성구 유성대로 1689번길 125 K-water연구원 (전민동 462-1) / http://www.kwater.or.kr/

/ 공개

2-3. ② 수질·녹조 과제 통합 전문가 토론회 개최 (2025. 4월)

물이 여는 미래, 물로 나누는 행복
국민 안전을 최우선으로 하는 '새로운 물의 시대'를 열어가겠습니다.

K water

한국수자원공사

새상에 행복을 水놓다

수신자 내부결재

(경유)

제목 조류 예측 분야 딥러닝 활용연구 전문가 초청 강연 계획(안)

1. 2025년도 물관리 디지털·AI 기술세미나 개최 계획(K-water연구원-1568, 2025.03.05.) 및 「수리특성을 고려한 자료기반 인공지능 녹조·수질 예측모형 개발」 연구과제 관련입니다.

2. 조류 예측 관련 AI 기술의 최신 트렌드를 파악하고, 향후 연구개발 방향 설정에 참고하고자 붙임과 같이 전문가 초청 강연을 개최하고자 합니다.

붙임 조류 예측 분야 딥러닝 활용연구 전문가 초청 강연 계획(안) 1부. 끝.

AI연구소장

★AI연구소 수석위원	이충성	AI연구소 소장	12/09 김성훈
감 사			
협조자			

시행 K-water연구원-8947 (2025.12.09.) 접수 ( )

우 34045 대전광역시 유성구 유성대로1689번길 125 K-water연구원 / http://www.kwater.or.kr/
(전민동 수자원연구원)

/ 공개

2-4. ① 지적재산권 소프트웨어(S/W) 등록 ('25. 11월)

- 명칭: AI 녹조예측을 위한 EDA SOP 프로그램

제 C-2025-053068 호

저작권 등록증

1. 저작물의 제호(명칭)	AI 녹조예측을 위한 EDA SOP(탐색적데이터분석 표준운영절차) 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>응용프로그램>과학기술>수치계산용 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	
5. 창작연월일	2025년11월07일
6. 공표연월일	2025년11월07일
7. 등록연월일	2025년11월27일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2025.11.07, 공표 : 2025.11.07

「저작권법」 제63조에 따라 위와 같이 등록되었음을 증명합니다.

2025년 11월 27일

한국저작권위원회

2-4. ① 지적재산권 소프트웨어(S/W) 등록 ('25. 11월)

- 명칭: 녹조예측 데이터 오버샘플링 프로그램

제 C-2025-053067 호

저작권 등록증

1. 저작물의 제호(명칭)	녹조예측 데이터 오버샘플링 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>응용프로그램>과학기술>수치계산용 S/W
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	
5. 창작연월일	2025년11월07일
6. 공표연월일	2025년11월07일
7. 등록연월일	2025년11월27일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2025.11.07, 공표 : 2025.11.07

「저작권법」 제63조에 따라 위와 같이 등록되었음을 증명합니다.

2025년 11월 27일

한국저작권위원회

2-5. 수자원 운영처 내부전문가 자문('25. 07월 ~ '25. 09월)

접수	일 자	2025.12.08.
	번 호	K-water연구원-8921

자문부서	★AI연구소 연구원	AI연구소 소장	
	김학준	12/09 김성훈	

내부전문가자문 결과서

건 명	가뭄 상황(영향·피해)조사 관련 상관성분석 요청			요청부서	수자원운영처	
자문기간	접 수 일	2025-07-01		완 료 일	2025-09-30	
참 여 자	성 명	직 급	참여율	성명	직 급	참여율
	김학준	원급	50	이충성	수석급	10
	류제완	선임급	40			

1. 자문요청 내용

□ 가뭄사례를 중심으로 항목별 상관성분석 수행 요청
* '22년~'23년 광주·전남 극한가뭄피해로 해당지역 시범적용 실시
□ 상관성 분석결과를 기반으로 기 정립된 가뭄 영향·피해 모니터링 항목 조정 요청
□ 가뭄 영향·피해 모니터링 항목 관련 외부전문가 자문회의 개최시 참석 및 기술지원 요청

2. 전문가자문결과

o 기존 가뭄 모니터링 항목 중 28개 조사항목을 선별, 광주·전남권 월별 데이터 기반의 통계적 검증 수행
o 분석 결과, 강수량, 댐 저수율 등 19개 항목이 가뭄과 유의미한 영향도가 있음을 확인
o 이를 토대로 조사항목에 대해 선행/동시/후행/보조 지표로 분류하였으며, 영향도가 낮은 항목은 축소·제외하여 모니터링 체계 효율성을 높이기 위한 근거 도출

3. 전문가자문 소요비용

23,459 천원

4. 효 과 (유무형 효과 기술)

o 기존에 수집되던 가뭄 조사항목을 통계적으로 재검증하여, 실효성 높은 핵심 지표 중심으로 모니터링 체계를 개편하기 위한 통계적 근거 확보
o 가뭄과의 낮은 영향으로 조사가 불필요한 항목에 대한 수집을 지양하고 모니터링 체계를 효율화함으로써, 효율적이고 신뢰성 있는 가뭄 대응·정책 수립을 위한 기반 마련

요청부서			

2-6. ① 국립환경과학원 외부 강의 (2025. 9월)

환경부

국립환경과학원

수신 한국수자원공사사장
(경유)
제목 외부전문가 초청 세미나 참석 요청

1. 귀 기관의 무궁한 발전을 기원합니다.

2. 우리원에서 생태가 공존하는 통합 수자원 관리 업무의 역량 강화를 위해 아래와 같이 관련 전문가를 초청하여 세미나를 개최하고자 하오니 협조해 주시기 바랍니다.

   가. 일 시 : 2025년 9월 9일(화), 14:00~16:00
   나. 장 소 : 국립환경과학원 환경위성센터 세미나실(1층)
   다. 발표자: 김성훈 센터장(Kwater연구원 AI연구센터)
   라. 주 제 : 물 SOC 관리를 위한 AI/ML 도입 및 활용. 끝.

국립환경과학원장

전문위원	김하경	환경연구관	유경아	과장	전결 2025. 8. 28. 민경혁
협조자					

시행 수자원연구과-1884 (2025. 8. 28.) 접수

우 22689 인천 서구 환경로 42(종합환경연구단지) 국립환경과학원 수자원연구과 / http://www.nier.go.kr

/ 비공개(5)

2-6. ② 한국하천협회 외부 자문 (2025. 11월)

하 천 관 리 전 문 기 관

한 국 하 천 협 회

(www.riverlove.or.kr)

우 06130 서울시 강남구 테헤란로7길 22 한국학기술회관 제1관 711호 /

문서번호 하천협25-327호

시행일자 2025. 11. 10.

받 음 한국수자원공사 사장

참 조

선결			지시		
접수	일자시간		결재·공람		
	번호				
처 리 과					
담 당 자					

제 목 「2025 하천관리 세미나」 주제발표 요청

1. 귀 공사의 무궁한 발전을 기원합니다.

2. 기후에너지환경부와 우리협회가 공동주최하는 『2025 하천관리 세미나』 행사가 2025.11.13(목)~14(금)까지 2일간, 롯데리조트부여(충남 부여군)에서 개최됩니다.

3. 올해로 20회째를 맞이하는 이번 세미나 행사는 「기후변화 대응과 물 위기 해소」를 주제로 정부 및 지자체 하천담당 공무원, 산·학·연의 하천분야 전문가를 대상으로, 정부 정책방향 및 전문가의 주제발표 등을 통해 미래지향적이고 바람직한 하천관리 방안을 모색하는 의미 있는 자리가 될 것입니다.

4. 이에 귀 공사에서 연구하신 사례를 동 세미나 행사에서 널리 소개하고자 아래와 같이 주제발표를 요청드리오니 협조하여 주시기 바랍니다.

- 아 래 -

가. 행 사 명 : 『2025 하천관리 세미나』
나. 주 제 : 「기후변화 대응과 물 위기 해소」
다. 일 시 : 2025.11.13(목) ~ 14(금), 2일간
라. 장 소 : 롯데리조트부여(충남 부여군)
마. 주제발표 요청사항
- 이충성 수석위원 : 기후위기의 시대 하천 분석 AI기술 실증 사례 및 물관리 AX를 위한 제언

붙 임 : 2025 하천관리 세미나 일정(안) 1부. 끝.

한 국 하 천 협 회 장

참 여 연 구 원 현 황

연구원	참 여 내 역	비 고
이충성	○ 연구과제 총괄 (연구책임자) ○ 데이터 증강기법(DA) 적용 및 검증 ○ 수질·녹조 예측 AI모형 개발	- ’24.2 ~ ’25.12 - K-water연구원 AI연구소
김성훈	○ 기존 플랫폼 기반 AI모형 연계 방안 수립	- ’24.2 ~ ’25.12 - K-water연구원 AI연구소
정지영	○ 수질·녹조 예측 인공지능 알고리즘 적용을 위한 데이터 증강기법 개발 및 검증	- ’24.2 ~ ’25.12 - K-water연구원 AI연구소
류제완	○ 밀도·성층, 지형, 체류시간 등 예측물질별 수리특성을 반영한 AI알고리즘 개량 ○ 대상지역·예측물질별 학습, 검증, 시험 수행, 기존모형 대비 예측성능 비교·평가	- ’24.9 ~ ’25.12 - K-water연구원 AI연구소
이승제	○ AI모형 탑재를 위한 DB 연결 방안 검토	- ’24.2 ~ ’25.12 - 물환경계획처
윤석제	○ 기존 사내 정보시스템(WQE)에 AI모형 내재화 방안 수립	- ’25.4 ~ ’25.12 - 물환경관리처
이준행	○ 데이터 증강기법 조사·분석 ○ 최종 모형 시험적용을 위한 학습자료 구축 ○ AI알고리즘 개량 및 학습, 검증, 시험 수행 지원	- ’25.4 ~ ’25.12 - K-water연구원 AI연구소

서 지 자 료

(1) 기술분류	(2) 수행방법	(3) 제출일
2026-WR-RR-21-107	자체수행	2025.12.31

(4) 제목/부제	(5) 연구기간
수리특성을 고려한 자료기반 인공지능 녹조·수질 예측 모형 개발	2024.02 ~ 2025.12
(6) 연구수행부서	**(7) 연구수행자(소속)**
한국수자원공사, K-water연구원 AI연구소	이충성, 김성훈, 정지영, 류제완, 이승제, 윤석제, 이준행
(8) 수행부서 주소	**(9) 연구의뢰기관**
대전광역시 유성구 유성대로1689번길 125	

(10) 초록

최근 기후변화 및 오염원 증가 등으로 주요 식수원인 댐에서 녹조 발생이 증가 추세다. 경계 단계가 발령되는 남조류 대량 증식(1만 셀/mL 이상)은 여름철 고질적 사회 이슈가 되고 있다. 그러나 남조류는 연중 대부분 매우 낮거나 발생하지 않다가 6~9월 급증하며, 원인이 되는 다양한 인자가 복잡하게 얽혀 있어 기존 물리 모델이나 AI 모델로도 고농도의 녹조를 정확히 예측하기가 쉽지 않다. 이처럼 특정 시기에 집중된 고농도 녹조 발생을 효과적으로 관리하고 예측하기 위해서는 지역별로 다양한 환경적 특성을 고려한 데이터분석 및 활용 표준화(SOP) 방안 마련이 시급하다.

본 연구는 대상 지역별 원시자료 특성과 현업 요구를 종합 반영한 표준운영절차(SOP)를 개발해 AI 모델의 예측력을 높이고자 했다. SOP에는 이상값 탐지 및 결측값 처리기법을 포함하는 전처리, 변수의 통계적 특성과 예측력을 평가하는 탐색적데이터분석(EDA), 최적의 변수선택 등으로 구성된다. 특히 변수선택 과정에서는 도메인 지식과 시계열 특성을 함께 반영하여 AI 모델의 학습성능 향상을 도모한다. 고농도의 녹조는 주로 여름철에 제한적으로 나타난다. 이러한 데이터 불균형 문제는 AI 모델이 저농도 데이터 위주로 학습하여, 실질적으로 중요한 고농도 녹조 사상에 대한 예측력이 낮아지는 결과로 나타난다. 이를 해결하기 위해 고농도 사상을 통계적으로 합성해 추가하는 데이터 증강(Data Augmentation) 기법을 적용하면 모델 예측력 향상에 도움이 될 수 있다. 이러한 과정을 거쳐 보완된 학습자료는 자료의 수가 적고 변수 간 복잡한 상호작용이 존재하는 환경에서도 안정적 성능을 발휘하는 것으로 알려진 Random Forest, GBM, XGBoost 등 의사결정나무 알고리즘을 적용해 녹조·수질 예측 모델을 구축하였다.

본 연구에서 개발된 표준분석절차(SOP)와 AI 예측 모델은 향후 현장 적용성을 높이기 위해 사용자 접근성이 뛰어난 웹기반 플랫폼으로 구축하였다. 또한, 향후 추가 연구를 통해 예보 자료 및 물리모델 모의 결과를 결합한 하이브리드 형태로 발전시켜 녹조·수질 예측의 정확도와 신뢰성을 지속적으로 향상시켜 나갈 계획이다. 이를 통해 다양한 저수지 내 녹조 발생 원인 규명 및 수질관리 정책효과 분석에 대한 기여가 기대된다.

(11) 키워드

녹조, 인공지능, 남조류, 데이터 증강, 탐색적 데이터분석, 하이브리드 모델

(12) #태그

#녹조예측, #인공지능

(13) 공개여부	(14) 총면수
예	377

BIBLIOGRAPHIC DATA SHEET

(1) Classification of Technology	(2) Research Method	(3) Submission Date
2026-WR-RR-21-107		Dec. 31, 2025

(4) Title/Subtitle	(5) Research Period
Development of an algal blooms prediction model via data-driven AI technique considering hydraulic characteristics	Feb. 1, 2024 ~ Dec. 31, 2025
(6) Performing Organization	**(7) Author(s)**
AI Research Lab., KIWE, K-water	Choongsung Yi, Seonghun Kim, Jiyeong Jung, Jewan Ryu, SeungJe Lee, Seokje Yoon, Junhaeng Lee
(8) Performing Organization Address	**(9) Sponsoring Agency**
125, Yuseong-daero 1689beon-gil, Yuseong-gu, Daejeon, Republic of Korea	

(10) Abstracts

Recently, the occurrence of algal blooms in reservoirs, which serve as major drinking water sources, has been increasing due to climate change and the growing influence of pollution sources. In particular, severe cyanobacterial blooms exceeding the alert threshold (over 10,000 cells/mL) have become a chronic social issue during the summer season. However, cyanobacteria remain at very low concentrations or are absent for most of the year, then rapidly increase between June and September. Because their outbreaks are driven by complex interactions among multiple environmental factors, accurately predicting high-concentration algal blooms remains challenging even with existing physical models or AI-based approaches. Therefore, to effectively manage and forecast high-density blooms concentrated in specific periods, there is an urgent need to establish standardized data analysis and utilization procedures (Standard Operating Procedures, SOPs) that reflect diverse regional environmental characteristics.

This study aimed to enhance the predictive performance of AI models by developing an SOP that comprehensively incorporates the raw data characteristics and operational demands of each target region. The proposed SOP consists of preprocessing steps including anomaly detection and missing-data imputation, exploratory data analysis (EDA) to evaluate statistical properties and predictive relevance of variables, and optimal feature selection. In particular, the feature selection process integrates domain knowledge and time-series characteristics to improve AI model learning performance. High-concentration algal bloom events occur primarily during the summer and are relatively rare, resulting in a severe data imbalance problem. Under such conditions, AI models tend to be trained mainly on low-concentration observations, leading to reduced predictive capability for practically critical high-density bloom events. To address this issue, data augmentation techniques that synthetically generate additional high-concentration samples can be applied to improve model performance. Based on the enhanced training dataset, this study developed algal bloom and water-quality prediction models using decision-tree-based algorithms such as Random Forest, GBM, and XGBoost, which are known to provide stable performance even with limited data and complex variable interactions.

To increase practical applicability, the SOP and AI prediction models developed in this study were implemented in a web-based platform with high user accessibility. Furthermore, future research will focus on advancing the system into a hybrid framework by integrating forecast data and physical model simulation outputs, thereby continuously improving the accuracy and reliability of algal bloom and water-quality prediction. The results are expected to contribute to identifying the causes of algal blooms in various reservoirs and to supporting the evaluation of water-quality management policy effectiveness.

(11) Keyword
Algal bloom, AI, Blue-Green Algae, Data augmentation, Exploratory Data Analysis(EDA), Hybrid Model

(12) # Tag
#Algal Bloom, #AI

(13) Security	(14) No. of Pages
No	377

주의사항

본 보고서의 저작권은 한국수자원공사에 있으므로, 본 자료의 내용을 허가없이 인용, 복사, 전재, 재배포를 할 경우 법적 제재를 받을 수 있습니다.

Copyright ⓒ 2025
by
Korea Water Resources Corporation

발행인 : 한국수자원공사 사장 윤석대
발행일 : 2025. 12. 31
발행처 : 한국수자원공사 K-water연구원
대전광역시 유성구 유성대로 1689번길 125
Tel. (042) 870-

한국수자원공사는 친환경 기업윤리 이념을 구현하기 위하여 『**환경경영**』을 선포하고, 모든 보고서 발간에 『**재생용지 및 무코팅 방식**』을 사용하고 있습니다.