K-water연구원
2021-WR-RR-1-6
M190096
Final Report

수자원분야 위성영상 활용기술개발

수자원분야 위성영상 활용 기술 개발

Development and further enhancement of hydrological applications using multi-source satellite-based products

2021. 1

K water 한국수자원공사

KOREA
WATER RESOURCES
CORPORATION

수자원분야 위성영상 활용 기술 개발

Development and further enhancement of hydrological applications using multi-source satellite-based products

2021. 1

K water 한국수자원공사

제 출 문

사 장 귀하

이 보고서를 2020년도 K-water연구원 유역물관리연구소에서 수행한 “수자원분야 위성영상 활용 기술개발”의 최종 연구보고서로 제출합니다.

2021. 1.

연구책임자 :	K-water연구원	차장	권 문 혁
연구수행자 :	K-water연구원	책임위원	최 성 화
	K-water연구원	대리	박 지 용

연구개발결과 활용보고서

<table>
<tr><td rowspan="13">1. 연구 총괄</td><td colspan="2">[간행물 관리번호: 2021-WR-RR-1-6]</td><td colspan="3">[과제번호: M190096]</td></tr>
<tr><td>(1)연구과제명</td><td colspan="4">수자원분야 위성영상 활용 기술 개발</td></tr>
<tr><td rowspan="4">(2)수 행 부 서</td><td rowspan="4">K-water연구원
유역물관리연구소</td><td rowspan="4">(3)연구책임자</td><td>성명</td><td>권문혁</td></tr>
<tr><td>소속</td><td>유역물관리연구소</td></tr>
<tr><td>전화번호</td><td>042-870-7417</td></tr>
<tr><td>E-mail</td><td>watermun@kwater.or.kr</td></tr>
<tr><td>(4)연 구 기 간</td><td>2018. 1. ~ 2020. 12.
(총 36개월)</td><td rowspan="3">(5)총연구개발비
(천원)</td><td colspan="2" rowspan="3">400,000</td></tr>
<tr><td>(6)협 동 기 관</td><td>-</td></tr>
<tr><td>(7)참 여 기 업</td><td>-</td></tr>
<tr><td>(8)기 술 분 야</td><td>위성</td><td>(9)참여 연구원</td><td colspan="2">3명/ 1년</td></tr>
<tr><td colspan="5">(10)연구개발목표</td></tr>
<tr><td colspan="5">○ 위성 자료를 활용 물 관리 분야에 적용 가능한 기술 검토 → 개발 → 검증 및 실용화 방안 마련</td></tr>
<tr><td colspan="5">(11)주요연구내용</td></tr>
<tr><td colspan="5">□ (물환경) 가용한 실측 자료를 추가 활용 회귀식 산정에 필요한 데이터를 확보 후, AI 등 新 기술을 활용 수질항목 예측(Chl-a, SS, 수온) 알고리즘 개선

□ (수변환경) 주요 수변환경 모니터링 지점을 중심으로 현장조사를 통한 위성자료 분류체계 개선

□ (수위추정) 남한지역 댐을 대상으로 검·보정을 통해 북한댐 수위 관측 정밀도 제고

□ (토양수분) 위성기반 토양수분 등 수문정보를 활용하여, 기존 유출모형과 결합한 Hybrid 모형을 개발하고, 미계측 유역 등에 적용성 검토

□ (가뭄지수) ERA-Interim 토양수분 데이터를 활용, 기상학적 가뭄지수(SPI)와 결합한 다변량 가뭄지수를 개발하여 남한을 대상으로 가뭄의 시공간적 경향성 분석</td></tr>
</table>

2. 연구성과 활용 유형 및 주요 연구성과

(12) 연구결과의 활용

구분	기술실용화				교육 및 지도	정책활용	설계기준, 시방서, 지침에 활용	기타
	실용화 완료	실용화 추진중	실용화 보류(중단)	선행 연구				
		○						

(13) 주요 연구성과 및 기술 개발단계

◦기 술 명 : ◦기술특성 :	◦기술의 완성도 기초, 탐색연구단계 ( ), 응용연구단계 ( ), 개발연구단계 ( ) 기업화 준비단계 ( ), 상품화 완료단계 ( ) ◦기술 수명주기 기술개념 정립기 ( ), 기술 실험기 ( ) 기술적용 시작기 ( ), 기술적용 성장기 ( ) 기술적용 성숙기 ( ), 기술적용 쇠퇴기 ( )

3. 경제적 효과

(14) 현장적용실적

① 공사현장 정보	공사명	공사기간	물량 (총물량)	발주기관	시공기관	R&D 참여자 역활

② 공사 현장별 적용효과

가. 현장명

구분	기 존 (A)	개 선 (B)	단위효과 (C=A−B)	현장 총물량 (D)	향상도 $(\frac{A-B}{A}X100)$	적용현장 총효과 (C×D)
공사비 (백만원/㎡)1)						
유지관리비 (백만원/㎡)1)						
기타비용절감 (백만원/㎡)1)						
사고율 (명/UC)						
고 용 (명/UC)						
공 기 (일/UC)						
내구성 (年)						

4. 기술적 효과

(15) 기술개발목표 달성도

구분	지표명 (단위)	개발전 국내수준	당개발사업 최종목표치	개발결과 실제달성치	현재국내 기술수준	세계 최고 기술수준
기술성능지표						

(16) 산업재산권 (발명특허·실용신안·의장·s/w)

구분	명칭	출원국	출원 및 등록자	출원		등록	
				출원일	출원번호	등록일	등록번호

(17) 건설신기술 지정

명 칭	출 원 일	고 시 일	보호기간	지정번호

(18) 기타 등록 및 지정현황(상품, 서비스 등록, KT 마크 등)

명 칭	출 원 일	고 시 일	보호기간	기 타

5. 학술적 효과

(19) 국내외 전문학술지 게재

구분	논문제목	학술지명	국명	통권, 호	년,월
일반 학술지	A Hybrid Approach Combining Conceptual Hydrological Model, Support Vector Machine and Remote Sensing Data for Rainfall-Runoff Modeling	Remote Sensing	스위스	1801, 12	2020.6

(20) 학술회의 발표

논문제목	학술회의 명칭	국 명	연 도 · 호

6. 공공적 효과

(21) 법·제도 (설계기준, 시방서, 지침) 등에 활용

구분	명칭 및 조항1)	시행일시	기 존 내 용	신 규 내 용
법				
규정/지침				
기준				
시방서				

(22) 정책수립에 활용

정책명	정책추진 실적	정책추진 일시	담당부처·팀	기대효과

(23) 교육 및 지도에 활용

구분	교육명	교육내용	교육대상	교육시간	교육인원	교육회수
교육훈련						
기술상담						
현장기술지도						

(24) 사회적 성과

요 약 문

1. 연구제목

□ 수자원분야 위성영상 활용 기술개발

2. 연구기간

□ 2018. 1. 1 ~ 2020. 12. 31

3. 연구목적

□ 홍수, 가뭄, 수질 등 물관리 요소들은 시공간적 변화가 큰 특성을 갖기 때문에 기존의 전통적인 점 단위 관측방법은 수문 요소의 공간적 변화 분석에 한계

○ 위성영상은 시공간적으로 광역단위의 관측이 가능하며, 특히 관측 센서 활용과 여러 알고리즘 적용에 따라 다양한 정보를 생산할 수 있는 장점이 있음

○ 본 연구에서는 위성 자료를 활용한 유출모형 적용기술, 수질 모니터링 및 예측기술, 미계측지역 수자원 조사 및 평가 기술 등을 개발하여 기술력 확보 및 K-water 사업 모델을 제안

4. 연구내용

□ (물환경) 가용한 실측 자료를 추가 활용 회귀식 산정에 필요한 데이터를 확보 후, AI 등 新 기술을 활용 수질항목 예측(Chl-a, SS, 수온) 알고리즘 개선

□ (수변환경) 주요 수변환경 모니터링 지점을 중심으로 현장조사를 통한 위성자료 분류 체계 개선

□ (수위추정) 남한지역 댐을 대상으로 검·보정을 통해 북한댐 수위 관측 정밀도 제고

□ (토양수분) 위성기반 토양수분 등 수문정보를 활용하여, 기존 유출모형과 결합한 Hybrid 모형을 개발하고, 미계측 유역 등에 적용성 검토

5. 연구결과

□ 물관리 분야 위성영상 활용 기술 조사

○ 위성영상을 활용한 수리 수문인자 (강우, 강설, 토양수분 등) 추출 기술동향 조사

○ 위성영상을 활용한 수자원활용 분야 사전연구 조사 및 국내 적용성 검토

□ AI기법을 활용한 수질분석 기술 개발

○ 고해상도 광학 (Sentinel-2)영상을 이용하여 낙동강 수계를 대상으로 수질인자 (클로로필-a, 조류세포수, 부유물질)를 추정하는 인공지능 (RF,XGB, CTB)기반의 알고리즘을 개발하였음

○ 모델성능의 개선을 위하여 각 수질인자별로 RFE (recursive feature elimination) 방법을 통한 변수 선택 과정을 거쳐 변수를 선정하였으며, 3 × 3 픽셀 윈도우를 활용한 smoothing 및 오버샘플링(oversampling)을 수행하였음

○ 수질인자별 분석 알고리즘을 활용하여 낙동강 수계에 대한 수질인자별 시각화 기법(mapping)과 시 · 공간적 변화탐지, 경향분석을 위한 통계처리 방안을 제시하였음

□ 하천경관 변화분석 기법 개발

○ 고해상도 광학 (Sentinel-2)영상을 이용하여 낙동강 유역을 대상으로 수변환경 분류를 수행하였으며, 랜덤 포레스트를기반으로 모델을 구축 하여 기존 알고리즘 (위성영상 활용 용수수요인자 및 수변환경변화 분석기법 연구, 2019) 대비 향상된 결과를 얻음.

○ 기존 알고리즘에서 한계점으로 분석되었던,

- 구름 및 구름 그림자로 인한 문제를 Fmask4.0 을 사용해 개선
- 나지의 반사도 학습이 어려운 문제를 분광(식생)지수를 사용해 개선
- 학습 샘플의 수가 부족하거나 치우친 문제를 조정하여 개선

○ 제시된 알고리즘은 수위변화에 따른 나지 면적의 증감을 파악할 수 있도록 고도화되었으며, 낙동강 내 댐 수위 및 강의 수위변화를 통해 검증한 결과 시공간적 나지 변화를 탐지할 수 있음을 확인하였음.

○ 위성영상을 통한 수변환경 분류지도 생산의 한계점 및 미계측유역 적용 시 발생할 수 있는 한계점에 대해 논의함.

□ 미계측 유역 수위추정 기법 개발

○ 위성영상을 활용하여 접경 북한댐 수위 모니터링을 개선하는 방안을 제시하기 위하여 실험대상 유역을 댐유역 규모 등을 고려하여 대청댐에 대하여 수행

○ 수체탐지를 위한 임계값 산출을 확인하기 위하여 SAR 위성인 Sentinel-1의 후방산란계수를 이용한 댐 수위 분석에서 수계경계 추출을 위한 후방산란계수위 임계값은 -14.5dB이 가장 적합하였고, 광학영상 Sentinel-2에서는 수체추출을 위하여 NDWI의 임계값을 분석한 결과 -0.1~-0.15를 적용하는 효율적으로 나타남.

○ 댐체영역과 댐상류 지표경사가 완만한 지역을 비교한 결과, 10m 급의 영상분석에

서는 큰 차이가 없었으나, 고해상도 위성영상에서는 수위변화에 따른 수면적이 변화가 큰 댐상류지역의 수위값 분석이 오차가 적게 나타남.

○ 전전후 SAR 위성과 기상조건에 민감하지만 자료처리 등의 장점이 있는 광학영상을 비교한 결과 수위분석 정확도에는 크게 차이가 없는 것으로 분석되었다.

□ 위성자료기반 Machine learning 기술을 활용한 Hybrid 유출모형 개발

○ 위성 토양수분자료(ESA CCI)를 Machine learning 기법을 활용하여 기존 강우-유출모형과 결합한 Hybrid 강우-유출모형 개발 및 용담댐을 대상으로 적용성 검토함.

○ Tank-LSSVM 모형이 Tank 및 LSSVM 기반의 강우-유출 모형보다 모의 성능이 우수한 결과를 나타냄.

- Tank 모형 : NSE 기준 탱크 모형의 강우-유출 모의 수행능력은 “Very Good (NSE > 0.7)”으로 평가되었으나 저유량 부분에서 관측 유량과 상대적 큰 차이를 보임
- LSSVM 모형 : Tank 모형보다 낮은 모의 능력을 보였으나, 위성 토양수분 자료의 강우-유출 모형에서 활용성 확인
- Tank-LSSVM 모형 : NSE 기준 Training 및 Testing 기간 모두 탱크 모형 및 LSSVM 기반의 강우-유출 모형과 비교하여 개선된 모의 능력을 보임

□ Remote Sensing 토양수분 데이터를 활용한 다변량 가뭄지수 개발

○ ERA-Interim 토양수분 데이터를 활용, 기상학적 가뭄지수(SPI)와 결합한 다변량 가뭄지수를(Multivariate Standardized Drought Index) 개발함.

○ 기상학적가뭄지수(SPI)와 농업적가뭄지수(SSI)의 교차상관분석(Cross correlation)

- 30년 이상 기상자료의 취득이 가능한 55개 지점을 대상으로 SPI-6 및 SSI-6의 교차상관분석결과 기상학적 가뭄에서 농업적 가뭄으로 전이는 대부분의 지점에서 1개월 소요
- SPI와 SSI의 상관관계 정도(기상학적 가뭄이 토양수분에 미치는 영향)는 계절별·월별 차이를 보이는 현상이 뚜렷함

○ 다변량 가뭄지수(Multivariate Standardized Drought Index) 활용한 가뭄특성 군집 분석

- SPI와 SSI 가뭄지수를 코플라 함수를 이용해서 하나의 결합된 다변량 가뭄지수인 MSDI 유도 → Hierarchical clustering 알고리즘을 이용 군집분석
- Quantile Regression 모델을 활용하여, 가뭄의 정도(분위)별 가뭄의 경향성(Trend) 분석

□ 수자원분야 위성영상 기술 활용방안 및 사업모델

○ 수자원분야 위성영상 기술 국내외 현업적용 사례를 분석

- 수자원 분야 위성영상 산출물 및 현업 플랫폼 운용 현황 분석을 통하여 국내 수자원 분야 적용성및 한계점을 도출
- 수자원 분야의 광학 기반, SAR 영상 기반 위성영상 국내 활용 방안을 제시

○ 국내.외 물산업트렌드를 고려한 위성영상 활용 사업모델을 제시

- 수자원 분야 빅데이터 통합 관리(QA/QC 및 표준화) 및 위성관측을 고려한 통합 현장자료 관리 시스템 개발 사업
- 다종위성 융합을 통한 기존 수자원 분야 산출물의 시·공간 상세화 사업
- 인공지능 및 자동화 알고리즘을 활용한 수자원 분야 빅데이터 자동 통합관리 플랫폼 개발 사업
- 저개발국가 대상 수자원 관리 기술 이전을 위한 공적원조개발 사업 추진 기법 개발 사업

목 차

제 출 문 ····· Ⅰ
요 약 문 ····· Ⅵ
목 차 ····· Ⅷ
표 목 차 ····· Ⅺ
그림목차 ····· Ⅻ

제1장 서 론 ····· 1

1.1 연구배경 ····· 1
1.2 연구 결과 요약 ····· 2

제2장 물관리 분야 위성영상 활용현황 조사 ····· 10

2.1 수리·수문인자 ····· 10
2.1.1 강우 (Rainfall) ····· 10
2.1.2 강설 (Snow cover) ····· 16
2.1.3 토양수분 (Soil moisture) ····· 18
2.2 위성자료의 수자원분야 활용현황 ····· 25
2.2.1 강우-유출 (Rainfall-runoff) ····· 25
2.2.2 가뭄 모니터링 (Drought monitoring) ····· 27
2.2.3 수질분야 (Water quality) ····· 32
2.2.4 수변환경(토질피복) (Land cover) ····· 49
2.2.5 수문량 추정 (Hydrology Estimation) ····· 65

제3장 AI기법을 활용한 수질분석 기법 개발 ····· 70

3.1 서론 ····· 70
3.2 수질분석 기법 현업 적용성 검토 ····· 70
3.2.1 수질분석 현업적용 가능한 위성 및 분식기법 검토 및 제시 ····· 70

3.3 위성영상 수질분석 알고리즘 개발 및 고도화 ····· 75
3.3.1 현장자료 및 위성관측자료 매칭을 통한 수질인자별 분광특성 분석 ····· 75
3.3.2 인공지능 기법 활용 수질 인자별 분석 알고리즘 도출 ····· 86
3.3.3 기존 알고리즘과의 비교·검증을 통한 정확도 평가 ····· 88
3.4 인공지능 기반 위성영상 수질분석기술 모듈화 및 현업화 지원 ····· 91
3.4.1 수질분석 자료의 시각화 기법 및 시·공간 경향 분석을 위한 기법 제시 ····· 91
3.4.2 개발한 알고리즘의 한계점 및 논의사항 제시 ····· 94
3.4.3 K-water 시스템 적용을 위한 소스코드 및 운영 매뉴얼 작성 ····· 95

제4장 하천경관변화 분석 기법 개발 ····· 106

4.1 연구 목적 ····· 106
4.2 기존 알고리즘 검증 및 한계점 분석 ····· 107
4.2.1 기존 알고리즘의 한계점 및 원인 제시 ····· 107
4.2.2 수변환경 변화분석 알고리즘 검증의 공간적 범위 ····· 108
4.2.3 기존 샘플 및 현장조사를 통한 위성활용 수변환경 변화 분석 알고리즘 검증 ····· 109
4.2.4 유사한 반사도 특성을 보이는 식생지역 (농경지, 초지, 목지) 비식생지역(나지, 건물)에 대한 오분류 분석 ····· 110
4.2.5 위성영상 자체의 문제(구름, 그림자)로 인한 기존 알고리즘의 한계점 분석 및 오분류 원인별 특성 ···· 113
4.3 알고리즘 개선 및 결과성능 검증 ····· 114
4.3.1 연구 개요 ····· 114
4.3.2 식생(광학)지수 사용을 통한 알고리즘 개선 ····· 119
4.3.3 추가적인 참조자료 구축을 통한 알고리즘 정확도 개선 및 평가 ····· 123
4.3.4 수위변화에 따른 나지 증감 파악을 위한 알고리즘 고도화 ····· 124
4.3.5 샘플 수 조정을 통한 알고리즘 고도화 ····· 126
4.3.6 구름 및 구름 그림자 제거를 통한 오분류 최소화 및 시계열 분석 ····· 126
4.3.7 수위변화에 따른 알고리즘 평가 ····· 134
4.3.8 변화탐지 알고리즘 구현 ····· 138
4.3.9 개선된 수변환경 분류 알고리즘의 공간적 분석 ····· 139
4.3.10 개선 알고리즘의 한계 및 보완사항 ····· 143
4.3.11 미계측지역 적용에 대한 한계 및 유의사항 검토 ····· 148
4.4 인공지능 기반 위성영상 수변환경 변화 분석 모듈 개선 및 현업화 지원 ····· 149
4.4.1 전처리 프로그램 설치 ····· 149
4.4.2 프로그래밍 언어 Python을 이용한 전처리 프로그램인 Fmask4.0 및 Sen2Cor 실행 ····· 156
4.4.3 프로그래밍 언어 Python을 이용한 수변환경 분류지도 생산 ····· 157

제 5 장 미계측 유역 수위 추정 기법 개발 ····· 174

5.1 서론 ····· 174
5.2 연구내용 및 방법 ····· 175
5.2.1 대상지역 ····· 175
5.2.2 자료수집 ····· 177
5.2.3 연구방법 ····· 179
5.3 결과 및 토의 ····· 182
5.4 결론 ····· 187

제6장 Machine learning 기술을 활용한 Hybrid 유출모형 개발 ····· 188

6.1 서론 ····· 188
6.2 연구대상지역 및 연구방법 ····· 189
6.2.1 용담댐 현황 ····· 189
6.2.2 연구방법 ····· 192
6.3 결과 및 토의 ····· 197
6.3.1 탱크모형을 이용한 강우-유출 모의 ····· 197
6.3.2 LSSVM 및 Tank-LSSVM 모형 ····· 200
6.4 결론 ····· 205

제7장 Remote Sensing 기술을 활용한 다변량 가뭄지수 개발 및 적용 ····· 208

7.1 서 론 ····· 208
7.2 연구방법 ····· 211
7.2.1 가뭄지수 산정방법 ····· 211
7.3 결과 및 토의 ····· 212
7.3.1 기상학적 가뭄지수(SPI) 및 농업적 가뭄지수(SSI) ····· 212
7.3.2 가뭄의 공간적 패턴 ····· 214
7.3.3 다변량 가뭄지수(Multivariate Standardized Drought Index, MSDI)를 활용한 가뭄특성 군집 분석 (Clustering analysis) ····· 217
7.4 결론 ····· 221

제8장 수자원분야 위성영상 기술 활용방안 및 사업모델 제시 ····· 224

8.1 연구 배경 및 방법 ····· 224
8.1.1 연구 배경 ····· 224

8.1.2 연구 방법 ····· 225
8.1.3 기대 효과 ····· 226
8.2 수자원분야 위성영상 기술 국내·외 현업적용 사례 조사 및 분석 ····· 227
8.2.1 국내·외 수자원분야 위성영상 산출물 현황 분석 ····· 227
8.2.2 국내·외 수자원분야 위성영상 기술 활용 사례 분석 ····· 230
8.2.3 국내·외 위성영상 활용 수자원 분야 플랫폼 현황 비교·분석 ····· 232
8.3 국내·외 물산업 트렌드를 고려한 위성영상 활용 국내외 사업 모델 제시 ····· 233
8.3.1 국내 물산업 트렌드 분석 ····· 233
8.3.2 수자원 분야 위성영상 활용 사례 분석을 통한 국내 적용 방안 제시 ····· 237
8.3.3 물산업 트렌드를 고려한 위성영상 활용 수자원 분야 사업모델 제시 ····· 246

제9장 맺음말 ····· **264**

표 목차

표 2.1 기관별-고도별 강우관측소 분포 ····· 11
표 2.2 Grid 기반 강우 데이터 현황 및 특징 ····· 13
표 2.3 위성 기반 강우 자료 현황 및 특징 ····· 14
표 2.4 Reanalysis 기반 강우자료(요약) ····· 16
표 2.5 강설량 관측에 주로 사용되는 센서 및 위성 현황 ····· 17
표 2.6 토양수분 측정 방법 (요약) ····· 19
표 2.7 위성영상을 활용한 토양수분 측정방법 및 장·단점 ····· 20
표 2.8 토양수분 관측 위성 리스트 및 특징 ····· 21
표 2.9 위성자료를 활용한 강우-유출모형 적용사례 ····· 26
표 2.10 가뭄의 정의 ····· 27
표 2.11 가뭄지수의 특징 및 장단점(요약) ····· 27
표 2.12 SPI에 의한 가뭄 상태의 분류 ····· 30
표 3.1 Sentinel-2A/B의 분광 밴드 특징 ····· 71
표 3.2 Landsat 7호 및 8호 위성 전자광학탑재체의 사양 ····· 72
표 3.3 RFE를 통해 선정된 각 수질인자별 추정 모델 추정 변수 ····· 85
표 4.1 계절별 수변 환경 overall 분류 정확도 ····· 107
표 4.2 과업에 사용된 Sentinel-2 각 밴드별 분광 영역, 파장대, 공간해상도 정보표 ····· 114
표 4.3 본 과업에서 개선한 알고리즘의 구름 마스킹 방법별 알고리즘 정확도 비교 ····· 130
표 4.4 무인항공기 기반 초지 샘플에 대한 예측결과 (경북 구미시 선산읍 20201123) ····· 141
표 4.5 무인항공기 기반 나지 샘플에 대한 예측결과 (경북 구미시 선산읍 20201123) ····· 141
표 4.6 무인항공기 기반 초지 샘플에 대한 예측결과 (대구 달성군 현풍읍 20201204) ····· 141
표 4.7 무인항공기 기반 목지 샘플에 대한 예측결과 (대구 달성군 현풍읍 20201204) ····· 141
표 5.1 임진강 유역 현황 ····· 174
표 5.2 Sentinel-1 IW 모드의 특성 ····· 178
표 5.3 Sentinel-2A 위성 채널 ····· 178
표 5.4 DEM 해상도에 따른 수위 ((a)1m DEM, (b)10m DEM) ····· 182
표 5.5 Sentinel-1 영상의 후방산란계수에 따른 수위분석 결과 ····· 184
표 5.6 Sentinel-2 영상의 NDWI에 따른 수위분석 결과 ····· 185
표 5.7 COSMO-SkyMed 영상의 후방산란계수에 따른 수위분석 결과 ····· 186
표 6.1 용담댐 유역 토양수분 및 강우측정 지점 현황 ····· 190
표 6.2 ESA CCI 토양수분자료 특성 ····· 196
표 6.3 모형 평가 지표(O: 관측값, E 모의값, $\overline{O}$: 관측값 평균, $\overline{E}$: 모의값 평균) ····· 197
표 6.4 3단 탱크모형의 파라미터 범위 및 본 연구에서 도출된 파라미터 값 ····· 198
표 6.5 입력 자료의 조합에 따른 LSSVM 모델 수행 결과 ····· 202
표 6.6 입력 자료의 조합에 따른 Tank-LSSVM 모델 수행 결과 ····· 203

표 7.1 강우관측소 제원 ····· 210
표 7.2 본 연구에서 고려된 Copula 함수군 ····· 211
표 7.3 기상관측소별 군집분석 결과 ····· 218
표 7.4 a) MSDI-3 및 b) MSDI-6의 가뭄 발생횟수, 지속기간(Duration) 및 심도(Severity) ····· 220
표 7.5 MSDI 가뭄지수의 분위별 Trend 분석 결과 ····· 220
표 8.1 국내·외 수자원 분야 위성 산출물 및 시·공간 해상도 ····· 229
표 8.2 국외 수자원·수재해 관련 위성 활용 현황 (채효석 외, 2017) ····· 230
표 8.3 국내 수자원분야 관련 빅데이터 분석 및 제공 시스템 현황 (K-water, 2019) ····· 231
표 8.4 「물관리 그린뉴딜」 정책심포지엄 (2020. 06. 29.) 발표주제 및 발표자 ····· 234
표 8.5 한국판 뉴딜과 물 분야의 그린뉴딜 심포지엄 (2020. 05. 20.) ····· 234
표 8.6 한국수자원학회「물과미래」지 수자원위성 특별호 게재 내용 (Vol. 52, No. 10) ····· 236
표 8.7 K-water 해외 사업 이력 ····· 241
표 8.8 K-water의 세계 물 포럼 참여 현황 ····· 244
표 8.9 주요 수자원 분야 위성별 품질관리 및 자료 검보정 방법 현황 ····· 248
표 8.10 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 위성 자료 ····· 252
표 8.11 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 현장 관측 자료 ····· 253
표 8.12 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템: 활용가능 위성 자료 ····· 254
표 8.13 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템: 활용가능 현장 관측 자료 ····· 254
표 8.14 위성 활용 실시간 수위, 수량 관측·관리 시스템: 활용가능 위성 자료 ····· 255
표 8.15 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 현장 관측 자료 ····· 257
표 8.16 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 위성 자료 ····· 261
표 8.17 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템: 활용가능 위성 자료 ····· 263

그림 목차

그림 2.1 지상 강우관측 장비 (출처: National Aeronautics and Space Administration(NASA)) ····· 10
그림 2.2 a) 고도에 따른 연평균 강수량(2016~2019), b) 고도별 강우관측소 현황(2020 기준) ····· 10
그림 2.3 고도에 따른 강우분포현황(남강댐 사례) ····· 11
그림 2.4 강우관측소 분포(국립공원공단 관리) ····· 12
그림 2.5 강우 관측 위성 현황 ····· 14
그림 2.6 위성을 활용한 강우자료 생성 절차 ····· 15
그림 2.7 원격탐사 기법을 활용한 강설분포도 ····· 17
그림 2.8 토양수분 측정 개념도(a: Neutron Probe, b: TDR) ····· 18
그림 2.9 토양수분 측정망 분포현황(출처: International Soil Moisture Network) ····· 19
그림 2.10 SMOS 토양수분 분포도(한반도) ····· 21
그림 2.11 SMOS 토양수분 분포(영국) ····· 22
그림 2.12 AMSR-2 토양수분 분포도 (Global scale) ····· 23

그림 2.13 AMSR 2 토양수분 분포도(한반도) ····· 23
그림 2.14 ASCAT 토양수분 분포(한반도) ····· 24
그림 2.15 가뭄의 전이 과정에 따른 가뭄정의 ····· 28
그림 2.16 SPI 산정 개념도 ····· 29
그림 2.17 가뭄특성 정의 ····· 29
그림 2.18 지하수 가뭄지수 (출처: https://grace.jpl.nasa.gov/applications/drought-monitoring/) ····· 31
그림 2.19 Sabeioon 외 (2020)에서 제시한 Cubist 모델을 통해 추정한 (좌) Chl-a 와 (우) TSS의 시간에 따른 분포 지도 ····· 32
그림 2.20 Pu 외 (2019)에서 사용된 수질 등급 분류 기준 ····· 33
그림 2.21 클로로필-a 농도 추정에 사용된 Landsat 밴드의 주성분 분석 결과의 PCA1과 PCA2 사이의 산점도 ····· 34
그림 2.22 위성영상과 SDA 기반 모델을 통해 추정된 결과 ····· 34
그림 2.23 Moses 외 (2012)에서 제시한 MERIS NIR-red 2-밴드 알고리즘을 통해 도출한 클로로필-a 분포 지도 ····· 35
그림 2.24 S.Ekercin 외 (2007)에서 제시한 IKONOS 위성영상을 통해 추정한 수질 결과 ····· 35
그림 2.25 Toming 외 (2016)에서 제시한 밴드비 기반 모델결과 ····· 36
그림 2.26 Wei 외 (2019)에서 고안된 모델인 PSO-LSSVM 모델 ····· 37
그림 2.27 Wei 외 (2019)에서 제안한 PSO-LSSVM 모델 결과의 공간적 분포 ····· 37
그림 2.28 Kudela 외 (2015)에서 제시한 세 가지 지표와 파장에 따른 위성 원격 반사도 값의 분포 (좌). 세 가지 인덱스와 추정된 마이크로시스티스 속 농도와의 상관관계 (우). ····· 38
그림 2.29 Yim 외 (2019)에서 사용한 현장 관측 피코시아닌 농도와 본 연구에서 고안한 SAE-DNN 모델 및 비교 모델을 통해 추정된 피코시아닌 농도 간의 산점도 ····· 39
그림 2.30 He 외 (2013)에서 제시한 UV-AC를 적용하여 추정된 부유물질 농도와 부이 기반 부유물질 간의 산점도 ····· 39
그림 2.31 Shahzad 외 (2018)에서 제시한 밴드별 반사도와 NDSSI 회귀 모델로 추정한 부유물질 농도와 현장관측 부유물질 농도 사이의 산점도 (좌)와 분포 지도 (우) ····· 40
그림 2.32 Nguyen 외 (2020)에서 제시한 NSMI 회귀모델로 추정한 부유물질 농도와 현장관측 부유물질 농도 사이의 산점도 ····· 40
그림 2.33 Shin 외 (2017)에서 제시한 시아노박테리아 예측 모델 흐름도 ····· 41
그림 2.34 수직-수직 편광 자료와 클로로필-a 농도 사이의 추세 ····· 42
그림 2.35 비교 모델인 3 밴드 모델과 SAR의 수평 및 수직 편광자료를 추가한 모델 간의 비교 결과 ····· 42
그림 2.36 Dörnhöfer 외 (2018)에서 제시한 다종 센서를 활용한 클로로필-a 모니터링 결과 ····· 43
그림 2.37 RapidEye 위성영상을 활용하여 추정한 클로로필-a의 농도 분포 ····· 44
그림 2.38 Lee 외 (2020)에서 제시한 적조 발생 탐지 알고리즘의 연구흐름도 ····· 45
그림 2.39 박성욱 외 (2018) Sentinel-2와 RapidEye 영상의 자료처리 과정 ····· 46
그림 2.40 박성욱 외 (2018)에서 제안한 알고리즘을 통해 추정된 Chl-a ····· 46
그림 2.41 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제 (2017) ····· 47
그림 2.42 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제 (2017) ····· 48
그림 2.43 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제 ····· 48

그림 2.44 Zhu와 Woodcock의 토지피복 변화탐지 및 분류결과 ····· 50
그림 2.45 Clerici 등 (2018)에서 제시한 연구흐름도 ····· 50
그림 2.46 Pereira 등 (2018)에서 사용한 광학 영상과 SAR 영상의 융합방법 ····· 51
그림 2.47 Pereira 등 (2018)에서 광학과 SAR 영상의 융합방법에 따른 토지 피복 분류결과 ····· 51
그림 2.48 Singh 등 (2018)에서 제시한 연구흐름도 ····· 52
그림 2.49 Merchant 등 (2018)에서 사용한 데이터셋 구성과 각 기계학습 별 모델 결과 ····· 53
그림 2.50 Steinhausen 등 (2018)에서 수행한 토지 피복 분류 방법 흐름도 ····· 54
그림 2.51 Demirkan 등 (2020)에서 수행한 토지피복 분류 방법의 흐름도 ····· 54
그림 2.52 Jamali (2020)의 토지피복 분류 연구흐름도 ····· 55
그림 2.53 Wahap (2020)의 CART알고리즘을 이용한 토지피복 분류 결과, 면적 및 각 토지피복이 연구지역 내에서 차지하는 비율 ····· 56
그림 2.54 Abdi (2020)의 기계학습 기반 Sentinel-2 밴드값 및 분광지수를 사용한 토지피복 분류 연구흐름도. ····· 57
그림 2.55 정운재 (2015)의 유역별 토지피복 분류 수행 결과 ····· 58
그림 2.56 박주성 등 (2016)의 창녕군의 최대우도법 기반 토지피복 분류지도 (좌측) Layer-stacking 기반 토지피복분류지도 (우측) ····· 59
그림 2.57 염준호 등 (2018)에서 제시한 연구흐름도 ····· 59
그림 2.58 김용민 등 (2010)에서 제시한 알고리즘의 연천지역 분류결과를 나타내는 혼동행렬 ····· 60
그림 2.59 최병구 등 (2013)의 강원도 고성군 DMZ 지역 토지피복분류 결과 ····· 60
그림 2.60 나현섭 등 (2015)에서 제시한 알고리즘의 결과 혼동행렬 및 분류지도 ····· 61
그림 2.61 환경부 환경공간정보서비스에서 제공하는 대분류 토지피복 분류지도 제작흐름도 ····· 62
그림 2.62 환경부 환경공간정보서비스의 해상도별 토지피복 분류지도. ····· 62
그림 2.63 유럽의 CORINE 토지피복 분류지도 ····· 63
그림 2.64 USGS NLCD 제작 흐름도 ····· 64
그림 2.65 하폭-유량 관계식을 이용한 유량 환산 회귀모형((a)RapidEye, (b)LandSat) ····· 65
그림 2.66 위성레이더 고도계로부터 산출된 수위를 이용한 유량 추정 ····· 66
그림 2.67 위성레이더 고도계를 활용한 고도(수위)측정원리 ····· 67
그림 3.1 Sentinel-2 각 밴드별 파장대 및 공간해상도 ····· 71
그림 3.2 인공지능 기반 위성영상 수질분석기술 모듈화 및 현업화 시나리오 방법론 흐름도 ····· 73
그림 3.3 Sentinel-2 위성 (출처: ESA) ····· 75
그림 3.4 수질측정망 운영 체계 ····· 76
그림 3.5 물환경정보시스템 수질측정망 자료화면 ····· 77
그림 3.6 Random Forest (RF) 모식도 ····· 77
그림 3.7 eXtreme Gradient Boosting (XGB) 모식도 ····· 78
그림 3.8 CaTBoost (CTB) 모식도 ····· 78
그림 3.9 본 과업의 공간적 분석 범위 ····· 79
그림 3.10 본 과업에서 제시한 수질인자 추정 알고리즘 흐름도 ····· 79
그림 3.11 정상 활용 가능 지점에 대한 처리 예시 ····· 80
그림 3.12 지리적 오차에 대한 전처리 예시 ····· 80

그림 3.13 위성 관측에 대한 전처리 예시 ····· 81
그림 3.14 Sentinel-2A/B cloud masking algorithm diagram ····· 81
그림 3.15 중심 픽셀 (P5)과 인근 3 * 3 픽셀 윈도우 (P1 ~ P9)의 예시 ····· 83
그림 3.16 원본 데이터의 클로로필-a 농도 분포와 오버샘플링 후의 농도 분포 비교 ····· 83
그림 3.17 원본 데이터의 부유물질(혼탁도) 농도 분포와 오버샘플링 ····· 83
그림 3.18 본 과업에 사용된 검증 방법인 LOOCV의 원리 설명도 ····· 84
그림 3.19 결과 비교에 활용한 세 가지 경험식 기반 클로로필-a 추정 알고리즘 ····· 85
그림 3.20 RF, XGB, CTB 활용 클로로필-a 농도 추정 결과 (LOOCV) 비교 ····· 87
그림 3.21 RF, XGB, CTB 활용 조류세포수 추정 결과 (LOOCV) 비교 ····· 87
그림 3.22 RF, XGB, CTB 활용 부유물질(혼탁도) 농도 추정 결과 (LOOCV) 비교 ····· 87
그림 3.23 선행연구 (박성욱 등, 2018)에서 제시하고 있는 클로로필-a의 분광 특성 ····· 88
그림 3.24 경험식 기반의 세 가지 다른 클로로필-a 농도 추정 알고리즘과의 성능 비교·검증 ····· 88
그림 3.25 국립환경과학원 물환경정보시스템과 본 과업에서 제안한 인공지능 기반 클로로필-a 추정 알고리즘 (RF, XGB, CTB)을 통해 산출된 창녕 함안보의 클로로필-a 농도 비교 ····· 89
그림 3.26 인공지능 기반 부유물질 (혼탁도) 추정 알고리즘을 통해 산출된 창녕 함안보의 부유물질 분포 ·· 90
그림 3.27 수질인자분석 알고리즘의 시각화를 위한 지리정보 프로그램 활용 ····· 91
그림 3.28 ArcGIS를 활용한 수질인자 추정 알고리즘 시각화 속성 변경 예시 ····· 92
그림 3.29 2020년 04월 14일 클로로필-a 농도 분포 시각화 예시 ····· 92
그림 3.30 시·공간 경향 분석을 위해 제시된 두 가지 통계처리 방안 모식도 ····· 93
그림 3.31 관측 정점 (point) 기반 시계열 분석 방안의 예시 (칠곡 조사정점 클로로필-a 농도의 시계열 분포) ·· 93
그림 3.32 낙동강 수계영역에 대한 시계열 분석 방안 예시 (T52SDF 타일의 클로로필-a 시계열 분포 박스 플랏) ···· 94
그림 3.33 모델 구축 및 저장에 사용되는 파이썬 라이브러리 (library)와 이를 로드하는 과정 ····· 96
그림 3.34 Random Forest (RF) 모델 구축 단계 ····· 96
그림 3.35 Random Forest (RF) 모델 저장 단계 ····· 97
그림 3.36 eXtreme Gradient Boosting (XGB) 모델 구축 단계 ····· 97
그림 3.37 eXtreme Gradient Boosting (XGB) 모델 저장 단계 ····· 98
그림 3.38 CaTBoost (CTB) 모델 구축 단계 ····· 98
그림 3.39 CaTBoost (CTB) 모델 저장 단계 ····· 98
그림 3.40 수질 분석 알고리즘 적용에 필요한 Python 패키지 ····· 99
그림 3.41 Python 환경에서 라이브러리 설치의 예시 ····· 99
그림 3.42 수질 분석에 사용되는 Python 패키지 ····· 100
그림 3.43 수질 분석 결과물이 출력되는 경로와 위성영상 이미지 경로 설정 ····· 100
그림 3.44 원하는 날짜의 위성영상을 불러오는 부분 ····· 100
그림 3.45 수질인자 추정 알고리즘 적용에 필요한 밴드와 밴드비 자료 산출 ····· 101
그림 3.46 수질 알고리즘을 적용하기 위한 수계영역 마스킹 ····· 102
그림 3.47 밴드 위 과정을 통해 생산된 수계 마스크 ····· 102
그림 3.48 각 밴드 자료들을 water mask를 활용하여 수체 영역만 추출 ····· 103
그림 3.49 최종 처리된 위성영상 자료를 한줄로 만들고 수질 알고리즘을 적용하기 위한 자료의 형태로 쌓기 103

그림 3.50 수질 알고리즘 모델을 불러와 원하는 날짜의 위성영상에 적용하는 과정 및 결과물 저장 단계 104
그림 3.51 수질인자 추정 알고리즘이 적용된 결과물 ····· 105
그림 4.1 구름 그림자로 인한 지표반사도 오염(좌측)과 그 결과로 발생하는 기계학습의 오분류 ····· 107
그림 4.2 나지 클래스 샘플의 Sentinel-2A 위성영상의 밴드 및 계절별 반사도 특성 ····· 108
그림 4.3 Sentinel-2 관측 계획. 좌측은 Sentinel-2A의 관측계획 ····· 109
그림 4.4 낙동강의 수변 환경 인자별 (클래스별) 분광특성 정보 ····· 111
그림 4.5 초지와 농경지, 그리고 목지 클래스간의 오분류 예시 ····· 112
그림 4.6 낙동강 수변 환경의 강수 전후 분류 결과 비교 ····· 112
그림 4.7 낙동강 수변 환경 분류에 있어 구름이나 구름 그림자 영역이 물이나 기타 클래스로 오분류 된 예시 ····· 113
그림 4.8 영산강 수변 환경 분류에 있어 구름이나 구름 그림자 영역이 물이나 기타 클래스로 오분류 된 예시 ····· 113
그림 4.9 Sentinel-2 위성의 타일 명명 체계 UTM 투영법에 따라 구분됨 ····· 115
그림 4.10 본 연구의 연구흐름도 ····· 116
그림 4.11 본 과업의 공간적 범위 ····· 116
그림 4.12 혼동행렬 형태 예시 ····· 118
그림 4.13 상자 그림의 형태 예시 ····· 119
그림 4.14 각 분광지수 NDVI, NDWI, NDII7, NDSI, NDBI의 클래스별 박스 플롯 ····· 122
그림 4.15 Google Earth 및 Sentinel-2 영상을 이용한 지상 참조자료 구축 예시 ····· 124
그림 4.16 낙동강의 계절별 클래스별 Sentinel-2 위성의 분광특성 ····· 125
그림 4.17 구름 마스킹에 따른 훈련자료에 사용된 참조자료 수 차이 ····· 126
그림 4.18 Fmask4.0 알고리즘의 구름 탐지 흐름도 (Qiu 등, 2019) ····· 127
그림 4.19 위: Sentinel-2의 기본 구름 마스크 (MSK_CLDPRB.jp2). 아래: Qiu 등 (2019) ····· 128
그림 4.20 구름 마스킹에 따라 제거되는 수변환경분류지도 비교 ····· 129
그림 4.21 본 연구에서 제시한 알고리즘의 구름 마스킹 방법별 시계열 성능평가 ····· 130
그림 4.22 봄의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%) ····· 131
그림 4.23 여름의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%) ····· 131
그림 4.24 가을의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%) ····· 131
그림 4.25 겨울의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%) ····· 132
그림 4.26 수변환경의 식생 (초지,목지,농경지) 의 정확도의 시계열 성능 평가 ····· 132
그림 4.27 위성영상 활용 용수수요 인자 및 수변환경 변화 분석기법 연구 (2019) 의 알고리즘 검증 정확도 ··· 133
그림 4.28 구름 마스킹 방법별 수변환경 분류 알고리즘의 연간 정확도 평가 ····· 134
그림 4.29 모래톱 증감 파악을 위한 나지 클래스 추출 및 면적 계산 흐름도 ····· 135
그림 4.30 하천 수위변화에 따른 나지증감 분석 ····· 136
그림 4.31 낙동강 댐 평균 수위와 나지 증감 시계열 그래프 및 경상북도 김천시 아포읍 의리 부근의 2020년 봄과 2020년 가을의 나지 면적 분석 ····· 137
그림 4.32 안동댐 평균수위에 따른 수변환경 변화탐지 지도 ····· 137
그림 4.33 수변환경 변화탐지 지도 ····· 138
그림 4.34 경상북도 구미시 선산읍 원리 부근의 2020년 11월 23일 무인항공기 현장관측 영상과 무인항공기로 구축된 참조자료 ····· 140

그림 4.35 대구광역시 달성군 현풍읍 대구환경공단 달성사업소 근방 차천합류점 부근의 2020년 12월 04일 무인항공기 현장관측 영상과 무인항공기로 구축된 참조자료 ····· 140
그림 4.36 경상북도 구미시 선산읍 원리 지류와 낙동강 본류의 합류점 부근 ····· 141
그림 4.37 대구광역시 달성군 현풍읍 대구환경공단 달성사업소 근방 합천합류점 부근 ····· 142
그림 4.38 경상북도 구미시 선산읍 원리 지류와 낙동강 본류 합류점으로부터 서쪽으로 500m 지점 ····· 142
그림 4.39 경상북도 구미시 선산읍 원리 부근의 도로, 나지, 수체 등이 혼합되어있는 영상 ····· 144
그림 4.40 2020년 11월 23일 경상북도 구미시 선산읍 원리 부근의 지류와 낙동강 본류의 합류점 (a),(b). 2020년 12월 3일 경상남도 합천군 청덕면 적포리 부근 낙동강 본류 서쪽 하안 (c)~(e) ····· 146
그림 4.41 2020년4월4일에 취득된 Sentinel-2 광학영상 (a)과 전처리를 마친 Sentinel-1 SAR 영상의 VV 편광 (b) 및 VH편광 (c) 영상 ····· 147
그림 4.42 위 그림과 동일한 지역의 광학영상 (위) 및 Sentinel-1 SAR 영상의 시계열 후방산란계수 ···· 147
그림 4.43 Fmask 4.0 다운로드 ····· 149
그림 4.44 다운받은 Fmask파일이 있는 경로로 이동 및 실행 ····· 149
그림 4.45 설치과정1 ····· 150
그림 4.46 설치과정2 ····· 150
그림 4.47 설치과정3 ····· 151
그림 4.48 설치과정4 ····· 151
그림 4.49 설치과정5 ····· 152
그림 4.50 설치과정6 ····· 152
그림 4.51 설치과정7 ····· 153
그림 4.52 Sen2Cor 다운로드 ····· 154
그림 4.53 Sen2Cor설치 ····· 154
그림 4.54 L2A_GIPP.xml 수정 ····· 154
그림 4.55 L2A_GIPP.xml 내의 DEM_directory를 수정 ····· 154
그림 4.56 CGIAR SRTM 다운로드 화면 ····· 155
그림 4.57 Python을 이용한 전처리 프로그램 Fmask4.0 및 Sen2Cor 실행 ····· 156
그림 4.58 Python 기반 수변환경 분류 알고리즘을 이용하기 위해 불러온 라이브러리 ····· 157
그림 4.59 수변환경 분류 알고리즘을 위한 혼동행렬 함수 및 좌표변환을 위한 함수 정의 ····· 157
그림 4.60 수변환경 분류 알고리즘 적용 준비1 ····· 158
그림 4.61 수변환경 분류 알고리즘 적용 준비2 ····· 159
그림 4.62 계산할 날짜 탐지, 출력폴더 생성 및 타일들별 반복 시작 ····· 159
그림 4.63 타일의 반사도파일을 불러와서 리샘플링 ····· 160
그림 4.64 반사도파일을 불러옴 ····· 161
그림 4.65 불러온 반사도값을 처리하고 Fmask를 불러와서 구름을 마스킹후 분광지수를 계산 ····· 162
그림 4.66 픽셀 위치를 찾고 픽셀 위치를 이용해서 반사도값을 추출해서 검증용 테이블에 저장 ····· 163
그림 4.67 저장한 반사도값 중 사용할수 있는 값만 걸러냄 ····· 164
그림 4.68 검증용 반사도값을 사용해서 예측한 뒤 혼동행렬을 통해 평가하고 혼동행렬을 저장 (아래 그림) ····· 164
그림 4.69 검증된 반사도값을 사용해서 예측한 뒤 생산한 혼동행렬 ····· 165

그림 4.70 수변환경 분류지도 생산 준비 ····· 165
그림 4.71 예측지도를 생산하고 지도를 저장, 혼동행렬 및 검증용 행렬을 저장 ····· 166
그림 4.72 수변환경 분류지도를 모자이크하고 수변환경으로 정의된 1km 이외의 범위를 마스킹 (아래 그림) ····· 166
그림 4.73 수변환경 분류지도를 모자이크하고 수변환경 이외의 범위를 마스킹한 지도 ····· 167
그림 4.74 시계열 전체정확도(OA) 평가 (아래 그림) ····· 167
그림 4.75 본 연구에서 제시한 알고리즘의 구름 마스킹 방법별 시계열 성능 평가 ····· 168
그림 4.76 나지(모래톱) 증감 파악을 위한 준비 ····· 168
그림 4.77 나지 모래톱 증감 파악을 위한 최빈수 지도 생산 과정(아래 그림) ····· 169
그림 4.78 타일별 최빈수 지도 (T52SDF) ····· 169
그림 4.79 계절별 타일 최빈값 지도를 모자이크(아래 그림) ····· 170
그림 4.80 모자이크된 수변환경 최빈수 지도 ····· 170
그림 4.81 모자이크된 지도로부터 나지 면적 계산 ····· 171
그림 4.82 낙동강 평균 댐 수위 파악 ····· 171
그림 4.83 낙동강의 댐 평균수위와 나지 면적간의 시계열 이미지 생산 (아래 그림) ····· 172
그림 4.84 낙동강의 댐 평균수위와 나지 면적간의 시계열 이미지 ····· 172
그림 4.85 수변환경 변화탐지 알고리즘 구축 (아래 그림) ····· 173
그림 4.86 수변환경 변화탐지 알고리즘으로부터 생산된 지도 ····· 173
그림 5.1 북한강 및 임진강 유역 댐 현황 ····· 174
그림 5.2 대청댐 유역 및 우량, 수위 관측소 위치 ····· 176
그림 5.3 ESA(유럽우주기구)에서 무료제공되는 (a) Sentinel-1 위성, (b) Sentinel-2 위성 ····· 178
그림 5.4 대청댐 유역 수치표고모형 ((a) 1m 해상도, (b) 10m 해상도) ····· 179
그림 5.5 SAR 영상의 Gamma-distribution fitting ····· 180
그림 5.6 대청댐 수위 추정 과정 ····· 181
그림 5.7 대청댐 수위 분석 위치((a)댐체영역, (b)상류 2km지점영역) ····· 182
그림 5.8 2020년 4월 3일 Sentinel-1 영상을 활용한 대청댐 수위 분석(댐체영역) ····· 183
그림 5.9 2020년 4월 3일 Sentinel-2 영상을 활용한 대청댐 수위 분석(댐체영역) ····· 184
그림 5.10 2020년 9월 20일 COSMO-SkyMed 영상을 활용한 대청댐 수위 분석(댐체영역) ····· 186
그림 5.11 2020년 9월 20일 COSMO-SkyMed 영상을 활용한 대청댐 수위 분석(댐상류영역) ····· 187
그림 6.1 용담댐 전경 ····· 188
그림 6.2 용담댐 유역현황 및 토양수분 관측지점 ····· 189
그림 6.3 토양수분계측기(TDR) 매설 및 토양수분(강우) 계측지점 전경 ····· 190
그림 6.4 용담댐유역 지형특성 현황 ····· 191
그림 6.5 3단 탱크모형 구조 ····· 192
그림 6.6 분석기간 연도별 강우량 및 모형 검·보정 기간 ····· 194
그림 6.7 LSSVM 기법의 개념적 구조도 ····· 195
그림 6.8 Tank-LSSVM 모형의 구조 및 수행절차 ····· 195
그림 6.9 탱크모형 수행결과(2007~2016) ····· 198
그림 6.10 6가지 탱크 조합(회색으로 채워진 탱크는 관측 토양수분과 비교 시 사용된 탱크를 의미) ····· 199

그림 6.11 탱크모형의 상태변수와 관측(in-situ) 토양수분과의 교차상관(Cross-correlation) 결과 ····· 199
그림 6.12 모델 입력 자료의 부분자기상관(Partial autocorrelation) 분석결과(a-e) 및 LSSVM 모델에서 고려된 지체시간(f) ····· 200
그림 6.13 Testing 기간의 SV1-SV9 모델 수행결과 ····· 202
그림 6.14 Testing 기간의 관측 및 모의유출 결과 비교 ····· 204
그림 6.15 HY1-HY4 모델, Tank 모델 및 관측유량 유황곡선 ····· 204
그림 6.16 HY1-HY4 모델, Tank 모델 및 관측유량의 시계열 자료 ····· 205
그림 7.1 강우관측소 분포현황 ····· 208
그림 7.2 토양수분 자료별 데이터 제공기간 ····· 209
그림 7.3 SPI와 SSI를 결합한 가뭄분석 절차 모식도 ····· 209
그림 7.4 국내 55개 강우관소별 SPI-6(a) 및 SSI-6(b) 시계열 Heatmap (1987-2016, 30년간) ····· 212
그림 7.5 SPI와 SSI사이의 교차상관 결과(a는 SPI/SSI-3, b는 SPI/SSI-6) ····· 213
그림 7.6 55개 지점에 대한 SPI-3와 SSI-3의 월별 상관관계 ····· 213
그림 7.7 지체시간(1~6개월)에 따른 SPI 및 SSI의 자기상관(Autocorrelation) 분석결과 ····· 214
그림 7.8 가뭄발생(event) 빈도의 공간적 분포 ····· 215
그림 7.9 SPI 기준 가뭄 지속기간(Duration) 및 가뭄강도(Severity)의 공간적 분포 ····· 215
그림 7.10 SSI기 준 가뭄 지속기간(Duration) 및 가뭄강도(Severity)의 공간적 분포 ····· 216
그림 7.11 SPI-3 및 SSI—3의 시계열 변화에 대한 공간분포 ····· 217
그림 7.12 클러스터 수의 증가에 따른 Standardized Fusion Levels ····· 218
그림 7.13 a) MSDI-3 및 b) MSDI-6의 군집 분석결과 ····· 219
그림 7.14 클러스터별 MSDI-3의 시계열 변화 및 가뭄 정도에 따른 경향성 ····· 220
그림 7.15 클러스터별 MSDI-6의 시계열 변화 및 가뭄 정도에 따른 경향성 ····· 221
그림 8.1 수자원 분야 위성 산출물 리스트 조사·분석 ····· 225
그림 8.2 위성 빅데이터 활용분야, 활용방안, 수요기관 등 비교·분석 ····· 226
그림 8.3 수자원 분야 위성 산출물 리스트 조사·분석 ····· 228
그림 8.4 K-water 댐·보유역 강우예측시스템(K-PPM) 생산 및 운영체계 (자료: K-water 홈페이지) ····· 232
그림 8.5 K-water 물산업 관련 연구 수립 방향 (출처: K-water 보도자료 및 홈페이지) ····· 235
그림 8.6 수자원 분야 국내 적용 방안 ····· 237
그림 8.7 수자원/수재해 중형 위성 개발 개념도 (좌) 및 탑재체 사양안 (우) (출처: 환경부, 2018. 07.) ····· 238
그림 8.8 고해상도 광학위성 활용 수자원분야 활용 방안 도출 결과 ····· 239
그림 8.9 C-band SAR 활용 수자원 분야 활용 분야 도출 결과 ····· 240
그림 8.10 K-water 해외 사업 대표 현황 (자료: K-water 해외사업현황, 2020. 12.) ····· 241
그림 8.11 위성활용 수자원분야 공적개발원조 사업 모델 다이어그램 ····· 245
그림 8.12 물산업 트렌드를 고려한 위성영상 활용 수자원 분야 사업모델 결과 ····· 246
그림 8.13 수자원분야 빅데이터 표준화 시스템 및 통합 현장관측 데이터 플랫폼 개발사업 ····· 247
그림 8.14 다종위성 및 빅데이터 융합활용 실시간 수질 관측 및 변화 예측 시스템 개발 사업담댐 ····· 252
그림 8.15 수자원 분야 빅데이터 자동 통합관리 플랫폼 개발 사업 ····· 259
그림 8.16 국제협력 강화를 위한 수자원 분야 해외 공적원조개발 사업추진 기술 개발 사업 ····· 260

제 1 장 서 론

1.1 연구개요

□ 홍수, 가뭄, 수질 등 물관리 요소들은 시공간적 변화가 큰 특성을 갖기 때문에 기존의 전통적인 점 단위 관측방법은 수문 요소의 공간적 변화 분석에 한계

○ 위성영상은 시공간적으로 광역단위의 관측이 가능하며, 특히 관측 센서 활용과 여러 알고리즘 적용에 따라 다양한 정보를 생산할 수 있는 장점이 있음

○ 본 연구에서는 위성 자료를 활용한 유출모형 적용기술, 수질 모니터링 및 예측기술, 미계측지역 수자원 조사 및 평가 기술 등을 개발하여 기술력 확보 및 K-water 사업모델을 제안

□ 위성영상 정보를 활용한 실무 적용 가능한 기술개발을 위하여 2017년 상반기에 K-water 전 부서를 대상으로 위성 활용에 대한 수요조사 결과를 반영하여,

○ 수자원관리(물순환, 수재해, 수질 등) 및 조사(국내, 북한, 해외 등) 분야의 12개 부서 21개의 위성 관련 현업의 기술 Needs를 반영한 수자원 분야 핵심기술 발굴 추진 중

□ '20년 3차년도에는 위성영상을 활용하여 아래 5분야에 대한 연구를 중점 추진

○ (기술조사) 위성을 활용한 수문요소 관측 및 강우-유출 등 위성활용 분야 기술 Trend 조사

○ (수질 및 하천경관) AI 등 新 기술을 활용 수질항목 예측(Chl-a, SS, 수온) 알고리즘 개선 및 위성 영상을 활용한 4대강 하천수변환경의 공간적 변화 모니터링

○ (수위추정) 남한지역 댐을 대상으로 검·보정을 통해 북한댐 수위 관측 정밀도 제고

○ (강우유출) 위성기반의 토양수분 정보를 이용하고 AI 기법을 활용, 기존 Tank 유출모형과 결합한 Hybrid 모형을 개발하고 용담댐 유역을 대상으로 모형 검·보정

○ (가뭄평가) 위성 자료를 활용 농업적 및 기상학적 가뭄지수를 통합한 다변량 가뭄지수 개발

1.2 연구 결과 요약

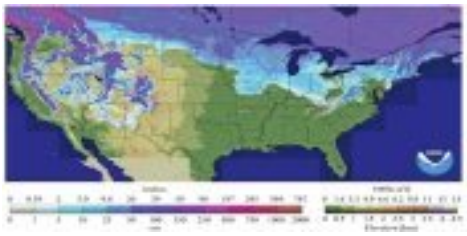
1 물관리 분야 위성영상 활용 기술 조사

□ 위성을 활용한 수리·수문인자 Monitoring 분야 조사결과

○ (강우) 강우량을 전지구 scale로 획득 가능한 방법 소개 및 강우 자료 활용성 조사

<table>
<tr><th>구분</th><th>특징</th></tr>
<tr><td>Gauge기반 강우자료</td><td>· 신뢰도는 높지만, 한 지점의 지상 관측치가 유역을 대표하기 어렵다는 단점도 있음
· 기상청, 환경부, K-water 등에서 국내 관측소를 운영 중이며, WMO에서는 전 세계적으로 기상자료를 공유하고 교환할 수 있는 Global Telecommunication System를 구축·운영</td></tr>
<tr><td>위성기반 강우자료</td><td>· '79년 GPCP 데이터를 시작으로, 현재는 GPM 글로벌 스케일의 강우데이터 취득가능
<table>
<tr><th>Data set</th><th>Resolution</th><th>Frequency</th><th>Coverage</th><th>Period</th><th>Data source</th></tr>
<tr><td>GPCP</td><td>2.5°</td><td>Monthly</td><td>Global</td><td>1979-</td><td>GPI, OPI, SSM/I, TOVS</td></tr>
<tr><td>GPCP 1dd</td><td>1.0°</td><td>Daily</td><td>Global</td><td>1996-</td><td>SSM/I-TMPI, TOVS</td></tr>
<tr><td>CMAP</td><td>2.5°</td><td>Monthly</td><td>Global</td><td>1979-</td><td>GPI, OPI, SSM/I, MSU, NCEP-NCAR</td></tr>
<tr><td>TRMM 3B43</td><td>0.25°</td><td>Monthly</td><td>50°S-50°N</td><td>1998-</td><td>TMI, TRMM, SSM/I, SSMIS, AMSR-E, MHS, MHS, GEO IR</td></tr>
<tr><td>TRMM 3B42</td><td>0.25°</td><td>3h/Daily</td><td>50°S-50°N</td><td>1998-</td><td>TMI, TRMM, SSM/I, SSMIS, AMSR-E, MHS, MHS, GEO IR</td></tr>
</table></td></tr>
<tr><td>Reanalysis 강우자료</td><td>· 관측자료와 기상 모델링을 통해 획득된 강우자료를 통계적인 방법으로 동화하여 전지구 범위의 강우자료를 재생산하는 방법 ☞ 시공간적인 해상도가 높은 장점</td></tr>
</table>

○ (강설) 강우-유출 분석에 중요한 수문정보지만, 산지, 비탈면 등과 같이 접근하기 어려운 지역의 강설 정보 취득은 제한적임. 최근에는 고해상도의 시·공간 관측 능력을 갖춘 위성이 개발됨에 따라, 위성을 활용한 강설량 관측연구가 진행중임. 일반적으로는 Optical원격탐사 기술이 강설 관측에서 사용됨



《RS 기법을 활용한 강설분포도》

○ (토양수분) 토양수분은 대기와 지표면 사이의 에너지 교환에 핵심적인 역할을 하는 인자로, 수문순환에서 강우-유출관계 및 증발산에 큰 영향이 있음

<table>
<tr><th>구분</th><th>특징</th></tr>
<tr><td>관측기반 토양수분</td><td>· (Direct) 실험실에서 현장에서 취득한 샘플시료의 토양내 수분을 증발 또는 화학적 방법으로 제거 후 무게차이로 토양수분 측정하는 방법
· (Indirect) 중성자의 산란 특성을 이용한 방법으로 neutron probe를 이용한 토양수분 함양정도를 관측하는 방법</td></tr>
<tr><td>위성기반 토양수분</td><td>· 원격탐사 기술을 이용해서 토양수분을 측정하는 방법은 크게 3가지로 Optical, Thermal, Microwave 구분할 수 있고, 대표적인 위성은 SMOS, AMSR2, ASCAT 등이 있음
<table>
<tr><th></th><th>ASCAT</th><th>AMSR2</th><th>SMOS</th><th>SMAP</th></tr>
<tr><td>Frequency</td><td>C-band</td><td>Multiple bands</td><td>L-band</td><td>L-band</td></tr>
<tr><td>Spatial resolution</td><td>12.5km, 25 km</td><td>10km, 25km</td><td>35-50km</td><td>3-40km</td></tr>
<tr><td>Temporal resolution</td><td>3 days</td><td>1-2 days</td><td>1-3 days</td><td>3 days</td></tr>
<tr><td>Observation depth</td><td>0.5-2cm</td><td>~ 1cm</td><td>~ 5cm</td><td>~ 5cm</td></tr>
<tr><td>Mission period</td><td>Since 2007</td><td>Since 2012</td><td>Since 2009</td><td>Since 2015</td></tr>
</table></td></tr>
</table>

□ 위성자료 활용 수자원 응용분야

○ (강우-유출) 최근 위성 자료를 활용해서 기존의 강우-유출모형과 결합해서 기존 모형의 장점을 살리고 단점을 최소화하고자 하는 연구가 활발히 진행 중

○ (가뭄 감시) 홍수피해와 달리 가뭄을 정량적 평가하는 것은 쉽지 않으나, 일반적으로 가뭄의 정도를 가뭄지수를 사용하여 평가하며, SPI, SMI 등이 활용됨

구분	특징
SPI (표준강수지수)	· SPI(Standardized Precipitation Index)는 강수의 양으로 가뭄을 판단하는 지수 · 강우량이 평상시보다 부족하면 수자원공급원인 지하수, 저수지 저류량 감소에 영향을 미친다는 가정에서 SPI는 가뭄 지수중에 가장 일반적으로 사용되고 있음
SSI (표준토양수분지수)	· SSI(Standardized Soil Moisture Index)는 토양수분의 시계열 자료를 이용하여 가뭄을 판단 ·식생 또는 작물의 성장 및 수확량에 영향을 주는 가뭄인자를 판단하기 위해 사용
위성영상 가뭄평가	· 가뭄 파악을 목적으로 인공위성 자료를 이용하는 방안은 위성 데이터만 이용하는 방법과 기상 및 강우자료가 조합된 기후학적 물수지를 이용하는 방법이 있음 · 기후학적 물수지를 이용한 방법은 위성자료와 기상 및 강우자료를 조합하는 다소 복잡한 방법이지만, 정확성이 뛰어나다는 장점이 있음 

○ (수질분야) 1972년 LandSat이 발사된 이후, 위성을 활용한 수질인자 측정 연구가 시작되었고, 기본원리는 내륙 담수의 수질인자 관측값과 위성에서의 반사도 값의 상관관계를 이용하는 것으로 초기에는 대부분 회귀모형 개발에 집중되었으나, 최근에는 수질인자와 위성밴드들 사이의 비선형적 상관을 해석하기 위해 인공지능 기술이 이용되고 있으며, 특히 Chl-a, 부유물질, 유해조류 농도를 산정하는 연구들이 진행중임

○ (토지피복) 토지피복분류는 전통적으로 토지피복별 원격탐사 센서의 반사도 특성에 따라 분류하는 기법이 개발되어 왔고, 최근에는 분류의 정확도 향상을 위하여 SAR 영상의 후방산란계수와 편파 특성을 기존 광학위성영상 분석에 융합하여 활용하기도 하며, 또한 기계학습법 등 인공지능 기술을 적용하는 연구가 주로 진행되고 있음

2 하천경관 변화분석 기법 개발

□ 연구목적

○ 정부의 하천 재자연화 정책에 의한 보 개방 등의 조치에 따라 4대강 하천수변환경의 공간적 변화를 모니터링하기 위하여 AI 기술을 활용한 위성영상기반 토지피복분류 기법 개발

□ 연구방법

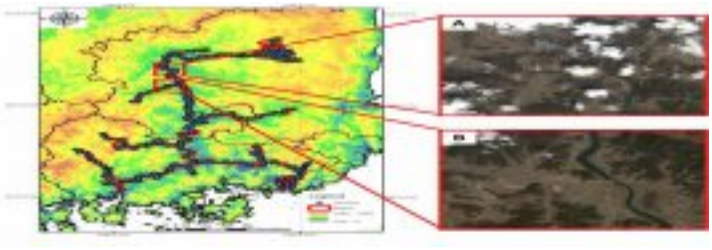
○ 국가 하천망도에서 추출된 수변공간 위성영상을 인공지능 기법 적용을 통해 피복분류하고 현장조사를 통해 검증

- (대상공간) 낙동강 수계 하천 제방기준 1km 이내 수변공간
- (자료) 국가 하천망도, Sentinel-2위성(Level-1C), 구글어스(7개 클래스 참조자료 구성)
- (민감도분석) cloud masking 수준(3가지)에 따른 RF(Randon Forest) 알고리즘 성능 평가

* (3개 모델) No-masking(WOMask), 70%이하 격자만 적용(Cldprb≤70), 구름/그림자제거(Fmask)



《하천 수변환경 분류 절차》



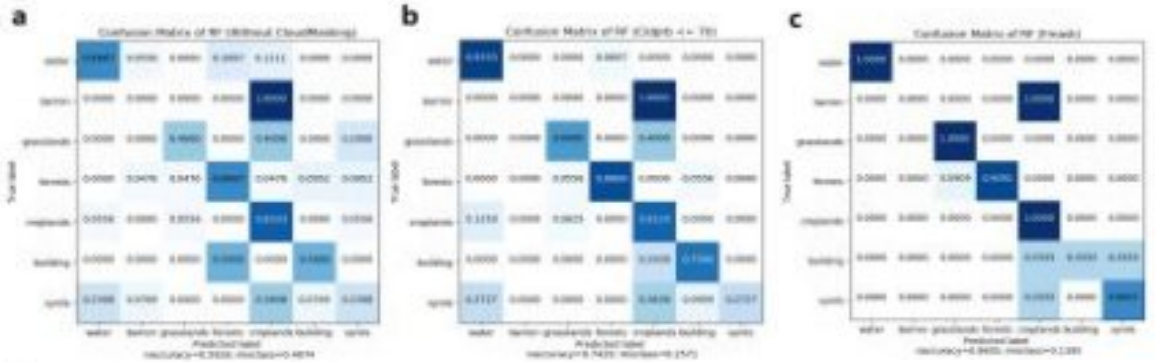
<연구대상지역 및 검증지역>

□ 연구결과

○ (WOMask) 전체 정확도 약 59%, 나지, 초지, 건물, 비닐하우스 클래스에서 성능이 낮음

○ (Cldprb≤70) 전체 정확도 약 74%, 수체, 초지, 목지, 건물, 비닐하우스 클래스에서 WOMask모델보다 성능 개선이 있으나, 나지 분류 정확도는 낮음

○ (Fmask) 전체 정확도 약 86%, 수체, 초지, 경작지를 완벽히 분류하였으나 나지, 건물 분류 성능은 상대적으로 낮은 것으로 평가 됨



《 랜덤포레스트 모델의 혼동 행렬 결과, a) WOMask, b) Cldprb <= 70, c) Fmask 》

3 미계측 유역 수위 추정 기법 개발

□ 연구목적

○ 미계측 지역인 임진강 상류 황강댐의 수위추정을 위해 계측자료가 존재하는 남한지역 댐을 대상으로 위성영상을 활용 수위관측 알고리즘 개선 ➜ 미계측지역으로의 확대·적용

□ 연구방법

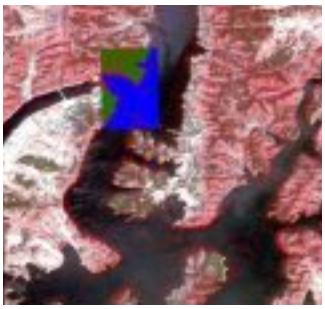
○ 위성영상에서 추출된 수체와 수치표고모델의 중첩을 통해 수위값 산출

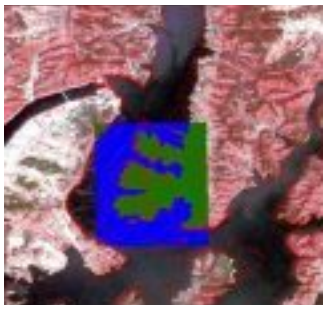
- 대상댐 : 대청댐(유효저수용량 7.9억m^3) 갈수기('19.4.3) 및 홍수기말('19.4.3) 수위
- 위성자료 : 현업활용을 목적으로 무료 확보 가능한 SAR(Sentinel-1(GRD)) 영상 및 광학위성(Sentinel-2(Level2)) 영상

- 수치표고모델 : K-water 항공 Lidar 측량자료(1m)
- 분석방법 : 후방산란계수(SAR), NDWI(광학), 수체탐지구역, SAR/광학영상 변화에 따른 실측 수위와 비교를 통해 최적의 수위분석방안 도출



<대청댐 수위 추정 절차>





<대청댐 수위판독 지점 ((좌)댐체, (우)댐상류 2km지역)>

□ 연구결과

<Sentinel-1위성, 후방산란계수에 따른 대청댐 수위>

Reference		후방산란계수(dB)					
날짜	수위(EL.m)	-14	차이	-15	차이	-16	차이
4.3. 18:31	74.17	75.60	1.43	73.98	-0.19	73.89	-0.28
9.30. 18:31	75.74	82.57	6.83	80.46	4.72	80.18	4.44

<Sentinel-2위성, NDWI에 따른 대청댐 수위>

Reference		NDWI					
날짜	수위(EL.m)	0.0	차이	-0.1	차이	-0.2	차이
4.3. 18:31	74.17	68.85	-5.32	72.24	-1.93	72.27	-1.90
9.30. 18:31	75.75	67.19	-8.56	71.91	-3.84	72.06	-3.69

《 수위판독 구역에 따른 대청댐 수위 》

Reference		댐체 구역				댐 상류			
날짜	수위 (EL.m)	Sentinel-1		Sentinel-2		Sentinel-1		Sentinel-2	
		-16dB	차이	NDWI -0.2	차이	-16dB	차이	NDWI -0.2	차이
4.3. 18:31	74.17	73.89	-0.28	72.27	-1.90	67.26	-6.91	75.49	1.32
9.30. 18:31	75.74	80.18	4.44	72.06	-3.69	69.47	-6.27	70.46	-5.29

○ 후방산란계수 분석(Sentinel-1 위성)

- 후방산란계수의 절대값이 클수록 탐지되는 수체면적이 증가
- Sentinel-1영상으로 수체탐지시 -15 ~ -16dB 적용이 적합
- 갈수기에는 -15dB, 홍수기에는 -16dB 일 때 더 적은 오차 발생
  ↳ 다중시기 분석으로 수체탐지 표준화 기법 개발 필요

○ NDWI 분석(Sentinel-2 위성)

- NDWI값이 작을수록 수체탐지 면적이 증가
- Sentinel-2영상으로 수체탐지시 NDWI threshold를 －0.2보다 작게 적용 필요

○ SAR/광학영상 비교분석

- Sentinel-1 영상이 Sentinel-2 영상보다 수위추정값에 대한 오차가 크고, bias도 일정하지 않아 광학영상이 수위추정에 보다 정확할 것으로 판단됨
- 복사보정, 기하보정 등 상대적으로 복잡한 SAR 영상의 전처리과정의 정확도가 중요

○ 수체탐지구역

- 댐체구역(수위계가 있어 추정수위와 비교가 용이하나, 급한 댐사면으로 수위변동에 따른 수체탐지가 어려움)과 댐상류(완만한 지형으로 수위변동에 따라 수체탐지 용이)로 구분하여 추정수위값을 비교
- Sentinel-1 영상은 수체경계가 명확한 댐사면에서의 수위측정 오차가 적음
  ↳수위정확도는 댐상류영역 수체경계를 추출하기 위한 speckle 제거 수준에 민감
- Sentinel-2는 갈수기에는 댐 상류, 홍수기에는 댐체 구역의 오차가 적음

4 Machine learning 기술을 활용한 Hybrid 유출모형 개발

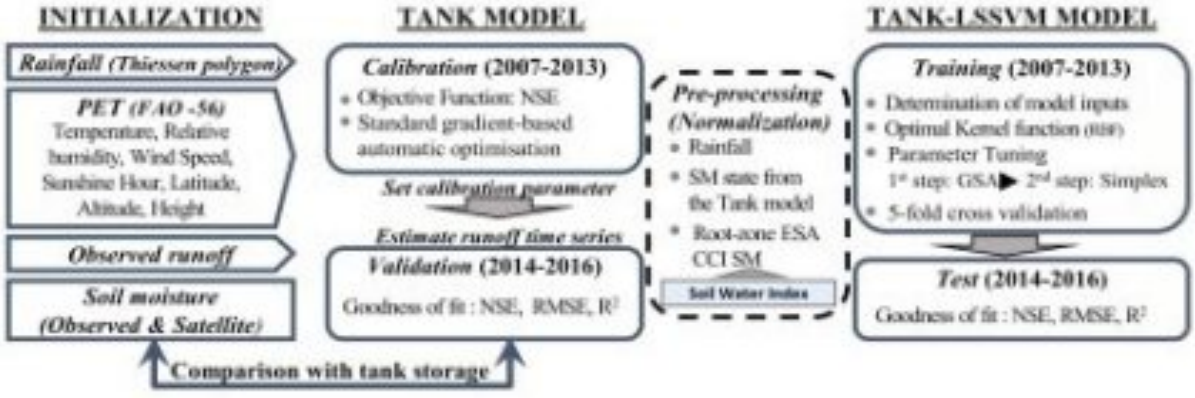
□ 연구목적

○ 위성 토양수분자료(ESA CCI)를 Machine learning 기법을 활용하여 기존 강우-유출 모형과 결합한 Hybrid 강우-유출모형 개발 및 용담댐을 대상으로 적용성 검토

□ 연구방법

○ Tank 모형에서 유도된 상태 변수를(ST_1, ST_2, ST_3) LSSVM 모형의 독립변수로 활용하여 hybrid 강우-유출모형 개발

* 여기서, ST_1 ~ ST_3은 Tank 모형의 최상단~최하단 Tank의 저류량을 의미

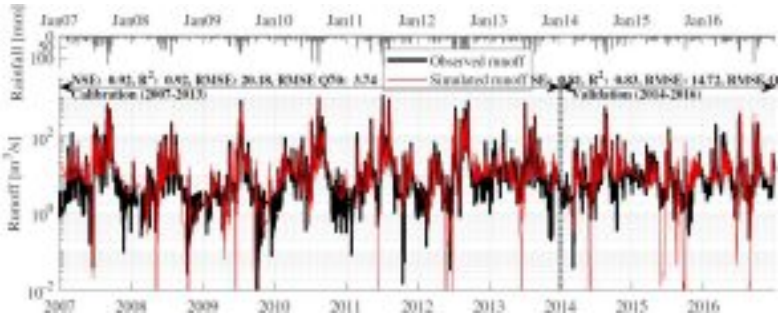


《 Tank-LSSVM 모형 구조 및 수행절차 》

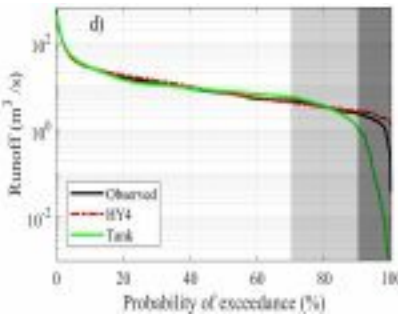
□ 연구결과

○ Tank-LSSVM 모형이 Tank 및 LSSVM 기반의 강우-유출 모형보다 모의 성능이 우수

① Tank 모형 : NSE 기준 탱크 모형의 강우-유출 모의 수행능력은 "Very Good (NSE > 0.7)"으로 평가되었으나 저유량 부분에서 관측 유량과 상대적 큰 차이를 보임



《 탱크모형 수행결과(2007～2016) 》



《 Tank VS. Tank-LSSVM(HY4) 》

② LSSVM 모형 : Tank 모형보다 낮은 모의 능력을 보였으나, 위성 토양수분 자료의 강우-유출 모형에서 활용성 확인 * 여기서, P는 강우, θ는 위성토양수분 데이터를 의미

《 입력 자료의 조합에 따른 LSSVM 모델 수행 결과 》

Model	Input combinations	Training (2007-2013)				Testing (2014-2016)			
		NSE	R^2	RMSE	RMSE Q70	NSE	R^2	RMSE	RMSE Q70
SV1	$P_{(t)}$	0.60	0.60	44.72	10.40	0.40	0.49	26.02	9.86
SV2	$P_{(t)},P_{(t-1)}$	0.84	0.84	28.21	6.73	0.45	0.61	24.81	5.42
SV3	$P_{(t)},\cdots,P_{(t-2)}$	0.88	0.88	24.88	5.11	0.57	0.65	22.04	4.49
SV4	$P_{(t)},\cdots,P_{(t-3)}$	0.89	0.89	23.01	4.44	0.62	0.70	20.77	3.99
SV5	$P_{(t)},\cdots,P_{(t-4)}$	0.91	0.91	21.33	4.00	0.68	0.75	18.91	3.86
SV6	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)}$	0.91	0.91	21.24	3.18	0.69	0.77	18.80	4.79
SV7	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)},\theta_{(t-1)}$	0.91	0.91	20.74	3.29	0.69	0.77	18.62	5.02
SV8	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)},\cdots,\theta_{(t-2)}$	0.92	0.92	19.53	3.12	0.72	0.79	17.90	4.93
SV9	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)},\cdots,\theta_{(t-3)}$	0.92	0.92	19.33	2.98	0.73	0.81	17.51	4.75

③ Tank-LSSVM 모형 : NSE 기준 Training 및 Testing 기간 모두 탱크 모형 및 LSSVM 기반의 강우-유출 모형과 비교하여 개선된 모의 능력을 보임

《 입력 자료의 조합에 따른 Tank-LSSVM 모델 수행 결과 》

Model	Input combinations	Training (2007-2013)				Testing (2014-2016)			
		NSE	R^2	RMSE	RMSE Q70	NSE	R^2	RMSE	RMSE Q70
Tank		0.92	0.96	20.18	3.74	0.81	0.91	14.72	3.12
HY1	$P_{(t)},ST1_{(t)}$	0.92	0.96	19.74	4.19	0.75	0.80	16.63	3.11
HY2	$P_{(t)},ST1_{(t)},ST2_{(t)}$	0.93	0.96	18.49	2.99	0.76	0.80	16.52	2.67
HY3	$P_{(t)},ST1_{(t)},ST2_{(t)},ST3_{(t)}$	0.95	0.97	16.24	2.50	0.85	0.86	12.91	2.13
HY4	$P_{(t)},ST1_{(t)},ST2_{(t)},ST3_{(t)},\theta_{(t)}$	0.94	0.97	17.43	2.34	0.85	0.85	12.96	2.23
HY5	$P_{(t)},P_{(t-1)},ST1_{(t)}$	0.92	0.96	19.87	4.40	0.71	0.77	17.93	3.11
HY6	$P_{(t)},ST1_{(t)},ST1_{(t-1)},ST2_{(t)},ST3_{(t)}$	0.93	0.96	18.75	2.94	0.84	0.85	13.38	2.19
HY7	$P_{(t)},ST1_{(t)},ST2_{(t)},ST2_{(t-1)},ST3_{(t)}$	0.93	0.96	18.87	2.99	0.85	0.85	13.18	2.34
HY8	$P_{(t)},ST1_{(t)},ST2_{(t)},ST3_{(t)},ST3_{(t-1)}$	0.93	0.96	18.97	2.93	0.85	0.85	13.13	2.39
HY9	$P_{(t)},ST1_{(t)},ST2_{(t)},ST3_{(t)},\theta_{(t)},\theta_{(t-1)}$	0.93	0.96	18.98	2.81	0.85	0.85	13.14	2.49

5 Remote Sensing 토양수분 데이터를 활용한 다변량 가뭄지수 개발

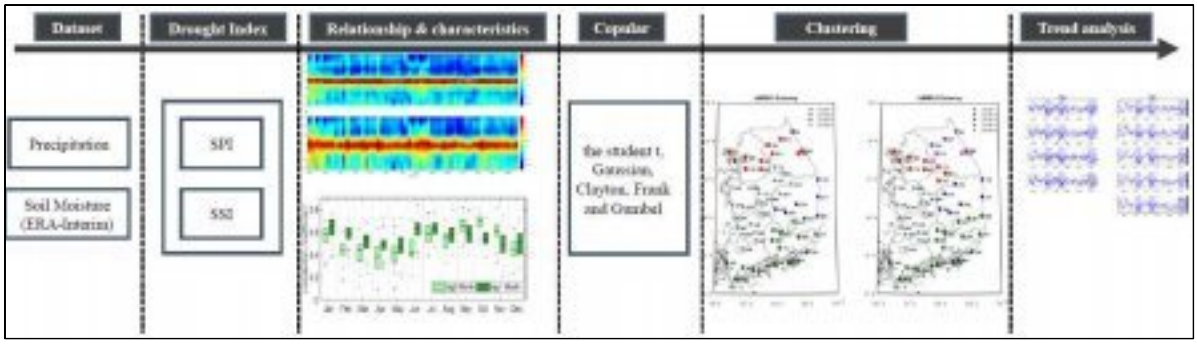
□ 연구목적

○ ERA-Interim 토양수분 데이터를 활용, 기상학적 가뭄지수(SPI)와 결합한 다변량 가뭄지수를 (Multivariate Standardized Drought Index) 개발

○ 개발된 가뭄지수를 활용하여, 남한을 대상으로 가뭄의 시·공간적 경향성 분석 및 가시화

□ 연구방법 :

○ Copular 함수를 활용한 기상학적 가뭄지수(SPI)와 농업적가뭄지수(SSI)를 동시에 고려한 다변량 가뭄지수(MSDI) 개발 → 군집분석(Clustering Analysis) → 경향성분석

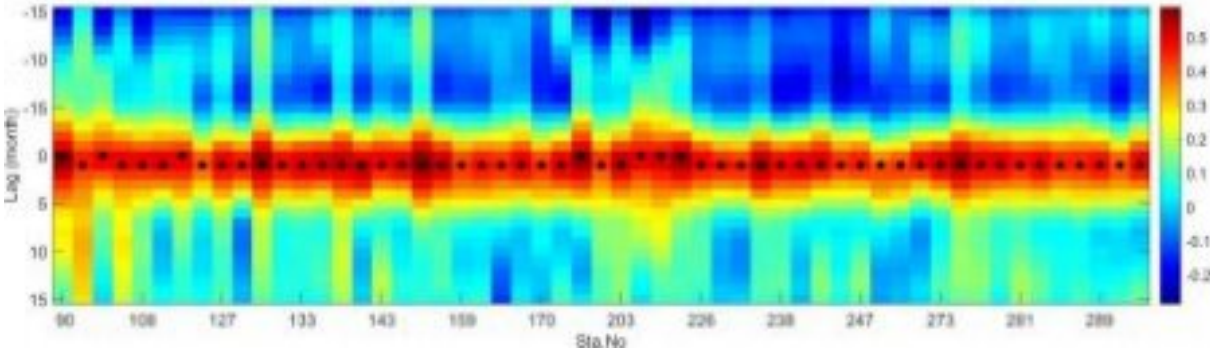


《 SPI와 SSI를 결합한 가뭄분석 절차 모식도 》

□ 연구결과

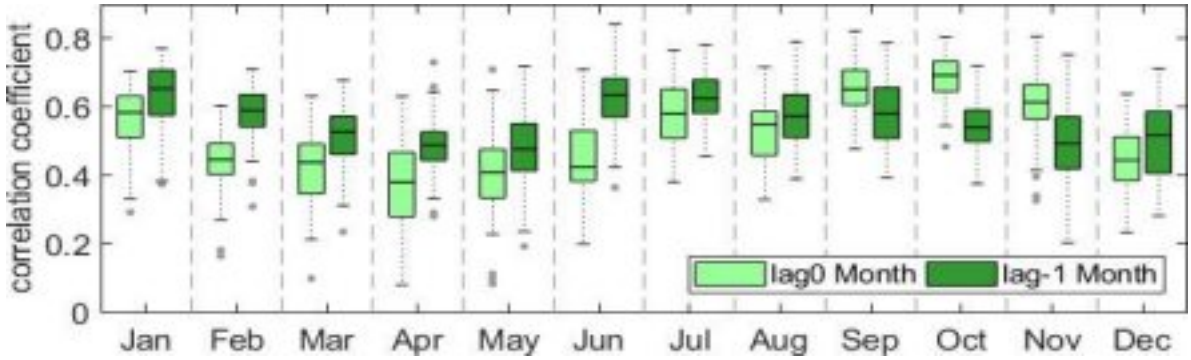
○ 기상학적가뭄지수(SPI)와 농업적가뭄지수(SSI)의 교차상관분석(Cross correlation)

- 30년 이상 기상자료의 취득이 가능한 55개 지점을 대상으로 SPI-6 및 SSI-6의 교차상관분석결과 기상학적 가뭄에서 농업적 가뭄으로 전이는 대부분의 지점에서 1개월 소요



《 SPI-6 와 SSI-6의 Cross-correlation 결과 (최대값을 보이는 지체시간을 검은점으로 표시) 》

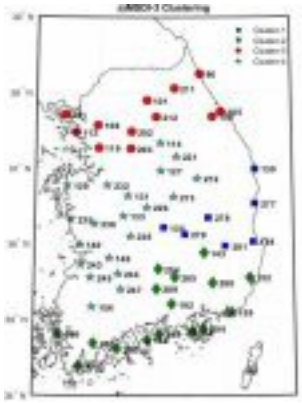
- SPI와 SSI의 상관관계 정도(기상학적 가뭄이 토양수분에 미치는 영향)는 계절별·월별 차이를 보이는 현상이 뚜렷함



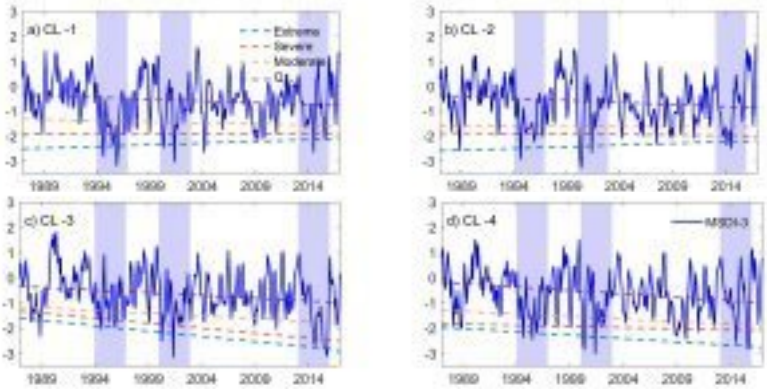
<55개 지점에 대한 SPI-3와 SSI-3의 월별 상관관계>

○ 다변량 가뭄지수(Multivariate Standardized Drought Index) 활용한 가뭄특성 군집 분석

- SPI와 SSI 가뭄지수를 코플라 함수를 이용해서 하나의 결합된 다변량 가뭄지수인 MSDI 유도 → Hierarchical clustering 알고리즘을 이용 군집분석
- Quantile Regression 모델을 활용하여, 가뭄의 정도(분위)별 가뭄의 경향성(Trend) 분석



《 군집 분석결과 (MSDI-3) 》



《 분위별 가뭄의 Trend 분석결과 》

《 MSDI-3 및 MSDI-6의 가뭄 발생횟수(Event), 지속기간(Duration) 및 심도(Severity) 》

Threshold	The number of Events					Duration					Severity				
	CL-1	CL-2	CL-3	CL-4	CL-5	CL-1	CL-2	CL-3	CL-4	CL-5	CL-1	CL-2	CL-3	CL-4	CL-5
MSDI-3															
Moderate	33	29	41	34		3.4	4.5	3.0	3.5		5.5	7.2	4.6	5.6	
Severe	22	25	26	26		2.6	2.8	2.2	2.5		5.1	5.4	4.2	4.8	
Extreme	11	13	7	11		1.8	1.6	2.3	1.6		4.4	3.8	5.8	3.9	
MSDI-6															
Moderate	25	25	23	20	24	4.6	4.8	5.2	6.4	5.0	7.1	7.6	8.3	10.3	8.2
Severe	17	20	16	17	19	2.6	2.7	3.9	3.8	3.8	5.4	5.3	7.6	7.4	7.4
Extreme	7	7	11	9	12	3.1	2.7	2.3	3.3	2.0	7.5	6.6	5.3	7.5	4.7

《 MSDI 가뭄지수의 분위별 Trend 분석 결과, 음영은 통계적으로 유의미한 결과를 표시 》

Cluster	MSDI-3($\times 10^{-3}$)				MSDI-6($\times 10^{-3}$)			
	Extreme	Severe	Moderate	Q_{50}	Extreme	Severe	Moderate	Q_{50}
CL-1	1.14	0.07	-0.79	-1.21	-3.55	-3.17	-1.60	-2.00
CL-2	1.13	-0.34	-0.07	-1.39	-3.63	-3.07	-3.19	-1.82
CL-3	-3.51	-3.29	-1.79	-1.78	-1.36	-1.15	-1.11	-1.96
CL-4	-2.21	-0.77	-1.70	-2.28	0.09	-0.13	-1.10	-1.92
CL-5					-2.69	-1.49	-1.32	-2.37

제 2 장 물관리 분야 위성영상 활용현황 조사

2.1 수리·수문인자

2.1.1 강우 (Rainfall)

본 장에서는 관측(gauge-based), 위성(satellite-based) 및 reanalysis data 등 강우량을 전 지구 scale로 획득 가능한 방법들을 소개하고 이렇게 획득된 강우 자료의 활용성을 조사보고자 한다. 강우는 물순환을 이해하는데 가장 중요한 수문 요소중에 하나이고 정확하고 신뢰성 있는 강우 자료는 기상변화 경향과 변동성을 분석에 필수적이며, 수자원 관리 뿐만 아니라 기상 및 수문예측을 위한 가장 중요한 자료로 인식된다. 강우 관측 자료는 전통적으로 강우를 직접적으로 계측하는 방법으로 취득하는 것이 일반적이다. 또한, 강우관측망은 관측지점 기반으로 구축되어 관측 공간 해상도 또한 다양하다. 지상관측 강우 자료는 위성, 레이더 등을 활용한 관측치보다 신뢰도가 높다고 인식되지만, 한 지점의 지상 관측치가 넓은 지역을 대표하기 어렵다는 단점 또한 존재한다. 강우는 높은 시공간적인 변동성을 보인다. 기후변화의 변동성을 분석은 지상관측 자료가 주로 사용되어왔다(그림 2.1). Rain gauge는 점단위의 지표면에 내리는 강우를 관측하기 위한 가장 일반적인 방법으로 사용 되어왔지만 강우취득 버켓의 물리적 부정확성은 잠재적 문제점으로 인식된다.

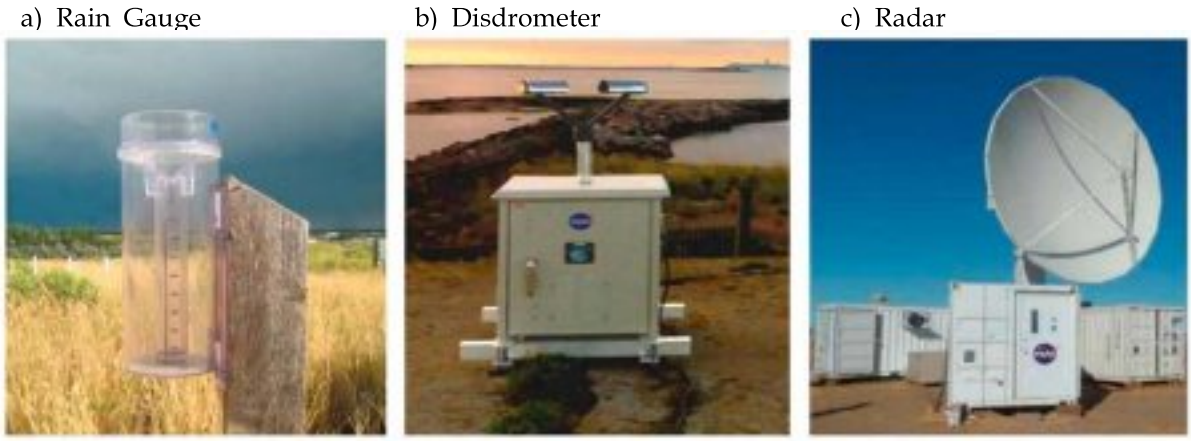


그림 2.1 지상 강우관측 장비 (출처: National Aeronautics and Space Administration(NASA))

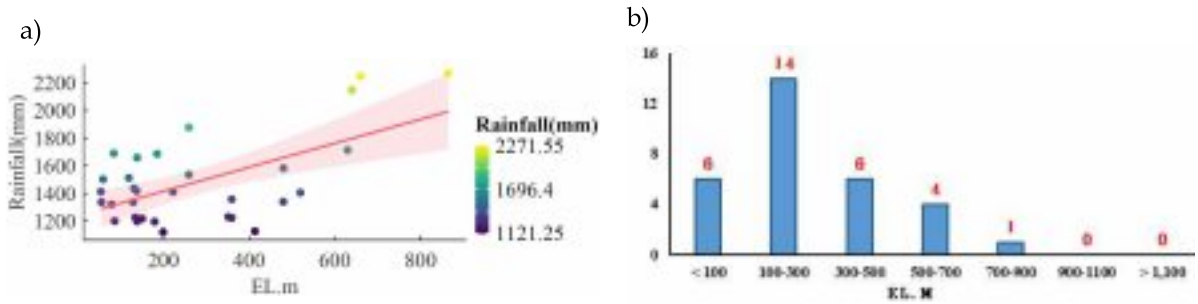


그림 2.2 a) 고도에 따른 연평균 강수량(2016~2019), b) 고도별 강우관측소 현황(2020 기준)

우리나라는 국토의 70%가 산악지형으로, 산지형 강우로(Orographic Rainfall) 인한 국지성 호우가 잦아 강우관측망 구축시 평면 뿐만 아니라 고도 분포도 고려가 필요하다. 하지만, 高 고도 기상관측소는 산림의 간섭으로 Open space 확보가 어려우며, 접근성 및 유지관리도 어려워 평지에 비해 관측밀도가 낮은 실정이다, 그림 2.2는 남강댐 유역을 예로, 강우와 고도와의 관계 및 고도별 강우관측소 현황을 조사한 것으로 그림에서 보듯이 연평균 강우와 고도는 높은 상관관계를 보이나, 高 고도의 강우관측소는 평지에 비해 낮은 관측밀도를 보임을 알 수 있다. 그림 2.3은 남강댐 유역의 고도분포와 연평균강우량 분포를 도시한 것으로 고도 분포와 연평균 강수량의 공간적 분포가 매우 유사한 형태를 보임을 알 수 있다.

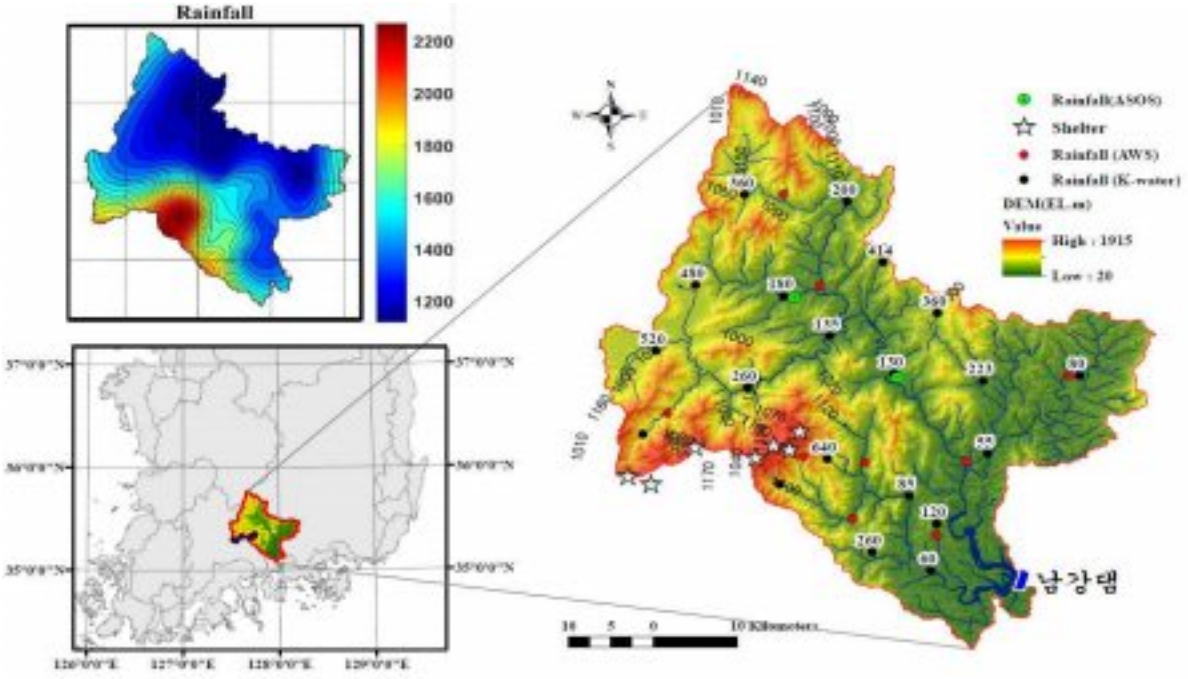


그림 2.3 고도에 따른 강우분포현황(남강댐 사례)

우리나라는 하천기본계획 등 국가 하천관리계획 수립시 사용되는 기상자료 자료는 기상청, Kwater, 환경부 등에서 취득하여 사용하는 것이 일반적이나, 국립공원공단 및 산림청(산악기상관측시스템)의 강우 자료를 활용하면 高 고도의 기상자료 획득이 가능할 것으로 보인다. 예를 들어, 국립공원공단은 '98년이후 재해예경보의 목적으로 전국에 걸쳐 국립공원내에 '20년 9월기준 총 151개소의 관측소를 운영중에 있다(그림 2.4). 이들 관측소는 지리산, 설악산, 치악산등 주로 高 고도에 분포되어 있어 그 활용도가 매우 높을 것으로 기대된다. 표 2.1은 Kwater와 국립공원공단에서 관리중인 강우관측소의 고도분포를 비교한 것으로 국립공원공단에서 관리중인 강우관측소가 상대적으로 고도별 고른 분포를 보임을 알 수 있다.

표 2.1 기관별-고도별 강우관측소 분포 단위 : 개소 (%)

기관	계	해발고 (EL.m)					
		≦ 300	300~600	600~900	900~1200	1200~1500	≧ 1,500
공 단	151	35 (23%)	39 (26%)	33 (22%)	20 (13%)	19 (13%)	5 (3%)
K-water	189	113 (60%)	58 (31%)	18 (9%)	-	-	-

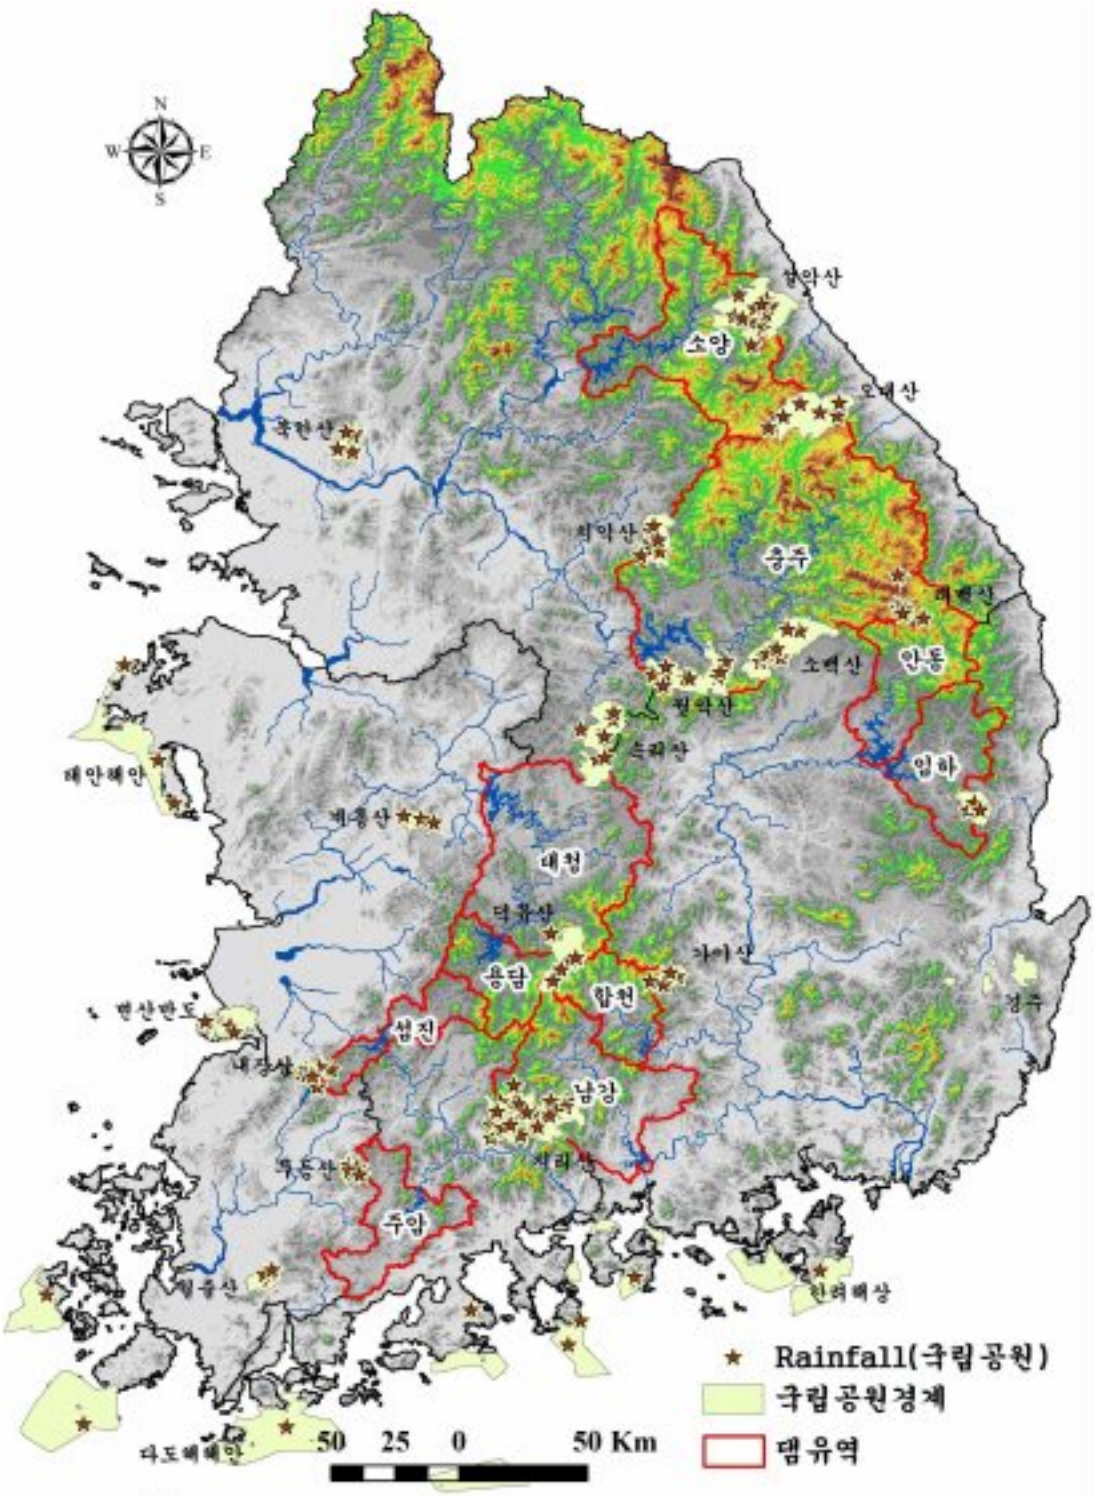


그림 2.4 강우관측소 분포(국립공원공단 관리)

최근에는 Radar 또는 Disdrometer와 같은 강우 관측기술이 전통적인 rain gauge의 단점을 보완하고자 개발되었다. Rain gauge와 달리, Disdrometer는 개개의 빗방울의 크기 계측이 가능하고 이렇게 계측된 자료의 분석을 통해 빗방울의 시·공간적인 분포를 파악하고 실시간으로 다음 time-step에서의 강우량 예측까지도 가능하다. 이러한 기술은 수치 기상모형 수행을 위한 파라미터값을 선정시에

도 활용이 가능하다. Radar를 활용한 강우관측 또한 활발한 연구와 실용화가 진행중이며, 높은 시공간해상도의 실시간 강우 관측이 가능하다는 점에서 앞서 언급한 두 계측방법의 대안으로 주목받고 있다. Radar는 강우의 3차원 structure를 관측 할 수 있다는 장점이 있지만, 아직 널리 보급되지는 못하였고 유지관리 비용이 많이 든다는 점에서 Radar를 활용하여 강우 관측 network 구축시 단점이 있다.

가. Guage 기반 강우자료

Gauge 기반의 강우 관측 자료는 대부분의 국가에서 날씨 예보를 담당하는 기관에서 관측·제공하고 있다. 우리나라 또한 기상청에서 자동기상관측소(Automatic Weather Station) 및 종기상관측시스템(Automated Surface Observing System)을 전국적으로 운영하고 있으며, K-water, 지자체 및 국립공원공단 등 기관별 필요에 따라 강우관측소를 운영중에 있다. 전 지구 스케일의 강우 자료를 제공하는 기관으로는 1873년에 설립된 세계기상기구(World meteorological Organization, WMO)가 대표적이라 하겠다. WMO에서는 전 세계적으로 기상자료를 공유하고 교환할 수 있는 Global Telecommunication System(GTS)를 구축·운영하고 있다. WMO에서는 기상 관련 자료의 다양한 수요를 만족하고 획득된 자료를 필요로 하는 국가에 무상으로 제공하기 위해 1992년에 Global Climate Observing System(GCOS)을 구축하여 현재까지 운영하고 있다. 강우를 포함한 온도, 이슬점, 풍속 등 기상 현상을 모니터링하고 예측하기에 필요한 자료의 공간적 비균질성을 보완하고자 점단위 자료를 Grid 형태로 변환하는 연구가 활발하게 진행되었으며, Grid 형태의 전 지구 스케일의 공간적으로 균질한 형태의 활용 가능한 강우 데이터의 현황은 표 2.2과 같다.

표 2.2 Grid 기반 강우 데이터 현황 및 특징

구분	공간 해상도	시간해상도	자료제공기간	출처
CRU	0.5°×0.5°	월	1901-2015	The CRU of the Uni. of East Anglia
CHCH-M	5°×5°	월	1900-현재	National Climatic Data Center
GPCC	5° × 5°, 1.0°×1.0°, 2.5°×2.5°	월	1901-2013	GPCC
GPCC-daily	1.0°×1.0°	일	1988-2013	GPCC
PRECL	0.5°×0.5°, 1.0°×1.0° 2.5°×2.5°	월	1948-2012(0.5°) 1948-현재	NCEP/NOAA
UDEL	0.5° × 0.5°	월	1900-2014	Uni. of Delaware
CPC-Global	0.5° × 0.5°	일	1979-2005	CPC

나. 위성기반 강우자료

1960년 최초 Television and IR Observation Satellite (TIROS) 발사 이후, 기상 현상을 관측하기 위한 많은 위성이 개발되었고 관측기술 또한 발전해왔다. 위성은 전 지구 스케일의 기상 관련 파라미터를 Remote Sensing 기술을 활용하여 관측하는데 중요한 Tool로 활용되었으며, 최근까지 기상 및 수문분야에 많은 관심을 받고 있다. 위성에 탑재되는 센서는 크게 3가지로 구분할 수 있다(①

Visible/Infrared 센서, ② Passive Microwave 센서, ③ Active Microwave 센서). 강우는 앞서 언급한 3가지 센서 중 하나 혹은 단일 센서의 장단점을 보완하기 위한 결합형태의 센서로 관측이 이루어지고 있다.

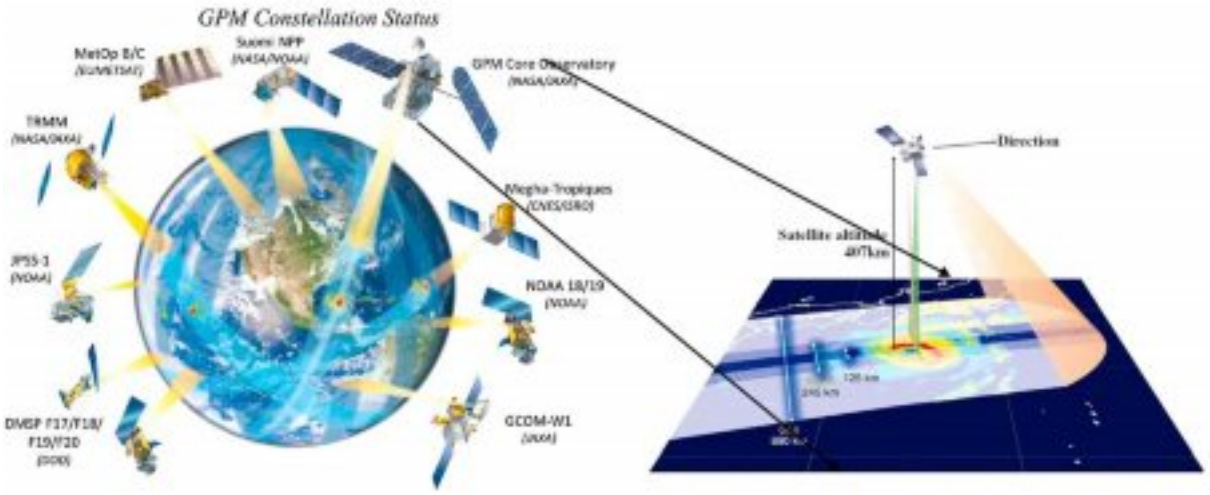


그림 2.5 강우 관측 위성 현황

표 2.3 위성 기반 강우 자료 현황 및 특징

Data set	Resolution	Frequency	Coverage	Period	Data source
GPCP	2.5°	Monthly	Global	1979-	GPI, OPI, SSM/I, TOVS
GPCP 1dd	1.0°	Daily	Global	1996-	SSM/I-TMPI, TOVS
CMAP	2.5°	Monthly	Global	1979-	GPI, OPI, SSM/I, MSU, NCEP-NCAR
TRMM 3B43	0.25°	Monthly	50°S-50°N	1998-	TMI, TRMM, SSM/I, SSMIS, AMSR-E, MHS, MHS, GEO IR
TRMM 3B42	0.25°	3h/Daily	50°S-50°N	1998-	TMI, TRMM, SSM/I, SSMIS, AMSR-E, MHS, MHS, GEO IR
GSMaP	0.1°	1h/Daily	60°S-60°N	2002-2012	TMI, AMSR-E, SSM/I, MTSAT, Meteosat-7/8, GOES 11/12
GPM	0.1°	30min/3h/ Daily	60°S-60°N	2015-	GMI, AMSR-2, SSMIS, Madaras, MHS, ATMS
MSWEP	0.1°/0.5°	3h/Daily	Global	1979-	CPC, GPCC, CMORPH, GSMaP-MVK, TMPA, ERA-Interim, JRA-55

위성에서 Active 센서를 이용한 강우 관측은 1997년 TRMM 위성이 최초로 시도되었고, 강우의 3차원적 정보의 취득이 가능하게 되었다. 전지구강수관측위성(Global Precipitation Measurement) 사업은 미국우주항공국(NASA)와 일본우주항공국(JASA)이 주도로 전 지구 스케일의 강수관측을 목적으로 시작되었고, 이후 프랑스, 미국의 NOAA 그리고 유럽연합의 EUMETSAT(European Organisation for the Exploitation of Meteorological Satellites)가 추가로 참여하였다. GMP 핵심위성이 2014년 2월 28일에 일본 가고 시마현 다네가시마 우주센터에서 성공적으로 발사 되었다. GPM 핵심위성과 JAXA의 GCOM-W1위성 의 AMSR-2, US DMSP위성의 SSMIS, CNES-IRSO의 SAPHIR 등 다른 12기의 위성자료들과 조합에 의한 네트워크로 지구상의 50% 이상을 커버하며 30분 간격으로

전세계 강수량을 관측하는 것을 목표로 하고 있으며(그림 2.5), 이러한 시도는 전 지구 스케일의 강우 관측 기술발달에 기여하였다.

국내의 경우 위성에서 취득된 강우를 활용한 연구사례는 많지 않은 실정이다. Kim et al.(2017)은 위성 강우자료를 이용해 모로코 세부강 유역을 대상으로 홍수량을 추정한 사례가 있으며, 그들은 위성에서 획득된 강우는 관측자료가 충분하지 않거나 미계측 지역의 홍수량 추정에 적용될 수 있음을 보였다. Kim et al.(2013)은 충주댐 유역을 대상으로 시범적으로 강우-유출 모의를 여러 종류의 위성으로부터 획득된 강우량 자료를 활용하여 수행하였으며, TRMM 위성 강우자료가 타 위성보다 유출모의에 적합하다고 제시하였다. 위성을 이용한 수문 자료의 관측은 간접측정에 의한 방법으로 위성자료의 적용에 앞서 획득된 데이터의 신뢰도를 검증하는 과정이 필수적이다. 그림 2.6는 위성에서 획득된 자료의 생산 및 검·보정 절차를 보여준다.

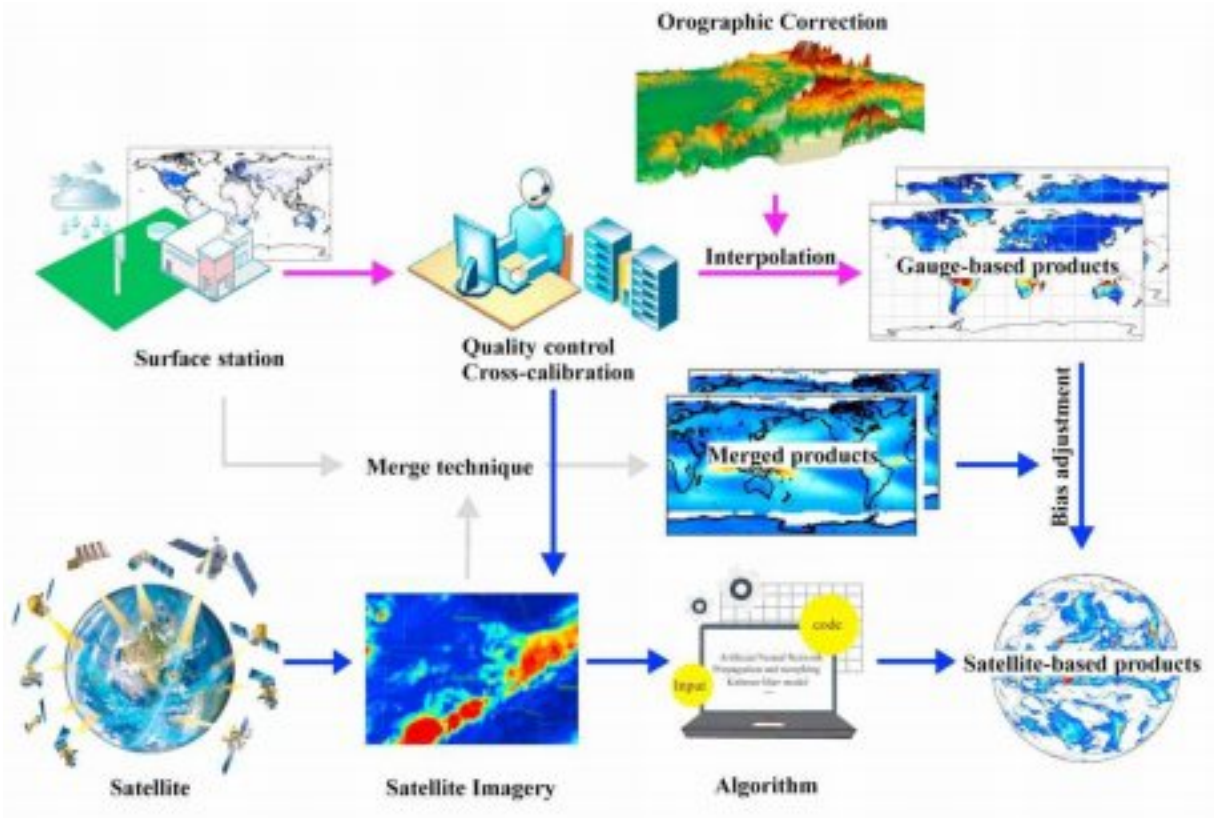


그림 2.6. 위성을 활용한 강우자료 생성 절차

다. Reanalysis 강우자료

Reanalysis 시스템의 기본은 관측 자료와 물리적 기반의 전지구 기상 모델링을 통해 획득된 강우자료를 통계적인 방법으로 동화(assimilation) 하여 전지구 범위의 강우 자료를 재생산하는 방법이다. 이렇게 획득된 자료는 시공간적인 해상도가 높고 연속적인 데이터 생성이 가능하다는 점에서 많은 연구가 이루어지고 있다. 전 지구적 스케일의 대표적 Reanalysis 데이터의 주요 특징은 표 2.4에 요약하였다.

표 2.4 Reanalysis 기반 강우자료(요약)

	Spatial Resolution	Temporal Resolution	Mission Period	Data Source
NCEP1	2.5°×2.5°	M/D/6h	1948-현재	NCEP/NCAR
NCEP2	1.875°×1.875°	M/6h	1979-현재	NCEP/DOE
ERA40	2.5°×2.5°, 1.125°×1.125°	M/6h	1957-2002	ECMWF
ERA Interim	1.5°×1.5°, 0.75°×0.75°	M/6h	1979-현재	CEMWF
20CRv2	2.0°×2.0°	M/D/6h	1871-2012	NOAA
JRA-55	60 km	M/3h/6h	1958-현재	Japanese Meterological Agency
MERRA	0.5°×0.67°	D	1979-현재	NASA
MERRA Land	0.5°×0.67°	M/M/1h	1980-현재	NASA
CFSR	38 km	6h	1979-2010	NOAA

2.1.2 강설 (Snow cover)

강우-유출 분석에 있어, 강설과 융설에 대한 정보는 모델링 수행을 위한 매우 중요한 수문 정보중 하나이나, 산지, 비탈면 등과 같이 접근하기 어려운 지역의 강설 정보 취득은 매우 제한적이다. 최근 고해상도의 시간 및 공간 관측 능력을 갖춘 위성이 개발됨에 따라, 위성을 활용해서 강설량을 관측하는 연구가 활발히 진행중에 있다. Microwave나 Optical 센서를 탑재한 위성을 활용해서 강설량을 관측하고 있으며, 강설량 관측에 사용되는 위성 현황 및 위성에 탑재된 센서의 특성은 표 2.5와 같다. 가시광선(Visible, wavelength 0.4-0.7 μm) 및 근적외선(Near Infrared, wavelength 0.7-1.3 μm)을 이용하는 Optical 원격탐사 기술은 강설 관측에 가장 일반적으로 사용되지만, 강설 발생 지역에 구름이 발생하면 관측하지 못한다는 단점도 있다. 이러한 단점을 극복하고자 구름을 통과하여 강설을 관측하고자 SAR(Synthetic Apeture Radar)와 같이 Active Microwave를 활용한 원격탐사 기술도 개발되었다. SAR를 이용한 강설의 관측은 마이크로파의 반사 정도가 눈이 쌓인 지표와 그렇지 않은 지표에서 큰 차이를 보이는 특성을 이용해서 강설 지역을 분석한다. 강설을 관측하는 또 다른 방법중에 하나는 Passive 마이크로 영상을 이용하는 기법이다. 지표에서 반사되는 마이크로파 시그널은 지표의 밝기 온도(Brightness temperature)를 평가하는데 이용되며 이러한 특성을 이용하여 강설 깊이 및 강설구간을 분석할 수 있다. 이러한 Snow water equivalent(SWE)는 아래 식과 같은 관계를 갖고 있다.

$$SWE = A + B\frac{T_b(f_1) - T_B(f_2)}{f_2 - f_1} \qquad \text{수식 2.1}$$

여기서 A 및 B는 지체상수(regression coefficients)를, T_B는 밝기온도(Brightness temperature)를 의미한다. 또한 f_1 및 f_2는 각각 저 산란 마이크로웨이브(low scattering microwave channel) 및 고 산란 마이크로웨이브의(high scattering microwave channel) 주파수(frequency)를 의미한다. Passive microwave 관측기술 또한 구름을 통과해서 강설을 측정할 수 있다는 장점을 갖고 있다. 위성 기술을 활용한 강설 관측은 전 지구 스케일로 관측이 가능하다는 점에서 레이더를 이용한 관측에 비해 비용 경제적이나, 레이더에 비해 저해상도의 공간 자료를 생성하는 단점도 있다.

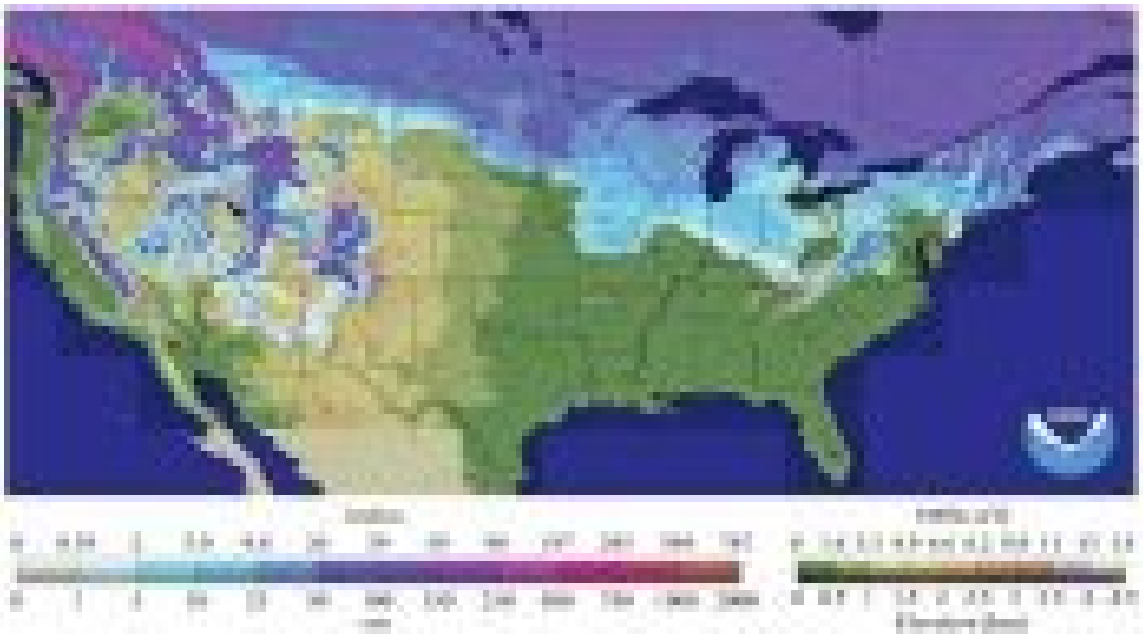


그림 2.7. 원격탐사 기법을 활용한 강설분포도

표 2.5 강설량 관측에 주로 사용되는 센서 및 위성 현황

Sensor	Satellite	Spectral bands	Characteristics
SMMR	Nimbus-7	Passive microwave	Daily data at 25 km spatial resolution
AMSR-E	AQUA	Passive microwave	Daily data at 12.5 km spatial resolution
Lansat TM	Landsat	VIS, NIR	30 m spatial resolution, revisit period is 16 days
AVHRR	NOAA	VIS, NIR	Daily data at 1 km spatial resolution
MODIS	Terra	VIS, NIR	Daily data at 250 m spatial resolution
SAR and Polarimetric SAR	ERS-1 and 2, Radarsat	Active microwave	8-100 m spatial resolution Repeat cycle is 24 days

AMSR-E: Advanced Microwave Scanning Radiometer-Earth Observing System
AVHRR: Advanced Very High Resolution Radiometer
ERS: European Remote Sensing Satellite
MODIS: Moderate Resolution Imaging Spectroradiometer
SAR: Synthetic Aperture Radar
SMMR: Scanning Multichannel Microwave Radiometer

서로 다른 장·단점을 갖고있는 원격탐사 기법 간의 장점은 극대화하고 단점은 최소화 하고자 다양한 위성을 조합하여 강설 데이터를 생성하는 연구 또한 활발하게 진행되고 있다. 예를 들어 NOAA에서는 NOAAs GOES Imager, Polar Orbiting Environmental Satellites (POES) AVHRR, US Air Force DMSP/SSMI 및 EUMETSAT MSG/SEVIRI 센서의 관측치를 조합해서 4 km의 공간해상도를 갖는 강설 데이터를 일단위로 글로벌 스케일로 제공하고 있다 (그림 2.7).

2.1.3 토양수분 (Soil moisture)

토양수분은 대기와 지표면 사이의 에너지 교환에 핵심적인 역할을 하는 인자이며, 수문순환에서 강우-유출관계 및 증발산에 큰 영향을 미친다. 위성을 활용해서 토양에 함유되어있는 수분양을 관측하는 분야는 강우 관측과 더불어 최근 가장 활발하게 연구되는 위성 활용기술 중 하나이다. 토양수분은 강우-유출, 침투, 가뭄 및 작물 성장 등 물관리를 위한 수문 순환을 해석하는데 매우 중요한 수문 요소이다. 따라서 신뢰도 높은 토양수분 정보의 취득은 효율적인 수자원 관리를 위한 중요한 데이터로 평가된다. 하지만, 시간과 공간적인 관점에서 이러한 양질의 데이터를 취득하는 것은 우리나라를 포함한 많은 나라에서 여전히 어려움을 겪고 있다. 최근에 지상 관측을 통한 토양수분 데이터의 대안으로 위성을 활용한 토양수분 정보를 취득하기 위한 연구가 활발히 진행되고 있다.

토양수분 자료는 지상관측, 위성관측, 토양수분 account model 그리고 각 기법의 장점은 살리고 단점을 최소화하기 위한 각기 다른 기법을 동화하는 assimilation 기법 등으로 취득이 가능하다. TDR 등을 이용한 지상에서 토양수분을 관측 방법은 가장 신뢰도 높은 데이터 취득을 위한 방법으로 인식되며, 토양수분을 이용한 수문 모델링 수행시 레퍼런스 데이터로 그 활용도가 높지만, 앞서 언급한 바와 같이 시공간적 관점에서 적합한 자료의 취득이 어려운 지역이 많다. 지상 즉 점단위 관측 자료의 또 다른 실무적 관점에서 단점은 수문해석은 전형적으로 유역단위로 이루어지는 반면, 점단위의 관측 자료는 비균질적인 지표의 상태를 고려할 때 유역 전체를 대표하기 어렵다는 점이다. 반면, 위성으로 취득된 토양수분 정보는 높은 시간 해상도와 대유역에 적용 가능하다는 점에서 지상 관측 토양수분 자료의 대안으로 그 활용도가 높다 할 수 있겠다.

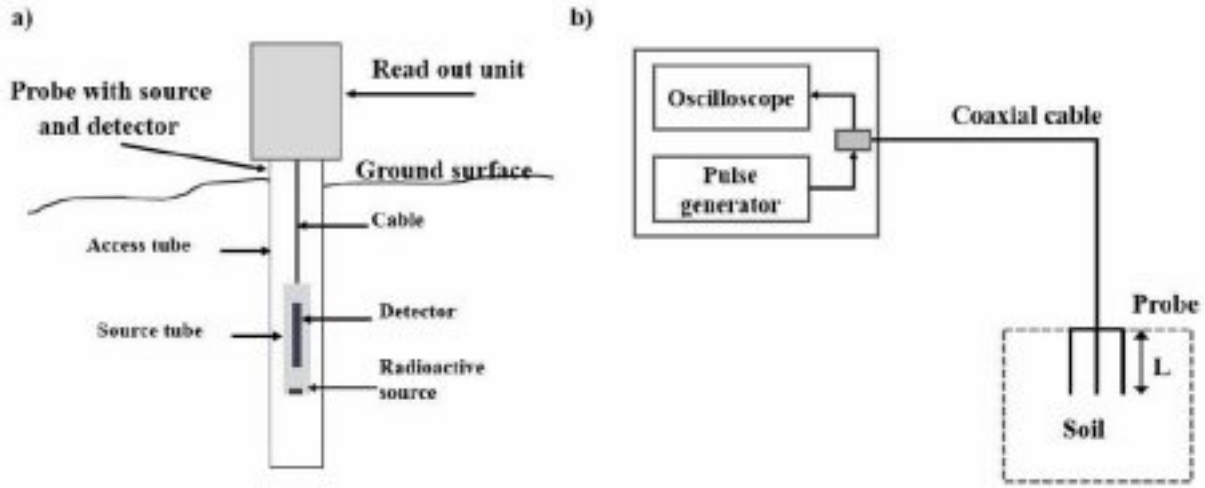


그림 2.8. 토양수분 측정 개념도(a: Neutron Probe, b: TDR)

가. 관측기반 토양수분 측정 방법

관측기반 토양수분 정보는 직접적인 방법과 간접적인 방법으로 취득가능하다. 직접적인 방법(Thermo-gravimetric technique)은 실험실 스케일에서 이루어지는 방법으로 현장에서 취득한 샘플 시료를 실험실에서 토양내 수분을 증발 또는 화학적 방법으로 제거 후 수분제거 전·후의 시료 무게의 차이로 토양수분을 측정하는 방법이다. 이러한 방법은 비교적 측정이 쉬우며 비용이 저렴하다는 장점이 있는 반면 동일 지점에서 동일한 조건으로 토양수분을 연속적으로 측정이 어렵다는 단점이 있다. 따라서 이러한 직접적인 토양수분 측정방법은 간적 측정방법의 토양수분 자료 검증 및 관측기

기 보정시에 주로 이용된다. 표 2.6는 토양수분 측정방법들의 각각의 특징을 보여준다.

표 2.6 토양수분 측정 방법 (요약)

Sensor	Flexibility	Principle	unit	Remarks
Thermo-gravimetric	Lab scale	Evaporation Chemical action	Gravimetric	High accuracy, no health risk, time-consuming, destructive
Neutron	In-situ	Neutron scattering	Volumetric	Health risk, immediate response
Dielectric	In-situ/lab	Dielectric constant	Volumetric	No health risk, easy to use, fail in highly saline soil

간접측정 방법 중에 하나인 중성자(Neutron)의 산란 특성을 이용한 방법은 전통적인 점단위 측정 방법과 원격탐사(Remote Sensing)의 단점(낮은 공간해상도)을 보완하는 주목할 만한 토양수분 측정 방법이다. 애리조나대학에서 미국에 토양수분 측정망을 구축한 이후로 수문연구그룹에서 많은 관심을 받고 있다. 현재까지, 200여개 지점에서 cosmic-ray neutron 센서를 이용해서 토양수분을 측정하고 있다. 이 측정 기술은 neutron probe를 이용해서 열중성자(Thermal neutron)를 측정 토양의 수분함양 정도를 관측하는 원리이다(그림 2.8a). Time Domain Reflectometry(TDR)에 의한 토양수분함량 측정은 유전율을 이용하는 것으로 물분자가 극성을 가짐으로써 다른 물질(건조한 토양 3~5)에 비하여 대단히 높은 유전율(물 80)을 가진다. 즉, 토양에서 유전율에 영향을 미치는 것을 토양 내에 물이라 볼 수 있다. 길이를 알고 있는 TDR 센서 probe 전자파가 다시 돌아오는 시간을 고려 속도를 측정하고 이러한 관계를 이용 토양수분을 측정한다(그림2.8b). TDR 방법은 토양무기물이나 염도 및 온도에 비교적 영향을 받지 않는 것으로 알려져 있지만 측정 장비가 고가인 단점도 있다.



그림 2.9. 토양수분 측정망 분포현황(출처: International Soil Moisture Network)

나. 위성 기반 토양수분

최근 토양수분 정보가 수문순환 해석에 있어서 중요함을 인지 관측지점의 확대를 위한 노력에도 불구하고 앞서 언급했듯이 관측 자료의 취득은 우리나라를 포함한 많은 나라에서 한계가 있는 것이 현실이다. 그림 2.9에서 보듯이 우리나라를 포함한 많은 나라에서 미국 및 유럽국가들에 비해 토양수분 관측밀도가 낮은 것을 알 수 있다. 이러한 현실적인 문제의 대안으로 인공위성을 포함한 원격탐사 기술로 토양수분 정보를 취득하고자 하는 연구가 활발히 진행되고 있다. 원격탐사 기술을 이용해서 토양수분을 측정하는 방법은 크게 3가지로 구분할 수 있다(① Optical, ② Thermal, ③ Microwave). 표 2.7은 각 방법에 대한 기본 개념 및 장·단점을 보여준다.

위성영상을 활용하여 토양수분의 관측은 직접적인 방법이 아니라, 위성에 탑재된 센서를 활용 Brightness Temperature를 관측하고, Brightness Temperature와 토양의 수분과의 관계를 이용 토양수분 자료를 생산·제공하는 것이 일반적이다. 토양수분의 산정은 물리적인 방법과 통계적인 방법으로 구분이 된다. 현재 위성을 통해 제공되는 토양수분은 대부분 물리적 특성을 반영한 Retrieval Algorithm을 개발·적용하고 있다. 반면, 통계 모델을 활용한 토양수분 정보 취득은 대부분 연구단계에서 진행되고 있으며 Retrieval Algorithm으로 추출한 토양수분 자료를 회귀모형, 기계학습 Algorithm 등과 같은 통계적인 모형을 이용하여 토양수분 자료를 재분석하여 원시 토양수분 자료의 시·공간 해상도 및 데이터 품질 신뢰성을 개선하는 방법이다.

표 2.7 위성영상을 활용한 토양수분 측정방법 및 장·단점

Group (Wavelength)		Porperty observed	Advantage	Shortcomings
Optical (0.4~2.5 μm)		Soil reflection	Fine spatial resolution Broad coverage	Sensitive to soil type Cloud contamination
Thermal Infrared (3.5~14 μm)		Earth surface temperature	High spatial resolution Physically well descrived	Bare soil only Very top soil only Cloud contamination Contaminated by surface topography
Microwave (1~30 cm)	Passive	Brightness temperature	All weather Penetrate some vegetation Broad coverage Physically well understood	Coarse spatial resolution Contaminated by surface roughness and vegetation Interference from communications
	Active	Backscatter coefficient	All weather Relatively higyh spatial resolution Physically well described	Low temporal resolution limited swath width Contaminated by surface roughness and vegetation

1) SMOS

SMOS (Soil Moisture and Ocean Salinity)는 유럽 우주국 (ESA)에서 지구 탐사 계획의 일환으로 개발한 위성으로 지난 2009년 11월 발사되어 현재까지 운행 중에 있다. SMOS는 전지구 단위의 토양수분과 해양염도 관측을 목적으로 발사된 특히 최초의 토양수분 관측을 목적으로 발사된 위성으로 C-band를 사용하는 AMSR Series의 위성이나 ASCAT 위성과는 달리 L-band를 사용하는 특이점도 있다. SMOS는 저궤도 (LEO)를 돌며 탑재된 마이크로파 라디오미터를 이용하여 지구의 밝기 온도 (Brightness Temperature)를 측정한다. 이 측정한 밝기 온도에서 기후 기상 연구의 중요한 데이터인 토양 수분량과 해양 염도를 추출한다.

위성에서 L-band를 활용하여 토양수분을 관측시 C-band 활용에 대비 토양수분 관측 심도가 깊은 장점이 있다(C-band 1-3cm, L-band 5cm). 하지만 L-band의 주파수(Frequecy)가 1.4 GHz로 휴대전

화의 주파수(1.8GHz)와 주파수 대역이 비슷함에 따라 인구밀도가 높은 지역에서 모바일 폰 사용량이 많아 휴대폰 주파수와 위성 센서 두 주파수 간 간섭(RFI, Radio Frequency Interference)으로 오측의 확률이 높고 결측치의 빈도가 높아지는 단점도 있다. Kwon. et al. (2019)의 연구 결과를 보면 우리나라는 RFI의 영향이 심하여 SMOS 토양수분 자료의 결측치가 많아 시계열 분석을 위한 SMOS 토양수분의 국내 적용은 어려운 것으로 검토 된 사례도 있다. 그림 2.10과 2.11은 특정 기간의(2013. 6. 8. - 2013. 6. 13) SMOS 토양수분 자료를 한반도와 영국을 대상으로 비교한 것으로 그림에서 보듯이 한반도는 영국에 비해 높은 빈도와 넓은 공간에서 결측치가 있음을 알 수 있다.

표 2.8 토양수분 관측 위성 리스트 및 특징

	ASCAT (Active)	AMSR2 (Passive)	SMOS	SMAP
Frequency	C-band	Multiple bands	L-band	L-band
Spatial resolution	12.5km, 25 km	10km, 25km	35-50km	3-40km
Temporal resolution	3 days	1-2 days	1-3 days	3 days
Observation depth	0.5-2cm	~ 1cm	~ 5cm	~ 5cm
Mission period	Since 2007	Since 2012	Since 2009	Since 2015

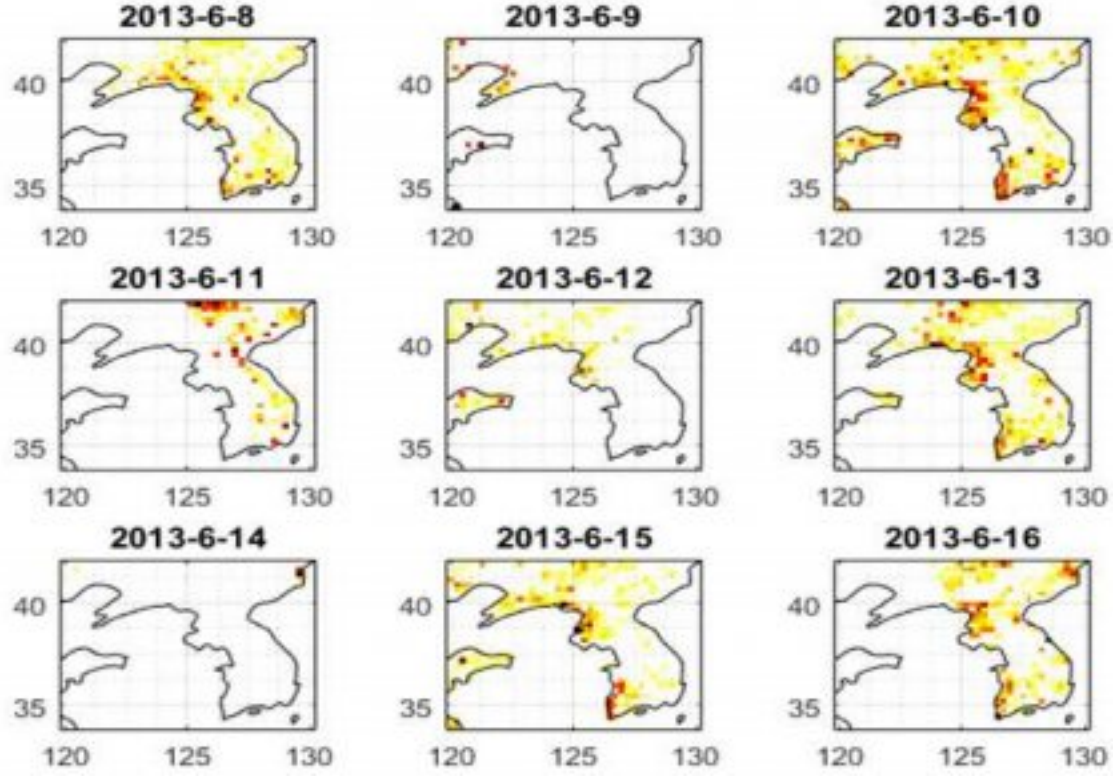


그림 2.10. SMOS 토양수분 분포도(한반도)

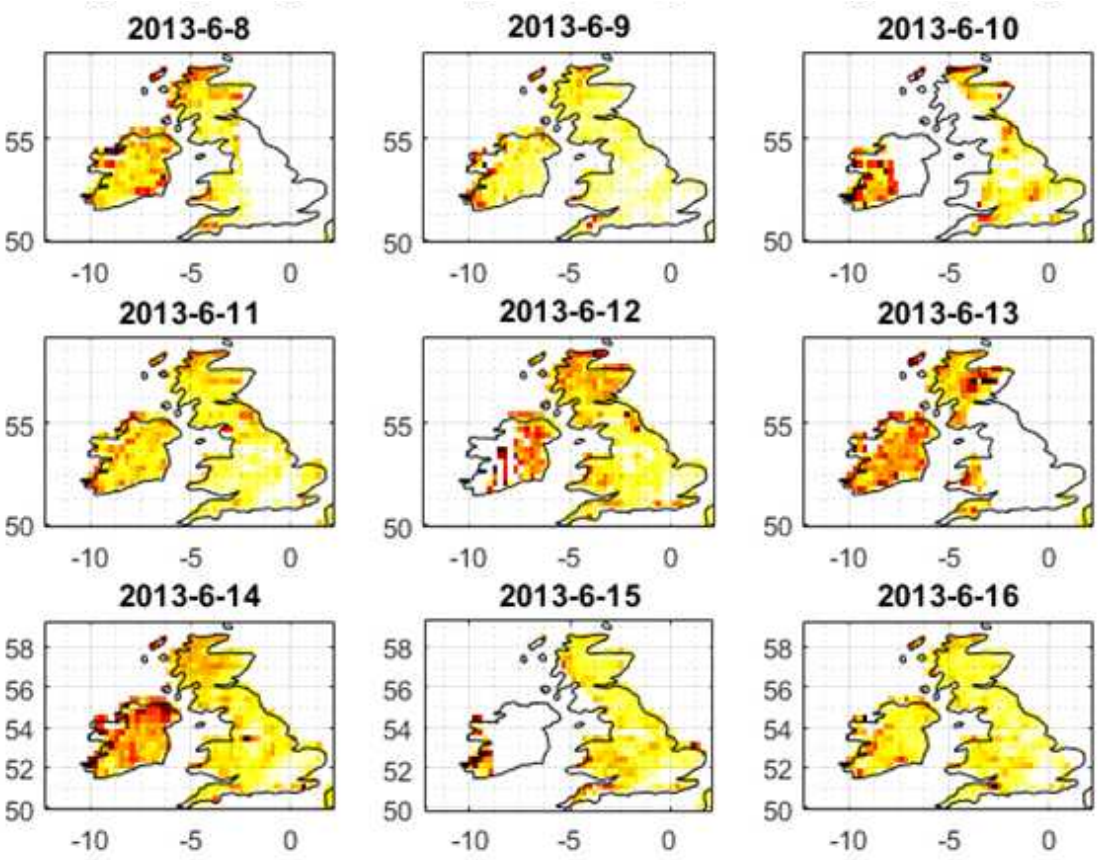


그림 2.11 SMOS 토양수분 분포(영국)

2) AMSR-2

GCOM-W1의 AMSR-2는 2011년 10월 관측을 중단한 AMSR-E(Advanced Microwave Scanning Radiometer-Earth Observing System)의 후속 위성이다. 토양수분 측정 방법은 이전의 AMSR-E와 이론적 배경을 같이한다. AMSR2는 AMSR-E가 수명을 다해 계측을 중단함에 따라 이를 대체하기 위하여 2012년 5월에 일본 JAXA(Japan Aerospace Exploration Agency)에서 GCOM-W1 (Global Change Observation Mission - Water) 위성에 탑재되어 발사이후 2012년 7월부터 현재(2020.8월)까지 토양수분, 강우, 강설깊이 등의 관측 자료를 사용자에게 무료로 제공 중이다. JAXA에서 운영중인 홈페이지 또는 FTP접속을 통해 AMSR2 토양수분 데이터를(공간 해상도 10km, 25km) 다운 받을 수 있다. AMSR2는 NASA와 JAXA의 협업으로 제작되었고, NASA와 JAXA는 각 기관 고유의 토양수분 추출 알고리즘을 개발하였다. NASA의 경우 LPRM(Land Parameter Retrieval Model) 알고리즘을 이용하여 AMSR2 센서에 탑재된 C1, C2, X band들의 토양수분 자료를 제공한다. Kim et al.(2016)은 한반도에서 AMSR2의 C1, C2, X band로부터 산출된 토양수분 자료들의 적용성에 대해 분석하였으며, RFI의 영향을 비교적 덜 받는 X band의 자료가 한반도에서의 토양수분 자료를 대표하기에 적절하다고 언급하였다.

AMSR-2 위성은 하루에 두 번 적도를 통과하고, 남에서 북으로 통과하는 것을 Ascending ,북에서 남으로 통과하는 것을 Descending이라고 한다. AMSR-2의 경우에는 Ascending은 1:30pm, Descending은 1:30am에 적도를 통과한다. 그림2.12 및 2.13는 각각 AMSR-2를 통해 취득된 글로벌 및 한반도 토양수분자료를 도시한 것이다.

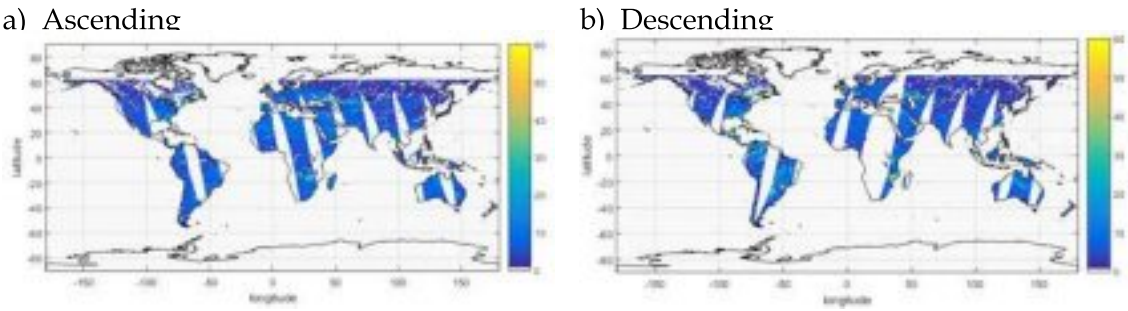


그림 2.12 AMSR-2 토양수분 분포도 (Global scale)

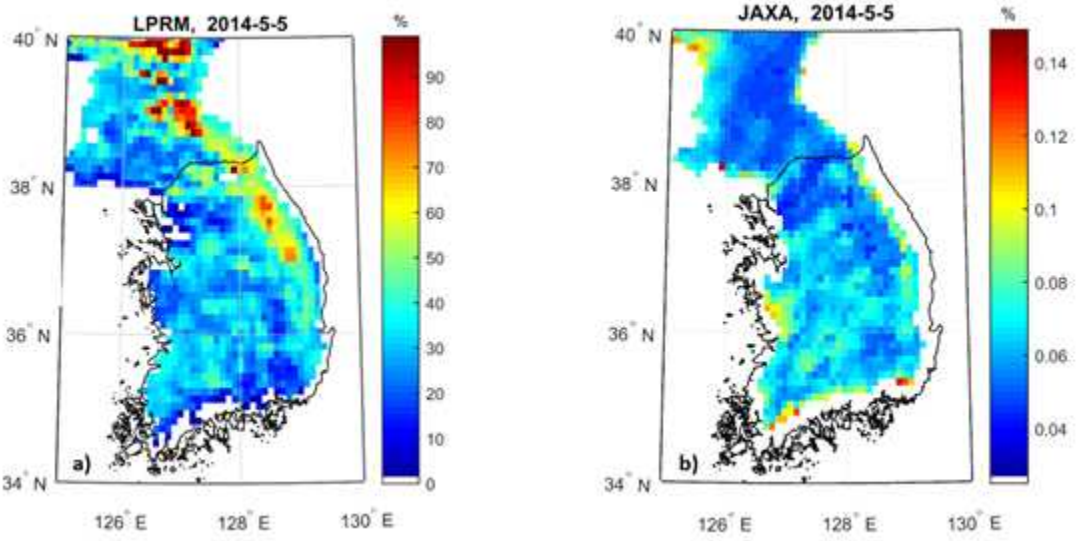


그림 2.13. AMSR 2 토양수분 분포도(한반도)

3) ASCAT(Advanced Scatterometer)

유럽기상위성기구는 기상, 환경 및 기후 모니터링을 목적으로 Metop 위성을 2006년에 발사하였다. Metop 위성에 탑재된 ASCAT 센서는 C band Microwave를 이용하여 토양수분을 측정한다. 앞서 소개한 Passive Microwave를 이용하는 SMOS와 AMSR2와는 달리 ASCAT은 극궤도 위성(Metop-A/B: Meteorological Operational satellite)에 장착된 Active 센서을 사용해서 전지구 범위의 토양수분자료를 제공한다. Metop 위성은 유럽 우주기구 ESA(European Space Agency)에서 위성을 발사, 유럽기상위성개발기구 EUMETSAT(European Organisation for the Exploitaion of Meteorological Satellites)에서 운영하고 있다. ASCAT 센서는 당초 바다 표면의 풍속을 관측하기 위해 개발되었으나, Vienna University of Technology에서 토양수분 자료를 추출하는 알고리즘을 개발하였고, 검증결과 비교적 양질의 토양수분 정보를 제공하는 것으로 알려져 있다. 기존의 선행 연구를 살펴보면 ASCAT 토양수분 자료는 건조한 지역에서 자료의 정확도가 떨어지는 것으로 알려져 있으며, 그 외 지역에서는 다른 위성에 비하여 정확성이 높다는 것이 알려진 바 있다. ASCAT 토양수분 자료의 시간 해상도는 일 단위이며 12.5km의 공간 해상도를 가지고 있다.

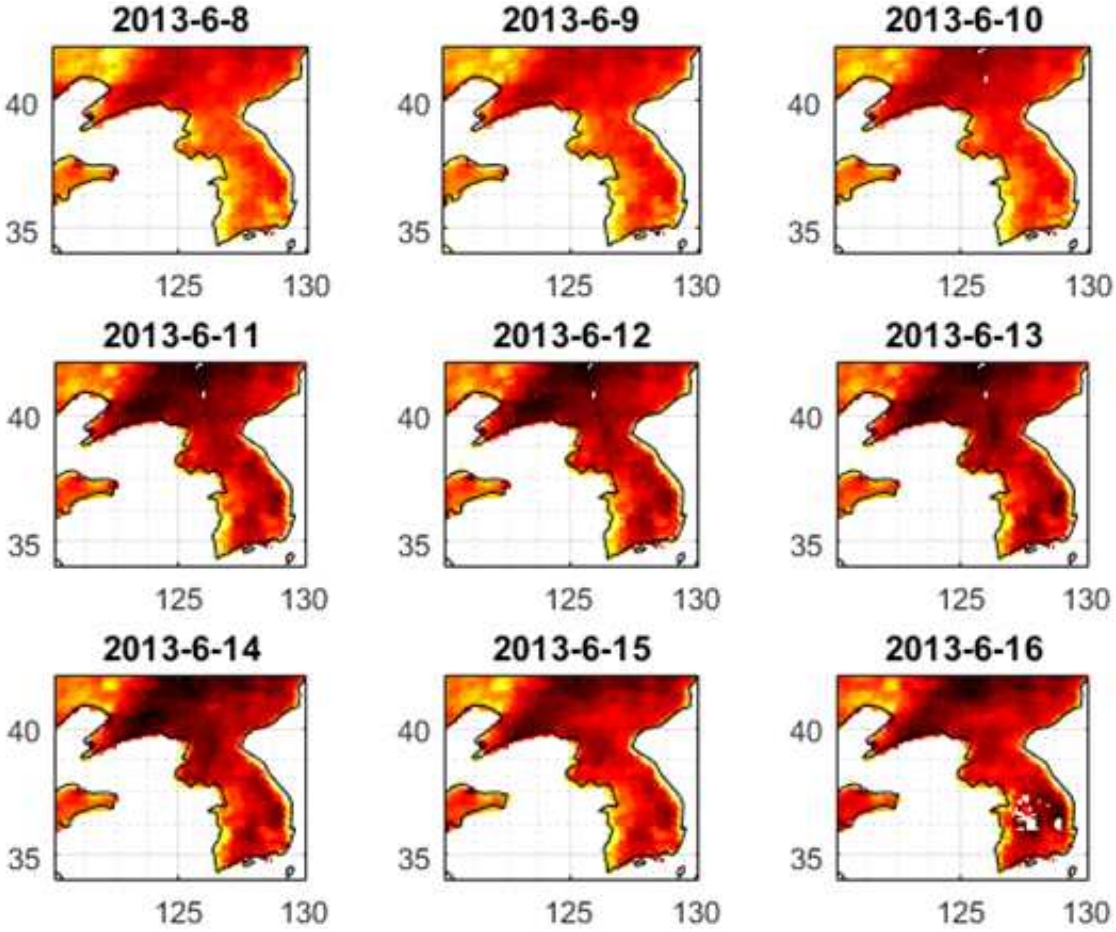


그림 2.14 ASCAT 토양수분 분포(한반도)

2.2 위성자료의 수자원분야 활용현황

2.2.1 강우-유출 (Rainfall-runoff)

강우-유출 모형은 유역의 복잡한 물순환의 과정을 단순화·개념화하여 강우 발생으로부터 기인한 하천(유역)의 유출 과정을 모의하는데 이용된다. 강우-유출모형은 수자원시설물을 설계하기에 앞서 관측 유량의 자료의 확장, 미계측 유역을 대상으로 과거 하천유량 모의 그리고 토지이용이나 기후변화에 따른 유출 패턴의 변화 등을 평가하는데 매우 중요한 Tool로 사용된다. 이러한 관점에서 과거부터 최근까지 강우-유출 모형의 개발과 평가는 수자원분야에서 주요 관심사였다. 그간 강우-유출모형의 개발에 많은 시간과 노력을 기울였음에도 불구하고, 현재까지 개발된 모형은 실무와 과학적 관점에서 여전히 개선의 여지가 있다 (Orth et al., 2015). 강우-유출과정에 있어서 시·공간적인 변동성은 매우 크다. 즉, 강우에 응답하는 유출 양상은 기상조건(선행강우 등), 토지 피복, 토양 및 지형특성에 크게 영향을 받을 뿐만 아니라 관개 및 도시화 등 인간 활동의 많은 요소에도 영향을 받는다 (Devia et al., 2015; Jakeman, 1993; Kisi and Parmar, 2016).

강우-유출모형은 그 특성에 따라 다양하게 군집화(Grouping) 할 수 있으나, 3종류로 분류하는 것이 일반적이다(Data-driven, Conceptual, Physically-based) (Devia et al., 2015; Shrestha, 2009). Data-driven 모델은 Empirical 또는 Black-box 모델이라고도 하며, 머신러닝 등의 통계모델을 활용해서 강우와 유출의 관계를 과거의 수많은 강우-유출 실측 자료를 이용해서 학습 후 강우-유출 양상의 구조를 구축하는 모델을 말한다 (Behzad et al., 2009; Young et al., 2017). Data-driven 모델과 달리 Conceptual 모델은 강우와 유출의 비선형적인 관계를 대표하는 연속된 일련의 시스템으로 구성된 개념화한 모델을 말한다. 반면, Physically-based 모델은 강우와 유출의 관계를 물리적으로 규명하고 수학적으로 해석 강우에 반응하는 유역의 특성을 모형으로 구축한 것이다.

최근 위성 자료를 활용해서 기 개발된 강우-유출모형과 결합해서 기존 모형의 장점을 살리고 단점을 최소화하고자 하는 연구가 활발히 진행 중에 있다. 표 2.9는 토양수분 위성 자료를 활용해서 장·단기 유출모형에 적용한 기존 연구사례와 성과를 요약한 것이다. 표에서 볼 수 있듯이 위성 토양수분자료는 주로 앞서 소개한 AMSR, SMOS 및 ASCAT 위성에서 취득하였고, 대부분의 연구에서 Data Assimilation 기법중에 하나인 Kalman Filter 기법을 주로 활용하여 위성에서 취득한 토양수분 정보를 기존 강우-유출모형에 반영하였다. 또한, 위성 토양수분 자료를 강우-유출 모형에 직접 적용하기에 앞서 Bias correction 기법을 활용 위성에서 획득한 토양수분 자료의 품질을 개선 후에 강우-유출모형에 사용하고 있다. 이는 극궤도 위성은 지상 약 700km 상공에서 지표의 Brightness temperature를 관측하고 이 값을 이용해서 토양수분 정보를 생성·제공하고 또한, 위성에서 관측한 토양수분 자료와(관측심 5cm 이내, 공간해상도 12.5km 이상) 지상 관측치와 발생하는 시·공간적인 Bias 발생은 어쩌면 불가피하며 이러한 Bias를 보정·제거하기 위한 Quantile Matching Method 등을 활용한 전처리 과정은 위성으로부터 획득한 토양수분 정보를 강우-유출 모형에 활용하기 전에 필수적으로 거쳐야하는 과정이라 사료 된다.

표 2.9 위성자료를 활용한 강우-유출모형 적용사례

Authors	Title	Satellite Sensor	Hydrological Model/Method	Study area	Objective	Key findings
Alvarez-Garret on et al. (2014)	The impacts of assimilating satellite soil moisture into a rainfall–runoff model in a semi-arid catchment	AMSR-E	·The probability distributed model (PDM) ·Bias correction ·EnKF	Australia (Semi-arid Warrego catchment)	· Provide continuous streamflow modelling within the catchment, which makes effective use of satellite soil moisture observations to improve predictions.	· The stochastic assimilation improves the prediction for both moderate and major floods; however, the improvement is higher and more consist for moderate events. · The stochastic assimilation efficacy considerably depends on the rescaling technique.
Brocca et al. (2012)	Assimilation of Surface- and Root-Zone ASCAT Soil Moisture Products Into Rainfall–Runoff Modeling	ASCAT	·MISDc ·EnKF	Italy (Tiver River Basin)	· Investigate the assimilation of SZSM and RZSM via synthetic and real data experiments to evaluate the corresponding benefits on runoff simulation.	· The assimilation of the exponentially filtered RZSM product has a significant impact on runoff simulation, providing also an evident improvement in the performance of the rainfall–runoff model.
Kumaretal. (2014)	Assimilation of Remotely Sensed Soil Moisture and Snow Depth Retrievals for Drought Estimation	AMSR-E(SM) SMMR(Snow)	·NoahLSM ·EnKF	USA	· Examine the influence of remotely sensed soil moisture and snow depth retrievals toward improving estimates of drought through data assimilation	· The influence of data assimilation on improving drought estimates was examined using the root-zone soil moisture– and streamflow-based percentiles.
Lietal. (2016)	Estimation of river discharge using satellite-derived flow signals and artificial neural network model: application to imjin river	Satellite-deri ved flow signals	·ArtificialNeural Network (ANN)	North-South Korea border (Imjin basin)	· Investigated the use of satellite-derived flow (SDF) signals and a data-based model for the estimation of runoff for an ungaged catchment	· SDF signals along with some local measured data can play an useful role in river flow estimation and especially in flood forecasting for data-scarce regions
Lievens et al. (2015)	SMOS soil moisture assimilation for improved hydrologic simulation in the Murray Darling Basin, Australia	SMOS	·Landsurface model (i.e., VIC) ·Biascorrection ·EnKF	Australia (Murray Darling Basin)	· Evaluate whether the assimilation of coarse-scale SMOS observations can improve the simulation of soil moisture and streamflow at a finer spatial resolution.	· The largest improvements were apparent in the simulation of peak runoff observations.
Loizu et al. (2018)	On the assimilation set-up of ASCAT soil moisture data for improving streamflow catchment simulation	ASCAT	·MISDc ·TOPLATS ·Bias correction ·EnKF	Italy,Spain (4 catchments)	· Do the SWI calculation and there-scaling techniques have a significant influence on the DA results? · Do the model choice influence the results?	· After model calibration, a conceptual model provides more accurate results than a physically based complex one(TOPLATS). · For some catchments, DA could not increase model perform once due to the already high NSE efficiency.
Massari et al. (2015)	The Use of H-SAF Soil Moisture Products for Operational Hydrology: Flood Modelling over Italy	ASCAT SM-DAS-2 (RZSMbydata assimilation)	·MISDc (1layer) ·SCRRM ·SWI	Italy (35 catchments)	· Investigate the performance of two of the satellite SM products of the H-SAF project (i.e., SM-OBS-1 and SM-DAS-2) in order to highlight the information content that they retain in flood modelling.	· MISDc generally outperforms SCRRM, except in a few cases. · By assimilating SM-OBS-1 and SM-DAS-2 products into the MISDc model, more robust results were achieved.
Massari et al. (2018)	Exploiting Satellite-Based Surface Soil Moisture for Flood Forecasting in the Mediterranean Area: State Update Versus Rainfall Correction	ASCAT ERA-Interim	·MISDc (2layers) ·SWI ·EnKF	Mediterranean area (10 catchments)	· To what extent updating soil moisture states leads to better flood predictions than the correction of the rainfall? · What is the impact of the basin size and the climate conditions on the results?	· The potentiality to improve operational streamflow forecasting by using remotely sensed surface soil moisture. · The bias-corrected SM produces an overall improvement.
Massari et al. (2018)	Data Assimilation of Satellite Soil Moisture into Rainfall-Runoff Modelling: A Complex Recipe?	ASCAT	·MISDc ·EnKF	CentralItaly (5 catchments)	· Explore the effects of different catchments characteristics (e.g.,size,landuse and morphology), climatology and SM conditionson DA · Compare the performance of the assimilation for three different rescaling techniques(LR,VM,CDF)	· There is no evidence of any relationship between the catchment area and the performance of the DA but catchment specific characteristics may prevent positive results of the DA · A uniform pattern of performance of the DA for LR,VM and CDF was found: simple techniques may be equally valid and easier to implement.
Parajka et al. (2006)	Assimilating scatterometer soil moisture data into conceptual hydrologic models at the regional scale	ERS	·HBVmodel ·SWI	Austria	· Test the potential of assimilating scatterometer data for improving hydrological predictions in ungauged catchments.	· The assimilation of scatterometer data into the calibration of the hydrologic model was found to improve the relationship between the two soil moisture estimates, without any significant decrease in runoff model efficiency.
Silvestro et al. (2015)	Uncertainty reduction and parameter estimation of a distributed hydrological model with ground and remote-sensing data	ASCAT	·Continuummodel ·GLUEmethod	Italy (Orba basin)	· Analyze the calibration skill of a distributed continuous hydrologic model by augmenting the model constraints with satellite-retrieved data.	· The skill scores on streamflows how good performances when satellite data are involved in the calibration process
Sunetal. (2010)	Towards improving river discharge estimation in ungauged basins: Calibration of rainfall-runoff models based on satellite observations of river flow width at basin outlet	JERS-1SAR	·HYdrological MODel (HYMOD)	Mekong River (Asia) at Pakse (1gauge)	· Minimize the difference between river widths observed from space and simulated widths by tuning parameters of rainfall-runoff model and at-a-station hydraulic geometry relation simultaneously	· Wide applicability for reproducing river streamflow time series on the daily scale in ungauged basin if satellite data is available.

2.2.2 가뭄 모니터링 (Drought monitoring)

최근 기후변화 등의 원인으로 세계적으로 가뭄과 홍수의 발생빈도가 높아지는 경향을 보이고, 우리나라도 최근 가뭄으로 사회·경제적 피해가 점증하고 있다. 가뭄의 정의는 다양하나 일반적으로 가뭄이란 장기간 강우의 부족으로 가용한 수자원의 부족한 상태를 의미한다. 미국 기상국(US Weather Bureau)에 따르면 "가뭄이란 어느 지역의 동식물 생육에 저해를 가져올 수 있을 정도로 강우의 부족이 매우 심각하게 장기간 지속되는 상태이거나 생활용수와 수력발전에 필요한 용수를 정상적으로 확보하지 못한 상태"로 정의하고 있다. 가뭄은 강우 현상과 수자원을 이용하는 분야에 따라 각기 다르게 정의될 수 있으나, 표 2.10과 같이 기상학적 가뭄, 농업적 가뭄, 수문학적 가뭄, 그리고 사회경제적 가뭄으로 분류하는 것이 일반적이다. 그림 2.15는 가뭄 단계별 가뭄의 정도를 평가하는 수문요소 및 기상학적 가뭄에서 사회경제적 가뭄으로 전파되는 과정을 보여준다.

표 2.10 가뭄의 정의

- 기상학적 가뭄 : 주어진 기간의 강우량이나 무강우 계속일수 등으로 정의되고 가뭄의 지속기간에 따라 주로 예년 치와의 비교로 가뭄의 정도를 평가한다.
- 농업적 가뭄 : 농업에 영향을 주는 가뭄을 언급한 것으로 농작물 생육에 지접 관계되는 토양수분의 정도로 주로 판단한다.
- 수문학적 가뭄 : 강우의 부족으로 지표수 및 지하수 양이 줄어드는 것을 말하며 이러한 수문학적 가뭄의 지속은 하천수 및 지하수의 고갈로 농업적 가뭄을 더욱 심화시키고 결국 사회경제적 가뭄을 야기한다.
- 사회경제적 가뭄 : 기상 및 수문학적 가뭄과 연관되어 수원의 부족으로 인해 용수공급과 수요측면에서 불균형을 발생시켜 일부 상품의 수요와 공급, 그리고 전력생산 등 인간의 경제활동에 피해를 주는 현상으로 정의된다.

표 2.11 가뭄지수의 특징 및 장단점(요약)

Indices	Input parameters	Strengths	Weaknesses
Standardized Precipitation Index (SPI)	P	Can be calculated over multiple timescales	Uses precipitation data only, i.e., it only detects the rainfall deficit.
Standardized Soil Moisture Index (SSI)	SM	Can be calculated over multiple timescales	Uses SM data only
Palmer Drought Severity Index (PDSI)	P, T, AC	Considers both water supply (precipitation) and demand (potential evapotranspiration)	Does not present accurate results in mountainous, frozen and snow covered areas.
Standardized Precipitation Evapotranspiration Index (SPEI)	P, T	Accounts for the influence of temperature changes	Requires a large amount of complete dataset for temperature and precipitation
Palmer Hydrological Drought Severity Index (PHDI)	P, T, AC	Allows comprehensive water system to be considered	Does not consider human impacts
Surface Water Supply Index (SWSI)	P, RV, SF, SP	Considers snow pack streamflow, rainfall and reservoir storage	Basin-dependent (cannot be compared with different regions)
Multivariate Standardized Drought Index (MSDI)	MI	Can be used to monitor more than just drought.	Requires serially multiple complete dataset

Note: P: precipitation, SM: soil moisture, T: temperature, AC: available water content, RV: reservoir storage, SF: streamflow, SP: snowpack, MI: multiple indicators.

홍수피해와 달리 가뭄을 정량적으로 평가하는 것은 쉽지 않은 일이다. 가뭄의 정도는 주로 가뭄지수를 사용하여 평가하며, 가뭄지수는 강우, 융설, 하천유량, 지하수 등 가뭄의 평가 목적에 따라 각

기 다른 물공급 관련 자료를 이용하여 가뭄 상황을 파악한다. 일반적으로 널리 이용되는 지수는 Standardized Precipitation Index(SPI), Palmer Drought Severity Index(PDSI), Surface Water Supply Index(SWSI) 등이 있다. 앞서 언급한 지수들은 각각 장점과 한계를 갖고 있어, 지수의 적용 대상 지역의 수자원 특성 및 물 공급 시설 등을 고려, 가뭄지수를 선택 가뭄을 평가하거나 각지수의 장점을 살리고 단점을 극복하고자 두 개 이상의 가뭄지수를 통계적 방법으로 통합하여 사용하기도 한다.

가) 표준강수지수 (SPI, Standardized Precipitation Index)

Mckee 등(1993)은 가뭄은 강수량의 감소에 의해 시작해서 물부족을 초래하는점에 착안해서 SPI 가뭄지수를 개발하였다. 즉, 강우량이 평상시보다 부족하면 수자원공급원인 지하수, 저수지 저류량, 토양내의 수분 함유량 및 하천유출량의 감소에 영향을 미친다는 가정에서 SPI는 가뭄 지수중에 가장 일반적으로 사용되고 있다. SPI는 월간 누적 강우량 시계열 자료를 3, 6, 9, 12개월 등과 같이 특정 시간 단위로 누적하여 사용하며 일반적으로 SPI-3, SPI-6 등과 같이 표현한다. SPI-3와 같은 단기간의 시간 단위는 강우의 부족에 비교적 빨리 그리고 직접 영향을 받는 농업분야에 사용이 되며, SPI-6 등과 같은 장기간의 시간 단위는 저수지 등의 수자원 공급시설 관리에 이용될 수 있다.

SPI를 산정하는 절차는 앞서 언급한 시간 단위별 누가강수 시계열을 산정하고 미리 설정한 지속 시간별 시계열을 구성한다. 산정된 시계열의 적합한 확률 분포형을 선정하고 이를 이용하여 변량의 누가확률을 산정한 후, 그림 2.16과 같이 표준정규분포에 적용하여 산정한다. 혹은, 특정 확률분포에 Fitting하는 불확실성을 고려 비모수적 방법으로 시계열값을 Fitting후 정규분포에 적용하기도 한다.

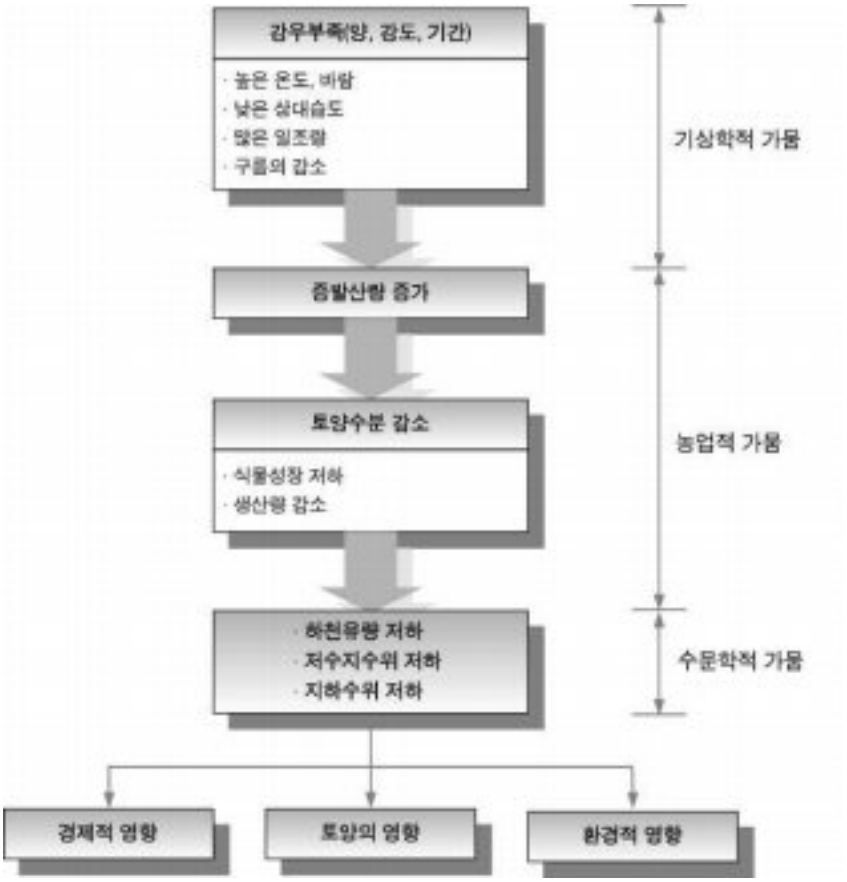


그림 2.15 가뭄의 전이 과정에 따른 가뭄정의

Mckee 등(1993)은 SPI 가뭄지수 값으로 가뭄의 정도를 표 2.12와 같이 가뭄의 정도를 7단계로 분류하였다. 가뭄 사상은 SPI 지수가 음의 값을 갖는 시점부터 발생하는 것으로 보며 SPI 지수가 다시 양의 값을 보이기까지의 기간을 가뭄의 지속기간으로 판단한다. 그림 2.17은 산정된 SPI 가뭄지수로부터 가뭄을 정량적으로 평가하는 개념을 도시화 한 것이다. 그림에서 보듯이 SPI=0을 기준으로 wet 혹은 dry한 상태를 판단할 수 있다. 가뭄 지속기간(Duration)은 SPI가 0 이하로 연속되는 기간을 의미하며, 가뭄심도(Severity)는 가뭄 지속 기간의 면적(Area) 그리고 가뭄의 강도(Intensity)는 가뭄 심도를 가뭄 지속기간으로 나누어 산정한다.

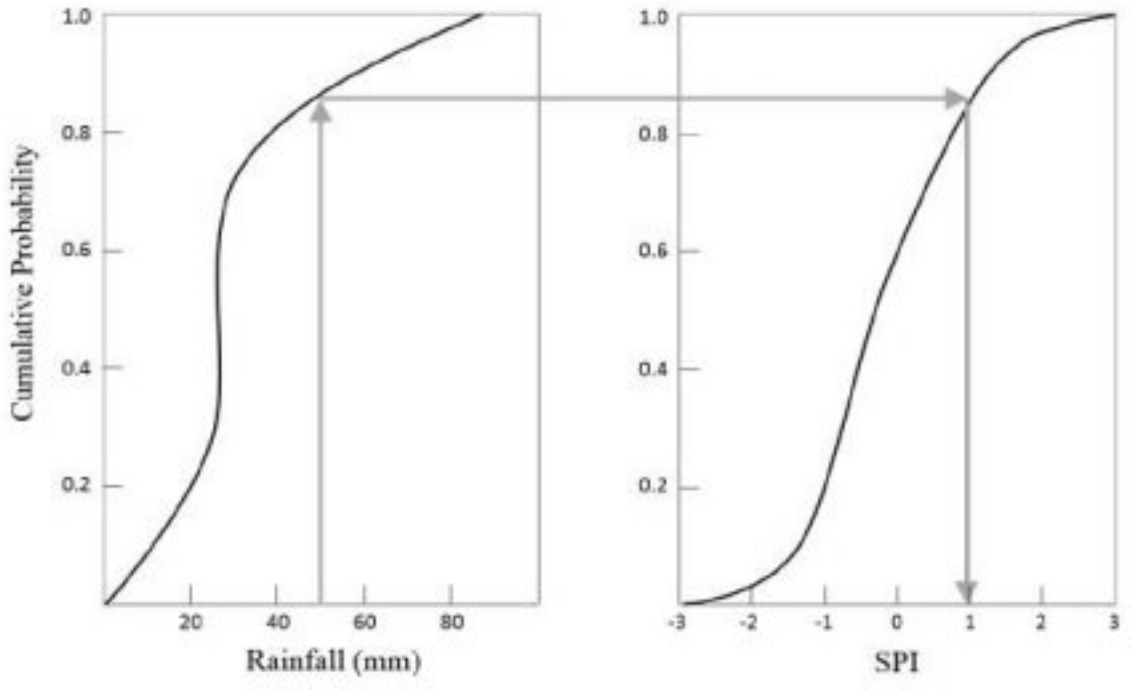


그림 2.16. SPI 산정 개념도

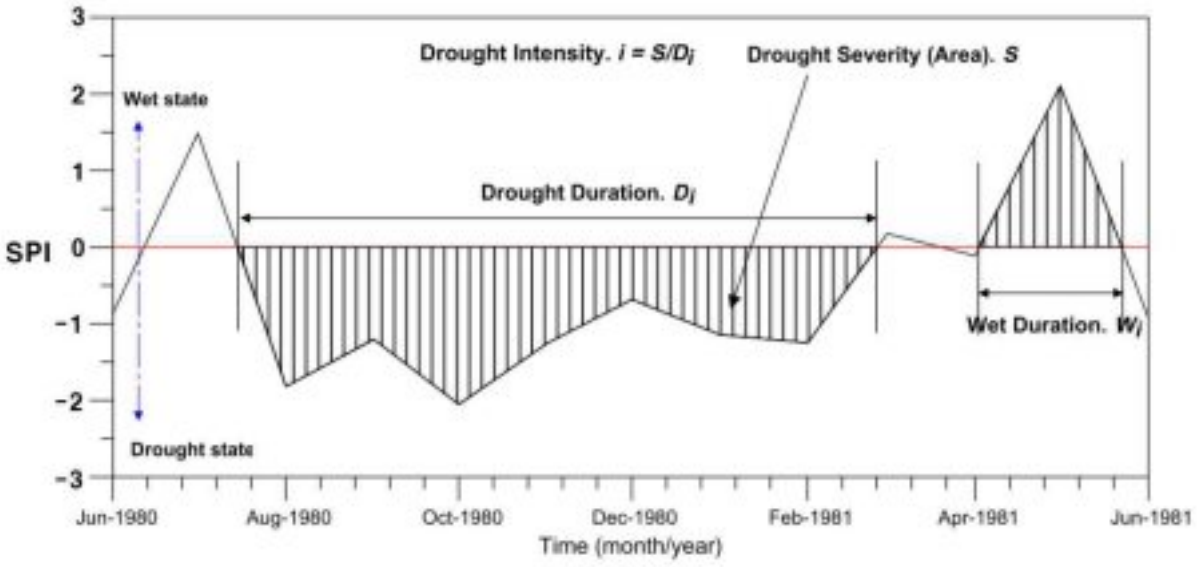


그림 2.17. 가뭄특성 정의

표 2.12 SPI에 의한 가뭄 상태의 분류

가뭄지수의 범위	가뭄 상태
2.00 이상	Extremely Wet
1.50 ~ 1.99	Very Wet
1.00 ~ 1.49	Moderately Wet
-0.99 ~ 0.99	Near Normal
-1.00 ~ -1.49	Modrately Dry
-1.50 ~ -1.99	Severely Dry
-2.00 이하	Extremely Dry

나) 토양수분지수 (SMI, Soil Moisture Index)

토양수분지수(Soil Moisture Index, SMI)는 가뭄지수는 토양수분의 시계열 자료를 이용하여 가뭄을 판단하는 지수로, 식생 또는 작물의 성장 및 수확량에 영향을 주는 가뭄 인자를 판단하기 위한 지표로 농업적 가뭄의 정도를 분석하기위해 주로 사용한다. 농업적 가뭄은 기상학적 또는 수문학적 가뭄이 농업에 미치는 영향, 즉 강수의 부족, 토양수분의 부족, 지하수나 저수지 수위의 저하 등의 여러 가지 특성에 의해서 정의될 수 있다. 작물 생육에 필요한 수분은 특정 지역, 특정 기후, 특정 생육기, 특정한 토양상태에 따라 다르기 때문에 농업적 가뭄을 정의하기가 어렵지만, 일반적으로 농업적 가뭄은 농작물의 생산량이 감소될 정도의 토양수분인 유효수분백분율의 50% 이하일 때로 정의하고 이를 근거로 해서 농업적 가뭄을 평가한다. 가뭄의 특성을 분석하는 방법으로써 가장 유용하게 이용되는 방법은 Runs 이론으로 기상학적 가뭄지수인 SPI와 동일하게 가뭄이 가지는 다양한 특성을 세 가지의 특성치로 구분하여 이를 각각 분석하는 이론으로써 가뭄의 세 가지 특성치는 기본수준(truncation level)에 대한 음의 부분 즉, 부족분에 대한 지속기간(duration ; D), 크기(magnitude ; M), 강도(severity ; S)로 분류할 수 있다.

가뭄의 시작은 유효수분백분율이 50% 이하로 내려가는 시점이며, 가뭄의 종료는 강우에 의해 충분한 수분이 공급되어 유효수분백분율이 50% 이상이 될 때이다. 가뭄강도는 유효수분백분율 50% 이하일 경우의 기간과 유효수분백분율 50%에서 현재의 토양수분함량을 뺀 값의 곱으로 정의하였으며, 이는 가뭄의 실제적인 크기를 나타내기 때문에 가뭄강도는 무게 단위의 토양수분과 기간의 곱(% Wt.×day), 부피 단위의 토양수분과 기간의 곱(% Vol.×day), 토양수분량과 기간의 곱(㎜×day), 유효수분백분율과 기간의 곱(%×day) 등과 같은 방법으로 표시할 수 있다.

다) 위성영상을 이용한 가뭄평가

광역적 가뭄 파악을 위하여 인공위성 자료를 활용하는 방안은 크게 인공위성에서 취득된 데이터만을 이용하는 방법과 위성 자료와 결합한 기후학적 물수지를 이용하는 방법을 생각할 수 있다. 위성 자료만을 이용하는 방법은 가뭄으로 인하여 식생의 활성도 저하와 지표면 온도의 상승으로 이어지는 현상을 위성으로부터 관찰하여 가뭄 현상을 파악하는 것이다. 위성 단일 자료만으로 가뭄 분석이 가능하다는 장점은 있으나, 가뭄을 평가하기 위한 데이터를 인공위성에 전적으로 의존하여야 하므로 보다 정확하고 주기적인 위성 관측 자료의 관측된 자료의 품질이 확보되어야 한다.

반면 기후학적 물수지를 이용하는 방법은 위성자료와 기상 및 강우 자료를 조합하여 가뭄분석을 수행하며, 지상의 관측자료가 필요하다는 단점을 갖지만, 인공위성 자료에서 파악할 수 없는 현상을 직접 기상 및 수문 자료를 통해 취득할 수 있으므로 정확성을 제고 할 수 있다는 장점이 있다. 우리나라는 전 국토의 70%가 산지로 이루어져 있으며 식생지수는 수문 분석에 있어서 중요한 지표로 활용이 가능하다. 또한 증발산량과 식생지수가 높은 상관관계가 있는점을 착안하여 MODIS 영상에서 취득된 NDVI와 기온자료를 활용하여 증발산량을 산정하고 이렇게 위성자료로부터 얻어진 증발산량을 이용 기후학적 물수지 분석을 통해 지표의 수분 부족량을 파악해서 가뭄의 심도를 파악하기도 한다. 식생지수는 무차원의 복사량으로서 녹색식물의 상대적 분포량과 활동성, 엽면적지수, 엽록소함량, 엽량 및 광합성 흡수복사량 등과 관련된 지표로 사용된다. NDVI (Normalized Difference Vegetation Index)라 알려진 정규화 식생지수가 가장 널리 이용되고 있다. 이러한 정규화 식생지수 NDVI는 인공위성 영상자료로부터 지표면의 식생 피복과 관련된 정보를 얻기 위한 수단으로 사용된다.

그림 2.18은 NASA에서 GRACE(Gravity Recovery and Climate Experiment) 위성을 활용하여 미국 전역의 가뭄상황을 모니터링 정보를 제공하는 화면을 캡쳐한 것이다. GRACE Mission은 월단위로 수자원의 저류량의 변동성을 지표 뿐만아니라 지표하의 수자원 부존량의 물 수지분석 결과를 제공한다. 이처럼 GRACE 위성의 총 수자원 저류량의 시계열 변동성을 관측결과를 분석해서 정상상태로 회복하기 위한, 즉 가뭄 상황을 극복하기 위한 수자원의 양의 정량적 계산이 가능하게한다. 또한, NASA에서는 Data Assimilation 기법을 활용해서 GRACE 위성에서 취득된 자료와 Land Surface 모델을 결합하여 데이터의 품질을 높이는 노력도 함께 이루어지고 있다.

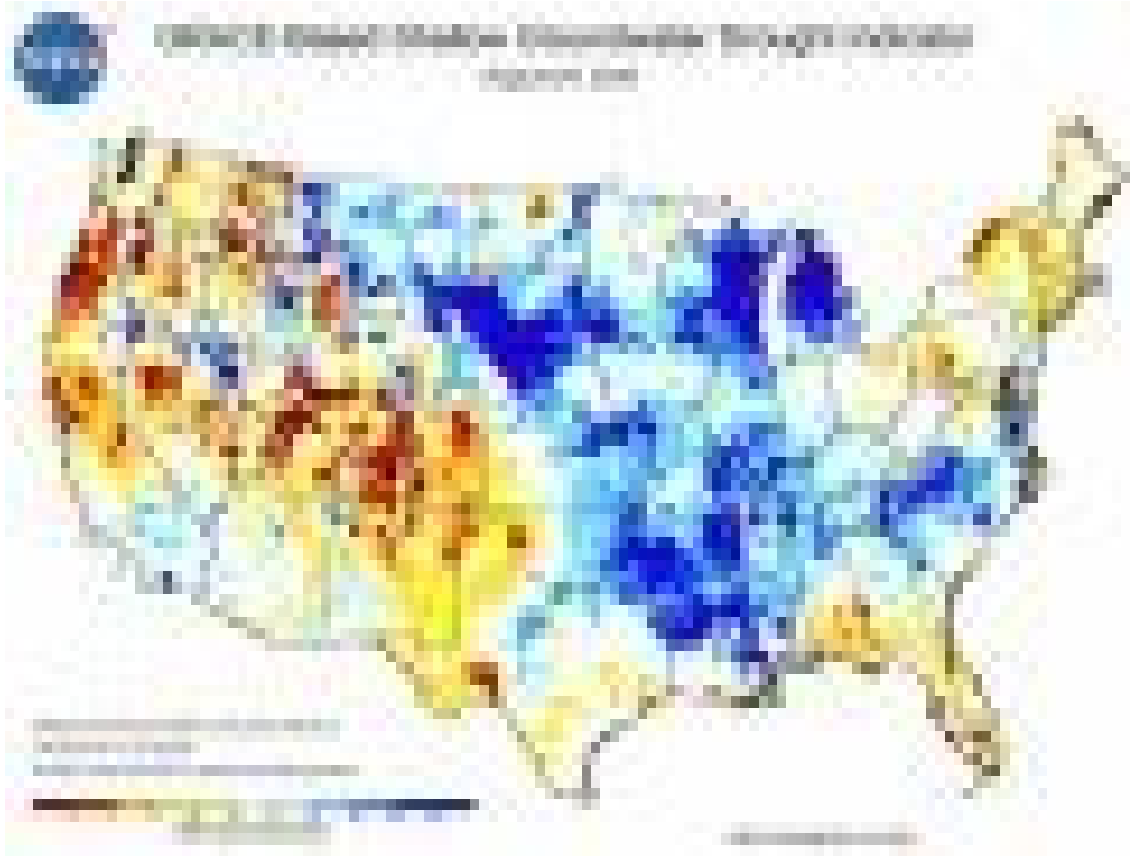


그림 2.18 지하수 가뭄지수 (출처: https://grace.jpl.nasa.gov/applications/drought-monitoring/)

2.2.3 수질분야 (Water quality)

인류의 삶의 질의 높아지면서 홍수, 가뭄 등 수량에 중심을 둔 물관리에 더하여 최근에서 수질과 관련한 물관리도 매우 중요한 요소로 인식되고 있다. 수질은 온도, 영양염류 분포와 확산, 유량 등 다양한 기상, 수문요소의 복합적인 결과로 발생하고 수공간 어디에서도 발생할 수 있기 때문에 이들의 지속적인 감시와 예측이 쉽지가 않다. 기존에는 주로 정기적인 직접 채수를 통한 분석을 시행해오고 있지만, 정확도가 높을 수는 있지만 점단위 관측의 한계 때문에 수공간 전체적인 모니터링은 쉽지 않다. 이를 보완하는 방안으로서 위성영상을 이용한 수질 모니터링이 광범위한 지역을 주기적으로 관측 가능하다는 점에서 여러 가지 방법으로 연구가 진행되고 있다. 최근에는 수질 인자 추정에 사용되는 변수 간의 비선형성을 효과적으로 모의하기 위하여 기존의 회귀분석이나 간단한 경험적 관계식 대신 인공지능 기반의 기법들을 활용한 수질 인자 분석 알고리즘 개발 연구가 활발하게 이루어지고 있다 (Keller 외 (2018), Pu 외 (2019), Pahlevan 외 (2020), Saberioon 외 (2020) 등).

국외에서는 1970년대 초 Landsat 1호가 발사된 이후부터 원격탐사를 이용한 수질인자 측정 연구가 수행되어오고 있다. 내륙 담수의 수질인자 현장 관측값과 Landsat, MODIS, AVHRR, Sentinel 등의 위성 영상자료로부터 회귀모형을 개발하는 사례가 다수로 (Zhou 외 (2004), Zhang 외 (2003), Allan 외 (2011), Kravitz 외 (2020) 등), 최근에는 초분광 영상자료를 이용하여 조류의 종별로 광합성 색소의 함유량 차이와 색소별 고유 반사 특성을 이용한 발생 조류의 종류 분류연구도 진행되고 있다. 위성영상을 이용한 수질 모니터링은 광범위한 지역을 주기적으로 관측 가능하다는 점에서 효율적이며 최근 수질 인자 추정에 사용되는 변수 간의 비선형성을 효과적으로 모의하기 위하여 기존의 회귀분석이나 간단한 경험식 대신 인공지능 기법들을 활용한 수질인자분석 알고리즘 개발 연구가 활발하게 이루어지고 있다. (Keller 외 (2018), Pu 외 (2019), Pahlevan 외 (2020), Saberioon 외 (2020) 등)

Saberioon 외 (2020)는 Sentinel-2A 영상을 이용하여 체코 남부의 저수지 지역을 대상으로 담수의 클로로필-a와 총 부유물질 (TSS; Total Suspended Solids)을 추정하였다. 수질인자 추정에는 인공지능 기법의 하나인 Cubist가 사용되었으며, 이는 Rule Quest Research에 의해 만들어진 상용 소프트웨어로, 수정된 회귀나무(modified regression tree)를 기반으로 한다. Cubist는 훈련자료로부터 규칙 기반 다중회귀모델들을 만들어 각 규칙에 따라 다중회귀모델이 적용되어 결과를 도출해내는 기법으로 다른 기법들에 비해 하이퍼 파라미터를 조정하기 쉽고 과적합 될 확률이 낮으며 변수 중요도를 제공하여 해석하기 쉽다는 장점이 있다. Cubist 모델을 통해 추정된 Chl-a와 TSS 농도의 정확도는 각각 R2 0.85와 0.80, RMSE 48.57과 19.55로 설득력 있는 결과를 보였다.

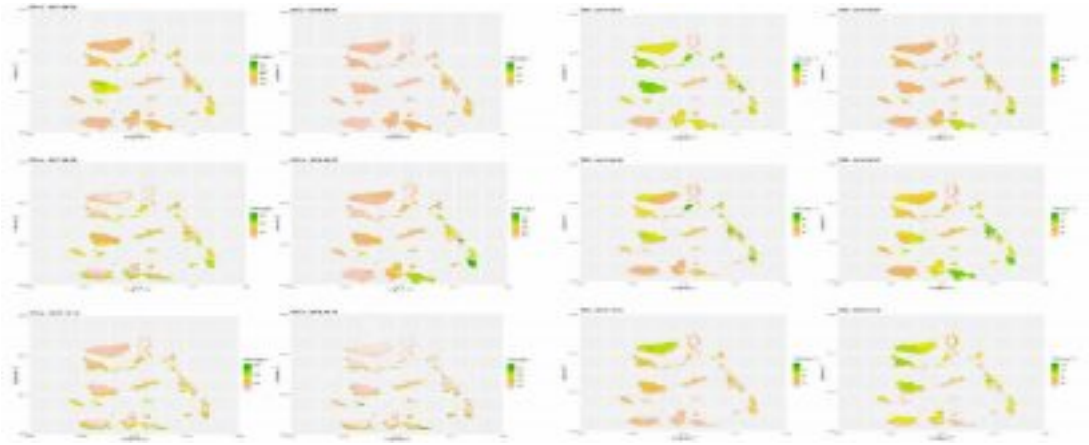


그림 2.19 Sabeioon 외 (2020)에서 제시한 Cubist 모델을 통해 추정한 (좌) Chl-a 와 (우) TSS의 시간에 따른 분포 지도

Pu 외 (2019)는 중국의 Yunnan 지방의 Dali에 위치한 Erhai Lake를 대상으로 Landsat8 위성영상을 활용한 내륙 수질 분류연구를 수행하였다. pH, 용존산소 (DO), 화학적산소요구량 (COD), 생물학적산소요구량 (BOD), 총인 (TP), 총질소 (TN) 등 다양한 파라미터들을 고려하여 수질 등급을 산정하였다. Landsat 8 영상과 수질 등급 사이의 관계를 학습하기 위해서 위 연구에서는 인공지능 기법의 하나인 CNN (Convolution Neural Network)를 사용하였다. SVR, RF, CNN 등 여러 가지 기법들의 비교를 수행하였을 때, CNN이 OA (Overall Accuracy) 92.49 (%)로 가장 높은 정확도를 보였으나, 각 수질 인자에 대한 정량적 분석은 이루어지지 않았다.

Numbers	Parameters (Unit: mg/L)	Water-Qualtiy Levels				
		I	II	III	IV	V
1	pH (No unit)			6–9		
2	DO	≥7.5	≥6	≥5	≥3	≥2
3	Permanganate	≤2	≤4	≤6	≤10	≤15
4	COD	≤15	≤15	≤20	≤30	≤40
5	BOD_5	≤3	≤3	≤4	≤6	≤10
6	NH_3-N	≤0.15	≤0.5	≤1	≤1.5	≤2
7	TP	≤0.02	≤0.1	≤0.2	≤0.3	≤0.4
8	TN	≤0.2	≤0.5	≤1	≤1.5	≤2
9	Cu	≤0.01	≤1	≤1	≤1	≤1
10	Zn	≤0.05	≤1	≤1	≤2	≤2
11	Fluoride	≤1	≤1	≤1	≤1.5	≤1.5
12	Se	≤0.01	≤0.01	≤0.01	≤0.02	≤0.02
13	As	≤0.05	≤0.05	≤0.05	≤0.1	≤0.1
14	Hg	≤0.00005	≤0.00005	≤0.0001	≤0.001	≤0.001
15	Cd	≤0.001	≤0.005	≤0.005	≤0.005	≤0.01
16	Cr	≤0.01	≤0.05	≤0.05	≤0.05	≤0.1
17	Pb	≤0.01	≤0.01	≤0.05	≤0.05	≤0.1
18	Cyanide	≤0.005	≤0.05	≤0.2	≤0.2	≤0.2
19	Volatile phenol	≤0.002	≤0.002	≤0.005	≤0.01	≤0.1
20	Petroleum	≤0.05	≤0.05	≤0.05	≤0.5	≤1
21	Anionic surfactant	≤0.2	≤0.2	≤0.2	≤0.2	≤0.3
22	Sulfide	≤0.05	≤0.1	≤0.2	≤0.5	≤1
23	Fecal coliform	≤200	≤2000	≤10,000	≤20,000	≤40,000

그림 2.20 Pu 외 (2019)에서 사용된 수질 등급 분류 기준

Svab, E 외 (2005)는 헝가리 서부 Balaton Lake를 대상으로 Landsat TM과 ETM+ 영상과 현장 관측자료를 이용하여 부유물질, 클로로필-a, 그리고 용존 유기탄소 농도를 추정하였다. 그 결과 부유물질의 농도가 높은 수체에서는 클로로필-a 농도 추정정확도가 매우 낮았으며, 주성분 분석을 통하여 고유의 단일분광요소를 찾아 선형 분광 혼합 화소 분석을 적용하여 다중회귀분석하였을 때 부유물질의 농도와 상관없이 클로로필-a의 농도 추정이 가능하였다. 현장자료가 충분하지 않기 때문에 미

리 학습된 비슷한 모델을 사용하는 방법인 전이학습 (transfer-learning) 전략이 사용되었으며, 시공간적으로 특성을 잘 반영한 것으로 나타났다.

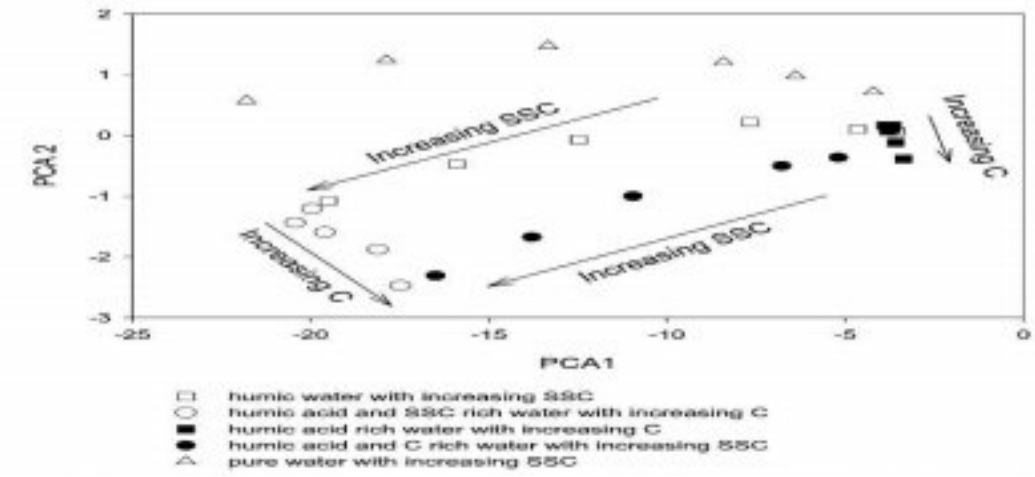


그림 2.21 클로로필-a 농도 추정에 사용된 Landsat 밴드의 주성분 분석 결과의 PCA1과 PCA2 사이의 산점도.

Oyama, Youichi 외 (2009)는 Landsat-TM 5 영상을 이용하여 일본의 가스미가우라 호수에 대해 클로로필-a, 비 식물플랑크톤성 부유물질 (NPSS; Non-Phytoplankton Suspended Solids) 농도를 추정하였다. 선형 분광 혼합 화소 분석을 기반으로 한 SDA (Spectral Decomposition Algorithm) 기법을 개발하여 수체에서의 반사율을 순수한 물과 클로로필-a, NPSS로 분리하여 분석하였다. 위성영상에서의 반사율을 앞에서 언급된 세 성분에 의한 반사율로 나누고 클로로필-a에 의한 반사율을 현장관측 값과 회귀분석하여 농도 회귀 식을 도출하는 과정을 수행함으로써 타 부유물질에 의한 영향을 줄여 정확도가 향상되는 결과를 보였다. 또한, 생물학적 광전달 모델에서 도출된 단일분광요소를 이용하여 클로로필-a 농도 추정 식을 유도하여 현장관측 값 없이도 영상자료로부터 직접 수질 인자를 추정하는 것이 가능하다는 장점이 있다.

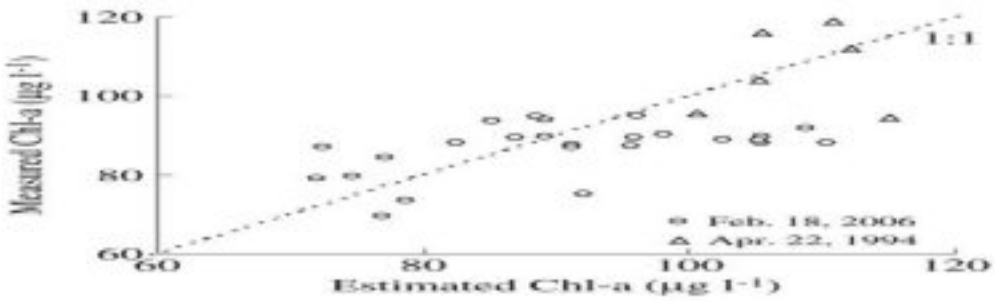


그림 2.22 위성영상과 SDA 기반 모델을 통해 추정된 결과

Moses 외 (2012)는 러시아의 Azov Sea와 Taganrog Bay에서 MERIS (MEdium Resolution Imaging Spectrometer) 영상을 이용하여 클로로필-a의 농도를 추정하였다. 농도 추정은 2009년에 Moses가 제한된 데이터셋을 통하여 개발하였으며 2010년 Gilerson에 의해 수정된 MERIS 기반의 NIR-red 2-밴드, 3-밴드 알고리즘을 사용하였으며 추가적으로 수집된 3년간의 데이터에 적용하였다. 그 결과 2-밴드와 3-밴드 알고리즘은 각각 MAE (mean absolute error) 4.32 mg/m3 과 4.71

mg/m3를 보였으며, 1.09 mg/m3 와 107.82 mg/m3 범위의 농도를 가지는 클로로필-a 데이터에 대하여 5.82 mg/m3의 낮은 RMSE 값을 보이며 유의미한 결과를 보였다. 또한, 시기에 상관없이 준실시간으로 클로로필-a의 정량적인 분석에 활용할 수 있을 것으로 판단된다.

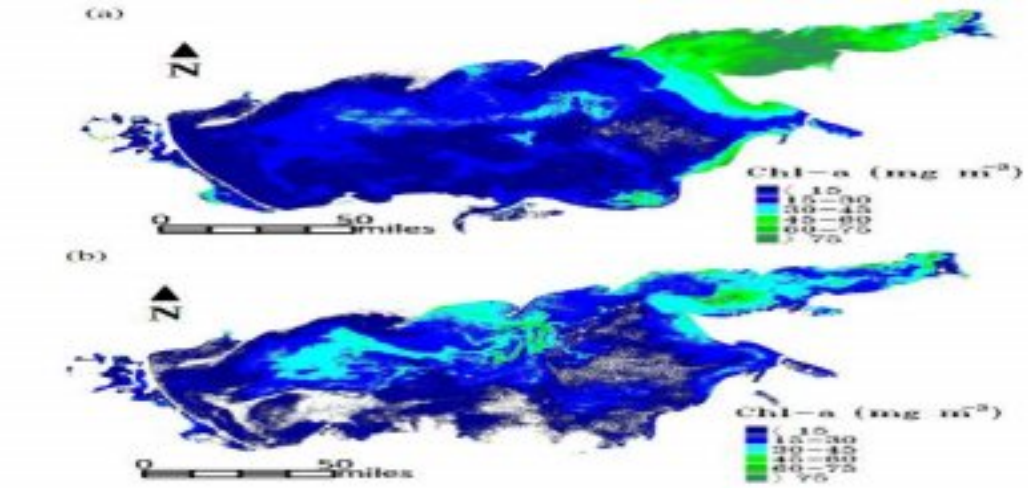


그림 2.23 Moses 외 (2012)에서 제시한 MERIS NIR-red 2-밴드 알고리즘을 통해 도출한 클로로필-a 분포 지도

S. Ekercin 외 (2007)는 IKONOS 고해상도 영상을 이용하여 이스탄불 Goldon Horn 지역의 SSD (Secchi Disc Depth), 클로로필-a, 총 부유물질 (TSS; Total Suspended Sediment) 농도를 추정하였다. B, G, R, NIR 네 가지 멀티 밴드를 사용한 회귀 식을 통한 각 수질인자의 추정을 수행하였다. GPS의 오류에 의한 오차를 최소화하기 위해 5 * 5 픽셀을 smoothing한 자료를 사용하였고, 제시한 모델의 검증 시 유의미한 수준의 RMSE 값이 도출되었으나, 관측자료가 충분하지 못하여 추가적인 샘플을 통한 훈련 및 검증이 필요하다고 판단된다.

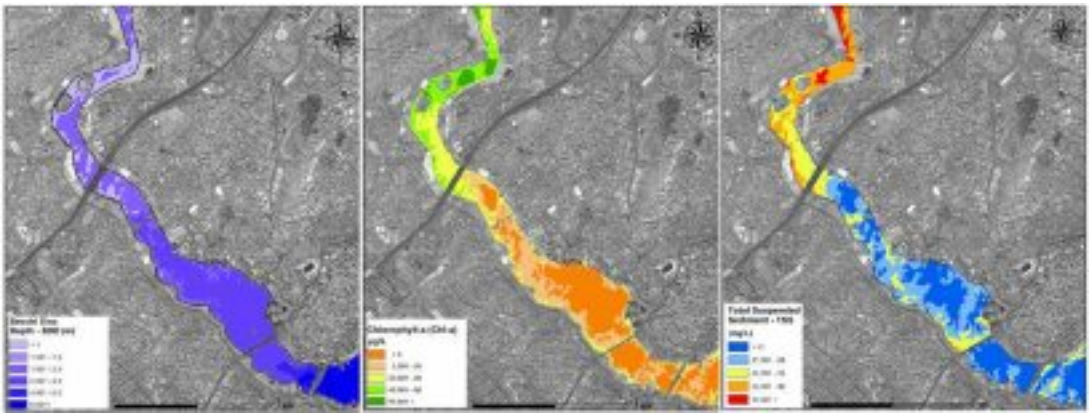


그림 2.24 S.Ekercin 외 (2007)에서 제시한 IKONOS 위성영상을 통해 추정한 수질 결과

Toming 외 (2016)에서는 Sentinel-2 MSI 영상을 이용하여 유럽의 에스토니아에 위치한 페이푸스호와 페르트스야르프호에 대하여 DOC (Dissolved Organic Carbon), 클로로필-a, CDOM (Colored Dissolved Organic Matter), Color (Water Color) 농도를 추정하였다. Sentinel-2 Level-1C 위성영상은 Sen2cor 기법을 이용한 대기 보정을 거쳐 Level-2A 형태로 처리되었다. Sen2cor는 Sentinel Toolbox에서 제공되고 있어 널리 사용되는 대기 보정 기법이지만, 수생 환경을 위해 개발된 알고리

즘이 아닌 육상에 초점을 맞춘 모델이기 때문에 물 환경에서의 대기 보정 성능을 검증할 필요가 있다. 따라서 현장에서 측정한 반사도 값을 Sentinel-2 밴드 대역에 맞추어 변환하여 대기보정 절차에 대한 성능 평가를 진행하였으며, 이후 Sentinel-2 MSI 자료와 수질 인자들을 통해 계산된 밴드비 알고리즘은 클로로필-a (R^2 = 0.83), CDOM (R^2 = 0.72), DOC (R^2 = 0.92), 그리고 water color (R^2 = 0.52)의 높은 상관관계를 보였다.

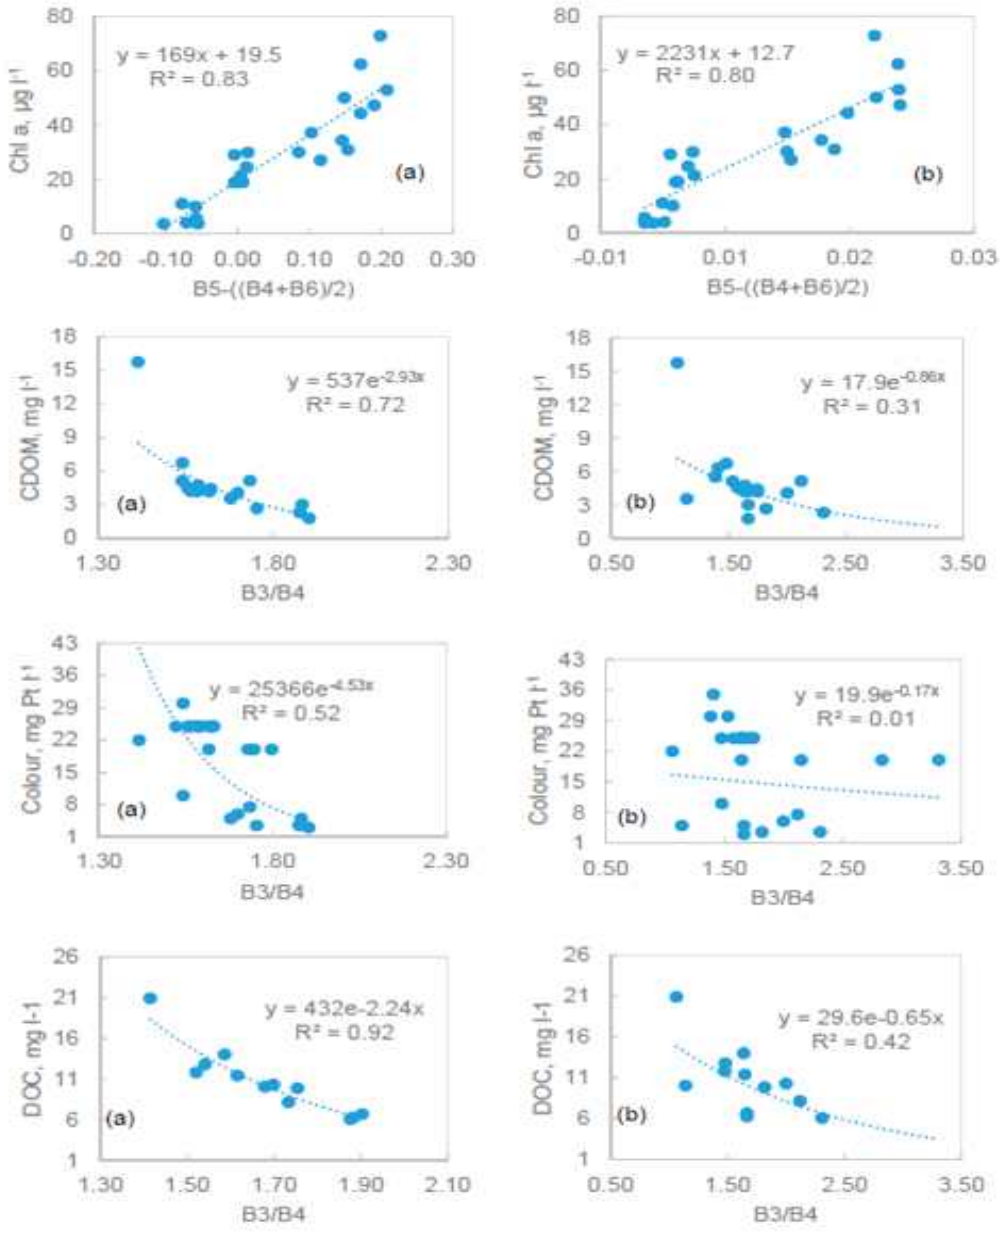


그림 2.25 Toming 외 (2016)에서 제시한 밴드비 기반 모델결과

Wei 외 (2019)에서는 중국의 저수지 및 하천에서 부유물질 (혼탁도)을 산출하는 경험식과 준경험식 모델을 구축하였다. 드론에 초분광센서를 사용하고 기하 보정 및 방사 보정을 수행하여 정밀한 반사도를 산출하도록 하였다. 현장 관측을 통해 측정한 부유물질의 반사도와 드론의 초분광 센서로 측정한 반사도를 통해 선형 회귀를 통한 보정 과정을 거친다. 현장자료로부터 보정된 드론 기반의 반사도를 서포트 벡터 머신 (SVM; Support Vector Machine), 최소 제곱 서포트 벡터 머신 (LSSVM; Least-Square-SVM), 랜덤 포레스트 (RF), 그리고 본 연구에서 제안하는 최적화 알고리즘인 Particle Swarm Optimization Algorithm (PSO)을 활용하여 PSO-LSSVM 모델을 구축하여 부유물질 (혼탁도) 농도를 산출하였다. PSO 알고리즘은 입자 속도 등의 파라미터를 넣고 모델링을 하여 최소 오차에 수렴하도록 학습하는 진화 알고리즘의 형태로, 최소 오차를 가지도록 학습하기 위해 활용된 모델은 LSSVM을 적용하였다. 본 연구에서 제시한 알고리즘과 이를 통해 추정된 부유물질 농도 결과는 아래 그림과 같은 분포를 보였다.

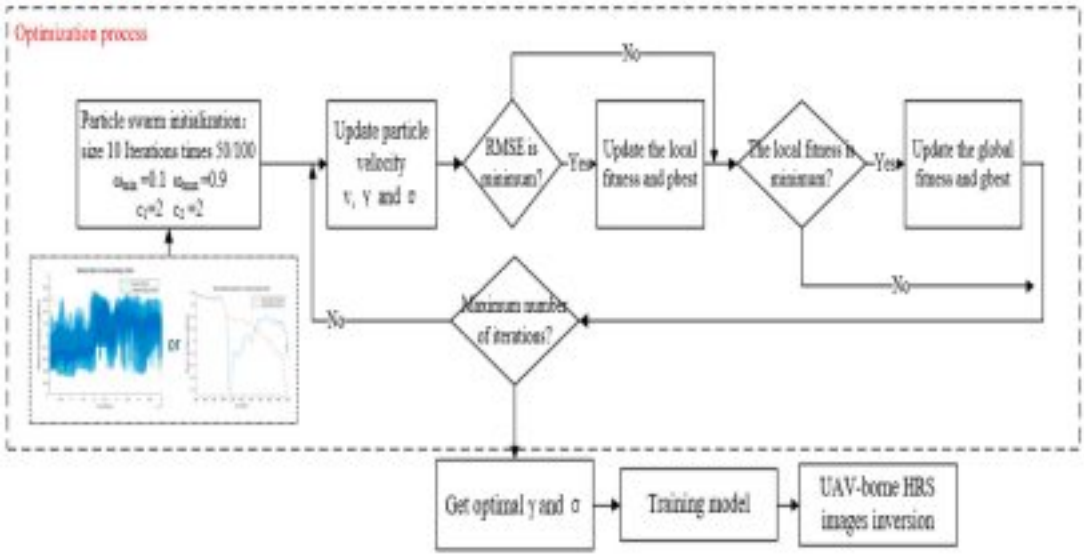


그림 2.26 Wei 외 (2019)에서 고안된 모델인 PSO-LSSVM 모델

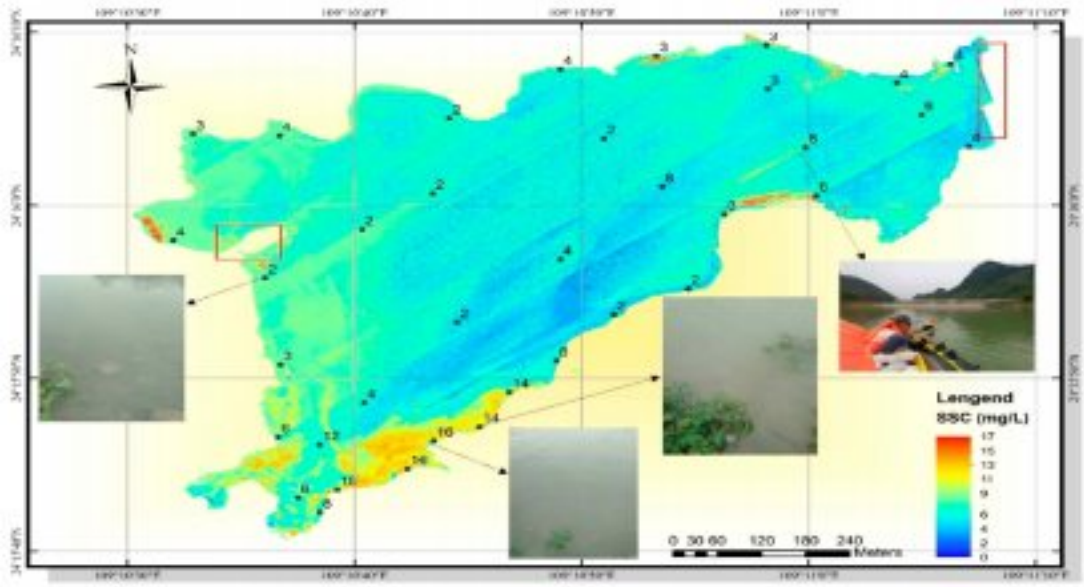


그림 2.27 Wei 외 (2019)에서 제안한 PSO-LSSVM 모델 결과의 공간적 분포

Kudela 외 (2015)에서는 내수면에서 클로로필-a와 유해남조류의 일종인 마이크로시스티스 (Microcystis) 속 (genus)과 아파니조메논 (Aphanizomenon) 속에 대하여 현장에서의 반사도를 측정하였다. 본 연구에서 활용한 원격탐사 자료들은 오픈소스로 제공되는 자료 혹은 과거 연구 자료 등을 활용하였다. 항공기 기반의 MODIS/ASTER Airborne Simulator (MASTER), Hyperspectral Imager for the Coastal Ocean (HICO), Sentinel-3 OLCI (Ocean and Land Color Imager) 등의 초분광 센서 및 광학 센서 자료들을 활용하였다. 원격탐사 자료를 전처리한 후 유해 남조류, 즉 마이크로시스티스 속과 아파니조메논 속을 구분하기 위한 분광 특성을 분리하였다. 본 연구에서는 수질 분석을 위한 세 가지 지표 – Cyanobacteria Index (CI), Scattering Line Height (SLH), 그리고 Aphanizomenon-Microcystis Index (AMI) – 를 개발하였다. 고안된 세 가지 인덱스를 원격 탐사 자료에 적용하여 각 수질 인자별 관련성에 대해 분석하였다. 아래 그림은 본 연구에서 고안된 세 가지 인덱스와 마이크로시스티스 속에 적용된 경우의 결과를 나타낸다.

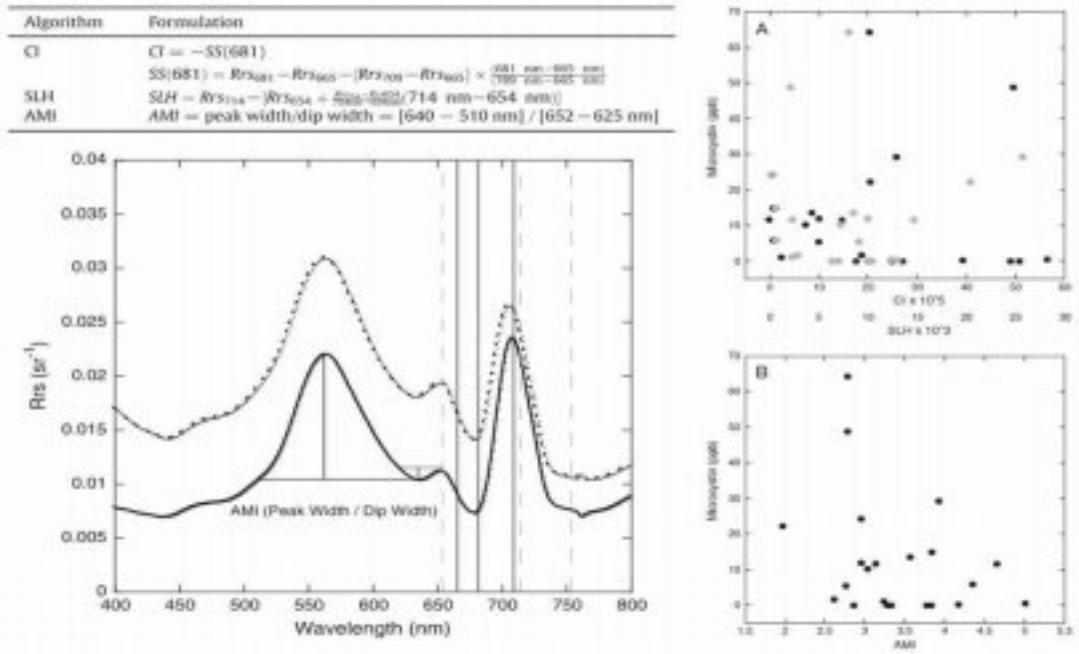


그림 2.28 Kudela 외 (2015)에서 제시한 세 가지 지표와 파장에 따른 위성 원격 반사도 값의 분포 (좌). 세 가지 인덱스와 추정된 마이크로시스티스 속 농도와의 상관관계 (우).

Yim 외 (2019)에서는 비지도 학습 (Unsupervised learning)인 Autoencoder와 심층 신경망 학습 (Deep Neural Network, DNN)을 적용하여 남조류 농도를 추정하는 알고리즘을 개발하였다. 본 연구에서 제시한 알고리즘은 단순 DNN 모델과 기존에 널리 사용되어 온 밴드비 알고리즘 대비 탁월한 성능을 보였다. 본 연구에서는 Stacked Autoencoder Deep Neural Network (SAE-DNN) 기법이 제시되었는데, 다층의 autoencoder 형태의 구조와 마지막 신경망 층을 결합하여 자동적으로 다수의 밴드 중 남조류 산출에 중요한 밴드를 추출해주고 농도를 동시에 산출할 수 있는 모델을 구축하였다. 물환경정보시스템의 남조류 세포수 현장 자료를 활용하여 초분광센서의 파장대로 모델을 학습시켜 백제 저수지의 농도를 추정하는 결과를 도출하였다. 고안된 알고리즘을 기존의 DNN 알고리즘 및 Rrs(709)/Rrs(620)와 Rrs(700)/Rrs(600) 밴드비 알고리즘과 비교한 결과는 아래와 같으며, 본 연구

에서 제시하고 있는 모델이 현장자료와의 검증 시 다른 비교 모델에 비해 상대적으로 우수한 성능을 보이는 것을 확인하였다.

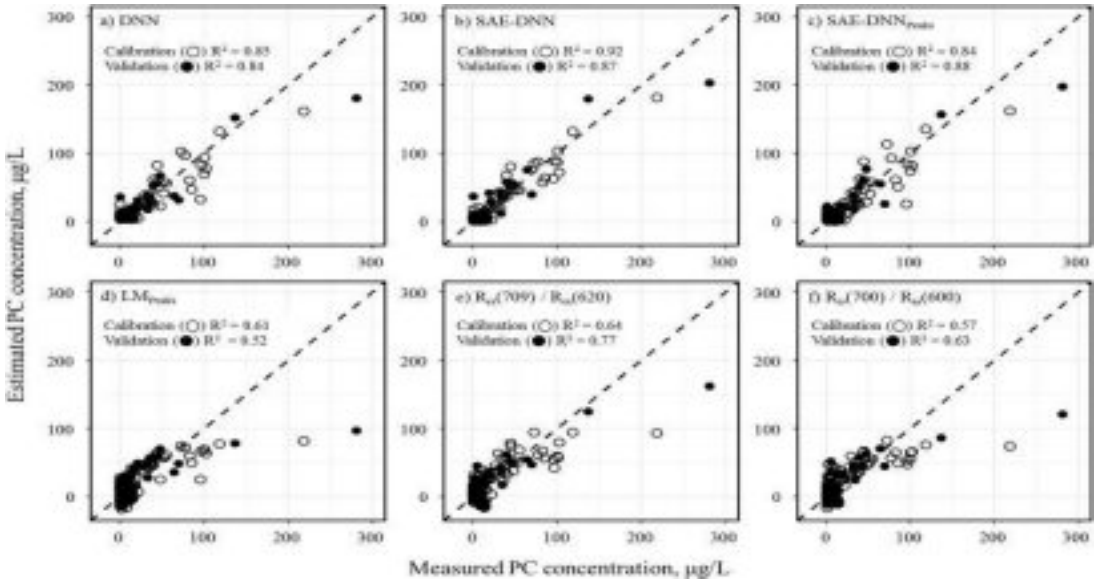


그림 2.29 Yim 외 (2019)에서 사용한 현장 관측 피코시아닌 농도와 본 연구에서 고안한 SAE-DNN 모델 및 비교 모델을 통해 추정된 피코시아닌 농도 간의 산점도

He 외 (2013)에서는 자외선-대기보정 (UV-AC) 알고리즘이 적용된 GOCI 영상을 이용하여 중국의 항저우 만에 대하여 부유입자물질 (SPM)의 농도를 추정하고 일주 변화를 분석하였다. 항저우 만과 같은 탁한 해역에서는 높은 부유물질 농도로 인해 가시광선과 근적외선 영역에서의 해수 수출 광량 (Lw)이 높게 나타나는 반면, 높은 유기물 (detritus, CDOM) 농도로 인해 자외선 영역에서의 해수 수출 광량이 낮게 나타날 수 있다. 이 경우 적외선 영역보다 자외선 영역의 밴드가 대기 보정에 사용되는 것이 더 유리하며, 본 연구에서는 자외선 대신 가장 짧은 가시광선 영역의 412 nm의 밴드가 사용되었다. 항저우 만에서 부유물질 농도의 지수 형태는 745 nm와 490 nm 밴드비와 높은 상관관계를 보였다 (R = 0.96). 현장 측정된 선박 부유물질의 짧은 시간 범위를 극복하기 위해, 더 넓은 시간 범위에서 수집된 부이 (buoy) 기반 탁도와의 선형 회귀를 통해 부이 부유물질 자료를 생성하였다. 이후 밴드비 알고리즘을 통해 추정된 부유물질 농도와 현장 측정 부이 부유물질 농도를 비교하였으며, 대수 눈금으로 10.9 %의 평균 상대 오차를 보였다. 부유물질의 일주 변화에 가장 영향을 많이 미치는 요소는 조류로 나타났으며, 태풍과 같은 특별한 이벤트가 부유물질의 농도에 영향을 주기도 하였으나 지속 시간이 길지 않았고 대부분 하루 사이에 회복되는 양상을 보였다.

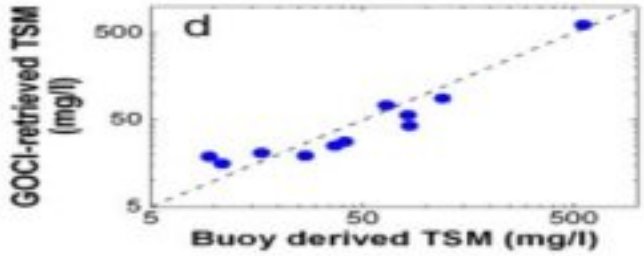


그림 2.30 He 외 (2013)에서 제시한 UV-AC를 적용하여 추정된 부유물질 농도와 부이 기반 부유물질 간의 산점도

Shahzad 외 (2018)에서는 Landsat 7 ETM+ 영상을 사용하여 파키스탄의 인더스 강 하구에 위치한 삼각주 지역에 대하여 부유물질 (혼탁도) 농도를 추정하였다. 위성 영상은 dark object subtraction (DOS) 기법을 사용하여 대기 보정 되었으며, DOS는 각 밴드에서 가장 어두운 픽셀값을 빼서 추가 산란에 의한 헤이즈를 제거하기 위한 대기 보정 기법이다. Landsat 7 ETM+ 밴드 1, 2, 3, 5의 반사도 값과 함께 Normalized Difference Suspended Sediment Index (NDSSI)가 회귀모델의 입력변수로 사용되었다. NDSSI는 탁도가 높은 물에서 적외선 영역의 반사도가 가시광선 영역의 반사도보다 높은 것을 이용해 부유물질의 농도를 나타내는 지표이다. 회귀 식으로 추정된 부유물질 농도는 현장 관측된 부유물질 농도와 높은 상관성을 보였다 (R2 = 0.88, RMSE = 67.24 mg/L, MAE = 54.75 mg/L).

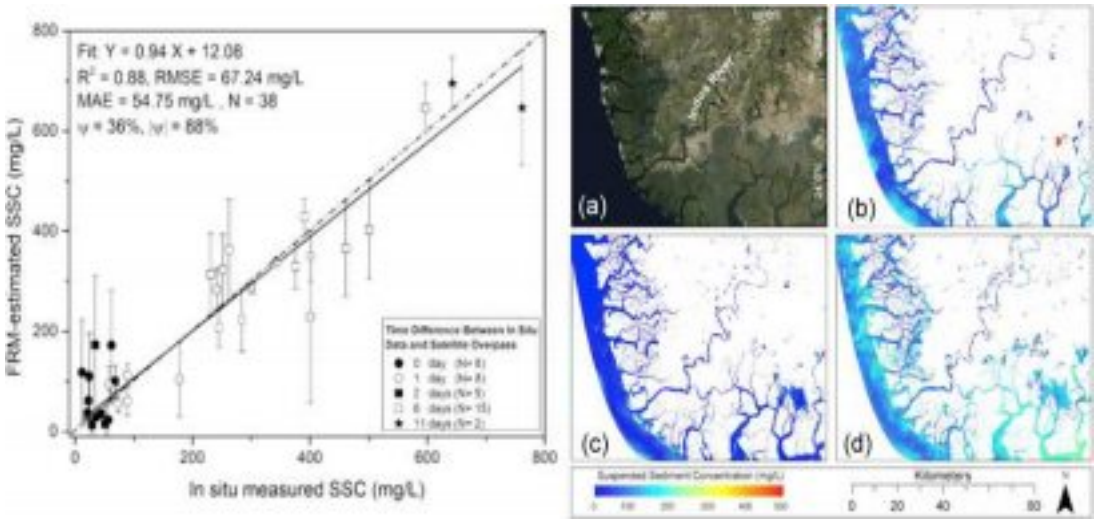


그림 2.31 Shahzad 외 (2018)에서 제시한 밴드별 반사도와 NDSSI 회귀 모델로 추정한 부유물질 농도와 현장관측 부유물질 농도 사이의 산점도 (좌)와 분포 지도 (우)

Nguyen 외 (2020)에서는 Sentinel-2A MSI 영상을 사용하여 베트남 남부에 위치한 메콩강 삼각주 지역에 대하여 부유물질 (혼탁도) 농도를 추정하였다. 본 연구에서는 Normalized Suspended Material Index (NSMI)가 회귀모델의 입력변수로 사용되었다. NSMI는 가시광선 영역의 반사도 값을 이용해 물의 탁도와 부유물질의 농도를 나타내는 지표로, Sentinel-2A MSI 영상의 NSMI 값은 현장 부유물질 농도와 높은 상관관계를 보였다 (두 날짜에 관해 각각 R2 = 0.92와 0.83). 이후 회귀모델로 추정된 부유물질 농도는 현장관측 부유물질 농도와 비교했을 때 매우 높은 추정 성능을 보였다 (R2 = 0.96).

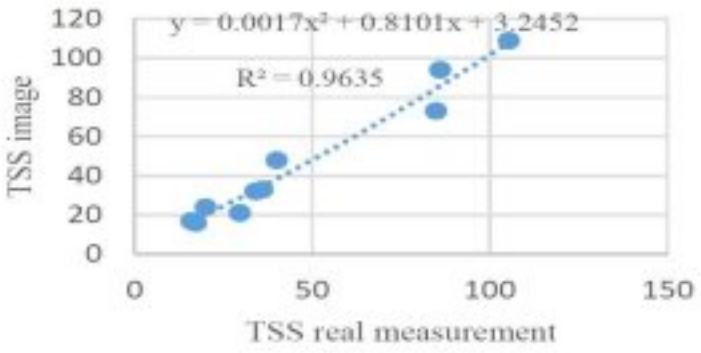


그림 2.32 Nguyen 외 (2020)에서 제시한 NSMI 회귀모델로 추정한 부유물질 농도와 현장관측 부유물질 농도 사이의 산점도

Beck 외 (2017)에서는 미국 북동부의 오하이오주 남서쪽에 위치한 저수지에 대하여 시아노박테리아 (cyanobacteria) 농도를 추정하기 위하여 피코시아닌 (phycocyanin) 색소의 반사도 알고리즘을 활용하였다. 본 연구에서는 초분광 항공 영상인 Compact Airborne Spectrographic Imager (CASI)와 다양한 위성 영상 (e.g., synthetic WorldView-2, Sentinel-2, Landsat-8, MODIS, 그리고 Sentinel-3/MERIS/OLCI)을 활용하였다. 초분광 항공 영상을 통해 밴드비를 활용한 알고리즘을 개발하였으며, 이를 다양한 위성영상에 적용하여 검증되었으며, 그 결과 MODIS를 제외한 모든 센서가 피코시아닌을 추정하는데 유용한 것으로 나타났다.

Shin 외 (2017)에서는 한국의 한강 하구를 대상으로 남세균 대발생 (cyanobacterial bloom)을 예측하기 위한 의사결정 나무 (Decision Tree) 기반의 알고리즘을 제시하였다. 의사결정 나무는 결측값이나 이상치 문제를 극복할 수 있는 기계학습 기법 중 하나로, 간단한 알고리즘임에도 불구하고 복잡한 자연 현상을 정확하게 예측할 수 있다는 장점을 가진 기법이다. 본 연구에서는 남세균 대발생의 지표인 클로로필-a 농도와 시아노박테리아 세포 수를 기준치 초과 혹은 비 초과 등급으로 분류하여 변수로 사용하였다. 기준치 초과 클래스의 경우 비 초과 클래스에 비해 확연하게 적은 비율을 가지기 때문에 오버샘플링 기법의 하나인 SMOTE (synthetic minority oversampling technique) 기법을 적용하여 클래스 간의 불균형을 완화하였다. 구축된 모델의 변수 중요도 분석 결과 수온, 조류 및 월 (month)이 남조류 농도 클래스 예측에 필수적인 요소인 것으로 나타났다.

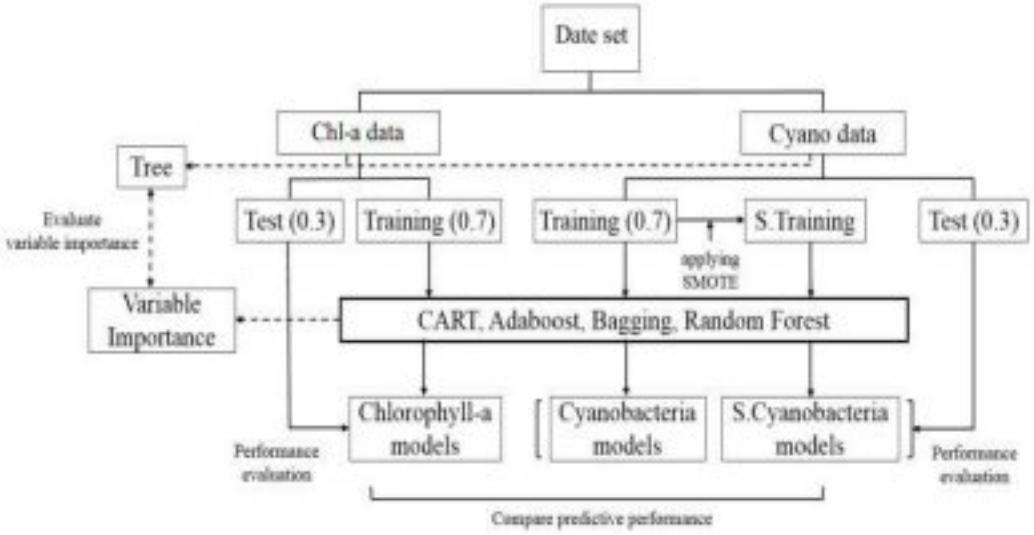


그림 2.33 Shin 외 (2017)에서 제시한 시아노박테리아 예측 모델 흐름도

Zhang 외 (2018)에서는 합성 개구 레이더 (Synthetic Aperture Radar, SAR)의 수질 분석에의 적용 가능성에 대한 연구를 수행하였다. 초분광 센서를 통해 클로로필-a 현장 농도의 반사도를 측정하고, ENVISAT (ENVIronmental SATellite) ASAR (Advanced SAR) 데이터를 융합한 알고리즘을 개발하였다. 준 경험식 모델 (2 밴드 혹은 3 밴드 모델)과 경험식 모델인 다중선형회귀 (Multiple Linear Regression, MLR)와 다층 퍼셉트론 (Multi Perceptron Network, MPN)을 활용하여 클로로필-a 농도를 추정하였다. 클로로필-a 농도가 26 ug/L 이상인 경우에는 공간적인 변동으로 인한 과소 모의를 하는 경향이 발견되었다. MLR 모델이 MPN 모델보다 상대적으로 안정적인 결과를 보이는데, MPN 모델은 과소 및 과대 모의하는 지역이 발견되었다. SAR를 융합한 모델의 결과는 준경험식 모델보다 약간의 성능 상승은 보이지만 큰 차이를 보이는 입력변수로 작용하지는 않았다. 이때 수직-수직 편

광이 수평-수평 편광 자료보다 클로로필-a 농도 산출에 연관성이 있는 것으로 나타났지만, 전체적인 편광자료와 클로로필-a 농도 간의 상호 연관성은 뚜렷한 관계를 나타내지 못하였다. 결론적으로, 본 연구에서 제시된 모델 결과에 따르면 SAR를 제외한 광학 밴드를 통한 모델의 결과와 유사한 수준의 결과를 보였으며, 오히려 성능이 저하되는 때도 있음을 시사한다.

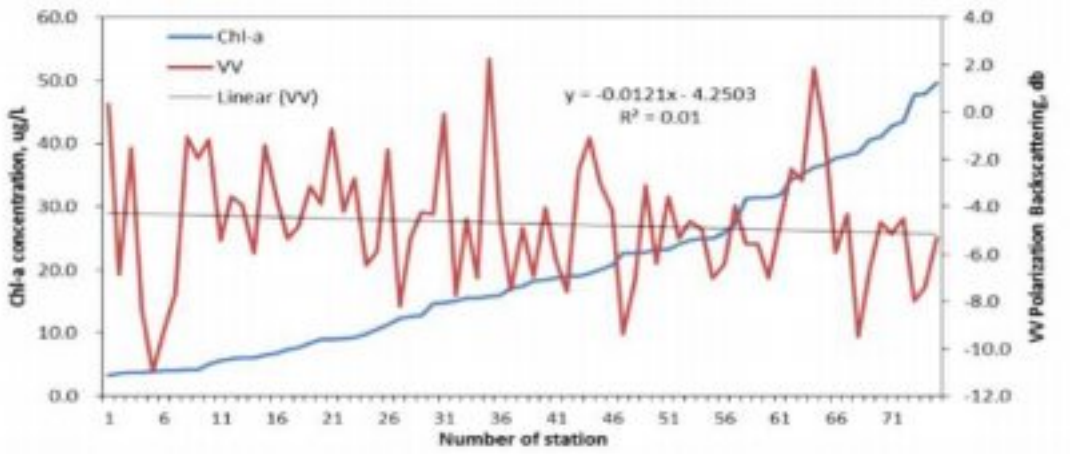


그림 2.34 수직-수직 편광 자료와 클로로필-a 농도 사이의 추세

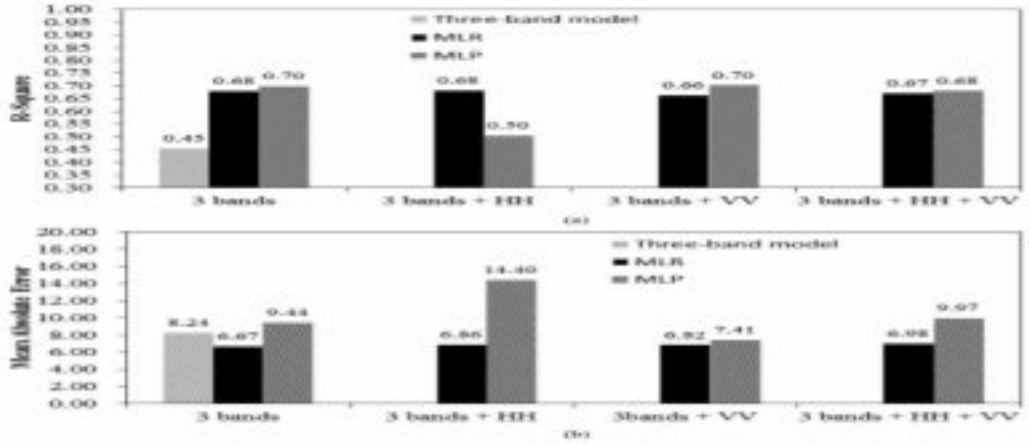


그림 2.35 비교 모델인 3 밴드 모델과 SAR의 수평 및 수직 편광자료를 추가한 모델 간의 비교 결과

Arabi 외 (2020)에서는 효과적인 수질 모니터링을 위하여 다양한 현장자료와 위성 센서들을 융합한 연구를 수행하였다. 2003년부터 2018년까지 15년 동안의 클로로필-a, 부유 퇴적물 (suspended particulate matter; SPM), 그리고 유색 용존 유기물 (colored dissolved organic matter; CDOM) 초분광 측정 현장자료와 해당 기간의 세 가지 위성영상 (ENVISAT MERIS, Sentinel-2 MSI, Sentinel-3 OLCI) 자료를 활용하여 유럽의 Wadden Sea에 대한 수질 인자 모니터링 연구를 수행하였다. 복사전달 (radiative transfer; RT) 모델을 활용하였으며, 클로로필-a의 경우 $R^2 \geq 0.70$, RMSE $\leq$7.5 [mg m^{-3}], SPM의 경우 $R^2 \geq 0.72$, RMSE $\leq$5.5 [g m^{-3}], 그리고 CDOM의 경우 $R^2 \geq 0.67$, RMSE $\leq$ 1.7 [m^{-1}]의 정확도를 보였다.

Dörnhöfer 외 (2018)에서는 단일 위성 센서를 활용한 수질 모니터링의 시공간 해상도 측면의 한계를 극복하기 위하여 다종위성을 활용한 식물플랑크톤 모니터링 연구를 수행하였다. 독일의 Kummerow 호수를 대상으로 연구가 수행되었으며, 호수 표면의 클로로필-a 농도는 다섯 가지 위성 센서 (MODIS-Terra, MODIS-Aqua, Landsat 8, Landsat 7, 그리고 Sentinel-2A) 영상으로부터 도출되었다. 본 연구에서는 다종 센서 접근법의 이점을 논하기 위하여 센서 독립적 모델인 MIP (Modular Inversion and Processing System)을 적용하였고, 센서별로 불확실성에 대한 분석을 수행하였다. 다종 센서를 활용함으로써 시공간적 해상도의 한계를 상호 보완하며 이론적으로 일별 (daily) 커버리지 (coverage)를 제공할 수 있게 되었다.

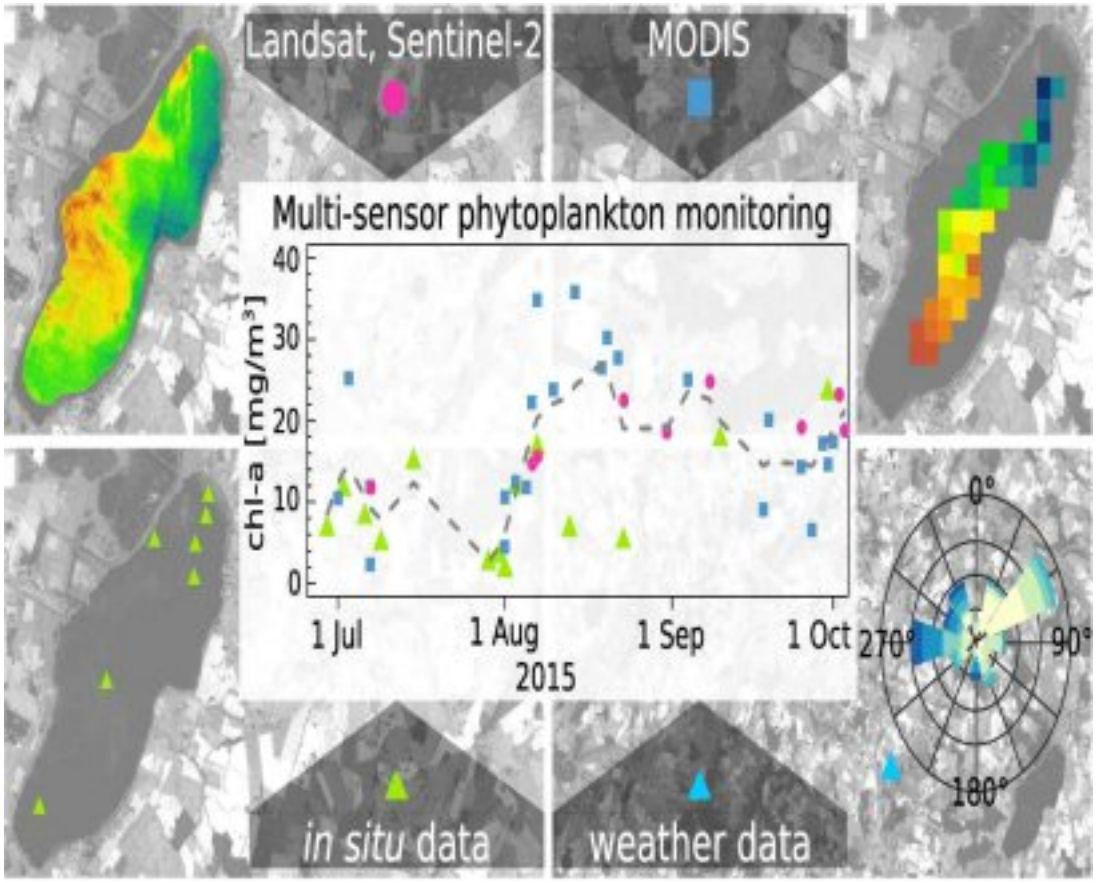


그림 2.36 Dörnhöfer 외 (2018)에서 제시한 다종 센서를 활용한 클로로필-a 모니터링 결과

국내에서는 1990년대 중반부터 Landsat TM, RapidEye, Sentinel 등의 위성영상을 활용하여 분광특성이 뚜렷한 클로로필-a와 부유물질의 농도 분포를 파악하는 연구가 수행되어오고 있다. 국내 연구의 경우, 조류세포수 혹은 피코시아닌에 대하여 따로 위성 영상을 활용한 추정 연구는 이루어지지 않았다.

서영상 외 (2006)는 SeaWiFS 위성 영상을 이용하여 동해 연근해역에서 일시적으로 나타나는 고농도 클로로필-a 이상분포를 정량화하는 연구를 수행하였다. 클로로필-a 추정에는 미국 NASA에서 사용을 권고하는 OC2 (ocean color 2) 알고리즘을 사용하였으며, OC2 알고리즘을 통하여 추정된 값은 현장관측 값보다 전반적으로 큰 값으로 과대추정하는 양상을 보였으나 농도의 분포 양상은 위성 추정치와 비슷하게 나타났다. 영상 분석을 통해 동해남부 연안에서의 클로로필-a 값이 주변보다 상대

적으로 높게 나타났으며, 해류의 영향에 의한 이상 분포인 것을 확인하였다.

최은영 등 (2011)은 고해상도 위성영상인 RapidEye 영상을 이용하여 수체의 크기와 폭이 현저히 작도 탁도가 있는 하천 중 하나인 낙동강 지역에 대해 6.5 m 해상도로 클로로필-a 농도를 추정하는 연구를 수행하였다. 기존의 위성영상을 이용한 해수나 연안수의 클로로필 농도 분석을 통해 가능성이 확인되었던 밴드비를 이용한 간단한 추정 모델에 Red와 Red-edge (RE), NIR 영역을 활용하는 Red-RE-NIR Three-band 모델을 적용하여 가장 유의한 수준의 클로로필-a 농도를 추정하였다. 그 결과 0.73의 결정계수 값과 22.4의 RMSE (Root Mean Square Error), 1.29의 RPD 값을 나타내어 Red-edge 밴드의 적용 가능성을 나타내었다.

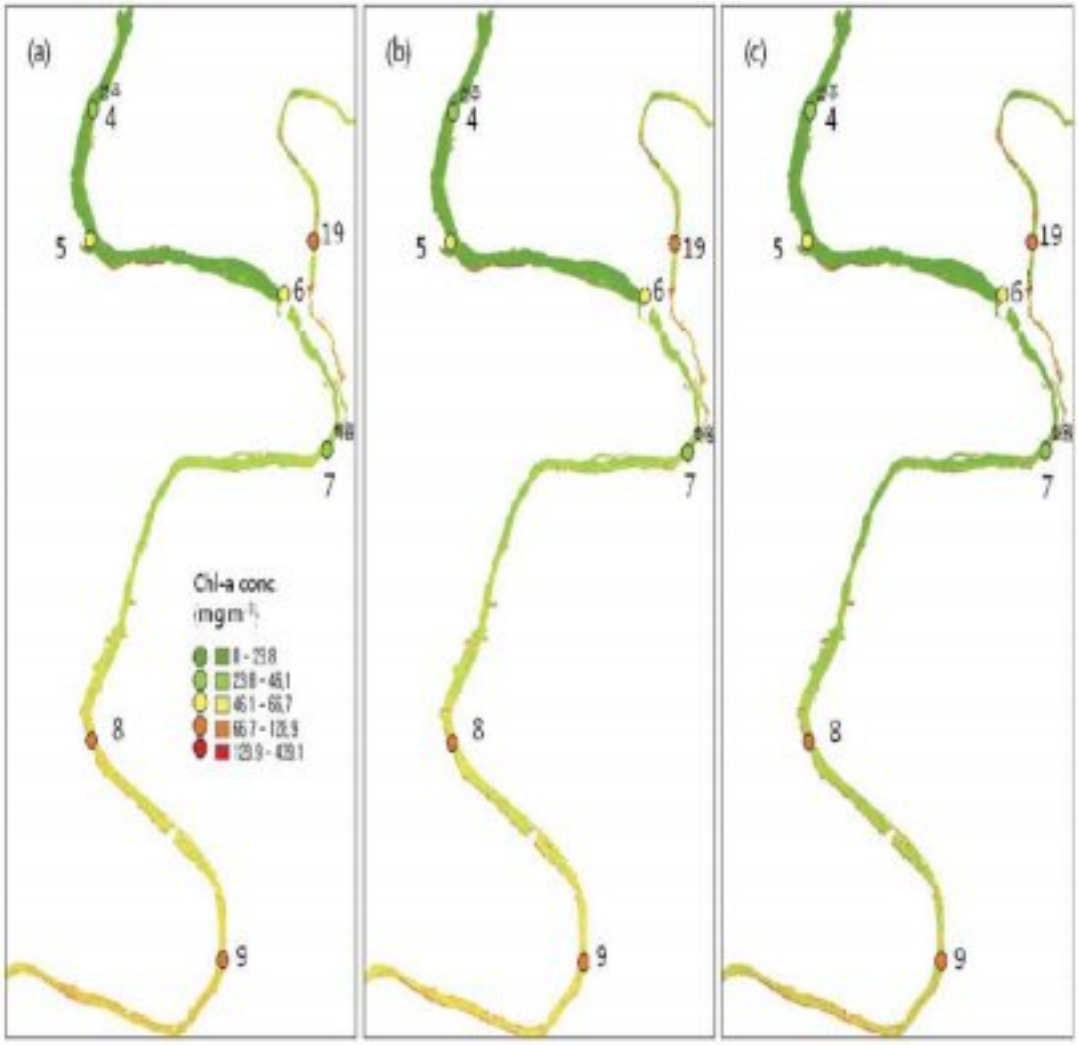


그림 2.37 RapidEye 위성영상을 활용하여 추정한 클로로필-a의 농도 분포

Lee 외 (2020)는 대한민국 남해안 지역을 대상으로 Landsat-8 OLI 영상과 클로로필-a, 부유입자물질 (SPM)을 활용하여 적조 발생을 탐지하는 연구를 수행하였다. 위성영상의 육상 및 구름 마스킹을 거친 후 level -2 반사도 값을 이용하여 밴드 값과 밴드 비(ratio), 그리고 두 밴드 간의 반사도 차이 등을 입력변수로 하여 인공지능 기법인 MFNN (Multilayer Feedforward Neural Network)를 적용하여 적조 발생 가능성을 픽셀 별로 0에서 1 사이 범위의 값으로 나타내었다. 1에 가까울수록 적조

발생 가능성이 큰 것으로 해석할 수 있으며, 적조 발생의 threshold를 0.5로 선정하여 정확도를 평가하였을 때, POD (Probability of detection) 0.89로 유의미한 결과를 보였다. 이후 클로로필-a와 SPM의 현장관측 값과 모델 결과를 비교함을 통해 검증을 수행하였다. 해양의 적용 결과이기도 하며 직접 수질 인자의 농도를 추정하는 알고리즘은 아니지만, 수질 분석에 고해상도 위성영상의 활용 가능성을 보여주었다.

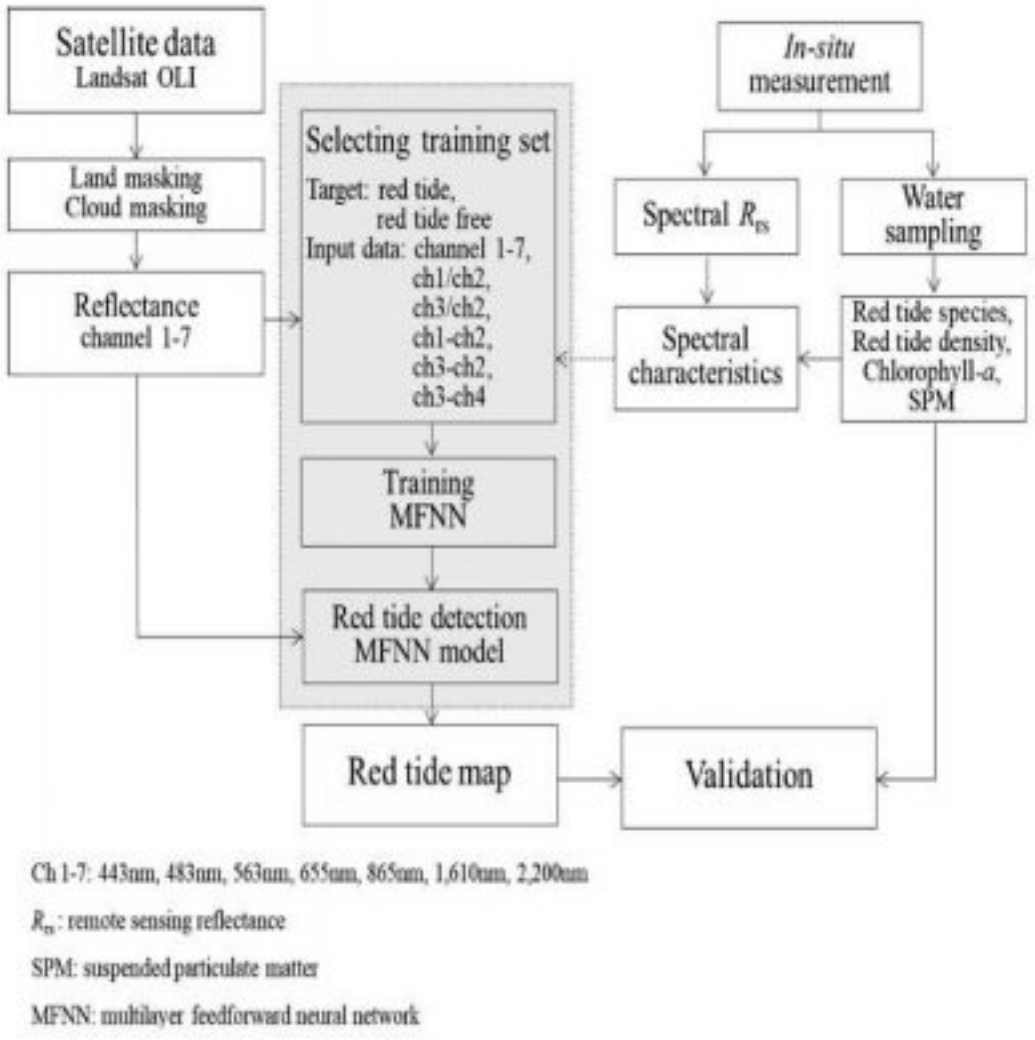


그림 2.38 Lee 외 (2020)에서 제시한 적조 발생 탐지 알고리즘의 연구흐름도

박성욱 외 (2018)는 4대강(한강, 낙동강, 금강, 영산강) 지역의 보 부근처럼 수질이 취약한 지역(한강의 여주보와 이포보, 낙동강의 달성보와 합천창녕보, 창녕함안보, 금강의 공주보와 세종보, 영산강의 죽산보와 승촌보)을 대상으로 Sentinel-2와 RapidEye 위성영상을 이용하여 담수역 클로로필-a 농도를 추정하였다. 우리나라 4대강에 관한 사례 분석을 통하여 현존 방법론들의 성능평가를 수행하였으며, 현존 모델 중 Red Edge 밴드를 활용하는 M09, M12 모델이 매우 양호한 추정치를 산출하는 것을 보였으며, 특히 RapidEye의 M09, M12 모델은 실측치와의 상관계수가 0.934, 0.936으로서 매우

양호한 추정치를 산출하였다. 영상보정에는 Erdas Imagine 2014의 ATCOR (Atmospheric & Topographic Correction-2) 모듈을 사용하였다. 본 연구에서 제안한 알고리즘을 통해 추정된 클로로필-a 농도와 현장관측 값과의 비교 결과는 아래 그림과 같은 분포를 보인다.

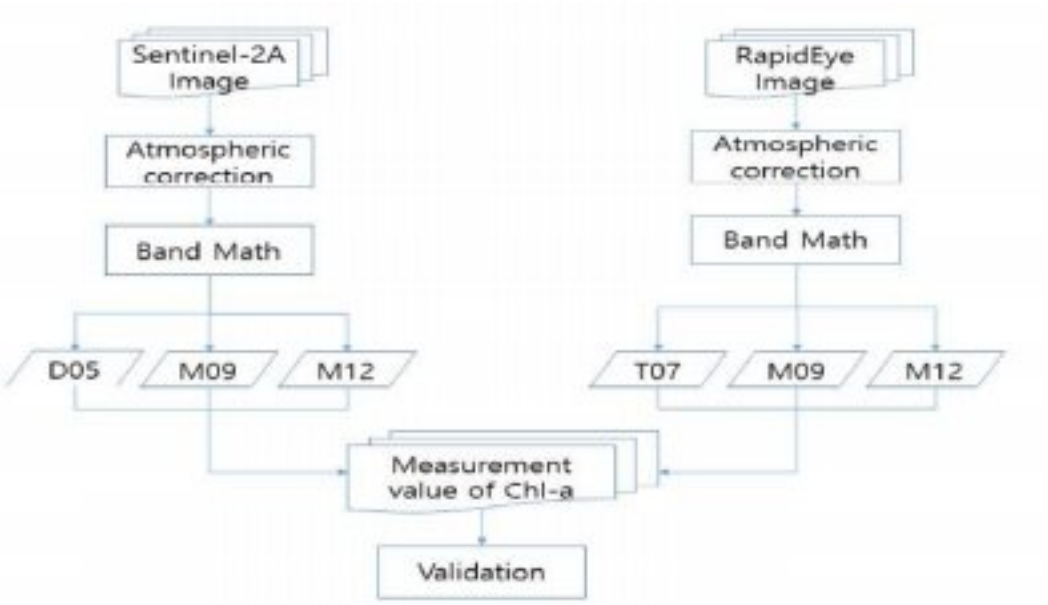


그림 2.39 박성욱 외 (2018) Sentinel-2와 RapidEye 영상의 자료처리 과정

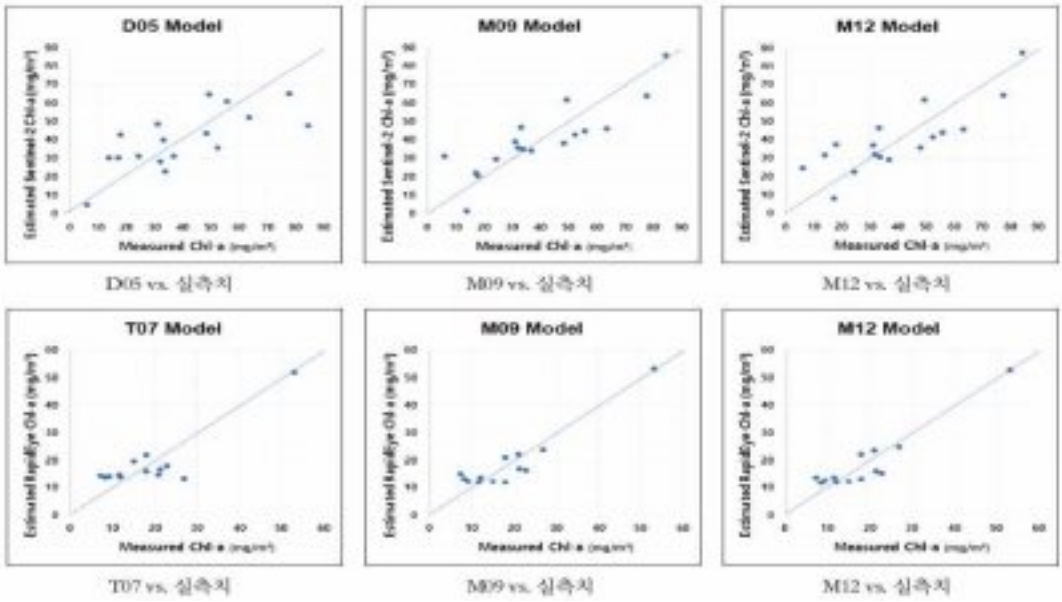


그림 2.40 박성욱 외 (2018)에서 제안한 알고리즘을 통해 추정된 Chl-a

위성영상을 활용한 하천의 수질 분석에 관한 연구는 국내·외에서 활발하게 수행되고 있으며, 연구목적이 아닌 현업 적용을 목적으로 한 국내 유사 과제들도 수행되었다.

미래창조과학부 한국연구재단 우주핵심기술개발사업의 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제에서는 내륙 담수의 실측 수질 자료와 위성영상을 이용하여 클로로필 추정

모델을 생성하고 이를 기반으로 담수 수역에 대한 클로로필-a 농도 분포도 생성 및 서비스 제공을 수행하였다. 이는 KOMPSAT 위성을 사용하였으며, 위성자료와 위성의 통과시간에 맞춰 지상에서 측정한 수질자료를 이용하여 클로로필-a 추정 모형을 산정하고 영상으로부터 클로로필-a 분포도를 자동으로 생성할 수 있는 알고리즘을 개발하였다. 이와 더불어 과거 연구사례를 참고하여 클로로필-a 분광특성에 적합한 파장 대역을 분석하였으며 이를 통해 회귀모형 개발 및 클로로필-a 분포도 작성사례를 고찰하였다. 해당 과제는 여름철에 남조류 수화현상이 자주 발생하는 대청호 지역 (금강 유역)을 대상으로 클로로필-a 추정 모델을 생성하였으며, 일반적으로 저수지 지역에서의 조류 발생원인은 영양염의 과도한 유입과 체류 시간 장기화, 높은 표층 수온의 성층화와 생리적 특성 등으로 알려져 있다. 호수나 저수지 등의 정체 수역에서의 수질오염은 생활용수와 공업용수 공급 등 수자원과의 직접적인 영향이 가지기 때문에 이와 관련된 수질 인자의 농도와 분포를 파악하는 것은 필수적이다. 위성영상으로부터 클로로필-a 농도를 산정할 수 있는 회귀모형을 개발하기 위해서는 아래 그림과 같은 절차를 거쳤는데, 이 때 화소값(DN)을 반사도로 변환하여 사용한 이유는 인공위성에서 촬영한 날짜가 다를 경우 각 밴드의 DN 값이 실제 지표면에 의한 반사도를 정량적으로 나타낼 수 없기 때문에 이를 물리적인 차원으로 변환시켜 그 값을 직접 비교할 수 있도록 데이터의 표준화를 도모하기 위함이다.

기하 보정 등의 전처리를 거친 영상을 이용하여 현장 수질측정지점을 중심으로 주변의 25개 (5 x 5) 픽셀에서 구한 DN 값을 산술평균하여 추출하였으며, 한국항공우주연구원에서 생산된 TOA REFLECTANCE CONVERSION OF KOMPSAT IMAGERY의 KOMPSAT-3호 자료를 사용하여 DN을 최종적으로 반사도 값으로 변환하였다. 위성영상의 밴드별 반사도 값을 추출한 후 클로로필-a 농도를 분석하기 위해서는 위성자료와 실측자료 사이의 상관성이 높은 밴드 선정이 필요하므로 두 자료 간의 상관성 분석이 수행되었다. 밴드 1은 청색(450-520 nm), 밴드 2는 녹색(520-600 nm), 밴드 3은 적색(630-690 nm), 그리고 밴드 4는 근적외(760-900 nm) 영역의 파장대를 가지며, 상관성 분석 결과 클로로필 반사파장인 밴드 2의 상관계수가 가장 높고, 다음으로 흡수파장인 밴드 3이 높아 클로로필 고유의 분광 특성이 잘 반영된 결과를 얻을 수 있었다. 이를 기반으로, 음의 상관관계를 보인 밴드 1을 제외한 세 가지 밴드를 활용하여 회귀모형을 유도하고 이를 통해 아래 그림과 같은 클로로필-a 분포도를 작성하였다.



그림 2.41 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제 (2017)

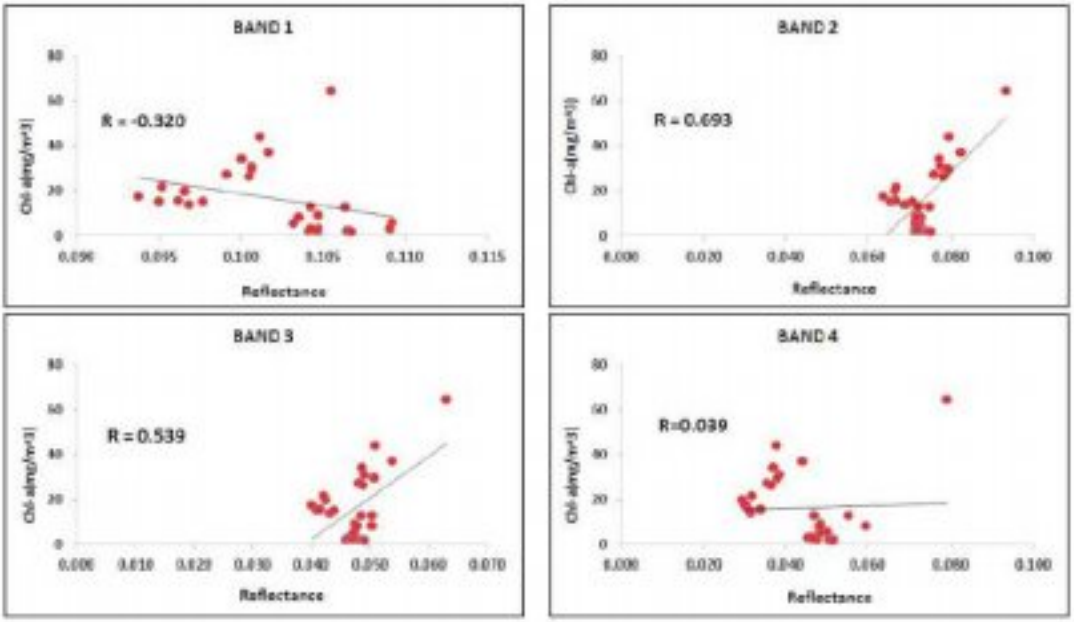


그림 2.42 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제 (2017)

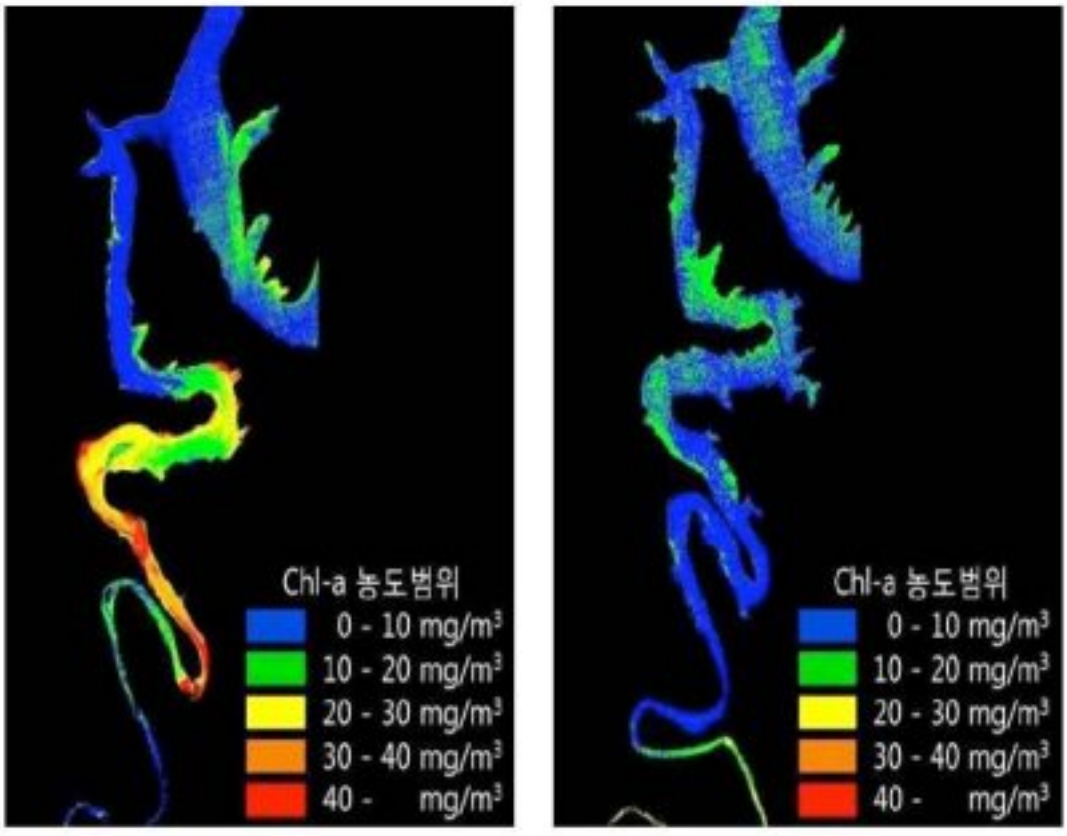


그림 2.43 '위성영상을 이용한 내륙 담수 클로로필 농도 분석 시스템 개발' 과제

2.2.4 수변환경(토지피복) (Land cover)

인공위성이 촬영한 영상을 이용하여 지표면의 상태를 표현한 지도를 만들 수 있는데, 이를 토지피복분류도(Land Cover Map)라 한다. 토지피복분류(Land Cover Classification)는 원격탐사 자료의 가장 대표적이고 전형적인 응용방법의 하나로서, 숲, 초지, 콘크리트 포장과 같은 지표면의 물리적 상황을 분류한 것이다. 이 같은 토지피복지도는 지표면의 현재 상황을 가장 잘 반영하고 있어 현실을 반영한 여러 모델링의 기초 자료로 활용되어 정책수립의 효율성·과학성을 높이는데 많은 기여를 하고 있다. 수자원 분야에서도 토지피복분류 정보는 수자원 조사, 유출모의 등 그 활용분야가 다양하고, 최근에는 하천재자연화 등 물환경 이슈와 관련하여 4대강 수변환경 모니터링을 위해 위성영상을 활용한 토지피복분류 기술을 적용하고 있다.

토지피복분류는 기본적으로 토지피복의 분광학적 특성에 따라 광학위성영상의 각 채널의 반사도를 기준으로 토지피복을 분류하게 된다. 피복별 반사특성 신호에 따라 clustering을 통한 classification하는 방법이 가장 기본적인 분류 컨셉이고, 이를 위한 방법으로 크게 감독분류, 무감독분류로 구분이 된다. 이 두 가지 방법을 구현하는 K-mens 기법, ISODATA 기법 등 다양한 영상분류 기법 들이 개발되어 왔고, 현재에도 토지피복분류에 이러한 방법들이 많이 사용되고 있다.

그러나, 인공지능기법 등을 활용한 다양한 분류기법들이 연구되고 있는데, 국외 연구 동향으로는 광학영상 및 SAR 영상을 융합하거나 다양한 기계학습을 활용하여 토지피복 분류정확도를 높이는 연구가 진행되고 있다 (Nascimento 등, 2013; Zhang 등, 2018; Steinhausen 등, 2018; Merchant 등, 2019). 장기간의 연속적인 자료를 제공한 Landsat 위성영상은 장기간 토지피복 변화에 대한 모니터링 및 예측에 활용되었다 (Zhu. and Woodcock, 2014; Singh 등, 2018). 근래에는 공간해상도와 시간해상도가 Landsat보다 우월한 Sentinel 위성 영상을 활용하여 높은 토지 피복 분류정확도를 산출하는 연구가 진행되어왔다 (Steinhausen 등, 2018).

Zhu 와 Woodcock (2014)는 장기간 수집된 Landsat 영상에 CCDC (Continuous Change Detection and Classification) 알고리즘을 적용하여 토지 피복 분류 및 변화 탐지를 수행하였다. 연구지역은 미국 뉴잉글랜드의 해안가이며 연구에 사용된 Landsat 자료는 1982년부터 2011년까지 Landsat 4 TM 3장, Landsat 5 TM 331장, Landsat 7 ETM+ 185장으로, 총 519개의 영상자료가 사용되었다. 영상자료는 대기 보정 전처리를 하였으며 후처리로 영상 내 구름, 구름그림자, 눈을 제거하였다. 토지 피복에 변화를 주는 연간변화, 연별변화, 갑작스러운 변화를 고려하기 위해 시계열 모델의 성분으로 계절성, 경향성, 단절을 사용하였다. CCDC는 RIRLS (Robust Iteratively Reweighted Least Squares) 기법을 이용한 시계열 모델로 예측한 값과 관측값을 비교하여 이상점을 탐지하는 알고리즘으로 세 번의 연이은 기간에 변화가 탐지되었을 때, 토지 피복이 변함라이고 분류하였음. 분류정확도는 90.2 %로 높은 정확도를 보였다.

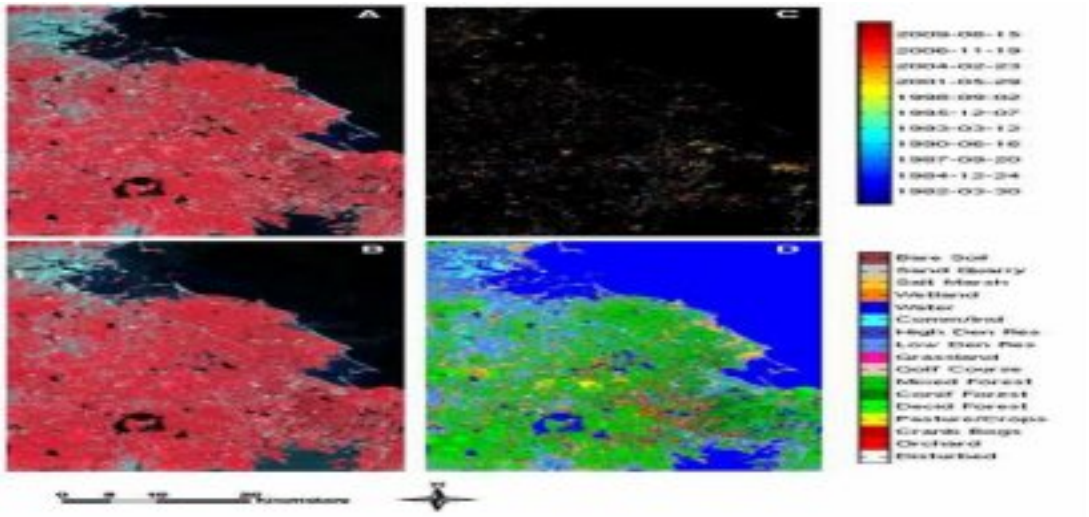


그림 2.44 Zhu와 Woodcock의 토지피복 변화탐지 및 분류결과

Clerici 등 (2017)은 Sentinel-1A의 C-band 레이더 자료와 Sentinel-2A MSI 센서의 다중분광 자료를 융합하여 콜롬비아 Lower Magdalena 지역의 토지 피복 분류를 수행하였다. 위성영상은 ESA (European Space Agency)의 SNAP (Sentinel Application Platform) toolbox와 SEN2COR toolbox를 사용하여 전처리를 수행하였다. 두 가지 Sentinel 자료를 융합한 경우와 광학과 SAR 각각의 위성자료만 사용하는 경우, 총 3가지 경우에 대하여 객체기반으로 분류기법 중 SVM (Support Vector Machine), RF (Random Forest), k-NN (k-Nearest Neighbor)을 적용하여 토지 피복을 분류하고 정확도를 평가하였다. 두 가지 위성자료를 모두 사용하여 SVM 기법을 이용하여 토지 피복을 분류하였을 때, 가장 높은 정확도인 88.75%를 보였다.

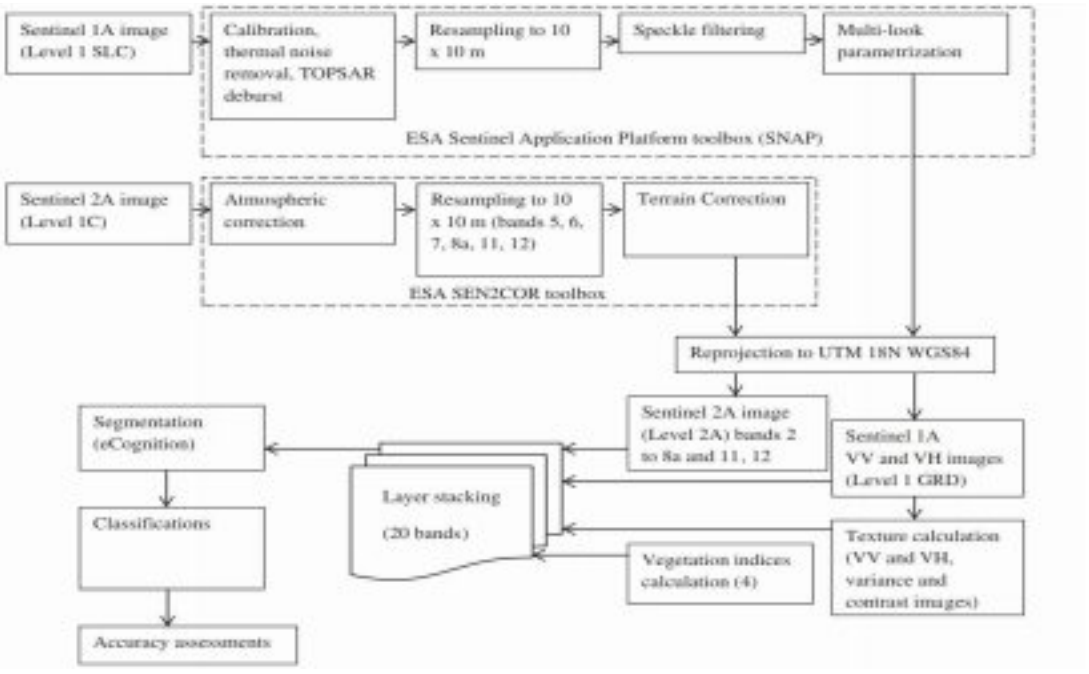


그림 2.45 Clerici 등 (2018)에서 제시한 연구흐름도

Pereira 등 (2018)은 아마존 지역에 대하여 ALOS PALSAR-1과 Landsat 5 TM 영상을 그림 2.46과 같이 다양한 방법으로 융합하여 토지 피복 분류결과를 비교하였다. 분류 클래스는 밀집한 산림, 산림, 농경지, 나지로 구분하였으며, 분류기법으로는 최대우도법과 ICM (Iterated Conditional Modes)를 적용하였다. 아래 표 그림에 나열된 방법 중 Ehlers, Wavelet átrous, IHS (Intensity, Hue and Saturation), SPC (Selective Principal Component analysis)을 사용한 방법들이 단순히 광학과 SAR 영상을 조합하여 사용하는 경우보다 향상된 정확도 (아래 막대그래프 그림)를 보였다. Ehlers 방법의 경우 융합 과정에서 SAR 영상의 HV 밴드가 포함되었을 때 만족할 만한 결과를 보였지만, 각 토지 피복 클래스별로 다른 융합방법에서 최선의 결과가 도출되었다.

TABLE II
ACRONYMS AND DESCRIPTION OF DATASET ANALYZED

Acronym	Description
TM6	Composed by six TM bands (1-5 and 7)
PALSAR	Composed by HH and HV amplitude bands
OPT3	Composed by three TM bands (2, 4 and 5) selected using the JM criteria
SAR3	Composed by the three SAR features selected (MEA_5(HV), HOM_15(HH) and DIS_15(HH))
Acronym	**Combination**
TM6+HH	Six TM bands combined with polarization HH from PALSAR data
TM6+HV	Six TM bands combined with polarization HV from PALSAR data
TM6+HH+HV	Six TM bands combined with polarization HH and HV from PALSAR data
TM6+SAR3	Six TM bands combined with three SAR features selected
OPT3+HH+HV	Three optical features selected combined with polarization HH and HV from PALSAR data
OPT3+SAR3	Three optical features selected with three SAR features selected
Acronym	**Fusion**
IHS_TM6X	IHS fusion of three TM bands (2, 4 and 5) selected using the JM criteria with SAR data
IHS_OPT3X	IHS fusion of three optical features selected with SAR data
TR_TM6X	Brovey Transformation fusion of three TM bands (2, 4 and 5) selected using the JM criteria with SAR data
TR_OPT3X	Brovey Transformation fusion of three optical features selected with SAR data
PC_TM3X	Principal Components Analysis fusion of three TM bands (2, 4 and 5) selected using the JM criteria with SAR data
PC_TM6X	Principal Components Analysis fusion of six TM bands (1-5 and 7) with SAR data
PC_OPT3X	Principal Components Analysis fusion of three optical features selected with SAR data
SPC_TM6X	Selective Principal Component Analysis fusion of six TM bands (1-5 and 7) with SAR data
WA_TM3X	Wavelet à trous fusion of three TM bands (2, 4 and 5) selected using the JM criteria with SAR data
WA_OPT3X	Wavelet à trous fusion of three optical features selected with SAR data
WAPC_TM3X	Wavelet à trous + PC fusion of three TM bands (2, 4 and 5) selected using the JM criteria with SAR data
WAPC_OPT3X	Wavelet à trous + PC fusion of three optical features selected with SAR data
W_TM6X	Wavelet fusion of six TM bands (1-5 and 7) with SAR data
W_OPT3X	Wavelet fusion of three optical features selected with SAR data
WIHS_TM3X	Wavelet + IHS fusion of three TM bands (2, 4 and 5) selected using the JM criteria with SAR data
WIHS_OPT3X	Wavelet + IHS fusion of three optical features selected with SAR data
WPC_TM6X	Wavelet + PC fusion of six TM bands (1-5 and 7) with SAR data
WPC_OPT3X	Wavelet + PC fusion of three optical features selected with SAR data
Ehlers_TM6X	Ehlers fusion of six TM bands (1-5 and 7) with SAR data
Ehlers_OPT3X	Ehlers fusion of three optical features selected with SAR data
X represent the SAR data used as input in the fusions methods described above	
X=HH	Means polarization HH was used in the fusion process
X=HV	Means polarization HH was used in the fusion process
X=HH+HV	Means PC1 extracted from PALSAR data (HH and HV) was used in the fusion process
X=SAR3	Means PC1 extracted from three SAR features selected (MEA_5(HV), HOM_15(HH) and DIS_15(HH)) was used in the fusion process

그림 2.46 Pereira 등 (2018)에서 사용한 광학 영상과 SAR 영상의 융합방법

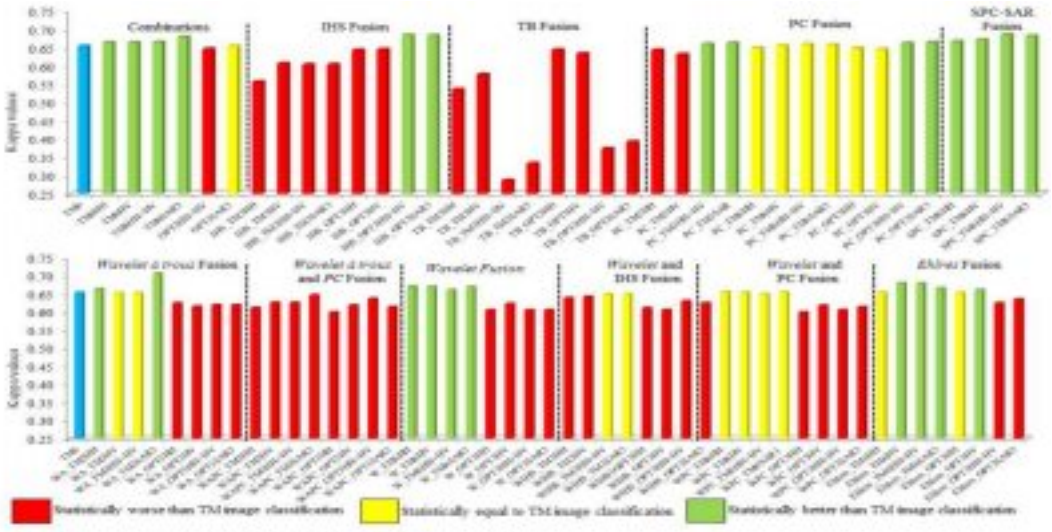


Fig. 4. Kappa index value of the 87 classifications and hypothesis test results.

그림 2.47 Pereira 등 (2018)에서 광학과 SAR 영상의 융합방법에 따른 토지 피복 분류결과

Singh 등 (2018)은 Tons 강 유역에 대하여 토지 피복 변화를 분석하였다 (아래 컬러 플로우차트 그림). 위성영상과 사회경제적인 통계자료는 1985, 1995, 2005, 2015년도를 대상으로 수집하였다. 위성영상의 경우 연도에 따라 Landsat TM (1985년 8월 24일, 1995년 8월 1일), Landsat ETM+ (2005년 8월 18일)과 Landsat 8 (2015년 6월 9일)을 이용하였다. 분류 클래스는 활엽림, 혼합림, 농경지, 수역, 시가지, 나지로 구분하였다. 토지 피복 분류에 무감독분류 기법인 ISODATA 알고리즘 사용, 구글어스를 통해 구축한 참조자료를 이용하여 분류정확도를 평가하였다. 분류 결과, 전체정확도는 83 % ~ 86 %로 나타났다. 본 연구에서는 분류된 토지 피복 결과를 바탕으로 CA-Markov chain이라는 모델을 이용하여 클래스 간에 피복이 변화할 확률을 계산하여 향후 2025년에 토지 피복이 어떻게 변화할 것인지 분석하였다.

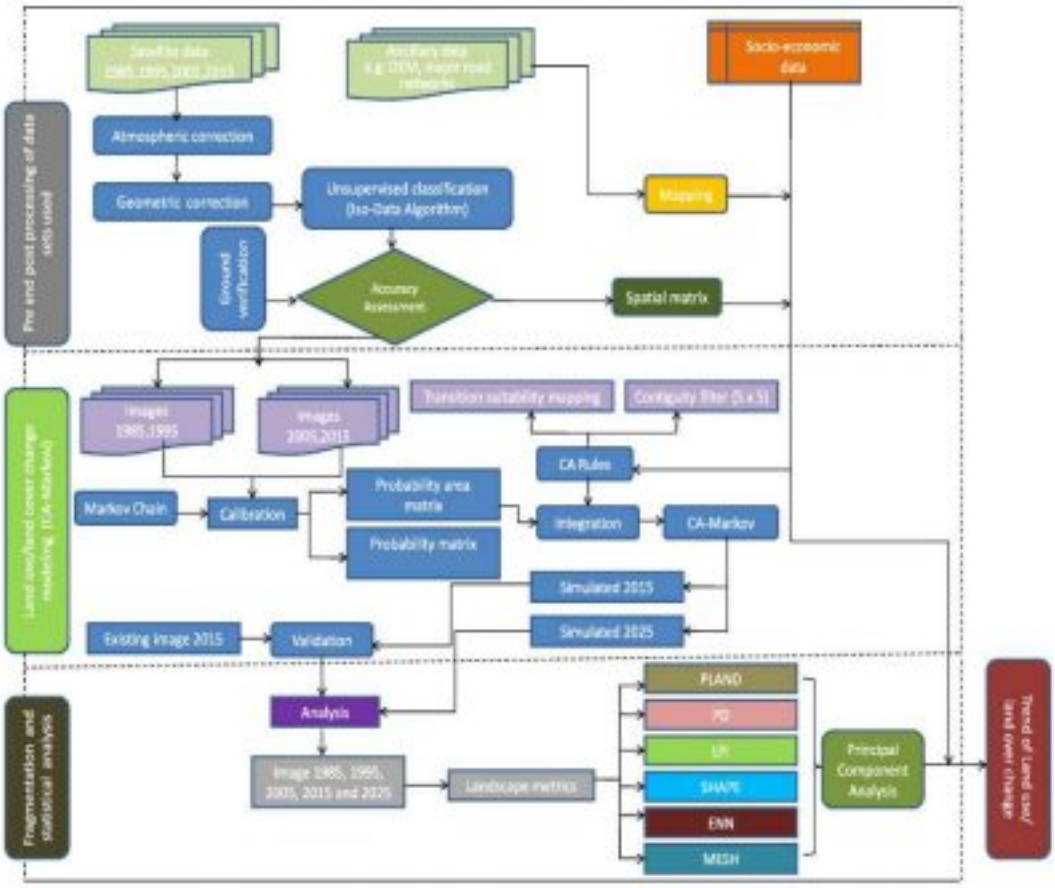


그림 2.48 Singh 등 (2018)에서 제시한 연구흐름도

Zhang 등 (2018)은 SAR (Synthetic Aperture Radar)와 광학 영상을 함께 사용하는 토지 피복 분류연구에서 Pixel level, Feature level, Decision level 중 어떤 level에서 융합하는 것이 좋은지 중국의 광저우, 선전, 및 홍콩 도시지역을 대상으로 연구를 수행하였다. SAR 영상은 ENVISAT ASAR와 TerraSAR-X를, 광학 영상은 Landsat ETM+, SPOT-5이 사용되었다. 융합하는 방법은 광학과 SAR 영상으로부터 추출된 값을 분류기법 (ML (Maximum Likelihood), ANN (Artificial Neural Network), RF (Random Forest), SVM (Support Vector Machine))에 함께 적용하는 방식을 이용하였다. 비교한

융합 레벨은 광학과 SAR 영상에서 (1) 원래의 픽셀값을 이용 (Pixel level), (2) 각 영상에서 추출한 GLCM 기반의 질감을 이용 (Feature level A), (3) 각 영상에서 추출한 GLCM 기반의 질감과 픽셀값을 이용 (Feature level B), (4) (1)-(3)에서 나온 결과들에서 다수결로 결정으로 나누어 비교를 수행하였다. 연구결과, 광학 영상만 사용하였을 때와 달리 SAR 영상을 함께 사용하였을 때 약 10%의 정확도 향상을 보였다. 융합 레벨의 경우, 데이터의 분포와 분류 알고리즘에 따라 최적의 융합 레벨이 다르다는 결과를 도출하였다. 또한, 융합 레벨의 선택과 융합방법에 따라 광학 영상과 SAR 영상의 융합이 단일 영상을 쓰는 것에 비해 향상을 보장하지 못한다는 연구결과를 도출하였다.

Merchant 등 (2019)은 아한대 코르디예라 지대에 속하는 캐나다에 있는 유콘지역을 대상으로 5개의 습지 클래스 (bog, fen, marsh, swamp, and shallow open water)를 분류하였다. 위성영상으로 Sentinel-2 광학 영상, Sentinel-1 C밴드 SAR, ALOS PALSAR L밴드 SAR, SRTM에서 산출되는 DEM (Digital Elevation Model)이 사용되었음. 분류는 객체기반으로 수행되었으며, RF (Random Forests), SVM (Support Vector Machine), kNN (k-nearest neighborgood)의 세 가지 기계학습 기법을 사용하였다. 모델 결과는 광학, SAR, DEM 자료를 모두 넣고 RF를 사용하여 모델을 학습하였을 때 86.5 %의 가장 높은 정확도를 보였다 (아래 정확도 표 그림). 습지 클래스 중에서 open water, marsh, swamps는 low backscatter로 인해 producer's accuracy가 각각 100 %, 75 %, 85.7 %로 다른 클래스들에 비하여 정확하게 분류하였다.

Table 5. Overall classification accuracies (%) and kappa coefficients for land cover classifications.

	RF		SVM		KNN	
Model	Overall	Kappa	Overall	Kappa	Overall	Kappa
S2	81.5	0.79	*84.5	*0.82	82.0	0.79
S1	54.0	0.47	34.0	0.22	25.0	0.14
AP	53.5	0.47	27.5	0.15	19.5	0.08
DEM	39.5	0.31	42.5	0.33	32.0	0.23
DEM + S2	*86.5	*0.84	84.0	0.82	80.0	0.77
DEM + S1	71.5	0.67	54.5	0.47	47.0	0.39
DEM + AP	68.5	0.64	48.5	0.40	42.5	0.34
S2 + S1	83.5	0.81	*84.5	*0.82	83.0	0.80
S2 + AP	83.0	0.80	82.0	0.79	82.0	0.79
S2 + AP + S1	83.5	0.81	83.5	0.81	*83.5	*0.81
S2 + AP + S1 + DEM	*86.5	*0.84	84.0	0.82	79.5	0.76

Note. S2: Sentinel-2; S1: Sentinel-1; AP: ALOS PALSAR; DEM: digital elevation model.
*Denotes most accurate model for each algorithm.

그림 2.49 Merchant 등 (2018)에서 사용한 데이터셋 구성과 각 기계학습 별 모델 결과

Steinhausen 등 (2018)은 구름이 빈번하게 발생하는 남아시아 몬순 기후 지역인 인도의 첸나이 유역에 대하여 토지 피복 지도를 개발했다. 위성영상은 2015년 11월과 2016년 5월 사이에 촬영된 ESA에서 제공하는 Sentinel-1의 이중 편광 C 밴드 Radar 영상 10장과 Sentinel-2의 고해상도 광학 영상 2장을 사용하였다. 토지 피복 클래스는 6개의 농경지 클래스, 산림, 초지, 습지, 암석지, 관목지, 시가지, 수역으로 구분하였으며, 지상 참조자료는 2016년 1월 ~ 2월 사이에 수행한 현장조사와 구글

어스를 바탕으로 구축하였다. 아래 흐름도와 같이 RF (Random Forest) 기반의 Wrapper 방식을 이용하여 토지 피복 분류를 수행하였다. 1장의 Sentinel-2 영상과 8장의 Sentinel-1 영상을 사용하였을 때 가장 높은 정확도 (91.53 % ± 0.89)를 보였다. 이는 Sentinel-2 영상만 사용하였을 때와 비교하여 5.68 %가 향상되는 결과를 보였으며, 클래스별로 보았을 때 Sentinel-1과 Sentinel-2를 같이 사용함으로써 많이 향상된 클래스는 논으로 나타났다.

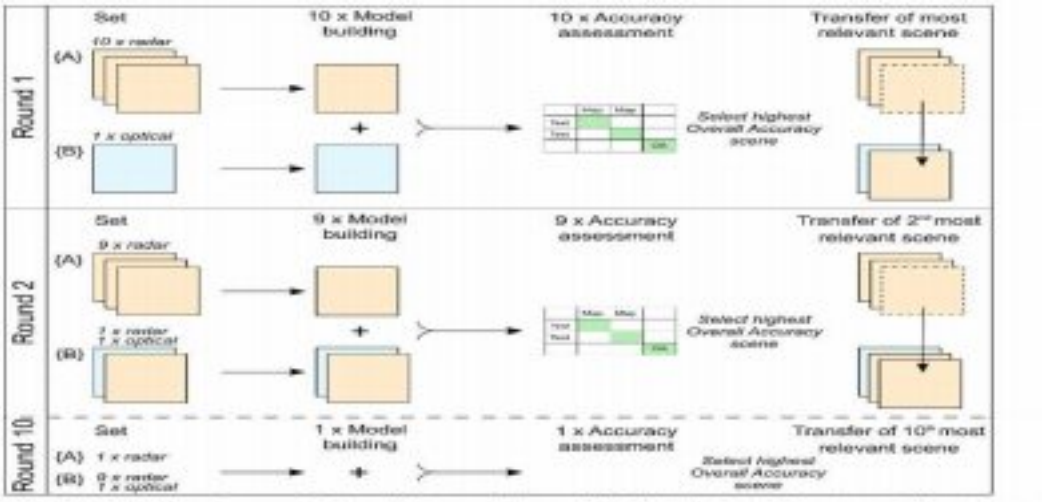


Fig. 2. Random Forest based wrapper for forward feature selection and the identification of the next most relevant scene.

그림 2.50 Steinhausen 등 (2018)에서 수행한 토지 피복 분류 방법 흐름도

Demirkan 외 (2020)은 터키의 이즈미르 및 앙카라 지역을 대상으로, 토지피복 분류지도를 개발하였다. 위성영상으로는 Sentinel-2 의 다중분광센서 자료를 사용하였으며, 분류 기법으로는 계층구조를 사용한 기법을 적용하였다. 다음 그림과 같이, 널리 쓰이는 기계학습 기법인 KNN, RF, SVM 기법을 바탕으로 먼저 토지피복을 분류하며, 순차적으로, 널리 사용되는 식생지수인 NDVI와 Normalized Difference Water Index (NDWI) 의 임계값과 추가적인 기계학습을 사용하였다. 아래 그림과 같은 계층적인 토지피복 분류방법을 통해 단순 기계학습 방법으로는 이즈미르 및 앙카라 지역에서 83% 및 72%의 정확도를 보인 반면 계층적인 방법을 통한 정확도에서 각각 85%와 84%의 정확도를 보였다.

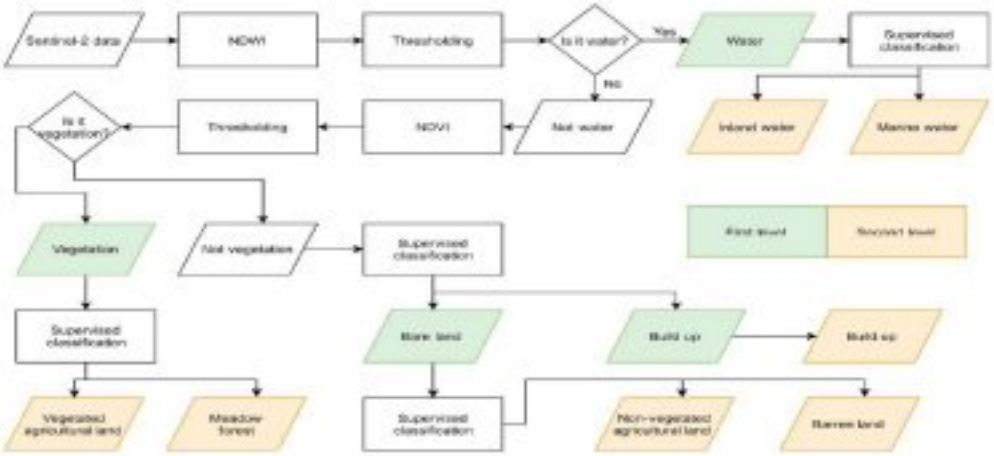


Fig. 1 General scheme of the proposed hierarchical classification method with respect to the CORINE system.

그림 2.51 Demirkan 등 (2020)에서 수행한 토지피복 분류 방법의 흐름도

Damali (2020)는 Landsat-8의 다중 분광 영상과 3가지의 분광 지수들을 이용하여 이란의 도시 중 하나인 Shiraz에 대하여 토지피복 및 토지이용도 LULC (Land Use Land Cover)를 제작하였다. 사용된 분광 지수들은 NDVI (Normalized Difference Vegetation Index), NDBI (Normalized Difference Built-up Index), SR (Simple Ratio)이다. LULC의 분류 클래스는 5가지로 농경지, 건물, 도로, 나지, 산림으로 나뉘며 SVM, DNN, CTree (Complex Tree), FDMLP (the Derivative-free Multi-layer Perceptron 기법을 이용하여 분류하였다. 기법들을 적용하기 앞서 사용하는 영상의 대기 보정 전처리 여부와 공간해상도(15m, 30m)에 따른 차이를 두어 3가지 시나리오를 정립하여 진행하였고, 테스트 결과, 15m의 공간해상도를 가진 영상에 대기보정과 고해상도로의 보정 (Pan-sharpening)을 거친 영상에 대하여 DNN 기법이 91.28%의 전체 정확도와 88.57%의 Kappa지수를 가지며 가장 높은 정확도를 보였다. 같은 조건에서 FDMLP기법이 전체 정확도 90.26%, Kappa지수 87.25%를 보이며 전처리된 영상에서 객체 기반의 분류가 그렇지 않은 것에 비해 더 좋은 결과를 낼 수 있음을 확인하였다.

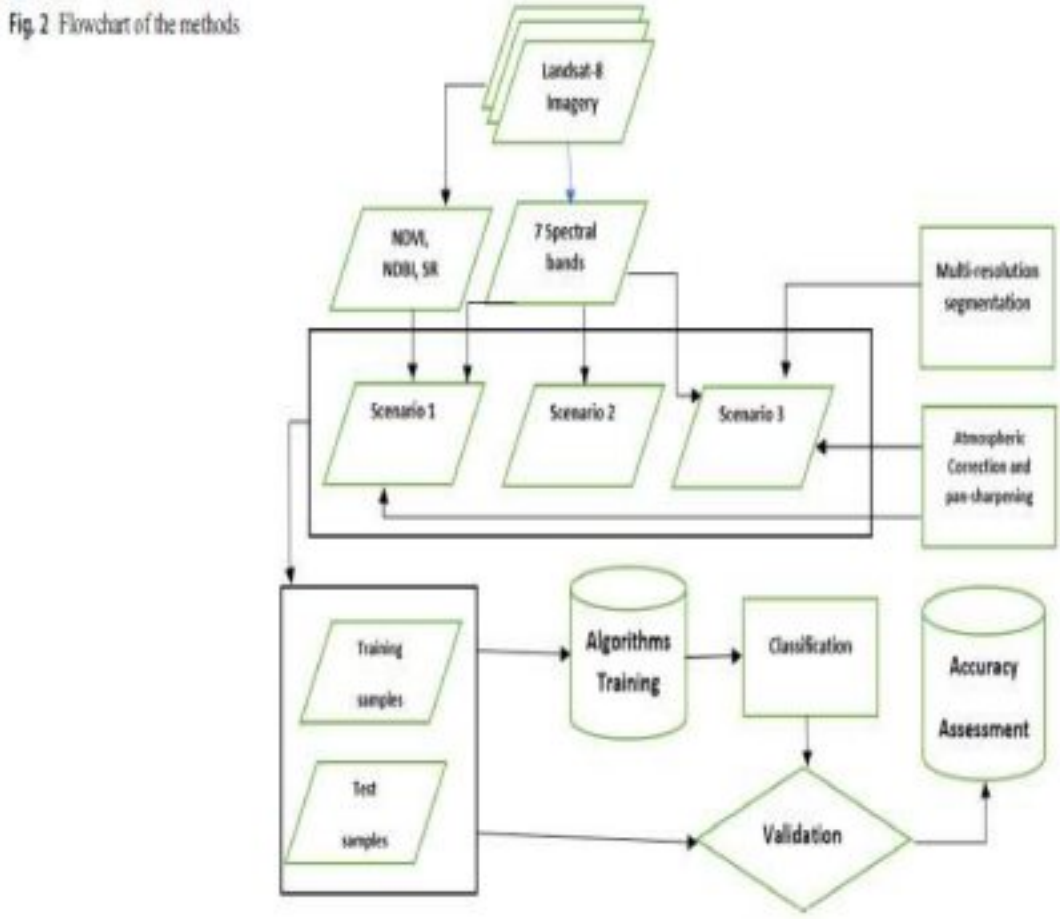


그림 2.52 Jamali (2020)의 토지피복 분류 연구흐름도

Wahap (2020)는 구글 어스 엔진 플랫폼을 이용하여 토지피복 분류를 모의하였다. 구글 어스 엔진 플랫폼에서는 Landsat 시리즈 영상을 대기 보정 후 지표 반사도 값으로 제공하며 해당 연구에서는

1998, 2003년 Landsat-5 MSS/TM, 2016년 Landsat-8 OLI/TIRS에서 얻은 다중 분광 영상을 이용하였다. 말레이시아의 Selangor 지역을 대상으로 CART (Classification and Regression Tree), SVM, RF (Random Forest)기법을 픽셀 기반으로 적용한 결과 CART 기법을 이용했을 때 1988년에 전체 정확도 94.71%, 2003년에 94.72%, 2018년에 96.57%로 모두 다른 두 기법보다 높은 정확도를 보였다.

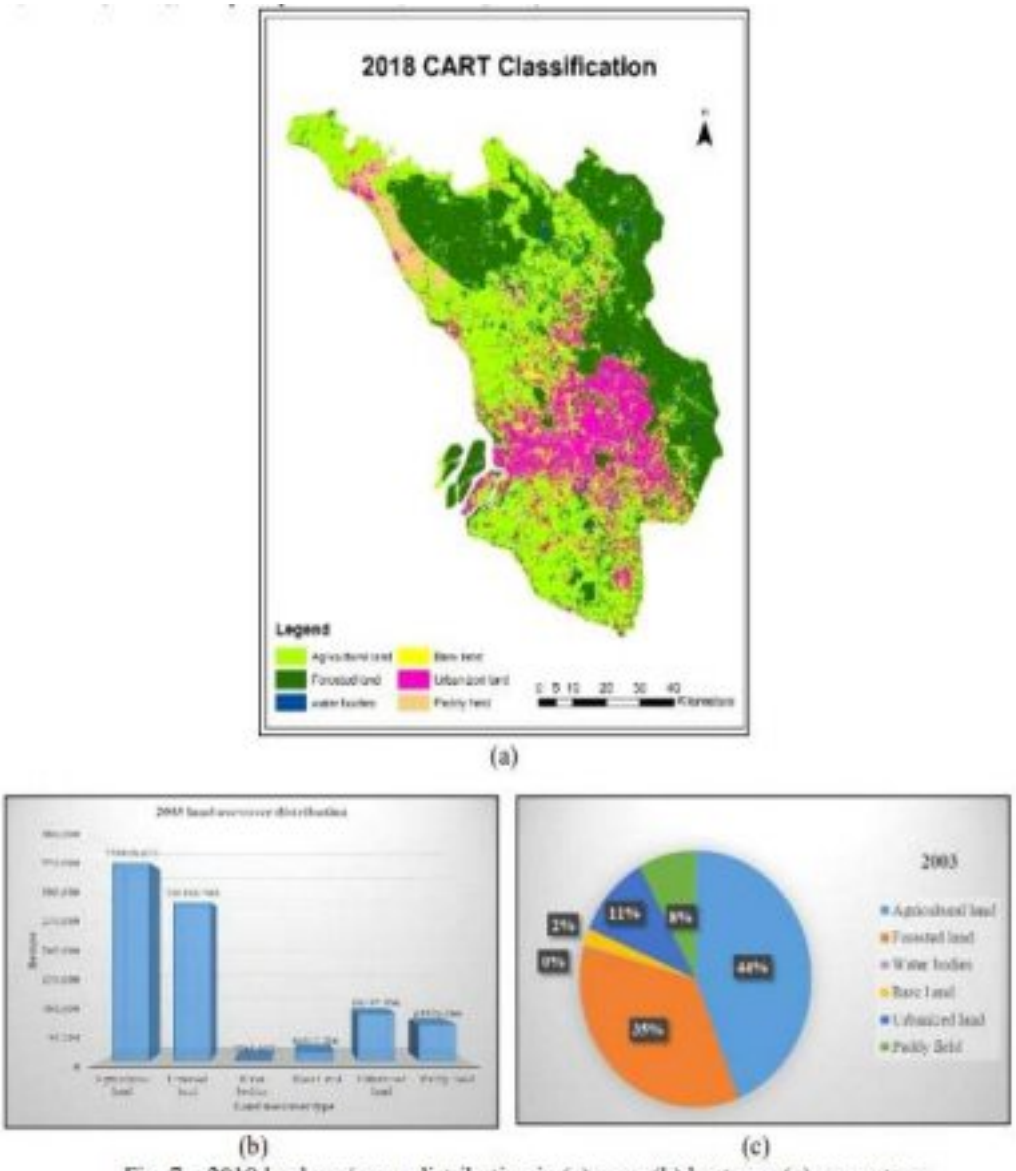


Fig. 7 – 2018 land use/cover distribution in (a) map; (b) hectares; (c) percentage

그림 2.53 Wahap (2020)의 CART알고리즘을 이용한 토지피복 분류 결과, 면적 및 각 토지피복이 연구지역 내에서 차지하는 비율

Abdi (2020)는 스웨덴 남동쪽에 위치한 Uppsala 지역에 대하여 Sentinel-2A, 2B의 다중 분광 영상과 3가지의 분광 지수 NDVI, NDBI, MNDWI (Modified Normalized Difference Water Index)를 이용하여 토지 피복을 분류하였다. 20m의 공간해상도를 가진 band5, 6 ,7 ,8a, 11, 12 영상은 10m로 리샘플링 과정을 거쳐 이용하였으며 모든 입력 자료의 공간해상도를 10m로 설정하여 고해상도 토지피복도를 제작하였다. SVM, RF, Xgboost (Extreme gradient boosting), DL (Deep learning)기법을

이용해 낙엽수, 침엽수, 물, 도시, 습지, 농업지, 벌목지, 초지로 총 8가지의 토지 피복을 분류하였으며 SVM이 전제 정확도 75.8%로 가장 높은 정확도를 보였고 Xgboost가 75.1%, RF가 73.9%, DL이 73.3%로 근사한 정확도를 보였다. 변수 중요도를 분석하였을 때 적외 영역 중 red edge가 25%로 가장 높은 중요도를 보였으며 적외단파 (SWIR)는 23%로 그 뒤를 따랐다. 분광 지수의 중요도는 높게 측정되지 않았는데 이는 분광 지수를 통한 산림 지역의 나무 분류와 나지-도시지역의 분류, 물-그림자의 분류에 한계가 있음을 암시하였고 이를 활용하기 위한 방법의 필요성을 제시하였다.

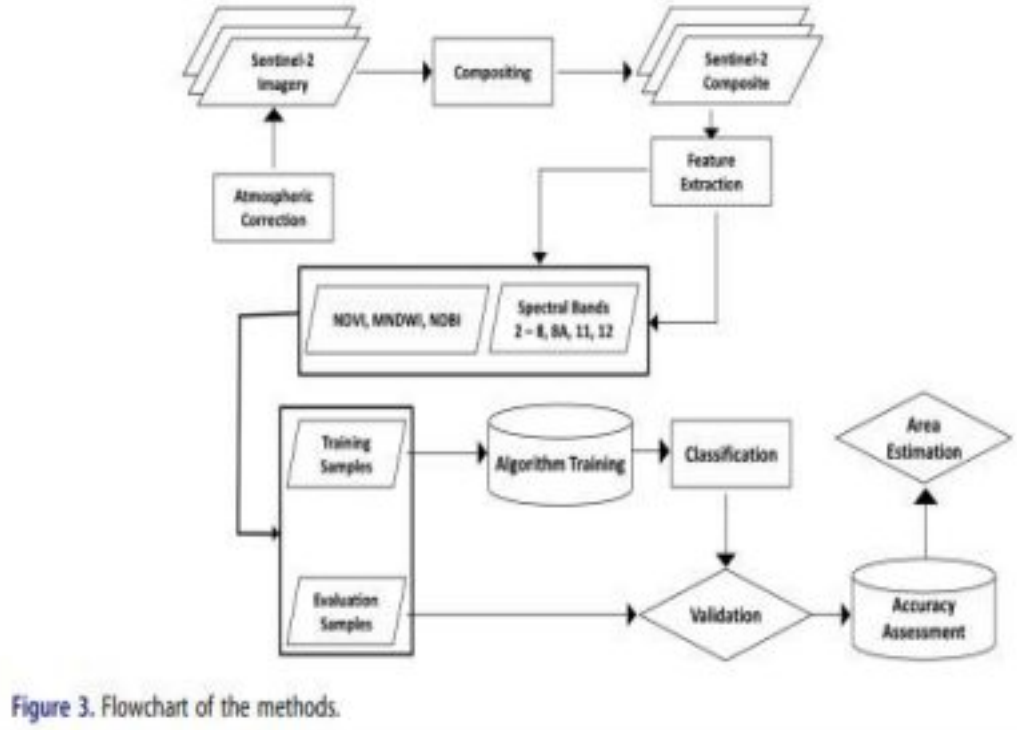


그림 2.54 Abdi (2020)의 기계학습 기반 Sentinel-2 밴드값 및 분광지수를 사용한 토지피복 분류 연구흐름도.

국내에서 위성영상을 활용한 수변 환경 모니터링 연구는 광학 위성영상을 위주로 수행하였다. 주로 QuickBrid와 같은 고해상도 영상이나 Landsat과 같이 중해상도의 광학 영상을 사용하였다. 광학 영상의 경우, 관측시간과 기상 현상에 따라 가용성이 크게 영향을 받으므로 기상 현상의 영향을 거의 받지 않는 SAR 영상을 토지 피복 분류에 활용하였으며, 특히 식생 분류에서 초지, 농업지역, 산림 지역의 표면 거칠기에 따라 다른 SAR 산란 특성을 가지기 때문에 SAR 영상과 위성영상을 복합적으로 활용하여 분류 정확도를 향상하였다 (염준호 등, 2011). 광학 영상을 활용하여 DMZ와 같이 미계측지역의 토지 피복 분류를 수행한 연구도 꾸준히 이루어지고 있는 것으로 나타났다 (김용민 등, 2010; 최병구 등, 2013; 나현섭 등, 2015).

정윤재 (2015)은 낙동강 본류 20 km 지역을 대상으로 4대강 정비사업이 시행되기 이전과 이후에 낙동강 유역에 발생한 토지 피복 변화를 탐지하고 분석하였다 LiDAR DEM(Digital Elevation Model)에서 추출한 제방경계선으로 하천유역을 설정하였다. 위성자료로 4대강 사업 이전 시기에 대

해서는 Landsat-5 TM 위성을, 이후 시기에는 Landsat-8 OLI 위성의 영상자료를 사용하였다. 토지피복 분류는 ISODATA 방법으로 클러스터링한 후, post-classification을 통해 최종적으로 하천, 나지, 초지의 총 3가지 클래스로 분류하였다. 분류정확도는 평균 1 km 간격의 50개의 점검점을 통해 검증, 82 % - 90 %의 정확도를 보였다. 초지의 경우 점검점의 개수가 상대적으로 적어 정확도가 40 % - 67 %로 낮게 평가된 것으로 판단된다. 연구결과, 4대강 정비사업이 시행된 전후로 하천유역 내에서 하천의 면적이 큰 폭으로 증가하였다. 이는 4대강 정비사업으로 인해 증가한 하천의 저수량 때문으로 분석되었다.

TABLE 3. Classification error matrix of land covers in the multiple river basin imagery

(a) Classification error matrix of land covers in the first river basin imagery

Class	River	Bare soil	Grass	User's accuracy
River	15	1	0	94%
Bare soil	0	28	1	97%
Grass	1	2	2	40%
Producer's accuracy	94%	90%	67%	90%(Overall accuracy)

(b) Classification error matrix of land covers in the second river basin imagery

Class	River	Bare soil	Grass	User's accuracy
River	16	1	0	94%
Bare soil	0	18	2	90%
Grass	1	5	7	54%
Producer's accuracy	94%	75%	78%	82%(Overall accuracy)

(c) Classification error matrix of land covers in the third river basin imagery

Class	River	Bare soil	Grass	User's accuracy
River	19	1	0	95%
Bare soil	3	22	2	81%
Grass	0	1	2	67%
Producer's accuracy	86%	92%	50%	86%(Overall accuracy)

(d) Classification error matrix of land covers in the fourth river basin imagery

Class	River	Bare soil	Grass	User's accuracy
River	18	1	1	90%
Bare soil	2	20	2	83%
Grass	2	0	4	67%
Producer's accuracy	82%	95%	57%	84%(Overall accuracy)

그림 2.55 정운재 (2015)의 유역별 토지피복 분류 수행 결과

박주성 등 (2016)은 창녕군에 대하여 Landsat-8 OLI 영상에 식생 및 수분지수를 결합하여 하천유역의 토지 피복 분류를 수행하였다. Landsat-8 OLI의 열 밴드를 제외한 9개의 밴드와 식생지수, 수분지수를 결합하여 하나의 영상으로 조합하는 layer-stakcking 기법을 사용하였다. 분류 항목으로는 식생(산림과 초지), 수계(하천과 호수 등), 인공구조물 (도심지와 도로, 비닐하우스 등을 포함), 농경지, 건천지역으로 5가지의 분류 항목을 선정하였다. 감독분류의 기법인 최대우도법과 SVM를 적용하

였으며, 정확도 검증은 7곳에 대하여 현장분석을 수행하였다. Layer-stacking 기법을 사용하였을 때, 기존 영상과 비교하여 분류정확도가 약 1.6 % - 8 % 개선됨을 보였다. 식생과 수계지역에 대해 높은 정확도를 보였으며, 이는 식생지수와 수분지수를 결합한 결과로 사료된다.

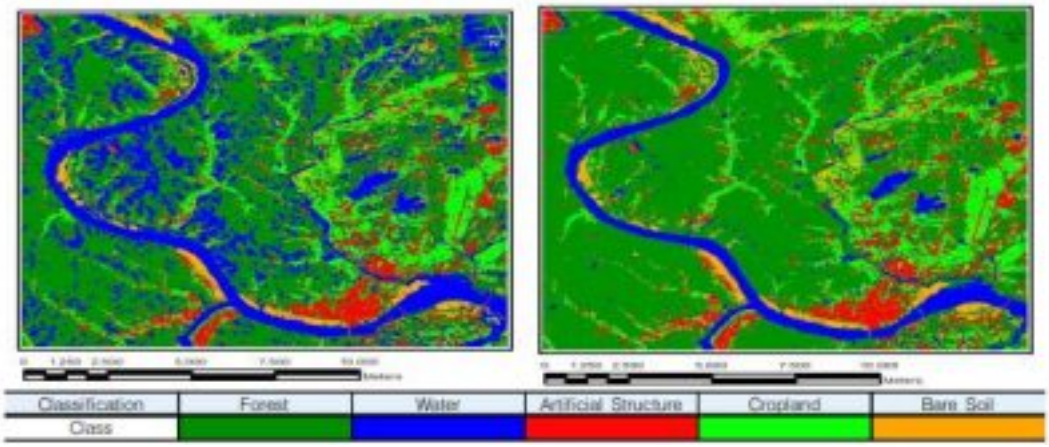


그림 2.56 박주성 등 (2016)의 창녕군의 최대우도법 기반 토지피복 분류지도 (좌측) Layer-stacking 기반 토지피복분류지도 (우측)

염준호 등(2011)은 식생 클래스의 분류에 있어 위성영상의 다중분광자료만 사용할 경우 정확도가 저하되는 문제를 지적하며 SAR 영상을 포함하여 식생을 세분화하였다. 연구 대상 지역은 제주도 표선면 일대이며 연구에 사용된 데이터는 2000년 10월 12일에 수집된 IKONOS 고해상도 위성영상의 다중 분광 정보와 2000년 9월 30일에 수집된 AIRSAR/TOPSAR 영상의 L 밴드 산란 정보 (HH, HV, VV)가 사용되었음. 전체 분류정확도는 95.96%로 높게 나타났으며 계층적 분류를 적용할 경우 식생분류에서 높은 정확도를 보이며 인공물 토지 피복의 과분류 방지, 비식생지역의 분류정확도 감소 문제를 줄일 수 있음을 보인다.

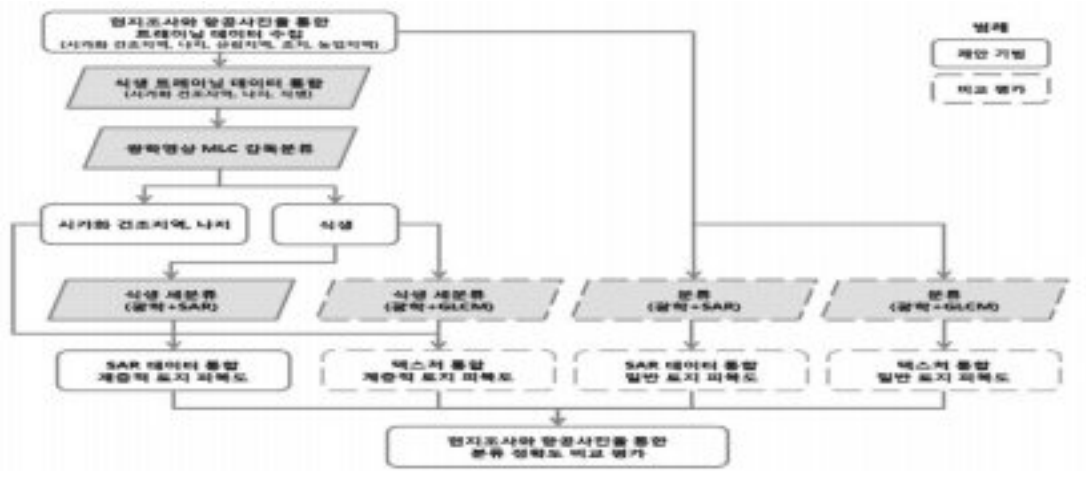


그림 2.57 염준호 등 (2018)에서 제시한 연구흐름도

김용민 등 (2010)은 DMZ 지역 중 연천 (100 km2)과 철원 (64 km2)에 위치한 사이트를 대상으로 토지피복분류를 수행하였다. 농경지, 수역, 시가지, 초지, 산림을 대상으로 분류를 수행하였으며, 철

원의 경우 초지를 제외하였다. 위성자료는 두 지역에 공통적으로는 공간 해상도가 30m인 Landsat 4, 5 TM을, 연천에는 공간해상도가 약 2.8 m인 QuickBird 영상을, 철원에는 10m 해상도를 가지는 QuickBird의 다중분광 밴드를 이용함. Landsat 영상과 클래스 정보가 있는 군사 디지털 지도를 최대우도법으로 우선적으로 학습시킨 후, 그 결과를 바탕으로 고해상도에 맞추어 식생지수 (NDVI; Normalized Difference Vegetation Index)와 이진 경계 변수를 추가하여 최대우도법으로 분류를 수행하였다. 제시된 분류 방법의 전체 정확도는 연천에서는 83.47 %, 철원에서는 88.98 %로 나타났다. 하지만 제시된 방법은 여름에 농경지와 초지 사이에서 비슷한 분광특성으로 인해 오분류가 일어날 가능성이 높으므로, 해결방안으로 질감 정보를 추가할 것을 제시하였다.

Table 9. Confusion matrix of manual method for site I

	Built-up	Water	Crop	Grass	Forest	User's Accuracy (%)
Built-up	773	2	0	10	0	98.47
Water	0	418	18	0	0	95.87
Crop	2	0	225	388	0	36.59
Grass	0	0	68	541	17	86.42
Forest	0	0	1	9	886	98.88
Producer's Accuracy (%)	99.74	99.52	72.12	57.07	98.12	84.66(Overall)

그림 2.58 김용민 등 (2010)에서 제시한 알고리즘의 연천지역 분류결과를 나타내는 혼동행렬

최병구 등 (2013)은 강원도 고성군 지역의 DMZ 일원에 대하여 토지피복분류를 수행하였다. 토지피복은 주거지, 농지, 나지, 산림, 준산림, 수역의 5가지 클래스로 분류하였고(아래 3장 그림), 사용된 위성영상은 Landsat TM 5이며, 2000년 6월 17일과 2009년 5월 25일에 촬영된 영상을 이용하였다. 구글어스 (Google Earth)의 고해상도 영상을 이용하여 참조자료를 구축하였다. 시기가 다른 두 영상에 기하보정을 수행하였으며, 구름이 있는 지역의 경우 마스킹 처리하였다. 분류기법으로는 감독분류방법 중 최대우도법, 최단거리법, SVM (Support Vector Machine)을 적용하였고, 토지 피복 분류 결과 최대우도법을 이용한 방법이 최단거리법과 SVM보다 높은 약 95 %의 정확도를 보였다. 분류된 두 시기의 영상을 이용하여 토지 피복 변화 분석을 수행하여 민통선 이북지역에서 산림 황폐화가 많이 발생함을 발견하였다.

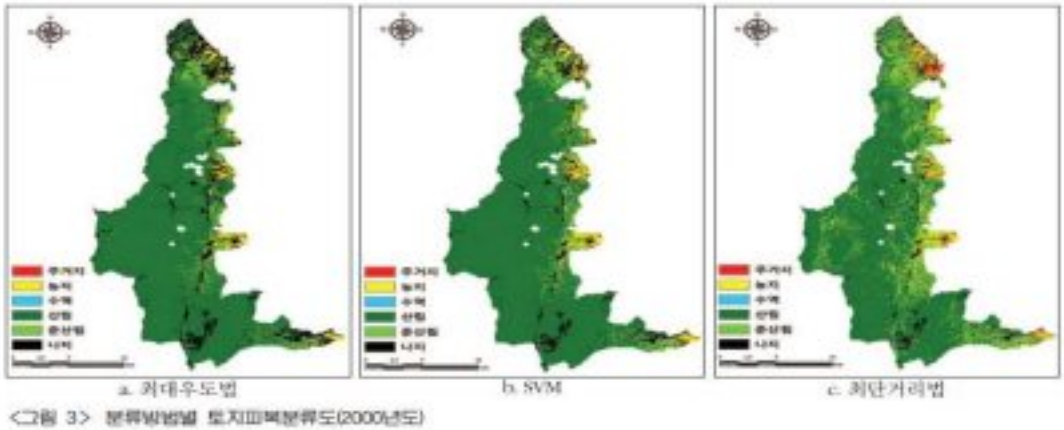


그림 2.59 최병구 등 (2013)의 강원도 고성군 DMZ 지역 토지피복분류 결과

나현섭 등 (2015)은 강원도 DMZ지역에 해당하는 민간인통제선 이북지역에서부터 남방한계선까지의 지역에 대하여 9개의 클래스(산림, 논, 밭, 시설재배지, 초지, 나지, 수역, 건물, 교통시설)에 대하여 토지피복분류를 수행하였다. 사용한 위성영상은 공간해상도가 5 m인 Rapid eye level 3A Product으로 2011년 9월 22일과 2013년 6월 2일 영상을 기하보정 및 방사보정을 수행한 후 사용함. eCognition 프로그램을 이용하여 반복을 통해 최적의 가중치를 선정하여 영상을 분할하였다. 토지피복분류는 분광정보만 사용하는 경우, 질감정보만 사용하는 경우, 분광정보와 질감정보를 함께 사용하는 경우로 나누어 최근린기법을 이용하여 분류를 수행하였다. 분광정보와 질감정보를 함께 사용하였을 때 약 96 %의 가장 높은 전체정확도를 보였다. 산림, 수역, 논의 경우에는 분광정보가 다른 클래스에 비해 명확하게 구분되어 분류정확도가 높다. 하지만 교통시설과 건물의 분류정확도는 각각 약 80 %와 약 70 %로 교통시설, 나지, 건물 사이에서 오분류가 많이 발생함을 확인하였다.

Unit: Pixel

Classification	Ground truth data									
	Bare land	Paddy field	Dry field	Protected cultivation	Forest	Water	Buildings	Road	Grass-land	Total
Bare land	16,298	-	-	-	48	-	288	1,437	274	18,345
Paddy field	-	54,066	295	-	-	471	-	134	-	54,966
Dry field	-	-	4,779	-	-	-	-	-	-	4,779
Protected cultivation	333	-	-	9,200	24	-	241	204	280	10,282
Forest	-	-	377	-	64,293	-	-	-	315	64,985
Water	-	643	-	-	-	82,903	-	-	-	83,546
Buildings	207	-	-	1,350	-	231	2,062	914	13	4,767
Road	494	-	-	-	-	-	298	13,427	164	14,383
Grass-land	260	58	229	-	475	-	41	739	6,073	7,875
Total	17,592	54,767	5,680	10,550	64,840	83,605	2,920	16,855	7,119	263,928
Accuracy	93%	99%	84%	87%	99%	99%	70%	80%	85%	

Overall accuracy : 96% Kappa : 0.95



그림 2.60 나현섭 등 (2015)에서 제시한 알고리즘의 결과 혼동행렬 및 분류지도

국내 토지피복 관련 서비스는 환경부의 환경공간정보서비스(https://egis.me.go.kr/main.do) 에서 이루어지고 있으며, 토지피복도의 제작과정은 아래 그림 2.61과 같다. 환경공간정보서비스의 토지피복지도는 해상도에 따라서 대분류(30m급), 중분류(5m급), 세분류(1m급)으로 3가지 위계를 가지며, 각각 7개, 22개, 41개 항목으로 분류하고 있다. 환경부 토지피복지도는 다양한 분야에 활용할 정도로 높은 정밀도를 가진 고품질 자료이지만, 제작기간과 갱신주기가 길어 시계열적인 변화를 탐지하는 데에 한계가 있다 (조원호 등, 2019).

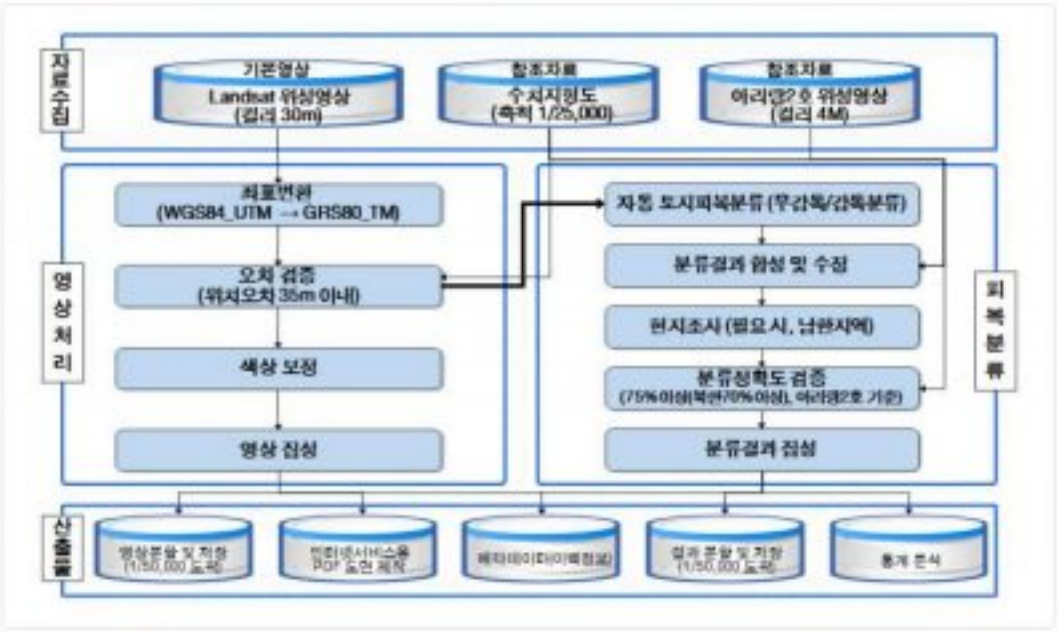


그림 2.61 환경부 환경공간정보서비스에서 제공하는 대분류 토지피복 분류지도 제작흐름도



그림 2.62 환경부 환경공간정보서비스의 해상도별 토지피복 분류지도.

국외 토지피복 관련 서비스는 유럽의 Co-ORdinated information on the Environment (CORINE)에서 제공하는 토지피복도(CORINE Land Cover, CLC), Copernicus에서 제공하는 연간 토지 피복도(Annual 100m global land cover map), 미국의 미국 지질 조사국(United States Geological Survey, USGS)에서 제공하는 국가 토지피복 데이터 베이스(National Land Cover Database, NLCD) 등이 있다.

유럽 CORINE에서 제공하는 토지피복도 CLC는 1985년부터 제작을 시작하여 2000년도부터 최근 2018년까지 6년마다 지속적으로 개선된 지도를 제공하고 있으며 44개의 항목으로 토지를 분류하고 있다. 각 년도마다 발간한 토지피복도는 제작 년도와 전년도의 위성 영상을 주 자료로 채택하여 지도를 제작하였으며 사용된 위성 자료는 그 시기에 따라 각각 다르다. 각 년도에 제작된 토지피복도에 사용된 위성자료의 해상도는 다르지만 제공되는 지도의 해상도는 100m로 통일되고 분류 정확도는 85% 이상을 가진다. 2018년도에 제작된 지도는 Sentinel-2와 Landsat-8을 사용, 두 위성 자료간 빈 공간을 채워주는 갭필링(Gap filling)과정을 거쳐 제작되었으며 유럽의 39개국 영역에 대해 토지피복 분류를 수행하였다. (European Environment Agency (EEA) 제공)

유럽의 Copernicus Global Land Service에서는 유럽국가들 뿐만 아니라 전지구 토지피복도를 100m급 공간해상도로 제작하여 제공하고 있으며 2020년 9월 경 2015-2019년도에 대한 연간 토지피복도를 공개하였다. 이는 관목지대, 숲, 초목, 이끼 지대, 나지, 경작지, 도시를 포함한 9개의 상위 분류 체계 아래 23개의 세부 분류 항목을 두어 토지 피복을 분류하고 있으며 상위 9개 분류 항목에 대한 분류 정확도는 80% 이상이다. 해당 연간 토지 피복도는 Gloval land cover viewr(https://lcviewer.vito.be/)에서 쉽게 확인할 수 있으며 이 외에 구글어스 엔진, Zenodo Open Science, Geo-WIKI 플랫폼들에서도 제공하고 있다. (Copernicus Global Land service, Providing bio-geophysical products of global land surface 제공)



그림 2.63 유럽의 CORINE 토지피복 분류지도

미국의 USGS에서 제공하는 토지피복도 NLCD는 Earth Resources Observation and Science (EROS) 센터에서 주축으로 연방 회사들과 합동으로 제작, 미국 국내 토지 피복을 분류하여 5년을 주기로 제공하고 있다. 이는 Landsat 위성 시리즈를 기반으로 하여 제작되어 30m급 공간해상도를 가지고 있다. NLCD는 물, 나지, 초지, 경작지, 낙엽수림, 상록수림, 도시 등 토지 피복을 총 16개의

주제별 항목으로 분류하며 분류 체계 내에서 나지, 초지, 숲의 경우 해당 영역에 대하여 분류 항목이 차지하는 비율을 퍼센트로 환산하여 제공하고 있다. 토지 피복 분류 정확도는 주제별 항목 분류에서 80% 이상의 정확도를 가진다. 모든 NLCD 데이터는 Multi-Resolution Land Characteristics (MRLC) 웹사이트(http://www.mrlc.gov)에서 제공받을 수 있다. (USGS NLCD 사이트 제공)

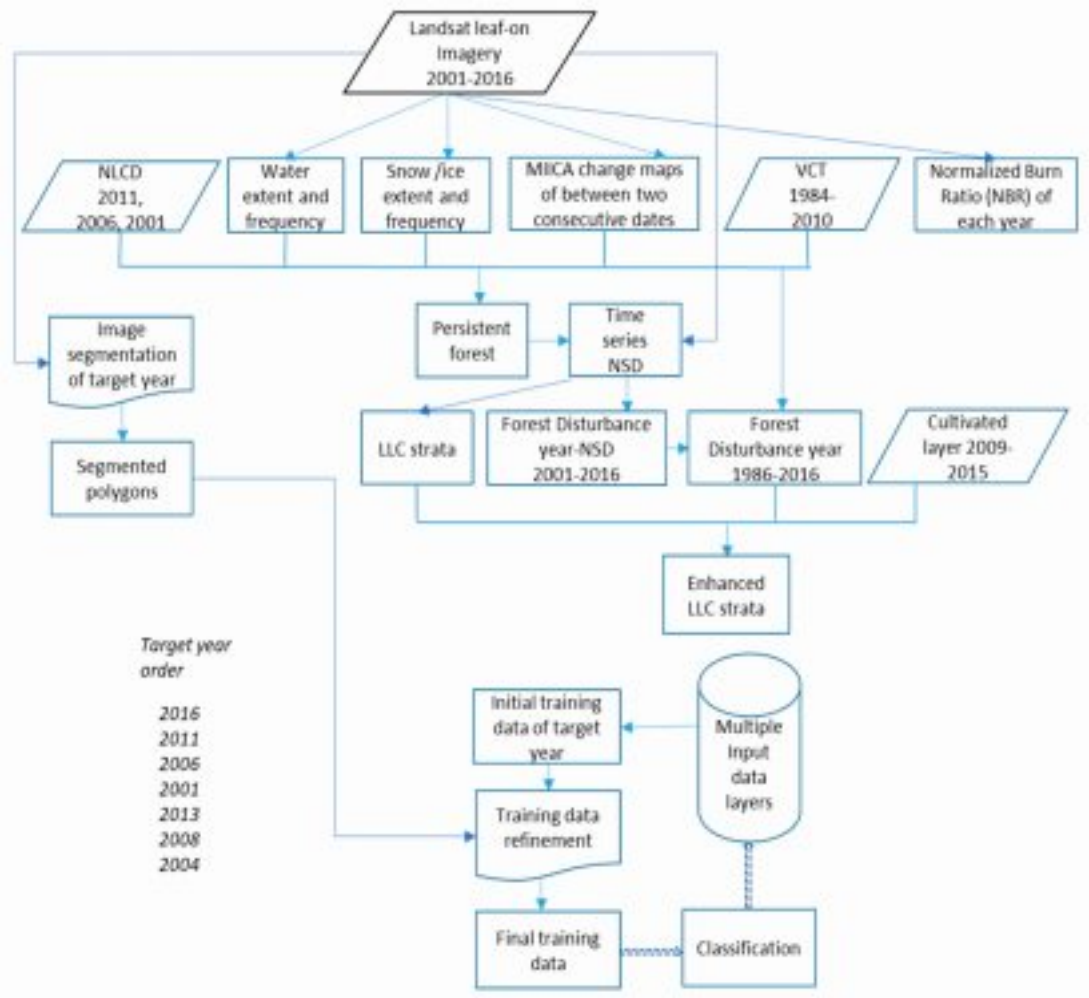


그림 2.64 USGS NLCD 제작 흐름도

외에도 영국에서는 영국 본토에 대하여 1990년, 2000년, 2007년, 2015년에 토지피복 분류지도(Land Cover Map, LCM)를 제작하여 제공하였다. 2015년에 공개된 LCM2015는 Landsat-8 데이터를 기반으로 제작되어 25m급의 공간해상도를 가졌으며 토지 피복은 총 21개의 분류 항목으로 분류되어있다.

국내·외 선행연구의 사례에서 보듯, 고해상도 광학영상을 활용한 토지 피복 분류는 상대적으로 높은 분류율을 보이고 있다. 하지만, 여전히 구름이나 구름 그림자 등에 의한 오염에 취약한 실정이며, 이는 다시기(time-series) 분석을 통해서 해결해야할 필요가 있다. 또한, 밴드가 제한된 다분광 위성의 특성상, 분류 대상의 반사도가 유사한 패턴을 보이면 분류에 어려움이 있다. 이는 보다 고도화된 샘플링, 전처리 기법, 기계학습 등을 통해 해결할 수 있을 것으로 기대된다.

2.2.5 수문량 추정

전 지구적으로 발생하고 있는 태풍, 홍수, 가뭄, 폭설 등에 대한 수문학적 연구가 다양하게 진행되고 있으나, 이들을 분석하는 모형과 현상을 규명하는 방법론에서는 기본적으로 신뢰성 높은 관측자료가 요구된다. 대표적인 관측방법인 관측소 기반의 점 관측방법이 매우 오래전부터 이루어져 왔으나 접근이 어렵거나 관측소의 설치가 불가능한 지역에 대한 관측이 어려워 미계측 지역이 광범위하게 발생한다는 단점이 있었다. 최근에 원격탐사 및 위성관측센서의 발달로 인해 기존의 방법으로는 접근이 어렵거나 충분한 자료가 확보되지 않은 지역에서까지 수문관측자료가 생성되고 있다. 위성 원격탐사로부터 얻은 수문자료는 점 자료가 아닌 공간자료를 제공하고 접근할 수 없는 지역을 포함한 전 지구적 관측을 할 수 있다는 장점이 있다.

수문분야에서는 위성 원격탐사자료를 이용하여 앞서 언급한 바와 같이, 강우, 강설, 토양수분, 증발산 관측 등 기초자료를 수집하는 노력과 함께 태풍, 홍수, 가뭄 등의 관측 및 분석에 관한 다양한 연구가 진행되고 있다. 본 절에서는 위성 원격탐사를 활용한 다양한 연구 중 하천 및 저수지의 수문량 추정에 관한 최근 연구동향을 알아보고 다양한 시각에서 분류하여 원격탐사를 활용한 수문량 추정의 현 상황과 발전방향에 관해 언급하고자 한다.

가) 유출대상별 분류

유출은 크게 지표유출과 지표하유출로 나눌 수 있으며, 지표유출은 그 대상에 따라 유역에서 발생하는 유역 유출, 유역 유출이 모여서 흐르는 하천유출, 하천유출량이 저수지로 흘러 들어가는 저수지 유입으로 나눌 수 있다. 위성 원격탐사를 활용한 유출량 추정분야에서는 하천유출 및 저수지 유입량을 산정하는 연구가 상당부분 진행되고 있으며, 우선 유출 대상별 유출량을 어떤 방법으로 산정하였는지 알아보고자 한다.

먼저 하천을 대상으로한 연구를 살펴보면 위성 원격탐사 영상으로부터 하천의 하폭을 추출하고 기 관측된 유량자료를 이용하여 하폭-유량 관계식을 사용하여 유량으로 환산한 연구가 있었다(Smith et al., 1996, 2008, Pavelsky, 2014). 또한, 위성으로부터 수위를 관측하고 기 구축된 수위-유량 관계식을 이용하여 유량으로 환산하는 연구도 진행되었다(Kouraev et al. 2004, Xu et al., 2004, Leon etl al., 2006).

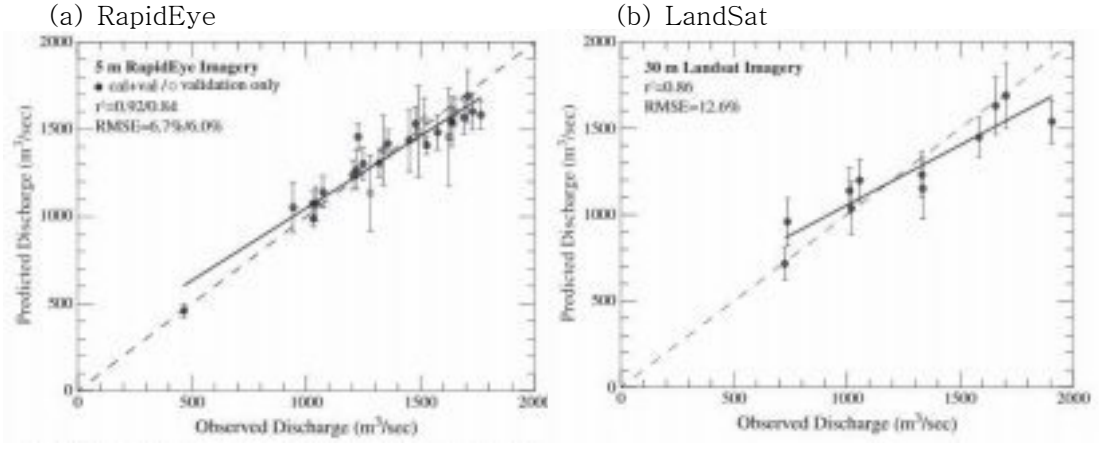


그림 2.65 하폭-유량 관계식을 이용한 유량 환산 회귀모형((a)RapidEye, (b)LandSat)

하천의 수위 및 하폭을 위성으로부터 관측하고 유량과의 관계식을 통해 유량을 산정하는 방법 외에도 Brankenridge et al.(2007)과 Tarpanelli et al.(2013)은 위성에서 수신하는 반사도와 유량과의 관계를 정립하고 유량추정에 이용하였다. Bjerklie et al.(2005)과 LeFavour et al.(2006)은 원격탐사를 이용하여 관측한 하천의 하폭 및 수면경사를 1차원 운동량 방정식인 Manning식에 적용하여 하천 유량을 추정하였다.

다음으로, 위성자료를 이용한 저수지의 유입량 및 저수량에 관한 연구를 살펴보면 저수지의 수위를 측정하고 수위-저수량 관계식을 이용한 연구가 주로 수행되었다(Asdorf et al., 2001, Coe et al., 2004, Daun et al., 2013). 수위 측정이 아니라 수표면적을 이용한 연구도 수행되었는데 Smith et al.(2009)과, Gao et al.(2012)은 위성영상으로부터 수표면적을 추출하여 수위-수표면적-저류량의 관계를 통해 저수지 저류량 및 유입량을 추정하였다.

저수지에 비해 많은 연구가 하천 유출량에 관해 다루고 있었으며, 하폭-유량, 수위-유량, 수위-저류량 등 기 관측된 유량 자료를 이용한 관계식을 정립하려는 연구가 진행되고 있다.

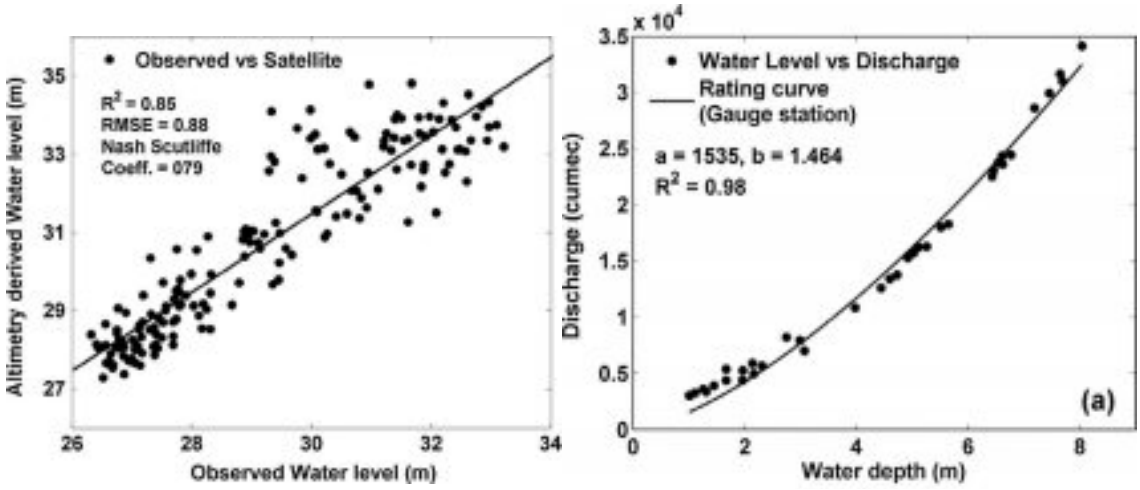


그림 2.66 위성레이더 고도계로부터 산출된 수위를 이용한 유량 추정

나) 관측항목별 분류

유출량을 추정하기 위해 위성으로부터 관측할 수 있는 항목은 크게 하폭, 수표면적, 수위로 구분할 수 있다. 이들을 관측할 수 있는 위성센서의 종류는 크게 가시광영역(Visible), 적외영역(Infrared), 극초단파영역(Microwave), 라디오영역(Radio wave)로 구분할 수 있으며, 각 영역에서 관측할 수 있는 항목이 다르다.

상대적으로 파장이 짧은 가시광, 적외, 극초단파 영역에서는 넓은 지역에서의 영상을 촬영하여 하폭, 수표면적 등의 광역관측을 할 수 있다는 장점이 있지만 고저차를 알 수 없다는 단점이 있다. Xu et al.(2004)과 Pavelsky(2014)는 가시광 영역의 센서를 이용하여 하폭을 추출하였고, MODIS 센서의 적외영역 영상을 이용하여 수표면적 및 하폭을 추출한 연구도 수행되었다(Smith et al., 2008, 2009, Gao et al., 2012). 파장이 긴 라디오영역을 활용하는 Radar Altimetry 센서는 수위 및 지표의 고저차를 관측할 수 있다는 장점이 있지만 관측영역이 좁다는 단점이 있다. Michailovsky et al.(2012)과 Duan et al.(2013)은 ENVISAT 위성의 Radar Altimetry 센서에서 관측한 수위를 이용하여 연구를 수

행하였다. 이러한 센서들의 단점을 보완한 Synthetic Aparture Radar(SAR) 센서는 넓은 지역의 영상과 지표의 고저차를 함께 추출할 수 있다. Bjerklie et al.(2005)는 ERS-1위성의 SAR 영상에서 하폭을 추출하여 활용하였고 많은 연구에서는 TOPEX/Poseidon 위성의 SAR 센서에서 관측한 수위자료를 활용하였다(Asdolf et al., 2001, Coe et al., 2004, Kouraev et al., 2004, Leon et al., 2006, Frappart et al., 2008).

많은 연구에서 하천 및 저수지의 하폭, 수표면적, 수위를 관측하려는 노력이 이어졌으며, 최근에는 SAR 센서와 Radar altimetry 센서를 이용한 수위관측 연구가 수행되고 있다.

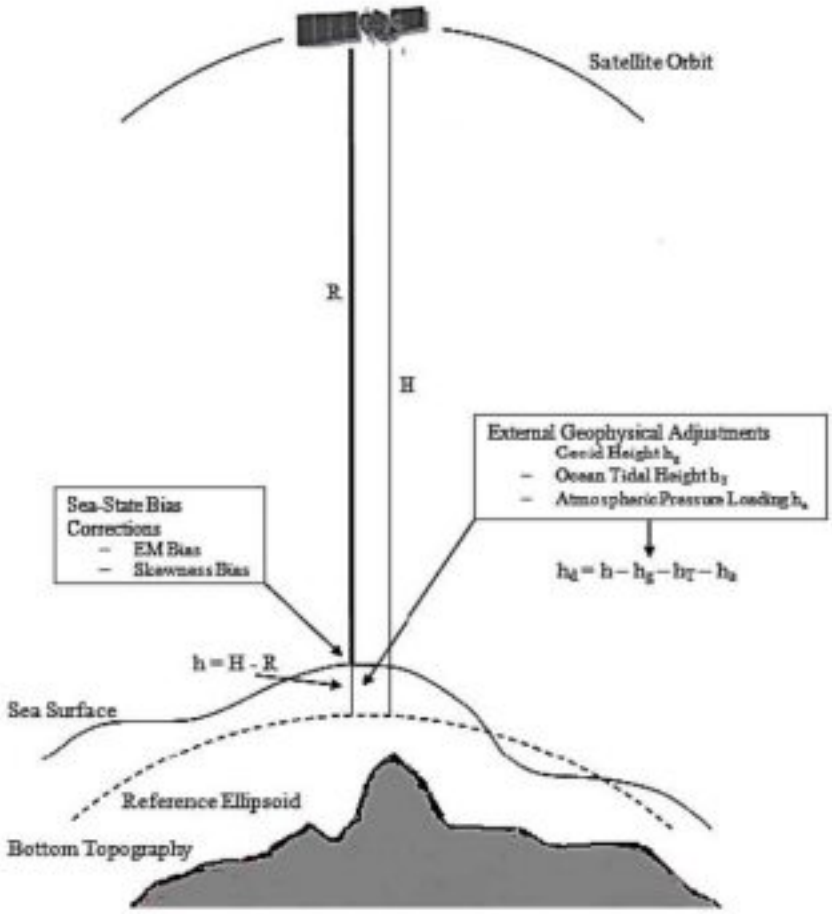


그림 2.67 위성레이더 고도계를 활용한 고도(수위)측정원리

다) 방법론별 분류

유출량을 추정하기 위해 적용할 수 있는 가장 간단한 방법론은 기 관측된 유량자료와의 회귀식을 구성하여 추정하는 방법이다. 가장 보편적으로 사용할 수 있는 회귀식은 수위-유량 관계식이며, 많은 연구들에서 위성 센서에서 관측한 수위값으로부터 기존에 수립된 수위-유량 관계식에 적용하거나 새롭게 수위-유량 관계식을 수립하는 방법을 사용하였다(Coe et al., 2004, Kouraev et al., 2004, Xu et al., 2004, Leon et al., 2006, Smith et al., 2009, Duan et al., 2013). 위성영상에서 추출할 수 있는 항목엔 하폭과 수표면적이 있으며 Smith et al.(1996, 2008)과 Pavelsky(2014)는 하천의 하폭을 이용하여 하폭-유량 관계식을 수립하고 적용하는 방법을 사용하였다. 회귀식 외에도 Bjerklie et al.(2005)과

LeFavour et al.(2006)은 위성센서에서 관측한 하천의 하폭 및 수면경사를 1차원 운동량 방정식인 Manning식에 적용한 사례도 있었다.

위성 원격탐사에서 획득할 수 있는 정보는 광범위한 장점이 있지만 항목에서 제한이 있기 때문에 기 구축된 수위-유량 관계를 이용한 연구가 주를 이루었으며, 하천의 단면 및 제원에 대해 아는 경우 하폭, 수위, 수면경사 등을 Manning식에 적용하고 검증하는 연구가 시도되었다.

최근 위성 원격탐사를 이용한 유출량 산정에 대한 연구가 활발히 이루어지고 있으며, 하천 유출량에 대한 연구가 상당부분 진행되었다. 이와 더불어 저수지 유입량 및 저수량에 대한 연구 또한 진행되고 있다. 과거 가시 및 극초단파 영역에서의 하폭 및 수표면적을 추정하는 수준에서 수위를 직접 관측하는 Radar Altimetry 센서 및 SAR 센서를 이용하려는 연구가 최근 들어 증가하고 있다. 향후, 하천 및 저수지에 대한 다양한 원격탐사 정보를 이용하여 연속방정식, 에너지방정식과 같은 물리적 관계식을 적용한 유출량 추정 연구가 필요할 것으로 판단되며, 계측지역에서의 검증과 미계측 지역에 대한 적용에 관한 연구가 수행되어야 할 것이다.

제 3 장 AI기법을 활용한 수질분석 기법 개발

3.1 서 론

낙동강 수계는 도시, 농촌 지역, 산업 및 공업단지 등 다양한 점오염원과 비점오염원으로부터 영향을 받아왔으며, 빈번한 부영양화 현상이 언급되어온 하천이다 (Yu 외, 2014; 서미진 외, 2019). 수계는 다양하고 복합적인 요인에 의해 영향을 받기 때문에 다양한 수질 인자들을 활용한 지속적인 관리·감독이 필요하다.

기존의 내륙 담수 수질 모니터링은 주로 하천이나 호수를 대표하는 지점에서의 시료 채취를 통해 수질 항목별 농도를 측정하는 방식으로 이루어지고 있으나, 계측 지점의 공간적 빈도가 낮아 수질 인자의 공간적 분포에 대한 정보 획득에 한계가 있다. 또한, 시료 채취에 걸리는 시간이 길어 시·공간적 분포 변화가 심할 경우 수질 인자들의 분포 상태와 이동에 대한 정확한 모의에 어려움이 있을 수 있다. 따라서, 낙동강 수계의 수질 현황을 파악하기 위해 광역 수계에 대한 동시 관측과 동일 지역의 반복관측이 가능한 원격탐사 기반의 모니터링 적용 시 효율적인 관리·감독이 가능하다.

본 과업에서는 낙동강 수계의 댐-보 유역 및 하천 본류에 대하여 인공위성 및 인공지능 기술을 활용하여 클로로필-a, 조류세포수, 부유물질 (혼탁도)에 대한 수질분석기술을 개발하고자 하며, 개발한 알고리즘을 통해 각 수질 인자별 시·공간적 변화를 탐지하고 경향 분석을 위한 통계처리 방안을 제시하고자 한다.

3.2 수질분석 기법 현업 적용성 검토

3.2.1 수질분석 현업적용 가능한 위성 및 분석기법 검토 및 제시

가. 위성 선정 결과

본 과업에서는 수질분석기술 개발을 위해 유럽우주기구(ESA; European Space Agency)에서 제공하는 Sentinel-2 위성을 활용하고자 하였다. Sentinel-2는 궤도를 공유하는 쌍둥이 위성인 Sentinel-2A와 Sentinel-2B를 포함하며 각각 2015년 06월 23일, 2017년 03월 07일에 발사되었다. 취득되는 자료의 시간 해상도는 적도 부근에서 5 일, 중위도에서 2~3일로, 광학 센서인 MSI (MultiSpectral Instrument)를 탑재하고 있다. MSI는 총 13 개의 분광 밴드를 가지고 있으며, 그 중 4 개의 밴드는 10 m, 6 개의 밴드는 20 m, 3 개의 밴드는 60 m의 공간해상도를 가지며, 이는 기타 고해상도 광학 위성에 비해 활용도가 월등히 높다고 판단된다. Sentinel-2A/B 관측자료는 모두 오픈되어 있어 추후 활용에도 문제가 없을 것으로 판단되며, SeNtinel Application Platform (SNAP)이라는 자체 위성자료 처리를 위한 오픈소스 (open source)가 함께 제공되고 있어 현업적용에 많은 장점이 있는 것으로 판단된다.

표 3.1 Sentinel-2A/B의 분광 밴드 특징

밴드	중심 파장대 (nm)		공간 해상도 (m)	활용
	S2A	S2B		
1	442.7	442.2	60	Aerosols
2	492.4	492.1	10	Blue
3	559.8	559.0	10	Green
4	664.6	664.9	10	Red
5	704.1	703.8	20	Red Edge 1
6	740.5	739.1	20	Red Edge 2
7	782.8	779.7	20	Red Edge 3
8	832.8	832.9	10	NIR
8a	864.7	864.0	20	Red Edge 4
9	945.1	943.2	60	Water vapor
10	1373.5	1376.9	60	Cirrus
11	1613.7	1610.4	20	SWIR 1
12	2202.4	2185.7	20	SWIR 2

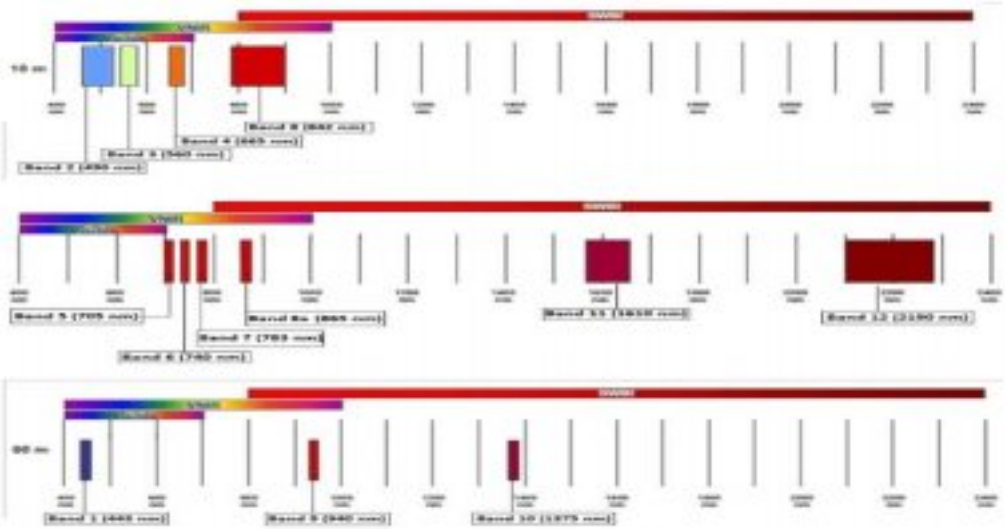


그림 3.1 Sentinel-2 각 밴드별 파장대 및 공간해상도

기존에 Sentinel-2와 함께 고려되었던 위성인 Landsat의 경우 1972년 최초로 발사된 민간 분야의 지구관측위성으로 현재 Landsat 8호까지 발사되었고 현재까지 MSS, TM, ETM+ 등의 탑재체로 설계되었다. 현재 운용중인 7 호는 ETM+, 8 호는 OLI/TIRS 탑재체로 설계되었다. Landsat 7호와 8호는 약 700 km 궤도에서 영상을 촬영하고 있으며, 지구 전체를 촬영하는 데 16일이 소요되며 16일 후에는 동일한 지역을 다시 촬영할 수 있다. Landsat 7호와 8호는 가시광선부터 열적외선까지 다양한 분광 밴드를 가지고 있다. 공간해상도는 가시광선, 근적외선, 중적외선 영역에서 30 m이 해상도를 가지며 촬영 폭은 약 185 km이다. 이처럼 Landsat 위성 영상은 시공간적 해상도 측면에서 본 과업의 수질분석기술 개발에 활용하기에 부적합하다고 판단되어 제외하였다.

표 3.2 Landsat 7호 및 8호 위성 전자광학탑재체의 사양

	Landsat 7 ETM+		Landsat 8 OLI/TIRS	
Launch	April 15, 1999		February 11, 2013	
Orbit	Sun-synchronous		Sun-synchronous	
Altitude	703 km		703 km	
Revisit time	16 days		16 days	
Swath width	185 km		185 km	
Spatial resolution	15 m (Pan) / 30 m (MS)		15 m (Pan) / 30 m (MS)	
Spectral bands (nm)	Blue	441-514	C/A	435-451
	Green	519-601	Blue	452-512
	Red	631-692	Green	533-590
	NIR	772-898	Red	636-673
	SWIR-1	1547-1749	NIR	851-879
	TIR	10310-12360	SWIR-1	1566-1651
	SWIR-2	2064-2345	TIR-1	10600-11190
	Pan	515-896	TIR-2	11500-12510
			SWIR-2	2107-2294
			Pan	503-676
			Cirrus	1363-1384

나. 분석기법 선정결과

국내·외 선행연구 분석 결과, 원격탐사 기반 수질분석 및 환경 분야에서 널리 쓰이며 좋은 성능을 보이는 기계학습 기법으로는 RF (Random Forest), XGB (eXtreme Gradient Boost), CTB (CaTBoost)가 주로 활용되는 것으로 나타났다. 따라서, 본 연구에서는 세 가지 기법 (RF, XGB, CTB)에 대한 분석 결과를 정량·정성적으로 비교·분석하여 최적의 분석 기법을 제시하고자 한다.

다. 현업운영 시나리오 방법론 제시

인공지능 기반 위성영상 수질분석기술 개발의 K-water 자체 운영 서버 내에서의 현업화를 위한 시나리오의 방법론은 아래 흐름도와 같이 제시된다. 이는 K-water 운영 서버 내에서 자동 수행할 수 있는 코드 개발을 포함하고 있으며, 구현코드 언어는 오픈소스 (open source)를 통해 무료로 제공되는 파이썬 (Python) 프로그램을 활용한다. 단계별 세부 항목 및 방법은 다음 단락에 상세히 서술하였다.



그림 3.2 인공지능 기반 위성영상 수질분석기술 모듈화 및 현업화 시나리오 방법론 흐름도

(1) 위성영상 수집 및 처리 체계 구축: 인공지능 기반 위성영상 수질분석기술에 적합한 위성영상을 수집 대상으로 (직)수신 및 수집체계를 구축하여 알고리즘이 지속적으로 구동될 수 있도록 한다. 현재 수질분석기술의 현업 운영을 고려하여 선정된 위성은 오픈소스로 제공되고 있는 Sentinel-2 위성이나, 향후 위성 종류가 추가되고 변경될 가능성을 고려하여 확장 및 수정이 용이하도록 위성영상 수집체계를 설계 및 구축하여야 한다. 본 과업을 통해 제시된 수질분석 알고리즘의 경우에는 Sentinel-2의 20 m 해상도 자료를 활용하였지만, 우리나라 하천의 좁은 수폭을 고려하여 10 m 공간해상도로 제공되는 밴드 값에 대해서는 보다 상세한 정보 제공이 가능하도록 모든 밴드를 10 m 해상도로 실시간 리샘플링 (resampling)하는 기술을 개발하여 활용 시 보다 상세화된 분석이 가능할 것으로 판단된다.

(2) 수질인자별 산출 알고리즘 수행: 클로로필-a, 조류세포수, 부유물질 (혼탁도) 각각의 농도 산출을 위해 개발된 알고리즘을 수행한다. 각 수질인자별로 개발된 인공지능(AI) 기반 분석 알고리즘을 오픈소스인 파이썬 (Python) 기반의 모듈로 구축하여, (1) 과정에서 수집 및 처리된 위성영상이 입력자료로 들어왔을 때 클로로필-a, 조류세포수, 부유물질 농도 분포 및 값이 산출되도록 한다.

(3) 수질분석기술 결과 저장 및 표출: 각 수질인자별로 수행된 알고리즘의 결과를 실시간으로 저장 및 표출할 수 있는 시스템을 개발한다. 본 과업에서 제안된 수질인자분석 알고리즘의 결과 산출물 (output)은 .tif 형태로 저장되도록 고안되었으며, 이를 K-water 자체의 운영 서버 내에서 저장 및 표출 가능한 시스템이 뒷받침되어야 한다. 낙동강 수계 전체 구간에 대한 수질인자들의 분포 현황 및 정량을 확인할 수 있는 시스템 구축을 통하여 효율적인 수질인자 모니터링 방안을 제시하고자 한다.

(4) 시공간적 변화탐지 및 경향 분석: 자동으로 표출되는 수질인자별 분포 결과를 육안으로도 쉽고 빠르게 확인할 수 있도록 시각화하는 단계로, 원격 모니터링의 장점을 살려 하천 전체 구간에 대한 수질인자 (클로로필-a, 조류세포수, 부유물질) 분포 상황을 지도화하여 나타낸다. 인공지능 기반 위성영상 수질분석기술을 통해 .tif 형태로 산출되는 결과물을 Python, ArcGIS, QGIS (Quantum GIS) 등의 프로그램을 통하여 시각화 (mapping)하여 시공간적 변화 탐지에 활용 가능하도록 한다. 이 역시 현업운영을 고려할 시 무료로 제공되는 프로그램인 Python 및 QGIS가 유용하게 활용될 것으로 판단된다. 시각화 기법을 활용한 분포 분석 외에도, 정량적인 분석을 위한 지점별 시계열 경향 분석 및 통계처리가 가능한 시스템을 개발하여 K-water 자체 운영 서버에서 구동할 수 있도록 할 시 수질인자 모니터링에 효과적으로 사용될 수 있을 것으로 판단된다.

3.3 위성영상 수질분석 알고리즘 개발 및 고도화

3.3.1 현장자료 및 위성관측자료 매칭을 통한 수질인자별 분광특성 분석

가. 연구자료

본 연구는 우리나라 남동부에 위치한 낙동강 수계를 한정하여 분석을 수행하였으며, 환경부에서 관리하는 물환경정보시스템(http://water.nier.go.kr/)에서 정의하는 2019년 기준 총 205개 낙동강 관측지점을 기준으로 자료를 분석하였다. 광학 영상으로는 상대적으로 짧은 재방문주기 (5일)와 고해상도 (10 ~ 60 m)의 공간해상도를 가지는 Sentinel-2A/B를 활용하였고, 현장 관측자료는 물환경정보시스템에서 제공하는 < 물환경데이터 - 물환경측정자료 - 수질측정망 - 하천 > 관측자료의 클로로필-a와 부유물질 (혼탁도) 자료와, < 조류정보방 - 측정자료조회 - 과거수질자료> 조류 관찰지점의 조류세포수 (유해남조류 세포) 자료를 활용하였다.

1) 위성 관측자료: Sentinel-2A/B

짧은 재방문주기와 높은 공간 해상도를 가지는 Sentinel-2 영상을 활용하여 수질 인자 추정 연구를 수행하고자 한다. 아래 표와 같이 10 ~ 60 m의 공간해상도로 가시광선 및 red-edge, NIR, SWIR 밴드까지 동시에 제공하고 있어 낙동강 유역의 하천에 대한 수질 분석에 매우 용이하다는 장점을 가진다. 앞서 조사한 선행 연구에서 보여주듯, Sentinel-2 시리즈와 유사한 밴드 구성을 가지는 Landsat 시리즈가 하천 수질 분석에 높은 활용도뿐만 아니라 우수한 성능을 보여 하천 수질 분석에 Sentinel의 적용성 또한 높을 것으로 판단된다. 클로로필-a, 부유물질 등 수표면에서 뚜렷하게 나타나는 분광특성을 가지는 물질의 경우, 높은 공간해상도를 기반으로 상세한 분석이 가능할 것으로 기대된다.

Sentinel-2A/B 관측자료는 유럽 코페르니쿠스 (https://scihub.copernicus.eu/dhus/#/home) 에서 무료로 받을 수 있으나, 관측 기간이 1년 이상 된 Long-term archive data의 경우 자료 제공에 제한을 두고 있다. 따라서 본 연구는 2019~2020년 사이의 관측 자료를 활용하여 분석을 수행하였다. 낙동강 지류가 관측되는 두 개의 타일(tile) - T52SDE, T52SDF - 자료를 활용하여 비교·분석하였으며, 2019. 01. 01. – 2020. 09. 30. 약 2년의 기간 동안 총 107장의 위성자료를 활용하였다.

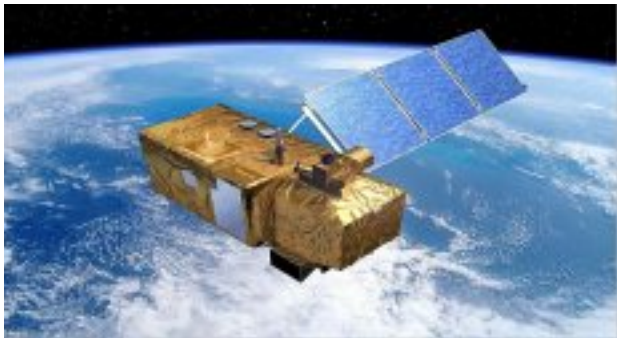


그림 3.3 Sentinel-2 위성 (출처: ESA)

2) 현장 관측자료: 물환경측정망 (하천 관측 자료)

환경부 산하 물환경정보시스템에서 제공하는 수질측정망 자료 및 조류 관찰지점 자료는 하천·호소 등 공공 수역의 수질 및 수생태계의 실태를 파악하기 위해 운영하는 물환경측정망의 설치, 운영, 관리에 필요한 전반적 사항을 지정하는데에 그 목적이 있으며, 「환경정책기본법」 제22조(환경상태의 조사·평가 등) 등의 법적 근거를 가지고 있다. 물환경정보시스템에 따르면, 크게 수질측정망, 자동측정망, 방사성물질 측정망, 비점오염물질 측정망, 총량 측정망, 퇴적물 측정망, 생물 측정망으로 구성되어있으며, 이 중 수질측정망 총 1,936개소로 하천 (683개소), 호소 (191개소), 농업용수 (955개소), 도시관류 (37개소), 산단하천 (70개소)으로 구분되어 제공되고 있다. 본 연구에서는 이 중 하천 측정망 자료를 분석에 활용하였다.

하천 측정망은 전국 4대강 유역에 걸쳐 683개소로 구성되어있으며, 유역(지역)환경청, 물환경연구소, 각 시·도, 한국 수자원공사 및 농어촌공사에서 각각의 지점을 관리하고 있다. 측정요소는 총 54 개로, 수심, 수온 등을 비롯하여 산소 요구량 (DO), 생/화학적 산소 요구량 (C/BOD), 클로로필-a, 부유물질 등 수질과 관련한 다양한 측정값을 제공하고 있다. 자료는 각 측정 지점에 대하여 일, 월, 연평균의 형태로 열람할 수 있으며, 본 연구에서는 일자료를 활용하여 위성관측자료와 비교·분석하였다.

본 자료에서 세부 관측 시간에 대한 자료가 제공되지 않아, Sentinel-2A/B의 촬영시간과의 차이를 고려하지 않고, 일별 수질 관측 값이 일정하다는 가정하에 매칭 (match-up)하여 비교·분석하였다. 수질관측망의 경우 1996년부터 제공되고 있으나, 위성자료의 제공 기간과 맞추어 대략 과거 2년 (2019.01 ~ 2020.09) 동안 낙동강 유역의 201개 지점에서 추출한 관측자료를 활용하여 분석을 수행하였다.



그림 3.4 수질측정망 운영 체계



그림 3.5 물환경정보시스템 수질측정망 자료화면

나. 연구방법

1) 인공지능 기법

본 과업에서는 수질 및 환경 분야에서 널리 활용되고 있는 기법인 RF (Random Forest), XGB (Extreme Gradient Boost), CTB (CaTBoost) 세 가지 기법을 활용하여 수질 분석을 수행하였다.

Random forest (RF)는 분류 및 회귀 분석 등에 사용되는 앙상블 학습 방법의 일종으로, 훈련 과정에서 구성한 다수의 결정 트리로부터 부류 (분류) 또는 평균 예측치 (회귀 분석)를 출력함으로써 동작하는 모델이다. 랜덤 포레스트를 구성하고 있는 각가의 결정 트리는 동일한 확률분포를 가지지만 독립적으로 구성되어있다. 훈련자료를 임의적으로 선택하여 입력 변수의 조합을 임의적으로 선택함으로써 이상치 (outlier)의 영향을 최소화하고 변수의 상대적인 중요도, 오차 등을 내부적으로 계산할 수 있다. 변수 중요도는 out-of-bagging (OOB)을 통해 변수가 분류에 포함되지 않았을 때의 오차를 추정함으로써 산출된다. RF는 월등히 높은 정확성과 간편하고 빠른 학습 및 테스트 알고리즘, 그리고 임의화를 통한 좋은 일반화 성능 등의 장점으로 인해 최근 다양한 분야에서 사용되고 있다. 본 과업에서는 프로그래밍 언어 Python 기반 Scikit-learn 라이브러리 (sklearn.ensemble.RandomForestRegressor)를 사용하여 구축하였다.

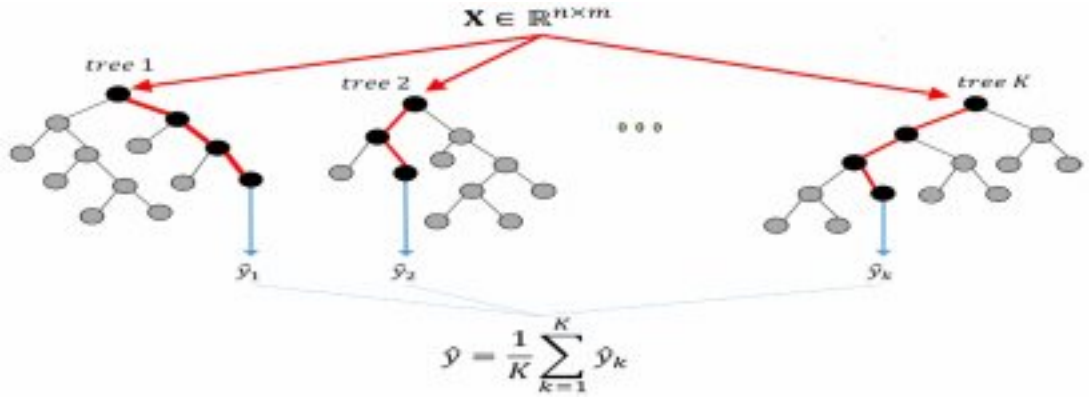


그림 3.6 Random Forest (RF) 모식도

eXtreme Gradient Boosting (XGB)은 gradient boosting 알고리즘을 분산환경에서도 실행할 수 있도록 구현해놓은 라이브러리로, 회귀 및 분류 문제를 모두 지원하며 성능과 자원 효율이 좋아 각광받고 있는 알고리즘이다. XGB 또한 여러 개의 의사결정 트리를 조합하여 사용하는 앙상블 알고리즘으로, 예측 변수를 차례로 추가하고 이전 모델을 수정한다. 그래디언트 부스팅 (gradient boosting)은 residual fitting으로 쉽게 이해할 수 있는데, 아주 간단한 모델 A를 통해 y를 예측하고 남은 잔차 (residual)를 다시 B라는 모델을 통해 예측하고, 모델 A+B를 통해 y를 예측한다면 A 보다 나은 B 모델을 만들 수 있게 된다. 이러한 과정을 반복하게 되면 잔차 (residual)는 계속 줄어들게 되고, 훈련 데이터셋을 잘 설명하는 예측 모형을 만들 수 있게 된다. 하지만 이러한 방식은 bias는 상당히 줄일 수 있지만, 과적합 (overfitting)이 일어날 수도 있다는 단점이 있다. 이처럼 표준 GBM (Gradient Boosting Machine)의 경우 과적합 규제 기능이 없으나 XGB는 자체에 과적합 규제 기능을 지니고 있어 좀 더 강한 내구성을 지니는 모델이며, GBM 대비 빠른 수행시간을 가진다. 본 과업에서는 프로그래밍 언어 Python 기반 라이브러리(xgboost)를 사용하여 구축하였다.

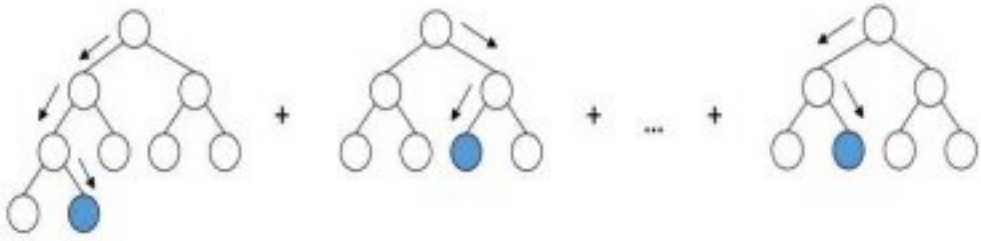


그림 3.7 eXtreme Gradient Boosting (XGB) 모식도

CaTBoost (CTB)는 최근에 개발된 의사결정 나무 기반의 부스팅 (boosting) 기법 중 하나로, 부스팅 기법에서 자주 발견되는 한계점인 데이터에 과적합 (overfitting)하는 문제를 완화한 기법이다 (Huang 외, 2019). CTB의 가장 큰 특징은 범주형 변수를 다루는 데에 특화되어 있다는 것이다. 일반적으로 인공지능 기법에서 범주형 변수를 다루는 대표적인 방법은 One-Hot encoding으로 범주형 변수를 0과 1을 통하여 표현할 수 있도록 이진형 변수의 조합으로 변환하는 반면, CTB는 Target statistics라고 불리는 각 범주별로 예상되는 예측값으로 변환하는 기법을 적용하여 정보 손실을 최소화하는 것으로 알려져 있다 (Prokhorenkova 외, 2018). XGB와 더불어 CTB는 level-wise로 트리를 만들어나가는데, 기존의 부스팅 모델이 일괄적으로 모든 훈련 데이터를 대상으로 잔차 계산을 했다면, CTB는 일부만 가지고 잔차 계산을 하여 모델을 만들고, 그 뒤의 데이터의 잔차는 이 모델로 예측한 값을 사용한다는 특징을 가진다. 본 과업에서는 Python 기반 라이브러리(catboost)를 사용하여 구축하였다.

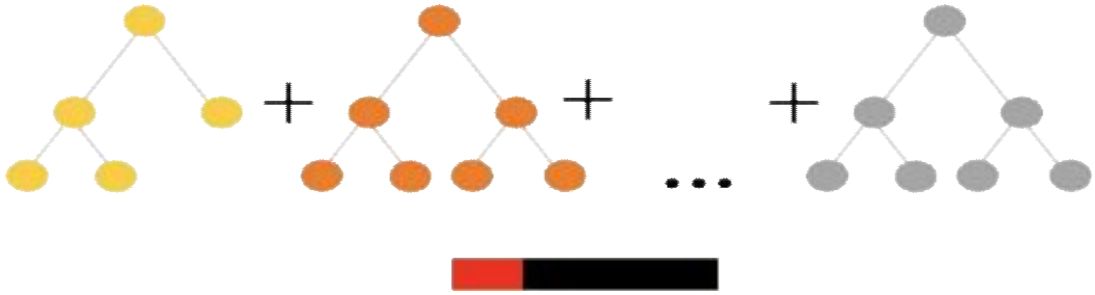


그림 3.8 CaTBoost (CTB) 모식도

2) 데이터 및 연구 방법 요약

본 연구에서는 클로로필-a, 조류세포수, 부유물질 (혼탁도) 세 가지 주요 수질인자를 대상으로 하여, 낙동강 유역에 대하여 2019년 01월부터 2020년 09월까지 대략 2년간의 연구 기간에 대하여 인공지능 기반 위성영상 수질분석기술 개발을 진행하였다. Sentinel-2A/B Level2A 위성원격반사도 (remote sensing reflectance, Rrs)를 활용하여 수질인자별 농도 추정 알고리즘을 개발하였으며, 본 과업의 공간적 분석 범위와 본 과업에서 제시하고 있는 알고리즘의 전체 연구흐름도는 아래 그림에 나타내었다. 이때 사용된 인공지능 기법으로는 Random Forest (RF), eXtreme Gradient Boosting (XGB), CaTBoost (CTB)가 있다.

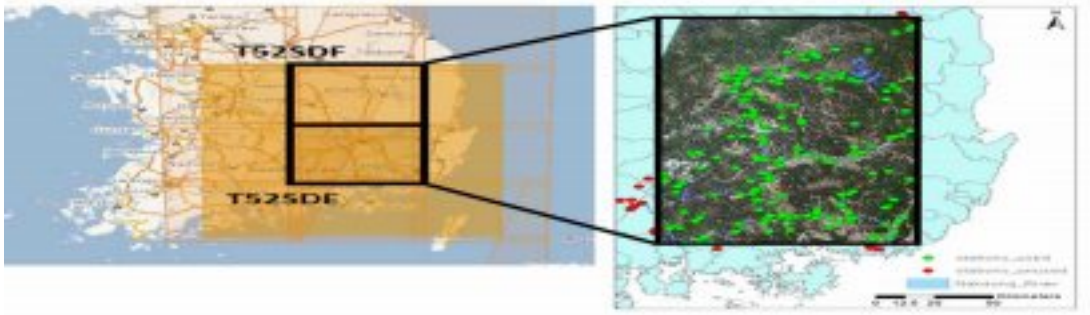


그림 3.9 본 과업의 공간적 분석 범위

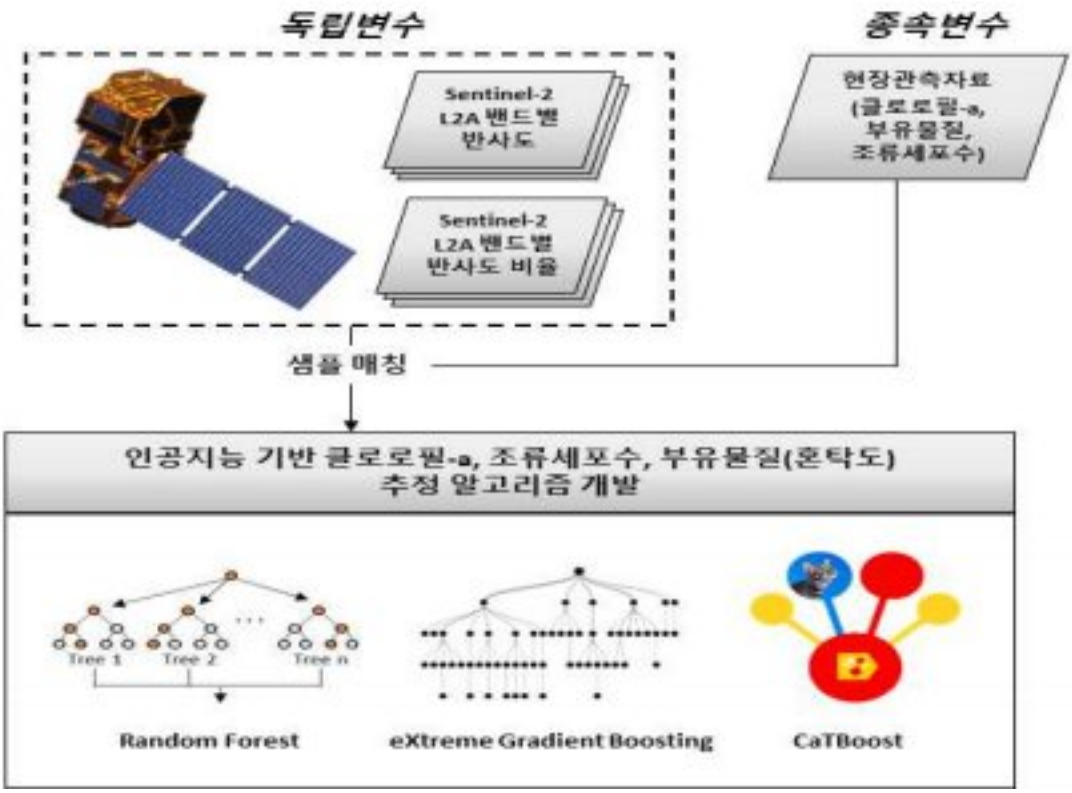


그림 3.10 본 과업에서 제시한 수질인자 추정 알고리즘 흐름도

다. 데이터 전처리 및 위성자료 후처리

1) 현장관측자료의 문제점 및 전처리

수질측정망 및 조류 관찰지점 자료는 일별 자료로, 날짜 정보까지만 제공이 되고 정확한 관측 시간에 대한 정보가 누락되어있어 위성자료와의 정확한 매칭이 어렵다. 수질 관측값과 더불어 관측지점의 좌표 (위·경도)를 함께 제공하고 있는데, 위·경도 좌표가 실제 하천 상에 위치하지 않은 경우가 많다. 따라서, 본 과업에서는 일차적으로 현장관측자료의 전처리를 수행하였으며, 이때 크게 세 가지 조건에 근거한 전처리가 수행되었다.

첫 번째로는, 강폭의 중앙에 위치하여 20 m의 해상도의 Sentinel-2 위성영상을 활용하여 분석하는데 이상이 없는 지점에 대해서는 추가적인 전처리 없이 그대로 사용하였다.



그림 3.11 정상 활용 가능 지점에 대한 처리 예시

두 번째 조건은 지리적 오차에 대한 전처리이다. 관측지점이 수변에 위치하거나 수심이 얕아 하상이 드러나는 곳에 있을 경우 20 m 해상도로 분석 시 다른 토지 피복에 의한 반사도의 오염이 예상되는 지역으로, 다시기 위성관측과의 비교 후 수체로 판단되는 가장 가까운 지점으로의 이동을 통한 전처리를 수행하였다. 수변이 아닌 멀리 떨어진 지점에 위치하는 경우는 관측지점에 대한 정보 업데이트가 되지 않은 것으로 판단하고 분석에서 제외하였다.



그림 3.12 지리적 오차에 대한 전처리 예시

마지막 조건은 위성관측에 대한 전처리로, 다리나 도로 등의 구조물에 의해 위성관측이 불가능한 지점의 경우, 강의 상류 및 하류 지점으로 20 m 이상 평행이동을 통한 전처리를 수행하였다. 이때 다리나 댐, 보 등 구조물 위에 관측지점이 위치하였을 때 이러한 구조물의 상·하류 수체의 수질 현황은 상당한 차이가 있을 것이라는 가정하에 실제 취수 위치를 알 수 없으므로 구조물을 기준으로 상·하류 두 지점으로의 이동을 통한 전처리를 수행하였다.

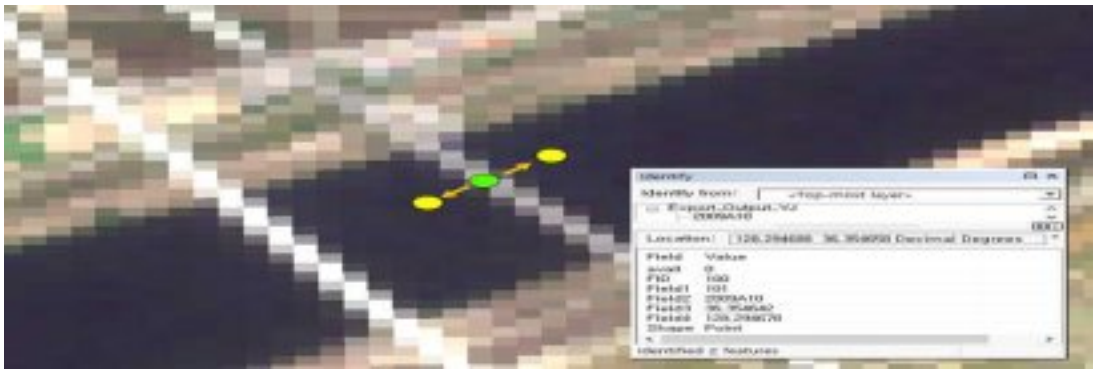


그림 3.13 위성 관측에 대한 전처리 예시

위와 관련된 사항에 대하여 낙동강물환경연구소 측에 문의 결과, 관측 위치의 경우 시간이 지나면서 불확실해질 수 있으며 채수 시간의 경우 하루 이틀 사이에 수질이 크게 변하지 않는다는 가정하에 따로 제공하지 않는다는 답변을 얻었다.

2) 위성자료의 후처리

광학 위성자료의 경우, 구름에 의한 오염에 취약하다는 단점이 있다. 따라서, 본 과업에서는 Sentinel-2 공식 구름 마스킹 알고리즘을 활용하여 구름에 의한 오염이 의심되는 픽셀은 분석에서 제외하는 후처리를 수행하였다. 알고리즘은 다음 그림과 같이 여러 단계에 걸쳐 수행되며, 해당 알고리즘을 따라서 후처리를 수행하였다.

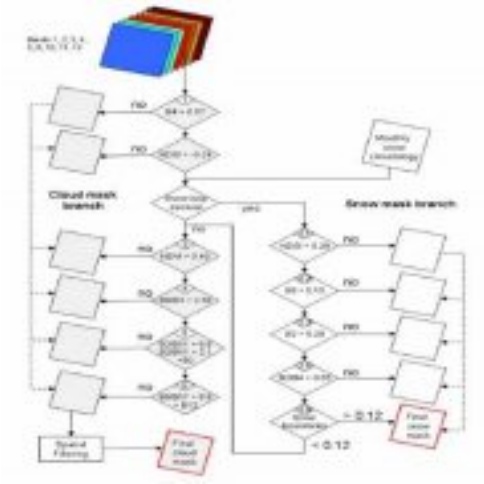


그림 3.14 Sentinel-2A/B cloud masking algorithm diagram

3) 3 * 3 픽셀 윈도우 활용한 스무딩(smoothing) 및 오버샘플링 (oversampling)

위의 과정에 따라 일차적으로 현장자료에 대한 전처리를 거친 후 추정 모델의 불확실성을 줄여주기 위해 위성자료와의 매칭 시 3 * 3 픽셀 영역에 대한 창 (window)을 활용한 smoothing 및 오버샘플링 (oversampling) 방법을 적용하였다. 이는 현장자료와 위성자료 사이의 1:1 매칭에서 나타나는 공간적 불확실성을 완화하고 고농도 샘플이 상대적으로 적은 수질 인자의 특성에 의해 발생하는 추정 모델의 한계점을 개선하기 위한 방법으로 채택되었다.

이때 20 m 공간 해상도 상에서 3 * 3 픽셀은 60 m * 60 m의 상당히 넓은 지역을 대표하기 때문에, 다시기 위성영상과의 비교를 통해 지속적으로 다른 토지 피복의 영향을 받지 않는 지점에 대해서만 윈도우를 적용하였다고 하더라도 이상치가 발생하여 모델에 오히려 좋지 않은 영향을 줄 수 있다고 판단하여 각 윈도우 별로 이상치를 제거하는 과정을 거쳤다. 이상치를 탐색하여 제거하기 위해서는 'generalized ESD (Extreme Studentized Deviate) test', 즉 gesd 방법을 거쳤으며, 이는 그럽스 T-검정을 일반화한 방법으로 여러개의 이상치에 대한 검정이 가능하다. 3 * 3 윈도우 내의 픽셀들의 밴드별 반사도끼리의 gesd 테스트를 거치면서 이로 인해 발생할 수 있는 오류를 최소화하고자 하였다.

대부분의 자연현상은 균등한 분포가 아닌 특정 조건에 편향된 분포를 가지기 때문에, 이러한 불균형을 해결해주기 위해 샘플의 빈도가 적은 구간에 대하여 임의로 샘플을 조정하여 데이터셋 내의 균형을 맞춰주는 오버샘플링 (oversampling) 기법이 최근 자주 사용되고 있다 (Park et al., 2019). 각 수질 인자 (클로로필-a, 조류세포수, 부유물질)별 샘플의 농도 분포를 고려하여 샘플이 적은 구간 (고농도 샘플)에 대하여 오버샘플링을 수행하였는데, 이때 관측지점 근처의 픽셀들은 관측지점에서의 관측값과 유사한 값을 가진다는 가정하에 3 * 3 윈도우를 활용하여 샘플을 불려주었다. 오버샘플링을 통하여 불려진 샘플은 모델 구축 시 샘플 분포의 균형을 맞춰주어 모델의 모의 능력 향상시키기 위함으로, 모델의 훈련 시에만 사용되며 모델 검증 시에는 제외하여 검증의 타당성을 확보하였다.

오버샘플링은 각 수질 인자별 전체 샘플의 개수가 N 개일 때 농도를 기준으로 내림차순으로 정렬 시 상위 10 % 에 해당하는 샘플 개수 (즉, 1/N 개)에 대해서만 적용하였다. 3 * 3 윈도우를 활용한 smoothing 및 oversampling 방법은 아래 그림의 예시를 통해 상세하게 설명된다. 먼저 스무딩 (smoothing)의 경우, 9 개의 픽셀 중 이상치 (outlier) n 개를 제거한 (9-n) 개 픽셀의 각 반사도 값을 평균을 통해 1:1 매칭에서 나타날 수 있는 불확실성을 제거해주었다. 아래 그림의 예시에서, 1:1 매칭 시 얻게 되는 중심 픽셀 P5에서의 밴드값 대신 (P1+P2+P3+P4+P5+P8+P9)/7의 값을 얻게 된다. 오버샘플링 (oversampling)의 경우, 9 개의 픽셀 중 이상치 n 개를 제거한 (9-n) 개 픽셀의 반사도 값을 각각 모두 취해 (9-n) 개의 샘플로 불려주어 고농도 샘플의 비율을 높여주는 역할을 한다. 다만, 검증 시에는 오버샘플링 된 샘플은 제외하였다. 아래 그림의 예시에서, 1:1 매칭 시 P5 한 픽셀에 대해서만 얻을 수 있는 고농도 샘플을 P1, P2, P3, P4, P5, P8, P9 (9-n) 개에 대한 샘플을 획득할 수 있다.



그림 3.15 중심 픽셀 (P5)과 인근 3 * 3 픽셀 윈도우 (P1 ~ P9)의 예시

이처럼 3 * 3 픽셀 창을 활용한 오버샘플링 기법 적용 시 고농도 샘플에 대한 보완이 이루어져 고농도 자료에 대한 모의력 향상에 기여하였다. 오버샘플링 전과 후의 각 수질 인자별 농도의 분포는 아래 그림과 같으며, 위에서 언급한 농도를 기준으로 상위 1/N 개의 샘플에 대하여 오버샘플링을 적용하였을 때 기준 농도 값은 각각 클로로필-a 40 mg/m^3, 부유물질 12 mg/L 로 선정되었으며, 아래 그림에 붉은색 상자로 표시하였다. 오버샘플링을 적용한 후 로그 변환을 통해 샘플의 분포를 조정한 후 모델링을 진행하여 성능을 개선했다. 조류세포수의 경우, 오버샘플링 기법을 적용하기에 충분한 샘플이 확보되지 않아 오히려 불확실성이 가중되는 것을 방지하기 위해 원본 샘플을 통한 모델링을 진행하였다.

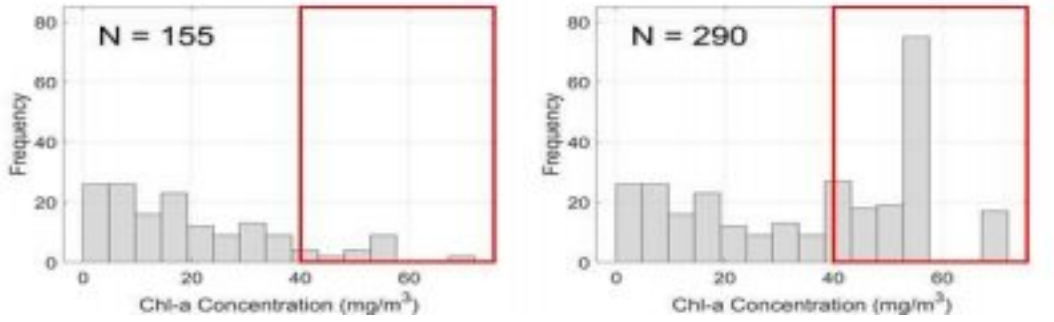


그림 3.16 원본 데이터의 클로로필-a 농도 분포와 오버샘플링 후의 농도 분포 비교

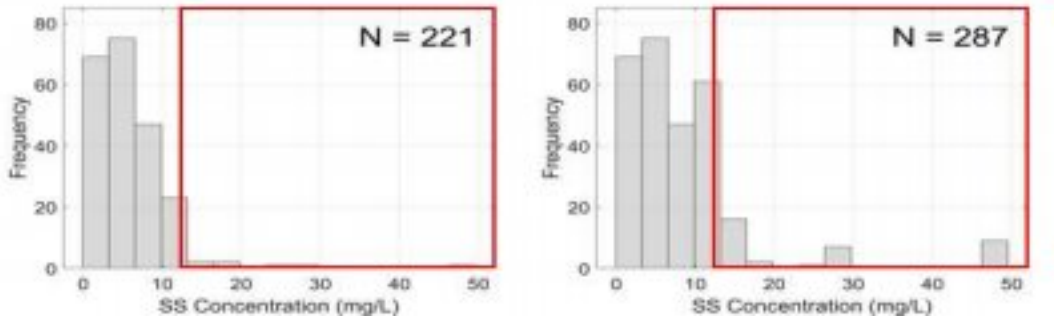


그림 3.17 원본 데이터의 부유물질(혼탁도) 농도 분포와 오버샘플링

라. 분석 모델 및 검증 방법

1) 분석 모델

모든 전처리 및 후처리 결과, 클로로필-a를 위한 샘플 290 개 (검증 시 155 개, 오버샘플링된 샘플은 제외), 조류세포수를 위한 샘플 17개, 그리고 부유물질 (혼탁도)을 위한 샘플 287 개 (검증 시 221 개)가 확보되었다. 훈련자료의 개수가 적어 n 개의 데이터에서 1 개를 검증 셋으로 정하고 나머지 (n-1) 개의 샘플로 훈련을 n 번 반복하는 방법인 Leave-One-Out Cross-Validation (LOOCV)을 활용하여 모델을 정량적으로 검증하였다.

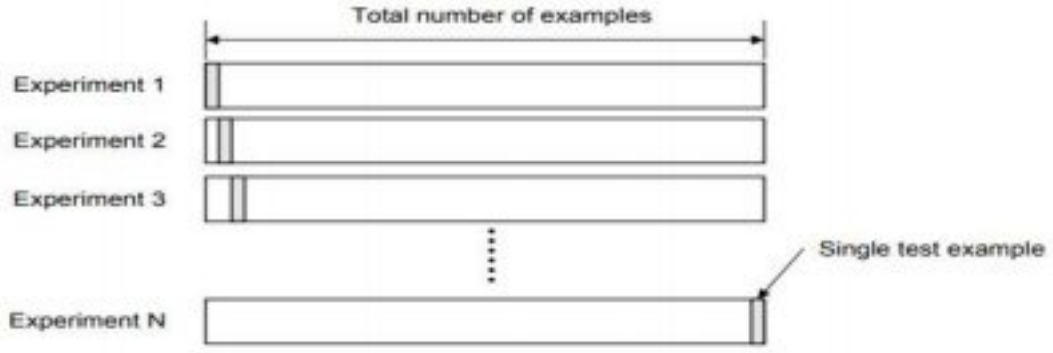


그림 3.18 본 과업에 사용된 검증 방법인 LOOCV의 원리 설명도

2) 모델 성과 개선: 변수 스케일링 및 분포 변환

선행 연구에서 주로 활용하는 가시 영역 밴드(R, G, B) 이외에 red-edge 밴드, NIR 밴드, 그리고 SWIR 밴드도 함께 활용하여 모델을 구축하였다. 인공지능 기반의 수질 인자 추정 알고리즘 개발 시 모델에 적용할 입력변수를 잘 선택하는 것은 모델의 성능에 직접적인 영향을 미치는 과정이므로, 각 수질 인자별 모델 구축을 위해 사용된 변수는 Recursive Feature Elimination (RFE) 알고리즘을 통한 변수 선택 (feature selection)을 거쳐 선정하였다.

이때, 변수 선택 과정은 첫 번째 모델의 성능을 baseline으로 참고하여 변수의 구성을 다르게 하여 모델의 최종 성능을 개선하는 과정의 하나로, 모델 특성 및 데이터 특성 등에 따라 적합한 전처리 과정이 다르므로 여러 번의 시도를 통해 모델의 성능을 향상할 수 있다. RFE는 Backward 방식 중 하나로, 모든 변수를 먼저 다 포함 시킨 후 반복해서 학습을 진행하면서 중요도가 낮은 변수를 하나씩 제거하는 방식으로, 본 과업에서 입력변수를 선정하기 위하여 초기에 총 24개의 밴드 반사도 및 밴드비 (20 m 해상도로 제공 가능한 밴드 2 ~ 밴드 12 (밴드 8 제외) + 이 중 VIS과 red-edge에 해당하는 밴드 간의 밴드비 (밴드 2 ~ 밴드 7 사이의 밴드비))를 변수로 사용하였다. 본 연구에서, RFE를 통해 선정된 클로로필-a, 조류세포수, 그리고 부유물질 (혼탁도) 추정 모델의 입력변수는 각각 아래와 같다.

표 3.3 RFE를 통해 선정된 각 수질인자별 추정 모델 추정 변수

Band	클로로필-a	조류세포수	부유물질(혼탁도)
Band 2 - Blue	■		
Band 3 - Green	■	■	■
Band 4 - Red			
Band 5 - Vegetation red edge			
Band 6 - Vegetation red edge			
Band 7 - Vegetation red edge		■	
Band 8A - Narrow NIR	■	■	
Band 11 - SWIR	■		■
Band 12 - SWIR	■		■
Band 6 / Band 7			
Band 5 / Band 7			■
Band 4 / Band 7			■
Band 3 / Band 7			
Band 2 / Band 7			■
Band 5 / Band 6			
Band 4 / Band 6	■		
Band 3 / Band 6			
Band 2 / Band 6			
Band 4 / Band 5	■		■
Band 3 / Band 5	■		■
Band 2 / Band 5	■		■
Band 3 / Band 4			
Band 2 / Band 4	■		■
Band 2 / Band 3			

3) 모델 검증

박성욱 등 (2018)에서 제시한 세 가지 경험식 기반의 4대강 주요 수계 대상 클로로필-a 추정 알고리즘과의 비교를 통하여 본 과업에서 제시한 알고리즘의 정확도와 정량적인 비교를 수행하였다.

- (1) T07: Tzortziou et al (2007)
- (2) M09: Moses et al (2009)
- (3) M12: Mishara and Mishara (2012)

또한, 실제 현업에 활용되고 있는 환경과학원의 물환경정보시스템에서 제공하고 있는 낙동강 수계의 수질 분석 결과와의 공간분포를 비교하여 본 과업에서 제시하는 수질 추정 알고리즘과의 유사성을 정성적으로 확인하였다.

$$T07Model: C_{chl\text{-}a} \propto R_{rs}^{-1}(665) \times R_{rs}(560) \quad (1)$$

Source: Tzortziou et al.(2007)

$$M09Model: C_{chl\text{-}a} \propto R_{rs}^{-1}(665) \times R_{rs}(705) \quad (2)$$

Source: Moses et al.(2009)

$$M12Model: C_{chl\text{-}a} \propto \frac{[R_{rs}(705) - R_{rs}(665)]}{[R_{rs}(705) + R_{rs}(665)]} \quad (3)$$

Source: Mishara andMishara(2012)

그림 3.19 결과 비교에 활용한 세 가지 경험식 기반 클로로필-a 추정 알고리즘

3.3.2 인공지능 기법 활용 수질 인자별 분석 알고리즘 도출

1) 모델 훈련 및 검증 결과

모델링 결과, 클로로필-a는 RF, XGB, CTB 세 모델에서 각각 결정계수 (R^2) 0.64, 0.66, 0.67 수준으로 세 가지 모델 모두 상당히 높은 수준의 추정력을 보였다. 3 * 3 픽셀 창을 활용한 오버샘플링 기법을 적용함으로써 고농도 샘플에 대한 보완이 이루어졌기 때문에, 기존의 저농도에 편향된 샘플로 훈련한 모델 대비 고농도에서 저추정하는 경향이 다소 개선된 것을 확인하였다. 이전의 방법론에서도 서술한바 있듯이, 오버샘플링 된 샘플의 경우에는 모델 검증 시에는 제외하여 검증의 타당성을 확보하였다.

조류세포수는 유해남조류인 마이크로시스티스 (Microcystis), 아나베나 (Anabaena), 오실라토리아 (Oscillatoria), 아파니조메논 (Aphanizomenon) 네 가지 속 (genus) 세포수의 합으로 나타나지만, 위성 자료와의 매칭 후 아파니조메논 속의 경우 Sentinel-2A/B 반사도 값과의 상관성이 매우 떨어져 모델 훈련에 있어 혼란을 주어 최종 모델 구축 시에는 이를 제외한 세 가지 속 세포수만을 사용하였다. 조류세포수의 경우, 관측 위치가 전국 여덟 개 보에 위치하기 때문에 본 과업의 연구기간 (2019년 1월 ~ 2020년 9월)의 Sentinel-2 영상 날짜에 맞추어 확보할 수 있는 샘플의 개수가 매우 한정적이다. 현장자료와 위성영상 자료와의 매칭 후 확보된 조류세포수 농도 범위는 0 cells/ml에서 100,000 cells/ml까지로 매우 다양한 분포를 보이나, 충분한 양의 샘플을 확보하지 못하여 1,000 cells/ml 이상의 고농도에 대해서는 극히 부족한 샘플로 인해 모델링이 어려워 제외한 후 진행하였다. 모델 구축에 사용된 샘플의 수는 총 17 개 관측값으로 오버샘플링 기법을 적용하기에는 원본 데이터의 양이 충분하지 않아 오히려 불확실성을 가중할 수 있다고 판단되어 조류세포수의 경우에는 오버샘플링 단계를 생략하였다. 그 결과 RF 모델의 결정계수 (R^2)는 0.65, XGB 0.61, CTB 0.58로 상당한 수준의 추정력을 보였으며, 이는 추후 샘플 보완을 통해 개선할 여지가 있을 것으로 판단된다.

부유물질 (혼탁도)의 경우, RF의 경우 R^2 = 0.31, XGB = 0.24, CTB = 0.16 수준으로 클로로필-a와 조류세포수에 비해 떨어지는 성능을 보였다. 부유물질 역시 고농도 데이터가 충분하지 못하여 오버샘플링 기법을 적용하였지만, 클로로필-a에 비해 고농도 샘플의 비율이 상대적으로 매우 부족해 오버샘플링의 효과를 충분히 발휘하지 못한 것으로 판단된다. 이 역시 추후 샘플 보완 시 개선 가능한 부분으로 보이며, 부유물질 역시 검증 시에는 오버샘플링 되지 않은 원본 샘플만을 사용하여 검증의 타당성을 확보하였다.

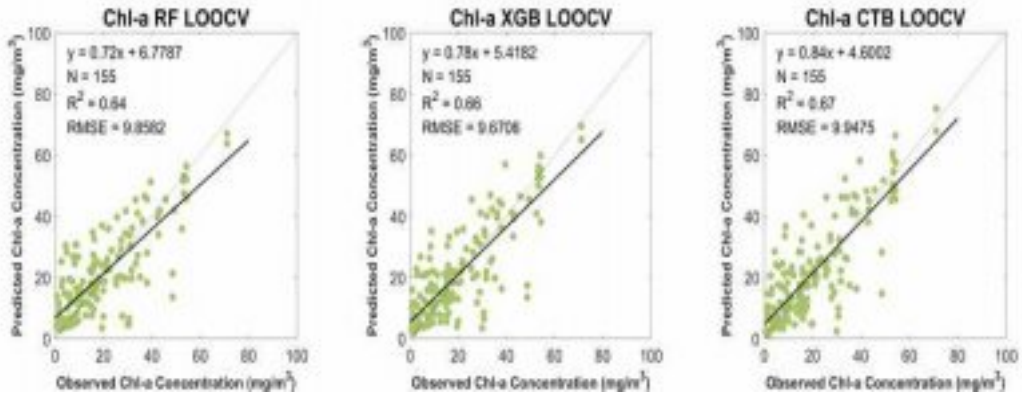


그림 3.20 RF, XGB, CTB 활용 클로로필-a 농도 추정 결과 (LOOCV) 비교

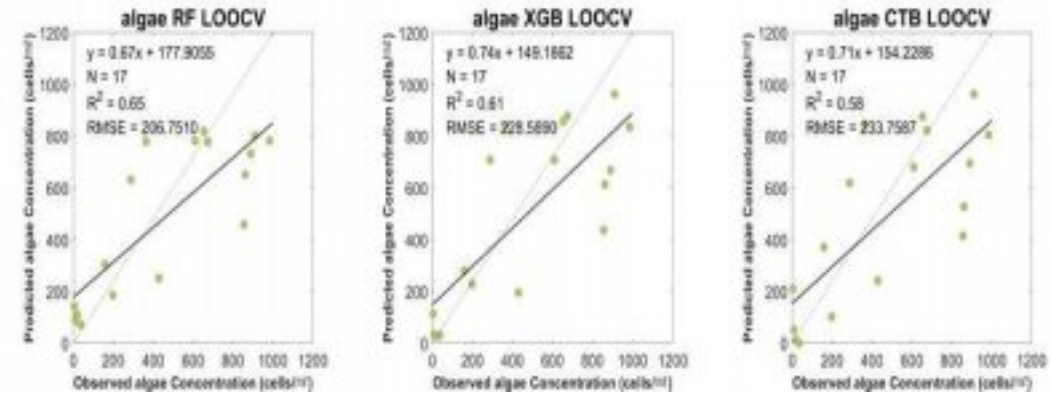


그림 3.21 RF, XGB, CTB 활용 조류세포수 추정 결과 (LOOCV) 비교

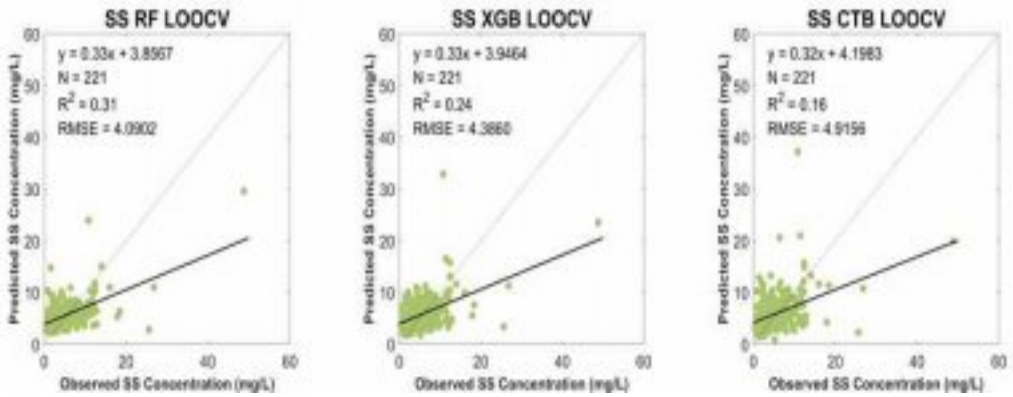


그림 3.22 RF, XGB, CTB 활용 부유물질(혼탁도) 농도 추정 결과 (LOOCV) 비교

3.3.3 기존 알고리즘과의 비교·검증을 통한 정확도 평가

1) 기존 알고리즘과의 정량적 비교·검증

기존에 개발된 경험식 기반의 알고리즘의 경우, Green 및 Red, Red-edge (RE) 파장대의 반사도 특성을 활용하여 개발되었지만, 이 같은 밴드별 반사특성을 활용한 경험식이 경우 관측치의 값에 따라 그 추정치의 오차가 발생할 수 있다는 한계가 있다. 실제 아래 그림에서 나타나듯, 클로로필-a의 농도에 따라 분광 특성이 크게 달라지는 것으로 나타나며, T07, M09, M12 세 가지 모델 모두 강한 농도의 클로로필의 분광 특성이 잘 드러나도록 설계된 알고리즘으로 각 파장대의 흡광 및 발광에 대한 피크(peak) 값을 기준으로 설계되었다. 따라서 상대적으로 고농도에 대한 훈련자료가 적은 본 과업의 자료를 고려하였을 때, 기존의 경험식 기반 알고리즘들이 제대로 구현되지 않은 것으로 판단된다.

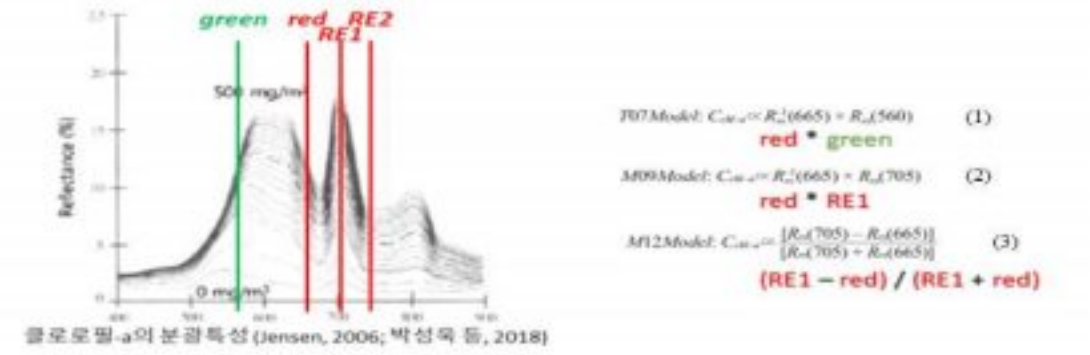


그림 3.23 선행연구 (박성욱 등, 2018)에서 제시하고 있는 클로로필-a의 분광 특성

실제로 세 가지 알고리즘의 성능을 검증한 결과, 세 모델 모두 결정계수(R^2)가 0.03 이하의 수준으로 나타나 모의를 하지 못하는 것으로 나타났다. 이는 저농도 샘플에 대한 약한 시그널 (signal)로부터 경험식 기반의 모델이 제대로 작동하지 못한다고 해석할 수 있으며, 본 과업에서 제시하고 있는 인공지능 기반의 저농도 클로로필-a 농도에 대한 추정력이 훨씬 뛰어나다고 해석할 수 있다.

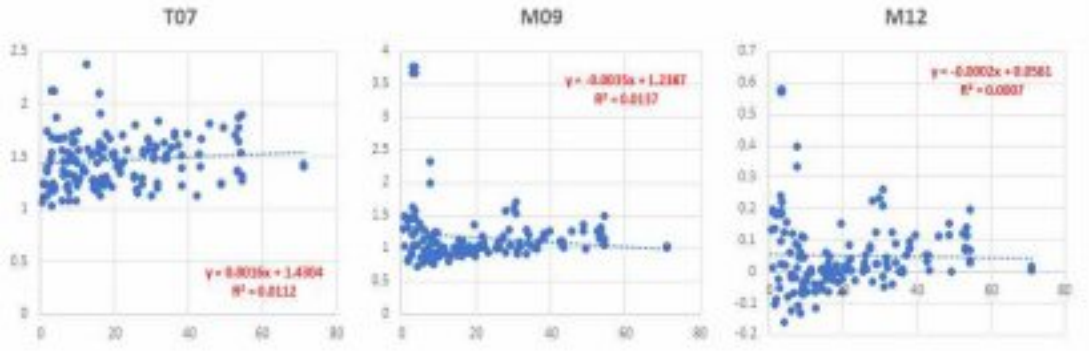


그림 3.24 경험식 기반의 세 가지 다른 클로로필-a 농도 추정 알고리즘과의 성능 비교·검증

2) 환경과학원 물환경정보시스템과의 정성적 비교·검증

본 과업에서 제시하고 있는 인공지능 기반 수질인자추정 알고리즘 중 클로로필-a 추정 알고리즘을 정성적으로 검증하기 위해 환경과학원 물환경정보시스템에서 초분광 항공영상을 활용하여 제공하고 있는 분포 지도와의 비교 및 검증을 수행하였다. 환경과학원 물환경정보시스템 조류항공영상에서는 클로로필-a와 피코시아닌에 대해 초분광 항공 영상을 활용한 농도 분포를 산출하여 연간 약 20회 제공하고 있다. 따라서 조류세포수와 부유물질(혼탁도)에 대해서는 비교할 수 없었으며, 클로로필-a의 경우에도 초분광 영상과 위성영상의 취득 일자에 차이가 있어 직접적인 비교에는 어려움이 있었다. 아래 그림은 클로로필-a 추정 알고리즘을 2019년 07월 04일 Sentinel-2 위성영상에 적용하여 산출된 클로로필-a 농도의 공간적 분포와 물환경정보시스템에서 초분광 항공영상을 통해 제공되고 있는 클로로필-a 농도를 비교하였다. 이때 정량적인 수치는 Sentinel-2 위성 영상 취득 시간과 초분광 항공 영상 취득 날짜의 차이로 인해 직접적인 비교를 하기에는 어려움이 있다. 아래 그림에서 물환경정보시스템을 통해 제공하고 있는 결과와 본 과업에서 제시한 모델 결과 비교 시 모두 강의 중간 상단부에 고농도 클로로필-a가 추정된 것을 확인할 수 있다. RF, XGB, 그리고 CTB 세 모델은 모두 공간적인 농도 분포와 수치에서 유사한 값을 보이는 것을 확인하였다.

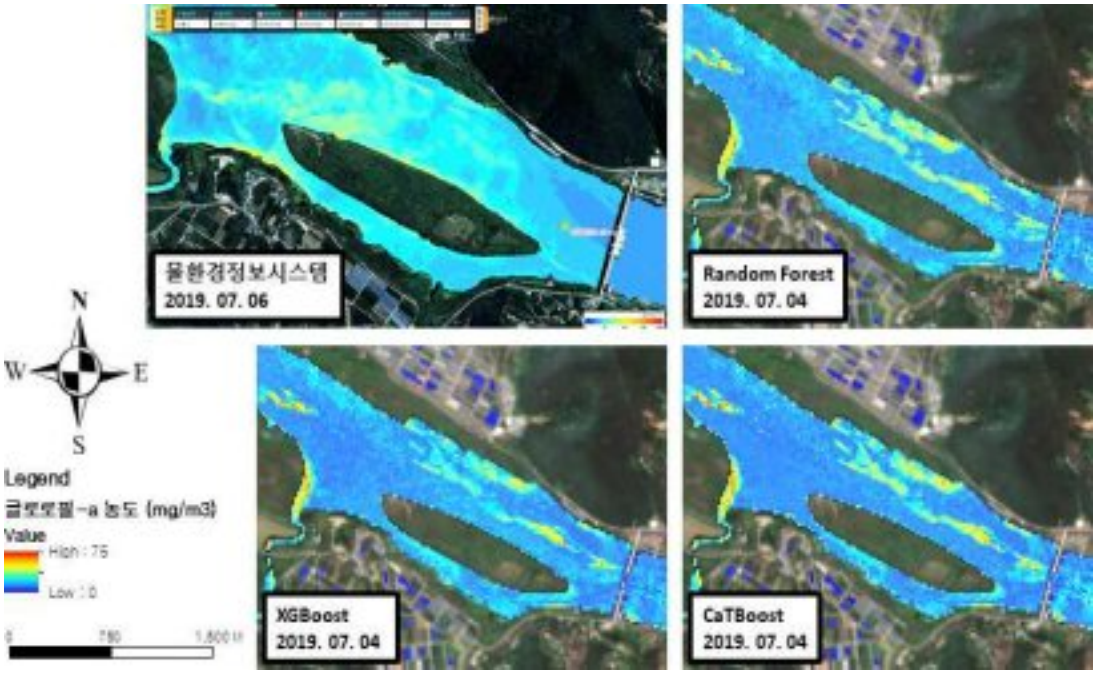


그림 3.25 국립환경과학원 물환경정보시스템과 본 과업에서 제안한 인공지능 기반 클로로필-a 추정 알고리즘 (RF, XGB, CTB)을 통해 산출된 창녕 함안보의 클로로필-a 농도 비교

부유물질 (혼탁도)의 경우 물환경정보시스템 초분광 항공 영상으로 산출되는 자료의 부재로 공간분포 비교 시 한계가 존재하여 본 과업에서 제시하고 있는 세 가지 인공지능 기반 알고리즘을 통해 산출된 농도 분포 결과만 첨부하였다.

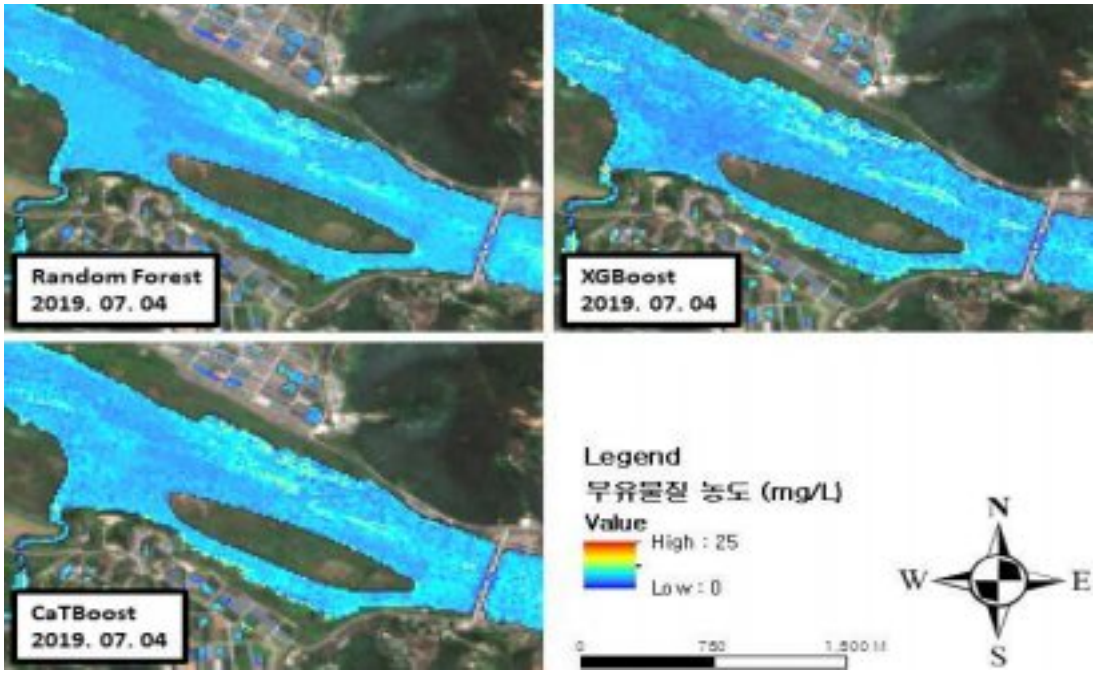


그림 3.26 인공지능 기반 부유물질 (혼탁도) 추정 알고리즘을 통해 산출된 창녕 함안보의 부유물질 분포

3.4 인공지능 기반 위성영상 수질분석기술 모듈화 및 현업화 지원

3.4.1 수질분석 자료의 시각화 기법 및 시·공간 경향 분석을 위한 기법 제시

1) 시·공간 분석을 위한 시각화 기법 제시

본 과업에서 제시하고 있는 인공지능 기반 위성영상 수질분석기술을 통해 산출된 결과의 시·공간적 분석을 위해서는 시각화 기법이 적용되어야 한다. 시각화 기법은 ArcGIS (유료), QGIS (무료) 등의 지리 정보 처리 프로그램을 활용하여 제시되었다. 파이썬 (Python) 기반 모듈을 통해 표출된 결과물, 즉 .tif 파일 포맷으로 제공되는 결과를 시각화하기 위하여 지리 정보 처리 프로그램을 활용하였다. 수질분석 자료의 시각화 기법 제시를 위해서는 ArcGIS를 활용하여 예시를 제공하였지만, 오픈소스 애플리케이션이며 무료로 제공되는 QGIS에서 역시 동일한 방법으로 진행될 수 있다. 시·공간 분석을 위한 시각화 기법은 다음과 같은 순서로 진행된다.

먼저, 아래 그림과 같이 파이썬 기반 모듈을 통해 산출된 .tif 포맷의 결과 파일 중 원하는 날짜의 자료를 지리정보 프로그램 (e.g., ArcGIS)에 드래그하여 로드 (load)해주면, 위·경도 등의 지리정보를 포함한 수질 인자 추정 알고리즘의 결과를 편리하게 분석할 수 있게 된다.

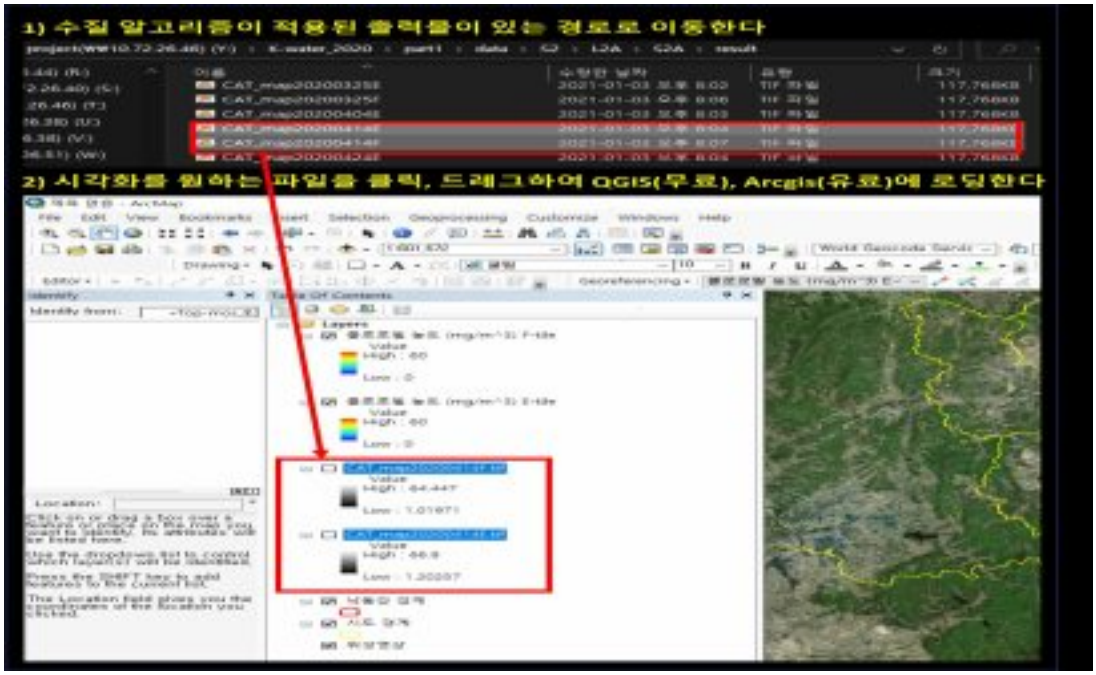


그림 3.27 수질인자분석 알고리즘의 시각화를 위한 지리정보 프로그램 활용

원하는 날짜의 결과 영상 (.tif 포맷)을 지리정보 프로그램에서 열어준 후 시·공간 분석에 활용할 수 있는 형태로 시각화하기 위하여 속성을 변경해주어야 한다. 아래 속성 변경 단계에 해당하는 예시 그림의 '3) 자료의 범위 설정' 부분의 경우 계절별로 일조량, 유량 등 환경적인 변수들로 인하여

수질 인자의 농도 변화가 발생하기 때문에 사용자가 최대·최소 값을 조절하여 공간적인 변이가 뚜렷하게 나타나도록 조절하여 나타낼 수 있다. 알고리즘의 현업화를 위해서는 이 부분을 자동화하기 위하여 영상별 통계처리를 통한 최대·최소 값을 설정할 수 있도록 하는 부분을 추가하거나, 결과 표출 화면에서 사용자가 컬러바 (colorbar)의 스케일을 조절할 수 있도록 하는 부분을 추가할 수 있을 것으로 판단된다. 국립환경과학원에서 운영하고있는 물환경정보시스템의 물환경지리정보 조류항공영상의 경우 모든 결과에 대한 농도 스케일을 동일하게 제공하고 있어 저농도 혹은 결과의 공간적인 변이가 작은 경우에 대한 분포 분석에 무리가 있는 것을 확인할 수 있다. 따라서, 시각화 과정에서 농도 범위의 스케일을 유동적으로 조정할 수 있도록 하였다. 지리정보 프로그램 (i.e., ArgGIS)에서 시각화 속성을 변경하는 방법은 아래 그림과 같다.



그림 3.28 ArcGIS를 활용한 수질인자 추정 알고리즘 시각화 속성 변경 예시

지리정보 프로그램 (ArcGIS)을 활용하여 본 과업에서 제시하고 있는 알고리즘의 결과를 시각화한 결과의 예시 (2020년 04월 14일 Sentinel-2 영상에 해당하는 결과)는 다음과 같다.

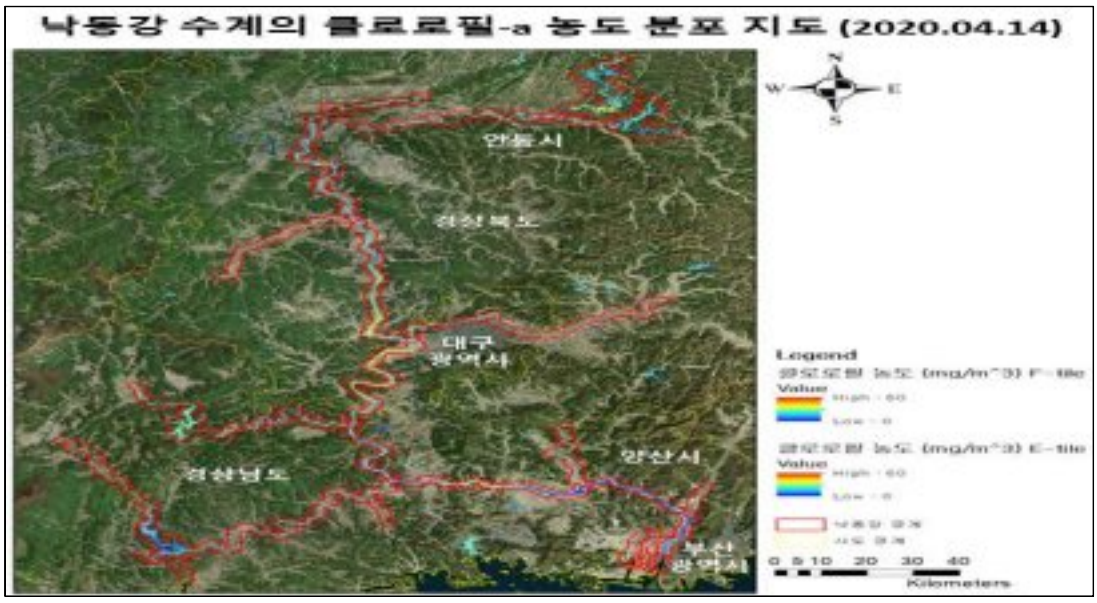


그림 3.29 2020년 04월 14일 클로로필-a 농도 분포 시각화 예시

2) 시·공간 경향 분석을 위한 통계처리 방안 제시

시·공간적인 경향 분석을 위한 통계처리 방안은 크게 두 가지로 제시할 수 있으며 아래 그림에 도식화하여 나타내었다. 첫 번째 방안은 관측 정점별, 즉 점 (point) 기반의 시계열 분석이며 두 번째는 위성영상의 각 타일 (tile)별 낙동강 수계영역 (area)에 대한 시계열 분석 방안이다. 두 방안 모두 본 과업에서 제시하고 있는 수질 인자 분석 알고리즘을 통해 산출된 다시기 결과를 활용하여 시계열 분포로 나타냄으로써 시·공간적 경향 분석이 가능하도록 한다. 이처럼 변화탐지 및 경향 분석을 위해서는 시·공간적 범위를 정의해야 하며, 시간적 범위 설정 시 너무 짧은 기간을 설정할 시 광학 위성영상의 구름에 의한 한계로 인해 분석에 어려움이 있으므로 적절한 기간을 설정해야 한다. 시간적 범위의 예시로는 주별, 월별, 계절별 등이 있으며 공간적 범위의 예시로는 정점별, 시/군/구 단위의 행정구역별, 유역별, 위성영상의 타일별 등의 영역별 범위 설정이 있다. 정의한 시공간적 범위 내의 수질 인자 농도의 최소값, 최대값, 평균값, 그리고 기울기 등의 통계값들을 활용하여 경향 분석이 가능하다.

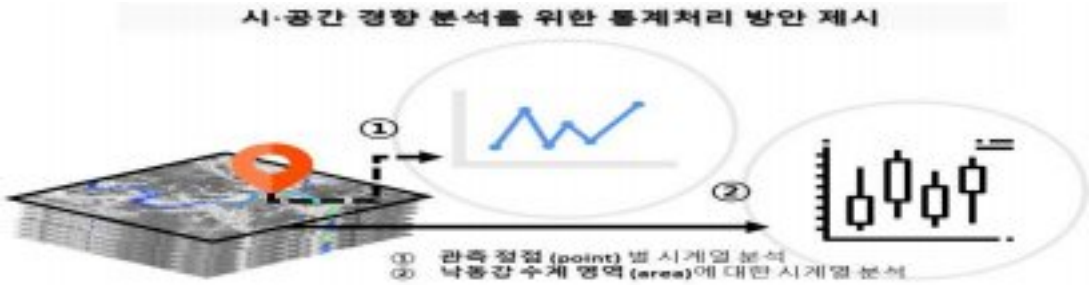


그림 3.30 시·공간 경향 분석을 위해 제시된 두 가지 통계처리 방안 모식도

관측 정점별, 즉 점 (point) 기반의 시계열 분석은 현재 운영되고 있는 수질측정망의 측정소들, 혹은 필요에 따라 지속적인 모니터링이 필요하다고 판단되는 지점에 대하여 각 지점별로 수질 인자 농도의 시간적 변화를 분석하는 방안이다. 현재 우리나라에서는 측정소별로 직접 채수를 통한 수질 모니터링을 수행하고 있으나, 이는 주로 분기별, 혹은 반기별로 측정이 이루어지기 때문에 현장 측정자료만을 가지고 시·공간적 경향 분석을 수행하기에는 어려움이 있다. 따라서, 본 과업에서 제안하고 있는 알고리즘을 통해 산출된 결과를 활용할 경우 Sentinel-2 위성의 재방문 주기에 해당하는 짧은 시간 간격으로 경향 분석이 가능하게 된다. 본 과업의 연구 기간에 해당하는 2019년 01월부터 2020년 09까지의 측정소별 수질 인자의 시계열 분포를 분석할 수 있다. 광학 영상의 한계로 해당 측정소 위치에 구름이 위치할 경우 값을 얻을 수 없지만, 현장관측 기반의 모니터링 대비 훨씬 더 효율적인 모니터링이 가능하다는 장점을 가진다. 관측 정점별 시계열 분석의 예시로, 물환경측정망 - 수질측정망의 측정소 중 하나인 칠곡 측정소에서의 클로로필-a 농도 분포를 아래 그림으로 나타내었다.



그림 3.31 관측 정점 (point) 기반 시계열 분석 방안의 예시 (칠곡 조사정점 클로로필a 농도의 시계열 분포)

두 번째는 위성영상의 각 타일 (tile)별 낙동강 수계영역 (area)에 대한 시계열 분석 방안으로, 시기별 낙동강 수계에 대한 전반적인 경향 분석에 유용하게 사용될 수 있다. 날짜별로 구름 및 수체 마스킹을 거친 후 얻어진 낙동강 수계영역에 해당하는 전체 결과에 대하여 아래 그림과 같이 상자 그림 (box plot)을 활용하여 나타내었다. 상자 그림은 자료로부터 얻어낸 통계량인 5 가지 요약 수치를 가지고 그리며, 이 때 5 가지 요약 수치란 최솟값, 제 1 사분위 (Q1), 제 2 사분위 (Q2), 제 3 사분위 (Q3), 최댓값을 일컫는다. 상자는 제 1 사분위 (Q1)와 제 3 사분위 (Q3)를 나타내며 상자 내의 붉은 가로 선은 중앙값을 의미하며, 검은색으로 나타난 수염은 각각 최솟값과 최댓값을 나타낸다. 상자 그림과 함께 나타난 붉은색 꺾은선 그래프는 날짜별 결과의 평균값을 나타낸 그래프이다. 이처럼 영상 내의 전체 픽셀에 대한 값을 통계적으로 나타낼 경우 시기별 낙동강 수계에서의 전반적 수질 인자의 분포 경향 파악이 가능하다. 이 역시 첫 번째 방안과 같이 모니터링이 필요하다고 판단되는 지역에 대하여 폴리곤 (polygon) 형태로 마스킹을 주고 분석 시 수질 인자의 장기경향 분석 및 통계처리에 유용하게 활용될 수 있을 것으로 판단된다.

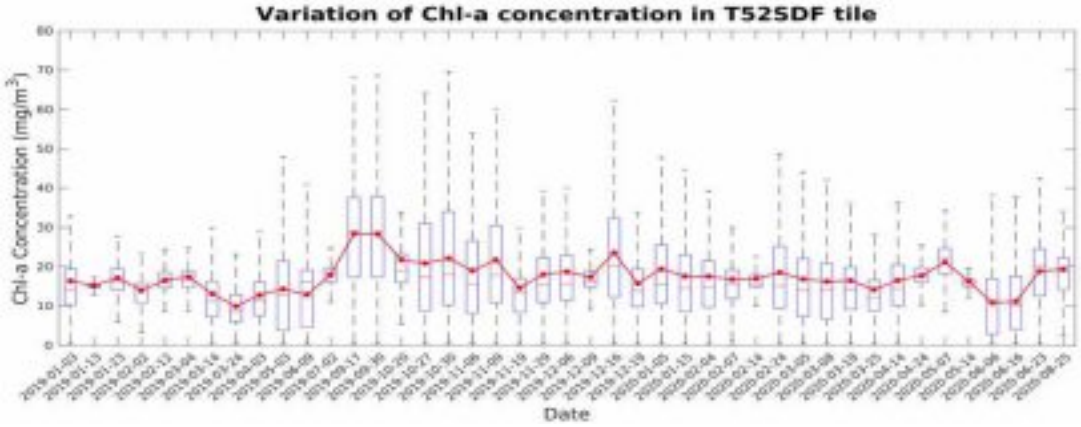


그림 3.32 낙동강 수계영역에 대한 시계열 분석 방안 예시 (T52SDF 타일의 클로로필-a 시계열 분포 박스 플랏)

3.4.2 개발한 알고리즘의 한계점 및 논의사항 제시

위성영상을 이용한 수질 모니터링은 광범위한 지역을 주기적으로 관측 가능하다는 점에서 효율적이며 수질인자 추정에 사용되는 변수 간의 비선형성을 효과적으로 모의하기 위해서 기존의 회귀 분석이나 간단한 경험식 대신 인공지능 기법을 사용할 경우, 보다 더 안정성 높은 모델을 구축 가능하다. 따라서 본 과업에서는, 인공지능 기반 위성영상 수질 (클로로필-a, 조류세포수, 부유물질) 분석 기술을 개발하고, 이를 모듈화 및 현업화하였다. 국내·외 선행 연구 분석 결과, 원격탐사 기반 수질 분석 및 환경 분야에서 널리 사용되며 좋은 성능을 보이는 기계학습 기법인 RF (Random Forest), XGB (eXtreme Gradient Boosting), CTB (CaTBoost)를 각각 수질 인자에 대하여 적용하고 결과를 정량·정성적으로 비교·분석하여 최적의 분석 기법을 제시하고자 하였다.

본 과업에서 개발한 수질 분석 알고리즘에 가장 큰 한계점으로 작용한 부분은 현장관측자료의 한계이다. 수질 측정망 및 조류 관찰지점 자료는 일별 자료로 날짜 정보까지만 제공이 되고, 위·경도 좌표가 실제 하천 상에 위치하지 않은 경우가 많아 시공간적으로 모두 불확실성을 내포하고 있다. 따라서, 현장자료와 위성자료의 매칭 시 세부적인 시간에 대한 고려가 생략되었으며 공간적으로 역시 지리적 오차 및 위성관측의 한계에 의한 불확실성을 내포하고 있다. 이러한 현장관측자료가 가진 한계점을 완화하기 위해 3 * 3 픽셀 윈도우를 통한 smoothing 등의 과정을 수행하였으나, 근본적인 문제점은 해결할 수 없어 모델의 성능 저하를 일으키는 한계점으로 대두되었다. 이러한 관점에서 미루어 볼 때, 추후 K-water 측에서 자체적인 현장 조사를 통해 정확한 시공간적 정보를 가진 양질의 자료를 확보할 시, 본 과업에서 제시되었던 한계점을 상당 부분 개선할 수 있을 것으로 판단된다.

또한, 본 과업에서 제시하고 있는 인공지능 기반 수질인자 추정 알고리즘은 원하는 날짜의 위성영상에 적용 시 위성영상의 대기보정 알고리즘에 따라 각 밴드의 반사도 값이 달라지게 되며, 대기보정 알고리즘은 경험식에 기반하기 때문에 우리나라 수계에 그대로 적용 시 지역적으로 정확한 보정에 한계가 존재한다.

물환경정보시스템에서 제공하는 초분광 항공 센서로부터 추정된 클로로필-a와 본 과업에서 제시한 알고리즘을 통해 추정된 결과 비교 시 위성영상을 통한 농도 추정이 비교적 과소 모의하고 있는 양상을 보인다. 초분광 항공영상을 통해 산출된 클로로필-a 농도는 1 m 이하의 해상도를 가지며 대기에 의한 오염이 적지만, 본 과업에서 사용된 고해상도 위성인 Sentinel-2는 해상도가 20 m로 수체의 측이 넓은 경우에는 물환경정보시스템에서 제공하는 결과와 비슷한 공간 분포를 보이지만 수폭이 좁은 경우에는 20 * 20 m 픽셀에서 육상에 의한 영향과 부유물질로 인한 정확한 값을 산출하는 데에는 한계가 있는 것으로 판단된다.

3.4.3 K-water 시스템 적용을 위한 소스코드 및 운영 매뉴얼 작성

1) Python 기반 모듈

본 과업에서는 오픈 소스 (open source)인 파이썬 (Python)을 활용하여 수질 분석기술을 개발하였다. 파이썬 (Python)은 1991년 귀도 반 로섬 (Guido Van Rossum)이 발표한 고급 프로그래밍 언어로써 다양힌 플랫폼에서 사용할 수 있고, 라이브러리가 풍부하여 초보자부터 전문가까지 다양하게 사용하고 있다. 파이썬에는 기본 인터프리터 이외에도 패키지 (package)와 개발 도구를 함께 제공하는 다양한 배포판 (distribution)이 있으며 본 과업에서는 운영체제, 32/64 비트 지원 여부, 무료/상용 여부 등을 고려하여 현재 가장 널리 사용되고 있는 아나콘다 (Anaconda)를 이용하였다. 아나콘다 배포판은 무료이며, 모든 패키지가 컴파일이 필요 없는 이진 (binary) 형태로 제공되어 설치 속도가 빠르고 관리가 편하다는 장점이 있다. 아나콘다 배포판에서 제공하는 다양한 파이썬 버전 중 파이썬 3.6 버전을 기준으로 본 과업을 수행하였다. 대부분의 파이썬 라이브러리들은 윈도우와 리눅스 환경의 아나콘다 가상환경에서 'conda install -c conda-forge (패키지 이름)' 명령어를 통해 설치할 수 있으나, 윈도우 64 비트 환경에서 fiona, gdal, geopandas, pyproj, rasterio, shapely 라이브러리

를 설치하는 경우, https://www.lfd.uci.edu/~gohlke/pythonlibs에서 .whl 확장자를 가지는 파일을 받은 후 관리자 권한으로 'pip install'을 통해 설치하였다. 이때 패키지의 버전 별 호환성을 고려하여 같은 이름 및 버전으로 설치해야 한다.

본 과업에서 제시한 인공지능 기반 수질인자분석 알고리즘은 파이썬 (Python) 기반의 모듈로 구축되었으며, 수질 인자별 알고리즘 구축에 사용된 소스코드는 아래와 같다. 세 가지 수질 인자 (클로로필-a, 조류세포수, 부유물질) 중 클로로필-a을 예시로 활용하였으며, 나머지 수질 인자에 대해서는 타겟 변수만 바뀌고 동일한 과정을 거쳐 각각 세 가지 알고리즘 (RF, XGB, CTB)을 구축하였다. 아래 단락에 기법별로 코드 설명을 첨부하였으며, 먼저 인공지능 기반 모델 구축 및 저장에 사용된 파이썬 라이브러리는 아래와 같다.



그림 3.33 모델 구축 및 저장에 사용되는 파이썬 라이브러리 (library)와 이를 로드하는 과정

클로로필-a 농도를 추정하기 위한 랜덤포레스트 (Random Forest, RF) 모델을 구축하고 저장하기 위한 단계는 다음과 같다. 먼저 모델은 Leave-one-out cross-validation (LOOCV)로 검증되어 전체 샘플 N 개를 샘플 하나를 validation으로, 나머지를 calibration으로 하여 검증하는 단계를 N 번 반복하기 때문에 for 문을 사용하여 수행하였다 (Line 30-72). 또한, 분석 시에 샘플별로 공간적 이동 여부 (avail), 3 * 3 윈도우 가능 여부 (avail_win)와 오버샘플링 여부 (ovr)에 따른 분석이 가능하도록 관측값 (ref)과 모델 추정값 (pred)와 함께 플래그 (flag)를 함께 저장해주었다 (Line 57-62, 74-75). RF 모델 구축 코드의 부분적 설명은 아래 그림에 주석처리하여 함께 나타내었다.

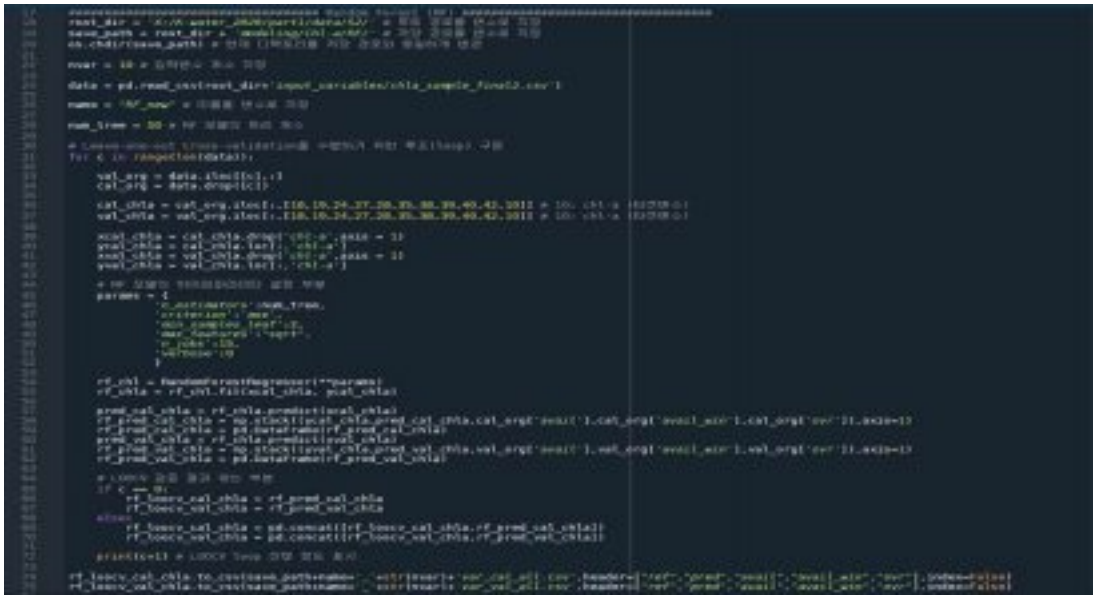


그림 3.34 Random Forest (RF) 모델 구축 단계

RF 모델 구축 후 구축한 모델을 저장하여 내보낸 후, 나중에 불러와 새로운 위상 영상에 적용하여 결과를 얻을 수 있게 하는 부분은 아래와 같다. LOOCV에 사용되었던 전체 훈련 샘플을 불러와 (Line 82) 구축한 모델과 동일한 하이퍼파라미터를 이용하여 모델을 구축하여 joblib 함수를 활용하여 저장한다 (Line 108). 아래 코드에서 모델의 이름은 'Chl-a_RF_10var_model.pkl'로 지정해주었기 때문에 (Line 107), 위와 같은 이름으로 모델을 불러올 수 있게 된다.

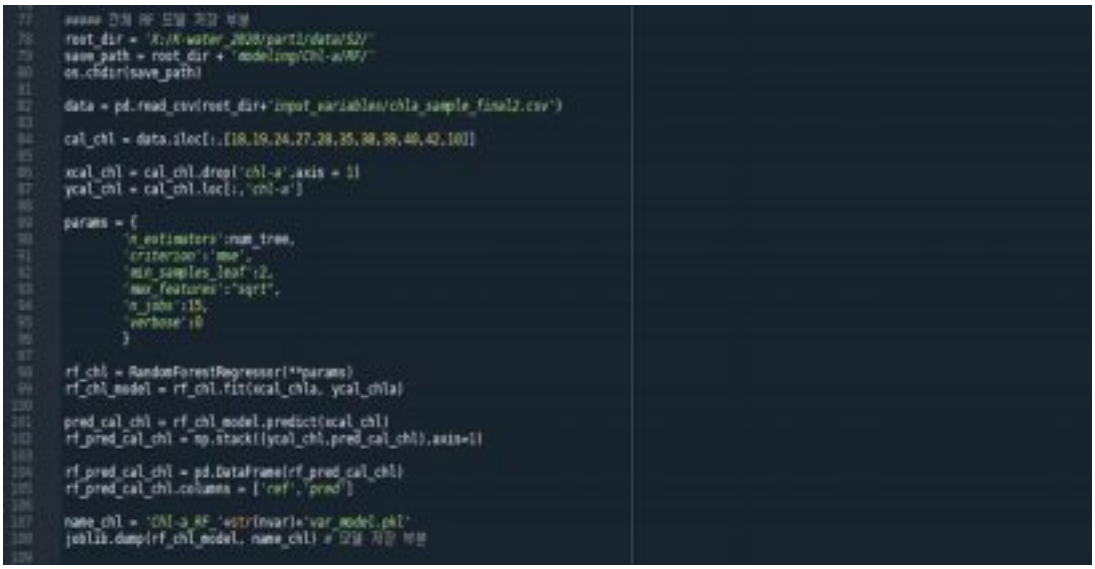


그림 3.35 Random Forest (RF) 모델 저장 단계

XGB와 CTB 모델 역시 RF와 동일한 구조로 모델 구축 및 저장 코드를 구성하였으며, 각각 완성된 코드를 첨부하였다. 각 알고리즘별로 하이퍼파라미터 설정 부분과 모델 구축하는 함수만 상이하며 다른 흐름은 모두 동일하다.

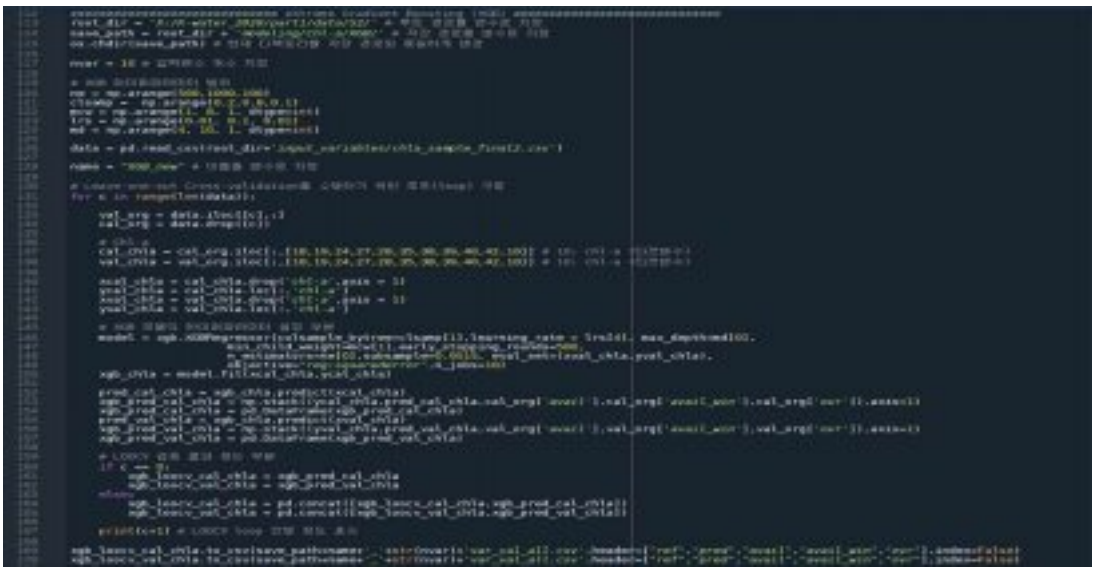


그림 3.36 eXtreme Gradient Boosting (XGB) 모델 구축 단계



그림 3.37 eXtreme Gradient Boosting (XGB) 모델 저장 단계

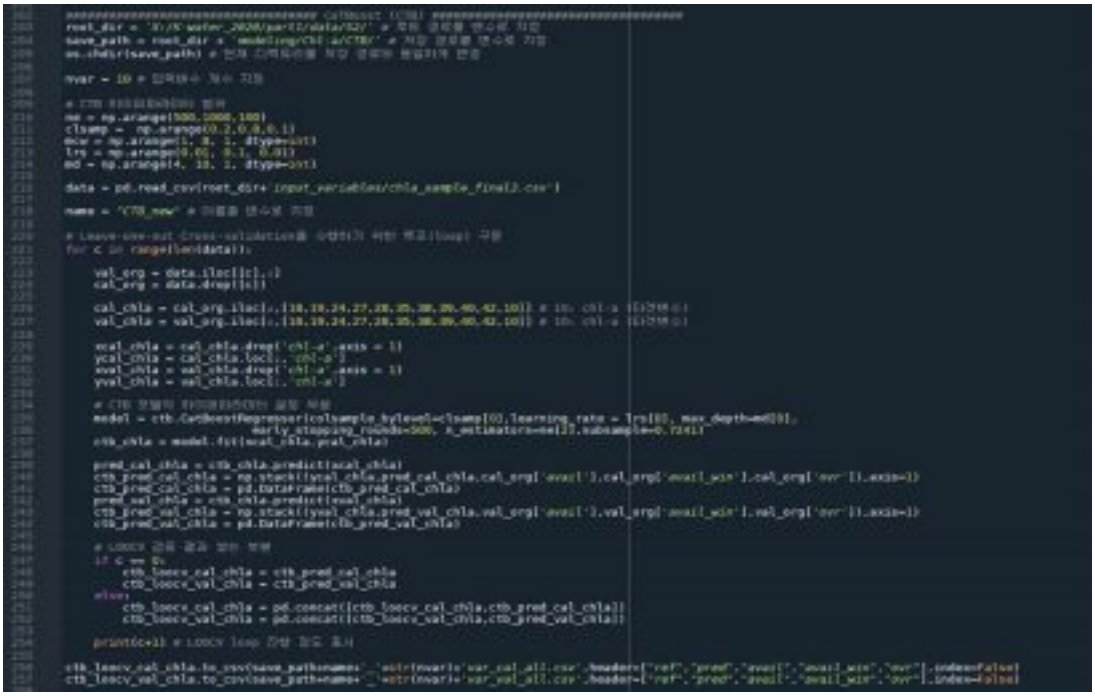


그림 3.38 CaTBoost (CTB) 모델 구축 단계

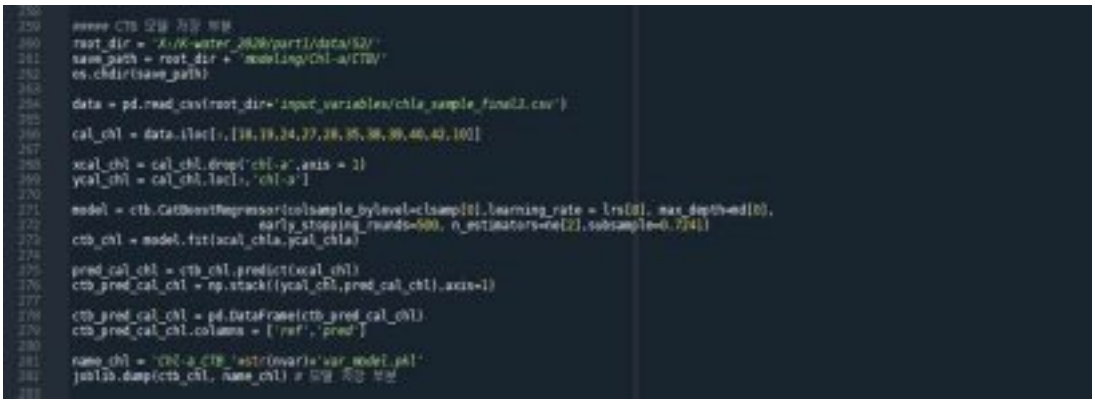


그림 3.39 CaTBoost (CTB) 모델 저장 단계

2) 시공간 분석을 위한 매핑 기법

본 과업에서 제시된 수질분석 알고리즘에 대한 시공간 분석을 위한 매핑을 Python 환경에서 구현하기 위해서는 필요한 패키지 (package)를 https://www.lfd.uci.edu/~gohlke/pythonlibs/에서 다운받아야하며, 패키지의 호환성을 위해 아래 그림과 동일한 이름과 버전으로 설치해야 한다. 아래의 패키지를 한 폴더에 저장한 후 window의 찾기 버튼에서 “Anaconda Prompt”를 작동시켜 패키지를 저장한 해당 폴더로 이동한 뒤 “pip install (패키지 이름)” 명령어를 기재하면 자동으로 패키지가 해당 컴퓨터에 설치된다.

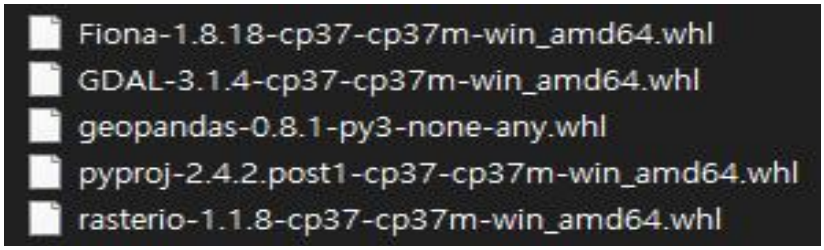


그림 3.40 수질 분석 알고리즘 적용에 필요한 Python 패키지



그림 3.41 Python 환경에서 라이브러리 설치의 예시

이와 같은 방법으로 매핑 (mapping)에 필요한 패키지를 다운받은 후 아래와 같이 패키지를 불러오면 (import) 본 과업에서 제시한 인공지능 기반 수질분석 알고리즘의 시각화가 가능해진다.



그림 3.42 수질 분석에 사용되는 Python 패키지

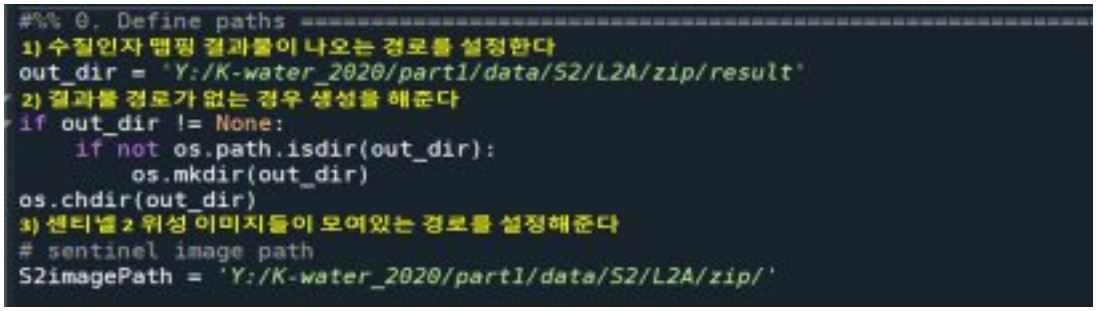


그림 3.43 수질 분석 결과물이 출력되는 경로와 위성영상 이미지 경로 설정

위 코드 부분에서 out_dir은 수질분석 알고리즘이 적용된 위성영상이 저장되는 경로를 설정해주는 부분으로, 결과물이 저장되는 경로가 본 폴더에 부재하는 경우 if~ 구문을 통해 경로를 생성해준다. S2imagePath는 시공간 분석에 사용될 Sentinel-2 위성영상의 경로를 지정해주는 부분이다.



그림 3.44 원하는 날짜의 위성영상을 불러오는 부분

위 그림에서 band(숫자)_name은 band 2부터 band 12까지 해당하는 위성영상의 파일 이름을 불러오는 부분이다. 2)에서는 1)의 밴드 자료 경로와 이름이 합쳐진 상태로 출력된다.



그림 3.45 수질인자 추정 알고리즘 적용에 필요한 밴드와 밴드비 자료 산출

위 그림에서 band(숫자)_name은 band 2부터 band 12까지 해당하는 위성영상의 파일 이름을 불러오는 부분이며, 불러온 위성영상 밴드 파일 이름을 rasterio 패키지를 활용하여 지리정보와 밴드값의 정보를 행렬 형태로 불러오게 된다. band(숫자)_array는 불러온 위성영상은 3-D 형태(밴드 수, 위도, 경도)로 불러오는데 밴드의 수는 각 파일에 한 개씩 있기 때문에 3차원 형태의 밴드 수 부분을 줄여서 2차원의 행렬로 출력된다. mask_band(숫자)는 python 패키지 중 numpy의 마스크를 활용하여 위성영상 중 값이 없는 부분에 대해서 연산이 되지 않도록 처리해준다.

클로로필-a 추정의 경우에는 1) band4/band5, 2) band4/band6, 3) band3/band5, 4) band2/band5, 5) band2/band4 총 네 개의 밴드비 자료를 생산하며, 부유물질 (혼탁도)의 경우에는 1) band5/band7, 2) band4/band7, 3) band2/band7, 4) band4/band5, 5) band3/band5, 6) band2/band5 총 6 개의 밴드비 자료를 생산하였다.

```
123  #%% MNDWI water mask
124
125  MNDWI= np.ma.divide((band3_array-band11_array),(band3_array+band11_array))
126  MNDWI1= np.where(MNDWI>0,1,MNDWI)
127  MNDWI2= np.where(MNDWI<0,0,MNDWI1)
128  mask_MNDWI= np.ma.masked_where(MNDWI2==0,MNDWI2)
129
```

그림 3.46 수질 알고리즘을 적용하기 위한 수계영역 마스킹

기존의 널리 알려진 Normalized Difference Water Index (NDWI)는 도심지와 수계 부분에 장애물이 있는 경우 수계 부분 추출에 한계점을 가진다. Xu 외 (2006)에서는 NDWI를 개선시킨 Modified Normalized Difference Water Index (MNDWI)를 사용하여 보다 정밀한 수계영역을 추출하였으며, 본 과업에서 역시 MDWI를 적용하여 수체 영역을 추출하였다.

$$MNDWI = (Green - SWIR1)/(Green + SWIR1)$$

수식 3.1 MNDWI 산출식

MNDWI를 계산하기 위해 Sentinel-2 위성의 Green 밴드인 band 3과 SWIR 1에 해당하는 band 11를 활용하여 수체 부분을 분리하기 위한 마스크를 생산하였고, MNDWI가 0보다 큰 경우에는 물을 나타냄으로 1로 부여 하고 0보다 작은 경우에는 육지, 구름 등 물 이외의 대상으로 간주하여 0을 부여하였다. mask_MNDWI에서는 물 이외의 지역은 불필요하므로 0인 부분은 유효하지 않게 만들었다.

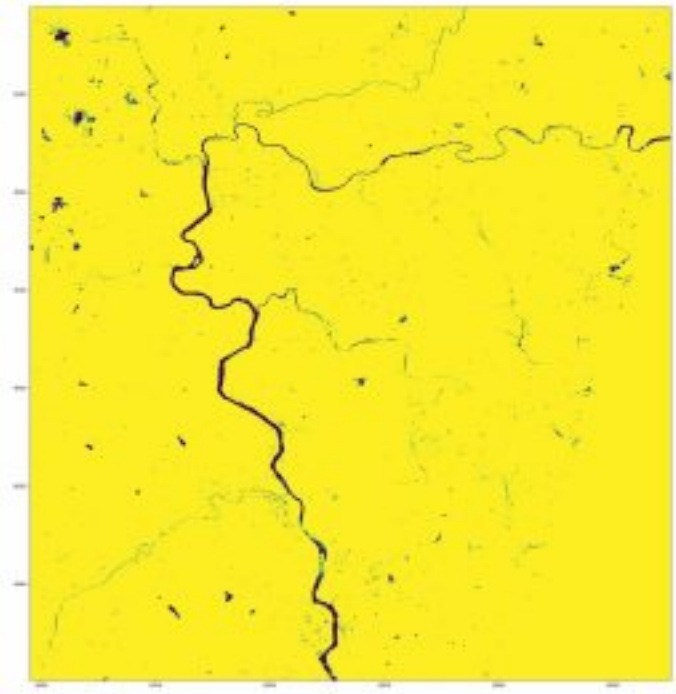


그림 3.47 밴드 위 과정을 통해 생산된 수계 마스크

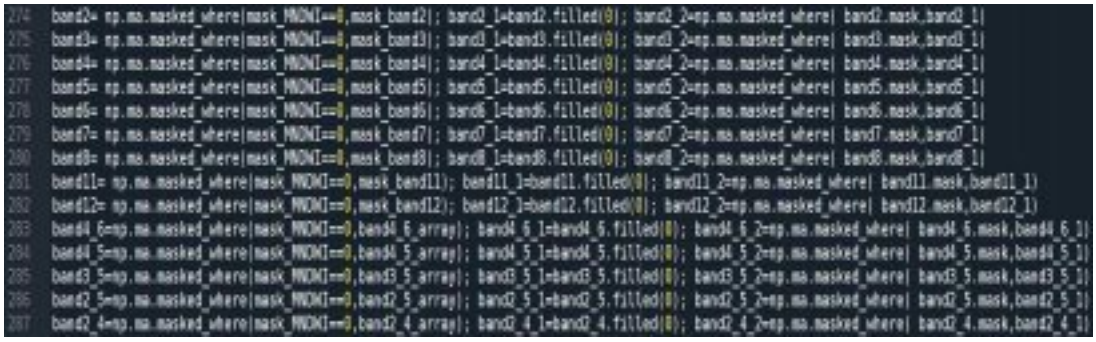


그림 3.48 각 밴드 자료들을 water mask를 활용하여 수체 영역만 추출

band(숫자)는 각 밴드를 수계영역 마스크를 해주며, band(숫자)_1은 수계영역 이외의 유효하지 않는 부분을 0을 부여한다. band(숫자)_2는 band(숫자)_1의 수계부분을 다시 마스킹하여 수질 알고리즘 모델 적용에서 연산이 되지 않도록 한다. 앞에서 생산된 수체 마스크를 알고리즘에 적용될 밴드와 밴드비 산출물에 적용하여 불필요한 부분을 제거한다. 수체 마스크의 경우 추후 본 과업의 수변환경 분류 파트에서 영상별로 제공되는 기계학습 기반의 수체 마스크를 적용 가능할 것으로 보인다.



그림 3.49 최종 처리된 위성영상 자료를 한줄로 만들고 수질 알고리즘을 적용하기 위한 자료의 형태로 쌓기

위 코드는 처리된 최종 위성자료를 한줄 로 세워 학습된 수질 알고리즘을 적용하기 위한 자료의 형태로 가공하는 단계이다.

마지막으로, 다음 그림은 앞부분에서 학습된 RF, XGB, CTB 모델을 불러와 위 과정들로부터 최종 처리된 자료를 적용하여 전체 수계영역에 대한 매핑을 하는 부분으로, 218번째 줄부터 231번째 줄까지 학습된 모델을 불러오는 단계이며, 233번째 줄부터 238번째 줄까지 학습된 모델을 적용하는 부분이다. 241번째 줄부터 245번째 줄까지는 알고리즘이 적용된 위도, 경도 등의 지리정보를 업데이트해주며, 247번째 줄에서 맨 처음 지정해준 결과물 출력 경로에 최종 결과물을 Tiff 파일 형태로 저장하는 부분이다.

```
#%% 6. Load model and Mapping ----------------------------------------------

model_path='Y:\K-water_2020\part1\data\S2\modeling\Chl-a'
RF_model='RF/Chl-a_RF_10var_model_log.pkl'
CTB_model='CTB/Chl-a_CTB_10var_model_log.pkl'
XGB_model='XGB/Chl-a_XGB_10var_model_log.pkl'
2) 모델의 경로에서 저장된 모델을 불러온다
# Load from file
with open(os.path.join(model_path, RF_model), 'rb') as file:
    RF = joblib.load(file)

with open(os.path.join(model_path, CTB_model), 'rb') as file:
    CTB = joblib.load(file)

with open(os.path.join(model_path, XGB_model), 'rb') as file:
    XGB = joblib.load(file)
3) 위의 과정에서 불러온 모델을 준비된 데이터에 적용한다
Pred = RF.predict(df_All_data_array)

Pred_map = Pred.reshape(1,band2_2.shape[0],band2_2.shape[1])
Pred_map = np.array(np.exp(Pred_map), dtype=np.float32)
Pred_map_mask= np.ma.array(Pred_map,mask=band2_2.mask)
Pred_map_fill=Pred_map_mask.filled(np.nan)

4) T52SDF / T52SDE 타일에 해당하는 지리정보를 수질 알고리즘 결과에 부여
new_meta = pred_meta.copy()
new_meta.update({"driver": "GTiff",
                 "dtype": rasterio.float32,
                 "nodata":np.nan,
                 "count":1})
5) 수질 알고리즘이 적용된 결과를 미리 선언한 결과물 경로에 저장한다
with rio.open(out_dir+"/RF_map"+"20190702F"+".tif","w",**new_meta) as dest:
    dest.write(Pred_map_fill)
```

그림 3.50 수질 알고리즘 모델을 불러와 원하는 날짜의 위성영상에 적용하는 과정 및 결과물 저장 단계

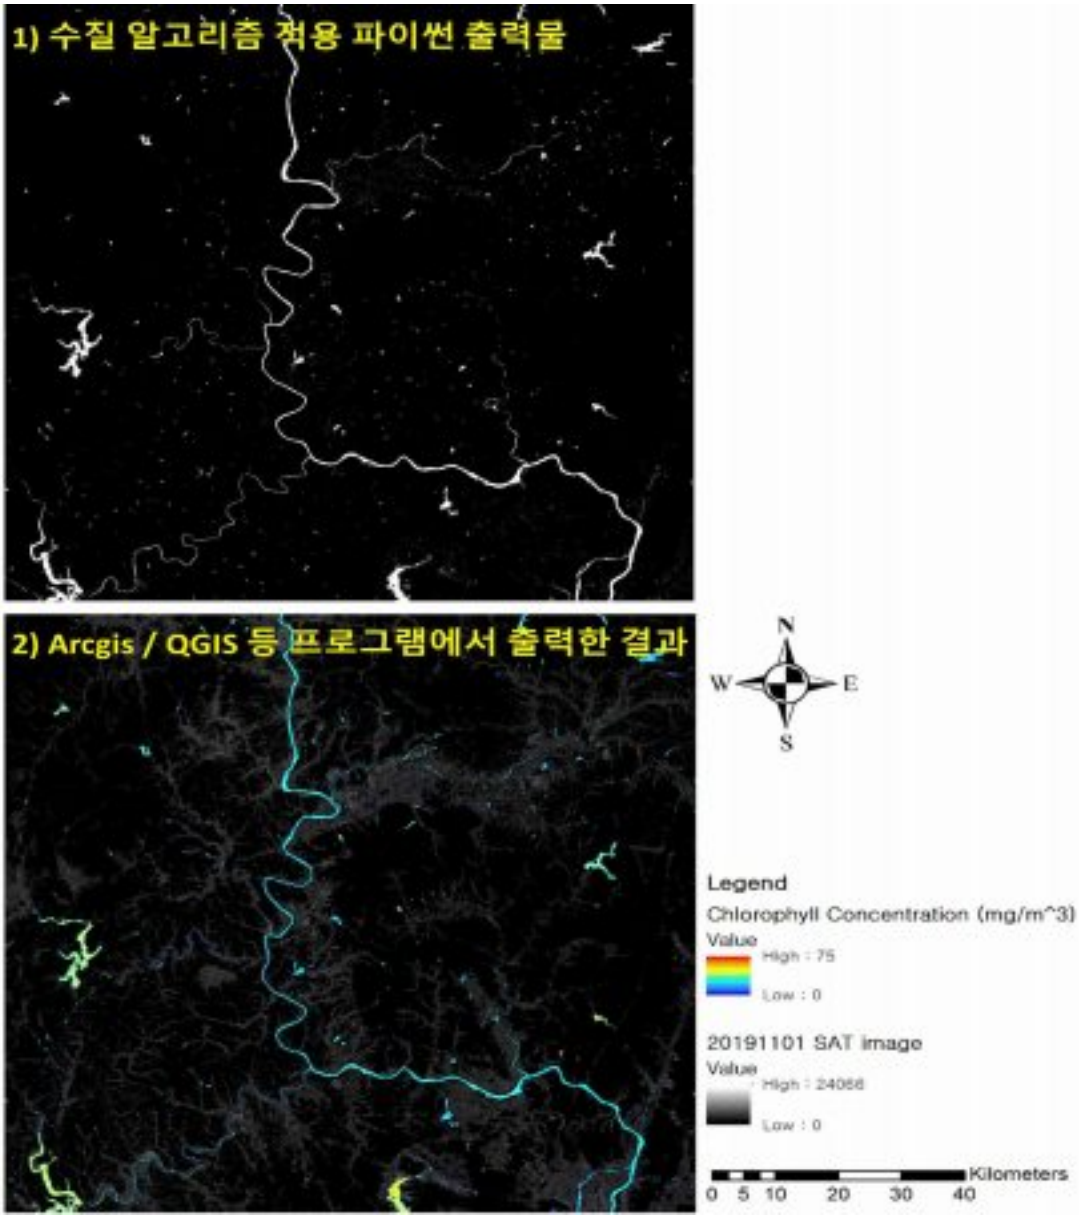


그림 3.51 수질인자 추정 알고리즘이 적용된 결과물 (위: 파이썬 출력물, 아래: Arcgis/QGIS 등 지리정보 tool 에서 보이는 자료)

제 4 장 하천경관변화 분석 기법 개발

4.1 연구 목적

수변구역은 환경부가 수계의 수질관리를 위해 상수원에 인접한 하천변을 대상으로 지정한 지역을 말한다. 수변환경은 하천습지, 하중도 및 모래톱과 같은 형태로 하천생태계의 안정성을 유지하는 중요한 역할을 하며, 특히 수변환경의 나지 (i.e. 하중도, 모래톱 등) 는 철새와 같은 다양한 생물의 휴식처 및 서식지로 중요한 역할을 함. 특히 낙동강은 철새들의 기착지 및 겨울새의 월동지 및 여름새의 번식지로 중요한 역할을 담당하고 있다 (김범수 등, 2015 최효연 등, 2019).

4대강 정비사업은 하천의 지형과 면적 그리고 수변구역 내 토지이용의 변화를 유발하였으며, 이는 수변환경의 기능 및 수생태계의 변화를 유발한다 (임란영 등, 2015; 박수국 등, 2013; 정윤재, 2015). 하천 정비사업 이외의 수자원 확보를 위한 수자원 시설물 설치 및 하천주변 개발·개간은 수변구역의 완충지대 기능을 약화하고 수생·수변 생태계 변화를 유발하였다.

더불어 현재까지 4대강 사업 이후 변화된 수변환경에 대한 조사는 지엽적으로 이루어지는 경향이 있으며, 수변환경 변화에 대한 정량적인 분석이 가능한 실무적인 광역 조사는 충분하지 않은 실정이다. 현장조사를 통한 수변환경 분석은 많은 인력과 시간을 필요로 하므로 시·공간적으로 넓은 지역에 대한 조사를 수행하기 어려움을 가진다. 그러나 위성 원격탐사기반 수변환경 분석은 현장답사기반 조사에 비해 광역의 범위에 대한 체계적인 자료를 취득할 수 있어 효율적이다. 특히 위성영상은 동일한 시간 간격으로 관측이 이루어져 수변환경의 시계열 변화탐지가 가능한 장점이 있다. 따라서 위성영상과 기계학습을 사용한 체계적이고 신뢰 가능한 수변환경 분류 알고리즘의 구축은 추후 수변환경 변화분석에 사용될 예산을 절약할 수 있을 것이다. 이에 국내·외에서 다양한 위성영상 (Landsat, Sentinel 등)을 이용한 수변환경 모니터링 연구가 활발히 수행되고 있는 실정이다 (Nascimento 등, 2013; Zhu & Woodcock, 2014; 정윤재, 2015; 박주성 등, 2016).

본 연구는 4대강 사업 이후 고해상도 위성영상과 기계학습을 사용하여 낙동강 환경변화를 시계열적 및 공간적으로 분석할 수 있는 알고리즘을 개발 및 고도화하며 경향 분석을 위한 통계처리 방안을 제시하고자 한다.

4.2 기존 알고리즘 검증 및 한계점 분석

4.2.1 기존 알고리즘의 한계점 및 원인 제시

1) 기존 연구 요약

- 과업명: 위성영상 활용 용수수요 인자 및 수변환경 변화 분석기법 연구 (2019)
- 목적: 수변환경 변화를 분석할 수 있는 분류 알고리즘을 개발
- 시.공간적 범위: 4대강 수계 수질 관측자료 및 위성관측 자료 ('19)
- 활용위성: Sentinel-2 / Landsat-8 OLI
- 분석 방법: 위성관측 반사도 활용 Random Forest (4대강 유역별 개별 모델)
- 분석 결과 (낙동강 유역, 아래 표 참고)

표 4.1 계절별 수변 환경 overall 분류 정확도

	봄	여름	가을	겨울
최대 (%)	83.33	80	85.5	85.21
평균 (%)	77.76	66.5	77.83	70.84
최소 (%)	71.19	58	60.78	55.47

2) 한계점

구름 및 그림자로 인한 지표반사도의 오염으로 인한 입력자료의 신뢰성 저하가 발생한다는 한계가 있다

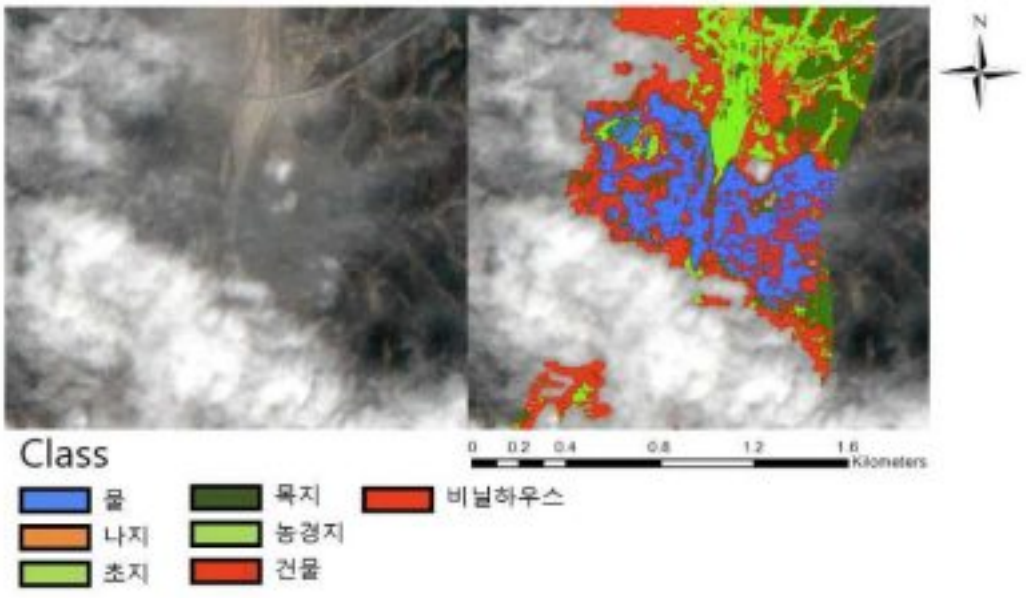


그림 4.1 구름 그림자로 인한 지표반사도 오염(좌측)과 그 결과로 발생하는 기계학습의 오분류

기계학습 기법의 특성에서 나타나는 한계점으로, 나지 클래스의 반사도 패턴을 학습하기 어렵다는 한계가 있다.

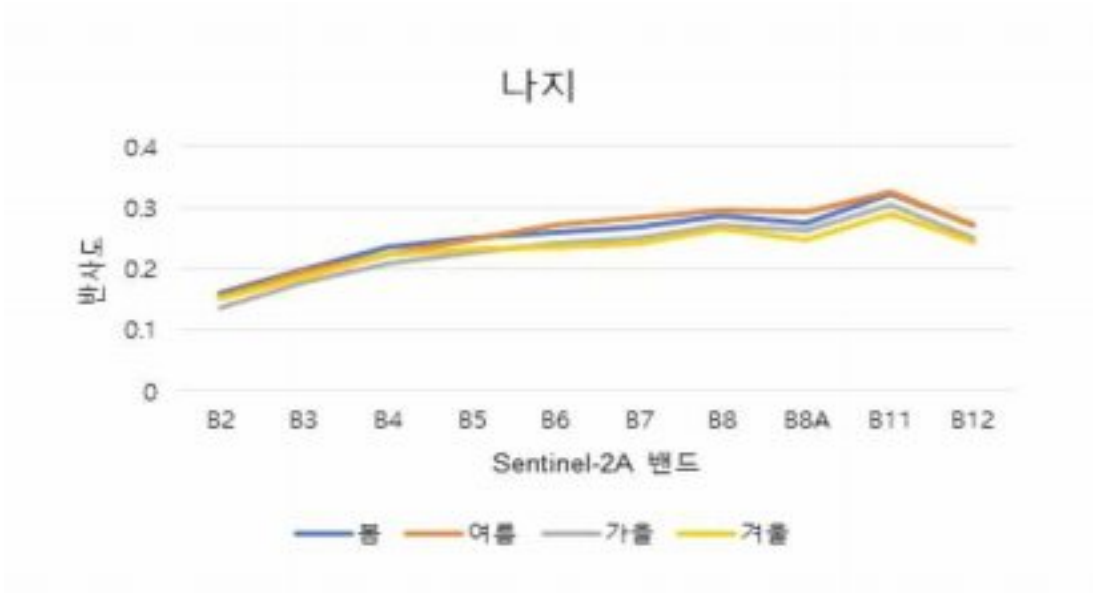


그림 4.2 나지 클래스 샘플의 Sentinel-2A 위성영상의 밴드 및 계절별 반사도 특성.

3) 기존 참조 자료 설명

낙동강 수변환경 분류를 위한 기계학습 모델의 훈련에 필요한 참조자료의 샘플링은 다음과 같은 기준을 고려하여 진행되었다. 먼저 Sentinel-2의 가시영상과 구글어스 고해상도 영상을를 비교하여 목지, 초지, 농경지, 나지, 건물, 비닐하우스, 그리고 수체의 7개 클래스에 대해 샘플링을 진행하였으며, 샘플링을 진행할 때, 양질의 참조자료를 획득하기 위하여 다음과 같은 기준을 고려하였다.

(1) Sentinel-2의 10m RGB 광학영상의 격자를 기준으로 3x3의 주변격자가 여러 가지 클래스로 복잡하지 않고 해당 격자가 순수하게 한 클래스를 가질 것
(2) 지상 참조자료를 구축함에 있어 토지피복 클래스가 수변환경에 고르게 분포할 것
(3) 선택된 격자는 구글어스 기준 최근 5년간 변화가 없을 것

4.2.2 수변환경 변화분석 알고리즘 검증의 공간적 범위

1) 수변환경 변화분석 알고리즘 검증의 공간적 범위

본 과업에서는 알고리즘 검증을 위해 기존 과업에서 정의한 국가 하천망도 기준 1km 범위에 더불어 댐별로 상시만수위에서 계획홍수위까지가 가용한 댐의 범위를 분석대상으로 하였다. 댐별 수위 자료는 국가수자원관리종합정보시스템(http://www.wamis.go.kr/; WAMIS)의 댐수문 자료에서 취득하였다. 취득된 자료를 바탕으로 수위에 따른 댐 지역의 수변환경 변화를 분석하였다.

4.2.3 기존 샘플 및 현장조사를 통한 위성활용 수변환경 변화 분석 알고리즘 검증

1) 알고리즘 검증을 위한 현장조사 개요

본 과업에서는 상술한 알고리즘의 한계점을 파악하고 개선안을 제시하기 위해 현장관측을 실시하였다. 먼저 현장관측 방식으로는 무인항공기(DJI Phantom4 Multispectral)를 이용한 항공촬영을 진행하였다. 사용된 무인항공기인 DJI Phantom Multispectral의 제원은 아래 붙임1 과 같으며, 무인항공기는 지표로부터 120m 높이에서 6cm급의 정밀한 공간해상도를 갖는 영상을 제작 가능하다. 이때, 전형적인 천연색(RGB) 밴드 이외에도 근적외선(NIR) 및 Red-Edge밴드가 사용 가능하며 때문에, 기존 위성영상의 m급 공간해상도에서 나타나지 않는 문제들을 파악할 수 있을 것으로 판단된다.

현장조사는 총 2회에 걸쳐 구미, 안동, 영주 지역을 2020년 11월 23일 ~ 2020년 11월 23일에, 합천 및 창녕지역을 2020년 12월 2일 ~ 2020년 12월 3일 조사하였다. 현장조사 관측일은 Sentinel-2 관측계획을 참고하여 가능한 위성영상과 가까운 날짜에 실시할 수 있도록 고려하였다. 현장조사를 통해 취득한 무인항공기 자료는 기존의 참조자료와 함께 개선된 알고리즘의 성능평가를 위해 활용하였다.

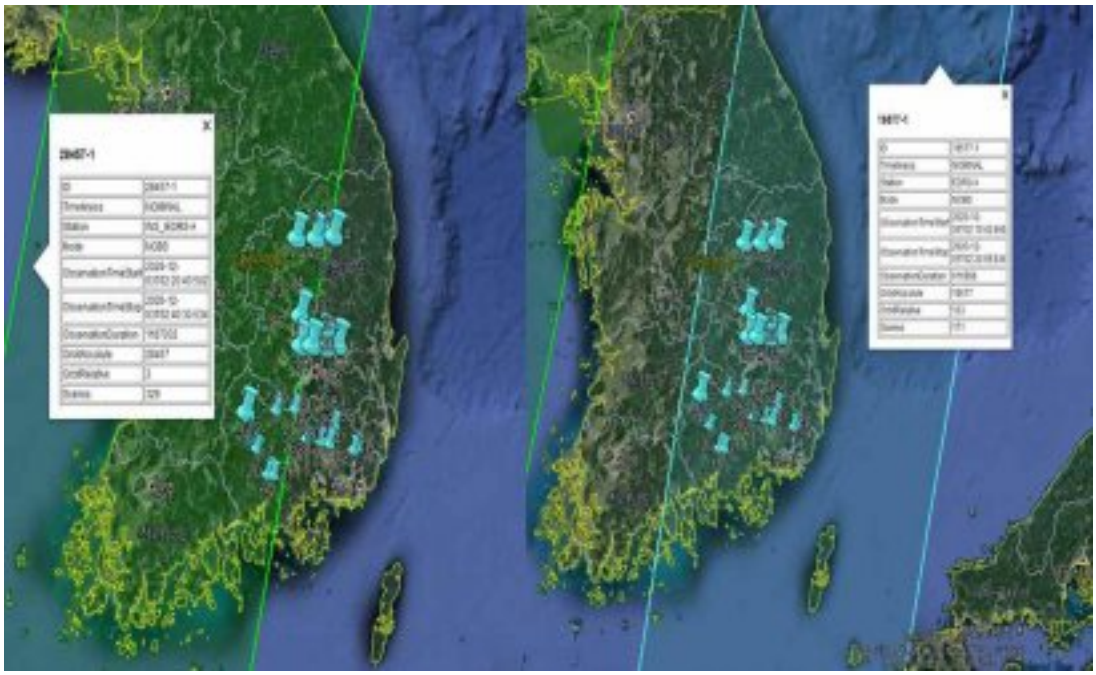


그림 4.3 Sentinel-2 관측 계획. 좌측은 Sentinel-2A의 관측계획

추가적인 현장관측에 더불어 기존 샘플을 사용해 알고리즘의 정확도를 평가하였다. 기존 알고리즘의 정확도 평가는 전체 샘플(n = 977) 에서 개개의 클래스별 임의로 추출된 80%의 자료를 사용해 토지피복 분류 알고리즘을 훈련하고 나머지 20%의 참조자료를 사용해 알고리즘의 평가를 진행하였다. 본 과업에서도 지난 과업과 동일한 방법으로 훈련 80% 검증 20% 비율로 검증을 진행하였다.

추가적인 현장자료를 통한 알고리즘 정확도를 평가할 때, 무인항공기를 이용하여 추가적인 현장자료를 수집한 뒤 육안판독을 통해 추가적인 샘플을 구축하고, 관측시간이 가장 가까운 Sentinel-2 영상으로 분류된 수변환경 분류지도와 비교하여 전체 정확도를 계산하는 방식으로 분류 알고리즘의 정확도를 검증하였다. 이때 혼동행렬을 사용하지 못한 이유는 아래 두 이유에 있다:

(1) 사용된 무인항공기의 체공시간이 충분하지 못하여 넓은 지역의 자료획득이 어려움
(2) 무인항공기가 관측하는 지역에 본 과업에서 다루는 모든 토지피복 클래스가 없음

4.2.4 유사한 반사도 특성을 보이는 식생지역 (농경지, 초지, 목지) 비식생지역(나지, 건물)에 대한 오분류 분석

1) 유사한 반사도 특성에 대한 오분류 분석

유사한 반사도 특성을 보이는 지역은 기계학습 모델에서 오분류가 발생하기 쉬운 문제가 있으므로, 그에 대한 오분류를 분석하였다.

특히 농경지, 초지 및 목지의 경우 가시광 영역에서는 반사도가 낮고 적외선 영역에서는 반사도가 높은 식생의 특징을 모두 갖고 있어, 클래스간의 구분에 어려움이 있었다. 또한, 이 클래스들의 계절변동성도 비슷한 경향을 나타내며 그 특성은 아래 그림 4.4와 같이 겨울이 되면 반사도가 낮아지는 패턴을 보인다. 그 결과로, 유사한 반사도 특성 및 경향을 가지는 세 클래스 간 오분류 예시는 아래 2019년 01월 13일의 광학영상 및 분류된 지도 영상에 잘 나타는데, 위성영상 취득시 태양 천정각에 따라 산 경사면이 농경지와 초지로 오뷴류된 것과 그림의 오른쪽 아래 그림자가 진 초지 부분이 목지로 오분류 된 것을 확인할 수 있다. 이를 통해 실제 토지피복이 다르더라도 비슷한 반사도 특성을 갖는 클래스 사이에서 태양천정각에 따라 클래스간 오분류가 일어날 수 있음을 확인하였다(그림 4.5).

나지와 건물, 비닐하우스는 낮은 가시광영역에서 낮은 반사도 패턴을 보이며 적외 영역에서 상대적으로 높은 반사도를 보이는 반사도특성을 가진다 (그림 4.4). 이들 토지피복의 시계열적 특성은 나지와 건물의 시간이 지남에 따라 경우완만한 경사를 보이며 변화하는 패턴을 보였으나,비닐하우스는 상대적으로 급한 경사를 보이며 두 클래스와는 다른 점을 보였다. 그러나, 세 클래스 모두 봄에 가장 높은 반사도를 보이고 계절간의 변동이 적은 경향은 비슷한 패턴을 보였다. 이러한 점에서 초지-목지-농경지의 오분류처럼 태양천정각에 따라 일사량과 위성관측시 입사각에 따라 반사도가 달라지면 나지-건물-비닐하우스 간의 오분류가 발생할 수 있음을 시사한다.

나지의 경우 강수 이후 건물이나 비닐하우스로 오분류되곤 하는데 이는 강수로 인해 토양이 젖음으로써 반사도의 변화가 일어남에 기인한 것으로 분석되었다. 나지로 분류된 지표의 경우 식생이 자라지 않은 모래톱이 많은데 이런 토양은 강수로 인하여 수분을 함유하게 될 경우 반사도가 낮아져 비슷한 반사도를 가지는 건물이나 비닐하우스로 오분류 될 가능성이 있다.

그 외에, 물의 경우 다른 클래스들과 확연히 다른 반사도 특성을 가져 오분류 될 확률이 낮았으며 오분류된 경우는 대부분 구름 그림자에 의해 토지가 낮은 반사도를 갖게 된 경우였다. (그림 4.6 위

사진이 강수 전 (2019년 5월 10일), 아래 사진이 강수 후 (2019년 5월 23일)). 구름 그림자에 의해 가려진 위치는 실제 기계학습에 훈련된 반사도와 다른 값을 가져, 기계학습 예측 결과에서는 오분류를 생산하는 결과를 확인하였다 (그림 4.7 및 그림 4.8)

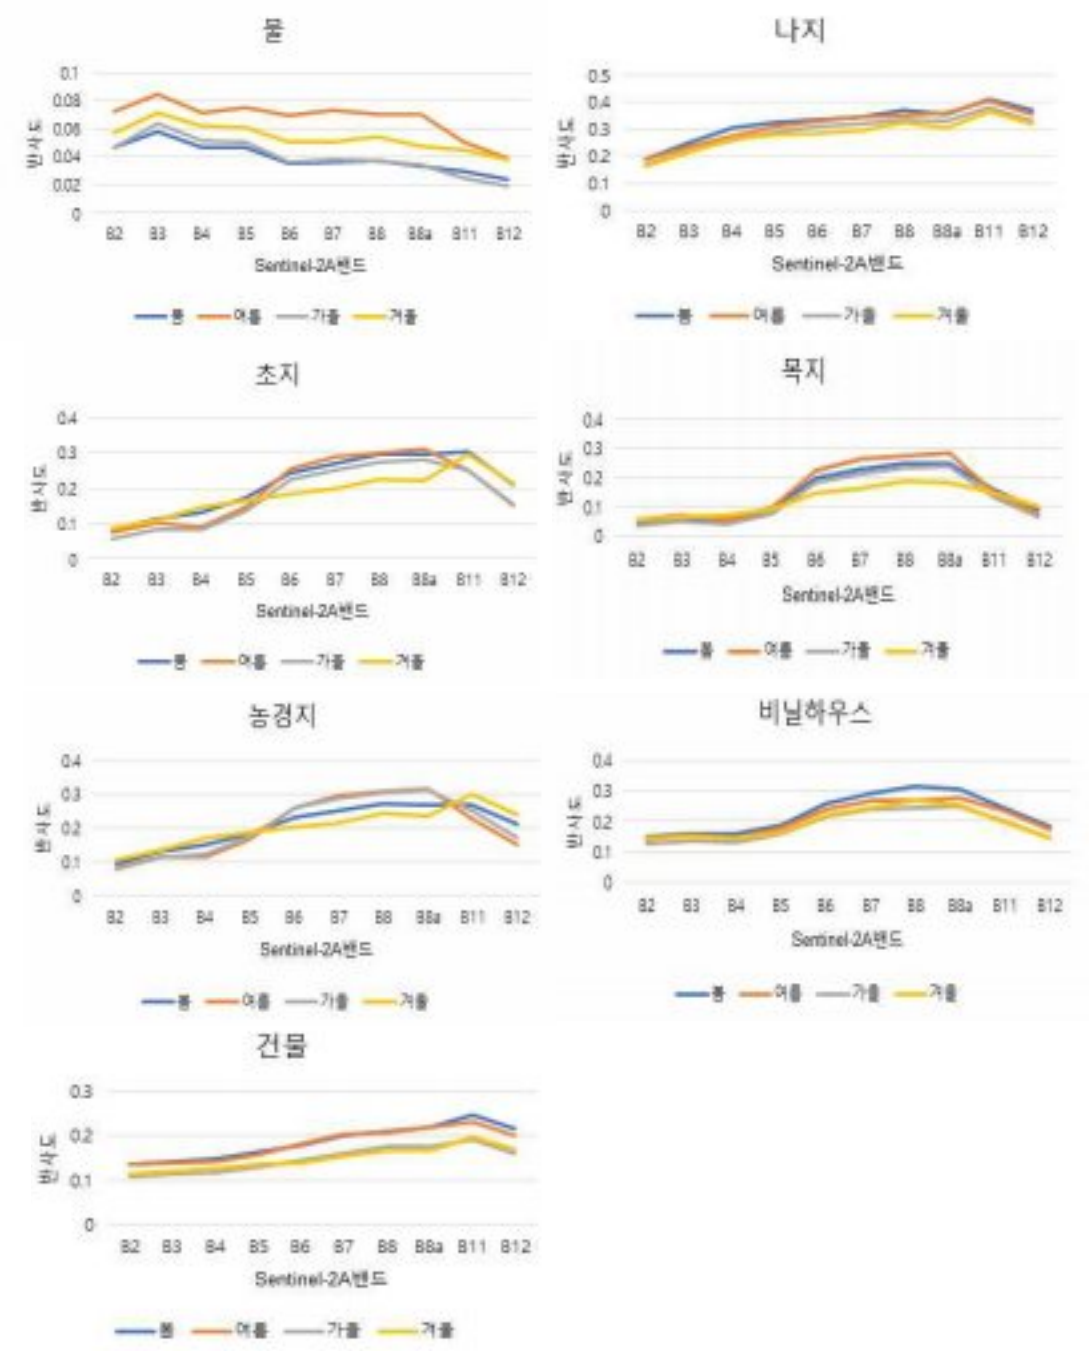


그림 4.4 낙동강의 수변 환경 인자별 (클래스별) 분광특성 정보

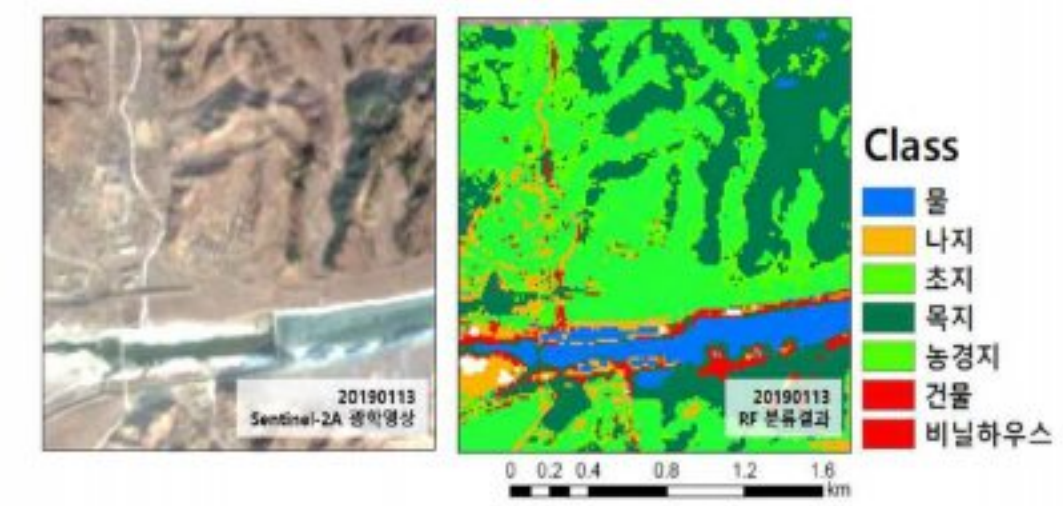


그림 4.5 초지와 농경지, 그리고 목지 클래스간의 오분류 예시

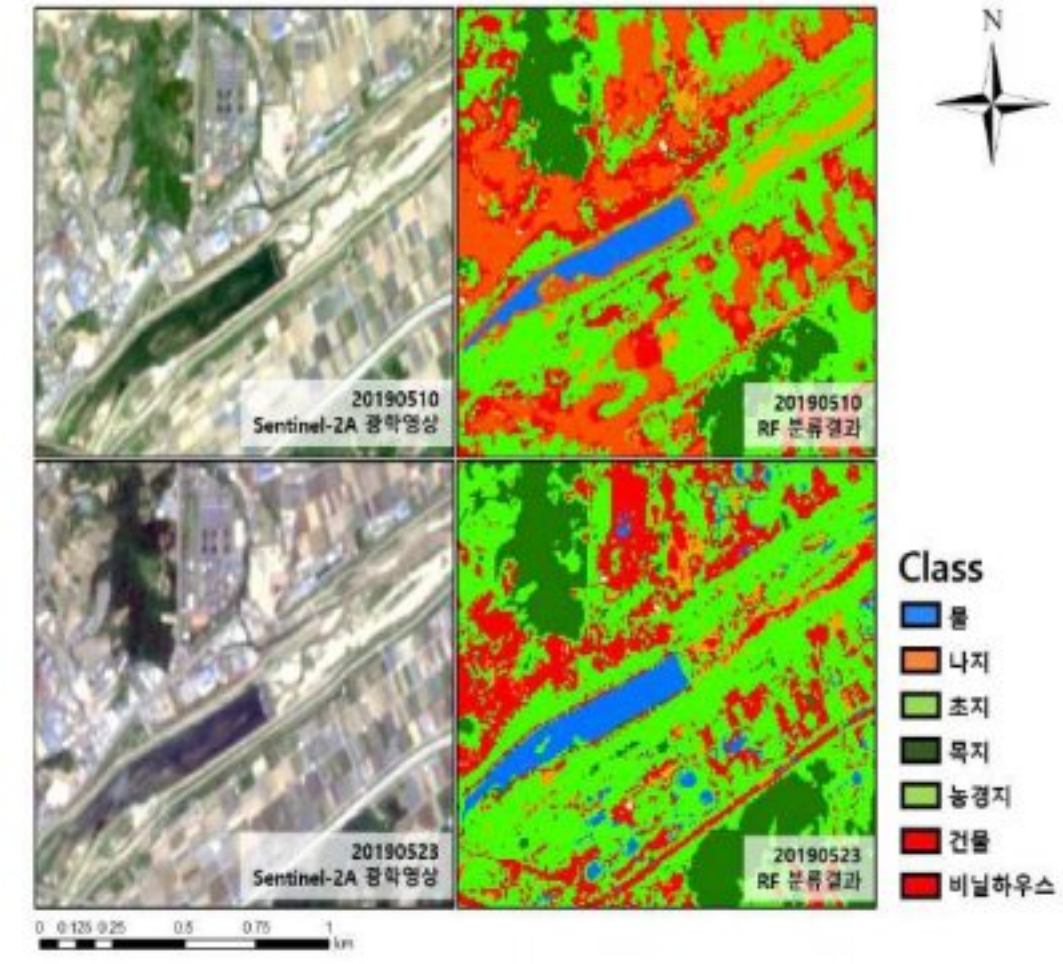


그림 4.6 낙동강 수변 환경의 강수 전후 분류 결과 비교

4.2.5 위성영상 자체의 문제 (구름, 그림자)로 인한 기존 알고리즘의 한계점 분석 및 오분류 원인별 특성

기존 알고리즘은 위성영상의 구름 및 그림자로 인한 한계를 가진다. 기존 알고리즘은 Sentinel-2 L2A 위성 영상과 함께 제공되는 구름 확률 자료 'MSK_CLDPRB_20m.jp2'를 이용하여 격자의 구름 확률이 70% 이상일 때 구름으로 판단 후 제거하는 방식을 사용하였다. 이때, 기준을 70%보다 낮게 설정할 경우 영상 내 구름이 제대로 제거되지 않았고 높게 설정할 경우 반사도가 높은 건물들이 함께 제거되어 알고리즘 수행에 영향을 미칠 수 있음을 확인하였다. 기준을 따라 구름을 제거하더라도 옅은 구름의 경우 제대로 제거되지 않는 경우가 존재해 격자의 반사도 값에 영향을 주었는데 대부분 반사도를 높이는데 기여하였고 다른 클래스의 토지 피복이 건물이나 비닐하우스로 오분류 되는 문제를 초래하였다. 또한 구름 그림자 아래에 있는 격자는 낮은 반사도를 갖게 되어 다른 클래스를 갖고 있음에도 불구하고 비슷한 반사도 값을 가지는 물로 오분류 되는 문제가 있음을 확인하였으며 이는 아래 그림 4.7 및 그림 4.8에 옅은 구름이 존재하는 격자의 경우 건물과 비닐하우스로 오분류 된 것과 접하는 부분이 물로 분류되며 구름 그림자가 물로 오분류되고 있음을 통해 확인 가능하다.

위와 같이 구름 및 그림자가 존재하는 경우, 그 지역에 실제 클래스와 다른 토지피복 클래스를 생산하기 때문에 신뢰도 높은 수변환경 변화 알고리즘을 구축하기 위하여 일반적 구름과 권운이나 권층운 같은 옅은 구름으로 분류되는 구름 및 구름 그림자를 제거하는 과정이 필요할 것으로 판단되었다.

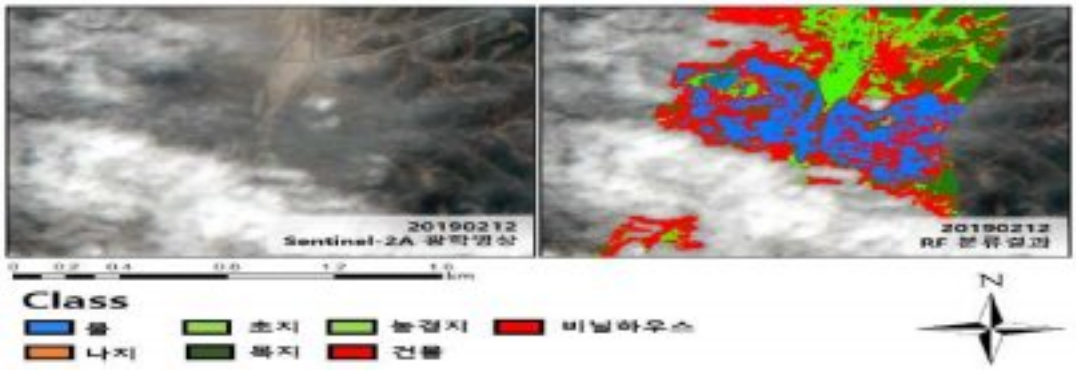


그림 4.7 낙동강 수변 환경 분류에 있어 구름이나 구름 그림자 영역이 물이나 기타 클래스로 오분류 된 예시

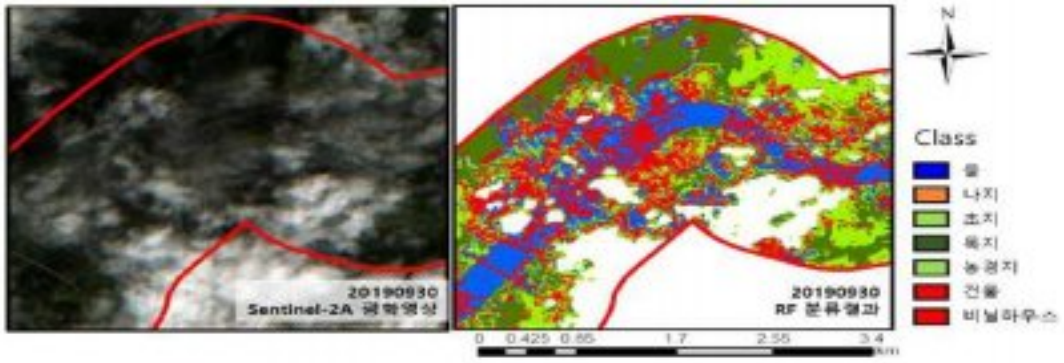


그림 4.8 영산강 수변 환경 분류에 있어 구름이나 구름 그림자 영역이 물이나 기타 클래스로 오분류 된 예시

4.3 알고리즘 개선 및 결과성능 검증

4.3.1 연구 개요

1) 위성영상자료

본 과업은 Sentinel-2 MSI의 Level-1C 대기상층반사도를 Sentinel-2 위성자료의 전용 전처리 프로그램인 Sen2Cor를 통해 L2A 지표반사도로 처리하여 사용하였다. Sentinel-2의 L1C를 사용하고 L2A 버전을 사용하지 않은 이유는 다음 절에서 사용한 Fmask4.0 구름 마스킹 알고리즘이 L1C자료를 통해 구름 마스크를 생산하기 때문이다.

Sentinel-2를 전처리 하는 과정에서 DEM correction을 사용하기 위해 CGIAR SRTM 자료를 이용하였다. Sen2Cor은 Linux의 GUI를 사용하지 않는 버전을 사용하였고, 프로그래밍 언어 python을 사용하여 자동화한 뒤 자료 전처리를 수행하였다.

표 4.2 과업에 사용된 Sentinel-2 각 밴드별 분광 영역, 파장대, 공간해상도 정보표.

Band	Sentinel-2A MSI		
	Spectral region	Wavelength range (nm)	Resolution (m)
2	Blue	458 - 523	10
3	Green	543 - 578	10
4	Red	650 - 680	10
5	Vegetation Red Edge	698 - 713	20
6	Vegetation Red Edge	733 - 748	20
7	Vegetation Red Edge	773 - 793	20
8	NIR	785 - 899	10
8a	Narrow NIR	855 - 875	20
11	SWIR	1565 - 1655	20
12	SWIR	2100 - 2280	20

낙동강 전체 수계 범위를 분석하기 위해 수집된 Sentinel-2 위성자료의 공간적 범위는 총 6개의 타일인 T52SDD, T52SDE, T52SDF, T52SED, T52SEE, T52SEF를 포함하며, 각 타일은 100km2 의 공간적 범위를 포함함 (그림 4.9) 수변환경의 식생의 계절 변동성을 고려하여, 과업의 시간적 범위는 2019년 10월부터 2020년 10월까지, 국내의 4계절을 모두 포함하도록 구성하였다. 자료취득은 Corpernicus Open Access Hub (https://scihub.copernicus.eu/)를 통해 이루어졌으며, 영상별 구름이 30퍼센트 이하인 자료만 취득하였기 때문에, 과업기간 내 위성영상 중 일별 구름양에 따라 일별 사용된 위성영상 수가 동일하지 않았다

.

위성영상 사용 시 Sentinel-2의 밴드 중 10m의 공간해상도를 갖는 밴드는 20m 공간해상도로 nearest neighbor 기법을 통해 resample하여 사용하였다.

과업에 사용된 Sentinel-2 의 밴드는 위 표 4.2와 같고, 분광지수를 계산하여 함께 기계학습의 입력변수로 사용하였다.

Corpernicus Open Access Hub에서 처리된 Sentinel-2 L2A 지표반사도 자료 및 Sen2Cor을 통해 처리된 L2A 자료 모두에서 제공하는 MSK_CLDPRB.jp2 구름 확률 마스크는, 기존 알고리즘에서 구름을 제거하는 방법으로 사용하였으나, 상술한 여러 가지 한계점을 확인하였다.

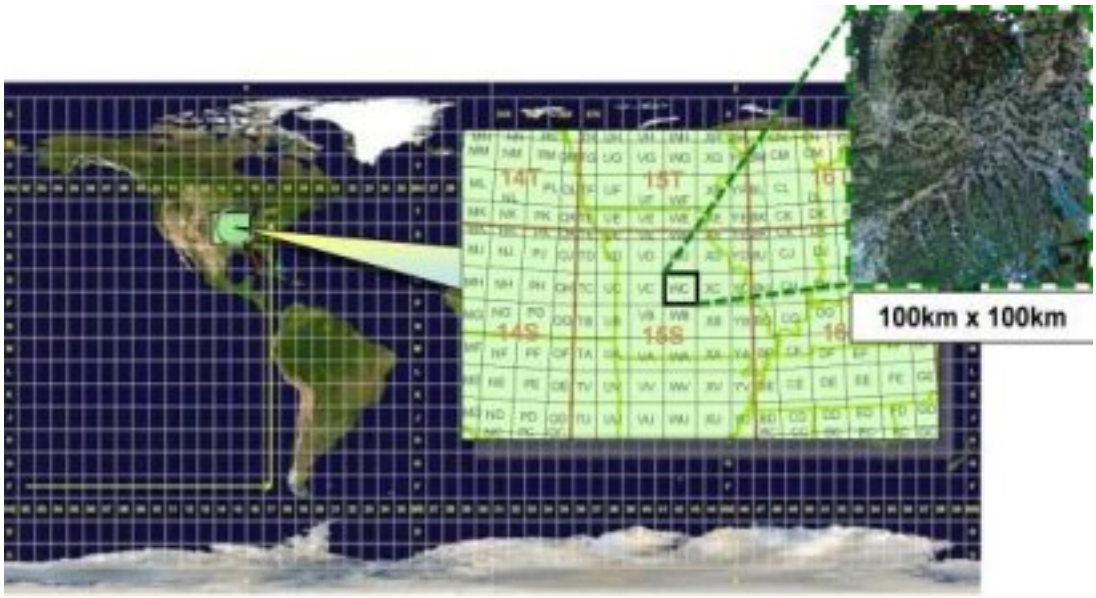


그림 4.9 Sentinel-2 위성의 타일 명명 체계 UTM 투영법에 따라 구분됨

2) 수변환경의 정의

수변환경은 강수에 따라 하천의 물이 불어나며, 최근 수요에 따라 개발이 이루어져 복잡한 토지피복으로 구성되는 특징이 있다. 본 과업에서는 이러한 수변환경의 특성을 고려하여 고해상도 위성영상을 이용하여 수변환경을 분석하고자 하였다. 이때, 수변구역의 범위는 「낙동강 수계 물관리 및 주민지원 등에 관한 법률」 제4조에 따라 하천 경계부터 500m ~ 1km 이내를 수변구역으로 정의하였고, 위의 법률 조항들을 기반으로 수자원공사와 협의하여 하천 경계부터 1km 이내를 수변구역으로 정의하였으며, 하천 경계자료는 국가수자원관리종합정보시스템에서 제공되는 국가 하천망도를 이용하였다.

3) 연구흐름의 개요

연구의 개요는 다음과 같다. 먼저 Sentinel-2영상을 전처리한 뒤 얻은 지표 반사도를 분광지수를 계산한 뒤 구름 마스킹 성능에 따라 참조자료와 매칭하여 기계학습 모델을 학습한 뒤 평가하고, 분광지수 기반 마스킹 방법의 적용성을 평가하였다. 이때 참조자료는 클래스별 80%를 훈련에, 20%를 검증에 사용하였고, 평가 후 결과인 기계학습 기반 수변환경 분류지도를 생산하였다. 생산된 수변환경 분류지도는 결측값 문제를 제거하기 위하여 최빈수를 이용해 계절별 지도를 생산하여 토지피복 변화탐지 지도 및 나지 증감 시계열 그래프를 생산하는데 사용되었다. 이때, 나지 면적은 수변환경 분류지도의 나지 격자 수 * 20 * 20m로 계산하였다.

이는 전체 연구흐름도인 아래 그림 4.10에 나타나 있으며, 연구지역인 낙동강 수변구역을 고려하여 아래 그림 4.11를 범위로 정하여 연구를 진행하였다.

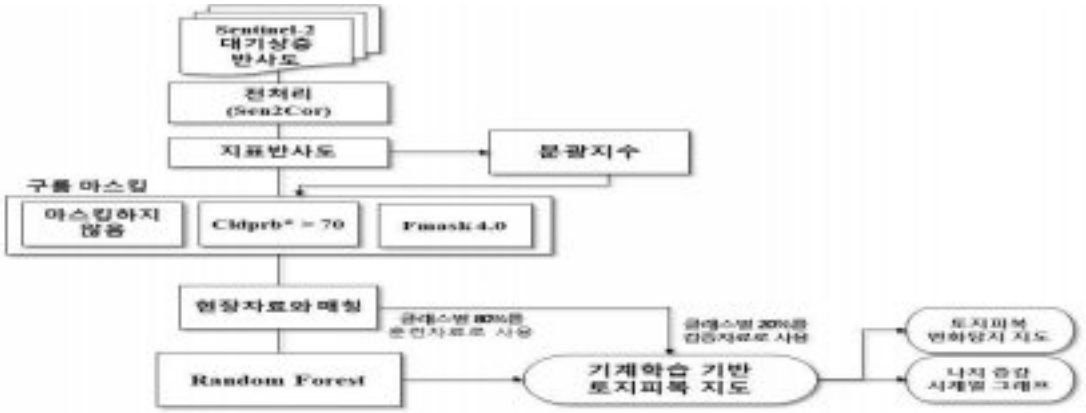


그림 4.10 본 연구의 연구흐름도

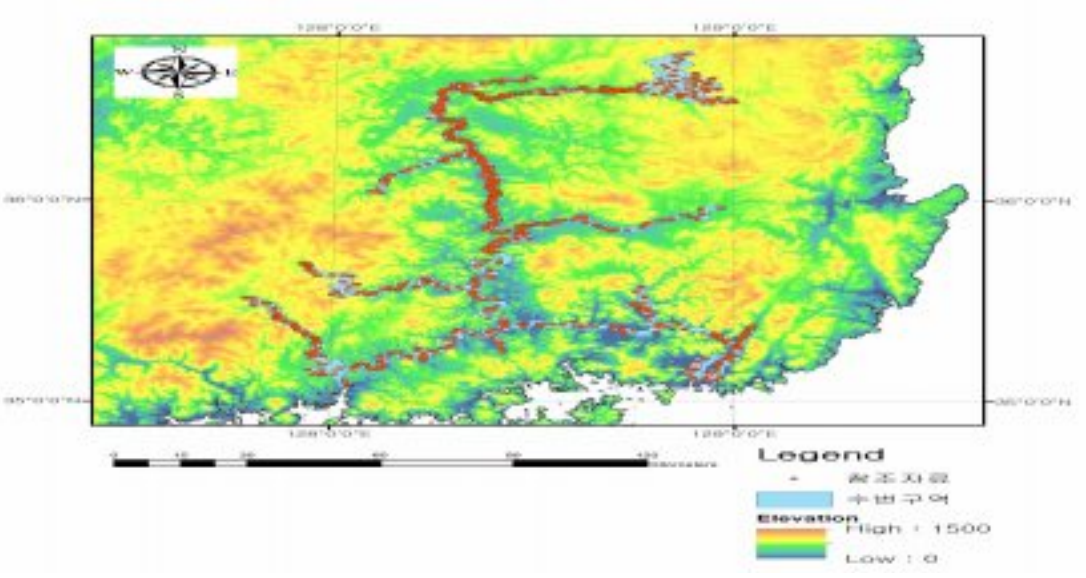


그림 4.11 본 과업의 공간적 범위

4) 기계학습 알고리즘

낙동강 수변 환경분류 모델은 기계학습 기법의 하나인 Random Forests (RF) 기법을 이용하여 구축하였다. RF는 분류 및 회귀 분석 등에 사용되는 앙상블 학습 방법의 일종으로, 훈련 과정에서 구성한 다수의 결정 트리로부터 부류 (분류) 또는 평균 예측치 (회귀 분석)를 출력함으로써 동작하는 모델이다. 랜덤 포레스트를 구성하고 있는 각가의 결정 트리는 동일한 확률분포를 가지지만 독립적으로 구성되어있다. 훈련자료를 임의적으로 선택하여 입력 변수의 조합을 임의적으로 선택함으로써 이상치 (outlier)의 영향을 최소화하고 변수의 상대적인 중요도, 오차 등을 내부적으로 계산할 수 있다.

변수 중요도는 out-of-bagging (OOB)을 통해 변수가 분류에 포함되지 않았을 때의 오차를 추정함으로써 산출된다. RF는 월등히 높은 정확성과 간편하고 빠른 학습 및 테스트 알고리즘, 그리고 임의화를 통한 좋은 일반화 성능 등의 장점으로 인해 최근 다양한 분야에서 사용되고 있다. 본 과업에서는 프로그래밍 언어 Python 기반 Scikit-learn 라이브러리 (sklearn.ensemble.RandomForestClassifier)를 사용하여 구축하였다.

Random Forests는 기존에 토지 피복 분류연구에서 빈번하게 사용되는 기법이며, 속도가 빠르다는 장점이 있다. 또한, 기존 연구들에서 여러 분류 문제 해결을 위한 기계학습 기법간 비교에서Random Forests 기법이 다른 기법에 비해 좋은 결과를 보여주었다.

수변 환경분류 모델의 종속변수는 지상 참조자료에서 구축한 바와 같이 물, 나 지, 초지, 농경지, 목지, 비닐하우스, 건물의 7개의 클래스로 하였다. 수변 환경분류 모델의 입력변수로서 광학 영상의 밴드 2~8A, 밴드 11~12까지의 지표면 반사도 값과 분광지수까지 총 15종의 변수를 사용하였다.

전처리에 방식에 따라 각 영상의 격자를 공간 해상도 20m로 변환한 뒤, 구축된 지상 참조자료의 좌표에서 영상과 참조자료의 값을 매칭하여 전체 데이터를 구축하였다. 기존 알고리즘과 달리 전체 연구기간동안 훈련자료가 위치한 격자의 반사도자료 및 분광지수 자료를 추출하여 Random Forest를 학습하였기 때문에, 기존 알고리즘에 비해 훈련자료가 충분히 많아지게 되었다. 알고리즘의 훈련 및 검증을 위해 각 클래스당 무작위 80%를 추출하여 모델 훈련자료로 20%는 모델 검증자료로 이용하였다. Random Forests 모델을 실행할 때 각 파라미터 값들은 함수에 내장된 기본 설정 (결정 트리 개수는 100개, 판단 기준은 Gini, 각 노드 분기 시 최소 샘플 개수는 2개)을 사용하였으며, 결정 트리의 최대 깊이와 트리의 마지막 노드의 개수는 제한하지 않았다. 이때 기존 알고리즘과 비교해 입력변수가 늘어난 만큼, Random Forest 알고리즘이 구성하는 개별 결정 트리가 다양성을 가질 수 있도록 max_features 파라미터를 'sqrt'로 변경하였고, 이는 개별 결정 트리를 구성할 때, 사용하는 입력변수의 개수를 총 개수의 제곱근 개수만큼 임의로 선택하여 사용하겠다는 의미이다.

5) 평가방법 및 평가지수

각 클래스의 분광학적인 특성을 고려하여 분류 알고리즘에서는 물, 나지, 초지, 농경지, 목지, 비닐하우스, 건물 총 7개 클래스로 분류하여 분석하였다. 개발된 분류모델의 정확도 평가를 위하여 분류모델의 성능평가에 널리 사용되는 전체 정확도 (OA; Overall Accuracy), 상자 그림 및 혼동행렬을 이용하여 클래스별 오차를 분석하였다 (김용민 등, 2010; 조원호 등, 2019; Clerici 등, 2017; Pereria 등, 2018).

전체 정확도의 계산식은 아래 수식 4.1과 같다:

$$\text{전체정확도}\ (OA) = \frac{\text{참조자료와 예측이 일치하는 경우}}{\text{전체 참조자료의 수}} \times 100\%$$

수식 4.1 전체정확도(overall accuracy) 산출식

혼동행렬의 대각성분은 예측과 참조자료가 일치하는 비율, 비대각성분은 예측자료와 참조자료가 일치하지 않는 비율을 나타냄. x축 및 y축 별 격자의 개수는 예측 및 참조자료의 클래스를 의미함 (아래 그림 전형적인 혼동행렬). 혼동행렬을 사용함으로써, 특정 클래스가 어떠한 다른 클래스로 오분류 되는가에 대해 시각적으로 확인할 수 있어 오류 분석에 효과적이다. (그림 4.12)

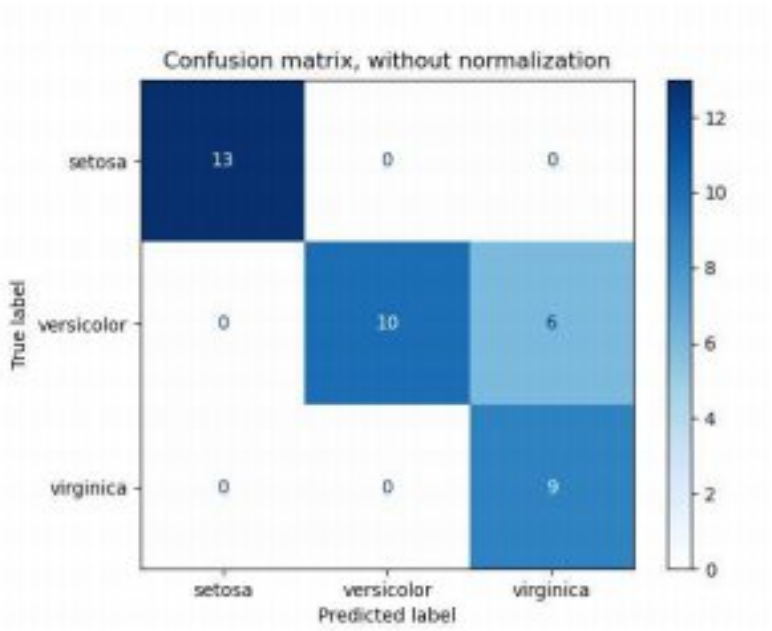


그림 4.12 혼동행렬 형태 예시

알고리즘의 클래스별 정확도의 분포를 확인하기 위하여 상자 그림(boxplot) 또는 상자-수염 그림(box-whisker plot)을 사용하여 평가하였다. 상자그림은 자료로부터 얻어낸 5가지 통계량인 최솟값, 제 1 사분위, 제 2사분위, 제 3사분위, 최댓값을 사용하여 자료의 분포를 설명 할 수 있다.상자의 아래부터 위로 제 1사분위, 제 2사분위, 제 3사분위를 나타낸다. 이때, 상자의 양 끝단에서 이어진 부분은 제 3사분위와 제1사분위의 차이로 그려지며 이 범위를 넘어서는 값을 이상치로써 점으로 표현한다. (그림 4.13)

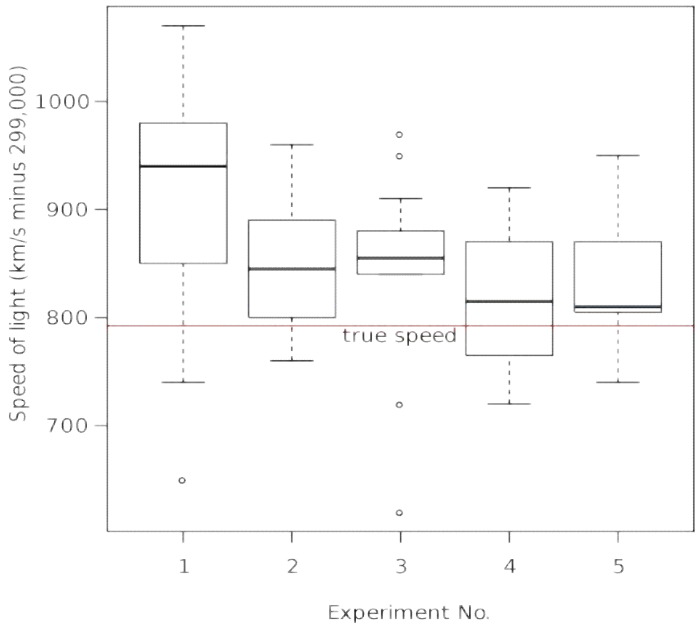


그림 4.13 상자 그림의 형태 예시

6) 검증의 공간적 범위

검증의 공간적 범위는 위 그림 4.11에서 제시한 것과 같이 기존 과업에서 정의한 국가 하천망도 기준 1km 범위에 더불어 댐별로 상시만수위에서 계획홍수위까지가 가용한 댐의 범위를 분석대상으로 하였다. 댐별 수위자료는 국가수자원관리종합정보시스템(http://www.wamis.go.kr/; WAMIS)의 댐수문자료에서 취득하였다. 취득된 자료를 바탕으로 수위에 따른 댐 지역의 수변환경 변화를 분석하였다.

4.3.2 식생(광학)지수 사용을 통한 알고리즘 개선

1) 수변환경 변화탐지에 사용 가능한 최적의 광학기반 식생지수 실험

본 과업에서는 기존 알고리즘에서 사용된 Sentinel-2 의 2, 3, 4, 5, 6, 7, 8, 8A, 11 및 12번 밴드의 반사도 이외에 추가적으로 다음과 같은 분광지수를 추가로 사용하여 기계학습의 입력변수로 사용하였다.

(1) NDVI (Normalized Difference Vegetation Index; Rouse 외 1974),

(2) NDWI (Normalized Difference Water Index; McFeeters, 1996),
(3) NDII7 (Normalized Difference Infrared Index; Wang 외, 2008),
(4) NDSI (Normalized Difference Soil Index; Rogers 외, 2004),
(5) NDBI (Normalized Difference Built Index; Zha 외, 2003)

분광지수는 반사도값들을 지수화하여 평활화하기 때문에, 반사도값이 가지는 특정을 강조하여 효과적으로 필요한 정보를 강조할 수 있는 장점이 있다. 이들은 Sen2Cor를 통해 전처리를 마친 지표반사도를 사용하여 계산되며 각 분광지수에 대한 계산식은 아래 수식 4.2 - 4.6와 같다.

$$NDVI = \frac{Band\,8a - Band\,4}{Band\,8a + Band\,4}$$

수식 4.2 NDVI 산출식

$$NDWI = \frac{Band\,3 - Band\,8a}{Band\,3 + Band\,8a}$$

수식 4.3 NDWI 산출식

$$NDII7 = \frac{Band\,8a - Band\,12}{Band\,8a + Band\,12}$$

수식 4.4 NDII7 산출식

$$NDSI = \frac{Band\,11 - Band\,8a}{Band\,11 + Band\,8a}$$

수식 4.5 NDSI 산출식

$$NDBI = \frac{Band\,8a - Band\,11}{Band\,8a + Band\,11}$$

수식 4.6 NDBI 산출식

아래 그림 4.14 박스플롯 은 낙동강 수변환경 참조자료의 전체 과업기간의 위성영상으로부터 계산된 클래스별 분광지수의 박스 플롯으로, 각 클래스별로 분광지수의 특성을 확인할 수 있었다.

2) 수변환경 인자별 분광특성 비교

NDVI는 근적외 파장과 적색 파장을 이용하여 식생의 활력도를 평가할수 있는 지수이다. 식생에서 근적외선의 반사율이 높게 나타나는 것을 활용하여 만든 지수이며 활력도가 높거나 밀도가 높은

경우 높은 값을 보이고 반대의 경우 낮은 값을 보인다. 값은 -1에서 1까지의 범위를 가진다. 이는 식생의 분포를 파악하는 데에 널리 이용되는 지수로 본 과업에서 사용함에 있어 식생 분류 및 초지와 나지 분류에도 도움이 될 것으로 기대된다. 목지가 평균적으로 가장 높은 NDVI 값을 가지고, 그 다음으로 나지, 농경지가 높은 값을 가짐을 확인하였고, 건물 클래스의 중앙값이 농경지보다 더 높게 측정되어 있으나 이는 샘플 수의 차에서 나오는 결과로 분석할 수 있다.

NDWI는 강이나 하천 같은 수체를 분석하기 위해서 사용되는 지수로, 녹색 파장과 근적외 파장을 이용하여 계산할 수 있다. 물은 근적외 파장의 빛을 흡수하는 특징을 가져 해당 파장대에 대하여 낮은 반사도를 보이고 녹색 파장에서는 높은 반사도를 보이는 것을 활용한 것으로 값의 범위는 -1에서 1까지이고 1에 가까울수록 수체라고 해석할 수 있다. NDWI의 경우 -1에서 0까지의 값을 가지면 식생과 물이 존재하지 않는 밝은 지표로 해석할 수 있는데 이를 통해 수체와 주변의 토지 피복 분류를 할 수 있을 것으로 기대하였다. 아래 그림 박스플롯 을 보면 물은 0보다 높은 값을, 나머지 클래스들은 0보나 낮은 값을 가짐으로 NDWI는 수체를 분류하기에 적절한 지수로 판단할 수 있다. 나지의 경우 평균적으로 -0.2 정도의 값을 가지고 건물과 비닐하우스도 이와 비슷한 값을 가져 초지, 목지, 농경지와의 구분이 가능할 것을 기대할 수 있다.

NDII7은 근적외 파장과 단파적외 파장을 이용한 지수로 물이 근적외 파장의 빛을 매우 잘 흡수하는 특징을 활용한 지수이다. 수체에 민감하게 반응하여 수체 탐지에 활용할 수 있고 토양 수분 및 식생의 수분 포함 정도 추정 가능성을 기대할 수 있다. 아래 그림 박스플롯 에서는 각 클래스간 값의 범위 분포가 산발적으로 이루어져 단일 값만을 이용한 토지 피복 분류에는 한계점이 있을 수 있으나 해당 샘플들의 지수 값들이 연간의 값들을 모은 것이란 것을 감안하였을 때 계절성을 고려한 뒤 분석할 필요가 있다.

NDSI는 Rogers(2004)에 따르면 토지의 반사도가 단파 적외 영역에서 적외 영엽보다 더 높은 반사도를 보이는 것에서 착안된 지수로 나지가 될 수 있는 토양과 도시지역의 불투과성 지표를 구분할 수 있을 것으로 기대된다. 아래 그림 박스플롯 을 보면 각 클래스별 값의 범위 분포가 비슷한 모습을 볼 수 있는데 이 또한 계절성을 고려한 분석이 필요할 것으로 보인다.

NDBI는 도시 지역을 분류하는 데에 쓰이는 지수로 초지, 목지와 달리 도시 지역에서는 단파 적외에서 높은 반사도를 가지고 근적외에서 비교적 낮은 반사도를 가지는 특성을 활용하였다. 값의 범위는 -1부터 1이며 0보다 낮은 값을 가지는 곳은 도시 지역으로 분류될 수 있다. NDBI는 아래 그림 박스플롯 에서 NDSI와 값이 반대되는 형상을 보이는데 이 또한 값의 범위 분포가 비슷하여 계절성을 고려한 분석후 활용하는게 필요하다.

분광 지수는 각 토지 피복의 파장별 반사도 차이를 봄으로써 기존 알고리즘에서 다중 분광 반사도만을 고려한 부분에서 나타났던 한계점, 초지-목지, 나지-빌딩과 같이 비슷한 특징을 가지는 곳들에서 오분류가 일어나는 점을 해결할 수 있는 방안으로 판단된다.

NDVI를 사용함으로써 식생의 활력도를 고려할 수 있게 되어 초지와 목지의 분류 정확도 향상을 기대할 수 있고 NDWI을 이용하여 수체와 주변 지역에 대하여 뚜렷한 분류를 기대할 수 있을 것이다. 나지와 건물의 반사도는 각 밴드별로 비슷한 값을 가지며 변화하는 경향 또한 비슷하여 각 샘플의 다중 분광 반사도 값에 대한 면밀한 분석 후 여러 분광 지수를 사용하여 분류를 시행한다면 효과적으로 오분류 확률을 낮출 수 있을 것으로 기대된다.

박스 플롯을 그리기 위해 사용한 농경지의 샘플 수는 8780개, 건물의 샘플 수는 4160개이다. 물의 평균 NDVI 값은 음의 값을 가짐으로 이를 통하여 NDVI 지수를 이용한 토지 피복 분류의 가능성을 기대할 수 있다.

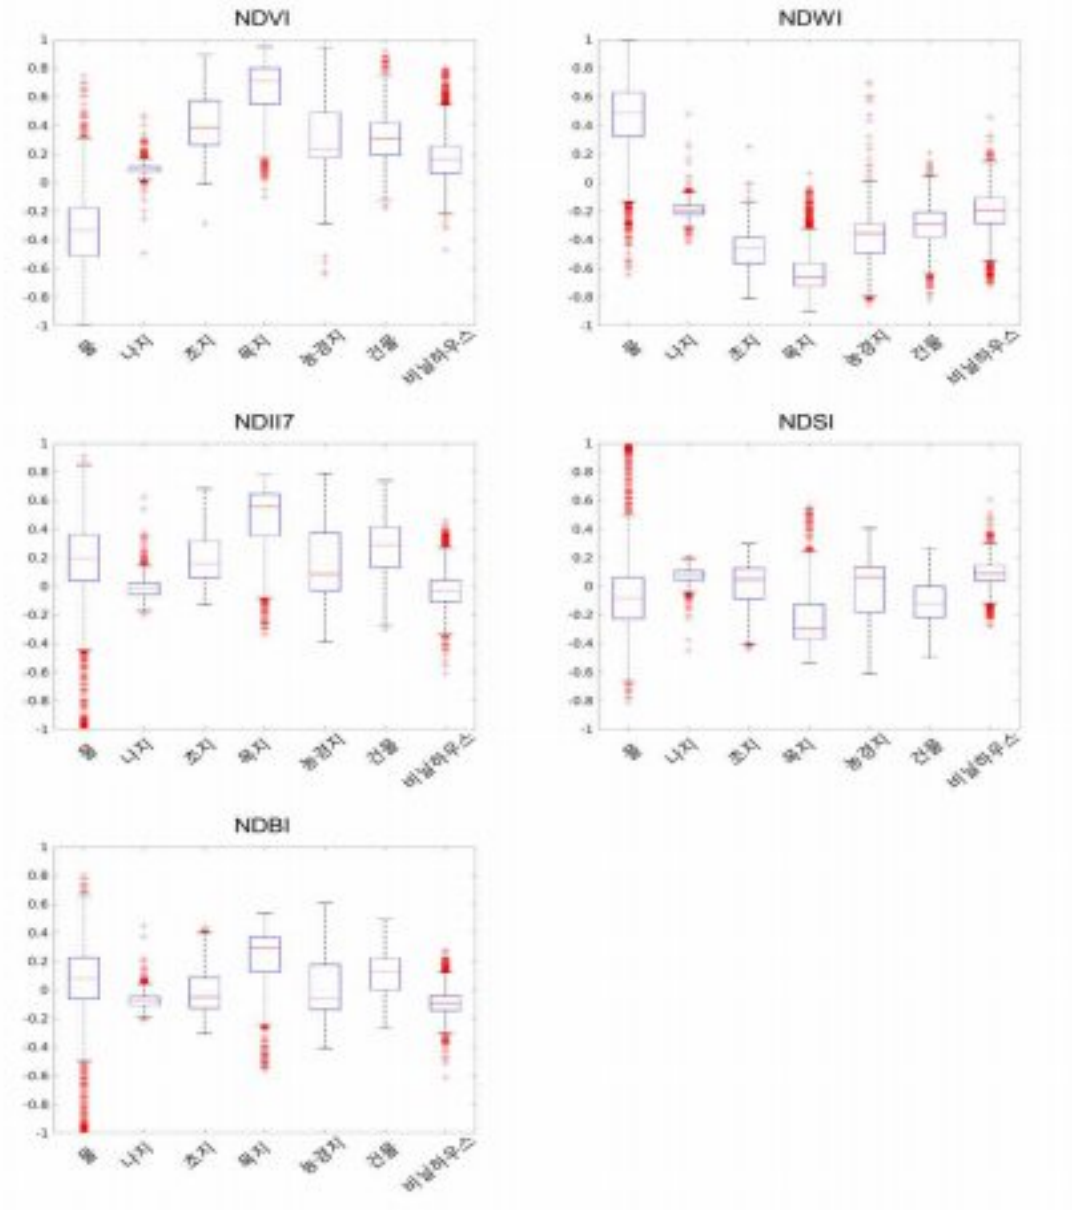


그림 4.14 각 분광지수 NDVI, NDWI, NDII7, NDSI, NDBI의 클래스별 박스 플롯

4.3.3 추가적인 참조자료 구축을 통한 알고리즘 정확도 개선 및 평가

1) 육안 판독을 통해 구축한 지상참조자료

낙동강 지상 참조자료는 Google Earth에서 제공하는 고해상도 영상 및 Sentinel-2 영상을 바탕으로 육안으로 판독하여 구축하였다.

기존 알고리즘의 경우 수변 환경은 7개의 클래스 (물, 나지, 초지, 목지, 농경지, 비닐하우스, 건물)로 구분하였으며, 수변 환경을 분석할 때에는 농경지는 초지에 포함하고 비닐하우스와 건물을 기타로 재분류하여 최종적으로 물, 나지, 초지, 목지, 기타의 5개의 클래스로 구분하였다. 기존 과업에서 7개의 클래스로 구분하여 지상 참조자료를 구축한 이유는 클래스마다 광학적인 특징이 다르게 나타나기 때문이며, 후에 분석을 위해 5개의 클래스로 재분류하였다.

이번 연구에서는 보다 상세한 분석을 위해 5개의 클레스로 재분류 하지 않은 상태의 7개의 클래스의 수변환경 분류지도를 사용해 분석을 실시하였다.

Google Earth 프로그램에 Sentinel-2A 영상의 10 m 공간해상도에 맞춘 격자를 오버레이한 후 3x3 근접영역 (30m x 30m)에 대해 최근 5년간 변화가 없는 픽셀을 선택하였다 (그림 4.15). 이때, 지상참조자료 구축 시 모든 토지 피복 클래스가 공간적으로 고르게 분포하도록 고려하였으며, 구축된 자료는 ArcMap을 통해 '.kmz'에서 '.shp'으로 변환 후 위·경도 값과 클래스 번호 (물: 0, 나지: 1, 초지: 2, 목지: 3, 농경지: 4, 비닐하우스: 5, 건물: 6)를 부여하였다.

또한, 이번 연구에서는 Fmask를 통해 지난 과업에서의 한계였던 구름의 오염으로 인해 참조자료의 수가 제한되는 한계를 제거하였다. 지난 과업에서는 각 날짜의 영상별로 훈련자료 및 검증자료를 취득하여 알고리즘을 구성하였으나, 본 연구에서는 구름 및 구름의 그림자를 제거하여, 전체 연구기간 내 구름과 구름 그림자에 오염되지 않은 모든 현장자료를 사용할 수 있게 되었고, 기계학습에 참조자료로 사용 가능한 자료의 수를 크게 증가시킬 수 있었다.

2) 무인항공기 기반 항공촬영 참조자료

본 과업에서는 상술된 알고리즘의 한계점을 파악하고 개선안을 제시하기 위해 추가적인 현장관측을 실시하였다. 현장관측 방식으로는 무인항공기(DJI Phantom4 Multispectral)를 이용한 항공촬영을 진행하였다. 사용된 무인항공기인 DJI Phantom Multispectral의 제원은 붙임1과 같다. 사용된 무인항공기는 지표로부터 120미터 높이에서 6cm급의 정밀한 공간해상도를 갖는 정사영상을 제작가능하며 전형적인 천연색(RGB) 밴드 이외에도 근적외선(NIR) 및 Red-Edge밴드가 사용 가능하기 때문에, 기존 위성영상의 m급 공간해상도에서 나타나지 않는 문제들을 파악 할 수 있을 것으로 판단된다.

현장조사는 총 2회에 걸쳐 구미, 안동, 영주 지역을 2020년 11월 23일 ~ 2020년 11월 23일에, 합천 및 창녕지역을 2020년 12월 2일 ~ 2020년 12월 3일 조사하였다. 현장조사 관측일은 가능하면 Sentinel-2 관측 계획을 참고하여 위성영상과 가까운 날짜에 현장관측을 실시할 수 있도록 고려함. 무인항공기로 관측한 영상에서 육안을 통한 판독을 통해 나지 클래스의 참조자료를 샘플링한 뒤, 가까운 날짜의 Sentinel-2 기반 수변환경 분류지도와 비교·분석하였다.

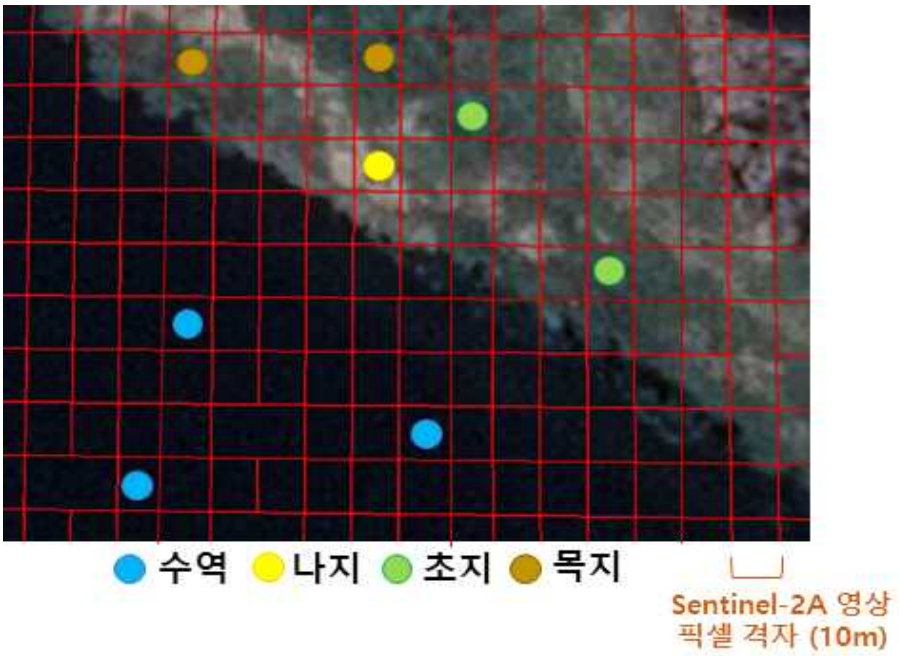


그림 4.15 Google Earth 및 Sentinel-2 영상을 이용한 지상 참조자료 구축 예시

4.3.4 수위변화에 따른 나지 증감 파악을 위한 알고리즘 고도화

1) 수변환경 인자의 채널별 민감도 분석

기존 알고리즘에서 한계로 지적되었던 알고리즘의 나지 탐지능력을 고도화하고 수위변화에 따른 나지 증감 파악을 가능하게 하기 위하여, 분광지수를 추가하고, 분광지수의 클래스별 특성을 분석하였다.

낙동강의 클래스별 분광특성은 아래 그림 4.16과 같다. 그래프를 작성할 때, 더욱 신뢰도 높은 클래스별 분광특성에 대한 분석을 위해서, Fmaks를 사용하여 구름과 구름의 그림자를 모두 제거한 뒤 반사도 및 분광지수의 시계열 값들을 취득하여 평균한 뒤 그래프를 작성하였다.

본 과업에서는 지난 과업에서 사용한 반사도 값 이외에 분광지수를 추가하였는데, 그 결과 지난 과업에서 확인하지 못했던 각 클래스의 계절별 변화패턴을 확인할 수 있었다. 이는 특히 초지, 농경

지 및 목지에서 NDVI 지수의 값이 뚜렷한데, NDVI 값이 겨울 < 봄 < 가을 < 여름 순으로 일반적인 식생의 생장패턴을 따라가는 것을 확인할 수 있다. NDII, NDBI에서도 NDVI보다 적은 강도이지만 비슷한 계절별 패턴을 확인할 수 있으며, NDSI에서는 NDVI와는 반대되는 패턴으로 겨울 > 봄 > 가을 > 여름 순으로 높은 값을 보이고 있음을 확인하였다.

그러나, 초지, 농경지 및 목지가 시계열적으로 달라지는 패턴을 보여줌에도 불구하고 세 클래스는 입력변수에 따른 패턴이 굉장히 유사하므로 세 클래스 사이에서 오분류가 발생할 가능성이 높다. 수체의 경우, NDVI값이 상당히 낮은 값을 보이며, 반면 NDWI값이 상당히 높은 값을 보이므로, 이 두 지수가 크게 관여하여 모델 학습에 크게 기여할 것으로 기대되었다. 나지와 건물, 비닐하우스의 경우 지난 과업에서와 같이 반사도패턴의 계절별 특성이 크게 나타나지 않았다. 건물 클래스의 경우, 비닐하우스 및 나지 클래스와 다르게 상대적으로 NDBI에서 높은 값을 보이기 때문에, 기계학습 알고리즘이 이 특성을 통해서 분류 성능을 높일 수 있을 것으로 기대되었다.

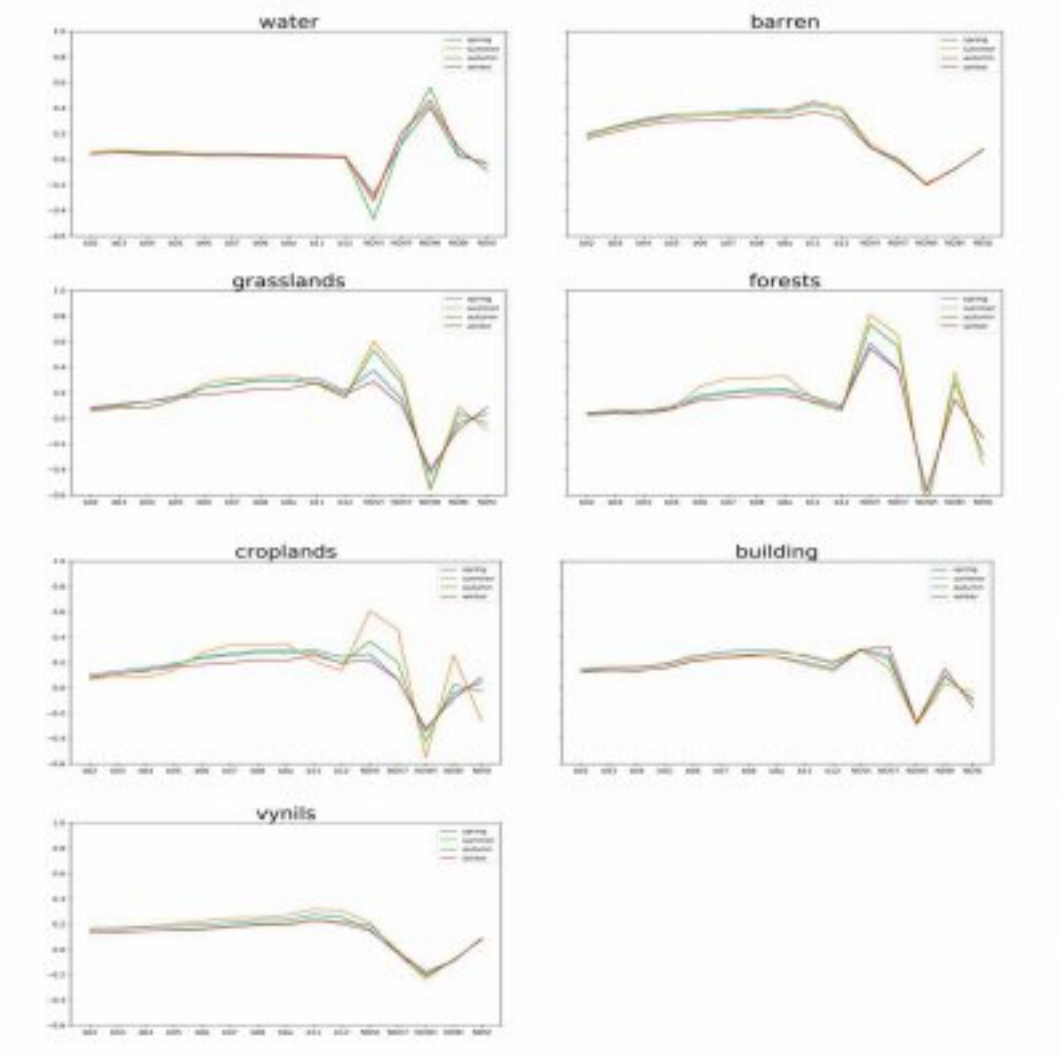


그림 4.16 낙동강의 계절별 클래스별 Sentinel-2 위성의 분광특성

4.3.5 샘플 수 조정을 통한 알고리즘 고도화

4.3.3에서 언급한 바와 같이, Fmask를 통해 구름의 오염으로 인해 참조자료의 수가 제한되는 한계를 제거하였다. 구름 및 구름의 그림자를 제거하여, 전체 연구기간 내 구름과 구름 그림자에 오염되지 않은 모든 현장자료를 사용하여, 기계학습에 참조자료로 사용하였다.

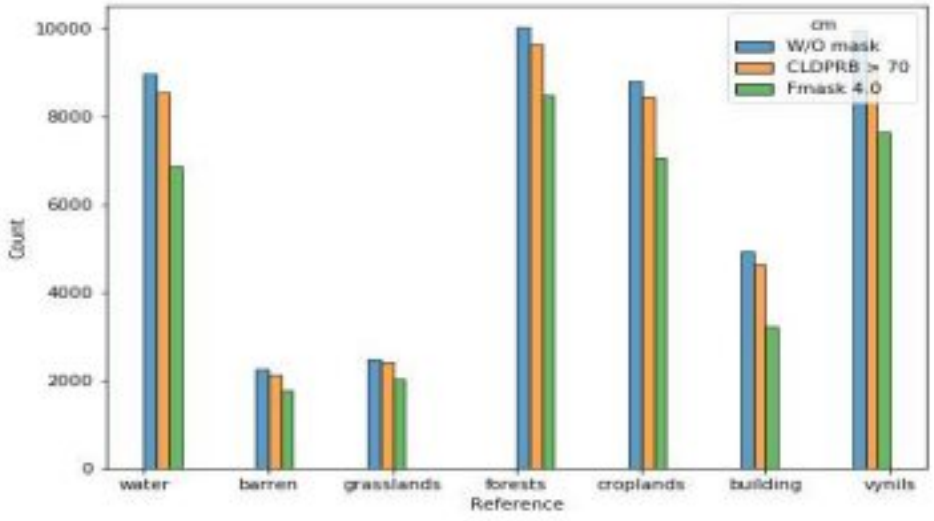


그림 4.17 구름 마스킹에 따른 훈련자료에 사용된 참조자료 수 차이

4.3.6 구름 및 구름 그림자 제거를 통한 오분류 최소화 및 시계열 분석

1) 구름 마스킹 방법

광학 위성영상에서 구름의 제거는 위성영상을 이용한 알고리즘 개발 시 알고리즘의 개발의 신뢰도를 높이기 위해 필수적인 부분이다. 기존 알고리즘에서 사용된 구름 마스킹 방법은 일반적인 구름 탐지에는 문제가 없었으나, 권운과 같이 옅은 구름 및 구름의 그림자 탐지에 한계를 보였기 때문에 본 과업에서는 구름 마스킹 성능에 따라 바뀌는 오염된 반사도값을 제거하는 것이 최종 알고리즘의 성능 향상에 영향을 미칠것이라는 가정을 바탕으로 다음과 같은 3가지 구성을 실험하였다:

(1) Womaks: 구름을 마스킹 하지 않은 경우,
(2) Cldprb: Sentinel-2 의 기본 구름 마스크 파일인 MSK_CLDPRB의 임계값 70을 적용하여 구름을 마스킹 (기존 알고리즘),
(3) Fmask: Qiu 등, (2019)에서 제시한 Fmask4.0 알고리즘을 적용하여 구름 및 구름 그림자를 탐지

세가지 실험 구성을 통해 구름을 마스킹 한 뒤 마스킹된 위성영상을 바탕으로 기계학습을 훈련한 뒤, 구축된 참조자료를 통해 평가하였다.

2) Fmask 4.0

Fmask 4.0은 Qiu 등, (2019)가 제시한 자동화된 Landsat 4-8 Colloection 1 Level 1자료 및 Sentinel-2 L1C 자료를 이용하여 다중의 단계를 거치는 결정나무 알고리즘을 통해 구름 및 구름 그림자를 탐지하는 알고리즘으로, 구름, 구름 그림자, 눈, 수체 그리고 육지 총 5개의 클래스를 탐지해냄 (그림 4.18). Fmask는 현재 많은 연구에서 구름을 제거하기 위해 사용되며 특히 Landsat 이미지의 기본 구름 탐지 알고리즘으로 적용되어 사용중이다. Fmask는 현재 Github을 통해 무료로 프로그램을 배포하고 있으며, Matlab, Linux, Winodws와 같이 다양한 프로그램 또는 OS에서 사용할 수 있는 장점이 있다 (https://github.com/GERSL/Fmask). Fmask 4.0은 프로그래밍 언어 python을 사용하여 손쉽게 자동화해서 사용할 수 있는 장점이 있어 본 과업에서는 Linux 버전의 Fmask4.0을 기반으로 하여 프로그래밍 언어 python을 사용해 자동화한 뒤 Sentinel-2 영상의 구름 및 구름 그림자 마스크를 산출하였다. Fmask를 사용 시 입력 가능한 파라미터는 기본 파라미터를 사용하였다.

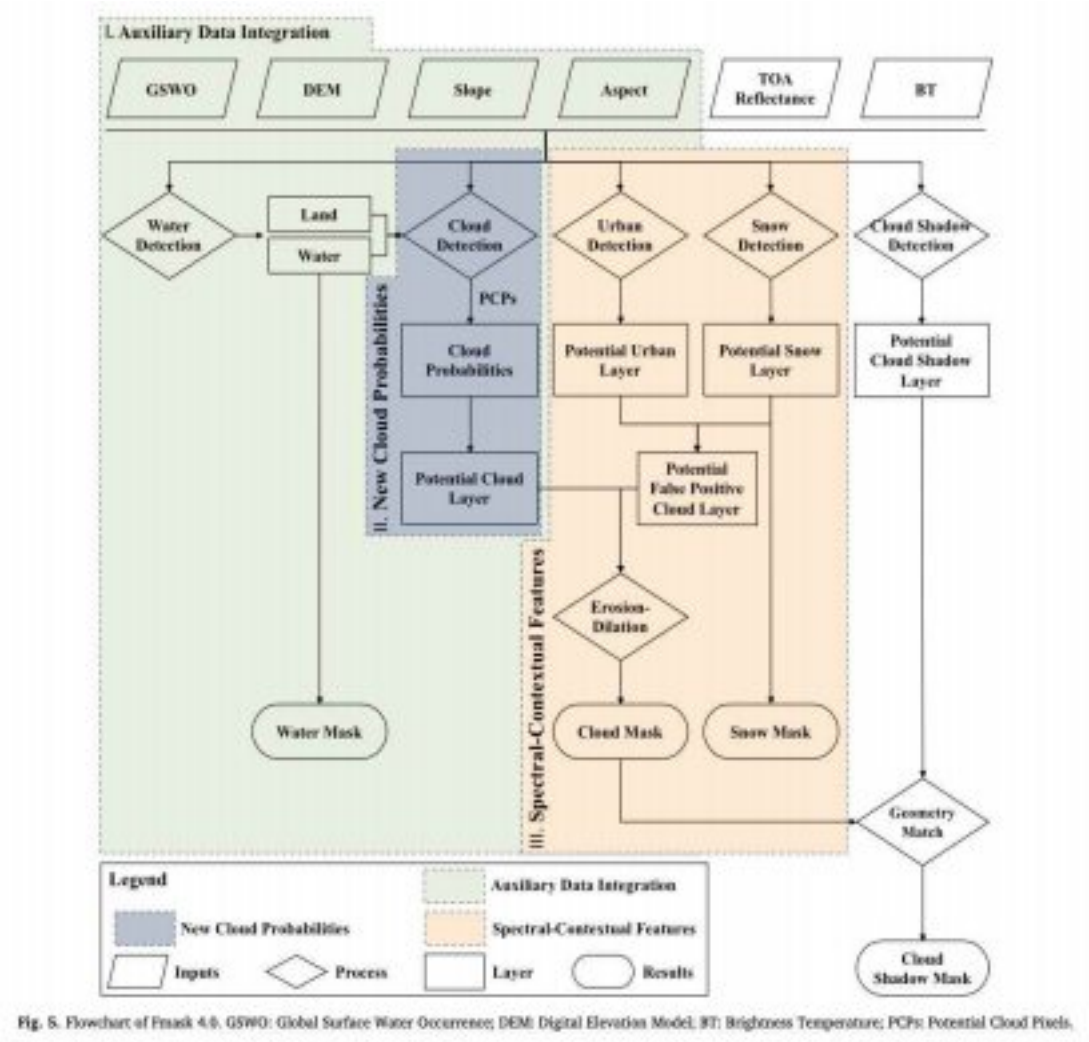


Fig. 5. Flowchart of Fmask 4.0. GSWO: Global Surface Water Occurrence; DEM: Digital Elevation Model; BT: Brightness Temperature; PCPs: Potential Cloud Pixels.

그림 4.18 Fmask4.0 알고리즘의 구름 탐지 흐름도 (Qiu 등, 2019)

3) 구름 마스킹의 영상기반 비교

그림 4.19에서 볼 수 있듯, Sentinel-2의 기본 구름 마스크(Cldprb)는 구름을 효과적으로 탐지할 수 있지만, 구름의 그림자를 탐지하지 못하는 결과를 나타내고 있다. 이는 비단, 기계학습의 입력자료로 구름의 그림자로 오염된 반사도값 및 분광지수가 사용될 수 있음 뿐 아니라 최종 결과지도에서 오염된 값으로 예측된 수변환경 분류지도를 산출하기 때문에 반드시 구름과 동시에 구름 그림자 격자를 탐지하여 제거할 수 있는 알고리즘 적용이 필요하다 (그림 4.19 및 그림 4.20)

그림 4.18 및 그림 4.19에서와 같이, Fmask는 구름 및 그림자를 효과적으로 탐지해내고 있으므로, 기계학습의 입력자료로 신뢰도 높은 반사도 값 및 분광지수가 사용될 수 있을 것으로 기대된다.

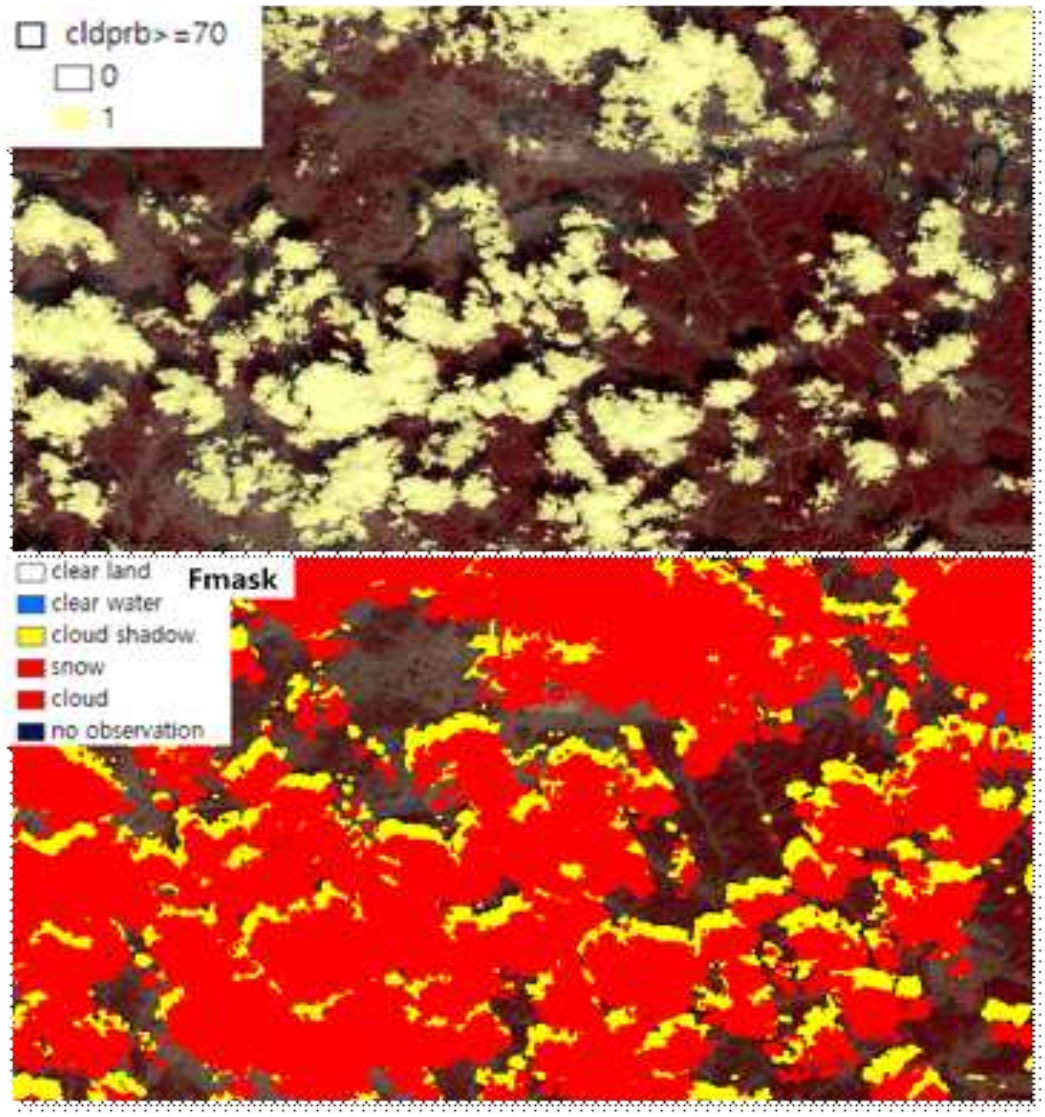


그림 4.19 위: Sentinel-2의 기본 구름 마스크 (MSK_CLDPRB.jp2). 아래: Qiu 등 (2019)

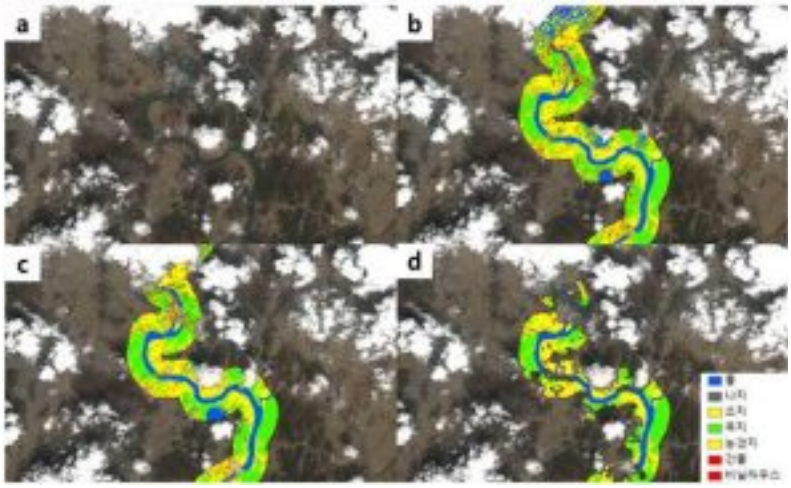


그림 4.20 구름 마스킹에 따라 제거되는 수변환경분류지도 비교

4) 구름 마스킹에 따른 샘플 수 비교

위 그림 4.19 및 그림 4.20에서 확인할 수 있듯, 구름과 구름 그림자가 마스킹됨에 따라 Sentinel-2 위성영상 중 가용한 격자의 수는 줄어들게 되고 따라서 훈련자료의 수가 감소할 것임을 알 수 있다. 이에 훈련자료 수가 구름 마스킹에 따라 변화하는 정도를 정량적으로 평가하기 위해 구름 마스킹 기법에 따른 클래스별 훈련자료 수의 히스토그램을 작성하였다 (그림 4.17). 그림에서 확인할 수 있듯이, Fmask를 사용한 실험구성에서 훈련자료의 수가 줄어들었지만, 기존 과업에서와 달리 구름을 제거하여 참조자료 위치의 반사도값을 시계열적으로 사용할 수 있게 됨으로써, 연구기간 내의 반사도 및 분광지수 값을 모두 사용해 기계학습 알고리즘 훈련이 가능하게 되었기 때문에, 알고리즘을 학습하기에는 충분한 자료가 확보되었을 것으로 판단되었다.

5) 구름 마스킹에 따른 알고리즘 정확도 비교

구름 마스킹에 따라 알고리즘 훈련의 정확도가 바뀔 것 이라는 가정을 평가하기 위하여 세 구름 마스킹 방법에 따른 수변환경 분류 알고리즘의 최소, 최대 및 평균 정확도를 계절별로 분석하였다. 아래 표 4.3 에서 확인할 수 있듯이, 지난 알고리즘의 결과 (표 3.1)와 비교하였을 때, 알고리즘의 계절별 평균 정확도가 크게 상승됨을 확인할 수 있었다. 특히 Fmask를 사용한 경우 분류알고리즘 정확도의 계절별 평균이 모두 84% 이상이며 최소 정확도가 66%로 구름 마스킹을 하지 않은 경우와 Sentinel-2 기본 구름 마스크를 사용했을 경우를 비교해 보았을 때 높은 성능을 보임을 확인할 수 있었다.

표 4.3 본 과업에서 개선한 알고리즘의 구름 마스킹 방법별 알고리즘 정확도 비교

		봄	여름	가을	겨울
Womask	최대 (%)	92.31	88.58	86.99	90.58
	평균 (%)	82.81	73.73	74.99	78.97
	최소 (%)	63.34	53.85	0.44	55.32
Cldprb	최대 (%)	100.00	87.85	88.26	91.91
	평균 (%)	84.68	78.72	79.28	79.63
	최소 (%)	67.41	0.7	57.14	54.55
Fmask	최대 (%)	92.45	89.66	89.83	91.34
	평균 (%)	84.92	84.63	85.74	84.92
	최소 (%)	66.99	77.14	77.08	72.73

기존 알고리즘은 위성영상이 주어질 때, 주어진 날짜의 샘플링 위치에서 훈련자료로 이용되는 위성영상의 반사도값을 추출하여 일별로 알고리즘 훈련에 사용된 참조자료 수가 상이할 수 있었고, 때문에 모델을 충분히 훈련하기 힘들었다는 한계가 존재하였다. 이는 기존 알고리즘에 사용한 구름 마스킹 방식의 문제인데, 기존의 알고리즘은 구름의 그림자를 충분히 걸러내지 못하는 한계가 있었고, 따라서 훈련에 사용된 샘플의 신뢰도가 구름 및 그림자를 제거한 경우에 비해서 낮을 가능성이 높았다.

본 과업에서는 Qiu 등, (2019)의 Fmask를 사용해 구름 및 구름 그림자를 제거하였고, 이를 통해 연구기간 내의 영상들로부터 양질의 충분한 훈련자료를 확보할 수 있었기 때문에, 가장 높은 분류 정확도를 낸 것으로 판단된다. 아래 그림 4.21 에서 볼 수 있듯이, Fmask를 사용한 분류모델이 전체 연구기간 동안 정확도의 일별 변동이 가장 작은, 즉 꾸준히 성능이 높은 결과를 보임을 확인할 수 있었다. 기존 알고리즘의 일별 평균 정확도가 일별로 크게 변동하는 것에 비해 안정적인 알고리즘 구성된 것을 확인할 수 있었다. 특히 Fmask모델은 가장 일별 평균 정확도의 최소값은 66.99로, 구름 마스킹을 하지 않은 경우나 구름만을 마스킹 한 경우에 비교하여 알고리즘 예측성능의 최소값이 높음을 확인하였다.

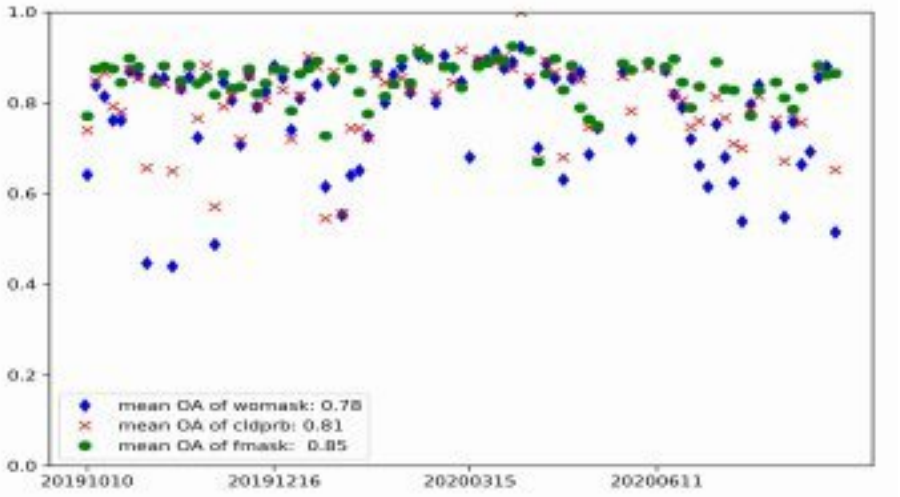


그림 4.21 본 연구에서 제시한 알고리즘의 구름 마스킹 방법별 시계열 성능평가

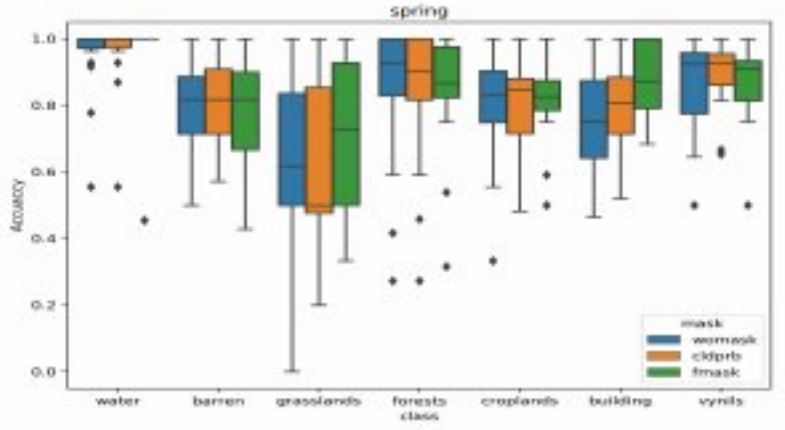


그림 4.22 봄의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%)

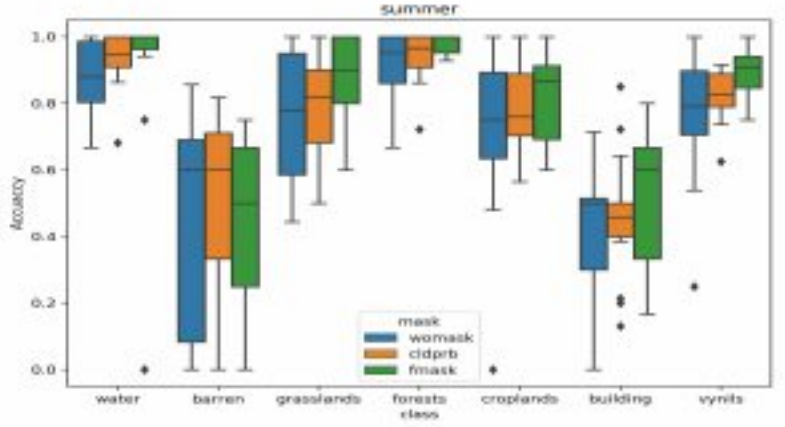


그림 4.23 여름의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%)

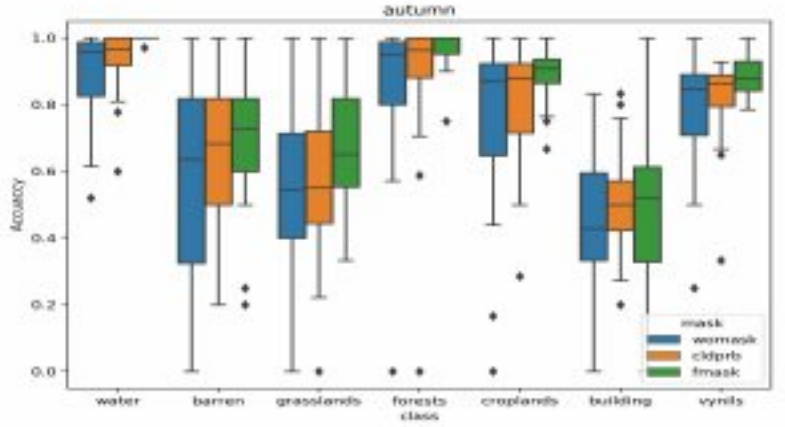


그림 4.24 가을의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%)

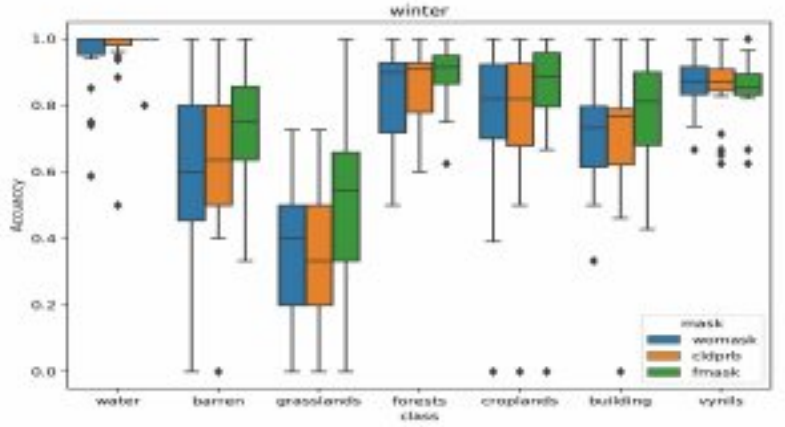


그림 4.25 겨울의 구름 마스킹 방법에 따른 클래스별 분류 정확도 (%)

위 상자 그림 4.22 - 그림 4.25은 계절별 구름 탐지 알고리즘 적용 방법에 따른 클래스별 분류 정확도를 나타낸 그림이다. 앞서 가정한 것과 같이, 전반적으로 모든 계절의 모든 클래스에서 Fmask를 사용해 구름 및 구름의 그림자를 제거한 경우 더 나은 정확도를 보여주는 경향을 발견하였다. 또한, 정확도의 분산이 줄어들어 Fmask를 사용해서 입력자료를 걸러낸 모델이 다른 모델에 비해 강건함을 확인할 수 있었다. 앞 절에서 논의하였듯, 구름 그림자로 인해서 목지와 초지 및 농경지가 오분류되는 경향이 있는데, Fmask를 사용한 기계학습 모델에서는 초지와 목지 그리고 농경지의 정확도가 개선되는 경향이 뚜렷한 것 또한 발견하였다.

식생 시계열 정확도 그림 4.26에서도 확인할 수 있듯이, 본 과업에서 제시하는 모델(녹색 동그라미)은 수변환경의 식생 분류시 계절별 영상에 의한 식생분류의 영향이 기존 알고리즘보다 적으므로 더 강건함을 확인할 수 있었다. 위 결과들을 바탕으로 수변 환경 분류 알고리즘에서 예측하는 식생 클래스를 식생분류의 기준으로 사용할 수 있을 것으로 판단된다.

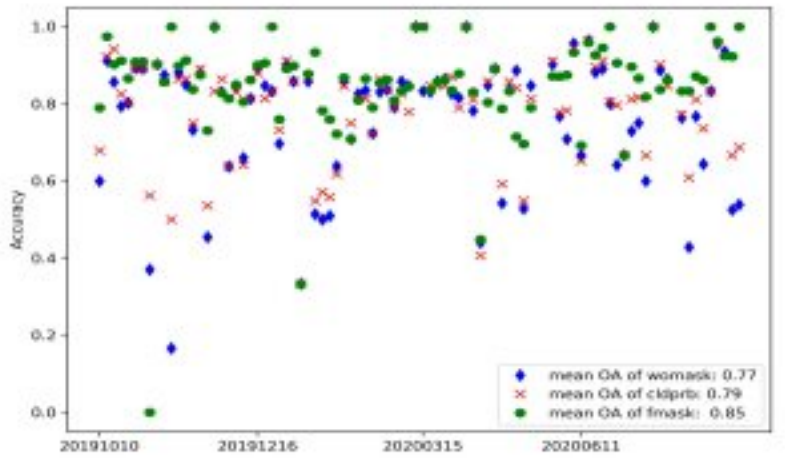


그림 4.26 수변환경의 식생 (초지,목지,농경지) 의 정확도의 시계열 성능 평가

6) 혼동행렬을 통한 모델의 연간 정확도 평가

앞 절에서 확인하였듯, 나지클래스와 비닐하우스 클래스가 유사한 분광패턴을 보이기 때문에 가장 주요한 오분류의 원인으로 나타났다. 또한 농경지, 초지, 목지에서 분류가 발생함 특히 농경지와 초지 사이에서 오분류 되는 경우가 많았다.

모든 클래스에서 Fmask를 사용한 모델이 나머지 모델에 비해서 높은 성능을 보여주는 것을 확인할 수 있었다. 특히 나지 클래스의 경우 기존 알고리즘의 가장 높은 계절별 평균 정확도가 여름 계절의 60%미만인 것과 비교하여(그림 4.27), 연간 평균 정확도가 71%로 기존 알고리즘에 비해 크게 향상됨을 확인할 수 있었다(그림 4.28).

이를 통해 본 과업에서 제시하는 알고리즘이 수위변화에 따라 나지의 증감을 더 정확하게 파악할 수 있을 것으로 기대되었다.

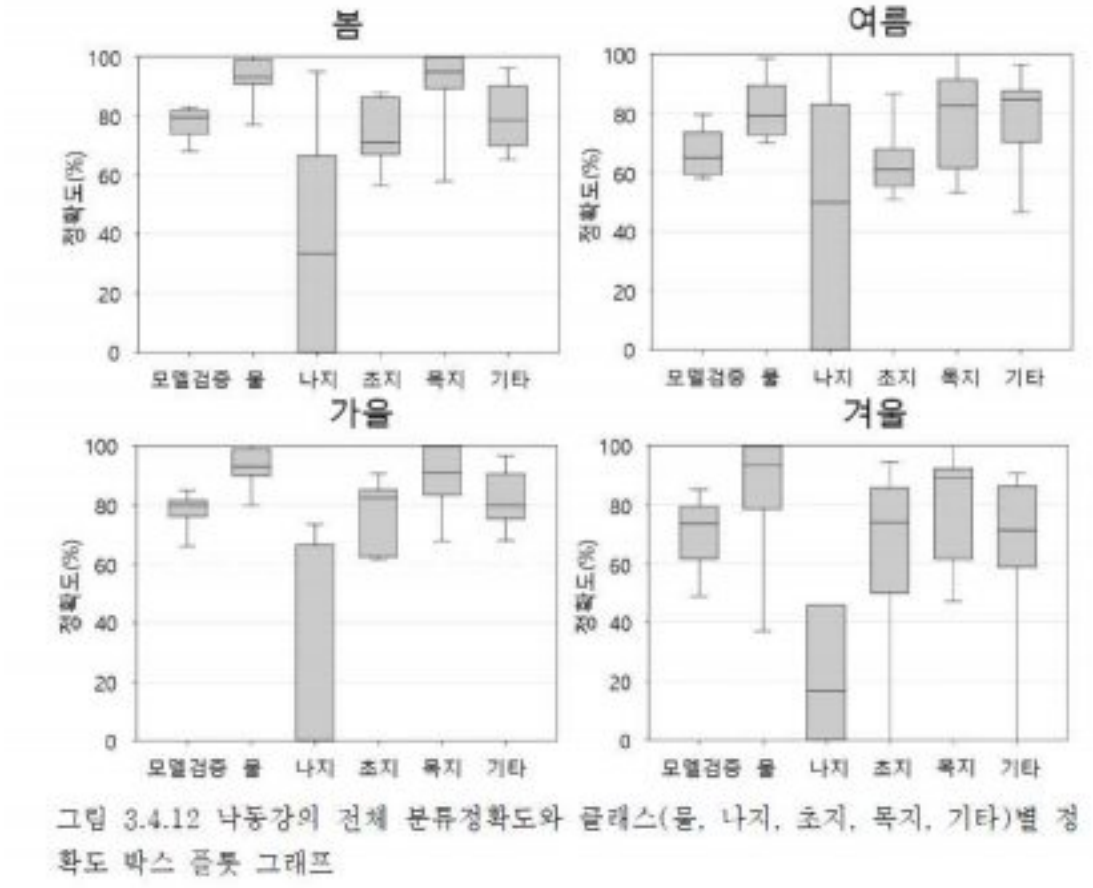


그림 3.4.12 나동강의 전체 분류정확도와 클래스(물, 나지, 초지, 목지, 기타)별 정확도 박스 플롯 그래프

그림 4.27 위성영상 활용 용수수요 인자 및 수변환경 변화 분석기법 연구 (2019) 의 알고리즘 검증 정확도

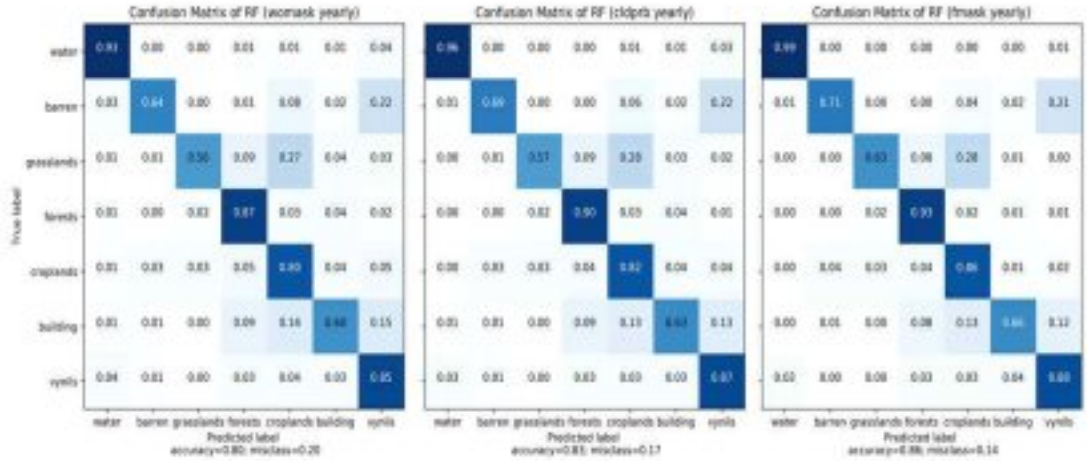


그림 4.28 구름 마스킹 방법별 수변환경 분류 알고리즘의 연간 정확도 평가

4.3.7 수위변화에 따른 알고리즘 평가

1) 수위에 따른 수변환경변화 평가

모래톱의 증감을 파악하기 위하여, 수변환경 분류지도 중 나지 클래스의 개수에 Sentinel-2 위성 격자의 크기인 20*20을 곱하여 모래톱의 증감을 분석하였다. 그러나 광학 위성영상의 한계로, 구름으로 인해 Sentinel-2의 한반도 관측시기마다 가용한 위성영상의 수가 차이나기 때문에, 실제 나지 증감의 위성 관측시마다 이루어지기에는 제한되는 점이 있었다. 따라서 본 과업에서는 모래톱의 증감 파악을 위해 수변환경 분류지도를 타일별, 계절별로 최빈수 (mode)를 통해 융합하였고, 그를 통해 계절별 수변환경 분류지도를 작성한 뒤, 나지클래스를 추출한 뒤, 면적을 계산하여 모래톱의 증감을 분석하였다 (그림 4.29)

아래 그림 4.30은 그림 (a)의 빨간색 X 표시 위치의 구미보(하)에서의 수위변화를 바탕으로 연구기간 중 수위가 낮은 날짜인 2020년 4월 4일 (그림 4.30의 주황색 막대) 및 수위가 가장 높은 날짜인 2020년 8월 20일(그림 4.30의 파란색 막대)의 Sentinel-2 광학영상 및 영상을 사용해 제작한 수변환경 분류지도를 사용해 제시한 알고리즘이 수위변화에 따른 나지증감을 파악할 수 있는지 분석하였다. 수위측정소는 영상 내에서 분석하려는 나지와 가장 가까운 측정소의 일자료를 국가수자원관리종합정보시스템(WAMIS)로부터 취득하여 사용하였다.

그림 4.30(a) 및 (e)의 주황색 막대에서 확인할 수 있듯이, 2020년 4월 4일은 수위가 낮기 때문에 나지의 면적이 넓을 것으로 판단되었고, 실제 수변환경 분류지도인 그림 4.30(b) 에서도 이를 확인할 수 있었다. 반면 그림 4.30(c) 및 (e)의 파란색 막대에서도 확인할 수 있듯이, 2020년 8월 20일은 수위가 높아 나지의 면적이 좁을 것으로 판단되었고, 실제 수변환경 지도에서도 이를 반영하여 나지의 면적이 감소하는것을 정성적으로 확인할 수 있었다.

이에 더해, 국가수자원관리종합정보시스템(WAMIS)로 부터 낙동강 권역 댐 수문정보 중 수자원공사에서 운용하는 안동, 안동조정지, 임하, 임하조정지, 영주, 부항, 영천, 합천, 남강, 합천조정지, 밀양 그리고 운문댐의 총 13개 위치의 일자료를 취득하여, 시계열 평균 댐 수위를 계산하였고, 이를 계절별 나지 면적과 비교하였을 때, 다음 그림 4.31과 같이 음의 상관관계가 있음을 확인하였다 (수위가 낮을 때 나지 면적이 증가, 수위가 높을 때 나지 면적이 감소). 그림 4.31는 시계열 나지 면적의 샘플 수가 부족하지만, 본 과업에서 제시하는 알고리즘이 수위변화에 대해 변화하는 나지 면적을 추정해 낼 수 있음을 시사하였다.

본 과업에서 제시하는 알고리즘이 댐 지역의 수위변화에 대해 발생하는 나지탐지 및 수위변화에 반응하는지에 대한 검증을 위하여 계획홍수위 및 상시만수위 부근까지 수위변화가 존재하며, 위성영상이 가용한 지역으로 안동댐을 선정하여, 위성영상 및 수변환경 지도 및 평균수위의 시계열자료를 비교하였다. 이때, 안동댐의 계획홍수위는 161.70 EL.m이고, 상시만수위는 160.00 EL.m이다. 안동댐의 수위자료는 국가수자원관리종합정보시스템(WAMIS)으로부터 취득하였다.

안동댐 평균수위가 낮은 기간(그림 4.32 (e)의 주황색) 중 위성영상이 사용가능한 2020년 7월 8일 영상과 그 영상으로 제작한 수변환경 분류지도 (그림 4.32 (a),(b)) 및 안동댐의 평균수위가 계획홍수위 및 상시만수위와 근접한 2020년 10월 6일의 영상 및 그 영상으로 제작한 수변환경 분류지도 (그림 4.32 (c),(d))이다. 그림 4.32 (b),(d)에서 확인할 수 있듯, 평균수위가 낮은 기간 중에 물 클래스로 분류된 격자 면적이 감소하는것을 확인할 수 있다. 동시에 육지 기슭 부근의 나지가 드러나는데, 이 곳이 수변환경 분류지도에서는 비닐하우스 및 농경지 클래스로 분류되는 것을 확인할 수 있었다. 이는 혼합픽셀의 문제로 나타나는 현상이며 3.3.11에서 논의할 것이다. 추가적으로, 이 영상의 구름및 구름 그림자가 수변환경 분류지도에서도 잘 제거된 것이 확인 가능하였다. 반대로 평균수위가 높은 기간의 영상에서는 물 클래스로 분류된 격자 수가 증가함을 확인할 수 있었다. 이 경우에 육지 기슭의 나지 부근 수몰됨으로써 위성영상에서도 탐지가 되지 않게 되었다. 이로써 본 과업에서 제시하는 알고리즘이 댐 수위변화에 반응함을 확인할 수 있었다.

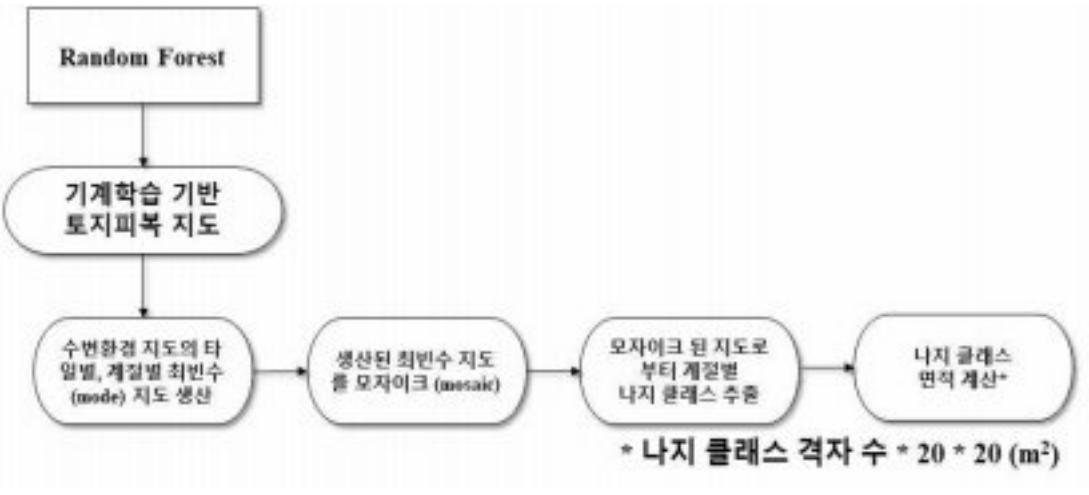


그림 4.29 모래톱 증감 파악을 위한 나지 클래스 추출 및 면적 계산 흐름도

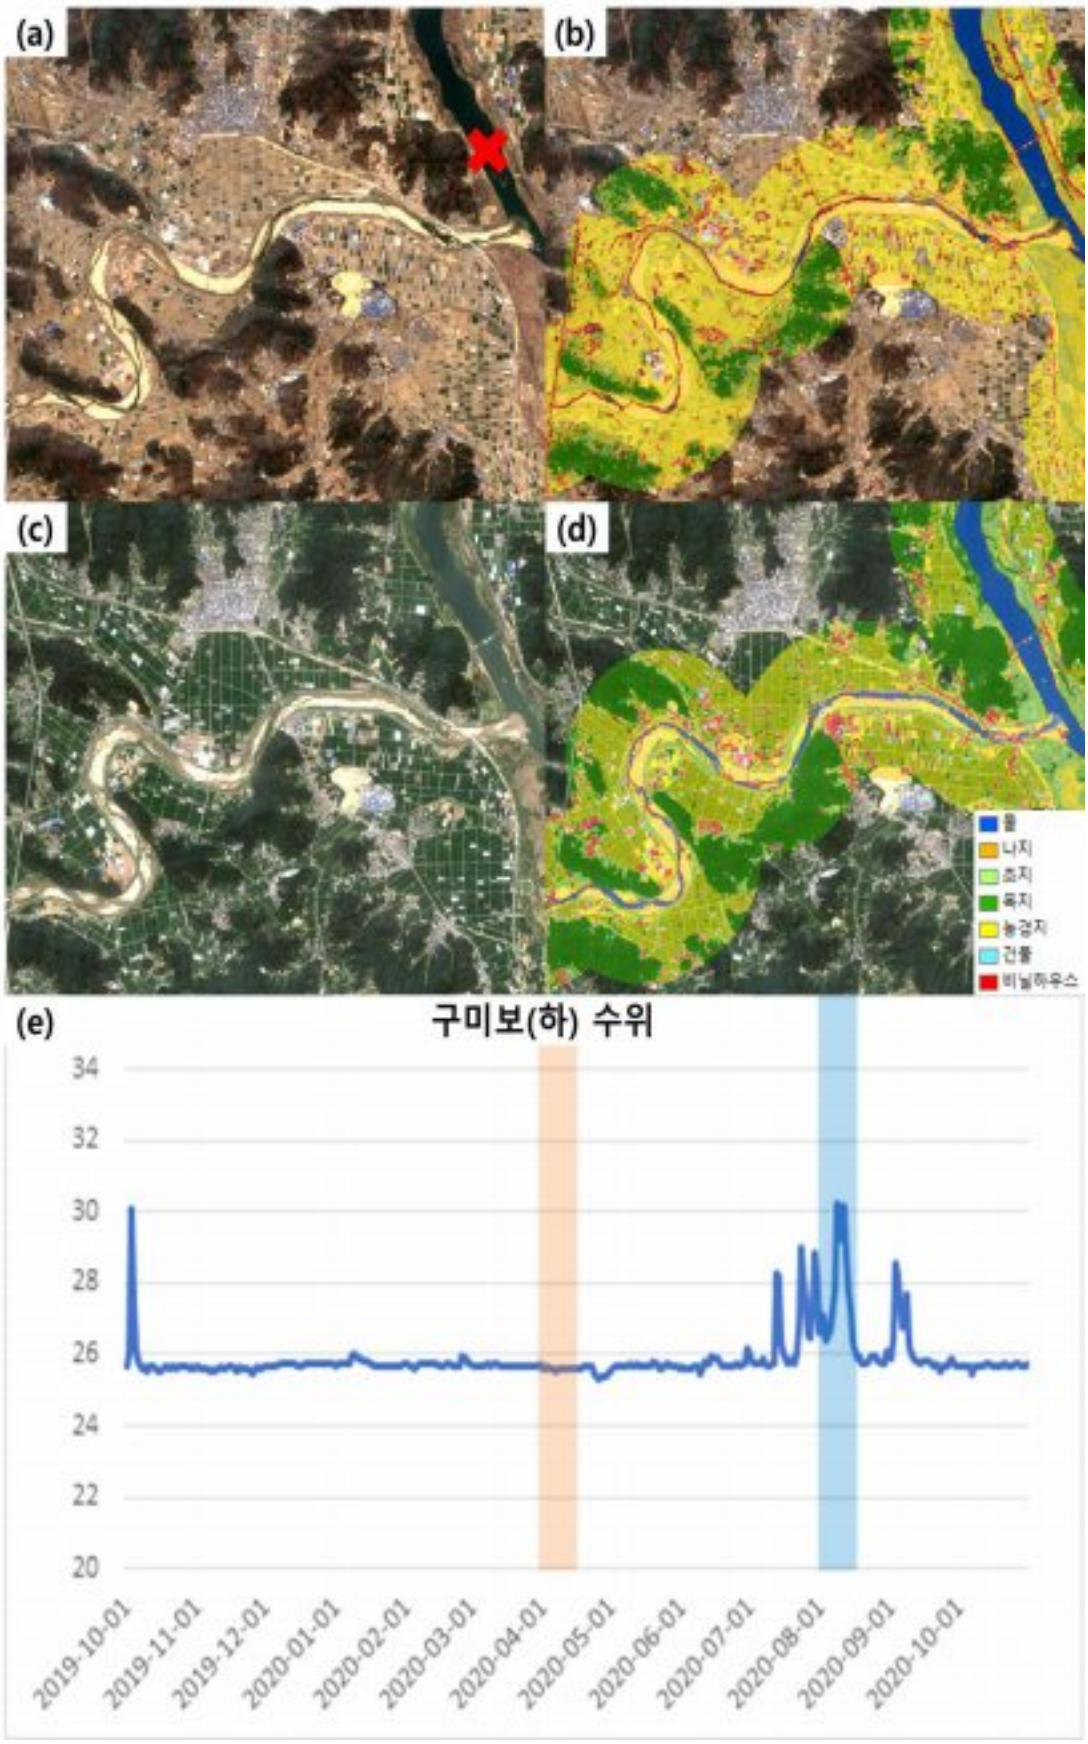


그림 4.30 하천 수위변화에 따른 나지증감 분석

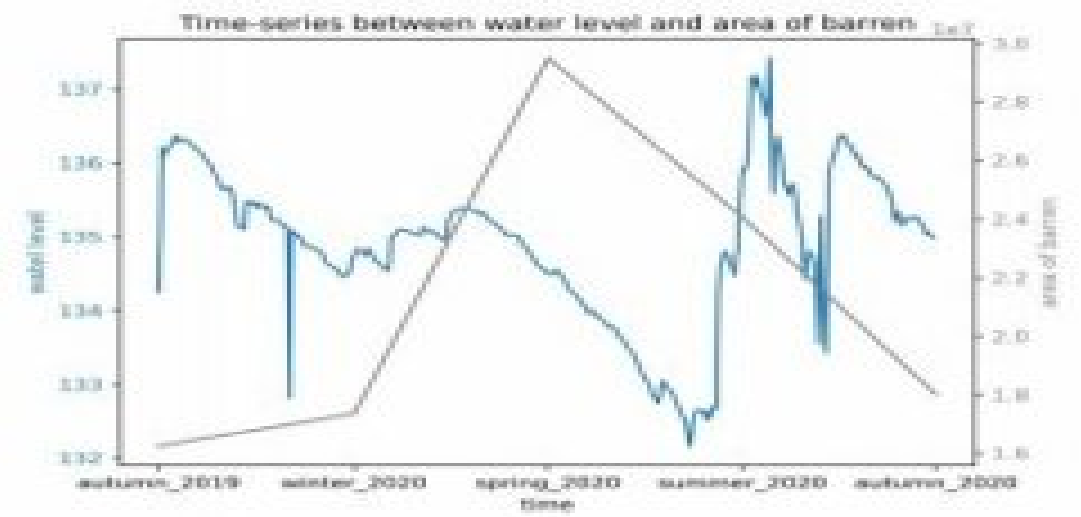


그림 4.31 낙동강 댐 평균 수위와 나지 증감 시계열 그래프 및 경상북도 김천시 아포읍 의리 부근의 2020년 봄과 2020년 가을의 나지 면적 분석

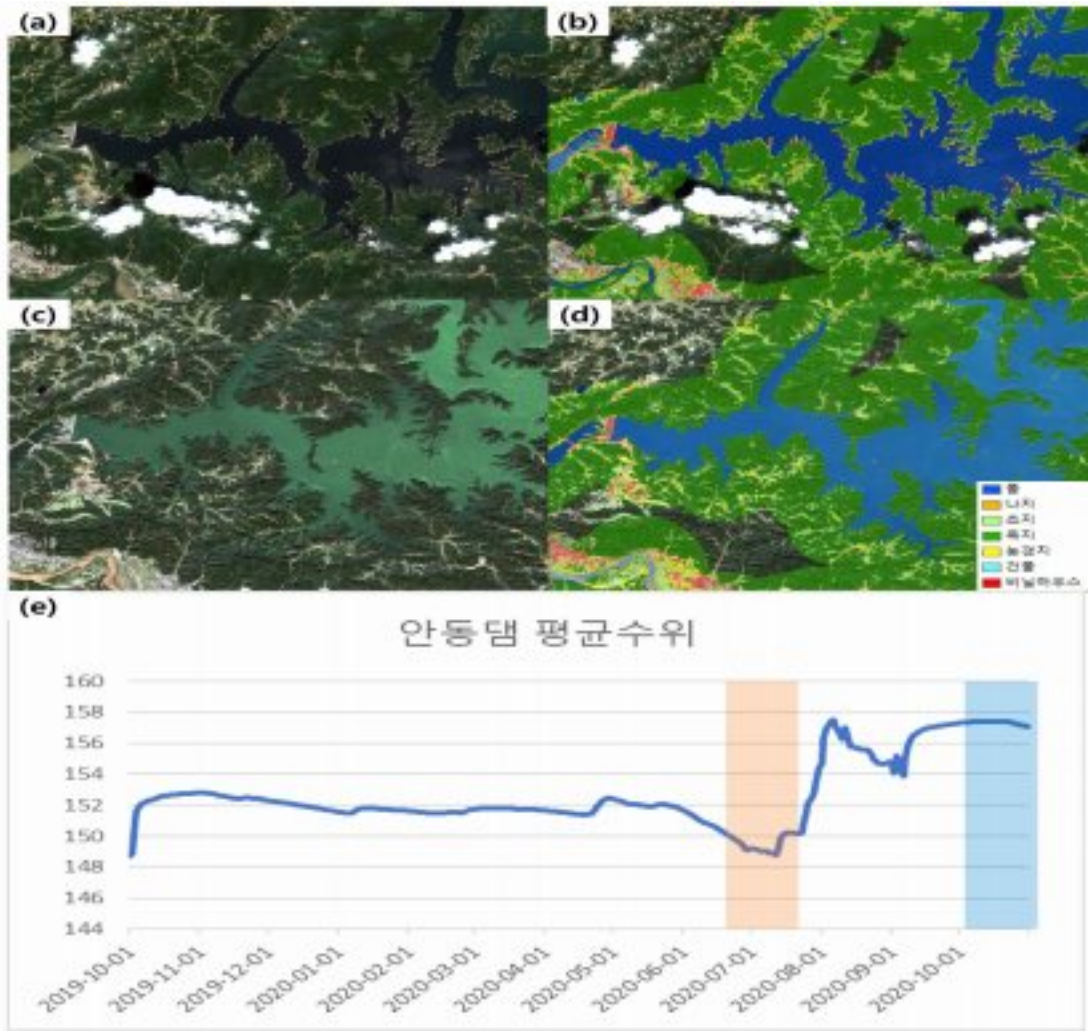


그림 4.32 안동댐 평균수위에 따른 수변환경 변화탐지 지도

4.3.8 변화탐지 알고리즘 구현

1) 계절별 수변환경 변화탐지

수변환경의 변화탐지를 위하여 계절별 최빈수를 통해 계산한 수변환경 분류지도를 사용하였다. 이는 모래톱 증감 파악의 경우와 동일하게, 구름으로 인해 위성영상 활용이 제한되는 경우의 발생하는 결측값 문제를 제거하기 위함이다.

수변환경의 변화탐지 지도를 작성하기 위해, 프로그래밍 언어 python을 사용해 계절별 수변환경 분류지도를 숫자 형태에서 문자 형태로 변환하였다 (5 -> '5'). 변환된 지도 값은 앞 계절과 뒤 계절 영상을 연결 (concatenate) 하였다. 이는 python의 경우, '5' + '3' 과 같은 형태로 계산이 이루어지는데, 이를 통해 '53'의 형태의 값을 반환한다. 이를 다시 숫자 형태로 변환하여 최종 지도를 생산하였다 (그림 4.33).

이 결과, 본 연구에서 분석한 7개의 클래스의 계절별 변화를 탐지할 수 있게 되었고, 수변환경 변화탐지 지도는 각각 1에서 77까지의 값을 가지게 되었다.

지도의 값 해석은 다음과 같다. 예를 들어, 격자값이 53인 경우 지난 계절의 격자 값은 5로, 농경지 클래스였고 이번 계절의 격자값이 3으로 초지 클래스로 변화한 것을 의미한다.

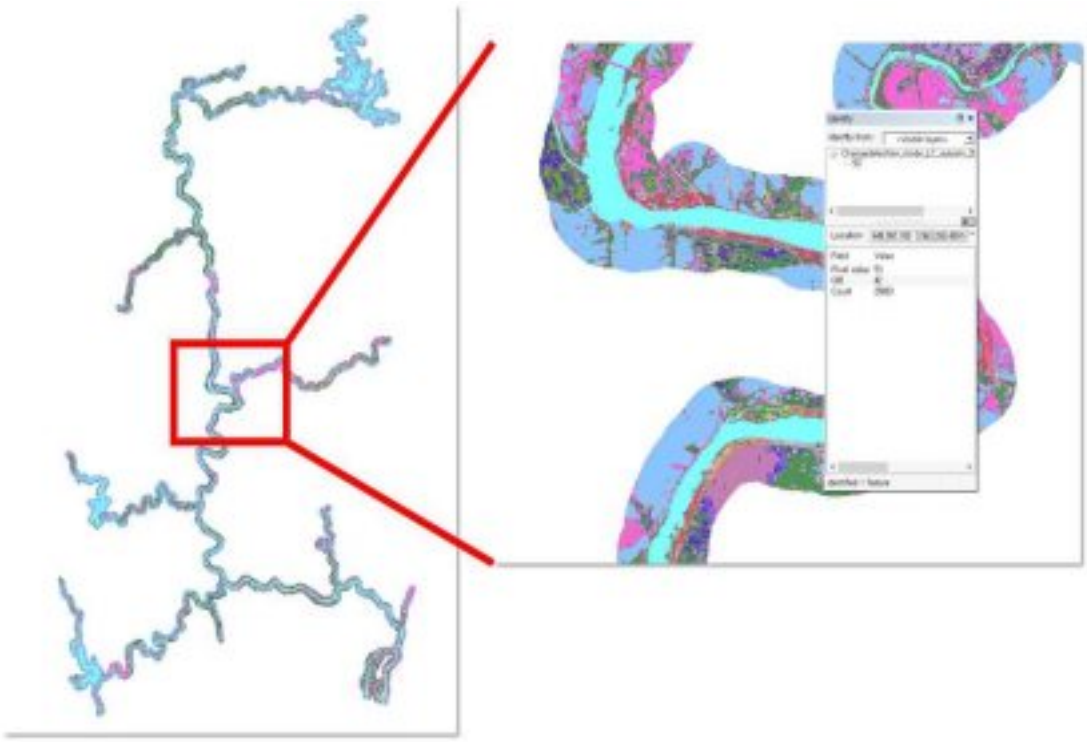


그림 4.33 수변환경 변화탐지 지도

4.3.9 개선된 수변환경 분류 알고리즘의 공간적 분석

1) 무인항공기 기반 참조자료를 통한 공간적 분석

지난 과업에서, 수변환경 분류 알고리즘은 나지 탐지의 정확도가 낮은 한계를 보였다. 본 과업의 알고리즘은 정량적으로 기존 알고리즘과 비교해서 보다 나은 성능을 보여주고 있기 때문에 더 나은 나지 탐지 능력을 갖고 있을 것으로 기대되며, 이를 추가적으로 평가하기 위하여 무인항공기를 통한 나지 현장관측을 실시하였고 그 결과를 위성영상과 함께 제시하였다 (그림 4.34 및 4.35).

이때, 정량적인 평가를 위해 무인항공기의 영상에서 Sentinel-2 영상 기준 (20m) 주위 3x3격자가 동질적인 위치에서 참조자료를 육안 판독을 통해 구축하였고 그 결과는 아래 그림 4.36 ~ 4.38과 같다.

분류결과, 전반적으로 분류가 정확한 것을 확인할 수 있었으나, 건물과 비닐하우스 클래스에서 크게 혼동이 일어나는 것을 확인할 수 있었다. 이는 알고리즘 학습에 이용된 건물 참조자료를 샘플이 색깔이 있는 지붕 (주황, 파랑 등)으로부터 추출되었기 때문에 도로 또는 다리 등의 RGB 천연색 광학영상 기준 흰색으로 나타나는 클래스에 대한 학습이 부족했기 때문으로 판단된다 (그림 4.36).

무인항공기 영상의 육안판독 기반 샘플을 통한 참조자료를 통해 정량적으로 평가했을 때 다음과 같은 준수한 결과를 얻을 수 있었다 (표 4.4 - 표 4.7 및 그림 4.36 - 그림 4.38).

무인항공기를 통한 현장관측은 고해상도 영상을 통해 실제 위성영상에서 판독 불가능한 실제 수변환경을 정확하게 육안으로 확인할 수 있는 장점이 있지만, 위성영상에 비해 좁은 관측 범위를 가져 본 과업에서 사용된 7개의 클래스를 모두 포함하는 단일 영상을 구축하지 못하는 한계를 가진다.

그림 4.38과 같이, 나지와 물이 만나는 지역의 혼합픽셀은 예상되는 클래스가 아닌 다른 클래스로 오분류되는 패턴을 확인할 수 있었다. 또한, 모래톱 위에 낮은 밀도의 식물이 자라는 경우는 농경지 클래스로 분류되는 것이 타당하다고 볼 수 있으나, 물과 나지 클래스가 혼합되 어 있을 것으로 예상되는 지점은 비닐하우스로 오분류되는 것을 확인하였다. 반면 순수하게 나지만이 넓은 면적으로 분포한 그림 4.38의 강 북쪽 부분은 정상적으로 나지가 탐지되는 것을 확인할 수 있었다.



그림 4.34 경상북도 구미시 선산읍 원리 부근의 2020년 11월 23일 무인항공기 현장관측 영상과 무인항공기로 구축된 참조자료를 이용해 Sentinel-2 영상의 수변환경 분류지도를 평가하였다



그림 4.35 대구광역시 달성군 현풍읍 대구환경공단 달성사업소 근방 차천합류점 부근의 2020년 12월 04일 무인항공기 현장관측 영상과 무인항공기로 구축된 참조자료를 이용해 2020년 12월 03일 Sentinel-2 해당영상의 수변환경 분류지도를 평가하였다

표 4.4 무인항공기 기반 초지 샘플에 대한 예측결과 (경북 구미시 선산읍 20201123)

	예측: 초지 (개)	예측: 초지가 아닌 다른 값 (개)	정확도 (%)
실제: 초지 (4개)	3	1	75

표 4.5 무인항공기 기반 나지 샘플에 대한 예측결과 (경북 구미시 선산읍 20201123)

	예측: 나지 (개)	예측: 나지가 아닌 다른 값 (개)	정확도 (%)
실제: 나지 (12개)	12	0	100

표 4.6 무인항공기 기반 초지 샘플에 대한 예측결과 (대구 달성군 현풍읍 20201204)

	예측: 초지 (개)	예측: 초지가 아닌 다른 값 (개)	정확도 (%)
실제: 초지 (4개)	3	1	75

표 4.7 무인항공기 기반 목지 샘플에 대한 예측결과 (대구 달성군 현풍읍 20201204)

	예측: 목지 (개)	예측: 목지가 아닌 다른 값 (개)	정확도 (%)
실제: 목지 (2개)	2	9	100

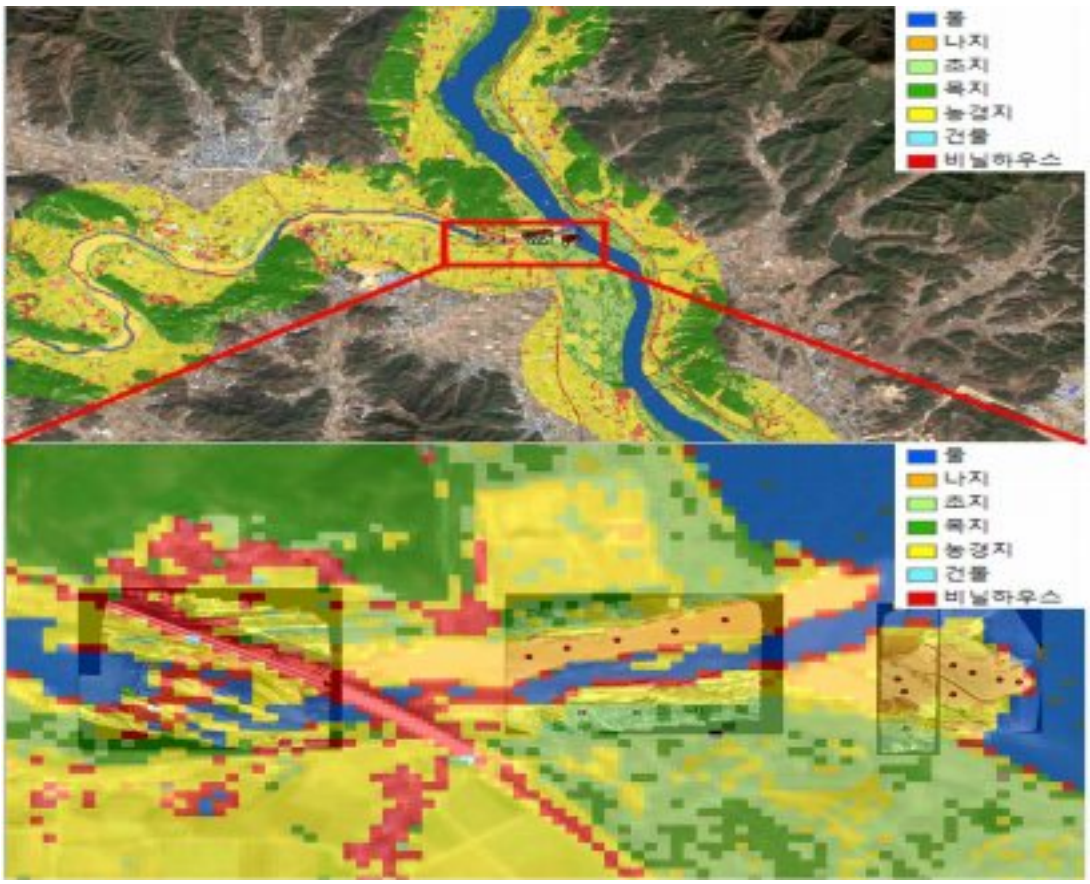


그림 4.36 경상북도 구미시 선산읍 원리 지류와 낙동강 본류의 합류점 부근

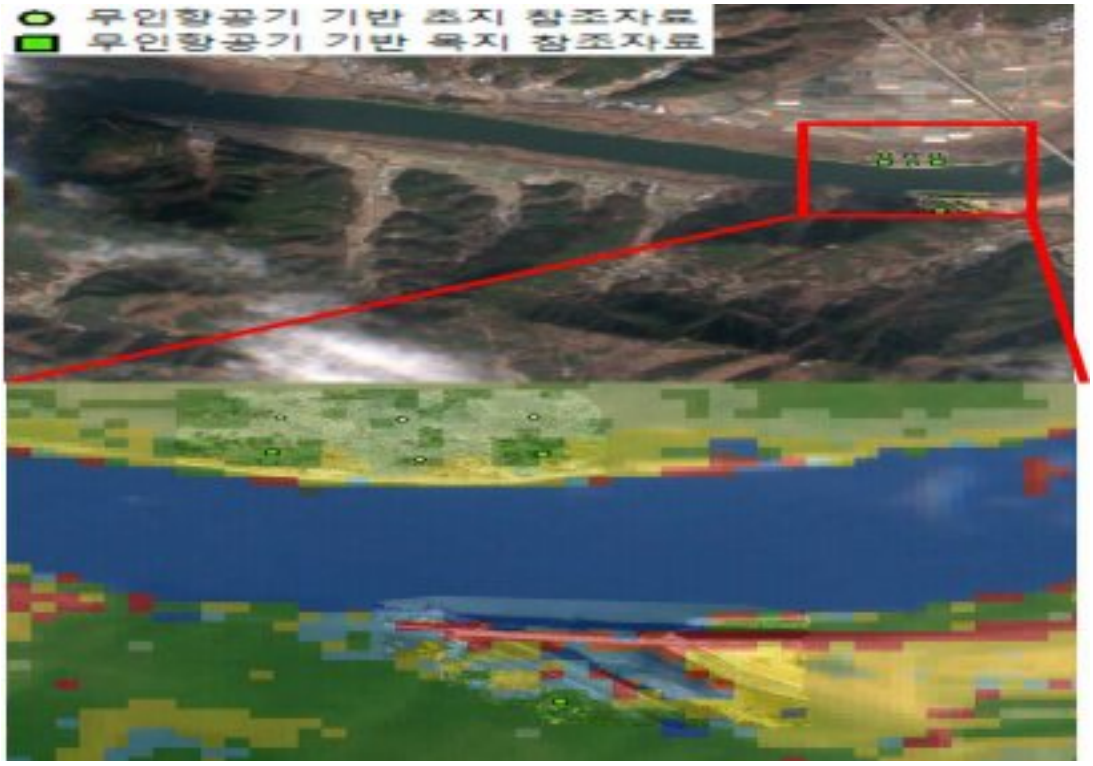


그림 4.37 대구광역시 달성군 현풍읍 대구환경공단 달성사업소 근방 합천합류점 부근

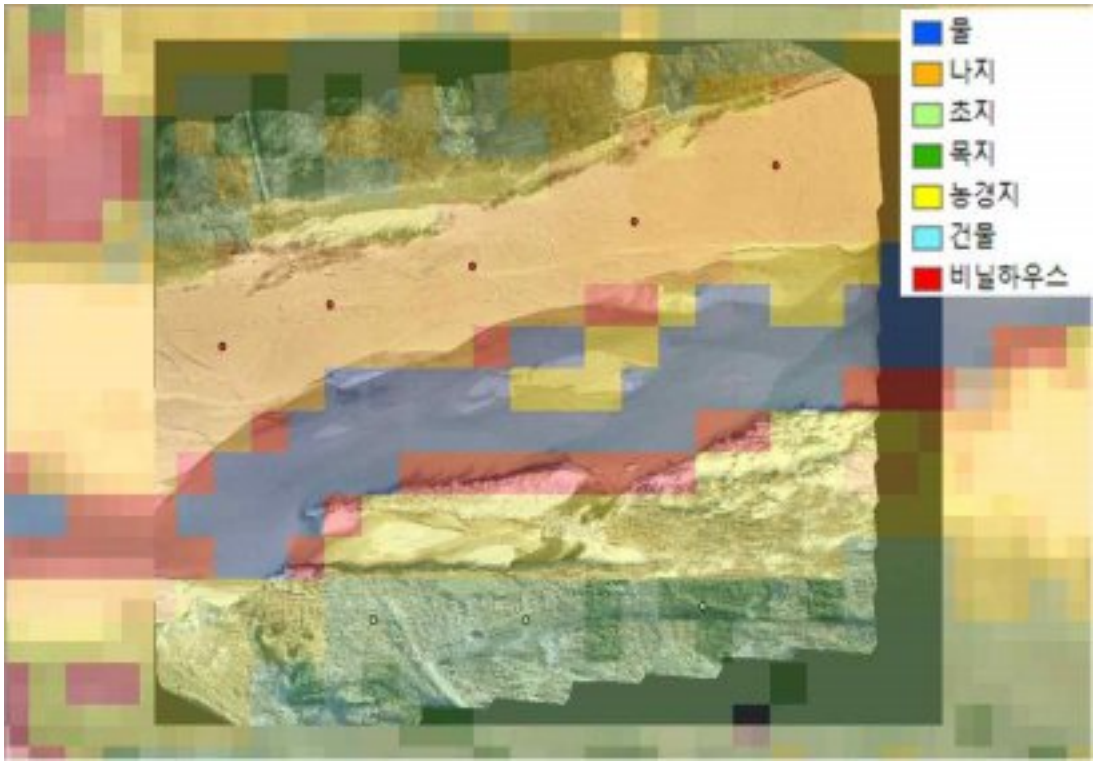


그림 4.38 경상북도 구미시 선산읍 원리 지류와 낙동강 본류 합류점으로부터 서쪽으로 500m 지점

4.3.10 개선 알고리즘의 한계 및 보완사항

1) 위성영상 해상도로 인한 혼합픽셀 문제

그림 4.39은 그림 4.34 및 그림 4.36과 동일한 2020년 11월 23일 위성영상기반 분류지도 및 무인항공기 영상이며 하도 중앙의 나지 혼합픽셀이 상당히 오분류되는 것을 확인할 수 있었다. 낙동강은 하폭이 넓지 않아 20m 공간해상도에서 이와같은 혼합픽셀 문제가 빈번히 나타나는 것을 확인하였다. 본 연구에 사용된 Sentinel-2 영상은 공간해상도 20m의 격자이므로 하도 내의 격자보다 작은 물체의 반사도는 주위 여러 가지 물체들로부터 오염된다 (그림 4.39의 위).

따라서 혼합픽셀로 인해 오염된 격자는 수변환경 분류 알고리즘에서 훈련된 알고리즘에서 예측 시 훈련과정에 포함되지 않은 값이기 때문에, 알고리즘에서 다른 예측을 하고, 때문에 수변환경 분류지도에서는 오류로 나타나게 되었다 (그림 4.39의 아래).

무인항공기 영상에서는 동일한 모래톱 및 물의 혼합인 상태이지만 이를 Sentinel-2 영상에서 분류했을 때, 나지 뿐 아니라 비닐하우스, 물, 농경지, 목지 등으로 다양하게 오분류되는 것을 확인하였다.

이를 개선하기 위해서는 Sentinel-2 위성보다 고해상도의 광학위성영상을 사용하는 방법이 있으나, 현재 무료로 제공되는 위성영상 중 Sentinel-2 위성과 비교할 수 있을만큼 다양한 밴드를 가짐과 동시에 고해상도의 영상을 제공하는 위성이 존재하지 않기 때문에 이는 추후 새로운 고해상도 다중밴드 위성이 추가적으로 발사되면 해결될 수 있을 것으로 판단되었다.

그림 4.32의 (b) 경우와 같이 수위가 낮을 때 육지 기슭이 농경지 및 비닐하우스로 오분류가 발생하는 것이 그림 4.38에서 나타난 문제와 같이, 물과 나지, 초지가 혼재해 있는 복잡한 격자가 20m 해상도에서 충분히 표현되지 않을 때 나타나는 것을 확인하였다.

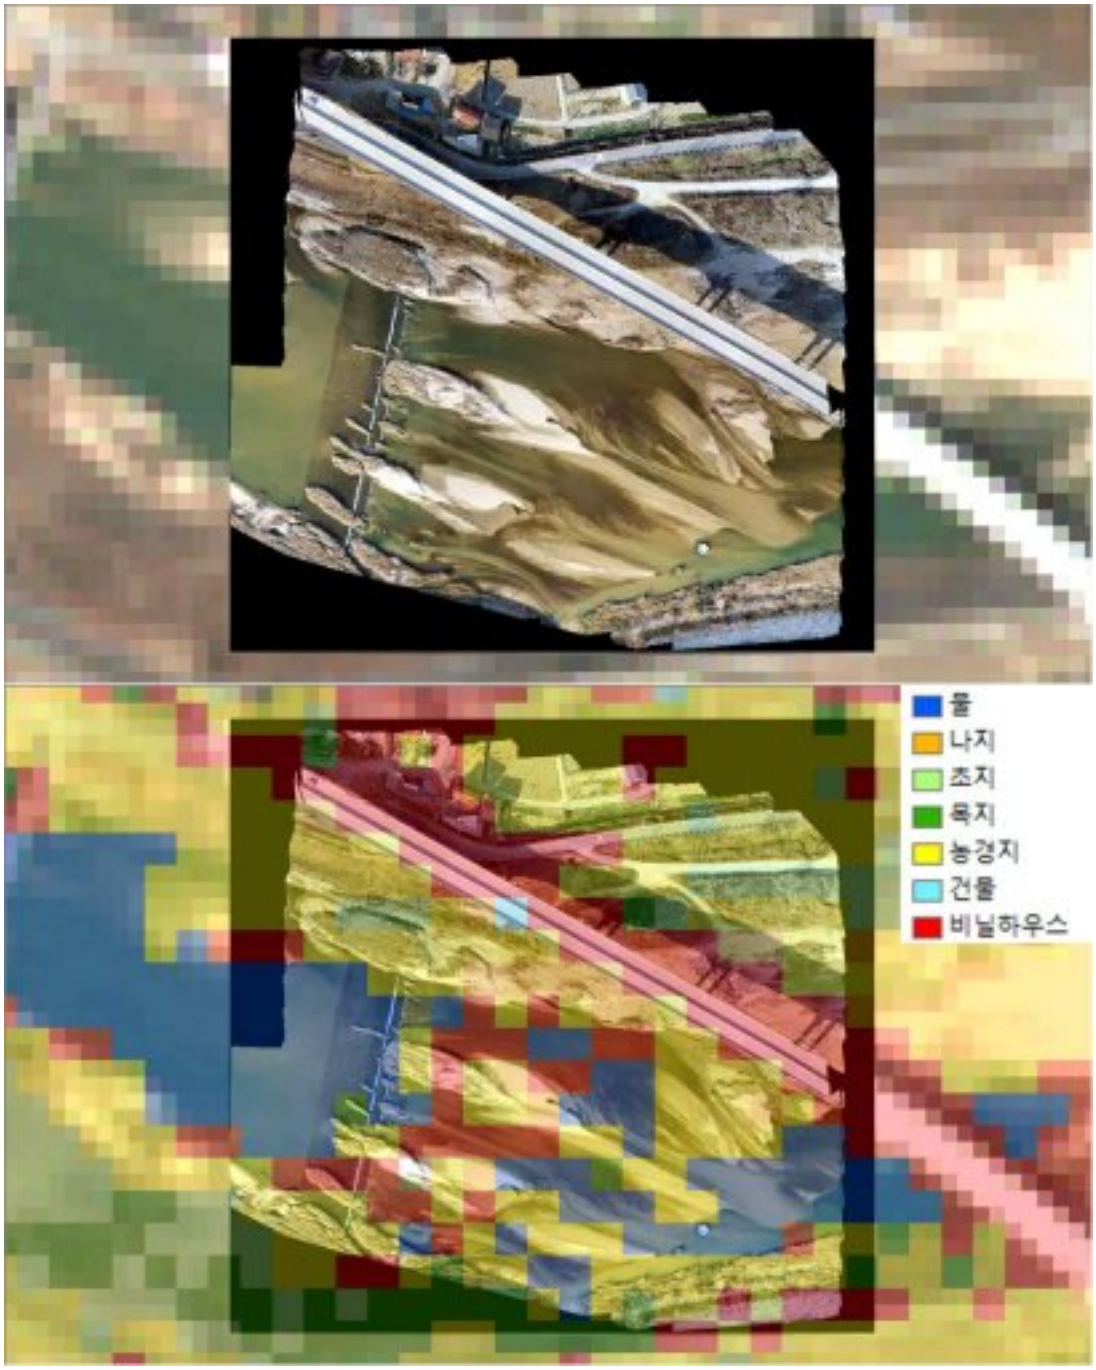


그림 4.39 경상북도 구미시 선산읍 원리 부근의 도로, 나지, 수체 등이 혼합되어있는 영상

2) 샘플링 기법의 한계

본 연구에서는 기계학습 훈련을 위한 참조자료를 획득하기 위해 구글어스 고해상도 영상 및 Sentinel-2 영상을 통해 참조자료를 구축하였다. 이러한 고해상도 영상을 사용하였음에도 불구하고, 위성영상 수준에서 발견하기 쉽지 않은 식생 등이 혼합되어 있을 수 있음을 고해상도 무인항공기 영상을 통해서 확인하였다 (그림 4.40). 또한 그림 4.40의 (c) - (f)에서와 같이 훈련자료로 이용한 참조자료 중 나지로 판단되는 지역의 샘플임에도 불구하고 훈련에 사용된 격자를 제외한 근처 격자에서 오분류가 발생하는 경우를 발견하였다. 이 경우 나지로 분류될것으로 예상되는 건조한 토양임에도 불구하고 토양의 질감의 달라 다른 클래스로 오분류되는 것으로 판단되며, 이런 경우를 위해서 광학영상에서 질감 정보를 생산하는 명암도 동시발생 행렬 (Gray-Level Co-occurrence Matrix; GLCM) 과 같은 기법이 추후 적용된다면 알고리즘 개선에 도움이 될 것으로 판단되었다.

3) Sentinel-1 SAR 영상의 낮은 적용가능성

아래 그림 4.41은 동일하게 2020년 4월 4일에 취득된 Sentinel-2 영상과 전처리를 마친 Sentinel-1 SAR Interferometric Wide Swath 모드 영상의 VV 및 VH편광 영상이다. 그림에서 확인할 수 있듯, Sentinel-1 SAR 영상이 토지피복에 따라 다른 후방산란계수를 나타내는 것을 확인하였다. 그러나, 본 과업의 중요한 요소 중 하나인, 나지 탐지능력 고도화를 달성하기 위해 Sentinel-1 SAR 영상을 융합하려고 시도하였지만 그림 4.41에서 확인할 수 있듯이 하천 내부의 나지 클래스가 Sentinel-2 광학영상에서는 확연하게 탐지 가능한것에 비해서 SAR 영상에서는 노이즈 형태로 나타나는 것을 확인하였다.

이러한 이유로 Sentinel-1 영상을 사용하는 것이 부적절할 것이라는 가정을 바탕으로 실제 나지 클래스의 후방산란계수의 시계열 패턴을 분석하였고, 그림 4.42에서와 같이, Sentinel-1 SAR VV 편광 영상을 이용하였을 때, 나지 클래스의 후방산란계수 (그림 4.42의 빨간색 및 분홍색)가 다른 클래스, 경작지, 목지, 경작지 등과 상당부분 중첩되는 것을 확인하였다 (VH 편광에서도 동일한 패턴을 확인) 이러한 분석을 통해 나지탐지 성능 향상을 위해서는 Sentinel-1 SAR 영상을 사용하지 않는 것이 나지분류 정확도 향상을 위해 필요하다 판단하여 본 과업에서는 SAR 영상을 사용하지 않기로 결정하였다. 선행연구 중 zhang 등 (2018)에서도 SAR영상의 융합이 융합 알고리즘 및 방법에 따라서 언제나 좋은 결과를 내는 것이 아니라는 것을 언급한 바 있다.

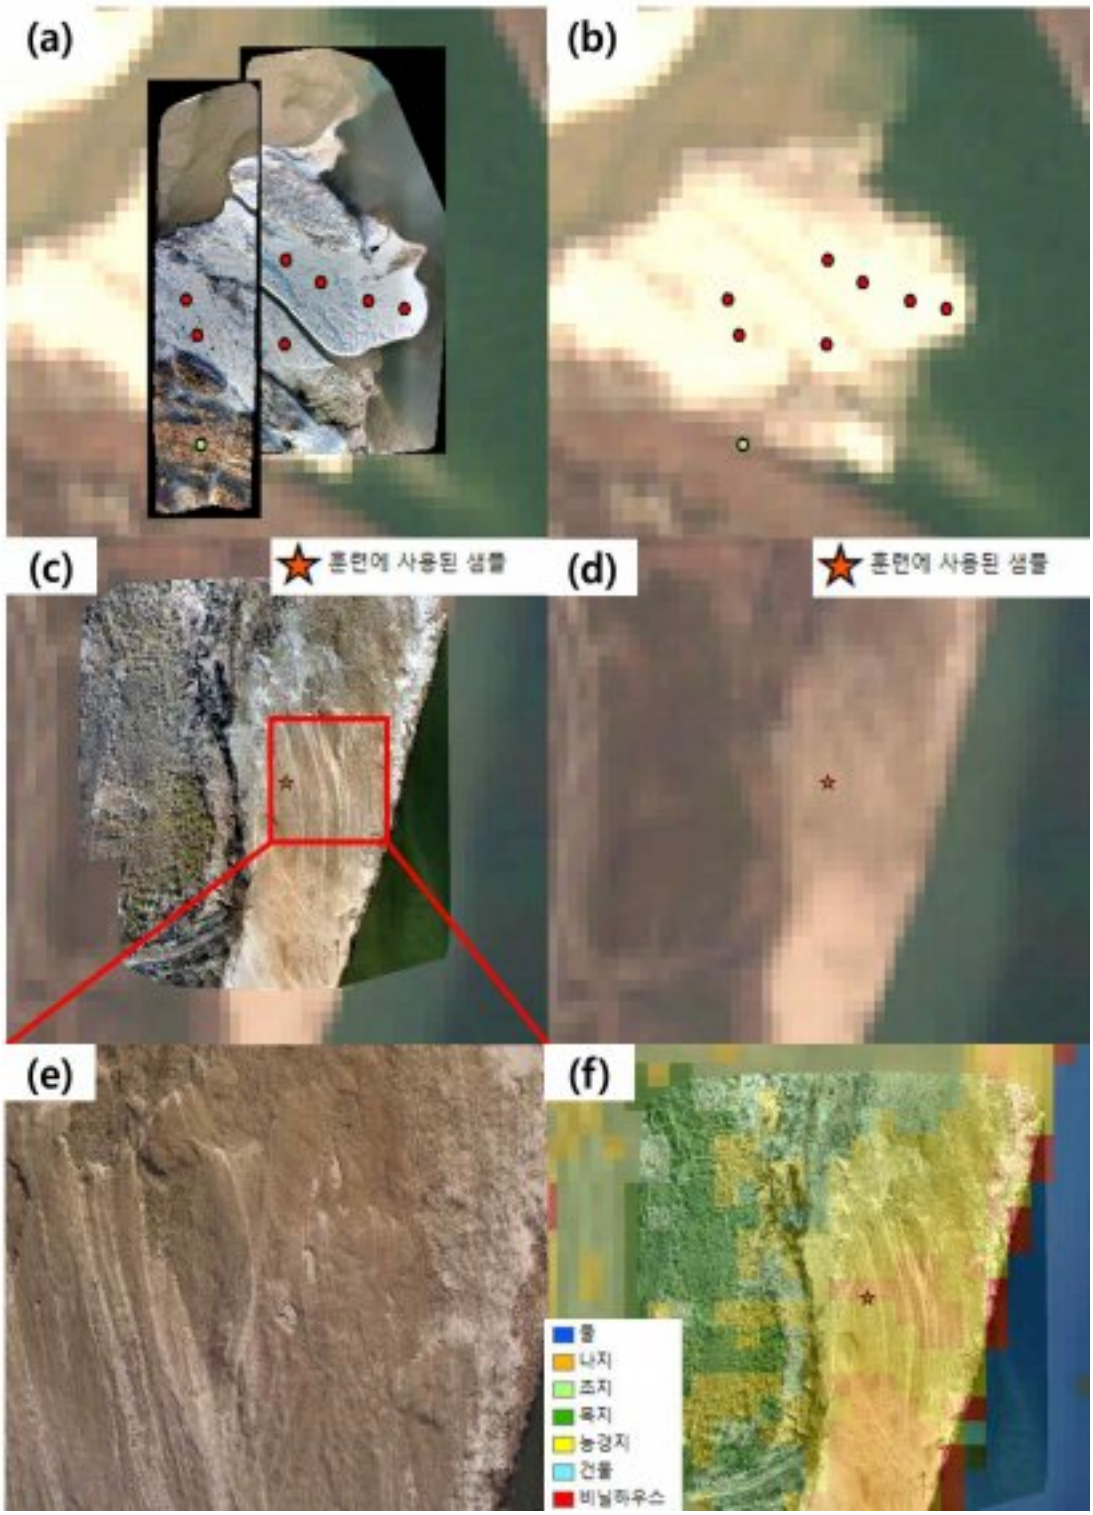


그림 4.40 2020년 11월 23일 경상북도 구미시 선산읍 원리 부근의 지류와 낙동강 본류의 합류점 (a),(b). 2020년 12월 3일 경상남도 합천군 청덕면 적포리 부근 낙동강 본류 서쪽 하안 (c)~(e)

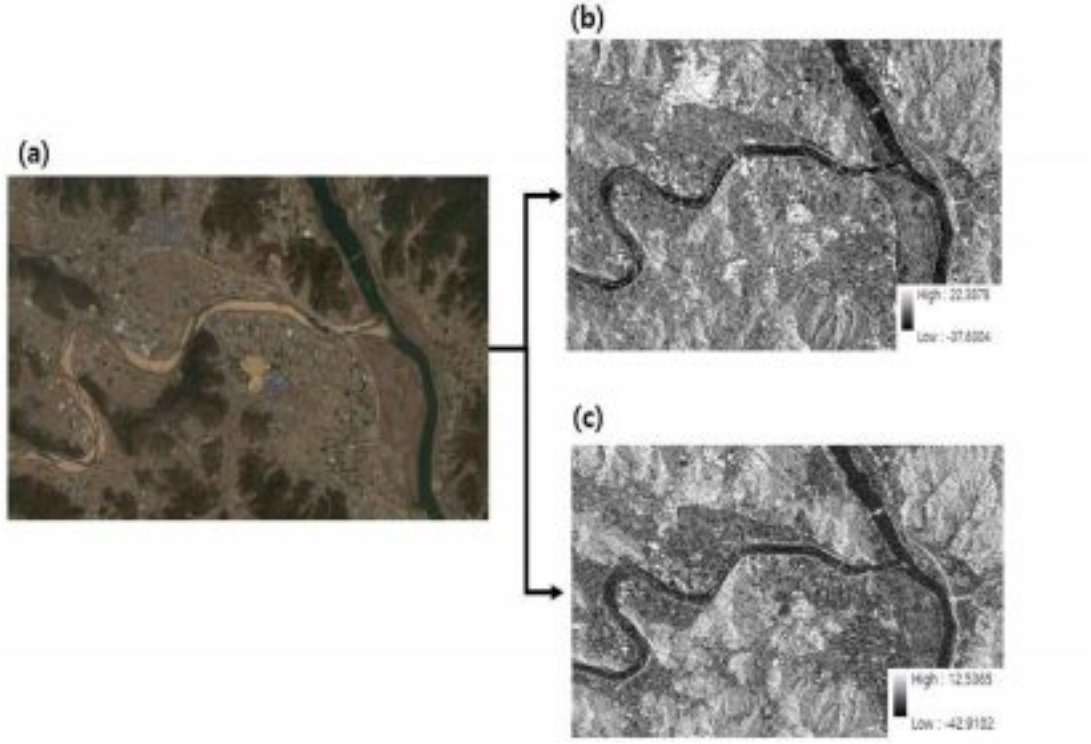


그림 4.41 2020년4월4일에 취득된 Sentinel-2 광학영상 (a)과 전처리를 마친 Sentinel-1 SAR 영상의 VV편광 (b) 및 VH편광 (c) 영상

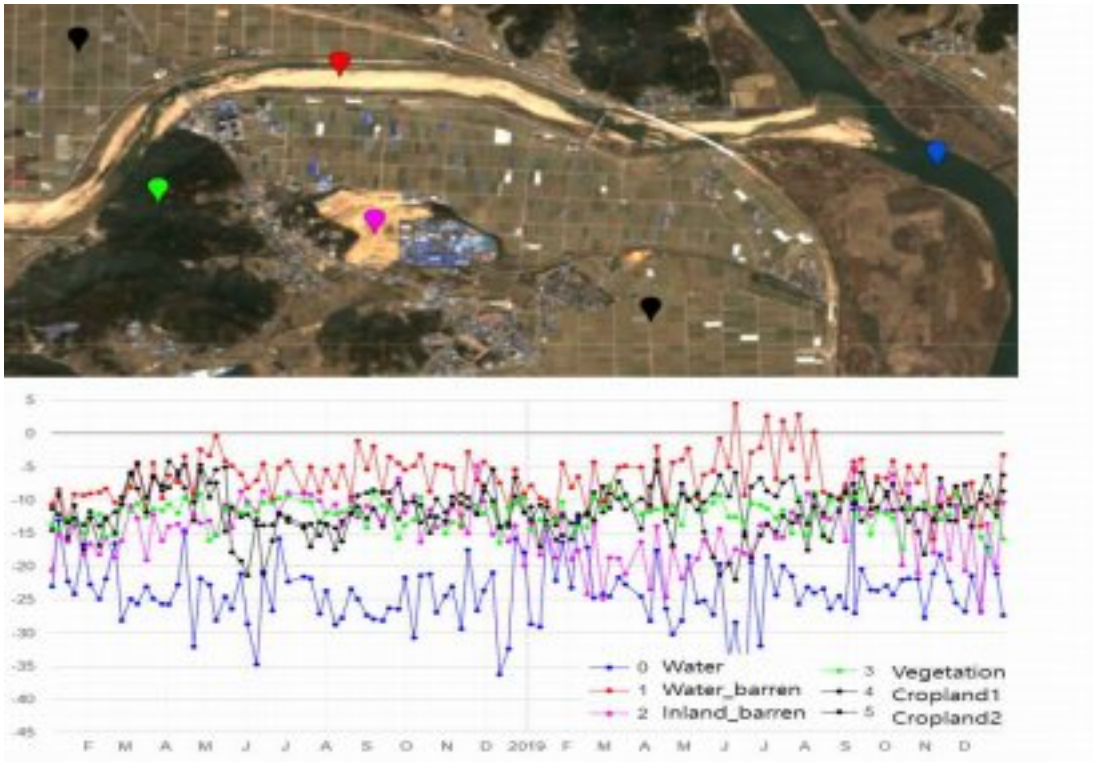


그림 4.42 위 그림과 동일한 지역의 광학영상 (위) 및 Sentinel-1 SAR 영상의 시계열 후방산란계수

4.3.11 미계측지역 적용에 대한 한계 및 유의사항 검토

1) 미계측지역 적용에 대한 한계/유의사항 검토

미계측지역이란 관측소가 없거나 접근성이 떨어져 계측이 어려운 곳을 의미하며 본 과업에서는 Sentinel-2 위성 영상을 이용해 토지 피복 분류를 수행하여 해당 지역에 대한 토지 피복 분류의 가능성을 보았다. 하지만 무인 항공기 자료를 이용하여 위성 영상만을 이용한 분류에서 혼합픽셀에 의한 분류의 한계점을 확인하였으며 이는 미계측지역에 본 알고리즘을 적용하는 데에 한계점이 될 수 있어 이에 대한 유의가 필요하다. 혼합픽셀은 강의 하폭이 좁은 낙동강 유역에서 대두된 한계점으로 미계측지역 중 강의 하폭이 넓은 부분에서는 분류 정확도가 높아질 것으로 기대할 수 있다. 또한 무인항공기의 이용으로 나지에 대한 샘플을 충분히 확보하여 훈련한다면 나지 분류의 정확도도 높일 수 있을 것으로 사료되나 미계측지역 중 대표적으로 들 수 있는 북한 지역에 대해서는 무인 항공기의 운용에 어려움이 있을 것으로 예상되어 해당 한계점의 대안이 필요하다. 물과 다른 토지피복간의 경계선에서 혼합픽셀에 의해 해당 토지피복이 비닐하우스나 건물로 오분류되는 문제점 또한 미계측지역에 대하여 발생할 수 있는 문제이므로 이에 대한 후처리나 개선안이 필요하다. 앞서 예를 든 미계측지역 중 북한 지역에 대해서는 토지 이용에 대한 조사가 부족하여 계절마다 변하는 경작지 외 초지에 대해 높은 정확도의 토지 피복 분류를 기대하기 어려우며 산림에서 화전(火田) 농업이 이루어질 경우 갑작스럽게 변하는 토지 피복에 의해 오분류가 일어날 수도 있을 것으로 예상된다. 미계측지역의 혼합픽셀에 대한 해결 방안으로 Sentinel-1 SAR를 이용한 고해상도 영상 분석을 도모할 수 있으나 무인항공기를 이용한 평가 중 Sentinel-1 SAR영상의 낮은 적용 가능성에서 언급한 바와 같이 광학 영상에서 픽셀 값이 해당되는 클래스의 특성을 뚜렷하게 나타냄과 달리 SAR영상에서는 노이즈가 나타나고 다른 클래스와 후방 산란 계수가 중첩되는 한계점이 있어 해당 영상의 사용은 지양하는 것이 좋을 것으로 사료된다.

4.4 인공지능 기반 위성영상 수변환경 변화 분석 모듈 개선 및 현업화 지원

4.4.1 전처리 프로그램 설치

1) 전처리를 위한 프로그램 소개

위성영상의 전처리를 위해 먼저 Fmask4.0 및 Sen2Cor를 Ubuntu 서버컴퓨터에 설치해야 함
실험환경은 다음과 같다
OS: Ubuntu 18.04.2 LTS (GNU/Linux 4.15.0-112-generic x86_64)
CPU: Intel(R) Xeon(R) CPU E5-2680 v2 @ 2.80GHz (10core 20thread * 2)
Memory (RAM): 128GB

2) Fmask4.0 설치

https://drive.google.com/drive/folders/1SXBnEBDJ1Kbv7IQ9qIgqloYHZfdP6O1O (2020.12.01. 접속 가능) 또는 https://github.com/GERSL/Fmask 로 접속하여 Fmask4.0 파일을 다운로드 (아래의 그림)



그림 4.43 Fmask 4.0 다운로드

cd 커맨드를 이용해서 Fmask_4_0_install 이 있는 경로로 이동

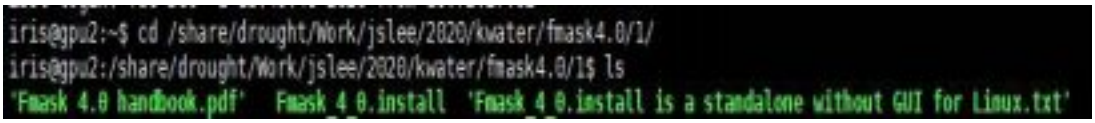


그림 4.44 다운받은 Fmask파일이 있는 경로로 이동 및 실행

다운로드받은 Fmask_4_0_install 파일을 관리자 권한으로 실행

만약 다음과 같은 에러가 발생한다면 “Problem with the SSL CA cert (path? access rights?)”

아래 패키지를 설치한 뒤 Fmask_4_0_install 재실행

apt-get install ca-certificates (Ubuntu)

yum install ca-certificates (Centos)



그림 4.45 설치과정1

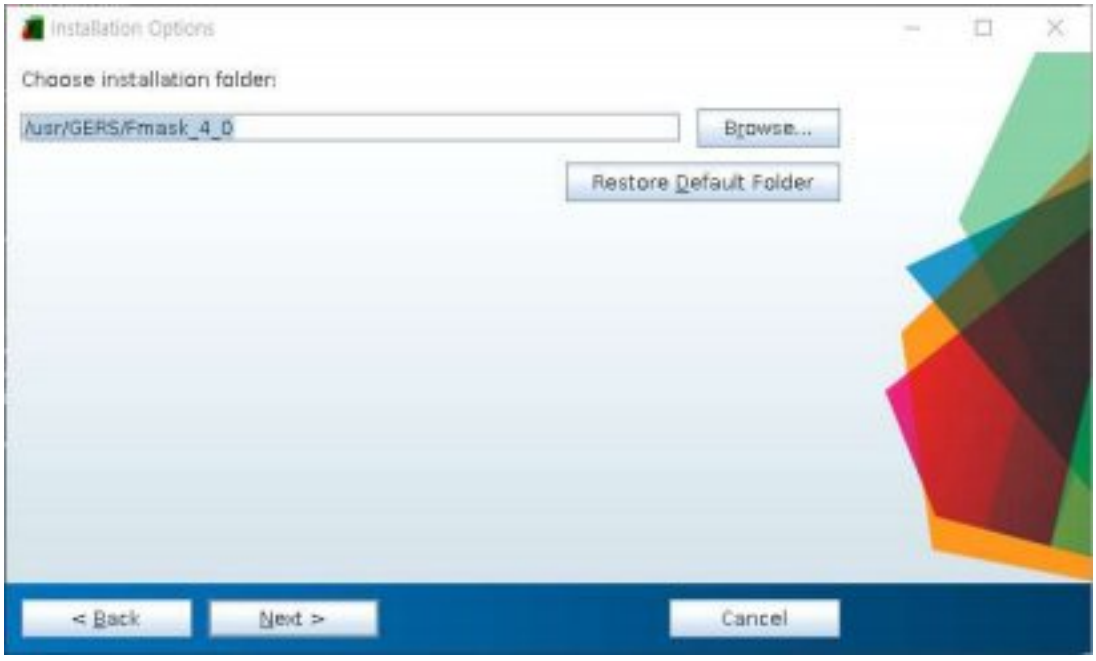


그림 4.46 설치과정2

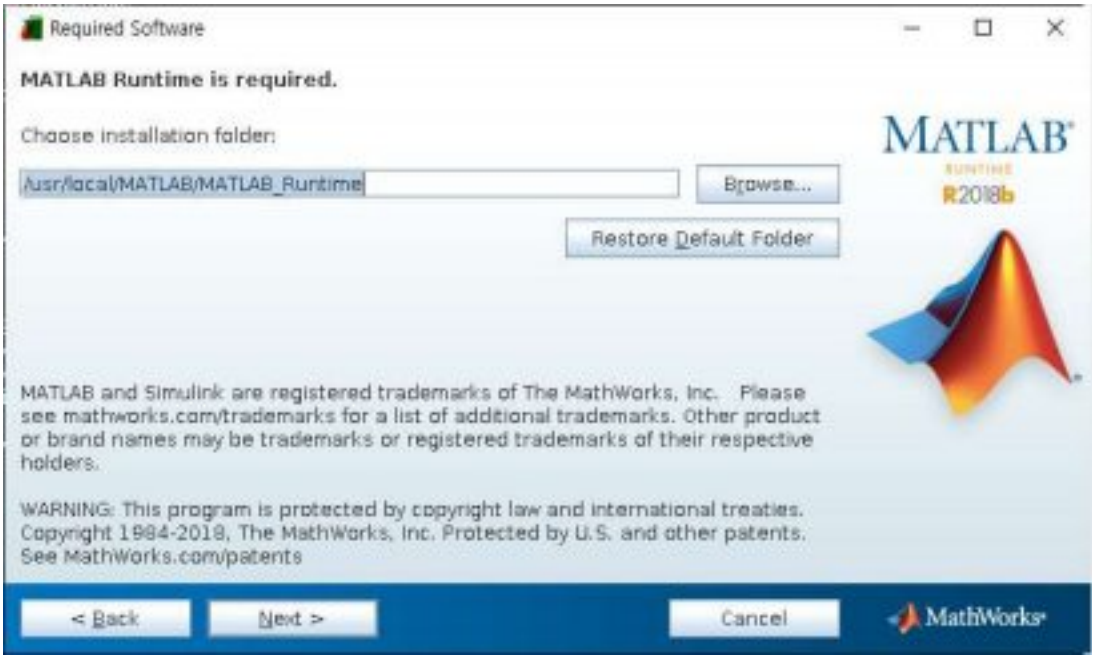


그림 4.47 설치과정3

여기 MATRAB Runtime이 설치되는 경로를 복사 후
/usr/local/MATLAB/MATLAB_Runtime 에 "/v95"를 더한 경로 필요

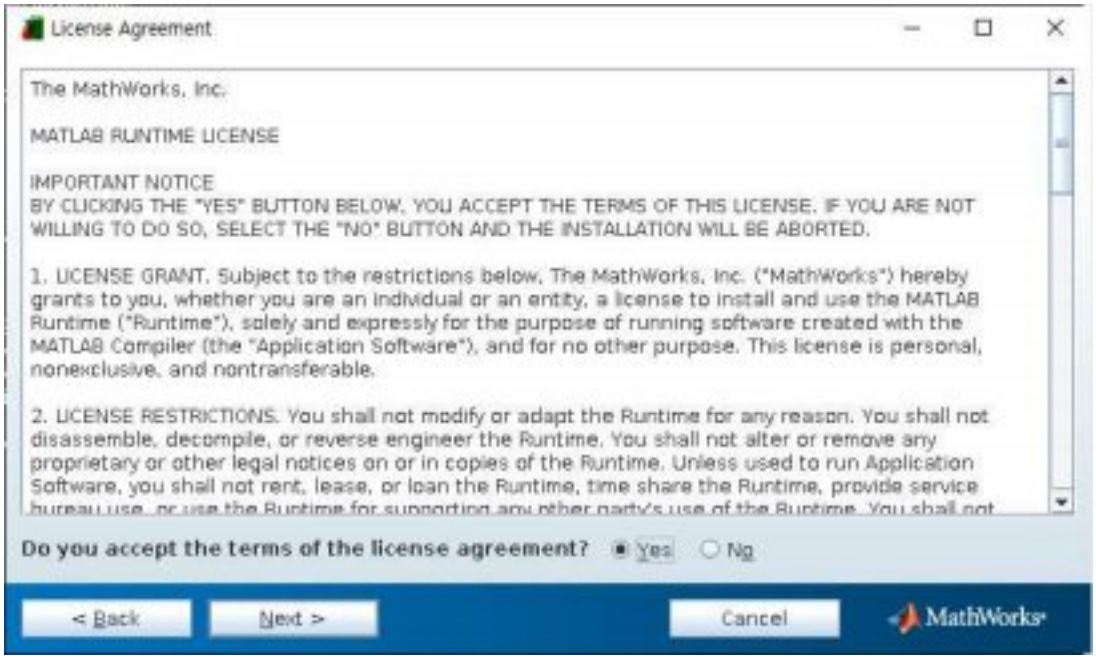


그림 4.48 설치과정4

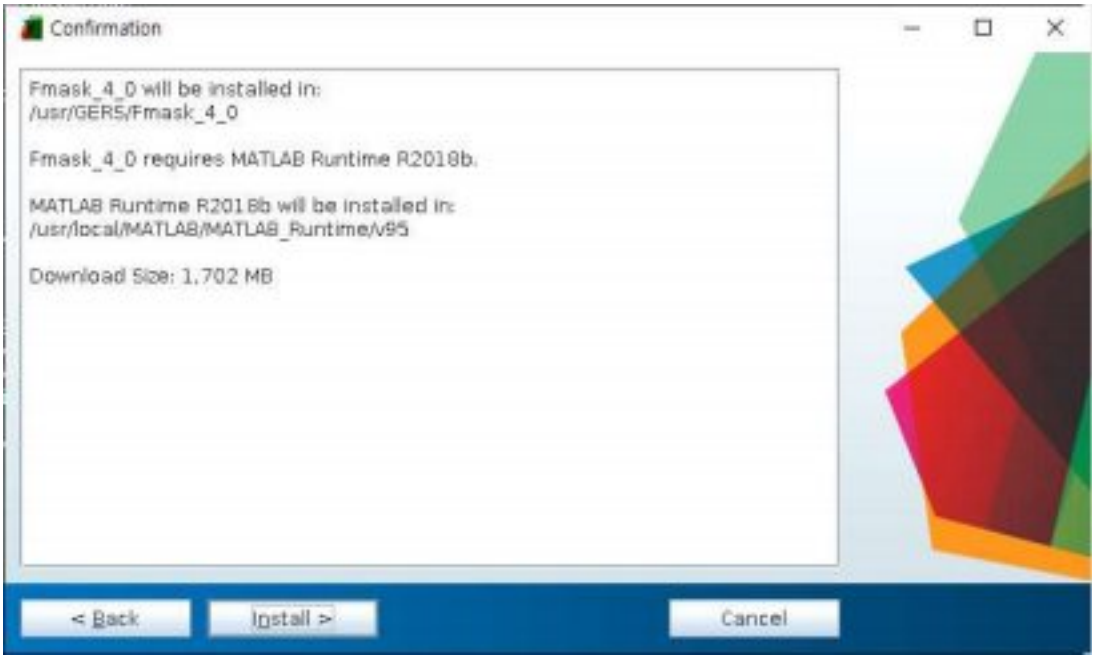


그림 4.49 설치과정5

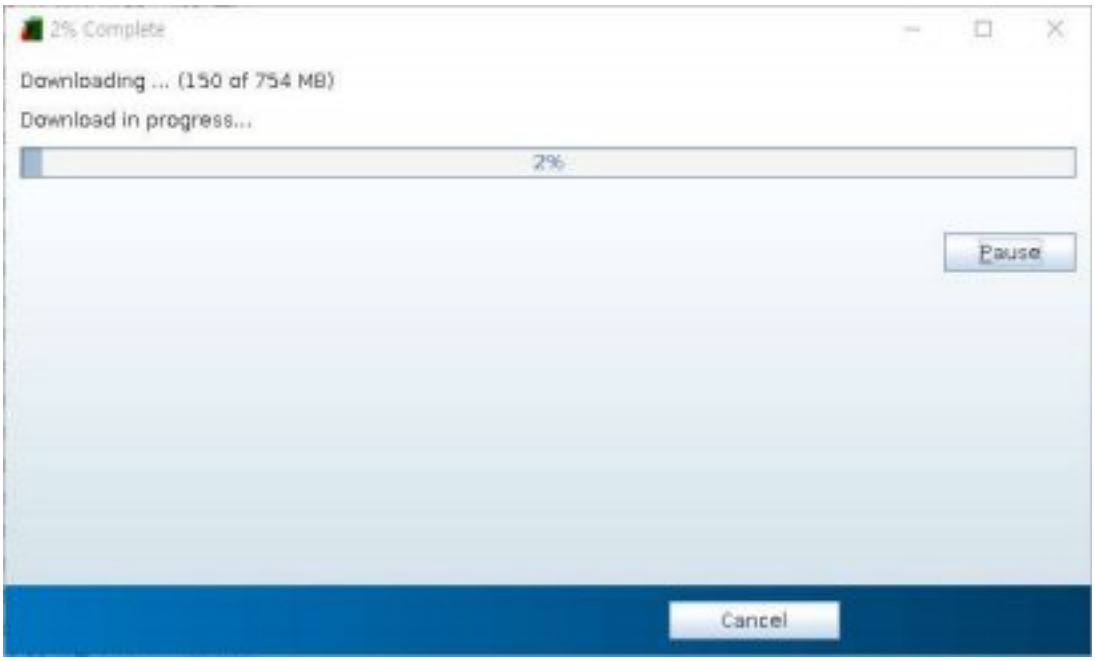


그림 4.50 설치과정6

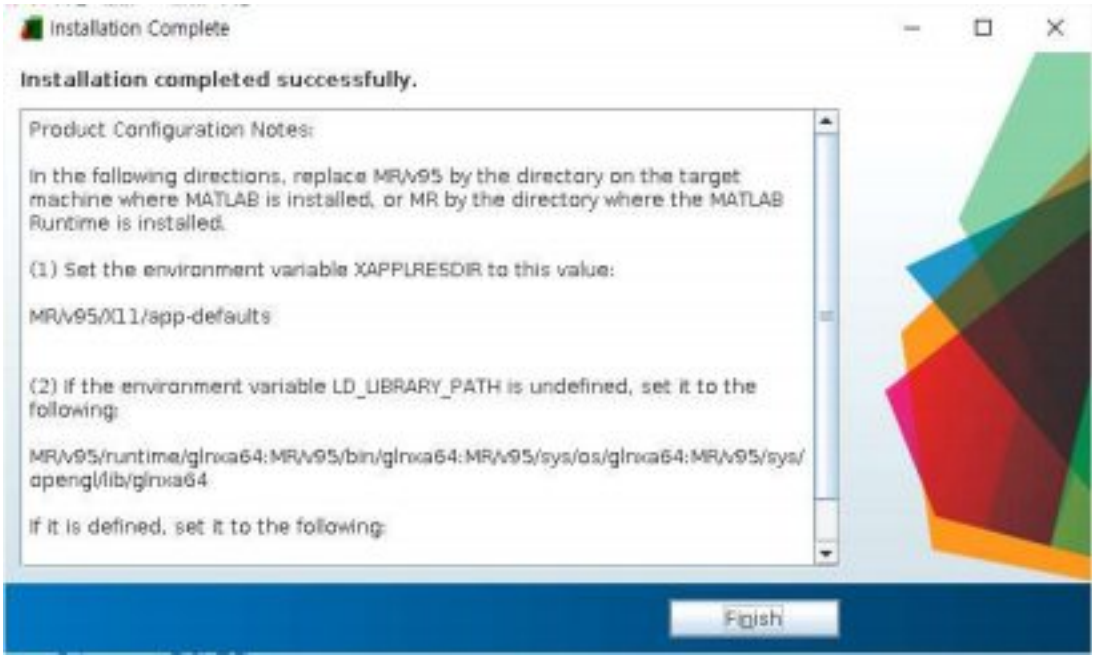


그림 4.51 설치과정7

설치가 끝나면 Fmask4.0을 사용하기 위해 두 환경변수 XAPPLRESDIR 및 LD_LIBRARY_PATH 설정이 필요함

위 페이지에서 복사해놓은 경로를 사용해 환경변수를 저장해줌

ex)

export XAPPLRESDIR=/usr/local/MATLAB/MATLAB_Compiler_Runtime/v95/X11/app-defaults

export LD_LIBRARY_PATH=/usr/local/MATLAB/MATLAB_Runtime/v95/runtime/glnxa64:/usr/local/MATLAB/MATLAB_Runtime/v95/bin/glnxa64:/usr/local/MATLAB/MATLAB_Runtime/v95/sys/os/glnxa64:/usr/local/MATLAB/MATLAB_Runtime/v95/sys/opengl/lib/glnxa64

2) Sen2Cor 설치

http://step.esa.int/main/snap-supported-plugins/sen2cor/sen2cor_v2-8/로 접속하여 Sen2Cor-02.08.00-Linux64.run 파일을 다운로드



It is important to know, that the default configuration of the L2A algorithm provided with Sen2Cor version 2.8 is the same configuration as for the L2A "Core" Products processing in Sentinel-2 Ground Segment with L2A processing baseline 02.12. Therefore, no further tuning should be required on user side to get L2A Core Products. In order to generate products compatible with the L2A Core Products it is necessary to set the usage of a Digital Elevation Model to improve Scene Classification and have the activation of ESA CCI data package to be downloaded here and installed. The usage of ESA CCI data package for Sen2Cor v2.8 is detailed in the dedicated Software User Manual: S2-PDGS-MPC-L2A-SUM-V2.8.

The only differences between "L2A Toolbox" and L2A Core Products are reported in the following table:

Category of Difference	Difference	L2A Toolbox	L2A Core Products
Product Format	HTML Folder	No	Yes
	Manifest	Same Set of items but arranged in different order	
	Product Quality Metadata	Copied from L1C	Generated by L2A On-line Quality Check (OLQC)
Radiometry at Pixel Level	Digital Elevation Model	e.g. SRTM/DEM defined by the users	PlanetDEM
	JPEG2000 encoding library	Kakadu	OpenJPEG

The evolution of the processing baseline used to process Sentinel-2 L2A Core Products in Ground Segment are reported in the L2A Data Quality Report.

For any questions about the usage of Sen2Cor, please follow the general STEP forum area dedicated to Sen2Cor: http://forum.step.esa.int/c/s2tbx/sen2cor

Latest release:

- 2.8 – It was released on February 21, 2017. This version runs on the operating systems: Linux, Mac OSX and Windows (64 bit is mandatory). For details about the features and fixes, see the release note.
  - Standalone installers:
    Windows installer: Sen2Cor-02.08.00-win64.zip
    Linux installer: Sen2Cor-02.08.00-Linux64.run
    Mac installer: Sen2Cor-02.08.00-Darwin64.run

Detailed information on all changes implemented in the new format of Sentinel-2 L2A product is available in the dedicated documentation online: Sentinel-2 Products Specification Document (PSD)

그림 4.52 Sen2Cor 다운로드

다운로드 받은 파일을 실행

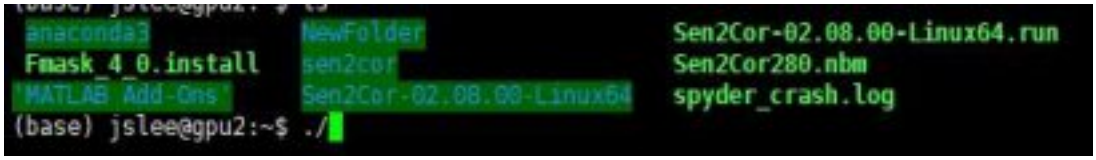


그림 4.53 Sen2Cor설치

설치가 끝난 뒤 홈 디렉토리에 생성된 sen2cor 안의 폴더의 L2A_GIPP.xml 파일을 수정

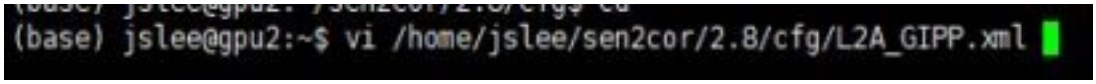


그림 4.54 L2A_GIPP.xml 수정

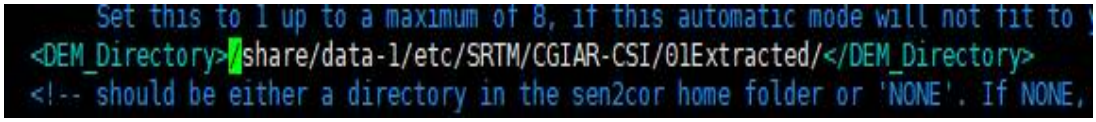


그림 4.55 L2A_GIPP.xml 내의 DEM_directory를 수정

Sentinel-2 이미지의 DEM correction을 위해 DEM_Directory에 CGIAR-SRTM을 다운로드 받아 저장한 폴더를 지정

srtm.csi.cgiar.org에 접속해서 DEM을 다운로드

* 남한 타일은 srtm_62_05.tif 및 srtm_63_05.tif

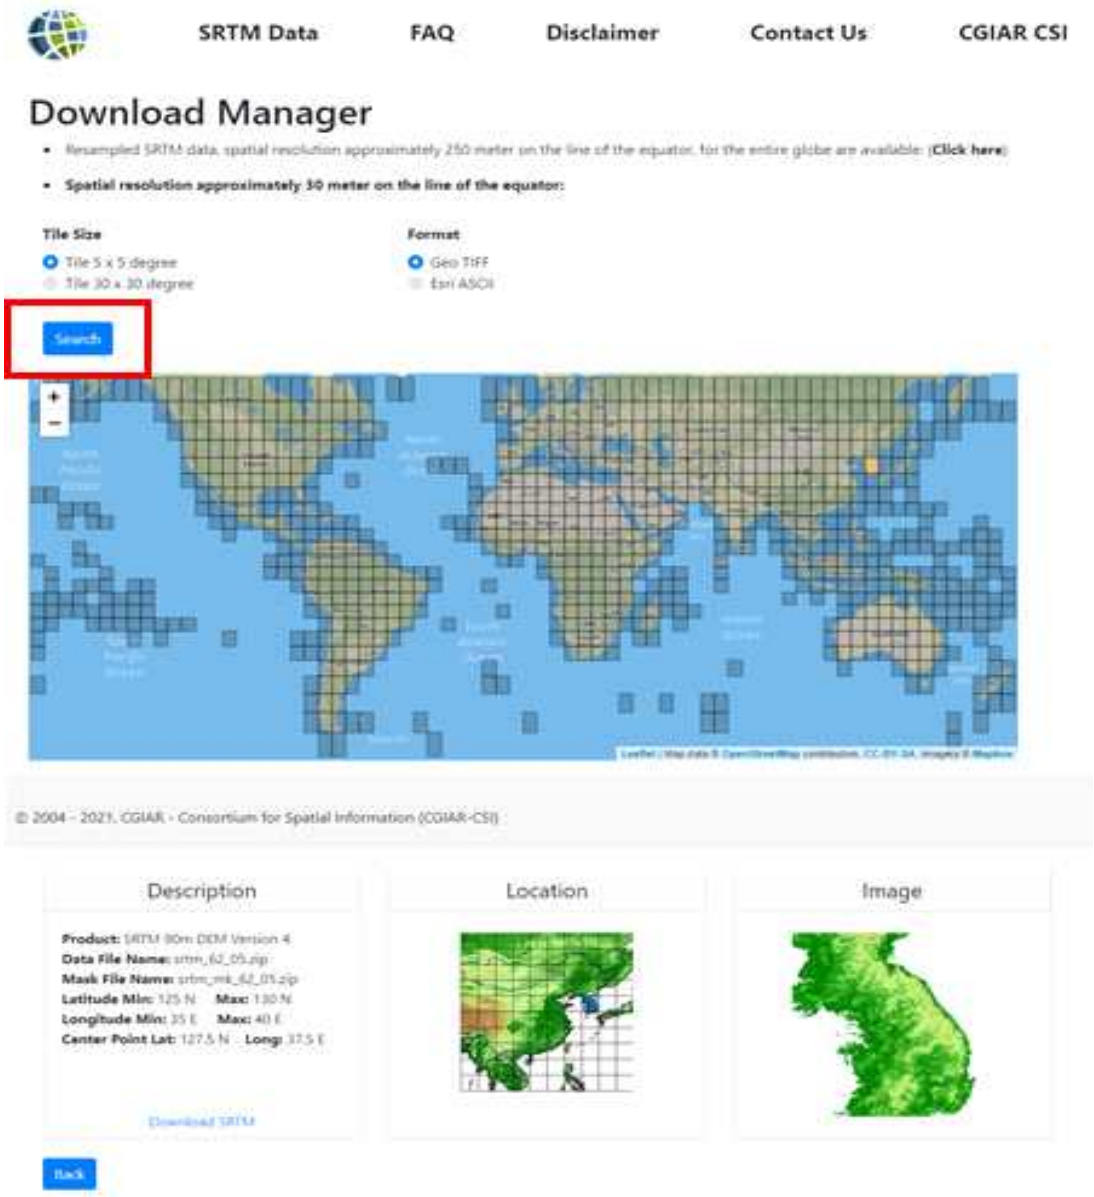


그림 4.56 CGIAR SRTM 다운로드 화면

4.4.2 프로그래밍 언어 Python을 이용한 전처리 프로그램인 Fmask4.0 및 Sen2Cor 실행

```python
import os
import glob as g

## 전처리 (구름 마스크 제작 Fmask4.0)
# 경로를 변수로 지정 해 줍니다
L1C_dir = '/share/project/K-water_2020/part2/data/comparison/*L1C*.SAFE'
fmask_dir = '/usr/GERS/Fmask_4_0/application/Fmask_4_0'

def run_fmask(L1C_dir):
    # Fmask4.0 적용이 필요한 L1C가 위치한 폴더의 리스트를 만듭니다
    folderlist = g.glob(L1C_dir)
    folderlist.sort() # 정렬합니다
    # for loof 를 사용해서 순차적으로 Fmask 적용
    for i in range(len(folderlist)):
        destination = g.glob('{}/GRANULE/*/'.format(folderlist[i]))
        print('Run Fmask for :', destination[0])
        os.chdir('{}'.format(destination[0]))
        os.system(fmask_dir)

## 전처리 (대기보정, Sen2Cor)
# 경로를 변수로 지정해줍니다
L1C_dir = '/share/project/K-water_2020/part2/data/comparison/*L1C*.SAFE'
Sen2Cor_dir = '/home/jslee/Sen2Cor-02.08.00-Linux64/bin/L2A_Process'

def run_sen2cor(Sen2Cor_dir, L1C_dir):
    # Sen2Cor를 통한 대기보정이 필요한 L1C 자료가 위치한 경로
    L1C_list = g.glob(L1C_dir)
    L1C_list.sort() # 정렬
    # for loof 를 사용해서 순차적으로 Sen2Cor 적용
    for i in range(len(L1C_list)):
        print('Run Sen2Cor for :', L1C_list[i])
        cmd = '{} {} --resolution 10'.format(Sen2Cor_dir, L1C_list[i])
        os.system(cmd)
```

그림 4.57 Python을 이용한 전처리 프로그램 Fmask4.0 및 Sen2Cor 실행

1-2: 필요한 라이브러리를 불러옴

6-18: Sentinel-1 L1C 파일이 다운로드되어있는 폴더에 fmask를 생성

22-33: Sentinel-1 L1C 파일이 다운로드되어있는 폴더에 대기보정을 마친 L2A 폴더를 생성

4.4.3 프로그래밍 언어 Python을 이용한 수변환경 분류지도 생산

36-53: 필요한 라이브러리를 불러옴 여기서 matplotlib, fiona, rasterio, geopandas, pandas, sklearn, pyproj는 conda 또는 pip를 통해 파이썬 환경에 설치해야 함

```
import numpy as np
import matplotlib.pyplot as plt
import fiona
import rasterio as rio
from rasterio.enums import Resampling
import rasterio.mask
from rasterio.merge import merge
import geopandas as gpd
import pandas as pd
import glob as g
from sklearn.metrics import confusion_matrix
import itertools
import pickle
import random
from copy import deepcopy
from pyproj import Proj, transform
import matplotlib
matplotlib.use('Agg')
```

그림 4.58 Python 기반 수변환경 분류 알고리즘을 이용하기 위해 불러온 라이브러리

```
## 혼동행렬
def plot_confusion_matrix(cm, target_names=None, cmap=None, normalize=True, labels=True, title='Confusion matrix'):
    accuracy = np.trace(cm) / float(np.sum(cm))
    misclass = 1 - accuracy

    if cmap is None:
        cmap = plt.get_cmap('Blues')

    if normalize:
        cm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]

    plt.figure(figsize=(8, 6))
    plt.imshow(cm, interpolation='nearest', cmap=cmap)
    plt.title(title)

    thresh = cm.max() / 1.5 if normalize else cm.max() / 2

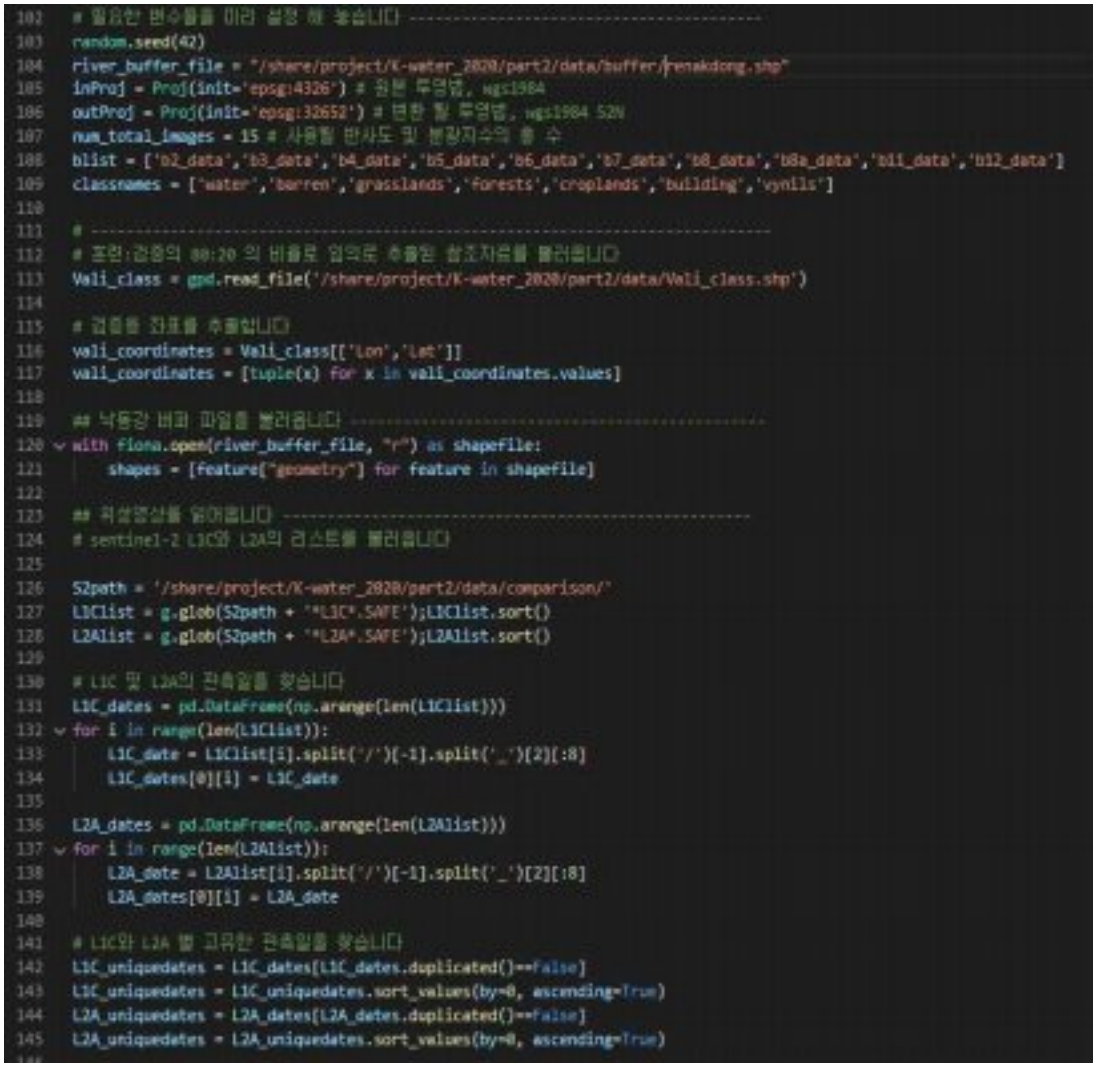
    if target_names is not None:
        tick_marks = np.arange(len(target_names))
        plt.xticks(tick_marks, target_names)
        plt.yticks(tick_marks, target_names)

    if labels:
        for i, j in itertools.product(range(cm.shape[0]), range(cm.shape[1])):
            if normalize:
                plt.text(j, i, "{:0.2f}".format(cm[i, j]),
                         horizontalalignment="center",
                         color="white" if cm[i, j] > thresh else "black")
            else:
                plt.text(j, i, "{:,}".format(cm[i, j]),
                         horizontalalignment="center",
                         color="white" if cm[i, j] > thresh else "black")

    plt.xlim(-0.5, len(np.unique(tick_marks))-0.5)
    plt.ylim(len(np.unique(tick_marks))-0.5, -0.5)
    plt.ylabel('True label')
    plt.xlabel('Predicted label \n accuracy={:0.2f}; misclass={:0.2f}'.format(accuracy, misclass))
    plt.show()

## 좌표 변환
def convertCoords(ref):
    x,y = transform(inProj,outProj,ref['lon'],ref['lat'])
    return pd.Series({'lon':x,'lat':y})
```

그림 4.59 수변환경 분류 알고리즘을 위한 혼동행렬 함수 및 좌표변환을 위한 함수 정의



```
# 필요한 변수들을 미리 설정 해 놓습니다 ------------------------------------
random.seed(42)
river_buffer_file = "/share/project/K-water_2020/part2/data/buffer/renakdong.shp"
inProj = Proj(init='epsg:4326') # 원본 투영법, wgs1984
outProj = Proj(init='epsg:32652') # 변환 될 투영법, wgs1984 52N
num_total_images = 15 # 사용될 반사도 및 분광지수의 총 수
blist = ['b2_data','b3_data','b4_data','b5_data','b6_data','b7_data','b8_data','b8a_data','b11_data','b12_data']
classnames = ['water','barren','grasslands','forests','croplands','building','vynils']

# ------------------------------------------------------------------------
# 훈련:검증의 80:20 의 비율로 임의로 추출된 참조자료를 불러옵니다
Vali_class = gpd.read_file('/share/project/K-water_2020/part2/data/Vali_class.shp')

# 검증용 좌표를 추출합니다
vali_coordinates = Vali_class[['Lon','Lat']]
vali_coordinates = [tuple(x) for x in vali_coordinates.values]

## 낙동강 버퍼 파일을 불러옵니다 ------------------------------------------
with fiona.open(river_buffer_file, "r") as shapefile:
    shapes = [feature["geometry"] for feature in shapefile]

## 위성영상을 읽어옵니다 ---------------------------------------------------
# sentinel-2 L1C와 L2A의 리스트를 불러옵니다

S2path = '/share/project/K-water_2020/part2/data/comparison/'
L1Clist = g.glob(S2path + "*L1C*.SAFE");L1Clist.sort()
L2Alist = g.glob(S2path + "*L2A*.SAFE");L2Alist.sort()

# L1C 및 L2A의 관측일을 찾습니다
L1C_dates = pd.DataFrame(np.arange(len(L1Clist)))
for i in range(len(L1Clist)):
    L1C_date = L1Clist[i].split('/')[-1].split('_')[2][:8]
    L1C_dates[0][i] = L1C_date

L2A_dates = pd.DataFrame(np.arange(len(L2Alist)))
for i in range(len(L2Alist)):
    L2A_date = L2Alist[i].split('/')[-1].split('_')[2][:8]
    L2A_dates[0][i] = L2A_date

# L1C와 L2A 별 고유한 관측일을 찾습니다
L1C_uniquedates = L1C_dates[L1C_dates.duplicated()==False]
L1C_uniquedates = L1C_uniquedates.sort_values(by=0, ascending=True)
L2A_uniquedates = L2A_dates[L2A_dates.duplicated()==False]
L2A_uniquedates = L2A_uniquedates.sort_values(by=0, ascending=True)
```

그림 4.60 수변환경 분류 알고리즘 적용 준비1

58-94: scikit-learn(sklearn)기반 confusion_matrix 함수를 사용해서 혼동행렬을 계산한 뒤 정의한 혼동행렬 함수를 통해 이미지로 불러옴

97-99: rasterio의 transform 함수를 통해서 WGS84 경위도좌표를 UTM52N 좌표로 변환할 때 사용함

102-109: 알고리즘 사용중에 필요한 변수 또는 리스트를 미리 정의함

113: 전체 참조자료중 검증용으로 분리해놓은 20%의 자료를 불러옴

116-117: 검증용으로 불러온 참조자료의 좌표를 추출함

120-121: 낙동강 버퍼파일을 불러오고, 연구지역의 범위를 국가하천도기준 1km이 되도록 제한하는데 사용함

126-128: glob을 통해 Sentinel-2 L1C와 L2A 자료를 불러옴

131-145: Sentinel-2 L1C 및 L2A의 고유한 관측일을 찾아냄

```
151  # Fmask4.0를 통해 얻어진 반사도 및 분광지수로 훈련된 RF모델를 불러옵니다
152  RF_trained = '/share/project/K-water_2020/part2/output/yearly/RF_riverenvironment.dat'
153  with open(RF_trained, 'rb') as f:
154      clf = pickle.load(f)
155
156  # 결과를 저장할 폴더의 이름를 정합니다
157  outpathname = 'output_validation'
158  outpath_metric = '/share/project/K-water_2020/part2/output_validation/'
```

그림 4.61 수변환경 분류 알고리즘 적용 준비2

151-154: pickle을 통해서 미리 훈련되어 저장되어있는 Random Forest 모델을 불러옴
157-158: 결과를 저장할 폴더의 이름을 정함

```
160  ## 위성영상의 날짜별로 토지피복을 분류하고 평가합니다
161  for id in range(len(L2A_uniquedates)):
162      outdate = L2A_uniquedates.iloc[id][0]
163      L2Alist = g.glob(S2path + '*L2A*{}*.SAFE'.format(outdate));L2Alist.sort()
164      L1Clist = g.glob(S2path + '*L1C*{}*.SAFE'.format(outdate));L1Clist.sort()
165
166      print('{} images exist in {}'.format(len(L2Alist), outdate))
167
168      outpath = ['/share/project/K-water_2020/part2/{}'.format(outpathname),
169                 '/share/project/K-water_2020/part2/{}/{}/'.format(outpathname, outdate)]
170      for op in outpath:
171          try:
172              os.mkdir(op)
173          except:
174              print('already exist directory')
175      outpath = outpath[-1]
176
177      for ii in range(len(L2Alist)): # 특정 날짜 안의 위성영상 타일 수 만큼 반복합니다
178          img_in = L2Alist[ii]
179          msk_in = g.glob(L1Clist[ii] + '/GRANULE/*/FMASK_DATA/*.tif')
180
181          imgtile = img_in.split('_')[-2]
182          msktile = msk_in[0].split('_')[-4]
183
184          outname = '{}_{}'.format(outdate, imgtile)
185          if imgtile != msktile:
186              print('different img and mask')
187              break
188          else:
189              print('matching Tile')
```

그림 4.62 계산할 날짜 탐지, 출력폴더 생성 및 타일들별 반복 시작

161-176: 131-145에서 얻어낸 위성영사의 날짜별로 계산할 날짜 준비 및 출력폴더를 생성
177-189: 특정 날짜 안의 낙동강을 관측한 타일들을 불러와 반복을 실행

```
191         # 파일을 불러와 정렬합니다
192         L21ist_20 = g.glob(img_in + '/GRANULE/*/IMG_DATA/R20m/*.jp2')
193         L21ist_10 = g.glob(img_in+ '/GRANULE/*/IMG_DATA/R10m/*.jp2')
194         L21ist_10.sort()
195         L21ist_10 = L21ist_10[4]
196         L21ist_20.sort()
197         L21ist_20 = L21ist_20[1:10]
198         L2mask = g.glob(img_in + '/GRANULE/*/QI_DATA/MSK_CLDPRB_20m.jp2')
199
200         # 밴드8을 20m로 리샘플링 하기 위한 기준을 얻기 위해 밴드5를 불러옵니다
201         with rio.open(L21ist_20[3], driver = 'JP2OpenJPEG') as b5:
202             b5_data = b5.read()
203             b5.close()
204
205         # 밴드8를 20m로 리샘플링 해 줍니다
206         with rio.open(L21ist_10, driver = 'JP2OpenJPEG') as b8:
207             b8_data = b8.read(
208                     out_shape=(b8.count, int(b8.height / 2), int(b8.width / 2)),
209                     resampling=Resampling.average
210                     )
211             out_meta = b8.meta.copy()
212             out_meta.update({"driver": "GTiff",
213                              "height": b5.shape[0],
214                              "width": b5.shape[1],
215                              "transform": b5.transform,
216                              "crs": rasterio.crs.CRS({'init': 'epsg:32652'}) # 52N
217                              })
218             with rasterio.open(outpath+"b8_mosaic_upscale.tif", "w", **out_meta) as dest:
219                 dest.write(b8_data)
220             b8.close()
```

그림 4.63 타일의 반사도파일을 불러와서 리샘플링

192-198: 반사도파일을 불러오고, 필요없는 파일들을 리스트로부터 제거

201－220: 밴드8 (10m 공간해상도)를 20m로 리샘플링

```
222         # 사용하지 않는 자료를 삭제합니다
223         del b5_data
224         del b8_data
225
226         ## 이미지를 불러옵니다
227         with rio.open(l21list_20[0], driver = 'JP2OpenJPEG') as b2:
228             b2_data, out_transform = rio.mask.mask(b2, shapes, crop=True) #
229             b2_meta = b2.meta
230             b2.close()
231         with rio.open(l21list_20[1], driver = 'JP2OpenJPEG') as b3:
232             b3_data, out_transform = rio.mask.mask(b3, shapes, crop=True) #
233             b3_meta = b3.meta
234             b3.close()
235         with rio.open(l21list_20[2], driver = 'JP2OpenJPEG') as b4:
236             b4_data, out_transform = rio.mask.mask(b4, shapes, crop=True) #
237             b4_meta = b4.meta
238             b4.close()
239         with rio.open(l21list_20[3], driver = 'JP2OpenJPEG') as b5:
240             b5_data, out_transform = rio.mask.mask(b5, shapes, crop=True) #
241             b5_meta = b5.meta
242             b5.close()
243         with rio.open(l21list_20[4], driver = 'JP2OpenJPEG') as b6:
244             b6_data, out_transform = rio.mask.mask(b6, shapes, crop=True) #
245             b6_meta = b6.meta
246             b6.close()
247         with rio.open(l21list_20[5], driver = 'JP2OpenJPEG') as b7:
248             b7_data, out_transform = rio.mask.mask(b7, shapes, crop=True) #
249             b7_meta = b7.meta
250             b7.close()
251         with rio.open(outpath+"b8_mosaic_upscale.tif") as b8:
252             b8_data, out_transform = rio.mask.mask(b8, shapes, crop=True) #
253             b8_meta = b8.meta
254             b8.close()
255         with rio.open(l21list_20[8], driver = 'JP2OpenJPEG') as b8a:
256             b8a_data, out_transform = rio.mask.mask(b8a, shapes, crop=True) #
257             b8a_meta = b8a.meta
258             b8a.close()
259         with rio.open(l21list_20[6], driver = 'JP2OpenJPEG') as b11:
260             b11_data, out_transform = rio.mask.mask(b11, shapes, crop=True) #
261             b11_meta = b11.meta
262             b11.close()
263         with rio.open(l21list_20[7], driver = 'JP2OpenJPEG') as b12:
264             b12_data, out_transform = rio.mask.mask(b12, shapes, crop=True) #
265             b12_meta = b12.meta
266             out_meta.update({"driver": "GTiff",
267                              "height": b12_data.shape[1],
268                              "width": b12_data.shape[2],
269                              "transform": out_transform,
270                              "crs": rasterio.crs.CRS({'init': 'epsg:32652'})
271                              })
272             with rasterio.open(outpath+"masked_img_{}.tif".format(outname), "w", **out_meta) as dest:
273                 dest.write(b12_data)
274             b12.close()
```

그림 4.64 반사도파일을 불러옴

222-224: 필요없는 파일을 메모리로부터 제거

227-274: 20미터 공간해상도의 반사도파일을 불러옴

```
276         # scale factor 와 valid range를 적용해줍니다
277         for sv in range(len(blist)):
278             exec('{}[{} > 10000] = 10000'.format(blist[sv],blist[sv]))
279             exec('{}[{} < 0] = 0'.format(blist[sv],blist[sv]))
280             exec('{} = {} * 0.0001'.format(blist[sv],blist[sv])) # convert into 0-1
281
282         # Fmask 파일을 읽어옵니다
283         with rio.open(msk_in[0]) as fm:
284             fmask, out_transform = rio.mask.mask(fm, shapes, crop=True) #
285             fm.close()
286
287
288         cloudmask = deepcopy(fmask)
289         ## 삭제하지 않는 값은 수체와 육지입니다
290         cloudmask[cloudmask == 1] = 0 # water to land and other classes will be removed
291         ## 삭제하는 값은 구름, 구름 그림자 및 미관측지입니다
292         cloudmask[cloudmask == 2] = 1 # water to land and other classes will be removed
293         cloudmask[cloudmask == 4] = 1 # water to land and other classes will be removed
294         cloudmask[cloudmask == 255] = 1 # water to land and other classes will be removed
295
296         # 0 => clear land pixel
297         # 1 => clear water pixel
298         # 2 => cloud shadow
299         # 4 => cloud
300         # 255 => no observation
301
302         # 불러온 반사도값들을 fmask를 통해서 마스킹해줍니다
303         for m in range(len(blist)):
304             e = '{}[cloudmask==1] = np.nan'.format(blist[m])
305             exec(e)
306
307         # 분광지수를 계산합니다
308         NDVI = ((b8a_data - b4_data) / (b8a_data + b4_data))
309         NDII7 = ((b8a_data - b12_data) / (b8a_data + b12_data))
310         NDWI = ((b3_data - b8a_data) / (b3_data + b8a_data))
311         NDBI = ((b8a_data - b11_data) / (b8a_data + b11_data))
312         NDSI = ((b11_data - b8a_data) / (b11_data + b8a_data))
313
314         # 반사도값 및 분광지수값을 저장하기 위해 빈 행렬을 만듭니다
315         vali_loc = np.empty((len(vali_coordinates),2,))
316         vali_loc.fill(np.nan)
```

그림 4.65 불러온 반사도값을 처리하고 Fmask를 불러와서 구름을 마스킹후 분광지수를 계산

277-280: 반사도파일의 불필요한 범위를 제거하고 0-1의 범위로 변환

283-305: 계산된 Fmask 파일을 불러와서 반사도값들을 마스킹

308-312: 분광지수 계산

315-316: 검증을 위해 반사도값들을 저장할 빈 행렬을 만듦

```
318         # 이미지를 사용해 픽셀위치를 찾습니다
319         with rio.open(outpath+"masked_img_{}.tif".format(outname)) as dataset:
320             # validation 참조자료의 위치를 얻어냅니다
321             for i, (lon, lat) in enumerate(vali_coordinates):
322                 px, py = dataset.index(lon, lat)
323                 vali_loc[i][0] = px
324                 vali_loc[i][1] = py
325                 # print('validation sample Pixel Y, X coords: {}, {}'.format(py, px))
326             dataset.close()
327 
328         vali_table = np.empty((len(vali_loc), num_total_images,))
329         vali_table.fill(np.nan)
330         masked_size = b12_data.shape
331 
332         # 검증용 테이블의 값을 추출합니다
333         for i in range(len(vali_loc)):
334             # print((i),(vali_loc[i][0]),(vali_loc[i][1]))  #Lon: [0] Lat: [1]
335             if 0 < int(vali_loc[i][1]) <= masked_size[2] and 0<int(vali_loc[i][0]) <= masked_size[1]:
336                 vali_table[i][0] = b2_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
337                 vali_table[i][1] = b3_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
338                 vali_table[i][2] = b4_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
339                 vali_table[i][3] = b5_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
340                 vali_table[i][4] = b6_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
341                 vali_table[i][5] = b7_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
342                 vali_table[i][6] = b8_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
343                 vali_table[i][7] = b8a_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
344                 vali_table[i][8] = b11_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
345                 vali_table[i][9] = b12_data[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
346                 vali_table[i][10] = NDVI[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
347                 vali_table[i][11] = NDII7[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
348                 vali_table[i][12] = NDWI[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
349                 vali_table[i][13] = NDBI[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
350                 vali_table[i][14] = NDSI[0,int(vali_loc[i][0]),int(vali_loc[i][1])]
351             else:
352                 vali_table[i][0] = np.nan
353                 vali_table[i][1] = np.nan
354                 vali_table[i][2] = np.nan
355                 vali_table[i][3] = np.nan
356                 vali_table[i][4] = np.nan
357                 vali_table[i][5] = np.nan
358                 vali_table[i][6] = np.nan
359                 vali_table[i][7] = np.nan
360                 vali_table[i][8] = np.nan
361                 vali_table[i][9] = np.nan
362                 vali_table[i][10] = np.nan
363                 vali_table[i][11] = np.nan
364                 vali_table[i][12] = np.nan
365                 vali_table[i][13] = np.nan
366                 vali_table[i][14] = np.nan
```

그림 4.66 픽셀 위치를 찾고 픽셀 위치를 이용해서 반사도값을 추출해서 검증용 테이블에 저장

319-366: 픽셀 위치를 찾고 픽셀 위치를 이용해서 반사도값을 추출해서 검증용 테이블에 저장

```
368         # 값이 없는곳은 nan이 되고 nan 값들은 삭제될 것입니다
369         vali_table[vali_table==0] = np.nan
370         nanloc = np.isnan(vali_table)
371         nanlocsum = np.sum(nanloc,axis=1)
372
373         vali_table = vali_table[nanlocsum <= 0]
374         vali_table = np.asarray(vali_table)
375         Vali_class[nanlocsum<=0]
376
377         Vali_table = Vali_table[1:,:]
378         ref_vali = Vali_class[nanlocsum<=0]
379         ref_vali.to_csv(outpath+'Vali_reference_{}.csv'.format(outname))
380
381         ref_class = Vali_class.Class[nanlocsum <=0] +1 # +1 to refernce values
382         ref_class = np.asarray(ref_class)
383         ref_class = np.reshape(ref_class, (len(ref_class), 1)) # columnized
384         Vali_class = pd.DataFrame(Vali_class)
385
386         # 위성영상 타일 수 만큼 반복하며 검증자료를 쌓습니다
387         Vali_table = np.concatenate((Vali_table, np.concatenate((ref_class,vali_table),axis=1)))
```

그림 4.67 저장한 반사도값 중 사용할수 있는 값만 걸러냄

369-386: 저장된 반사도값 중 사용할 수 있는 값만 걸러내고 필요한 검증용 파일을 저장할 경로(outpath)에 저장

387: ii를 통해 반복하며 얻어진 검증 위치별 반사도값을 Vali_table에 쌓는다

```
389         # 예측 및 평가
390         yPred = clf.predict(Vali_table[:,1:])
391         errors = abs(yPred - Vali_table[:,0])
392         a = np.sum(len(errors[errors==0]))
393         accuracy = a/len(errors) * 100
394         print('Validation Accuracy of {}:'.format(outdate), round(accuracy, 2), '%')
395
396         # 혼동행렬을 통한 평가 및 혼동행렬 기록
397         CM = confusion_matrix(Vali_table[:,0], yPred)
398         plot_confusion_matrix(CM, classnames, title='Confusion Matrix of RF ({})'.format(outdate))
399         plt.savefig(outpath+'Cmatrix_fmask_{}png'.format(outdate))
400         plt.close()
401
402         try:
403             CMarr_cloud[0, id,:,:] = CM
404         except:
405             CMarr_cloud[0, id,:,:] = np.nan
```

그림 4.68 검증용 반사도값을 사용해서 예측한 뒤 혼동행렬을 통해 평가하고 혼동행렬을 저장 (아래 그림)

390-394: 검증샘플에서 예측 및 예측정확도 분석

397-405: 혼동행렬을 계산한 뒤 저장함

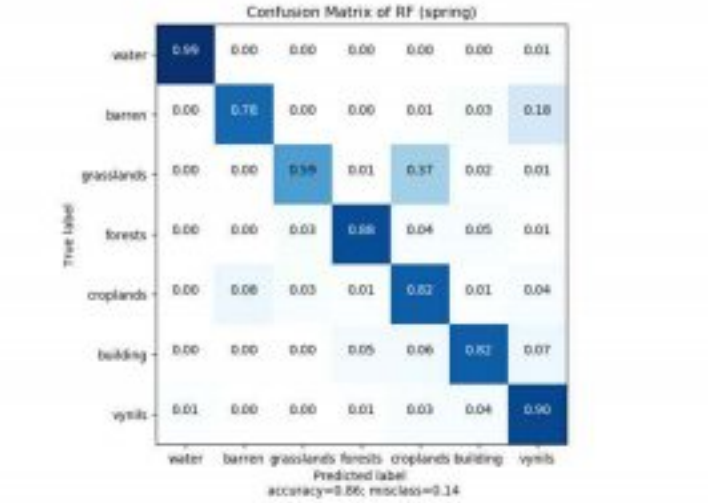


그림 4.69 검증된 반사도값을 사용해서 예측한 뒤 생산한 혼동행렬

```
# 지도 생성
b2_data = b2_data[0]
b3_data = b3_data[0]
b4_data = b4_data[0]
b5_data = b5_data[0]
b6_data = b6_data[0]
b7_data = b7_data[0]
b8_data = b8_data[0]
b8a_data = b8a_data[0]
b11_data = b11_data[0]
b12_data = b12_data[0]
ndvi_data = NDVI[0]
ndi17_data = NDI17[0]
ndwi_data = NDWI[0]
ndbi_data = NDBI[0]
ndsi_data = NDSI[0]

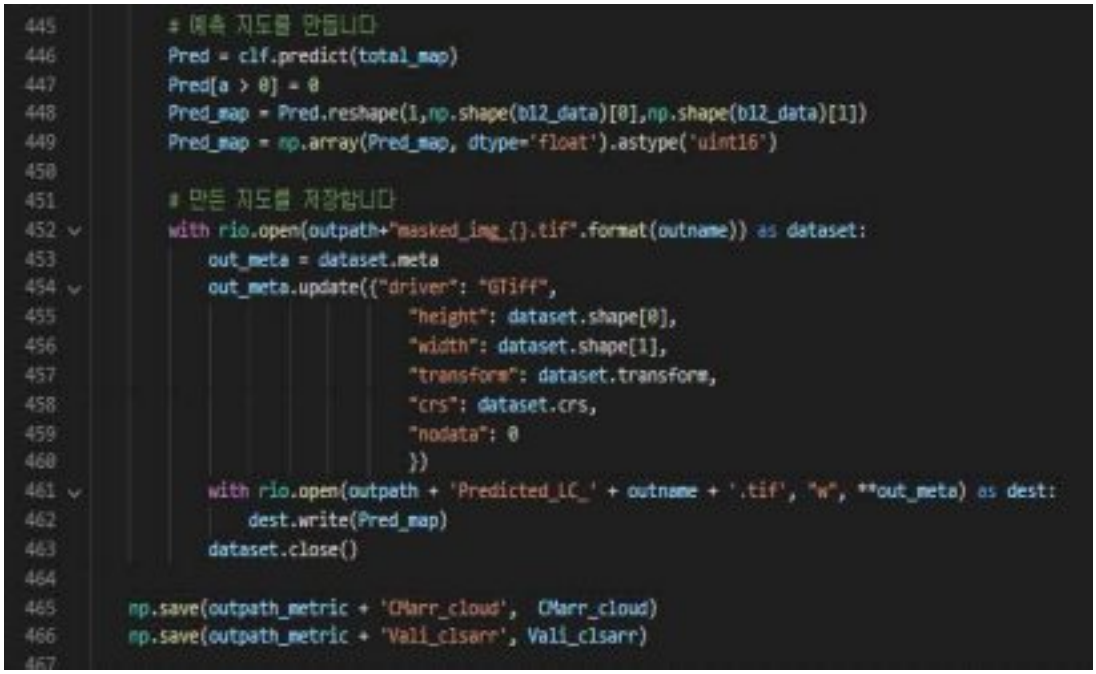
b2_1d = b2_data.reshape((np.shape(b2_data)[0]*np.shape(b2_data)[1]), 1)
b3_1d = b3_data.reshape((np.shape(b3_data)[0]*np.shape(b3_data)[1]), 1)
b4_1d = b4_data.reshape((np.shape(b4_data)[0]*np.shape(b4_data)[1]), 1)
b5_1d = b5_data.reshape((np.shape(b5_data)[0]*np.shape(b5_data)[1]), 1)
b6_1d = b6_data.reshape((np.shape(b6_data)[0]*np.shape(b6_data)[1]), 1)
b7_1d = b7_data.reshape((np.shape(b7_data)[0]*np.shape(b7_data)[1]), 1)
b8_1d = b8_data.reshape((np.shape(b8_data)[0]*np.shape(b8_data)[1]), 1)
b8a_1d = b8a_data.reshape((np.shape(b8a_data)[0]*np.shape(b8a_data)[1]), 1)
b11_1d = b11_data.reshape((np.shape(b11_data)[0]*np.shape(b11_data)[1]), 1)
b12_1d = b12_data.reshape((np.shape(b12_data)[0]*np.shape(b12_data)[1]), 1)
ndvi_1d = ndvi_data.reshape((np.shape(b12_data)[0]*np.shape(b12_data)[1]), 1)
ndi17_1d = ndi17_data.reshape((np.shape(b12_data)[0]*np.shape(b12_data)[1]), 1)
ndwi_1d = ndwi_data.reshape((np.shape(b12_data)[0]*np.shape(b12_data)[1]), 1)
ndbi_1d = ndbi_data.reshape((np.shape(b12_data)[0]*np.shape(b12_data)[1]), 1)
ndsi_1d = ndsi_data.reshape((np.shape(b12_data)[0]*np.shape(b12_data)[1]), 1)

total_map = np.concatenate((b2_1d,b3_1d,b4_1d,b5_1d,b6_1d,b7_1d,b8_1d,b8a_1d,b11_1d,b12_1d, ndvi_1d, ndi17_1d, ndwi_1d, ndbi_1d, ndsi_1d),axis=1)
a = np.sum(total_map==0,axis=1)
b = np.isnan(total_map)
total_map[b] =0
```

그림 4.70 수변환경 분류지도 생산 준비

407-440: 수변환경 분류 지도를 생산하기 위해 반사도값을 한 변수(total_map)에 쌓는다

441-443: 이때 쌓인 값중 이상치를 제거하기위한 기준을 만든다



```
        # 예측 지도를 만듭니다
        Pred = clf.predict(total_map)
        Pred[a > 0] = 0
        Pred_map = Pred.reshape(1,np.shape(b12_data)[0],np.shape(b12_data)[1])
        Pred_map = np.array(Pred_map, dtype='float').astype('uint16')

        # 만든 지도를 저장합니다
        with rio.open(outpath+"masked_img_{}.tif".format(outname)) as dataset:
            out_meta = dataset.meta
            out_meta.update({"driver": "GTiff",
                             "height": dataset.shape[0],
                             "width": dataset.shape[1],
                             "transform": dataset.transform,
                             "crs": dataset.crs,
                             "nodata": 0
                             })
            with rio.open(outpath + 'Predicted_LC_' + outname + '.tif', "w", **out_meta) as dest:
                dest.write(Pred_map)
            dataset.close()

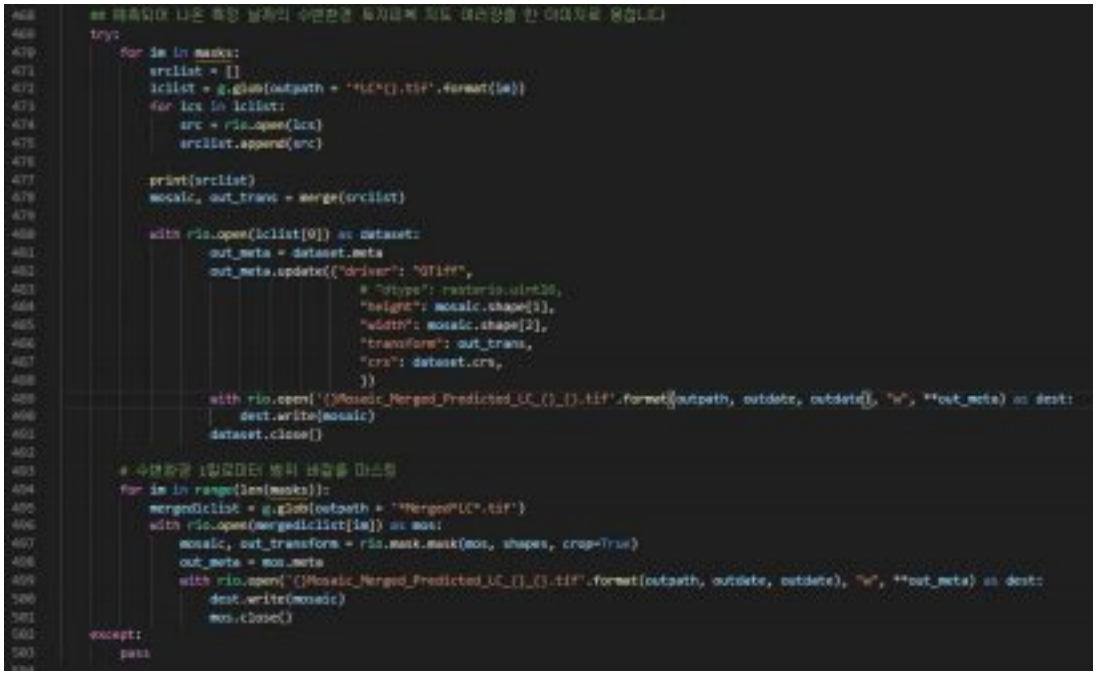
    np.save(outpath_metric + 'CMarr_cloud',  CMarr_cloud)
    np.save(outpath_metric + 'Vali_clsarr', Vali_clsarr)
```

그림 4.71 예측지도를 생산하고 지도를 저장, 혼동행렬 및 검증용 행렬을 저장

445-449: 예측지도를 생산, 이때 이상치를 제거하고 지도형태로 변환함 데이터 타입은 int16으로 정함

452-463: 만들어진 지도를 저장함

465-466: 혼동행렬과 검증용 행렬을 저장함 (파이썬이 실행 도중에 멈춘 경우 다시 이어서 분석용 자료를 저장할 용도)



```
## 예측입력 나온 특정 날짜의 수변환경 특징파일 지도 데이터셋을 만 다음지로 봉합니다
try:
    for im in masks:
        srclist = []
        lclist = g.glob(outpath + '*LC*{}.tif'.format(im))
        for lcs in lclist:
            src = rio.open(lcs)
            srclist.append(src)

        print(srclist)
        mosaic, out_trans = merge(srclist)

        with rio.open(lclist[0]) as dataset:
                out_meta = dataset.meta
                out_meta.update({"driver": "GTiff",
                                 "dtype": rasterio.uint16,
                                 "height": mosaic.shape[1],
                                 "width": mosaic.shape[2],
                                 "transform": out_trans,
                                 "crs": dataset.crs,
                                 })
                with rio.open('{}Mosaic_Merged_Predicted_LC_{}_{}.tif'.format(outpath, outdate, outdate), "w", **out_meta) as dest:
                    dest.write(mosaic)
                dataset.close()

    # 수변환경 1킬로미터 범위 내외를 마스킹
    for im in range(len(masks)):
        mergedlclist = g.glob(outpath + '*MergedPLC*.tif')
        with rio.open(mergedlclist[im]) as mos:
            mosaic, out_transform = rio.mask.mask(mos, shapes, crop=True)
            out_meta = mos.meta
            with rio.open('{}Mosaic_Merged_Predicted_LC_{}_{}.tif'.format(outpath, outdate, outdate), "w", **out_meta) as dest:
                dest.write(mosaic)
                mos.close()
except:
    pass
```

그림 4.72 수변환경 분류지도를 모자이크하고 수변환경으로 정의된 1km 이외의 범위를 마스킹 (아래 그림)



그림 4.73 수변환경 분류지도를 모자이크하고 수변환경 이외의 범위를 마스킹한 지도

469-491: 만들어진 개별 타일의 수변환경 분류지도를 불러와서 모자이크함
494-503: 모자이크된 파일을 다시 불러와 수변환경으로 정의한 1km 밖의 값들을 마스킹함

```
505  ## 시계열 정확도 평가
506  accuracy = [];
507  for i in range(L2A_uniquedates):
508      accuracy.append(np.trace(CMarr_cloud[2,i,:,:]) / float(np.sum(CMarr_cloud[2,i,:,:])))
509
510  plt.figure(figsize=(8,6));
511  plt.plot(accuracy, 'go');
512  plt.ylim(0,1);
513  plt.ylabel('Overall Accurcay')
514  plt.xlabel('Date')
515  plt.legend('mean accuracy: {}'.format(round(np.nanmean(accuracy),2)))
516  plt.savefig(outpath_metric + 'time-series-accracyplot.png', dpi=326)
```

그림 4.74 시계열 전체정확도(OA) 평가 (아래 그림)

506-516: 분석을 위해 저장한 CMarr_cloud 파일을 이용해 시계열 전체정확도 평가를 진행함

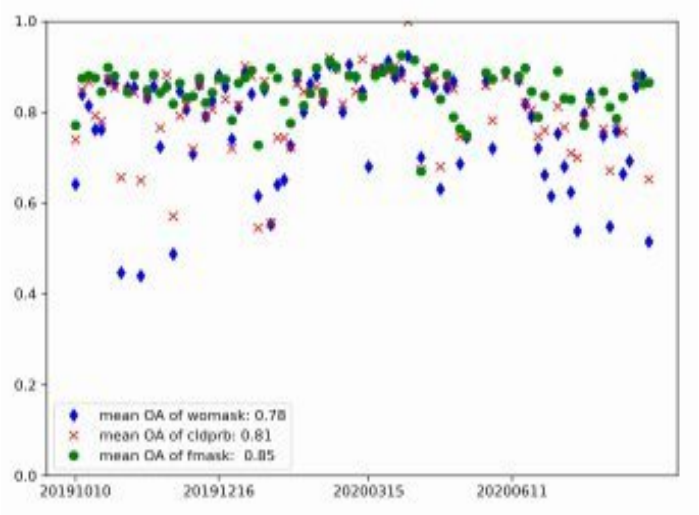


그림 4.75 본 연구에서 제시한 알고리즘의 구름 마스킹 방법별 시계열 성능 평가 (여기서 파란 다이아몬드와 뽈간 x는 제외됨)

```
519  ## 모래톱 증감 파악
520  from scipy.stats import mode
521  import glob as g
522  import rasterio as rio
523  import rasterio.mask
524  import numpy as np
525  import fiona
526  import pandas as pd
527
528  outpath = '/share/project/K-water_2020/part2/output7_mode/'
529
530  # 계절_연도 리스트형 변수에 계절별 모래톱 증감에 필요한 시간을 연구기간의 연 월을 월단위로 yyyymm 순으로,
531  # tiles 리스트형 변수에 연구의 범위에 해당하는 Sentinel-2 타일 이름을 채워줍니다
532  # seasons 리스트형 변수에 534-538의 계절_연도 변수를 할당합니다
533  # seasons_name 리스트형 변수에 seasons 변수의 이름을 할당합니다
534
535  autumn_2019 = ['201910','201911',]
536  winter_2020 = ['201912','202001','202002']
537  spring_2020 = ['202003','202004','202005']
538  summer_2020 = ['202006','202007','202008']
539  autumn_2020 = ['202009','202010']
540
541  tiles = ['T52SDD','T52SDE','T52SDF','T52SED','T52SEE','T52SEF',]
542  seasons = [autumn_2019,winter_2020,spring_2020,summer_2020,autumn_2020]
543  seasons_name = ['autumn_2019','winter_2020','spring_2020','summer_2020','autumn_2020']
544
545  ## 낙동강 버퍼 파일을 불러옵니다 ----------------------------------------------
546  river_buffer_file = "/share/project/K-water_2020/part2/data/buffer/renakdong.shp"
547  with fiona.open(river_buffer_file, "r") as shapefile:
548      shapes = [feature["geometry"] for feature in shapefile]
```

그림 4.76 나지(모래톱) 증감 파악을 위한 준비

519-526: 모래톱 증감 파악에 필요한 파이썬 라이브러리 불러오기

528-548: 모래톱 증감 파악에 필요한 사전 변수들 설정

```
# 타일 인수만큼 반복
for it in tiles:
    # 계절 인수만큼 반복
    for isl in range(len(seasons)):
        # 계절별 영상인 파일을 찾기위한 빈 리스트 변수를 만들어줍니다
        container = []
        for ise in range(len(seasons[isl])):
            # 계절별로 입력된 녹물수 만큼
            LClist = g.glob(f'/share/project/K-water_2020/part2/output6_year1y/*/Predicted_LC*{seasons[isl][ise]}*_{it}_Fmask.tif')
            LClist.sort()
            container.append(LClist)

        # 리스트 변수 container를 정리합니다
        container = sum(container, [])
        print(container)
        # 날짜별 수변환경 지도를 불러옵니다. 이때 마스크를 통해서 수변환경 부분만 잘라서 불러옵니다
        for im in range(len(container)):
            with rio.open(container[im]) as mm:
                m, out_transform = rio.mask.mask(mm, shapes, crop=True)
                # 필요없는 부분을 nan으로 처리하기 위해 float로 변환
                m = m.astype(float)
                # 0 인것 nan으로 변경합니다
                m[m==0]=np.nan
                # 계절별 수변환경지도를 할당하기위한 빈 행렬을 만듭니다
                if im == 0:
                    modearr = np.zeros((len(container),m.shape[1],m.shape[2]))
            # 수변환경지도를 할당합니다
            modearr[im,:,:] = m

        # 수변환경지도를 (계절별 영상 갯수, 영상 가로 픽셀수 * 영상 세로 픽셀 수)의 2d 형태로 변환합니다
        modearr = np.reshape(modearr, (len(container),m.shape[1]*m.shape[2]))
        # 각 계절별 최빈값을 입력할 빈 행렬을 만듭니다
        mode_img = np.zeros((modearr.shape[1],1))
        for ip in range(modearr.shape[1]):
            # print(ip) # 진척 확인
            mode_img[ip] = mode(modearr[:,ip], nan_policy = 'omit').mode[0].astype(int)
        # 영상을 다시 이미지 형태로 변환합니다
        img_mode = np.reshape(mode_img, (1, m.shape[1], m.shape[2]))

        # 메타데이터를 저장합니다
        out_meta = mm.meta
        # 특정 계절의 특정 타일의 수변환경 최빈값 이미지를 저장합니다
        with rio.open(f'{outpath}mode_LC_{it}_{seasons_name[isl]}.tif', 'w', **out_meta) as dest:
            dest.write(img_mode.astype('uint16'))
            dest.close()
        print('save done')
```

그림 4.77 나지 모래톱 증감 파악을 위한 최빈수 지도 생산 과정(아래 그림)

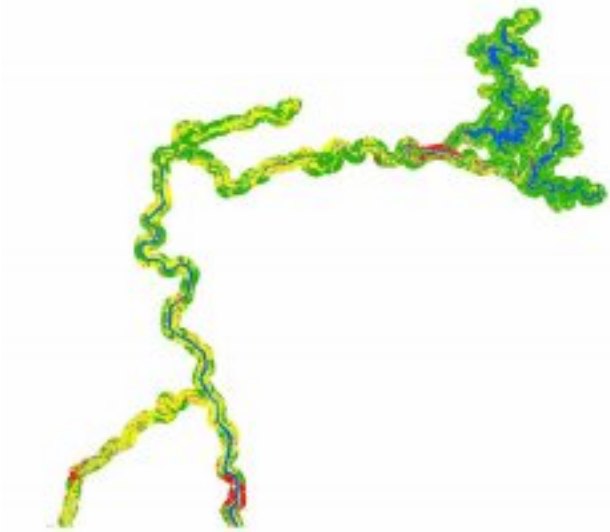


그림 4.78 타일별 최빈수 지도 (T52SDF)

```
599  ## 계절별로 생산된 타일별 최빈값 이미지를 계절별 1장의 이미지로 모자이크 (mosaic)
600  from rasterio.merge import merge
601  outpath = '/share/project/K-water_2020/part2/output7_mode/merged/'
602
603  # 반복
604  for i in range(len(seasons)):
605      # 계절별 타일 이미지들을 모두 리스팅
606      tilelist = g.glob(f'/share/project/K-water_2020/part2/output7_mode/*{seasons_name[1]}.tif')
607
608      # 이미지들을 담을 컨테이너
609      srclist = []
610
611      # 반복을 통해 이미지를 컨테이너에 할당
612      for lcs in tilelist:
613          src = rio.open(lcs)
614          srclist.append(src)
615
616      # 이미지 확인
617      print(srclist)
618
619      # 모자이크
620      mosaic, out_trans = merge(srclist)
621
622      # 모자이크된 계절별 수변환경 최빈수 지도를 저장
623      with rio.open(tilelist[0]) as dataset:
624              out_meta = dataset.meta
625              out_meta.update({"driver": "GTiff",
626                               "height": mosaic.shape[1],
627                               "width": mosaic.shape[2],
628                               "transform": out_trans,
629                               "crs": dataset.crs,
630                               })
631              with rio.open(f'{outpath}Merged_mode_LC_{seasons_name[1]}.tif', "w", **out_meta) as dest:
632                  dest.write(mosaic)
633              dataset.close()
```

그림 4.79 계절별 타일 최빈값 지도를 모자이크(아래 그림)

599-501: 필요한 함수를 rasterio로 부터 불러오고, 지도가 저장될 위치를 설정합니다

602-633: 계절별 타일 이미지를 불러오고 모자이크하여 지도를 저장합니다



그림 4.80 모자이크된 수변환경 최빈수 지도

```
635  ## 나지 면적 계산
636  # 컨테이너
637  areaofbarren = []
638  for i in range(len(seasons_name)):
639      # 계절별 이미지를 리스팅합니다
640      imlist = g.glob(f'/share/project/K-water_2020/part2/output7_mode/merged/*{seasons_name[i]}.tif')
641      imlist.sort()
642
643      # 이미지를 읽습니다
644      with rio.open(imlist[0]) as dataset:
645          image = dataset.read()
646      # 이미지의 2번 클래스 (나지)에 해당하는 격자 수를 추출한 뒤 * 20 * 20을 통해 면적을 계산합니다
647      print(f'area of barren in {seasons_name[i]} = {image[image==2].shape[0] * 20 * 20} m2')
648      areaofbarren.append(image[image==2].shape[0] * 20 * 20)
```

그림 4.81 모자이크된 지도로부터 나지 면적 계산

635-648: 계절별 타일 이미지를 불러오고 모자이크하여 지도를 저장합니다

```
650  ## 수위 파악
651  # 수위 파일들을 리스팅합니다
652  levellist = g.glob('/share/project/K-water_2020/part2/data/level/*.xls')
653
654  # 반복
655  for il in range(len(levellist)):
656      # WAMIS로 부터 취득한 댐별 수위자료를 불러옵니다
657      level = pd.read_excel(levellist[il], skiprows=3, header=None)
658      # 첫번째 반복에서 빈 컨테이너를 만듭니다
659      if il == 0:
660          levels = np.empty((len(levellist), len(level.iloc[:,0])))
661      # 컨테이너에 댐별 수위자료를 할당합니다
662      levels[il,:] = level.iloc[:,1]
663  # 할당된 수위자료를 평균합니다
664  meanlevel_nakdongriver = levels.mean(axis=0)
665  # 할당된 수위자료를 pandas DataFrame 형태로 변환합니다
666  levels2 = pd.DataFrame(levels, columns= level.iloc[:,0])
667  # 변환된 수위자료를 저장합니다
668  levels2.to_csv(outpath + 'table_dam_level.csv')
```

그림 4.82 낙동강 평균 댐 수위 파악

650-668: 연구기간동안의 낙동강 수위파악을 위해서 연구기간동안의 낙동강 댐별 평균수위자료를 불러와서 평균한 뒤 저장합니다

```
671   ## 댐 평균수위와 나지 면적의 시계열 분석
672   # 댐 평균수위와 나지 면적에 사용할 각각의 x축 길이를 정합니다
673   t = np.arange(0, len(level.iloc[:,1]))
674   t2 = np.ceil(np.linspace(0, len(level.iloc[:,1]),5))
675
676   # 빈 이미지를 만듭니다
677   fig, ax1 = plt.subplots()
678
679   # 댐 평균수위 플롯에 대한 이미지 특성을 설정합니다
680   color = 'tab:blue'
681   ax1.set_xlabel('time')
682   ax1.set_ylabel('watel level', color=color)
683   ax1.plot(t, meanlevel_nakdongriver, color=color)
684   ax1.tick_params(axis='y', labelcolor=color)
685
686   # 두번째 그림이 첫번째 그림과 같은 x 축을 공유하도록 하게 합니다
687   ax2 = ax1.twinx()
688
689   # 나지 면적 플롯에 대한 이미지 특성을 설정합니다
690   color = 'tab:gray'
691   ax2.set_ylabel('area of barren', color=color)
692   ax2.plot(t2, areaofbarren, color=color)
693   ax2.tick_params(axis='y', labelcolor=color)
694
695   # x축의 레이블 및 이미지 제목을 설정합니다
696   plt.xticks(t2,seasons_name)
697   plt.title('Time-series between water level and area of barren')
698
699   # 이미지를 창에 꽉 차게 하여 저장합니다
700   fig.tight_layout()
701   plt.savefig(f'{outpath}time-seires.png', dpi=326)
```

그림 4.83 낙동강의 댐 평균수위와 나지 면적간의 시계열 이미지 생산 (아래 그림)

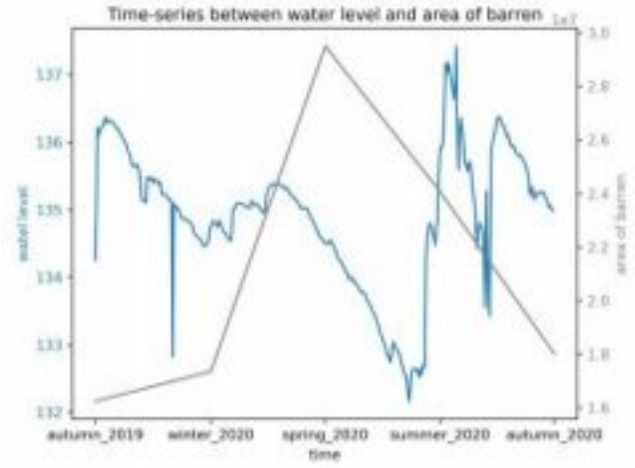


그림 4.84 낙동강의 댐 평균수위와 나지 면적간의 시계열 이미지

```
## 초분수 이미지를 통해 수변환경 지도 변화탐지 알고리즘 구축
# 저장될 경로 설정, 빈 컨테이너 생성
outpath = '/share/project/K-water_2020/part2/output7_mode/barren/'
areaofbarren = []

# 반복
for i in range(len(seasons_name)-1):
    # 변화탐지에 사용될 두 수변환경 지도를 리스팅합니다
    imlist1 = g.glob(f'/share/project/K-water_2020/part2/output7_mode/merged/*{seasons_name[i]}.tif')
    imlist2 = g.glob(f'/share/project/K-water_2020/part2/output7_mode/merged/*{seasons_name[i+1]}.tif')
    imlist1.sort()
    imlist2.sort()

    # 두 지도를 불러옵니다
    with rio.open(imlist1[0]) as dataset:
        image = dataset.read()
    with rio.open(imlist2[0]) as dataset2:
        image2 = dataset2.read()
    # 변화탐지를 위한 빈 컨테이너
    changedetection = []
    # 이미지를 1d 형태로 변환한 뒤, 문자열(string) 형태로 변환합니다
    cd = image[0].flatten().astype('str').tolist()
    cd2 = image2[0].flatten().astype('str').tolist()

    # 두 이미지를 연결(concatenate)합니다
    cc = cd+cd2
    # 반복 횟수 설정을 위한 원래 수변환경 지도의 크기
    imsize = image.shape[1] * image.shape[2]
    # 반복을 통해 빈 컨테이너에 격자별로 연결된 이미지를 채웁니다
    for ii in range(imsize):
        changedetection.append(cd[ii] + cd2[ii])
    # 반복을 통해 변화탐지 격자들을 숫자형태로 변환합니다
    cdone = [int(x) for x in changedetection]
    # 이미지 형태로 변환합니다
    cdone2 = np.array(cdone).reshape((1, image.shape[1], image.shape[2]))

    # 수변환경 변화탐지 지도를 저장합니다
    out_meta = dataset.meta
    with rio.open(f'{outpath}Changedetection_mode_if_{seasons_name[i]}_to_{seasons_name[i+1]}.tif', 'w', **out_meta) as dest:
        dest.write(cdone2.astype('uint16'))
    dataset.close()
```

그림 4.85 수변환경 변화탐지 알고리즘 구축 (아래 그림)

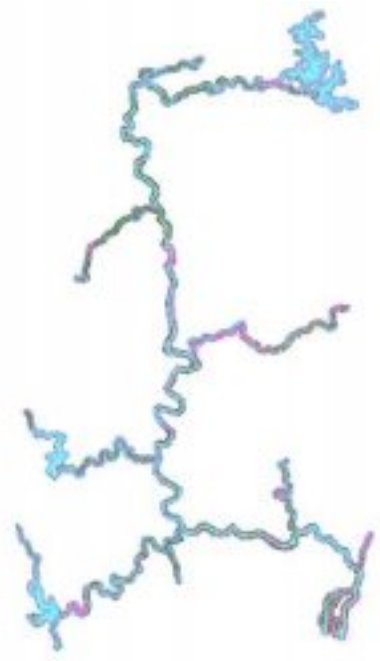


그림 4.86 수변환경 변화탐지 알고리즘으로부터 생산된 지도

제 5 장 미계측 유역 수위추정 기법 개발

5.1 서 론

기초수문자료의 확보는 일차적으로 지상관측자료인 기상관측소나 수위관측소 자료를 바탕으로 하여야 하나, 북한지역의 경우 이 같은 자료가 매우 제한적이다. 한강권역의 북한강과 임진강은 그림 5.1과 같이 상류지역이 북한에 속한 대표적인 남북 공유하천으로 북한강 상류에 임남댐, 임진강 상류에 황강댐 등을 운영 중에 있다.



그림 5.1 북한강 및 임진강 유역 댐 현황

임진강은 강원도 법동군 두류산에서 발원하여 파주시 탄현면 부근에서 한강에 합류되는 강으로, 표 5.1과 같이 임진강의 대부분이 북한에 위치하여 상류 황강댐 등으로 인해 남한에서는 하천수량의 감소 및 댐 무단 방류로 인한 피해 등 북한댐에 의해 영향을 받고 있다.

표 5.1. 임진강 유역 현황

구 분	전 체	남 한	북 한
유역면적 (㎢)	8,118	3,009 (37.1 %)	5,109 (62.9 %)
유로연장 (㎞)	254.6	92.0	162.6

이러한 불확실한 하천관리 형태를 극복하기 위해 정부에서는 2000년 8월 남북장관급 회담에서 임진강 수방사업을 추진하기로 합의하여 2004년 5월 북한에 조사용 기자재를 제공하고 북한 기상자료를 일부 인수하였고, 2007년 2월에는 북한에 포함된 임진강 유역에 수문관측소 설치 및 묘목 제공 등을 골자로 하는 임진강 수방사업을 계획하였다. 또한 임진강유역의 이상강우로 인한 하류지역 홍수피해 예방, 북한 황강댐 무단방류로 인한 피해발생에 대비하기 위하여 경기도 연천시에 군남홍수조절지를 건설하여 운영중이다. 그러나 이러한 노력에도 불구하고 접경지역의 수자원 관리에 대한 불확실성은 개선되지 않고 있다. 2001년 이후 북한의 예고 없는 댐 방류 등으로 인한 하류지역의 급작스러운 수위 변화로 약 5억 4천여만원의 재산피해 및 6명의 인명피해 발생하고 있고, 특히 2009년 9월, 임진강 상류 황강댐의 물을 방류하여 남한 임진강에서 6명의 인명피해 및 143백만원의 재산피해가 발생하기도 하였다. 이를 개선하기 위해서는 북한의 기상상황 및 댐의 방류징후를 파악하여야 하는데, 현실적으로 북한상황을 감시할 수 없으므로 군, 정보기관 등 국가 일부기관의 협조를 통한 간접적인 방법을 통해 북한상황을 감시하고 대비하고 있다.

한편, 통일시대를 대비하여 북한지역의 수자원 개발계획을 수립하기 위해서는 북한지역에 대한 수문조사(水文調査)가 필수적이다. 여기에는 단기적으로 공유하천사업, 접경유역 재해예측시스템 구축, 중장기적으로는 수도건설, 하천정비, 북한수자원 장기종합개발 계획수립 등이 포함된다.

이와 같이 이와 같이 접경유역의 홍수관리 및 통일대비 북한수자원 계획수립을 위한 기초수문자료의 확보가 절실히 요구되고 있으며, 레이더와 위성영상 등의 활용을 통한 과학적 예측기반을 구축해야 하는 필요성이 지속적으로 제기되고 있다.

따라서, 이번 장에서는 위성영상을 활용한 미계측지역인 임진강 상류 황강댐의 수위추정을 목적으로 계측자료가 존재하는 남한지역 댐(대청댐)을 기준으로 수위를 추정해봄으로써, 황강댐과 같은 미계측지역으로의 확대 적용성을 검토하고자 한다. 이를 위해 육지와 수계를 구분하고, 수계선을 추출 후 고도정보가 포함된 수치표고모델과 중첩하여 수계선의 고도(수위)를 산출하는 방식을 제안하고 북한지역의 수위관측의 적용성을 모색하고자 한다.

5.2 연구내용 및 방법

5.2.1 대상지역

위성을 활용한 수위추정 방안 적용성을 검토하기 위하여 대청댐 갈수기부터 홍수기까지 댐 운영 시기별 특성과 수위를 고려하여 2019년 4월~11월 중에서 2일을 선택하여 연구를 수행하였다.

대청댐은 대청댐은 충북 청원군, 보은군과 대전시 동구 대덕구에 인접하여 소백산맥의 주봉인 덕유산으로부터 발원되어 중부 내륙에서 서해로 흐르는 유로연장 401km에 유역면적이 전국토지면적이 전국토지면적의 약 10%에 해당하는 9,886km^2 인 금강 상류부에 위치한다. 금강 하구로부터 상류 약 150km지점에 위치한 대청댐은 1980년 12월에 준공되어 한국수자원공사에서 관리・운영중에 있다. 주요시설로는 저수지 길이 86km로 국내 최대 최장의 호수로 저수용량 14억 9천만m^{3}을 갖는 복합형 본댐과 조정지댐이 있다. 본댐 주변에는 저수지내의 물이 다른 지역으로 넘치지 못하도록 해주는 3개의 부댐이 있으며, 대전과 청주지역으로 용수를 공급하기 위한 도수로와 시설용량 9만 kW의 수력발전소가 있다.

댐의 완공으로 댐 하류지역의 홍수피해와 하류연안 농경지의 농업용수공급 및 급격히 증가하고

있는 유역내 인접도시의 생활용수 및 공업용수를 공급하고 있다. 유역 대부분이 산지로 이루어져 있고, 댐 지점으로부터 하류 약 6km에 주거지가 밀집되어 있으며, 계곡을 따라 소규모의 농경지가 형성되어 있다.

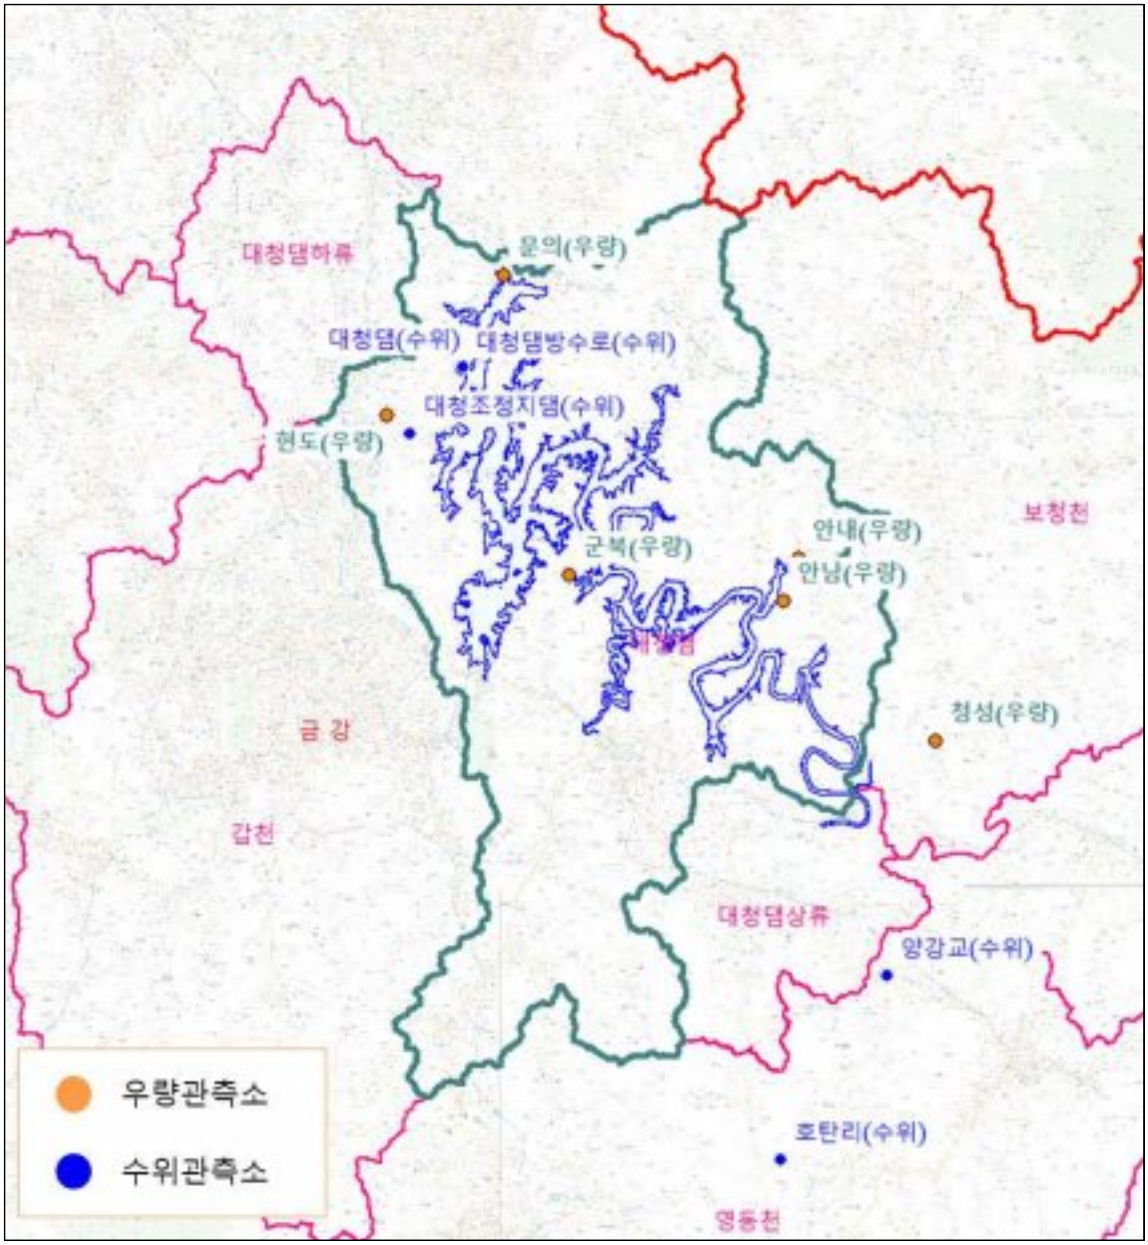


그림 5.2 대청댐 유역 및 우량, 수위 관측소 위치

대청댐(유효저수용량 약 7.9억m^3)을 수위추정 대상 댐으로 선정한 것은 최종적인 수위추정의 대상이 되는 북한 황강댐의 유효저수용량 규모인 3억m^3 이상인 남한 댐을 대상으로 우선적으로 선별하였고, 그 중 2019년 1월부터 2020년도 9월까지 기상조건(구름 등)을 고려했을 때, 각 시기별로 활용가능한 위성영상(SAR 40장, 광학 26장)이 대청댐이 가장 많아 홍수기, 갈수기 등 주요 시점별 분석이 가능한 장점이 있었다. 또한 연구원에서 지리적으로 가장 가깝게 위치하는 대규모 댐이라 수위추정 판독지점 현장조사 등의 장점이 있었으므로 분석대상 댐으로 선정하였다.

5.2.2 자료수집

가. 위성자료

북한 황강댐의 주기적인 수위추정이 본 연구의 최종목표임을 고려할 때, 무료위성영상의 정기적인 획득이 가장 중요하다. 현재 무료로 수집하여 활용가능은 위성영상은 AQUA, TERRA, Suomi-NPP 등 대부분 지구관측위성으로서 다양한 관측채널을 보유하고 있어, 대기, 기상, 환경, 수문 등 다양한 정보를 산출하고 있다. 하지만 이들의 공간해상도는 종관규모 이상의 전 지구 모니터링에 적합한 수백m~km급의 해상도 산출물만 제공되고 있어, 실제적으로 우리나라의 저수지 수위를 측정하는데 사용하기에는 적합하지 않다. 이러한 저해상도 위성외에 15~100m급 LandSat과 같은 중해상도 위성이 있으나 시간해상도가 16일로 재방문주기가 매우 길다. 특히 기상조건에 극단적으로 의존하는 광학위성임을 고려할 때 홍수대응을 목적으로 하는 황강댐 모니터링에 사용하기에는 적합하지 않다. 이러한 한계점을 고려할 때, 유럽우주기구(ESA)에서 전 지구 관측을 목적으로 최초로 실시한 코페르니쿠스 프로그램 위성 constellation으로 2014년부터 운영중인 Sentinel 위성시리즈는 대안이 될 수 있다. 특히, Sentinel-1 위성은 기상조건에 관계없이 지표면 관측이 가능한 C밴드 SAR 위성이며, Sentinel-2 위성은 역시 10m 급의 광학위성으로 해상도 측면에서 기 언급된 위성보다 활용성이 높다. 특히 이들은 A, B 형태의 쌍둥이 위성으로서 시간해상도가 5~7일로 유사한 스펙의 위성인 Landsat 시리즈보다 동일지점을 보다 자주 고해상도로 관측할 수 있는 장점이 있다. 특히 이러한 고해상도 영상임에도 무료로 영상을 활용할 수 있는 장점이 있다. 이러한 장점을 고려하여 본 연구에서는 향후 북한 황강댐 수위 추정을 감안하여 대청댐 수위 추정시에도 Sentinel-1, 2 위성을 활용함으로써 황강댐 확대 적용성을 검토하고자 한다. 또한 Sentinel-1, 2 영상보다 고해상도 위성영상을 추가로 적용, 분석하여 공간해상도에 따른 수위추정 신뢰도의 영향을 분석하고자 한다.

대청댐의 수위추정에 사용되는 Sentinel-1(그림 5.3(a)) 영상은 동일한 궤도를 비행하는 2014년 4월 3일 발사된 Sentinel-1A 위성과 2016년 4월 25일 발사된 Sentinel-1B 위성으로 구성되어 있으며 두 위성은 180°의 위상차로 비행한다. 각각의 위성은 12일 반복주기로 비행하며 두 위성을 함께 활용하는 경우 반복주기는 6일이다. 본 연구에서는 Sentinel-1의 4가지 자료 획득 모드(Stripmap (SM), Interferometric Wide swath (IW), Extra-Wide swath (EW), Wave (WV)) 중 주된 획득 모드이며 20 m × 22 m (range×azimuth) 공간 해상도로 데이터를 수집하는 Interferometric Wide swath Mode (IW)의 Ground Range Detected (GRD)자료(표 5.2)를 사용하였다. Sentinel-1 위성 영상은 Copernicus Open Access Hub (https://scihub.copernicus.eu/dhus)에서수집하였다.

Sentinel-2(그림 5.3(b))는 산림감시, 토지피복 변화 탐지 및 자연재해 관리와 같은 서비스를 지원하기 위해 지상관측을 수행하는 코페르니쿠스 프로그램의 일환으로 ESA에서 개발된 지구관측임무 위성이다. 최대 10m급 해상도, Push-broom 형식으로 290㎢의 넓은 관측 폭, 적도에서 5일의 재방문주기(구름이 없는 조건하에서)와 중위도에서 2~3일의 짧은 재방문 주기, 전처리가 완료된 위성영상의 제공 등을 통해 그 활용성을 인정받고 있다.

동일 궤도의 2개 위성인 Sentinel-2A와 Sentinel-2B로 구성되며 최적의 적용 범위와 데이터 획득을 위해 2개의 위성체는 180° 떨어져 있다. Sentinel-2는 13개 밴드의 다중분광 위성으로 10m 해상도의 가시근적외밴드 4개, 20m 해상도의 식생적색경계밴드 3개, 단파적외선밴드 2개, 협대역근적외밴드 1개, 60m 해상도의 수증기, 대기단파적외선, 연안 에어로졸 각각 1개씩의 밴드를 포함하고 있다. 표 5.3은 Sentinel-2A의 밴드, 파장, 해상도와 대역폭을 나타낸다. Sentinel-2 위성영상도 Copernicus

Open Access Hub (https://scihub.copernicus.eu/dhus)에서 수집하였다.

(a) Sentinel-1 (b) Sentinel-2



그림 5.3 ESA(유럽우주기구)에서 무료제공되는 (a) Sentinel-1 위성, (b) Sentinel-2 위성

표 5.2 Sentinel-1 IW 모드의 특성

특 성	Interferometric Wide Swath Mode (IW)
Swath Width	> 250 km
Incidence angle range	29.1° ~ 46.0°
Number of sub-swaths	3
Azimuth steering angle	± 0.6°
Polarisation Options	Single (HH or VV) or Dual (HH+HV or VV+VH)

표 5.3 Sentinel-2A 위성 채널

밴 드	중심파장(㎛)	해상도(m)	대역폭(nm)
Band 1 - Coastal aerosol	0.443	60	20
Band 2 - Blue	0.49	10	65
Band 3 - Green	0.56	10	35
Band 4 - Red	0.665	10	30
Band 5 - Vegetation Red Edge	0.705	20	15
Band 6 - Vegetation Red Edge	0.74	20	15
Band 7 - Vegetation Red Edge	0.783	20	20
Band 8 - NIR	0.842	10	115
Band 8A - Narrow NIR	0.865	20	20
Band 9 - Water vapour	0.945	60	20
Band 10 - SWIR - Cirrus	1.375	60	20
Band 11 - SWIR	1.61	20	90
Band 12 - SWIR	2.19	20	180

대청댐 수위추정에 사용된 날짜는 2019년 갈수기인 4월 3일과 홍수기 후반 수위가 연중 가장 높을 시기인 9월 30일이다. 수위변화는 대략 74~76m 범위에서 변동이 있었다.

나. 수치표고모형

위성영상으로부터 추출된 수계영역을 수치표고모형과 중첩을 통해서 최종적인 댐 수위값을 추정해낼 수 있다. 이를 위하여 수치표고모형 자료 활용이 필수적이다. 본 연구에서는 적용하는 수치표고모형의 해상도에 따른 수위변화를 민감도를 분석하기 위하여 1m 급의 대청댐 수치표고모형 자료(그림 5.4.(a))와 10m 급(그림 5.4.(b))의 한반도 전체 수치표고모형을 이용하였다.

1m 수치표고모형은 2020년 K-water에서 측량조사사업의 항공 Lidar측량을 통해 생성한 자료이다. 항공 LiDAR측량의 정확도를 위하여 동시간대 지상 GPS로부터 취득된 지상기준국 GPS 데이터성과, 항공기 DGPS에 의한 항공 GPS 데이터성과, 항공기 IMU 데이터 함께 취득하였다. 이를 통해서 항공 Lidar 원시데이터를 취득하고 지상기준국 데이터의 처리를 포함하여 레이저 관측점에 대한 3차원 좌표 값을 얻는 전처리를 수행한다. 이후 코스별 정확도 확인, 정표고 보정, 지형데이터 분류 등의 후처리 과정을 거친 후 검증을 통해 최종적인 수치표고모형을 산출하게 된다. 10m 수치표고모형은 2007년 국토지리정보원에서 생산한 자료로서, 위성 스테레오 영상을 통해 남한 전체에 대한 모형을 구축한 것이다. 그림 5.4(b)를 보면 저수지 면적에 해당하는 부분에서 등고선이 부족한 것을 볼 때, 대청댐의 수위가 고수위일 때 생성된 것으로 추정된다.

(a) (b)

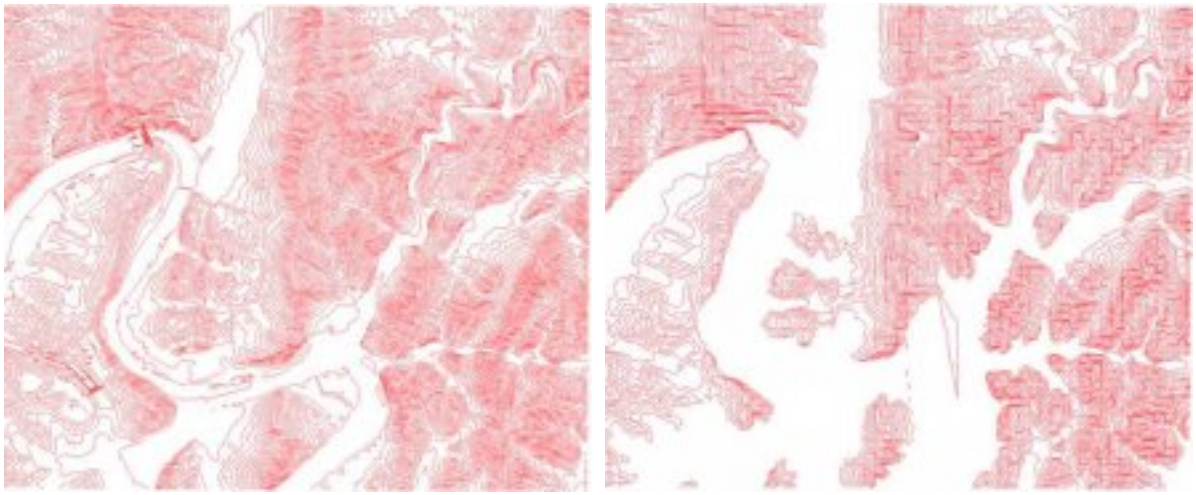


그림 5.4 대청댐 유역 수치표고모형 ((a) 1m 해상도, (b) 10m 해상도)

5.2.3 연구방법

위성영상과 수치표고모델(DEM)을 활용한 수위산출 과정은 위성영상의 전처리, 수체분류, DEM 중첩, 수위산출의 과정으로 이루어진다. 위성영상은 SAR영상과 광학영상의 관측원리 차이로 인해 각각 전처리가 수행된다. SAR 영상은 관측특성상 전파를 side-looking 형태로 송출하여 반사된 신호를 분석하기 때문에 광학영상의 전처리 과정과는 다르다.

SAR 영상인 Sentinel-1은 ESA(유럽우주기구)에서 ESA에서 개발한 무료 프로그램인 Sentinels Application Platform (SNAP, http://step.esa.int/main/download)을 이용하였다. 먼저, 이미지의 픽셀값을 레이더 후방 산란 값으로 변환하기 위하여 Calibration 과정을 거쳤다. 초기 이미지 픽셀값은 방사보정이 되어있지 않아 방사 측정시의 편차가 남아있다. 그러므로 이미지의 픽셀값이 실제로 레이더 후방 산란 값을 나타낼 수 있도록 방사보정 과정을 거쳐야한다. 이 과정은 특히 본 연구와 같이 서로 다른 시간에 얻어진 이미지들을 비교할 때 필수적인 과정이다. 다음으로 산란에 의해 발생한 밝거나 어두운 점들인 Speckle을 제거하기 위하여 Speckle filtering 과정을 거쳤다. SNAP 프로그램에서는 다양한 분포 형태의 노이즈들을 처리하기 위하여 Mean, Median, Lee, Lee Sigma, Gamma-MA 등 8개의 필터를 지원한다. 본 연구에서는 노이즈를 가우시안 분포로 가정하는 Lee Sigma 필터를 사용하여 필터링을 하였다. 이 필터는 관심 픽셀의 값을 지정된 범위 내에 있는 모든 픽셀값의 평균으로 바꿔준다. 그리고 지형 보정(Range-Doppler terrain correction)을 통해 이미지의 좌표체계를 WGS84 좌표계로 변환시키고 보정 하였다. 이를 통해 지형변화와 위성 센서의 기울기에 의한 왜곡을 보정하여 이미지의 기하학적인 형태가 실제와 최대한 가깝도록 만들었다. 이렇게 보정된 영상은 후방산란신호(dB, 데시벨)에 따라 수체를 탐지하게 된다. 수체탐지시 후방산란계수의 확률분포를 감마분포로 가정하고 영상의 히스토그램 중 수체에 해당하는 부분에 적합한 감마분포를 찾아낸 후 이를 바탕으로 임계값을 설정하였다. 그러나 임계값에 따라 탐지되는 수체면적이 변화하고 이는 위성종류에 따라 달라지는 특성이 있으므로 임계값의 -14 ~ -16 dB 변화에 따라 수체탐지 민감도를 분석하였고, 이 결과들의 DEM과의 중첩을 통해 얻어진 추정수위를 실측자료와 비교하였다.

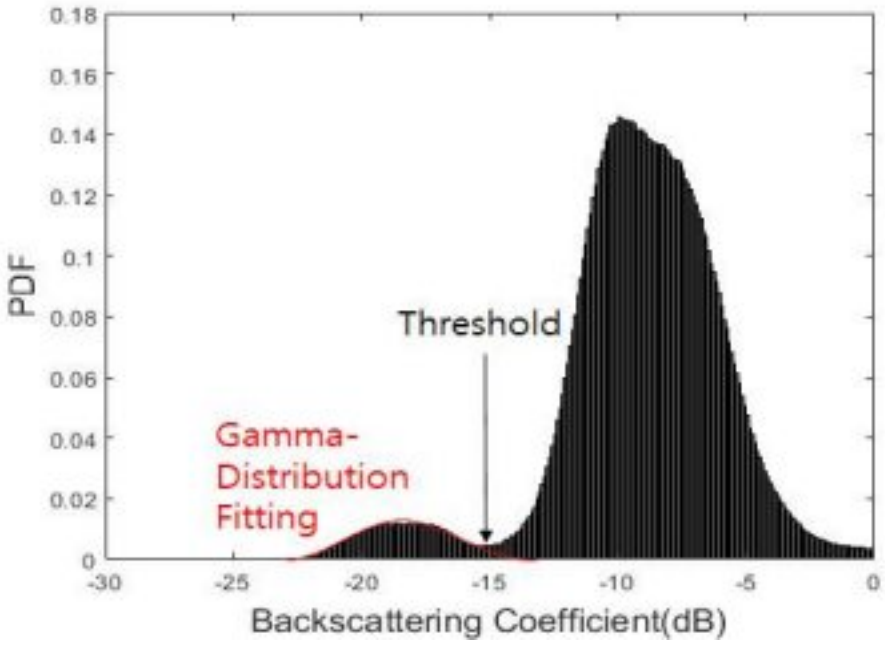


그림 5.5 SAR 영상의 Gamma-distribution fitting

광학영상의 경우, Sentinel-2는 기본적인 전처리(복사, 기하보정 등)가 모두 수행된 Level2 영상을 활용하였기 때문에 별도의 추가적인 전처리는 수행하지 않았다. 광학영상의 수체탐지 및 분류는 SAR 영상과 달리 태양복사에너지의 파장별 반사도를 이용해서 산출한다. 일반적으로 수체는 IR채널

에서 수체에 의한 태양복사에너지의 흡수가 있기 때문에 그 반사도 값이 다른 파장대역에 비교하여 낮기 때문에서 영상에서 어둡게 나타난다. 이러한 성질을 이용하여 보통 NDWI(Normalized Difference Water Index)라는 정성적 지수를 사용하여 수체를 탐지한다. NDWI는 식5.1과 같이 가시대역의 green 채널과 근적외채널 반사도를 이용해 산출한다.

$$NDWI = \frac{R(\text{녹색}) - R(\text{근적외})}{R(\text{녹색}) + R(\text{근적외})} \qquad \text{수식 5.1}$$

여기에서, R(녹색)은 가시광 녹색채널의 반사도, R(근적외)는 근적외채널의 반사도를 의미한다. NDWI는 위성의 각 채널별 중심파장과 밴드폭에 따라서 값이 조금씩 다르게 나타나지만 보통 0.0 값을 기준으로 이 값보다 작은 구역이 수체로 탐지될 수 있다. 이 연구에서는 NDWI 값에 따른 수체 탐지 면적, 그로 인한 수위변화의 민감도를 평가한다. 마지막으로 NDWI로 산출된 수체 부분을 DEM과 중첩하여 겹쳐진 지점의 표고값을 모두 산출하고, 이들 값을 히스토그램을 이용해 가우시안 분포를 가정하여 평균에서 ±1σ 안에 해당되는 포인트들의 산술평균을 통해서 최종적인 추정수위값을 산출한다.

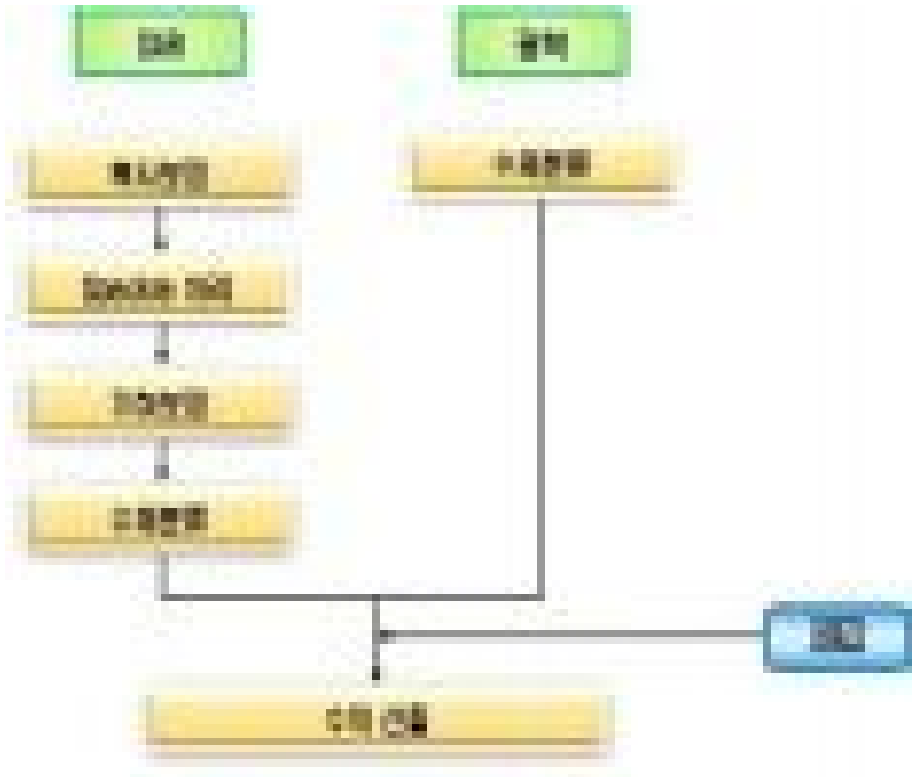


그림 5.6 대청댐 수위 추정 과정

수위판독을 하는 위치는 두 개 영역으로 구분하였다. 우선 수위측정이 시행되고 있는 댐체 부근과 지표의 경사가 완만하여 수위변화에 따라 수체면적 변화가 잘 인식될 수 있는 구역으로 구분하였다. 댐체 부근 영역(그림 5.7(a))은 실제로 수위가 실시간으로 측정되고 있어 위성에서 산출된 추정값과의 비교에 효과적이지만, 댐체의 경사도가 다소 급하고, 이로 인해서 위성에서 수체 탐지시에 수위변동에 대한 민감도가 낮게 나타날 수 있어, 수위 변동에 따른 정확한 수체 탐지가 어려울 수 있는 단점이 있다. 이러한 단점을 보완하기 위해 경사가 다소 완만하여 수위 변동에 따라 수체면적이 민감

하게 나타나는 영역(그림 5.7(b))을 구성하였다. 하지만 이 경우, 수위측정이 시행되지 않는 지역이라 댐체에서의 수위측정값과의 절대적인 비교에 한계가 있을 수 있다. 그러나, 실험에서 선택한 수위판독 영역은 댐체에서 약 2km 상류지점이라 큰 수위변동은 없음을 가정하여 수행하였다.

(a) (b)



그림 5.7 대청댐 수위 분석 위치((a)댐체영역, (b)상류 2km지점영역)

5.3 결과 및 토의

가. DEM 해상도에 따른 수위 분석

Sentinel-1/2 영상을 활용하여 DEM 해상도에 따른 수체면적 탐지에 대한 민감도를 확인해 보았다. 수위를 분석한 영역은 댐체 영역으로만 한정하여 수행하였고, DEM 해상도에 따라 Sentinel-1에서는 후방산란계수 값에 따라, Sentinel-2는 NDWI 값에 따라 수위를 분석하였다(표 5.4).

표 5.4 DEM 해상도에 따른 수위 ((a)1m DEM, (b)10m DEM)

(a) 1m DEM

Reference		후방산란계수(dB)						NDWI					
날짜	수위(EL.m)	-14	차이	-15	차이	-16	차이	0.0	차이	-0.1	차이	-0.2	차이
4.3	74.17	75.60	1.43	73.98	-0.19	73.89	-0.28	68.85	-5.32	72.24	-1.93	72.27	-1.90
9.30	75.74	82.57	6.83	80.46	4.72	80.18	4.44	67.19	-8.56	71.91	-3.84	72.06	-3.69
		표준편차	3.49	표준편차	2.36	표준편차	2.22	표준편차	5.04	표준편차	2.15	표준편차	2.08

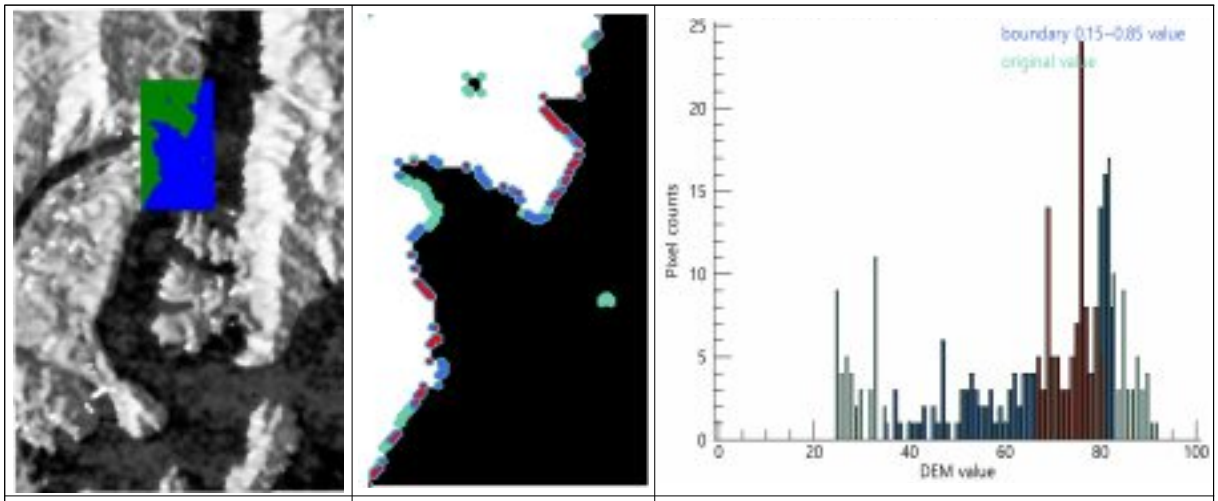
(b) 10m DEM

Reference		후방산란계수(dB)						NDWI					
날짜	수위(EL.m)	-14	차이	-15	차이	-16	차이	0.0	차이	-0.1	차이	-0.2	차이
4.3	74.17	75.00	0.83	75.00	0.83	75.00	0.83	75.00	0.83	75.00	0.83	75.00	0.83
9.30	75.74	75.00	-0.74	75.03	-0.71	75.00	-0.74	75.00	-0.74	75.00	-0.74	75.00	-0.75
		표준편차	0.56	표준편차	0.55	표준편차	0.56	표준편차	0.56	표준편차	0.56	표준편차	0.56

1m DEM과 10m DEM을 각각 적용하여 수위를 비교하였을 때, 1m DEM을 적용하여 수위를 산출했을 때보다 10m DEM을 이용한 수위분석의 편차 더 적게 나타났다. 이것은 10m DEM의 경우, 수계부분에 대한 DEM의 고도값이 75m로 고정되어 있어, 그 수위 이하의 값은 측정이 불가능하여 상대적으로 적은 편차를 발생시킨 것으로 보인다. 따라서, DEM 해상도에 따른 수위분석의 영향은 명확히 확인하기 어려웠다. 이러한 점을 고려하여, 이후 과정에 대한 분석은 1m DEM을 이용해서 분석한다.

나. 후방산란계수에 따른 수위 분석(SAR위성 영상)

Sentinel-1 영상을 활용하여 후방산란계수에 따른 수체면적 탐지를 통한 수위분석의 민감도를 확인해 보았다. 후방산란계수를 -13.0부터 -16.0까지 0.5 간격으로 변화시키며 그에 따른 수위결과를 실제 수위값과 비교하였다. 그림 5.8은 2020년 4월 3일 Sentienl-1 영상을 활용하여 수위를 분석하는 과정을 나타내고 있다. 그림 5.8(a)와 같이 후방산란계수별로 수체를 탐지하고, 수체로 탐지된 픽셀들을 DEM과 중첩하여 그림 5.8(b)와 같이 각 픽셀별 DEM 값을 추출하여 그림 5.8(c)처럼 DEM 값에 따른 픽셀갯수를 히스토그램으로 나타낸다. 다양한 스펙트럼을 갖는 픽셀값들로부터 최종적인 수위값 산출을 위해 히스토그램의 분포를 가우시안분포로 가정하여 평균에서 ±1σ 에 해당되는 outlier를 제거하고 픽셀갯수가 가장 많은 값으로부터 가장 근접한 50% 픽셀값을 산술평균한다. 그 값을 최종 분석수위로 가정하여 표5.5로 나타내었다. 각 픽셀별 수위추정영역은 댐체영역과 댐상류 2km지점 영역으로 구분하고, DEM은 1m로 하여 분석한 결과, 후방산란계수가 -14.5dB일 때 실제 수위와의 편차가 가장 적게 나타났다. 일반적으로 후방산란계수가 클수록 수체로 탐지되는 면적이 넓어지게 된다. 따라서 DEM과 중첩했을 때 분석되는 수위값도 더 높게 나타나는 경향이 있다. 표5.5를 보면 그러한 경향을 확인할 수 있고, 본 실험에서는 후방산란계수가 -14.5dB 일 때, 계측된 수위와 가장 근접한 값을 가짐을 확인할 수 있었다.



(a)수체탐지 영역 | (b)수체경계 픽셀 중첩 | (c)히스토그램

그림 5.8 2020년 4월 3일 Sentinel-1 영상을 활용한 대청댐 수위 분석(댐체영역)

표 5.5 Sentinel-1 영상의 후방산란계수에 따른 수위분석 결과

(a) 댐체 영역

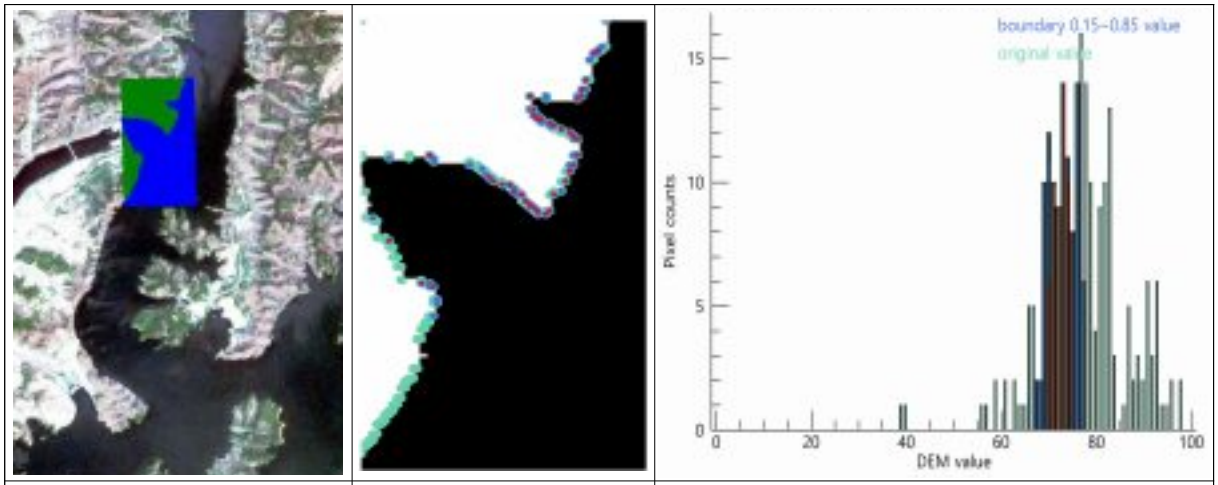
Reference		후방산란계수(dB)						
날짜	수위(EL.m)	-13.0	-13.5	-14.0	-14.5	-15.0	-15.5	-16.0
4.3	74.17	78.38	83.20	75.60	74.38	73.98	74.36	73.89
9.30	75.74	84.05	72.98	82.57	79.47	80.46	80.49	80.18
4.3	관측값 차이	4.21	9.03	1.43	0.21	-0.19	0.19	-0.28
9.30		8.31	-2.76	6.83	3.73	4.72	4.75	4.44
	표준편차	6.59	6.67	4.93	2.64	3.34	3.37	3.14

(b) 상류 2km지점 영역

Reference		후방산란계수(dB)						
날짜	수위(EL.m)	-13.0	-13.5	-14.0	-14.5	-15.0	-15.5	-16.0
4.3	74.17	71.37	72.39	72.40	72.50	72.50	69.46	67.26
9.30	75.74	71.58	70.16	69.41	72.43	68.81	68.55	69.47
4.3	관측값 차이	-2.80	-1.78	-1.77	-1.67	-1.67	-4.71	-6.91
9.30		-4.16	-5.58	-6.33	-3.31	-6.93	-7.19	-6.27
	표준편차	3.55	4.14	4.64	2.62	5.04	6.08	6.60

다. NDWI에 따른 수위 분석(광학위성 영상)

Sentinel-1과 같은 SAR영상을 광학영상인 Sentinel-2 영상과 비교하기 위하여 NDWI에 따른 수체 면적 탐지를 통한 수위분석 결과의 민감도를 확인해 보았다. 최대한 정확한 비교를 위하여 관측시각은 다르지만 날짜는 같은 영상을 활용하였다. 일반적으로 NDWI가 0보다 작은 픽셀은 수체로 탐지하게 되는데, 정확한 수체 경계를 산출하기 위해 표 5.6과 같이 NDWI를 0.1부터 -0.2까지 0.05단위로 구분하여 수체탐지를 수행하였고, 탐지된 수체 경계를 DEM과 중첩하여 최종 수위값을 산출하였다. 실제 측정된 수위값과의 오차는 댐체 영역에서 NDWI를 산출했을 때는 -0.15, 댐 상류영역에서는 -0.1일 때가 가장 적게 나타났다. 이 때의 실제 수위와의 절대오차의 표준편차는 각각 2.87과 2.38 EL.m 였다.



(a)수체탐지 영역 (b)수체경계 픽셀 중첩 (c)히스토그램

그림 5.9 2020년 4월 3일 Sentinel-2 영상을 활용한 대청댐 수위 분석(댐체영역)

표 5.6 Sentinel-2 영상의 NDWI에 따른 수위분석 결과

(a) 댐체 영역

Reference		NDWI						
날짜	수위(EL.m)	0.1	0.05	0	-0.05	-0.1	-0.15	-0.2
4.3	74.17	69.75	72.16	68.85	72.43	72.24	72.37	72.27
9.30	75.75	72.00	71.00	67.19	68.72	71.91	72.10	72.06
4.3	관측값 차이	-4.42	-2.01	-5.32	-1.74	-1.93	-1.80	-1.90
9.30		-3.74	-4.74	-8.55	-7.02	-3.83	-3.64	-3.68
	표준편차	4.10	3.64	7.12	5.12	3.03	**2.87**	2.93

(b) 상류 2km지점 영역

Reference		NDWI						
날짜	수위(EL.m)	0.1	0.05	0	-0.05	-0.1	-0.15	-0.2
4.3	74.17	72.39	72.40	72.41	72.38	73.45	73.33	75.49
9.30	75.75	67.29	68.35	70.32	70.38	72.45	70.36	70.46
4.3	관측값 차이	-1.78	-1.77	-1.76	-1.79	-0.72	-0.84	1.32
9.30		-8.45	-7.39	-5.42	-5.36	-3.29	-5.38	-5.28
	표준편차	6.11	5.37	4.03	4.00	**2.38**	3.85	3.85

라. 수체탐지 영역 및 영상종류별(SAR/광학) 비교

표 5.5 (a)와 (b)를 통해서 Sentinel-1 SAR 영상을 활용한 수위분석 영역별 수위정확도를 비교해 본 결과, 댐체의 경우 위성자료로 추정된 수위가 실제 값보다 높게 산출되었으나, 댐 상류 영역에서는 오히려 댐 실제 수위보다 더 낮은 값이 산출되었다. 이것은 SAR 영상에서의 수위분석 정확도는 댐 상류영역 수체경계를 추출하기 위한 speckle 제거 수준에 따라 의존하는 것으로 판단된다. 반면에 Sentinel-2 영상을 활용하여 수위분석 영역별 수위정확도는 확인한 결과, 댐체 영역과 상류지점 영역 모두 산출된 수위가 실제 수위보다 낮게 나타났다. 이러한 일정한 bias가 보이는 것은 georeferencing의 오차나 수면경계로 인식된 픽셀들을 이용한 최종적인 수위값 산출을 위한 통계분석 방법 개선을 통해서 보다 정확한 수위를 산출할 수 있을 것으로 생각된다.

SAR 영상과 광학영상간 결과를 비교해보면, 두 영상의 오차는 큰 차이가 없는 것으로 나타났다. SAR영상이 관측방법이나 영상처리과정이 광학영상보다 복잡하지만 수위분석 결과로만 보면 수위분석 정확도에는 크게 차이가 나지 않는 것으로 나타났다. SAR 영상은 지표를 관측함에 있어 어떠한 기상조건에서도 관측이 가능하다는 장점으로 볼 때, 영상처리의 복잡함을 감수하더라도 SAR 영상을 통한 댐 수위분석이 광학영상보다 용이할 수 있음을 보여주었다.

마. 고해상도 SAR영상을 활용한 수위분석

전천후로 수위분석이 가능하고, 특히 별도의 영상구매 비용없이 10m급의 영상을 무료로 활용할 수 있는 Sentinel-1 영상보다 고해상도인 COSMO-SkyMed 영상(해상도 3m)과 비교하여 보았다. 객관적인 비교를 위하여 Sentinel-1 영상과 가장 가까이 촬영된 날짜(4월 2일 21시, 9월 20일 21시)를 활용하였다. 이 때의 수위는 각각 74.17m, 72.83m로 Sentinel-1 영상에서의 4월 3일 18시에는 수위가 74.17m로 같았으나, 9월 30일 18시에는 75.74m로 약 3m 정도 차이가 났다.

영상분석 결과는 표 5.7과 같이, 댐체영역과 상류영역 모두 후방산란계수가 -14.5dB 일 때, 오차가 가장 적게 나타났고, 특히 댐체영역보다는 상류영역에서의 수위분석 정확도가 더 높게 나타났다. 그러한 이유는 그림 5.10과 그림 5.11을 통해서 추정해 볼 수 있다. 그림 5.10(b)를 보면 수체경계에 대한 픽셀 중첩된 포인트들 중에서 히스토그램상에서 최종수위값으로 산정되는 빨간색 픽셀들의 위치를 보면 수체경계 뿐만 아니라 육지 부분에서 수체로 인식되는 부분들의 DEM 값을 최종수위값 산출에 계산됨으로 인해서 실제 수위값보다 매우 높게 산출된 것으로 보인다.

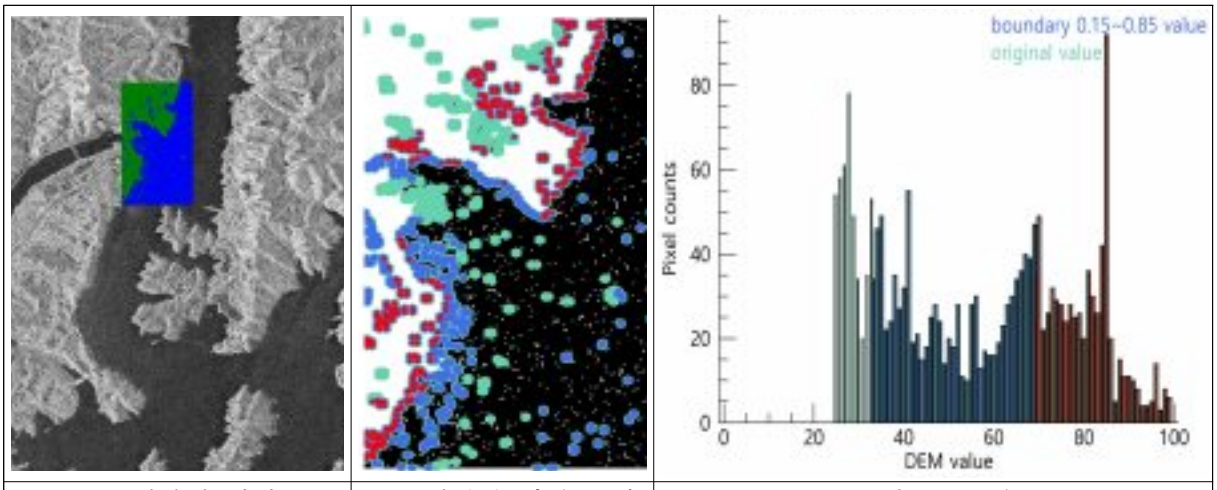
표 5.7 COSMO-SkyMed 영상의 후방산란계수에 따른 수위분석 결과

(a) 댐체 영역

Reference		후방산란계수(dB)						
날짜	수위(EL.m)	-13.0	-13.5	-14.0	-14.5	-15.0	-15.5	-16.0
4.2	74.17	84.19	83.58	83.11	67.77	68.23	69.27	30.37
9.20	72.83	83.72	83.36	82.64	80.21	35.24	33.10	32.06
4.2	관측값 차이	10.02	9.41	8.94	-6.40	-5.94	-4.90	-43.80
9.20		10.89	10.53	9.81	7.38	-37.59	-39.73	-40.77
	표준편차	10.46	9.99	9.39	**6.91**	26.91	28.30	42.31

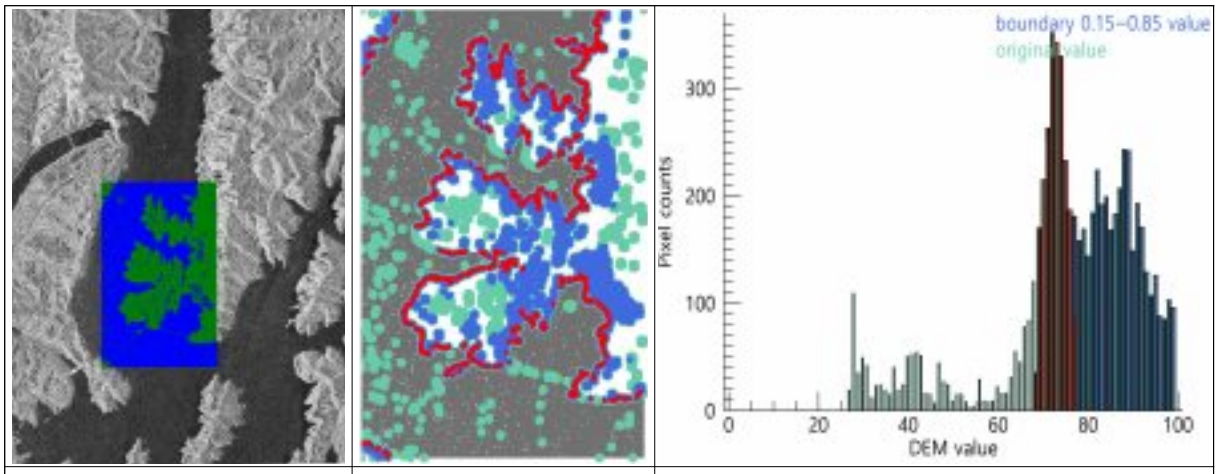
(b) 상류 2km지점 영역

Reference		후방산란계수(dB)						
날짜	수위(EL.m)	-13.0	-13.5	-14.0	-14.5	-15.0	-15.5	-16.0
4.2	74.17	75.68	74.80	73.40	73.48	73.96	69.97	38.67
9.20	72.83	74.68	73.69	69.65	72.27	71.14	33.58	32.72
4.2	관측값 차이	1.51	0.63	-0.77	-0.69	-0.21	-4.20	-35.50
9.20		1.85	0.86	-3.18	-0.56	-1.69	-39.25	-40.11
	표준편차	1.69	0.76	2.31	**0.62**	1.20	27.91	37.87



(a)수체탐지 영역 (b)수체경계 픽셀 중첩 (c)히스토그램

그림 5.10 2020년 9월 20일 COSMO-SkyMed 영상을 활용한 대청댐 수위 분석(댐체영역)



(a)수체탐지 영역 (b)수체경계 픽셀 중첩 (c)히스토그램

그림 5.11 2020년 9월 20일 COSMO-SkyMed 영상을 활용한 대청댐 수위 분석(댐상류영역)

반면에 그림 5.11(b)에서는 최종 수위값을 산정하는 빨간색 포인트들의 위치가 그림 5.11(a)의 수면경계를 댐체영역보다는 전영역에 걸쳐서 균등하게 구분해내고 있고, 최종 수위값 산출을 하는 히스토그램(그림 5.11(c))에서도 픽셀별 수위값의 편차가 크지 않아 최종 수위값에서 안정적으로 나타내고 있음을 알 수 있다.

5.4 결론

본 장에서는 미계측 접경유역에 대한 국가공유하천 관리와 북측의 무단방류 등 국가안보 대비를 위하여 다양한 위성영상을 활용하여 접경 북한댐 수위 모니터링을 개선하는 방안을 제시하기 위한 실험을 수행하였다. 북한 황강댐 수위가 목표 대상이지만, 실제 수위를 알 수 없는 문제로 그 실험대상 유역을 댐유역 규모 등을 고려하여 대청댐에 대한 실험을 수행하였고, 그 수행 결과를 다음의 몇 가지로 요약하였다.

1) 수체탐지를 위한 임계값 산출을 확인하기 위하여 SAR 위성인 Sentinel-1의 후방산란계수를 이용한 댐 수위 분석에서 수계경계 추출을 위한 후방산란계수위 임계값은 -14.5dB이 가장 적합하였고, 이를 댐 수위 분석에 적용한 결과 실제 수위와 가장 적은 오차를 보였음을 확인할 수 있었다. 또한 광학영상 시스템으로 운영되는 Sentinel-2에서는 수체추출을 위하여 NDWI의 임계값을 분석한 결과 -0.1~-0.15를 적용하는 것이 가장 적은 오차를 나타내었다.

2) 수위변화에 따른 수체변화 면적이 실제 수위분석에 영향을 주는지를 확인하기 위하여 댐체여역과 댐상류 지표경사가 완만한 지역을 비교한 결과, 10m 급의 영상분석에서는 큰 차이가 없었으나, 고해상도 위성영상에서는 수위변화에 따른 수면적이 변화가 큰 댐상류지역의 수위값 분석이 오차가 적게 나타났다.

3) 전전후 SAR 위성과 기상조건에 민감하지만 자료처리 등의 장점이 있는 광학영상을 비교한 결과 수위분석 정확도에는 크게 차이가 없는 것으로 분석되었다. 다만, SAR 영상의 경우 speckle 처리 등 전처리가 수위값 산출에 매우 중요한 요소가 됨을 확인할 수 있었다.

제 6 장 Machine Learning 기법을 활용한 Hybrid 강우-유출 모형 개발

6.1 서 론

본 장에서는 위성에서 취득한 토양수분자료를 Machine learning 기법을 활용 기존 강우-유출 모형과 결합한 새로운 개념의 Hybrid 강우-유출모형을 개발하고 적용성을 검토하고자 한다. 강우-유출 과정을 재현하는 수문 모형은 수자원의 계획과 관리단계에 있어서 매우 중요한 수문분석 Tool로 여겨진다. 지금까지 강우 사상에 대한 유역의 응답을 효율적으로 해석하는 강우-유출모형을 개발하기 위한 많은 노력에도 불구하고, Orth et al. (2015)은 실무적·연구적 관점에서 강우-유출 모델은 모델 수행 목적에 따라 여전히 개선할 점이 있다고 하였다. 강우-유출모형은 모델 구축의 내부적 구조뿐만 아니라 토양이 함유하는 수분의 정도, 증발산, 침투, 침루 등 강우에 응답하는 수문 요소 등을 모의하는 과정에서 어떻게 분석되는지가 모형수행 능력에 중요한 요소로 평가되며 이러한 수문요소들은 결국 유출 양상에 밀접한 영향을 미친다. 특히, 유출모형의 모형 수행능력은 여러 수문 요소 중 특히 토양수분의 시공간적인 변화를 얼마나 정밀하게 모의하는 정도에 따라 크게 영향을 받는다 (Brocca et al., 2010; Loizu et al., 2018). 이처럼 유역내에서 토양수분의 시공간적인 변동을 묘사하는 것이 수문순환 해석에 필수적이며, 강우-유출 모델링에서 중요한 요소임에도 불구하고, 우리나라를 포함한 많은 지역에서 토양수분 관측망의 부족으로 토양수분자료를 유출모형에 직·간접적으로 적용한 사례는 매우 제한적이다.



그림 6.1 용담댐 전경

2장에서 언급하였듯이 위성에서 획득된 토양수분 정보는 최근 데이터의 질과 시·공간 해상도가 많이 개선되었으며, 수문학적 관점에서도 강우-유출, 수치기상예보(Dharssi et al., 2011), 강우 추정 (Brocca et al., 2014; Ciabatta et al., 2018) 그리고 가뭄 모니터링 (Enenkel et al., 2016) 등 그 활용성이 확대되고 있다. 또한, 위성토양수분자료는 conceptual 모델 (Brocca et al., 2012; Massari et al.,

2015) 또는 physically-based 강우-유출 모형에(Lievens et al., 2015; Loizu et al., 2018; Young et al., 2017) 주로 데이터 Assimilation 기법 기반으로 융합되어 유출모형의 성능을 향상시키는데 이용되기도 한다. 이전 연구들의 결과를 살펴보면 위성 토양수분자료를 유출모형과 동기화한(Assimilation) 성과는 연구자 및 연구지역에 따라 상이하게 나타났다. Lievens et al. (2015)은 위성토양수분 자료를 기존 모형에 동기화 결과 유출 예측에 있어서 제한된 효과를 보인 반면, Brocca et al. (2012) 와 Massari et al. (2015)은 강우-유출모형과 위성토양수분 자료를 결합해서 기존 모형에 비해 모의 능력에 있어서 유의미한 개선 효과를 도출하였다. 6장에서는 위성토양수분 자료와 우리나라에서 광범위하게 쓰이는 Tank 모형을 Machine Learning 기법 중 Least Squares Support Vector Machine 기법을 이용 Hybrid 강우-유출 모형을 개발하고 개발된 모형의 용담댐 유역을 대상으로 적용성을 평가하고자 한다.

6.2 연구대상지역 및 연구방법

6.2.1 용담댐 현황

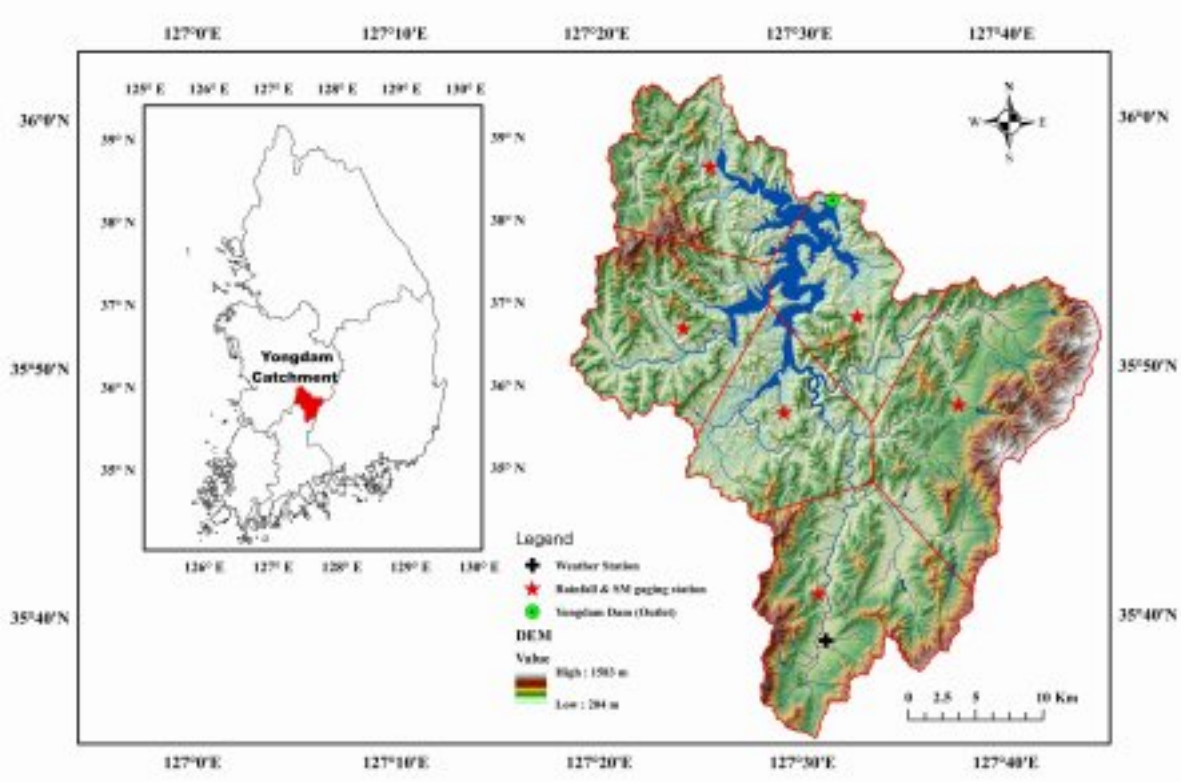


그림 6.2 용담댐 유역현황 및 토양수분 관측지점

용담댐 유역은 금강 상류 즉, 북위 35°35′ ~ 36°00′, 동경 127°20′ ~ 127°45′ 사이에 위치하고 있으며, 행정구역으로는 진안군, 장수군, 무주군 등을 포함한 전라북도와 충청남도 그리고 경상남도에 걸쳐 위치하고 있다. 유역출구에는 2001년에 준공한 높이 70m, 길이 498m, 총 저수용량이 815백만㎥의 용담다목적댐이 위치하고 있으며(그림6.1), 유역면적은 930㎢로 금강유역면적의 약 9.5%를 차지한다. 본 연구에서 용담댐 유역을 선정한 사유는 용담유역은 K-water 연구원에서 운영하고 있는 시험유역

으로 신뢰도 높은 수위, 유량, 강우량 등 수문 관측 자료의 취득이 가능할 뿐만 아니라, 2014년 이후의 유역 내 6개 지점에서 토양수분을 관측하고 있어 유역 전반의 토양수분 시계열 자료 또한 취득이 가능한 유역이기도 하다.

표 6.1 용담댐 유역 토양수분 및 강우측정 지점 현황

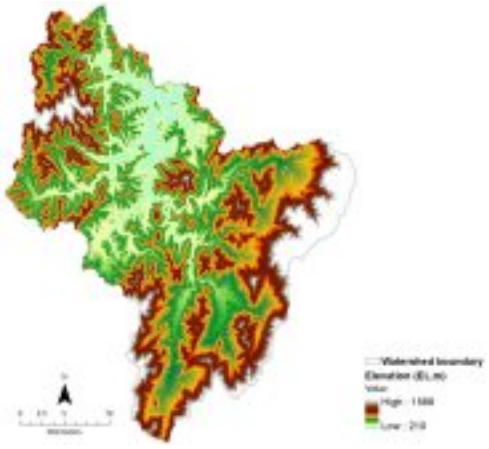
관측소명	위 치(degree)		관측소표고 (EL.m)	토양수분 관측심도 (cm)
	경도	위도		
Soil moisture & Rainfall				
안천 (SM#1)	127.55	35.87	313.0	10, 20, 40, 60, 80
주천 (SM#2)	127.43	35.97	330.0	10, 20, 40, 60
부귀 (SM#3)	127.40	35.86	396.0	10, 20, 40, 60
상전 (SM#4)	127.49	35.80	334.0	10, 20, 40, 60, 80
계북 (SM#5)	127.63	35.81	453.0	10, 20, 40, 60, 80
천천 (SM#5)	127.51	35.68	409.0	10, 20, 40, 60, 80





그림 6.3 토양수분계측기(TDR) 매설 및 토양수분(강우) 계측지점 전경

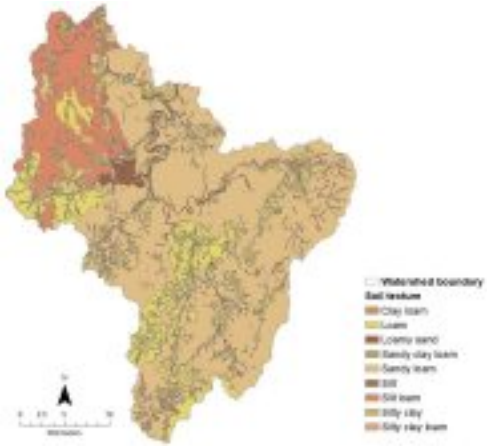
표 6.1은 용담댐 유역 6개의 토양수분관측소 현황 및 특성을 보여주며, 토양수분 관측지점에서 강우량 관측도 동시에 이루어지고 있다. 그림 6.3은 토양수분 계측기 매설 및 토양수분(강우) 계측지점의 전경을 보여준다. 용담댐 유역의 토지이용, 토양도 등 지형특성은 그림 6.4와 같다. 용담댐 유역은 산지가 70.1%, 농업지역 19.2% 그리고 도시지역이 2.6%를 각각 차지하고 본 연구기간(2007-2016)의 연평균 강우량은 1,299mm 그리고 유출고는 680mm로 나타났다.



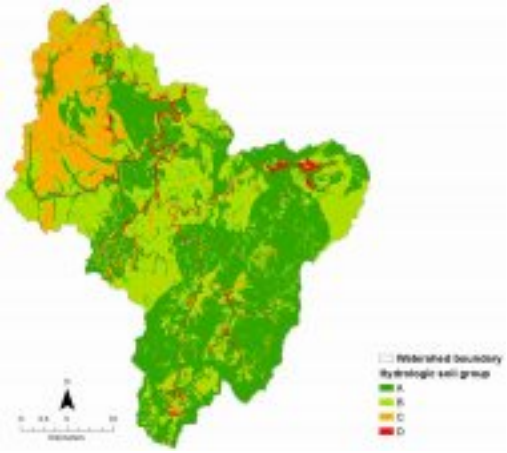
(a) Elevation



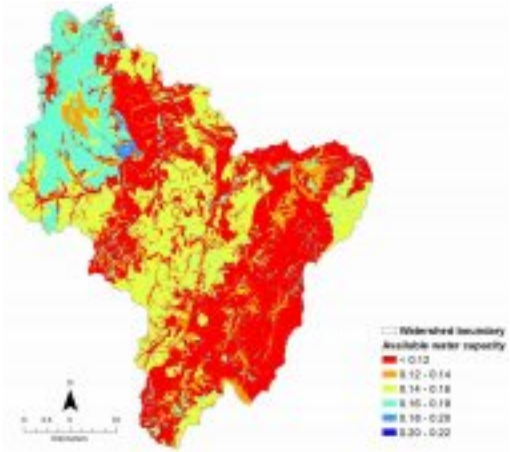
(b) Landuse classification



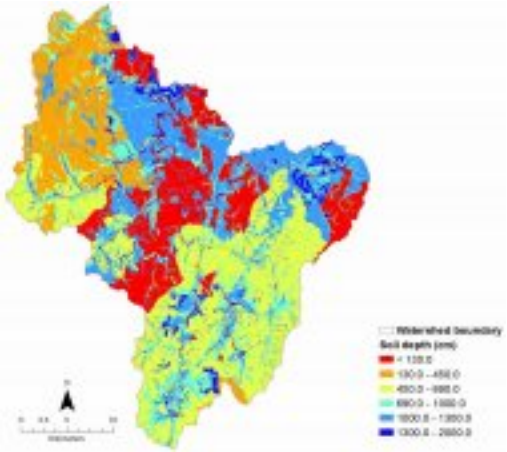
(c) Soil texture



(d) Hydrologic soil group



(e) Soil available water capacity



(f) Soil depth

그림 6.4 용담댐유역 지형특성 현황

6.2.2 연구방법

가. Tank Model

Sugawara(1979)가 제안한 탱크 강우-유출 모델은 결정론적(Determistic), 개념적(Conceptual) 그리고 연속(Continuous) 모형으로 정의할 수 있다. 다른 일반적인 개념적 강우-유출 모델과 유사하게 본 연구에서 사용된 탱크모형은 일련의 연속된 저장 탱크를 이용하여 강우에 반응하는 유역의 유출 특성을 묘사한다. 탱크 모형은 물리적 모형에 비해 비교적 단순한 구조로 적은수의 입력 자료로(강우, 증발산, 유량) 높은 수준의 강우-유출 모의가 가능하다. 이러한 이유로 국내에서는 학술분야 뿐만 아니라 실무에도 수자원분야 최상위 계획인 '수자원장기종합계획' 수립 시에도 탱크모형이 사용되었다. 탱크모형에서 탱크의 수와 각 탱크별 유출공의 수는 모의하고자 하는 목적과 유역의 특성에 따라 다르게 구성이 가능하다. 예를 들어, Basri (2013)는 논경지 특성을 고려하여 2단 탱크 모형으로 강우-유출 모의를 수행한 반면, Paik et al. (2005)은 4단 탱크를 사용하여 유역의 침투와 침루를 좀 더 상세히 모의하였다.

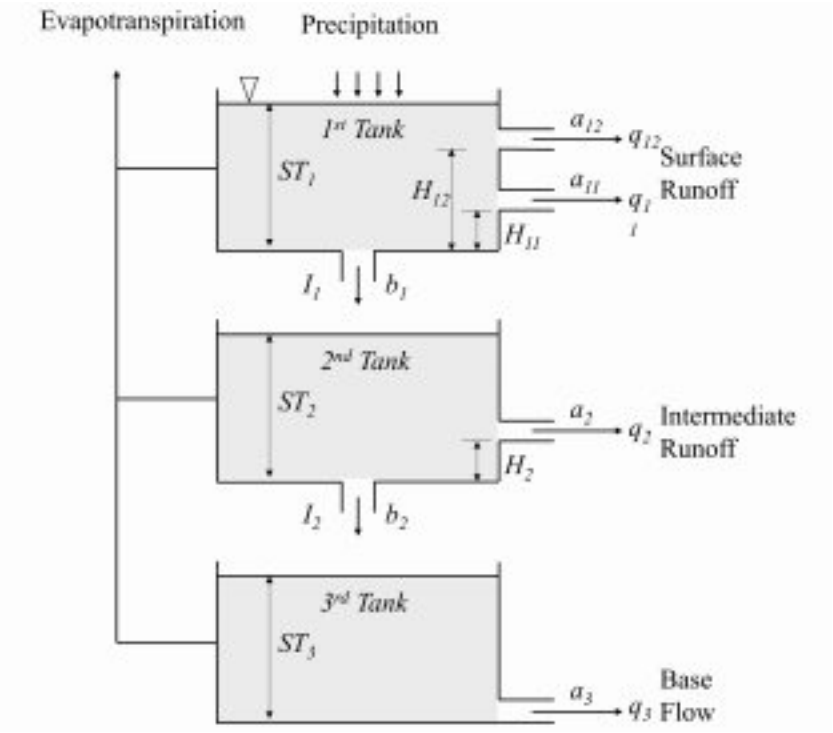


그림 6.5 3단 탱크모형 구조

본 연구에서 사용된 3단 탱크모형의 구조는 그림 6.5과 같이 연직으로 배열된 일련의 탱크와 각 탱크에 배치된 유출공으로 구성된다. 식 6.1-6.9 및 그림 6.5에서 보는 바와 같이 q_{11}과 q_{12}는 각각 1단 탱크에서의 측방 유출공을 의미하고, q_2(2번째 탱크)는 중간유출, q_3(최하단 탱크)는 기저유출을 모의하도록 고안되었다. 여기서 P, ET, I는 강우, 증발산 및 침투를 각각 의미한다. 본 연구에서 사용된 3단 탱크모형의 경우 강우는 1단 탱크에서만 Input 자료로 고려되며, 증발산은 3개의 탱크 모두에서 발생하는 것으로 고려하였다. 즉, 1단(최상단) 탱크에 저장된 수분이 증발산을 만족하기 충분하지 못

하면 2단 탱크를 통해 증발산량을 만족시키는 것으로 탱크모형의 실제증발산을(Actual evapotranspiration) 추정토록 알고리즘을 구축하였다. 또한, 1단과 2단 탱크에서의 수분 부족은 최하단에 있는 3단 탱크의 수위에도 영향을 미친다. 첫 번째 탱크는 지표유출(Surface runoff), 두 번째 탱크는 중간유출(Intermediate runoff) 그리고 최하단에 있는 탱크는 기저유출(Base flow)을 반영하여 모의토록 하였다. 본 연구에서 사용된 3단 탱크모형의 강우-유출 과정을 식으로 표현하면 식 6.1~6.9와 같다. 본 연구에서 탱크 모형을 포함해 이후에 설명될 탱크모형으로부터 유도된 상태변수와 수문요소를(강우, 위성 토양수분 등) 결합하기 위해 사용된 Support Vector Machine 기반의 강우-유출 모형 등 모든 모형은 Matlab을 이용하여 개발하였다.

1st Tank

$$\frac{dST_1}{dt} = RF - ET - q_{12} - q_{11} - I_1 \quad \text{수식 6.1}$$

$$\text{if } ST_1 > H_{12,} q_{12} = (ST_1 - H_{12}) \times a_{12} \text{ ; if } ST_1 \le H_{12,} q_{12} = 0 \quad \text{수식 6.2}$$

$$\text{if } ST_1 > H_{11,} q_{11} = (ST_1 - H_{11}) \times a_{11} \text{ ; if } ST_1 \le H_{11,} q_{12} = 0 \quad \text{수식 6.3}$$

2nd Tank

$$\frac{dST_2}{dt} = I_1 - I_2 - q_2 \quad \text{수식 6.4}$$

$$\text{if } ST_2 > H_{2,} q_{12} = (ST_2 - H_2) \times a_{12} \text{ ; if } ST_2 \le H_{2,} \; q_2 = 0 \quad \text{수식 6.5}$$

$$I_2 = ST_2 \times b_2 \quad \text{수식 6.6}$$

3rd Tank

$$\frac{dST_3}{dt} = I_2 - q_3 \quad \text{수식 6.7}$$

$$q_3 = ST_3 \times a_3 \quad \text{수식 6.8}$$

Total runoff

$$Q = q_{11} + q_{12} + q_2 + q_3 \quad \text{수식 6.9}$$

그림 6.6은 모형 수행 기간(2007-2016)의 연도별 강우량과 모형 검·보정 기간을 도시한 것이다. 강우-유출모형을 수행하기 위한 최적의 파라미터는 평년, 갈수년 및 풍수년을 모두 포함한 기간을 활용해서 Calibration 과정을 통해 결정하는 것이 추천된다. 본 연구에서는 탱크 모형의 파라미터를 튜닝하기 위한 Calibration 기간을 앞서 언급한 조건을 만족하는 2007~2013년으로, 나머지 2014~2016년을 Validation 기간으로 설정하고 모형의 검·보정 과정을 수행하였다. 또한, 탱크모형의 10개의 파라미터는 최적화 기법의 하나인 Standard Gradient-based Automatic Optimization(Bober, 2013) 기

법을 이용해서 최적화하였다. 모형 수행에 필요한 입력 자료인 강우량 자료는 K-water에서 제공하는 자료를 사용하였으며, 잠재증발산량은 FAO-56 Penman-Monteith 방법에 의거 기상청에서 생산하는 장수지점의 상대습도, 일평균 기온, 일조시간 등을 이용하여 계산하였으며, 강우량과 함께 모형의 입력 자료로 활용하였다.

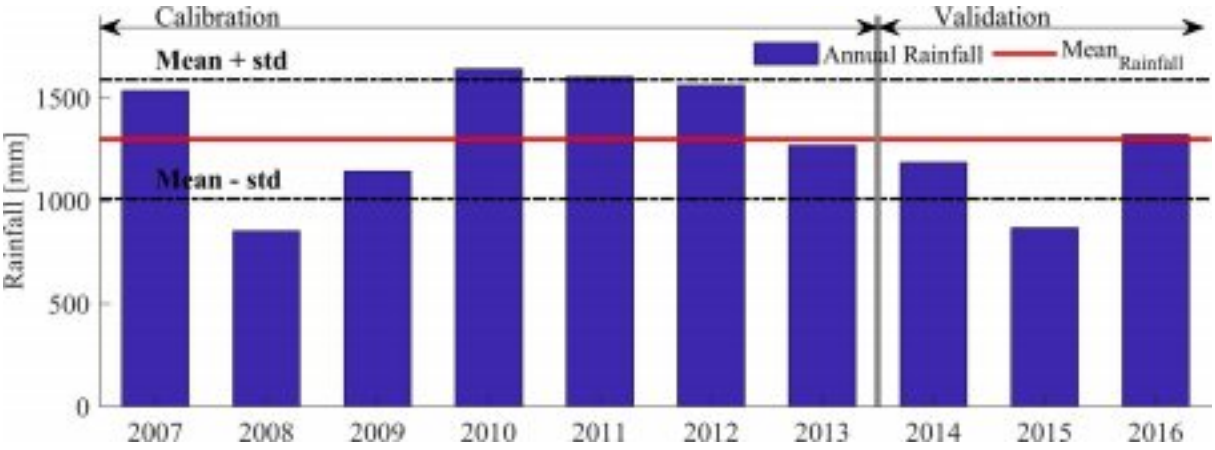


그림 6.6 분석기간 연도별 강우량 및 모형 검·보정 기간

나. Least Square Support Vector Machine (LSSVM)

Vapnik (1995)에 의해 개발된 Support Vector Machine(SVM)은 분류(Classification), 회귀(Regression) 및 군집(Clustering) 분석에 그 효용성이 높은 것으로 알려져 있으며, 최근에는 강우-유출 모형에도 적용된 사례가 있다(Okkan and Serbes, 2012; Raghavendra and Deka, 2014). 본 연구에서는 전통적인 SVM의 업그레이드된 버전이라고 할 수 있는 LSSVM 기법을 활용하여 유역의 강우-유출 과정을 모의하고자 하였으며, LSSVM 모형의 개념적 구조는 그림 6.7과 같다. 본 장에서는 LSSVM의 개념을 간단히 설명하고자 하며, 자세한 내용은 Suykens et al.(2002)에서 확인할 수 있다. $\{x_k, y_k\}_{k=1}^{N}$가 입력($x \in R^N$)과 출력($y \in R$) 자료를 가진 N개의 데이터 set이라 가정하면(여기서 R^N은 n-차원의 입력 및 출력자료의 백터 공간을 의미), LSSVM 모델은 식 6.10과 같이 나타낼 수 있다.

$$y(x) = w^T \varphi(x) + b \qquad \text{수식 6.10}$$

식 6.10에서 $\varphi(x)$는 feature map이라 정의하며, 입력 자료를 다차원의 feature space에 매칭 시킬 수 있다. w는 가중치(Weight vector), 그리고 b는 편향(Bias)을 의미한다. LSSVM 기법을 이용한 회귀분석에서 최적해는 식 6.10와 같이 산정된다.

$$\text{Minimize} : \frac{1}{2}\omega^T\omega + \frac{1}{2}\sum_{k=1}^{N} e_k^2 ,$$

$$\text{Subject to} : y(x) = \omega^T \varphi(x_k) + b + e_k, \; K = 1, ..., N \qquad \text{수식 6.10}$$

식 6.10은 Lagrange multiplier를 이용하면 식 6.11과 같이 표현된다.

$$y(x) = \sum_{k=1}^{N} a_K K(x, x_k) + b \qquad \text{수식 6.11}$$

여기서 a_k는 Lagrangian mulitiplier이며, $K(x_k, x_l)$은 kernel 함수이다.

$$K(x, x_k) = \exp\left\{-\frac{(x_k - x_l)^T (x_k - x_l)}{2\sigma^2}\right\}, \; K, l = 1, ..., N \qquad \text{수식 6.12}$$

LSSVM 기법은 커넬 함수의 선택에 의해 모델의 신뢰도에 크게 영향을 받는다. 일반적으로 사용되는 커넬 함수는 Linear, Polynomial, Sigmoid 그리고 Radial Basis Function (RBF) 있으며 RBF가 다른 커넬 함수에 비해 적은 수의 파라이터로 우수한 결과를 내는 것으로 알려져 있으며 본 연구에서는 RBF 커넬 함수를 사용하였다.

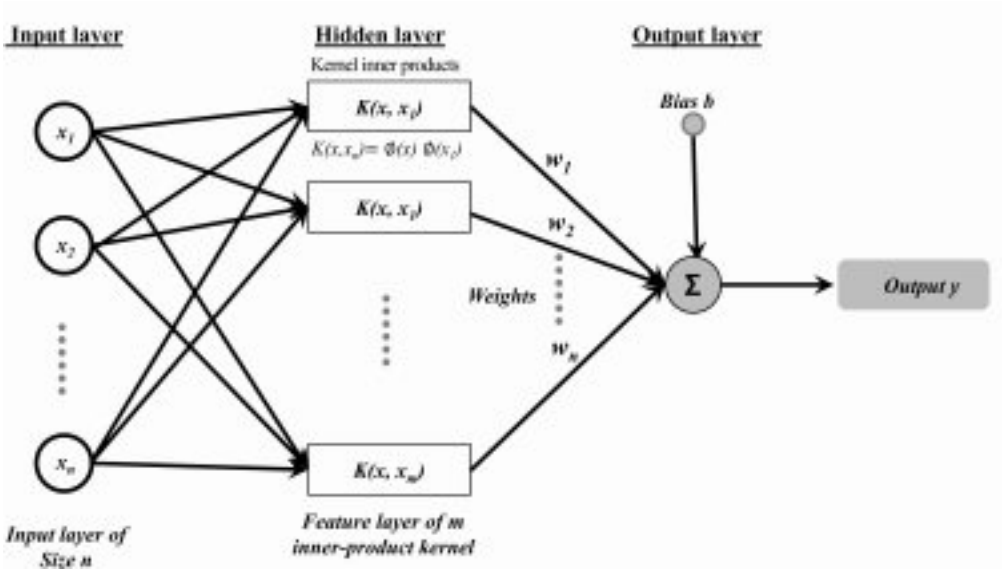


그림 6.7 LSSVM 기법의 개념적 구조도

다. Tank-LSSVM hybrid 모델



그림 6.8 Tank-LSSVM 모형의 구조 및 수행절차

Tank 모형에서 유도된 상태 변수를(ST_1, ST_2, ST_3) LSSVM 회귀모형의 독립변수로 활용하여

hybrid 강우-유출 모형을 개발하였으며, 본 연구에서 개발된 Tank-LSSVM 강우-유출 모형의 구조 및 모형 개발 절차는 그림 6.8과 같다.

Machine learning 기반의 강우-유출모형에 있어서 입력 자료의 선택은 매우 중요한 문제이며, 본 연구에서는 강우, 탱크모델의 상태변수 그리고 위성 토양수분 자료를 잠재적 모델 입력 자료로 구성하여 최적의 조합을 찾고자 하였다. 특히, 본 연구에서 강우-유출모형의 입력 자료로 사용된 위성 토양수분 자료를 활용한 강우-유출 모형은 미계측 유역에 적용성이 높을 것으로 기대된다. 본 연구에서 사용된 토양수분 자료는 European Space Agency(ESA)에서 제공하는 자료를 사용하였으며, ESA는 여러 종류의 위성에서 제공하는 토양수분 자료를 결합해서 토양수분 데이터를 생산·배포하고 있다. 표 6.2는 ESA 에서 제공하는 ESA CCI 토양수분 자료의 버전별 특성을 보여준다. 본 연구에서는 4.2버전의 ESA CCI 토양수분 자료의 공간 해상도는 0.25°로 Active, Passive 및 Active 및 Passive 센서가 결합된 3가지 형태의 자료가 가용하다. 본 연구에서는 Active와 Passive 센서를 조합해서 생성한 토양수분 자료의 시간 해상도 및 신뢰도가 가각의 센서를 개별로 사용한 토양수분 자료보다 높은 점을 감안 Active 및 Passive 센서로부터 관측된 토양수분 데이터를 사용하였다.

표 6.2 ESA CCI 토양수분자료 특성

	Version number			
	V1	**V2.2**	**V3.2**	**V4.2**
Release date	2012/6	2014/7	2017/2	2017/7
Products provided	Combined	Active, Passive, Combined	Active, Passive, Combined	Active, Passive, Combined
Scatterometer products	ERS-1/2 AMI WS, MetOp-A ASCAT	ERS-1 AMI WS, ERS-2AMIWS, MetOp-AASCAT	ERS-1/2 AMI WS, ERS-2 AMI WS, MetOp-A + B, ASCAT	AMI-WS, MetOp-A + B, ASCAT
Radiometer products	SMMR, SSM/I, TMI, AMSR-E	SMMR, SSM/I, TMI, AMSR-E, WindSat, AMSR2	SMMR, SSM/I, TMI, WindSat, AMSR-E, AMSR2,SMOS	SMMR, SSM/I, TMI, AMSR-E, WindSat,AMSR2,and SMOS
Time period covered	1978/11–2010/12	1978/11–2014/12 (PASSIVE and COMBINED); 1991/08–2014/12 (ACTIVE)	1978/11–2015/12 (PASSIVE and COMBINED); 1991/08–2015/12(ACTIVE)	1978/11–2016/12

라. Root-zone ESA CCI 토양수분

위성을 활용한 토양수분의 관측에 있어서 주목할 제약사항은 위성에서 관측 가능한 토양수분의 깊이가 위성별로 약간의 차이가 있지만 지표에서 약 5cm까지라는 것이다. 이러한 얕은 관측심은 토양수분 정보를 이용해서 수문 모형에 적용하기에 한계가 있으며, Root zone 까지의 토양수분 정보가 강우 발생 시 유역의 유출 반응을 해석하는데 더 유용하다 할 수 있다. 본 연구에서는 위성에서 관측된 토양수분(표층 토양수분)이 유역 전반의 토양수분을 대표 하는데 한계가 있음을 감안하여, 표층의 토양수분으로부터 Root-zone 까지의 토양수분은 식 6.13-6.14과 같이 filtering 기법을 활용하여 유도하였으며, 이렇게 전 처리된 토양수분 지수를 이후 강우-유출 모형의 입력 자료로 활용하였다.

$$SWI_n = SWI_{n-1} + K_n\left[SSM_{t_n} - SWI_{n-1}\right] \quad \text{수식 6.13}$$

여기서 SWI_n 와 SSM_{t_n}은 각각 시간 t_n에서의 토양수분지수(SWI)와 ESA CCI 토양수분을 의미한다. 파라미터 K는 0과 1사이에서 식 6.14를 이용해서 산정할 수 있다.

$$K_n = \frac{K_{n-1}}{K_{n-1} + e^{\frac{-(t_n - t_{n-1})}{T}}} \qquad \text{수식 6.14}$$

Root-zone 토양수분 시계열 값은 T 값을 증가시키면서 탱크모델에서 3개의 탱크 평균값과 위성 토양수분 값과의 상관계수가(r) 최대가 되는 값을 찾아 Root-zone 토양수분 시계열을 구축하였다. 또한, 본 연구에서 사용된 모형의 적합도(goodness-of-fit)는 표 6.3과 같이 Nash-Sutcliffe efficiency(NSE), 결정계수(Coefficient of determination, R^2) 및 평균제곱근오차(Root mean square error, RMSE) 3개의 평가지표를 이용하여 모형의 수행 능력을 비교·평가하였다. 위 3개의 평가지표는 수문학에서 일반적으로 사용되는 모형의 수행능력을 평가하는 지표들이며, 수자원계획에서 중요시되는 저유량(Low flow)의 모의 능력을 평가하기 위해 초과확률 70-100% 유량에 대해 RMSE Q70 지표를 이용하여 본 연구에서 제시된 모형들의 모의 능력을 비교·평가 하고자 하였다.

표 6.3 모형 평가 지표(O: 관측값, E 모의값, $\overline{O}$: 관측값 평균, $\overline{E}$: 모의값 평균)

Performance Metrics	Equations	Range	Optimal value
Nash-Sutcliffe efficiency (NSE)	$NSE = 1 - \frac{\sum_{i=1}^{n}(O_i - E_i)^2}{\sum_{i=1}^{n}(O_i - \overline{O})^2}$	-∞ ~ 1	1
Coefficient of determinant (R^2)	$R^2 = 1 - \frac{\left[\sum_{i=1}^{n}(O_i - \overline{O})\cdot(E_i - \overline{E})\right]^2}{\sum_{i=1}^{n}(O_i - \overline{O})^2 \sum_{i=1}^{n}(E_i - \overline{E})^2}$	0 ~ 1	1
Root mean square error (RMSE)	$SE = \sqrt{\frac{\sum_{i=1}^{n}(O_i - E_i)^2}{n}}$	0 ~ ∞	0

6.3 결과 및 토의

6.3.1 탱크모형을 이용한 강우-유출 모의

탱크모형은 비교적 작은 수의 입력 자료와 파라미터로 유출을 모의하는 집중형 강우-유출 모형이다. 본 연구에서는 앞서 언급하였듯이, Calibration 기간에 최적화 기법을 이용 탱크모형을 구성하는 10개 파라미터를 결정하였으며, 이렇게 산정된 파라미터값을 모형 Validation 기간 파라미터를 적용하여 탱크모형의 유출 모의 능력을 검증하였다. 모형의 Calibration시 도출하기 위한 최적의 파라미터 Set은 standard gradient-based automatic optimization 기법을 적용하여 추출할 수 있도록 모형을 구성하였으며, 파라미터 최적화시 목적함수는 NSE로 하였다. 모형 최적화시 Matlab의 내장함수

인 'fmincon'을 이용 하였으며, 본 연구에 적용된 최적화 기법에 대한 좀 더 자세한 내용은 https://www.mathworks.com/help/optim/ug/fmincon.html에서 확인할 수 있다. 탱크모형의 파라미터별 최소·최대치 구간과 본 연구에서 도출된 최적의 파라미터 값은 표 6.4와 같다.

그림 6.9는 탱크모형 수행 결과 모의된 유량과 관측 유량을 도시한 것으로, 모형의 Calibration 및 Validation 기간 모두 우수한 결과를 보여준다 (Calibration 기간 : NSE = 0.92, R^2 = 0.92, RMSE = 20.18, RMSE Q70 = 3.74, Validation 기간 : NSE = 0.81, R^2 = 0.83, RMSE = 14.72, RMSE Q70 = 3.12). 그림에서 보듯이 Tank 모형은 Validation 기간에 Calibration비해 전체적으로 낮은 모의 능력을 보였으며 복잡한 강우-유출의 과정을 묘사하는데 어느 정도 한계가 있음을 알 수 있다. 또한, 관측 유량과 모의 유량의 차이는 고유량(High flow)에 비해 저유량(Low flow)에서 확연히 볼 수 있으며, 이러한 저유량에서 탱크 모형의 강우에 반응하는 한계는 본 연구에서 머신러닝 기법을 기반으로 기존의 모형과 결합된 Hybrid 강우-유출모형 개발의 동기가 되었다.

표 6.4 3단 탱크모형의 파라미터 범위 및 본 연구에서 도출된 파라미터 값

Parameter		a11	a12	a2	a3	b1	b2	b3	h11	h12	h20
Range	Min.	0.08	0.08	0.03	0.00	0.10	0.01	0.00	5.00	20.00	0.00
	Max.	0.50	1.00	1.00	0.03	0.50	0.35	0.11	60.00	150.00	100.00
Obtained value		0.13	0.33	0.71	0.02	0.14	0.07	0.01	10.72	62.94	35.14

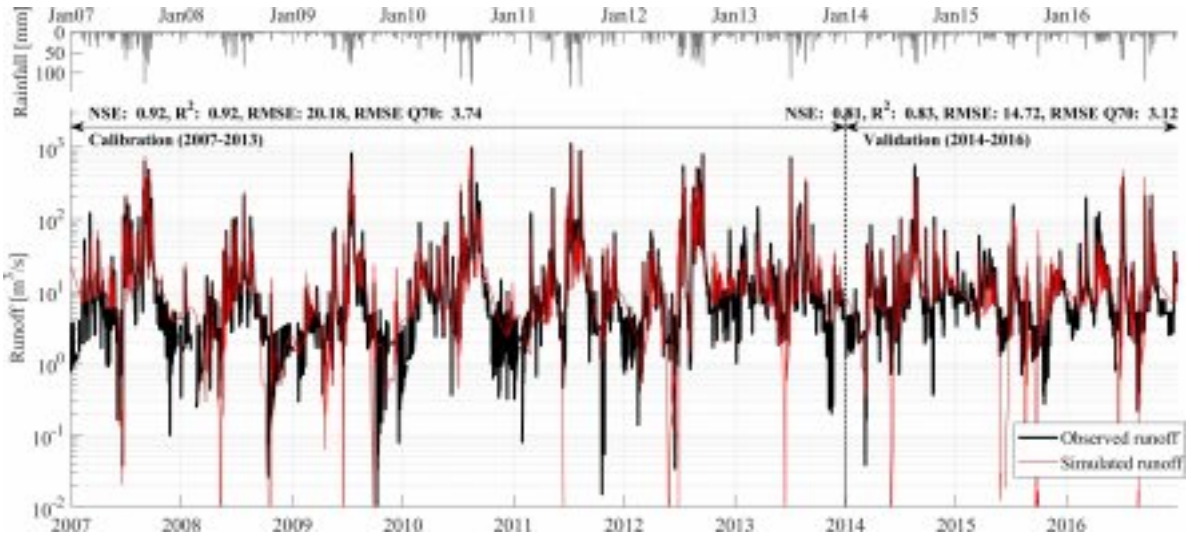


그림 6.9 탱크모형 수행결과(2007~2016)

탱크모형의 각 탱크(1st - 3rd 탱크)에서 Storage 변화와 용담 유역의 관측 토양수분의 상관관계를 살펴보았으며, 본 연구에서는 그림 6.11에서 보듯이 6가지의 각기 다른 탱크 Storage의 조합과 관측 토양수분 값의 상관관계를 검토하였다. 가용한 관측치의 자료 기간의 제약으로 2014-2016년 3개년간의 모의 값과 실측값을 비교하였으며, 교차상관(Cross-correlation) 분석을 통해 상관계수뿐만 아니라 두 시계열 데이터간의 시간 지체된 상관 관계도 동시에 분석하였다 (그림 6.12).

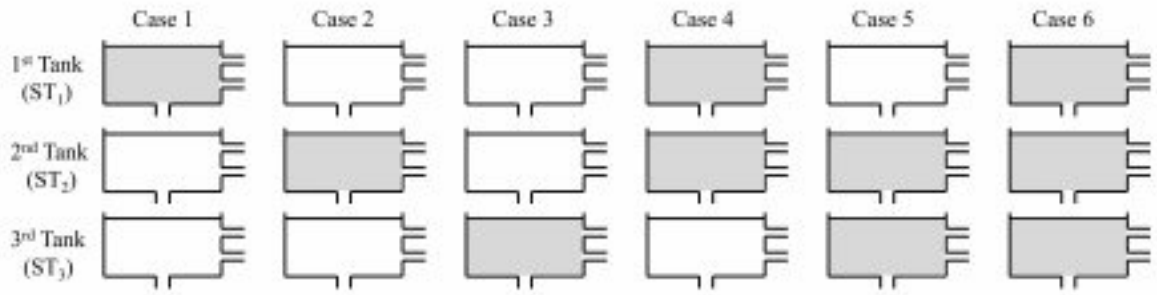


그림 6.10 6가지 탱크 조합(회색으로 채워진 탱크는 관측 토양수분과 비교 시 사용된 탱크를 의미)

그림 6.11에서 보듯이 탱크모형 모의 결과에서 도출된 탱크 상태변수(Tank Storage)와 관측 토양수분과는 높은 상관관계가 있음을 보여주며, 시간 지체를 미 고려 시(Lag = 0) 가장 높은 상관관계는 두 번째 탱크로(ST2) 분석되었으며, 이때 상관계수(r)는 0.77을 보였으며, 가장 낮은 상관계수는 Case 3로(3rd 탱크) 나타났다. 교차 상관분석 결과에서 보듯이 탱크모형의 각 탱크는 토양수분의 시간적 변동성을 비교적 잘 반영함을 알 수 있다. 탱크 모형의 탱크 상태변수를 조합(Case4-6) 해서 평가한 결과, Case 2(2nd 탱크)의 결과보다 약간 높거나 낮은 상관관계를 보인다. Case 2의 경우에는 lag-1에서 가장 높은 상관계수 0.78을 보이며, Case 3의 경우에는 lag-11에서 가장 높은 상관관계를 보이는 것으로 분석되었다. 이는 3rd 탱크가 기저 유출을 잘 반영하여 지체시간이 상대적으로 큰 것으로 판단된다. 위에서 도출된 교차상관분석 결과로부터 탱크모형에서 도출된 상태변수는 유역의 토양수분의 시간적 변화를 반영하는 대리변수(Proxy Variable)로 사용될 수 있음을 보여준다.

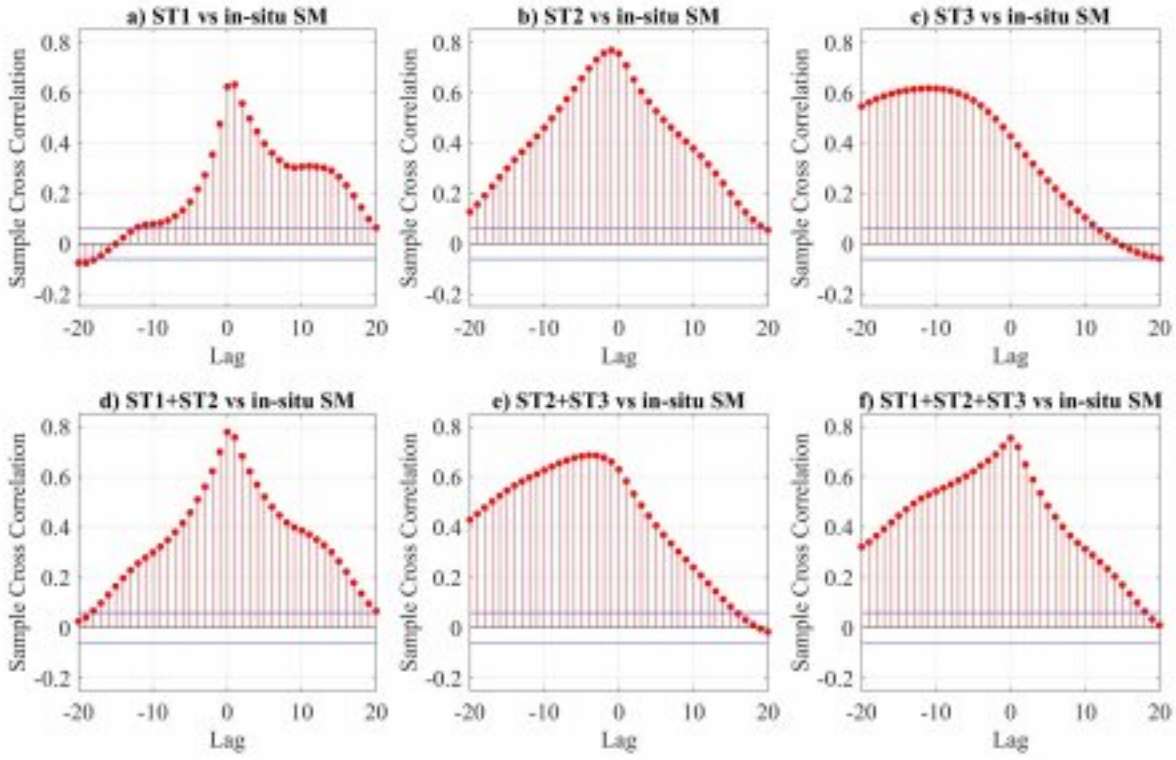


그림 6.11 탱크모형의 상태변수와 관측(in-situ) 토양수분과의 교차상관(Cross-correlation) 결과

6.3.2 LSSVM 및 Tank-LSSVM 모형

가. 모델 입력자료 검토

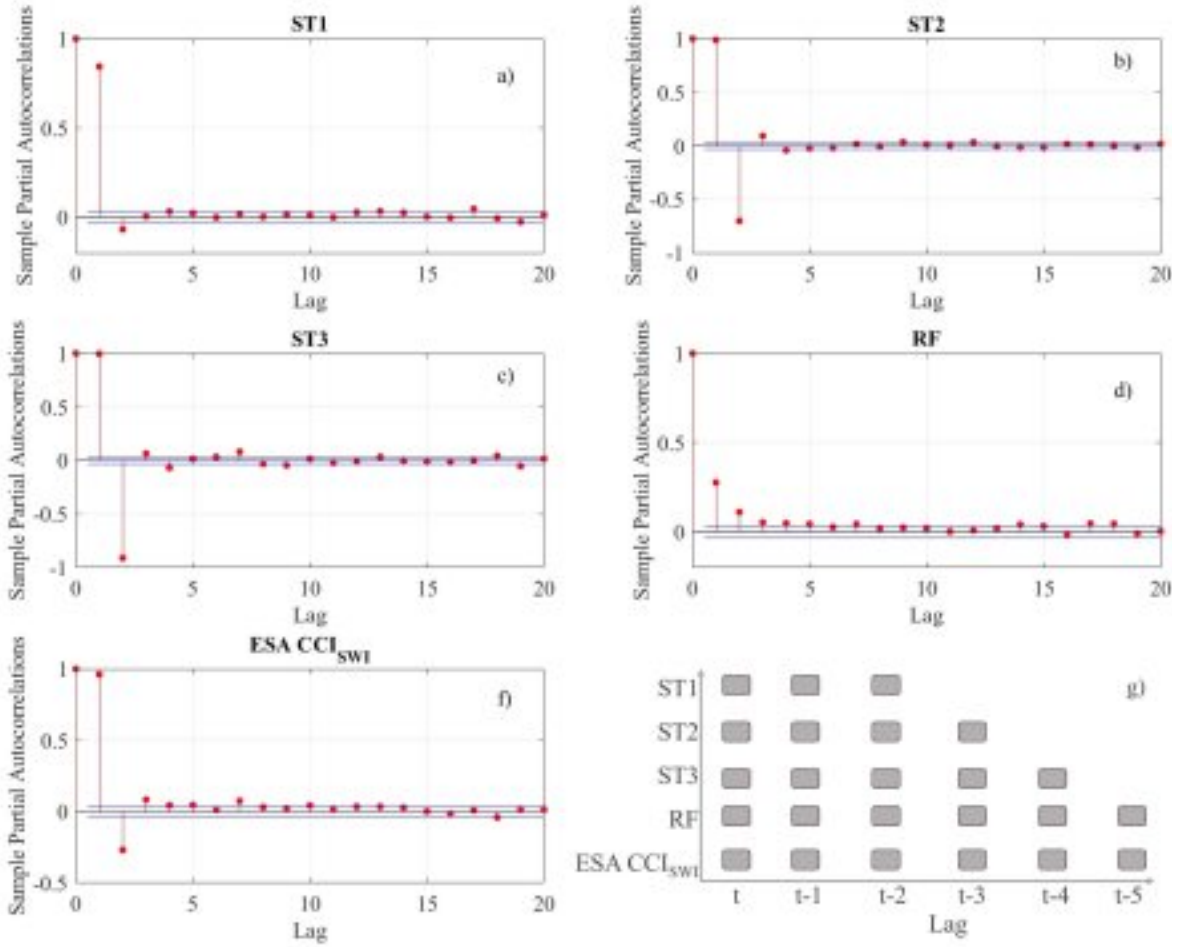


그림 6.12 모델 입력 자료의 부분자기상관(Partial autocorrelation) 분석결과(a-e) 및 LSSVM 모델에서 고려된 지체시간(f). 여기서 STn, RF 및 ESA CCI_{SWI}는 탱크모델에서 n-th 탱크 Storage, 강우(Rainfall) 및 Root-zone ESA CCI 토양수분자료를 의미한다.

머신러닝(Machine learning) 기반의 수문모형에서 모델의 수행능력은 모델 학습(Training)을 위한 입력 자료의 선정과 채택된 입력 자료의 지체시간 선정에 민감하게 반응한다(Bray and Han, 2004; Yu et al., 2006). 본 연구에서는 강우 외에 위성에서 획득한 토양수분 자료 및 탱크모형에서 유도된 탱크 상태변수를 LSSVM 강우-유출 모형 및 Tank-LSSVM 모형에 입력 자료로 사용되었고, 각 입력 자료의 지체시간 또한 고려하였다. 여기서 LSSVM 모형은 입력 자료로 강우와 위성 토양수분 자료를 사용한 모형을 의미하며, Tank-LSSVM 모형은 LSSVM 모형을 탱크모형의 상태변수와 결합된 Hybrid 강우-유출 모형을 의미한다. 머신러닝 기반의 회귀 모형에서 선정된 입력 자료들의 최적 지체시간 선정을 위한 절차는 정형화된 방법이 없으며 시행착오법(Trial and error)을 통해 최적의 지체시간을 결정하는것이 일반적이다 (Bray and Han, 2004). 본 연구에서는 부분 자기상관 (Partial autocorrelation function, PACF) 분석을 통해 시계열 입력 데이터와 그 입력 데이터의 과거값과의 선형적 상관 관계를 분석하여 자료의 주기성을 분석하여 입력자료별 지체시간을 결정하는데 간접적

으로 이용하였다(그림 6.12). 즉, 부분자기상관분석 결과를 기초로 하여 LSSVM 모델을 구성하는 각 입력 자료의 지체시간의 결정하였다. 예를 들어, ST1의 경우에는 통계적으로 유의미한 자기상관이 lag-2까지 관찰되었고, 자기부분상관의 결과가 lag-3이하는 95% 신뢰도 기준으로 통계적으로 유의미하지 않다. 따라서 ST1 입력 변수는 lag-0 – lag-2 까지 고려하여 최적의 모형을 구축하는데 이용되었고, 다른 입력 변수 또한 같은 절차로 모델을 구성하는 입력자료 구축시 고려되는 지체시간을 결정하였다.

나. LSSVM(Least square support vector machine) 기반 강우-유출 모델

본 장에서는 머신러닝을 이용한 데이터 기반의 강우-유출모형을 개발하고 모의 능력을 평가하였으며, 탱크모형에서 유도된 상태변수(ST_n)를 제외한 강우(P_{t-n}) 및 위성 토양수분 자료를 ($ESACCI_{SWI}(\theta_{t-n})$)와 각 변수의 지체된 자료를 이용하여 LSSVM 강우-유출 모형을 개발하였다. 모형 구축에 앞서 입력 자료는 학습(Training phase)과 데스트(Testing phase)의 두 그룹으로 구분하였으며, 탱크모형과 동일하게 2007~2013년의 자료를 학습을 위한 자료로 활용하였고, 나머지 기간(2014-2016)의 자료는 학습 과정에서 도출된 파라미터 값의 모델 적용(범용)성을 검토하기 위한 테스트용 데이터로 사용하였다. 또한, 본 모형에서 사용된 종속 및 독립 변수는 모형에 적용 전에 식 6.15를 이용 표준화(Normalization)한 이후에 사용하여, 매우 크거나 매우 작은 값에 의해 결과치가 왜곡되는 오류를 방지하고자 하였다.

$$Z_i = \frac{x - \bar{x}}{S} \qquad \text{수식 6.15}$$

여기서, Z_i는 표준화된 값을 의미하며, S는 표준편차 그리고 $\bar{x}$는 독립(강우 및 위성 토양수분 등) 및 종속(유량) 변수의 평균을 의미한다. LSSVM 기반의 강우-유출 모델은 우선 강우량 자료를 유일한 입력 자료로 구축하였으며, 이후 위성에서 취득한 토양수분 자료의 독립변수로서의 가용(효용)성을 확인하고자 강우량 자료에 위성 토양수분 자료를 더하여 강우-유출 모형을 구축하였다. 이는 많은 수문기상 변수 중 강우와 토양수분의 시간에 따른 변동성과 상태가 유역의 유출 과정에서 중요한 역할을 한다는 가정으로 이 두 변수를 입력 자료로 선정하였다. 표 6.5는 강우(p)와 위성 토양수분자료(θ)를 입력 변수로 강우-유출 모형을 구축·모의한 결과를 보여준다. Machine learning 기반의 모형에 있어서 과접합 (Overfitting)이 우려되는 문제 중에 하나임을 감안하여, 본 연구에서는 Training 기간보다 Testing 기간의 결과를 중심으로 토의하고자 한다.

표 6.5의 SV1-SV5 모델 수행 결과를 보면, NSE 값이 SV1의 경우 0.40 에서 SV5 모델의 경우 0.68까지 강우의 지체시간을 추가적으로 고려할 경우 모델 수행능력이 향상됨을 볼 수 있다. NSE 값과 같은 추세의 모의 결과는 R^2 및 RMSE에서도 볼 수 있다. SV6-SV9 모델은 강우 자료와 위성 토양수분 자료를 함께 사용하여 강우-유출 모델을 구축하였으며, 강우 자료만을 입력 자료로 사용했을 때보다 향상된 모의 결과가 도출되었다. SV6-SV9의 NSE 값은 0.69에서 0.73으로 개선되었으며, R^2, RMSE 및 RMSE Q70 평가 기준에서도 모형 수행능력이 향상됨을 볼 수 있다. 강우와 위성으로부터 획득한 토양수분 정보를 입력 자료로 활용해서 본 연구에서 구축한 LSSVM 기반의 강우-유출 모형은 Kalin et al. (2010)이 제안한 강우-유출 모형의 모의 능력 평가 기준에 의하면 매우 우수한 것으로 평가된다 (Kalin et al. (2010)의 모델 평가 기준 : Very good: NSE $\geq$0.7; Good: 0.5 $\leq$ NSE < 0.7;

Satisfactory: 0.3 ≤ NSE < 0.5; Unsatisfactory: NSE < 0.3). 그러나 RMSE Q70 결과를 볼 때 저유량을 모의하기에는 한계가 있음을 보인다. 즉, 위성에서 취득한 토양수분 자료가 시·공간적인 유역의 토양수분 변화를 대표하기에는 제한적이라 판단된다.

표 6.5 입력 자료의 조합에 따른 LSSVM 모델 수행 결과

Model	Input combinations	Training (2007-2013)				Testing (2014-2016)			
		NSE	R^2	RMSE	RMSE Q70	NSE	R^2	RMSE	RMSE Q70
SV1	$P_{(t)}$	0.60	0.60	44.72	10.40	0.40	0.49	26.02	9.86
SV2	$P_{(t)},P_{(t-1)}$	0.84	0.84	28.21	6.73	0.45	0.61	24.81	5.42
SV3	$P_{(t)},\cdots,P_{(t-2)}$	0.88	0.88	24.88	5.11	0.57	0.65	22.04	4.49
SV4	$P_{(t)},\cdots,P_{(t-3)}$	0.89	0.89	23.01	4.44	0.62	0.70	20.77	3.99
SV5	$P_{(t)},\cdots,P_{(t-4)}$	0.91	0.91	21.33	4.00	0.68	0.75	18.91	3.86
SV6	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)}$	0.91	0.91	21.24	3.18	0.69	0.77	18.80	4.79
SV7	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)},\theta_{(t-1)}$	0.91	0.91	20.74	3.29	0.69	0.77	18.62	5.02
SV8	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)},\cdots,\theta_{(t-2)}$	0.92	0.92	19.53	3.12	0.72	0.79	17.90	4.93
SV9	$P_{(t)},\cdots,P_{(t-4)},\theta_{(t)},\cdots,\theta_{(t-3)}$	0.92	0.92	19.33	2.98	0.73	0.81	17.51	4.75

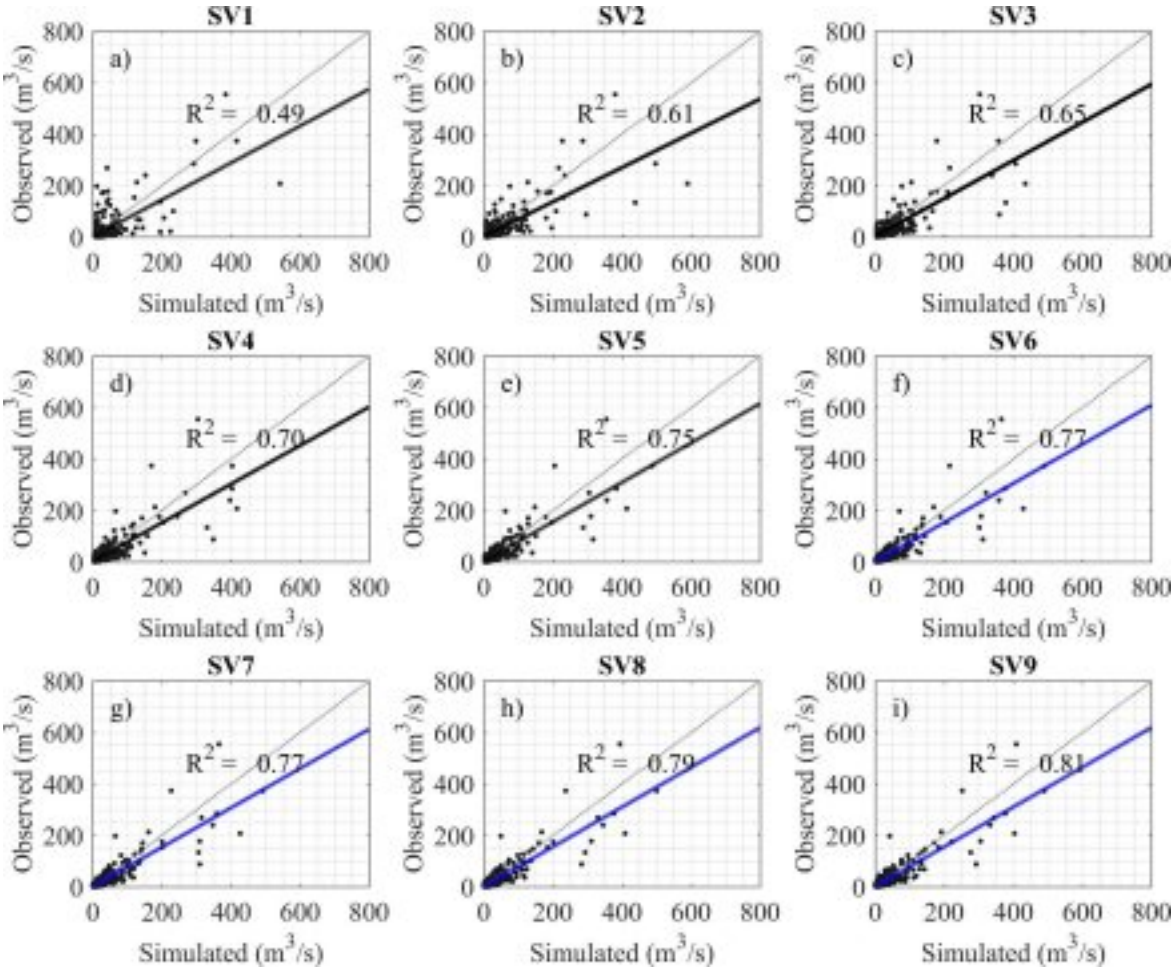


그림 6.13 Testing 기간의 SV1-SV9 모델 수행결과

다. Tank-LSSVM 모델

본 장에서는, 탱크 모델에서 유도된 상태변수와 머신러닝의 회귀분석 모형의 하나인 LSSVM 모델을 이용해서 Hybrid 형태의 강우-유출 모델을(Tank-LSSVM) 구축하였으며, 입력 자료로 탱크모형의 상태변수(STn)와 더불어 강우(p) 및 위성 토양수분(θ) 데이터도 함께 사용하였다. 입력 변수의 조합에 따른 모형 수행 결과는 표 6.6과 같다. HY1-HY4 모델은 시간 지체(Time lag)를 고려하지 않은 반면, HY5-HY-9 모델은 앞서 분석한 자기상관분석 결과를 반영하여 시간 지체를 고려하여 입력 자료를 구성하였다. LSSVM 모델과 달리 시간 지체를 고려 시 모형 수행능력의 개선은 미미하거나 거의 없는 결과를 보였다. 이는 탱크모형에서 유도된 상태변수 자체가 유역의 토양수분의 변화를 높으 수준으로 모의하기 때문에 다른 입력 변수들은 시간 지체를 고려한 효과가 상대적으로 약해진 결과로 판단된다. HY1 모델은 최상단의 탱크만을 고려하였으며, HY2 및 HY3 모델은 두 번째 및 세 번째 탱크를 각각 고려하였다. HY4 모델은 HY3 모델에 위성으로부터 취득한 토양수분자료의 강우-유출 모형에 기여도를 평가하고자 ESA CCI_{SWI} 자료를 추가하여 모델을 구성하였다.

표 6.6 입력 자료의 조합에 따른 Tank-LSSVM 모델 수행 결과

Model	Input combinations	Training (2007-2013)				Testing (2014-2016)			
		NSE	R^2	RMSE	RMSE Q70	NSE	R^2	RMSE	RMSE Q70
Tank		0.92	0.96	20.18	3.74	0.81	0.91	14.72	3.12
HY1	$P_{(t)}$,$ST1_{(t)}$	0.92	0.96	19.74	4.19	0.75	0.80	16.63	3.11
HY2	$P_{(t)}$,$ST1_{(t)}$,$ST2_{(t)}$	0.93	0.96	18.49	2.99	0.76	0.80	16.52	2.67
HY3	$P_{(t)}$,$ST1_{(t)}$,$ST2_{(t)}$,$ST3_{(t)}$	0.95	0.97	16.24	2.50	0.85	0.86	12.91	2.13
HY4	$P_{(t)}$,$ST1_{(t)}$,$ST2_{(t)}$,$ST3_{(t)}$,$\theta_{(t)}$	0.94	0.97	17.43	2.34	0.85	0.85	12.96	2.23
HY5	$P_{(t)}$,$P_{(t-1)}$,$ST1_{(t)}$	0.92	0.96	19.87	4.40	0.71	0.77	17.93	3.11
HY6	$P_{(t)}$,$ST1_{(t)}$,$ST1_{(t-1)}$,$ST2_{(t)}$,$ST3_{(t)}$	0.93	0.96	18.75	2.94	0.84	0.85	13.38	2.19
HY7	$P_{(t)}$,$ST1_{(t)}$,$ST2_{(t)}$,$ST2_{(t-1)}$,$ST3_{(t)}$	0.93	0.96	18.87	2.99	0.85	0.85	13.18	2.34
HY8	$P_{(t)}$,$ST1_{(t)}$,$ST2_{(t)}$,$ST3_{(t)}$,$ST3_{(t-1)}$	0.93	0.96	18.97	2.93	0.85	0.85	13.13	2.39
HY9	$P_{(t)}$,$ST1_{(t)}$,$ST2_{(t)}$,$ST3_{(t)}$,$\theta_{(t)}$, $\theta_{(t-1)}$	0.93	0.96	18.98	2.81	0.85	0.85	13.14	2.49

본 연구에서 개발한 Tank-LSSVM 모델의 강우-유출 모의 수행 능력은 Training 및 Testing 기간 모두 NSE 기준 “Very Good”으로 평가되었고, LSSVM 모델 및 Tank 모델과 비교해서도 Tank-LSSVM 모델이 개선된 강우-유출 모의 결과를 보여준다. HY2 모델은 HY1 모델과 비교하여 특히 저유량 (RMSE Q70)을 모의하는데 유의미한 개선된 결과를 보였다 (Tank 모델: 3.12, HY2 모델: 2.67). 이러한 결과를 볼 때 Tank-LSSVM 모델에서 두 번째 탱크에서 유도된 중간유출을 반영하는 상태변수(ST2)가 강우-유출 과정을 모의시 중요한 역할을 함을 알 수 있다. HY3 모델은 HY2 모델에 최 하단 탱크에서 유도된 상태변수(ST3)를 입력 데이터로 추가하며 모델을 구축하였으며, 저유량 부분에서 더욱 향상된 결과를 얻을 수 있었다 (RMSE Q70 : 2.13). HY3 모델 수행 결과로 볼 때, 세 번째 탱크의 상태변수(ST3) 또한 기저유량의 대리변수로써 저유량 부분을 모의시 중요한 변수라 판단된다. Tank-LSSVM 모형의 모의 결과는 그림 6.14와 같으며, 그림에서 보듯이 선형 회귀분석 결과로부터 HY4 모델은 강우, 탱크 모델의 상태변수 및 위성에서 획득한 토양수분 자료를 이용해서 모델

을 구축하였으며, 약 6% 정도 관측유량 대비 저평가 하는 것으로 나타났으며 (y=0.94x + 0.5), 탱크 모형보다 개선된 모의결과를 보인다(그림 6.14d). 그러나 위성 토양수분자료를 고려하지 않은 HY3 모델과 비교해서 유의미한 개선된 결과를 보여주지는 못한다. 이는 유역에서의 토양수분의 시간적 변화가 탱크모형에서 도출되는 토양수분의 시계열자료로 대표가 되기에 위성 자료의 역할이 상대적으로 미미하여 나타난 결과로 판단된다.

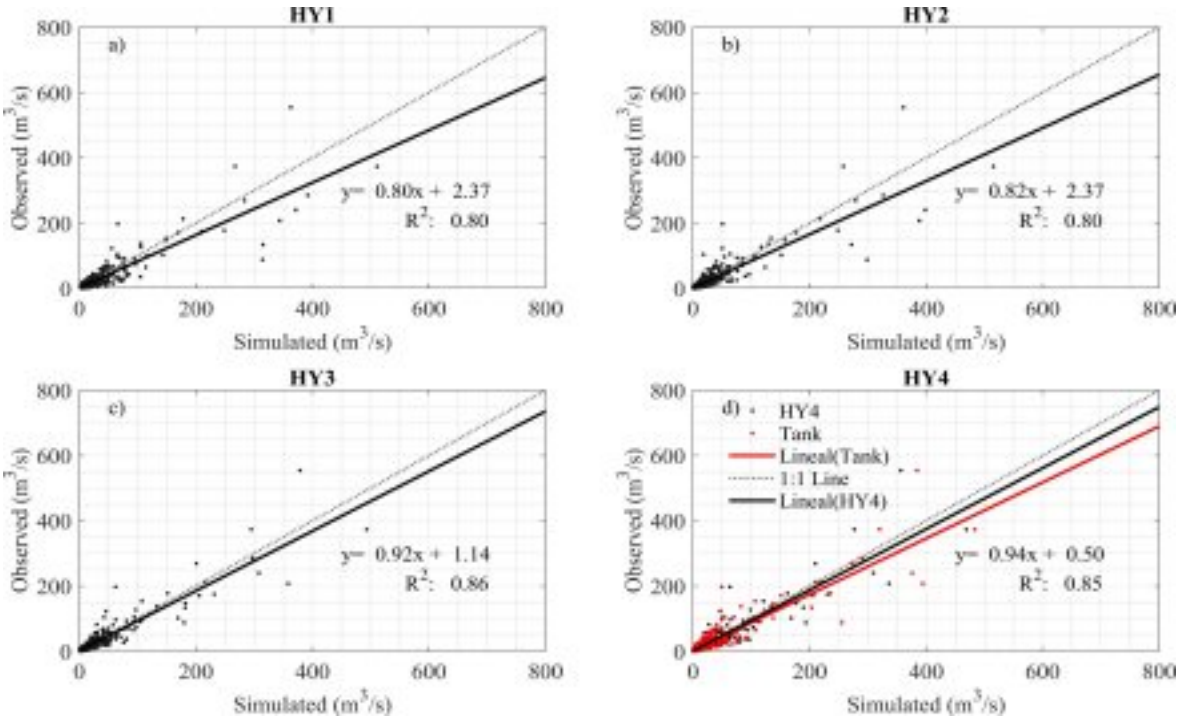


그림 6.14 Testing 기간의 관측 및 모의유출 결과 비교

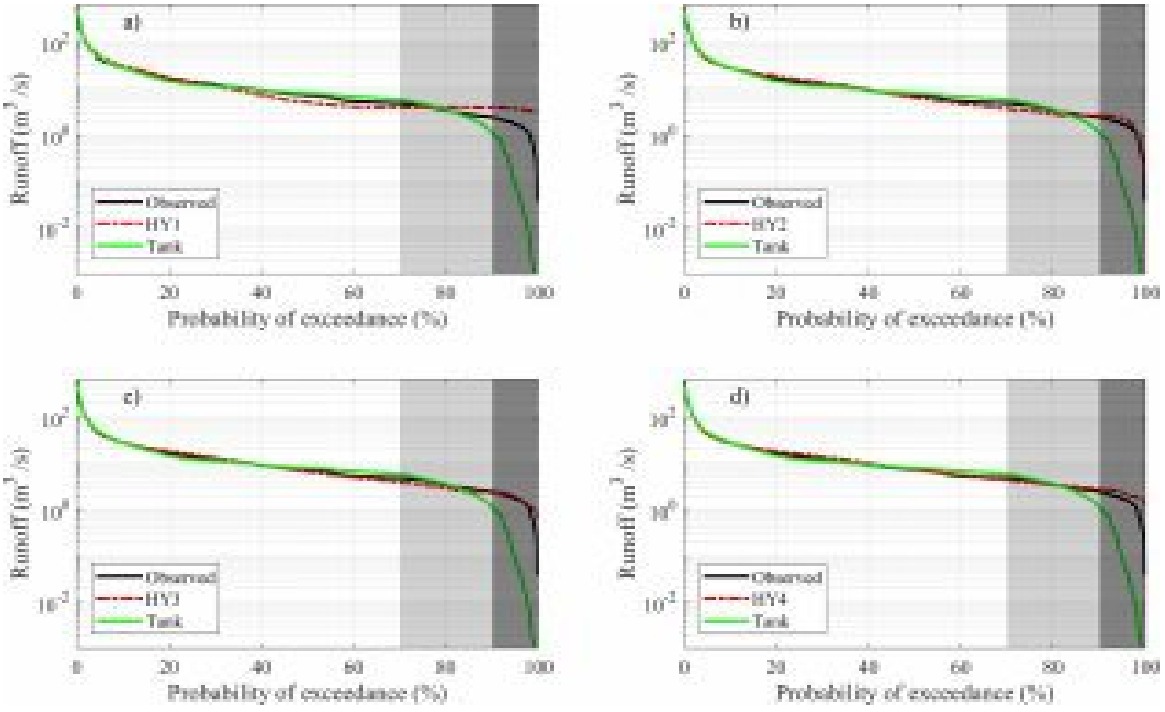


그림 6.15 HY1-HY4 모델, Tank 모델 및 관측유량 유황곡선

최근 이상기후로 인한 집중호우, 가뭄 등 자연재해의 위험성이 점증 되고 있으며, 이러한 재해의 위험을 예방하고 평가하기 위한 유역관리 기술개발이 요구된다. 정밀도 높은 강우-유출 모델은 유역의 유출 특성을 분석, 수자원 관련 계획수립 및 관리를 위한 중요한 Tool이다. 특히 수질 및 가뭄과 관련된 수자원 문제는 갈수기에 주로 이슈화되며, 따라서 강우-유출 모형의 저유량 부분의 모의 능력의 중요성이 증대되고 있다. 그림 6.16은 Testing 기간(2014-2016년)의 Tank 모델, Tank-LSSVM 모델 및 관측값의 시계열 자료를 시각적으로 비교한 것으로 본 연구에서 개발된 Tank-LSSVM 모델이 저유량 부분에서도 기존 Tank 모형보다 개선된 모델 수행능력을 보여준다.

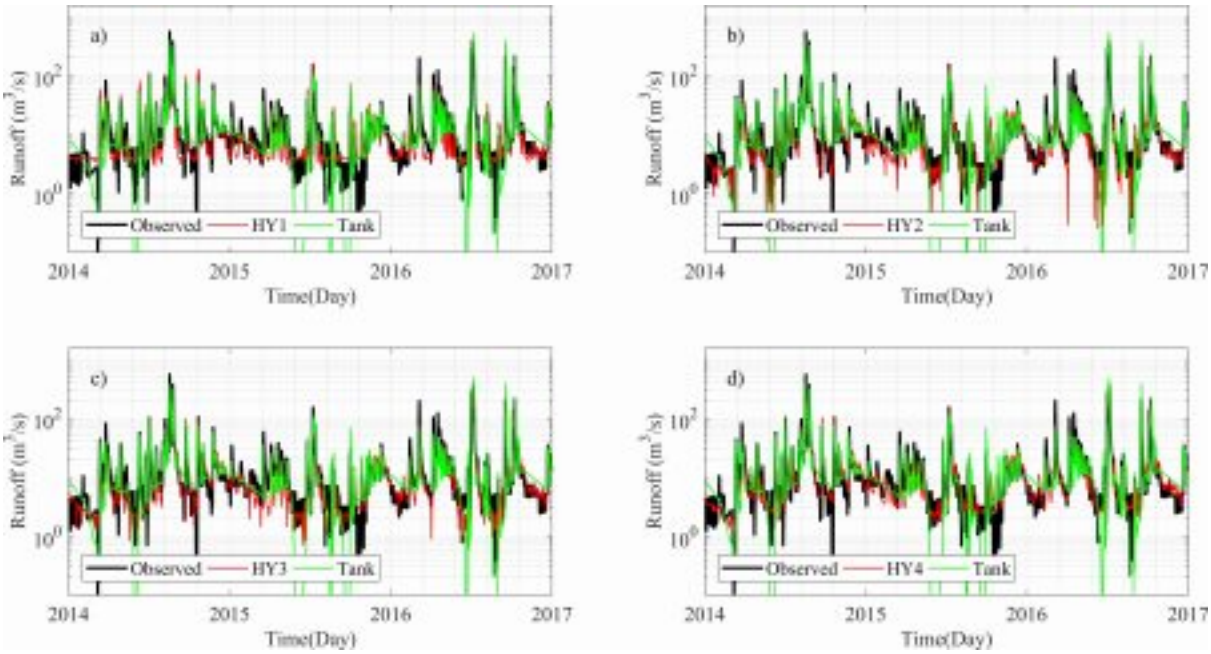


그림 6.16 HY1-HY4 모델, Tank 모델 및 관측유량의 시계열 자료

6.4 결론

본 연구에서는 탱크모형에서 유도된 유역의 토양수분의 시간적 변화를 대표하는 상태변수를 이용해서 LSSVM 머신러닝 기법을 활용해서 비선형 회귀분석을 통해 강우-유출 모형을 개발하였다. 기존의 강우-유출 모형과 유역의 강우-유출 과정을 설명할 수 있는 수문인자들을 머신러닝 기반으로 조합은 향상된 강우-유출 모의 결과를 도출할 수 있다는 가설로 연구를 착수하였다. 본 연구에서 개발된 Hybrid 강우-유출 모형은 탱크 모형 및 Data 기반의 LSSVM 모형보다 유역 유출을 우수하게 모의한 결과를 보였으며, 특히 저유량(Low flow) 부분에서 개선된 결과를 보였다. 본 연구의 성과는 다음과 같이 요약할 수 있다.

1) Calibration 과정에서 도출된 파라미터를 이용해서 탱크모형의 모의 수행능력을 평가한 결과 NSE 기준 탱크 모형의 강우-유출 모의 수행능력은 “Very Good (NSE > 0.7)”으로 평가되었다. 하지만 저유량 부분에서 관측 유량과 비교적 큰 차이를 보였으며, 이러한 결과는 본 연구에서

개발된 머신러닝 기반의 Hybrid 강우-유출모형 개발의 동기가 되었다.

2) 이에, 강우 및 위성 토양수분 자료를 활용하여 LSSVM 기반의 강우-유출 모형의 적용성을 검토하였으며, 모의 결과 입력 자료의 조합에 따라 다소 차이는 있지만 “Good ($0.5 \leq NSE < 0.7$)” 혹은 “Very Good ($NSE > 0.7$)”의 모의 결과를 얻을 수 있었다. 전반적으로 탱크모형보다 낮은 결과를 얻었지만, 위성 토양수분 자료의 강우-유출 모의에서 활용성은 확인할 수 있었다.
3) 본 연구에서 개발된 Tank-LSSVM 모델은 NSE 기준 학습 및 테스트 기간 모두 탱크 모형 및 LSSVM 기반의 강우-유출 모형과 비교하여 개선된 모의 능력을 보였으며 모의수행능력은 “Very Good”로 평가되었다.

본 연구에서 개발된 Hybrid 강우-유출 모형의 기존 탱크 모형에 비해 개선된 모의 능력을 보여주었고, 향후 수문학에서 적용성이 높다 할 수 있겠다. 하지만, 본 연구 결과를 확장해서 향후 탱크모형뿐만 아니라 다른 집중형 모델을 이용 본 연구의 성과를 검증할 필요도 있다. 더불어, 물리적 기반의 분포형 강우-유출 모형에도 본 연구에서 개발된 방법을 적용해서 Hybrid 강우-유출 모형의 적용성을 살펴볼 필요도 있다. 기존 강우-유출 모형에서 유도된 상태변수를 결합해서 개발된 강우-유출 모형이 위성 토양수분자료와 결합해서 개발한 모형보다 우수한 모의 능력을 보였다. 이는 위성 토양수분 자료가 유역 스케일의 토양수분의 시계열 변화를 탱크모형을 통해 간접적으로 도출한 성과에 비해 낮은 수준의 정보를 제공하는 것으로 판단된다.

제 7 장 Remote Sensing 기술을 활용한 다변량 가뭄지수 개발 및 적용

7.1 서론

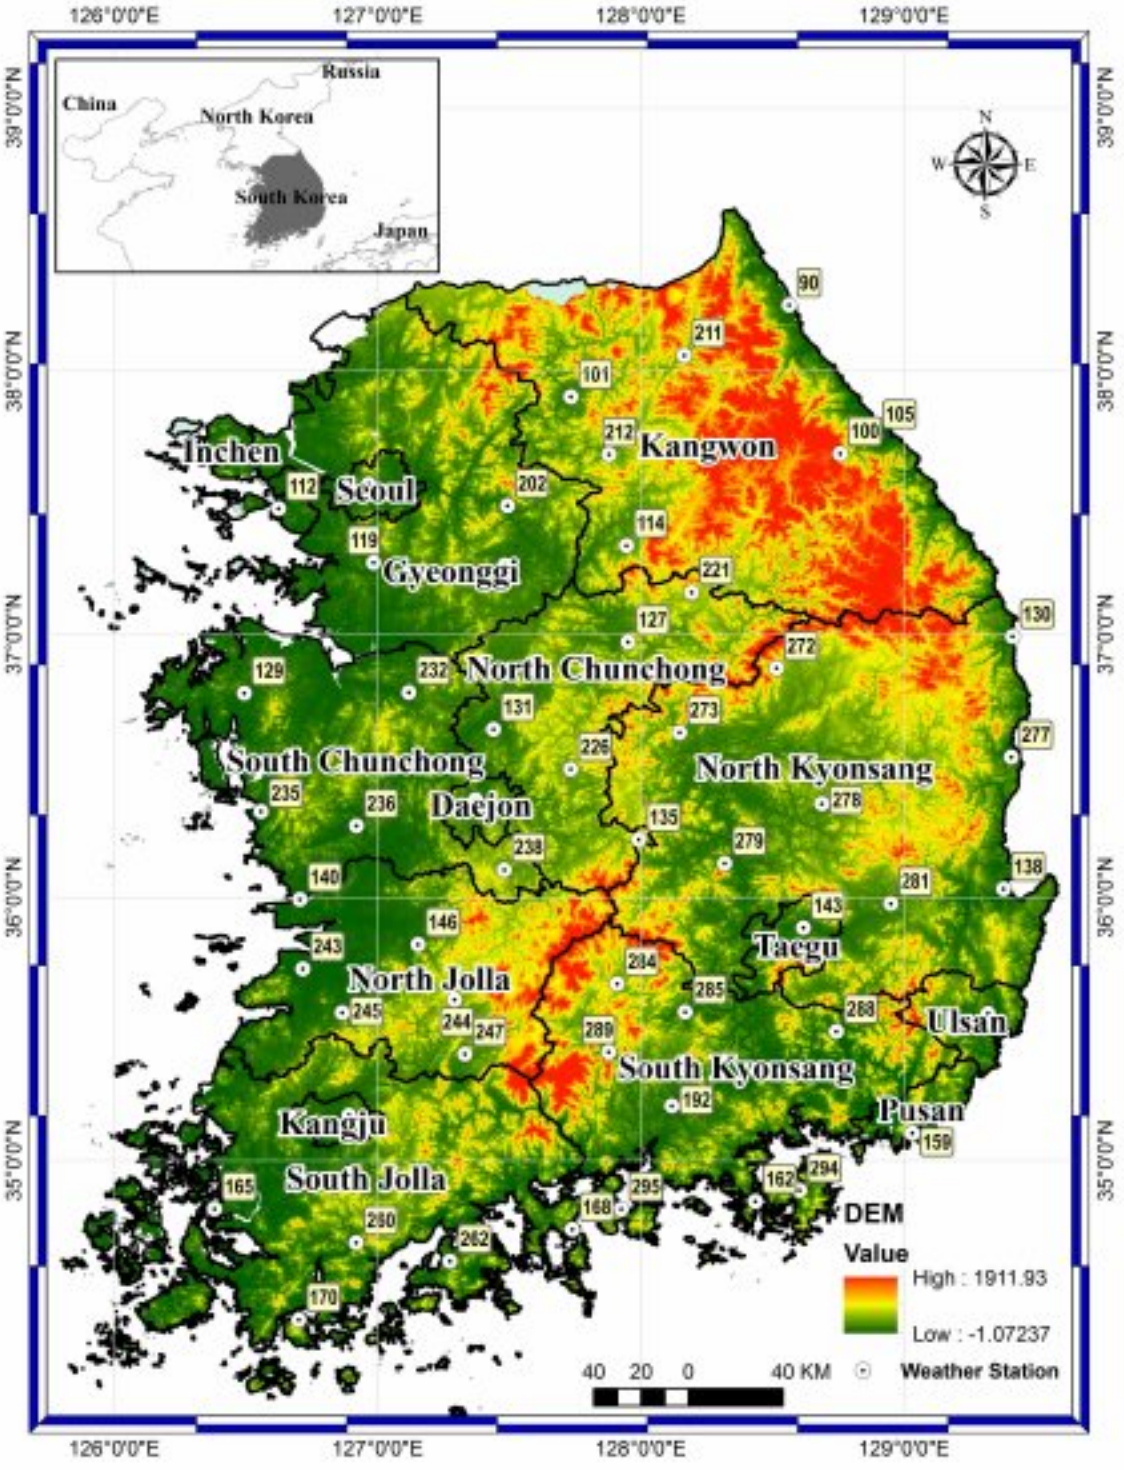


그림 7.1 강우관측소 분포현황

본 장에서는 원격탐사(Remote Sensing, RS) 기법을 활용해서 강우 자료와 RS 자료를 결합하여 가뭄을 평가하는 방법을 소개하고 남한을 대상으로 가뭄평가에 적용하였다. WMO(2012)는 가뭄 분석을 위해서는 최소 20-30년간의 과거 자료를 사용할 것을 권고하고 있다. 그림 7.1 및 표 7.1은 기상청(Korea Meteorological Administration, KMA)에서 운영중인 강우관측소로 30년 이상의 자료의 제공이 가능한 관측소의 분포 및 제원을 보여 준다. 반면 그림 7.2는 관측(In-situ) 및 RS 기술로 취득 가능한 토양수분 자료의 가용 기간을 도시한 것이다. 그림에서 볼 수 있듯이 Reanalysis 데이터인 ERA-Interim 토양수분 자료가 유일하게 가뭄 분석을 위한 최소한의 조건을 만족하는 것으로 검토되었다. 토양수분을 이용한 가뭄분석시 관측자료(In-situ)를 이용하는 것이 가장 이상적이겠지만 K-water 및 기상청에서 제공하는 토양수분 자료의 시·공간적 가용성은 강우 자료에 비해 매우 부족함을 알 수 있다. 이러한 점에서 우리나라와 같이 토양수분 관측자료를 자료의 기간과 공간적 분포 측면에서 수자원 분야 적용에 제한적인 국가(지역)에서 RS 기술로 취득한 자료가 관측치의 대안으로 유용하게 사용될 수 있음을 반증한다.

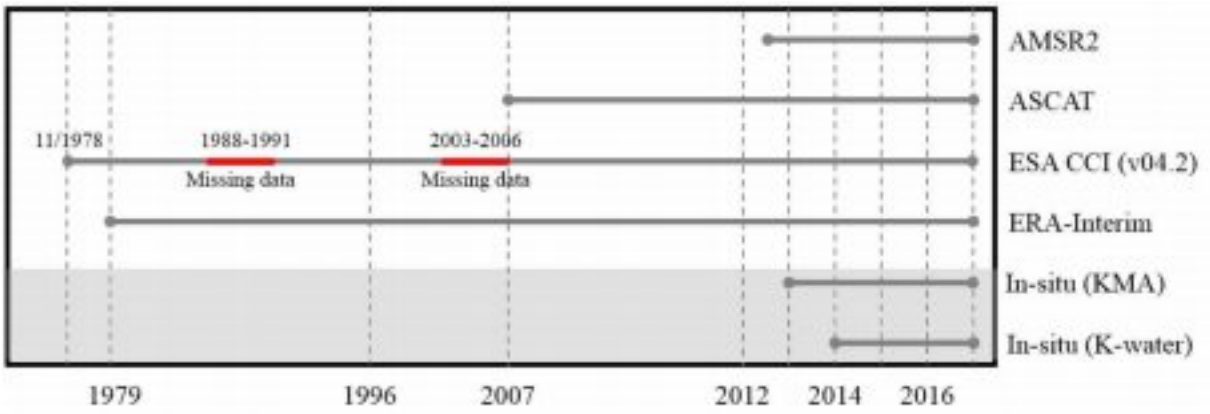


그림 7.2 토양수분 자료별 데이터 제공기간

RS 기술로 획득된 토양수분 자료의 사용에 앞서 가용한 관측 자료와의 비교를 통해서 RS자료의 신뢰도를 평가 후 자료의 가용성 여부를 판단하는 절차는 필수적이다. Kwon et al (2019)는 ERA-Interim 자료를 용담댐 유역 및 전북도를 대상으로 취득한 관측자료와 비교해서 수자원분야에 적용 가능하다는 것을 검증했기에 본장에서는 ERA-Interim 토양수분 자료의 검증절차는 생략하기로 한다.

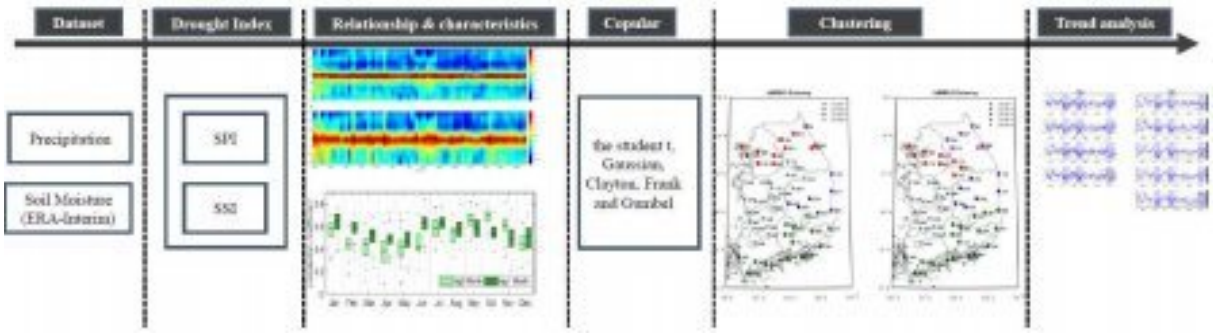


그림 7.3 SPI와 SSI를 결합한 가뭄분석 절차 모식도

표 7.1 강우관측소 제원

Sta. No	Sta. Name	Lat. (N)	Lon. (E)	Alt. (m)	Rainfall (mm)				
					Annual	NDJ	FMA	MJJ	ASO
90	Sokcho	38.25	128.56	18.1	1,386	142	207	653	384
100	Daegwallyeong	37.69	128.76	772.6	1,765	150	274	897	444
101	Chuncheon	37.90	127.74	76.5	1,356	70	205	850	231
105	Gangneung	37.75	128.89	26.0	1,451	154	222	653	422
108	Seoul	37.57	126.97	85.8	1,453	69	214	919	251
112	Incheon	37.48	126.62	68.2	1,237	64	194	742	238
114	Wonju	37.34	127.95	148.6	1,346	73	203	819	252
119	Suwon	37.27	126.99	34.1	1,327	73	207	803	244
127	Chungju	36.97	127.95	116.3	1,239	75	199	721	244
129	Seosan	36.78	126.49	28.9	1,273	91	219	714	249
130	Uljin	36.99	129.41	50.0	1,155	133	197	508	318
131	Cheongju	36.64	127.44	58.7	1,242	83	203	717	240
133	Daejeon	36.37	127.37	68.9	1,366	97	225	792	252
135	Chupungnyeong	36.22	127.99	243.7	1,897	136	484	931	346
138	Pohang	36.03	129.38	2.3	1,850	144	479	906	322
140	Gunsan	35.99	126.71	23.2	1,554	97	282	873	302
143	Daegu	35.89	128.62	53.5	1,233	80	258	673	222
146	Jeonju	35.82	127.15	61.4	1,298	77	236	747	237
152	Ulsan	35.56	129.32	83.2	1,309	88	230	744	247
156	Gwangju	35.17	126.89	72.4	1,091	68	199	604	220
159	Busan	35.10	129.03	69.6	1,073	69	210	589	205
162	Tongyeong	34.85	128.44	32.3	1,078	107	202	505	263
165	Mokpo	34.82	126.38	38.0	1,015	59	189	576	191
168	Yeosu	34.74	127.74	64.6	1,185	86	210	668	221
170	Wando	34.40	126.70	35.2	1,183	115	227	562	279
192	Jinju	35.21	128.12	30.2	1,243	105	211	688	240
201	Ganghwa	37.71	126.45	47.0	1,075	68	200	597	210
202	Yangpyeong	37.49	127.49	48.0	1,293	105	218	740	231
203	Icheon	37.26	127.48	78.0	1,277	109	273	631	264
211	Inje	38.06	128.17	200.2	1,394	120	241	786	247
212	Hongcheon	37.68	127.88	140.0	1,520	119	383	757	262
221	Jecheon	37.16	128.19	259.8	1,463	113	384	705	260
226	Boeun	36.49	127.73	175.0	1,163	110	231	595	228
232	Cheonan	36.78	127.12	81.5	1,445	96	351	750	248
235	Boryeong	36.33	126.56	15.5	1,536	127	384	737	288
236	Buyeo	36.27	126.92	11.3	1,524	107	340	803	274
238	Geumsan	36.11	127.48	170.4	1,337	58	210	818	251
243	Buan	35.73	126.72	12.0	1,409	68	202	893	246
244	Imsil	35.61	127.29	247.9	1,361	74	215	810	263
245	Jeongeup	35.56	126.87	69.8	1,197	60	189	729	218
247	Namwon	35.41	127.33	132.5	1,362	65	209	843	245
260	Jangheung	34.69	126.92	45.0	1,412	82	231	847	253
262	Goheung	34.62	127.28	53.1	1,308	89	219	767	233
272	Yeongju	36.87	128.52	210.8	1,238	78	191	718	251
273	Mungyeong	36.63	128.15	170.6	1,230	93	203	690	244
277	Yeongdeok	36.53	129.41	42.1	1,358	97	235	773	254
278	Uiseong	36.36	128.69	81.8	1,289	98	220	746	225
279	Gumi	36.13	128.32	48.9	1,222	113	211	661	237
281	Yeongcheon	35.98	128.95	93.8	1,352	107	226	774	244
284	Geochang	35.67	127.91	226.0	1,327	124	226	722	254
285	Hapcheon	35.57	128.17	32.0	1,348	103	229	772	243
288	Miryang	35.49	128.74	11.2	1,485	106	310	804	265
289	Sancheong	35.41	127.88	138.1	1,448	103	355	735	254
294	Geoje	34.89	128.60	45.4	1,322	75	255	748	244
295	Namhae	34.82	127.93	43.7	1,288	77	241	742	230

7.2 연구방법

7.2.1 가뭄지수 산정방법

그림 7.3은 기상학적 가뭄지수인 SPI와 농업적 가뭄지수인 SSI를 결합해서 기상학적 가뭄과 농업적 가뭄의 상태를 동시에 분석하는 절차를 보여준다. 그림에서 보듯이 강우량자료와 ERA-Interim 토양수분 자료를 이용해서 SPI와 SSI를 각각 산정한다. 본 연구에서는 3개월 및 6개월간의 두 개의 스간 스케일의 누적 강우량을 산정하여 SPI를 도출하였으며(SPI-3/6), 동일한 절차로 SSI-3/6 또한 계산하였다. 누적강우량은 Gamma 혹은 Pearson type Ⅲ 확률분포형에 적합(fitting) 시킨 후 평균값 0 및 표준편차 1을 갖는 표준정규분포에 전이하여 산정하는 것이 일반적이나, 확률분포형 선정에 따라 가뭄지수 값의 차이를 보이고 본 연구처럼 다수의 강우관측소를 해석시 관측소별 최적 분포형이 다를 수 있다는 점을 고려하여 본 연구에서는 비모수(non-parametric) 방법인 kernel density 함수에 강우량 및 토양수분의 시계열 자료을 fitting 시킨 후 앞서 설명한 그림 2.16과 같이 표준정규 분포형으로 전이시켜 SPI 및 SSI 가뭄지수를 유도하였다.

표 7.2 본 연구에서 고려된 Copula 함수군

구 분	C(u,v)	출처
Gaussian	$\int_{-\infty}^{\Phi^{-1}(U)}\int_{-\infty}^{\Phi^{-1}(v)}\frac{1}{2\pi\sqrt{1-\theta^2}}\exp\left(\frac{2\theta xy-x^2-y^2}{2(1-\theta^2)}\right)dxdy$	Li et al., (2013)
t	$\int_{-\infty}^{t_{\theta_2}^{-1}(U)}\int_{-\infty}^{t_{\theta_2}^{-1}(v)}\frac{\Gamma\left(\frac{\theta_2+2}{2}\right)}{\Gamma(\theta_2)\pi\theta_2\sqrt{1-\theta_1^2}}\left(1+\frac{x^2-2\theta_1xy+y^2}{\theta_2}\right)^{(\theta_2+2)/2}dxdy$	Li et al., (2013)
Clayton	$\max(U^{-\theta}+v^{-\theta}-1,0)^{\frac{-1}{\theta}}$	Clayton, (2016)
Frank	$\frac{-1}{\theta}\ln\left[1+\frac{(\exp(-\theta u)-1(\exp(-\theta v)-1)}{\exp(-\theta)-1}\right]$	Li et al., (2013)
Gumbel	$\exp\left\{-1\left[(-\ln(u))^{\theta}+(-\ln(v))^{\theta}\right]^{\frac{1}{\theta}}\right\}$	Li et al., (2013)

산정된 기상학적 가뭄지수(SPI)와 농업적 가뭄지수(SSI)는 코플라함수(Copular function)를 이용해서 식 7.1~7.2를 적용하여 결합활률분포(Joint probability)형태인 결합된 다변량 가뭄지수(Multivariate Standardized Drought Index, MSDI)를 유도하였다. 코플라 함수는 수학적으로 두 개 이상의 활률변수의 결합활률분포를 유도하기 위해 두 확률변수의 주변확률분포(Maginal probability distribution)로부터 결합확률 분포를 유도하기 위해 사용된다. 결합활률분포를 유도하는 식은 7.2와 같다.

$$P(X \le x,\ Y \le y) = C[F(X),\ G(Y)] = p \qquad \text{수식 } 7.1$$

여기서 X, Y는 SPI 및 SSI이며, C는 코플라 함수이다. 이렇게 산출된 누계결합활률(Cumulative joint probability, p)는 식 7.2와 같이 표준정규함수의 역함수를(inverse of the standard normal distribution function) 이용해서 MSDI를 유도하였다.

$$MSDI = \phi^{-1}(P) \qquad \text{수식 7.2}$$

7.3 결과 및 토의

7.3.1 기상학적 가뭄지수(SPI) 및 농업적 가뭄지수(SSI)

본 연구에서는 표 7.2와 같이 5개의 후보 코플라 함수 중 지점별 최적의 코플라 함수를 선정하여 이후 분석을 수행하였다. 코플라 함수의 parameter는 최우도법(Maximum Likelihood, ML)을 이용하여 결정하였으며, 코플라 함수 후보군 중 지점별 최적의 코플라 함수는 Akaike Information Criteria(AIC)를 기준으로 채택하였다. 그림 7.4는 SPI-6 및 SSI-6의 시계열 자료를 도시한 것이다. 그림에서 볼 수 있듯이 SSI는 가뭄의 빈도는 SPI에 비해 적으나 가뭄 도래 시 그 지속기간이 SPI에 비해 길다는 것을 알 수 있다. 이는 SPI와 SSI 가뭄지수를 결합한 가뭄지수는 가뭄을 모니터링시 각 가뭄지수의 특징을 모두 취할 수 있다는 장점을 보여준다.

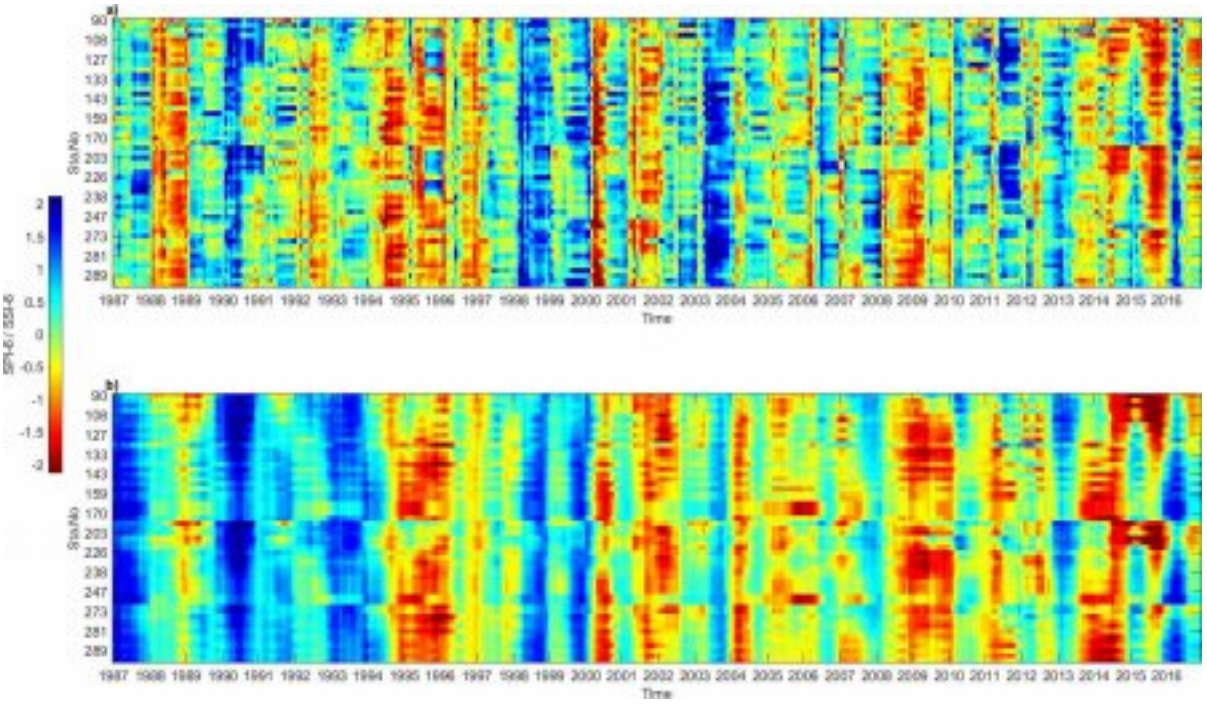


그림 7.4 국내 55개 강우관소별 SPI-6(a) 및 SSI-6(b) 시계열 Heatmap (1987-2016, 30년간)

기상학적으로 시작한 가뭄이 농업적 가뭄으로의 전파 특성를 분석하기 위해서 55개 지점을 대상으로 SPI와 SSI의 교차상관(Cross-correlation) 분석을 실시 하였으며 결과는 그림 7.5와 같다. 여기서, 각 지점별 Cross-corrlation의 최대값을 보이는 지체시간을 검은점으로 표시하였다. 대부분의 지점에서 SPI가 1개월 지체된 SSI와 가장 상관관계가 높음을 알 수 있다. 이는 기상학적가뭄이 수문순환과정을 통해서 농업적 가뭄으로 전파하는데 1개월의 지체가 발생함을 알 수 있다. 가뭄의 출현뿐

만 아니라 가뭄의 지속성을 이해하는 것은 수자원 관리 측면에서 중요하다. 가뭄의 지속성은 다른 가뭄특성과 같이 시간과 공간적인 측면에서 다르게 나타나며, 특정 가뭄의 출현 주기성은 자기상관(Auto-correlation) 기법을 이용해서 통계적으로 분석할 수 있다(Tatli, 2015).

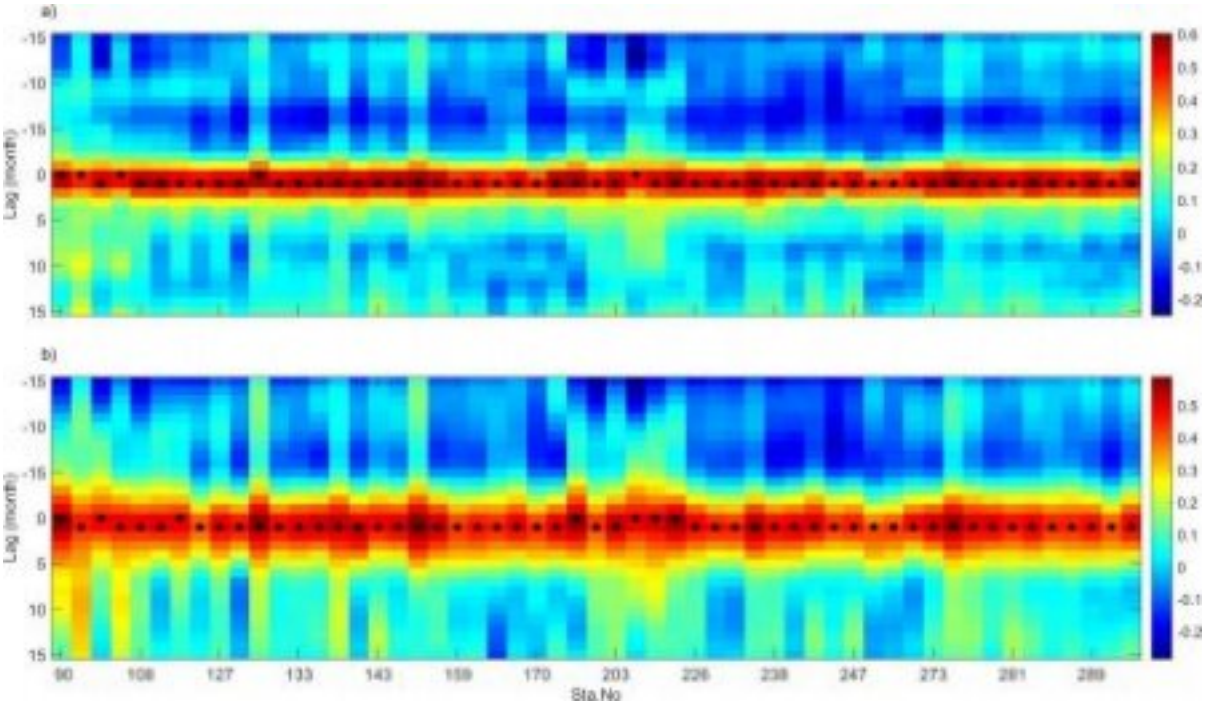


그림 7.5 SPI와 SSI사이의 교차상관 결과(a는 SPI/SSI-3, b는 SPI/SSI-6)

55개 기상관측지점에 대해 SPI-3와 SSI-3에 대한 월별 상관관계 및 1개월 지체된 월별 상관관계는 그림 7.6에 도시하였다. 그림 7.6에서 보듯이 SPI와 SSI는 양의 상관관계가 있으며 이는 토양에 수분의 부족은 기상학적 가뭄과 높은 관련성이 있음을 알 수 있다. 또한, SSI와 SPI의 상관관계 정도는 월별로 차이를 보이며, 이는 기상학적 가뭄이 농업적 가뭄에 미치는 영향의 정도는 계절에 따라 다름을 알 수 있다. 더욱이 SPI와 SSI의 상대적 높은 상관관계가 우리나라의 경우에는 dry season인 겨울-봄 이후 wet season으로 접어드는 시점에서 높아지다 다시 dry season으로 접어들면 감소하는 추세를 보인다.

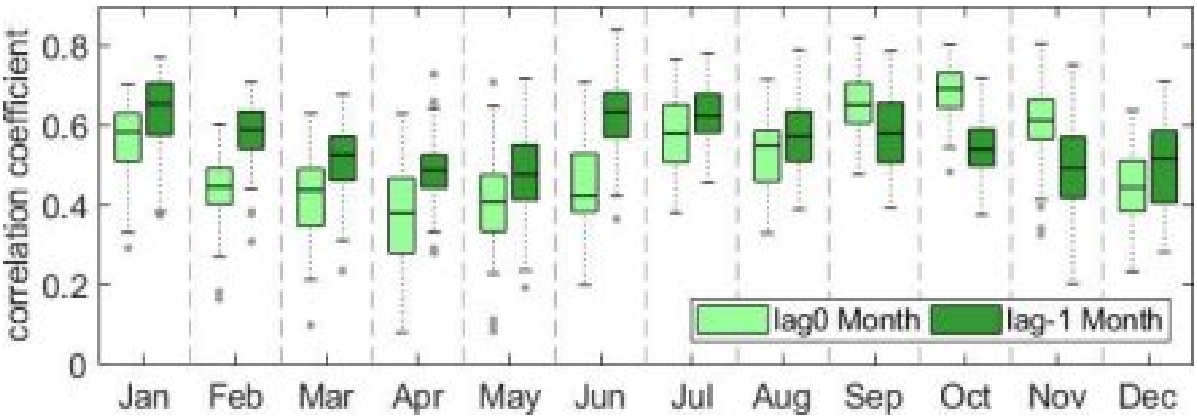


그림 7.6 55개 지점에 대한 SPI-3와 SSI-3의 월별 상관관계

가뭄의 지속(Persistence) 기간은 자기상관(Autocorrelation) 기법을 이용 통계적으로 분석이 가능하다. 55개 지점에 대한 자기상관 분석 결과는 그림 7.7에서 보듯이 지체시간이 길어짐에 따라 두 가뭄지수의 상관관계는 낮아지며, 모든 지체시간에서 SPI에 비해 SSI가 상대적으로 높은 상관관계를 (즉, 높은 가뭄의 지속성) 보인다. 이를 통해 농업적 가뭄이 도래되면 기상학적 가뭄보다 상대적으로 지속기간이 길다는 것을 통계적으로 알 수 있다. 자기상관 분석 결과는 가뭄 분석 시 서로다른 특성을 가진 다양한 가뭄지수를 이용하는 필요성을 보여준다. 즉, SPI는 가뭄의 출현을 인지하기에 유리한 가뭄지수이며, SSI 가뭄지수는 가뭄의 지속성을 평가하는데 장점이 있는 가뭄지수라 할 수 있다.

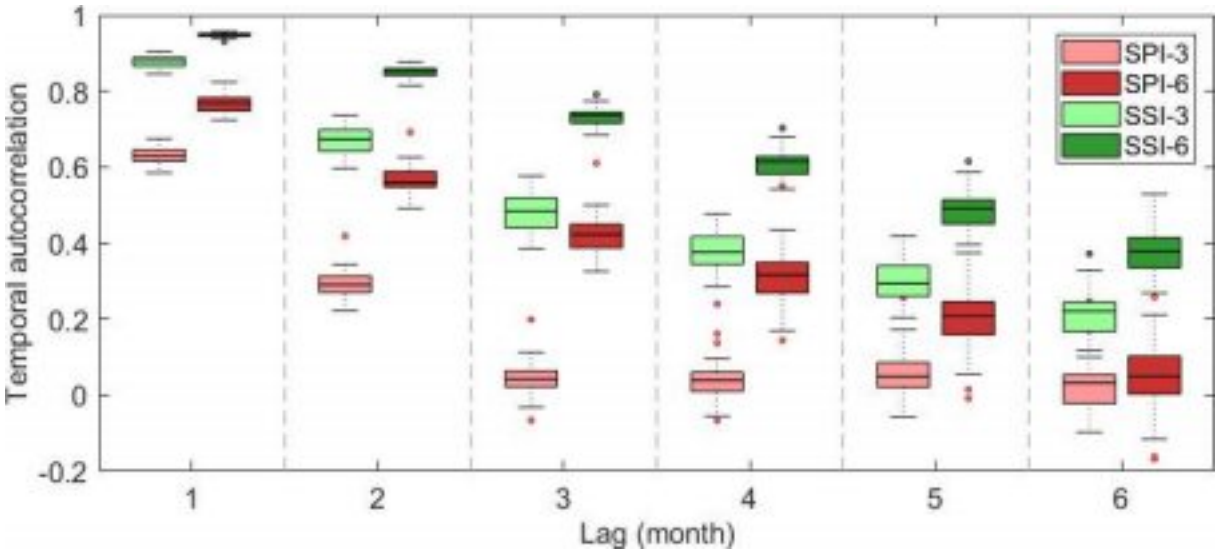


그림 7.7 지체시간(1~6개월)에 따른 SPI 및 SSI의 자기상관(Autocorrelation) 분석결과

7.3.2 가뭄의 공간적 패턴

본 절에서는 남한을 대상으로 SPI와 SSI 가뭄지수를 대상으로 지속시간별 공간적인 패턴분석을 수행하였다. 그림 7.8은 앞서 표 2.12에서 정의한 Moderately Dry(Threshold = -1) 상태를 기준으로 과거 가뭄 발생 횟수(event)의 공간적 분포를 보여준다. SPI와 비교해서 SSI는 낮은 가뭄의 발생 빈도를 보여주며 이는 Farahmand 등 (2015)의 연구결과와도 동일한 경향을 보인다. 더욱이, 높은 가뭄 발생 빈도는 상대적으로 약한 가뭄의 지속성(그림 7.8d, 7.8h)으로 인해 짧은 시간 스케일에서 SPI 및 SSI에서 나타났다(그림 7.8c, 7.8g). 또한, SSI의 가뭄 지속성은 SPI에 비해 현저하게 길게 나타났으며, 이러한 현상은 SPI/SSI-6이 SPI/SSI-3 보다 뚜렷함을 보인다. 다시 말하면, 3개월 누적치의 가뭄지수는 6개월 자료를 누적한 가뭄지수보다 음의 값을 더 자주 보이며, 기상학적 가뭄인 SPI는 농업적 가뭄 SSI 가뭄지수에 비해 가뭄 단계에서 정상 단계로 회복되는 속도가 빠름을 알 수 있다.

다음 단계로 SPI 및 SSI에 대한 가뭄의 지속기간 및 심도를 평가하였으며, 공간분포는 그림 7.9 및 그림 7.10과 같다. SPI-3의 경우, 가뭄 지속기간(Duration)은 남한의 북쪽과 남쪽 지역에서 장기간인 현상이 뚜렷하며 가뭄의 심도(Severity) 또한 지속기관과 비슷한 공간적 분포를 보인다. SPI-6 가뭄지수 분석 결과 가뭄 누적 기간이 길어짐에 따라 가뭄의 공간분포가 동쪽 지역으로 확대됨을 알 수 있으며 또한, 가뭄의 지속기간과 가뭄의 심도는 높은 공간 상관관계가 있음을 알 수 있다.

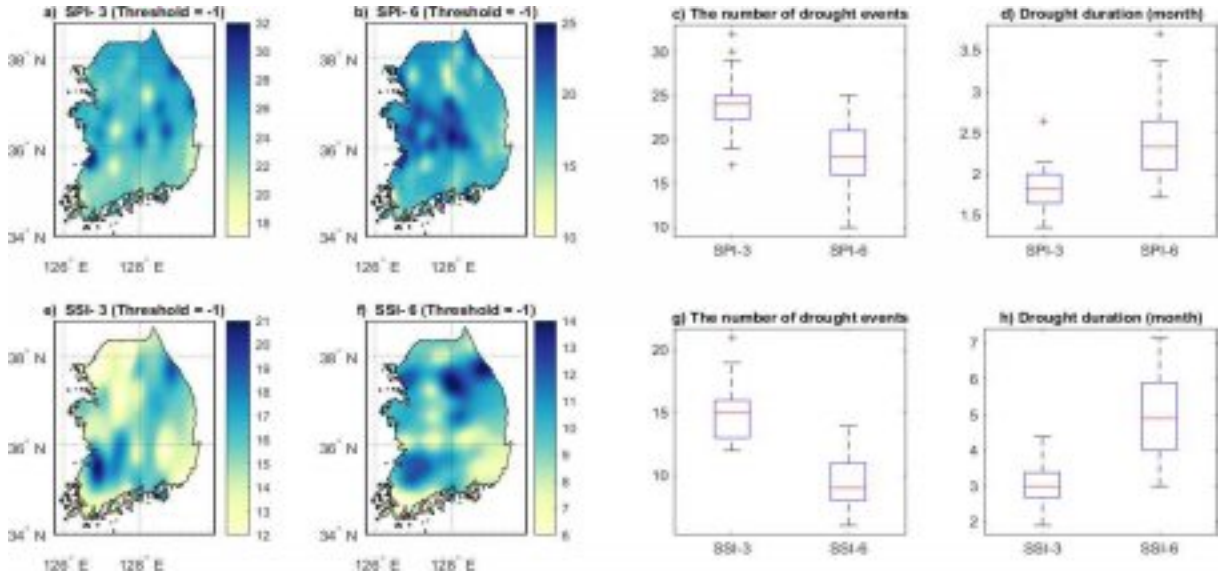


그림 7.8 가뭄발생(event) 빈도의 공간적 분포

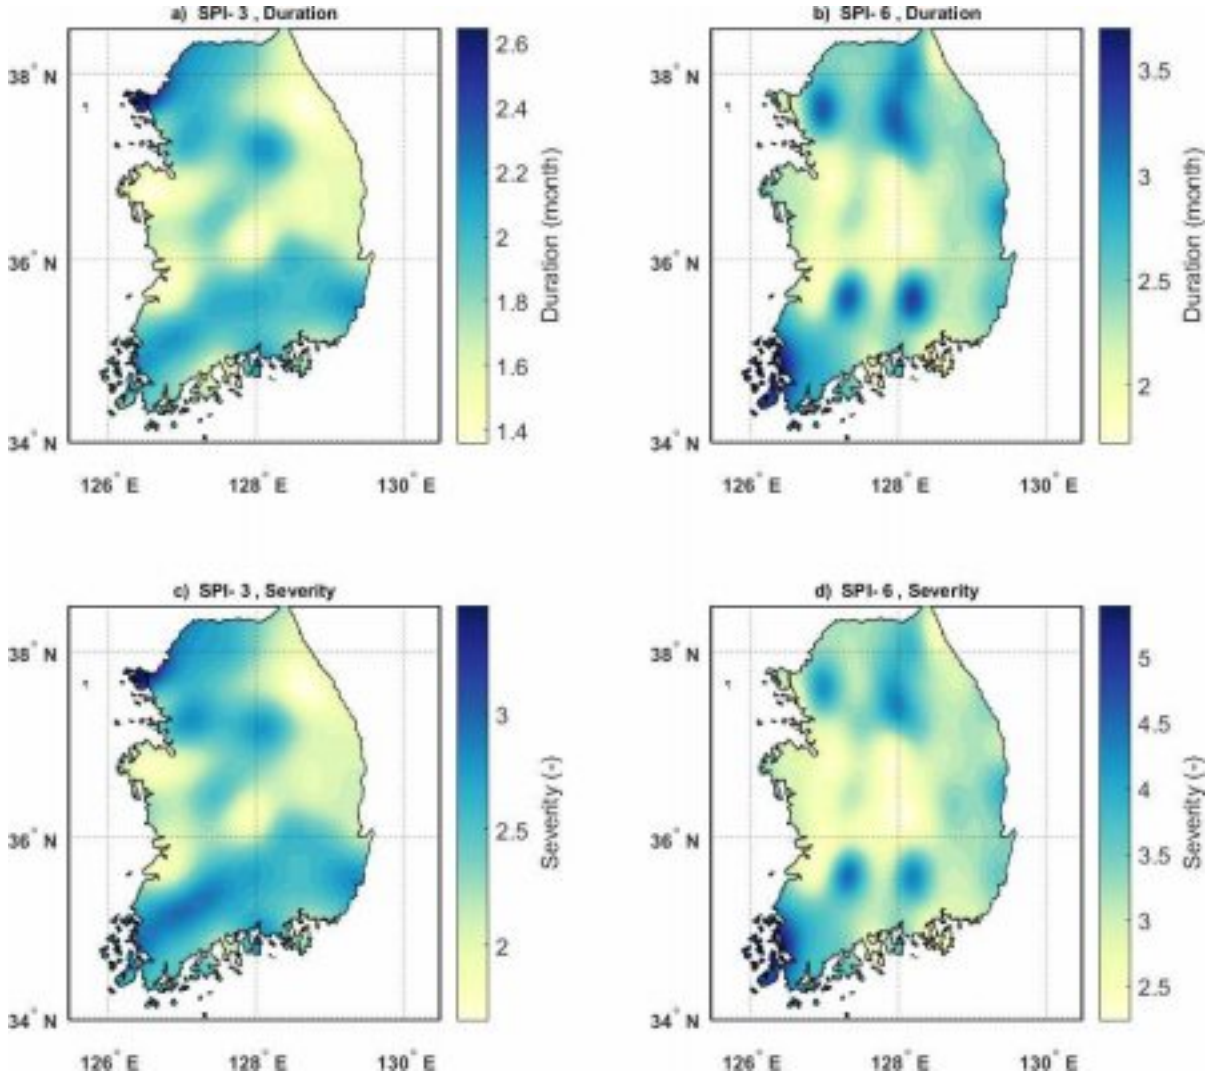


그림 7.9 SPI 기준 가뭄 지속기간(Duration) 및 가뭄강도(Severity)의 공간적 분포

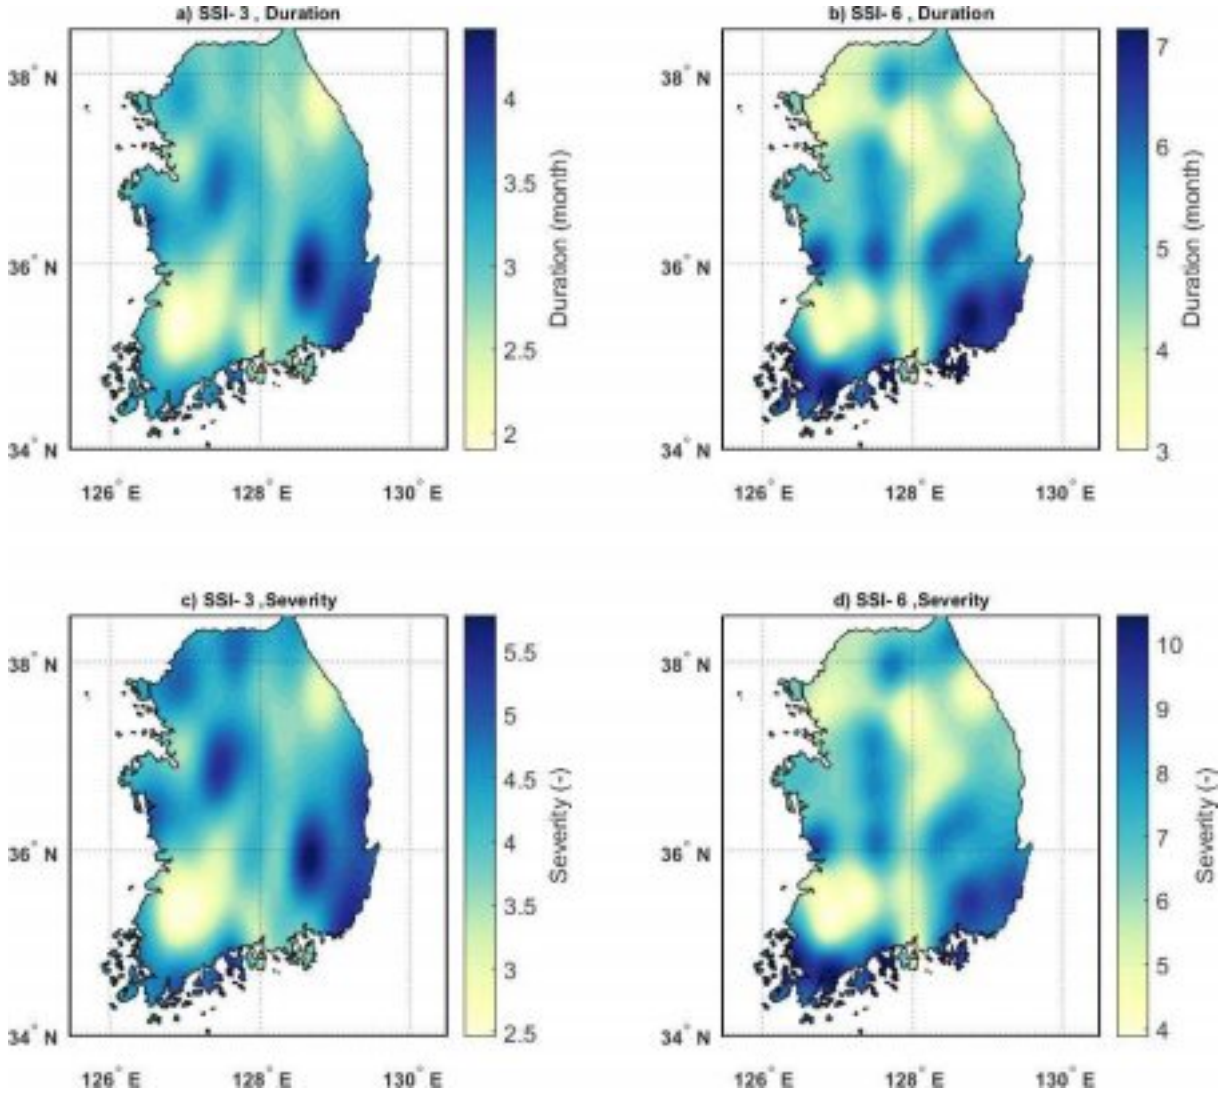


그림 7.10 SSI기 준 가뭄 지속기간(Duration) 및 가뭄강도(Severity)의 공간적 분포

SPI 및 SSI 가뭄지수의 과거 31개년간 (1986-2016) 가뭄의 강도-빈도-지속기간 등의 증·감 경향성 분석은 분위회귀분석(Quantile regression) 모델을 이용하여 실시하였다. Quantile-regression 모델은 다양한 분위의 시간에 따른 증·감 경향을 분석하는데 유용하게 사용될 수 있다. 본 연구에서는 중간 규모의 가뭄의 Trend와 더불어 극한가뭄 등 분위별 가뭄특성의 시간별 변화 경향성 등을 분석하였다. 앞서 정의된 가뭄의 정도별(Threshold = -1.0, -1.5, -2.0) 유도된 SPI/SSI-3의 시계열 데이터의 증감 경향을 보여주는 slope 파라미터의 공간분포는 그림 7.11에 도시하였다. 7.11a 및 7.11-d에서 볼 수 있듯이, Treshold=-1 기준 경기도, 강원북부 및 충청 북부 지역에 걸쳐 음의 경향 즉 가뭄이 증가하는 경향을 보이는 반면 남쪽 지역은 양의 경향 즉 가뭄이 감소하는 경향을 보인다. 이러한 가뭄추세는 Treshold = -1.5 기준에서도 비슷한 분포를 보인다. 극심한 가뭄의 경우 다른 패턴을 보이는데, SPI-3와 달리 SSI-3의 경우 경기도 및 충청도에서 가뭄이 증가하는 경향이 뚜렷하다. 이는 최근 2014-2015에 걸쳐 발생하였던 충청권 가뭄을 잘 반영하고 있는 것으로 판단된다. 상기의 분석 결과를 요약하자면, 남한의 북쪽지역에 가뭄지수의 음의경향 즉 가뭄이 증가하는 트렌드가 보이며, 이러한 가뭄 Risk의 증가는 남한의 중부지역에 몬순밸트가 북상하지 못한 최근의 경향과 밀접한 관련이 있을것으로 추정이 되면 이에대한 좀더 구체적인 연구가 필요할 것 이다(Zhang and Zhou, 2015).

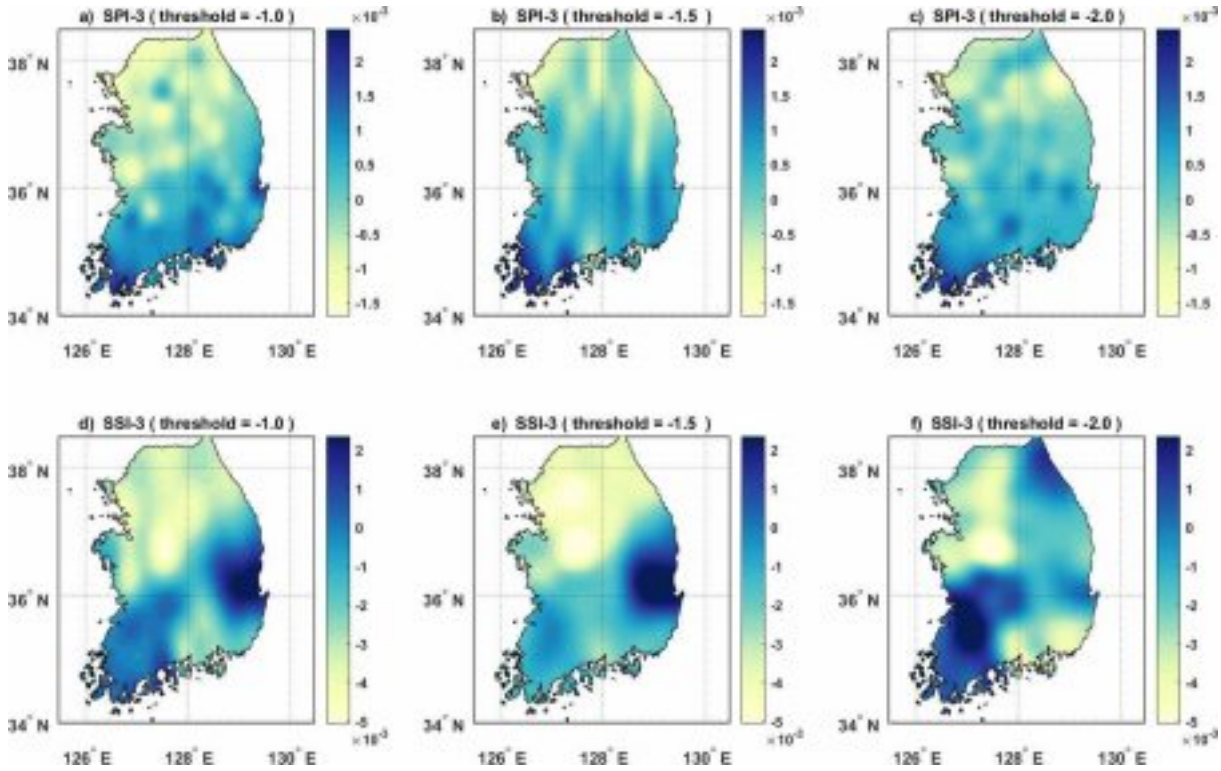


그림 7.11 SPI-3 및 SSI－3의 시계열 변화에 대한 공간분포

7.3.3 다변량 가뭄지수(Multivariate Standardized Drought Index, MSDI)를 활용한 가뭄특성 군집 분석 (Clustering analysis)

앞서 언급한 바와 같이 SPI와 SSI 가뭄지수를 코플라 함수를 이용해서 하나의 결합된 다변량 가뭄지수인 MSDI를 유도하였으며, 유도된 MSDI 시계열 자료는 응집형 계층적 군집분석(Agglomerative Hierachical Clustering) 알고리즘을 이용하여 과거 30년간의 지역별 가뭄의 경향이 비슷한 지역을 기준으로 분류하였으며, MSDI-3 및 MSDI-6 지수에 대한 군집분석 결과 및 결합확률분포를 이용하여 MSDI 가뭄지수 산정시 강우관측소별 채택된 코플라 함수는 표 7.3과 같다. 본 연구에서는 앞서 설명한것과 같이, 코플라 함수 중 Student t, Gaussian, Clayton, Frank 그리고 Gumbel 코플라 함수를 후보군으로 고려하였으며 Akaike Information Criteria (AIC)를 기준으로 지점별 최적의 코플라 함수를 결정하였다. 선정결과 연구에서 고려된 5개의 코플라 함수 중 Frank 코플라가 MSDI-3 및 MSDI-6 모두에서 가장 빈도수가 많게 채택되었다(표 7.3).

이렇게 산정된 MSDI는 가뭄의 지역적 경향을 분석하고자 군집분석(Clustering Analysis)을 수행하였다. 계층적 군집분석에 있어서 전체 자료를 몇 개의 그룹으로 나눌지는 중요한 문제이며 본 연구에서는 Mojena (1977)가 제안안 upper-tale rule을 사용하여 MSDI-3와 MSDI-6의 군집수를 결정하였으며, 분석 결과는 그림 7.12에서 보는 바와 같이 MSDI-3의 경우 클러스터의 수가 4개 이상으로 증가하면 Standardized Fusion Level의 감소의 경향이 줄어들고 MSDI-6의 경우 클러스터의 수가 5개의 경우에 변곡점이 형성됨을 알 수 있다. 따라서, MSDI-3 가뭄지수는 4개, MSDI-6는 5개의 군집으로 우리나라를 지역화하여 가뭄특성 분석을 수행하였다. 각 기상 관측소별 MSDI의 군집분석 결과는 그림 7.13에 도시화 하였다. 그림에서 볼수 있듯이, MSDI-3 경기도와 강원도가 동일한 그룹으로 묶

여 있는데 반해 MSDI-6의 경우 강원도 지역이 별도의 클러스터로 구분됨을 보인다. MSDI-3와 MSDI-6의 지역화 결과는 비슷한 경향을 보이며, 인접한 지역의 기상관측소가 일반적으로 동일한 그룹에 포함됨을 알 수 있다.

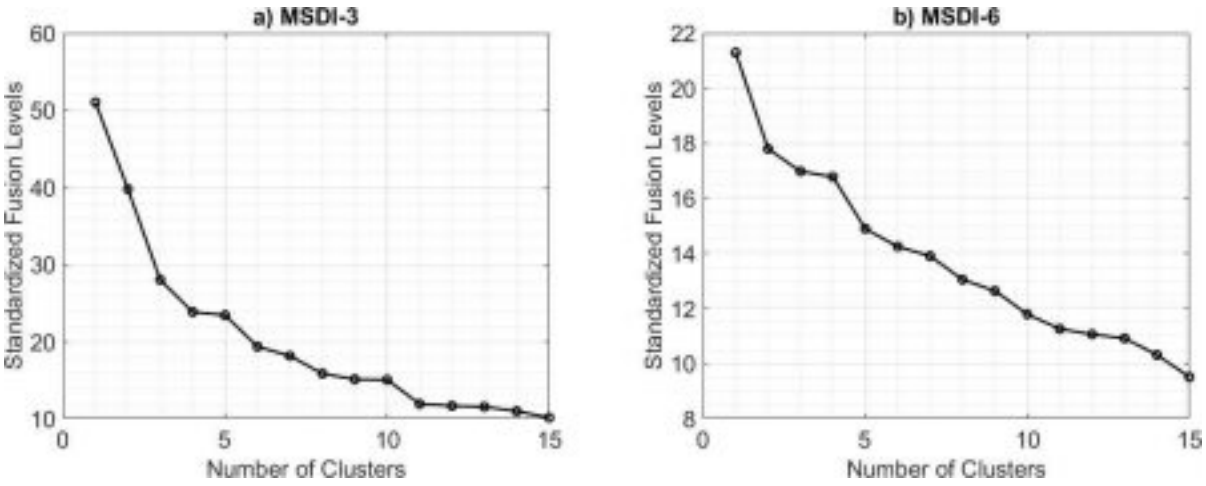


그림 7.12 클러스터 수의 증가에 따른 Standardized Fusion Levels

표 7.3 기상관측소별 군집분석 결과

MSDI-3						MSDI-6					
Sta. No	Copula	Cluster No	Sta. No	Copula	Cluster . No	Sta.No	Copula	Cluster No	Sta.No	Copula	Cluster . No
90	Frank	3	203	Frank	4	90	Gaussian	1	203	t	2
100	t	3	211	Frank	4	100	Frank	1	211	Gaussian	1
101	Gumbel	3	212	Gaussian	1	101	Gaussian	1	212	Clayton	1
105	t	3	221	Gaussian	1	105	Frank	1	221	Frank	2
108	Gumbel	3	226	Frank	4	108	Gumbel	2	226	Frank	5
112	Gumbel	3	232	Frank	4	112	Gumbel	2	232	Frank	5
114	Gaussian	4	235	Frank	4	114	Gaussian	2	235	Frank	5
119	Frank	3	236	Frank	4	119	t	2	236	Frank	5
127	Frank	4	238	Frank	4	127	Frank	2	238	Frank	5
129	Frank	4	243	Frank	4	129	Frank	5	243	Frank	5
130	t	1	244	Frank	4	130	t	3	244	Gaussian	5
131	Frank	4	245	Frank	4	131	Frank	5	245	Gaussian	5
133	Frank	4	247	Gaussian	1	133	Frank	5	247	Gaussian	5
135	Frank	1	260	Gumbel	5	135	Frank	3	260	Frank	4
138	t	1	262	Gumbel	5	138	t	4	262	Gaussian	4
140	Frank	4	272	Gumbel	5	140	Frank	5	272	Frank	3
143	Gaussian	2	273	Frank	4	143	Frank	4	273	Frank	3
146	Frank	4	277	t	2	146	Frank	5	277	t	3
152	Frank	2	278	Gaussian	1	152	Frank	4	278	Frank	3
156	Frank	4	279	Frank	4	156	Frank	5	279	Frank	3
159	Gumbel	2	281	Gaussian	1	159	t	4	281	t	4
162	Gumbel	2	284	t	2	162	Frank	4	284	Frank	4
165	Gumbel	2	285	Gaussian	1	165	Frank	4	285	Frank	4
168	Gaussian	2	288	Gumbel	5	168	Frank	4	288	Frank	4
170	Gumbel	2	289	Frank	4	170	Frank	4	289	Frank	4
192	Frank	2	294	Gumbel	5	192	Frank	4	294	Frank	4
201	Gumbel	3	295	Gumbel	5	201	Gumbel	2	295	Frank	4
202	Gaussian	3				202	Clayton	2			

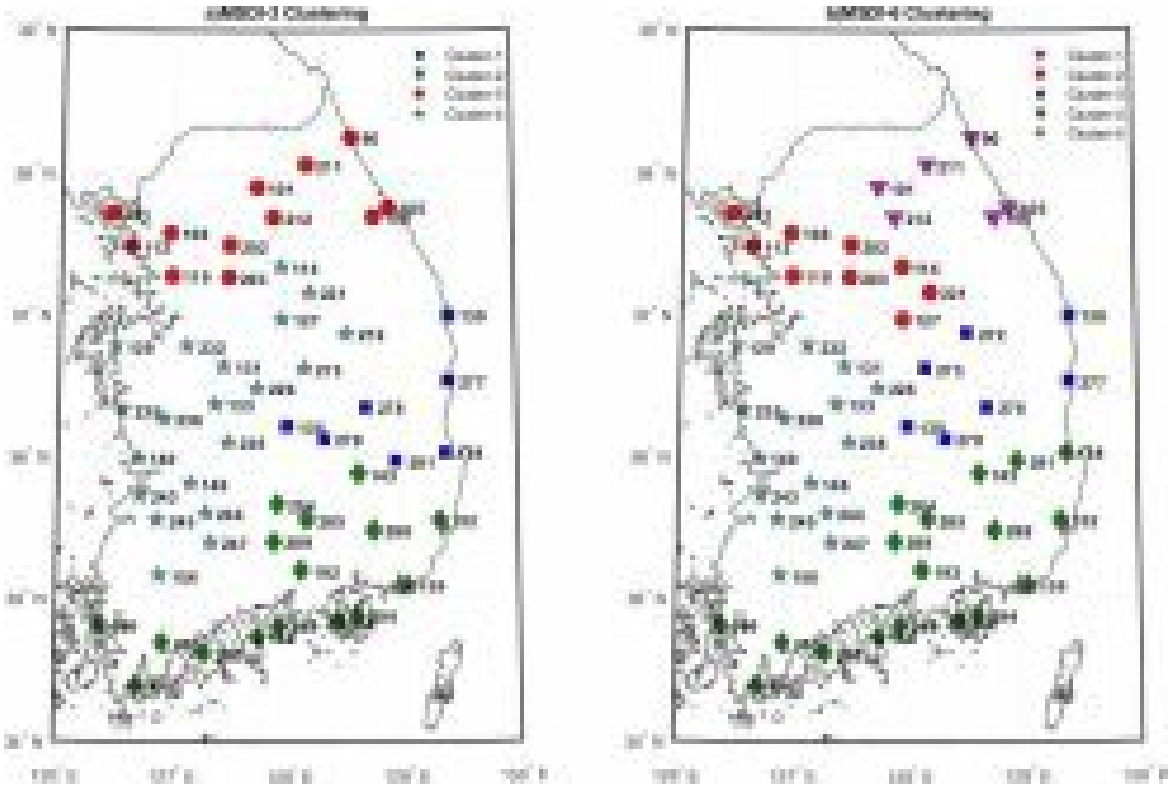


그림 7.13 a) MSDI-3 및 b) MSDI-6의 군집 분석결과

각 클러스터에 대해 동일 클러스터의 MSDI를 평균한 자료는 그림 7.14 및 7.15에 도시화 하였으며, 가뭄의 심도에 따른 가뭄의 증·감 경향을 분석하였다. MSDI-6와 비교하여 가뭄의 빈도가 MSDI-3에서 뚜렸담을 보이며 가뭄의 발생횟수, 지속기간 및 심도는 표 7.4에 정리하였다. MSDI-6는 MSDI-3에 비해 긴 가뭄 지속기간을 보이는 경향을 보이며 이러한 차이는 가뭄의 심도가 깊어짐에 따라 더욱 뚜렷이 나타나는 특성을 보인다. 비슷하게, MSDI-6에서 가뭄의 심도(Severity)가 증가함 또한 관찰된다. 중간 및 심각한 가뭄의 빈도는 남한의 북쪽 지역에서 발생하는 것으로 분석된다. 이에반해, MSDI-3의 경우 CL-2에서 그리고 MSDI-6의 경우 CL-4에서 남쪽 해안 지여에서 가뭄의 지속시간이 길고 심도가 높음을 보인다. 공간 평균된 가믐의 형태는 가뭄의 정도가 매우 심각한(Extreme Drought) 조건에서는 다른 경향을 보인다. 즉, MSDI-3의 경우 CL-3 지역 (북쪽지역)에서 심각한 가뭄을 보이는 반면 MSDI-6의 경우에는 CL-4(남쪽 해안)지역에서 심각한 가뭄이 발생함을 보인다.

추가적으로, Quantile Regression 모델을 이용하여 사전데 정의된 가뭄 기준에 대한 과거 경향성을 분석하였으며 그 결과는 그림 7.14 및 표 7.4에 정리하였다. 표 7.4에 음영 및 볼드체로 표시된 결과는 $P < 0.05$ 조건하에서 통계적으로 유의미한 가뭄의 증·감 경향이 있는 결과를 표시한 것이다. MSDI-3의 경우, CL-1 지역은 통계적으로 유의미한 가뭄의 증·감 추세는 보이지 않는 것으로 분석되었으나, CL-3 지역에서는 감소 경향이 뚜렷이 나타났다. MSDI-3의 경우, 현저한 감소 경향은 CL-2 지역에서는 가뭄심도의 중간(median) 값에서 그리고 CL-4 지역에서는 모든 가뭄의 심도(즉, extreme, moderate and median) 에서 보였다.

표 7.4 a) MSDI-3 및 b) MSDI-6의 가뭄 발생횟수, 지속기간(Duration) 및 심도(Severity)

Threshold	The number of Events					Duration					Severity				
	CL-1	CL-2	CL-3	CL-4	CL-5	CL-1	CL-2	CL-3	CL-4	CL-5	CL-1	CL-2	CL-3	CL-4	CL-5
MSDI-3															
Moderate	33	29	**41**	34		3.4	**4.5**	3.0	3.5		5.5	**7.2**	4.6	5.6	
Severe	22	25	**26**	**26**		2.6	**2.8**	2.2	2.5		5.1	**5.4**	4.2	4.8	
Extreme	11	**13**	7	11		1.8	1.6	**2.3**	1.6		4.4	3.8	**5.8**	3.9	
MSDI-6															
Moderate	**25**	**25**	23	20	24	4.6	4.8	5.2	**6.4**	5.0	7.1	7.6	8.3	**10.3**	8.2
Severe	17	**20**	16	17	19	2.6	2.7	**3.9**	3.8	3.8	5.4	5.3	**7.6**	7.4	7.4
Extreme	7	7	**11**	9	12	3.1	2.7	2.3	**3.3**	2.0	7.5	6.6	5.3	**7.5**	4.7

전반적으로 MSDI-6가 MSDI-3에 비해 가뭄의 경향이 심화되는 (음의 기울기) 경향이 뚜렷하다 (그림 7.14-15). 더불어, 본 연구에서 개발된 MSDI는 과거 30년간에 발생되었던 가뭄을 잘 재현하는 것으로 나타났으며 이는 그림 7.14 및 7.14에서 음영으로 처리한 막대 그래프에서 확인할 수 있다. 그림에서 표시된 바와 같이 과거 1994-1996, 2000-2002 그리고 2013-2015 가뭄이 사전 연구와 같이 잘 표현된 것이 확인된다 (Kwon et al., 2016; Min et al., 2003; Nam et al., 2015).

표 7.5 MSDI 가뭄지수의 분위별 Trend 분석 결과

Cluster	MSDI-3($\times 10^{-3}$)				MSDI-6($\times 10^{-3}$)			
	Extreme	Severe	Moderate	Q_{50}	Extreme	Severe	Moderate	Q_{50}
CL-1	1.14	0.07	-0.79	-1.21	**-3.55**	**-3.17**	**-1.60**	**-2.00**
CL-2	1.13	-0.34	-0.07	**-1.39**	**-3.63**	**-3.07**	**-3.19**	**-1.82**
CL-3	**-3.51**	**-3.29**	**-1.79**	**-1.78**	-1.36	-1.15	-1.11	**-1.96**
CL-4	**-2.21**	-0.77	**-1.70**	**-2.28**	0.09	-0.13	-1.10	**-1.92**
CL-5					-2.69	-1.49	-1.32	**-2.37**

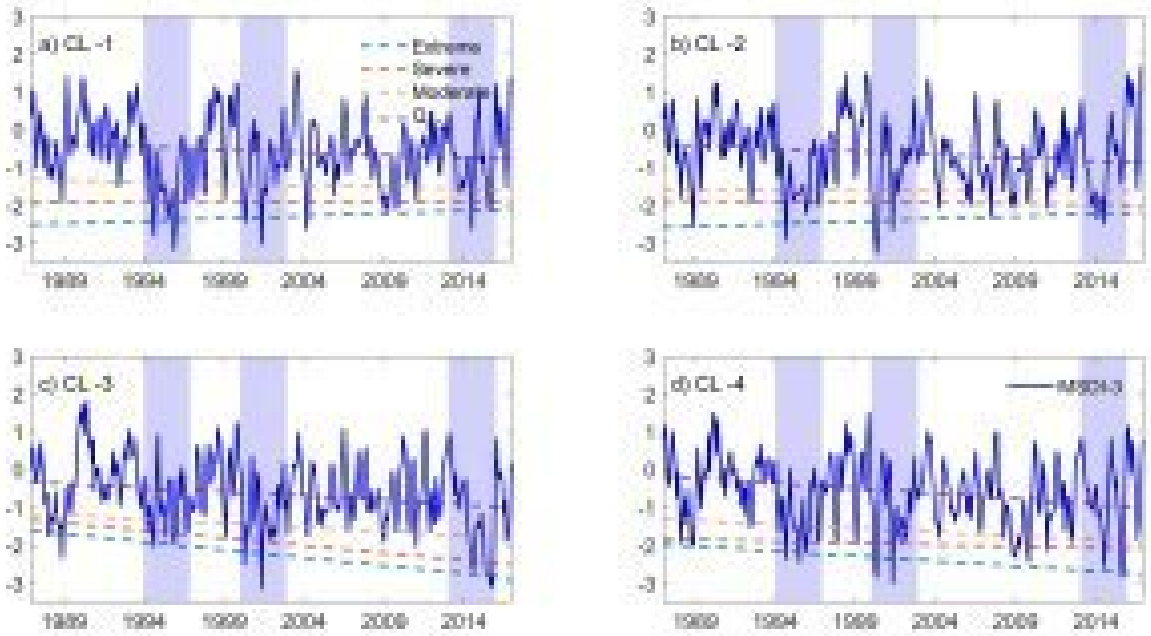


그림 7.14 클러스터별 MSDI-3의 시계열 변화 및 가뭄 정도에 따른 경향성

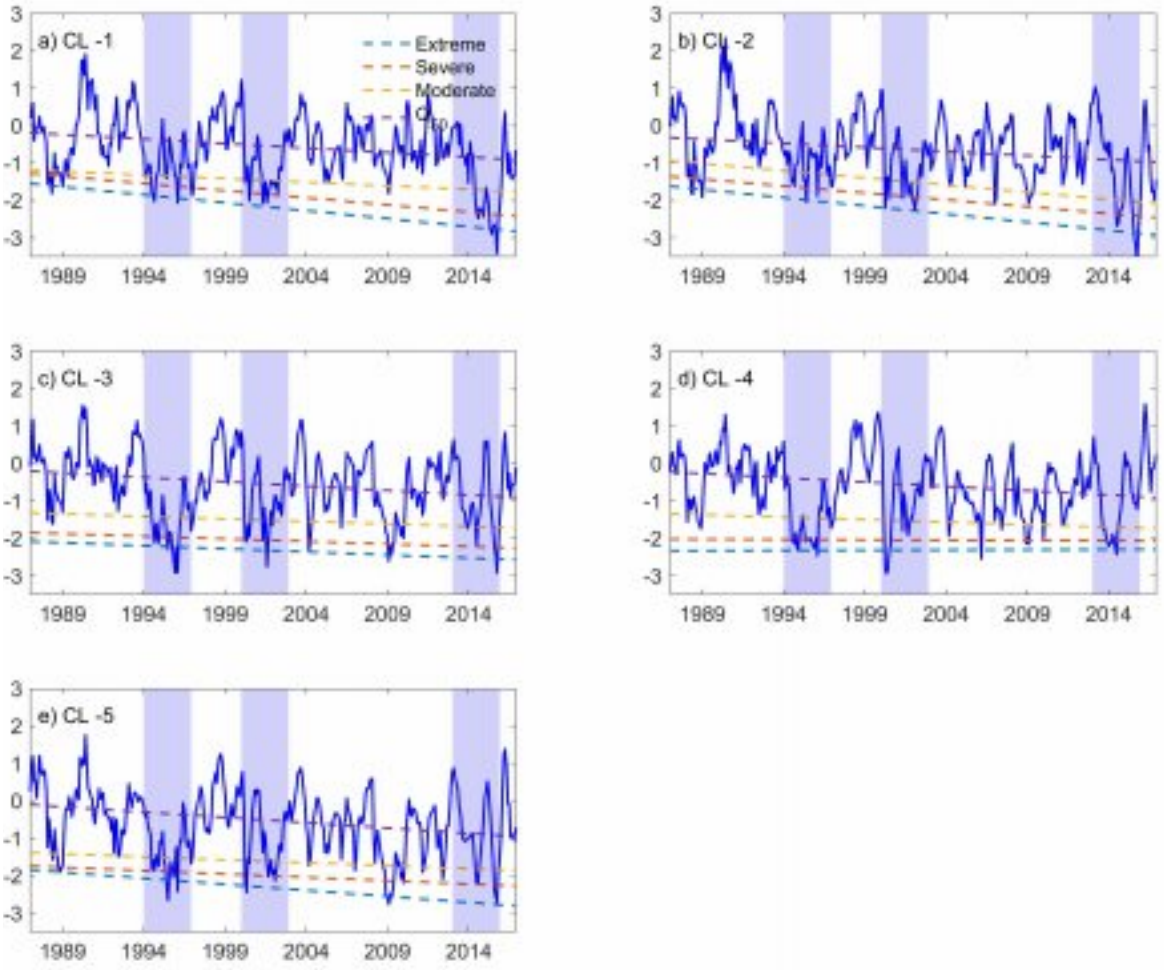


그림 7.15 클러스터별 MSDI-6의 시계열 변화 및 가뭄 정도에 따른 경향성

7.4 결 론

가뭄은 기후변화 등으로 세계 여러 지역에서 점증되는 이슈로 등장하고 있으며, 가뭄의 자연재해와 그리고 이와 관련된 사회경제적 취약성을 평가하고 모니터링을 하기 위해서는 수문기상학적 모델링 프레임워크가 필요하다. 본 장에서는 다른 시공간 스케일에서 기상학적 가뭄지수(SPI) 및 농업적가뭄지수(SSI)를 유도하고 두 가뭄지수를 이용 과거 가뭄 양상을 평가하였으며 강우로부터 유도된 SPI와 토양수분자료를 활용 산정된 SSI의 각각의 특징을 살펴보았으며 또한 두 가뭄지수의 특성을 비교·평가도 수행하였다. 결론적으로 두 가뭄지수는 지속 시간 및 가뭄심도에 있어서 다소 다른 특성을 보이나, 또한 기상학적 가뭄이 농업적 가뭄으로 전이되는 현상도 분석할 수 있었다.

더불어, 이러한 두가뭄의 상호 영향 및 독립적 경향을 고려하여 코플라 함수를 이용하여 유도된 다변량 가뭄지수(MSDI)도 본 장에서 소개하였다. 이렇게 도출된 MSDI는 가뭄의 지역적 특성을 해석하기위해 군집분석을 통해 서로 비슷한 과거 가뭄 사상을 보이는 지역을 클러스터링후 가뭄의 특성을 개별 지점이 아닌 지역화하여 분석도 실시하였다. 본 장의 연구성과를 요약하자면 다음과 같다.

1) 기상학적 가뭄에서 농업적가뭄으로 전이되는 현상은 확연히 보였으나, 이러한 관계의 정도는

계절적 영향을 많이 받는 것으로 나타났다. 다시말하자면, 농업적 가뭄은 건조(winter-spring) 기간에는 1개월정도의 지체시간을 보였으며, 우기시에는 SPI와 SSI 지수가 거의 동일하게 반응하는 것을 알 수 있었다. 이는 선행 토양수분의 조건에 따라 기상학적 가뭄이 농업적가뭄으로 전이되는 시간에 영향을 미치는 것으로 사료된다. 즉, 토양수분량이 많은 우기시에는 기상학적 가뭄이 농업적 가뭄에 영향이 건기시보다 약함을 알 수 있다.

2) 농업적 가뭄지수 SSI의 특성을 자기상관분석(autocorrelation) 기법을 활용 분석한 결과 기상학적 가뭄 지수인 SPI에 비해 그 출현 빈도는 적으나, 지속시간은 상대적으로 긴 것으로 나타났다. 이러한 현상을 볼 때, 가뭄의 출현의 예측은 SPI 지수를 통해 감시하고, 가뭄의 지속성은 SSI 지수를 활용하는것이 보다 합리적이라 판단된다. 이러한 분석 결과는 과거 31년의(1986-2016) 가뭄지수를 분석한 결과 대부분의 관측 지점에서 SSI 지수가 SPI 지수대비 1개월의 지체된 사실에서도 알 수 있다.

3) 본 장에서는 수문학적 가뭄지수와 농업적 가뭄지수 간의 상호 작용(interaction) 및 상호 의존성(interdependence)을 분석하고자 코플라 함수에 기반한 MSDI 가뭄지수를 소개하였다. 더불어, MSDI 가뭄지수의 공간적인 패턴을 분석하기위해 Hierarchical agglomerative clustering 기법을 이용하였다. 군집분석 결과 대부분의 지점에서 공간적으로 인접한 관측소가 같은 군집(cluster)에 포함된 것이 보였으며 이는 지역별 가뭄에 대처하고 가뭄의 영향을 최소화하는 계획을 수립하는 것이 타당함을 보여준다.

4) MSDI 가뭄지수의 지역화이후 과거 가뭄의 증·감 경향(trend)을 분석하기 위해 분위회귀분석(quantile regression) 모델을 사용하여 가뭄의 심도에 따른 증·감 경향을 파악하였다. Moderate에서 Severe한 가뭄조건에서, 남쪽 해안지역이 가뭄의 출현 빈도가 높음을 알 수 있었으며, 또한 남한의 북쪽지역에서 가뭄의 심도가 깊음을 볼 수 있었다. 전반적으로 MSDI-6 가뭄지수의 감소 경향(가뭄의 출현 경향이 높아짐)이 지배적임을 알 수 있었다.

제 8 장 수자원분야 위성영상 기술 활용방안 및 사업모델

8.1 연구 배경 및 방법

8.1.1 연구 배경

1) 정부의 그린뉴딜 정책에 부합하는 수자원 분야 위성영상 기술 활용 플랫폼 개발 사업 모델 필요성

기후변화 적응역량 강화를 위한 수자원 분야의 위성영상 기술 활용 물관리 및 수변환경 관리를 위한 분석 플랫폼 개발이 필요한 실정이다.

기법 및 자동화 모듈 적용 등을 통한 지능형 스마트 물관리 시스템의 개발이 필요한 실정이며, 다양한 위성영상의 빅데이터를 융합·활용한 기술 개발이 필요하다.

2) 차세대 중형위성 개발사업에 따른 수자원 분야 위성 영상 기반 활용 사업 모델 제시 필요

K-water, 미래창조과학부, 한국항공우주연구원 중심 2025년까지'차세대 중형위성 개발사업'을 통한 수자원·수재해 위성 개발 계획에 맞추어 새로운 수자원 분야 위성 영상 기반 활용 사업 모델의 제시가 필요하다 (약 1,384억 원 규모, 환경부 880억 원, 과학기술정보통신부 504억 원).

대용량의 위성 자료 빅데이터를 보다 효율적으로 처리·관리·서비스하기 위한 수자원 및 수재해 위성 산출물에 대한 생산 공정, 데이터베이스, 자료의 품질 등의 표준화 체계의 구축이 필요하다 (Ahn and Park, 2012).

위성기반 수자원 분야 빅데이터 분석 및 분석 기술 개발을 통한 세계적 수준의 위성활용기술 위상 제고 및 지구촌 물 문제 해결에 대한 선제적 대응이 가능할 것으로 기대된다.

3) 국내·외 물 산업 트렌드를 고려한 위성영상 활용 방안 제시 필요성 대두

국내 위성기반 수자원 분야의 활용을 위한 인프라 및 관련 기술 수준이 상대적으로 미진한 것으로 나타나, 해당 분야에 대한 기술 개발 및 추가적인 투자가 필요한 실정이다 (국토지리정보원, 2014).

기상청, 한국항공우주연구원, 한국해양과학기술원 해양위성센터 등 각각 다양한 위성을 운영하고 있으나, 생산된 정보를 종합적으로 관리하는 시스템 및 주체가 명확하지 않은 실정이다.

물산업 트렌드를 고려한 위성영상 활용 방안 제시를 통하여 이수, 치수, 생태환경 등 수자원 분야에 대한 광범위한 실시간 정보를 제공할 수 있으며, 이에 대한 지속적인 개발이 추진되어야 한다.

보다 효율적인 자료의 활용을 위해서 수자원 및 수재해 위성 산출물에 대한 지상(on-ground) 및 비행(in-flight)에 해당하는 검보정 처리과정 및 절차의 수립이 필요하며, 신뢰도 확보를 위한 평가·검증 시스템의 마련이 필요하다 (황의호 외, 2018).

* 수자원 : 모든 데이터의 오결측을 룰 베이스로 탐지, 동일 기법을 활용하여 보정 (강수량・수위

자동보정 및 수동 검보정을 위한 알고리즘 지원)

* 수도 : 본사로 전송되는 데이터만 대상으로 룰 베이스로 오결측을 탐지, 필요시에만 수동 보정 시행 (관리자가 직접 검보정하여 값 입력)

실제 관측시설, 계측기기, 그리고 해석 방법 등의 한계로 유체, 수리 및 수문학적 의미에 부합하지 않는 데이터가 발생하는 문제가 있으며, 물리적 의미에 맞지 않는 데이터는 최종 데이터 정리・발간 단계에서 일부 확인 및 필요에 따라서 수정하고 있으나 검보정, 현장 관측 및 해석 방법 등에 대한 피드백은 이루어지 않는 실정이다 (K-water, 2019).

이에 따라 품질관리 단계별로 최적화된 알고리즘의 개발・제시하는 한편 물관련 모든 분야에 공통으로 적용할 수 있는 시스템 구축이 필요하며, 시계열 관측데이터의 특징을 고려, 수자원 및 수도 분야에 공통적으로 적용할 수 있는 검보정 알고리즘 Pool의 도출・개발이 필요한 실정이다.

8.1.2 연구 방법

가. 수자원분야 위성영상 기술 국내외 현업적용 사례 조사 및 분석

1) 국내·외 문헌조사를 통한 수자원 분야 위성영상 활용 기술 현황 조사 및 분석

- 기존 국내·외에서 활용중인 수자원 분야 위성 산출물 및 현업 적용 사례 조사·분석
- 위성 산출물 이외 수자원 분야 위성영상 기술을 활용한 국내·외 현업 적용 사례조사 및 분석

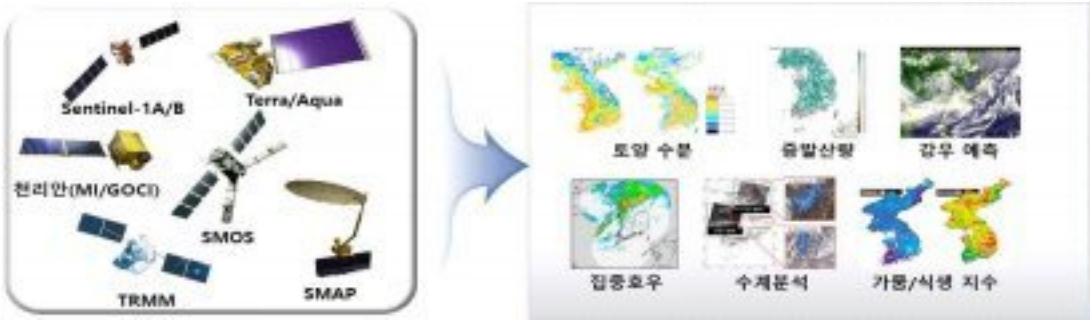


그림 8.1 수자원 분야 위성 산출물 리스트 조사·분석

2) 수자원 분야 위성영상 활용 사례 분석을 통한 국내 적용 방안 제시

- 수자원 분야 위성영상 활용 사례 분야별 분류
- 국가 물관리 분야(수자원 관리, 수재해 등)에 대한 위성영상 활용기술의 현업 적용 사례를 통한 국내 적용 방안 제시
- 국가 물환경 분야(수질, 수생태 분석 등)에 대한 위성영상 활용기술의 현업 적용 사례를 통한 국내 적용 방안 제시
- K-water에서 추후 적용할 수 있는 위성영상 활용 현업 적용 방향 제시

나. 국내외 물산업 트렌트를 고려한 위성영상 활용 국내외 사업모델 제시

1) 국내·외 위성영상 활용 수자원 분야 플랫폼 현황 비교·분석

- 국내·외 물 분야 관련 위성 영상 및 공간 빅데이터 활용 플랫폼 현황 비교·분석
- 각 플랫폼에서 제공하는 정보의 비교·분석을 통한 국내·외 물산업 트렌드 분석

2) 물산업 트렌드를 고려한 위성영상 활용 수자원 분야 사업모델 제시

- 관측, 분석, 가시화 등 통합 플랫폼 개발을 고려한 사업화 모델 제시
- K-water가 확보해야 할 위성 활용기술 제시
- 국내·외 유관기관과의 협력사업, MOU 등 기술교류 방안 제시



그림 8.2 위성 빅데이터 활용분야, 활용방안, 수요기관 등 비교·분석 (예)

8.1.3 기대 효과

가. 수자원분야 위성영상 기술 국내외 현업적용 사례 조사 및 분석

1) 기존에 널리 흩어져 있는 수자원분야의 위성영상 기술 활용 현황 및 현업화 사례를 총 망라함으로써, 추후 K-water 및 더 나아가 우리나라의 물관리를 위한 위성 영상 기술의 활용방안을 도출하는 데에 활용할 수 있음

2) 수자원 조사, 수재해 분석 등 홍수, 가뭄과 같은 수량 중심의 국가 물관리 분야에 대한 참고자료로 활용 가능

3) 기존 수자원 분야 산출물 이외에 C-band 등의 차세대 중형위성을 활용한 수자원분야의 활용 가능성을 탐색하여 참고자료로 활용할 수 있음

4) 치수, 이수, 수재해 등 국내·외 국가단위의 물 관리에 필요한 위성의 활용방안을 비교·분석함으로써 우리나라 4대강 수질 및 수변환경 관리에 참고자료로 활용이 가능 할 것으로 기대됨

나. 국내외 물산업 트렌드를 고려한 위성영상 활용 국내외 사업모델 제시

1) 위성 빅데이터 분석, 위성 정보활용 촉진, 관련산업 육성 등을 통해 일자리 창출에 기여할 것으로 기대됨

2) 위성기반 수자원 분야 분석 기술 개발을 통한 세계적 수준의 위성활용기술 위상을 제고하고 및 지구촌 물 문제 해결에 대한 선제적 대응이 가능할 것으로 기대됨

3) 홍수 및 가뭄, 수자원 관련 시설물 및 환경의 변동, 녹조 및 적조 탐지, 호소 및 해양환경의 주기적인 감시, 농작물 생육 및 농수수요 예측 등 다양한 분야에서 활용이 가능하며, 최종적으로 국내의 통합적 물 관리 플랫폼 실현의 중추적 역할을 수행할 것으로 기대됨

4) K-water에서 추진할 수 있는 물분야 사업모델의 밑그림을 제시할 수 있으며, 국가 차원의 협력사업, MOU 등 대규모 사업에 참고자료로 활용할 수 있음

8.2 수자원분야 위성영상 기술 국내·외 현업적용 사례 조사 및 분석

8.2.1 국내·외 수자원분야 위성영상 산출물 현황 분석

가. 수자원 위성의 정의

- “수문순환, 토양수분, 지하수, 식생지수, 증발산량 등 물관리에 필요한 수자원 자료들을 관측하는 위성 (K-water, 2016)”
- 수자원 분야에 활용 가능한 수자원 위성의 자료를 활용한 가뭄, 홍수, 수질 등의 모니터링과 각 수재해에 대한 분석·대응체계 등의 구축이 필요한 실정이다.

나. 기존 국내·외에서 활용중인 수자원 분야 위성 산출물 조사·분석

- 수자원 분야에서 주로 활용되는 국내·외 위성 영상 활용 기술 현황 조사 및 분석 결과, 강우강도, 가강수량 등 강우량 관련 산출물 및 토양수분 관련 산출물이 많은 것으로 나타났다.
- 우리나라 천리안위성 (Communication, Ocean and Meteorological Satellite; COMS), 천리안위성 2호 (GEO-KOMPSAT-2)를 비롯한 기상, 해양관측 위성은 각각 강우, 수질과 관련한 다양한 산출물을 제공하는 것으로 나타났다.
- 해양관측위성의 경우, 연안해역 및 원해에 초점을 맞추어 전반적인 해양의 수질에 관한 인자를 분석하고 있지만, 충분히 호소 및 하천 수질 분석에도 활용이 가능 할 것으로 기대된다. 하지만, 수폭이 상대적으로 좁은 우리나라의 하천에 대한 활용도는 상대적으로 낮다고 판단된다 (GOCI: 500m, GOCI-Ⅱ: 250m 공간 해상도).

- Soil Moisture Ocean Salinity (SMOS) 및 Soil Moisture Active Passive (SMAP)의 경우, L-band (약 1.43GHz) 수동마이크로웨이브를 활용한 토양수분 및 해양염분 추정에 널리 활용되는 위성으로, 국내·외 토양수분 관련 연구에 활발하게 활용이 되는 위성이다. 이러한 토양수분 관련 산출물은 가뭄 등 통합적 물관리에 활용도가 높은 것으로 보이나, 마찬가지로 우리나라의 복잡한 토지피복 및 넓은 산지지형에 대해서는 적용하기가 어려울 것으로 판단된다.
- 추가적으로, Landsat-8 Operational Land Imager (OLI)와 Sentinel-2A/B 의 경우 수자원 분야의 위성 산출물을 따로 제공하고 있지는 않지만, 다양한 선행연구에서 시도 하였듯, 높은 공간해상도 (10~30m)를 기반으로 호소 및 하천의 수질 분석에 충분히 활용할 수 있을 것으로 기대된다.
- COMS-MI / GK2A-AMI, TRMM, GPM 등의 위성이 강우와 밀접한 관계가 있는 산출물을 생산하고 있는 것으로 나타났고, 상대적으로 수자원 분야에서의 C-band SAR 활용도는 아직 미비한 실정으로 판단된다.
- 다양한 수자원 인자에 대한 산출물이 제공되고 있으나, 이들 산출물에 대한 국내·외 지역적인 특성을 고려한 현장자료가 충분하지 않은 실정이다. 특히, 토양 수분 산출물 자료의 경우, 산지가 많고 토지피복이 상대적으로 복잡한 우리나라에 적용할 경우, 보다 다양한 현장관측자료와의 비교를 통한 보완이 필요한데, 국내·외 현장자료(reference) 네트워크가 미비하다고 판단된다.
- 추후 수자원 분야의 위성 활용도에 대한 추가적인 분석이 필수적으로 선행되어야 한다고 판단되며, 각 수자원 분야 산출물의 검보정을 위한 통합형 현장자료 네트워크 (reference network) 구축 및 관리가 필요하다고 판단된다.

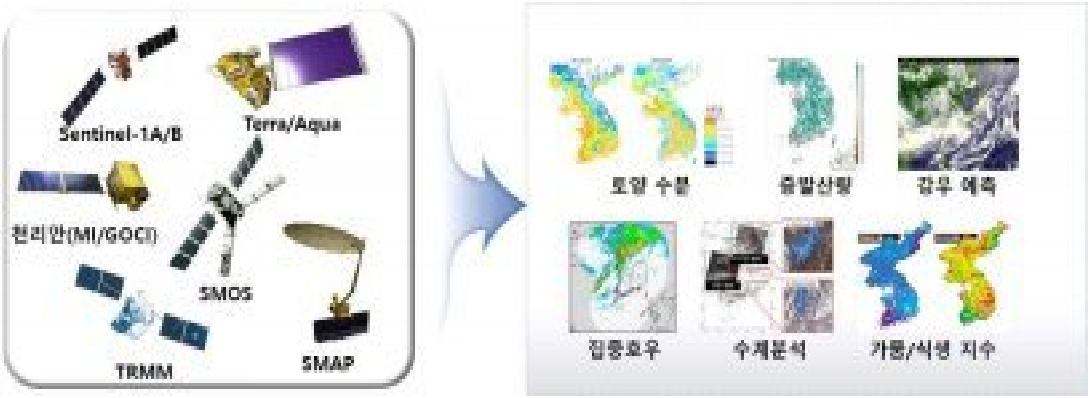


그림 8.3 수자원 분야 위성 산출물 리스트 조사·분석

표 8.1 국내·외 수자원 분야 위성 산출물 및 시·공간 해상도

센서	수자원 산출물	공간해상도	시간해상도
COMS-MI / GK2A-AMI	Perceptible water, rainfall intensity, solar surface insolation, … (L2)	1-4km	15min
COMS-GOCI / GK2B-GOCI II	Chl-a, SS, under water visibility, water quality, … (L2)	0.5-2km	Hourly
SMOS	Soil moisture (L2)	35 - 50km	1-3 days
SMAP	Soil moisture (L2, L3, L4)	3 - 36km	1-7days
TRMM	Rainfall profile (L2), precipitation (L3)	5km/0.25deg	Daily/3hour
MODIS-Terra/Aqua	NDVI and EVI (L3)	0.25 - 1 km	16 days
	Evapotranspiration (L4)	500m	8 days / yearly
	Total precipitable water (L2, L3)	1km - 0.5deg	Daily / 8 days
Sentinel-1A/B	Ocean wind, swell, surface radial velocity (L2)	5m	-
Sentinel-2A/B	(ocean) Chl-a, ... (L2)	10-20m	3-5days
Sentinel-3A/B	(ocean) Chl-a, TSM, Kd490, ADG, ... (L2)	300 - 1,000m	2 days
GPM	Precipitation radar (L2), monthly rainfall (L3)	Orbit / 0.5deg	30min / monthly

다. 한계점 및 논의사항

- 국내·외 운영 중인 해양관측위성의 경우, 연안해역 및 원해의 수질에 초점을 맞추고 있지만, 충분히 호소 및 하천 수질 분석에도 활용이 가능 할 것으로 기대됨, 하지만 수폭이 상대적으로 좁은 우리나라의 하천에 대한 활용도는 상대적으로 낮다고 판단된다.
- 토양수분 관련 산출물의 경우, 우리나라의 복잡한 토지피복 및 넓은 산지지형에 대해서는 적용하기가 어려울 것으로 보인다.
- 다양한 선행 연구에서 볼 수 있듯, Landsat 및 Sentinel 시리즈의 경우 높은 공간해상도를 기반으로 호소 및 하천의 수질 분석에 활용하기 용이하다고 판단된다.
- 다양한 수자원 관련 산출물을 분석에 활용하기 위한 현장자료가 충분하지 않은 상황으로, 각 수자원 분야 산출물의 검보정을 위한 통합형 현장자료 네트워크 (reference network) 구축 및 관리가 필요하다고 판단된다.
- 수자원 분야에서의 C-band SAR 활용도는 상대적으로 미비하므로, 추후 수자원 분야의 위성 활용도에 대한 추가적인 분석이 필수적으로 선행되어야 한다고 판단된다.

8.2.2 국내·외 수자원분야 위성영상 기술 활용 사례 분석

가. 국내·외 수자원분야 위성영상 활용 현황 분석

- 수자원 분야에서는 수문순환과 관련하여 토양수분, 증발산 등과 같은 위성 산출물을 활용하고 있으며, 가시광선 및 마이크로파 센서가 탑재된 인공위성을 주로 활용하고 있다.
- 증발산 정보의 경우 에너지 수지 기반의 가시광선 센서가 주로 활용되며, 토양 수분 관련 지표는 마이크로파 센서를 주로 사용하고 있다 (Baik et al., 2017).
- 국외 가시광선을 활용한 위성은 GOES, MODIS, VIIRS, MTSAT, Landsat 등이 있으며, 마이크로파를 활용한 위성은 AMSR-E, AMSR2, ASCAT, SMAP, SMOS 등이 있다.
- 대표적인 국외 수자원·수재해 관련 위성 활용 현황은 아래 표와 같음

표 8.2 국외 수자원·수재해 관련 위성 활용 현황 (채효석 외, 2017)

센서명	국가	발사일	적용분야
Sentinel-1A	유럽	‘14. 04. 25	전지구 재해, 해양, 지형 등 변화 관측
RADARSAT-1	캐나다	‘95. 11. 04	전지구 기후변화 감시 및 지표면 변화 탐지
RISAT-1	인도	‘12. 04. 26	자연재해관리, 농업계획, 홍수예측·예방을 위한 관측
SMAP	미국, 캐나다	‘15. 01. 29	전지구 토양수분 측정
Terra	미국, 캐나다, 일본	‘99. 12. 18	미국, 캐나다, 일본의 공동 지구 관측
GPM	미국, 일본	‘14. 02. 28	기후 변화 및 물 순환 변동 분석
GRACE	미국, 독일	‘02. 03. 17	중력장 모델링을 위한 고정밀 중력 측정
AQUA	미국	‘02. 05. 04	물 순환 및 대기, 해양, 육지 분야 등 지구 환경변화 연구
SMOS	EU	‘09. 11. 02	토양 수분 분석 및 해양 염분 분포 조사
Landsat-8	미국	‘13. 02. 11	다중분관 영상 및 열적외 영상을 통한 전지구 관측

- 국내·외 모두 수자원 분야에 위성영상을 적극적으로 활용하고 있으나, 빅데이터 기반 융·복합 활용 플랫폼은 제대로 구축되어있지 않은 실정이다.
- 국토교통부, 환경부 등에서 수자원 관련 정보 제공 시스템을 구축·운영하고 있으나, 가뭄, 하천건천화, 홍수 등 수자원 분야의 재난과 관련한 실시간 감시·예측 시스템은 활용되고 있지 않은 실정이다 (K-water, 2013).

- 현재 국내에서 제공되고 있는 수자원 관련 정보 시스템은 아래 표와 같으며, 기관 간 자료의 공유·전송·관리 등 통합적 시스템은 미비한 상황이다.

표 8.3 국내 수자원분야 관련 빅데이터 분석 및 제공 시스템 현황 (K-water, 2019)

운영 주체	시스템
국토교통부	국가수자원관리종합정보시스템(WAMIS), 하천관리지리정보시스템(RIMGIS), 물관리정보유통시스템(WINS), 홍수예보시스템 등
행정안전부	재난정보공동활용시스템, 상황전파시스템, 중앙 및 지자체 재난관리 시스템, 재난관리정보 DB센터
환경부	물환경정보시스템, 방재기상정보시스템, 상하수도정보시스템, 환경공간정보서비스 등
농림수산식품부	농촌용수종합정보시스템(RAWRIS), 농어촌지하수넷 등
K-water	국가지하수정보센터, K-water 위성영상관리시스템
기상청	기상청 종합기상정보시스템(COMIS-3), 날씨예보

- 한국항공우주연구원에서 운용하는 다목적실용위성 5호의 경우, X-band SAR 영상을 활용한 구름에 영향을 받지 않는 수자원 감시가 가능하지만, 수자원 관련 기관과 공동 활용을 위한 인프라가 미비한 실정이다 (정수은 외, 2018).
- K-water에서 2015년 K-water 위성영상관리시스템 (K-SIMS, K-water Satellite Image Management System)을 구축하여 AQUA, TERRA, NPP, GCOM-W, GMP와 같은 다양한 위성에서 얻어지는 57종의 수자원 관련 빅데이터를 활용하여 토양수분, 증발산 등의 분석에 이용하고 있으며, 북한지역과 같은 미계측지역에 대한 모니터링에 활용하고 있으나(Choi et al., 2017), 아직 활용도는 미진한 상황이다.
- 미국 NASA에서 운용하는 SMAP 위성 산출물의 경우, 수량 예측을 위하여 MSFC 알고리즘 기반의 수분 표면 광도 및 유량 모델에 대한 정확한 정보를 확보하여 홍수 및 가뭄 예측, 기후변화 예측 등에 활용하고 있으며, 보다 정확한 강수량 산출을 위하여 다중위성자료(GPM, DMSP, AQUA 등)를 활용하고 있다 (정수은 외, 2018).
- 일본 JAXA는 Sentinel Asia (아시아-태평양 재난관리를 위한 국제기구) 웹사이트를 통하여 모니터링 자료를 공유하고 있다.
- 유럽의 경우, 홍수 관리를 위한 JRC (Joint Research Center)를 설립하여 AMSR-E 관측정보 기반의 전세계 홍수 모니터링 시스템을 구축하였으며, 독일의 경우 RapidEye 위성을 활용하여 대륙 규모의 수자원관리를 위한 정보를 제공하고 있다 (KAIA, 2016).
- 미국의 경우, NASA 및 USGS 에서 가뭄 및 홍수의 감시, 녹조 탐지, 적설 탐지 등 다양한 분야에 위성을 활용하고 있으며, 유럽 ESA와 일본 JAXA 또한 Sentinel, GCOM 등 다양한 위성을 활용하여 수자원분야에 활용하고 있는 실정이다 (Choi et al., 2017).

8.2.3 국내·외 위성영상 활용 수자원 분야 플랫폼 현황 비교·분석

가. 위성영상 활용 수자원 분야 위성영상 활용 플랫폼 운영 사례 조사.분석

- 국내 수자원분야에서 위성영상을 활용한 각종 시스템에 대한 사례를 조사·분석 한 결과, 국토교통부, 국민안전처, 환경부를 비롯한 다양한 기관에서 각 목적에 맞춘 다양한 수자원 정보를 제공하고 있는 것으로 나타났다.
- 하지만, 부처간에 중복된 정보를 제공하는 경우도 많은 것으로 나타났으며, 각 수자원 정보에 대한 표준화(standardization) 관련 정책이 미비한 것으로 판단된다.
- 교육기관 및 연구소 등에서 국가에서 제공하는 자료의 활용도를 증진하고 민·관에서 보다 의미 있는 정보로 활용·제공하기 위해서는 각 자료에 대한 보다 심도 있는 자료의 관리가 필요하다고 판단된다.
- 사용자의 입장을 고려한 정보의 표준화 과정 및 quality assurance (QA)/quality control(QC) 과정이 적용 될 필요가 있는 것으로 보인다.

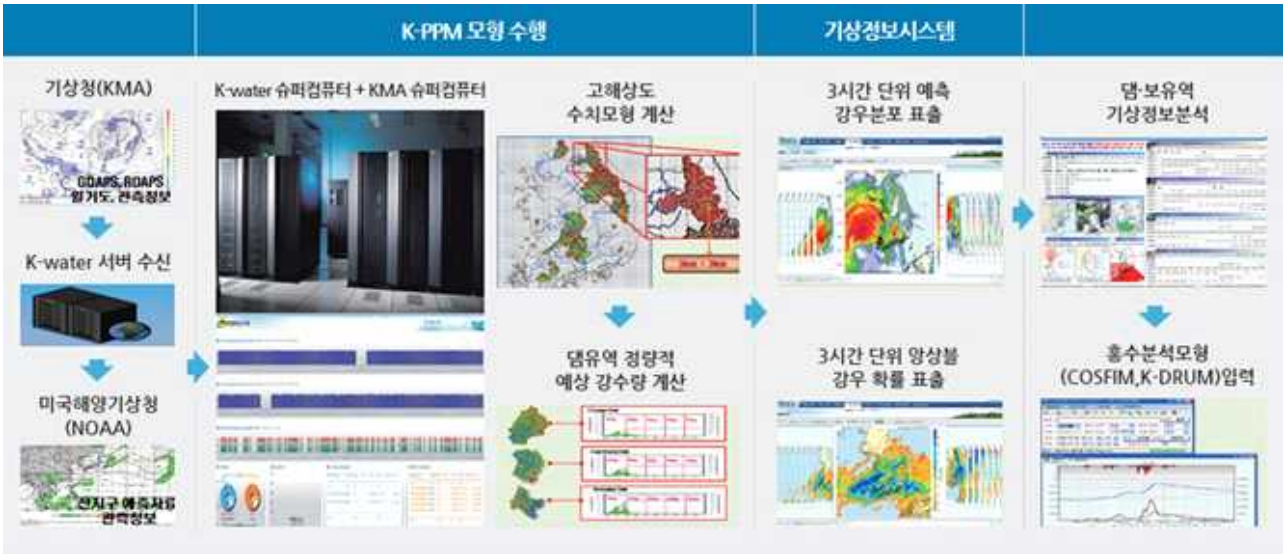


그림 8.4 K-water 댐·보유역 강우예측시스템(K-PPM) 생산 및 운영체계 (자료: K-water 홈페이지)

8.3 국내외 물산업 트렌드를 고려한 위성영상 활용 국내외 사업 모델 제시

8.3.1 국내 물산업 트렌드 분석

가. 물산업 트렌드 분석

- 본 과업에서는 국내외 물산업 트렌드 분석을 위하여 환경부 물산업 통계조사 결과를 활용하였으나, 위성활용에 대한 내용이 부족하다고 판단하여, 한국수자원학회, 수자원 관련 그린뉴딜 정책, K-water 관련 문헌조사를 추가적으로 수행하였다.

나. 국내외 물산업 트렌드 분석: 2019년 물산업 통계조사 (환경부, 2019. 12.)

- 국내 물산업의 경우, 내수시장에 의존하고 있어, 해외 수출로 인한 매출을 증가시킬 수 있는 접근이 필요 한 것으로 보인다. 물 산업 분야 총 매출의 1.2%만이 해외 수출로 인한 매출을 구성하고 있으며, 이어서 공공기관 (40.3%) 및 민간기업 (58.0%)으로 나타났다.
- 우리나라의 경우 과학기술 R&D 규모가 상대적으로 작은 것으로 나타났으며, 총 8,943억원 가량의 물산업 규모 중, 단 13%만이 과학기술 및 엔지니어링 분야인 것으로 나타났다. 이 외 물산업 관련제품 제조업이 63.5%, 건설업이 19.9%로 나타나, 과학기술 및 엔지니어링분야에 대한 보다 적극적인 R&D 창출이 필요할 것으로 보인다.
- 세계 물 시장은 약 5,800억 달러 규모의 거대 산업 시장을 이루고 있으며, 이러한 트렌드에 따라서 우리나라 또한 세계 시장에서 활약할 수 있을 물산업 성장기반을 마련할 필요가 있다.
- 또한, 미국 및 유럽 등 각 선진국에서는 통합물관리 (Integrated Water Resource Management, IWRM)에 대한 수요가 지속적으로 증가하고 있는 것으로 나타났으며, 특히 물, 토양 등 수자원과 직·간접적으로 관련된 자원의 조직화된 스마트 관리 기술 수요가 증가하고 있는 것으로 나타났다.

다. 물산업 트렌드 분석: 한국형 뉴딜

- 그린 뉴딜 정책의 경우, 디지털 뉴딜과 그린뉴딜 사업의 융합 형태로 진행될 예정이다 ('20. 05. 20. 보도자료).
- 이 중, 그린뉴딜은 4차산업혁명 기술(AI, ICT, IoT 등)의 접목을 통해 아래와 같이 두 가지 목표를 가지고 진행예정이다.

  * (1) 집중적인 저탄소 융합형 RDD&D (연구, 개발, 실증, 확산) 추진 및 (2) 융합형의 요체는 지역경제/일자리 효과를 최대화하도록 관리체제 제도적 기반을 정립하도록 그린뉴딜을 접근하는 것이 필요

- 한국수자원학회, 대한상하수도학회 등이 모여 논의한 「물관리 그린뉴딜」 정책심포지엄 (2020. 06. 29.)에서는 다음과 같이 네 가지 주제에 대하여 심포지엄을 진행하였다.

표 8.4 「물관리 그린뉴딜」 정책심포지엄 (2020. 06. 29.) 발표주제 및 발표자

주제	발표자 및 소속
(1) 녹색전환 실현을 위한 바람직한 물관리 그린뉴딜	전경수, 한국수자원학회장
(2) 그린뉴딜, 물환경분야에는 어떤 의미로 다가와야 하는가	이창희, 한국물환경학회장
(3) 그린뉴딜에 입각한 통합물관리 방향과 현안과제	박창근, 대한하천학회장
(4) 상하수도인이 바라본 그린뉴딜 사업	구자용, 대한상하수도학회장
(5) 한국판 뉴딜과 물복지	김병기, K-water 물정책연구소장

- 강살리기네트워크 대한하천학회 및 물개혁포럼 수돗물시민네트워크 환경운동연합에서 주최한 [한국판 뉴딜과 물 분야의 그린뉴딜] 심포지엄 (2020. 05. 20.)에서는 생태하천, 물관리 인프라, 비점오염원 저감, 시민참여와 관련한 주제에 대한 논의가 이루어졌다.

표 8.5 한국판 뉴딜과 물 분야의 그린뉴딜 심포지엄 (2020. 05. 20.)

세션	주제	발제자
생태하천	대청댐 중초천 사례를 통한 댐 상류 생태하천 복원사업	- 민경진 한국수자원공사 금강유역본부장
	보철거를 통한 하천 연속성 회복	- 김원 한국건설기술연구원 선임연구위원
	멸종위기 어류 보호와 생태하천 지키기	- 남준기 내일신문 기자
인프라전환	물-에너지-도시 넥서스 그린인프라 전환	- 현경학 환경정의연구소 그린인프라위원회 위원장
	친환경 녹색전환 수상태양광사업	- 주인호 한국수자원공사 물에너지처 부장
	노후 수도시설 조사 및 개선	- 최승일 고려대학교 명예교수
비점오염저감	비점오염원 저감사업	- 김미선 한국강살리기네트워크 정책위원장
	생명의 강을 위한 수변매입 사업	- 이준경 생명그물 대표
시민참여	시민참여 수돗물관리	- 이상현 수돗물시민네트워크 집행위원장
	시민 참여 강가꾸기 사업	- 염형철 사회적협동조합 한강 대표
	기후변화시대, 상수원 보호구역의 생태계서비스지불제도 도입	- 신재은 환경운동연합 생태보전국 국장

라. 물산업 트렌드 분석: K-water

- K-water에서 활용하고자 하는 물산업 트렌드의 경우, 아래와 같이 세가지 분야로 구분할 수 있다.

(1) 물재해 대응능력 제고

· (홍수·가뭄) 장기 유황변화 모니터링 및 공간적 홍수·가뭄정보 생산, 감시, 평가, 광역/지역 침수재해 예측, 피해 모니터링 및 피해 산정 평가

· (수질감시) 광범위한 영역에 발생하는 유역 오염원의 변화 추적 감시, 탁수유발 유역 토양 유실 및 클로로필-a 농도분석을 통한 녹조 예측, 수질사고 감시 등

(2) 미래성장기반 마련

· (해외·에너지사업) 해외사업(투자사업, ODA사업, PM사업 등) 관리 지원 및 신규 투자지역에 대한 조사 활용
· (북한사업) 접경지역 공유하천 관리 및 국가안보에 대비(무단방류 및 시설붕괴)하고, 통일대비 협력사업 발굴을 위한 북한지역 수자원분야 정보(공간정보 등) 축적

(3) 위성정보 활용 부가가치 창출

· (통합물관리) 하천 감시·변화 분석 및 관리방안 수립 등 유역관리 실현
· (재난관리) 선제적 재난대응
· (사전예방) 및 신속·정확한 긴급대응체계 확립
· (우주개발분야 경제 활성화) 수자원 기상 우주 ICT 등 융복합 핵심기술의 선점을 통한 공공 민간부문 위성정보 활용산업 활성화 기여
· (국제협력강화) 차세대 중형위성 탑재체 개발 및 수자원위성 활용센터 운영으로, 위성자료 처리·활용기술 확보 및 국제협력사업 추진

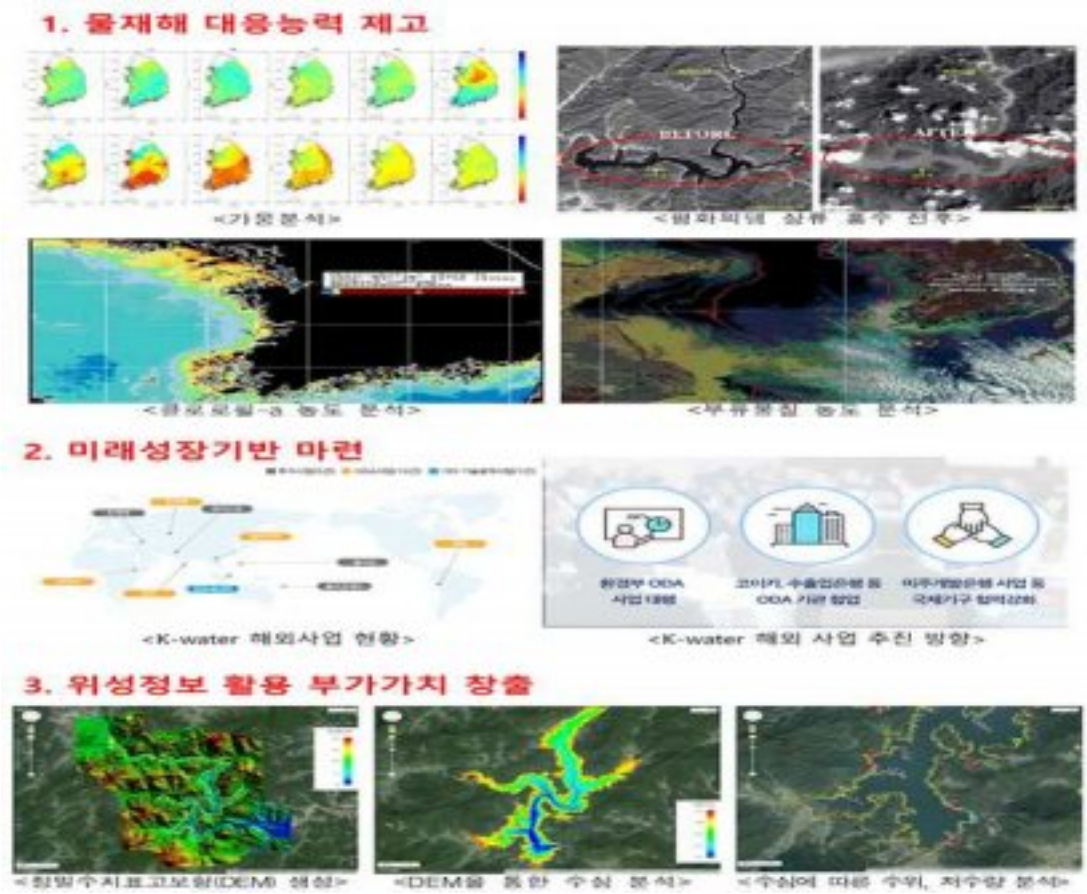


그림 8.5 K-water 물산업 관련 연구 수립 방향 (출처: K-water 보도자료 및 홈페이지)

마. 물산업 트렌드 분석: 한국수자원학회

- 본 과업에서는 한국 수자원학회가 발간하는 「물과미래」 학회지의 수자원 위성 활용 관련 문헌을 조사·분석 하였다.
- 특히, 2019년 10월에 발간된 물과미래 수자원위성 특별호의 경우(Vol. 52, No. 10), 물환경 분야에서의 수자원위성 활용에 대한 깊은 논의가 이루어지고 있어, 본 과업에서 중요한 참고자료로 활용할 수 있을 것이라고 판단하였다.
- 조사 결과, 한국수자원학회에서는 수자원/수재해 모니터링을 위한 위성 탑재체에 관심이 많은 것으로 나타났으며, 물관리 분야 뿐만 아니라, 환경분야에 대한 활용성에도 관심이 있는 것으로 조사되었다.
- C-band SAR 영상을 활용한 활용도 모의중인 것으로 나타났으며, 수자원 분야 위성 관측자료를 종합 활용하여 수리.수문 관련 인자를 산출하고 표준화 알고리즘을 개발하는 것에 대한 활용방안도 제시하였다.

표 8.6 한국수자원학회「물과미래」지 수자원위성 특별호 게재 내용 (Vol. 52, No. 10)

논문 제목	저자
수자원/수재해 전용 위성 영상레이더 탑재체 핵심 기반기술 개발 사업	채효석; 황의호; 최성화; 이승현
수자원/수재해 모니터링을 위한 위성 탑재체 개발 전략 수립	채효석; 황의호; 최성화; 이승현; 이형기; 김동환; 이종혁
C-밴드 영상레이더 탑재체 기술 개발 현황	이상규; 백명진; 유상범; 이현철
영상레이더 환경 분야 활용 기술 및 체계 정립	이명진; 한형경; 윤정호; 이선민; 조남욱
수자원 위성 영상 활용을 위한 수문인자 산출 전략 수립 및 알고리즘 기반 기술 정립과 표준화 및 모듈화	원중선; 박욱; 오광우; 최준혁; 정지훈; 이용관; 장원진; 김성준; 방상호; 최하연; 장수민

8.3.2 수자원 분야 위성영상 활용 사례 분석을 통한 국내 적용 방안 제시

가. 수자원 분야 위성영상 활용 국내 적용 방안 제시

- 본 장에서는 앞서 분석한 수자원분야 국내·외 활용 사례, 플랫폼 운영 현황, 물산업 트렌드 분석 결과를 종합·활용하여 수자원 분야에서 우리나라에 적용 가능한 위성 활용 방안을 제시한다.
- 현재 기대 가능한 위성영상 활용 물분야 빅데이터 적용 범위의 경우 아래와 같이 정리할 수 있으며, 최종적으로는 수자원 분야의 빅데이터 자동 통합관리 플랫폼이 필요한 것으로 판단되며, 아래와 같이 각 단계별로 중·장기 개발 사업을 기획하여 실현할 수 있을 것으로 기대된다.

(1) 수자원 분야의 위성 산출물 품질관리 및 상세화: 수자원 빅데이터 관리 및 QA/QC 시스템 구축
(2) 수자원 분야 다종 위성 융합 활용을 통한 산출물의 고도화: (시·공간) 고해상도 수자원 산출물 생산 및 제공
(3) 다부처 협력을 통한 통합 위성 활용 물관리: 표준화 및 빅데이터 통합 관리·제공 플랫폼 구축
(4) AI 및 자동화 알고리즘 활용 자동 물관리: 수자원 빅데이터의 자동 취득·분석·제공 통합 시스템 구축

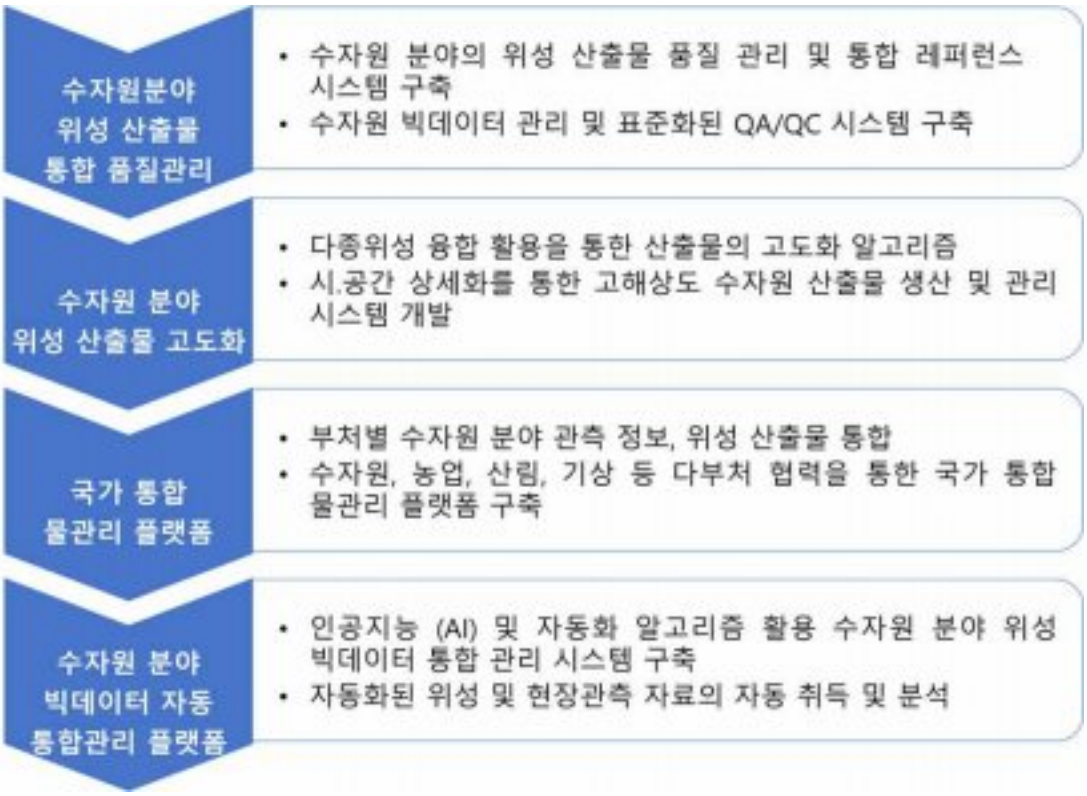


그림 8.6 수자원 분야 국내 적용 방안

나. 수자원 분야 위성영상 활용 범위 조사.분석

- 본 장에서는 수자원 위성 빅데이터를 활용한 활용분야를 제시하고자 하며, 크게 광학기반 위성관측자료와 차세대 수자원위성이 확보하게 될 C-band 레이더를 활용한 관측자료의 활용분야를 구분하여 제시하였다.
- 차세대 수자원/수재해 중형 위성의 경우, 주야 및 기상조건에 상관없이 홍수 및 가뭄 등 수자원·수재해 감시에 필요한 광역적 국토 및 수자원 관련 인자를 관측하고 산출 및 전달 가능한 센서가 탑재된 위성으로, C-band SAR 영상레이더를 활용할 것으로 알려져 있으며, 10m의 공간해상도로 일 1회 이상(2 times/day로 예상)의 관측주기를 가짐으로써 높은 시·공간해상도를 제공할 예정이다.
- 차세대 수자원 분야 중형위성에 대한 활용도가 클 것으로 예상되며, 이에 대한 치수·이수·환경분야의 활용을 위한 방안을 정리하여 제시하였다.



그림 8.7 수자원/수재해 중형 위성 개발 개념도 (좌) 및 탑재체 사양안 (우) (출처: 환경부, 2018. 07.)

- 기존 널리 알려진 광학을 활용한 수자원 분야 활용 방안의 경우, 이수·치수·환경 분야로 구분 하였을 때, 다음과 같은 활용이 가능 할 것으로 기대된다.
  (1) (치수분야) 다종 위성 활용을 통한 수위 및 유량산정이 가능 할 것으로 기대되며 (관련 현장관측센서를 활용한 검증 필요), 더 나아가 각종 수리·수문 모델과의 융합을 통한 침수지 분석 및 홍수 피해 예측 기술 개발이 가능 할 것으로 기대된다.
  (2) (치수분야) 홍수 피해 예측 기술의 고도화를 통하여 각종 오염원 배출시설에서의 실시간 오염물질별 배출량 자료를 활용한 준 실시간 수질 분석 및 수재해 예측 시스템 개발이 가능 할 것으로 기대된다.
  (3) (이수분야) 위성자료를 활용한 농경지 탐지가 가능하며, 이에 대한 농업 용수 수요 예측

이 가능하다고 판단된다. 고해상도 위성을 활용하면 광역에 대한 농경지 면적의 변화를 정량적으로 분석할 수 있을 것으로 보이며, 더 나아가 계절별 변화 특성, 미계측 지역에 대한 적용성 등 다양한 활용이 기대된다.

(4) (환경분야) 고해상도 위성 및 광학 센서가 부착된 고해상도 드론 (UAV) 영상을 융합하여 널리 분석되고 있는 클로로필-a 및 부유물질 (SS) 뿐만 아니라, 조류세포수, pH, DO, DIN 등 다양한 수질 인자의 분석에 활용이 가능 할 것으로 판단된다.

(5) (환경분야) 고해상도 광학위성 및 UAV를 활용한다면, 4대강 사업으로 인한 갈수기 때의 하상변화 분석, 모래톱이 드러남에 따른 모래톱 탐지 및 면적 변화 분석, 나지(barren)의 면적 및 나지지역에 대한 고도화된 분류기법 (모래톱, 자갈, 혼합, 초지, 목지 등) 개발에 활용이 가능할 것으로 기대된다.



그림 8.8 고해상도 광학위성 활용 수자원분야 활용 방안 도출 결과

- 차세대 수자원 중형위성이 활용할 C-band SAR 레이더의 경우, 높은 시·공간 해상도를 가지고 있어, 다음과 같이 각종 모니터링 및 기존에 수자원 분야에서 분석이 어려웠던 토양수분 관련 인자, 그리고 수변환경변화에 대한 고도화된 모니터링이 가능 할 것으로 기대된다.

(1) (치수분야) C-band SAR를 활용한 각종 수자원 시설물의 변위 측정과 같은 모니터링 기법개발이 가능 할 것으로 보이며, 이를 활용하여 daily 모니터링 뿐 만 아니라 중·장기 시설물의 변화탐지 및 분석에 활용이 가능 할 것으로 판단된다. 특히, 올 여름 (2020.

07.) 중국의 대홍수로 인한 싼샤댐의 경우를 본다면, 우리나라의 각종 보 및 댐에 대한 고해상도 변화 분석이 필수적으로 이루어 져야 할 것으로 보인다.

(2) (치수분야) C-band SAR의 얕은 투과성을 활용하여 얕은 지하에 대한 지하수 및 지하수 저수량 등의 각종 수자원의 변동성 분석에 활용이 가능할 것으로 기대된다.

(3) (이수분야) 기존 국내에서 분석이 어려웠던 토양수분과 관련된 인자들에 대한 개발 및 분석이 차세대 수자원 위성과 융합활용을 통하여 개선이 이루어질 수 있을 것으로 기대된다. L-band passive microwave 분석 기법과 C-band SAR 관측자료를 융합하여 보다 고도화된 토양수분 산정에 대한 분석이 가능 할 것으로 보이며, 이를 통해 우리나라의 가뭄지수 개발에 활용할 수 있을 것으로 기대된다.

(4) (이수분야) C-band 및 다종위성 SAR-bands (X, L, P-band 등)의 반사특성을 융합 활용하여 식생수분함량을 분석하는 기법 또한 개발 할 수 있을 것으로 보인다.

(5) (환경분야) 고해상도의 C-band SAR를 활용하여 수변환경의 변화를 보다 세밀하게 분석할 수 있을 것으로 기대된다. 특히, 급격한 변화의 분석 및 탐지를 통한 대응 및 복구계획을 세워야 하는 수재해(홍수, 산사태, 산불 등)의 경우, daily로 관측하는 수자원위성의 관측자료를 활용한다면 기존보다 고도화된 물환경 재난관리에 기여할 수 있을 것으로 보인다.

(6) (환경분야) SAR의 dual-pol 반사특성을 활용한다면, 수체, 눈 (dry/wet snow), 얼음 (thin/thick ice)에 대한 분류·분석이 가능 할 것으로 기대된다. 이를 활용하여 우리나라 주요 하천에 대한 겨울철 변화분석 및 얼음 두께 추정 뿐 만 아니라, 더 나아가 snow melting으로 인한 유량 변화영향예측 등 다양한 활용이 가능 할 것으로 기대된다.

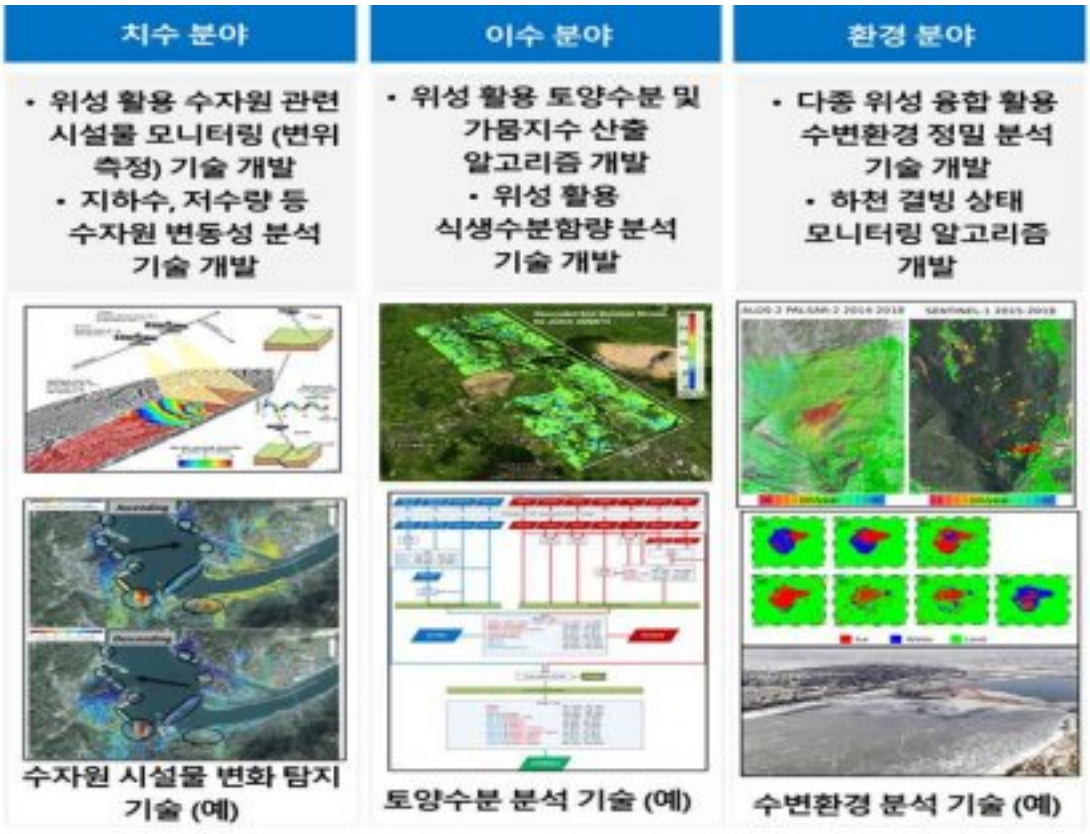


그림 8.9 C-band SAR 활용 수자원 분야 활용 분야 도출 결과

다. 위성영상 활용 수자원 분야 공적개발원조 현황 분석

- 물분야의 해외 사업 적용 방안의 경우, 대표적으로 공적개발원조 (ODA) 사업형태로 진행할 수 있으며, 한국국제협력단 (KOICA)을 통한 무상원조사업과 한국수출입은행 (ExIm Bank)을 통한 유상원조사업으로 구성할 수 있다.
- K-water는 현재 ODA사업의 경험을 바탕으로 기술용역사업을 수행하고 있으며, 현지 정부 또는 사업자와 K-water가 직접 계약을 통해 타당성조사, 설계, 기술지원, 건설관리, 시설물 운영관리 등을 제공하는 유형의 사업으로 현지 정부 또는 사업자의 자체예산을 통해 이루어지고 있다 (K-water 해외사업현황, 2020. 12.).
- 해외 사업의 경우, 수자원과 관련한 각종 인프라 및 환경영향평가 등은 K-water가 주도하여 수행 중에 있으며, 대부분 공적개발원조의 형태로 이루어지고 있다. 하지만, 수력발전사업, 상하수도사업 등 시설물과 관련된 인프라 구축 사업에 치중되어있어 상대적으로 위성활용 및 현장관측 시스템 등과 관련한 사업은 미진한 상황이다.

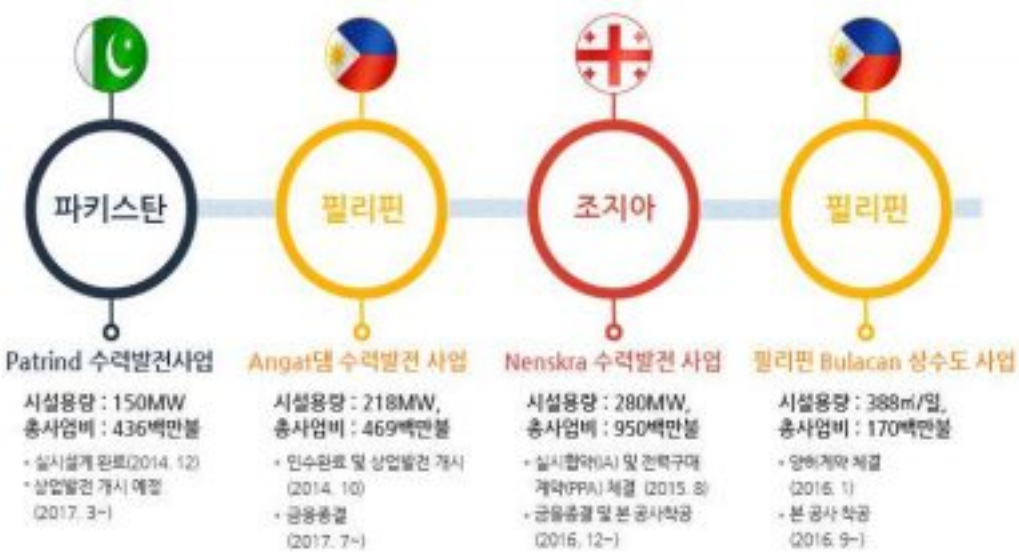


그림 8.10 K-water 해외 사업 대표 현황 (자료: K-water 해외사업현황, 2020. 12.)

- 주로 동아시아 지역의 국가에 치중되어있으며, 특히 동남아시아 지역 국가에 대한 수자원 인프라 구축 지원 사업이 주로 이루어져왔다.

표 8.7 K-water 해외 사업 이력

1 [중국] 강소성 사양현 상수도사업 (2010 ~ 2015)
2 [적도기니] 에베비인시 상수도사업(1차) (2013 ~ 2015)
3 [적도기니] 에비나용시 상수도사업(1차) (2013 ~ 2015)

4 [인도네시아] 페칸바루 상수도 M/P 수립 (2014)

5 [베트남] 렌홍마이강 수자원개발사업 타당성조사 (2014)

6 [스리랑카] 수자원 환경영향평가 (2014)

7 [인도네시아] 하상 수력발전투자사업 (2014)

8 [미얀마] 에야와디강 수자원 M/P 수립 (2013 ~ 2014)

9 [중국] 황해오염 방지 연구사업 (2012 ~ 2014)

10 [이라크] 베칼 소수력발전소 건립사업 (2011 ~ 2014)

11 [몽골] 울란바타르시 수자원이용 효율화 사업 (2011 ~ 2014)

12 [케냐ㆍ에티오피아] 식수위생분야 기본계획 수립 (2012 ~ 2013)

13 [DR콩고] 이디오파지역 식수개발사업 (2012 ~ 2013)

14 [적도기니] 몽고모 정수장 유지관리사업(2차) (2010 ~ 2013)

15 [캄보디아] 다운트리댐 개발사업 타당성조사 보완 (2013)

16 [베트남] 부온호현 상수도시설 건설사업 (2010 ~ 2013)

17 [라오스] 세방파이 상수도사업 (2010 ~ 2012)

18 [키르기스스탄] 수력발전사업 타당성 조사 (2011 ~ 2012)

19 아프칸 이스탈리프 소수력발전소 2차사후관리 사업 (2008 ~ 2011)

20 [스리랑카 등] 상수도사업 사후평가 (2011.04~2011.06)

21 [우즈베키스탄] Kaparask 식수공급 개선사업 ('10.07~'11.05)

22 [인도네시아] Karian댐 및 수로건설('10.02~'12.02)

23 [이라크] 아르빌 침사지 설치사업 ('09.11~'11.05)

24 [캄보디아] 프렉트놋 수자원 개발사업 ('09.11~'10.02)

25 [캄보디아] 푸삿강 수자원 개발사업 ('09.10~'10.04)

26 [캄보디아] 다운트리 다목적댐/몽콜보레이 댐 개발사업 ('09.03~'09.08)

27 [콩고] 댐 재개발 예비타당성조사('09.03~'09.06)

28 [아이티] 크루아데부께 식수공급확장 사업 ('08.10~'09.12)

29 [필리핀] 팜팡가 홍수통제 사업 ('08.10~'09.04)

30 [캄보디아] 세산Ⅲ 수력발전 사업 ('08.06~'08.11)

31 [필리핀] 보홀주 말리나오댐 개선 타당성 조사 및 실시설계사업 (2008~2009)

32 [베트남] 호아깐떠이 상수도 사업 ('07.09~'07.12)

33 [베트남]끼엔장성 우밍 및 빙빙남지역 식수개발사업 (2007~2010)

34 [라오스] 볼리칸군 7개마을 식수개발사업 (2007~2009)

35 [방글라데시] 치타공 상하수도 마스터플랜수립사업 (2007~2008)

36 [케냐] 수스와 상수도 개보수사업 (2007~2008)

37 [케냐] 아셈보 정수장 건설사업 (2007~2008)

38 [르완다] 나바롱고강 식수개발 타당성조사사업 (2007~2008)

39 [이라크] 베칼 소수력발전소 건설사업 설계·감리용역 (2007 ~ 2009)

40 [캄보디아] Krang Ponley 수자원개발사업 (2007 ~ 2011)

41 [아프간] 이스탈리프 소수력발전소 1차사후관리 사업 ('06.12~'07.12)

42 [베트남] 호아빈 상수도 타당성 조사사업 (2006 ~ 2007)

43 [아프가니스탄] 소수력 발전소 운영관리사업 (2006 ~ 2007)

44 [스리랑카] 발레츠나이 홍수방지사업 (2006 ~ 2008)

45 [캄보디아] 수자원 장기종합계획 사업 (2006 ~ 2008)

46 [적도기니] 몽고모시 상수도시설 운영관리사업 (2006 ~ 2009)

47 [인도] 리키모 수력발전소 운영관리 기술지원사업 (2006 ~ 2010)

48 [몽골] 식수개발사업 (2006 ~ 2007)

49 [이라크] 아르빌 상하수도 현대화 사업 (2005 ~ 2007)

50 [페루] 아마릴리스 상수도사업 타당성조사사업 (2004 ~ 2006)

51 [인도네시아] 까리얀 다목적댐 타당성조사 및 실시설계사업 (2004 ~ 2006)

52 [캄보디아] 크랑폰리강 유역개발 타당성 조사사업 (2004 ~ 2005)

53 [아프가니스탄] 이스탈리프 소수력 발전소 건립사업 (2004 ~ 2006)

54 [캄보디아] 타목저수지 복구지원사업 (2003 ~ 2004)

55 [네팔] 챠멜리아 수력발전소 실시설계사업 (2000 ~ 2002)

56 메콩강 수자원조사사업 (1999 ~ 2000)

57 [중국] 산서성 분하강 유역조사사업 (1994 ~ 1996)

- 물융합 분야의 변화에 맞추어, K-water는 또한 물산업 육성을 위한 국제협력 및 국제교육을 수행 중에 있으며, 다음과 같이 진행이 되고있다.

  (1) (국제협력 분야) 아시아 물위원회(Asia Water Council; AWC), 세계물포럼(World Water Forum; WWF), 2018 싱가포르국제물주간(Singapore International Water Week; SIWW) 등에 참석하여 아시아지역의 물 분야 구심점으로서의 역할을 수행 중에 있다.

표 8.8 K-water의 세계 물 포럼 참여 현황

Classification	Venue	Participation	Theme and major performance
1st (1997)	Marrakesh, Morocco	63 countries, Approx. 500 people	Vision for Water, Life, and the Environment, 'Marrakesh declaration' adopted
2nd (2000)	Hague, Netherland	114 countries, Approx. 5,700 people	From Vision to Action 'World Water Vision' announced
3rd (2003)	Kyoto / Siga, Japan	130 countries, Approx. 24,000 people	A Forum with a Difference Cabinet declaration announced
4th (2006)	Mexico City, Mexico	150 countries, Approx. 20,000 people	Local Actions for a Global Challenge Minister declaration announced
5th (2009)	Istanbul, Turkey	190 countries, Approx. 33,000 people	Bridging Divides for Water Appeal by chief of state/minister declaration announced
6th (2012)	Marseille, France	170 countries, Approx. 35,000 people	Time for Solutions
7th (2015)	Daegu, Gyeongbuk	-	Water for Our Future

(2) (국제교육 분야) K-water는 우리나라의 우수한 물관리 기술 및 노하우 전파를 국제사회에 공유·전파하기 위해 정책수립부터 건설, 운영관리에 이르는 물관리 전분야에 대한 강의 및 이를 연계한 현장학습 및 실습, 국가별 물문제 해결과제 구체화 및 실행대안과 계획을 수립해보는 Action Plan의 교육과정을 제공하고 있다.

- 다음과 같이 (1) 수자원 개발 및 관리, (2) 상수도 건설 및 운영관리, (3), 수질관리 및 수질분석, (4) 신재생에너지 개발 및 효율향상, (5) 수도공급 누수율 감소, (6) 지하수 개발 및 관리 등과 관련한 교육 모듈을 제작·제공하고 있다.
- 앞서 조사한 자료와 더불어 기존 공적개발원조가 추구하는 방향성에서 확인할 수 있듯, 동아시아 지역에 대한 물관리 기술의 공적개발원조가 필요한 실정이며, 본 과업에서도 또한 동남아시아 지역에 대한 물 관련 기술원조 사업아이디어를 제시하고자 한다.

- 동남아시아 지역의 개발도상국의 경우, 국가별로 인프라, 경제상황, 기후 및 지리적 특성이 모두 상이하기에, 본 과업에서는 특정 국가를 대상으로 한 수자원 분야 사업 모델을 제시하는 대신, 보편적으로 수행할 수 있는 수자원 관리 기법(이수, 치수, 환경 분야)에 대한 공적개발원조 사업 모델을 제시하고자 한다.
- 상대적으로 각종 기술적 인프라가 낙후된 동남아시아 지역에서 위성자료를 활용하기 위해서는 우선적으로 자료를 송·수신할 수 있는 설비가 필요할 것으로 판단되며, 각종 댐이나 수력발전소에 실시간으로 수위 및 시설물의 상태를 확인할 수 있는 센서와 관리기술에 대한 기술이전이 필요할 것으로 판단된다.
- 더 나아가 현장 센서 기반 관측자료(reference)와 위성자료를 융합하여 스마트 물관리 및 수재해 관리를 실현시킬 수 있는 교육 및 인력양성이 필요할 것으로 보인다.



그림 8.11 위성활용 수자원분야 공적개발원조 사업 모델 다이어그램

8.3.3 물산업 트렌드를 고려한 위성영상 활용 수자원 분야 사업모델 제시

- 본 과업에서는 앞서 조사·도출한 물산업 트렌드 및 위성 활용 수자원 분야 활용방안을 종합적으로 고려하여 다음과 같은 위성영상 활용 수자원 분야 사업모델을 제시하고자 한다.
- 다음 다이어그램과 같이 크게 네 단계에 걸친 사업모델을 구성하였으며, 국내에서 필요한 사업모델을 먼저 제시한 후, 최종적으로는 해외 저개발국가에 대한 기술 이전 사업이 이루어질 수 있도록 설계하였다.
  (1) 수자원 분야의 각종 빅데이터를 수집하여 통합 관리(QA/QC 및 표준화)할 수 있는 시스템과 위성관측을 고려한 통합 현장자료 관리 시스템 개발 사업
  (2) 다종위성 융합을 통한 기존 수자원 분야 산출물의 시·공간 상세화 사업
  * 다양한 산출물에 대한 상세화가 가능 할 것으로 기대되며, 본 과업에서는 실시간 수질 분석 시스템을 대표적인 예로써 제안하였다.
  (3) 인공지능 및 자동화 알고리즘을 활용한 수자원 분야 빅데이터 자동 통합관리 플랫폼 개발 사업
  (4) 저개발국가 대상 수자원 관리 기술 이전을 위한 공적원조개발 사업 추진 기법 개발 사업

- 각 사업 단계별 세부 설명은 다음 단락에서 상세히 서술하였다.

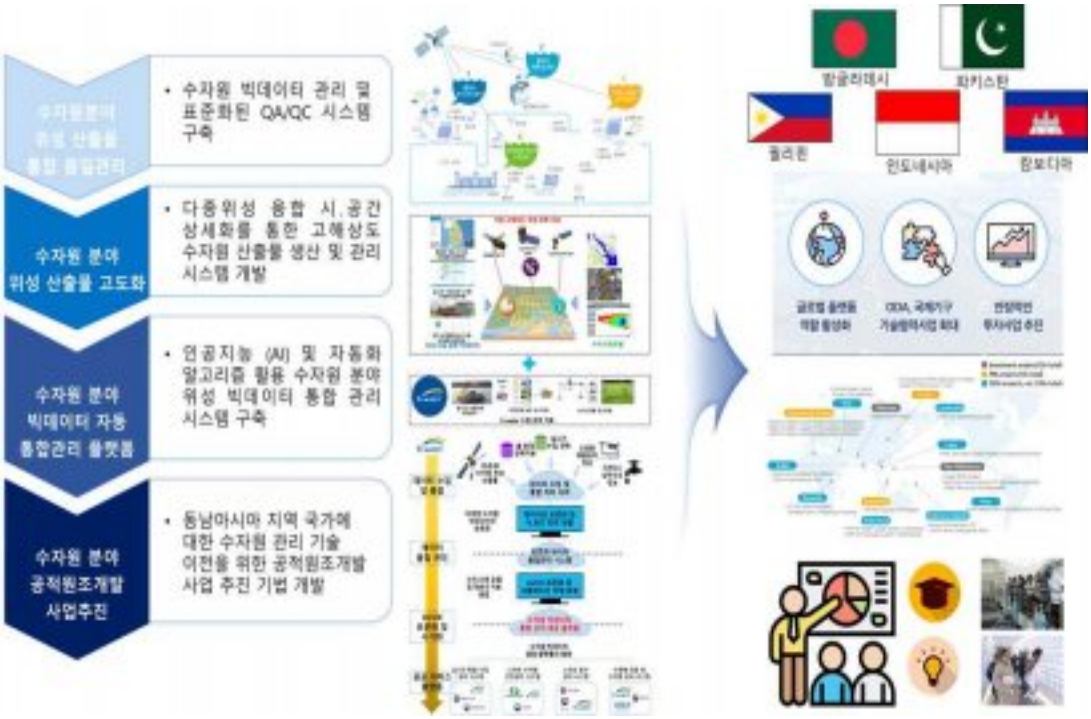


그림 8.12 물산업 트렌드를 고려한 위성영상 활용 수자원 분야 사업모델 결과

가. 수자원분야 빅데이터 표준화 시스템 및 통합 현장관측 데이터 플랫폼 개발 사업

1) 수자원 분야의 각종 빅데이터를 수집하여 통합 관리(QA/QC 및 표준화)할 수 있는 시스템과 위성 관측을 고려한 통합 현장자료 관리 시스템 개발 사업

- 본 과업에서는 수자원 분야의 각종 빅데이터 (위성 관측, 위성 산출물, 현장 관측자료, 현장 분석자료 등)의 품질관리와 표준화에 대한 사업이 필요하며, 위성 관측 시기 및 해상도를 고려한 현장자료 네트워크의 구축 방안을 제시한다.



그림 8.13 수자원분야 빅데이터 표준화 시스템 및 통합 현장관측 데이터 플랫폼 개발사업

- 현재 수자원 분야의 위성 관측 기반 산출물, 각종 현장 관측자료에 대한 표준화 및 품질관리(QA/QC)가 필요하다고 앞서 제시하였다. 본 과업에서는 이러한 자료의 품질관리와 표준화에 대한 사업이 필요하며, 그 방법에 대한 가이드라인을 제시하였다.
- 특히, 수자원 분야 위성산출물의 경우는, 상대적으로 강폭이 좁은 우리나라에서 현장자료와의 매칭을 통한 자료의 품질 향상이 반드시 선행되어야 하는데, 주로 수변에서 측정하고 있는 현장자료와의 매칭이 어려운 실정이다.
- 이러한 위성관측을 고려한 통합 현장자료 관리 시스템의 개발이 필요하다고 판단되며, 수자원 분야에서 활용이 용이하다고 판단되는 위성의 촬영주기 및 해상도를 고려한 체계적인 수자원 분야 현장관측 및 자료관리 시스템의 개발이 반드시 선행되어야 한다.
- 그림 8.1에서 분석하였듯, 문헌조사를 통한 수자원 분야 위성 산출물 리스트 분석 결과, 기존 국내·외에서 활용중인 수자원 분야 관련 위성의 산출물은 강우강도, 가강수량 등과 같은 강

우량 관련 산출물이 가장 많은 것으로 나타났고, 그 뒤로 토양수분과 증발산량과 관련된 산출물이 많은 것으로 나타났다. 토양 수분에 대한 위성 산출물의 경우, 상대적으로 파장대가 긴 수동 마이크로파를 활용하고 있기 때문에 공간해상도가 많이 낮은 것으로 나타나고 있다. 모든 수자원 산출물은 Level 2 (L2) 이상의 위성 관측 기반 산출물로써 위성으로부터 관측된 Level 1 (L1) 자료를 가공하여 2차적으로 생산된 가공품으로 나타났다.

- 이들 중, 상대적으로 시·공간 해상도가 떨어지는 토양수분 및 증발산량과 관련된 위성(SMOS, SMAP, TRMM)등이 우리나라를 스캔하는 날짜 및 지역을 고려하여 현장자료 관측 지점을 재구성할 필요가 있다.
- 또한, 본 과업에서 수질 및 수변환경 분석을 위해 활용한 Sentinel-2A/B 위성자료의 수질 분석 분야 및 수변환경 분석 분야에서의 활용도 및 유용성을 확인하였기 때문에, Sentinel-2A/B의 촬영시기 및 지역에 맞춘 수질 및 수변환경과 관련한 현장관측 시스템을 구성 할 필요가 있다.
- 위성관측자료의 표준화 및 품질관리와 같은 경우, 다음 표와 같이 현장관측자료와의 매칭을 통해서 관리를 하는 것이 일반적이다. SMOS, SMAP과 같은 토양수분 산출물의 경우, 독자적인 Flight operation system 운용을 통하여 현장자료를 취득·검보정을 수행하고 있으며, TRMM, GPM과 같은 증발산 관련 산출물 또한 Ground validation field campaigns를 활용하여 위성관측과의 매칭을 통한 검보정을 통해 보다 수준 높고 신뢰할 만한 산출물을 제공하기 위하여 힘쓰고 있다.

표 8.9 주요 수자원 분야 위성별 품질관리 및 자료 검보정 방법 현황

위성자료	수자원 산출물 품질관리 및 검보정 방법
COMS-MI / GK2A-AMI	복사보정 및 위치보정수행을 통한 가시채널 및 적외채널 품질 관리 * 가시채널의 경우, 2018년부터 Ray-matching 검.보정 기술 도입, MODIS와의 비교를 통한 검보정 수행
SMOS	정기.비정기적 SMOS Flight Operation (FOS) 운영을 통한 자료의 검보정 수행 토양수분의 경우, 다양한 토지피복에 대하여 현장자료와의 검보정을 통한 품질관리가 수행되고 있음
SMAP	토양수분 산출물 자체적 flag 데이터 활용 통한 품질정보 제공
TRMM, GPM	강우량에 대한 Ground validation 수행 (Ground Validation (GV) field campaigns)

- 하지만, 현재 우리나라의 수자원분야 현장관측자료의 관리 및 운용이 위성자료와의 매칭이 어려운 상황이기 때문에, 본 과업에서는 시·공간 통계치를 활용한 이상치 탐지(anomaly detection) 등의 기법을 제안하고자 한다.
- 본 과업에서는 K-water에서 지난번 수행한 [위성영상 활용 용수수요 인자 및 수변환경 변화 분석기법 연구 (2019)]의 수자원분야 위성 빅데이터 분석 및 예측 방안 제시 연구 결과를 참고하여, 아래와 같이 세 가지 통계 기반 품질관리 방안을 제시하고자 한다.

- 위성 자료의 성능평가를 위하여 다양한 통계 기반 metrics가 활용되고 있으며, 기존 문헌들에서 주로 제시되고 있는 성능평가 통계(performance (error) metrics; PM), 의사결정 지원 통계(decision metrics; DM), 시공간 정합성 통계 (spatial/temporal stability metrics; SM)를 활용할 수 있다.
- ① 성능평가 통계 (performance metrics analysis)

ⓐ mean absolute error (MAE)

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|x_i - x\right|$$

수식 8.1 MAE matrics

- MAE는 측정값에 대한 평균 절대오차로, 측정값에 실제값의 오차에 대한 제곱을 인스턴스의 개수로 나누어준 값이다 (수식 8.1). 다양한 공간 통계기법에서 활용되고 있는 통계지표로, 오차에 대한 절대 값을 활용하므로 저측정(under estimation)하였는지, 혹은 과대측정(over estimation)하였는지에 대한 판단은 어렵다는 단점이 있다. 각 산출물의 grid별 측정값과 실제값 사이의 오차를 모두 계산해준 후, 절대 오차들의 총 합을 개수로 나누어 계산할 수 있다. 값의 범위는 없으며, 값이 크게 나타날수록 오차가 크다고 할 수 있다. 이를 이용하여 이상치(outlier)의 탐지가 가능 할 것으로 기대되며, 위성 산출물 자료의 품질관리에 적극적으로 활용될 수 있을 것이다.

ⓑ root mean square error (RMSE)

$$RMSE = \frac{1}{n}\sum_{i=1}^{n}(x_i - x)^2$$

수식 8.2 RMSE matrics

- RMSE는 평균제곱근오차로, MAE와 비슷한 개념이지만, 오차의 제곱의 총 합을 인스턴스의 개수로 나누어준 값이다 (수식 8.2). 이 또한 다양한 공간 통계기법에서 활용되고 있는 통계지표로, 오차에 대한 제곱 값을 활용하므로 저측정 하였는지, 혹은 과대측정 하였는지에 대한 판단은 어렵다는 단점이 있다. 또한, RMSE의 경우, 측정값들이 정규분포를 가정하기 때문에(Gaussian distribution), 측정값들이 이를 잘 따르고 있다면 매우 적합한 통계치를 보여줄 수 있으나, 정규분포를 따르지 못할 때는 평균값(mean value)의 오차(error)를 잘 나타내지 못한다는 단점이 있다 (국립환경과학원, 2018). RMSE 또한 값의 범위는 없으며, 값이 크게 나타날수록 오차가 크다고 할 수 있다. 이를 이용하여 이상치(outlier)의 탐지가 가능 할 것으로 기대되며, 위성 산출물 자료의 품질관리에 적극적으로 활용될 수 있을 것이다.

ⓒ Pearson's correlation coefficient (R)

$$r = \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{(n-1)s_x s_y} = \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2\sum_{i=1}^{n}(y_i-\bar{y})^2}}, \bar{x}: \text{표본평균}; s_x : \text{표본표준편차}$$

수식 8.3 Pearson's correlation coefficient matrics

- 관측값과 실제값 두 변수의 상호관계만을 알아보고자 할 때, 주로 상관관계 분석 (correlation analysis)를 수행하며, 가장 대표적인 지표로 Pearson's correlation coefficient (R)을 활용하고 있다. 두 변수간의 인과관계(causality)를 나타내지는 못하며, 단순히 상호관계만을 파악할 수 있는 지표이다. 상관관계의 크기는 정량적인 상관계수(correlation coefficient)로 나타낼 수 있으며, 결정계수(R2)는 이 상관계수를 제곱한 값으로 나타낼 수 있다. 하지만, 결정계수의 경우는 양 혹은 음의 상관관계를 나타내지 못하기 때문에, 상관계수를 이용하여 분석하는 것이 바람직하다. 상관계수가 ±1에 가까울수록 강한 양・음의 상관관계를 가지고 있다는 것을 뜻하며, 0에 가까울수록 그 관계가 적다고 할 수 있다. 이러한 상관계수를 이용한다면 위성 산출물의 이상치(outlier)의 탐지가 가능 할 것으로 기대된다.
- 이러한 성능평가 통계모델을 이용하여 국립환경과학원(2018)은 검증 대상 자료의 특성에 따라 다양한 지표를 활용하기를 제시하고 있다. 만일 자료가 정규분포(Gaussian distribution)를 따른다면, RMSE가 가장 적합한 통계 지표가 될 수 있지만, 그렇지 못하다면 MAE를 활용하여 판단하는 것이 더 바람직 할 것이다. 또한 이상치에 대한 영향이 상대적으로 많이 나타날 경우 또한 MAE를 활용하는 것이 나을 것으로 판단된다. 검증 대상 산출물 자료의 분포가 충분히 넓고 많을 경우에는 상관계수(R)을 활용하는 것이 좋다.

- ② 의사결정 지원 통계 (decision metrics analysis)

ⓐ hitting percent

- hitting percent는 측정값이 추정오차 허용값 (critical bias range)내에 얼마나 잘 들어왔는가에 대한 비율로, 검증 대상 산출물 값에 대한 불합격(failure) 판단이 가능하다. 이는 위성 운용 중에 알고리즘의 version 변화에 따른 성능 변화에 대한 분석도 가능하며(국립환경과학원, 2018), 이를 통하여 유용한 평가가 가능하다. 각 산출물 별 추정오차(expected error)가 잘 정의되어 있다면 이를 활용하여 산출물의 품질관리에 활용이 가능하다. 0에서 100% 사이의 값으로 나타낼 수 있으며, 값이 높을 수록 신뢰할 수 있는 자료로 판단할 수 있다.

ⓑ diagnostic expected error

- diagnostic expected error는 hitting percent 값을 활용한 의사결정 기법 중 하나로, 장기간에 걸친 관측을 통하여 특정 산출물의 추정오차의 범위가 산정되어 있다고 했을 때, 해당 산출물을 추정하는 새로운 알고리즘이 기존의 추정 알고리즘 보다 더 개선되었는지 판단할 수 있는 객관적인 지표가 될 수 있다. 예를 들어, 두 가지 version의 산출물 추정 알고리즘이 있을 때, 두 알고리즘에 대한 diagnostic expected error에 대한 hitting percent를 각각 계산할 수 있으며, 이를 비교하여 보다 높은 hitting percent를 보이는 알고리즘이 더 낫다고 판단할 수 있는 근거가 될 수 있다

- ③ 시·공간 정합성 통계 (temporal/spatial stability metrics analysis)

ⓐ temporal/spatial binning

- 시・공간적 binning은 위성 산출물 자체에 대한 시・공간 격자의 변환(binning; gridding)이 필요할 때 활용되는 기법이며, 주로 Level 3 이상의 충분히 넓은 격자로 변환할 때 활용되는 기법이다(국립환경과학원, 2018). 이 때, 변환하고자 하는 공간 및 시간대의 충분한 양의 전・후 관측치를 활용하여 변환하여야 하며, 대푯값을 지정한 후, 각각의 bin별로 변환할 수 있다.
- ⓑ coefficient of variation (CV)
- 시・공간 binning 수행 시, 각각의 bin에 대한 표준편차와 평균값을 구할 수 있으며, 이 둘의 비율로 CV를 도출할 수 있다. 장기간에 대한 binning를 거쳐 각 bin별 기후값(CVclimate)과의 해당 시점의 CV값을 비교한다면, 시・공간적 정합성과 안정성을 검증할 수 있다 (국립환경과학원, 2018).
- 이러한 시・공간 정합성 통계기법은 위성자료의 신뢰도를 평가・검증할 때 매우 유용하지만, 엄격한 시・공간 일치를 위한 전처리가 선제되어야 한다. 예를 들어, 지상 측정소가 점 데이터의 형태로 공간에 흩어져 있을 때, 각각의 측정소 간 거리별 측정값의 상관도와 공간상의 대표성 등을 평가해야 한다. 이러한 공간적 특성을 확인 하는 절차를 거친 후에 spatial binning을 수행해야 하며, 이를 통해 각 bin별로 이상치를 탐지할 수 있다. 마찬가지로 시간에 대해서도 충분히 많은 관측자료를 확보한 후 위성과 지상관측자료의 시간적 일치를 수행해야 하며, 이러한 전처리를 거쳐야 temporal binning을 수행할 수 있을 것이다.
- 시공간적 일치(spatial co-location / temporal hominization)를 위하여 주로 자기상관분석(auto-correlation analysis)을 수행하고 있으며, 충분한 시・공간적 자기상관을 확보한 후 안정성과 정합성을 종합적으로 평가한 후 지상자료와의 검・보정을 수행해야 할 필요가 있다(국립환경과학원, 2018).

나. 다종위성 및 빅데이터 융합활용 실시간 수질 관측 및 변화 예측 시스템 개발 사업

1) 다종위성 및 빅데이터 융합활용 실시간 수질 관측 및 변화 예측 시스템 개발 사업 개요

- 본 과업에서 제시하고자 하는 사업은 다음과 같이 크게 세 가지 빅데이터에 대한 수집 및 관리가 필요하며, 각종 수자원 관련 위성 빅데이터자료, 국내 다양한 기관별 수질 관련 빅데이터, 각종 수리·수문 모델의 융합이 필요하다.
- 위의 세 가지 빅데이터를 표준화·QA/QC 과정을 거친 후, K-water에서 측정하고 있는 각종 하천망도의 관측자료(실시간 수질 자동 측정 장치, 무인항공 녹조 모니터링 시스템, CCTV 활용 모니터링 등)를 더해 준 실시간 다종위성 활용 실시간 수질관리 시스템 개발이 사업의 최종 목표이다.
- 자료의 표준화 및 품질관리와 관련한 기술은 앞서 제안한 자원분야 빅데이터 표준화 시스템 및 통합 현장관측 데이터 플랫폼 개발 사업에서 개발한 기법이 활용될 것이다.

(1) 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템



그림 8.14 다종위성 및 빅데이터 융합활용 실시간 수질 관측 및 변화 예측 시스템 개발 사업

- 목표: 위성자료를 활용한 수질 분석 및 수체의 영양상태 실시간 평가
- 시·공간 해상도: 2.8~30m 단위, daily-weekly-monthly 시계열 분석
- 활용 위성: 해수나 연안수보다 수체의 크기와 폭이 현저히 작고 탁도가 높은 하천에 대한 원격탐사; 고해상도 위성영상의 적색 ~ 근적외선 파장영역을 활용하는 two-band 및 three-band reflectance 모델의 적용성 활용 기대

표 8.10 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 위성 자료

위성	스펙	이미지
KOMPSAT-3	공간 해상도: 2.8 m (0.7m pan) 밴드 위: 0.45 – 0.9 μm 밴드 수: 5 개 시간 해상도: 1.4 일 이미지 크기: 15km	

Landsat 8 (OLI)	공간 해상도: 30 m (15m pan) 밴드 범위: 0.43 - 1.39 μm 밴드 수: 9 개 시간 해상도: 16 일 이미지 크기: 185 km X 180 km	
Sentinel 2-A/B (MSI)	공간 해상도: 20 m (10m RGB) 밴드 범위: 0.44 - 2.20 μm 밴드 수: 12 개 시간 해상도: 5 일(A/B 각 10일) 이미지 크기: 290 km	

- 활용 현장 자료: 실시간 홍수통제소 관측 자료 (환경부), 각종 수리.수문 관측자료 (환경부, 한국수자원조사기술원, 산업통상자원부), 각종 지자체 제공 수질자료

표 8.11 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 현장 관측 자료

자료명	현장 관측 자료	운영기관
각종 홍수 통제소	수문 : 국가하천 강우 수위, 유량 자료관리 이수 : 하천수 취수 및 인허가 사항 치수 : 홍수예경보, 홍수지도 본류구간	환경부
한국수자원조사기술원	수문 : 국가하천 수위, 유량조사 유역 : 치수시설조사 등 14개 항목	한국수자원조사기술원
물환경연구소	수문 : 유량(오염총량지점) 수질 : 일반, 총량 및 퇴적물측정망	환경부
유역환경청	수질 : 일반측정망(하천, 호소 및 산단)	환경부
한국환경공단	수질자동측정망 설치·관리	환경부
기상청	수문 : 강수량, 증발량 등 재난 : 태풍, 해일, 황사, 지진 등	환경부
한국농어촌공사	수문 : 강수, 수위, 유량, 토양수분량 수질 : 일반측정망(농업용수) 지하수 : 농촌지역 지하수 정보 댐·보 : 저수위, 방류량 등 운영실적	농림수산식품부
한국수력원자력	수문 : 강수, 수위, 유량(발전용댐 상류)	산업통상자원부
도발전연구원 보건환경연구원	수문 : 강수량, 수위, 유량(지방하천) 수질 : 일반측정망(하천, 호소, 도시관류) 지하수 : 지하수 개발, 이용허가 상수도운영 : 상수도통계	지자체

(2) 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템

- 목표: 기상 및 오염원의 변화에 따른 수질변화를 사전에 예측할 수 있는 수질예측시스템의 구축
- 시·공간 해상도: 5~30m 단위, daily 분석
- 활용 위성: 해수나 연안수보다 수체의 크기와 폭이 현저히 작고 탁도가 높은 하천에 대한 원격탐사; 고해상도 위성영상의 적색 ~ 근적외선 파장영역을 활용하는 two-band 및 three-band reflectance 모델의 적용성 활용 기대

표 8.12 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템: 활용가능 위성 자료

위성	스펙	이미지
RapidEye	Blue to NIR 6.5m, resampled to 5m pixel size Daily (off-nadir), 5.5 days (at nadir)	
Landsat 8 (OLI)	30 m (visible, NIR, SWIR), 15 m (panchromatic) 16 days	
Sentinel 2-A/B (MSI)	10m, 20m 5 days	

- 활용 현장 자료: 기상 관측 및 예측 자료(기상청), 실시간 수질 관측자료 (한국환경공단, 국립환경과학원), 실시간 오염원 정보 (국립환경과학원), 실시간 홍수통제소 관측 자료 (환경부)

표 8.13 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템: 활용가능 현장 관측 자료

자료명	현장 관측 자료	운영기관
기상관측자료	기온, 상대습도, 이슬점온도, 강수량, 일사량, 풍속 등 (1시간)	기상청
기상예측자료	기온, 상대습도, 이슬점온도, 강수량, 일사량, 풍속, 증발량 등 (3시간)	기상청

수질원격감시체계 SOOSIRO	수질 TMS (Tele Monitoring System), 유량, BOD, COD, TN, TP, SS 등	한국환경공단
물 환경 정보시스템	수온, DO, BOD, COD, SS, TN, TP, TOC 등 (월별)	국립환경과학원
실시간 수질 정보시스템	수온, pH, 전기전도도, DO, 탁도, TOC, TN, 클로로필 등 (일별)	국립환경과학원
전국 오염원 조사시스템	인구, 상수도사용량, 폐수방류량, 폐수오염도 등 (연간)	국립환경과학원
각종 홍수 통제소	수위, 강수량, 댐, 보	환경부

- 활용 모델 자료: 수체모델(EFDC*), 유역모델(HSPF**), 수질모의모델(WASP***)

* 수체모델 – EFDC (Environmental Fluid Dynamic Code) 모델 : 하천, 호수, 하구 등에서의 수리 및 수질 거동 해석 (입력자료: 수위, 유량, 취수량, TMS 측정망도, 국가수질측정망도, 기온, 지상기압, 일사량, 수질자료 등)

** 유역모델 – HSPF (Hydrological Simulation Program-Fortran) 모델 : 물리적 기반의 준분포형 모델로 강우에 대한 유역유출 및 하천 및 호소에서의 수리·수질 모의가 가능한 대표적인 유역모델 (입력자료: 유량, 댐방류량, 취수량, DEM, 토지이용현황도, 하천도, 기온, 강수량, 풍속, 수질자료 등)

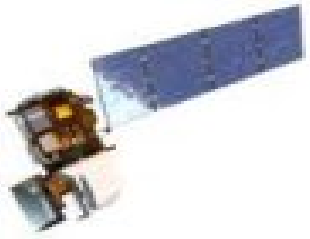
*** WASP (Water Quality Analysis Simulation Program)

(3) 위성 활용 실시간 수위, 수량 관측·관리 시스템

- 목표: 농업, 산업 용수와 더불어 식수원까지 포괄적인 수자원 관리를 위한 다양한 위성 원격탐사를 이용한 수량을 산정함에 따라 하천 건천화, 가뭄 상습지에 대한 농어촌 지하수 자원관리를 통해 효과적인 용수공급 기대, 지하수 탐지 등
- 시·공간 해상도: 2.8~30m 단위, daily-weekly-monthly 시계열 분석
- 활용 위성: 위성 영상자료, 광학위성자료, 마이크로웨이브 정보, SAR위성 (다종위성)

표 8.14 위성 활용 실시간 수위, 수량 관측·관리 시스템: 활용가능 위성 자료

위성	스펙	이미지
KOMPSAT-3 (광학)	공간 해상도: 2.8 m (0.7m pan) 밴드 위: 0.45 – 0.9 μm 밴드 수: 5 개 시간 해상도: 1.4 일 이미지 크기: 15km	

Landsat 8 (OLI, 광학)	공간 해상도: 30 m (15m pan) 밴드 범위: 0.43 – 1.39 μm 밴드 수: 9 개 시간 해상도: 16 일 이미지 크기: 185 km X 180 km	
Sentinel 2-A/B (MSI, 광학)	공간 해상도: 20 m (10m RGB) 밴드 범위: 0.44 – 2.20 μm 밴드 수: 12 개 시간 해상도: 5 일(A/B 각 10일) 이미지 크기: 290 km	
Cosmo-Skymed-1,2,3,4 (SAR)	공간 해상도: 1 ~ 100m 모드 범위: 9.6GHz(X밴드) 모드 수: 5개 시간 해상도: 12시간(4개 동시) 이미지 크기: 7x7 ~ 200x200 km	
RADARSAT-2 (SAR)	공간 해상도: 8 ~ 100m 모드 범위: 5.405GHz(C밴드) 모드 수: 17개 시간 해상도: 24일 이미지 크기: 50 ~ 90km	
ALOS-2 (SAR)	공간 해상도: 8 ~ 100m 모드 범위: 1.2GHz(L밴드) 모드 수: 6개 시간 해상도: 14일 이미지 크기: 25 ~ 490km	
RapidEye (광학)	공간 해상도: 5m 모드 범위: 440 ~ 850nm 모드 수: 5개 시간 해상도: 1 ~ 5.5일 이미지 크기: 77km	

- 활용 현장 자료: 실시간 홍수통제소 관측 자료 (환경부), 각종 수리.수문 관측자료 (환경부, 한국수자원조사기술원, 산업통상자원부), 각종 지자체 제공 수질자료

표 8.15 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 현장 관측 자료

자료명	현장 관측 자료	운영기관
각종 홍수 통제소	수문 : 국가하천 강우 수위, 유량 자료관리 이수 : 하천수 취수 및 인허가 사항 치수 : 홍수예경보, 홍수지도 본류구간	환경부
한국수자원조사기술원	수문 : 국가하천 수위, 유량조사 유역 : 치수시설조사 등 14개 항목	한국수자원조사기술원
물환경연구소	수문 : 유량(오염총량지점) 수질 : 일반, 총량 및 퇴적물측정망	환경부
유역환경청	수질 : 일반측정망(하천, 호소 및 산단)	환경부
기상청	수문 : 강수량, 증발량 등 재난 : 태풍, 해일, 황사, 지진 등	환경부
한국농어촌공사	수문 : 강수, 수위, 유량, 토양수분량 수질 : 일반측정망(농업용수) 지하수 : 농촌지역 지하수 정보 댐·보 : 저수위, 방류량 등 운영실적	농림수산식품부
한국수력원자력	수문 : 강수, 수위, 유량(발전용댐 상류)	산업통상 자원부
도발전연구원 보건환경연구원	수문 : 강수량, 수위, 유량(지방하천) 수질 : 일반측정망(하천, 호소, 도시관류) 지하수 : 지하수 개발, 이용허가 상수도운영 : 상수도통계	지자체

- 활용 모델 자료: 광학-분광특성, 후방산란계수 분석, 텍스처 추출 기법, 지구 중력장 변화 탐지, 밴드 조합 사용, 감독토지피복분류, 무감독 토지피복 분류, 물 특성 산출 알고리즘, 토양 수분

다. 수자원 분야 빅데이터 자동 통합관리 플랫폼 개발 사업

1) 수자원 분야 빅데이터 자동 통합관리 플랫폼 개발 사업 개요

- 본 사업 모델은 앞에서 제시한 수자원 분야의 각종 빅데이터의 품질관리(QA/QC) 및 표준화 시스템 사업과 시·공간 상세화 사업의 최종 융합한 형태로, 대국민 대상 수자원 빅데이터 통합 플랫폼을 개발하는데에 그 목적이 있다.
- 아래 그림과 같이 크게 네 단계로 구성된 국가 공공 빅데이터 제공 플랫폼이 최종 형태로 활용 될 수 있으며, 각 단계는 다음과 같이 구성되어있다. (1) 수자원 분야의 각종 빅데이터의 수집·통합, (2) 데이터의 표준화 및 품질관리, (3) 수리·수문 모델과의 융합을 통한 UI/UX (User Interfaces / User Experience) 정립, (4) 공공 대상 스마트 수자원 자료 제공 플랫폼
- 본 사업모델의 경우, 대규모의 재원 및 장기적인 개발 계획의 마련이 필요하며, 본 과업에서는 각 단계별로 개략적인 사업 모델을 구상할 때 필수적으로 고려해야할 아이템을 제시하고 있으며, 구체적인 수치나 운용방안에 대한 아이디어를 제시하지 못한다는 한계점이 존재한다.
- 우선, 국내/외 수자원 위성의 관측자료 및 산출물, 물환경 관측자료, 실시간 수질 관측자료, 오염원 배출관리, 지하수 및 상하수도 정보 등 우리나라에서 제공·관리하고 있는 수자원 다양한 source에서 수집되는 실시간 빅데이터를 처리하기 위해서는 무엇보다 높은 스펙의 서버 운용이 필요하다. 또한 자료 전송 방법이나 권한문제, 자료 전송의 형태 등 추가적인 논의도 필요하다. 방대한 양의 자료를 관리하기 위한 대용량의 storage system, NAS system, Cloud system 에 대한 고려가 필요하다.
- 이후, 위성관측을 고려한 현장관측시스템에서 얻어지는 자료와의 매칭을 통한 빅데이터의 품질관리가 필요하며, 각종 통계기법을 활용한 이상치 탐지를 통해 자료의 신뢰도에 대한 flag 정보를 함께 제공할 필요가 있다. 최종적으로 품질검수가 된 자료는 표준화된 (unit, data format, spatio-temporal resolution) 형태로 정리되어 제공될 것이다. 구체적인 수치는 추가적인 논의가 필요하다.
- 이후 표준화된 수자원 분야 빅데이터를 시각화하고 각종 수리·수문 모델과의 융합을 통한 변화 예측, 영향 분석 등의 결과를 표출할 수 있는 시각화 기법에 대한 논의가 필요하다. 이 과정에서 또한 산출물에 대한 불확실성이 논의될 필요가 있으며 이는 자료의 uncertainty flag의 형태로 추가적으로 제공할 필요가 있다.
- 최종적으로 산출된 수자원 분야의 빅데이터는 각각 수요에 맞춘 공공데이터로써 표출될 것이며, 실시간 통합 수질 관리시스템, 스마트 수자원 안전관리 시스템, 스마트 용수 관리 시스템, 수재해 대응 및 수자원 관리 시스템 등과 같은 분야로 구분되어 다양한 민·관 수요처에서 활용할 수 있는 자료 배포 시스템이 갖추어져야 한다.

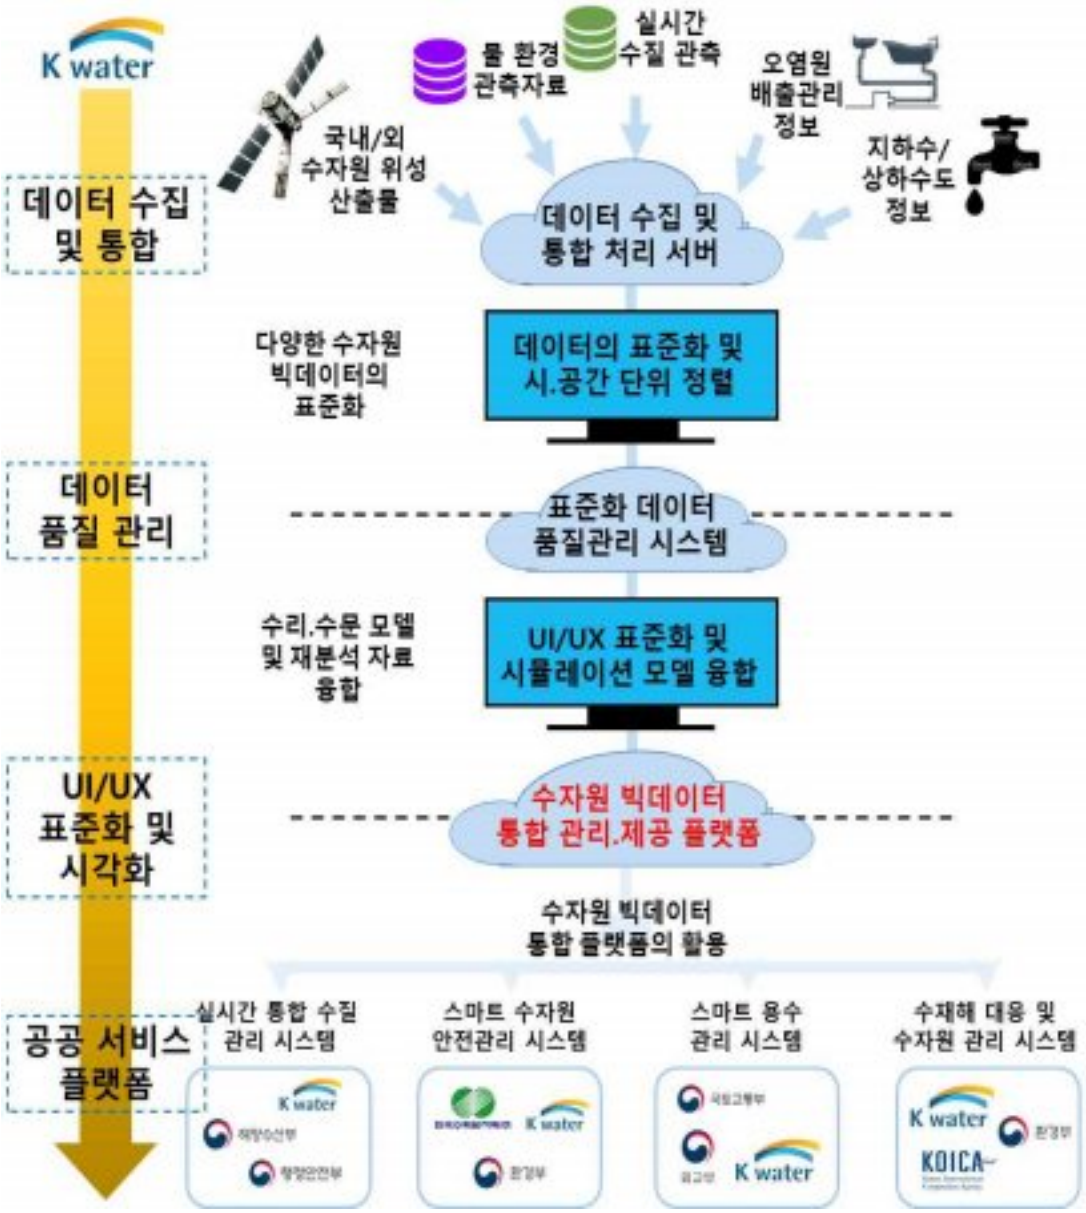


그림 8.15 수자원 분야 빅데이터 자동 통합관리 플랫폼 개발 사업

라. 국제협력 강화를 위한 수자원 분야 해외 공적원조개발 사업추진 기술 개발 사업

1) 국제협력 강화를 위한 수자원 분야 해외 공적원조개발 사업추진 기술 개발 사업 개요

- 본 과업에서는 국제협력 강화를 위하여 저개발국가를 대상으로 한 우리나라의 선진화된 수자원 분야 위성활용 방재기술의 공적원조개발 사업추진 기법을 제안하고자 한다. 대상 국가별 기술수요 분석 및 전문가의 종합적인 평가를 통한 맞춤형 기술이전이 이루어져야 하며, 기술의 장기적인 운영을 위한 각종 교육 및 인력사업에 대한 후속사업도 필요하다.



그림 8.16 국제협력 강화를 위한 수자원 분야 해외 공적원조개발 사업추진 기술 개발 사업

- 앞 절에서 분석한 바와 같이, 동아시아 지역에 대한 물관리 기술의 공적개발원조가 필요한 실정이며, 본 과업에서도 또한 동남아시아 지역에 대한 물 관련 기술원조 사업아이디어를 제시하고자 한다. 상대적으로 각종 기술적 인프라가 낙후된 동남아시아 지역에서 위성자료를 활용하기 위해서는 우선적으로 자료를 송·수신할 수 있는 설비가 필요할 것으로 판단되며, 각종 댐이나 수력발전소에 실시간으로 수위 및 시설물의 상태를 확인할 수 있는 센서와 관리기술에 대한 기술이전이 필요할 것으로 보인다.
- 동남아시아 지역의 저개발국가의 경우, 국가별로 인프라, 경제상황, 기후 및 지리적 특성이 모두 상이하기에, 본 과업에서는 특정 국가를 대상으로 한 수자원 분야 사업 모델을 제시하는 대신, 보편적으로 수행할 수 있는 위성활용 수자원 관리 기법(이수, 치수, 환경 분야)에 대한 공적개발원조 사업 모델을 제시하고자 한다. 이와 관련하여 본 과업에서는 수자원 분야의 재난으로 인한 피해를 저감하기위한 위성 활용 방안을 예시로 제안하였다.

(1) 저개발국가 대상 위성 활용 실시간 수질 관측 및 변화 예측 시스템 개발

- 목표: 다종 위성 활용 실시간 수질 분석 및 변화 예측 시스템 개발
- 시·공간 해상도: 2.8~30m 단위, daily-weekly-monthly 시계열 분석
- 활용 위성: 해수나 연안수보다 수체의 크기와 폭이 현저히 작고 탁도가 높은 하천에 대한 원격탐사; 고해상도 위성영상의 적색 ~ 근적외선 파장영역을 활용하는 two-band 및 three-band reflectance 모델의 적용성 활용 기대
- 특이사항: 동남아시아지역의 경우, 구름에 의한 위성자료 오염이 잦기 때문에 (특히 여름철), 앞서 제안한 visible band를 활용한 국내 지역의 위성활용 수질분석 시스템과 다르게 SAR를 활용한 방안을 제시할 필요가 있음
- 특히, 각 국가별 물관리 시설물 및 인프라에서 얻어지는 준·실시간 수질 관측자료와의 연계가 필수적이며, SAR 관측 자료를 활용한 추가적인 수질 분석 모델의 개발이 필요함
- 추가적으로 각종 수질모의 모델을 활용하기 위한 자료의 유무와 신뢰도를 파악할 필요가 있음. *분석에 필요한 데이터: 수위, 유량, 취수량, TMS 측정망도, 국가수질측정망도, 기온, 지상기압, 일사량, 수질자료 등

표 8.16 다종위성 관측자료를 활용한 실시간 수질 관측 및 변화 예측 시스템: 활용가능 위성 자료

위성	스펙	이미지
Landsat 8 (OLI)	공간 해상도: 30 m (15m pan) 밴드 범위: 0.43 - 1.39 μm 밴드 수: 9 개 시간 해상도: 16 일 이미지 크기: 185 km X 180 km	

Sentinel 1-A/B SAR	L1 single look complex 공간 해상도: 2 - 5 m 밴드: C-band 시간 해상도: 6 일(A/B 각 12일) 이미지 크기: 400 km	
Sentinel 2-A/B (MSI)	공간 해상도: 20 m (10m RGB) 밴드 범위: 0.44 - 2.20 μm 밴드 수: 12 개 시간 해상도: 5 일(A/B 각 10일) 이미지 크기: 290 km	
Cosmo-Skymed -1,2,3,4 (SAR)	공간 해상도: 1 ~ 100m 모드 범위: 9.6GHz(X밴드) 모드 수: 5개 시간 해상도: 12시간(4개 동시) 이미지 크기: 7x7 ~ 200x200 km	
RADARSAT-2 (SAR)	공간 해상도: 8 ~ 100m 모드 범위: 5.405GHz(C밴드) 모드 수: 17개 시간 해상도: 24일 이미지 크기: 50 ~ 90km	
ALOS-2 (SAR)	공간 해상도: 8 ~ 100m 모드 범위: 1.2GHz(L밴드) 모드 수: 6개 시간 해상도: 14일 이미지 크기: 25 ~ 490km	

(2) 위성 활용 수재해 분석 시스템 개발

- 목표: 기상이변에 따른 홍수 및 가뭄에 대한 수재해 피해 저감을 위한 위성활용 기술 개발
- 시・공간 해상도: 5~30m 단위, daily 분석
- 활용 위성: 수체탐지를 위한 각종 광학 및 SAR 기반의 위성 활용
- 특이사항: 구름에 의한 오염이 많을 것으로 기대되므로, SAR 센서를 활용한 고해상도의 수체 탐지를 기반으로 한 수변환경 변화 및 홍수위 변화에 대한 분석이 필요함
- 대상 국가별 물관리 시설물 및 인프라에서 얻어지는 수위 및 수량 관측자료와의 연계가 필수적이며, SAR 활용 고해상도 분석을 위한 보다 지역 특화된 분석 기법의 적용이 필요한 실정임 (예, 광학-분광특성, 후방산란계수 분석, 텍스처 추출 기법, 지구 중력장 변화 탐지, 밴드 조합 사용, 감독토지피복분류, 무감독 토지피복 분류, 물 특성 산출 알고리즘)

표 8.17 기상 및 오염원 변화에 따른 위성 융합 수재해 예측시스템: 활용가능 위성 자료

위성	스펙	이미지
RapidEye	Blue to NIR 6.5m, resampled to 5m pixel size Daily (off-nadir), 5.5 days (at nadir)	
Sentinel 1-A/B SAR	L1 single look complex 공간 해상도: 2 - 5 m 밴드: C-band 시간 해상도: 6 일(A/B 각 12일) 이미지 크기: 400 km	
Sentinel 2-A/B (MSI)	공간 해상도: 20 m (10m RGB) 밴드 범위: 0.44 - 2.20 μm 밴드 수: 12 개 시간 해상도: 5 일(A/B 각 10일) 이미지 크기: 290 km	
Cosmo-Skymed-1,2,3,4 (SAR)	공간 해상도: 1 ~ 100m 모드 범위: 9.6GHz(X밴드) 모드 수: 5개 시간 해상도: 12시간(4개 동시) 이미지 크기: 7x7 ~ 200x200 km	
RADARSAT-2 (SAR)	공간 해상도: 8 ~ 100m 모드 범위: 5.405GHz(C밴드) 모드 수: 17개 시간 해상도: 24일 이미지 크기: 50 ~ 90km	
ALOS-2 (SAR)	공간 해상도: 8 ~ 100m 모드 범위: 1.2GHz(L밴드) 모드 수: 6개 시간 해상도: 14일 이미지 크기: 25 ~ 490km	

제 9 장 맺음말

위성영상은 지구의 시공간적인 정보를 광역적, 연속적, 실시간으로 수집할 수 있는 데이터로서 관측센서 활용과 여러 알고리즘 적용에 따라 다양한 물 관련 정보를 생산할 수 있는 장점이 있어, 다양한 분야에 이용되고 있으며, 이에 2025년 수자원위성 개발 및 발사에 발맞추어 위성영상 활용 자체 기술력 확보를 위하여 수자원분야 위성영상 활용 기술 연구를 수행하였다.

우선, 기술 조사를 통해서 물 관리 분야에 위성영상 활용 사례와 기술 수준을 파악하고, 분석함으로써 실제 상당한 수준의 연구가 되었거나 현업에 적용되고 있는 요소들을 조사하였다. 그 요소로는 기초 수문인자로서 강우와 강설, 토양수분 등의 활용성을 확인하였고, 응용분야로서 강우-유출, 가뭄감시, 수질분석, 토지피복 조사 분야에서 위성영상을 활용한 알고리즘과 기법들이 연구개발 되고 있었다..

3차년도 연구는 위성을 활용한 수질분석 기술개발, 하천경관 변화분석 기법 개발, 미계측유역 수위추정기법 개선방안 분석, 인공지능기법 기반 Hybrid 유출모형 개발, 토양수분자료를 활용한 다변량 가뭄지수 개발을 수행하였다.

위성영상을 활용한 수질분석의 경우, 기존의 회귀모형에서 보였던 오차들을 인공지능 기법을 이용하여 정확도를 개선하기 위하여 원격탐사 기반 수질 분석 및 환경 분야에서 널리 사용되며 좋은 성능을 보이는 기계학습 기법인 RF (Random Forest), XGB (eXtreme Gradient Boosting), CTB (CaTBoost)를 각각 수질 인자에 대하여 적용하였다. Chl-a의 결정계수(R^2)는 RF 모델의 경우, 0.65, XGB가 0.61, CTB가 0.58 로 나타났고, 조류세포수는 각각 0.64, 0.66, 0.67 로 유의할 수준으로 산출되었으나, 부유물질은 0.31, 0.24, 0.16 수준으로 개선의 여지가 있는 것으로 판단되었다.

하천경관분류 분석 기술은 기존의 분류방법을 여러 가지 인공지능 방법들을 적용하여 평가하고, 구름제거 등으로 인한 오분류를 보완하여 정확도를 개선하고, 오분류 현장조사를 통해 오분류 원인을 분석하였다. 구름제거 알고리즘을 통해 분류 정확도를 86% 까지 확보할 수 있었고, 특히 수체, 초지, 경작지를 완벽히 분류할 수 있었으나, 나지, 건물 분류 등에 대해서는 상대적으로 낮은 분류 정확도를 보여 향후 개선 과제를 남겼다.

댐, 하천 등 수자원 관리에 있어서 중요한 요소 중 하나인 수위를 위성영상을 이용해 분석하고 그 결과의 정확도 개선 가능성과 방안 검토에서는 수체경계 추출을 위한 SAR 영상의 임계값은 -14.5dB, 광학영상에서는 NDWI -0.1 ~ -0.15를 확인할 수 있었다. 또한 수위분석 영역은 경사가 급한 댐체영역보다는 지형경사가 완만한 댐상류영역이 효율적임이 확인되었고, SAR영상과 광학영상의 수위정확도는 큰 차이가 없음을 알 수 있었다. 다만 SAR 영상의 전처리가 수위분석 오차에 중요한 요소임도 확인하였다. 이 결과들은 향후 황강댐 유역 적용을 위한 가이드라인으로 활용할 예정이다.

강우-유출분야 활용을 목적으로, 위성기반의 토양수분 정보를 이용하고 인공지능 기법을 활용하여 기존 Tank 유출모형과 결합한 Hybrid 모형을 개발하고 용담댐 유역을 대상으로 모형 성능을 검·보정하는 연구를 수행하였다. 그 결과 탱크 모형 및 Data 기반의 LSSVM 모형보다 유역 유출을 우수하게 모의한 결과를 보였으며, 특히 저유량(Low flow) 부분에서 개선된 결과를 보였다.

위성자료를 활용하여 농업적, 기상학적 가뭄지수를 통합한 다변량 가뭄지수를 개발하고 결과를 분석하였다. 그 결과 농업적, 기상학적 가뭄지수는 지속 시간 및 가뭄심도에 있어서 다소 다른 특성을 보이나, 또한 기상학적 가뭄이 농업적 가뭄으로 전이되는 현상을 확인할 수 있었고, 이를 활용한 다변량 가뭄지수를 통해서 우리나라 지역별 가뭄심도 특성을 분석할 수 있었다.

참고문헌

Abdi, A. M. (2020). Land cover and land use classification performance of machine learning algorithms in a boreal landscape using Sentinel-2 data. GIScience & Remote Sensing, 57(1), 1-20.

Arabi, B., Salama, M. S., Pitarch, J., & Verhoef, W. (2020). Integration of in-situ and multi-sensor satellite observations for long-term water quality monitoring in coastal areas. Remote sensing of environment, 239, 111632.

Basri, H., 2013. Development of Rainfall-runoff Model Using Tank Model: Problems and Challenges in Province of Aceh, Indonesia. Aceh Int. J. Sci. Technol. 2, 26–36. https://doi.org/10.13170/aijst.2.1.574

Beck, R., Xu, M., Zhan, S., Liu, H., Johansen, R. A., Tong, S., ... & Berling, K. (2017). Comparison of satellite reflectance algorithms for estimating phycocyanin values and cyanobacterial total biovolume in a temperate reservoir using coincident hyperspectral aircraft imagery and dense coincident surface observations. Remote Sensing, 9(6), 538.

Behzad, M., Asghari, K., Eazi, M., Palhang, M., 2009. Generalization performance of support vector machines and neural networks in runoff modeling. Expert Syst. Appl. 36, 7624–7629. https://doi.org/10.1016/j.eswa.2008.09.053

Bober, W., 2013. Introduction to Numerical and Analytical Methods with MATLAB for Engineers and Scientists. https://doi.org/https://doi.org/10.1201/b16030

Brocca, L., Melone, F., Moramarco, T., Wagner, W., Hasenauer, S., 2010b. ASCAT soil wetness index validation through in situ and modeled soil moisture data in central Italy. Remote Sens. Environ. 114, 2745–2755. https://doi.org/10.1016/j.rse.2010.06.009

Brocca, L., Moramarco, T., Melone, F., Wagner, W., Hasenauer, S., Hahn, S., 2012. Assimilation of surface- and root-zone ASCAT soil moisture products into rainfall-runoff modeling. IEEE Trans. Geosci. Remote Sens. 50, 2542–2555. https://doi.org/10.1109/TGRS.2011.2177468

Brocca, L., Ciabatta, L., Massari, C., Moramarco, T., Hahn, S., Hasenauer, S., Kidd, R., Dorigo, W., Wagner, W., Levizzani, V., 2014. Journal of Geophysical Research : Atmospheres rainfall from satellite soil moisture data. J. Geophys. Res. 1–14. https://doi.org/10.1002/2014JD021489

Ciabatta, L., Massari, C., Brocca, L., Gruber, A., Reimer, C., Hahn, S., Paulik, C., Dorigo, W., Kidd, R., Wagner, W., 2018. SM2RAIN-CCI: A new global long-term rainfall data set derived from ESA CCI soil moisture. Earth Syst. Sci. Data 10, 267–280. https://doi.org/10.5194/essd-10-267-2018

Brocca, L., Tarpanelli, A., Filippucci, P., Dorigo, W., Zaussinger, F., Gruber, A., & Fernández-Prieto, D. (2018). How much water is used for irrigation? A new approach exploiting coarse resolution satellite soil moisture products. International journal of applied earth observation and geoinformation, 73, 752-766.

Choe, S. H., Lee, H. G., Chae, H. S., Hwang, U. H., Kim, D. H., Lee, S. H., & Lee, J. H. (2019). 수자원/수재해 모니터링을 위한 위성 탑재체 개발 전략 수립. Water for future, 52(10), 12-21.

Clayton, D.G., 1978. A Model for Association in Bivariate Life Tables and Its Application in Epidemiological Studies of Familial Tendency in Chronic Disease Incidence. Biometrika 65, 141–151.

Clerici, N., Valbuena Calderón, C. A., & Posada, J. M. (2017). Fusion of Sentinel-1A and Sentinel-2A data for land cover mapping: a case study in the lower Magdalena region, Colombia. Journal of Maps, 13(2), 718-726.

Demirkan, D. Ç., Koz, A., & Düzgün, H. S. (2020). Hierarchical classification of Sentinel 2-a images for land use and land cover mapping and its use for the CORINE system. Journal of Applied Remote Sensing, 14(2), 026524.

Deng, Y., Wu, C., Li, M., & Chen, R. (2015). RNDSI: A ratio normalized difference soil index for remote sensing of urban/suburban environments. International Journal of Applied Earth Observation and Geoinformation, 39, 40-48.

Devia, G.K., Ganasri, B.P., Dwarakish, G.S., 2015. A Review on Hydrological Models. Aquat. Procedia 4, 1001–1007. https://doi.org/10.1016/j.aqpro.2015.02.126

Dharssi, I., Bovis, K.J., Macpherson, B., Jones, C.P., 2011. Operational assimilation of ASCAT surface soil wetness at the Met Office. Hydrol. Earth Syst. Sci. 15, 2729–2746. https://doi.org/10.5194/hess-15-2729-2011

Dörnhöfer, K., Klinger, P., Heege, T., & Oppelt, N. (2018). Multi-sensor satellite and in situ monitoring of phytoplankton development in a eutrophic-mesotrophic lake. Science of The Total Environment, 612, 1200-1214.

Ekercin, S. (2007). Water quality retrievals from high resolution IKONOS multispectral imagery: A case study in Istanbul, Turkey. Water, Air, and Soil Pollution, 183(1-4), 239-251.

Enenkel, M., Steiner, C., Mistelbauer, T., Dorigo, W., Wagner, W., See, L., Atzberger, C., Schneider, S., Rogenhofer, E., 2016. A combined satellite-derived drought indicator to support humanitarian aid organizations. Remote Sens. 8. https://doi.org/10.3390/rs8040340

Farahmand, A., AghaKouchak, A., 2015. A generalized framework for deriving nonparametric standardized drought indicators. Adv. Water Resour. 76, 140–145. https://doi.org/10.1016/j.advwatres.2014.11.012

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. Remote Sensing of Environment, 202, 18-27.

He, X., Bai, Y., Pan, D., Huang, N., Dong, X., Chen, J., ... & Cui, Q. (2013). Using geostationary satellite ocean color data to map the diurnal dynamics of suspended particulate matter in coastal waters. Remote Sensing of Environment, 133, 225-239.

Herkelrath WN, Hamburg SP, Murphy F. 1991;Automatic, real-time monitoring of soil moisture in a remote field area with time domain reflectometry. Water Resources Research 27(5):857–864.

Huang, G., Wu, L., Ma, X., Zhang, W., Fan, J., Yu, X., ... & Zhou, H. (2019). Evaluation of CatBoost method for prediction of reference evapotranspiration in humid regions. Journal of Hydrology, 574, 1029-1041.

Jadav, J. J., & Panchal, M. (2012). Association rule mining method on OLAP cube. International Journal of Engineering Research and Applications (IJERA), 2(2), 1147-1151.

Jakeman, A.J., 1993. How Much Complexity Is Warranted in a Rainfall-Runoff Model ? are good predictors of streamflow and. Water Resour. Res. 29, 2637–2649. https://doi.org/10.1029/93WR00877

Jalilvand, E., Tajrishy, M., Hashemi, S. A. G. Z., & Brocca, L. (2019). Quantification of irrigation water using remote sensing of soil moisture in a semi-arid region. Remote Sensing of Environment, 231, 111226.

Jamali, A. (2020). Land use land cover mapping using advanced machine learning classifiers: A case study of Shiraz city, Iran. Earth Science Informatics, 1-16.

Ju, J., & Roy, D. P. (2008). The availability of cloud-free Landsat ETM+ data over the conterminous United States and globally. Remote Sensing of Environment, 112(3), 1196-1211.

Keller, S., Maier, P. M., Riese, F. M., Norra, S., Holbach, A., Börsig, N., ... & Hinz, S. (2018). Hyperspectral data and machine learning for estimating CDOM, chlorophyll a, diatoms, green algae and turbidity. International journal of environmental research and public health, 15(9), 1881.

Kisi, O., Parmar, K.S., 2016. Application of multivariate adaptive regression spline models in long term prediction of river water pollution. J. Hydrol. 534, 104–112. https://doi.org/10.1016/j.jhydrol.2015.12.014

Kouraev, A. V., Zakharova, E. A., Samain, O., Mognard, N. M., and Cazenave, A. (2004). “Ob'river discharge from TOPEX/Poseidon satellite altimetry (1992–2002).” Remote Sensing ofEnvironment, Elsevier, Vol. 93, No. 1-2, pp. 238-245.

Kudela, R. M., Palacios, S. L., Austerberry, D. C., Accorsi, E. K., Guild, L. S., & Torres-Perez, J. (2015). Application of hyperspectral remote sensing to cyanobacterial blooms in inland waters. Remote Sensing of Environment, 167, 196-205.

Kwon, H.H., Lall, U., Kim, S.J., 2016. The unusual 2013–2015 drought in South Korea in the context of a multicentury precipitation record: Inferences from a nonstationary, multivariate, Bayesian copula model. Geophys. Res. Lett. 43, 8534–8544. https://doi.org/10.1002/2016GL070270

Kwon, M., Kwon, H.H., and Dawei Han. 2019. “Spatio-temporal Drought Patterns of Multiple Drought Indices Based on Precipitation and Soil Moisture: A case study in South Korea.” International Journal of Climatology. DOI: 10.1002/joc.6094.

Lee, M. J., Yun, J. H., Jo, N. U., Han, H. G., & Lee, S. M. (2019). 영상레이더 환경 분야 활용 기술 및 체계 정립. Water for future, 52(10), 29-36.

Lee, S. G., Yu, S. B., Baek, M. J., & Lee, H. C. (2019). C-밴드 영상레이더 탑재체 기술 개발 현황. Water for future, 52(10), 22-28.

Lievens, H., Tomer, S.K., Al Bitar, A., De Lannoy, G.J.M., Drusch, M., Dumedah, G., Hendricks Franssen, H.J., Kerr, Y.H., Martens, B., Pan, M.,

Roundy, J.K., Vereecken, H., Walker, J.P., Wood, E.F., Verhoest, N.E.C., Pauwels, V.R.N., 2015. SMOS soil moisture assimilation for improved hydrologic simulation in the Murray Darling Basin, Australia. Remote Sens. Environ. 168, 146–162. https://doi.org/10.1016/j.rse.2015.06.025

Li, C., Singh, V.P., Mishra, A.K., 2013. A bivariate mixed distribution with a heavy-tailed component and its application to single-site daily rainfall simulation. Water Resour. Res. 49, 767–789. https://doi.org/10.1002/wrcr.20063

Loizu, J., Massari, C., Álvarez-Mozos, J., Tarpanelli, A., Brocca, L., Casalí, J., 2018. On the assimilation set-up of ASCAT soil moisture data for improving streamflow catchment simulation. Adv. Water Resour. 111, 86–104. https://doi.org/10.1016/j.advwatres.2017.10.034

Mansaray, L., Huang, W., Zhang, D., Huang, J., & Li, J. (2017). Mapping rice fields in urban Shanghai, southeast China, using Sentinel-1A and Landsat 8 datasets. Remote Sensing, 9(3), 257.

Massari, C., Brocca, L., Ciabatta, L., Moramarco, T., Gabellani, S., Albergel, C., De Rosnay, P., Puca, S., Wagner, W., 2015. The Use of H-SAF Soil Moisture Products for Operational Hydrology: Flood Modelling over Italy. Hydrology 2, 2–22. https://doi.org/10.3390/hydrology2010002

McFeeters, S. K. (1996). The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features. International journal of remote sensing , 17 (7), 1425-1432.

Mckee, T.B., Doesken, N.J., Kleist, J., 1993. The relationship of drought frequency and duration to time scales. AMS 8th Conf. Appl. Climatol. 179–184. https://doi.org/citeulike-article-id:10490403

Merchant, M. A., Warren, R. K., Edwards, R., & Kenyon, J. K. (2019). An Object-Based Assessment of Multi-Wavelength SAR, Optical Imagery and Topographical Datasets for Operational Wetland Mapping in Boreal Yukon, Canada. Canadian Journal of Remote Sensing, 1-25.

Min, S.K., Kwon, W.T., Park, E.H., Choi, Y., 2003. Spatial and temporal comparisons of droughts over Korea with East Asia. Int. J. Climatol. 23, 223–233. https://doi.org/10.1002/joc.872

Mojena, R., 1977. Hierarchical grouping methods and stopping rules: An evaluation. Coputer J. 20, 359–363.

Moses, W. J., Gitelson, A. A., Berdnikov, S., Saprygin, V., & Povazhnyi, V. (2012). Operational MERIS-based NIR-red algorithms for estimating chlorophyll-a concentrations in coastal waters—The Azov Sea case study. Remote Sensing of Environment, 121, 118-124.

Musa, Z., Popescu, I., and Mynett, A. (2015). “A review of applications of satellite SAR, optical, altimetry and DEM data for surface water modelling, mapping and parameter estimation.” Hydrology and Earth System Sciences, Copernicus GmbH, Vol. 19, No. 9, pp. 3755-3769.

Nam, W.H., Hayes, M.J., Svoboda, M.D., Tadesse, T., Wilhite, D.A., 2015. Drought hazard assessment in the context of climate change for South Korea. Agric. Water Manag. 160, 106–117. https://doi.org/10.1016/j.agwat.2015.06.029

Nascimento, W. R., Souza-Filho, P. W. M., Proisy, C., Lucas, R. M., & Rosenqvist, A. (2013). Mapping changes in the largest continuous Amazonian mangrove belt using object-based classification of multisensor satellite imagery. Estuarine, Coastal and Shelf Science, 117, 83–93.

Nguyen, T. H. D., Phan, K. D., Nguyen, H. T. T., Tran, S. N., Tran, T. G., Tran, B. L., & Doan, T. N. (2020). TOTAL SUSPENDED SOLID DISTRIBUTION IN HAU RIVER USING SENTINEL 2A SATELLITE IMAGERY. ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 6, 91-97.

Okkan, U., Serbes, Z.A., 2012. Rainfall-runoff modeling using least squares support vector machines. Environmetrics 23, 549–564. https://doi.org/10.1002/env.2154

Onojeghuo, A. O., Blackburn, G. A., Wang, Q., Atkinson, P. M., Kindred, D., & Miao, Y. (2018). Mapping paddy rice fields by applying machine learning algorithms to multi-temporal Sentinel-1A and Landsat data. International journal of remote sensing, 39(4), 1042-1067.

Orth, R., Staudinger, M., Seneviratne, S.I., Seibert, J., Zappa, M., 2015. Does model performance improve with complexity? A case study with three hydrological models. J. Hydrol. 523, 147–159. https://doi.org/10.1016/j.jhydrol.2015.01.044

Oyama, Y., Matsushita, B., Fukushima, T., Matsushige, K., & Imai, A. (2009). Application of spectral decomposition algorithm for mapping water quality in a turbid lake (Lake Kasumigaura, Japan) from Landsat TM data. ISPRS Journal of Photogrammetry and Remote sensing, 64(1), 73-85.

Pahlevan, N., Smith, B., Schalles, J., Binding, C., Cao, Z., Ma, R., ... & Matsushita, B. (2020). Seamless retrievals of chlorophyll-a from Sentinel-2 (MSI) and Sentinel-3 (OLCI) in inland and coastal waters: A machine-learning approach. Remote Sensing of Environment, 111604.

Paik, K., Kim, J.H., Kim, H.S., Lee, D.R., 2005. A conceptual rainfall-runoff model considering seasonal variation. Hydrol. Process. 19, 475–476. https://doi.org/10.1002/hyp.5984

Raghavendra, S., Deka, P.C., 2014. Support vector machine applications in the field of hydrology: A review. Appl. Soft Comput. J. 19, 372–386. https://doi.org/10.1016/j.asoc.2014.02.002

Park, S., Im, J., Park, S., Yoo, C., Han, H., & Rhee, J. (2018). Classification and mapping of paddy rice by combining Landsat and SAR time series data. Remote Sensing, 10(3), 447.

Park, S., Shin, M., Im, J., Song, C. K., Choi, M., Kim, J., ... & Kim, S. K. (2019). Estimation of ground-level particulate matter concentrations through the synergistic use of satellite observations and process-based models over South Korea.

Pereira, L. O., Freitas, C. C., Sant, S. J., & Reis, M. S. (2018). Evaluation of Optical and Radar Images Integration Methods for LULC Classification in Amazon Region. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 11(9), 3062-3074.

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A.

(2018). CatBoost: unbiased boosting with categorical features. Advances in Neural Information Processing Systems, 31, 6638-6648.

Pu, F., Ding, C., Chao, Z., Yu, Y., & Xu, X. (2019). Water-quality classification of inland lakes using landsat8 images by convolutional neural networks. Remote Sensing, 11(14), 1674.

Qin, Y., Xiao, X., Dong, J., Zhou, Y., Zhu, Z., Zhang, G., ... & Li, X. (2015). Mapping paddy rice planting area in cold temperate climate region through analysis of time series Landsat 8 (OLI), Landsat 7 (ETM+) and MODIS imagery. ISPRS Journal of Photogrammetry and Remote Sensing, 105, 220-233.

Qiu, S., Zhu, Z., & He, B. (2019). Fmask 4.0: Improved cloud and cloud shadow detection in Landsats 4–8 and Sentinel-2 imagery. Remote Sensing of Environment, 231, 111205.

Rogers, A. S., & Kearney, M. S. (2004). Reducing signature variability in unmixing coastal marsh Thematic Mapper scenes using spectral indices. International Journal of Remote Sensing, 25(12), 2317-2335.

Rouse Jr, J. W., Haas, R. H., Schell, J. A., &Deering, D. W. (1974). Paper A 20. In Third Earth Resources Technology Satellite-1 Symposium: The Proceedings of a Symposium Held by Goddard Space Flight Center at Washington, DC on December 10-14, 1973: Prepared at Goddard Space Flight Center (Vol. 351, p. 309). Scientific and Technical Information Office, National Aeronautics and Space Administration.

Saberioon, M., Brom, J., Nedbal, V., Souček, P., & Císař, P. (2020). Chlorophyll-a and total suspended solids retrieval and mapping using Sentinel-2A and machine learning for inland waters. Ecological Indicators, 113, 106236.

Scharroo, R., Bonekamp, H., Ponsard, C., Parisot, F., von Engeln, A., Tahtadjiev, M., de Vriendt, K., and Montagner, F. (2016). “Jason continuity of services: continuing the Jason altimeter data records as Copernicus Sentinel-6.” Ocean Science, Copernicus GmbH, Vol. 12, No. 2, pp. 471-479.

Seegers, B. N., Stumpf, R. P., Schaeffer, B. A., Loftin, K. A., & Werdell, P. J. (2018). Performance metrics for the assessment of satellite data products: an ocean color case study. Optics express, 26(6), 7404-7422.

Shahzad, M. I., Meraj, M., Nazeer, M., Zia, I., Inam, A., Mehmood, K., & Zafar, H. (2018). Empirical estimation of suspended solids concentration in the Indus Delta Region using Landsat-7 ETM+ imagery. Journal of environmental management, 209, 254-261.

Shin, J., Yoon, S., & Cha, Y. (2017). Prediction of cyanobacteria blooms in the lower Han River (South Korea) using ensemble learning algorithms. DESALINATION AND WATER TREATMENT, 84, 31-39.

Shrestha, D.L., 2009. Uncertainty Analysis in Rainfall-Runoff Modelling: Application of Machine Learning Techniques, Delft University of Technology and \rof the Academic Board of UNESCO-IHE Institute for Water \rEducation.

Singh, S. K., Laari, P. B., Mustak, S., Srivastava, P. K., & Szabó, S. (2018).

Modelling of land use land cover change using earth observation data-sets of Tons River Basin, Madhya Pradesh, India. Geocarto international, 33(11), 1202-1222.

Steinhausen, M. J., Wagner, P. D., Narasimhan, B., & Waske, B. (2018). Combining Sentinel-1 and Sentinel-2 data for improved land use and land cover mapping of monsoon regions. International journal of applied earth observation and geoinformation, 73, 595-604.

Sugawara, M., 1979. Automatic calibration of the tank model. Hydrol. Sci. Bull. 24, 375–388. https://doi.org/10.1080/02626667909491876

Suykens, J.A.K., De Brabanter, J., Lukas, L., Vandewalle, J., 2002. Weighted least squares support vector machines: Robustness and sparce approximation. Neurocomputing 48, 85–105. https://doi.org/10.1016/S0925-2312(01)00644-0

Svab, E., Tyler, A. N., Preston, T., Presing, M., & Balogh, K. V. (2005). Characterizing the spectral reflectance of algae in lake waters with high suspended sediment concentrations. International Journal of Remote Sensing, 26(5), 919-928.

Tatli, H., 2015. Detecting persistence of meteorological drought via the Hurst exponent. Meteorol. Appl. 22, 763–769. https://doi.org/10.1002/met.1519

Toming, K., Kutser, T., Laas, A., Sepp, M., Paavel, B., & Nõges, T. (2016). First experiences in mapping lake water quality parameters with Sentinel-2 MSI imagery. Remote Sensing, 8(8), 640.

Torbick, N., Chowdhury, D., Salas, W., & Qi, J. (2017). Monitoring rice agriculture across myanmar using time series Sentinel-1 assisted by Landsat-8 and PALSAR-2. Remote Sensing, 9(2), 119.

Vapnik, V., 1995. The Nature of Statistical Learning Theory. Springer, New York.

Wahap, N. A., & Shafri, H. Z. (2020, July). Utilization of Google Earth Engine (GEE) for land cover monitoring over Klang Valley, Malaysia. In IOP Conference Series: Earth and Environmental Science (Vol. 540, No. 1, p. 012003). IOP Publishing.

Wang, L., Qu, J. J., Hao, X., &Zhu, Q. (2008). Sensitivity studies of the moisture effects on MODIS SWIR reflectance and vegetation water indices. International Journal of Remote Sensing , 29 (24), 7065-7075.

Wei, L., Huang, C., Zhong, Y., Wang, Z., Hu, X., & Lin, L. (2019). Inland waters suspended solids concentration retrieval based on PSO-LSSVM for UAV-borne hyperspectral remote sensing imagery. Remote Sensing, 11(12), 1455.

Western AW, Zhou SL, Grayson RB, McMahon TA, Blöschl G, Wilson DJ. 2004;Spatial correlation of soil moisture in small catchments and its relationship to dominant spatial hydrological processes. Journal of Hydrology 286(1–4):113–134.

Won, J. S., Park, U., Choe, J. H., Jeong, J. H., Lee, Y. G., Jang, W. J., ... & Jang, S. M. (2019). 수자원 위성 영상 활용을 위한 수문인자 산출 전략 수립 및 알고리즘 기반 기술 정립과 표준화 및 모듈화. Water for future, 52(10),

37-44.

Yim, I., Shin, J., Lee, H., Park, S., Nam, G., Kang, T., ... & Cha, Y. (2020). Deep learning-based retrieval of cyanobacteria pigment in inland water for in-situ and airborne hyperspectral data. Ecological Indicators, 110, 105879.

Young, C.C., Liu, W.C., Wu, M.C., 2017. A physically based and machine learning hybrid approach for accurate rainfall-runoff modeling during extreme typhoon events. Appl. Soft Comput. J. 53, 205–216. https://doi.org/10.1016/j.asoc.2016.12.052

Yu, J. J., Lee, H. J., Lee, K. L., Lyu, H. S., Whang, J. W., Shin, L. Y., & Chen, S. U. (2014). Relationship between distribution of the dominant phytoplankton species and water temperature in the Nakdong River, Korea. Korean Journal of Ecology and Environment, 47(4), 247-257.

Zha, Y., Gao, J., & Ni, S. (2003). Use of normalized difference built-up index in automatically mapping urban areas from TM imagery. International journal of remote sensing, 24(3), 583-594.

Zhang, H., & Xu, R. (2018). Exploring the optimal integration levels between SAR and optical data for better urban land cover mapping in the Pearl River Delta. International journal of applied earth observation and geoinformation, 64, 87-95.

Zhang, L., Zhou, T., 2015. Drought over East Asia: A review. J. Clim. 28, 3375–3399. https://doi.org/10.1175/JCLI-D-14-00259.1

Zhang, M., Lin, H., Wang, G., Sun, H., & Fu, J. (2018). Mapping Paddy Rice Using a Convolutional Neural Network (CNN) with Landsat 8 Datasets in the Dongting Lake Area, China. Remote Sensing, 10(11), 1840.

Zhang, Y., Hallikainen, M., Zhang, H., Duan, H., Li, Y., & San Liang, X. (2018). Chlorophyll-a estimation in turbid waters using combined SAR data with hyperspectral reflectance data: A case study in Lake Taihu, China. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 11(4), 1325-1336.

Zhu, Z., & Woodcock, C. E. (2014). Continuous change detection and classification of land cover using all available Landsat data. Remote Sensing of Environment, 144, 152–171. https://doi.org/10.1016/j.rse.2014.01.011

Zhu, Z., & Woodcock, C. E. (2014). Continuous change detection and classification of land cover using all available Landsat data. Remote Sensing of Environment, 144, 152–171. https://doi.org/10.1016/j.rse.2014.01.011

국립환경과학원. (2018). 환경위성 산출 자료 실시간 검증을 위한 기법 개발 연구.

국토교통부. (2016). 통계로 보는 한국의 수자원

김성준. (2004). 농촌용수 물수요량 추정을 위한 GIS/RS 기반의 통합시스템 정보체계, 한국관개배수논문집/11(1), 17-24, 한국관개배수위원회

김연수, 김경태, 노희성, 김형수 (2015). 빅 데이터 기반의 수자원 정보 관리 방안. 대한토목학회지, 63(3), 50-57

김용민, 박완용, 어양담, & 김용일. (2010). 다중센서와 GIS 자료를 이용한

접근불능지역의 토지피복 분류. 한국측량학회지, 28(5), 493-504.

나현섭, 박정묵, & 이정수. (2015). 원격탐사와 공간통계 기법을 이용한 토지피복 분류 및 패턴 분석-강원도 DMZ 일원을 대상으로. 한국지리정보학회지, 18(4), 100-118.

박성욱, 이수진, 윤예슬, 신대윤, 박상영, & 이양원. (2018). Sentinel-2 와 RapidEye 위성의 Red Edge 밴드를 활용한 담수역 클로로필-a 농도 추정. 국토지리학회지, 52(3), 445-454.

박주성, 이원희, & 조명희. (2016). Landsat-8 OLI 영상과 식생 및 수분지수를 이용한 하천유역 토지피복분류 정확도 개선. 한국지리정보학회지, 19(2), 98-106.

박현수, 장동호, & 이승호. (2018). 다중시기 위성영상과 기후자료를 활용한 쌀 생산지 면적 및 생산량 분석-방글라데시 Barisal 지역을 중심으로. 기후연구, 13(2), 105-117.

서미진, 조창대, 임태효, 김상훈, 윤현정, 김용석, & 김경훈. (2019). 낙동강수계 수질의 시· 공간적 특성에 대한 통계학적 분석. 한국환경과학회지, 28(3), 303-320.

서영상. (2006). 해수색 원격탐사에 의한 동해 연근해역 클로로필 a 이상분포 연구. 한국환경과학회지, 15(1), 59-66.

신용철, 이태화, 김상우, 이현우, 최경숙, 김종건, & 이기하. (2017). SMAP 토양수분 이미지를 이용한 농업가뭄 평가 기법 개발. 한국농공학회논문집, 59(1), 57.

염준호, 이정호, 김덕진, & 김용일. (2011). IKONOS 와 AIRSAR 영상을 이용한 계층적 토지 피복 분류. 대한원격탐사학회지, 27(4), 435-444.

이동국, 방대식, 이현직. (2019). 다시기 위성영상 기반의 NDVI 및 NDWI 생성과 객체기반분류 기법을 적용한 농경지 객체 추출. 대한공간정보학회 학술대회, (), 77-78.

이상현, 오윤경, 박나영, 이성학, & 최진용. (2014). RapidEye 위성영상의 시계열 NDVI 및 객체기반 분류를 이용한 북한 재령군의 논벼 재배지역 추출 기법 연구. 한국농공학회논문집, 56(3), 55–64.

전왕수, 유호진, & 최현. (2019). Kompsat-3A 영상과 Deep Learning 을 이용한 농경지 분류. 대한공간정보학회 학술대회, 210-211.

정윤재. (2015). LiDAR DEM 과 다중시기에 촬영된 Landsat 영상을 이용한 낙동강 유역 내 토지피복 변화 탐지. 한국지리정보학회지, 18(2), 135-148.

정재환, 조성근, 백종진, & 최민하. (2018). 산악 지형에서의 토양 수분 관측소 구축을 위한 연구 (2). 1. 한국방재학회 논문집, 18, 83-91.

조원호, 임용호, &박기호. (2019). 합성곱 신경망을 이용한 딥러닝 기반의 토지피복 분류: 한국 토지피복을 대상으로. 대한지리학회지 , 54 (1), 1-16.

최병구, 박정묵, & 이정수. (2013). Landsat TM 위성영상을 활용한 토지피복변화탐지 및 파편화 분석-강원도 고성군의 DMZ 지역 일원을 대상으로. 한국사진지리학회지, 23(1), 75-85.

최은영, 이재운, & 이재관. (2011). 고해상도 위성영상을 이용한 낙동강 유역의 클로로필-a 농도 추정. Korean Journal of Remote Sensing, 27(5), 613-623.

홍석영, 민병걸, 이지민, 김이현, & 이경도. (2012). RapidEye 영상을 이용한 북한의 논 면적 산정. 한국토양비료학회지, 45(6), 1194-1202.

홍석영, 홍진영, 김이현, & 오이석. (2007). 지상관측 레이다 산란계를 이용한 벼 군락의 후방산란계수 측정. 대한원격탐사학회지, 23(2), 145-152.

환경부. (2019. 12.). 2019년 물산업 통계조사 보고서(2018년 기준).