K-water연구원
2025-WR-RR-26-84
G230159
Final Report

위성영상기반 공간적 녹조 예측기술 개발

Development of Satellite Image-based Spatial Algal blooms Prediction Technology

2024. 12.

K water 한국수자원공사

KOREA
WATER RESOURCES
CORPORATION

위성영상기반 공간적 녹조 예측기술 개발

K water 한국수자원공사

위성영상기반 공간적 녹조 예측기술 개발

Development of Satellite Image-based Spatial Algal blooms Prediction Technology

2024. 12.

K water 한국수자원공사

제 출 문

사 장 귀하

이 보고서를 2024년도 K-water연구원 수자원환경연구소에서 수행한 “위성영상기반 공간적 녹조 예측기술 개발”의 최종 연구보고서로 제출합니다.

2024. 12.

연구책임자 : K-water연구원		책임연구원	이 혜 숙
연구수행자 : K-water연구원		책임연구원	정 선 아
		책임연구원	최 정 규
		선임연구원	박 형 석
		책임위원	최 성 화
		선임연구원	남 기 범
		수석위원	정 지 영
		위촉연구원	전 유 호
겸직연구원	물환경관리처	전문위원	이 희 숙
	물환경관리처	선임위원	윤 석 제
	대청댐지사	환경 3급	장 봉 호
	대청댐지사	환경 4급	김 동 윤
	영주댐지사	환경 3급	배 원 민
	소양강댐지사	수석연구원	최 광 순
자문	부산대학교	교수	표 종 철

연구개발결과 활용보고서

<table>
<tr><td rowspan="12">1. 연구 총괄</td><td colspan="2">[간행물 관리번호: 2025-WR-RR-26-84]</td><td colspan="3">[과제번호: G230159]</td></tr>
<tr><td>(1)연구과제명</td><td colspan="4">위성영상기반 공간적 녹조 예측기술 개발</td></tr>
<tr><td rowspan="4">(2)수행부서</td><td rowspan="4">K-water연구원</td><td rowspan="4">(3)연구책임자</td><td>성명</td><td>이혜숙</td></tr>
<tr><td>소속</td><td>K-water연구원</td></tr>
<tr><td>전화번호</td><td>042-870-7454</td></tr>
<tr><td>E-mail</td><td>yihs@kwater.or.kr</td></tr>
<tr><td>(4)연 구 기 간</td><td>2024. 2. ~ 2024. 12.
(총 11개월)</td><td rowspan="3">(5)총연구개발비
(천원)</td><td>총액</td><td>70,303</td></tr>
<tr><td>(6)협 동 기 관</td><td></td><td>정부</td><td></td></tr>
<tr><td>(7)참 여 기 업</td><td></td><td>기업</td><td></td></tr>
<tr><td>(8)기 술 분 야</td><td></td><td>(9)참여 연구원</td><td colspan="2">7명/ 11개월</td></tr>
<tr><td colspan="5">(10)연구개발목표</td></tr>
<tr><td colspan="5">○위성영상 기반 클로로필-a 정확도 개선 및 세포수 추정 알고리즘 개발
○ 위성영상 기반 공간적 클로로필-a 변화 단기 예측 기술 개발
○ 광역적·원격 녹조 모니터링 기반 사전 녹조관리 의사결정 프로세스 마련</td></tr>
<tr><td colspan="5">(11)주요연구내용</td></tr>
<tr><td colspan="5">○ 대청·영주댐 저수지 클로로필-a 원격관측 알고리즘 정확도 개선
– 측정망 및 Sentinel-2 관측일 매칭후 분석DB 구축
– 위성영상 기반 공간적 클로로필-a 농도 추정 알고리즘 개발
○ 대청·영주댐 저수지 세포수 원격관측 알고리즘 구축
– 위성영상 기반 총조류 및 남조류 세포수 추정 알고리즘 개발
○ 위성영상-기상-수문연계 단기 녹조 예측 프로그램 개발
– 측정망 활용 Chl-a 및 세포수 단기예측 알고리즘 분석
– 단기예측 기간별 모델 입력변수 상대적 중요도 평가
– 합성데이터 활용 클로로필-a 단기예측 모델 및 시각화 S/W 개발</td></tr>
</table>

※ 연구개발결과 활용보고서 작성시, 지면이 부족하거나 또는 상기 문항 이외의 성과 활용 사항이 있는 경우 별지를 사용하여 작성해 주시기 바랍니다.
※ 해당사항이 없을 경우 공란으로 비워두시기 바랍니다.

2. 연구성과 활용 유형 및 주요 연구성과

(12) 연구결과의 활용

구분	기술실용화				교육 및 지도	정책활용	설계기준, 시방서, 지침에 활용	기타
	실용화 완료	실용화 추진중	실용화 보류 (중단)	선행 연구				
		○						

(13) 주요 연구성과 및 기술 개발단계

◦기 술 명 : ◦기술특성 :	◦기술의 완성도 기초, 탐색연구단계 ( ), 응용연구단계 (○), 개발연구단계 ( ) 기업화 준비단계 ( ), 상품화 완료단계 ( ) ◦기술 수명주기 기술개념 정립기 ( ), 기술 실험기 (○) 기술적용 시작기 ( ), 기술적용 성장기 ( ) 기술적용 성숙기 ( ), 기술적용 쇠퇴기 ( )

3. 경제적 효과

(14) 현장적용실적

① 공사현장 정보	공사명	공사기간	물량 (총물량)	발주기관	시공기관	R&D 참여자 역활

② 공사 현장별 적용효과

가. 현장명

구분	기 존 (A)	개 선 (B)	단위효과 (C=A-B)	현장 총물량 (D)	향상도 $\frac{A-B}{A} X100$)	적용현장 총효과 (C×D)
공사비 (백만원/㎡)[1]						
유지관리비 (백만원/㎡)[1]						
기타비용절감 (백만원/㎡)[1]						
사고율 (명/UC)						
고 용 (명/UC)						
공 기 (일/UC)						
내구성 (年)						

※ 개별 공사에 가장 적합한 척도 사용가능 ex) m^2, Km

※ 적용 현장이 여러 곳일 경우 위 서식 복사해서 사용

4. 기술적 효과

(15) 기술개발목표 달성도

구분	지표명 (단위)	개발전 국내수준	당개발사업 최종목표치	개발결과 실제달성치	현재국내 기술수준	세계 최고 기술수준
기술 성능 지표						

(16) 산업재산권 (발명특허·실용신안·의장·s/w)

구분	명칭	출원국	출원 및 등록자	출원		등록	
				출원일	출원번호	등록일	등록번호
s/w	위성영상 및 기상수문 자료를 활용한 딥러닝기반 단기 녹조예측 프로그램					'24.12.09.	C-2024-051209
s/w	앙상블기법을 활용한 위성영상 기반 녹조예측 및 결과 시각화 프로그램					'25.01.20.	C-2025-002901

(17) 건설신기술 지정

명 칭	출 원 일	고 시 일	보호기간	지정번호

(18) 기타 등록 및 지정현황(상품, 서비스 등록, KT 마크 등)

명 칭	출 원 일	고 시 일	보호기간	기 타

5. 학술적 효과

(19) 국내외 전문학술지 게재

구분	논문제목	학술지명	국명	통권, 호	년,월
SCI 학술지	Investigating Algal Sensor Utilization Methods for Three-Dimensional Algal Control Technology Evaluation	Water		16(12)	'24.06.
일반 학술지					

(20) 학술회의 발표

논문제목	학술회의 명칭	국 명	연 도 · 호
Sentinel-2 위성영상을 활용한 단기 클로로필-a 예측 기법 연구	한국습지학회		2024 정기학술대회
위성영상과 합성데이터 기반 단기 녹조예측 기법개발	한국환경영향평가학회		2024 추계
Sentinel-2 위성영상을 활용한 단기 세포수 예측 기법 연구	한국환경영향평가학회		2024 추계
위성영상과 기상 및 수문 자료를 연계한 단기 녹조예측 기법개발	한국산학기술학회		2024 추계

6. 공공적 효과

(21) 법・제도 (설계기준, 시방서, 지침) 등에 활용

구분	명칭 및 조항[1)]	시행일시	기 존 내 용	신 규 내 용
법				
규정/지침				
기준				
시방서				

(22) 정책수립에 활용

정책명	정책추진 실적	정책추진 일시	담당부처・팀	기대효과

(23) 교육 및 지도에 활용

구분	교육명	교육내용	교육대상	교육시간	교육인원	교육회수
교육훈련						
기술상담						
현장기술지도						

(24) 사회적 성과

○ 위성영상기반 공간적 녹조발생 예측기술 개발을 통한 데이터기반 물환경기술력 선도
○ 광역적 녹조발생 파악을 위한 모니터링에 필요한 예산 절감, 사전 녹조대응기술력 확보
○ 현업 물환경관리부서 녹조발생파악 등에 연구성과 활용
○ 향후 물환경분야 디지털 트윈 구축시 위성기반 공간적 녹조발생 및 예측에 활용

요 약 문

1. 연구제목

위성영상기반 공간적 녹조 예측기술 개발

2. 연구기간

2024. 2. 1. ~ 2024. 12. 31.

3. 연구목적

본 연구는 대청댐과 영주댐을 대상지로 하고 있으며 Sentinel-2 위성영상 기반으로 원격 녹조발생 농도를 추정하고 기상과 수문자료를 연계하여 단기 예측 알고리즘을 개발하고자 하였다. 이를 위해서 대청댐, 영주댐 각 댐별로 수질측정망 지점과 조류경보제 지점을 대상으로 측정망 관측일과 위성영상 관측일을 매칭하여 구름 등 기상 상황을 고려하여 활용가능한 데이터 세트를 구축하여 앙상블기법과 딥러닝 기법으로 위성영상 기반 원격 녹조발생 농도 추정, 단기예측 알고리즘을 개발하였다. 또한, 알고리즘 정확도 개선을 위하여 3차원 수질모델을 활용하여 표층 Chl-a 농도 합성데이터를 활용하여 성능을 개선시키고 최종적으로 물환경 디지털 트윈 요소기술로 활용하는 것을 목표로 하였다.

4. 연구내용

- 국내·외 녹조발생 원격 모니터링 기법 연구 사례 조사 및 분석
- 댐 저수지 클로로필-a 원격관측 알고리즘 정확도 개선을 위한 측정망 및 Sentinel-2 관측일 매칭후 분석DB 구축
- 위성영상 기반 공간적 클로로필-a 농도 및 세포수 원격 추정 알고리즘 개발
- 위성영상-기상-수문연계 단기 녹조 예측 프로그램 개발을 위한 측정망 활용 Chl-a 및 세포수 단기예측 알고리즘 분석
- 단기예측 기간별 모델 입력변수 상대적 중요도 평가
- 합성데이터 활용 클로로필-a 단기예측 모델 및 시각화 S/W 개발

5. 연구결과

○ 대청댐 및 영주댐 저수지 클로로필-a 원격관측 알고리즘 정확도를 개선하고자 하였다. 모델 예측성능, 입렵변수 설명력, 과적합 방지 등을 고려하여 앙상블

기법(랜덤포레스트, XGBoost), 딥러닝(CNN), 합성데이터, 설명가능한AI(SHAP) 기법을 선정한 후에 수질측정망 관측일과 Sentinel-2 관측일을 매칭하여 구름 등 기상자료 고려하여 총 98개 데이터세트 구축하였다. 대청댐은 59개로 0.4～42.9 mg/m^3, 영주댐은 39개로 1.1～173.4 mg/m^3 범위를 데이터세트를 구축하였다. Sentinel-2 위성영상 밴드별 반사도값, 기온, 유입량, Chl-a 입력자료를 활용하여 독립변수 및 앙상블기법 성능 비교를 통한 최적 모델 도출한 결과, XGBoost기법보다 랜덤포레스트 기법 적용시 모델 성능 높게 분석되었다. 밴드 4～7 반사도값, 밴드조합 파생변수, 기온 활용한 랜덤포레스트 적용시 모델성능 가장 좋았으며 2024년 현장조사결과 활용 모델성능 검증시, 대청댐 및 영주댐 R 0.7이상으로 측정망 기반 Chl-a 추정모델 활용성을 확인하였다.

○ 세포수 원격관측 알고리즘 구축하기 위하여 측정망과 Sentinel-2 관측일을 매칭하여 총조류 및 남조류 세포수 추정 알고리즘 개발 하였다. 밴드 1～12의 반사도값, 기온을 입력자료로 활용하여 XGBoost 기법 적용시 총조류 및 남조류 추정 모델 성능 가장 좋은 것으로 분석되었으며 Chl-a 추정 모델보다는 세포수 추정 모델의 정확도가 낮게 나타났다. 총조류 세포수에 비해 남조류 세포수 추정 모델 성능이 25% 이상 높은 것으로 분석되어 위성영상기반 세포수 추정시 총조류보다는 남조류 파악 모델 성능이 더 높았다. 측정망 지점별로 추정값과 관측값을 비교한 결과, 대청댐은 관측값보다 과소평가되고 영주댐의 경우에는 다소 과대 평가경향이 나타나 세포수 원격 추정을 위해서 댐 저수지별 개별 모델개발이 필요한 것으로 판단되었다.

○ 위성영상-기상-수문연계 단기 녹조 예측 프로그램 개발하기 위하여 첫 번째로 측정망 기반 Chl-a 및 세포수 3, 5, 7일 예측을 위한 DB를 구축하였으며 입력변수 및 적용기법별로 모델 성능을 비교하여 최적 모델을 선정하였다. Sentinel-2 밴드 1~12 반사도값, 예측기간을 고려하여 일별 평균 기온, 일별 유입량을 활용한 경우에 모델 성능이 가장 좋게 분석되었다. Chl-a 단기 예측의 경우에는 랜덤포레스트 기법의 모델 성능이 가장 높았으며, 세포수 단기 예측의 경우에는 XGBoost 기법의 모델 성능이 가장 높은 것으로 분석되었다. 세포수 예측 모델의 경우에는 위성영상 반사도값과 기온, 유입량, 수위 등의 입력자료를 활용하였을 때 모델성능이 높아졌다.

○ 단기예측 기간별 모델 입력변수 상대적 중요도 분석하기 위하여 설명가능한 AI(SHAP 기법)을 활용하여 입력변수 기여율을 분석하였다. Chl-a 3일 후 단

기 예측모델의 경우에는 위성영상 반사도값이 중요도가 높게 분석되었고, 5일 후 단기 예측모델의 경우에는 기온의 중요도가 높게 분석되었으며 7일 후 단기 예측모델의 경우에는 위성영상 반사도값, 기온, 유입량의 다양한 변수 중요도가 유사한 것으로 분석되었다. 반면에, 세포수 단기 예측의 경우에는 Chl-a 단기 예측 모델과 달리 위성영상 밴드별 반사도값을 조합한 파생변수의 중요도 크게 분석되었다.

○ 위성영상 기반으로 기상 및 수문을 연계한 단기예측 모델 정확도 개선을 위하여 3차원 모델(AEM3D)을 활용하였으며 Chl-a 등 수질 모의 재현성을 검증한 후에, 표층 Chl-a의 합성데이터를 생성하였다. 대청댐 저수지는 2017년 6~10월, 영주댐 저수지는 202년 5~9월 대상으로 모의하여 월별로 Sentinel-2 관측일을 매칭하여 3일 후 단기 예측 모델개발을 위하여 32,314개 데이터세트, 5일 후 단기 예측 모델개발을 위하여 32,301개 데이터세트, 7일 후 단기 예측 모델개발을 위하여 32,300개 데이터세트를 구축하였다. 위성영상 밴드 1~12 반사도값, 예측기간 일별 평균 기온, 예측기간 일별 댐유입량을 입력변수로 활용하였으며 XGBoost 적용시 Chl-a 단기예측(3, 5, 7일) 모델 성능이 가장 높은 것으로 분석되었다. 댐저수지별 예측모델 개발시 영주댐의 경우, 랜덤포레스트, CNN-RF 기법 정확도 높아 타댐 확장시 개별 모델 개발이 필요할 것으로 판단되었다.

○ 위성영상 기반 공간적 녹조 단기예측결과 시각화를 위한 프로그램을 개발하여 사용자가 손쉽게 활용할 수 있도록 하였다. 대화형 웹 애플리케이션을 빠르게 만들 수 있도록 돕는 오픈소스 라이브러리를 활용하여 활용하여 개발한 모델을 활용하여 구글 맵에 생성 지도를 표출하고 데이터와 시각화 지도를 저장할 수 있도록 하였다. 사용자가 원하는 댐 저수지에 대한 입력자료를 선택하면 예측결과 및 위경도별 공간적 녹조발생을 시각화 하여 지도를 표출할 수 있으며 예측 결과를 시각화 파일 뿐만 아니라 데이터로 저장할 수 있어 사용자가 데이터 분석에도 활용할 수 있도록 하였다.

목 차

제 출 문 ····· i
요 약 문 ····· vi
목 차 ····· ix
표 목 차 ····· xi
그림목차 ····· x iii

제 1 장 서 론 ····· 1

1.1 연구 배경 ····· 1
1.2 연구 내용 및 범위 ····· 1
1.3 연구 수행방법 ····· 2

제 2 장 재료 및 방법 ····· 3

2.1 연구대상지 ····· 3
2.1 연구대상지 ····· 3
2.1.1 대청댐 저수지 ····· 3
가. 일반 현황 ····· 3
나. 녹조발생 현황 ····· 4
2.1.2 영주댐 일반 현황 ····· 8
가. 일반 현황 ····· 8
나. 녹조발생 현황 ····· 8
2.2 조사 및 분석 방법 ····· 11
2.2.1 위성영상 ····· 11
2.2.2 현장조사 ····· 12
2.2.3 모델링 ····· 13
2.2.4 머신러닝 ····· 14
가. 앙상블 기법 ····· 14
나. 딥러닝 기법 ····· 16

제 3 장 결과 및 고찰 ····· 17

3.1 녹조 원격 모니터링 기법 검토 ····· 17
3.1.1 공간적 녹조발생 조사방법 ····· 17
3.1.2 위성영상 기반 녹조추정 알고리즘 및 입력변수 검토 ····· 18
3.2 녹조발생 현장조사 결과 ····· 20
3.2.1 2024년 대청댐 녹조발생 조사결과 ····· 20
3.2.2 2024년 영주댐 녹조발생 조사결과 ····· 22
3.3 위성영상 기반 녹조 원격 모니터링 알고리즘 개발 ····· 26
3.3.1 측정망 기반 클로로필-a 추정 알고리즘 개발 ····· 26
가. 입력자료 구축 결과 ····· 26
나. 앙상블 기법 적용 결과 ····· 27
3.3.2 측정망 기반 세포수 원격 모니터링 알고리즘 개발 ····· 33
가. 입력자료 구축 결과 ····· 33
나. 앙상블 기법 적용 결과 ····· 35
3.4 위성-기상-수문 연계 녹조 단기예측 알고리즘 개발 ····· 42
3.4.1 측정망 기반 단기예측 알고리즘 개발 ····· 42
가. 입력자료 구축 결과 ····· 42
나. 앙상블 기법 적용 결과 ····· 45
다. 주요 입력변수 분석결과 ····· 62
3.4.2 합성데이터를 활용한 단기예측 알고리즘 개발 ····· 64
가. AEM3D 결과를 활용한 분석 DB 구축결과 ····· 64
나. 앙상블 및 딥러닝 기법 적용 결과 ····· 74
3.5 사전 녹조관리 의사결정 프로세스 ····· 93
3.5.1 공간적 녹조발생 및 단기예측결과 시각화 S/W 개발 ····· 93
3.5.2 녹조관리 프로세스 ····· 95
3.5.3 단기 대책방안 검토 ····· 96

제 4 장 결 론 ····· 98

참 고 문 헌 ····· 101

표 목 차

표 2.1 대청댐 수질측정망 상층 Chl-a 농도 통계값 ····· 4
표 2.2 대청댐 수질측정망 상층 월별 Chl-a 농도 ····· 5
표 2.3 대청댐 조류경보제 지점별 유해남조류 세포수 통계값 ····· 6
표 2.4 대청댐 조류경보제 지점 월별 유해남조류 세포수 통계값 ····· 7
표 2.5 영주댐 수질측정망 상층 Chl-a 농도 통계값 ····· 9
표 2.6 영주댐 수질측정망 상층 Chl-a 농도 통계값 ····· 9
표 2.7 Sentinel-2 위성영상 밴드 정보 ····· 11
표 2.8 수중형 연속 조류농도 측정장비 개요 ····· 12
표 3.1 머신러닝에 사용된 원격 모니터링 사용 밴드조합 ····· 19
표 3.2 대청댐 저수지 2024년 계절별 표층 Chl-a 농도 ····· 20
표 3.3 대청댐 저수지 2024년 계절별 표층 세포수 통계값 ····· 21
표 3.4 영주댐 저수지 2024년 계절별 Chl-a 농도 ····· 23
표 3.5 영주댐 저수지 2024년 계절별 세포수 통계값 ····· 24
표 3.6 클로로필-a 원격 모니터링 알고리즘 분석 입력자료 현황 ····· 27
표 3.7 Chl-a의 원격 모니터링을 위한 머신러닝 분석 결과 ····· 28
표 3.8 Chl-a의 랜덤포레스트 기반 원격 추정값과 2024년 관측값 검증 결과30
표 3.9 대청댐 및 영주댐 관측 상층 Chl-a 관측 및 계산 결과 비교 ····· 34
표 3.10 세포수 원격 모니터링 알고리즘 분석 입력자료 현황 ····· 35
표 3.11 총조류 세포수 원격 모니터링을 위한 머신러닝 분석 결과 ····· 36
표 3.12 총남조류 세포수 원격 모니터링을 위한 머신러닝 분석 결과 ····· 36
표 3.13 총조류 세포수의 XGBoost 기반 원격 추정값과 관측값 검증 결과 ····· 38
표 3.14 총남조류 세포수의 XGBoost 기반 원격 추정값과 관측값 검증 결과 ···· 39
표 3.15 측정망 자료 기반 3일 후 Chl-a 단기예측 알고리즘 분석 입력자료 현황 ··· 42
표 3.16 측정망 자료 기반 5일 후 Chl-a 단기예측 알고리즘 분석 입력자료 현황 ··· 43
표 3.17 측정망 자료 기반 7일 후 Chl-a 단기예측 알고리즘 분석 입력자료 현황 ··· 43
표 3.18 측정망 자료 기반 3일 후 세포수 단기예측 알고리즘 분석 입력자료 현황 · 44
표 3.19 측정망 자료 기반 5일 후 세포수 단기예측 알고리즘 분석 입력자료 현황 · 44
표 3.20 측정망 자료 기반 7일 후 세포수 단기예측 알고리즘 분석 입력자료 현황 · 45
표 3.21 3일 후 Chl-a 예측 앙상블 기법 적용 결과 ····· 46

표 3.22 5일 후 Chl-a 예측 앙상블 기법 적용 결과 ····· 48
표 3.23 7일 후 Chl-a 예측 앙상블 기법 적용 결과 ····· 49
표 3.24 3일 후 총조류 및 남조류 세포수 예측 앙상블 기법 적용 결과 ····· 52
표 3.25 5일 후 총조류 및 남조류 세포수 예측 앙상블 기법 적용 결과 ····· 55
표 3.26 7일 후 총조류 및 남조류 세포수 예측 앙상블 기법 적용 결과 ····· 57
표 3.27 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 7일 후 원격 추정값과 관측값 검증 결과 ····· 59
표 3.28 Chl-a 단기 예측에 사용된 입력변수의 SHAP 분석 결과 ····· 62
표 3.29 총조류세포수 단기 예측에 사용된 입력변수의 SHAP 분석 결과 ····· 63
표 3.30 대청댐 및 영주댐 AEM3D 모형에 적용된 수질계수 ····· 68
표 3.31 2017년 대청댐 머신러닝 입력자료 기온, 유입량 및 Chl-a 범위 ····· 69
표 3.32 2021년 영주댐 머신러닝 입력자료 기온, 유입량 및 Chl-a 범위 ····· 70
표 3.33 단기 (3~7일) 예측 알고리즘 개발을 위한 분석DB 구축내용 ····· 71
표 3.34 단기 (3~7일) 예측 알고리즘 개발을 합성데이터 입력자료 현황 ····· 71
표 3.35 2017년 대청댐 합성데이터(AEM3D 모의결과) 입력자료 ····· 72
표 3.36 2021년 영주댐 합성데이터(AEM3D 모의결과) 입력자료 ····· 72
표 3.37 대청댐 및 영주댐 AEM3D 모의값 기반 Chl-a 단기예측 모델 통계값 76
표 3.38 대청댐 AEM3D 모의값 기반 Chl-a 단기예측 모델 통계값 ····· 76
표 3.39 영주댐 AEM3D 모의값 기반 Chl-a 단기예측 모델 통계값 ····· 76
표 3.40 AEM3D 모의값 기반 Chl-a 단기예측 2024년 추정값과 관측값(XGBoost) ··· 86
표 3.41 위성영상-기상-수문 연계 단기예측을 위한 개발모델 현황 ····· 95
표 3.42 주요 녹조대응 기술별 원리 및 효과 ····· 97

그 림 목 차

그림 2.1 대청댐 저수지 및 측정망 위치도 ····· 3
그림 2.2 대청댐 수질측정망 상층 Chl-a 농도변화 ····· 4
그림 2.3 대청댐 저수지 Chl-a 계절별 공간분포('20~'23년 평균) ····· 5
그림 2.4 대청댐 조류경보제 지점 유해남조류 세포수 변화 ····· 6
그림 2.5 대청댐 저수지 유해남조류 계절별 공간분포('20~'23년 평균) ····· 7
그림 2.6 영주댐 저수지 및 측정망 위치도 ····· 8
그림 2.7 영주댐 수질측정망 상층 Chl-a 농도변화 ····· 9
그림 2.8 영주댐 저수지 Chl-a 계절별 공간분포('20~'23년 평균) ····· 10
그림 2.9 대청댐 및 영주댐 저수지 현장조사 지점도 ····· 12
그림 2.10 대청댐 AEM3D 격자 구성도 ····· 13
그림 2.11 영주댐 AEM3D 격자 구성도 ····· 14
그림 2.12 랜덤포레스트 알고리즘 구조 ····· 15
그림 2.13 CNN 모델 구조 ····· 16
그림 3.1 대청댐 저수지 및 측정망 위치도 ····· 17
그림 3.2 대청댐 조사지점별 2024년 Chl-a 변화 ····· 20
그림 3.3 대청댐 2024년 계절별 조류강별 비율 ····· 21
그림 3.4 영주댐 조사지점별 2024년 Chl-a 변화 ····· 23
그림 3.5 영주댐 2024년 계절별 조류강별 비율 ····· 24
그림 3.6 Sentinel-2 반사도값과 수질측정망 매칭 ····· 26
그림 3.7 Sentinel-2 반사도값과 측정망 Chl-a 매칭 DB결과 ····· 27
그림 3.8 Chl-a 원격 추정 Case6 학습 및 검증결과 ····· 29
그림 3.9 대청댐 Chl-a의 랜덤포레스트 기반 2024년 원격 추정농도 시각화 결과 ····· 31
그림 3.10 영주댐 Chl-a의 랜덤포레스트 기반 2024년 원격 추정농도 시각화 결과 ····· 32
그림 3.11 Sentinel-2 반사도값과 조류세포수 측정망 매칭 ····· 33
그림 3.12 대청댐 및 영주댐 상층 및 평균 Chl-a 비교 ····· 34
그림 3.13 Sentinel-2 반사도값과 측정망 세포수 매칭 DB결과 ····· 34
그림 3.14 총조류 세포수 XGBoost(Case2) 학습 및 테스트 결과 ····· 37
그림 3.15 남조류 세포수 XGBoost(Case2) 학습 및 테스트 결과 ····· 37
그림 3.16 대청댐 총조류 및 총남조류 세포수의 XGBoost 기반 원격 추정농도 시각화 결과 ····· 40

그림 3.17 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 원격 추정농도 시각화 결과 ····· 41
그림 3.18 Chl-a 3일 후 예측을 위한 Case4 앙상블기법 Training 및 Test 결과 ····· 47
그림 3.19 영주댐 Chl-a의 랜덤포레스트 기반 2024년 3일 후 원격 추정농도 시각화 결과 ····· 47
그림 3.20 Chl-a 5일 후 예측을 위한 Case4 앙상블기법 Training 및 Test 결과 ····· 48
그림 3.21 영주댐 Chl-a의 랜덤포레스트 기반 2024년 5일 후 원격 추정농도 시각화 결과 ····· 49
그림 3.22 Chl-a 7일 후 예측을 위한 Case4 앙상블기법 Training 및 Test 결과 ····· 50
그림 3.23 영주댐 Chl-a의 랜덤포레스트 기반 2024년 7일 후 원격 추정농도 시각화 결과 ····· 50
그림 3.24 3일 후 총조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과 ····· 53
그림 3.25 3일 후 남조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과 ····· 53
그림 3.26 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 3일 후 원격 추정농도 시각화 결과 ····· 54
그림 3.27 5일 후 총조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과 ····· 56
그림 3.28 5일 후 남조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과 ····· 56
그림 3.29 7일 후 총조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과 ····· 58
그림 3.30 7일 후 남조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과 ····· 58
그림 3.31 위성영상-기상-수문 연계 Chl-a 단기 예측 앙상블 알고리즘 및 S/W등록증 ····· 60
그림 3.32 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 7일 후 원격 추정농도 시각화 결과 ····· 61
그림 3.33 대청댐2(댐앞) 지점 2017년 6~10월 수질 보정결과 ····· 64
그림 3.34 대청댐3 지점 2017년 6~10월 수질 보정결과 ····· 65
그림 3.35 대청댐5 지점 2017년 6~10월 수질 보정결과 ····· 66
그림 3.36 영주댐1(댐앞) 지점 2021년 5~9월 수질 보정결과 ····· 67
그림 3.37 2017년 대청댐 머신러닝 입력자료 공간적 Chl-a 분포도 ····· 69
그림 3.38 2021년 영주댐 머신러닝 입력자료 공간적 Chl-a 분포도 ····· 70
그림 3.39 Sentinel-2 반사도값과 측정망 AEM3D 모의결과 매칭(3일후 예측) ····· 73
그림 3.40 Sentinel-2 반사도값과 측정망 AEM3D 모의결과 매칭(5일후 예측) ····· 73
그림 3.41 Sentinel-2 반사도값과 측정망 AEM3D 모의결과 매칭(7일후 예측) ····· 73
그림 3.42 위성영상-기상-수문 연계 Chl-a 단기 예측 CNN-RF 파이썬 모듈 및 함수 75
그림 3.43 위성영상-기상-수문 연계 Chl-a 단기 예측 CNN-RF S/W등록증 ····· 75
그림 3.44 대청·영주댐 AEM3D 모의값 기반 Chl-a 단기예측(3일 후) 알고리즘 학습 및 검증결과 ····· 77
그림 3.45 대청·영주댐 AEM3D 모의값 기반 Chl-a 단기예측(5일 후) 알고리즘 학습 및 검증결과 ····· 78

그림 3.46 대청·영주댐 AEM3D 모의값 기반 Chl-a 단기예측(7일 후) 알고리즘 학습 및 검증결과 ····· 79
그림 3.47 대청댐 AEM3D 모의값 기반 Chl-a 단기예측(3일 후) 알고리즘 학습 및 검증결과 ····· 80
그림 3.48 대청댐 AEM3D 모의값 기반 Chl-a 단기예측(5일 후) 알고리즘 학습 및 검증결과 ····· 81
그림 3.49 대청댐 AEM3D 모의값 기반 Chl-a 단기예측(7일 후) 알고리즘 학습 및 검증결과 ····· 82
그림 3.50 영주댐 AEM3D 모의값 기반 Chl-a 단기예측(3일 후) 알고리즘 학습 및 검증결과 ····· 83
그림 3.51 영주댐 AEM3D 모의값 기반 Chl-a 단기예측(5일 후) 알고리즘 학습 및 검증결과 ····· 84
그림 3.52 영주댐 AEM3D 모의값 기반 Chl-a 단기예측(7일 후) 알고리즘 학습 및 검증결과 ····· 85
그림 3.53 대청댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(RandomForest) ····· 87
그림 3.54 대청댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(XGBoost) ····· 88
그림 3.55 대청댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(CNN-RF) ····· 89
그림 3.56 영주댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(RandomForest) ····· 90
그림 3.57 영주댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(XGBoost) ····· 91
그림 3.58 영주댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(CNN-RF) ····· 92
그림 3.59 위성영상-기상-수문 연계 Chl-a 공간적 단기 예측 시각화코드 ····· 93
그림 3.60 위성영상-기상-수문 연계 Chl-a 공간적 단기 예측 시각화 S/W 화면 ····· 94
그림 3.61 공간적 단기 예측 시각화 S/W를 활용한 녹조관리 프로세스 ····· 96

제 1 장 서 론

1.1 연구 배경

최근 기후 변화와 산업화의 진행으로 인해 수질 오염이 세계적인 환경 문제로 부각되고 있다. 특히, 담수에서 발생하는 녹조(Algal Bloom)는 수질 뿐만 아니라 수생태계에도 영향을 미칠 뿐만 아니라 인간의 건강에도 영향을 줄 수 있어 측정망 지점과 우심지역을 대상으로 지속적으로 모니터링하여 관리하고 있다. 녹조는 주로 여름철 높은 기온과 강수량, 영양염류의 농도가 높아지면서 발생하고 있으며 정수과정에서의 추가적인 비용을 초래하는 등 사회경제적으로도 영향을 주고 있다. 우리나라 댐 저수지에서는 강도 차이가 있지만 매년 녹조가 발생하고 있으며 특히, 대청댐과 영주댐과 같은 주요 댐에서는 매년 녹조 현상이 발생하고 있으며 수질관리와 상수원 보호 측면에서 신속한 녹조 모니터링은 필수적이라 할 수 있다. 기존의 녹조 발생 모니터링 방법은 현장조사와 실험실 분석을 기반으로 하지만, 시간적·공간적 제약이 크고, 대규모 저수지에서의 실시간 모니터링에는 한계가 있다. 최근에는 위성영상, 수문·기상 데이터, 그리고 머신러닝 기법을 활용한 모니터링 및 예측 기술이 발전하면서, 이러한 한계를 극복할 수 있는 가능성이 제시되고 있다. 특히, 위성 영상은 넓은 영역을 빠르고 저렴하게 모니터링할 수 있는 장점이 있어, 녹조 발생의 실시간 모니터링 및 예측에 활용될 수 있다. 녹조 발생을 모니터링하고 예측하는 방법에 대한 연구는 최근 몇 년간 활발히 이루어지고 있으며 특히, 위성영상을 활용한 녹조 감지 기술은 다양한 형태로 발전하고 있다. NASA의 MODIS(Monitoring Ocean and Vegetation) 센서를 이용한 수질 모니터링 연구를 진행했는데, MODIS는 전 세계 해양 및 담수에서의 녹조 발생을 감지하는 데 사용되며, 고해상도 위성 이미지를 통해 실시간으로 녹조 분포를 추적할 수 있다. 또한, Sentinel-2 위성은 더 높은 공간 해상도를 제공하여, 소규모 저수지나 호수에서도 세밀한 녹조 분석을 가능하게 한다. 국내에서도 위성 영상을 활용한 녹조 모니터링 연구가 활발히 진행되고 있으며 Chl-a 농도를 추정하고 이를 통해 녹조의 발생 시기와 강도를 예측하려는 시도가 이어지고 있다.

1.2 연구 내용 및 범위

본 연구는 대청댐과 영주댐을 대상지로 하고 있으며 Sentinel-2 위성영상 기반으로 원격 녹조발생 농도를 추정하고 기상과 수문자료를 연계하여 단기 예측 알고리즘을 개발하고자 하였다. 이를 위해서 각 댐별로 수질측정망 지점과 조류경보제 지점을 대상으로 측정망 관측일과 위성영상 관측일을 매칭하여 구름 등 기상 상황을 고려하여 활용가능한 데이터 세트를 구축하여 앙상블기법과 딥러닝 기법으로 위성영상 기반 원격 녹조발생 농도 추정, 단기예측 알고리즘을 개발하였다. 또한 모델

정확도 개선을 위하여 3차원 수질모델을 활용하여 표층 Chl-a 농도 합성데이터를 생성하여 모델 성능을 개선시키고 최종적으로 물환경 디지털 트윈 요소기술로 활용하는 것을 목표로 하였다. 연구의 주요 내용은 아래와 같다.

- 국내·외 녹조발생 원격 모니터링 기법 연구 사례 조사 및 분석
- 댐 저수지 클로로필-a 원격관측 알고리즘 정확도 개선을 위한 측정망 및 Sentinel-2 관측일 매칭후 분석DB 구축
- 위성영상 기반 공간적 클로로필-a 농도 및 세포수 원격 추정 알고리즘 개발
- 위성영상-기상-수문연계 단기 녹조 예측 프로그램 개발을 위한 측정망 활용 Chl-a 및 세포수 단기예측 알고리즘 분석
- 단기예측 기간별 모델 입력변수 상대적 중요도 평가
- 합성데이터 활용 클로로필-a 단기예측 모델 및 시각화 S/W 개발

1.3 연구 수행방법

연구 수행은 위성영상 등 원격 녹조발생 모니터링 기법 연구 사례를 조사 및 분석하여 물환경 디지털 트윈에 필요한 요소 기술 도출하고자 하였다. 신속한 공간적 녹조발생 모니터링에 위성영상 활용성을 활용하였으며 단기 예측 정보를 제공하는 기술을 개발함으로써 물환경분야 디지털 트윈에 활용 될 수 있도록 연구를 진행하였다. 환경부 수질측정망 자료를 활용하고, 현장 조사를 추가로 시행하여 공간적 자료를 확보하였으며 합성데이터를 생성하여 개발 모델의 정확도를 개선하여 저수지 내 공간적 녹조발생을 정확하게 예측하고자 하였다. 이를 위하여 첫째, GIS(Geological Information System)를 활용하여 위성영상을 분석하여 밴드별 반사도값을 추축하여 측정망 지점과 매칭하였다. 둘째, 파이썬을 활용하여 위성영상 반사도값, 기상 및 수문자료를 입력자료로 활용하여 머신러닝 기법으로 Chl-a 및 세포수 추정, 예측 알고리즘을 개발하였다. 셋째, 현장조사를 통해 위성영상으로 확인된 녹조 발생 지역에서 실제로 발생한 녹조의 특성을 확인하고, 위성영상 기반 원격추정, 예측 농도값의 정확도를 검증하였다. 넷째, 3차원모델링을 활용하여 합성데이터를 생성하여 녹조 발생 단기예측 모델 정확도 개선하고자 하였으며, 마지막으로 개발 모델을 활용하여 공간적 녹조발생 정보를 시각화하는 소프트웨어를 개발하고자 함으로써 물환경 분야 디지털 트윈에 활용하는데 기여하고자 하였다.실시간으로 녹조를 관리할 수 있는 시스템을 구축하여, 환경 관리에 실질적으로 기여하고자 하였다.

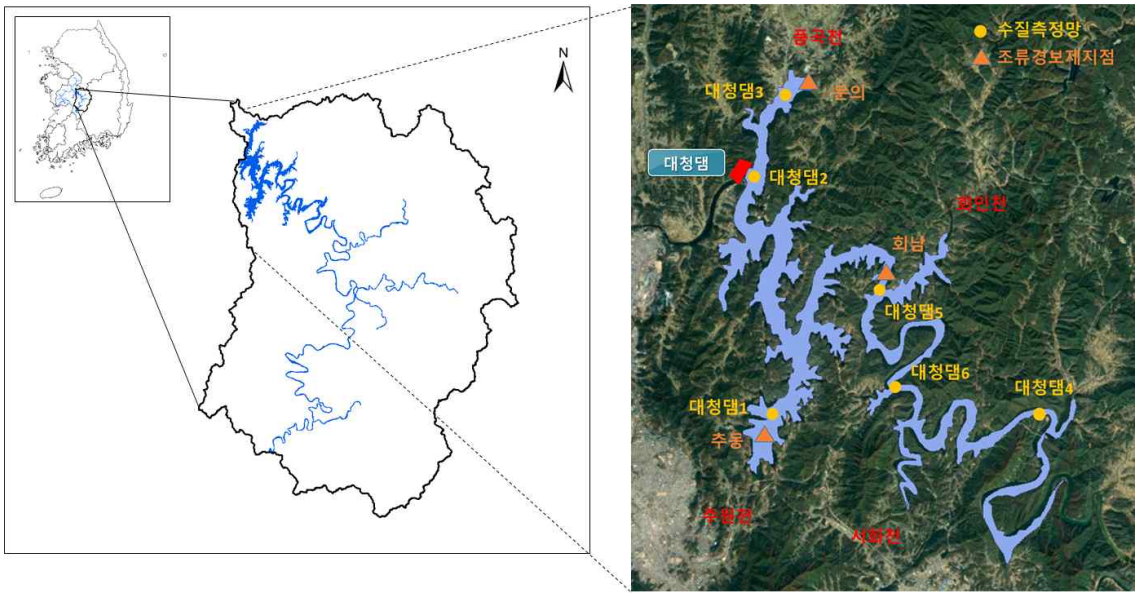
제 2 장 재료 및 방법

2.1 연구대상지

2.1.1 대청댐 저수지

가. 일반 현황

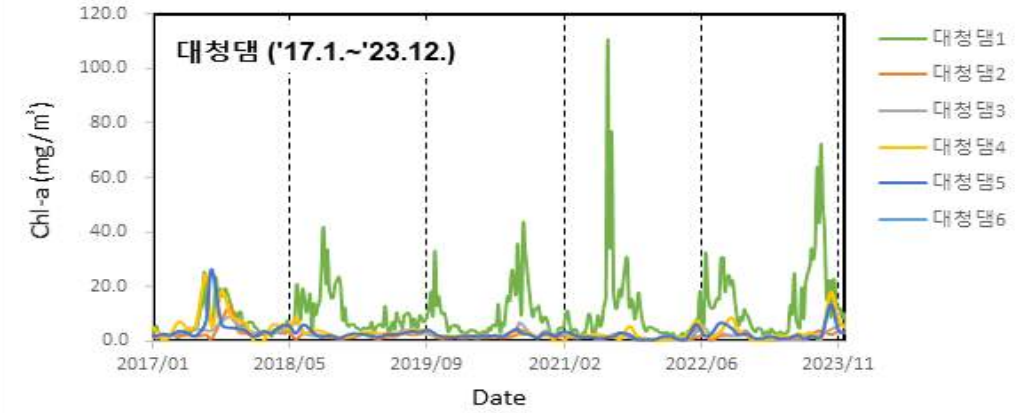
대청댐은 금강수계 중류에 위치하고 있으며 하류지역 홍수조절, 용수공급 및 수력발전을 목적으로 1981년에 준공되었다. 유역면적은 상류 용담댐 유역을 제외하고 3,204.0 km^2으로 대전광역시 대덕구 및 동구, 충청북도 청원군, 보은군, 옥천군 및 영동군, 충청남도 금산군, 전북 무주군 및 진안군, 경상북도 상주시 일부 지역이 포함된다. 대청댐 유역 전체 배출부하량은 2022년 전국오염원조사 결과 기준으로 BOD 18.441.2 kg/일, TN 16,477.9 kg/일, TP 1,188.2 kg/일이며 비점배출부하량 비율이 BOD, TN, TP 각각 86.2%, 91.6%, 87.8%을 차지한다. 저수지 표면적은 72.8 km^2로서 저수면적 대비 유역면적의 비는 44.0이다. 총 저수용량은 14억 9천만 m^3이며, 유효저수량은 7억 9천만 m^3이다. 대청호내 취수를 위한 수리구조물은 추동과 문의에 위치한 취수탑(EL. 57.0 m) 2개와 댐의 발전방류구(EL. 52.0 m)가 있으며, 그리고 홍수를 조절하기 위한 본댐 여수로(EL. 64.5 m)와 비상 여수로(EL. 65.0 m)가 있다(Kwater, 2019).



<그림 2.1> 대청댐 저수지 및 측정망 위치도

나. 녹조발생 현황

대청댐은 6개 호소 수질측정망을 운영중이며 Sentinel-2 위성영상을 활용할 수 있는 2017년도 이후부터 최근 7년간(2017~2023년) 지점별 상층의 Chl-a 농도 변화를 분석한 결과, 대청댐1(추동) 지점의 Chl-a가 연평균 10.8 mg/m^3 (7.7~14.8 mg/m^3), 여름철(7~9월) 23.2 mg/m^3 (7.5~36.6 mg/m^3)의 범위로 가장 높게 나타났다. 월별 Chl-a 평균 농도는 지점별로 차이는 있으나 회남 지점부터 상류 지점은 8월에 가장 높고, 회남 지점 하류 부터는 9월에 가장 높은 것으로 관측되었다. 대청댐1(추동) 지점의 9월 평균 농도가 24.0 mg/m^3으로 가장 높은 것으로 관측되었다(환경부 물환경정보시스템).



<그림 2.2> 대청댐 수질측정망 상층 Chl-a 농도변화

<표 2.1> 대청댐 수질측정망 상층 Chl-a 농도 통계값

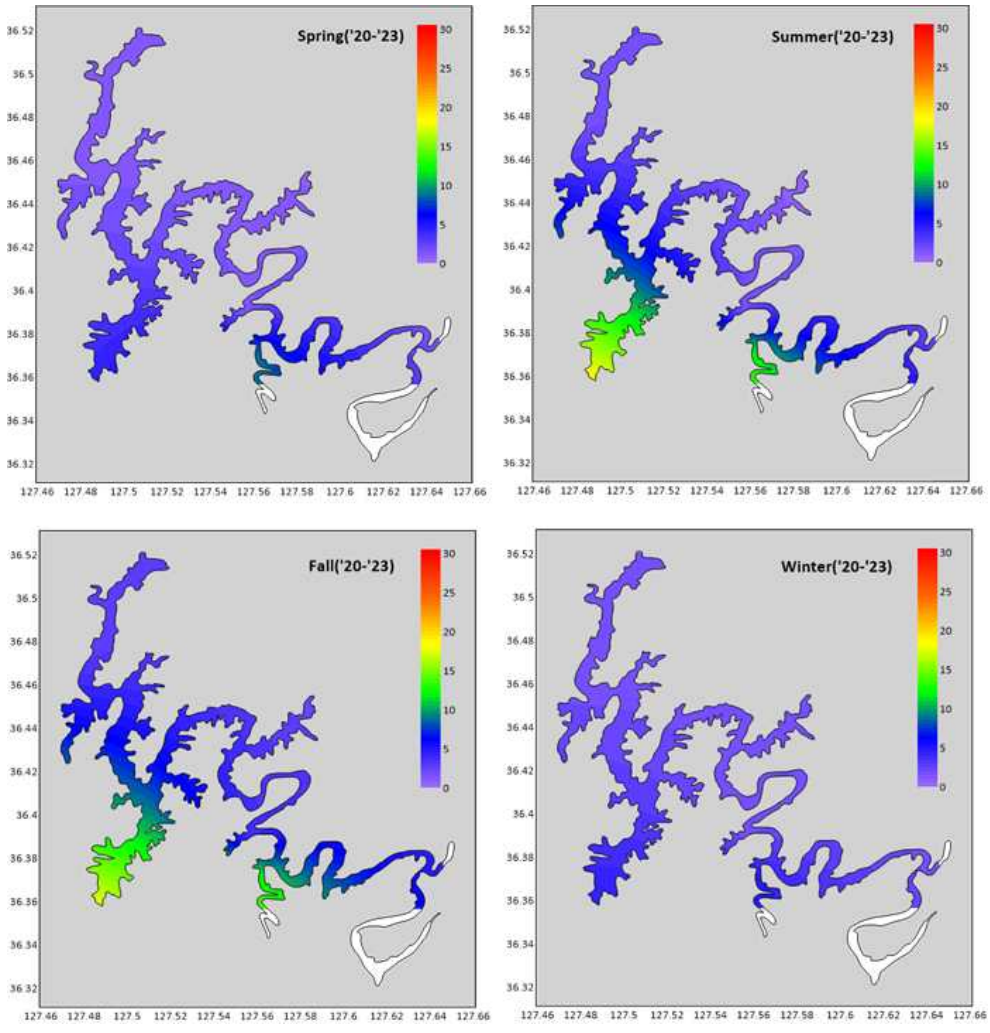
년도	연평균/여름철	Chl-a (mg/m^3)					
		대청댐1 (추동)	대청댐2 (댐앞)	대청댐3 (문의)	대청댐4	대청댐5 (회남)	대청댐6
2017	연평균	7.6	3.4	4.2	8.7	5.6	6.4
	여름철(7-9월)	15.2	3.7	5.0	16.1	13.3	14.4
2018	연평균	10.9	2.1	3.0	4.0	3.0	3.8
	여름철(7-9월)	16.9	2.4	2.3	3.6	3.5	5.9
2019	연평균	7.7	1.9	2.4	3.0	2.5	2.2
	여름철(7-9월)	7.5	2.7	3.6	3.7	3.1	2.5
2020	연평균	9.4	1.8	2.5	2.2	2.1	2.1
	여름철(7-9월)	21.9	2.5	4.2	2.6	3.0	2.6
2021	연평균	12.7	1.4	1.6	2.1	1.7	1.6
	여름철(7-9월)	31.3	1.7	2.1	1.4	1.9	2.1
2022	연평균	9.4	1.5	2.0	3.1	2.6	2.2
	여름철(7-9월)	18.8	1.4	3.1	2.5	3.7	3.1
2023	연평균	14.8	1.7	2.1	4.3	2.7	3.2
	여름철(7-9월)	36.6	2.4	1.5	2.1	1.3	2.6
평균	연평균	10.8	1.6	2.1	2.9	2.3	2.3
	여름철(7-9월)	23.2	2.1	2.9	2.4	2.6	2.6

※ 최근 7년(2017~2023년) 평균값

<표 2.2> 대청댐 수질측정망 상층 월별 Chl-a 농도

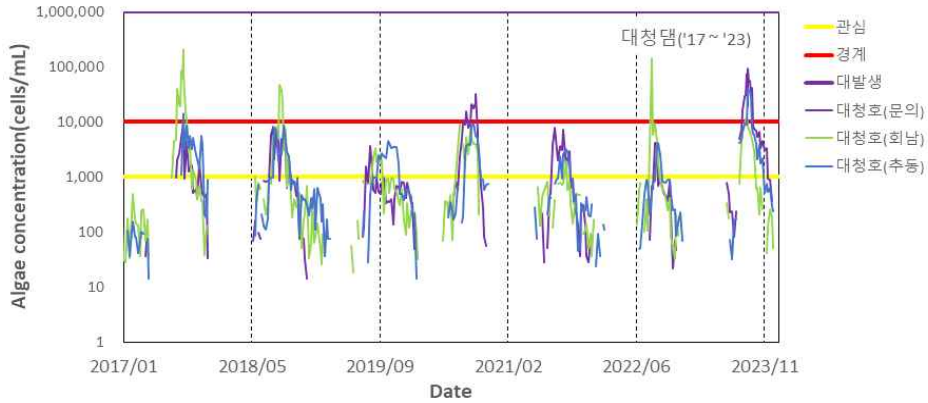
구분	Chl-a (mg/m^3)					
	대청댐1 (추동)	대청댐2 (댐앞)	대청댐3 (문의)	대청댐4	대청댐5 (회남)	대청댐6
1월	4.1	1.2	1.6	2.3	1.5	1.4
2월	3.5	1.7	1.8	2.5	2.2	2.2
3월	3.2	1.6	1.6	2.4	2.1	2.2
4월	3.3	1.4	1.6	3.3	2.0	2.5
5월	5.5	1.7	2.5	2.7	2.2	2.7
6월	8.5	1.3	3.0	4.5	2.6	1.6
7월	18.4	1.9	2.8	5.7	3.0	4.9
8월	20.1	1.8	2.8	3.3	6.2	5.4
9월	24.0	3.5	3.8	4.7	3.5	3.8
10월	16.3	3.6	3.4	7.3	4.8	5.2
11월	11.1	2.0	2.7	3.6	2.1	2.3
12월	6.3	2.1	2.9	2.7	2.4	2.4

※ 최근 7년(2017~2023년) 평균값



<그림 2.3> 대청댐 저수지 Chl-a 계절별 공간분포('20~'23년 평균)

대청댐 호내 3개 조류경보제 지점을 운영중이며 Sentinel-2 위성영상을 활용할 수 있는 2017년도 이후부터 최근 7년간(2017~2023년) 유해남조류 세포수 관측자료를 분석한 결과, 회남 지점의 유해남조류 세포수가 연평균 2,858 cells/mL (290~9,392 cells/mL), 여름철(7~9월) 8,079 cells/mL (898~23,986 cells/mL)의 범위로 가장 높게 나타났다. 월별 유해남조류 세포수 월별 평균값은 회남, 추동 지점은 8월에 가장 높은 값이 관측되었고, 문의 지점은 9월에 가장 높은 것으로 관측되었다. 최근 7년간 유해남조류 세포수 최고 값은 회남 지점에서 206,126 cells/mL였으며 문의 지점에서 최대값은 94,208 cells/mL, 추동 지점 최대값은 38,812 cells/mL로 관측되었다(환경부 물환경정보시스템).



<그림 2.4> 대청댐 조류경보제 지점 유해남조류 세포수 변화

<표 2.3> 대청댐 조류경보제 지점별 유해남조류 세포수 통계값

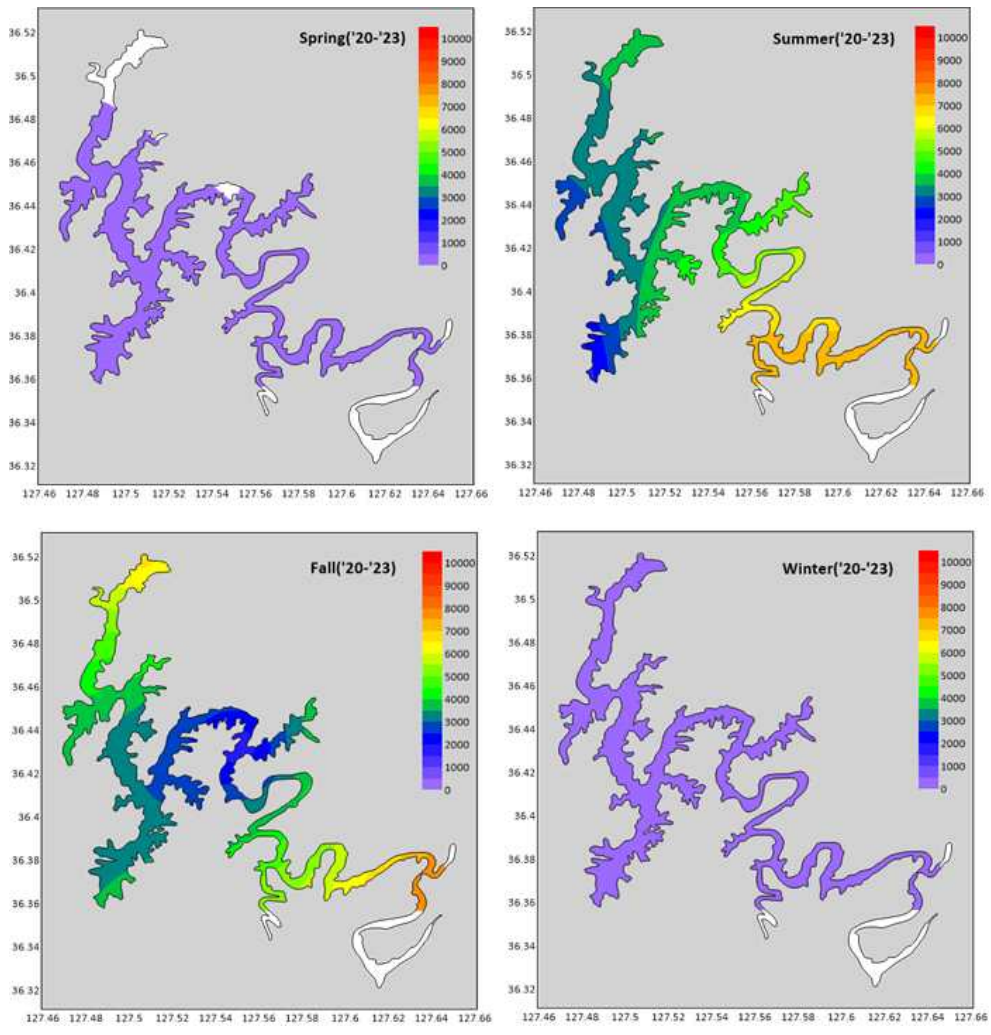
년도	연평균/여름철	유해남조류 세포수 (cells/mL)		
		문의	회남	추동
2017	연평균	694	10,532	1,194
	여름철(7-9월)	2,360	26,382	3,275
2018	연평균	1,115	3,196	1,046
	여름철(7-9월)	3,740	9,060	3,132
2019	연평균	365	501	851
	여름철(7-9월)	898	1,114	624
2020	연평균	3,155	1,020	1,007
	여름철(7-9월)	7,527	3,265	2,609
2021	연평균	828	258	443
	여름철(7-9월)	2,570	608	1,202
2022	연평균	290	3,276	418
	여름철(7-9월)	958	11,427	1,219
2023	연평균	9,392	1,222	3,373
	여름철(7-9월)	23,986	4,696	9,570
평균	연평균	2,263	2,858	1,190
	여름철(7-9월)	6,006	8,079	3,090

※ 최근 7년(2017~2023년) 평균값

<표 2.4> 대청댐 조류경보제 지점 월별 유해남조류 세포수 통계값

구분	유해남조류 세포수 (cells/mL)		
	문의	회남	추동
1월	74	78	158
2월	22	65	68
3월	1	25	21
4월	5	7	3
5월	11	54	14
6월	97	190	64
7월	673	1,857	353
8월	7,815	16,300	2,809
9월	9,529	6,079	6,109
10월	3,007	775	2,192
11월	491	243	1,021
12월	145	130	326

※ 최근 7년(2017~2023년) 평균값

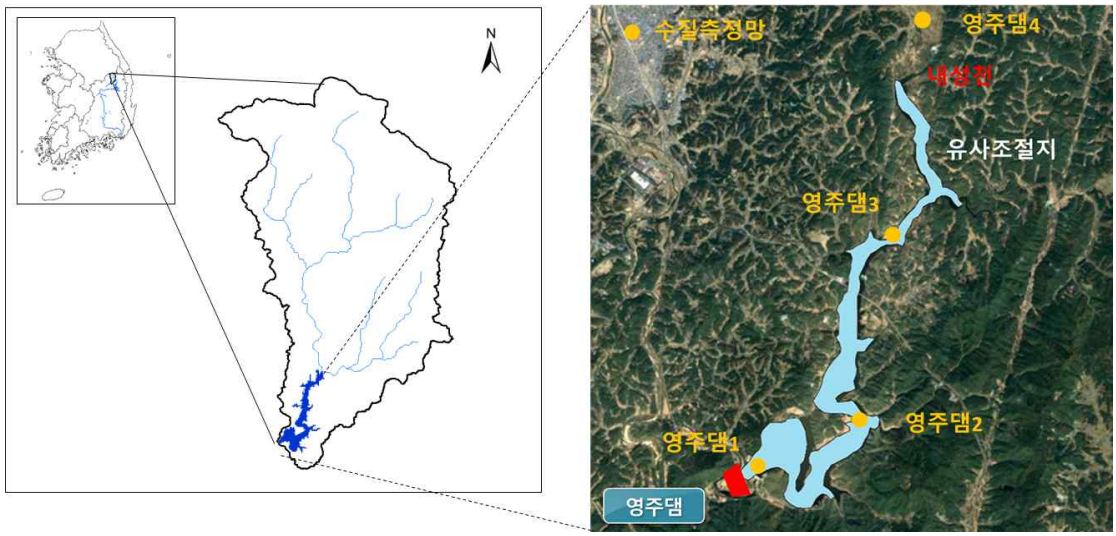


<그림 2.5> 대청댐 저수지 유해남조류 계절별 공간분포('20~'23년 평균)

2.1.2 영주댐 일반 현황

가. 일반 현황

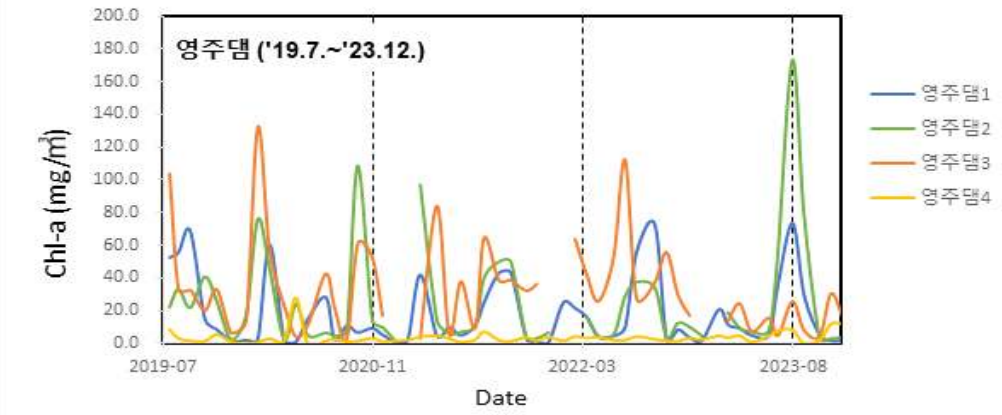
영주댐은 낙동강의 수질개선, 하류하천의 홍수피해 경감 등을 목적으로 2009년 12월에 착공하여 2016년 12월에 낙동강 제1지류인 내성천 상류에 조성된 다목적댐이다. 유역면적은 500 km2으로 내성천 유역면적 대비 27.6%를 차지하며, 유역 내에는 3개 시군(영주시, 봉화군, 안동시), 10개 읍면(이산면, 평은면, 문수면, 상운면, 녹전면, 봉성면, 명호면, 봉화읍, 부석면, 물야면)이 포함되어 있으며, 가축사육밀도가 높은 지역으로 특히 우사가 유역 전반에 걸쳐 분포하고 있다. 영주댐 유역 전체 배출부하량은 2022년 전국오염원조사 결과 기준으로 BOD 5,078.6 kg/일, TN 4,080.8 kg/일, TP 298.4 kg/일이며 비점배출부하량 비율이 BOD, TN, TP 각각 91.8%, 95.4%, 91.6%을 차지한다. 총저수량은 181.1백만m^3이며 연평균 유입량은 316.6백만m^3으로 수리학적 체류시간은 0.57년이다. 영주댐 상류 약 14.4 km 지점에는 유사조절지(sediment control dam)를 설치하여 댐 내부로 유입되는 유사를 사전에 조절할 수 있도록 계획되었다(K-water, 2022).



<그림 2.6> 영주댐 저수지 및 측정망 위치도

나. 녹조발생 현황

영주댐은 4개 수질측정망을 운영중이며 Sentinel-2 위성영상을 활용할 수 있는 2020년도 이후부터 최근 4년간(2020~2023년) 지점별 상층의 Chl-a 농도 변화를 분석한 결과, 연평균 Chl-a 농도는 영주댐 3 지점에서 33.6 mg/m^3 (15.4~46.7 mg/m^3)으로 가장 높았으며, 여름철(7~9월) 평균 농도는 영주댐 2 지점에서 43.7 mg/m^3 (6.2~101.8 mg/m^3)으로 가장 높게 관측되었다. 월별 Chl-a 평균 농도는 상류 지점의 겨울철 농도가 하류보다 높았으며, 지점별로 차이는 있으나 8월에 Chl-a 농도가 가장 높은 것으로 관측되었으며, 댐앞은 9월에 가장 높았다(환경부 물환경정보시스템).



<그림 2.7> 영주댐 수질측정망 상층 Chl-a 농도변화

<표 2.5> 영주댐 수질측정망 상층 Chl-a 농도 통계값

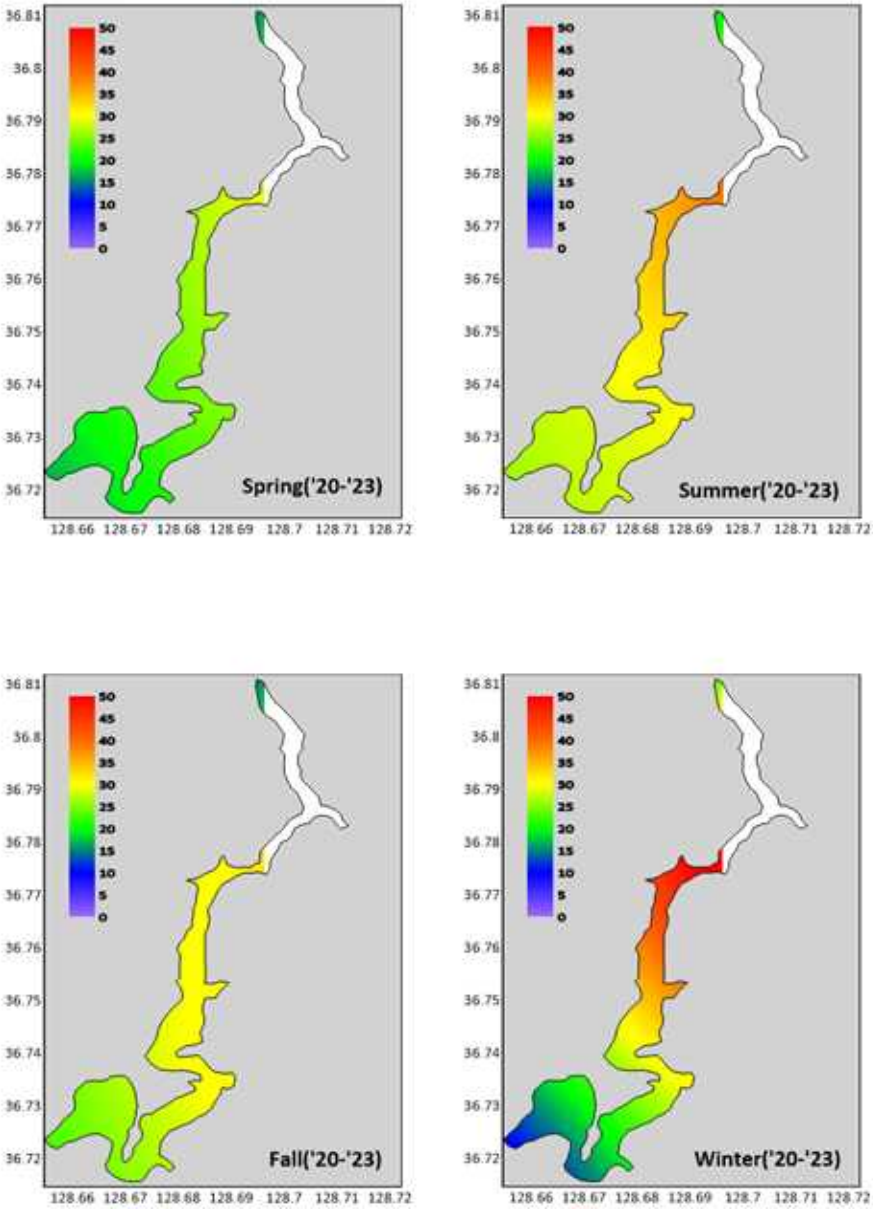
년도	연평균/여름철	Chl-a (mg/m³)			
		영주댐1(댐앞)	영주댐2	영주댐3	영주댐4
2020	연평균	12.2	26.8	36.9	4.0
	여름철(7-9월)	13.8	6.2	22.8	2.1
2021	연평균	15.8	25.7	35.4	3.2
	여름철(7-9월)	26.3	33.5	37.8	4.2
2022	연평균	18.7	15.8	46.7	3.2
	여름철(7-9월)	46.1	33.4	59.3	3.3
2023	연평균	16.6	33.0	15.4	5.6
	여름철(7-9월)	45.9	101.8	13.1	5.7
평균	연평균	15.8	25.3	33.6	4.0
	여름철(7-9월)	33.0	43.7	33.3	3.8

※ 최근 4년(2020~2023년) 평균값

<표 2.6> 영주댐 수질측정망 상층 Chl-a 농도 통계값

구분	Chl-a (mg/m³)			
	영주댐1(댐앞)	영주댐2	영주댐3	영주댐4
1월	21.0	25.1	42.6	3.8
2월	39.3	63.9	35.1	5.9
3월	38.9	42.2	22.0	1.8
4월	14.3	41.3	40.4	2.0
5월	5.6	8.3	36.6	5.4
6월	3.1	6.7	22.0	4.9
7월	1.4	7.3	13.9	2.3
8월	12.6	75.9	132.4	2.6
9월	33.8	53.9	34.7	4.0
10월	8.0	10.6	43.7	4.0
11월	5.1	10.2	11.1	9.2
12월	7.4	6.3	29.8	2.2

※ 최근 4년(2020~2023년) 평균값



<그림 2.8> 영주댐 저수지 Chl-a 계절별 공간분포('20~'23년 평균)

2.2 조사 및 분석 방법

2.2.1 위성영상

Sentinel-2 위성은 유럽우주국(European Space Agency, ESA)에서 2015년에 발사된 2A와 2017년에 발사 된 2B로 구성된 쌍둥이 위성으로서 정밀한 해상도와 다양한 분광 정보를 제공하고 있다. 두 쌍둥이 위성(Sentinel-2A, Sentinel-2B)이 10일의 재방문 주기를 가지고 임무를 수행하고 있으며, 다중분광 장비(MultiSpectral Instrugment, MSI)로 가시, 적외채널 등 13개의 밴드를 동시 촬영하고 있다(K-water, 2020; K-water, 2022; Yi et al., 2023). 무료로 제공되는 다른 광학 위성영상보다 높은 공간 해상도와 다양한 다중분광 밴드를 제공한다. Sentinel-2 위성의 MSI센서는 채널에 따라 10 m에서 60 m에 이르는 다양한 고해상도 이미지를 제공하며, 가시광선(visible, VIS), 근적외(nearinfrared) 및 단파적외(short-wave infrared) 파장 영역까지 13개의 파장 영역(442.3~2202.4nm)의 영상을 제공한다(EU, Copernicus Data Space Ecosystem). Sentinel-2는 원시 이미지 데이터에서 방사형 및 기하학적으로 보정된 레벨 1C 대기 상부(TOA) 데이터와 레벨 1C 제품의 대기 보정 표면 반사 제품인 레벨 2A 하부(BoA) 데이터를 제공하고 있으며, 코페르니쿠스 오픈 액세스 허브에서 위성영상을 취득할 수 있다. 이 때, 여기서 Sentinel 2 MSI 데이터의 값을 활용하려면 처리 기준선(PB)을 확인해야 하는데, PB의 '04.00' 이전에는 BoA 반사율 값을 10,000으로 나누어야 하며, 2022년 1월 25일 이후에는 BoA 반사율이 1,000씩 변경되었기 때문에 이를 고려하여 1,000을 빼고 10,000으로 나눈 값으로 분석되어야 한다.

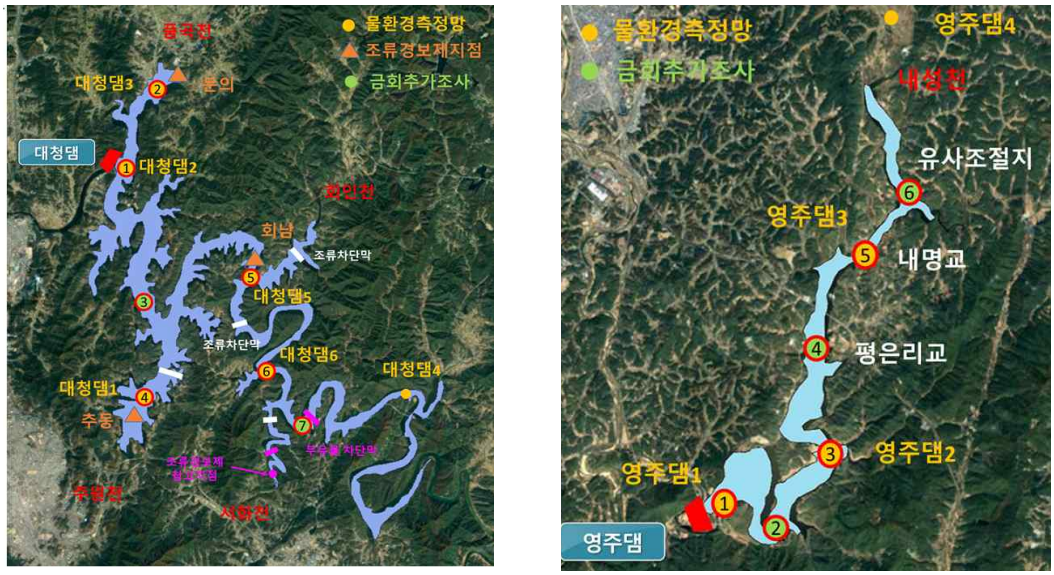
<표 2.7> Sentinel-2 위성영상 밴드 정보

밴드	중심파장(μm)	공간해상도(m)	촬영파장폭(nm)
Band 1 - Coastal aerosol	0.443	60	20
Band 2 - Blue	0.490	10	65
Band 3 - Green	0.560	10	35
Band 4 - Red	0.665	10	30
Band 5 - Vegetation Red Edge	0.705	20	15
Band 6 - Vegetation Red Edge	0.740	20	15
Band 7 - Vegetation Red Edge	0.783	20	20
Band 8 - NIR	0.842	10	115
Band 8A - Narrow NIR	0.865	20	20
Band 9 - Water vapour	0.945	60	20
Band 10 - SWIR - Cirrus	1.375	60	20
Band 11 - SWIR	1.610	20	90
Band 12 - SWIR	2.190	20	180

NIR, near-infrared; SWIR, short-wave infrared.

2.2.2 현장조사

대청댐 저수지와 영주댐 저수지를 대상으로 수질모델 보정과 개발된 알고리즘 정확도를 평가하기 위하여 2024년 4월부터 11월까지 현장조사를 수행하여 기초수질, Chl-a 및 세포수를 분석하였다. Sentinel-2 위성영상 관측일에 현장조사를 수행하였으며 다항목수질측정기(YSI社, Pro DSS)를 활용하여 수온, DO, 탁도 등 기초수질을 측정하였고, 수중형 연속 조류농도 측정장비(bbe社, FluoroProbe)를 활용하여 조류綱별 Chl-a 농도를 측정하였다. 그리고, 세포수 분석은 채수후 루골 용액으로 고정하여 현미경 검경을 수행하였다. 현장 Chl-a 센싱 측정값은 채수후 수질오염공정시험기준에 따라 Chl-a 분석을 통해 정확도를 검증하였으며 조류강별 농도와 세포수 간 상관성 분석을 수행하였다. 현장조사 지점은 환경부 수질측정망 지점과 녹조발생 우심지역을 고려하여 선정하였다.



(a) 대청댐 저수지 (b) 영주댐 저수지

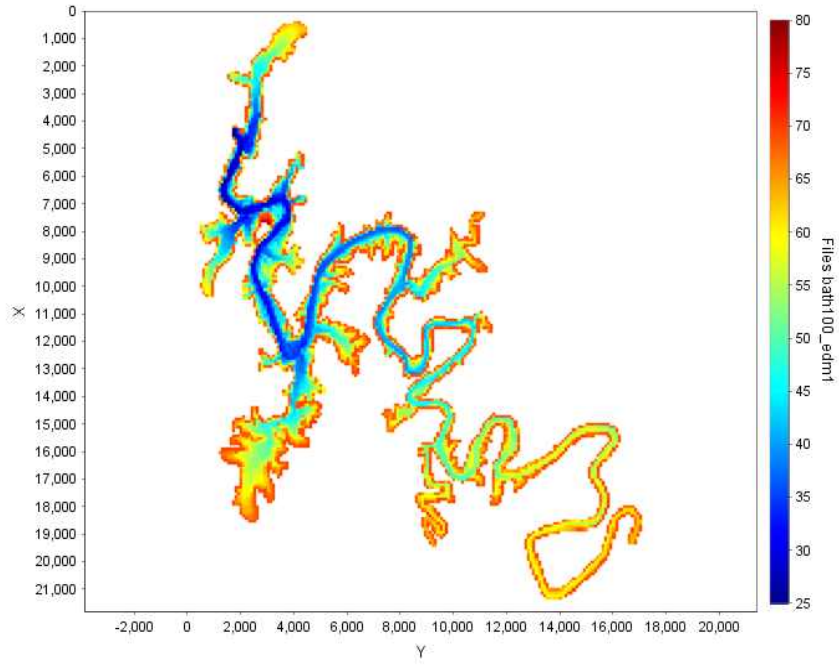
<그림 2.9> 대청댐 및 영주댐 저수지 현장조사 지점도

<표 2.8> 수중형 연속 조류농도 측정장비 개요

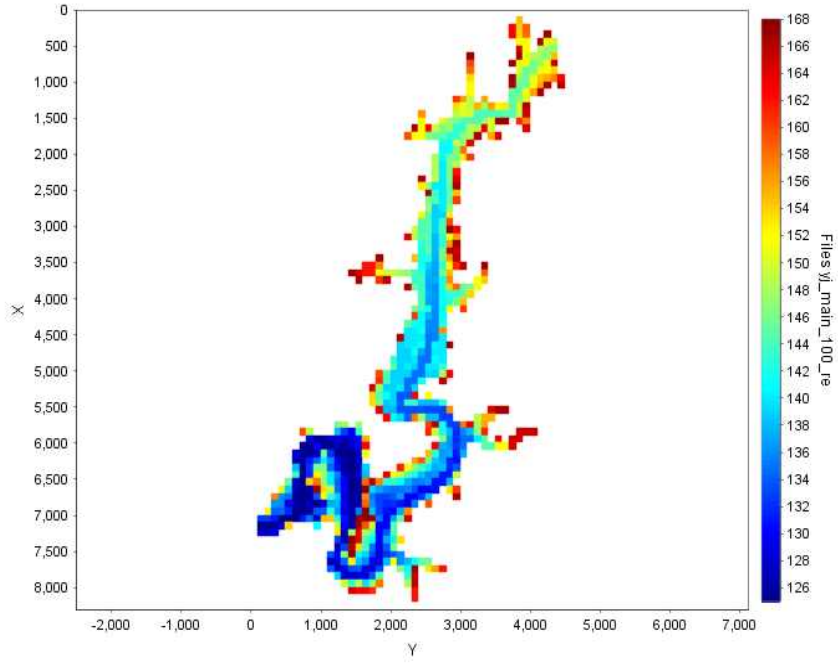
구 분	내 용	외형
측정원리	• 다파장 형광측정을 통한 조류강별 Chl-a 농도 분석 - 5개 독립 다파장 (450, 525, 570, 590, 610 nm) - 4개 조류강 (녹조류, 규조류, 남조류, 편모조류)	
작동시간	• 충전후 연속측정시 10시간, 충전중 측정가능	
측정범위	• Chl-a 농도 0 ~ 200 μg/L, 수심 0 ~ 100 m	
무게,크기	• 무게 : 5 kg • 크기(H × W) : 450 × 140 mm	

2.2.3 모델링

본 연구에서는 물환경측정망 자료 개수의 한계점을 보완하기 위하여 합성데이터 확보 목적으로 AEM3D 3차원 수리수질 모델을 활용하였다. AEM3D(Aquatic Ecology Model 3D) 모델은 서호주대학교의 물연구센터에서 개발된 Estuary, Lake and Coastal Ocean Model(ELCOM)과 Computational Aquatic Ecosystem Dynamics Model(CAEDYM)을 기반으로 호주 HydroNumerics사에서 개발한 모델이다(Hodges & Dallimore, 2019). 지배방정식은 운동량 방정식, 연속방정식, 자유수면방정식, 물질 이송-확산방정식이 포함된다. 운동량 방정식은 Reynolds-averaged Navier-Stokes (RANS)방정식을 사용하며, 기본적으로 유체의 특성에 대해서는 Boussinesq 가정과 수직방향의 운동량 방정식은 정수압(Hydrostatic pressure) 이론을 사용하지만, 비정수압(Non-hydrostatic)이 중요한 경우에는 nonhydrostatic code 옵션을 사용하여 수직방향의 운동량 방정식을 포함할 수 있다(Hodges & Dallimore, 2019; K-water, 2019; K-water. 2022). 본 연구의 대상지인 대청댐 및 영주댐 저수지를 대상으로 활용한 AEM3D 모델은 K-water(2019) 및 K-water(2022)에서 기 구축된 모델을 사용하였으며 각 대상지별 지형도는 <그림 2.10>과 같다. 격자 셀의 크기는 대청댐 및 영주댐 저수지 모두 100m×100m×1m (Δx×Δy×Δz)으로 구성하였다. Sentinel-2 위성영상 반사도값 매칭을 위해 적용한 시기는 대청댐은 2017년 6월부터 10월까지, 영주댐은 2021년을 대상으로 5월부터 9월까지로 선정하여 모의하였다.



<그림 2.10> 대청댐 AEM3D 격자 구성도

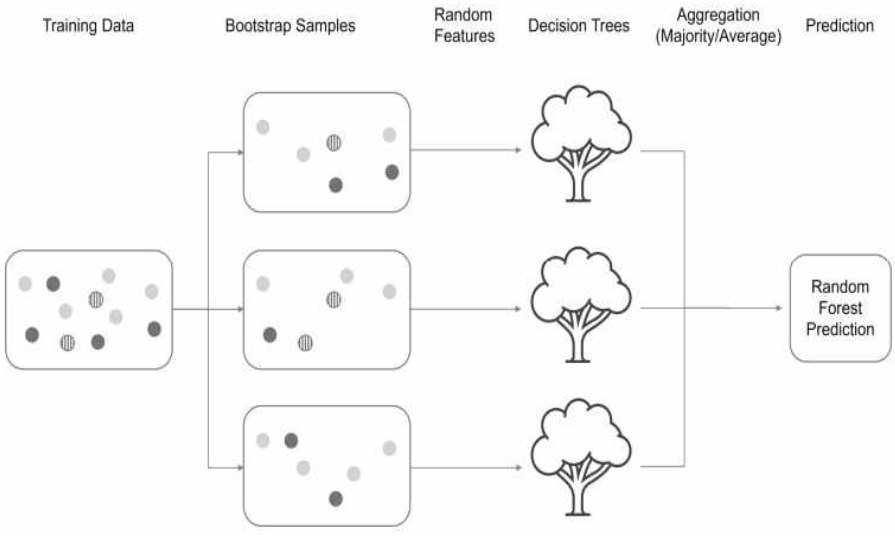


<그림 2.11> 영주댐 AEM3D 격자 구성도

2.2.4 머신러닝

가. 앙상블 기법

Sentinel-2 위성영상 반사도값과 기온, 유입량 등 기상 및 수문 자료를 독립변수로 단기 녹조 예측 알고리즘을 개발하기 위하여 정확도가 높아 최근 많이 사용되고 있는 랜덤포레스트(RandomForest) 기법과 XGBoot(eXtreme Gradient Boosting) 기법을 적용하였다. 랜덤포레스트 기법은 의사결정트리(Decision Tree) 기반 기법으로 과적합(overfitting) 문제를 보완하기 위해 Breiman (2001)에 의해 소개된 앙상블 알고리즘의 하나로 분류 및 회귀 분석 등 다양한 문제에 폭넓게 사용되고 있다. 앙상블이란 주어진 자료를 통해 다수의 예측 모델을 만들어 학습한 뒤, 모델들을 하나로 결합하여 더 강한 최종 예측 모델을 만들어내는 기법이다. 앙상블 방법은 크게 배깅(Bootstrap Aggregating)과 부스팅(Boosting)으로 나눌 수 있다. 랜덤포레스트는 이 중 배깅을 사용하는 대표적인 알고리즘으로 입력 데이터로부터 부트스트랩(Bootstrap) 샘플링을 통해 임의의 부트스트랩 표본을 추출한 후에, 부트스트랩 표본과 함께 전체 특성(feature)중 랜덤하게 m개를 선택하여 최적의 분할을 만드는 결정 트리를 생성한다. 이와 같은 과정을 N번 반복하여 총 N개의 결정트리를 생성하고, 하나의 분류기로 결합하여 랜덤포레스트 모델을 만들고, 각 결정 트리의 결과를 평균하여 최종결과를 도출한다(Tyralis et al., 2019; Kang and Park, 2021; Kim et al., 2021).



<그림 2.12> 랜덤포레스트 알고리즘 구조

XGBoost기법은 앙상블 학습하는 방식의 머신러닝 기법으로 Gradient boosting 기반의 알고리즘으로, 2016년 Tianqi Chen에 의해 소개되었다. Gradient boosting이란 앙상블(ensemble) 알고리즘 중 하나인 부스팅(boosting)기법에 경사하강법을 적용하여 정확도가 높아지는 방향으로 가중치를 갱신하여 반복적으로 새로운 예측 모델을 만들어 강한 예측 모델을 구현하는 방법이다. 이때, 부스팅기법은 약한 분류기(weak classifier)를 통해 학습한 결과를 토대로 강한 분류기(strong classifier)를 만드는 방법으로 부스팅기법을 이용해 분류기 M이 Y를 예측할 확률은 다음과 같이 표현할 수 있다. 이때, M은 트리 모델을, Y는 모델 예측 결과, $error_n$(n= 1~3)은 예측 시 생기는 error를 의미한다(Lee et al., 2020; Sim et al., 2022).

$$Y = M(x) + error_1(x) \quad (1)$$

$$error_1(x) = G(x) + error_2(x) \quad (2)$$

$$error_2(x) = H(x) + error_3(x) \quad (3)$$

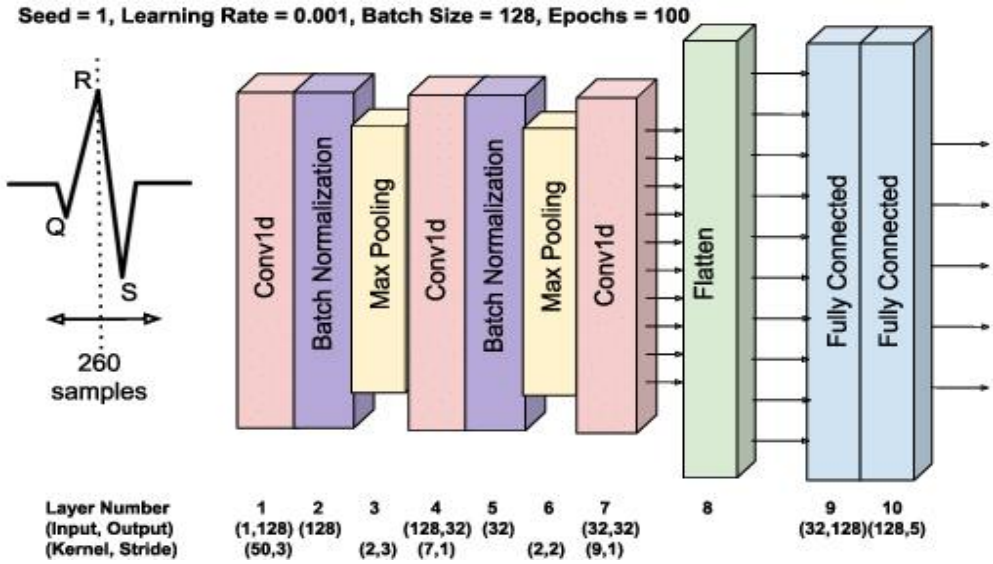
$$Y = M(x) + G(x) + H(x) + error_3(x) \quad (4)$$

$$Y = w_1 M(x) + w_2 G(x) + w_3 H(x) + e(x) \quad (5)$$

식 (2)에서 $error_1$을 모델 G(x)와 $error_2$로 상세히 분리하여 표현하고, 동일한 방법으로 식 (3)의 $error_2$를 모델 H(x)와 $error_3$으로 더 세밀하게 분리하여 표현할 수 있다. 이를 식 (1)에 대입하여 최종식 (4)를 만든다. 이후 식 (5)에서 더 좋은 성능의 분류기를 만들기 위하여 가중치(w_1, w_2, w_3)를 적용하여 최적의 가중치를 찾는다. 위 과정을 통해 약한 분류기를 강한 분류기로 만들어 분류기 M을 단독 사용했을 때보다 더 높은 예측 정확도를 얻을 수 있다.

나. 딥러닝 기법

최근 머신러닝 기법은 물리 모형의 한계점을 해결할 수 있는 방안으로 활용되고 있으며 특히, 딥러닝 모델의 경우 점단위 데이터 뿐만아니라 이미지와 같은 다차원 데이터의 시공간적인 특징들을 효율적으로 추출하여 분류와 회귀 문제에 많이 활용되고 있다. 딥러닝의 대표적인 아키텍처는 순환신경망(Recurrent neural network, RNN)과 합성곱신경망(Convolutional neural network, CNN)이며, 파생되는 딥러닝 구조들은 이 두 모형에 기반하여 디자인된다. CNN은 정방향 및 역방향 전파를 사용하는 심층 신경망이므로 컨볼루션 레이어, 풀링 레이어 및 활성화 함수로 다차원 이미지 데이터를 처리한다. 컨볼루션 레이어는 입력 벡터와 학습 가능한 가중치 및 편향의 elemental-wise곱셈을 수행하여 입력 내부 특징을 추출한다. 그런 다음 활성화 함수가 적용되며, 여기에는 요소별 비선형성 곱셈을 포함한다(Pyo et al., 2019; Pyo et al., 20020).



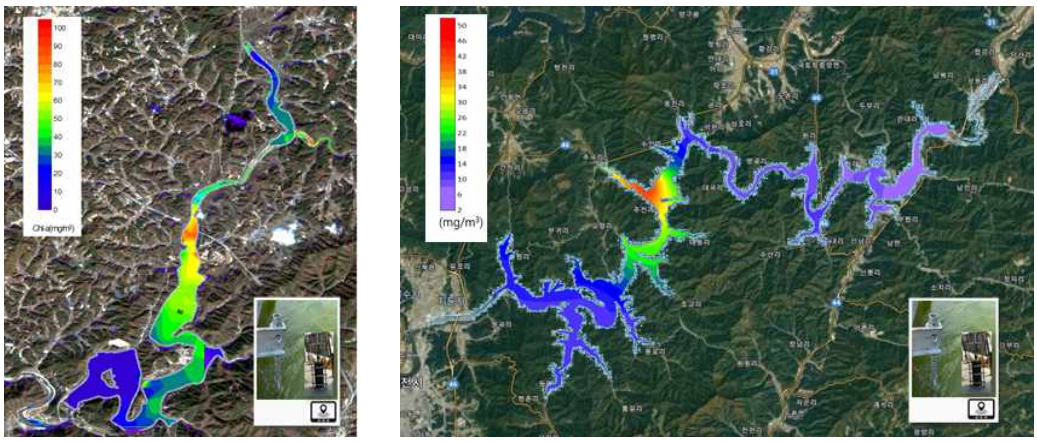
<그림 2.13> CNN 모델 구조

제 3 장 결과 및 고찰

3.1 녹조 원격 모니터링 기법 검토

3.1.1 공간적 녹조발생 조사방법

수질 및 녹조 등 물환경을 모니터링하기 위하여 국가 수질측정망이 지점단위로 운영되어 Chl-a 농도가 제공되고 있으며, 조류경보 및 관찰 지점을 대상으로 유해남조류세포수를 측정하여 정보를 제공하고 있다. 하지만, 지점단위 측정으로 공간적 녹조 발생을 파악하는 데 한계가 있으며 공간적 녹조발생 상황을 파악하기 위하여 선박 부착식 장비를 활용한 수체접촉식(in-situ) 센싱 기법으로 저수지 표층의 면단위 모니터링을 수행한 바 있다(K-water, 2022). 센서기반 측정 장비를 선박에 부착하여 GPS기반으로 공간적 Chl-a 농도를 취득함으로써 지점단위 측정 자료의 한계점을 개선하고자 하였다. 하지만 이와 같은 지점단위 및 면단위 모니터링은 많은 시간과 인력이 필요하기 때문에 큰 수체 및 동시다발적인 녹조발생을 모니터링 하기 위해서는 위성영상과 무인항공과 같이 원격으로 모니터링 기법이 필요하다. 이에 국내외 많은 연구가 많이 진행되고 있다.



(a) 영주댐 (b) 소양강댐

<그림 3.1> 대청댐 저수지 및 측정망 위치도

환경부에서는 조류항공영상 정보를 통해 하천 전체 구간에 대한 녹조발생 분포를 제공하고 있다. 기존 국가 수질측정망의 지점(點)단위 직접 분석방식은 전반적인 조류 발생현황을 파악하기 위해 많은 시간과 인력이 필요한 반면, 원격 모니터링 기법은 항공기에서 촬영하는 영상 정보를 통해서 공간적인 녹조발생 상황을 알 수 있

는 장점이 있다. 제공하는 정보는 총 조류 농도를 대변하는 Chl-a 농도와 남조류에 함유된 대표 색소인 피코시아닌 농도를 제공하고 있으며 한강, 북한강, 금강, 낙동강, 영상강과 일부 저수지를 대상으로 비가오지 않고 최대한 구름이 없는 날을 기준으로 항공촬영을 통해 녹조발생 상황을 제공하고 있다. 2024년을 기준으로 낙동강은 11회, 금강은 13회, 영상강은 1회 촬영되었다.

K-water에서는 위성영상, 무인항공 영상을 활용하여 주요 댐 저수지 및 보를 대상으로 녹조발생 상황을 제공하고 있다. Sentinel-2 위성영상을 활용하여 대상 수체 전체의 녹조발생 분포도와 무인항공 촬영을 통해 녹조발생 우심지역을 대상으로 녹조발생 분포 영상을 제공하고 있다.

3.1.2 위성영상 기반 녹조추정 알고리즘 및 입력변수 검토

녹조 원격 모니터링을 위해 위성영상 분석 알고리즘과 활용 밴드 적용 사례를 검토하였다. Meng et al.(2022)은 Sentinel MSI 데이터로 선형회귀분석을 진행하여 Chl-a 농도, 조류 밀도, 탁도를 추정하고 저수지의 수질 현황과 변화 특성을 파악하고자 하였다. 회귀 모델의 타당성을 확인하기 위해 위성 밴드 데이터를 이용하여 클로로필-a 농도를 추정하고 현장 Chl-a 농도와 비교한 결과 위성영상 밴드 4, 밴드 5, 밴드 6 반사도값을 이용한 파생변수를 사용하였을 때 알고리즘 성능이 향상되었으며 최적 모델의 회귀식 R^2 값은 0.61로 분석되었다. Toming et al.(2024)은 Sentinel-2 MSI 데이터와 GA_XGBoost 머신러닝 알고리즘, 현장 수질 데이터를 활용하여 14가지 수질을 추정하는 모델을 구축하고, 여러 호수에서 다른 날짜의 수질을 동시에 추정할 수 있는 모델의 적용 가능성을 검증하였다. 여러 가지 밴드 조합을 사용하여 클로로필-a와 남조류 생물량을 추정한 결과, 남조류 생물량은 MAPE 값이 모델 활용 가능 기준(>50%)을 초과하여 예측에 어려움이 있었으나 클로로필-a의 경우에는 모델 활용 가능 기준 이내(48.8%)로 분석되어 활용 가능한 것으로 판단하였다. Wang et al.(2024)은 중국의 Shending River 배수구 지역의 클로로필-a 농도를 추정하기 위해 Sentinel-2 MSI의 반사도값을 추출하고, 피어슨 상관 분석을 통해 다양한 반사도 조합과 실제 클로로필-a 농도와의 상관계수를 산정하였다. 또한, 가장 높은 상관계수를 나타낸 밴드 조합을 매개변수로 사용하여 클로로필-a 농도를 산정하여 실제 클로로필-a 농도와 비교하였으며 R^2 값은 0.69, MAE 1.006 mg/m^3, RMSE 1.219 mg/m^3로 나타남에 따라 클로로필-a 농도 추정에 위성영상 반사도값 활용이 가능하다고 판단하였다.

Dong et al.(2023)은 네 가지 머신러닝 기법(랜덤포레스트, XGBoost, CatBoost, SVR)을 활용해 클로로필-a의 추출 모델을 구축하고 Sentinel-2 위성의 원격 탐사 이미지를 활용하여 클로로필-a 농도를 추출하였다. 클로로필-a 농도를 예측하기 위해 총 4개의 밴드 조합을 사용하고 Dianshan Lake와 Taihu Lake에서 추출한 398개의 클로로필-a 데이터를 예측값과 비교한 결과, CatBoost, 랜덤포레스트, XGBoost 기법이 SVR 모델에 비해 측정값을 보다 정확하게 추정하는 성능을 나타내었다. 그리고

Villota et al.(2023), Arabi et al.(2020), Shi et al.(2022) 등 많은 연구에서 Sentinel-2 데이터의 단일 위성영상 밴드를 이용하여 클로로필-a 농도를 추정하는 연구를 진행한 바 있다. 본 연구에서는 각 연구에서 가장 높은 효율을 보인 밴드 조합과 단일 밴드를 머신러닝의 매개변수로 활용하여 가장 효율이 좋은 조합을 선정하여 모델별 성능을 비교하였다.

<표 3.1> 머신러닝에 사용된 원격 모니터링 사용 밴드조합

저자(년도)	표출항목	위성영상 밴드 적용 조합
Meng *et al.*(2022)	Chl-a Algal density	Band 5 - (Band 4 + Band 6) / 2
Toming *et al.*(2024)	Chl-a	(Band 2 + Band 4) × Band 8A (Band 2/Band 6) × (Band 2/Band 6) Band 4/Band 1 × Band 4/Band 5
	CYBM[1)]	Band 4 + Band 3 × Band 7 (Band 5 + Band 4) × Band 8A (Band 8A + Band 4) × Band 7
Wang *et al.*(2024)	Chl-a	(1/Band 4-1/Band 5) × Band 6 (1/Band 4-1/Band 5) × Band 7 (1/Band 4-1/Band 5) × Band 8 (1/Band 4-1/Band 5) × Band 8A
Dong *et al.*(2023)	Chl-a	Band 7 - Band 9 Band 4/Band 5 (Band 5-Band 4)/(Band 5 + Band 4) Band 2 × (1/Band 4-1/Band 5)

1) CYBM(Biomass of cyanobacteria)

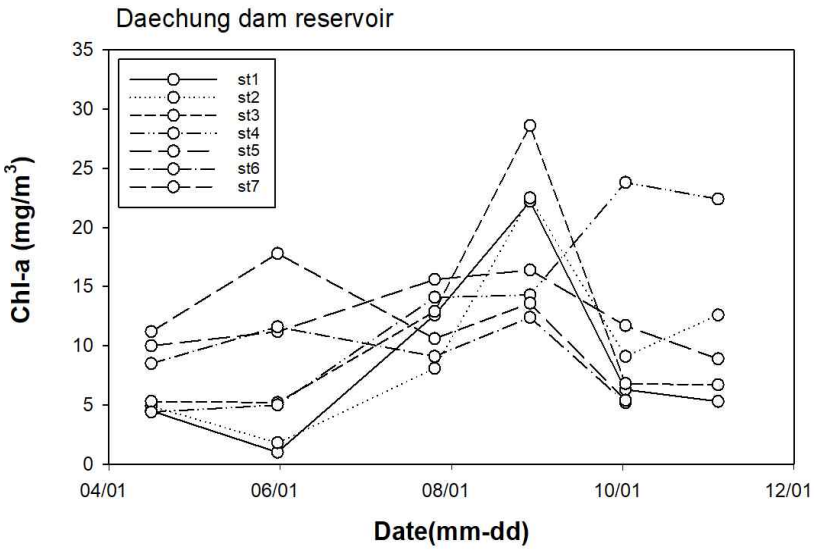
3.2 녹조발생 현장조사 결과

3.2.1 2024년 대청댐 녹조발생 조사결과

Sentinel-2 위성영상 기반 단기 녹조 예측 알고리즘을 개발한 후에 정확도를 평가하기 위하여 2024년도 4월부터 11월까지 현장조사를 수행하여 Chl-a 농도와 세포수를 분석하였다. 대청댐 호내 전체 지점 Chl-a 평균 농도는 11.1 mg/m3 (7.7~17.7 mg/m3) 였으며 8월에 가장 높았다. 지점별로는 7월에 회남 지점(st5)이 가장 높은 농도가 관측되었고 8월에는 하류 지점에서 높은 농도가 관측되었다. 세포수 분석 결과, 4월에 88% 이상 규조류가 우점하였으며 6월에 남조류가 증가하였으나 상류에는 녹조류, 하류에는 규조류가 우점하는 것으로 관측되었다. 8월에는 남조류가 94% 이상 남조류가 우점하였으며 11월까지 남조류가 관측되었다.

<표 3.2> 대청댐 저수지 2024년 계절별 표층 Chl-a 농도

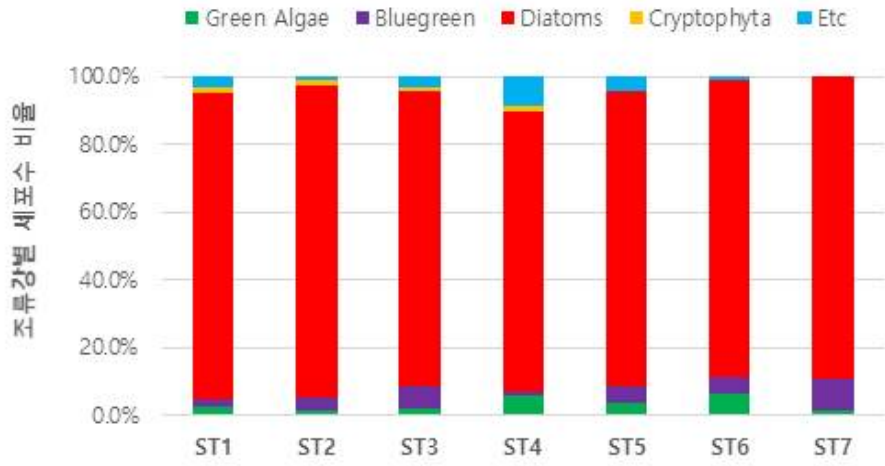
일자	지점 평균	지점						
		st1	st2	st3	st4	st5	st6	st7
2024-04-16	7.0	4.5	4.9	5.3	4.4	10.0	8.5	11.2
2024-05-31	7.7	1.0	1.8	5.2	5.0	11.2	11.6	17.8
2024-07-26	12.7	12.6	8.1	12.9	14.1	15.6	-	-
2024-08-29	17.7	22.2	22.5	28.6	14.3	16.4	9.1	10.6
2024-10-02	12.0	6.3	9.1	6.8	23.8	11.7	12.4	13.6
2024-11-04	9.5	5.3	12.6	6.7	22.4	8.9	5.2	5.4
평균	11.1	8.6	9.8	10.9	14.0	12.3	9.4	11.7



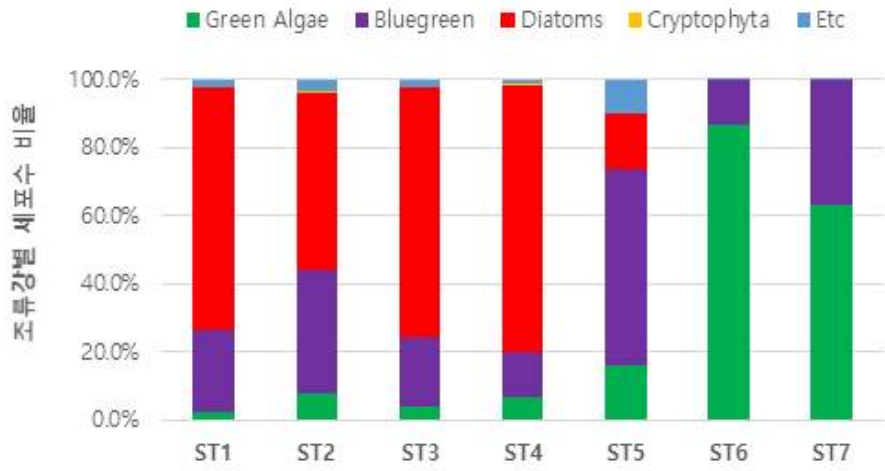
<그림 3.2> 대청댐 조사지점별 2024년 Chl-a 변화

<표 3.3> 대청댐 저수지 2024년 계절별 표층 세포수 통계값

일자	녹조류	윤조류	남조류		규조류	기타	총계
			총	유해			
04/16	120	26	167	167	3,066	93	3,472
	3.5%	0.8%	4.8%	4.8%	88.3%	2.7%	100.0%
06/26	7,751	16	4,401	1,524	2,786	216	15,169
	51.1%	0.1%	29.0%	10.0%	18.4%	1.4%	100.0%
08/29	2,114	156	69,038	8,551	122	66	71,496
	3.0%	0.2%	96.6%	12.0%	0.2%	0.1%	100.0%
11/04	798	68	8,217	3,458	5,690	396	15,169
	5.3%	0.4%	54.2%	22.8%	37.5%	2.6%	100.0%

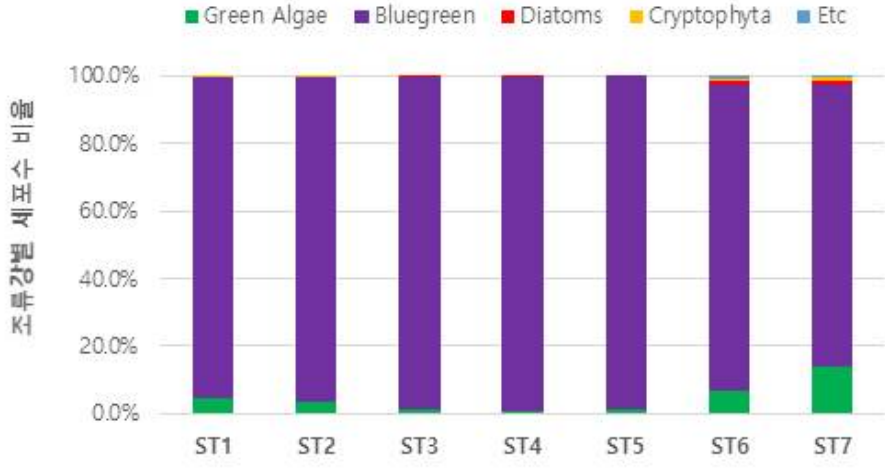


(a) 4월(2024-04-16)

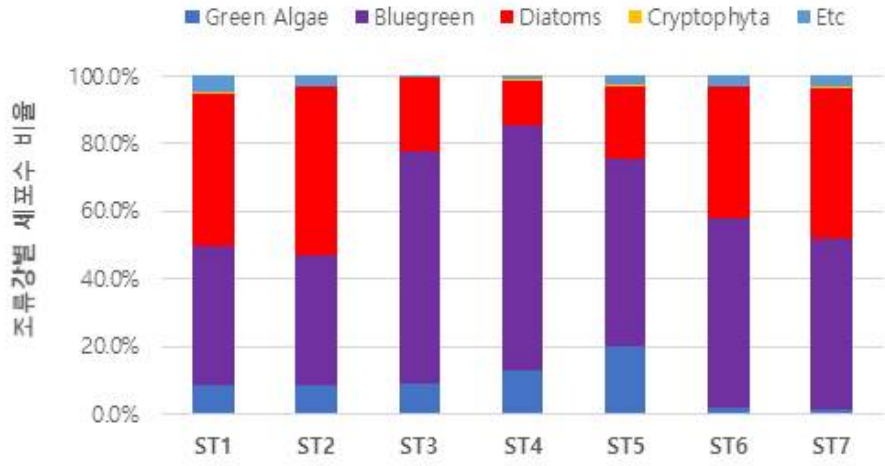


(b) 6월(2024-06-26)

<그림 3.3> 대청댐 2024년 계절별 조류강별 비율



(c) 8월(2024-08-29)



(d) 11월(2024-11-04)

<그림 3.3> 대청댐 2024년 계절별 조류강별 비율

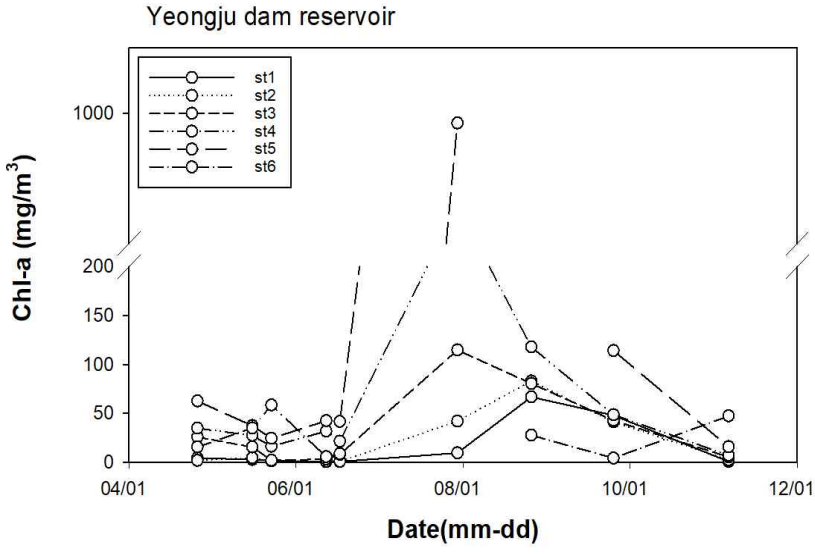
3.2.2 2024년 영주댐 녹조발생 조사결과

Sentinel-2 위성영상 기반 단기 녹조 예측 알고리즘을 개발한 후에 정확도를 평가하기 위하여 2024년도 4월부터 11월까지 현장조사를 수행하여 Chl-a 농도와 세포수를 분석하였다. 영주댐 호내 전체 지점 Chl-a 평균 농도는 53.7 mg/m^3 (-3.8~284.2 mg/m^3) 였으며 7월에 가장 높았다. 지점별로는 5월까지는 댐 상류의 유사조절지에서 Chl-a 농도가 가장 높았으며, 7월부터 9월까지 유사조절지 직하류 지점(st5)에서 높은 값을 나타내었다. 11월에는 영주댐 호내 지점보다 상류 유사조절지에 농도가 다시 높아지는 것으로 관측되었다. 세포수 분석 결과, 4월에 대부분 규조류가 71% 이상으로 우점하였으나 녹조류의 비율이 높은 지점이 관측되었고, 6월부터 남조류

가 74% 이상 우점하는 것으로 관측되었다. 8월에는 유사조절지를 제외하고 99% 이상 남조류가 우점하였으며, 11월까지 남조류가 88% 우점하는 것으로 관측되었다. 영주댐 저수지 상류에 유사조절지의 경우에는 6~8월에 남조류와 녹조류가 우점하였으나 11월에는 오히려 남조류가 우점하는 것으로 관측되었다.

<표 3.4> 영주댐 저수지 2024년 계절별 Chl-a 농도

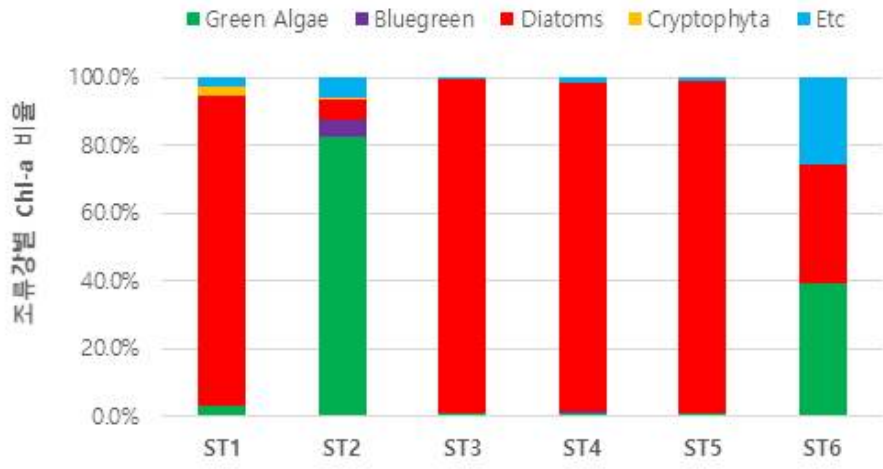
일자	지점 평균	지점					
		st1	st2	st3	st4	st5	st6
2024-04-26	24.1	4.2	1.7	25.7	34.8	62.5	15.5
2024-05-16	20.4	2.7	4.5	15.5	27.4	37.4	35.0
2024-05-23	17.3	1.5	1.2	1.9	16.2	24.4	58.5
2024-06-12	14.0	0.4	0.9	3.2	31.8	42.4	5.6
2024-06-17	13.5	0.5	0.8	7.9	21.4	41.6	8.5
2024-07-30	284.2	9.4	42.0	114.8	262.5	992.4	-
2024-08-26	75.1	66.7	83.0	80.5	117.9	-	27.6
2024-09-25	49.7	47.8	41.2	42.8	48.5	114.1	4.1
2024-11-06	13.1	0.6	2.3	5.3	7.1	15.7	47.3
평균	53.7	14.3	19.5	29.8	58.6	157.3	23.0



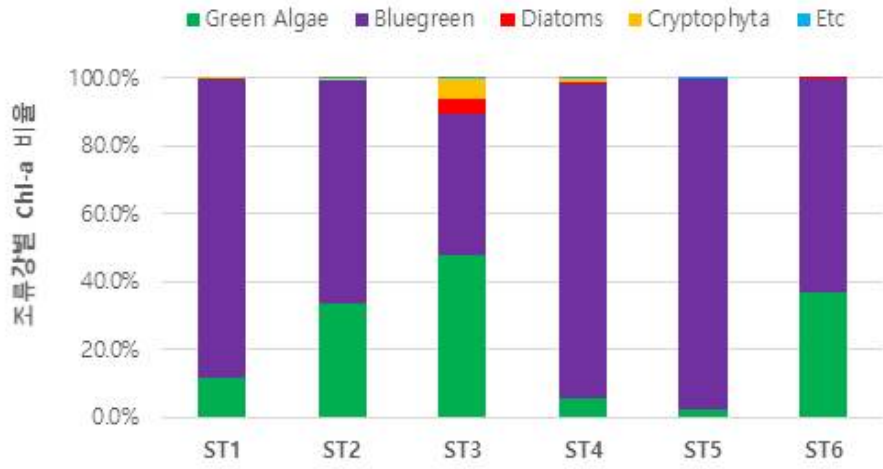
<그림 3.4> 영주댐 조사지점별 2024년 Chl-a 변화

<표 3.5> 영주댐 저수지 2024년 계절별 세포수 통계값

일자	녹조류	윤조류	남조류		규조류	기타	총계
			총	유해			
04/26	평균	250	11	9	9	8,821	113
	2.7%	0.1%	0.1%	0.1%	95.9%	1.2%	100.0%
06/12	4,227	143	27,380	21,173	137	4	31,891
	13.3%	0.4%	85.9%	66.4%	0.4%	0.0%	100.0%
08/26	4,442	5	314,141	27,643	1	0	318,589
	1.4%	0.0%	98.6%	8.7%	0.0%	0.0%	100.0%
11/06	614	1	30,587	223	525	164	31,891
	1.9%	0.0%	95.9%	0.7%	1.6%	0.5%	100.0%

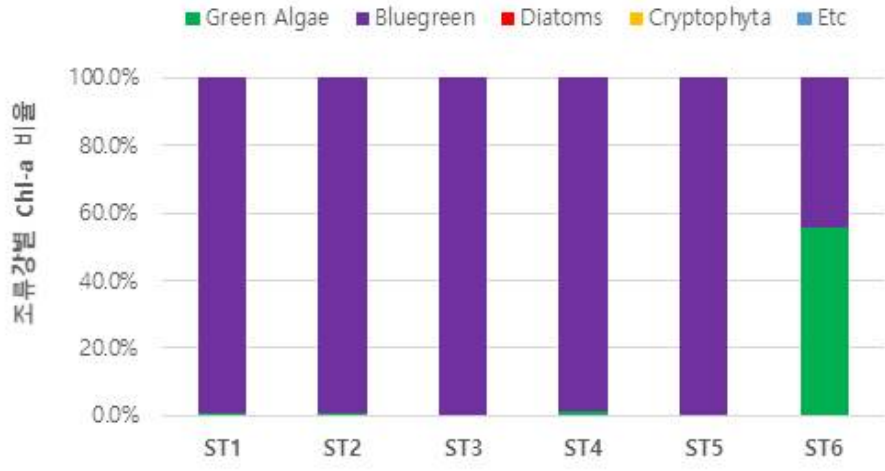


(a) 4월(2024-04-26)

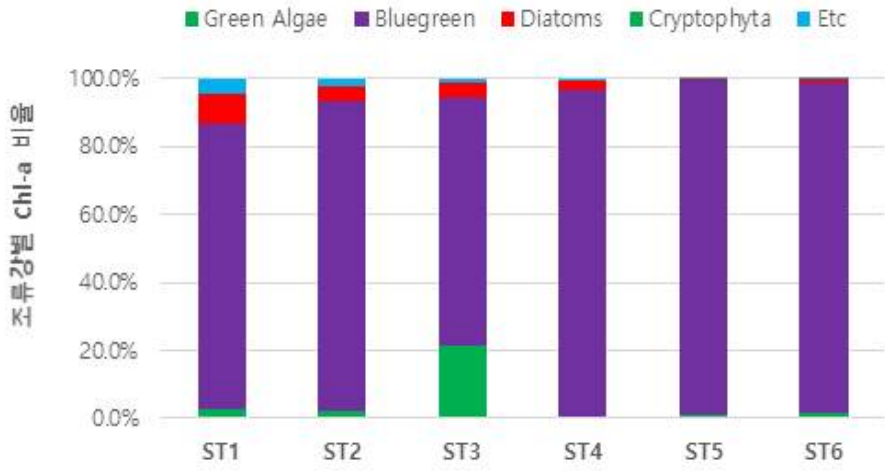


(b) 6월(2024-06-12)

<그림 3.5> 영주댐 2024년 계절별 조류강별 비율



(c) 8월(2024-08-26)



(d) 11월(2024-11-06)

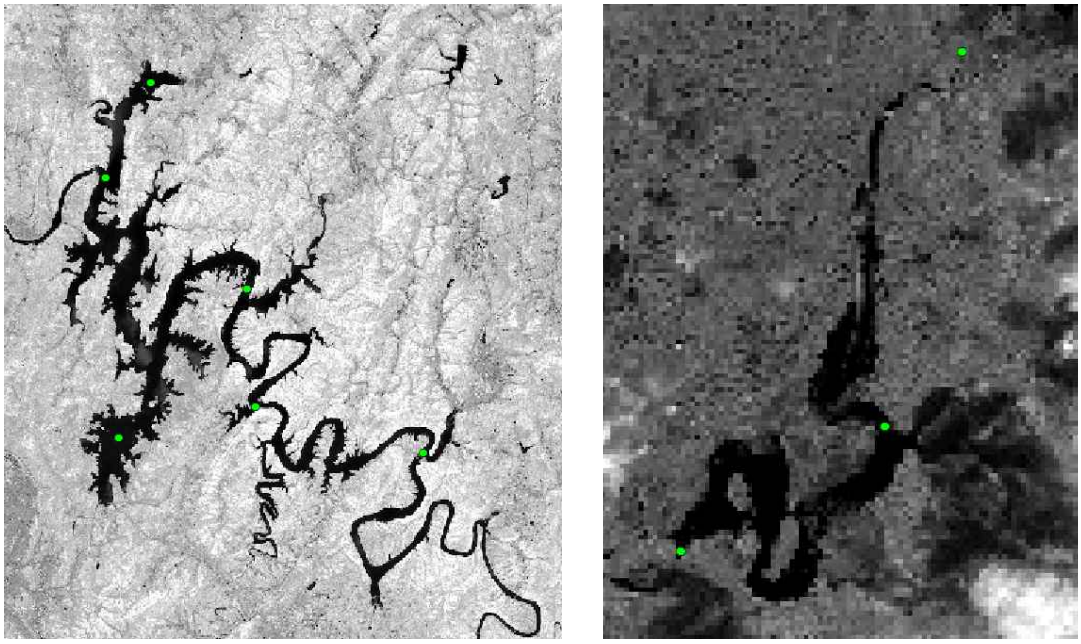
<그림 3.5> 영주댐 2024년 계절별 조류강별 비율

3.3 위성영상 기반 녹조 원격 모니터링 알고리즘 개발

3.3.1 측정망 기반 클로로필-a 추정 알고리즘 개발

가. 입력자료 구축 결과

위성영상 기반으로 댐저수지 현재 상태의 녹조발생 현황을 원격 모니터링을 위한 알고리즘을 개발하기 위하여 측정망 Chl-a 농도를 활용하여 입력자료를 구축하였다. 대청댐과 영주댐 수질측정망 관측일 중에서 Sentinel-2 관측일을 매칭하고 운량 등 기상을 고려하여 날짜를 선별하였다. Sentinel-2 위성영상은 대기보정까지 수행된 L2A 파일을 2017년도부터 제공하고 있고 수질측정 개시일을 고려하여, 대청댐은 저수지는 2017년 1월부터 2023년 12월까지, 영주댐 저수지는 2019년 6월부터 2023년 12월까지를 대상으로 위성과 영주댐의 위성 관측일과 수질측정망 채수일을 매칭하였다. 매칭한 날짜를 기준으로 코페르니쿠스 오픈 액세스 허브에서 Sentinel-2의 L2A 영상을 다운받은 후에 ArcMap을 활용하여 수질측정망 위경도를 기준으로 각 밴드별 반사도값과 Chl-a 농도를 매칭하였다. 총 98개 입력자료를 구축하였으며, 대청댐 저수지는 59개로 클로로필-a 농도 범위는 0.4~42.9 mg/m^3이며, 영주댐 저수지는 39개로 클로로필-a 농도 범위는 1.1~173.4 mg/m^3였다. 해당 날짜의 Chl-a 농도를 종속변수로 설정하였으며 독립변수는 위성영상 밴드별 반사도값, 기온, 보조변수를 산정하여 설정하여 위성영상 기반 현재 Chl-a 농도를 추정하기 위한 알고리즘분석 데이터 세트를 구성하였다.



(a) 대청댐 (b) 영주댐

<그림 3.6> Sentinel-2 반사도값과 수질측정망 매칭

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	Chla	Band1	Band2	Band3	Band4	Band5	Band6	Band7	Band8	Band8A	Band10	Band11	Band12
2	19.1	0.1574	0.1672	0.1691	0.1511	0.1609	0.1531	0.1518	0.1469	0.1468	0.1346	0.1207	0.1131
3	10.1	0.0960	0.1047	0.1146	0.1060	0.1053	0.1008	0.1016	0.1023	0.1018	0.0982	0.1021	0.1018
4	5.8	0.1421	0.1363	0.1413	0.1278	0.1298	0.1285	0.1316	0.1245	0.1288	0.1302	0.1218	0.1183
5	4.0	0.0703	0.0746	0.0639	0.0544	0.0528	0.0496	0.0489	0.0500	0.0460	0.0373	0.0276	0.0219
6	5.9	0.1495	0.1532	0.1541	0.1464	0.1480	0.1462	0.1477	0.1438	0.1448	0.1437	0.1369	0.1323
7	2.5	0.1185	0.1181	0.1224	0.1138	0.1126	0.1104	0.1106	0.1112	0.1100	0.1108	0.1104	0.1078
8	1.7	0.1231	0.1223	0.1245	0.1154	0.1142	0.1108	0.1109	0.1097	0.1109	0.1104	0.1109	0.1084
9	2.3	0.1259	0.1262	0.1288	0.1178	0.1158	0.1166	0.1166	0.1167	0.1151	0.1143	0.1112	0.1089
10	3.1	0.1240	0.1226	0.1266	0.1170	0.1151	0.1098	0.1093	0.1100	0.1102	0.1117	0.1103	0.1082
11	2.7	0.1248	0.1233	0.1279	0.1192	0.1180	0.1182	0.1177	0.1193	0.1170	0.1165	0.1154	0.1108
12	7.5	0.2087	0.2192	0.2252	0.2183	0.2232	0.2160	0.2151	0.2119	0.2148	0.2231	0.2185	0.2125
13	4.6	0.1177	0.1227	0.1226	0.1090	0.1075	0.1051	0.1092	0.1055	0.1045	0.1034	0.1019	0.1013
14	13.1	0.1157	0.1242	0.1248	0.1153	0.1155	0.1128	0.1140	0.1135	0.1126	0.1055	0.1046	0.1032
15	1.5	0.1026	0.1125	0.1110	0.1071	0.1055	0.1040	0.1054	0.1044	0.1026	0.1006	0.1030	0.1040
16	1.0	0.1038	0.1124	0.1111	0.1071	0.1059	0.1032	0.1035	0.1032	0.1012	0.1006	0.1037	0.1023
17	1.4	0.1023	0.1140	0.1122	0.1071	0.1052	0.1051	0.1038	0.1050	0.1041	0.1007	0.1040	0.1033
18	1.2	0.1049	0.1130	0.1139	0.1074	0.1052	0.1031	0.1040	0.1053	0.1022	0.0998	0.1036	0.1019
19	2.0	0.1043	0.1144	0.1194	0.1103	0.1091	0.1055	0.1076	0.1058	0.1036	0.1019	0.1056	0.1045
20	6.8	0.1162	0.1074	0.1169	0.1124	0.1182	0.1142	0.1154	0.1092	0.1134	0.1030	0.1071	0.1051
21	3.6	0.1402	0.1445	0.1422	0.1275	0.1255	0.1231	0.1227	0.1216	0.1193	0.1165	0.1090	0.1066
22	3.1	0.0449	0.0416	0.0393	0.0264	0.0242	0.0196	0.0186	0.0191	0.0153	0.0180	0.0115	0.0087
23	2.0	0.1755	0.1770	0.1812	0.1630	0.1629	0.1584	0.1598	0.1692	0.1587	0.1858	0.1556	0.1492
24	1.2	0.1892	0.1876	0.1956	0.1777	0.1758	0.1755	0.1831	0.1751	0.1808	0.1822	0.1686	0.1617
25	1.7	0.1523	0.1553	0.1558	0.1475	0.1457	0.1454	0.1437	0.1489	0.1446	0.1607	0.1450	0.1384
26	2.0	0.1595	0.1693	0.1714	0.1572	0.1570	0.1597	0.1623	0.1715	0.1629	0.1790	0.1514	0.1453
27	1.8	0.1955	0.1860	0.1946	0.1790	0.1888	0.2022	0.2080	0.1948	0.2093	0.2273	0.1841	0.1712
28	5.5	0.2030	0.2001	0.2033	0.1941	0.1972	0.1908	0.1934	0.1858	0.1914	0.1916	0.1896	0.1824
29	42.9	0.1364	0.1421	0.1657	0.1349	0.1369	0.1138	0.1148	0.1112	0.1079	0.1067	0.1063	0.1054

<그림 3.7> Sentinel-2 반사도값과 측정망 Chl-a 매칭 DB결과

<표 3.6> 클로로필-a 원격 모니터링 알고리즘 분석 입력자료 현황

년도	대청댐		영주댐	
	데이터수	Chl-a(mg/m^3)	데이터수	Chl-a(mg/m^3)
2017	2	14.6 (10.1~19.1)	-	-
2018	1	5.8	-	-
2019	16	3.8 (1.0~13.1)	8	10.7 (1.3~33.4)
2020	11	7.2 (1.2~42.9)	11	13.2 (1.6~43.0)
2021	8	5.9 (0.4~34.4)	4	12.8 (1.1~38.2)
2022	13	2.6 (0.5~15.8)	8	17.8 (2.1~56.1)
2023	8	3.1 (0.5~11.7)	8	39.4 (1.8~173.4)
합계/평균	59	6.1	39	18.8

나. 앙상블 기법 적용 결과

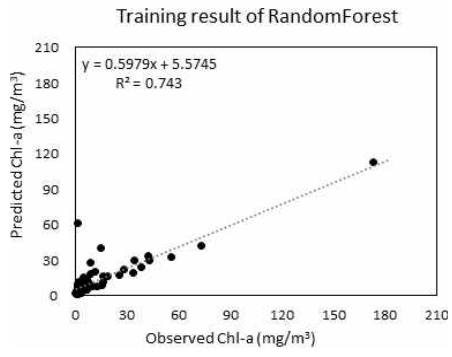
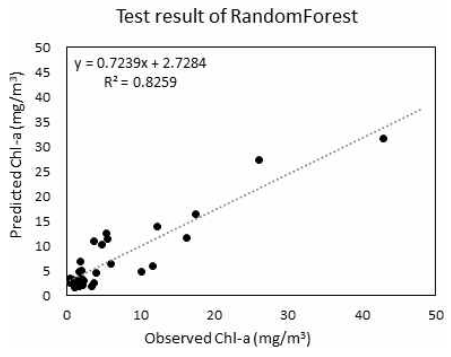
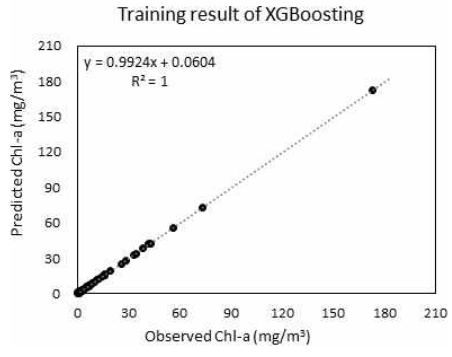
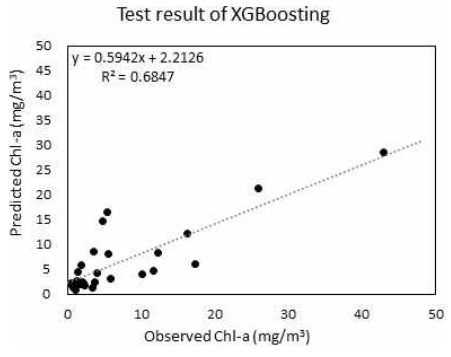
RandomForest와 XGBoost 기법을 적용하기 위한 훈련 및 테스트 데이터 구분은 입력자료 개수가 충분하지 않아 랜덤으로 구분하지 않고 R^2값을 기준으로 최적의 결과를 도출하기 위한 알고리즘을 적용하여 70%는 학습데이터로, 30%는 테스트 데이터로 구분하였다. 앞서 검토한 연구사례를 활용하여 Sentinel-2 밴드별 반사도값, 밴드조합에 의한 파생변수 및 기온을 입력자료로 활용하여 6가지 입력자료 항목 조

합을 구성하여 정확도 높은 입력변수 항목을 선정하였다. 랜덤포레스트와 XGBoot 기법을 적용하여 분석한 결과, 각 알고리즘 모두 밴드 4, 5, 6, 7의 반사도값과 기온을 독립변수로 적용한 경우가 가장 정확도가 높았으며 XGBoost보다 랜덤포레스트 기법이 정확도가 높은 것으로 분석되었다. 밴드 4, 5, 6, 7의 반사도값과 기온을 독립변수로 적용하여 랜덤포레스트 기법을 적용한 결과, 학습결과는 R^2 값은 0.74, RMSE 값은 11.4 mg/m^{3}였으며 검증결과는 R^2 값은 0.83, RMSE 값은 4.2 mg/m^{3}로 분석되었다. XGBoost 기법을 적용한 결과, 학습결과는 R^2 값은 0.99, RMSE 값은 0.2 mg/m^{3}였으며 검증결과는 R^2 값은 0.68, RMSE 값은 6.7 mg/m^{3}로 분석되었다. 따라서, Chl-a의 경우 검증 결과를 기준으로 XGBoost 보다 랜덤포레스트 기법의 정확도가 가장 높게 분석되었으며 공간적 녹조 분포를 관측값과 유사하게 나타내었다. 하지만, 고농도에서 과소 평가되는 것을 확인할 수 있었는데, 이는 모델 개발을 위해 활용한 분석데이터수가 작고 고농도 데이터가 부족했기 때문으로 판단되며 추후 지속적인 데이터가 추가되고 이를 반영하여 모델이 개선된다고 더욱 정확한 Chl-a 원격 관측이 가능할 것으로 판단된다.

<표 3.7> Chl-a의 원격 모니터링을 위한 머신러닝 분석 결과

Case	입력항목	구분	통계값	RandomForest	XGBoost
Case1	Band1~12, B1*	Training	R^2	0.74	0.99
			RMSE(mg/m^3)	12.2	0.2
		Test	R^2	0.55	0.33
			RMSE(mg/m^3)	6.6	9.7
Case2	Band2~11, B1*	Training	R^2	0.79	0.99
			RMSE(mg/m^3)	11.0	0.2
		Test	R^2	0.67	0.64
			RMSE(mg/m^3)	5.3	7.8
Case3	Band4~7, B1*	Training	R^2	0.75	0.99
			RMSE(mg/m^3)	11.0	0.2
		Test	R^2	0.67	0.64
			RMSE(mg/m^3)	5.3	7.8
Case4	Band1~12, 기온	Training	R^2	0.74	0.99
			RMSE(mg/m^3)	11.5	0.2
		Test	R^2	0.38	0.42
			RMSE(mg/m^3)	13.0	25.1
Case5	Band2~11, B1*, 기온	Training	R^2	0.78	0.99
			RMSE(mg/m^3)	11.3	0.2
		Test	R^2	0.66	0.46
			RMSE(mg/m^3)	5.1	23.6
Case6	Band4~7, B1*, 기온	Training	R^2	0.74	0.99
			RMSE(mg/m^3)	11.4	0.2
		Test	R^2	0.83	0.68
			RMSE(mg/m^3)	4.2	6.7

* B1 = Band5 - (Band4 + Band6)/2

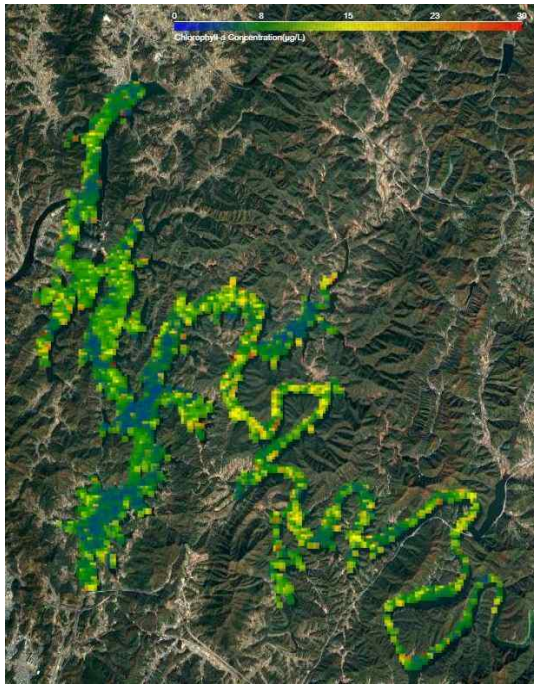
기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.8> Chl-a 원격 추정 Case6 학습 및 검증결과

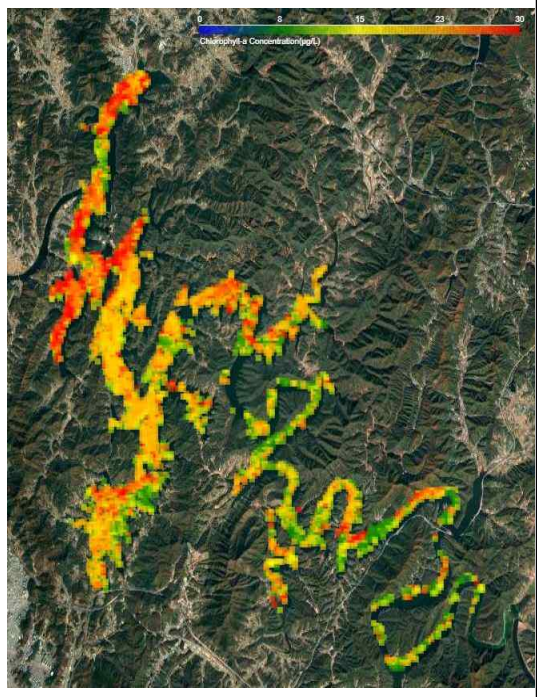
Sentinel-2의 밴드 4~7, 파생변수(밴드 4~5), 기온을 입력자료로 랜덤포레스트 기법으로 개발한 알고리즘으로 2024년도 본 연구에서 조사한 지점별 표층 Chl-a 농도를 비교하여 모델을 검증하였으며, 공간적 Chl-a 분포를 시각화하였다. 대청댐의 경우에는 추정 Chl-a 농도가 관측값을 잘 재현하는 것으로 나타났으며 8월 Chl-a 농도가 증가하는 것을 잘 재현하였다. 영주댐의 경우에는 추정 Chl-a 농도가 관측값에 비해 다소 30 mg/m^3 이상인 농도에서 과소 평가되는 것으로 나타났으며 이는 측정망이 '19년 6월부터로 영주댐 고농도 Chl-a 자료 확보의 부족에 의한 것으로 판단되었다. 하지만, 댐 상류에 고농도 우심지역의 Chl-a 농도가 높은 현상을 잘 재현하는 것으로 나타나 개발 알고리즘에 의한 원격 Chl-a 농도 추정이 가능한 것으로 판단되었다.

<표 3.8> Chl-a의 랜덤포레스트 기반 원격 추정값과 2024년 관측값 검증 결과

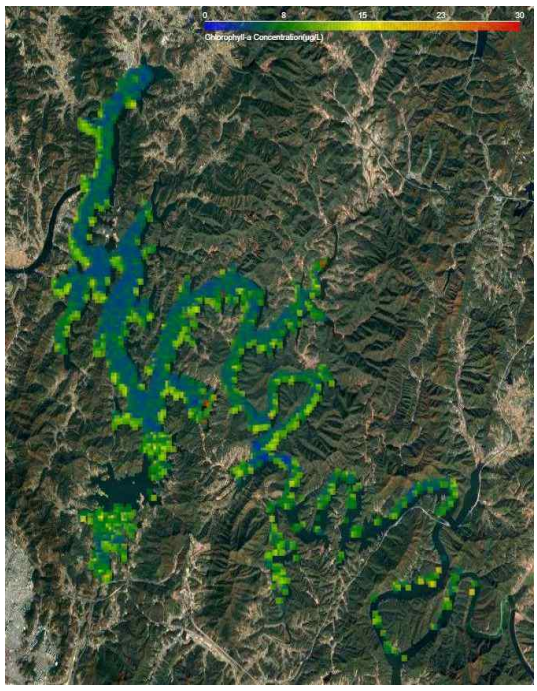
댐	지점	Chl-a (mg/m^3)					
대청댐	날짜	2024-05-31		2024-08-29		2024-11-04	
	구분	추정값	관측값	추정값	관측값	추정값	관측값
	ST1	5.3	1.0	24.4	22.2	3.5	5.3
	ST2	6.2	1.8	24.4	22.5	4.0	12.6
	ST3	5.3	5.2	24.4	28.6	3.5	6.7
	ST4	6.4	5.0	17.1	14.3	4.0	22.4
	ST5	8.0	11.2	11.0	16.4	7.4	8.9
	ST6	9.0	11.6	12.3	9.1	5.2	5.2
	ST7	14.7	17.8	8.1	10.6	8.4	5.4
	평균 (범위)	7.9 (5.3~14.7)	7.7 (1.0~17.8)	17.3 (8.1~24.4)	17.7 (9.1~28.6)	5.1 (3.5~8.4)	9.5 (5.2~22.4)
영주댐	날짜	2024-05-23		2024-06-12		2024-11-06	
	구분	추정값	관측값	추정값	관측값	추정값	관측값
	ST1	3.5	1.5	6.5	0.4	2.2	0.6
	ST2	4.9	1.2	6.3	0.9	1.9	2.3
	ST3	3.8	1.9	9.2	3.2	3.9	5.3
	ST4	18.0	16.2	15.3	31.8	4.8	7.1
	ST5	21.4	24.4	17.3	42.4	7.5	15.7
	ST6	-	58.5	-	5.6	12.5	47.3
	평균 (범위)	10.3 (3.5~21.4)	17.3 (1.2~58.5)	17.3 (6.3~17.3)	14.0 (0.4~42.4)	5.5 (1.9~12.5)	13.1 (0.6~47.3)



(a) 2024/05/31



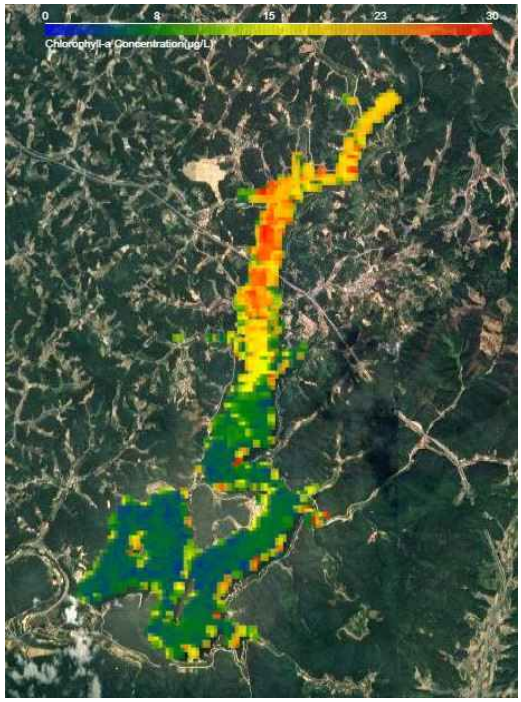
(b) 2024/08/29



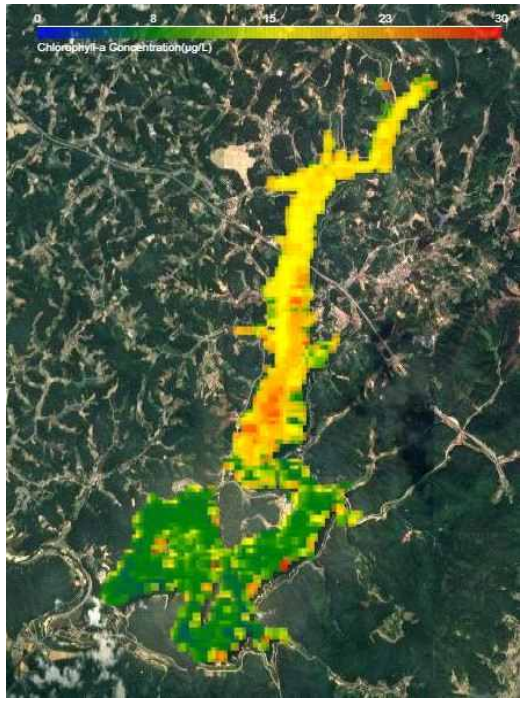
(c) 2024/11/04

대청댐
Chl-a 측정일: ’24-11-04
Sentinel-2 관측일: ‘24-11-02

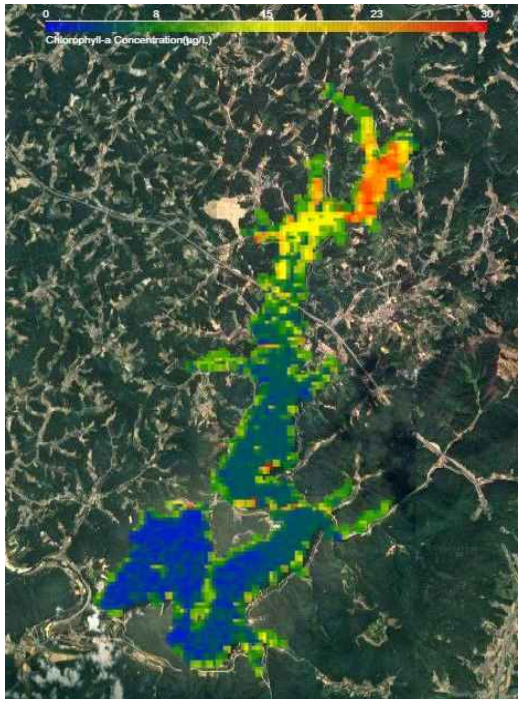
<그림 3.9> 대청댐 Chl-a의 랜덤포레스트 기반 2024년 원격 추정농도 시각화 결과



(a) 2024/05/23



(b) 2024/06/12



(c) 2024/11/06

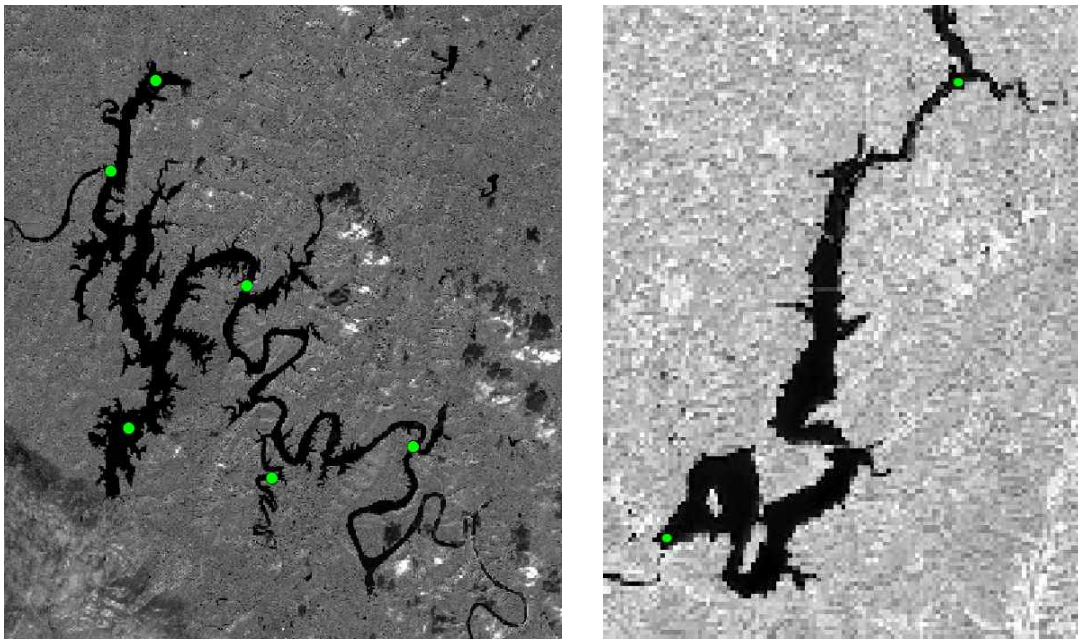
영주댐
Chl-a 측정일: ’24-11-06
Sentinel-2 관측일: ‘24-11-07

<그림 3.10> 영주댐 Chl-a의 랜덤포레스트 기반 2024년 원격 추정농도 시각화 결과

3.3.2 측정망 기반 세포수 원격 모니터링 알고리즘 개발

가. 입력자료 구축 결과

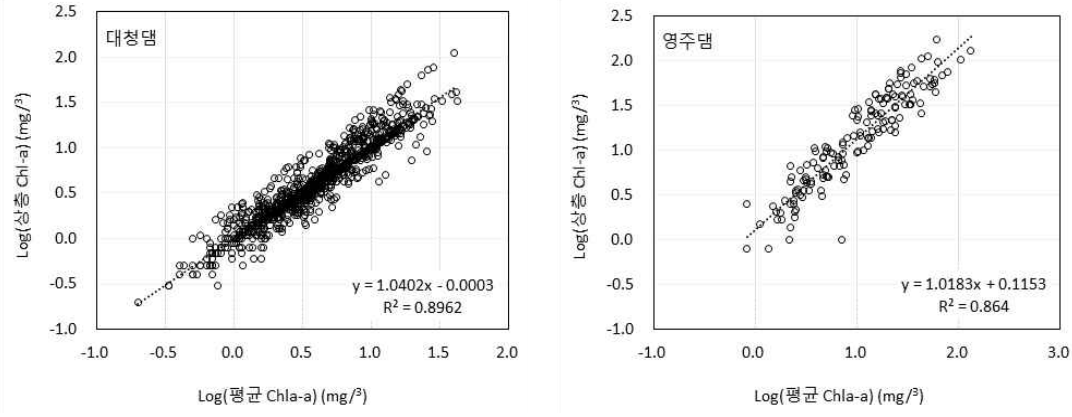
위성영상 기반으로 댐저수지 현재 상태의 녹조발생 세포수값 원격 모니터링을 위한 알고리즘을 개발하기 위하여 조류경보제 및 참고지점의 세포수 분석자료를 활용하여 입력자료를 구축하였다. 대청댐과 영주댐 측정망 세포수 관측일 중에서 Sentinel-2 관측일을 매칭하고 운량 등 기상을 고려하여 날짜를 선별하였다. Sentinel-2 위성영상은 대기보정까지 수행된 L2A 파일을 2017년도부터 제공하고 있고 측정망 개시일을 고려하여, 대청댐은 저수지는 2017년 1월부터 2023년 12월까지, 영주댐 저수지는 2019년 6월부터 2023년 12월까지를 대상으로 위성과 영주댐의 위성 관측일과 세포수 분석 채수일을 매칭하였다. 매칭한 날짜를 기준으로 코페르니쿠스 오픈 액세스 허브에서 Sentinel-2의 L2A 영상을 다운받은 후에 ArcMap을 활용하여 측정망 위경도를 기준으로 각 밴드별 반사도값과 세포수값을 매칭하였다.



(a) 대청댐 (b) 영주댐

<그림 3.11> Sentinel-2 반사도값과 조류세포수 측정망 매칭

호소 수질측정망은 수심별 상, 중, 하층 조사가 이루어지며 조류경보제 지점은 상·중·하층의 혼합 시료에 대한 유해남조류세포수이다. 이에, 상층의 세포수 데이터 확보를 위하여 상, 중, 하층의 Chl-a 농도와 혼합 시료에 대한 상층 Chl-a 농도의 회귀식을 산정하고 이를 활용하여 혼합 시료에 대한 세포수를 상층의 세포수로 환산하여 알고리즘 분석에 활용하였다. 로그변환하여 회귀식을 산정하여 지점별 평균값을 비교한 결과, 차이값이 대청댐은 0.3 mg/m^3 였으며 영주댐은 3.0 mg/m^3으로 대청댐보다 영주댐의 차이가 크게 나타났다.



(a) 대청댐 (b) 영주댐

<그림 3.12> 대청댐 및 영주댐 상층 및 평균 Chl-a 비교

<표 3.9> 대청댐 및 영주댐 관측 상층 Chl-a 관측 및 계산 결과 비교

댐		대청댐						영주댐		
지점번호		st1	st2	st3	st4	st5	st6	st1	st2	st3
Chl-a (mg/m^3)	관측	9.6	2.6	3.7	5.8	3.7	4.4	17.8	25.4	34.3
	계산	8.7	2.4	3.9	5.9	3.5	4.3	15.0	22.2	37.2
	차이	0.9	0.2	0.2	0.1	0.2	0.1	2.8	3.2	2.9

총 205개 입력자료를 구축하였으며, 대청댐 저수지는 125개로 총조류 세포수 및 남조류 세포수 값의 범위는 범위는 227~39,517 cells/mL 및 0~38,097 cells/mL이며, 영주댐 저수지는 80개로 총조류 세포수 및 남조류 세포수 값의 범위는 범위는 104~200,404 cells/mL 및 0~199,969 cells/mL이다. 해당 날짜의 총 세포수, 남조류 세포수 등을 각각 종속변수로 설정하였으며 독립변수는 위성영상 밴드별 반사도값, 기온, 보조변수를 산정하여 설정하여 위성영상 기반 현재 세포수 값을 추정하기 위한 알고리즘분석 데이터 세트를 구성하였다.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	Total	Bluegreer	Diatom	Green	Band1	Band2	Band3	Band4	Band5	Band6	Band7	Band8	Band8A	Band10	Band11	Band12
2	24,753	24,381	39	138	0.1426	0.1464	0.1592	0.1340	0.1360	0.1284	0.1292	0.1253	0.1250	0.1154	0.1092	0.1060
3	4,922	3,755	564	302	0.1425	0.1499	0.1500	0.1348	0.1385	0.1339	0.1349	0.1299	0.1297	0.1208	0.1170	0.1103
4	1,995	1,316	419	138	0.1598	0.1716	0.1710	0.1541	0.1700	0.1710	0.1775	0.1645	0.1686	0.1592	0.1271	0.1160
5	6,522	5,142	1,081	133	0.1550	0.1657	0.1692	0.1516	0.1801	0.2113	0.2221	0.2391	0.2151	0.1598	0.1298	0.1144
6	1,553	1,160	224	81	0.0971	0.1040	0.1090	0.1056	0.1018	0.0978	0.0993	0.0829	0.0996	0.0972	0.1051	0.1038
7	3,288	2,544	406	145	0.1001	0.1043	0.1102	0.1038	0.1012	0.0965	0.1007	0.1001	0.0984	0.0952	0.1048	0.1038
8	12,008	10,297	401	967	0.0962	0.1008	0.1107	0.1052	0.1037	0.1006	0.1025	0.1020	0.1011	0.0985	0.1015	0.1029
9	2,028	201	1,016	346	0.1503	0.1447	0.1550	0.1432	0.1453	0.1393	0.1417	0.1353	0.1421	0.1431	0.1394	0.1352
10	3,041	2,266	466	23	0.1380	0.1313	0.1384	0.1221	0.1226	0.1201	0.1198	0.1167	0.1192	0.1236	0.1163	0.1127
11	3,001	229	1,830	78	0.1276	0.1272	0.1323	0.1173	0.1171	0.1148	0.1163	0.1163	0.1156	0.1176	0.1105	0.1056
12	4,619	1,358	2,308	176	0.2302	0.2190	0.2111	0.1928	0.1975	0.1958	0.1942	0.1891	0.1882	0.1826	0.1353	0.1211
13	5,518	2,400	1,847	118	0.1966	0.1850	0.1815	0.1632	0.1687	0.1731	0.1720	0.1709	0.1666	0.1604	0.1260	0.1160
14	8,710	4,105	2,710	427	0.2114	0.1988	0.1907	0.1741	0.1758	0.1754	0.1724	0.1671	0.1638	0.1653	0.1270	0.1167
15	3,693	503	2,575	140	0.1297	0.1359	0.1319	0.1251	0.1220	0.1200	0.1192	0.1181	0.1163	0.1132	0.1100	0.1083
16	5,118	1,199	3,166	143	0.1245	0.1285	0.1283	0.1196	0.1180	0.1152	0.1155	0.1168	0.1127	0.1085	0.1099	0.1066
17	9,416	4,337	4,036	296	0.1211	0.1302	0.1265	0.1192	0.1180	0.1167	0.1142	0.1165	0.1125	0.1105	0.1075	0.1054
18	2,157	289	682	304	0.1380	0.1434	0.1429	0.1344	0.1326	0.1309	0.1317	0.1325	0.1295	0.1263	0.1262	0.1222
19	1,158	30	485	81	0.1372	0.1416	0.1420	0.1323	0.1317	0.1303	0.1300	0.1315	0.1281	0.1252	0.1244	0.1198

<그림 3.13> Sentinel-2 반사도값과 측정망 세포수 매칭 DB결과

<표 3.10> 세포수 원격 모니터링 알고리즘 분석 입력자료 현황

년도	대청댐			영주댐		
	데이터 개수	총조류 세포수	남조류 세포수	데이터 개수	총조류 세포수	남조류 세포수
2017	7	7,863 (1,553~24,753)	6,942 (1,160~24,381)	-	-	-
2018	9	5,016 (2,028~9,416)	1,844 (201~4,337)	-	-	-
2019	27	8,163 (372~39,311)	6,336 (0~38,097)	10	25,033 (412~96,582)	14,885 (0~80,501)
2020	33	5,105 (240~33,636)	3,583 (0~30,512)	25	23,267 (284~200,404)	14,173 (0~199,969)
2021	18	4,835 (227~39,517)	2,804 (0~36,730)	14	15,002 (104~67,978)	6,412 (0~64,449)
2022	13	3,828 (575~11,020)	1,992 (0~7,920)	13	28,584 (342~115,473)	22,342 (0~114,265)
2023	18	1,538 (304~5,130)	264 (0~2,190)	18	18,835 (421~124,980)	14,270 (0~119,554)
합계/평균	125	5,193 (227~39,517)	3,395 (0~38,097)	80	22,144 (104~200,404)	14,416 (0~199,969)

나. 앙상블 기법 적용 결과

RandomForest와 XGBoost 기법을 적용하기 위한 훈련 및 테스트 데이터 구분은 입력자료 개수가 충분하지 않아 랜덤으로 구분하지 않고 R^2값을 기준으로 최적의 결과를 도출하기 위한 알고리즘을 적용하여 70%는 학습데이터로, 30%는 테스트 데이터로 구분하였다. 앞서 검토한 연구사례를 활용하여 Sentinel-2 밴드별 반사도값과 기온을 입력자료로 활용하여 각 앙상블 기법 적용결과, 밴드 1~12 반사도값, 기온을 적용하여 XGBoost 기법 적용시 정확도가 가장 높게 나타났다. 밴드 1~12 반사도값, 기온을 적용한 경우의 랜덤포레스트의 총조류 추정 알고리즘의 학습 및 검증데이터 분석 결과, R^2 값은 0.99 및 0.56이었으며 RMSE 값은 156 cells/mL 및 12,579 cells/mL로 분석되었다. XGBoost를 적용하여 총남조류 세포수 추정 알고리즘의 경우에는 학습 및 검증데이터 분석 결과 R^2 값은 0.99 및 0.70이었으며 RMSE 값은 129 cells/mL 및 11,289 cells/mL로 분석되었으며 총조류 세포수에 비해 총남조류 세포수 추정 모델의 성능이 다소 높게 분석되었다. Chl-a 추정 모델에 비해 세포수 추정 모델은 추정값이 관측값을 과소 산정하는 경향으로 나타났으며 이는 Chl-a 와 마찬가지로 고농도 관측값이 부족한 것에서 기인한 것으로 판단되며 측정망 데이터가 누적된다면 더욱 정확한 알고리즘으로 개선할 수 있을 것으로 판단된다.

<표 3.11> 총조류 세포수 원격 모니터링을 위한 머신러닝 분석 결과

Case	입력항목	구분	통계값	RandomForest	XGBoost
Case1	Band1~12, C1[1], C2[2], C3[3], 기온	Training	R^2	0.75	0.99
			RMSE(mg/m^3)	12,840	140
		Test	R^2	0.61	0.51
			RMSE(mg/m^3)	9,568	13,257
Case2	Band1~12, 기온	Training	R^2	0.92	0.99
			RMSE(mg/m^3)	12,707	156
		Test	R^2	0.40	0.56
			RMSE(mg/m^3)	10,309	12,579
Case3	세포수 로그변환 Band1~12, C1[1], C2[2], C3[3], 기온	Training	R^2	0.83	0.96
			RMSE(mg/m^3)	0.27	0.13
		Test	R^2	0.47	0.43
			RMSE(mg/m^3)	0.47	0.46
Case4	세포수 로그변환 Band1~12, 기온	Training	R^2	0.83	0.96
			RMSE(mg/m^3)	0.26	0.13
		Test	R^2	0.46	0.48
			RMSE(mg/m^3)	0.49	0.49
Case5	C1[1], C2[2], C3[3], 기온	Training	R^2	0.70	0.99
			RMSE(mg/m^3)	13,995	263
		Test	R^2	0.59	0.57
			RMSE(mg/m^3)	10,597	11,751

1) C1 = Band4 + Band3 × Band7

2) C2 = (Band5 + b4) × Band8A

3) C3 = (Band8A + Band4) × Band7

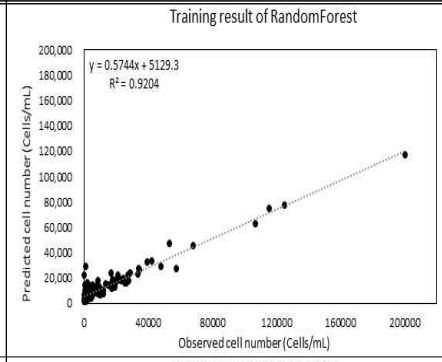
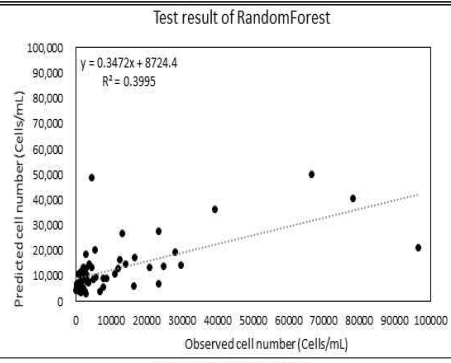
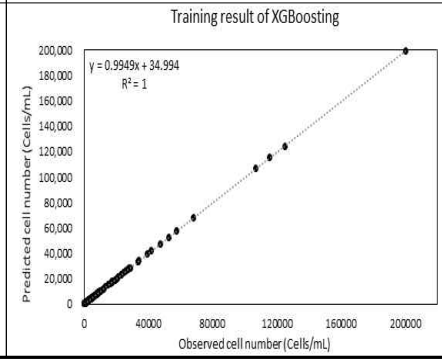
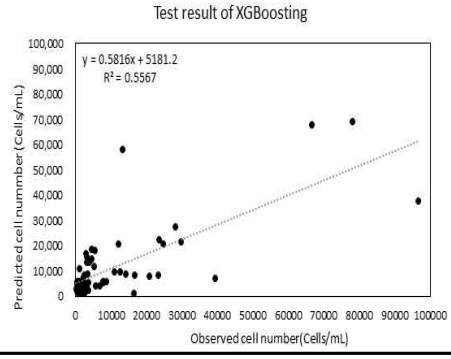
<표 3.12> 총남조류 세포수 원격 모니터링을 위한 머신러닝 분석 결과

Case	입력항목	구분	통계값	RandomForest	XGBoost
Case1	Band1~12, C1[1], C2[2], C3[3], 기온	Training	R^2	0.79	0.99
			RMSE(mg/m^3)	11,776	136
		Test	R^2	0.70	0.57
			RMSE(mg/m^3)	5,426	12,195
Case2	Band1~12, 기온	Training	R^2	0.15	0.99
			RMSE(mg/m^3)	12,004	129
		Test	R^2	0.01	0.70
			RMSE(mg/m^3)	5,264	11,289

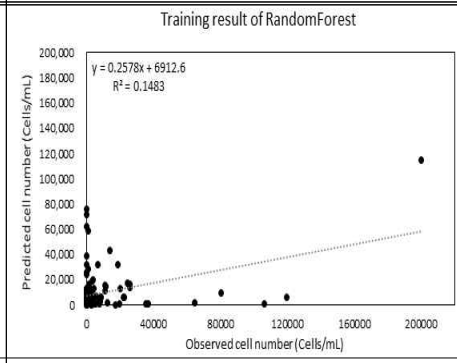
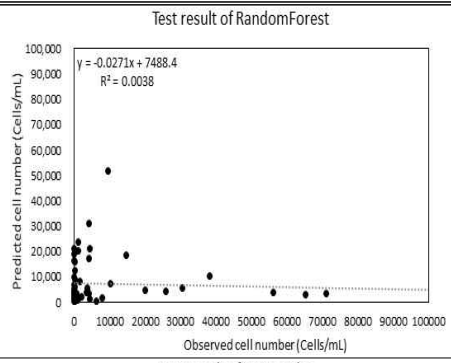
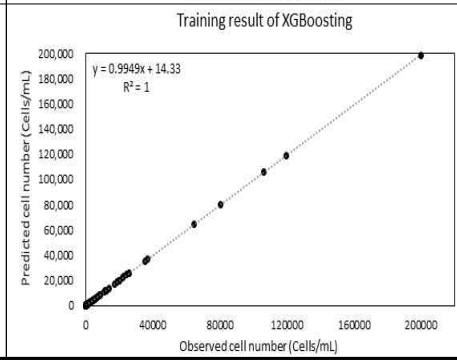
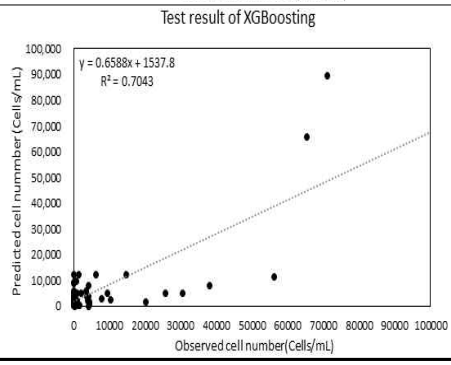
1) C1 = Band4 + Band3 × Band7

2) C2 = (Band5 + b4) × Band8A

3) C3 = (Band8A + Band4) × Band7

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.14> 총조류 세포수 XGBoost(Case2) 학습 및 테스트 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.15> 남조류 세포수 XGBoost(Case2) 학습 및 테스트 결과

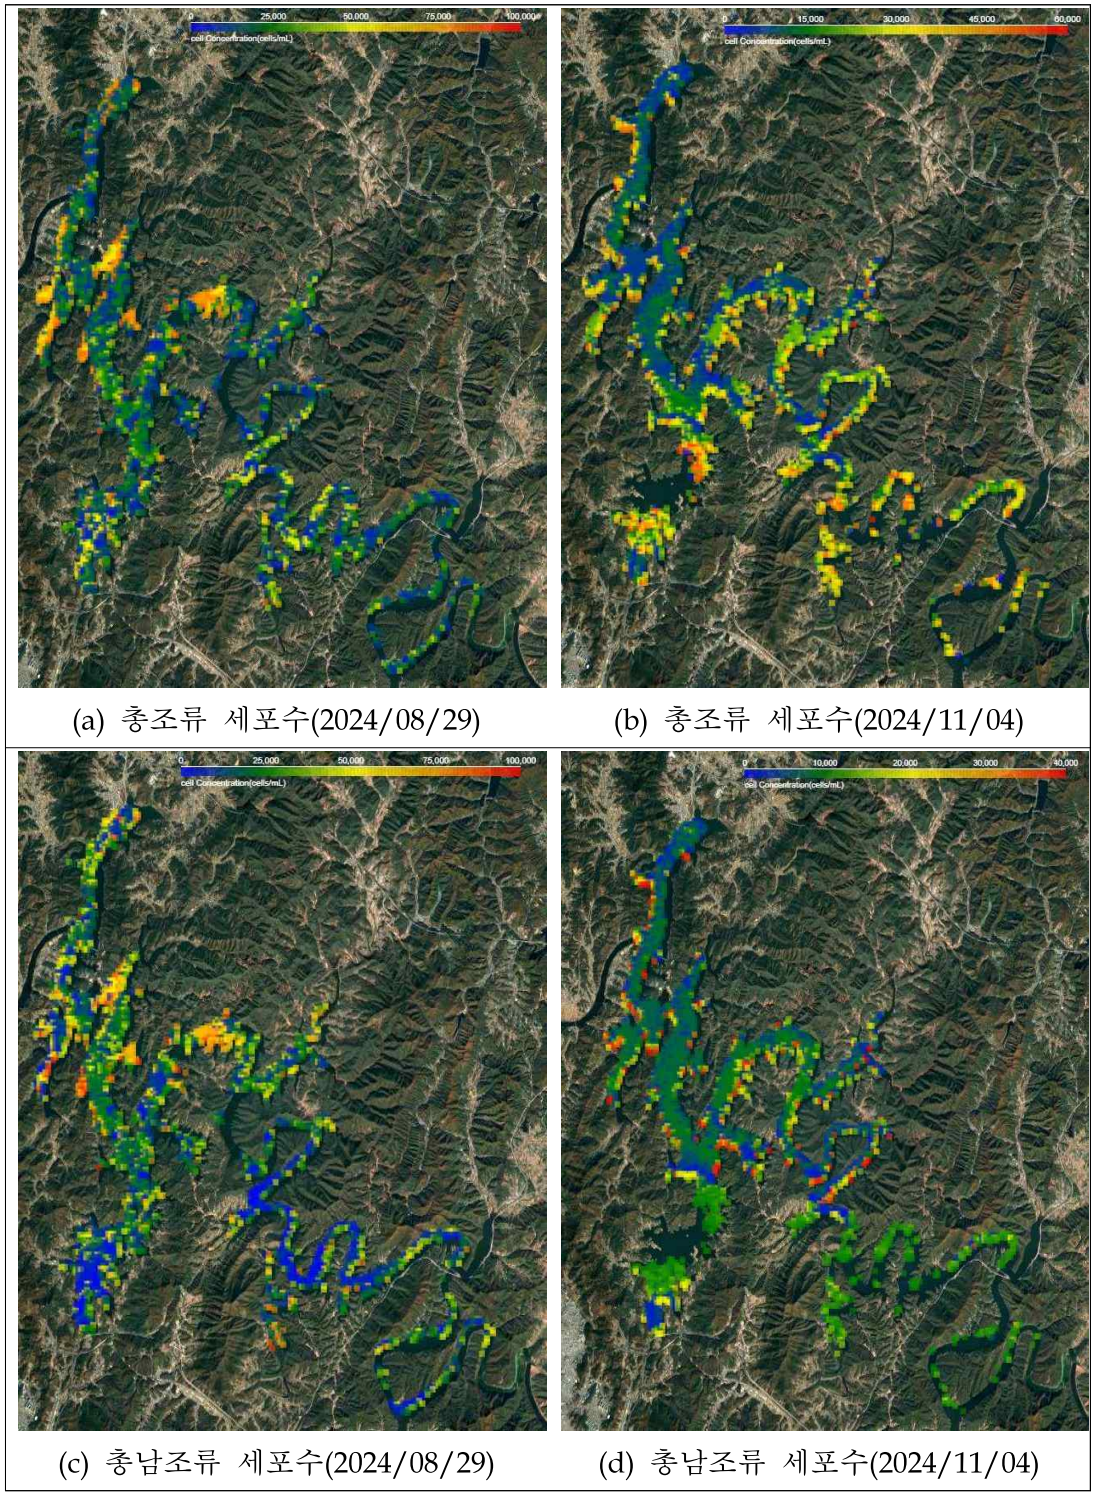
Sentinel-2의 밴드 1~12, 기온을 입력자료로 XGBoost 기법으로 개발한 알고리즘으로 2024년도 본 연구에서 조사한 지점별 총조류 및 남조류 세포수 관측값과 비교하여 모델을 검증하였으며, 공간적 세포수 분포를 시각화하였다. 6월과 8월 여름철 비교 결과, 대청댐은 과소 평가되었으며 영주댐은 과대 평가되는 것으로 나타나 이는 개발된 모델이 대청댐과 영주댐 자료를 활용하여 평균화되었기 때문으로 판단된다. 반면에, 11월 세포수는 대청댐과 영주댐 추정 세포수가 관측값을 잘 재현하는 것으로 나타나 여름철 관측값 누적에 의해 지속적으로 모델 개선이 필요할 것으로 판단되었다.

<표 3.13> 총조류 세포수의 XGBoost 기반 원격 추정값과 관측값 검증 결과

댐	지점	세포수 (cells/mL)			
대청댐	날짜	2024-08-29		2024-11-04	
	구분	추정값	관측값	추정값	관측값
	ST1	12,998	83,065	5,958	3,397
	ST2	16,383	93,234	6,401	7,084
	ST3	12,998	144,386	5,958	5,824
	ST4	11,561	58,551	2,894	9,611
	ST5	20,649	75,573	27,937	8,739
	ST6	5,392	28,256	14,201	26,893
	ST7	45,017	17,404	20,461	44,645
	평균 (범위)	17,857 (5,392~45,017)	71,496 (17,404~144,386)	11,973 (2,894~27,937)	15,169 (3,387~44,645)
영주댐	날짜	2024-06-12		2024-11-06	
	구분	추정값	관측값	추정값	관측값
	ST1	61,702	6,619	7,083	6,620
	ST2	60,870	4,745	2,951	4,745
	ST3	58,972	7,790	3,170	7,790
	ST4	86,265	34,169	13,914	34,169
	ST5	60,299	97,789	8,205	97,789
	ST6	구름으로 인해 제외	40,232	49,818	40,232
	평균 (범위)	65,622 (58,972~86,265)	31,891 (4,745~97,789)	14,190 (2,951~49,818)	27,380 (3,128~95,148)

<표 3.14> 총남조류 세포수의 XGBoost 기반 원격 추정값과 관측값 검증 결과

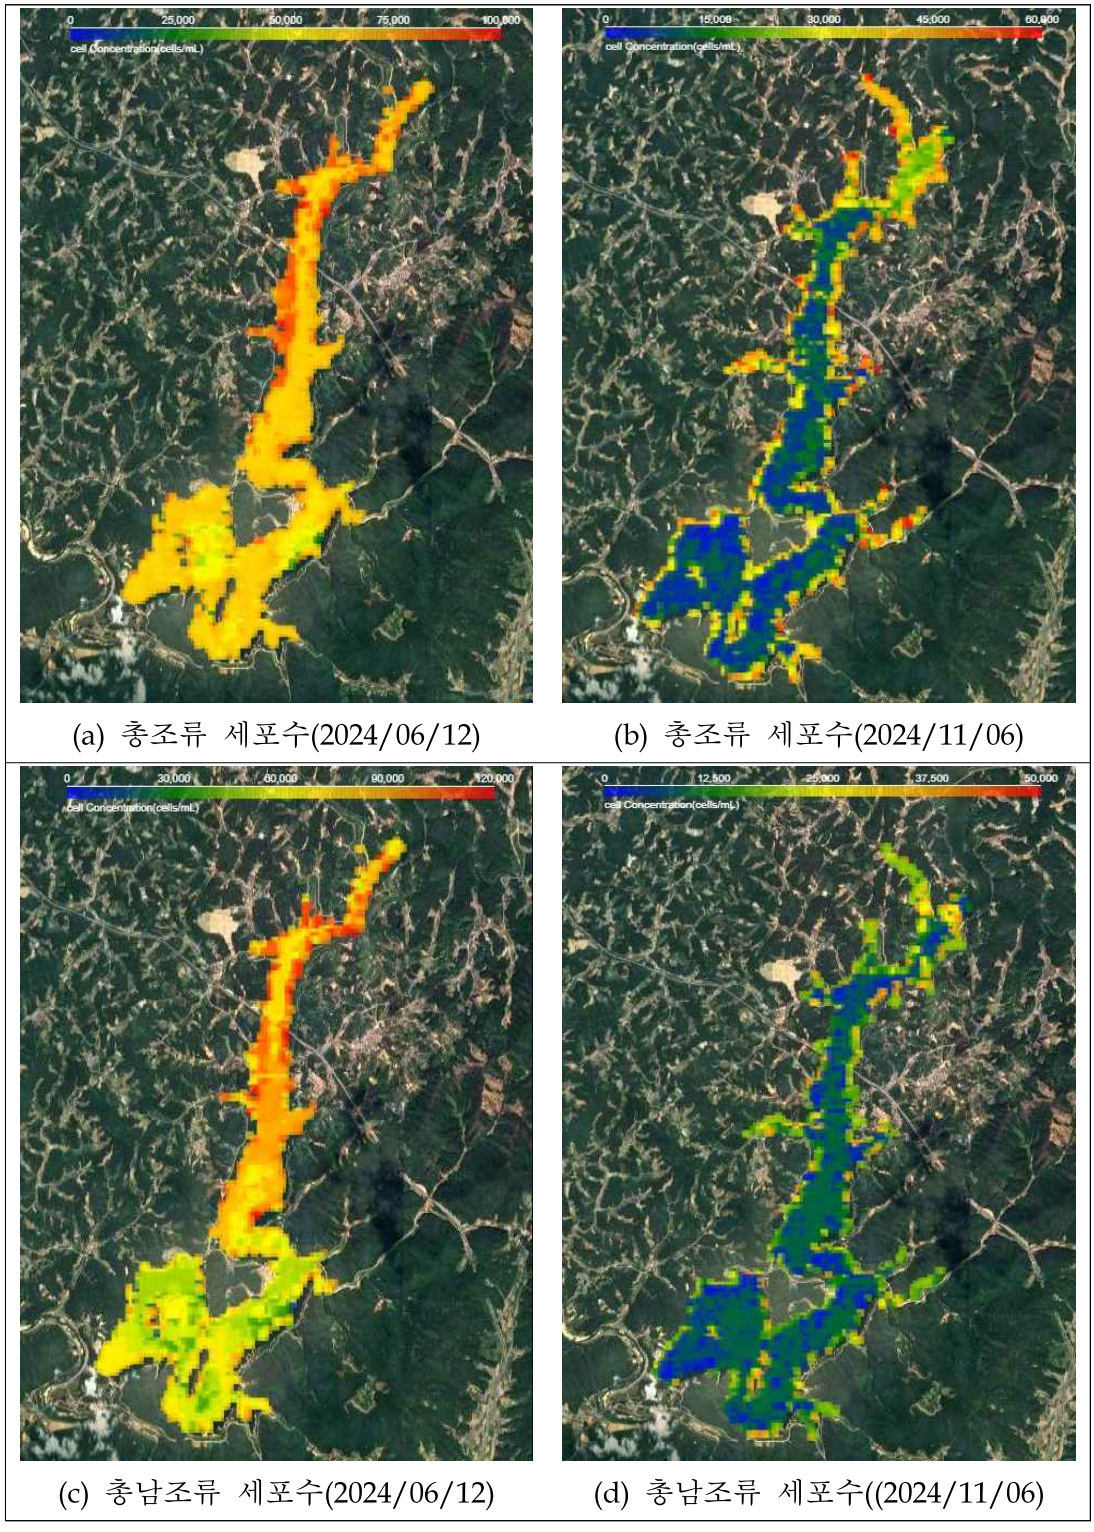
댐	지점	세포수 (cells/mL)			
대청댐	날짜	2024-08-29		2024-11-04	
	구분	추정값	관측값	추정값	관측값
	ST1	13,148	78,739	4,206	1,394
	ST2	19,036	89,772	7,623	2,706
	ST3	13,148	142,277	4,206	4,012
	ST4	10,215	57,802	2,741	6,965
	ST5	6,507	74,423	13,124	4,815
	ST6	1,025	25,630	13,459	15,028
	ST7	2,569	14,574	10,327	22,598
	평균 (범위)	9,378 (1,025~19,036)	69,038 (14,574~142,277)	71,032 (49,459~102,000)	27,380 (3,128~95,148)
영주댐	날짜	2024-06-12		2024-11-06	
	구분	추정값	관측값	추정값	관측값
	ST1	65,969	5,840	1,279	5,550
	ST2	65,350	3,128	1,253	4,331
	ST3	49,459	3,233	625	5,711
	ST4	102,000	31,738	9,695	32,896
	ST5	72,391	95,148	7,920	95,948
	ST6	구름으로 인해 제외	25,194	38,331	39,085
	평균 (범위)	7955 (2,741~13,459)	8,217 (1,394~22,598)	9,850 (625~38,331)	30,587 (4,331~95,948)



(a) 총조류 세포수(2024/08/29) (b) 총조류 세포수(2024/11/04)

(c) 총남조류 세포수(2024/08/29) (d) 총남조류 세포수(2024/11/04)

<그림 3.16> 대청댐 총조류 및 총남조류 세포수의 XGBoost 기반 원격 추정농도 시각화 결과



(a) 총조류 세포수(2024/06/12) (b) 총조류 세포수(2024/11/06)

(c) 총남조류 세포수(2024/06/12) (d) 총남조류 세포수((2024/11/06)

<그림 3.17> 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 원격 추정농도 시각화 결과

3.4 위성-기상-수문 연계 녹조 단기예측 알고리즘 개발

3.4.1 측정망 기반 단기예측 알고리즘 개발

가. 입력자료 구축 결과

2017~2023년 대청댐과 2019~2023년 영주댐의 위성 관측일을 기준으로 3, 5, 7일 후의 수질측정망 관측일 및 세포수 측정일을 매칭하고, 위성 반사도 값에 예측 예정 날짜의 Chl-a 농도 또는 총조류 세포수 자료를 입력하였다. Chl－a 농도 관측값은 3일 후 0.2~132.4 mg/m^3로 분포했으며, 5일 후는 0.7~84.4 mg/m^3, 7일 후는 0.0~76.9 mg/m^3으로 분포했다. 세포수의 관측값은 3일 후 284~122,688 cells/mL, 5일 후 104~275,277 cells/mL, 7일 후 186~337,305 cells/mL로 분포했다. 구름 등 기상을 고려하여 위성영상을 활용 가능한 날짜를 선정하였으며 위성-기상-수문을 연계한 예측 알고리즘 개발을 위해 기온, 수위, 유입량 등의 자료를 추가한 결과, 클로로필-a의 경우에는 3일 후 예측을 위한 분석 데이터 수는 58개, 5일 후는 97개, 7일 후는 57개로 구성하였다. 세포수의 경우에는 3일 후 예측을 위한 분석 데이터 수는 95개, 5일 후는 146개, 7일 후는 169개로 구성하였다.

<표 3.15> 측정망 자료 기반 3일 후 Chl-a 단기예측 알고리즘 분석 입력자료 현황

년도	3일 후 예측				
	대청댐		영주댐		데이터수 합계
	데이터수	Chl-a (mg/m^3)	데이터수	Chl-a (mg/m^3)	
2017	-	-	-	-	-
2018	8	7.2 (0.8~16.9)	-	-	8
2019	2	7.7 (5.3~10.1)	4	18.4 (5.8~33.4)	6
2020	3	7.9 (2.5~12.5)	12	23.3 (0.2~132.4)	15
2021	3	16.5 (3.4~15.4)	10	19.5 (1.5~97.1)	13
2022	4	3.9 (1.8~7.3)	4	38.3 (2.4~112.6)	8
2023	4	4.2 (3.3~4.6)	4	12.0 (3.7~18.9)	8
합계/평균	24	7.9	34	22.3	58

<표 3.16> 측정망 자료 기반 5일 후 Chl-a 단기예측 알고리즘 분석 입력자료 현황

년도	5일 후 예측				
	대청댐		영주댐		데이터수 합계
	데이터수	Chl-a (mg/m^3)	데이터수	Chl-a (mg/m^3)	
2017	10	3.9 (2.0~7.6)	-	-	10
2018	22	3.9 (0.9~19.9)	-	-	22
2019	10	4.4 (1.0~13.1)	8	10.7 (1.3~33.4)	18
2020	1	3.6	8	7.1 (1.4~17.4)	9
2021	8	4.4 (1.1~17.7)	8	30.6 (4.5~84.4)	16
2022	5	11.2 (0.7~24.0)	4	9.6 (3.6~26.1)	9
2023	7	7.2 (2.1~27.8)	6	6.8 (2.4~20.8)	13
합계/ 평균	63	5.5	34	13.0	97

<표 3.17> 측정망 자료 기반 7일 후 Chl-a 단기예측 알고리즘 분석 입력자료 현황

년도	7일 후 예측				
	대청댐		영주댐		데이터수 합계
	데이터수	Chl-a (mg/m^3)	데이터수	Chl-a (mg/m^3)	
2017	6	8.9 (6.1~18.3)	-	-	6
2018	2	7.8 (7.4~8.2)	-	-	2
2019	4	9.6 (5.9~16.3)	4	7.7 (1.8~40.7)	8
2020	10	7.2 (0.4~32.6)	7	5.0 (0.0~14.8)	17
2021	8	11.3 (0.4~76.9)	-	-	8
2022	4	4.5 (2.1~10.1)	-	-	4
2023	4	4.1 (2.4~8.3)	8	10.2 (1.7~31.0)	12
합계/ 평균	38	7.6	19	7.6	57

<표 3.18> 측정망 자료 기반 3일 후 세포수 단기예측 알고리즘 분석 입력자료 현황

년도	3일 후 예측				
	대청댐		영주댐		데이터수 합계
	데이터수	Cell number (cells/mL)	데이터수	Cell number (cells/mL)	
2017	-	-	-	-	-
2018	6	3,888 (556~12,532)	-	-	6
2019	9	4,187 (1,117~11,596)	4	7,211 (1,744~13,360)	13
2020	9	15,558 (978~86,362)	11	19,402 (284~59,238)	20
2021	6	3,534 (1,894~7,573)	6	11,476 (295~31,588)	12
2022	16	2,191 (535~4,708)	4	49,228 (4,749~122,688)	20
2023	12	1,838 (414~7,808)	12	11,955 (5,267~18,642)	24
합계/ 평균	58	5,199	37	19,854	95

<표 3.19> 측정망 자료 기반 5일 후 세포수 단기예측 알고리즘 분석 입력자료 현황

년도	5일 후 예측				
	대청댐		영주댐		데이터수 합계
	데이터수	Cell number (cells/mL)	데이터수	Cell number (cells/mL)	
2017	3	895 (487~1,327)	-	-	3
2018	18	2,120 (296~9,416)	-	-	18
2019	22	5,269 (372~28,007)	10	12,645 (412~41,997)	32
2020	3	2,094 (1,240~3,041)	12	11,789 (1,058~26,514)	15
2021	18	3,963 (265~15,194)	13	35,965 (104~275,277)	31
2022	18	6,087 (948~19,000)	10	15,897 (927~42,277)	28
2023	4	794 (482~1,223)	15	5,221 (421~23,485)	19
합계/ 평균	86	3,032	60	16,303	146

<표 3.20> 측정망 자료 기반 7일 후 세포수 단기예측 알고리즘 분석 입력자료 현황

년도	7일 후 예측				
	대청댐		영주댐		데이터수 합계
	데이터수	Cell number (cells/mL)	데이터수	Cell number (cells/mL)	
2017	4	12,288 (4,945~19,672)	-	-	4
2018	6	3,776 (1,930~6,662)	-	-	6
2019	21	11,814 (401~63,275)	8	46,417 (996~142,770)	29
2020	27	3,024 (186~33,486)	19	25,370 (400~200,404)	46
2021	18	16,477 (601~169,651)	8	11,715 (880~27,611)	26
2022	12	5,017 (997~12,110)	14	19,635 (1,475~81,895)	26
2023	17	1,162 (250~4,406)	15	35,880 (226~337,305)	32
합계/ 평균	105	7,651	64	27,803	169

나. 앙상블 기법 적용 결과

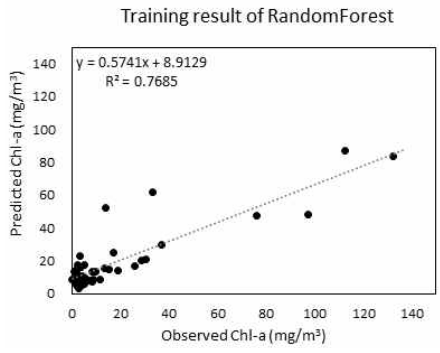
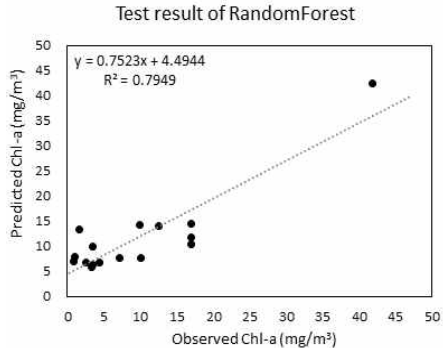
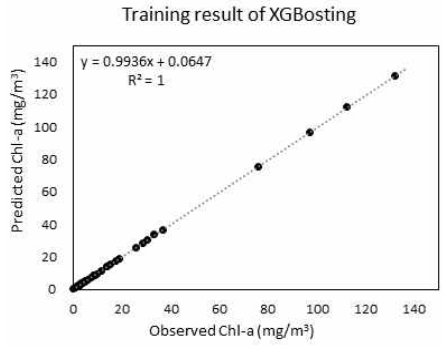
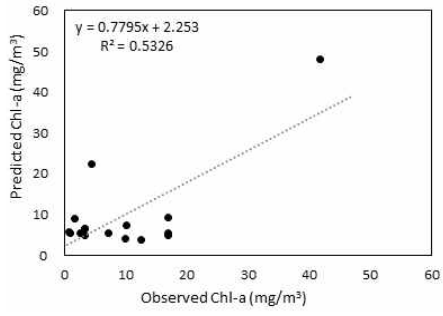
위성영상, 수문 및 기상자료를 연계하여 3일, 5일, 7일 후 단기 Chl-a 및 세포수(총조류, 남조류) 예측 알고리즘 분석 DB 구축 후, 독립변수 조합을 통해 정확도 높은 독립변수 조합을 선정하였다. 국내외 논문, 보고서 등에서 검토한 결과를 바탕으로 총 4개 독립변수 조합 Case를 설정하여 비교하였으며 독립변수로 활용한 항목은 Sentinel-2 13개 밴드별 반사도값, 밴드 4, 5, 6 반사도값을 조합하여 생성한 파생변수(B1), 예측 기간을 고려하여 일별 평균 기온, 일 유입량, 일 평균 수위를 활용하였다. 적용한 앙상블 기법은 랜덤포레스트와 XGBoost를 적용하여 검증(Test)결과를 기준으로 가장 정확도 높은 모델을 선정하였다. 알고리즘 분석은 데이터 세트를 랜덤으로 구분하여 70%를 학습 자료로 나머지 30%를 검증 자료를 활용하였으며 측정망 자료를 활용한 경우 충분한 데이터세트 확보가 어렵기 때문에, 여러 번의 랜덤 데이터 구분 과정을 통해 최적의 알고리즘 성능을 도출하고자 하였다. 3일 후 Chl-a 예측 알고리즘 분석 결과, Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용하여 랜덤포레스트 적용시 가장 우수한 성능을 나타내었으며, 학습 결과의 경우에는 R^2은 0.77, RMSE값은 16.4 mg/m^3이었으며 검증 결과의 경우에는 R^2은 0.79, RMSE값은 6.0 mg/m^3으로 분석되었다. Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용하여 XGBoost 적용시 학습 결과의 경우에는 R^2은 0.99, RMSE값은 0.2 mg/m^3이었으나 검증 결과의 경우에는 R^2은 0.53, RMSE값은 24.3 mg/m^3으로 검증 결과에서 랜덤포레스트 기법보다 낮게 분석되었다. 5일 후 Chl-a 예측 알고리즘 분석 결과, Sentinel-2 밴드별 반사도값과 밴드 4, 5, 6을 활용한 파생

변수, 일평균 기온, 일 유입량, 일 수위를 활용하여 XGBoost 적용한 경우와 Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용하여 랜덤포레스트 적용시 우수한 성능을 나타내었다. XGBoot 적용시 학습 결과의 경우에는 R^2은 0.99, RMSE값은 0.2 mg/m^3이었으며 검증 결과의 경우에는 R^2은 0.84, RMSE값은 5.1 mg/m^3으로 분석되었다. 그리고 Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용하여 랜덤포레스드 적용시 학습 결과의 경우에는 R^2은 0.76, RMSE값은 6.9 mg/m^3이었으나 검증 결과의 경우에는 R^2은 0.76, RMSE값은 5.6 mg/m^3으로 5일 후 예측 알고리즘은 랜덤포레스트와 XGBoost 기법 성능이 유사하게 나타났다. 7일 후 Chl-a 예측 알고리즘 분석 결과, Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용하여 랜덤포레스트 적용시 가장 우수한 성능을 나타내었으며, 학습 결과의 경우에는 R^2은 0.94, RMSE값은 5.4 mg/m^3이었으며 검증 결과의 경우에는 R^2은 0.78, RMSE값은 2.8 mg/m^3으로 분석되었다. Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용하여 XGBoost 적용시 학습 결과의 경우에는 R^2은 0.99, RMSE값은 0.2 mg/m^3이었으나 검증 결과의 경우에는 R^2은 0.33, RMSE값은 6.1 mg/m^3으로 검증 결과에서 랜덤포레스트 기법보다 낮게 분석되었다. 3, 5, 7일 후 예측 알고리즘은 예측 기간별로 다소 차이는 있었으나 위성 밴드별 반사도값과 기온을 활용하여 랜덤포레스트 기법을 적용한 경우의 모델 성능이 가장 좋은 것으로 분석되었다.

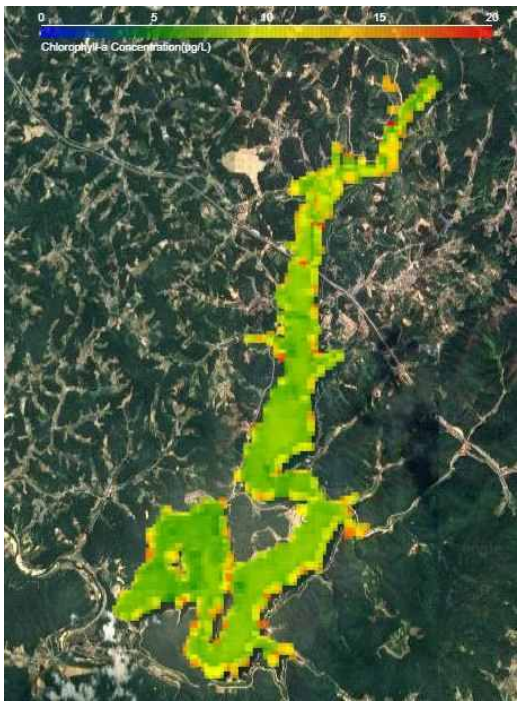
<표 3.21> 3일 후 Chl-a 예측 앙상블 기법 적용 결과

Case	독립변수	구분	통계값	RandomForest	XGBoost
Case1	Band1~12, B1*, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.70	0.99
			RMSE(mg/m^3)	14.5	0.2
		Test	R^2	0.51	0.48
			RMSE(mg/m^3)	18.2	19.1
Case2	Band1~12, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.70	0.99
			RMSE(mg/m^3)	16.4	0.2
		Test	R^2	0.48	0.28
			RMSE(mg/m^3)	7.4	22.3
Case3	Band4~7, B1*, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.70	0.99
			RMSE(mg/m^3)	14.3	0.3
		Test	R^2	0.40	0.39
			RMSE(mg/m^3)	21.0	9.0
Case4	Band1~12, 기온 0~3일,	Training	R^2	0.77	0.99
			RMSE(mg/m^3)	16.4	0.2
		Test	R^2	0.79	0.53
			RMSE(mg/m^3)	6.0	24.3

* B1: Band5 - (Band4 + Band6) / 2

구분	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.18> Chl-a 3일 후 예측을 위한 Case4 앙상블기법 Training 및 Test 결과



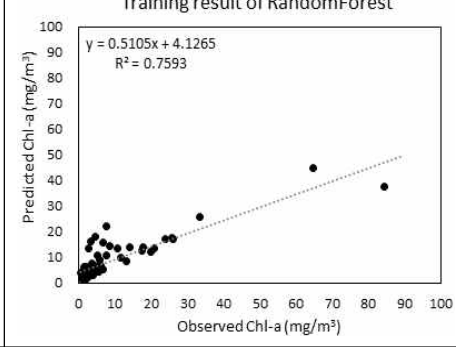
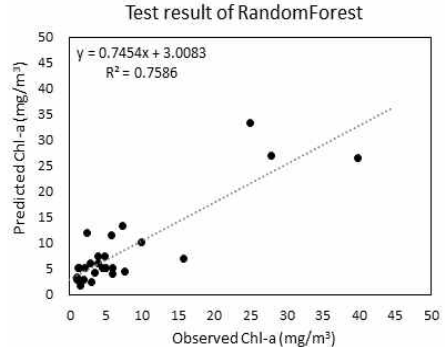
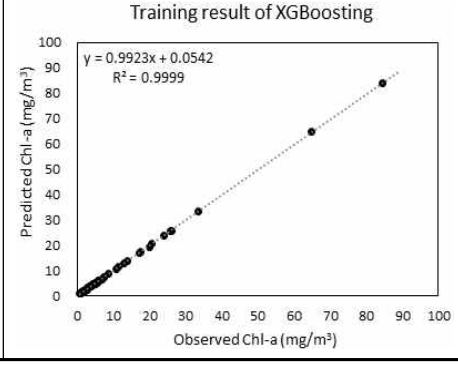
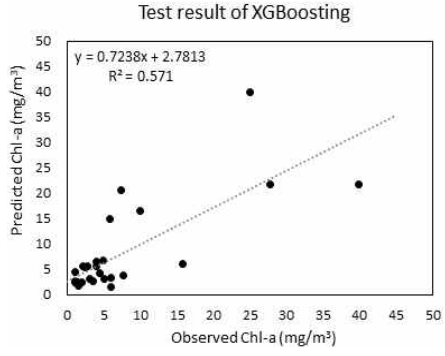
(a) 2024/05/16

<그림 3.19> 영주댐 Chl-a의 랜덤포레스트 기반 2024년 3일 후 원격 추정농도 시각화 결과

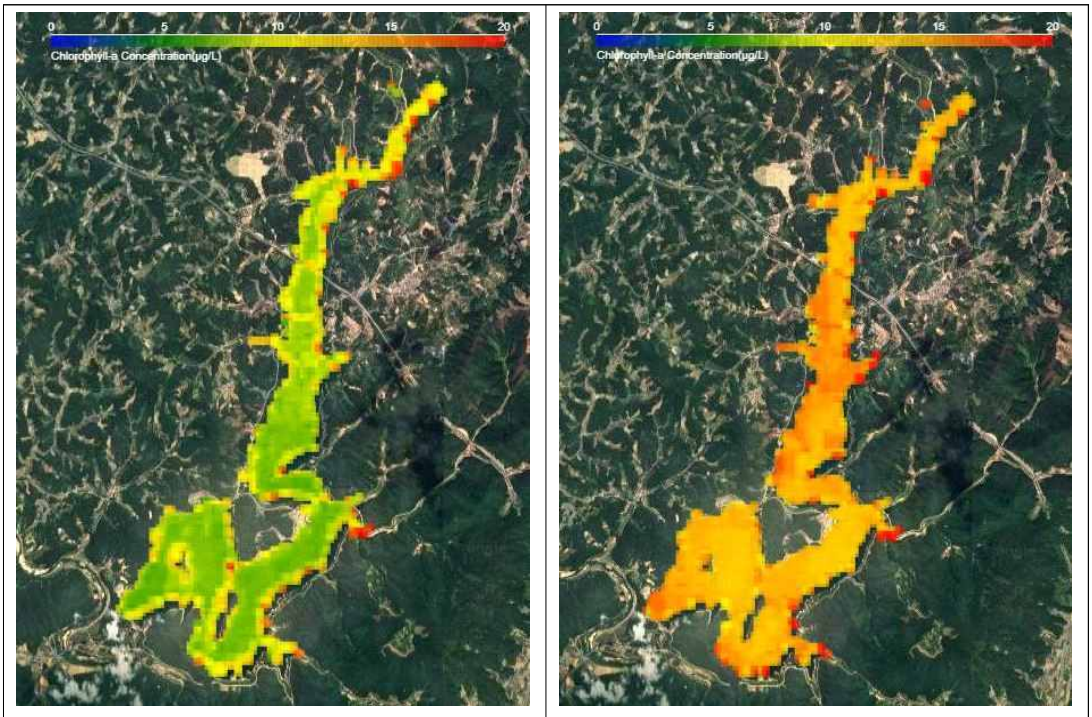
<표 3.22> 5일 후 Chl-a 예측 앙상블 기법 적용 결과

Case	독립변수	구분	통계값	RandomForest	XGBoost
Case1	Band1~12, B1*, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.71	0.99
			RMSE(mg/m^3)	7.2	0.2
		Test	R^2	0.58	0.80
			RMSE(mg/m^3)	5.9	5.9
Case2	Band1~12, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.72	0.99
			RMSE(mg/m^3)	6.3	0.2
		Test	R^2	0.55	0.84
			RMSE(mg/m^3)	8.9	5.1
Case3	Band4~7, B1*, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.72	0.99
			RMSE(mg/m^3)	7.0	0.2
		Test	R^2	0.44	0.70
			RMSE(mg/m^3)	7.0	6.9
Case4	Band1~12, 기온 0~5일,	Training	R^2	0.76	0.99
			RMSE(mg/m^3)	6.9	0.2
		Test	R^2	0.76	0.57
			RMSE(mg/m^3)	5.6	6.3

* B1: Band5 - (Band4 + Band6) / 2

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.20> Chl-a 5일 후 예측을 위한 Case4 앙상블기법 Training 및 Test 결과



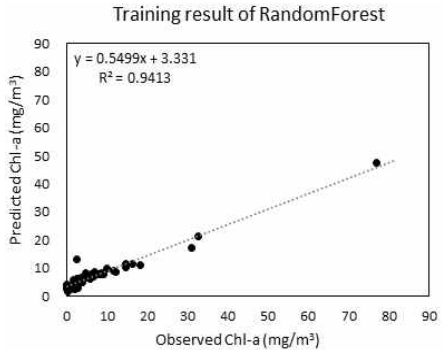
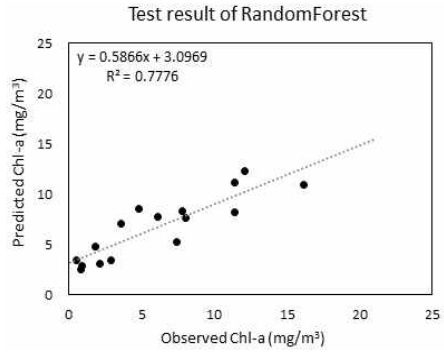
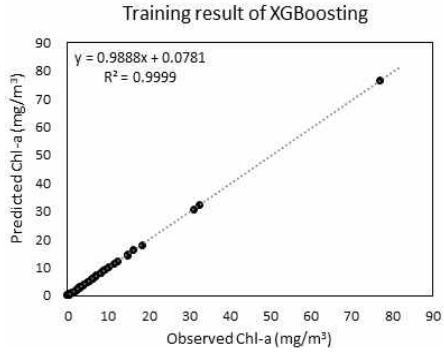
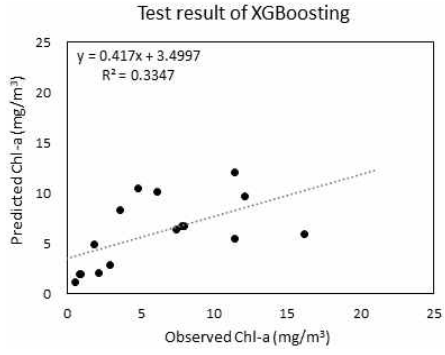
(a) 2024/05/23 (b) 2024/06/17

<그림 3.21> 영주댐 Chl-a의 랜덤포레스트 기반 2024년 5일 후 원격 추정농도 시각화 결과

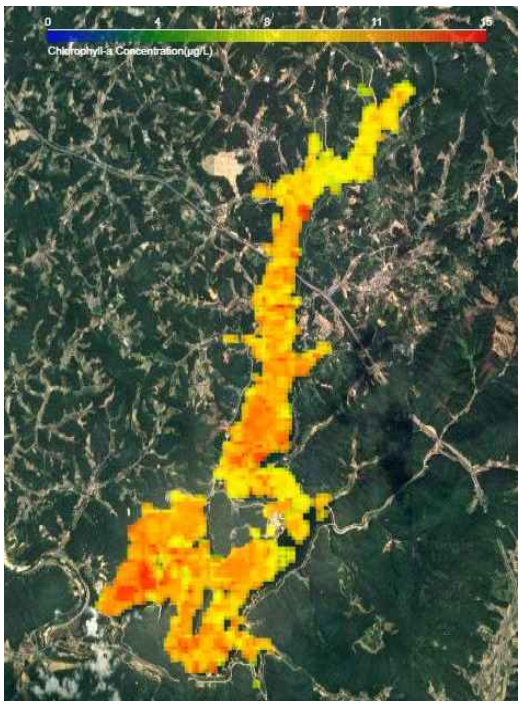
<표 3.23> 7일 후 Chl-a 예측 앙상블 기법 적용 결과

Case	독립변수	구분	통계값	RandomForest	XGBoost
Case1	Band1~12, B1*, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.71	0.99
			RMSE(mg/m^3)	7.1	0.2
		Test	R^2	0.46	0.54
			RMSE(mg/m^3)	3.5	3.3
Case2	Band1~12, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.72	0.99
			RMSE(mg/m^3)	6.9	0.2
		Test	R^2	0.45	0.49
			RMSE(mg/m^3)	3.5	3.6
Case3	Band4~7, B1*, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.72	0.99
			RMSE(mg/m^3)	6.9	0.2
		Test	R^2	0.42	0.45
			RMSE(mg/m^3)	3.5	5.6
Case4	Band1~12, 기온 0~7일,	Training	R^2	0.94	0.99
			RMSE(mg/m^3)	5.4	0.2
		Test	R^2	0.78	0.33
			RMSE(mg/m^3)	2.8	6.1

* B1: Band5 - (Band4 + Band6) / 2

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.22> Chl-a 7일 후 예측을 위한 Case4 앙상블기법 Training 및 Test 결과



(a) 2024/08/26

<그림 3.23> 영주댐 Chl-a의 랜덤포레스트 기반 2024년 7일 후 원격 추정농도 시각화 결과

3일 후 세포수 예측 알고리즘 분석 결과, 랜덤포레스트 적용시에는 Sentinel-2 밴드별 반사도값과 일평균 기온을 독립변수로 활용한 경우에 가장 우수한 성능을 나타내었으며, 총조류 세포수 예측시에는 학습 결과의 경우에 R^2은 0.68, RMSE값은 11,977 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.56, RMSE값은 5,400 cells/mL으로 분석되었다. 그리고 총남조류 세포수 예측시에는 R^2은 0.68, RMSE값은 10,434 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.84, RMSE값은 1,842 cells/mL으로 분석되었다. XGBoost 적용시에는 밴드별 반사도값, 파생변수, 기온, 유입량 및 수위자료를 활용한 경우에 가장 우수한 성능을 나타내었으며, 총조류 세포수 예측시에는 학습 결과의 경우에 R^2은 0.99, RMSE값은 121 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.79, RMSE값은 9,380 cells/mL으로 분석되었다. 그리고 총남조류 세포수 예측시에는 R^2은 0.99, RMSE값은 120 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.89, RMSE값은 3,788 cells/mL으로 분석되어 두 기법 모두 총조류 세포수 보다 총남조류 세포수 예측시 정확도가 더 높게 분석되었다.

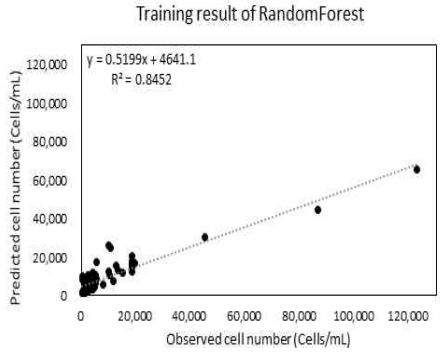
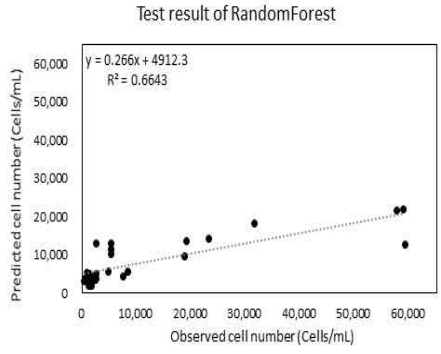
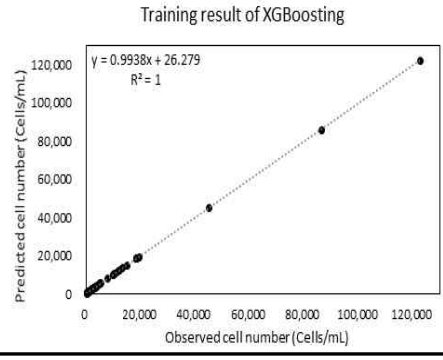
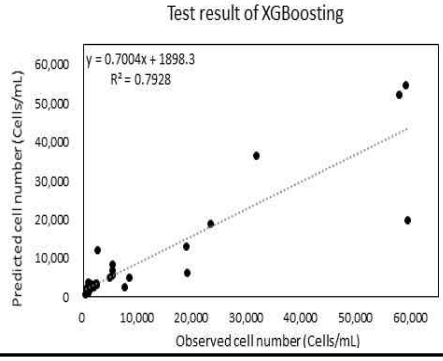
5일 후 세포수 예측 알고리즘 분석 결과, 총조류 및 총남조류 세포수 모두 밴드별 반사도값, 밴드 파생변수, 기온, 유입량 및 수위자료를 모두 활용한 경우에 모델 성능이 우수하게 나타났으며 랜덤포레스트보다는 XGBoost 기법의 성능이 다소 높은 것으로 분석되었다. 랜덤포레스트 적용시에는 총조류 세포수 예측시에는 학습 결과의 경우에 R^2은 0.90, RMSE값은 14,336 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.74, RMSE값은 6,737 cells/mL으로 분석되었다. 그리고 총남조류 세포수 예측시에는 R^2은 0.51, RMSE값은 16,047 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.52, RMSE값은 4,213 cells/mL으로 분석되었다. XGBoost 적용시에는 총조류 세포수 예측시에는 학습 결과의 경우에 R^2은 0.99, RMSE값은 193 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.77, RMSE값은 5,146 cells/mL으로 분석되었다. 그리고 총남조류 세포수 예측시에는 R^2은 0.99, RMSE값은 182 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.67, RMSE값은 2,807 cells/mL으로 분석되어 두 기법 모두 총조류 세포수 보다 총남조류 세포수 예측시 정확도가 더 높게 분석되었다.

7일 후 세포수 예측 알고리즘 분석 결과, 적용 기법이나 독립변수에 따른 모델성능의 차이가 3일 및 5일 후 예측 모델에 비해 차이가 크지 않았다. 5일 후 예측모델과 마찬가지로 총조류 및 총남조류 세포수 모두 밴드별 반사도값, 밴드 파생변수, 기온, 유입량 및 수위자료를 모두 활용한 경우에 모델 성능이 우수하게 나타났으며 랜덤포레스트보다는 XGBoost 기법의 성능이 다소 높은 것으로 분석되었다. XGBoost 적용시에는 총조류 세포수 예측시에는 학습 결과의 경우에 R^2은 0.99, RMSE값은 257 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.73, RMSE값은 22,428 cells/mL으로 분석되었다. 그리고 총남조류 세포수 예측시에는 R^2은 0.99, RMSE값은 239 cells/mL이었으며 검증 결과의 경우에는 R^2은 0.65, RMSE값은 19,371 cells/mL으로 분석되었으며 3일 예측 및 5일 후 예측 모델에 비해 성능이 다소 낮아지는 것으로 분석되었다.

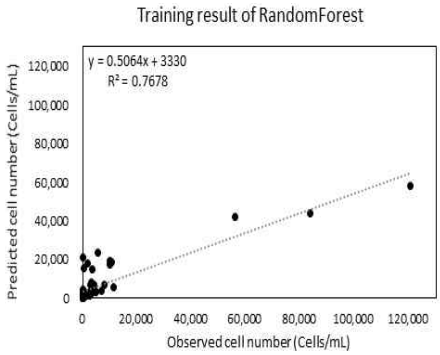
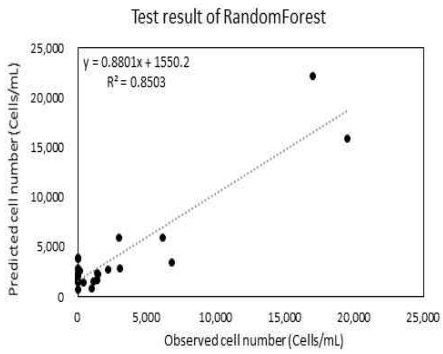
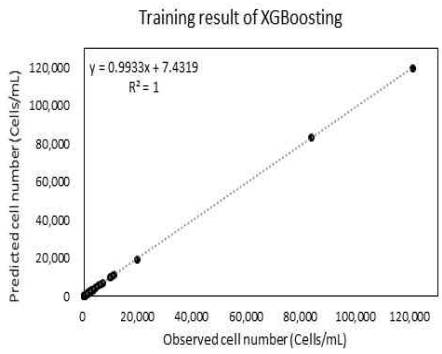
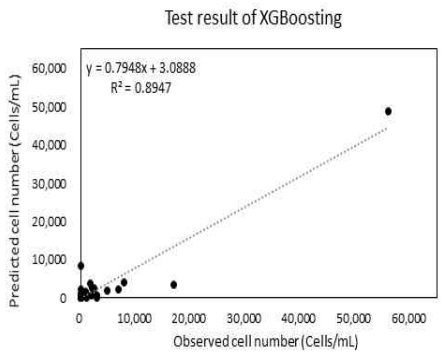
<표 3.24> 3일 후 총조류 및 남조류 세포수 예측 앙상블 기법 적용 결과

Case		독립변수	구분	통계값	RandomForest	XGBoost
총조류 세포수	Case 1-1	Band1~12, B1*, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.85	0.99
				RMSE(mg/m^3)	10,466	121
			Test	R^2	0.66	0.79
				RMSE(mg/m^3)	4,351	9,380
	Case 1-2	Band1~12, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.68	0.99
				RMSE(mg/m^3)	11,970	79
			Test	R^2	0.54	0.28
				RMSE(mg/m^3)	4,602	19,730
	Case 1-3	Band1~12, 기온 0~3일	Training	R^2	0.68	0.99
				RMSE(mg/m^3)	11,977	116
			Test	R^2	0.56	0.42
				RMSE(mg/m^3)	5,400	8,696
총남조류 세포수	Case 2-1	Band1~12, B1*, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.77	0.99
				RMSE(mg/m^3)	10,488	120
			Test	R^2	0.85	0.89
				RMSE(mg/m^3)	2,249	3,788
	Case 2-2	Band1~12, 기온 0~3일, 유입량 0~3일, 수위 0~3일	Training	R^2	0.67	0.99
				RMSE(mg/m^3)	10,576	121
			Test	R^2	0.72	0.79
				RMSE(mg/m^3)	2,555	1,586
	Case 2-3	Band1~12, 기온 0~3일	Training	R^2	0.68	0.99
				RMSE(mg/m^3)	10,434	120
			Test	R^2	0.84	0.92
				RMSE(mg/m^3)	1,842	3,002

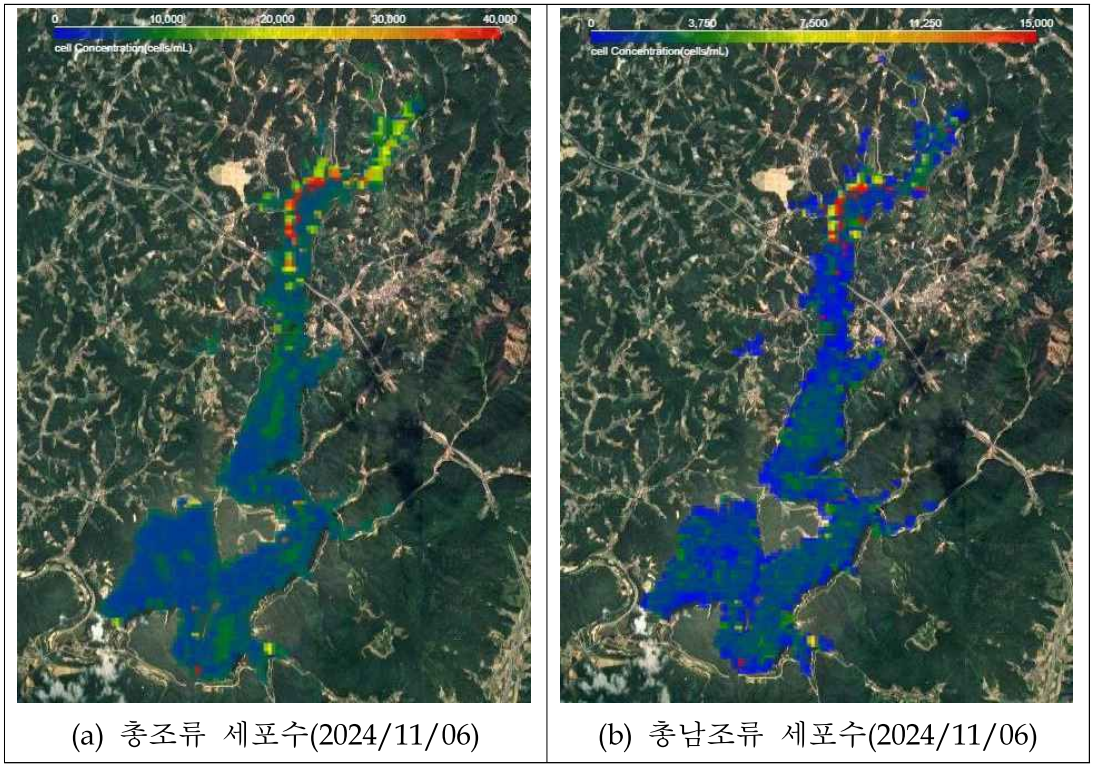
* B1: Band5 - (Band4 + Band6) / 2

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.24> 3일 후 총조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.25> 3일 후 남조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과



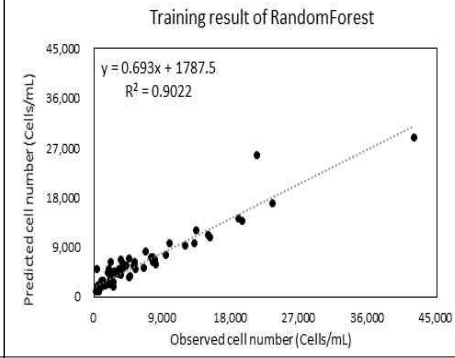
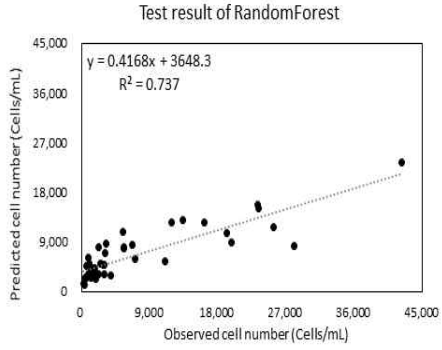
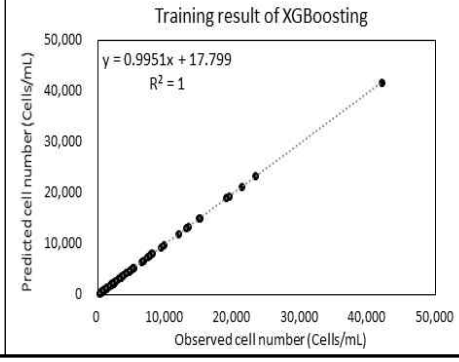
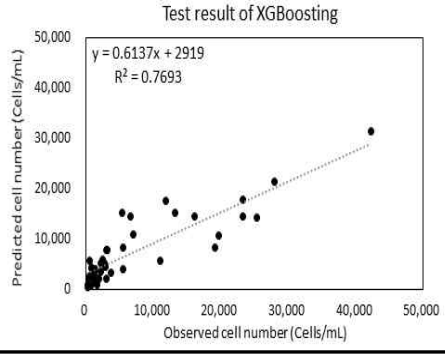
(a) 총조류 세포수(2024/11/06) (b) 총남조류 세포수(2024/11/06)

<그림 3.26> 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 3일 후 원격 추정농도 시각화 결과

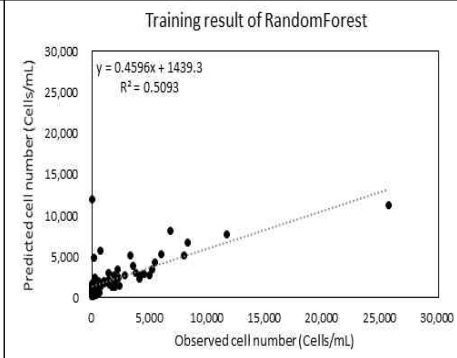
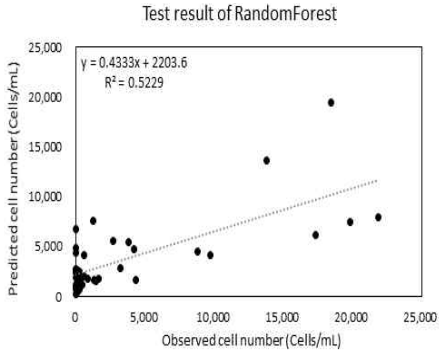
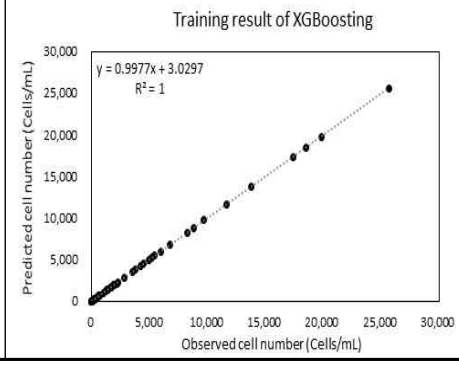
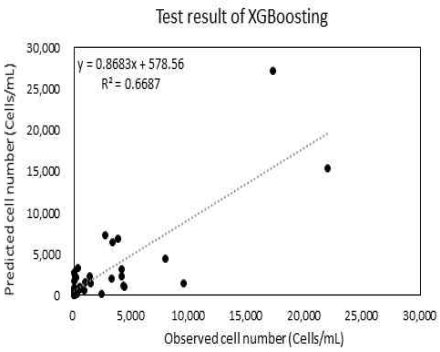
<표 3.25> 5일 후 총조류 및 남조류 세포수 예측 앙상블 기법 적용 결과

Case		독립변수	구분	통계값	RandomForest	XGBoost
총조류 세포수	Case 1-1	Band1~12, B1*, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.90	0.99
				RMSE(mg/m^3)	14,336	193
			Test	R^2	0.74	0.77
				RMSE(mg/m^3)	6,737	5,146
	Case 1-2	Band1~12, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.77	0.99
				RMSE(mg/m^3)	13,720	196
			Test	R^2	0.72	0.66
				RMSE(mg/m^3)	4,469	5,498
	Case 1-3	Band1~12, 기온 0~5일	Training	R^2	0.73	0.99
				RMSE(mg/m^3)	14,354	60
			Test	R^2	0.68	0.46
				RMSE(mg/m^3)	7,786	30,514
총남조류 세포수	Case 2-1	Band1~12, B1*, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.51	0.99
				RMSE(mg/m^3)	16,047	182
			Test	R^2	0.52	0.67
				RMSE(mg/m^3)	4,213	2,807
	Case 2-2	Band1~12, 기온 0~5일, 유입량 0~5일, 수위 0~5일	Training	R^2	0.66	0.99
				RMSE(mg/m^3)	15,859	183
			Test	R^2	0.51	0.51
				RMSE(mg/m^3)	3,458	4,023
	Case 2-3	Band1~12, 기온 0~5일	Training	R^2	0.67	1.00
				RMSE(mg/m^3)	15,769	182
			Test	R^2	0.51	0.46
				RMSE(mg/m^3)	3,304	4,214

* B1: Band5 - (Band4 + Band6) / 2

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.27> 5일 후 총조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과

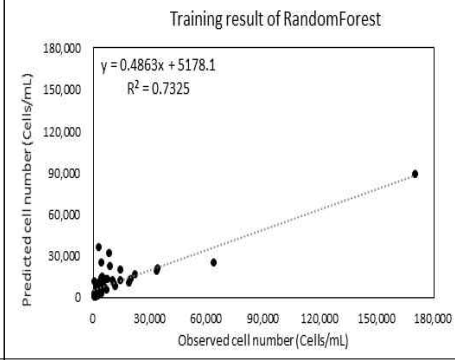
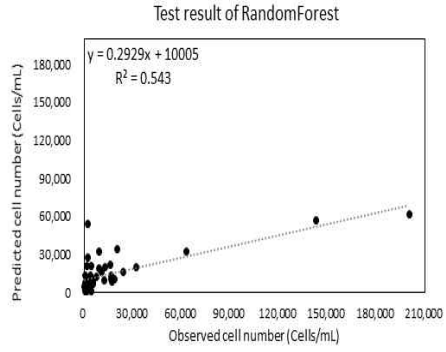
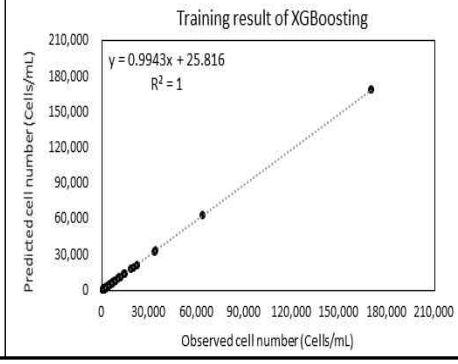
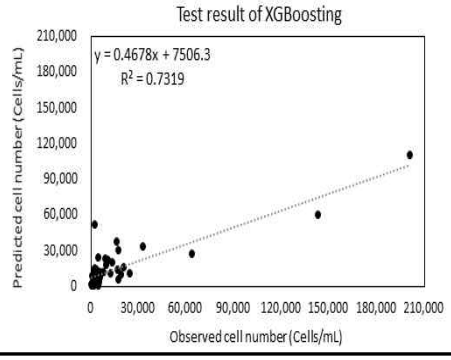
기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.28> 5일 후 남조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과

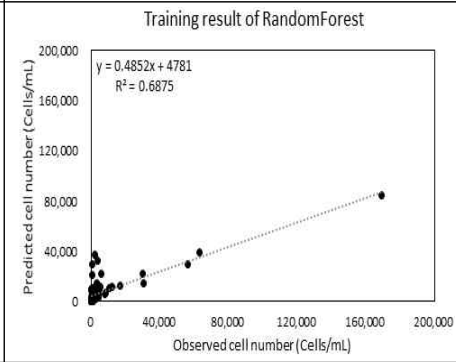
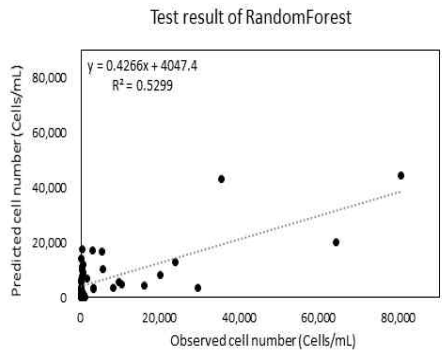
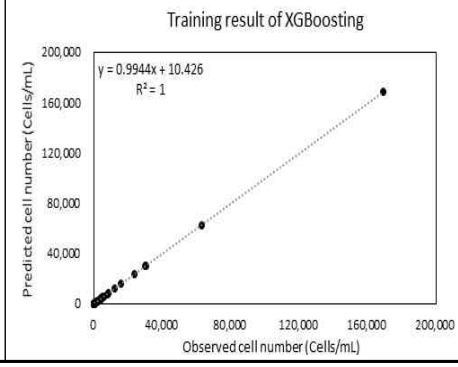
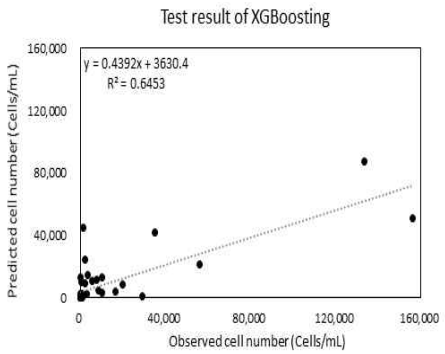
<표 3.26> 7일 후 총조류 및 남조류 세포수 예측 앙상블 기법 적용 결과

Case		독립변수	구분	통계값	RandomForest	XGBoost
총조류 세포수	Case 1-1	Band1~12, B1*, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.73	0.99
				RMSE(mg/m^3)	25,508	257
			Test	R^2	0.54	0.73
				RMSE(mg/m^3)	11,742	22,428
	Case 1-2	Band1~12, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.65	0.99
				RMSE(mg/m^3)	25,627	256
			Test	R^2	0.60	0.63
				RMSE(mg/m^3)	10,011	8,946
	Case 1-3	Band1~12, 기온 0~7일	Training	R^2	0.71	0.99
				RMSE(mg/m^3)	23473	266
			Test	R^2	0.60	0.47
				RMSE(mg/m^3)	10,544	20,103
총남조류 세포수	Case 2-1	Band1~12, B1*, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.69	0.99
				RMSE(mg/m^3)	25,149	239
			Test	R^2	0.53	0.65
				RMSE(mg/m^3)	11,020	19,371
	Case 2-2	Band1~12, 기온 0~7일, 유입량 0~7일, 수위 0~7일	Training	R^2	0.65	0.99
				RMSE(mg/m^3)	25,191	251
			Test	R^2	0.44	0.39
				RMSE(mg/m^3)	15,281	17,548
	Case 2-3	Band1~12, 기온 0~7일	Training	R^2	0.71	0.99
				RMSE(mg/m^3)	23,432	258
			Test	R^2	0.47	0.59
				RMSE(mg/m^3)	11,065	14,484

* B1: Band5 - (Band4 + Band6) / 2

기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.29> 7일 후 총조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과

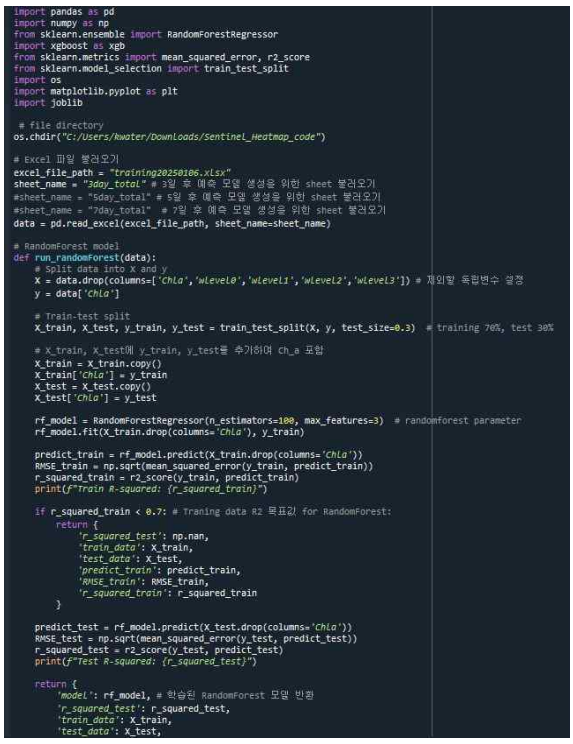
기법	학습결과	검증 결과
Random Forest		
XGBoost		

<그림 3.30> 7일 후 남조류 세포수 예측을 위한 머신러닝 Training 및 Test 결과

<표 3.27> 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 7일 후 원격 추정값과 관측값 검증 결과

2024년	영주댐					
	총조류 세포수			남조류 세포수		
	날짜	추정값	관측값	날짜	추정값	관측값
08/26	Site 1.	208,738	196,086	Site 1.	231,990	194,131
	Site 2.	290,388	302,214	Site 2.	231,379	299,985
	Site 3.	22,563	254,978	Site 3.	50,245	254,323
	Site 4.	107,926	259,407	Site 4.	118,513	256,118
	Site 5.	254,053	869,190	Site 5.	142,309	867,093
	Site 6.	-	29,660	Site 6.	-	13,196
11/06	Site 1.	5,873	6,620	Site 1.	2,607	5,550
	Site 2.	11,172	4,745	Site 2.	4,519	4,331
	Site 3.	9,845	7,790	Site 3.	10,670	5,711
	Site 4.	17,539	34,169	Site 4.	8,220	32,896
	Site 5.	14,790	97,789	Site 5.	12,050	95,948
	Site 6.	-	40,232	Site 6.	-	39,085

본 연구에서 개발한 알고리즘은 파이썬 코드를 활용하였으며 위성영상 반사도와 기온, 유입량을 앙상블기법(RandomForest, XGBoost) 기반으로 최적 성능을 나타내는 모델을 생성하고, 생성한 모델을 활용하여 공간적 녹조 예측결과 시각화를 지원할 수 있다. 주요 기능으로는 첫 번째로, 위경도별로 위성영상 밴드별 반사도값과 예측하고자 하는 기간의 일별 기온, 댐 유입량을 RandomForest, XGBoost의 최적 성능을 나타내는 모델을 생성하기 위한 Training, Test 데이터 구분 및 파일을 저장할 수 있다. 또한, 최적 성능을 나타내는 모델을 저장, 관측 및 예측값 비교 그림 표출할 수 있다. 그리고, 저장된 모델을 활용하여 공간적 녹조 변화를 예측, 결과 시각화 및 파일로 저장할 수 있다. 사용 방법은 1) 단기예측 모델 생성을 위한 입력자료 구성, 2) 파이썬 코드 실행을 위한 라이브러리 설치하기, 3) 파이썬 코드 내 실행 디렉토리, 입력파일 및 sheet명 설정한 후에 실행하여 모델 생성, 4) 사용하고자 하는 모델명을 입력하여 예측결과 시각화를 위한 파일 및 sheet명 선택, 5) 예측결과 데이터 및 그림파일 저장하기의 과정으로 수행될 수 있다.



```python
import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestRegressor
import xgboost as xgb
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.model_selection import train_test_split
import os
import matplotlib.pyplot as plt
import joblib

 # file directory
os.chdir("C:/Users/Kwater/Downloads/Sentinel_Heatmap_code")

# Excel 파일 불러오기
excel_file_path = "training20250106.xlsx"
sheet_name = "3day_total" # 3일 후 예측 모델 생성을 위한 sheet 불러오기
#sheet_name = "5day_total" # 5일 후 예측 모델 생성을 위한 sheet 불러오기
#sheet_name = "7day_total"  # 7일 후 예측 모델 생성을 위한 sheet 불러오기
data = pd.read_excel(excel_file_path, sheet_name=sheet_name)

# RandomForest model
def run_randomForest(data):
    # Split data into X and y
    X = data.drop(columns=['Chla','wlevel0','wlevel1','wlevel2','wlevel3']) # 제외할 독립변수 설정
    y = data['Chla']

    # Train-test split
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)  # training 70%, test 30%

    # X_train, X_test에 y_train, y_test를 추가하여 Ch_a 포함
    X_train = X_train.copy()
    X_train['Chla'] = y_train
    X_test = X_test.copy()
    X_test['Chla'] = y_test

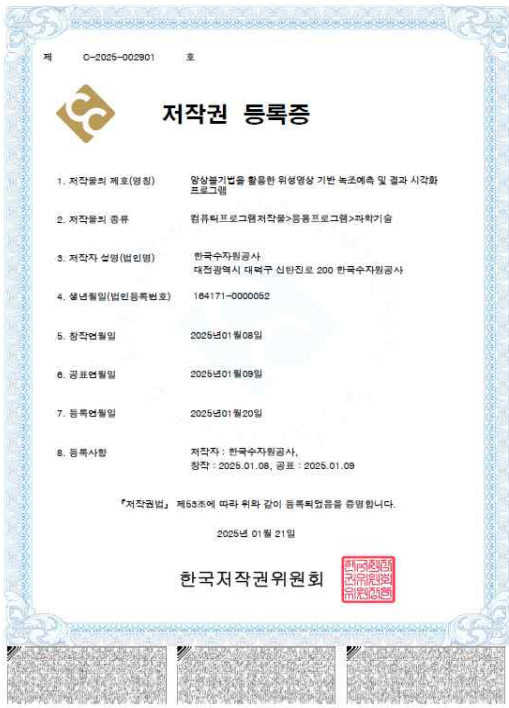
    rf_model = RandomForestRegressor(n_estimators=100, max_features=3)  # randomforest parameter
    rf_model.fit(X_train.drop(columns='Chla'), y_train)

    predict_train = rf_model.predict(X_train.drop(columns='Chla'))
    RMSE_train = np.sqrt(mean_squared_error(y_train, predict_train))
    r_squared_train = r2_score(y_train, predict_train)
    print(f"Train R-squared: {r_squared_train}")

    if r_squared_train < 0.7: # Traning data R2 목표값 for RandomForest:
        return {
            'r_squared_test': np.nan,
            'train_data': X_train,
            'test_data': X_test,
            'predict_train': predict_train,
            'RMSE_train': RMSE_train,
            'r_squared_train': r_squared_train
        }

    predict_test = rf_model.predict(X_test.drop(columns='Chla'))
    RMSE_test = np.sqrt(mean_squared_error(y_test, predict_test))
    r_squared_test = r2_score(y_test, predict_test)
    print(f"Test R-squared: {r_squared_test}")

    return {
        'model': rf_model, # 학습된 RandomForest 모델 반환
        'r_squared_test': r_squared_test,
        'train_data': X_train,
        'test_data': X_test,
```



제 C-2025-002901 호

저작권 등록증

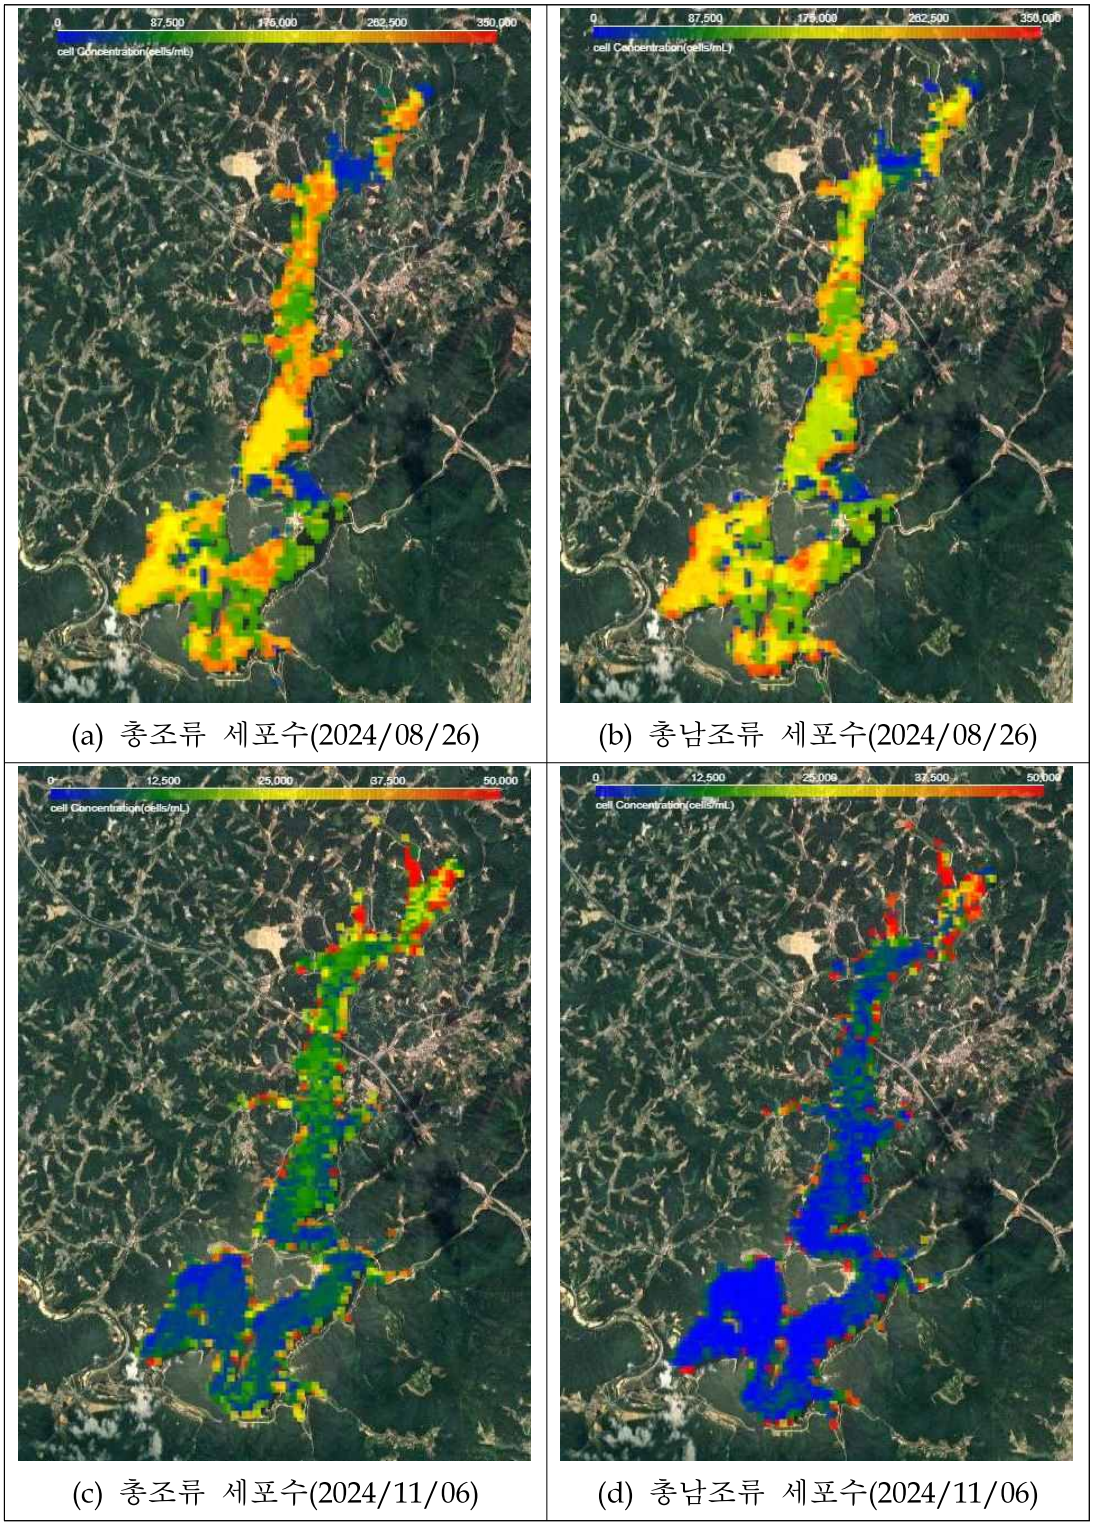
1. 저작물의 제호(명칭)	앙상블기법을 활용한 위성영상 기반 녹조예측 및 결과 시각화 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>응용프로그램>자학기술
3. 저작자 성명(법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사
4. 생년월일(법인등록번호)	184171-0000052
5. 창작연월일	2025년01월08일
6. 공표연월일	2025년01월09일
7. 등록연월일	2025년01월20일
8. 등록사항	저작자 : 한국수자원공사, 창작 : 2025.01.08, 공표 : 2025.01.09

「저작권법」 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2025년 01월 21일

한국저작권위원회

<그림 3.31> 위성영상-기상-수문 연계 Chl-a 단기 예측 앙상블 알고리즘 및 S/W등록증



(a) 총조류 세포수(2024/08/26)

(b) 총남조류 세포수(2024/08/26)

(c) 총조류 세포수(2024/11/06)

(d) 총남조류 세포수(2024/11/06)

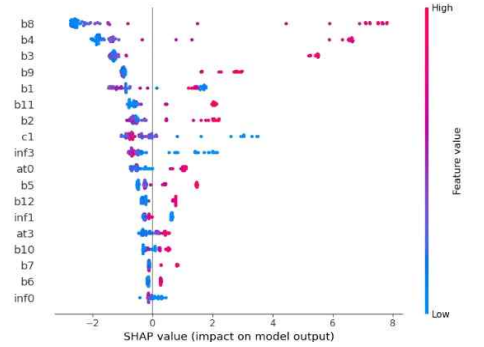
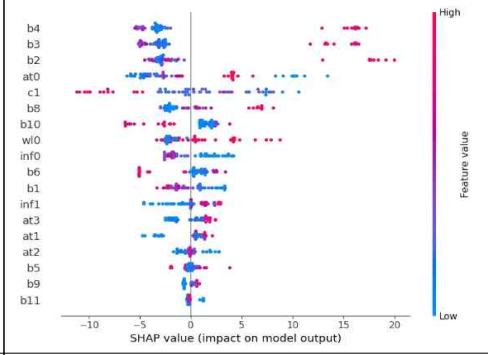
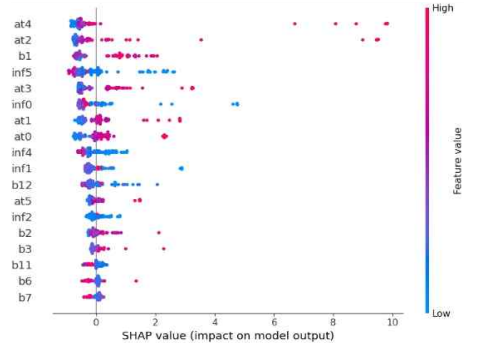
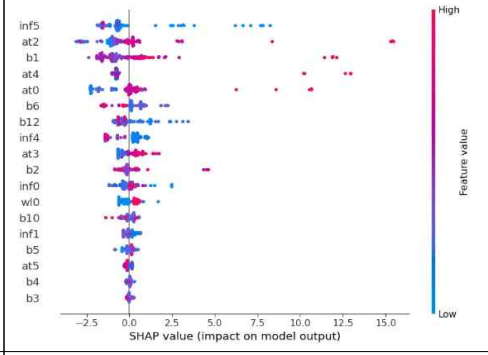
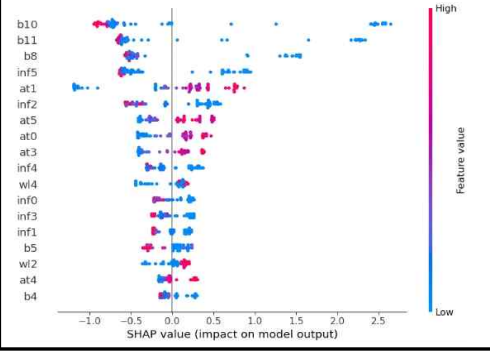
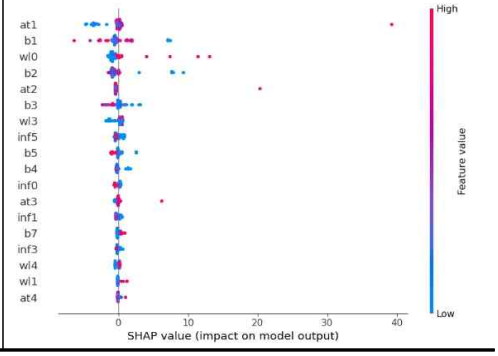
<그림 3.32> 영주댐 총조류 및 총남조류 세포수의 XGBoost 기반 7일 후 원격 추정농도 시각화 결과

다. 주요 입력변수 분석결과

1) Chl-a 단기예측모델 설명력 분석결과

앙상블 기법을 적용하여 위성영상 밴드별 반사도값, 수문 및 기상자료를 연계하여 분석한 공간적 Chl-a 예측 모델의 설명력을 설명가능한 AI를 활용하여 분석하였다. SHAP(SHapley Additive exPlanations) 기법을 활용하여 랜덤포레스트 및 XGBoost 적용시 입력변수별 중요도를 분석한 결과, 앙상블 기법별로 차이는 있었으나 3일 후 예측 모델에서는 위성영상 반사도값의 중요도가 크게 나타났으며 5일 후 예측 모델에서는 기온의 중요도가 커지는 것으로 분석되었고, 7일 후 예측 모델에서는 위성영상 반사도값, 기온 및 유입량 각 입력변수의 중요도가 유사한 것으로 분석되었다.

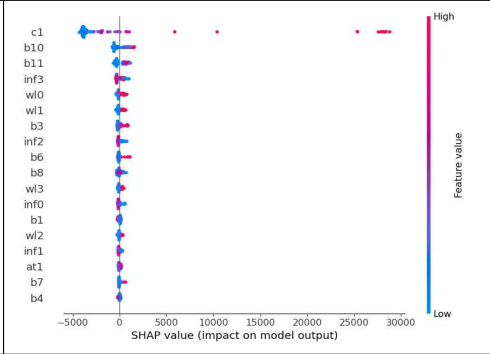
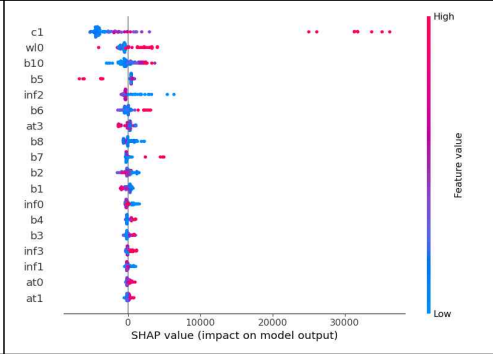
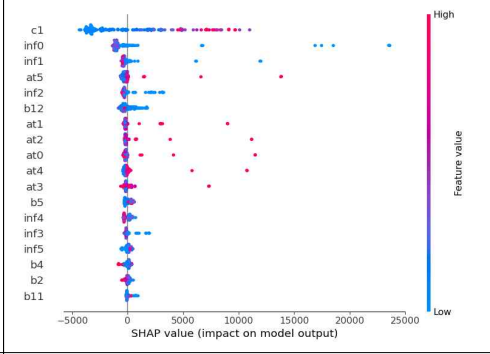
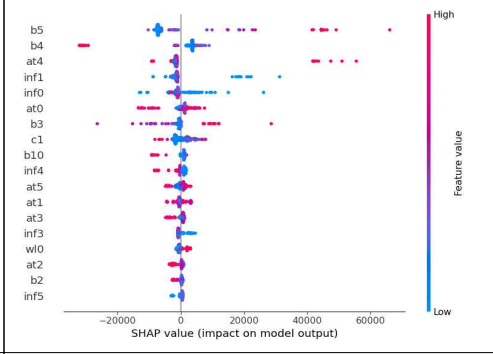
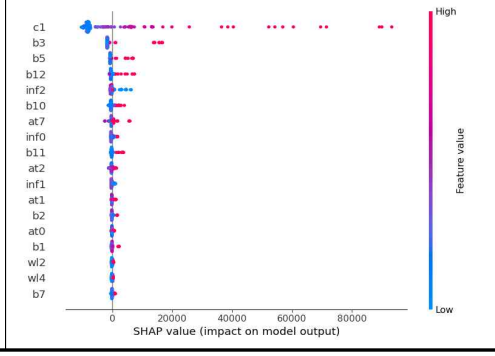
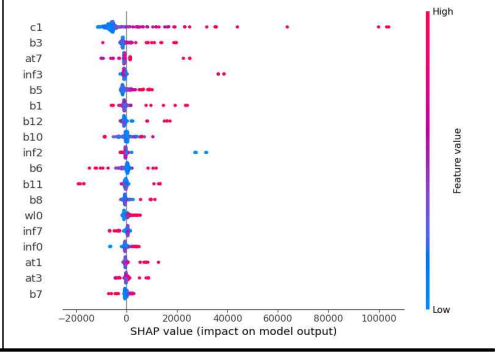
<표 3.28> Chl-a 단기 예측에 사용된 입력변수의 SHAP 분석 결과

기간	RandomForest	XGBoost
3일 후		
5일 후		
7일 후		

2) 총조류 세포수 단기예측모델 설명력 분석결과

앙상블 기법을 적용하여 위성영상 밴드별 반사도값, 수문 및 기상자료를 연계하여 분석한 공간적 총조류 세포수 예측 모델의 설명력을 설명가능한 AI를 활용하여 분석하였다. SHAP(SHapley Additive exPlanations) 기법을 활용하여 랜덤포레스트 및 XGBoost 적용시 입력변수별 중요도를 분석한 결과, 앙상블 기법별로 차이는 있었으나 3일 후 예측 모델에서는 위성영상 중요 밴드 조합에 의한 반사도값의 중요도가 크게 나타났으며 5일 후 예측 모델에서는 중요 밴드 조합에 의한 반사도값 뿐만 아니라 기온의 중요도가 커지는 것으로 분석되었고, 7일 후 예측 모델에서는 중요 밴드 조합에 의한 반사도값과 기온 뿐만 아니라 유입량의 중요도가 커지는 것으로 분석되었다. Chl-a 와 달리 총조류세포수 예측 모델에서는 기온과 유입량 보다는 중요 밴드 조합에 의한 반사도값의 중요도가 큰 것으로 분석되었다.

<표 3.29> 총조류세포수 단기 예측에 사용된 입력변수의 SHAP 분석 결과

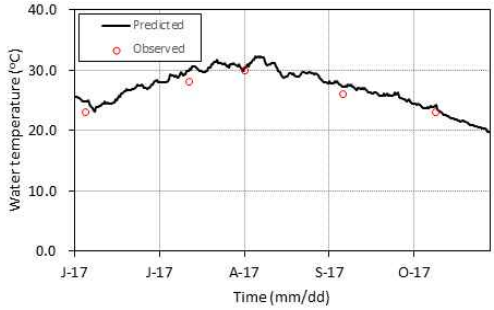
기간	RandomForest	XGBoost
3일 후		
5일 후		
7일 후		

3.4.2 합성데이터를 활용한 단기예측 알고리즘 개발

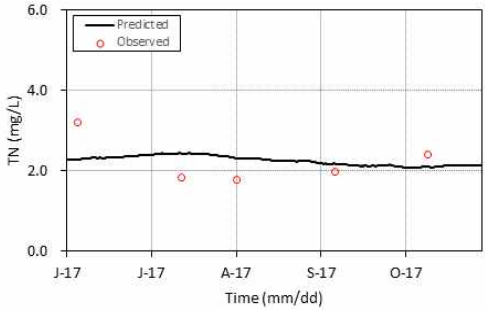
가. AEM3D 결과를 활용한 분석 DB 구축결과

대청댐 AEM3D 모델은 격자 셀의 크기는 100 m×100 m×1 m(△X×△Y×△Z)로 설정하여 총 wet cell 178,310개로 구성하였다. 기상자료는 대전 기상청 자료를 활용하였으며, 초기 및 경계조건은 K-water 운영통합시스템(WRO)의 수위, 유입량 자료와 댐앞(대청댐2) 환경부 수질측정망 지점의 수질자료를 입력하였다. 모의 기간은 2017년 6~10월까지로 분석하였으며 모델의 수위를 관측 수위와 비교하여 모델의 물수지 재현력을 검증하였다. 수질 보정은 수질측정망 지점을 대상으로 수온, DO, TN, TP, TOC, Chl-a 항목의 모델 재현력을 제시하였으며 시간적인 수질 변화를 모델이 비교적 유사하게 재현하는 것으로 나타났다.

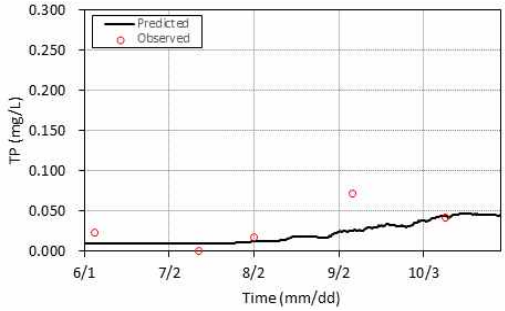




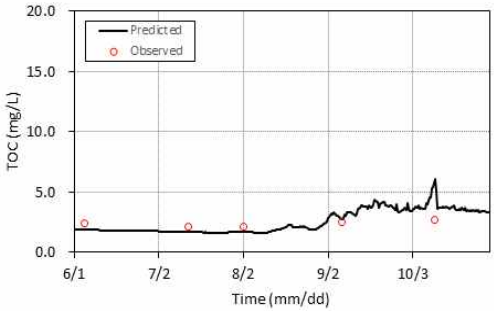
(a) 댐앞(대청댐2) 수온



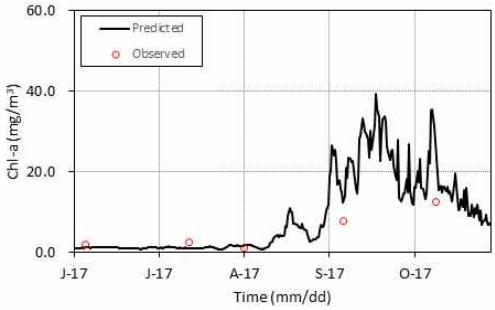
(b) 댐앞(대청댐2) TN



(c) 댐앞(대청댐2) TP

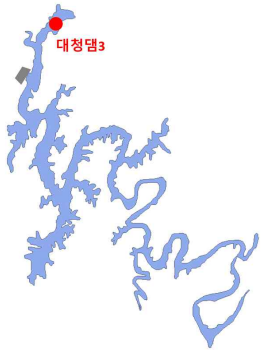


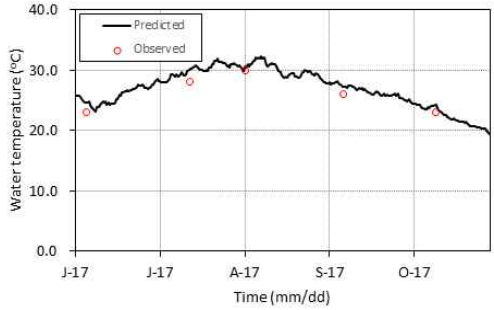
(d) 댐앞(대청댐2) TOC



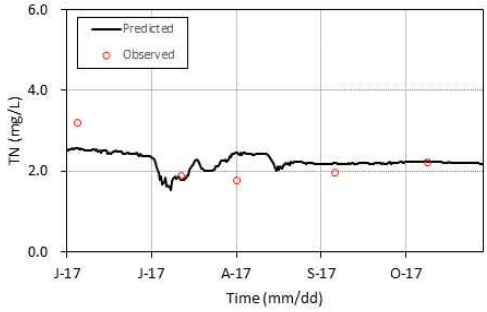
(e) 댐앞(대청댐2) Chl-a

<그림 3.33> 대청댐2(댐앞) 지점 2017년 6~10월 수질 보정결과

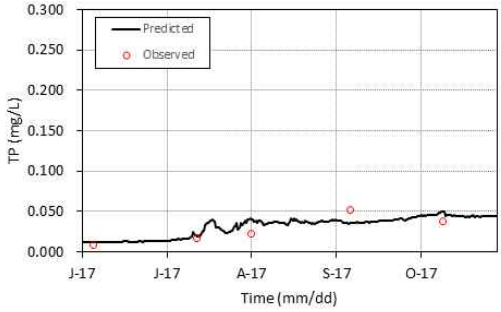




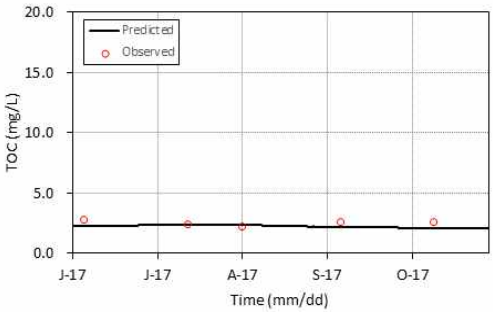
(a) 문의(대청댐3) 수온



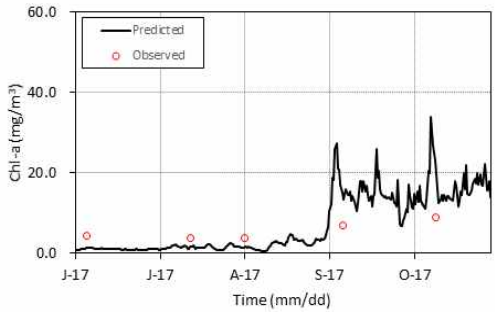
(b) 문의(대청댐3) TN



(c) 문의(대청댐3) TP



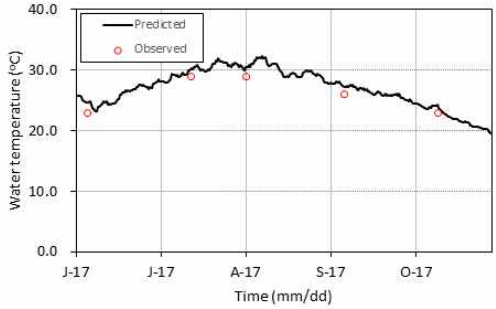
(d) 문의(대청댐3) TOC



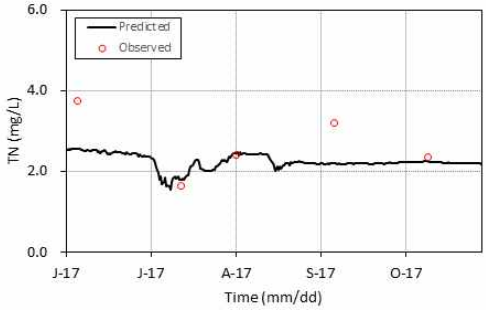
(e) 문의(대청댐3) Chl-a

<그림 3.34> 대청댐3 지점 2017년 6~10월 수질 보정결과

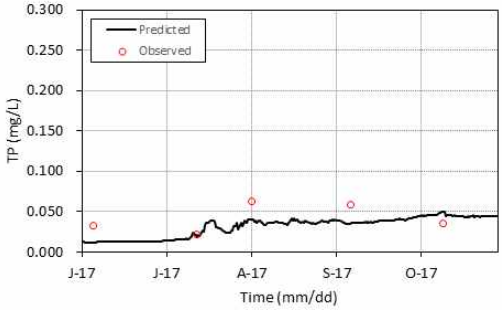




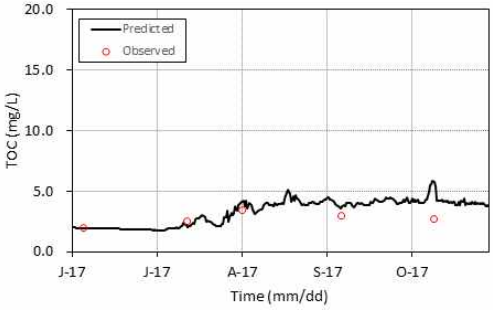
(a) 문의(대청댐5) 수온



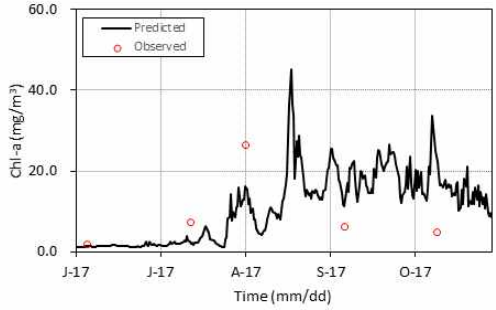
(b) 문의(대청댐5) TN



(c) 문의(대청댐5) TP



(d) 문의(대청댐5) TOC

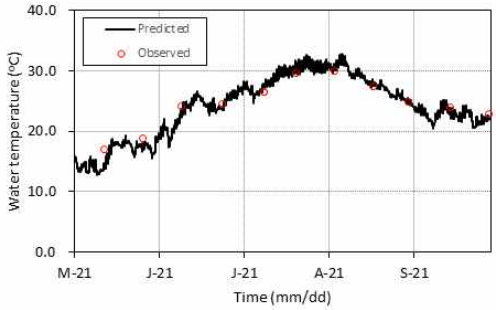


(e) 문의(대청댐5) Chl-a

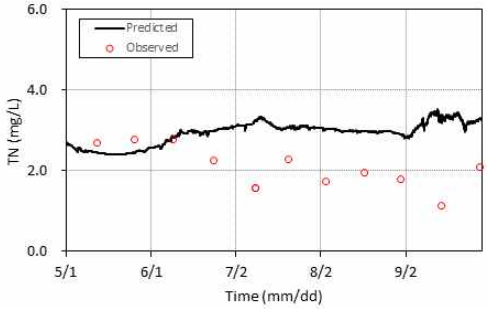
<그림 3.35> 대청댐5 지점 2017년 6~10월 수질 보정결과

영주댐 AEM3D 모델은 격자 셀의 크기는 100 m×100 m×1 m이며 총 wet cell은 21,5619개이다. 유입 경계조건은 댐 상류의 유사조절지 방류수로 구성되어 있으며, 유출 경계조건은 여수로, 취수탑 취수, 배사문 방류 등을 수심별로 세분화하여 적용할 수 있도록 구성되어 있다. 기상자료는 영주, 안동 기상청 자료를 활용하였으며, K-water 운영통합시스템(WRO) 시간별 유입, 방류량 자료를 활용하고, 유입수질은 K-water 자체연구(K-water, 2022) 조사자료를 활용하였다. 모의 기간은 2021년 5~9월까지로 분석하였으며 모델의 수위를 관측 수위와 비교하여 모델의 물수지 재현력을 검증하였다. 수질 보정은 댐 앞 지점을 대상으로 수온, DO, TN, TP, TOC, Chl-a 항목의 모델 재현력을 검토하였으며 시간적인 수질 변화를 모델이 비교적 유사하게 재현하는 것으로 나타났다. 특히, 8월 기온 증가와 비점오염물질 유입에 의한 Chl-a 농도 증가를 비교적 유사하게 재현하는 것으로 나타났다.

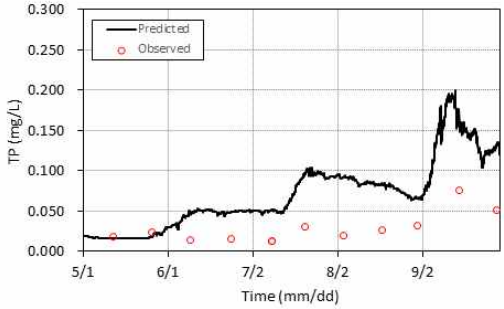




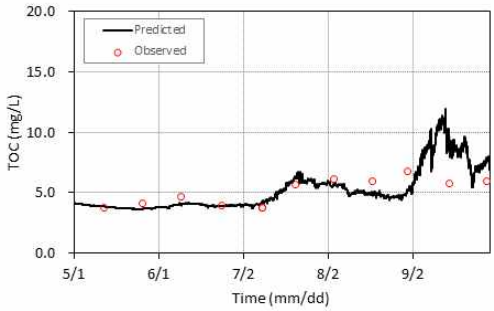
(a) 댐앞 수온



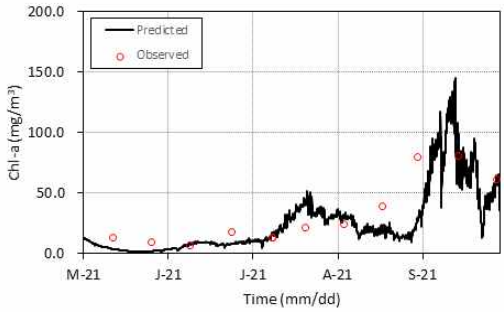
(b) 댐앞 TN



(c) 댐앞 TP



(d) 댐앞 TOC



(e) 댐앞 Chl-a

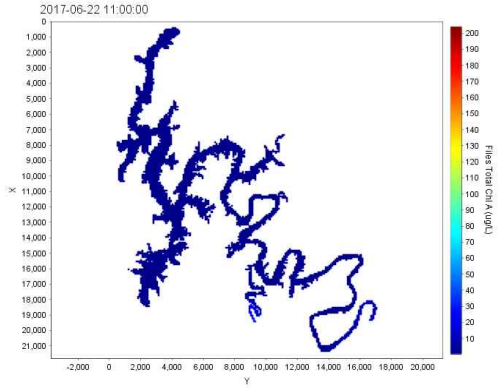
<그림 3.36> 영주댐1(댐앞) 지점 2021년 5~9월 수질 보정결과

보정이 완료된 모델 결과를 활용하여 위경도별 Chl-a 농도와 Sentinel-2 위성영상 밴드별 반사도값을 매칭하여 머신러닝 분석을 위한 입력자료를 구축하였다. 월별로 운량 등 기상조건이 양호한 날짜를 선정하였으며 입력자료로 활용된 시기의 Chl-a 농도 범위를 다음 그림과 표에 나타내었다. 그리고 Sentinel-2 위성영상, 기상 및 수문자료를 연계하여 단기(3~7일) Chl-a 농도 예측 알고리즘을 개발하기 위하여 월별로 선정한 위성영상 관측일 이후 3, 5, 7일 후의 공간적 Chl-a 농도를 예측 알고리즘 개발을 위한 독립변수로 구축하여 알고리즘 분석을 수행하였다.

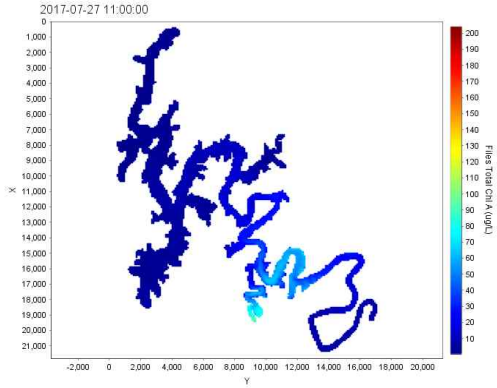
<표 3.30> 대청댐 및 영주댐 AEM3D 모형에 적용된 수질계수

Parameter		Description	Unit	Assigned value		Reference
				DC	YJ	
Phytoplankton parameters	μmax	Maximum specific growth rate	/day	1.0-2.0	0.3-1.2	1.1-1.2
	Ycc	Average ratio of C to chlorophyll a	mg-C/mg-Chl.a	40	20-40	40
	ISt	Light saturation for max. production	uE/m^2/s	70-1300	60-130	100-130
	Kpa	Half saturation constant for P	mg/L	0.0002	0.005	0.008
	Kna	Half saturation constant for N	mg/L	0.006 -0.060	0.045 -0.050	0.030
	KCa	Half saturation constant for C	mg/L	1.5	2	-
	Ksa	Half saturation constant for Si	mg/L	0.15	0	-
	INmin/max	Min/max internal N concentration	mg-N/mg-Chl.a	2.0//9.0	2.0/4.0	-
	IPmin/max	Min/max internal P concentration	mg-P/mg-Chl.a	0.1/0.5	0.1/0.6	-
	ICmin/max	Min/max internal C concentration	mg-C/mg-Chl.a	15/80	15/80	-
	vT	Temperature multiplier for growth	-	1.06	1.06	1.07
	Tsta	Standard temperature	℃	15.0-20.0	20.0	20.0
	Topt	Optimum temperature	℃	20.0-29.0	18-29.0	22.0-30.0
	Tmax	Maximum temperature	℃	32-34	32-36	35.0-39.0
	kr	Respiration rate coefficient	/day	0.08-0.12	0.08-0.12	0.070-0.1
	vR	Temperature multiplier for respiration	-	1.08	1.08	-
Nutrient parameters	koN2	Denitrification rate coefficient(20℃)	/day	0.01	0.01	0.03-0.15
	KN2	Inverted half-saturation constant for effect of oxygen on denitrification	mg/L	0.5	0.5	0.44
	vON	Temperature multiplier for denitrification	-	1.08	1.08	1.08
	koNH	Nitrification rate coefficient(20℃)	/day	0.050	0.050	0.065-0.25
	KOn	Half-saturation constant for effect of oxygen on nitrification	mg/L	2	2	0.5-0.75
	vN2	Temperature multiplier for nitrification	-	1.08	1.08	1.08
	PON1max	Rate coefficient of PONL to DONL(20℃)	/day	0.010	0.010	0.003-0.005
	DON1max	Rate cofficient of DONL to NH_4(20℃)	/day	0.003	0.003	0.008-0.08
	POP1max	Rate coefficient of POPL to DOPL(20℃)	/day	0.05	0.05	0.02-0.03
	DOP1max	Rate coefficient of DOPL to PO_4(20℃)	/day	0.003	0.005	0.025-0.25

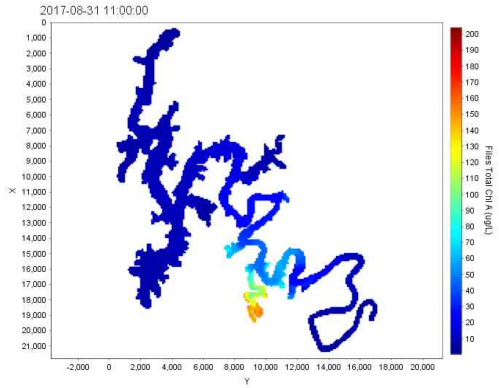
DC : Daechung dam reservoir, YJ : Youngju dam reservoir



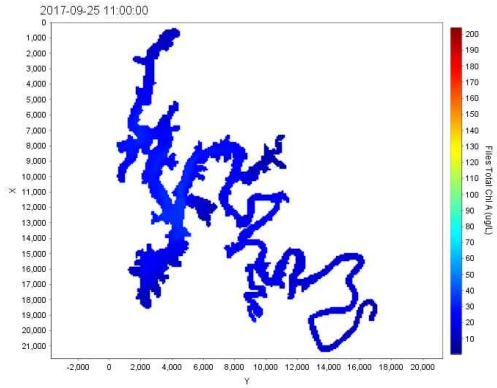
(a) 2017-06-22



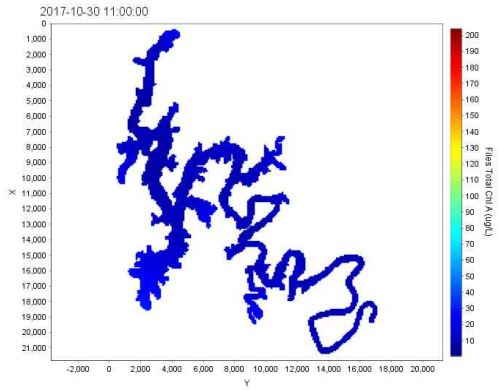
(b) 2017-07-27



(c) 2017-08-31



(d) 2017-09-25

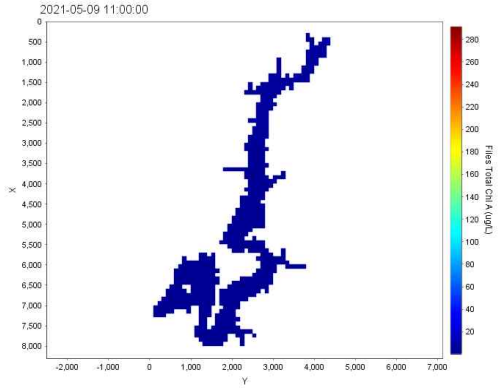


(e) 2017-10-30

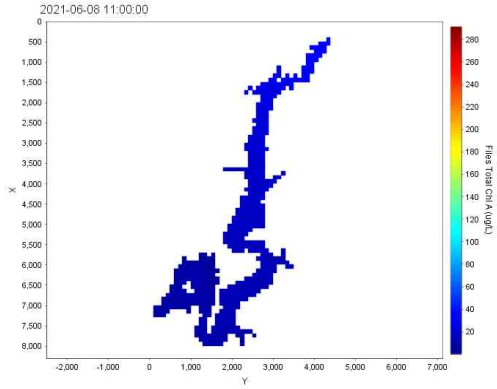
<그림 3.37> 2017년 대청댐 머신러닝 입력자료 공간적 Chl-a 분포도

<표 3.31> 2017년 대청댐 머신러닝 입력자료 기온, 유입량 및 Chl-a 범위

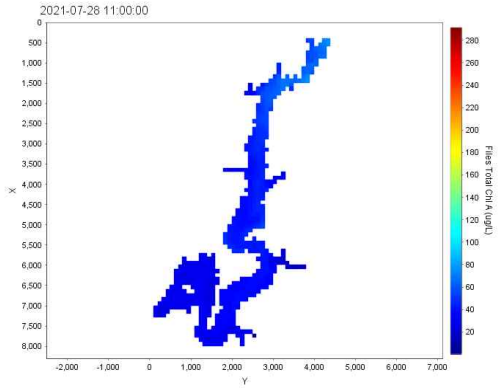
위성관측일		2017-06-22	2017-07-27	2017-08-31	2017-09-25	2017-10-30
기온		25.0	27.8	21.6	23.3	7.6
유입량		5.0	60.3	63.2	23.9	6.6
Chl-a (mg/m^3)	평균	1.4	13.0	19.4	20.6	12.6
	(범위)	(0.8~34.0)	(1.3~96.7)	(3.5~156.0)	(4.5~36.1)	(5.9~32.6)



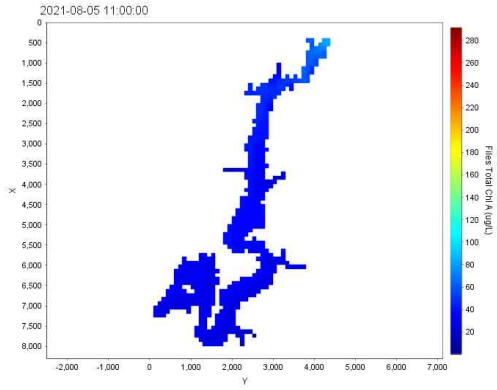
(a) 2021-05-09



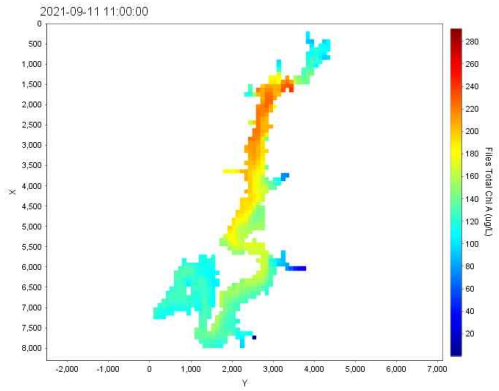
(b) 2021-06-08



(c) 2021-07-28



(a) 2021-08-05



(a) 2021-09-11

<그림 3.38> 2021년 영주댐 머신러닝 입력자료 공간적 Chl-a 분포도

<표 3.32> 2021년 영주댐 머신러닝 입력자료 기온, 유입량 및 Chl-a 범위

위성관측일		2021-05-09	2024-06-08	2024-07-28	2024-08-05	2024-09-11
기온		15.7	22.6	27.0	27.4	21.3
유입량		3.3	3.7	0.0	0.9	9.4
Chl-a (mg/m^3)	평균 (범위)	4.7 (2.9~7.0)	15.8 (0.7~34.4)	39.1 (0.7~76.0)	34.6 (0.9~84.2)	150.4 (4.3~240.6)

위성영상 반사도값과 3, 5, 7일간 일평균 기온 및 유입량을 입력자료로 구축한 내용을 <표 3.34>에 나타내었다. 3일 후 예측을 위하여 위성영상 관측일의 밴드별 반사도값, 관측일을 포함하여 3일 후 기간까지 일평균 기온, 관측일을 포함하여 3일 후 기간까지 일유입량을 입력자료로 구축하였으며 종속변수는 위성영상 관측일 3일 후의 Chl-a 농도값이다. 5일 후 예측을 위하여 위성영상 관측일의 밴드별 반사도값, 관측일을 포함하여 5일 후 기간까지 일평균 기온, 관측일을 포함하여 5일 후 기간까지 일유입량을 입력자료로 구축하였으며 종속변수는 위성영상 관측일 5일후의 Chl-a 농도값이다. 7일 후 예측을 위하여 위성영상 관측일의 밴드별 반사도값, 관측일을 포함하여 7일 후 기간까지 일평균 기온, 관측일을 포함하여 7일 후 기간까지 일유입량을 입력자료로 구축하였으며 종속변수는 위성영상 관측일 7일후의 Chl-a 농도값이다. 단기예측 알고리즘 개발을 위한 합성데이터 수는 3일 후 예측은 대청댐 29,200개 및 영주댐 3,114개로 총 32,314개로 구축하였고, 5일 후 예측은 대청댐 29,200개 및 영주댐 3,101개로 총 32,301개로 구축하였으며, 7일 후 예측은 대청댐 29,200개 및 영주댐 3,100개로 총 32,300개로 구축하였다. 데이터세트를 랜덤으로 추출하여 70%는 학습, 나머지 30%는 검증하는데 활용하였다.

<표 3.33> 단기 (3~7일) 예측 알고리즘 개발을 위한 분석DB 구축내용

구분	독립변수	종속변수
3일후 예측	Sentinel-2 관측일 밴드별 반사도값(0일)	3일후 Chl-a
	위성관측일 이후 3일간 일평균 기온(0, 1, 2, 3일)	
	위성관측일 이후 3일간 일평균 유입량(0, 1, 2, 3일)	
5일후 예측	Sentinel-2 관측일 밴드별 반사도값(0일)	5일후 Chl-a
	위성관측일 이후 5일간 일평균 기온(0, 1, 2, 3, 4, 5일)	
	위성관측일 이후 5일간 일평균 유입량(0, 1, 2, 3, 4, 5일)	
7일후 예측	Sentinel-2 관측일 밴드별 반사도값(0일)	7일후 Chl-a
	위성관측일 이후 7일간 일평균 기온(0, 1, 2, 3, 4, 5, 6, 7일)	
	위성관측일 이후 7일간 일평균 유입량(0, 1, 2, 3, 4, 5, 6, 7일)	

<표 3.34> 단기 (3~7일) 예측 알고리즘 개발을 합성데이터 입력자료 현황

구분		3일후 예측	5일후 예측	7일후 예측
독립변수 개수		20개	24개	28개
데이터수	대청댐	29,200	29,200	29,200
	영주댐	3,114	3,101	3,100
	합계	32,314	32,301	32,300

<표 3.35> 2017년 대청댐 합성데이터(AEM3D 모의결과) 입력자료

구분		기온(℃)	유입량(m^3/s)	Chl-a(mg/m^3)
위성관측일(2017-06-22)		25.0	5.0	1.4
단기예측	3일후	23.9	8.1	1.5
	5일후	24.8	24.9	2.0
	7일후	26.6	41.2	2.3
위성관측일(2017-07-27)		27.8	60.3	13.0
단기예측	3일후	28.1	66.6	12.3
	5일후	27.2	152.4	10.5
	7일후	28.7	74.0	14.7
위성관측일(2017-08-31)		21.6	63.2	19.4
단기예측	3일후	22.8	37.5	28.2
	5일후	21.7	24.0	21.9
	7일후	22.4	29.9	18.8
위성관측일(2017-09-25)		23.3	23.9	20.6
단기예측	3일후	20.2	58.7	13.5
	5일후	18.6	38.0	15.6
	7일후	19.8	36.0	13.7
위성관측일(2017-10-30)		7.6	6.6	12.6
단기예측	3일후	14.2	21.6	14.9
	5일후	8.1	14.9	11.6
	7일후	9.0	17.7	11.7

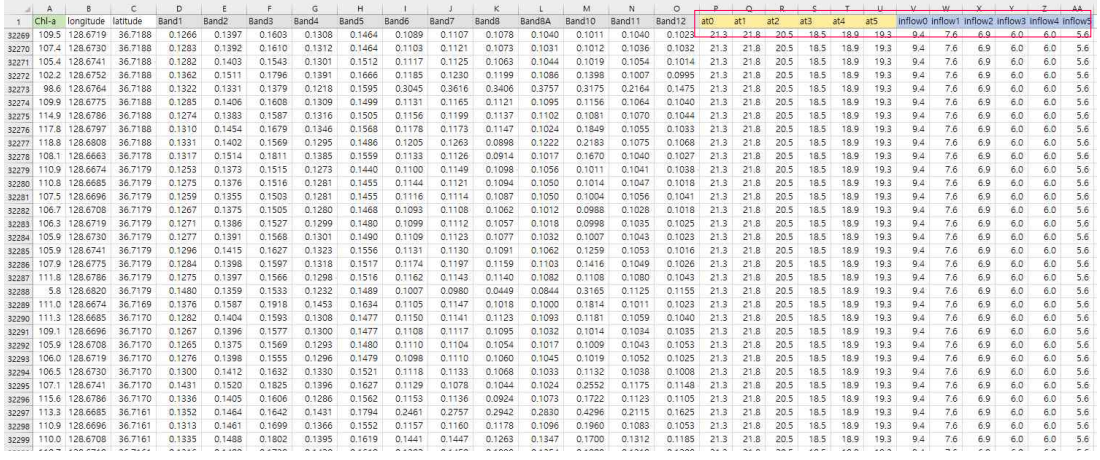
<표 3.36> 2021년 영주댐 합성데이터(AEM3D 모의결과) 입력자료

구분		기온(℃)	유입량(m^3/s)	Chl-a(mg/m^3)
위성관측일(2021-05-09)		15.7	3.3	4.7
단기예측	3일후	15.8	2.6	3.5
	5일후	20.4	1.1	2.9
	7일후	18.9	34.6	2..4
위성관측일(2021-06-08)		22.6	3.7	15.8
단기예측	3일후	20.9	7.2	16.7
	5일후	23.8	5.0	18.5
	7일후	20.2	5.0	18.5
위성관측일(2022-07-28)		27.0	0.0	39.1
단기예측	3일후	26.8	1.2	40.3
	5일후	25.5	9.4	36.2
	7일후	27.2	6.7	34.3
위성관측일(2022-08-05)		27.4	0.9	34.6
단기예측	3일후	23.8	5.0	32.6
	5일후	22.2	4.3	24.1
	7일후	24.6	2.1	30.7
위성관측일(2022-09-11)		21.3	9.4	150.4
단기예측	3일후	18.5	6.0	142.5
	5일후	19.3	5.6	103.4
	7일후	17.8	8.5	91.6



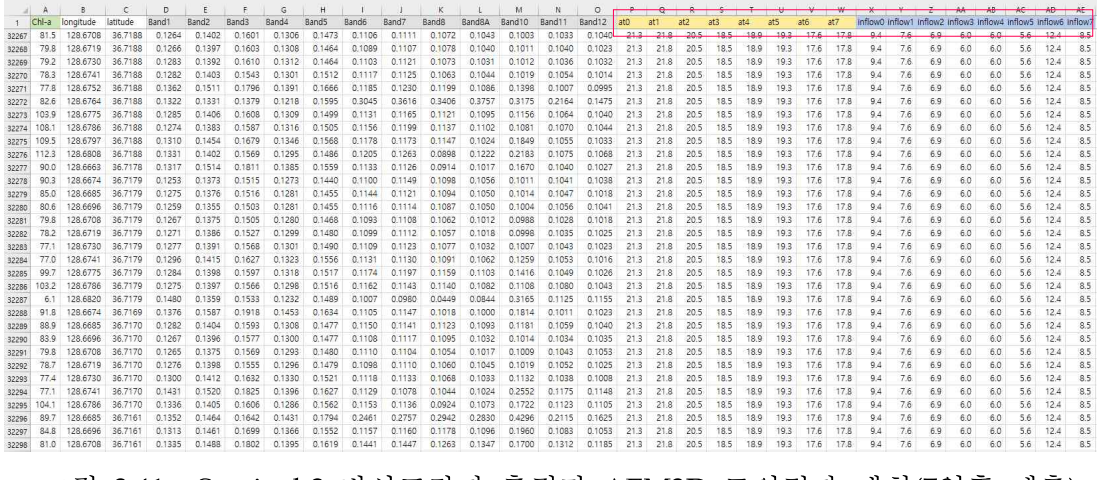
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W
1	Chl-a	longitude	latitude	Band1	Band2	Band3	Band4	Band5	Band6	Band7	Band8	Band8A	Band10	Band11	Band12	at0	at1	at2	at3	inflow0	inflow1	inflow2	inflow3
32287	135.5	128.6775	36.7188	0.1285	0.1406	0.1608	0.1309	0.1499	0.1131	0.1165	0.1121	0.1095	0.1156	0.1064	0.1040	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32288	131.5	128.6786	36.7188	0.1274	0.1383	0.1587	0.1316	0.1505	0.1156	0.1199	0.1137	0.1102	0.1081	0.1070	0.1044	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32289	134.4	128.6797	36.7188	0.1310	0.1454	0.1679	0.1346	0.1568	0.1178	0.1173	0.1147	0.1024	0.1849	0.1055	0.1033	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32290	133.3	128.6808	36.7188	0.1331	0.1402	0.1569	0.1295	0.1486	0.1205	0.1263	0.0898	0.1222	0.2183	0.1075	0.1068	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32291	129.9	128.6663	36.7178	0.1317	0.1514	0.1811	0.1385	0.1559	0.1133	0.1126	0.0914	0.1017	0.1670	0.1040	0.1027	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32292	136.2	128.6674	36.7179	0.1253	0.1373	0.1515	0.1273	0.1440	0.1100	0.1149	0.1098	0.1056	0.1011	0.1041	0.1038	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32293	137.0	128.6685	36.7179	0.1275	0.1376	0.1516	0.1281	0.1455	0.1144	0.1121	0.1094	0.1050	0.1014	0.1047	0.1018	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32294	136.7	128.6696	36.7179	0.1259	0.1355	0.1503	0.1281	0.1455	0.1116	0.1114	0.1087	0.1050	0.1004	0.1056	0.1041	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32295	137.5	128.6708	36.7179	0.1267	0.1375	0.1505	0.1280	0.1468	0.1093	0.1108	0.1062	0.1012	0.0988	0.1028	0.1018	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32296	136.1	128.6719	36.7179	0.1271	0.1386	0.1527	0.1299	0.1480	0.1099	0.1112	0.1057	0.1018	0.0998	0.1035	0.1025	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32297	134.1	128.6730	36.7179	0.1277	0.1391	0.1568	0.1301	0.1490	0.1109	0.1123	0.1077	0.1032	0.1007	0.1043	0.1023	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32298	132.5	128.6741	36.7179	0.1296	0.1415	0.1627	0.1323	0.1556	0.1131	0.1130	0.1091	0.1062	0.1259	0.1053	0.1016	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32299	136.4	128.6775	36.7179	0.1284	0.1398	0.1597	0.1318	0.1517	0.1174	0.1197	0.1159	0.1103	0.1416	0.1049	0.1026	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32300	136.6	128.6786	36.7179	0.1275	0.1397	0.1566	0.1298	0.1516	0.1162	0.1143	0.1140	0.1082	0.1108	0.1080	0.1043	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32301	5.1	128.6820	36.7179	0.1480	0.1359	0.1533	0.1232	0.1489	0.1007	0.0980	0.0449	0.0844	0.3165	0.1125	0.1155	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32302	133.4	128.6674	36.7169	0.1376	0.1587	0.1918	0.1453	0.1634	0.1105	0.1147	0.1018	0.1000	0.1814	0.1011	0.1023	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32303	136.8	128.6685	36.7170	0.1282	0.1404	0.1593	0.1308	0.1477	0.1150	0.1141	0.1123	0.1093	0.1181	0.1059	0.1040	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32304	133.6	128.6696	36.7170	0.1267	0.1396	0.1577	0.1300	0.1477	0.1108	0.1117	0.1095	0.1032	0.1014	0.1034	0.1035	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32305	133.0	128.6708	36.7170	0.1265	0.1375	0.1569	0.1293	0.1480	0.1110	0.1104	0.1054	0.1017	0.1009	0.1043	0.1053	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32306	134.0	128.6719	36.7170	0.1276	0.1398	0.1555	0.1296	0.1479	0.1098	0.1110	0.1060	0.1045	0.1019	0.1052	0.1025	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32307	130.9	128.6730	36.7170	0.1300	0.1412	0.1632	0.1330	0.1521	0.1118	0.1133	0.1068	0.1033	0.1132	0.1038	0.1008	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32308	125.1	128.6741	36.7170	0.1431	0.1520	0.1825	0.1396	0.1627	0.1129	0.1078	0.1044	0.1024	0.2552	0.1175	0.1148	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32309	140.4	128.6786	36.7170	0.1336	0.1405	0.1606	0.1286	0.1562	0.1153	0.1136	0.0924	0.1073	0.1722	0.1123	0.1105	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32310	136.5	128.6685	36.7161	0.1352	0.1464	0.1642	0.1431	0.1794	0.2461	0.2757	0.2942	0.2830	0.4296	0.2115	0.1625	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32311	136.4	128.6696	36.7161	0.1313	0.1461	0.1699	0.1366	0.1552	0.1157	0.1160	0.1178	0.1096	0.1960	0.1083	0.1053	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32312	132.3	128.6708	36.7161	0.1335	0.1488	0.1802	0.1395	0.1619	0.1441	0.1447	0.1263	0.1347	0.1700	0.1312	0.1185	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32313	131.7	128.6719	36.7161	0.1316	0.1480	0.1738	0.1420	0.1619	0.1382	0.1450	0.1898	0.1354	0.1808	0.1319	0.1208	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32314	130.9	128.6730	36.7161	0.1301	0.1436	0.1668	0.1339	0.1507	0.1007	0.1048	0.1103	0.0923	0.2374	0.0984	0.1031	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0
32315	138.2	128.6786	36.7161	0.1418	0.1569	0.1850	0.1621	0.2291	0.4466	0.5140	0.5721	0.5278	0.3879	0.3542	0.2440	21.3	21.8	20.5	18.5	9.4	7.6	6.9	6.0

<그림 3.39> Sentinel-2 반사도값과 측정망 AEM3D 모의결과 매칭(3일후 예측)



	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA
1	Chl-a	longitude	latitude	Band1	Band2	Band3	Band4	Band5	Band6	Band7	Band8	Band8A	Band10	Band11	Band12	at0	at1	at2	at3	at4	at5	inflow0	inflow1	inflow2	inflow3	inflow4	inflow5
32269	109.5	128.6719	36.7188	0.1266	0.1397	0.1603	0.1308	0.1464	0.1089	0.1107	0.1078	0.1040	0.1011	0.1040	0.1023	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32270	107.4	128.6730	36.7188	0.1283	0.1392	0.1610	0.1312	0.1464	0.1103	0.1121	0.1073	0.1031	0.1012	0.1036	0.1032	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32271	105.4	128.6741	36.7188	0.1282	0.1403	0.1543	0.1301	0.1512	0.1117	0.1125	0.1063	0.1044	0.1019	0.1054	0.1014	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32272	102.2	128.6752	36.7188	0.1362	0.1511	0.1796	0.1391	0.1666	0.1185	0.1230	0.1199	0.1086	0.1398	0.1007	0.0995	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32273	98.6	128.6764	36.7188	0.1322	0.1331	0.1379	0.1218	0.1595	0.3045	0.3616	0.3406	0.3757	0.3175	0.2164	0.1475	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32274	109.9	128.6775	36.7188	0.1285	0.1406	0.1608	0.1309	0.1499	0.1131	0.1165	0.1121	0.1095	0.1156	0.1064	0.1040	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32275	114.9	128.6786	36.7188	0.1274	0.1383	0.1587	0.1316	0.1505	0.1156	0.1199	0.1137	0.1102	0.1081	0.1070	0.1044	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32276	117.8	128.6797	36.7188	0.1310	0.1454	0.1679	0.1346	0.1568	0.1178	0.1173	0.1147	0.1024	0.1849	0.1055	0.1033	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32277	118.8	128.6808	36.7188	0.1331	0.1402	0.1569	0.1295	0.1486	0.1205	0.1263	0.0898	0.1222	0.2183	0.1075	0.1068	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32278	108.1	128.6663	36.7178	0.1317	0.1514	0.1811	0.1385	0.1559	0.1133	0.1126	0.0914	0.1017	0.1670	0.1040	0.1027	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32279	110.9	128.6674	36.7179	0.1253	0.1373	0.1515	0.1273	0.1440	0.1100	0.1149	0.1098	0.1056	0.1011	0.1041	0.1038	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32280	110.8	128.6685	36.7179	0.1275	0.1376	0.1516	0.1281	0.1455	0.1144	0.1121	0.1094	0.1050	0.1014	0.1047	0.1018	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32281	107.5	128.6696	36.7179	0.1259	0.1355	0.1503	0.1281	0.1455	0.1116	0.1114	0.1087	0.1050	0.1004	0.1056	0.1041	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32282	106.7	128.6708	36.7179	0.1267	0.1375	0.1505	0.1280	0.1468	0.1093	0.1108	0.1062	0.1012	0.0988	0.1028	0.1018	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32283	106.3	128.6719	36.7179	0.1271	0.1386	0.1527	0.1299	0.1480	0.1099	0.1112	0.1057	0.1018	0.0998	0.1035	0.1025	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32284	105.9	128.6730	36.7179	0.1277	0.1391	0.1568	0.1301	0.1490	0.1109	0.1123	0.1077	0.1032	0.1007	0.1043	0.1023	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32285	105.9	128.6741	36.7179	0.1296	0.1415	0.1627	0.1323	0.1556	0.1131	0.1130	0.1091	0.1062	0.1259	0.1053	0.1016	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32286	107.9	128.6775	36.7179	0.1284	0.1398	0.1597	0.1318	0.1517	0.1174	0.1197	0.1159	0.1103	0.1416	0.1049	0.1026	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32287	111.8	128.6786	36.7179	0.1275	0.1397	0.1566	0.1298	0.1516	0.1162	0.1143	0.1140	0.1082	0.1108	0.1080	0.1043	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32288	5.8	128.6820	36.7179	0.1480	0.1359	0.1533	0.1232	0.1489	0.1007	0.0980	0.0449	0.0844	0.3165	0.1125	0.1155	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32289	111.0	128.6674	36.7169	0.1376	0.1587	0.1918	0.1453	0.1634	0.1105	0.1147	0.1018	0.1000	0.1814	0.1011	0.1023	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32290	111.3	128.6685	36.7170	0.1282	0.1404	0.1593	0.1308	0.1477	0.1150	0.1141	0.1123	0.1093	0.1181	0.1059	0.1040	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32291	109.1	128.6696	36.7170	0.1267	0.1396	0.1577	0.1300	0.1477	0.1108	0.1117	0.1095	0.1032	0.1014	0.1034	0.1035	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32292	105.9	128.6708	36.7170	0.1265	0.1375	0.1569	0.1293	0.1480	0.1110	0.1104	0.1054	0.1017	0.1009	0.1043	0.1053	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32293	106.0	128.6719	36.7170	0.1276	0.1398	0.1555	0.1296	0.1479	0.1098	0.1110	0.1060	0.1045	0.1019	0.1052	0.1025	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32294	106.5	128.6730	36.7170	0.1300	0.1412	0.1632	0.1330	0.1521	0.1118	0.1133	0.1068	0.1033	0.1132	0.1038	0.1008	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32295	107.1	128.6741	36.7170	0.1431	0.1520	0.1825	0.1396	0.1627	0.1129	0.1078	0.1044	0.1024	0.2552	0.1175	0.1148	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32296	115.6	128.6786	36.7170	0.1336	0.1405	0.1606	0.1286	0.1562	0.1153	0.1136	0.0924	0.1073	0.1722	0.1123	0.1105	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32297	113.3	128.6685	36.7161	0.1352	0.1464	0.1642	0.1431	0.1794	0.2461	0.2757	0.2942	0.2830	0.4296	0.2115	0.1625	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32298	110.9	128.6696	36.7161	0.1313	0.1461	0.1699	0.1366	0.1552	0.1157	0.1160	0.1178	0.1096	0.1960	0.1083	0.1053	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6
32299	110.0	128.6708	36.7161	0.1335	0.1488	0.1802	0.1395	0.1619	0.1441	0.1447	0.1263	0.1347	0.1700	0.1312	0.1185	21.3	21.8	20.5	18.5	18.9	19.3	9.4	7.6	6.9	6.0	6.0	5.6

<그림 3.40> Sentinel-2 반사도값과 측정망 AEM3D 모의결과 매칭(5일후 예측)



	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	AB	AC	AD	AE
1	Chl-a	longitude	latitude	Band1	Band2	Band3	Band4	Band5	Band6	Band7	Band8	Band8A	Band10	Band11	Band12	at0	at1	at2	at3	at4	at5	at6	at7	inflow0	inflow1	inflow2	inflow3	inflow4	inflow5	inflow6	inflow7
32267	81.5	128.6708	36.7188	0.1264	0.1402	0.1601	0.1306	0.1473	0.1106	0.1111	0.1072	0.1043	0.1003	0.1033	0.1040	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32268	79.8	128.6719	36.7188	0.1266	0.1397	0.1603	0.1308	0.1464	0.1089	0.1107	0.1078	0.1040	0.1011	0.1040	0.1023	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32269	79.2	128.6730	36.7188	0.1283	0.1392	0.1610	0.1312	0.1464	0.1103	0.1121	0.1073	0.1031	0.1012	0.1036	0.1032	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32270	78.3	128.6741	36.7188	0.1282	0.1403	0.1543	0.1301	0.1512	0.1117	0.1125	0.1063	0.1044	0.1019	0.1054	0.1014	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32271	77.8	128.6752	36.7188	0.1362	0.1511	0.1796	0.1391	0.1666	0.1185	0.1230	0.1199	0.1086	0.1398	0.1007	0.0995	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32272	82.6	128.6764	36.7188	0.1322	0.1331	0.1379	0.1218	0.1595	0.3045	0.3616	0.3406	0.3757	0.3175	0.2164	0.1475	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32273	103.9	128.6775	36.7188	0.1285	0.1406	0.1608	0.1309	0.1499	0.1131	0.1165	0.1121	0.1095	0.1156	0.1064	0.1040	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32274	108.1	128.6786	36.7188	0.1274	0.1383	0.1587	0.1316	0.1505	0.1156	0.1199	0.1137	0.1102	0.1081	0.1070	0.1044	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32275	109.5	128.6797	36.7188	0.1310	0.1454	0.1679	0.1346	0.1568	0.1178	0.1173	0.1147	0.1024	0.1849	0.1055	0.1033	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32276	112.3	128.6808	36.7188	0.1331	0.1402	0.1569	0.1295	0.1486	0.1205	0.1263	0.0898	0.1222	0.2183	0.1075	0.1068	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32277	90.0	128.6663	36.7178	0.1317	0.1514	0.1811	0.1385	0.1559	0.1133	0.1126	0.0914	0.1017	0.1670	0.1040	0.1027	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32278	90.3	128.6674	36.7179	0.1253	0.1373	0.1515	0.1273	0.1440	0.1100	0.1149	0.1098	0.1056	0.1011	0.1041	0.1038	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32279	85.0	128.6685	36.7179	0.1275	0.1376	0.1516	0.1281	0.1455	0.1144	0.1121	0.1094	0.1050	0.1014	0.1047	0.1018	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32280	80.6	128.6696	36.7179	0.1259	0.1355	0.1503	0.1281	0.1455	0.1116	0.1114	0.1087	0.1050	0.1004	0.1056	0.1041	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32281	79.8	128.6708	36.7179	0.1267	0.1375	0.1505	0.1280	0.1468	0.1093	0.1108	0.1062	0.1012	0.0988	0.1028	0.1018	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32282	78.2	128.6719	36.7179	0.1271	0.1386	0.1527	0.1299	0.1480	0.1099	0.1112	0.1057	0.1018	0.0998	0.1035	0.1025	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32283	77.1	128.6730	36.7179	0.1277	0.1391	0.1568	0.1301	0.1490	0.1109	0.1123	0.1077	0.1032	0.1007	0.1043	0.1023	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32284	77.0	128.6741	36.7179	0.1296	0.1415	0.1627	0.1323	0.1556	0.1131	0.1130	0.1091	0.1062	0.1259	0.1053	0.1016	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32285	99.7	128.6775	36.7179	0.1284	0.1398	0.1597	0.1318	0.1517	0.1174	0.1197	0.1159	0.1103	0.1416	0.1049	0.1026	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32286	103.2	128.6786	36.7179	0.1275	0.1397	0.1566	0.1298	0.1516	0.1162	0.1143	0.1140	0.1082	0.1108	0.1080	0.1043	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32287	6.1	128.6820	36.7179	0.1480	0.1359	0.1533	0.1232	0.1489	0.1007	0.0980	0.0449	0.0844	0.3165	0.1125	0.1155	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32288	91.8	128.6674	36.7169	0.1376	0.1587	0.1918	0.1453	0.1634	0.1105	0.1147	0.1018	0.1000	0.1814	0.1011	0.1023	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0	5.6	12.4	8.5
32289	88.9	128.6685	36.7170	0.1282	0.1404	0.1593	0.1308	0.1477	0.1150	0.1141	0.1123	0.1093	0.1181	0.1059	0.1040	21.3	21.8	20.5	18.5	18.9	19.3	17.6	17.8	9.4	7.6	6.9	6.0	6.0

나. 앙상블 및 딥러닝 기법 적용 결과

합성데이터인 AEM3D 모델결과를 활용하여 구축한 입력자료로 앙상블 기법인 랜덤포레스트와 XGBoost, 딥러닝 기법인 CNN을 활용하여 위성영상 및 기상수문 자료 기반 단기 녹조 예측 알고리즘을 개발하였다. 대청댐과 영주댐 자료를 전체 사용하여 랜덤포레스트 적용한 결과, 3일 후 예측시 학습 결과는 R^2 값은 0.91, RMSE는 7.8 mg/m^3이었으며 검증 결과는 R^2 값은 0.75, RMSE는 12.4 mg/m^3로 분석되었다. 5일 후 예측시 학습 결과는 R^2 값은 0.90, RMSE는 5.9 mg/m^3이었으며 검증 결과는 R^2 값은 0.77, RMSE는 8.8 mg/m^3로 분석되었고, 7일 후 예측시 학습 결과는 R^2 값은 0.90, RMSE는 5.9 mg/m^3이었으며 검증 결과는 R^2 값은 0.71, RMSE는 9.7 mg/m^3로 분석되어 예측 기간에 따른 모델의 정확도 차이는 크지 않는 것으로 분석되었다. XGBoost 기법을 적용한 결과, 3일 후 예측시 학습 결과는 R^2 값은 0.93, RMSE는 6.4 mg/m^3이었으며 검증 결과는 R^2 값은 0.78, RMSE는 12.1 mg/m^3로 분석되었다. 5일 후 예측시 학습 결과는 R^2 값은 0.99, RMSE는 1.3 mg/m^3이었으며 검증 결과는 R^2 값은 0.98, RMSE는 2.6 mg/m^3로 분석되었고, 7일 후 예측시 학습 결과는 R^2 값은 0.99, RMSE는 1.2 mg/m^3이었으며 검증 결과는 R^2 값은 0.99, RMSE는 2.2 mg/m^3로 분석되어 RandomForest보다 알고리즘 정확도가 높았으며 예측 기간이 증가 할수록 모델 성능이 다소 증가하는 것으로 분석되었다. CNN-RF 기법을 적용한 결과, 3일 후 예측시 학습 결과는 R^2 값은 0.96, RMSE는 5.0 mg/m^3이었으며 검증 결과는 R^2 값은 0.70, RMSE는 13.5 mg/m^3로 분석되었다. 5일 후 예측시 학습 결과는 R^2 값은 0.97, RMSE는 3.6 mg/m^3이었으며 검증 결과는 R^2 값은 0.70, RMSE는 9.9 mg/m^3로 분석되었고, 7일 후 예측시 학습 결과는 R^2 값은 0.95, RMSE는 4.1 mg/m^3이었으며 검증 결과는 R^2 값은 0.62, RMSE는 10.8 mg/m^3로 분석되어 RandomForest기법과 유사한 성능을 나타내었다. 댐 저수지 별로 구분하여 알고리즘을 적용하여 비교한 결과, 대청댐은 XGBoost 알고리즘 모델 성능이 가장 좋게 분석되었으며 영주댐은 XGBoost 알고리즘보다 RandomForest와 CNN-RF 알고리즘이 유사하게 모델 성능이 더 좋은 것으로 분석되었다. 본 연구에서 개발한 알고리즘은 파이썬 코드를 활용하여 개발하였으며 프로그램 저작권 등록을 완료하였다.

```python
#data preprocessing
import pandas as pd
#math operations
import numpy as np
#data visualization
import matplotlib.pyplot as plt
#host-os operations
import os
from os import listdir, makedirs, path
from os.path import isfile, join, basename, splitext, isfile, exists
from pathlib import Path
#import keras.utils as utils
from tqdm import tqdm_notebook
from keras.preprocessing import sequence
from keras.models import Sequential
from keras.layers import Dense, Dropout, Activation, Conv1D, MaxPooling1D, Embedding, GlobalAveragePooling1D, BatchNormalization, Flatten, Add
from keras.optimizers import Adam
from keras.callbacks import Callback, EarlyStopping, ModelCheckpoint, ReduceLROnPlateau
from keras.utils import plot_model
from keras import optimizers
# Graphic output
from IPython.display import SVG
# from keras.utils.vis_utils import model_to_dot
# from tensorflow.keras.layers import Layer
from sklearn.metrics import r2_score
from sklearn.metrics import mean_squared_error
from math import sqrt
import tensorflow as tf
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
import openpyxl
from keras.layers import Input
from keras.models import Model
import datetime
from sklearn.metrics import r2_score
from sklearn.metrics import mean_squared_error
from math import sqrt
from sklearn.ensemble import RandomForestRegressor
```

<그림 3.42> 위성영상-기상-수문 연계 Chl-a 단기 예측 CNN-RF 파이썬 모듈 및 함수



제 C-2024-051209 호

저작권 등록증

1. 저작물의 제호(명칭)	위성영상 및 기상수문 자료를 활용한 딥러닝기반 단기 녹조예측 프로그램
2. 저작물의 종류	컴퓨터프로그램저작물>응용프로그램>과학기술
3. 저작자 성명(법인명)	한국수자원공사 외 1인 (별지기재)
4. 생년월일(법인등록번호)	164171-0000052 (별지기재)
5. 창작연월일	2024년11월19일
6. 공표연월일	2024년11월20일
7. 등록연월일	2024년12월09일
8. 등록사항	저작자 : 한국수자원공사·부산대학교산학협력단, 창작 : 2024.11.19, 공표 : 2024.11.20

「저작권법」 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2024년 12월 09일

한국저작권위원회

제 C-2024-051209 호 [별지]

저작권 등록증

등 록 번 호	C-2024-051209
저작자 성명 (법인명)	한국수자원공사 대전광역시 대덕구 신탄진로 200 한국수자원공사 (생년월일 (법인등록번호) 164171-0000052)
	부산대학교산학협력단 부산광역시 금정구 부산대학로63번길 2 부산대학교내 (장전동) (184771-0000478)

「저작권법」 제53조에 따라 위와 같이 등록되었음을 증명합니다.

2024년 12월 09일

한국저작권위원회

<그림 3.43> 위성영상-기상-수문 연계 Chl-a 단기 예측 CNN-RF S/W등록증

<표 3.37> 대청댐 및 영주댐 AEM3D 모의값 기반 Chl-a 단기예측 모델 통계값

기법	통계값	3일후 예측		5일후 예측		7일후 예측	
		학습	검증	학습	검증	학습	검증
Random Forest	R^2	0.91	0.75	0.90	0.77	0.90	0.71
	RMSE (mg/m^3)	7.8	12.4	5.9	8.8	5.9	9.7
XGBoost	R^2	0.93	0.78	0.99	0.98	0.99	0.99
	RMSE (mg/m^3)	6.4	12.1	1.3	2.6	1.2	2.2
CNN-RF*	R^2	0.96	0.70	0.97	0.70	0.95	0.62
	RMSE (mg/m^3)	5.0	13.5	3.6	9.9	4.1	10.8

* CNN-RF : Convolutional neural network 및 RandomForest 연계적용

<표 3.38> 대청댐 AEM3D 모의값 기반 Chl-a 단기예측 모델 통계값

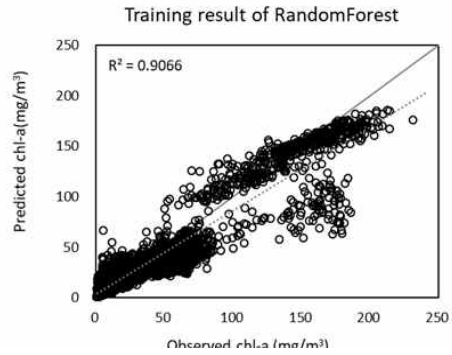
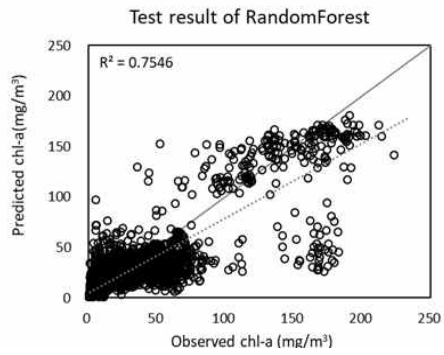
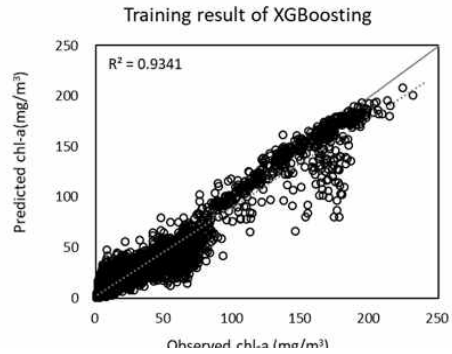
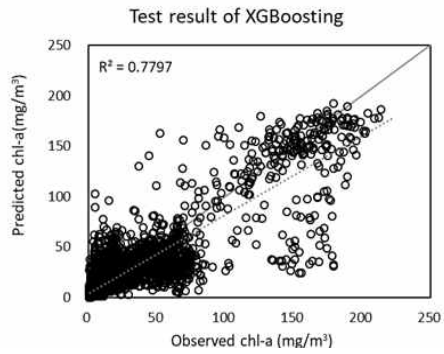
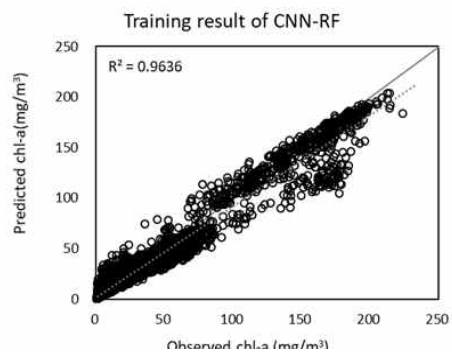
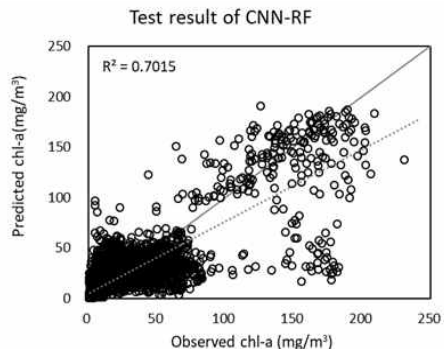
기법	통계값	3일후 예측		5일후 예측		7일후 예측	
		학습	검증	학습	검증	학습	검증
Random Forest	R^2	0.82	0.30	0.84	0.54	0.86	0.49
	RMSE (mg/m^3)	7.9	14.3	5.9	8.8	5.9	10.0
XGBoost	R^2	0.24	0.26	0.99	0.98	0.99	0.99
	RMSE (mg/m^3)	15.4	14.7	1.1	2.0	0.9	1.5
CNN-RF*	R^2	0.94	0.39	0.94	0.45	0.94	0.38
	RMSE (mg/m^3)	15.4	14.7	3.6	9.6	4.0	10.3

* CNN-RF : Convolutional neural network 및 RandomForest 연계적용

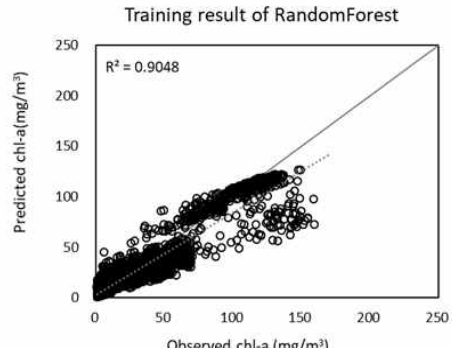
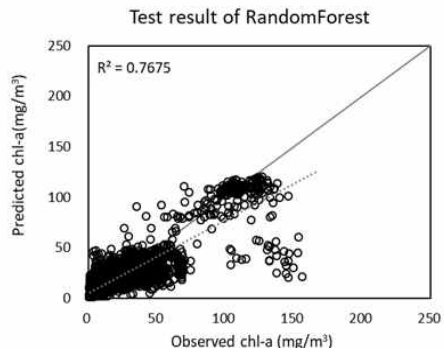
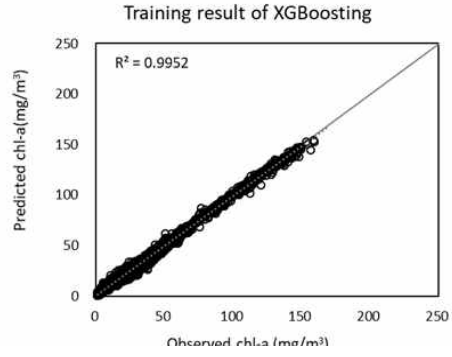
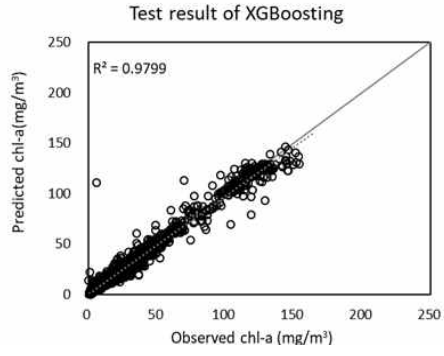
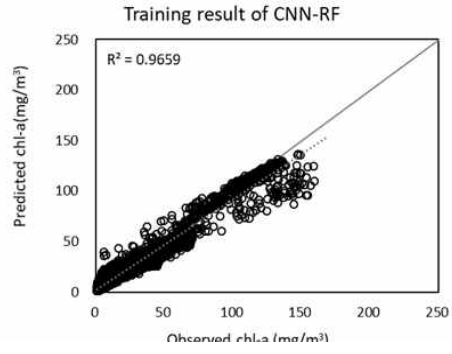
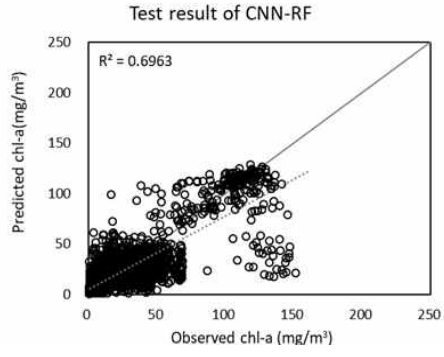
<표 3.39> 영주댐 AEM3D 모의값 기반 Chl-a 단기예측 모델 통계값

기법	통계값	3일후 예측		5일후 예측		7일후 예측	
		학습	검증	학습	검증	학습	검증
Random Forest	R^2	0.97	0.94	0.98	0.94	0.98	0.92
	RMSE (mg/m^3)	8.6	13.0	5.5	9.3	5.1	9.4
XGBoost	R^2	0.90	0.86	0.91	0.90	0.87	0.80
	RMSE (mg/m^3)	17.2	20.4	11.2	12.2	11.9	14.9
CNN-RF*	R^2	0.99	0.92	0.99	0.92	0.99	0.91
	RMSE (mg/m^3)	5.8	15.1	3.8	9.9	3.6	9.6

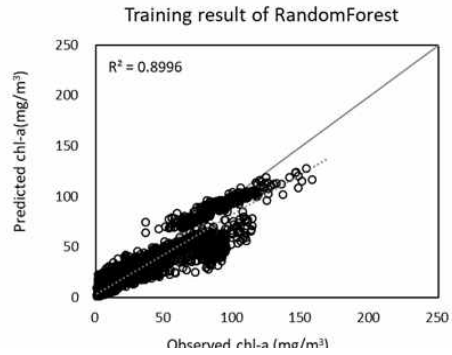
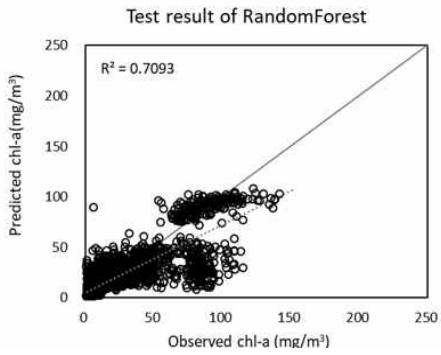
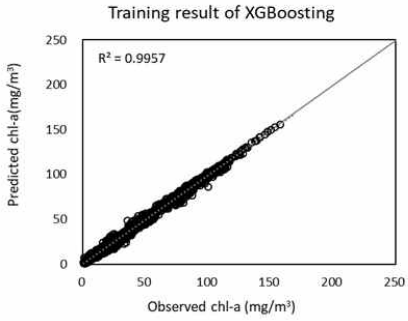
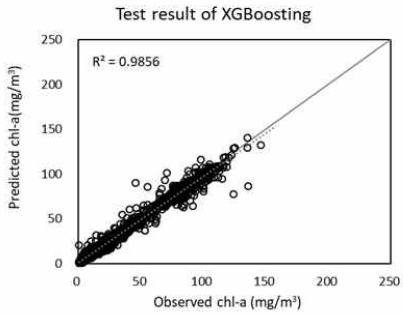
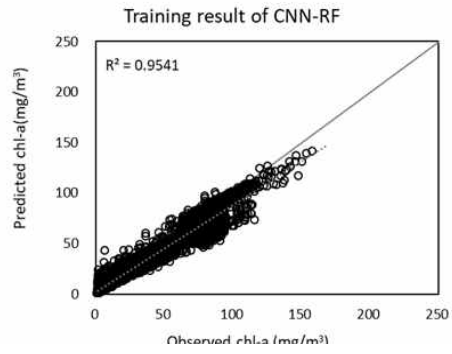
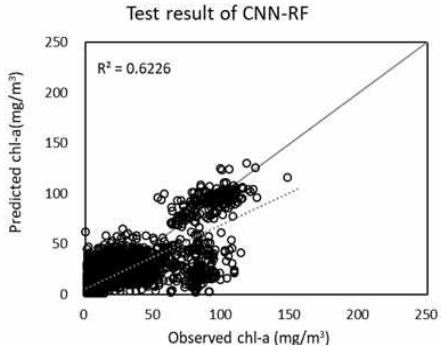
* CNN-RF : Convolutional neural network 및 RandomForest 연계적용

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

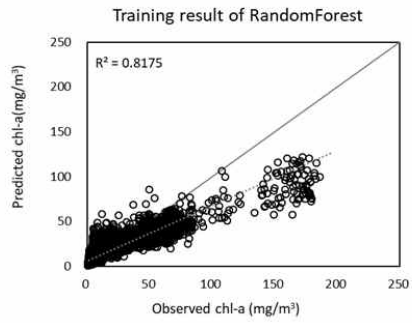
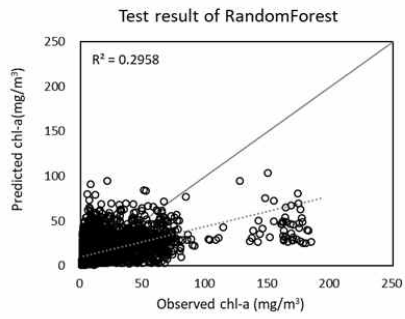
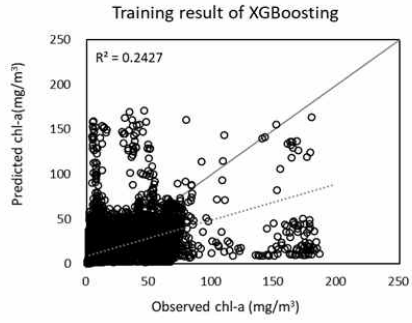
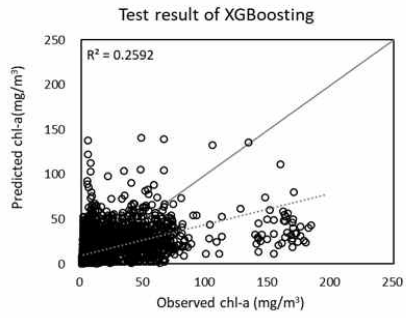
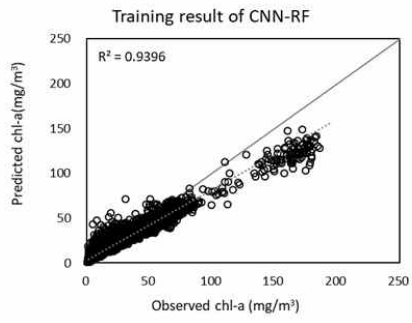
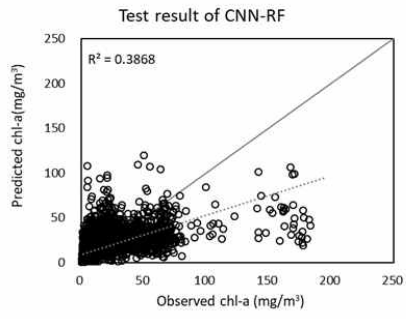
<그림 3.44> 대청·영주댐 AEM3D 모의값 기반 Chl-a 단기예측(3일 후) 알고리즘 학습 및 검증결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

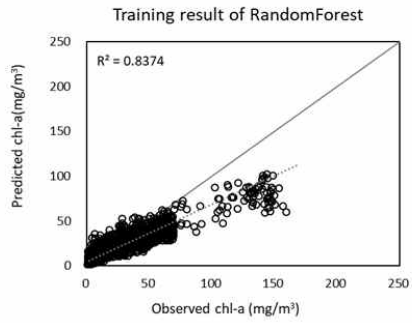
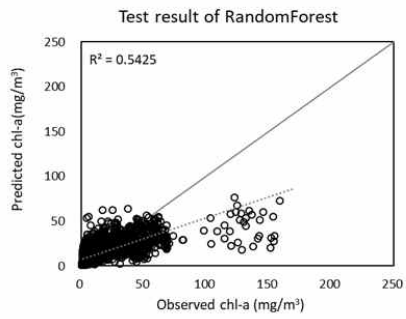
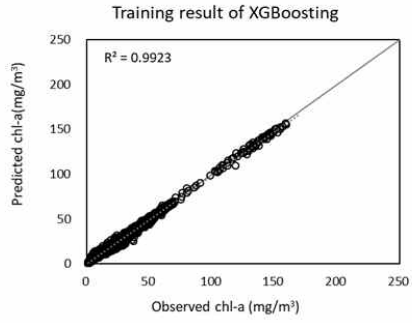
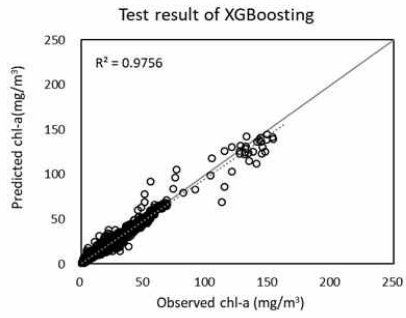
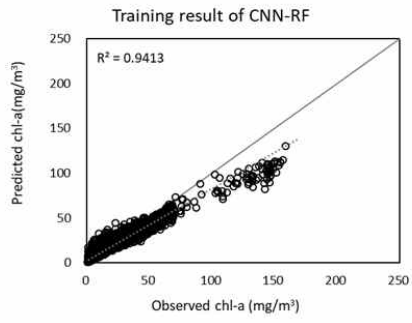
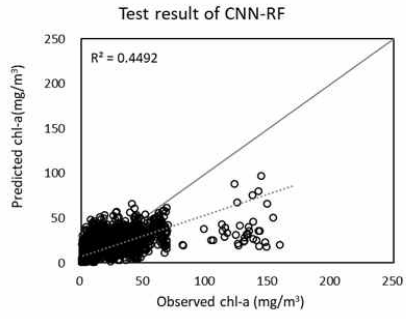
<그림 3.45> 대청·영주댐 AEM3D 모의값 기반 Chl-a 단기예측(5일 후) 알고리즘 학습 및 검증결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

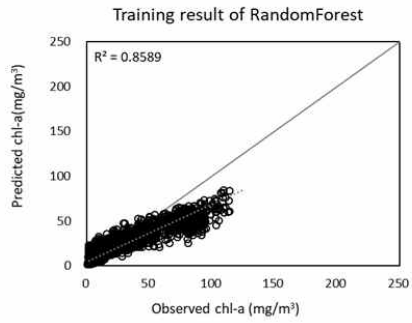
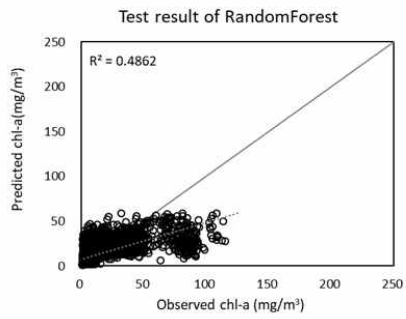
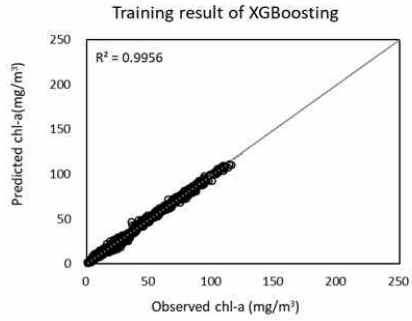
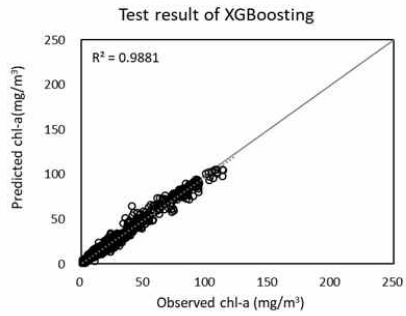
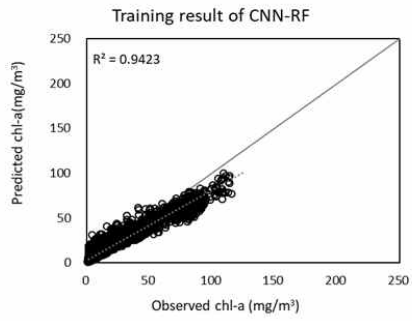
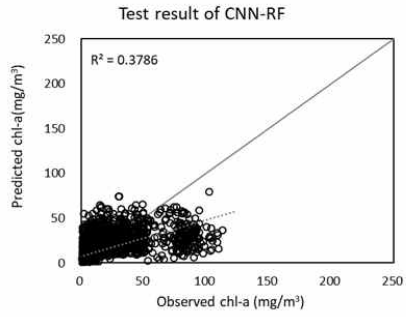
<그림 3.46> 대청·영주댐 AEM3D 모의값 기반 Chl-a 단기예측(7일 후) 알고리즘 학습 및 검증결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

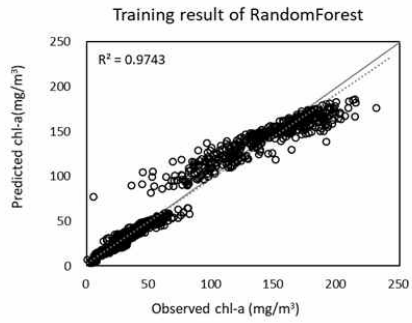
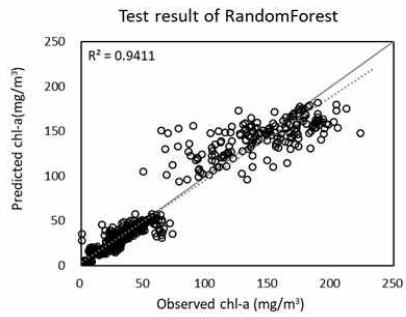
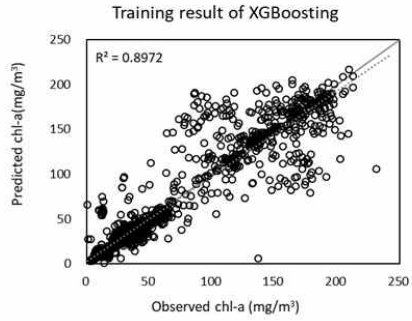
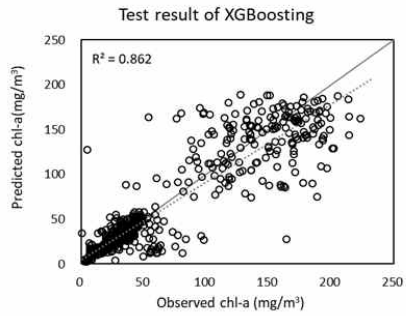
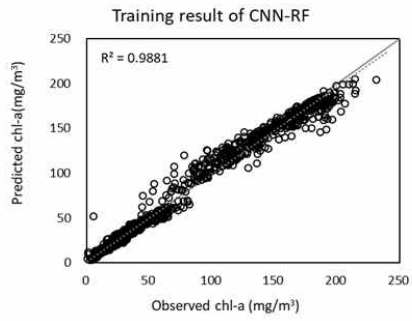
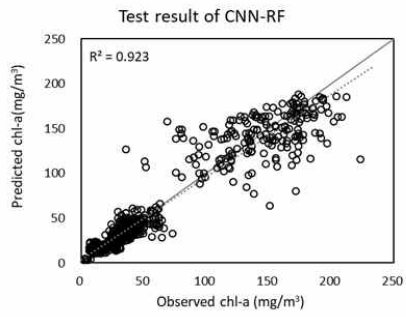
<그림 3.47> 대청댐 AEM3D 모의값 기반 Chl-a 단기예측(3일 후) 알고리즘 학습 및 검증 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

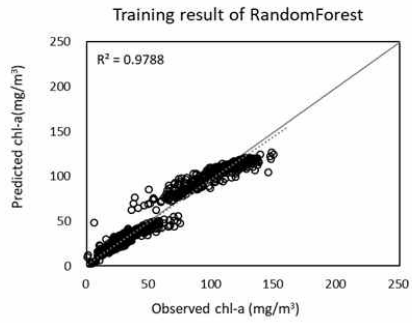
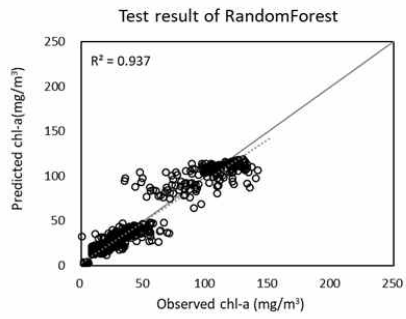
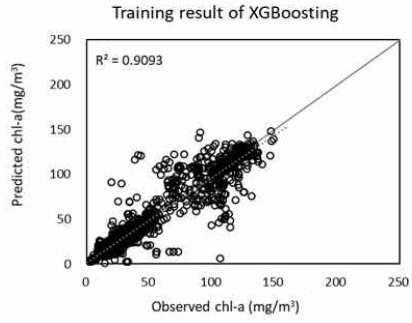
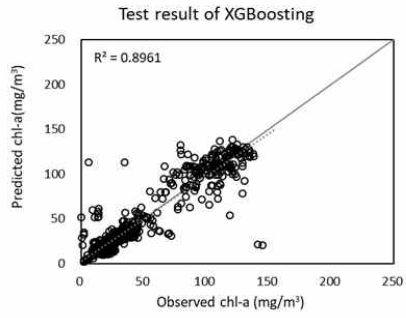
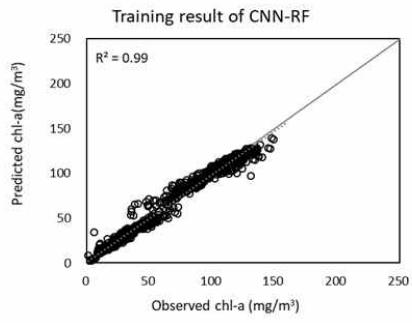
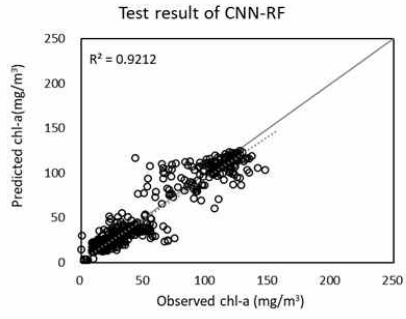
<그림 3.48> 대청댐 AEM3D 모의값 기반 Chl-a 단기예측(5일 후) 알고리즘 학습 및 검증 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

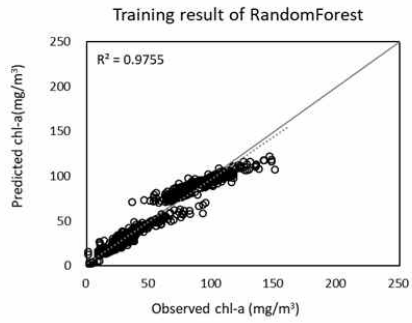
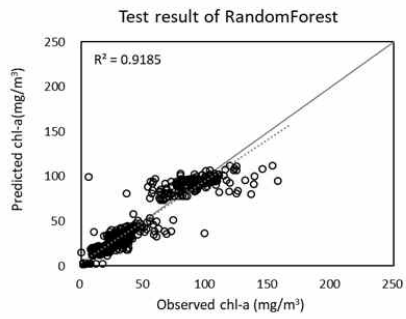
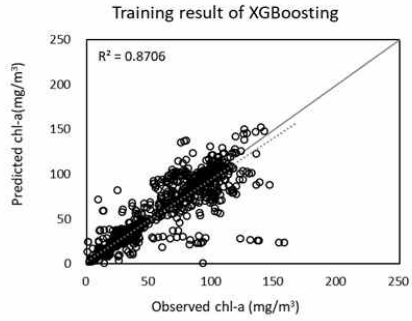
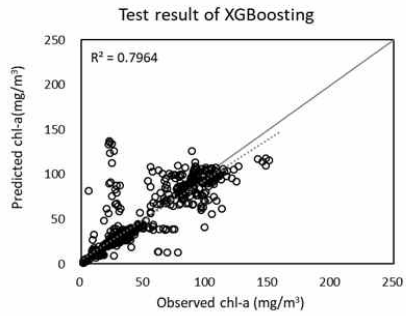
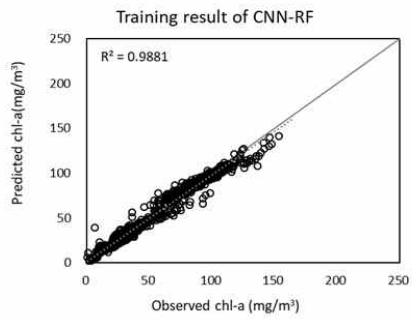
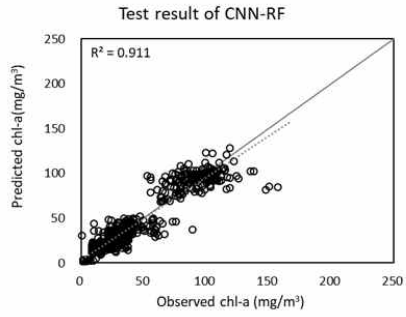
<그림 3.49> 대청댐 AEM3D 모의값 기반 Chl-a 단기예측(7일 후) 알고리즘 학습 및 검증 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

<그림 3.50> 영주댐 AEM3D 모의값 기반 Chl-a 단기예측(3일 후) 알고리즘 학습 및 검증 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

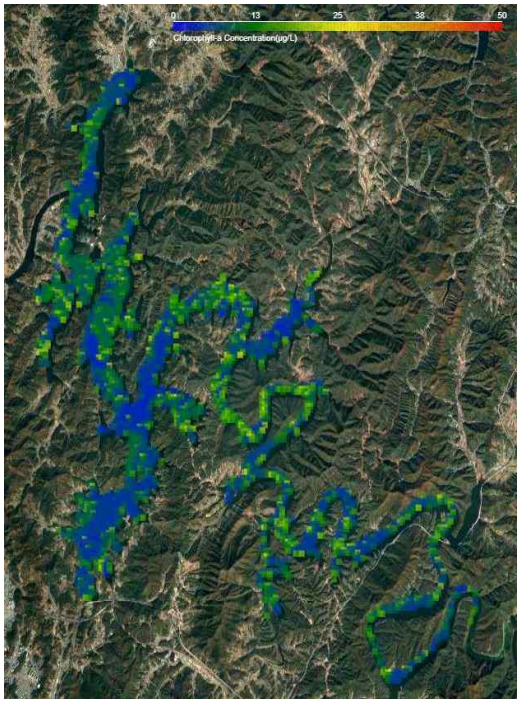
<그림 3.51> 영주댐 AEM3D 모의값 기반 Chl-a 단기예측(5일 후) 알고리즘 학습 및 검증 결과

기법	학습결과	검증 결과
Random Forest		
XGBoost		
CNN-RF		

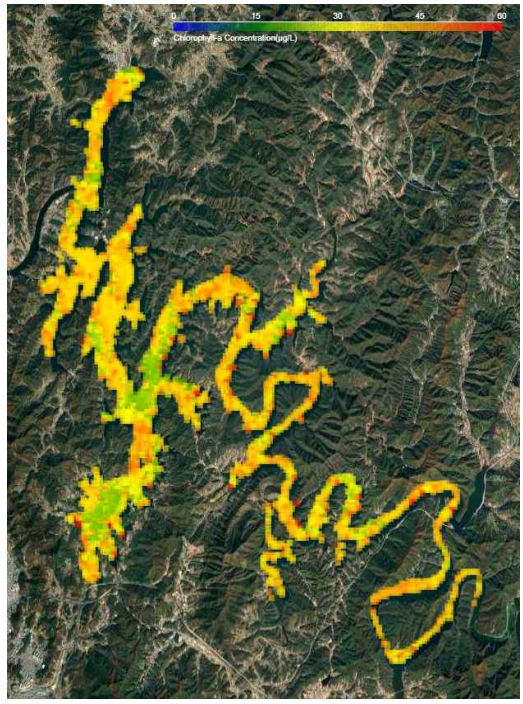
<그림 3.52> 영주댐 AEM3D 모의값 기반 Chl-a 단기예측(7일 후) 알고리즘 학습 및 검증 결과

<표 3.40> AEM3D 모의값 기반 Chl-a 단기예측 2024년 추정값과 관측값(XGBoost)

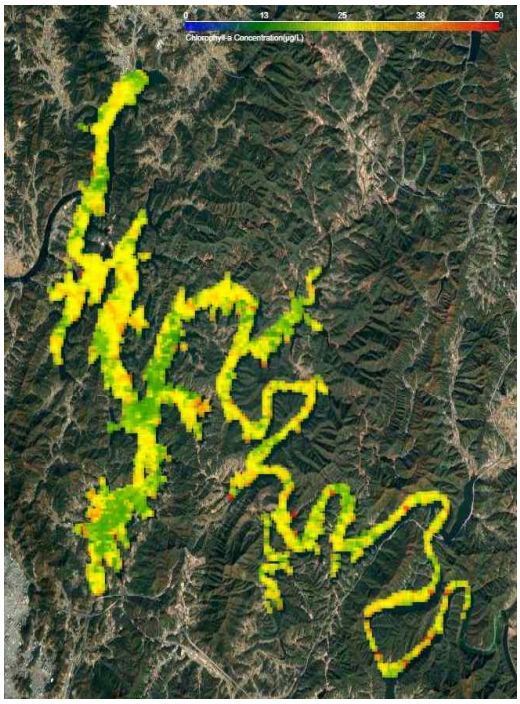
지점	예측기간	날짜	지점	Chl-a (mg/m^3)	
				추정값	관측값
영주댐	3일후 예측	2024/05/16	ST1	10.8	2.7
			ST2	10.0	4.5
			ST3	10.9	15.5
			ST4	16.4	27.4
			ST5	18.7	37.4
			ST6	-	35.0
	5일후 예측	2024/06/17	ST1	7.9	0.5
			ST2	4.0	0.8
			ST3	5.8	7.9
			ST4	13.8	21.4
			ST5	16.3	41.6
			ST6	-	8.5
	7일후 예측	2024/08/26	ST1	29.5	66.7
			ST2	33.7	83.0
			ST3	23.7	80.5
			ST4	23.2	117.9
			ST5	36.7	237.3
			ST6	-	27.6



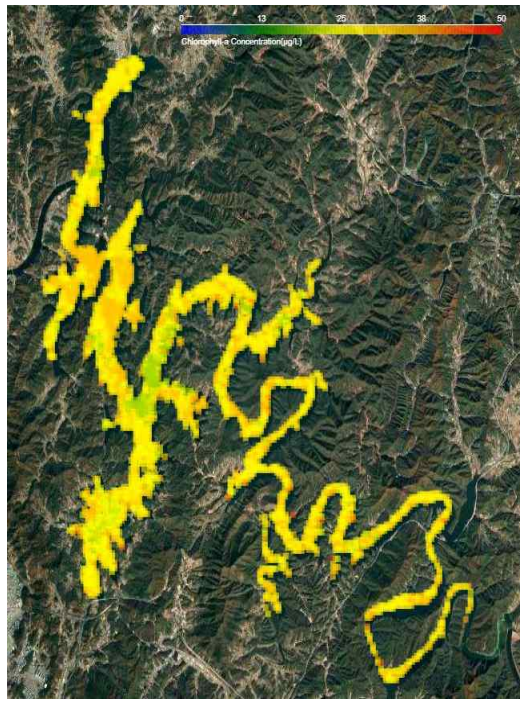
(a) 2024/05/31 (현재 상태)



(b) 2024/06/03 (3일후 예측)

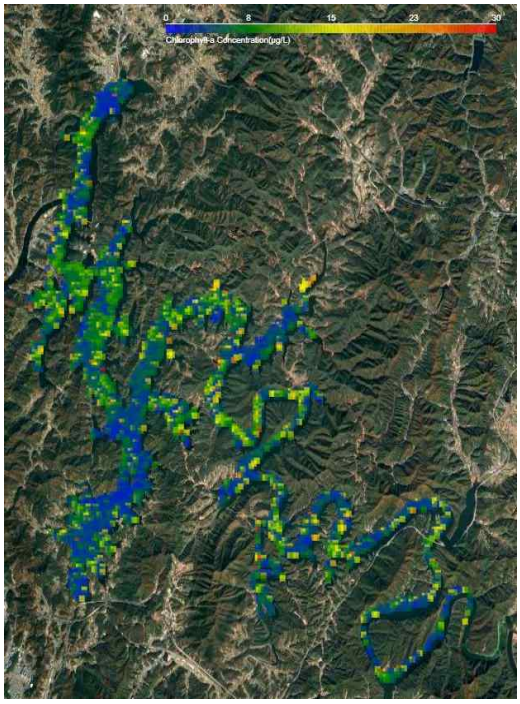


(c) 2024/06/05 (5일후 예측)

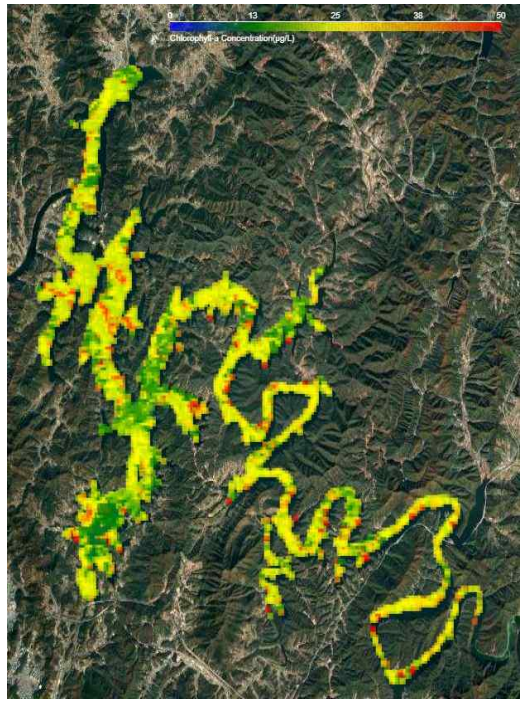


(d) 2024/06/07 (7일후 예측)

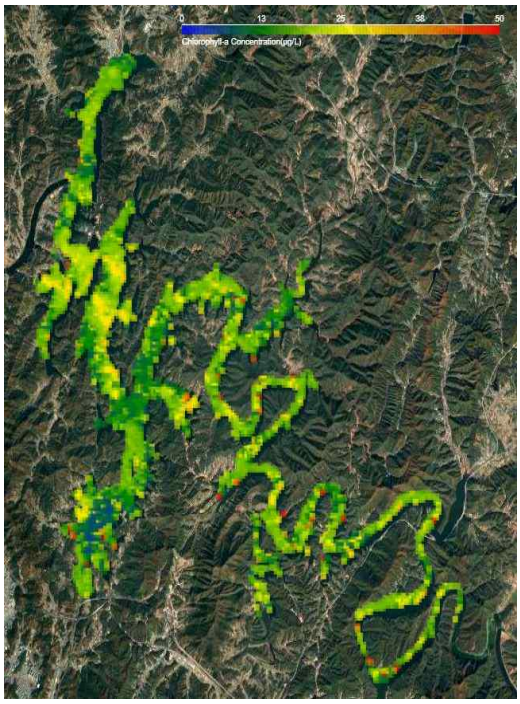
<그림 3.53> 대청댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(RandomForest)



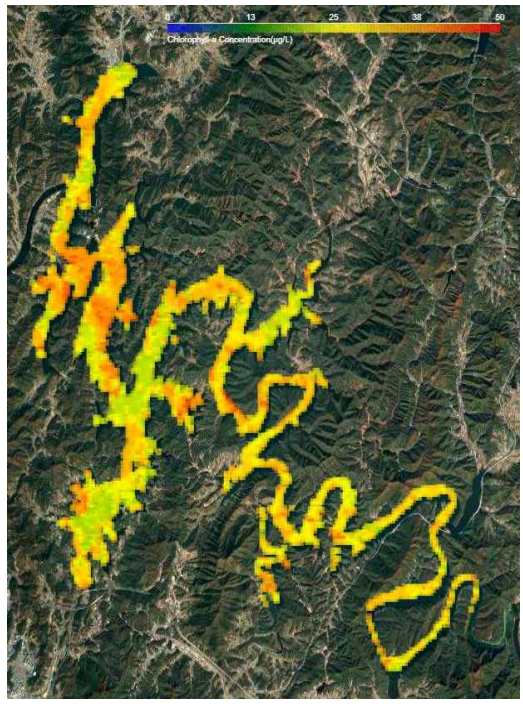
(a) 2024/05/31 (현재 상태)



(b) 2024/06/03 (3일후 예측)

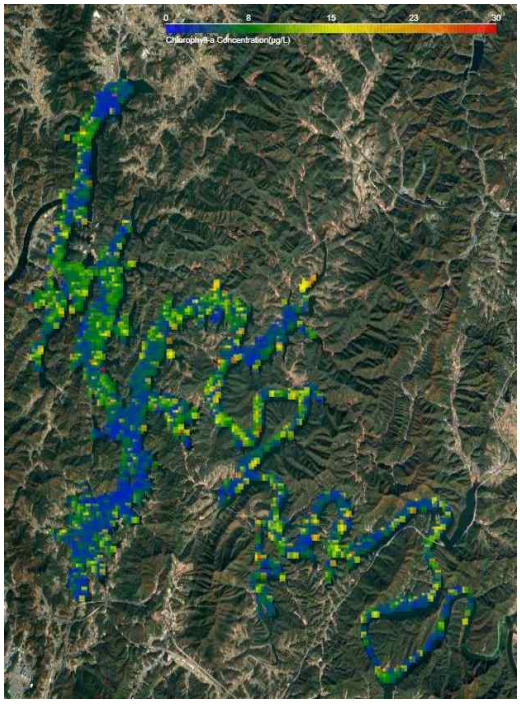


(c) 2024/06/05 (5일후 예측)



(d) 2024/06/07 (7일후 예측)

<그림 3.54> 대청댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(XGBoost)



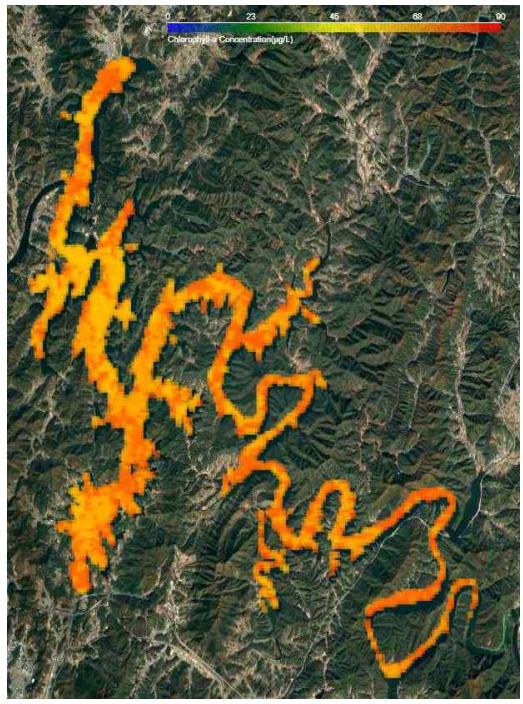
(a) 2024/05/31 (현재 상태)



(b) 2024/06/03 (3일후 예측)

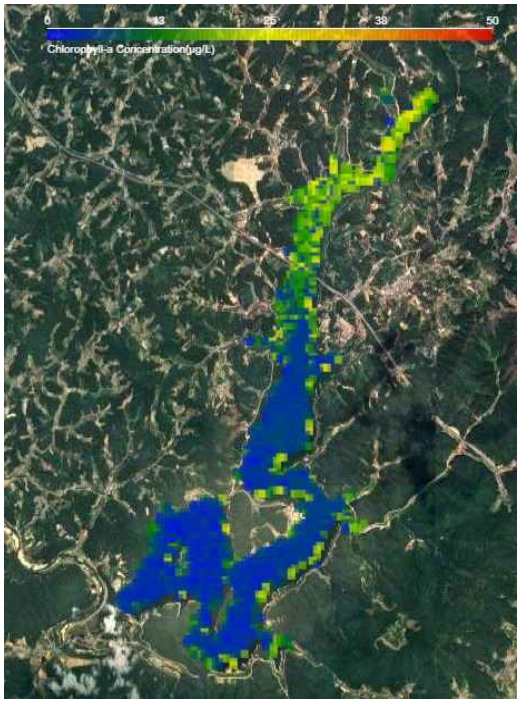


(c) 2024/06/05 (5일후 예측)

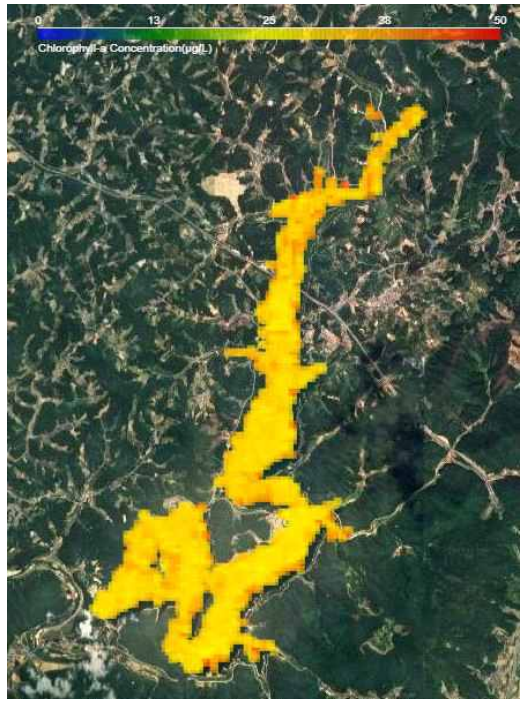


(d) 2024/06/07 (7일후 예측)

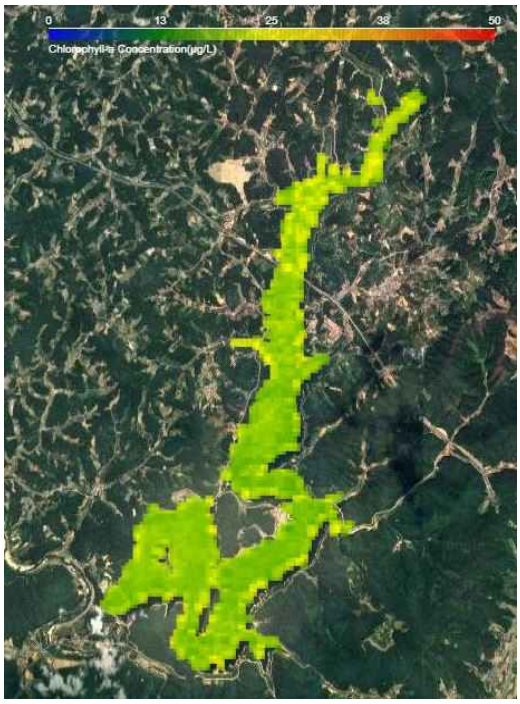
<그림 3.55> 대청댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(CNN-RF)



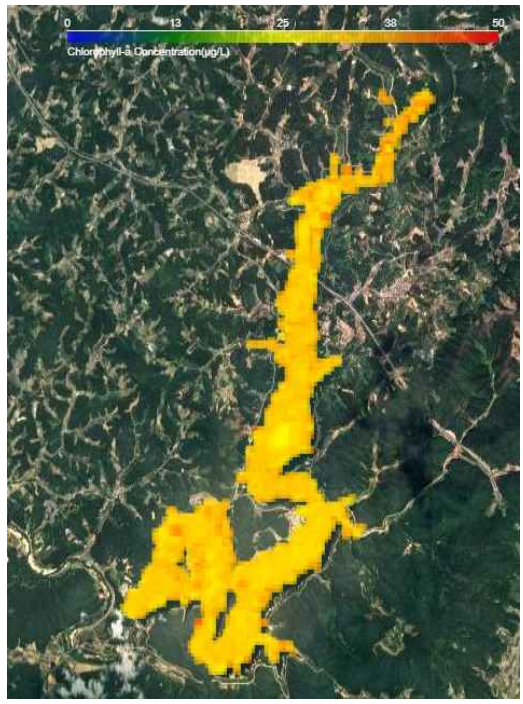
(a) 2024/05/13 (현재 상태)



(b) 2024/05/16 (3일후 예측)

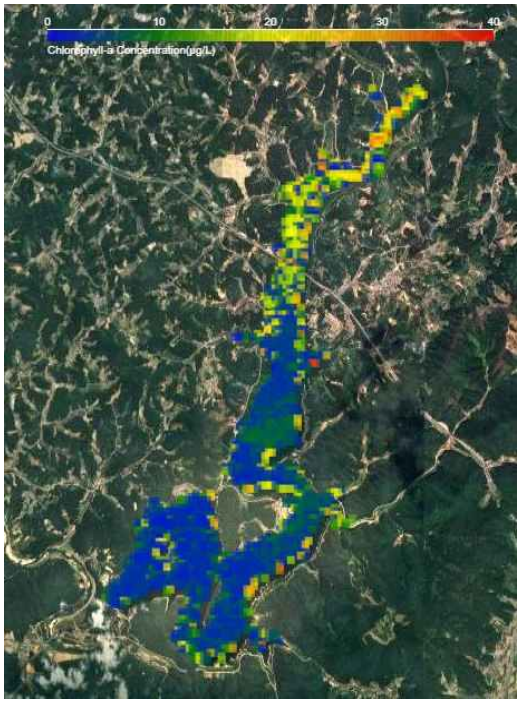


(c) 2024/05/18 (5일후 예측)

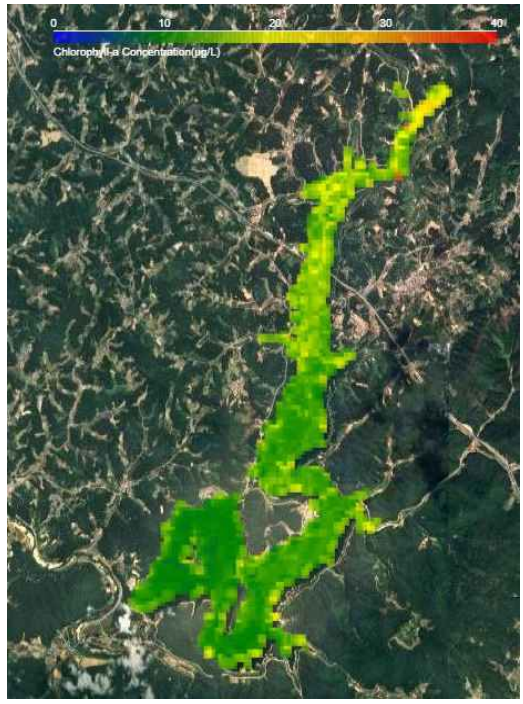


(d) 2024/05/20 (7일후 예측)

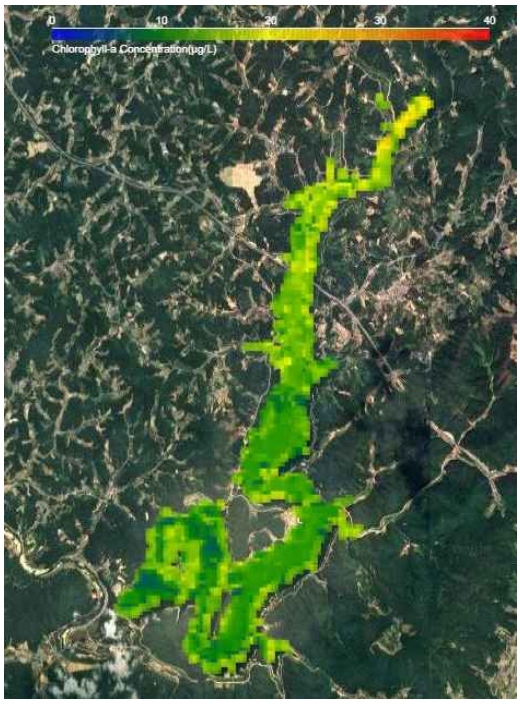
<그림 3.56> 영주댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(RandomForest)



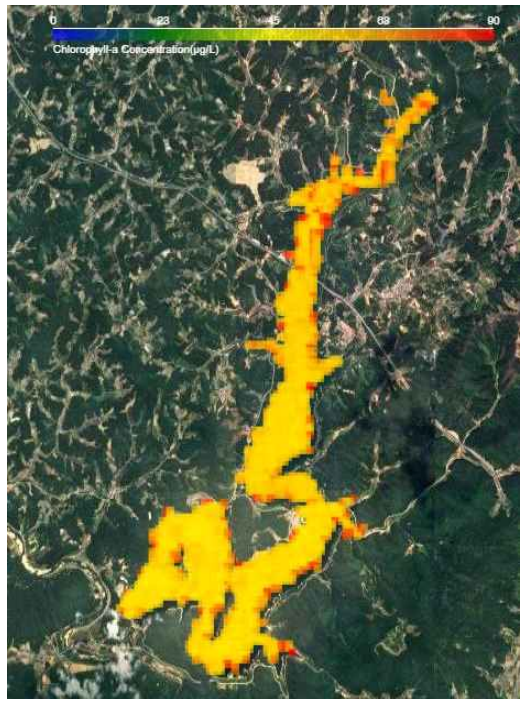
(a) 2024/05/13 (현재 상태)



(b) 2024/05/16 (3일후 예측)

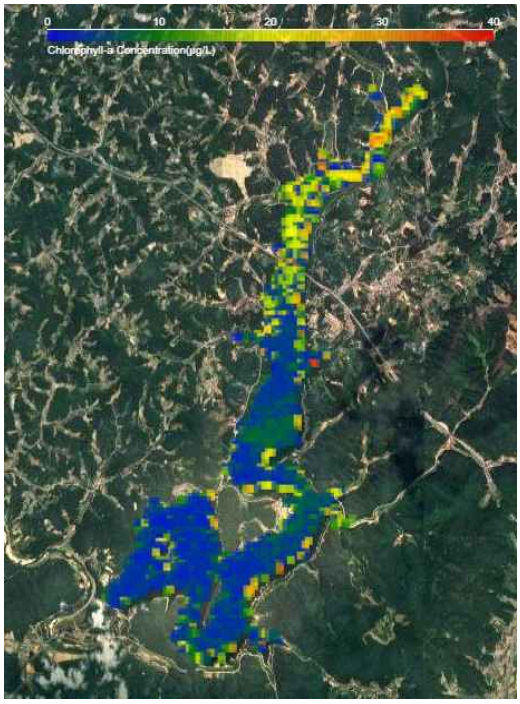


(c) 2024/05/18 (5일후 예측)

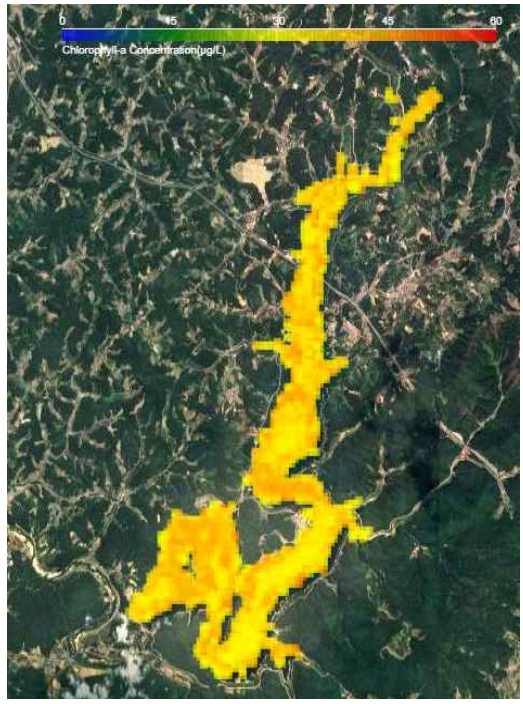


(d) 2024/05/20 (7일후 예측)

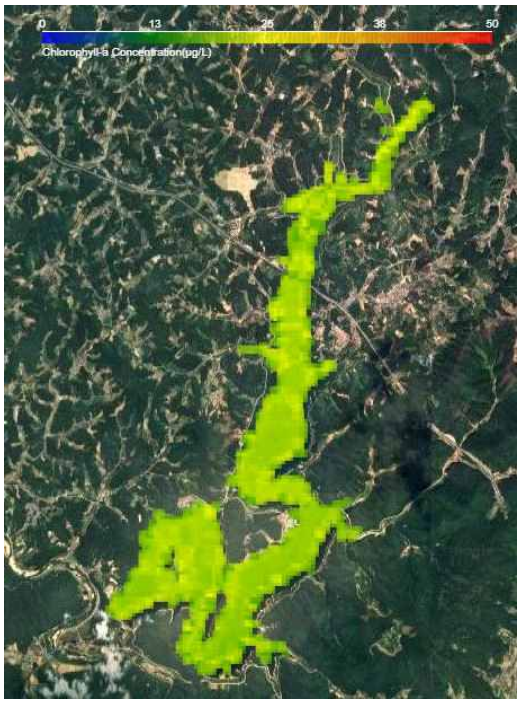
<그림 3.57> 영주댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(XGBoost)



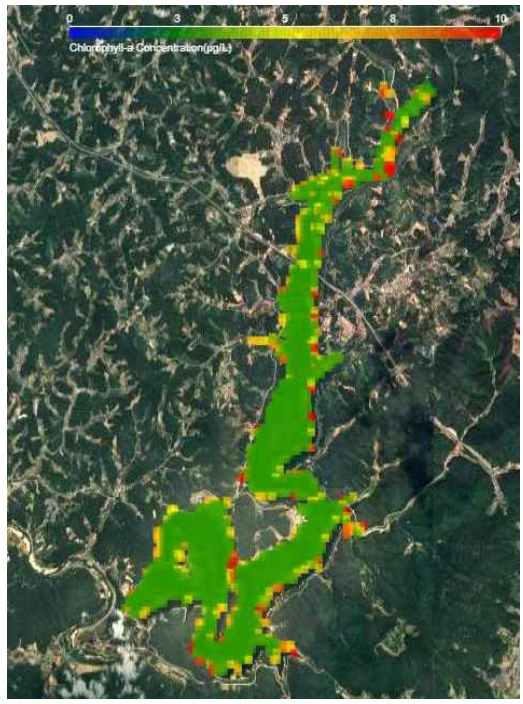
(a) 2024/05/13 (현재 상태)



(b) 2024/05/16 (3일후 예측)



(c) 2024/05/18 (5일후 예측)



(d) 2024/05/20 (7일후 예측)

<그림 3.58> 영주댐 합성데이터 기반 Chl-a 단기예측 알고리즘 적용결과(CNN-RF)

3.5 사전 녹조관리 의사결정 프로세스

3.5.1 공간적 녹조발생 및 단기예측결과 시각화 S/W 개발

파이썬을 활용하여 위성영상 반사도값, 기온 및 유입량 변화에 따른 3, 5, 7일 후 Chl-a 예측후 시각화 코드를 작성하여 녹조 관리부서에 활용할 수 있도록 하였다. Streamlit 코드를 활용하여 개발한 모델을 활용하여 구글맵에 생성 지도를 표출하고 데이터와 시각화 지도를 저장할 수 있도록 하였다. 위성영상 기반 댐저수지 Chl-a 혹은 세포수 공간적 분포를 시각화 하기 위한 과정은 다음과 같다. 우선, Visual Studio Code(VS Code)에서 개발한 모델 중에서 현재 녹조발생 농도를 추정하는 모델, 3일 후 예측 모델, 5일 후 예측모델 및 7일 후 예측 모델 중에서 필요한 모델을 로드할 수 있도록 수정하고, 대화형 웹 애플리케이션을 빠르게 만들 수 있도록 돕는 오픈소스 라이브러리인 streamlit을 실행한다. 이 때, 현재 녹조발생 상태를 추정하는 목적인지 단기 예측하는 목적인지에 따라 적용 모델을 사용자가 수정하고 파이썬 코드를 실행해야 한다. 이 때, 개발된 모델은 다음 표에 나타내었다.

Heatmap_Folium_Chla.py > ...

적용 모델 선택

```
19
20  if uploaded_file is not None:
21      try:
22          # RandomForest 모델 로드
23          rf_model = joblib.load('best_Chla_0day_rf_model.pkl')
24          #xgb_model = joblib.load('best_dc17yjz1_5day_XGB_model(AEM3D).pkl')
25
26          # 엑셀 파일 읽기
27          xls = pd.ExcelFile(uploaded_file, engine='openpyxl')
28          sheet_names = xls.sheet_names
29
30          # 사용자가 sheet를 선택할 수 있도록 selectbox 제공
31          sheet_name = st.selectbox("시트를 선택하세요", sheet_names)
32
33          # 선택한 sheet 데이터 읽기
34          data = pd.read_excel(uploaded_file, sheet_name=sheet_name)
35
36          # Chl-a 데이터 확인 및 히트맵 생성
37          if {'latitude', 'longitude'}.issubset(data.columns):
38              input_features = data.iloc[:, 2:23] # 4번째부터 23번째 열까지 선택
39              #input_features = data.iloc[:, 2:27] # 4번째부터 27번째 열까지 선택
40              #input_features = data.iloc[:, 2:31] # 4번째부터 31번째 열까지 선택
41              x = input_features
42              #x = input_features.values
43
44              # 예측 수행
45              data['Chl_a_predicted'] = rf_model.predict(x)
46              #data['Chl_a_predicted'] = xgb_model.predict(x)
47
48              output_data = data[['latitude','longitude','Chl_a_predicted']]
49
50              heat_data = output_data[['latitude','longitude','Chl_a_predicted']].values.tolist()
51
```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

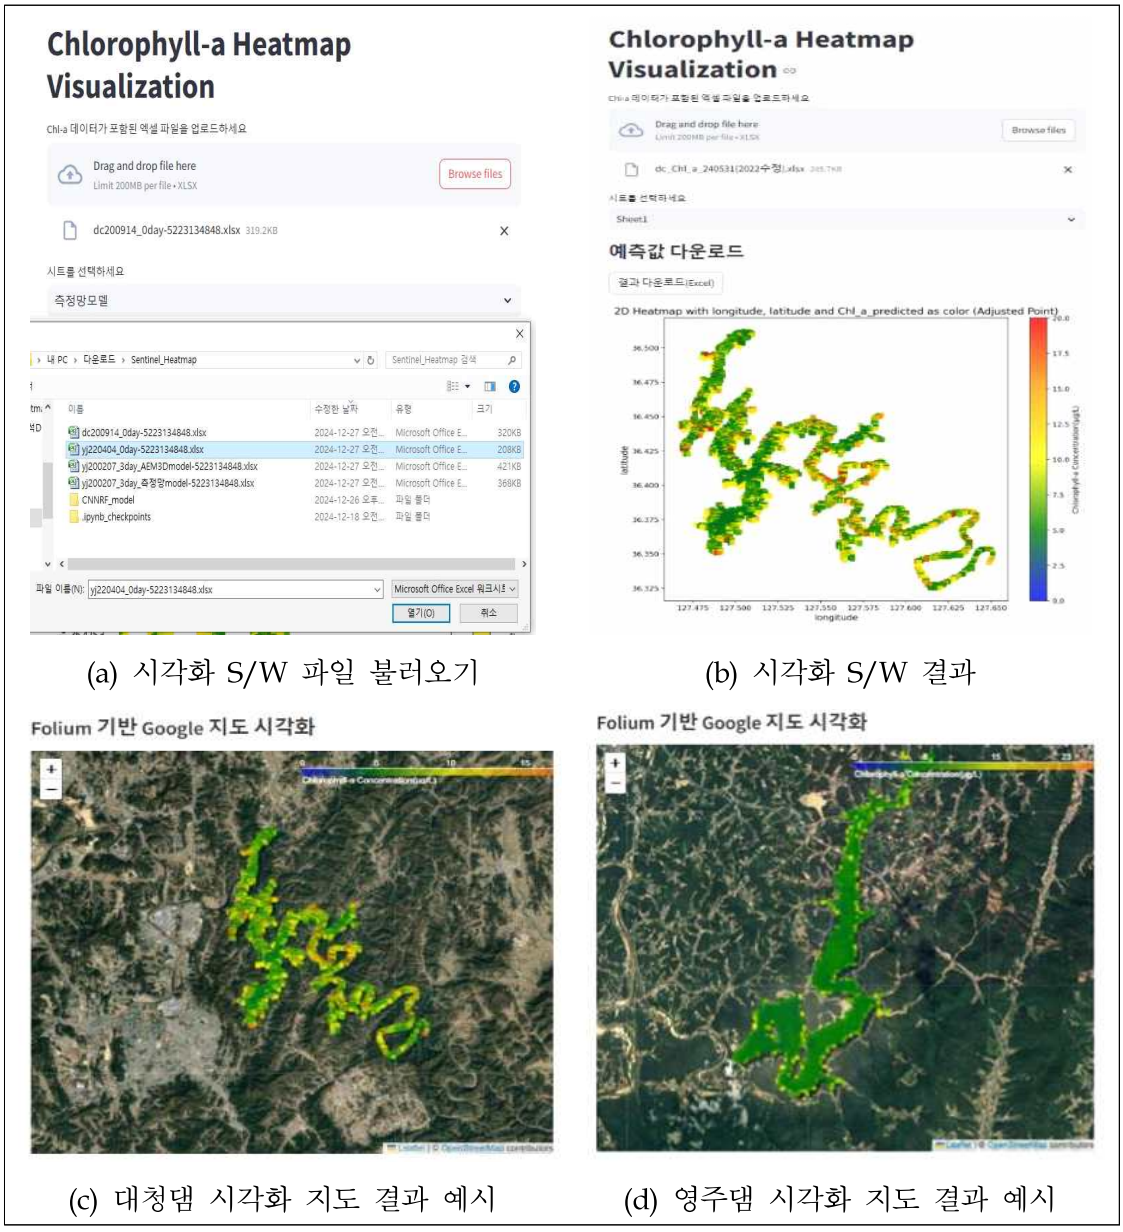
```
Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.

PS C:\Users\kwater\Downloads\Sentinel_Heatmap> streamlit run .\Heatmap_Folium_Chla.py

  You can now view your Streamlit app in your browser.
```

<그림 3.59> 위성영상-기상-수문 연계 Chl-a 공간적 단기 예측 시각화코드

이후에, 시각화를 위한 화면이 나타나면 사용자가 원하는 댐 저수지에 대한 입력 자료를 선택하면 예측결과 및 위경도별 공간적 녹조발생을 시각화 하여 지도를 표출하게 된다. 예측 결과를 시각화 파일 뿐만 아니라 데이터로 저장할 수 있어 사용자가 데이터 분석에도 활용할 수 있도록 하였다. 개발한 코드를 활용하여 대청댐 및 영주댐 단기 예측 시각화 결과 예시를 나타내었다. 이와 같이 streamlit을 활용하여 웹 애플리케이션을 개발하여 활용하게 되면 별도의 애플리케이션 개발을 하지 않고도 사용자가 원하는 데이터 시각화가 가능하고 대시보드 등을 손쉽게 수정할 수 있는 장점이 있다. 또한, 로컬 및 클라우드 플랫폼에 배포하여 공유가 가능하다.



(a) 시각화 S/W 파일 불러오기 (b) 시각화 S/W 결과

(c) 대청댐 시각화 지도 결과 예시 (d) 영주댐 시각화 지도 결과 예시

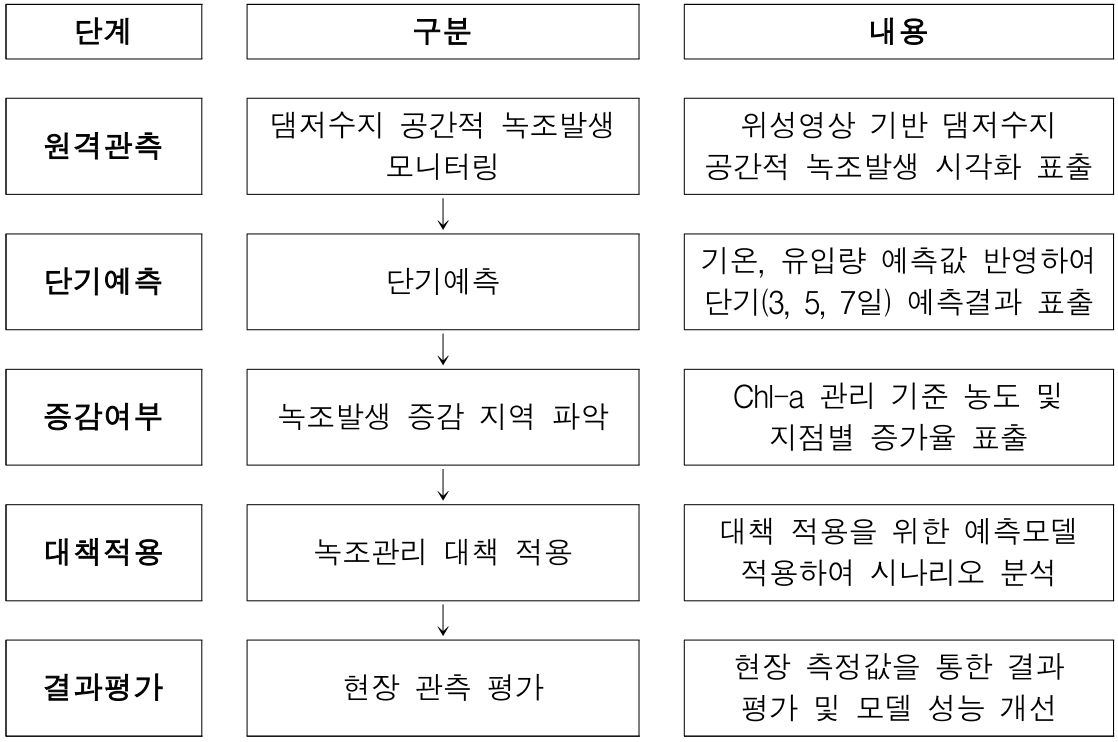
<그림 3.60> 위성영상-기상-수문 연계 Chl-a 공간적 단기 예측 시각화 S/W 화면

<표 3.41> 위성영상-기상-수문 연계 단기예측을 위한 개발모델 현황

구분	모델명	기법 및 입력자료
측정망 데이터 활용 개발 모델	best_Chla_0day_rf_model.pkl best_Chla_3day_rf_model.pkl best_Chla_5day_rf_model.pkl best_Chla_7day_rf_model.pkl	- 기법: 랜덤포레스트 - 출력 : Chl-a - 입력 : Sentinel-2 밴드 4~7의 반사도값, 파생변수[1], 기온 1) 밴드5 - (밴드4 + 밴드6)/2
AEM3D 합성데이터 활용 개발 모델	dcyj_3day_CNN_RF.h5 dcyj_3day_CNN_RF.pkl dcyj_5day_CNN_RF.h5 dcyj_5day_CNN_RF.pkl dcyj_7day_CNN_RF.h5 dcyj_7day_CNN_RF.pkl yj21_3day_CNN_RF.h5 yj21_3day_CNN_RF.pkl yj21_5day_CNN_RF.h5 yj21_5day_CNN_RF.pkl yj21_7day_CNN_RF.h5 yj21_7day_CNN_RF.pkl	- 기법 : CNN-RF(랜덤포레스트) - 출력 : Chl-a - 입력 : Sentinel-2 밴드 1~12의 반사도값, 기온, 유입량 - 3day : 3일 후 예측 - 5day : 5일 후 예측 - 7day : 7일 후 예측
	best_dc17yj21_3day_rf_model(AEM3D).pkl best_dc17yj21_3day_XGB_model(AEM3D).pkl best_dc17yj21_5day_rf_model(AEM3D).pkl best_dc17yj21_5day_XGB_model(AEM3D).pkl best_dc17yj21_7day_rf_model(AEM3D).pkl best_dc17yj21_7day_XGB_model(AEM3D).pkl	- 기법 : 랜덤포레스트, XGBoost - 출력 : Chl-a - 입력 : Sentinel-2 밴드 1~12의 반사도값, 기온, 유입량 - 3day : 3일 후 예측 - 5day : 5일 후 예측 - 7day : 7일 후 예측

3.5.2 녹조관리 프로세스

위성영상 관측일 댐저수지 공간적 녹조발생을 공간적으로 시각화하여 표출함으로써 녹조 관리자에게 사전정보를 제공할 수 있다. 또한, 단기 예측을 통한 녹조발생 정보를 제공하고 녹조발생 증감지역을 시각화 및 정량화하여 제시함으로써 사전 녹조관리를 위한 방안 수립의 의사결정에 활용할 수 있도록 해야할 것이다. 본 연구에서 개발한 알고리즘은 물환경분야 디지털 트윈 요소기술로 활용가능하며 현장 관측값은 모델 개선에 지속적으로 활용하여 성능을 개선하는데 활용이 가능하다. 이와 같은 프로그램을 활용한 녹조관리 프로세스에 대한 과정을 다음과 같이 제한하였다. 우선, 위성영상 기반 물환경(수질, 녹조) 관리 댐 저수지의 공간적 녹조발생 시각화 지도를 표출하여 현재 녹조발생 현황을 확인한다. 이 때, 현재의 녹조발생 현황 뿐만 아니라 기온, 유입량 예측값 반영하여 단기(3, 5, 7일) 예측결과를 제공한다. 단기 예측 결과를 활용하여 녹조발생 농도의 증감 지역을 시각적 그리고 정량적으로 파악하여 대책 적용이 필요한 지역을 선정하는데 활용할 수 있다.



<그림 3.61> 공간적 단기 예측 시각화 S/W를 활용한 녹조관리 프로세스

3.5.3 단기 대책방안 검토

녹조현상(남조류)은 태양광, 수온, 영양염류, 체류시간 등 여러 환경요인이 복합적으로 작용해 발생한다. 태양광은 조류 성장에 가장 기본적인 요소이지만 제한요소는 아니며, 수온은 조류 종류별 최적 온도가 다르며, 계절별 천이과정이 나타나 늦가을~초봄(<10 ℃)에는 규조류가 우점하고 봄~초여름(<10~20 ℃)에는 규조류 및 녹조류가 우점, 여름~초가을(>20 ℃)에는 남조류가 우점한다. 영양염류의 경우에는 영양염류가 많은 부영양상태 수체에서 남조류 출현하는데, 일반적으로 하천, 호수 등 담수에서는 조류성장의 제한 영양염류는 인(P)이며 다른 연구에서는 국내 호소는 질소/인 비 16이상인 경우 남조류 우점 가능성 높다고 나타나기도 하였다(국립환경과학원, 2014). 이와 같은 조건으로 녹조가 발생시 그간 댐 저수지 녹조 발생시 대책은 사전관리와 사후대응으로 구분할 수 있는데, 사전관리방안으로 하·폐수처리시설 총인 배출량 자발적 감축 유도, 장마철 전 축분, 쓰레기 등 비점오염원집중 관리, 하수도 시설 확충, 생태습지, 생태벨트, 비점오염원 저감사업 등 유역 오염원에 의한 영양염류 발생을 최소화 하는 방법이 수행되어 왔다. 사후대응으로는 조류제거선, 차단막, 녹조퇴치밭 등 녹조제거시설 운영, 수류확산장치, 물순환설비, 수면포기기 등 물순환 설비를 가동하여 확산 방지하는 방법 등이 있다(K-water, 2023).

<표 3.42> 주요 녹조대응 기술별 원리 및 효과

구분		작동원리 및 가동효과
물순환 설비	대류식	• 수표면 임펠러 회전으로 심층부 물을 유출하여 물을 순환
	산기식	• 심층부에 압축공기를 공급하여 상승류를 형성하고 물을 순환
	지하수	• 저온의 지하수 수면에 분사하여 수온상승 방지 및 녹조 발생 억제
횡방향 수류확산장치		• 교반기로 수면에 수류를 발생시켜 표층부에 집적된 녹조띠 희석·배제
수면포기기		• 수차의 회전력으로 수면에 수류 발생 및 수중 산소공급
나노버블		• 미세기포를 생성하고 수중에 주입하여 용존산소 공급 및 성층완화, 조류 흡착·교란 및 유기물 산화·분해
하천형수거설비		• 수면의 녹조를 흡입하여 육상부로 신속하게 배제(차량형) (흡입펌프, 스키머 및 탈수장치 구성)
수상녹조제거선		• 수면에 집적된 녹조를 수집·회수하여 수체 밖으로 배제(특수선박형)
에코로봇		• 무인자동운영이 가능 녹조 모니터링 및 제거(필터링) 장치
멀티녹조제거장치 (스키머 일체형)		• 녹조를 부상·농축하고 스키머로 회수하여 수체 밖으로 배제 (멀티녹조제거장치 - 마이크로버블, 확산교반기 복합구성)
조류차단막		• 댐 내 조류확산 방지(확산방지막) 및 취수탑 조류유입 차단(유입차단막)
녹조퇴치밭		• 녹조 우심지역에 차단막을 설치, 녹조 과성장 구간을 조성하고, 물속 영양염류를(인, 질소) 소비시키고 녹조를 과성장 시켜 제거

제 4 장 결 론

본 연구는 댐 저수지를 대상으로 위성영상 기반 공간적 녹조발생을 예측하여 의사결정에 활용할 수 있는 알고리즘을 개발하고자 수행되었다. 대청댐 및 영주댐을 대상으로 측정망 Chl-a 및 세포수를 공간적으로 원격 관측할 수 있는 알고리즘을 개발하고 정확도를 개선하였으며, Sentinel-2 위성영상과 기상 및 수문을 연계하여 단기 녹조 예측 프로그램을 개발하고자 하였다. 개발된 프로그램을 물환경분야 디지털 트윈 요소기술로 활용하는 것을 목표로 하였으며 연구수행을 통해 도출된 내용은 다음과 같다.

○ 대청댐 및 영주댐 저수지 클로로필-a 원격관측 알고리즘 정확도를 개선하고자 하였다. 모델 예측성능, 입렵변수 설명력, 과적합 방지 등을 고려하여 앙상블 기법(랜덤포레스트, XGBoost), 딥러닝(CNN), 합성데이터, 설명가능한AI(SHAP) 기법을 선정한 후에 수질측정망 관측일과 Sentinel-2 관측일을 매칭하여 구름 등 기상자료 고려하여 총 98개 데이터세트 구축하였다. 대청댐은 59개로 0.4～42.9 mg/m^3, 영주댐은 39개로 1.1～173.4 mg/m^3 범위를 데이터세트를 구축하였다. Sentinel-2 위성영상 밴드별 반사도값, 기온, 유입량, Chl-a 입력자료를 활용하여 독립변수 및 앙상블기법(랜덤포레스트, XGBoost) 성능 비교를 통한 최적 모델 도출한 결과, XGBoost기법보다 랜덤포레스트 기법 적용시 모델 성능 높게 분석되었다. 밴드 4～7 반사도값, 밴드조합 파생변수, 기온 활용한 랜덤포레스트 적용시 모델성능 가장 좋았으며 2024년 현장조사결과 활용 모델성능 검증시, 대청댐 및 영주댐 R 0.7이상으로 측정망 기반 Chl-a 추정모델 활용성을 확인하였다.

○ 세포수 원격관측 알고리즘 구축하기 위하여 측정망과 Sentinel-2 관측일을 매칭하여 총조류 및 남조류 세포수 추정 알고리즘 개발 하였다. 밴드 1～12의 반사도값, 기온을 입력자료로 활용하여 XGBoost 기법 적용시 총조류 및 남조류 추정 모델 성능 가장 좋은 것으로 분석되었으며 Chl-a 추정 모델보다는 세포수 추정 모델의 정확도가 낮게 나타났다. 총조류 세포수에 비해 남조류 세포수 추정 모델 성능이 25% 이상 높은 것으로 분석되어 위성영상기반 세포수 추정시 총조류보다는 남조류 파악 모델 성능이 더 높았다. 측정망 지점별로 추정값과 관측값을 비교한 결과, 대청댐은 관측값보다 과소평가되고 영주댐의 경우에는 다소 과대 평가경향이 나타나 세포수 원격 추정을 위해서 댐 저수지별 개별 모델개발이 필요한 것으로 판단되었다.

○ 위성영상-기상-수문연계 단기 녹조 예측 프로그램 개발하기 위하여 첫 번째로 측정망 기반 Chl-a 및 세포수 3, 5, 7일 예측을 위한 DB를 구축하였으며 입력변수 및 적용기법별로 모델 성능을 비교하여 최적 모델을 선정하였다. Sentinel-2 밴드 1~12 반사도값, 예측기간을 고려하여 일별 평균 기온, 일별 유입량을 활용한 경우에 모델 성능이 가장 좋게 분석되었다. Chl-a 단기 예측의 경우에는 랜덤포레스트 기법의 모델 성능이 가장 높았으며, 세포수 단기 예측의 경우에는 XGBoost 기법의 모델 성능이 가장 높은 것으로 분석되었다. Chl-a 단기 예측 최적 모델의 경우, 학습 및 검증 결과의 R^2와 RMSE 값은 각각 3일 후 예측모델은 0.77, 16.4 mg/m^3 및 0.79, 6.0 mg/m^3, 5일 후 예측모델은 0.76, 6.9 mg/m^3 및 0.76, 5.6 mg/m^3, 7일후 예측모델은 0.94, 5.4 mg/m^3 및 0.78 및 2.8 mg/m^3로 분석되었다. 세포수 예측 모델의 경우에는 위성영상 반사도값과 기온, 유입량, 수위 등의 입력자료를 활용하였을 때 모델 성능이 높아졌으며 총조류세포수의 3, 5, 7일 후 예측모델 검증 결과의 R2와 RMSE 값은 각각 0.79, 9,380 cells/mL 및 0.77, 5,146 cells/mL, 그리고 0.78, 22,428 cells/mL이었으며 남조류세포수의 3, 5, 7일 후 예측모델 검증 결과의 R2와 RMSE 값은 각각 0.89, 3,788 cells/mL 및 0.67, 2,807 cells/mL, 그리고 0.65, 19,371 cells/mL로 분석되었다.

○ 단기예측 기간별 모델 입력변수 상대적 중요도 분석하기 위하여 설명가능한 AI(SHAP 기법)을 활용하여 입력변수 기여율을 분석하였다. Chl-a 3일 후 단기 예측모델의 경우에는 위성영상 반사도값이 중요도가 높게 분석되었고, 5일 후 단기 예측모델의 경우에는 기온의 중요도가 높게 분석되었으며 7일 후 단기 예측모델의 경우에는 위성영상 반사도값, 기온, 유입량의 다양한 변수 중요도가 유사한 것으로 분석되었다. 반면에, 세포수 단기 예측의 경우에는 Chl-a 단기 예측 모델과 달리 위성영상 밴드별 반사도값을 조합한 파생변수의 중요도 크게 분석되었다.

○ 위성영상 기반으로 기상 및 수문을 연계한 단기예측 모델 정확도 개선을 위하여 3차원 모델(AEM3D)을 활용하였으며 대청댐 및 영주댐 저수지 모두 모델 지형 격자 셀의 크기는 100m×100m×1m (Δx×Δy×Δz)으로 구성하여 Chl-a 등 수질 모의 재현성을 검증한 후에, 표층 Chl-a의 합성데이터를 생성하였다. 대청댐 저수지는 2017년 6~10월, 영주댐 저수지는 202년 5~9월 대상으로 모의하여 월별로 Sentinel-2 관측일을 매칭하여 3일 후 단기 예측 모델개발을 위하여

32,314개 데이터세트, 5일 후 단기 예측 모델개발을 위하여 32,301개 데이터세트, 7일 후 단기 예측 모델개발을 위하여 32,300개 데이터세트를 구축하였다. 위성영상 밴드 1~12 반사도값, 예측기간 일별 평균 기온, 예측기간 일별 댐유입량을 입력변수로 활용하였으며 XGBoost 적용시 Chl-a 단기예측(3, 5, 7일) 모델 성능이 가장 높은 것으로 분석되었다. 댐저수지별 예측모델 개발시 영주댐의 경우, 랜덤포레스트, CNN-RF 기법 정확도 높아 타댐 확장시 개별 모델 개발이 필요할 것으로 판단되었다.

○ 위성영상 기반 공간적 녹조 단기예측결과 시각화를 위한 프로그램을 개발하여 사용자가 손쉽게 활용할 수 있도록 하였다. 대화형 웹 애플리케이션을 빠르게 만들 수 있도록 돕는 오픈소스 라이브러리인 streamlit을 활용하여 개발한 모델을 활용하여 구글맵에 생성 지도를 표출하고 데이터와 시각화 지도를 저장할 수 있도록 하였다. 사용자가 원하는 댐 저수지에 대한 입력자료를 선택하면 예측결과 및 위경도별 공간적 녹조발생을 시각화 하여 지도를 표출할 수 있으며 예측 결과를 시각화 파일 뿐만 아니라 데이터로 저장할 수 있어 사용자가 데이터 분석에도 활용할 수 있도록 하였다.

참 고 문 헌

1. 환경부, 물환경정보시스템, www.water.nier.go.kr

2. Behnaz Arabi, Mhd. Suhyb Salama, Jaime Pitarch, Wouter Verhoef, “Integration of in-situ and multi-sensor satellite observations for long-term water quality monitoring in coastal areas”, Remote Sensing of Environment, 239(15), 2020.

3. Bo Wang, Lingxi Luo, Liyong Mei, and Hui Zeng, “Temporal and Spatial Distribution of Phytoplankton and Role of Environment Factors in the Shending River Backwater in the Danjiangkou Reservoir Area”, Water, 16(2), 326, 2024.

4. Breiman, L., "Random Forest", Machine Learning", 45, 2001.

5. Byeon Y, Seo M, Jin D, et al., "Green algae detection in the middle·downstream of Nakdong river using high-resolution satellite data. Korean J Remote Sens, 37(3), 493-502, 2021.

6. EU, Copernicus Data Space Ecosystem, dataspace.copernicus.eu

7. Freddy Hernán Villota-González, Belkis Sulbarán-Rangel, Florentina Zurita-Martínez, Kelly Joel Gurubel-Tun, and Virgilio Zúñiga-Grajeda, “Assessment of Machine Learning Models for Remote Sensing of Water Quality in Lakes Cajititlan and Zapotlan, Jalisco-Mexico”, Remote Sens., 15(23), pp 326, 2023.

8. Haobin Meng, Jing Zhang, and Zhen Zheng, "Retrieving Inland Reservoir Water Quality Parameters Using Landsat 8-9 OLI and Sentinel-2 MSI Sensors with Empirical Multivariate Regression“, Int. J. Environ. Res. Public Health, 19(13), pp 7725, 2022.

9. Hodges, B., Dallimore, C., “Aquatic ecosystem model: AEM3D v1.0 user manual. Victoria”, HydroNumerics, 2019.

10. Yi, H.-S., Choi, S., Kim, D.-K., and Kim, H., “Improvement of Algal Bloom Identification Using Satellite Images by the Algal Spatial

Monitoring and Machine Learning Analysis in a New Dam Reservoir“, GEO DATA, 5(3), pp 26-136, 2023.

11. K-water, “위성기반 수질 및 수변환경분석 신뢰도 개선 연구 용역”, 한국수자원공사 용역보고서, 2020.

12. K-water, "수질을 고려한 대청댐 운영 고도화 방안 시범 연구", 한국수자원공사, 용역보고서, 2019.

13. K-water, “댐 유역단위 통합형 물환경 관리기술 개발”, 한국수자원공사 자체보고서, 2022.

14. Kaire Toming, Hui Liu, Tuuli Soomets, Evelyn Uuemaa, Tiina Nõges, and Tiit Kutser, "Estimation of the Biogeochemical and Physical Properties of Lakes Based on Remote Sensing and Artificial Intelligence Applications“, Remote Sens 16(3), pp 464, 2024.

15. Kang, B. K. and Park, J., "Effect of input variable characteristics on the performance of an ensemble machine learning model for algal bloom prediction, Journal of Korean Society of Water and Wastewater, 35(6), 2021.

16. Kang K.H., Lee W.S., "Introduction for eco-friendly project of Yeongju multi-purpose dam". Water for Future, 48(9), pp 72-77, 2015.

17. Kim D.S., Lee Y.W., "Detection of landslide-damaged areas using Sentinel-2 image and ISODATA" J of the Korean Assoc of Geogr Inf Stud, 23(4), pp 253-265, 2020.

18. Kim J, Gwon Y, Park Y, et al, "A study on the analysis of current status of Seonakdong River algae using hyperspectral imaging" J Korea Water Resour Assoc, 55(4), pp 301-308, 2022.

19. Kim K.S., Moon G..S, Chong Y..J, "Analysis on the changes of remote sensing indices on each land cover before and after heavy rainfall using multi-temporal Sentinel-2 satellite imagery and daily precipitation data" J of the Korean Assoc of Geogr Inf Stud, 23(2), pp 70-82, 2020.

20. Kim, H. I., Lee, Y. S., and Kim, B., "Real-time flood prediction applying random forest regression model in urban areas", Journal of Korea Water Resources Association, 54(spc1), 2021.

21. Kim S.H., Lee G.S., Ma J.L., Kook M.J., "Current status of hyperspectral remote sensing: principle, data processing techniques, and application", Korean J Remote Sens, 21(4), pp 341-369 2005.

22. Kim S.H., Park, J.H., Kim B., "Prediction of cyanobacteria harmful algal blooms in reservoir using machine learning and deep learning" J Korea Water Resour Assoc, 54(S-1), pp 1167-1181, 2021.

23. Kutser T, Metsamaa N, Strombeck N, Vahtmae E, "Monitoring cyanobacterial blooms by satellite remote sensing", Estuar Coast Shelf Sci, 67(1-2). pp 303-312, 2006.

24. Kwon, D.H., Hong, S.M., Abbas A., Park, S., Nam, G., Yoo J.H., Kim, K., Kim, H.T., Pyo, J., amd Cho K.H., "Deep learning-based super-resolution for harmful algal bloom monitoring of inland water", GIScience & Remote Sensing, 60.1, 2023.

25. Lee S, Park JR, Hwang TM, Ahn CH, "Analysis of water quality characteristics according to short-term fluctuation of water level in the new dam: focused on the upstream watershed of Yeongju multipurpose dam.", J Korean Soc Water Environ 36(5):431-444, 2020.

26. Lee, Y. and Sun, J., “Predicting highway concrete pavement damage using XGBoost, Korean Journal of Construction Engineering and Management, 21(6), pp 46-55., 2020.

27. Lei Dong, Cailan Gong, Hongyan Huai, Enuo Wu, Zhihua Lu, Yong Hu, Lan Li, and Zhe Yang, “Retrieval of Water Quality Parameters in Dianshan Lake Based on Sentinel-2 MSI Imagery and Machine Learning: Algorithm Evaluation and Spatiotemporal Change Research”, Remote Sens., 15(20), pp 5001, 2023.

28. Matthews M.W., "Remote Sensing of Water Quality Parameters in Zeekoevlei, a Hypertrophic, Cyanobacteria-Dominated Lake", Ph.D.

Thesis, University of Cape Town, pp 161, 2009.

29. McCulloch W.S., Pitts W., "A logical calculus of the ideas immanent in nervous activity", Bull Math Biophys, 5(4), pp 115-133, 1943.

30. Moses WJ, Gitelson AA, Berdnikov S, Povazhnyy V, "Satellite estimation of chlorophyll-a concentration using the red and NIR bands of MERIS-The Azov Sea case study", IEEE Geosci Remote Sens Lett, 6(4), pp 845-849, 2009.

31. Pyo, J., Duan, H., Baek, S., Kim, M.S., Jeon, T., Kwon, Y.S., Lee, H., and Cho, K.H., " A convolutional neural network regression for quantifying cyanobacteria using hyperspectral imagery, Remote Sens. Environ., 233, 2019.

32. Pyo, J., Park, S., Cho, K.H., and Baek S.S.,, "Deep learning model in water-environment field", Journal of Korean Society of Water and Wastewater, 34(6), 2020

33. Shim, S.H., Kim, Y.H., Lee, H., Kim, M., and Choi, J.H., "Comparison of Chlorophyll-a Prediction and Analysis of Influential Factors in Yeongsan R iver U sing Machine L earning and Deep Learning", Journal of Korean Society on Water Environment, 38(6), 2022.

34. Sijia Li, Kaishan Song, Shuai Wang, Ge Liu, Zhidan Wen, Yingxin Shang, Lili Lyu, Fangfang Chen, Shiqi Xu, Hui Tao, Yunxia Du, Chong Fang, Guangyi Mu, “Quantification of chlorophyll-a in typical lakes across China using Sentinel-2 MSI imagery with machine learning algorithm”, Ecological Indicators, 778(15), 2021.

35. Sim, D., Lee, J. Y., Jang, J., and Lee, M., "Prediction of chloride concentration in groundwater on Jeju Island using XGBoost regression machine learning", Journal of the Geological Society of Korea, 55(2), pp 243-256, 2022.

36. Smetacek V, Zingone A, "Green and golden seaweed tides on the rise", Nature, 504, pp 84-88, 2013.

37. Soryeon Park, Sanghun Son, Jaegu Bae, Doi Lee, Dongju Seo, and Jinsoo Kim, “Estimation of Chlorophyll-a Concentration in Nakdong River Using Machine Learning-Based Satellite Data and Water Quality, Hydrological, and Meteorological Factors”, Korean Journal of Remote Sensing, 39(5), 2023.

38. Tyralis, H., Papacharalampous, G., and Langousis, A., “A brief review of random forests for water scientists and practitioners and their recent history in water resources“, Water, 11(5), pp 910, 2019.

39. Wonjin Jang, Jinuk Kim, Jin Hwi Kim, Jae-Ki Shin, Kangmin Chon, Eue Tae Kang, Yongeun Park, and Seongjoon Kim, “Evaluation of Sentinel-2 Based Chlorophyll-a Estimation in a Small-Scale Reservoir: Assessing Accuracy and Availability”, Remote Sens., 16(2), pp 326, 2024.

40. Yan K, Li J, Zhao H, et al, "Deep learning-based automatic extraction of cyanobacterial blooms from Sentinel-2 MSI satellite data. Remote Sens 14(19), pp 4763, 2022.

41. Ye NH, Zhang XW, Mao YZ, et al, "‘Green tides’ are overwhelming the coastline of our blue planet: taking the world’s largest example", Ecol Res., 26, pp 477-485, 2011.

42. Yi GH, Jeon HS, Kim TG, Cho GS, "The interpretation of chlorophyll a and transparency in a lake using LANDSAT TM imagery", Korean J Remote Sens, 13(1), pp 47-56, 1997.

43. Young Woo Kim, TaeHo Kim, Jihoon Shin, Dae-Seong Lee, Young-Seuk Park, Yeji Kim, and YoonKyung Cha, “Validity evaluation of a machine-learning model for chlorophyll a retrieval using Sentinel-2 from inland and coastal waters”, Ecological Indicators, 137, 2022.

참 여 연 구 원 현 황

연구원	참 여 내 역	비 고
이혜숙	○ 연구업무총괄 (연구책임자) ○ 참여분야 : 문헌조사, 현장조사, 수질모델링, 알고리즘 개발 ○ 참여내역 - 적용 AI 기법 사례조사 - 현장조사 및 입력 DB 구축 - 수질모델링 - Chl-a 세포수 추정 알고리즘 개발 - 위성영상 기반 기상, 수문 연계 단기 예측 알고리즘 개발	- ’24.2 ~ ’24.12 - K-water연구원 수자원환경구소 - 042-870-7454
정선아	○ 연구참여 ○ 참여내역 - 현장조사, 영주댐 수질모델링	- ’24.2 ~ ’24.12 - K-water연구원 수자원환경구소 - 042-870-7455
최정규	○ 연구참여 ○ 참여내역 - 현장조사, 대청댐 수질모델링	- ’24.2 ~ ’24.12 - K-water연구원 수자원환경구소 - 042-870-7406
박형석	○ 연구참여 ○ 참여내역 - 현장조사 - 적용 AI 기법 사례조사 - 알고리즘 결과 시각화 기법 개발	- ’24.2 ~ ’24.12 - K-water연구원 수자원환경구소 - 042-870-7653
최성화	○ 연구참여 ○ 참여내역 - 문헌조사	- ’24.2 ~ ’24.12 - K-water연구원 수자원위성센터 - 042-870-7616
남기범	○ 연구참여 ○ 참여내역 - 위성영상 정리	- ’24.2 ~ ’24.12 - K-water연구원 수자원위성센터 - 042-870-7498
정지영	○ 연구참여 ○ 참여내역 - 적용 알고리즘 검토	- ’24.6 ~ ’24.12 - K-water연구원 AI연구센터 - 042-870-7342
전유호	○ 연구참여 ○ ○ 참여내역 - 적용 AI 기법 사례조사 - 현장조사 및 입력 DB 구축 - 알고리즘 개발	- ’24.4 ~ ’24.12 - K-water연구원 수자원환경구소 - 042-870-7434

부 록

부록 1 : 세포수 분석자료

부록 2 : 자문보고서

◦ 자문명 : 위성-기상-수문 연계 녹조예측 AI 기법적용 타당성 검토
◦ 자문자 : 부산대학교 표종철 교수

부록 1. 2024년 대청댐 및 영주댐 세포수 분석결과

댐	날짜	총종수	총세포수 (cells/mL)	제1우점종/제2우점종	%	종다양성	균등도	풍부도	우점도
영주댐	4/26	11과 14종	2,033	*Fragilaria crotonensis* *Trachelomonas lefevrei*	91.7 2.2	0.45	0.17	1.71	0.94
	4/26	17과 22종	640	*Pandorina morum* *Aphanizomenon flos-aquae*	81.3 5.0	0.90	0.29	3.25	0.86
	4/26	13과 20종	20,275	*Fragilaria crotonensis* *Asterionella formosa*	92.8 5.5	0.33	0.11	1.92	0.98
	4/26	16과 24종	12,340	*Fragilaria crotonensis* *Aulacoseira ambigua f. japonica*	86.8 5.2	0.62	0.20	2.44	0.92
	4/26	12과 23종	19,104	*Fragilaria crotonensis* *Asterionella formosa*	85.9 7.9	0.62	0.20	2.23	0.94
	4/26	12과 25종	822	*Cryptomonas erosa* *Monoraphidium contortum*	25.4 24.3	2.14	0.66	3.58	0.50
	6/12	12과 20종	6,619	*Aphanizomenon flos-aquae* *Cocystis lacustris*	86.6 8.2	0.58	0.19	2.16	0.95
	6/12	11과 16종	4,745	*Aphanizomenon flos-aquae* *Cocystis lacustris*	65.4 24.2	1.00	0.36	1.77	0.90
	6/12	17과 32종	7,790	*Coenochloris mucosa* *Cocystis lacustris*	24.9 18.2	2.18	0.63	3.46	0.43
	6/12	19과 37종	34,169	*Microcystis sp.* *Microcystis aeruginosa*	61.1 9.4	1.57	0.43	3.45	0.70
	6/12	20과 37종	97,789	*Microcystis sp.* *Anabaena planctonica*	55.5 21.4	1.46	0.40	3.13	0.77
	6/12	17과 30종	40,232	*Merismopedia tenuissima* *Coelastrum astroideum*	62.6 36.4	0.73	0.21	2.74	0.99
	8/26	5과 9종	196,086	*Microcystis sp.* *Microcystis wesenbergii*	86.2 6.9	0.57	0.26	0.66	0.93
	8/26	6과 10종	302,214	*Microcystis sp.* *Microcystis aeruginosa*	94.4 3.0	0.30	0.13	0.71	0.97
	8/26	6과 12종	254,978	*Microcystis sp.* *Microcystis wesenbergii*	96.9 1.5	0.19	0.08	0.88	0.98
	8/26	10과 17종	259,407	*Microcystis sp.* *Microcystis wesenbergii*	95.4 1.6	0.27	0.10	1.28	0.97
	8/26	12과 20종	869,190	*Microcystis sp.* *Microcystis aeruginosa*	89.3 4.9	0.47	0.16	1.39	0.94
	8/26	17과 36종	29,660	*Eutetramorus fottii* *Microcystis sp.*	44.3 20.6	1.66	0.46	3.40	0.65
	11/6	13과 24종	6,620	*Chroococcus limneticus* *Microcystis flos-aquae*	74.1 8.6	1.06	0.33	2.61	0.83
	11/6	18과 27종	4,745	*Chroococcus limneticus* *Cryptomonas erosa*	90.9 2.4	0.52	0.16	3.07	0.93
	11/6	14과 25종	7,790	*Chroococcus limneticus* *Volvox tertius*	68.9 19.6	1.08	0.34	2.68	0.89
	11/6	14과 21종	34,169	*Chroococcus limneticus* *Aulacoseira granulata*	94.5 1.9	0.32	0.11	1.92	0.96
	11/6	22과 37종	97,789	*Chroococcus limneticus* *Phormidium mucicola*	94.5 2.4	0.32	0.09	3.13	0.97
	11/6	20과 30종	40,232	*Chroococcus limneticus* *Phormidium mucicola*	87.4 5.7	0.57	0.17	2.74	0.93

댐	날짜	총종수	총세포수 (cells/mL)	제1우점종/제2우점종	%	종다양성	균등도	풍부도	우점도
대청댐	4/16	14과 20종	2,993	*Fragilaria crotonensis* *Asterionella formosa*	42.9 36.7	1.43	0.48	2.37	0.80
	4/16	16과 24종	4,228	*Asterionella formosa* *Fragilaria crotonensis*	33.1 29.9	1.77	0.56	2.75	0.63
	4/16	17과 24종	2,768	*Asterionella formosa* *Fragilaria crotonensis*	47.6 25.8	1.55	0.49	2.90	0.73
	4/16	18과 27종	2,668	*Aulacoseira ambigua f. japonica* *Asterionella formosa*	35.2 26.8	1.85	0.56	3.30	0.62
	4/16	15과 22종	3,743	*Synedra tenuissima* *Stephanodiscus hantzschii f. tenuis*	62.2 7.6	1.52	0.49	2.55	0.70
	4/16	16과 28종	5,058	*Synedra tenuissima* *Stephanodiscus hantzschii f. tenuis*	46.3 18.5	1.77	0.53	3.17	0.65
	4/16	17과 30종	2,849	*Stephanodiscus hantzschii f. tenuis* *Synedra tenuissima*	65.6 10.1	1.31	0.39	3.65	0.76
	6/26	23과 44종	3,383	*Synedra tenuissima* *Cyclotella stelligera*	33.6 15.8	2.13	0.56	5.29	0.49
	6/26	28과 63종	7,086	*Synedra tenuissima* *Microcystis sp.*	22.9 11.7	2.77	0.67	6.99	0.35
	6/26	23과 38종	5,826	*Synedra tenuissima* *Cyclotella stelligera*	34.6 15.4	2.14	0.59	4.27	0.50
	6/26	24과 48종	9,610	*Synedra tenuissima* *Microcystis sp.*	68.5 6.1	1.51	0.39	5.13	0.75
	6/26	19과 46종	8,741	*Microcystis aeruginosa* *Phormidium mucicola*	37.2 10.7	2.32	0.61	4.96	0.48
	6/26	21과 41종	26,895	*Coelastrum cambricum* *Merismopedia tenuissima*	78.5 12.1	0.91	0.25	3.92	0.91
	6/26	20과 37종	44,645	*Coelastrum cambricum* *Merismopedia tenuissima*	52.1 33.4	1.33	0.37	3.36	0.85
	8/29	20과 27종	83,065	*Microcystis aeruginosa* *Microcystis sp.*	42.2 26.4	1.52	0.46	2.30	0.69
	8/29	15과 24종	93,234	*Microcystis aeruginosa* *Microcystis sp.*	50.9 23.7	1.44	0.45	2.01	0.75
	8/29	22과 44종	144,386	*Microcystis sp.* *Microcystis aeruginosa*	42.4 31.3	1.37	0.36	3.62	0.74
	8/29	16과 31종	58,551	*Microcystis aeruginosa* *Phormidium granulatum*	32.4 23.3	1.66	0.48	2.73	0.56
	8/29	15과 31종	75,573	*Microcystis aeruginosa* *Microcystis sp.*	36.5 19.6	1.72	0.50	2.67	0.56
	8/29	26과 45종	28,256	*Phormidium granulatum* *Microcystis aeruginosa*	42.9 29.7	1.67	0.44	4.29	0.73
	8/29	26과 47종	17,404	*Phormidium granulatum* *Microcystis aeruginosa*	26.5 24.1	1.92	0.50	4.71	0.51
	11/4	24과 43종	3,387	*Aulacoseira ambigua f. japonica* *Microcystis sp.*	17.7 8.3	3.01	0.80	5.17	0.26
	11/4	26과 49종	7,084	*Aulacoseira ambigua f. japonica* *Aulacoseira granulata*	18.8 15.6	2.82	0.72	5.41	0.34
	11/4	33과 61종	5,824	*Gaiterinema amphibium* *Pomeria okensis*	28.4 15.1	2.61	0.63	6.92	0.43
	11/4	29과 58종	9,611	*Pomeria okensis* *Pseudanabaena limnetica*	17.8 15.0	2.69	0.66	6.22	0.33
	11/4	26과 55종	8,739	*Pseudanabaena limnetica* *Gaiterinema amphibium*	21.5 16.0	2.65	0.66	5.95	0.38
	11/4	19과 36종	26,893	*Phormidium mucicola* *Aphanocapsa grevillei*	14.6 10.6	2.73	0.76	3.43	0.25
	11/4	26과 41종	44,645	*Oscillatoria nigra* *Cuspidothrix issatschenkoi(Aphanizomenon이명)*	23.9 12.3	2.51	0.68	3.74	0.36

자문보고서 - 본 문

위성-기상-수문 연계 녹조예측 AI 기법적용 타당성 검토

2024. 10.

부산대학교 표종철 교수

1. 상수원 녹조 관리의 필요성

녹조는 수생태계의 1차 생산자로서의 역할 뿐만 아니라 먹이사슬의 가장 아래에 해당되어 1차 소비자로서의 중요한 역할을 담수 시스템에서 담당하고 있다. 하지만, 도시화와 산업화로 인한 수계로 유출되는 점, 비점오염원 증가, 기후변화로 인한 이상온도 상승 등 인간의 행동으로 인한 녹조 대발생 현상이 나타나고 있다 (그림 1). 녹조가 대발생되면 녹조의 대량 사멸이 나타나며, 사멸된 녹조 세포의 분해를 위한 박테리아의 용존산소 소비에 따라 수체내의 산소량이 고갈되며 수생식물들의 폐사로 이어져 수질악화의 악순환 고리가 발생이 된다. 또한, 남조류의 경우 마이크로시스틴과 같은 간과 신경 독소를 생성하여 수생태계 뿐만 아니라 인간사회에도 직간접적인 악영향을 미치고 있다. 따라서, 전세계적으로 수질관리에 우려의 목소리가 나타나고 매년 녹조 대발생 횟수와 강도가 증가하고 있는 추세이다.



그림 1. 녹조 발생 매커니즘 (2017년 조류(녹조)발생과 대응 연차보고서, 환경부)

우리나라의 경우도 4대강의 유속감소와 비점오염원의 증가, 여름철 장마패턴 변화, 가뭄일수 증가, 고수온현상으로 인해 발생하는 녹조, 특히 유해남조류의 대발생의 횟수와 강도가 점점 증가하고 있다 (그림 2).

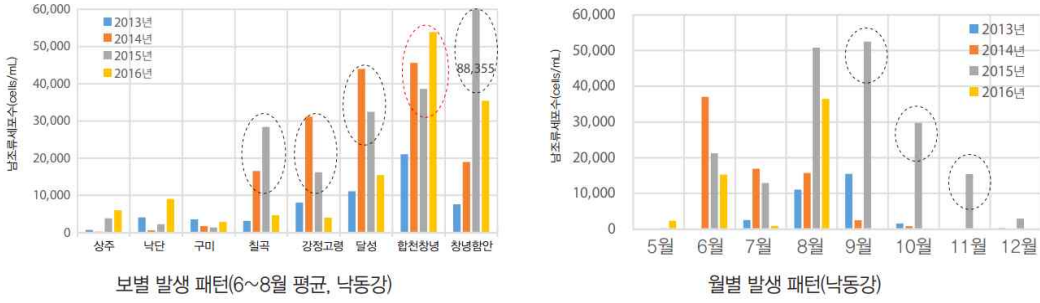


그림 2. 낙동강 유해남조류 발생 패턴 (4대강 녹조발생 원인규명과 모니터링, 물과미래)

4대강 유역의 주요 보, 호소, 저수지에 걸쳐 남조류 대발생 현상의 매년 강도는 새로이 갱신되며 발생 패턴 또한 늦가을까지 지속되는 변화를 보이고있다. 이한구 등 (2017)에서 4대강 사업 이후 낙동강수계의 보별 녹조발생 현황을 보면 오염부하가 크고 체류시간이 긴 하류지역에서 남조류의 발생이 증가하였고, 특히 가뭄과 폭염이 심한 2015년과 2016년에는 남조류가 더 많이 발생하는 경향을 보여 수문기상조건에도 많은 영향을 받는 것으로 보고하였다. 또한 연도별 월별녹조발생 패턴도 상이 하였으며, 특히 가뭄이 심한 2015년에는 12월까지 남조류가 출현하여 녹조발생의 장기화현상이 나타난 사례를 보고하였다. 그리고, 폭염이 심한 2015년과 2016년에는 남조류가 더 많이 발생하는 경향을 보여 수문기상조건에도 많은 영향을 받는 것으로 제시하였다. 또한 연도별 월별녹조발생 패턴도 상이하였는데 가뭄이 심한 2015년에는 12월까지 남조류가 출현하여 녹조발생의 장기화현상이 나타남을 보고하였다. 따라서, 효율적인 수질 관리를 위해서는 유해남조류의 상세한 모니터링과 모델링을 통한 정확한 예측이 필요하다.

현재 우리나라의 경우 1998년부터 수질 및 수생태계 보전에 관한 법률 제 21조 조류경보제의 법적근거를 마련하고, 이를 실시하여 조류발생에 따른 피해를 최소화하고 상수원의 안정성을 확보하고 있다. 조류 경보제의 발령기준은 남조류 세포수로 설정이 되며 남조류 세포수는 *Anabaena, Aphanizomenon, Microcystis, Osciliatoria* 속 세포수의 합으로 설정된다. 조류 경보 발령기준은 상수원구간은 2회 연속 측정하여 남조류 세포수가 1,000세포/ml 이상 10,000세포/ml 미만일 경우 '관심', 10,000세포/ml 이상 1,000,000세포/ml 미만일 경우 '경계', 1,000,000세포/ml 이상일 경우 '조류대발생', 그리고 1,000세포/ml 미만일 경우 '해제'로 발령된다. 친수활동구간의 경우 2회 연속 측정 기준이며 남조류 세포수가 20,000세포/ml 이상 100,000세포/ml 미만일 경우 '관심', 100,000세포/ml 이상일 경우 '경계', 그리고 20,000세포/ml 미만일 경우 '해제'가 발령된다. 위 기준을 통해 지속적인 조류경보 현황이 관계부처 및 국민들에게 고시가 이루어진다 (그림 3). 그리고 발령 단계에 따른 조치사항을 법적 근거로 마련하여 관계부처 간의 수질 관리를 통한 조류 대발생 완화와 홍보를 통한 국민체감형 감시 제도를 구성하여 운영하고 있다 (그림 4).



그림 3. 전국 조류경보제 운영지점 및 발령현황 (2024년 8월 29일 기준, 환경부)

수질오염경보 발령시 단계별 조치사항(제6조제3항관련)

○ 조류예보 발령시

단계	관계기관	조 치 사 항
조류주의보	4대강 물환경연구소장 (시·도 보건환경연구원장 또는 수면관리자)	○주 1회 이상 시료채취 및 분석 ○발령기관에 대한 시험분석결과의 신속한 통보
	수면관리자 (수면관리자)	○취수구 및 조류우심지역에 대한 펜스설치 등 조류제거 조치 실시
	취·정수장 관리자 (취·정수장 관리자)	○정수처리강화(활성탄처리, 오존처리)
	유역·지방환경청장 (시·도지사)	○조류주의보 발령 ○주변오염원에 대한 철저한 지도·단속
조류경보	4대강 물환경연구소장 (시·도 보건환경연구원장 또는 수면관리자)	○주 2회 이상 시료채취·분석(클로로필-a, 남조류 세포수, 취기, 독소) ○발령기관에 대한 시험분석결과의 신속한 통보
	수면관리자 (수면관리자)	○취수구 및 조류우심지역에 대한 펜스설치 등 조류제거 조치 실시
	취·정수장 관리자 (취·정수장 관리자)	○조류증식 수심 이하로 취수구 이동 ○정수처리강화(활성탄처리, 오존처리) ○정수의 독소분석 실시
	유역·지방환경청장 (시·도지사)	○조류경보 발령 및 대중매체를 통한 홍보 ○주변오염원에 대한 단속강화 ○수상스키·수영·낚시·취사 등의 활동 자제 권고 ○어패류어획·식용 및 가축방목의 자제 권고
조류대발생경보	4대강 물환경연구소장 (시·도 보건환경연구원장 또는 수면관리자)	○주 2회 이상 시료채취·분석(클로로필-a, 남조류 세포수, 취기, 독소) ○발령기관에 대한 시험분석결과의 신속한 통보
	수면관리자 (수면관리자)	○취수구 및 조류 우심지역에 대한 펜스설치 등 조류제거 조치 실시 ○황토 등 흡착제 살포, 조류제거선 등을 이용한 조류 제거 조치 실시
	취·정수장 관리자 (취·정수장 관리자)	○조류증식 수심 이하로 취수구 이동 ○정수처리강화(활성탄처리, 오존) ○정수의 독소분석
	유역·지방환경청장 (시·도지사)	○조류대발생경보의 발령 및 대중매체 통한 홍보 ○주변오염원에 대한 지속적인 단속강화 ○수상스키·수영·낚시·취사 등의 활동 금지 ○어패류어획·식용 및 가축방목의 금지
해제	4대강 물환경연구소장 (시·도 보건환경연구원장 또는 수면관리자)	○발령기관에 대한 시험분석결과의 신속한 통보
	유역·지방환경청장 (시·도지사)	○각종 경보의 해제 및 대중매체를 통한 홍보

비고 : 1. 위 표의 관계기관란의 괄호는 시·도지사가 조류예보를 발령하는 경우에 관계되는 기관을 말한다.
2. 관계기관별로 위 표에서 기술한 조치사항 이외에도 현지 실정에 맞게 탄력적으로 적절하게 조치할 수 있다.
3. 조류주의보, 조류경보 또는 조류대발생경보의 발령 이전이라도 수면관리자는 수온상승 등으로 조류발생 가능성이 증가할 경우 일정기간 방류량의 증가조치 등 조류에 따른 피해를 최소화하는 방안을 사전에 마련하여 추진할 수 있다.

그림 4. 조류경보발령시 조치사항 (수질 및 수생태계 보전에 관한 법률, 환경부)

조류경보제의 조류 데이터는 수질예보 및 조류 관측지점에서 생산이 된다. 이러한 데이터는 조류 발생 현황 파악과 대응에 효과적이지만 부영양화, 강우량, 보 운영, 수온변화 등 복합적인 요소에 대한 영향으로 인한 조류 발생 변화를 파악하기엔 한계가 있다. 따라서, 세밀한 모니터링 기법이 함께 지속이 되어야 한다. 원격탐사 기술은 가시광 영역의 파장대의 빛을 측정을 하여 해수 및 담수의 수질 인자를 예측 산정하고 공간분포를 파악할 수 있게 한다 (그림 5). 원격탐사 플랫폼은 위성, 항공기, 드론, 초소형위성이 있으며 초분광 및 다분광 센서를 탑재하여 지상을 관측한다. 녹조의 경우 정량지표인 클로로필-a를 가시광 파장대로 산정할 수 있으며, 유해남조류의 경우 정량색소인 피코시아닌 농도를 계산할 수 있다 (그림 5).

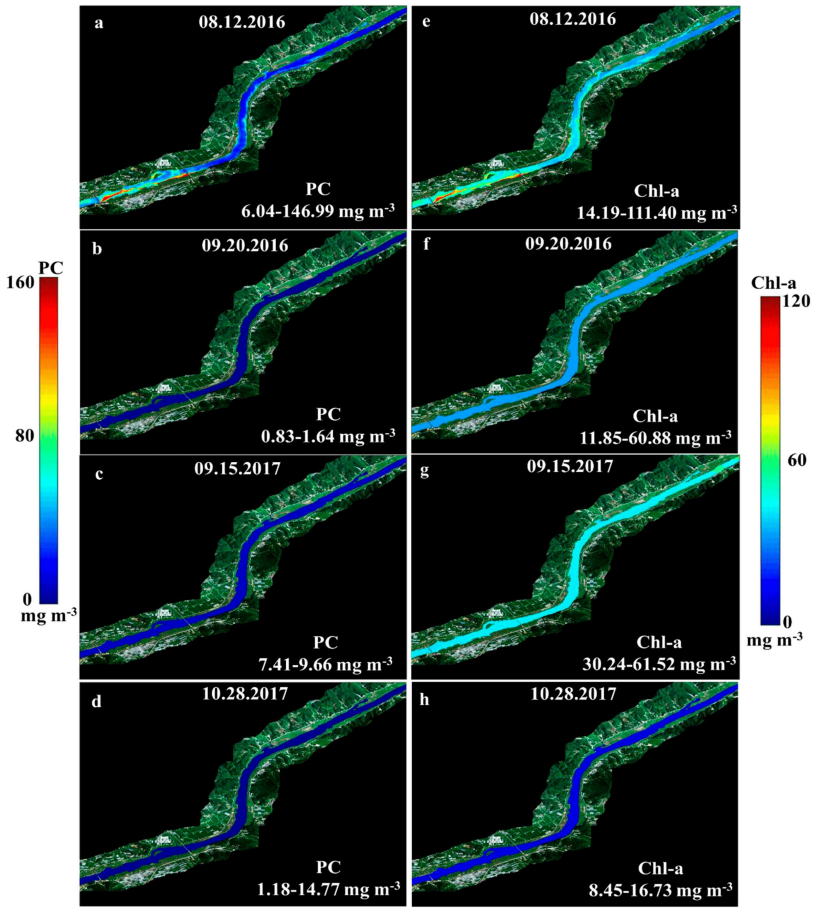


그림 5. 원격탐사 기법을 통한 조류 색소 산정 및 공간 분포 결과 (Pyo et al., 2020)

공간분포 해석을 통해 수체의 유해남조류 우심지역과 주요 우심 지천을 파악하여 효과적인 조류 발생 관리를 시의성 있게 수행할 수 있다. 또한, 선제적으로 녹조 대발생에 대응하기 위해 녹조를 정확하게 예측할 수 있는 방안이 필요하다. 현재에도 물리모델을 활용하여 녹조 농도를 예측하는 연구들이 진행되고 있다. CE-QUAL-W2, Environmental Fluid Dynamcis Code (EFDC), QUAL2E, Soil and Water Assessment Tool (SWAT) 등 많은 유체역학기반의 수질 모형들이 수질, 녹

조 예측에 활용이 되고 있다 (그림 6). 모델의 물리-화학-생물학적인 매개변수들을 점 단위 관측 수질데이터 뿐만 아니라 원격탐사 기술로 생산된 공간적인 수질 데이터를 같이 활용하여 정확한 보정을 진행하고 모델의 성능을 제고시킬 수 있다. 이후 시나리오분석을 활용하여 특정 환경상황에 적합한 녹조 대발생 예측을 수행하여 이에 대한 대비책을 마련할 수 있다. 하지만, 물리모델은 내부의 매개변수 보정과정이 복잡하고 견고한 모델구축을 위해서는 상당한 시간이 소요가 된다. 또한, 모델이 업데이트가 필요할 때 다시 보정을 위해 많은 인력, 비용, 시간이 소요되는 단점이 존재한다.

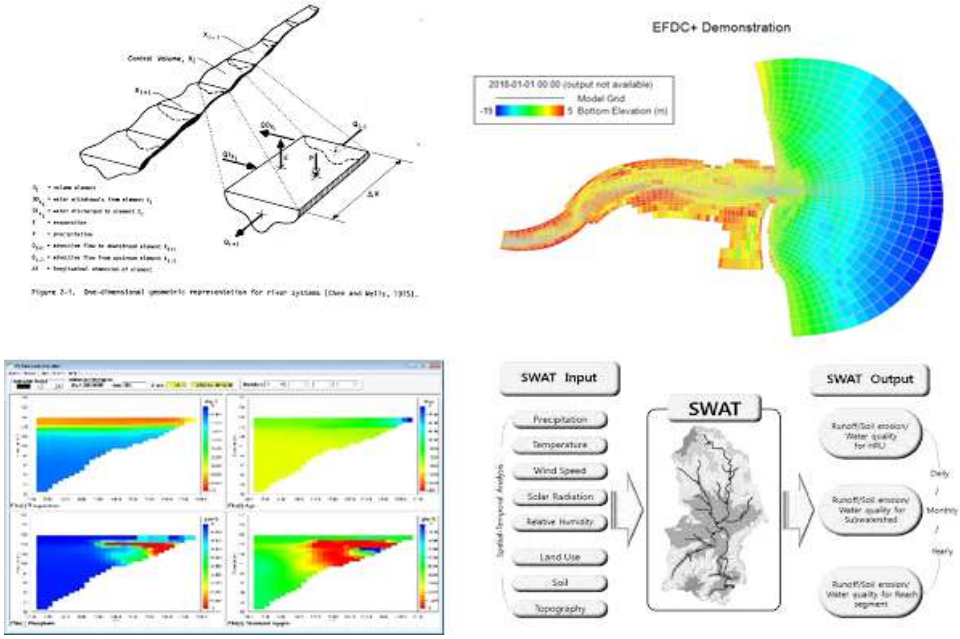


그림 6. 물리모형 예시 (왼쪽위부터 QULA2E, EFDC, CE-QUAL-W2, SWAT 모델)

최근 기계학습 모델은 이러한 물리모형의 한계점을 해결할 수 있는 방안으로 떠오르고 있다. 기계학습 모델은 학습을 위한 데이터와 입력데이터와의 연결성을 바탕으로 결과를 내기 때문에 물리모델 구축에 비해 시간 및 비용을 상대적으로 절감할 수 있는 이점을 가진다. 특히, 딥러닝 모델의 경우 점단위 데이터 뿐만 아니라 이미지와 같은 다차원데이터의 시공간적인 특징들을 효율적으로 추출하여 분류와 회귀 문제에 많이 활용되고 있다. 즉, 수질데이터와 원격탐사 이미지를 딥러닝과 함께 활용하면 녹조 대발생에 예측에 활용할 수 있다. 딥러닝의 대표적인 아키텍처는 순환신경망(Recurrent neural network, RNN)과 합성곱신경망(Convolutional neural network, CNN)이며, 파생되는 딥러닝 구조들은 이 두 모형에 기반하여 디자인 된다 (그림 7). 생성형 딥러닝 모델, 트랜스포머 모델, 대형언어모델, 멀티모달 모델 등 최근에 다양한 모델들이 개발이 되고 있으며 다양한 분야에서 괄목할만한 성능들을 제공하고 있다 (그림 8).

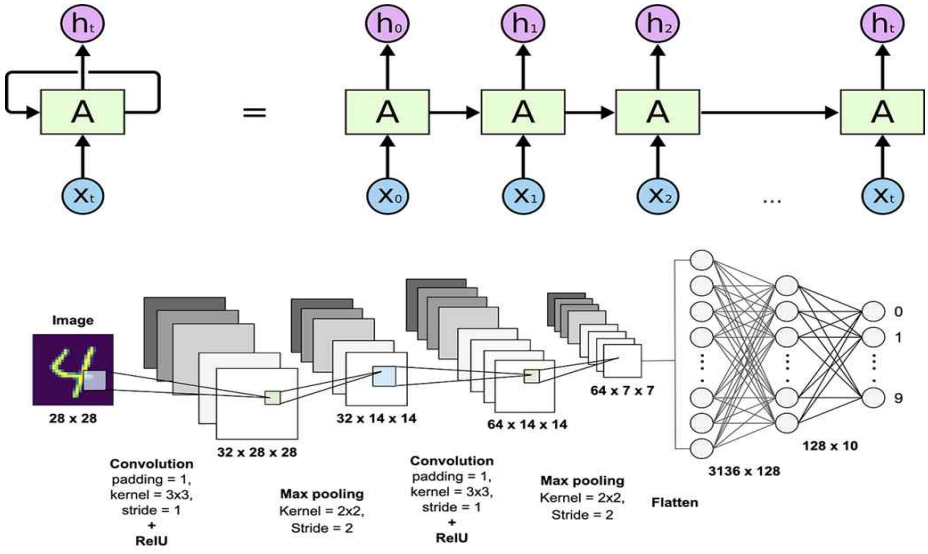


그림 7. 딥러닝 모델 구조 (위: RNN 모델, 아래: CNN 모델)

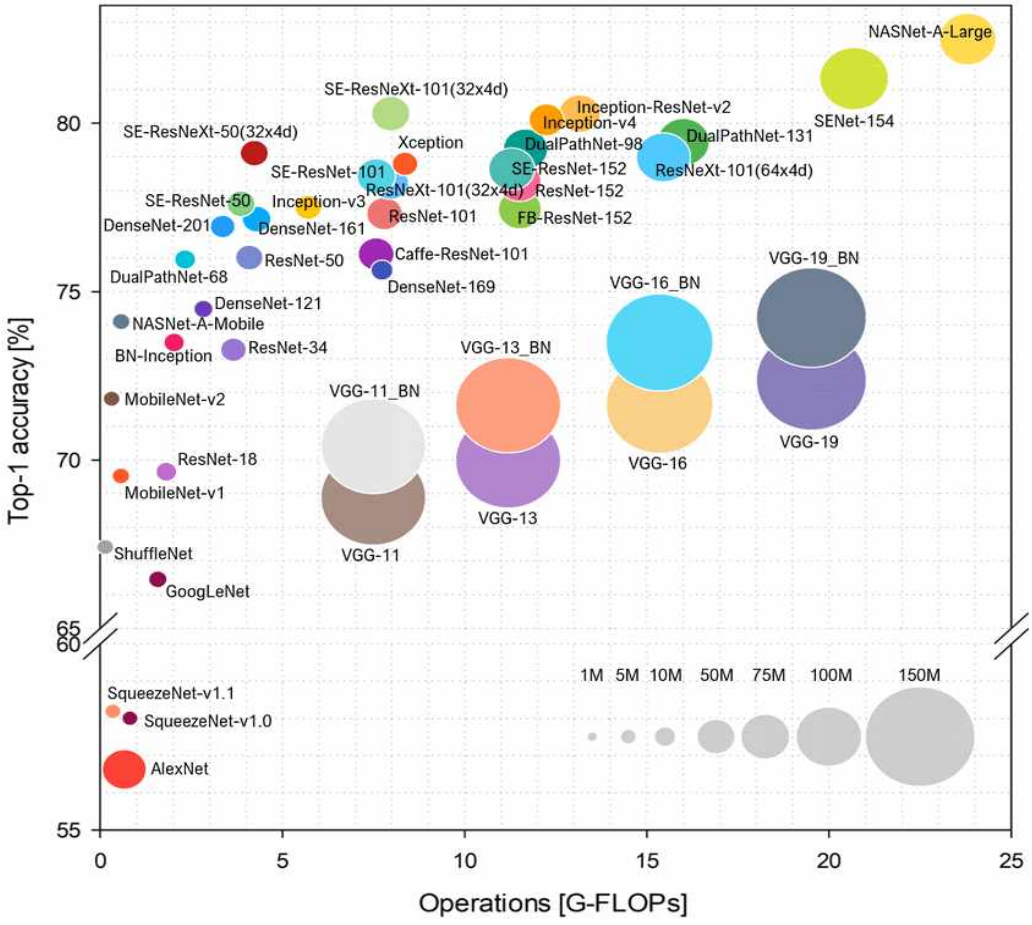


그림 8. CNN 기반 모델 구조에 따른 모델 크기 및 성능 비교 (Bianco et al., 2018)

딥러닝을 활용한 녹조 예측을 위해서는 시계열적으로 밀도가 있는 데이터의 확보가 중요하다. 주단위인 관측 수질데이터, 날씨에 영향을 많이 받는 원격탐사 데이터를 함께 활용해도 좋지만, 보정이 잘된 모델링 데이터가 있으면 이와 같은 합성데이터를 관측, 이미지데이터와 함께 융합하여 딥러닝 모델의 녹조 예측 성능을 제고할 수 있다. 최근에 많은 연구들에서 딥러닝모델과 물리모델을 융합하여 활용하고 있는 추세이다 (그림 9).

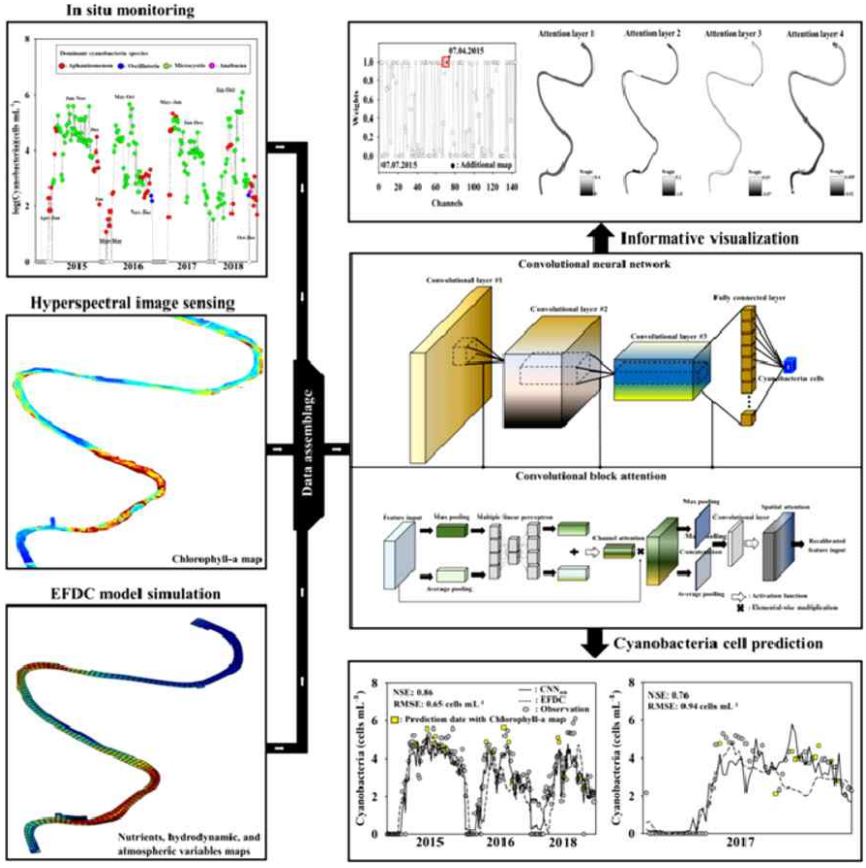


그림 9. 녹조 예측을 위한 관측, 이미지, 물리모형 데이터의 유합을 통한 딥러닝 적용 연구 (Pyo et al., 2021)

2. 녹조 예측을 위한 기법

2.1 원격탐사

다중 스펙트럼 및 초분광 원격탐사는 녹조 대발생의 농도와 분포를 산정하고 예측하기 위한 최적의 기술이다. 특히, 원격탐사는 남조류 분포를 상세하게 감지하는데 적합하다. 높은 공간 해상도는 우리나라 강과 같이 얕은 긴 수역에서 정밀한 정보를 제공해준다. 공간해상도가 높은 다분광, 초분광 이미지 센서는 내수면의 식물성 플랑크톤에서 광학적 특징을 식별할 수 있다. 광학적 특징은 원격탐사 반사도

(Rrs)로 나타낼 수 있으며 많은 선행연구들이 반사도 스펙트럼을 이용하여 분광특성 알고리즘을 개발하여 클로로필-a와 피코시아닌 두 농도를 산정하였다.

$$R_{rs} = (L_w - 0.025L_{sky}) / E_d$$

여기서 Rrs는 원격탐사반사도, Lw는 upwelling radiance from water surface, Lsky는 downwelling radiance from sky, Ed는 downwelling irradiance를 나타냄. 0.025는 수표면의 sun glint를 보정하기위한 보정 계수를 나타낸다.

이러한 알고리즘은 합리적인 남조류 시공간적 분포 해석을 제공했다. 여기서, 클로로필-a는 식물성 플랑크톤 바이오매스의 전형적인 지표이며, 피코시아닌은 남조류에 존재한다는 바이오매스 지표이다. 하지만, 기존의 분광특성 알고리즘은 식물성 플랑크톤, 부유 물질 및 유색 용존 유기물의 농도와 고유한 광학적 특성이 큰 탁한 수체의 광학적 복잡성에 따라 달라지며, 내륙수의 생물물리학적 복잡성은 빛 영역에 대한 다양한 색소, 조류 종 구성 및 대기 간섭의 영향으로 인해 경험적 알고리즘의 불확실성을 초래한다. 조류 색소 성분 측면에서 광학적 특성의 변화를 분석해 보면 현장 반사율 스펙트럼은 클로로필-a와 피코시아닌 농도에 따라 다양한 결과가 보고됨 (Pyo et al., 2019). 높은 클로로필-a 및 피코시아닌 농도는 높은 광 흡수로 인해 615-620 및 660-670nm 부근에서 더 깊은 반사 곡률을 보였다 (그림 10). 이는 700nm 부근에서 이 최대 피크의 크기와 위치가 클로로필-a 농도와 밀접한 관련이 있었기 때문으로 보고되었다. 또한 620nm 부근의 피크는 피코시아닌의 흡수가 클로로필-a의 흡수에 상당한 영향을 받았기 때문에 더 긴 파장으로 이동했다. 해당 반사율 스펙트럼에서 높은 색소 농도가 관찰되었을 때 동일 밴드에서 높은 흡수 피크가 관찰됨을 통해 위 결과를 입증했다 (그림 11).

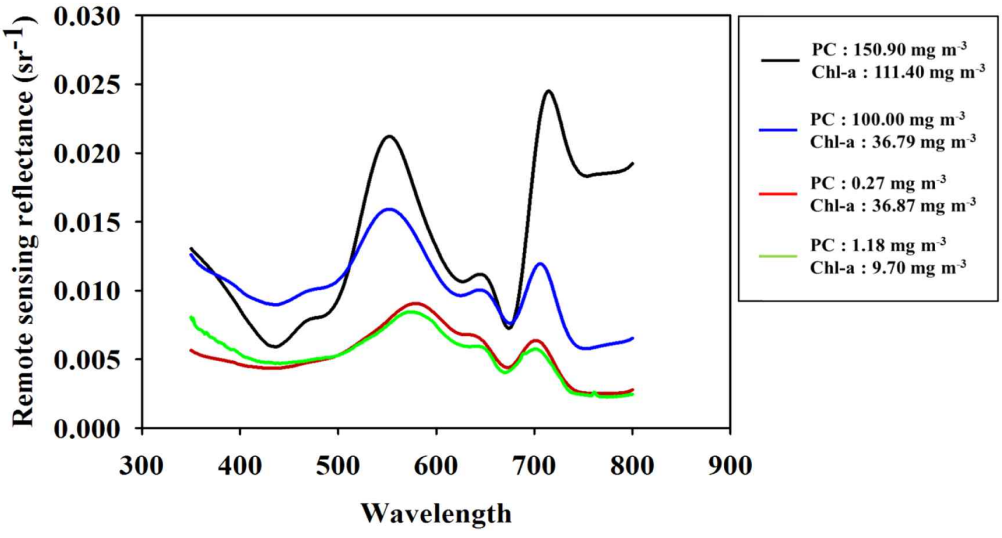


그림 10. 클로로필-a 및 피코시아닌 농도에 따른 원격탐사 반사도 피크의 변화

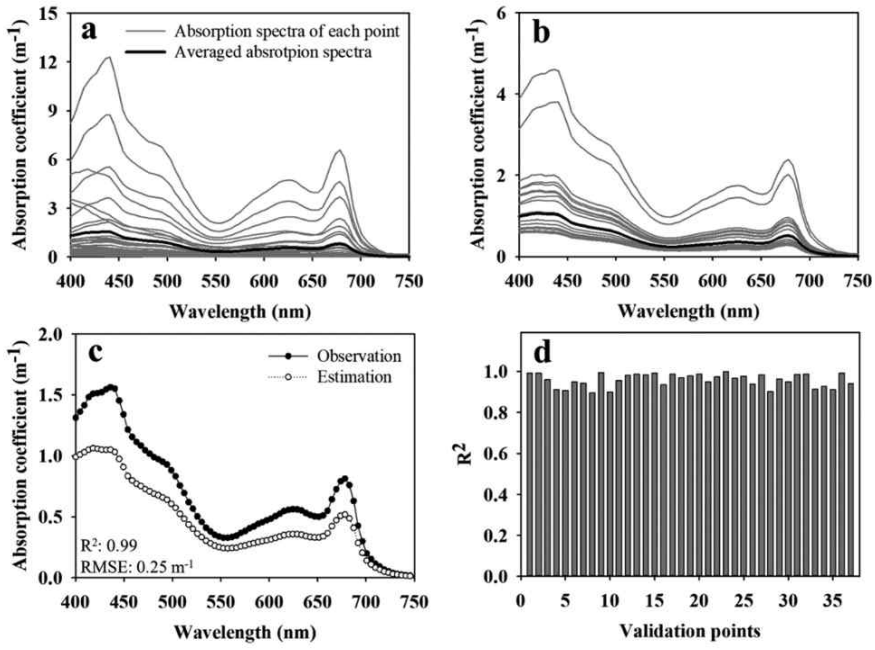


그림 11. 순수 녹조 색소 흡수 스펙트럼 (Pyo et al,, 2022)

Sentinel-2는 지구 관측과 관련된 ESA의 프로젝트로, 내륙수 원격 감지를 위한 높은 공간(10m에서 60m까지), 시간적(5일의 짧은 재방문 시간), 다중 스펙트럼 해상도를 제공한다 (그림 12). Sentinel-2 MSI는 가시광선, 근적외선(VNIR) 및 단파 적외선(SWIR)을 포함한 13개의 스펙트럼 대역(442.3~2202.4nm)을 제공한다. 이러한 스펙트럼 대역 데이터를 활용하려면 정확한 상관관계가 필수적입니다. Sentinel-2는 원시 이미지 데이터에서 방사형 및 기하학적으로 보정된 레벨 1C 대기 상부(TOA) 데이터와 레벨 1C 제품의 대기 보정 표면 반사 제품인 레벨 2A 하부(BoA) 데이터를 제공한다. Sentinel-2 데이터는 코페르니쿠스 오픈 액세스 허브에서 취득할 수 있다 (https://scihub.copernicus.eu/). 우리나라 4대강의 유역은 UTM/WGS84 투영에서 109.8km * 109.8km 직교 images로 위성의 타일(과립) 1개로 관측되며 10m 해상도의 4개 대역과 10m 해상도로 재조정된 20m 해상도의 6개 대역을 활용할 수 있다 (그림 13). 여기서 Sentinel 2 MSI 데이터의 값을 활용하려면 처리 기준선(PB)을 확인해야 한다. PB는 임무 수명에 걸쳐 진화하는 가이드라인이며 Sentinel 온라인 기술 가이드에서 확인할 수 있다. PB의 '04.00' 이전에는 BoA 반사율 값을 10,000으로 나뉜다. 2022년 1월 25일 이후에는 Sentinel-2의 PB '04.00' 배포에 따라 BoA 반사율이 1,000씩 변경되었다. 따라서 BoA 반사율은 1,000을 빼고 10,000으로 나누어 추가 분석때 활용이 되어야한다 (그림 14).



그림 12. Sentinel-2 위성 (Sentinel Online)

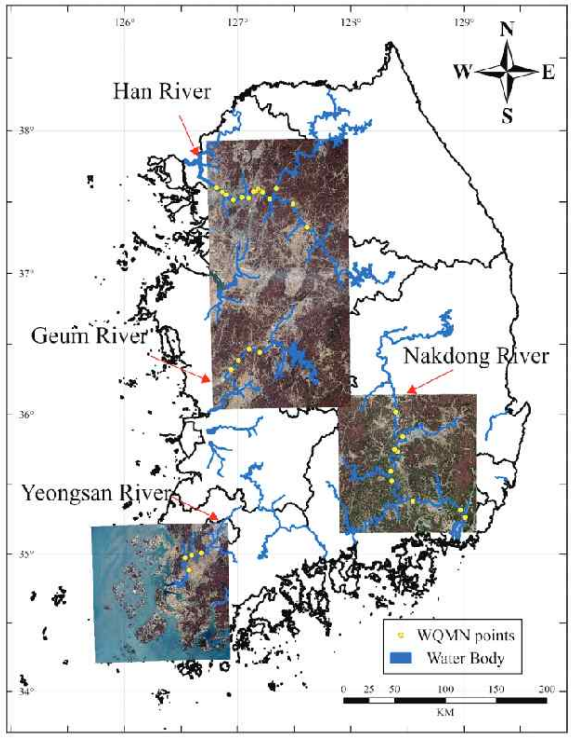


그림 13. 우리나라 4대강의 Sentinel-2 이미지
(Moon et al., 2024)

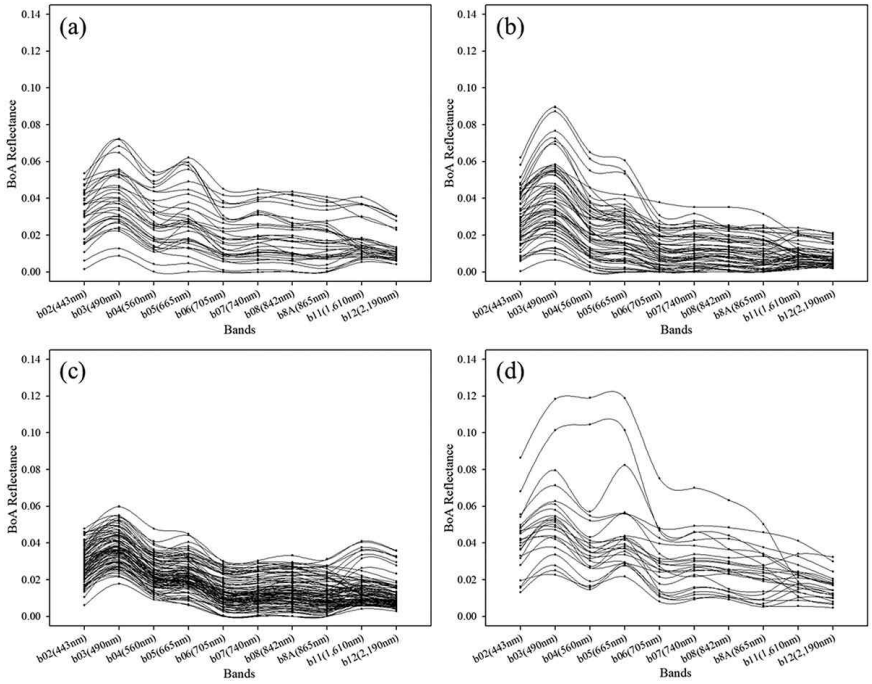


그림 14. 우리나라 4대강의 Sentinel-2 BOA 반사도 스펙트럼 (a: 금강, b: 한강, c: 낙동강, d: 영산강) (Moon et al., 2024)

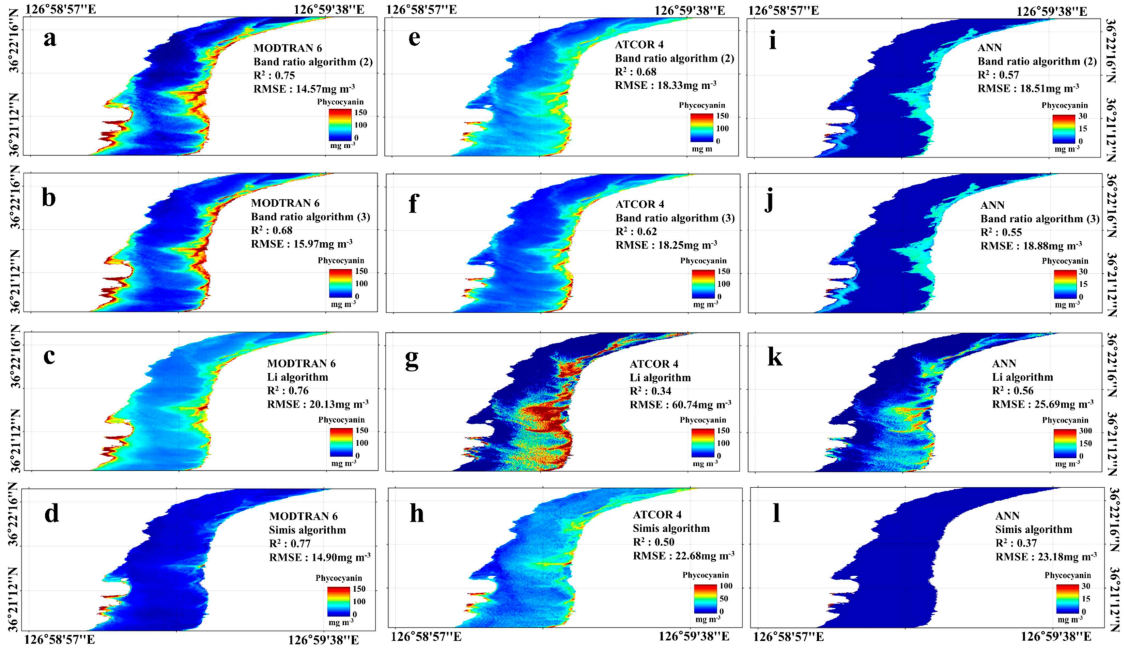


그림 15. 원격탐사이미지를 활용한 조류 분포 지도 (Pyo et al., 2018)

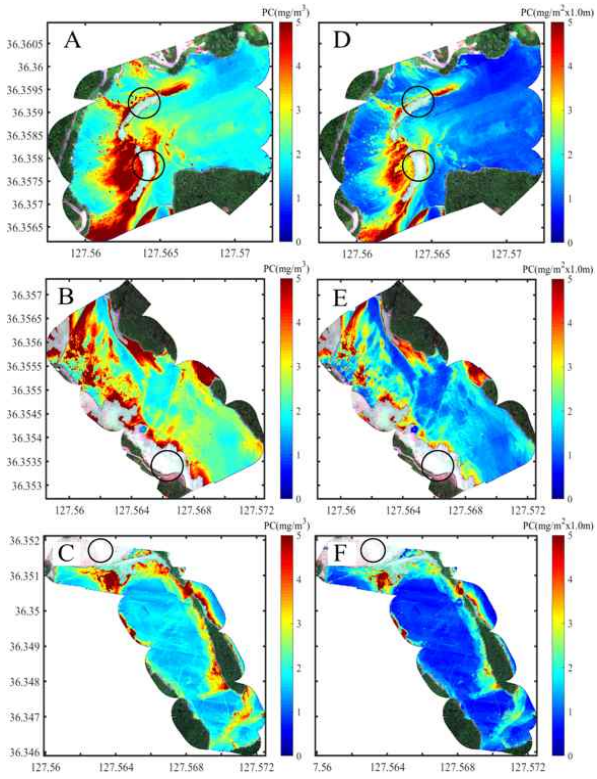


그림 16. 원격탐사 이미지를 활용한 조류 분포 지도 (Kwon et al., 2019)

2.2 모델링

컴퓨팅 하드웨어가 빠르게 발전함에 따라 수질 모델을 steady state 모델에서 3차원 dynamics 모델로 전환하기 위한 수많은 노력이 이루어지고 있다. 특히 조류 관련 예측을 위해 kinetics 모델이 지속적으로 개선되고 있다.

$$\frac{\partial B_c}{\partial t} = (P_c - BM_c - PR_c)B_c + \frac{\partial}{\partial z}(WS_c \bullet B_c) + \frac{WB_c}{V}$$

여기서 Bc는 조류 종별 생체량, t는 시간, Pc는 조류 성장률, BMc는 조류 대사량, PRc는 조류 포식률, WSc는 조류 침강속도, WBc는 추가 유입, V는 세포 부피, c는 조류 종을 나타낸다.

Clark and Jaworski(1972)는 조류 농도를 예측하기 위해 1차원 동적 하구 모델을 활용했다. 그러나 1차원 접근 방식은 상당한 수직 차이와 같은 중요한 물리적 현상을 무시했으며, 수직 및 측면 변화를 평균하는 단순화된 방정식의 사용으로 인해 예측 정확도가 저하되었다. 이후 연구에서는 종단 및 수직 이류를 고려하기 위해 2차원 유체역학 시뮬레이션을 개발했다. Martin(1988)은 조류 역학을 예측하기 위해 유체역학 알고리즘과 결합된 2차원 수질 모델을 적용했다. 그러나 2차원 모델은 측면 차이가 뚜렷한 수역에 대한 적용이 제한적이었다. 최근에는 3차원 유체역학 모델이 조류 농도를 예측하는 데 적극적으로 활용되고 있다(그림 17). Wu와 Xu(2011)와 Kim et al.(2017)은 환경 유체 역학 코드(EFDC)를 적용하여 유의미한 정확도로

조류 개화를 예측했다. 이 모델은 충분한 관측 데이터를 사용할 수 있을 때 조류 개화 추세를 예측하기 위해 개발되었지만 조류 역학을 예측하는 데는 여전히 개선이 필요하다. 주요 조류 매커니즘 간의 상호 작용, kinetics, 매개 변수 값의 불확실성, 3차원 유체역학 시뮬레이션의 복잡성은 조류 대발생 예측 모델의 효율적인 적용에 한계점으로 지적됐다 (그림 18).

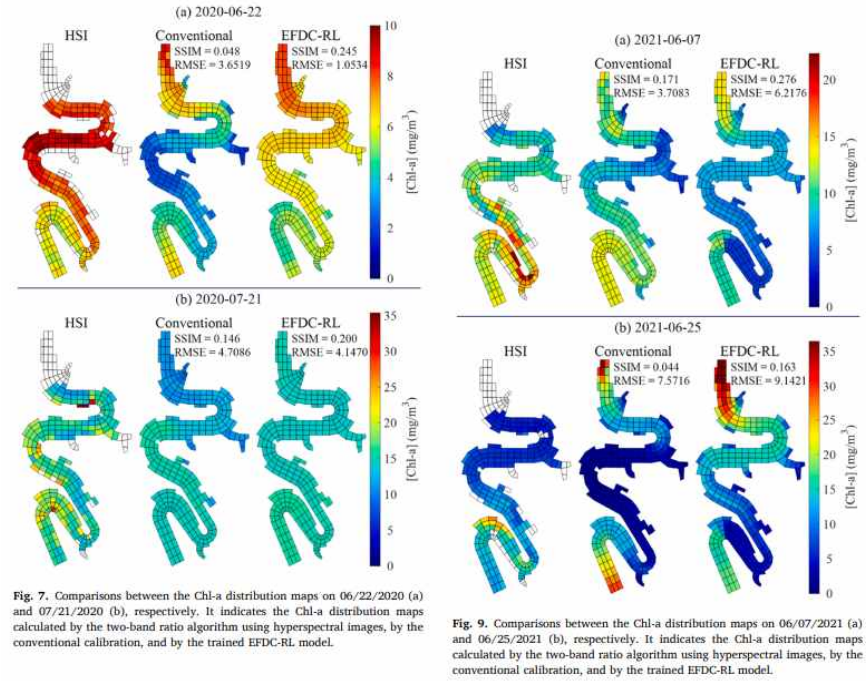


Fig. 7. Comparisons between the Chl-a distribution maps on 06/22/2020 (a) and 07/21/2020 (b), respectively. It indicates the Chl-a distribution maps calculated by the two-band ratio algorithm using hyperspectral images, by the conventional calibration, and by the trained EFDC-RL model.

Fig. 9. Comparisons between the Chl-a distribution maps on 06/07/2021 (a) and 06/25/2021 (b), respectively. It indicates the Chl-a distribution maps calculated by the two-band ratio algorithm using hyperspectral images, by the conventional calibration, and by the trained EFDC-RL model.

그림 17. EFDC 조류 시뮬레이션 결과 예시 (Hong et al., 2023)

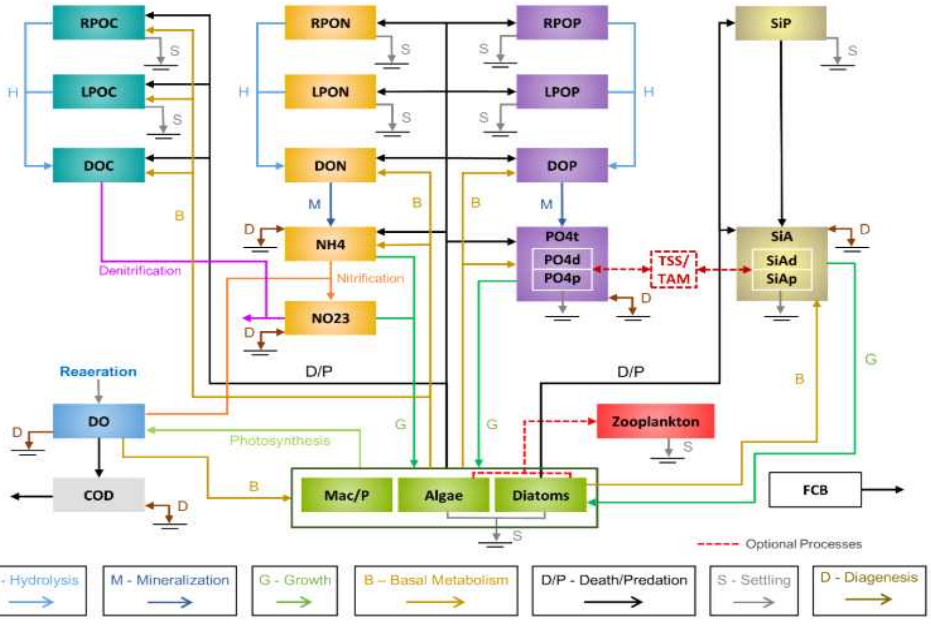


그림 18. EFDC 녹조 매커니즘

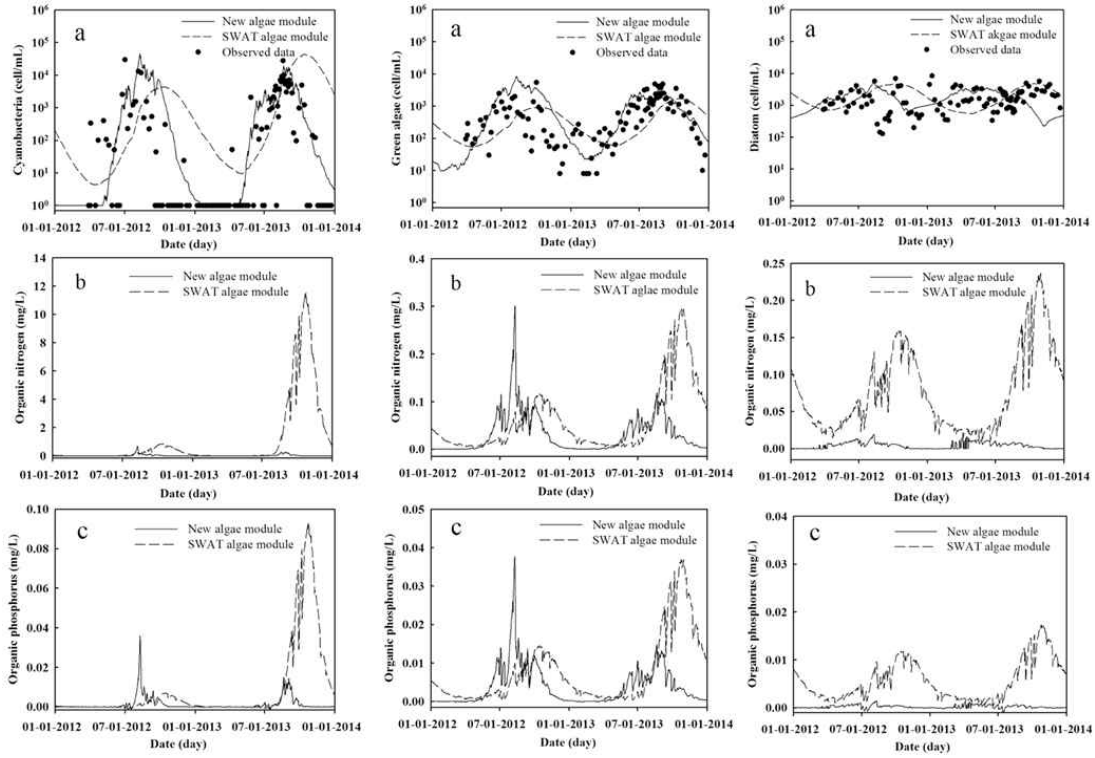


그림 19. 모델링을 활용한 남조류, 녹조류, 규조류 시뮬레이션 (Pyo et al., 2019)

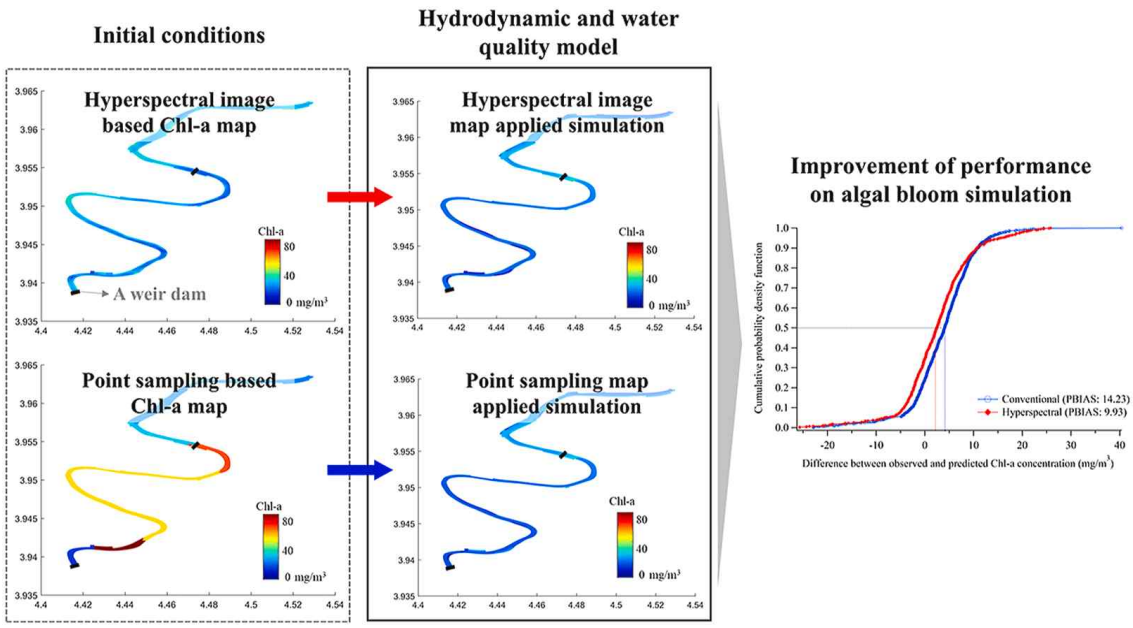


그림 20. 모델링과 원격탐사 자료를 이용한 조류 예측 성능 제고 (Pyo et al., 2021)

2.3 인공지능 모델을 활용한 녹조 예측

가. 합성곱 신경망

이와 관련하여 데이터 기반 모델링은 남세균 세포 수를 직접 예측하기 위해 데이터 분포만 필요하기 때문에 대안적인 접근 방식이 될 수 있다. 데이터 기반 모델은 물 구성 역학의 기본 특징을 반영하여 수질 매개변수를 추정하는 대안적인 접근 방식으로 각광받고 있다. Teles et al. (2006)은 인공 신경망 (ANN)을 사용하여 남세균의 시계열 예측을 효과적으로 구현했다. Cho et al. (2011)은 ANN을 사용하여 지하수의 비소 농도를 성공적으로 예측했으며, Park et al. (2015)은 엽록소-a 예측에서 지원 벡터 머신 (SVM) 의 만족스러운 성능을 보여주었다. 점단위 모니터링으로 측정된 수질 및 환경 요소의 시계열과 같이 상대적으로 저차원 데이터를 사용하는 데이터 기반 모델은 합리적인 정확도를 보여주었다. 그러나 이러한 모델에는 많은 내부 구성요소 설계 및 다차원 이미지와 같은 고차원 데이터를 사용하여 정확한 예측을 수행할 때 높은 훈련 시간이 요구되는 단점이 있다. 머신러닝 모델 중 딥러닝 모델은 다차원 이미지와 같은 복잡한 데이터 세트를 효율적으로 처리할 수 있으므로 물체 감지 및 분류에 탁월한 성능을 발휘한다. 따라서 이 접근 방식은 유해한 남세균 농도 예측에 점점 더 많이 사용되고 있다. 특히, 컨볼루션 신경망(CNN)과 같은 딥러닝 기술은 CNN이 고차원 이미지를 입력으로 사용하고 이미지 데이터에서 정교한 특징을 추출하여 신경망의 설명 및 예측 능력을 급격히 높일 수 있기 때문에 분류 및 회귀 작업을 위해 다차원 이미지를 처리하는 데 적합하다. CNN은 다양한 특징 필터를 사용하여 복잡한 입력에서 추상적인 특징을 추출할 수 있는 컨볼루션 연산자를 활용한다. 따라서 CNN은 다차원 데이터로 조류 농도를 추정하는 데 활용할 수 있다.

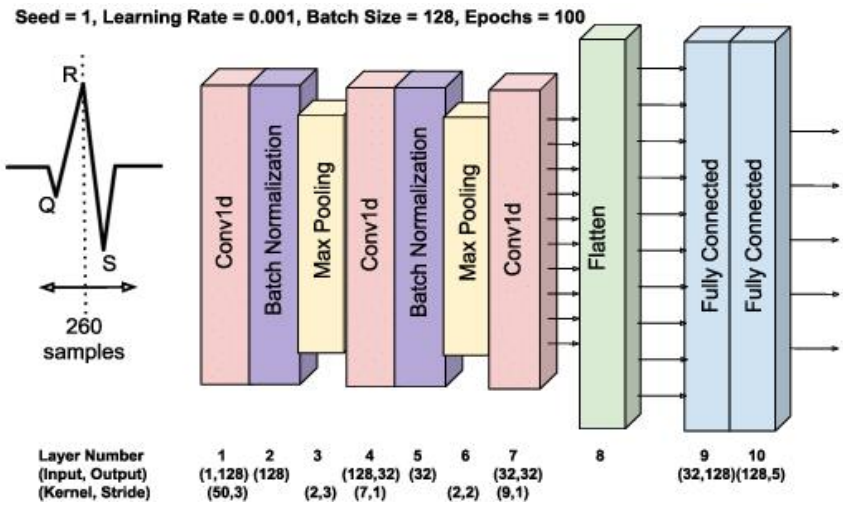


그림 21. CNN 모델 구조

CNN은 정방향 및 역방향 전파를 사용하는 심층 신경망이므로 컨볼루션 레이어, 풀링 레이어 및 활성화 함수로 다차원 이미지 데이터를 처리한다 (그림 21). 컨볼루션 레이어는 입력 벡터와 학습 가능한 가중치 및 편향의 elemental-wise곱셈을 수행하여 입력 내부 특징을 추출한다. 그런 다음 활성화 함수가 적용되며, 여기에는 요소별 비선형성 곱셈을 포함한다.

$$\mathbf{x}_{i+1}^{l} = \mathbf{f}_{a}\left(\mathbf{k}_{i,i+1}^{l}\mathbf{x}_{i}^{l-1} + \mathbf{b}_{i+1}^{l}\right)$$

여기서 i는 i번째 출력, l은 l번째 컨볼루셔널 레이어, x는 특징맵, k는 커널, b는 잔차, fa는 활성화함수를 나타낸다.

풀링 레이어는 공간 차원을 따라 연산자를 다운샘플링하여 입력의 고유한 특징을 추출하는 데 사용된다. 학습 프로세스는 역전파 알고리즘이 네트워크에서 손실의 도함수를 계산하는 손실함수를 최소화한다. 많은 연구에서는 텐서플로우 및 파이토치 라이브러리를 사용하여 CNN 시뮬레이션을 구현했다.

각 컨볼루션 레이어에 배치 정규화, 최대 풀링 레이어, 드롭아웃 레이어가 이어진다. 입력 이미지는 필터 크기 FW × FH와 커널 크기 N의 컨볼루션 레이어에 입력되며, 여기서 FW와 FH는 각각 필터 폭과 높이, N은 필터 깊이이다. 입력 이미지 (IW × IH)가 포함된 첫 번째 컨볼루션 레이어가 적용된 후 출력 이미지 크기는 각각 IW와 IH가 입력 폭과 높이인 곳으로 변경되고 S와 P는 각각 스트라이드와 패딩에 의해 결정된다.

배치 정규화는 내부 공변량 이동을 줄이기 위해 CNN 구조의 배치 정규화를 활용하여 사라지는 gradient 문제를 피하고 CNN 네트워크의 훈련을 가속화했다. 또한 배치 정규화는 입력 값과 네트워크 매개변수의 규모 기울기를 줄여 분산 위험 없이 상대적으로 높은 학습률을 CNN에 적용한다. 정규화 단계에서는 입력의 평균과 분산이 결정된다.

$$\mathbf{Norm}(\mathbf{x}_i) = \frac{\mathbf{x}_i - \mathbf{E}(\mathbf{x}_i)}{\sqrt{\mathbf{Var}(\mathbf{x}_i)}}$$

$$\mathbf{y}_i = \gamma \mathbf{Norm}(\mathbf{x}_i) + \beta$$

여기서 Norm(xi)는 배치정규화된 훈련데이터, E(xi)는 배치 평균, Var(xi)는 배치 분산, 감마와 베타는 배치정규화의 크기와 이동 변수를 나타낸다. 이 두변수들은 모델훈련과정중에 학습된다.

배치 정규화 후, 최대 풀링 레이어를 사용하여 상위 수준의 특징을 추출한다. 또한, 풀링 레이어는 특징 표현의 공간적 크기를 줄이기 위해 활용된다. 이렇게 하면 매개변수의 수와 계산 부하가 줄어든다. 풀링 레이어는 각 특징 맵에 독립적으로 적용된다. 최대 풀링 레이어는 여러 필터 깊이가 없는 컨볼루션 레이어의 고정 영역에서 최대값을 추출한다. 그런 다음 출력이 다운샘플링되고 고유한 특징이 추출된다.

$$\mathbf{f}_{m}\left(\mathbf{x}^{l}\right) = \mathbf{max}\left(\mathbf{x}_{i}^{l}\right)$$

여기서 max(x)는 입력데이터의 최대값을 나타낸다.

그런 다음 드롭아웃 레이어를 적용하여 딥러닝 네트워크가 추가 또는 미래 데이터를 예측하는 데 실패하는 과적합을 방지한다.

첫 번째 컨볼루션 레이어의 출력은 더 작은 입력 크기와 더 깊은 커널 크기로 두 번째 컨볼루션 레이어에 공급되어 더 높은 수준의 특징 추출을 수행한다. 모든 컨볼루션 레이어를 거쳐서 나온 출력은 완전히 연결계층(Fully connetected layer)에 연결되어 유해남조류 시뮬레이션을 위해 클로로필-a 및 피코시아닌 두 개의 출력으로 나타낸다. 그런 다음 각 출력은 Adam최적화 함수에 공급되며, 손실 함수를 통해 추정된 피코시아닌과 클로로필-a와 관측값 간의 차이를 최소화한다.

$$y = \frac{\sum_{i=1}^{n} \left(x_i^l - o_i^l\right)^2}{n}$$

x는 CNN 결과값, o는 관측값, y는 손실함수를 나타낸다.

$$\varphi_i^l = \frac{\partial y}{\partial\left(k_{i,i+1}^l x_i^{l-1} + b_{i+1}^l\right)}$$

위 식은 역전파를 통한 훈련 가중치 변화에 따른 손실함수의 변화를 나타내며 CNN 학습은 모델값과 관측값의 차이가 최소가 되는 가중치를 찾을 때 까지 훈련된다.

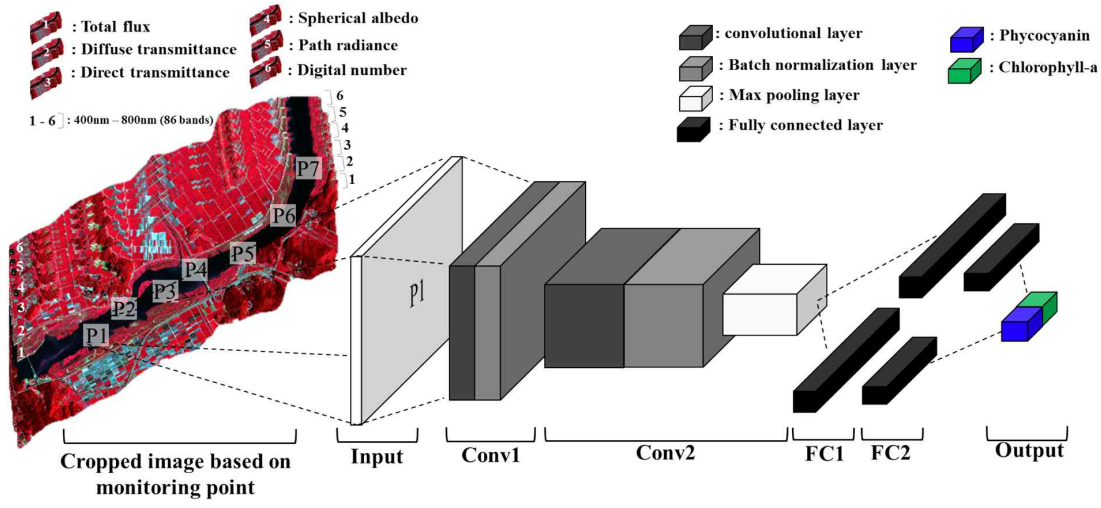


그림 22. 원격탐사 이미지를 활용한 CNN 모델 구조 (Pyo et al., 2019)

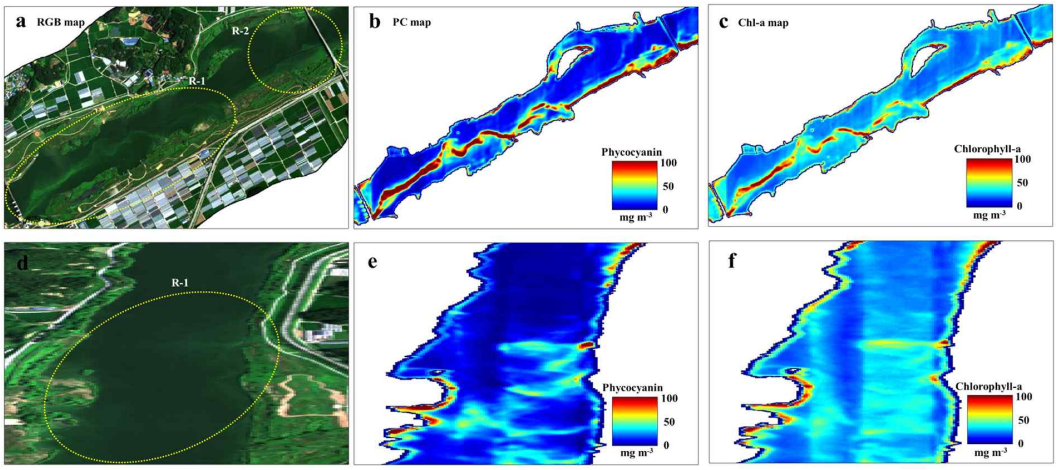


그림 23. CNN 모델을 활용한 유해남조류 공간분포 시뮬레이션 (Pyo et al., 2019)

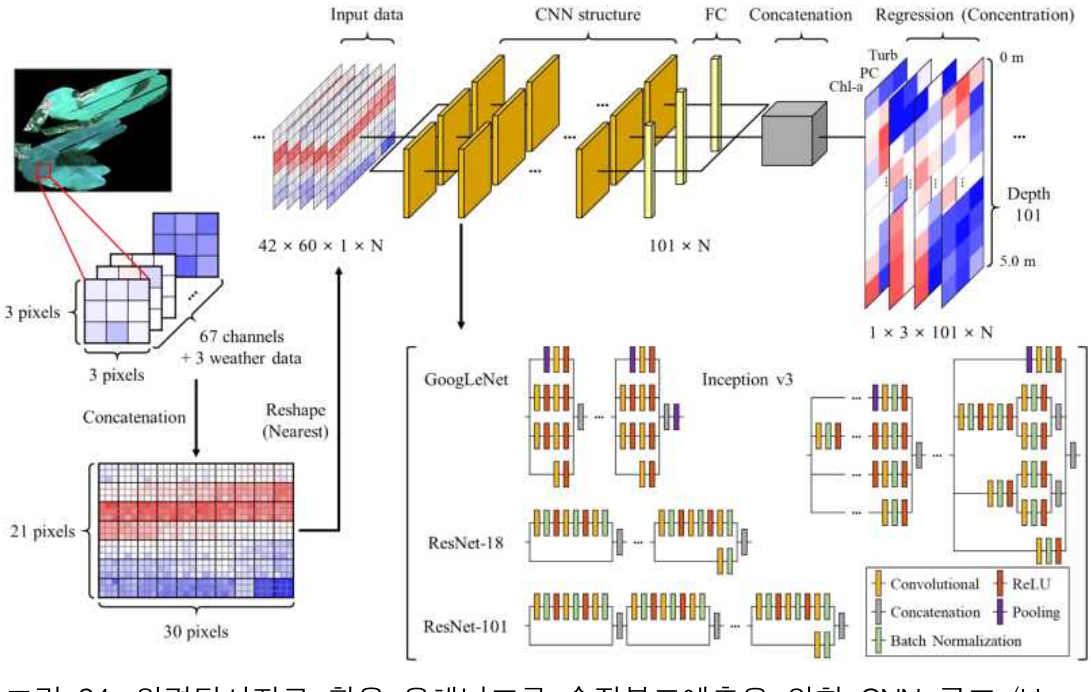


그림 24. 원격탐사자료 활용 유해남조류 수직분포예측을 위한 CNN 구조 (Hong et al., 2021)

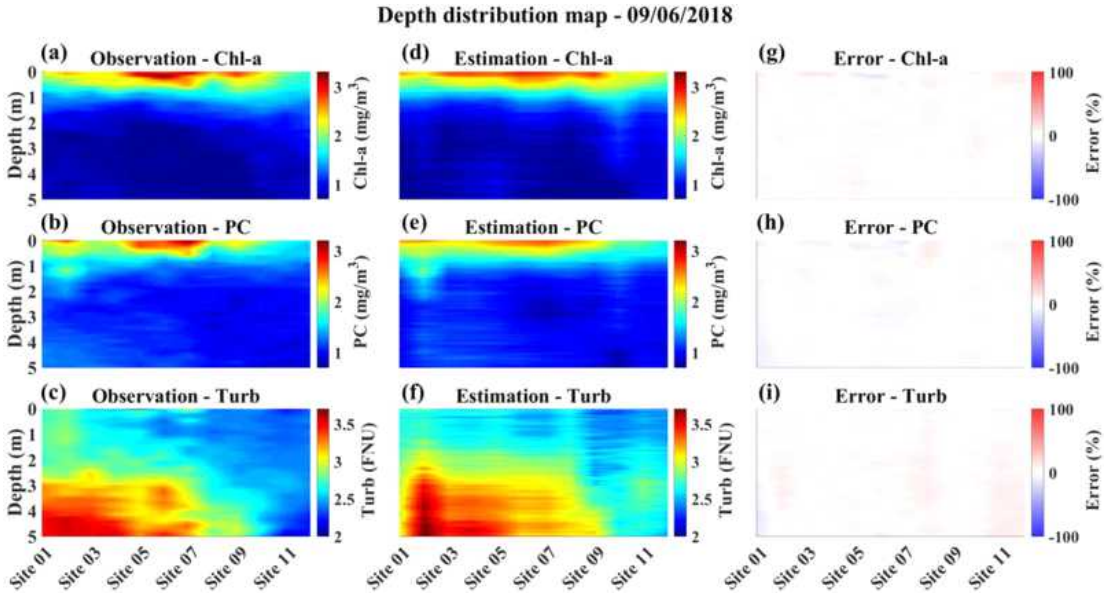


그림 25. CNN 활용 남조류 수직 분포 예측 (Hong et al., 2021)

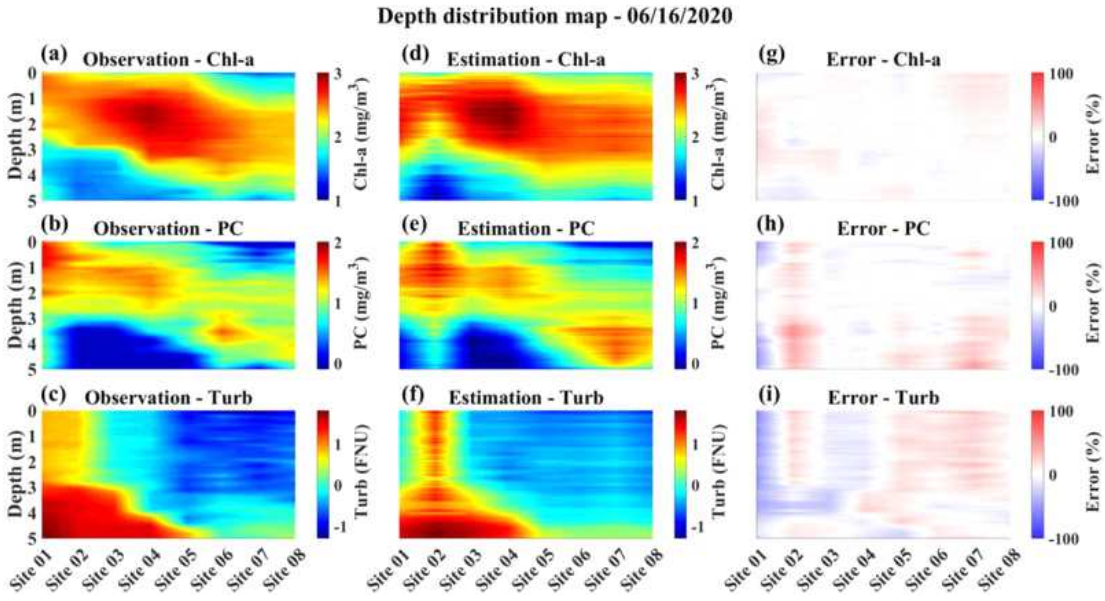


그림 26. CNN 활용 남조류 수직 분포 예측 (Hong et al., 2021)

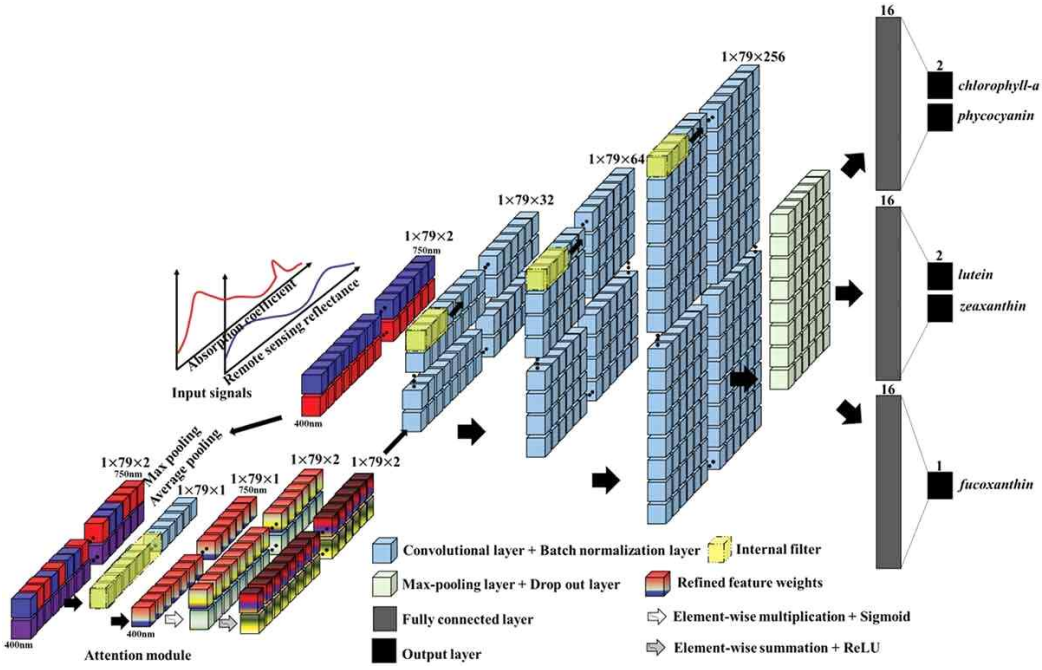


그림 27. 원격탐사 데이터 및 CNN 모델을 활용한 조류 정량색소 및 정성색소 산정 모델 구조 (Pyo et al., 2022)

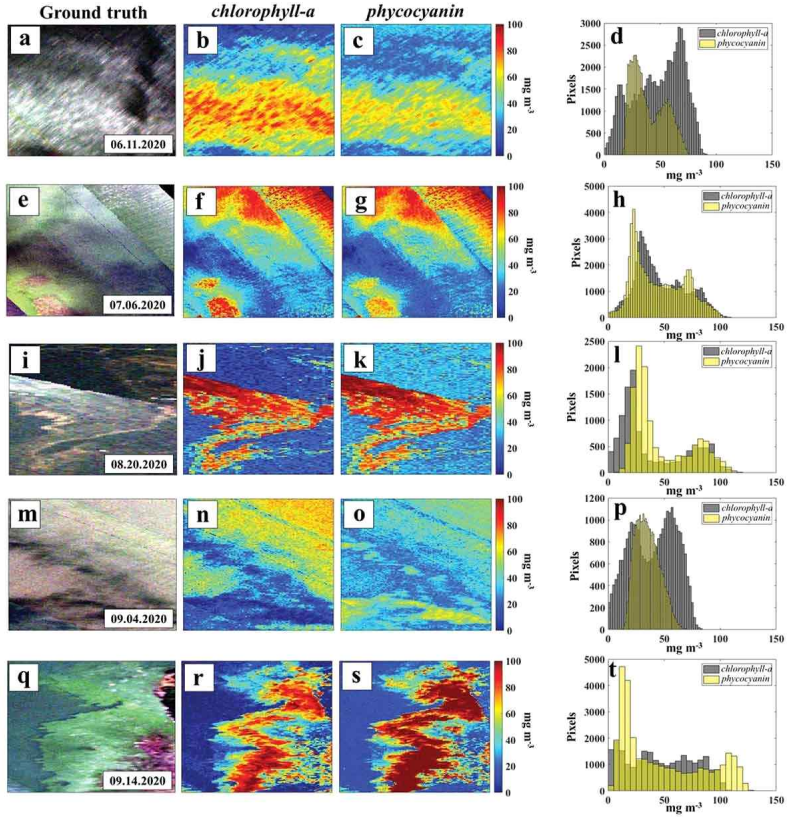


그림 28. CNN 활용 녹조 클로로필-a, 피코시아닌 산정 지도 (Pyo et al., 2022)

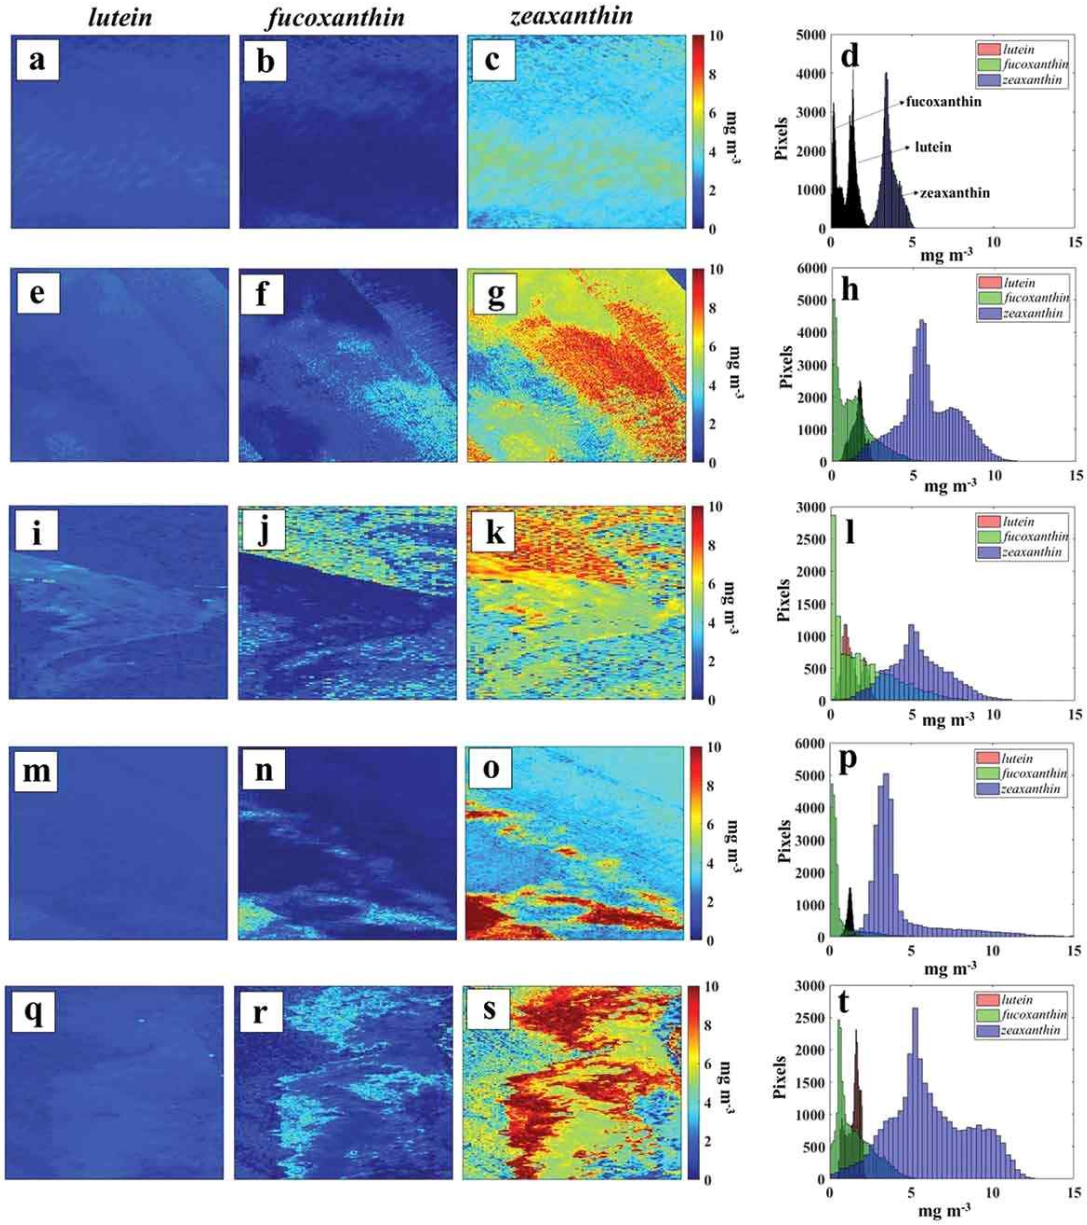


그림 29. CNN 활용 녹조 lutein, fucoxanthin, zeaxanthin 농도 산정 지도 (Pyo et al., 2022)

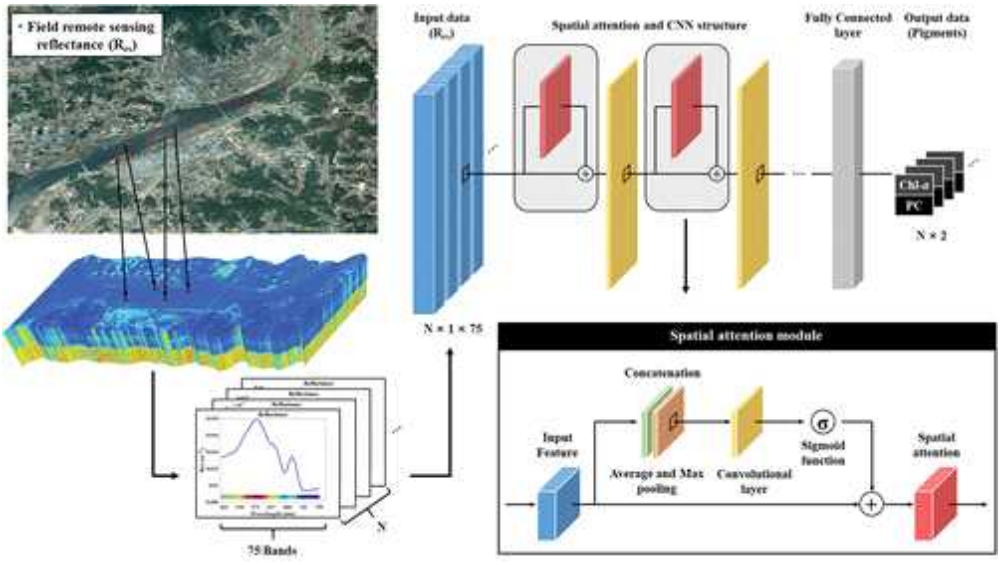


그림 30. CNN 모델 활용 유해남조류 예측 구조 (Hong et al., 2022)

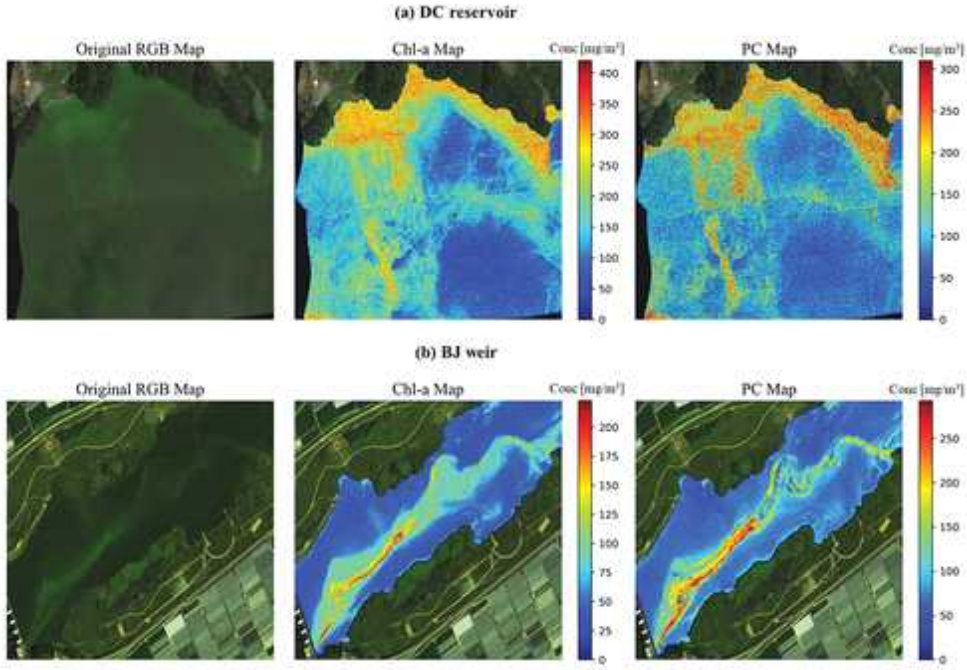


그림 31. CNN 모델 활용 녹조 산정 지도 (Hong et al., 2022)

나. 오토인코더

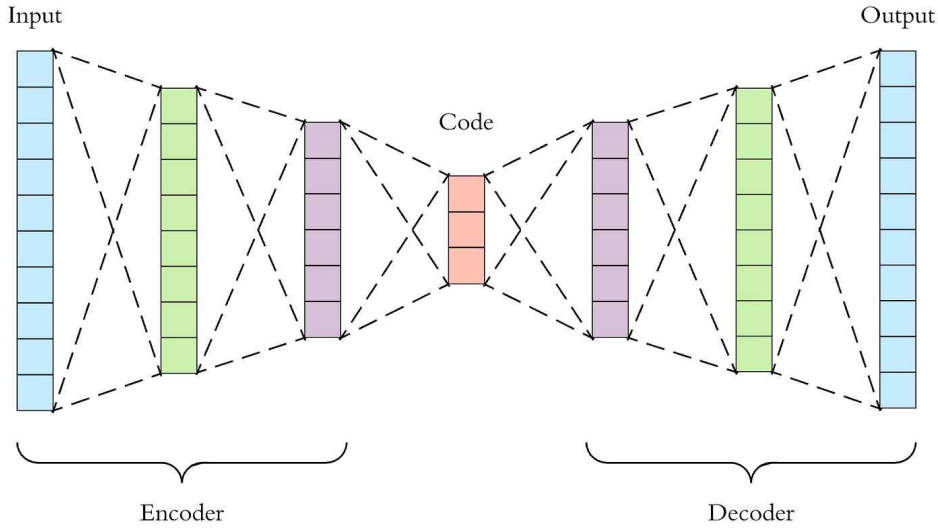


그림 32. 오토인코더 구조

딥러닝 방법은 이미지 기반 데이터 처리와 관련하여 최첨단 성능을 입증했다. 특히 컨볼루션 신경망(CNN)은 다중 커널 학습에 의해 얽힌 데이터 세트에서 심층 특징을 추출하는 뛰어난 기능을 제공했다. 또한 딥러닝 방법은 오토인코더를 활용하여 데이터 복잡성과 차원을 줄일 수 있다. 이러한 딥러닝의 특성은 가시광선 및 근적외선 분광 데이터 처리에 큰 잠재력을가지고 있다. 오토인코더는 비지도 특징 학습을 위한 신경망이다. 오토인코더의 일반적인 구조는 대표적인 비선형 자동 인코더 기능으로 구성된 인코더와 디코더로 구성된다 (그림 32).

$$f(x) = e_f\,(W_e x_i + b_e)$$

$$g(x) = d_f\,(W_d f(x_i) + b_d)$$

여기서 f(x)와 g(x)는 각각 인코더와 디코더 함수이고, We와 Wd는 가중치 행렬을 나타내며, Be와 bd는 바이어스 벡터이다. 활성화 함수의 경우 식들에 주어진 것처럼 인코딩 및 디코딩 레이어에서 시그모이드 함수를 활용했다. 인코딩 레이어에서 이미지 픽셀은 입력 피처로 입력된다. 그런 다음 입력 픽셀의 스펙트럼 및 공간 정보가 압축되어 중간 레이어로 인코딩되므로 숨겨진 노드의 수가 줄어든다. 디코딩 레이어에서 터미널 노드는 원래 입력 이미지와 동일하게 재구성된다. 인코딩 레이어는 고차원 데이터를 저차원 데이터로 변환하는 반면, 디코딩은 저차원 데이터를 복구하여 원래 입력 구조와 동일한 고차원 데이터로 변환한다. 여기서 오토인코더 레이어의 숨겨진 노드는 입력 이미지의 하이퍼큐브에서 다양한 특징을 처리한다. 특히 오토인코더는 비선형 데이터의 특징 추출 및 차원 축소에 이점이 있다. 그러나 이는 소수의 스펙트럼 대역으로만 제한된다. 데이터 복잡성으로 인해 입력 특징의 적절한 추상화를 추출하는 데 어려움이 있기 때문에 수백 개의 초분광 대역을

처리하는 것은 자동 인코더에 바람직하지 않다. 따라서 이런 경우 stacted 오토인코더(SAE) 형태의 변형 오토인코더 네트워크도 활용될 수 있다. SAE의 기본 원리는 원래 자동 인코더 네트워크의 원리와 유사하다. 초분광 이미지 와같이 복잡한 특징 정보를 다룰 때 SAE는 기본 오토 인코더 네트워크의 대안으로 사용될 수 있다. 단일 히든 레이어를 가진 오토인코더와 달리 SAE는 여러 인코딩 및 디코딩 레이어로 구성된다.

$$f_k(x) = e_{k,f}(W_{k,e}x_{k,i} + b_{k,e})$$

$$g_t(x) = d_{t,f}(W_{t,d}f(x_{t,i}) + b_{t,d})$$

여기서 fk(x)와 gt(x)는 각각 k번째와 t번째 인코더와 디코더 레이어 함수이고, Wk,e와 Wk,d는 k번째 및 t번째 레이어의 가중치 행렬을 나타내며, bk,e와 bt,d는 k번째 및 t번째 레이어의 바이어스 벡터이다.

SAE 네트워크를 훈련하기 위해 역전파 오차 도함수를 사용하여 네트워크의 오토인코더 레이어에서 훈련 가중치를 업데이트한다.

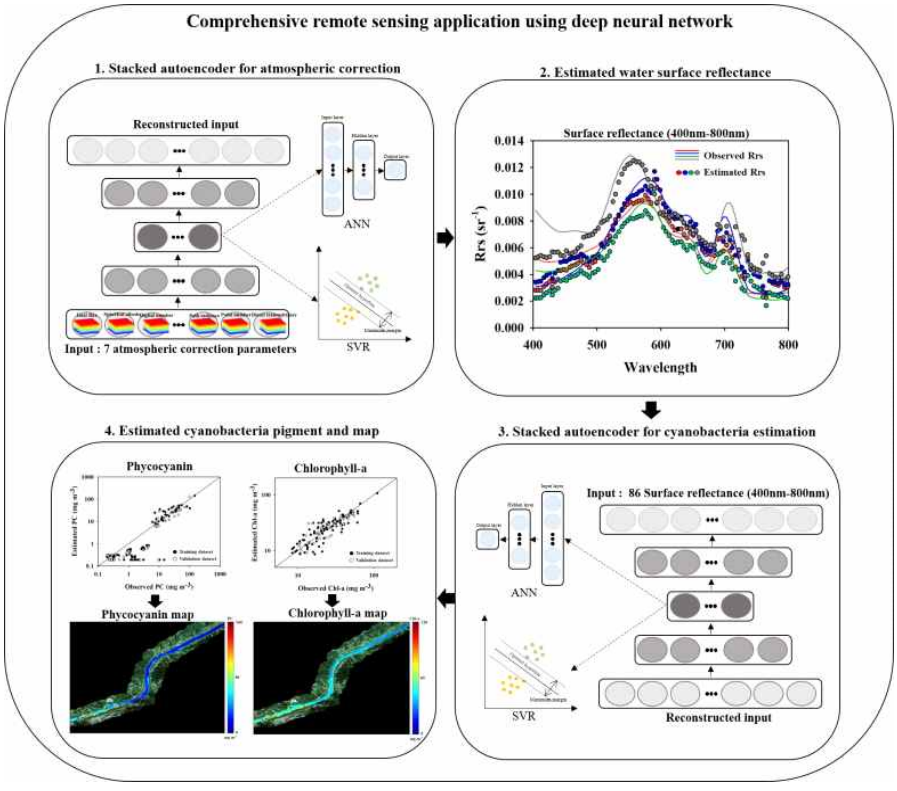


그림 33. SAE 활용 녹조 예측 (Pyo et al., 2020)

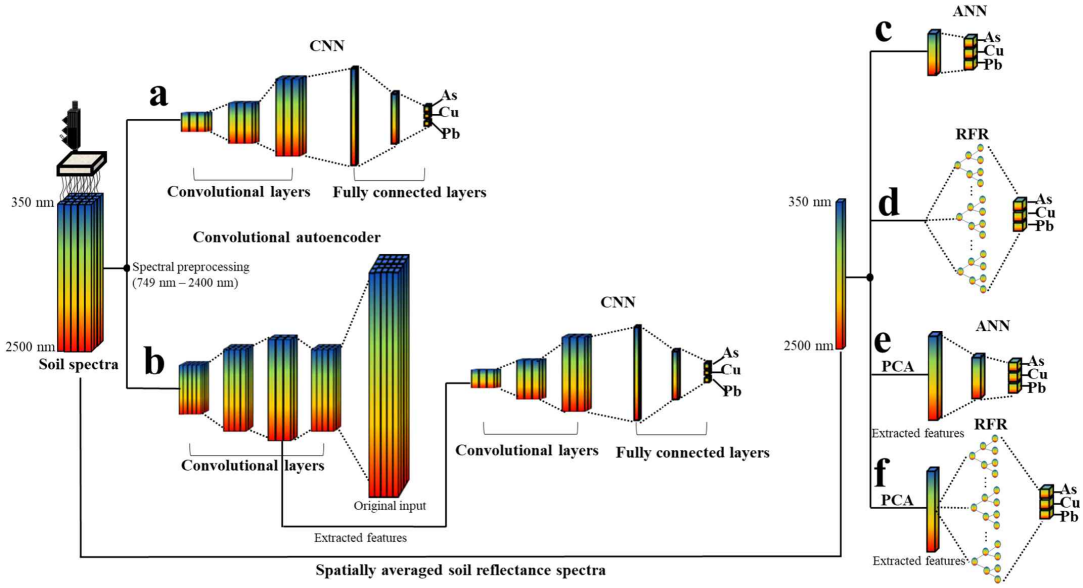


그림 34. CNN 기반 SAE 활용 예시 (Pyo et al., 2020)

다. 멀티모달

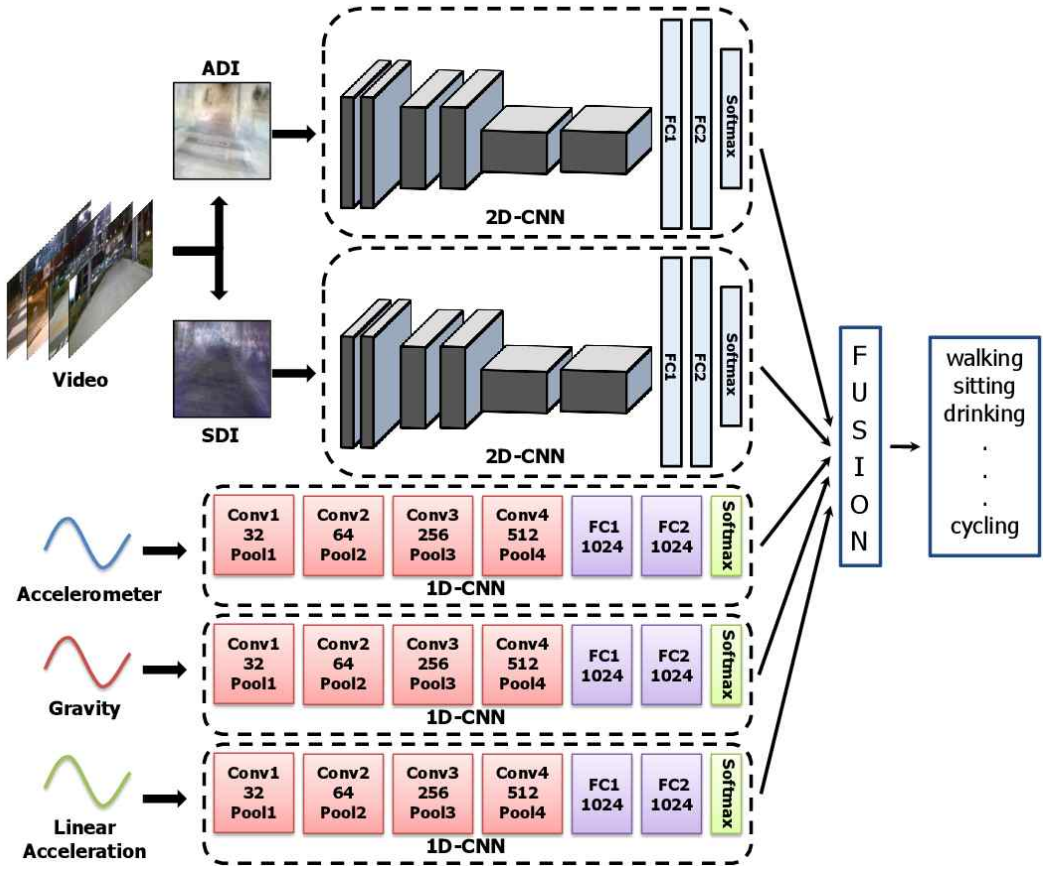


그림 35. CNN 기반 멀티모달 모델

CNN 기반 멀티모달 모델은 이미지와 텍스트와 같은 다양한 형태의 데이터를 결합하여 복합 정보를 효과적으로 처리하는 모델입이다. CNN은 주로 이미지 데이터에서 특징을 추출하는 데 사용되며, 멀티모달 모델에서는 CNN을 통해 이미지의 시각적 정보를 처리한 뒤, 텍스트 또는 시계열 데이터와 결합하여 예측 성능을 높인다. 멀티모달 모델의 주요 목적은 여러 데이터 소스 간의 상관관계를 학습하여 더욱 정교한 예측 및 분류 작업을 수행한다. 멀티모달 모델에서 CNN은 주로 이미지 데이터를 처리하는 데 사용되며 이때 컨볼루션 층과 풀링 층을 통해 이미지의 공간적 특징을 추출하고, 이러한 특징들을 통해 중요한 시각적 패턴을 감지한다. 대표적인 CNN 구조로는 ResNet, VGG, Inception 등이 있으며, 이들은 이미지의 저수준 특징(엣지, 텍스처)부터 고수준 특징(객체, 형태)까지 다양한 정보를 학습할 수 있다. 이 과정을 통해 이미지 데이터는 시각적 특징 벡터로 변환된다. 멀티모달 모델에서 이미지뿐만 아니라 텍스트 및 시계열 데이터도 중요한 역할을 한다. 텍스트 및 시계열 데이터는 RNN(Recurrent Neural Network), LSTM(Long Short-Term Memory), 또는 최근에는 BERT, GPT 같은 Transformer 기반 모델을 통해 처리되며, 이로 인해 텍스트의 의미와 문맥 정보를 벡터 형태로 추출할 수 있다.

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}$$

여기 식은 어텐션 메커니즘을 통해 각 단어/시간의 중요도를 반영한 가중치의 합을 나타낸다.

이렇게 이미지와 텍스트 또는 시계열로부터 얻어진 특징 벡터들은 공통 잠재 공간에서 결합된다. 이 과정에서 이미지와 텍스트, 시계열데이터 간의 관계를 학습하여 복합 정보를 기반으로 예측이나 분류 작업을 수행한다. 멀티모달 모델에서 이미지와 텍스트 또는 시계열 정보를 결합하는 방식에는 여러 가지가 있다. Early Fusion은 이미지와 텍스트/시계열 데이터를 결합한 후 하나의 네트워크에 입력하여 학습하는 방식이다. 데이터 레벨에서 결합하여 두 가지 데이터 간의 관계를 초기부터 학습할 수 있다. Late Fusion은 이미지와 텍스트/시계열 데이터를 개별적으로 처리한 후, 마지막 단계에서 결합하는 방식이다. 이를 통해 각 모달리티의 특성을 별도로 학습할 수 있으며, 마지막에 결합하여 예측 성능을 향상시킨다. Joint Embedding은 이미지와 텍스트 특징을 공통의 잠재 공간으로 투영하여 임베딩 공간에서 결합하는 방식이다. 이를 통해 두 데이터의 의미적 유사성을 효과적으로 학습할 수 있다.

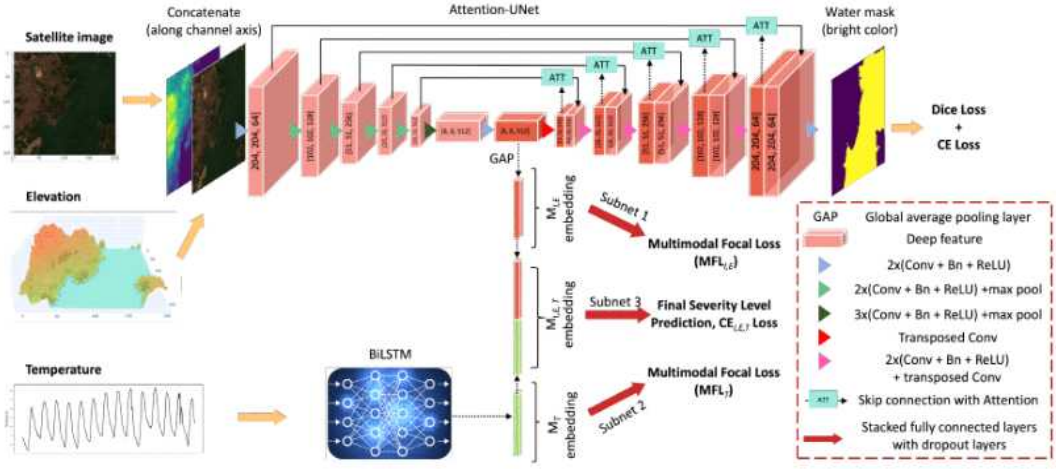


그림 36. 멀티모달 기반 녹조 심각성 예측 모델 (Zhao et al., 2023)

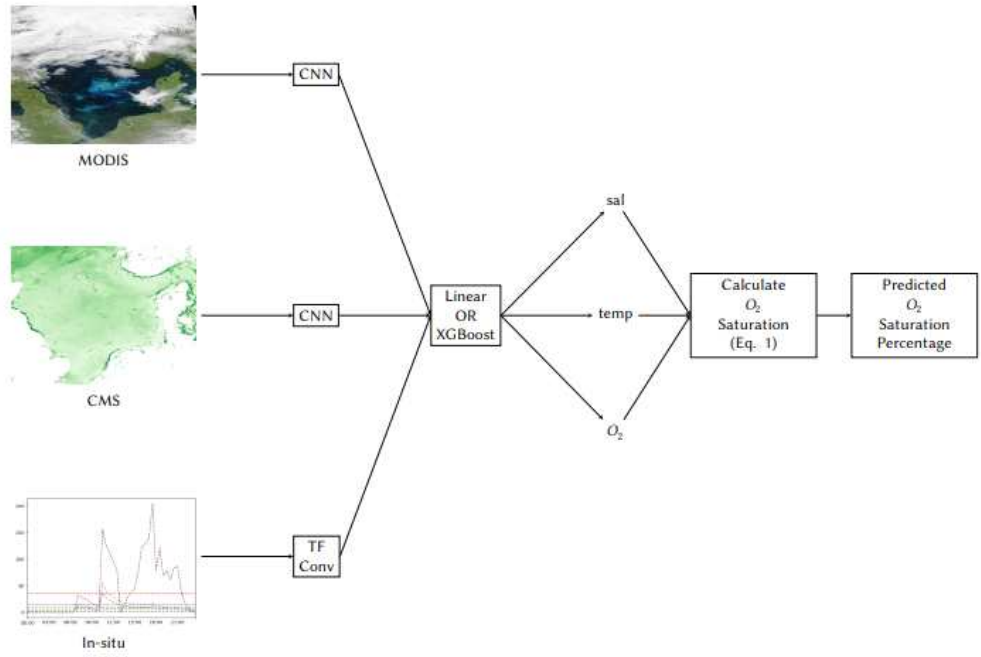


그림 37. 멀티모달 기반 녹조 초기 예측 모델 (Dagtekin and Dethlefs, 2022)

3. 위성-기상-수문 연계데이터의 AI 모델 적용을 통한 녹조 예측

본 보고서는 위성이미지자료, 기상데이터자료, 수문 모델링 합성 자료를 연계하여 이를 AI 모델에 적용을 통해 영주댐 수계의 녹조 예측 가능성을 평가하였다. AI 모델은 CNN 기반 모형을 중심으로 구조를 설계하고 하이퍼파라미터를 최적화 하였다. 비정형 이미지 데이터, 유량 데이터와 static한 기상 자료를 처리하기 위해 오토인코더, 멀티모달, CNN 기반의 데이터 특징 처리방법을 도입하여 성능을 평가해 보았다.

3.1 입출력 데이터

입력데이터는 영주댐 수계의 2021년 5월 9일, 6월 8일, 7월 28일, 8월 5일, 9월 11일 Sentinel-2 이미지의 반사도 스펙트럼 12개의 밴드와 유량 및 기온데이터로 구성하였다. 이때 유량 및 기상 데이터는 이미지 데이터 날짜 기준 3일전, 7일전 데이터로 구성하였고 3일 후 그리고 7일 후의 클로로필-a를 출력자료로 설정하였다 (그림 38). 3일 후 예측에는 총 12147개, 7일 후 예측에는 12093개의 데이터를 활용하였으며 이중 70%는 훈련데이터 30%는 딥러닝 모델 검증데이터로 랜덤하게 나누어 모델 훈련을 수행하였다. 입력자료 종류의 구성은 반사도 데이터만으로 3일 후, 7일 후 클로로필 예측 그리고 반사도 및 유량과 기상데이터 활용 3일 후, 7일 후 클로로필 예측 성능을 테스트하였다.

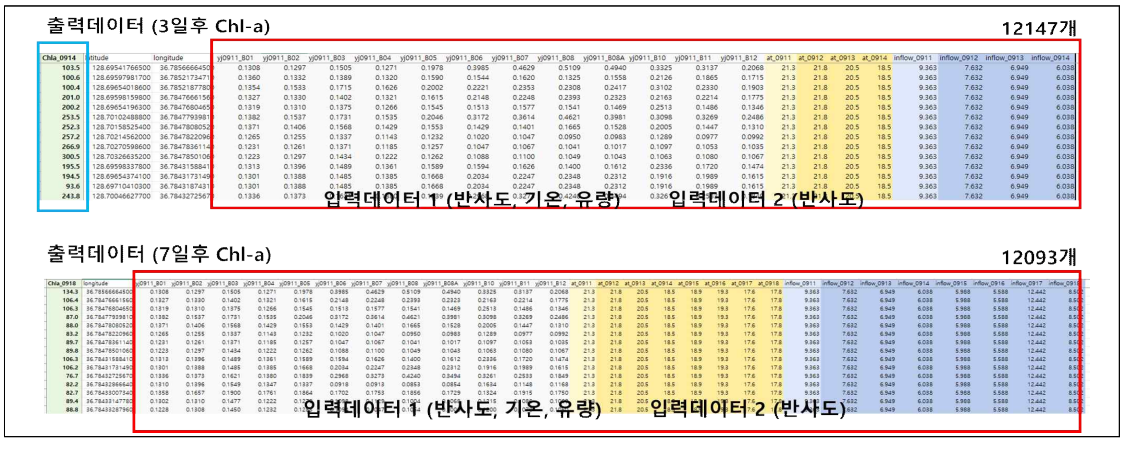


그림 38. 클로로필-a 예측 입력자료 구성

3.2 딥러닝 모델링 구조 및 하이퍼파라미터 최적화

Sentinel-2 반사도, 유량, 그리고 기상 데이터의 비정형적 그리고 static한 특징들을 효율적으로 추출하기 위해 1D-CNN 모델을 구성하여 3일 후 및 7일 후 녹조 예측 성능을 평가하였다. 기본이 되는 CNN 모델은 3개의 컨볼루셔널 레이어로 구성하였고 각각 64, 128, 256의 레이어수와 1x2, 1x2, 1x3의 커널 사이즈, 모두 패팅을 도입하였고 스트라이드는 1로 구성하였다. 이후 완전연결계층을 취한 후 8개의 노

드를 가지는 히든 레이어를 도입하여 클로로필-a를 예측하였다. 이때 활성화 함수는 leaky relu함수를 모든 레이어에 동일하게 도입하였다. 훈련을 위해 배치사이즈를 256, 훈련 에폭을 1000, 학습율을 0.00001로 설계하여 훈련을 수행하였다.

멀티모달의 경우 반사도 데이터는 32, 64, 128의 CNN레이어 수와 1x3의 필터사이즈 강우 및 유량데이터는 16,32,32,32 레이어수 1x2 필터사이즈의 멀티모달 모델을 구성하여 클로로필-a를 예측하였다.

오토인코더를 CNN 모델 앞단에 도입하여 반사도, 유량, 기상데이터의 비선형적 특징을 강화시키고자하였다. 오토인코더는 4개의 인코더 및 3개의 디코더 레이어로 구성하였고 70, 60, 50, 40, 50, 60, 70의 히든노드개수를 설계하였다. 이후 40개의 latent 특징을 CNN 모델 입력자료로 활용하여 클로로필-a를 예측하였다.

CNN모델을 활용하여 반사도, 유량, 기상데이터의 특징을 변환한후 랜덤포레스트(RF)를 적용하여 클로로필-a를 예측하였다. RF의 estimator는 100으로 설정하여 훈련을 진행하였다.

3.3 딥러닝 모델링을 통한 녹조 예측 결과

그림 39는 반사도, 기상, 유량 입력자료와 CNN 모델을 활용한 3일 후의 클로로필-a의 훈련 및 검증 결과를 나타냈다. 검증 정확도의 상관관계는 높게 나타났지만 클로로필-a분포의 경우 static한 기온 및 유량 데이터의 특징을 많이 따라가는 경향을 보였다.

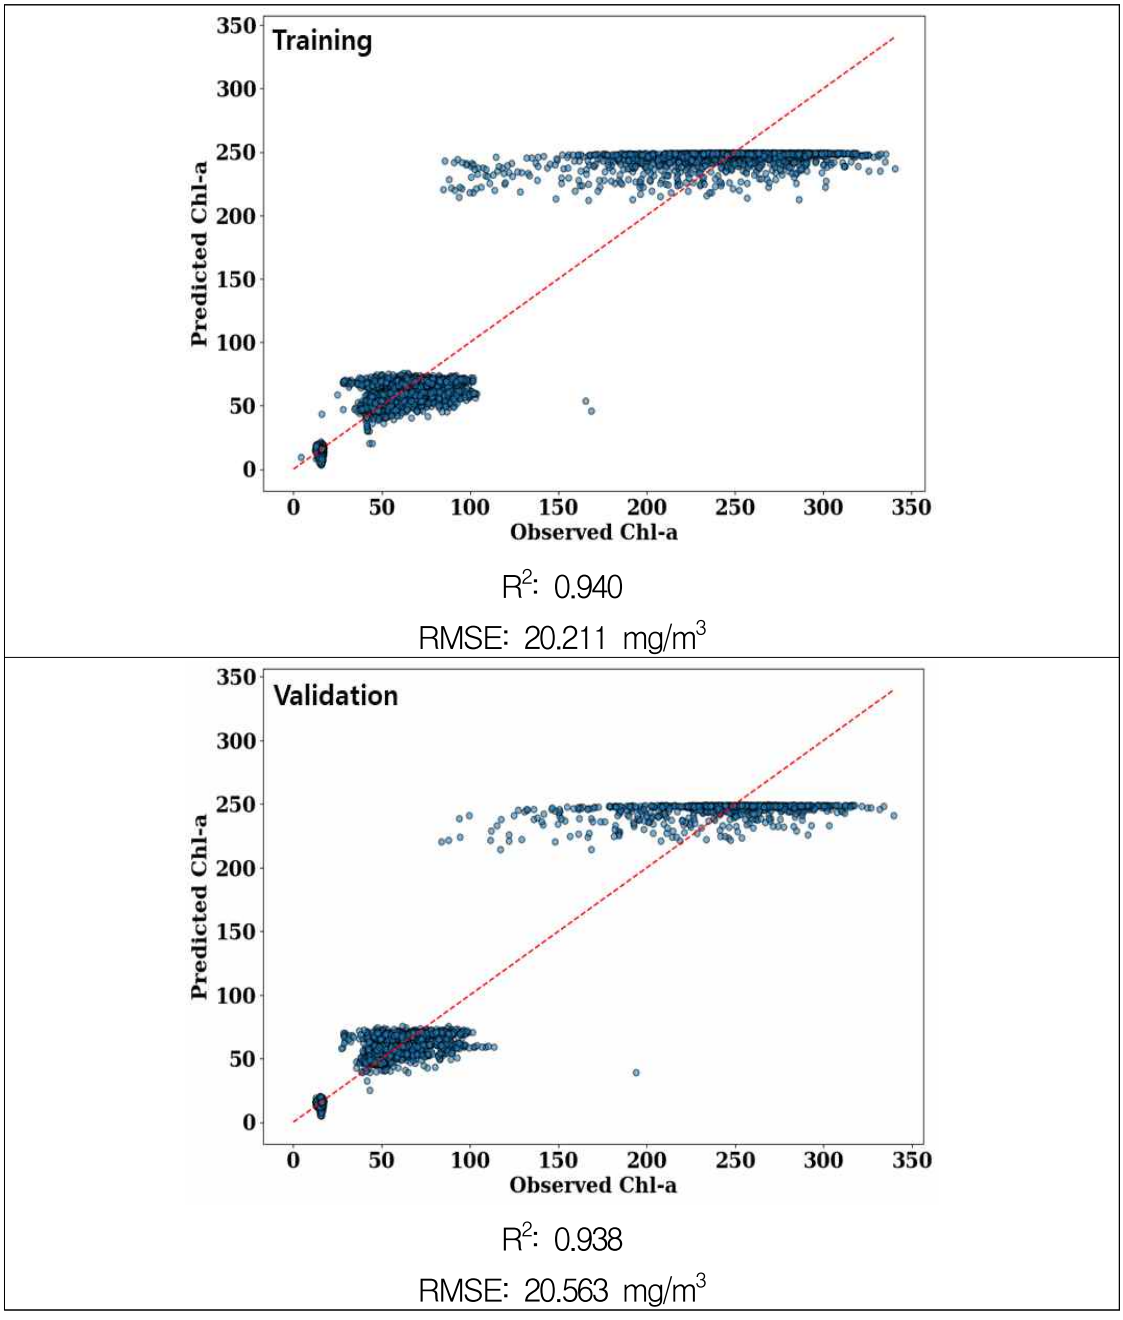


그림 39. CNN 기반 3일 후 클로로필-a 예측 성능 (반사도, 기온, 유량 입력)

그림 40은 반사도 입력자료와 CNN 모델을 활용한 3일 후의 클로로필-a의 훈련 및 검증 결과를 나타냈다. 반사도 데이터를 활용하였을 때 현실적인 훈련 및 검증 산포도 결과가 나타났다.

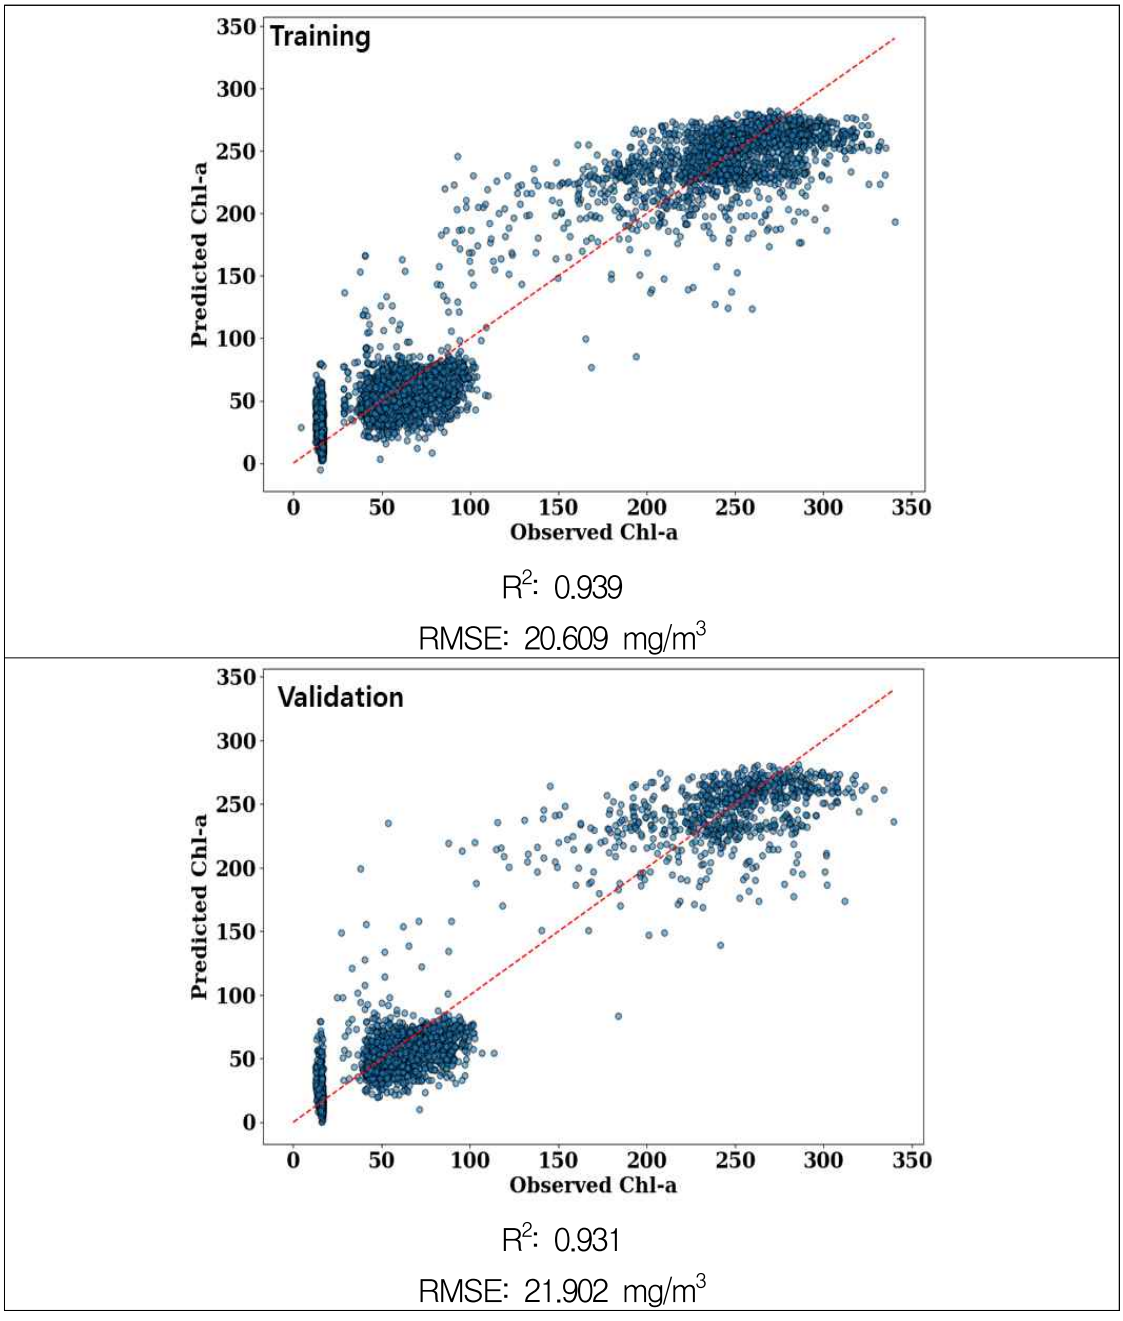


그림 40. CNN 기반 3일 후 클로로필-a 예측 성능 (반사도 입력)

그림 41은 반사도, 기상, 유량 입력자료와 오토인코더와 CNN 모델을 활용한 7일 후의 클로로필-a훈련 및 검증 결과를 나타냈다. 7일 후의 결과이기 때문에 입력자료와의 상관관계가 낮아져 3일 후에 비해 상대적으로 낮은 성능을 보였다. 또한, 산포도 분포를 확인하였을 때 오토인코더의 입력자료 특징변환의 효과가 크게 나타나지 않았다.

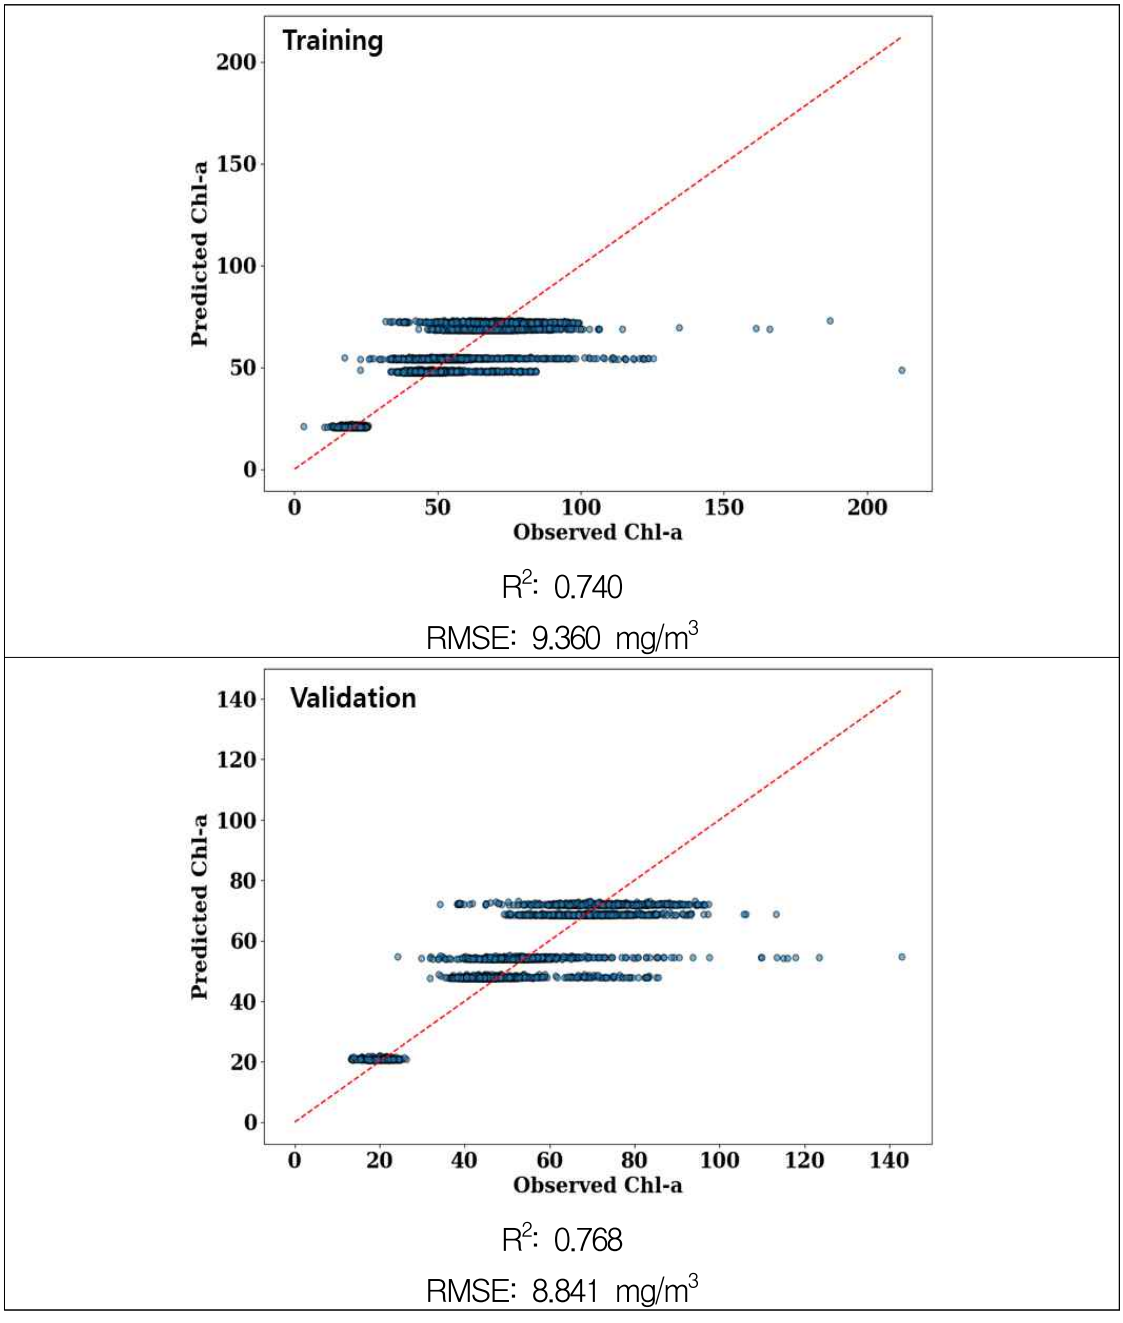


그림 41. 오토인코더 CNN 기반 7일 후 클로로필-a 예측 성능 (반사도, 기온, 유량 입력)

그림 42는 반사도 입력자료와 오토인코더와 CNN 모델을 활용한 7일 후의 클로로필-a훈련 및 검증 결과를 나타냈다. 7일 후의 결과이기 때문에 입력자료와의 상관관계가 낮아져 3일 후에 비해 상대적으로 낮은 성능을 보였다. 오토인코더 특징추출이 CNN모델의 예측성능 제고에 효과가 미미함을 확인하였다.

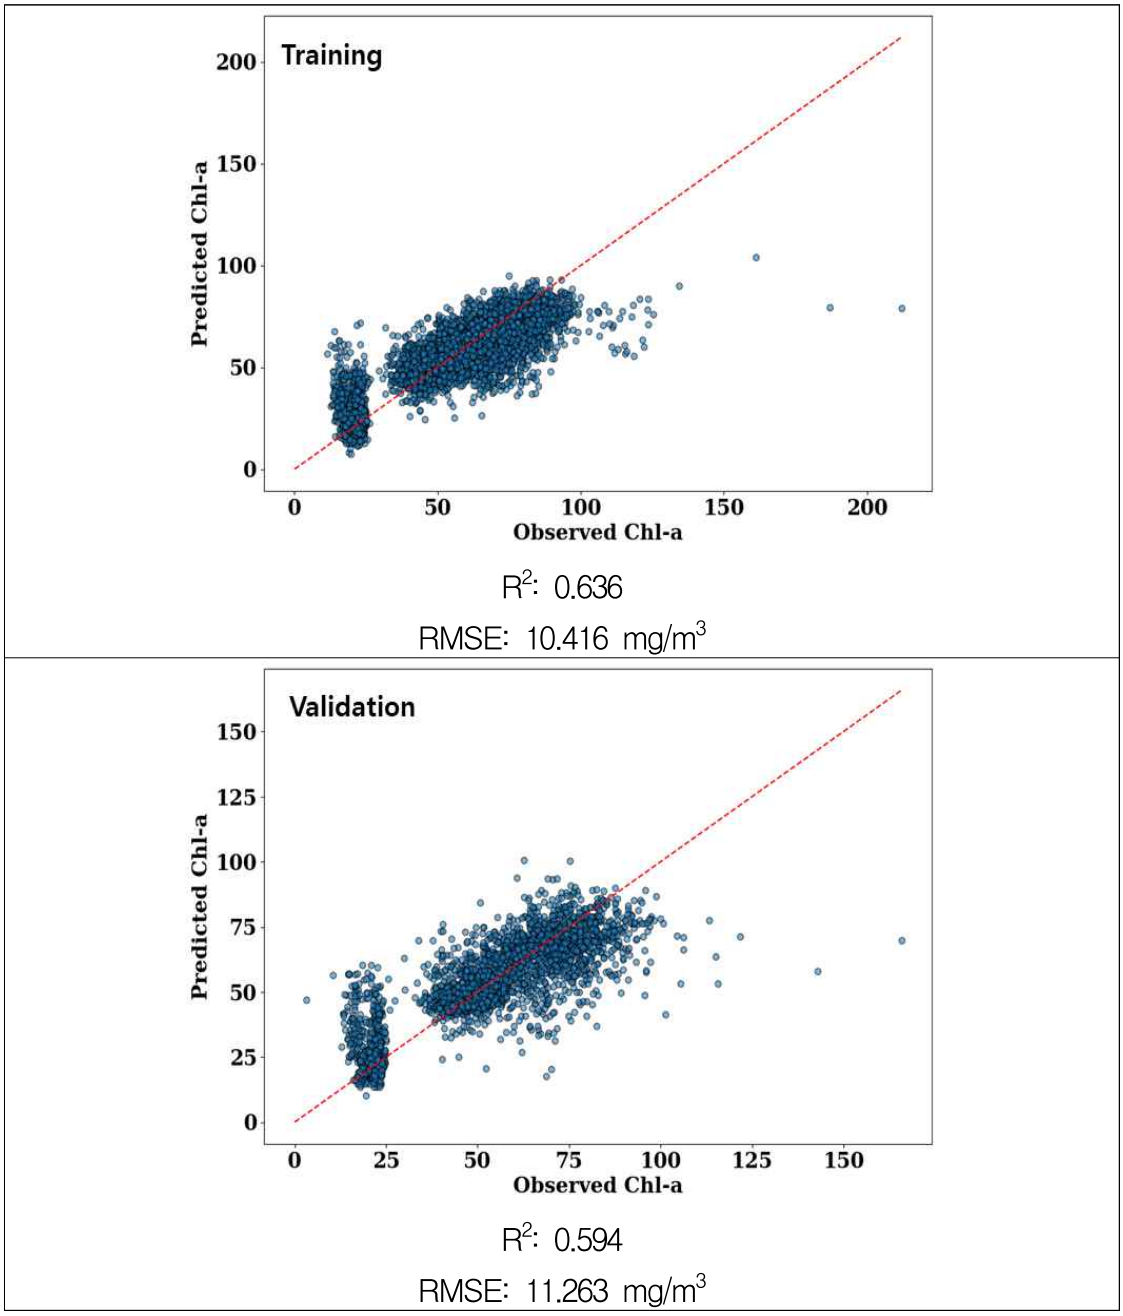


그림 42. 오토인코더 CNN 기반 7일 후 클로로필-a 예측 성능 (반사도 입력)

그림 43은 반사도, 기상, 유량 입력자료와 멀티모달 모델을 활용한 3일 후의 클로로필-a 훈련 및 검증 결과를 나타냈다. 멀티모달로 병렬적으로 기상 유량 데이터를 처리하였지만 static 지배적인 클로로필-a 산포도 결과를 확인하였다.

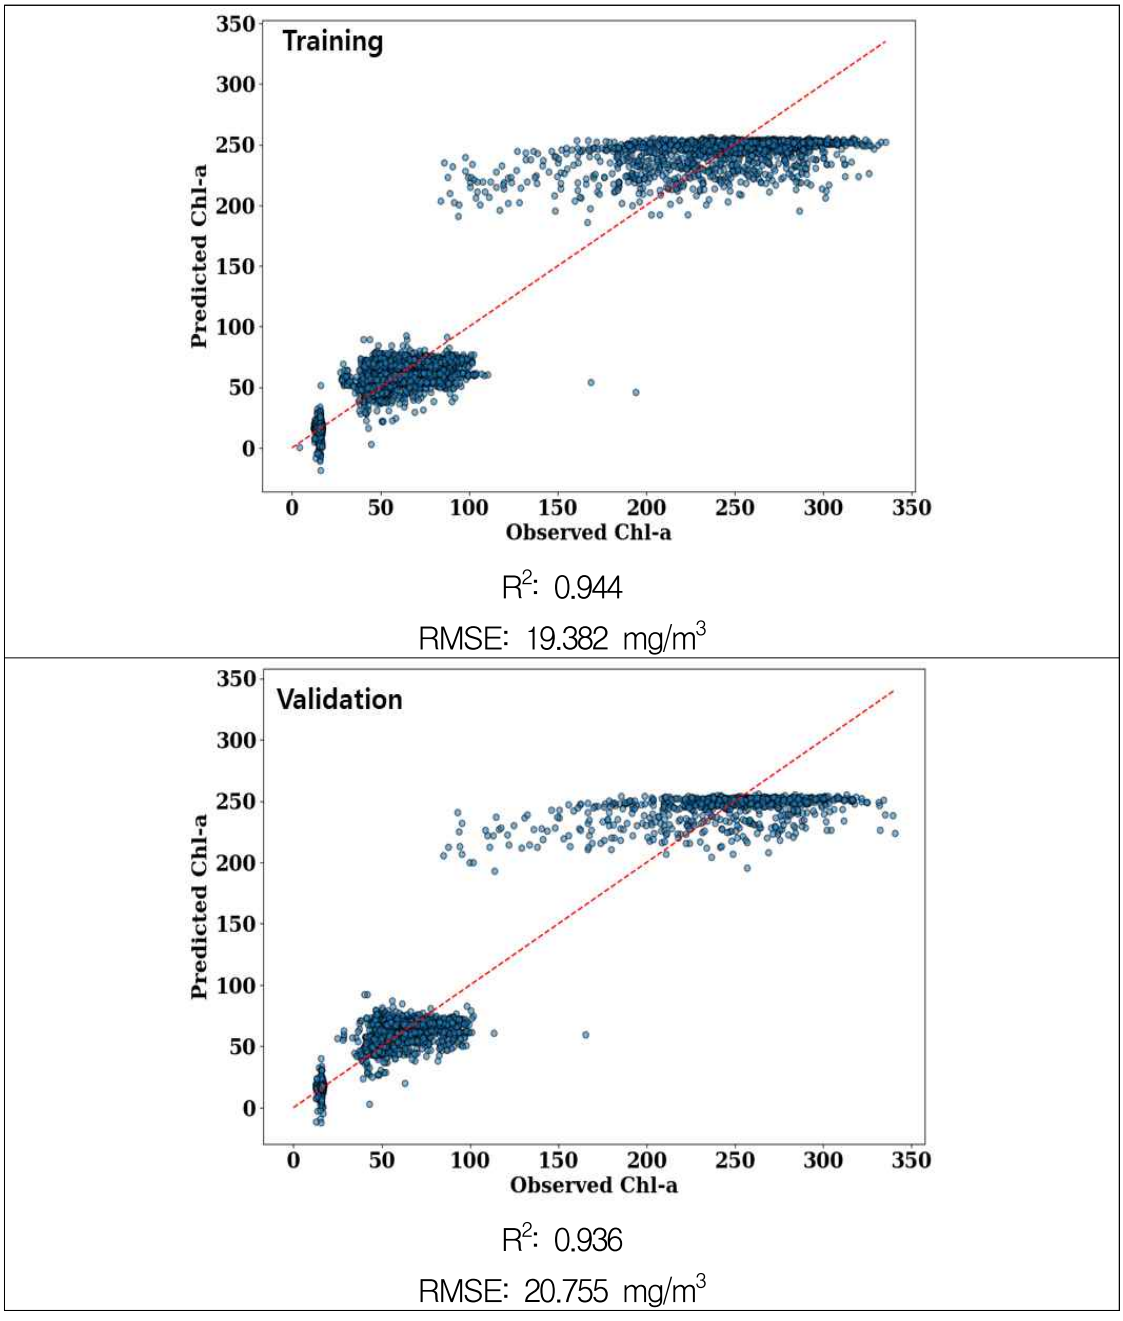


그림 43. 멀티모달 기반 3일 후 클로로필-a 예측 성능 (반사도, 기온, 유량 입력)

그림 44는 반사도, 기상, 유량 입력자료와 CNN과 RF모델을 활용한 3일 후의 클로로필-a 훈련 및 검증 결과를 나타냄. CNN을 활용한 입력자료 특징 변환과 RF 모델의 클로로필-a 예측성능이 robust함을 확인하였다.

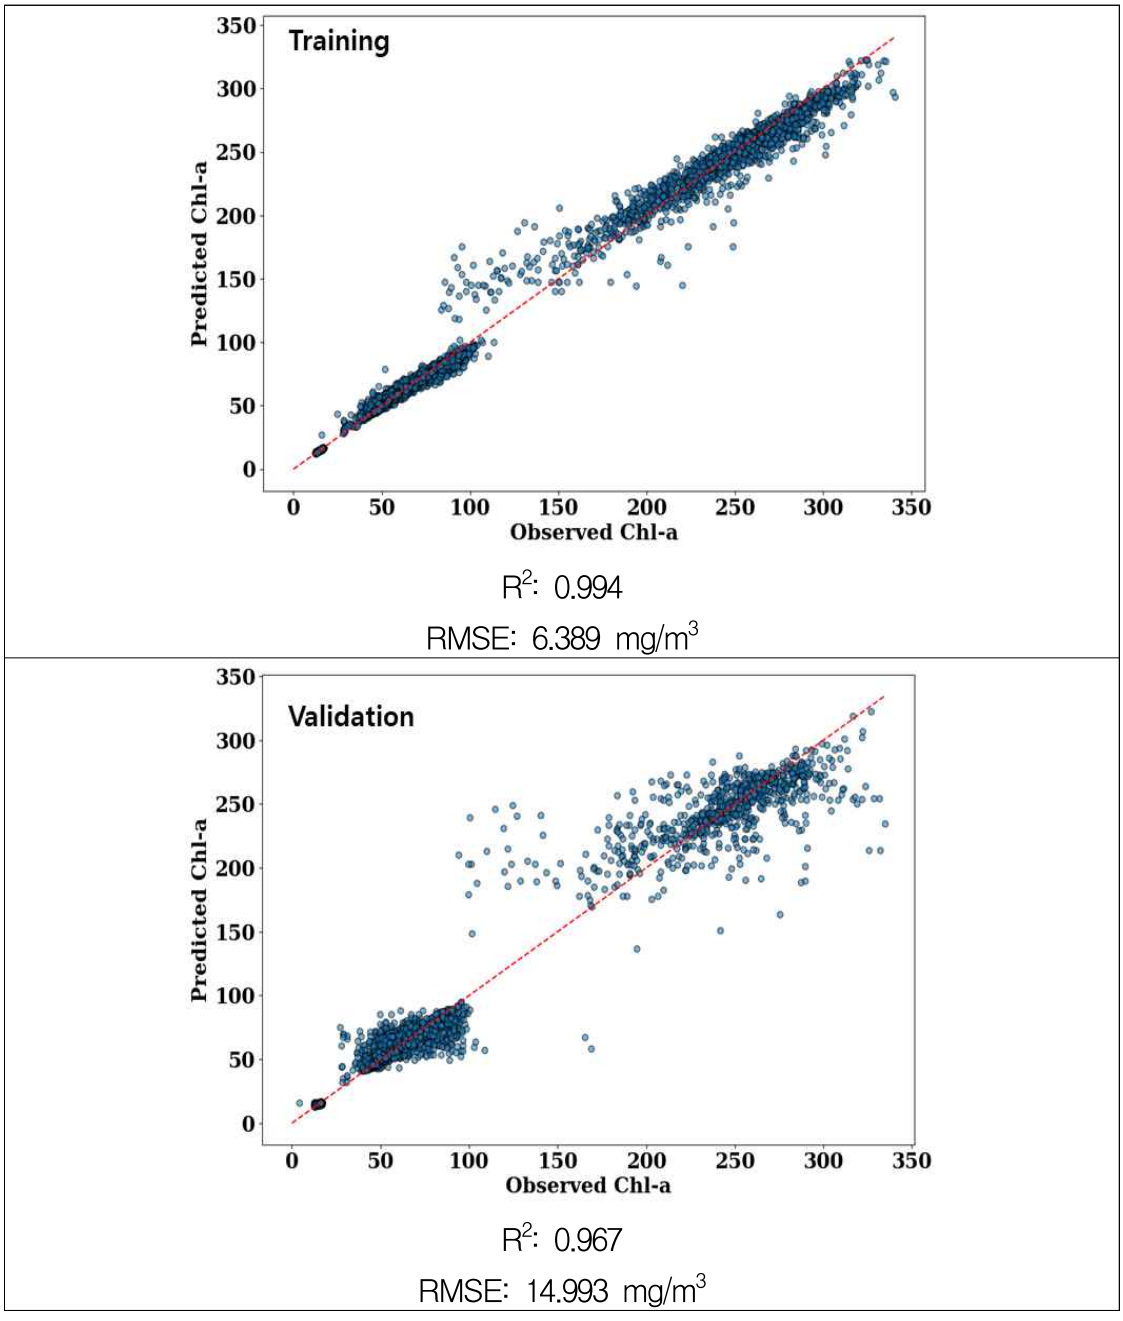


그림 44. CNN 및 RF 기반 3일 후 클로로필-a 예측 성능 (반사도, 기온, 유량 입력)

그림 45는 반사도 입력자료와 CNN과 RF모델을 활용한 3일 후의 클로로필-a훈련 및 검증 결과를 나타냄. CNN을 활용한 입력자료 특징 변환과 RF 모델의 클로로필-a 단기 예측을 높은 정확도로 하였고 추가적인 기상 및 유량데이터의 필요성을 확인하였다.

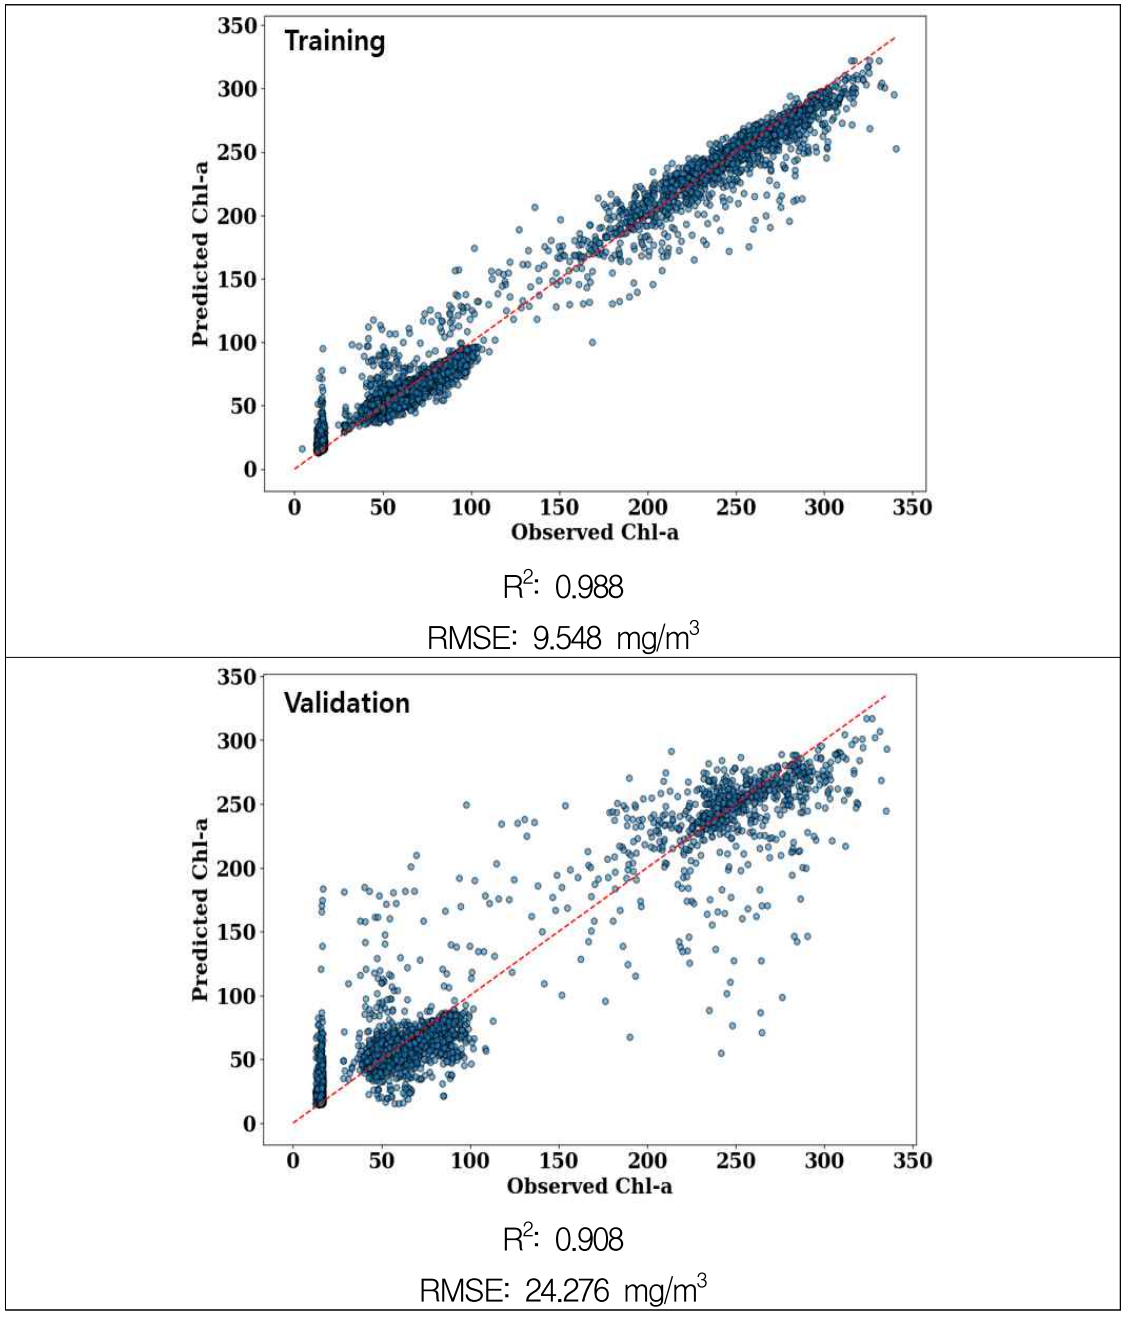
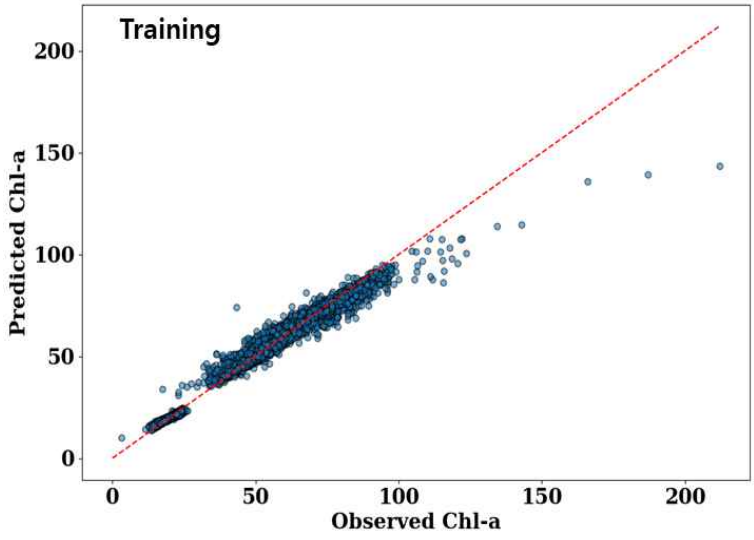


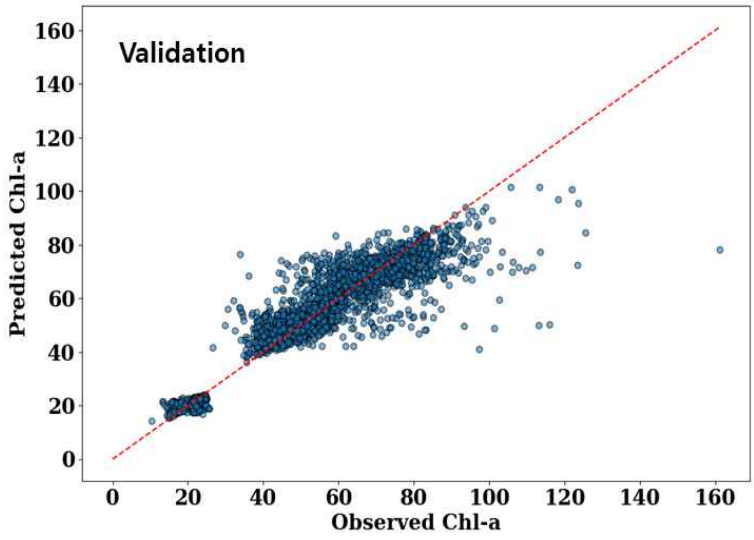
그림 45. CNN 및 RF 기반 3일 후 클로로필-a 예측 성능 (반사도 입력)

그림 46은 반사도, 기상, 유량 입력자료와 CNN과 RF모델을 활용한 7일 후의 클로로필-a훈련 및 검증 결과를 나타냄. CNN을 활용한 입력자료 특징 변환과 높은 RF 모델의 7일 후의 클로로필-a 예측성능을 확인하였다.



R^2: 0.980

RMSE: 2.824 mg/m^3



R^2: 0.864

RMSE: 7.084 mg/m^3

그림 46. CNN 및 RF 기반 7일 후 클로로필-a 예측 성능 (반사도, 기온, 유량 입력)

그림 47은 반사도 입력자료와 CNN과 RF모델을 활용한 7일 후의 클로로필-a 훈련 및 검증 결과를 나타냄. 반사도 CNN을 활용한 입력자료 특징 변환 RF 모델의 검증 정확도를 제고하지 못하였음. 유량 및 기상데이터의 추가 및 전처리 모델 설정을 통한 클로로필-a 단기 예측의 필요성을 확인하였다.

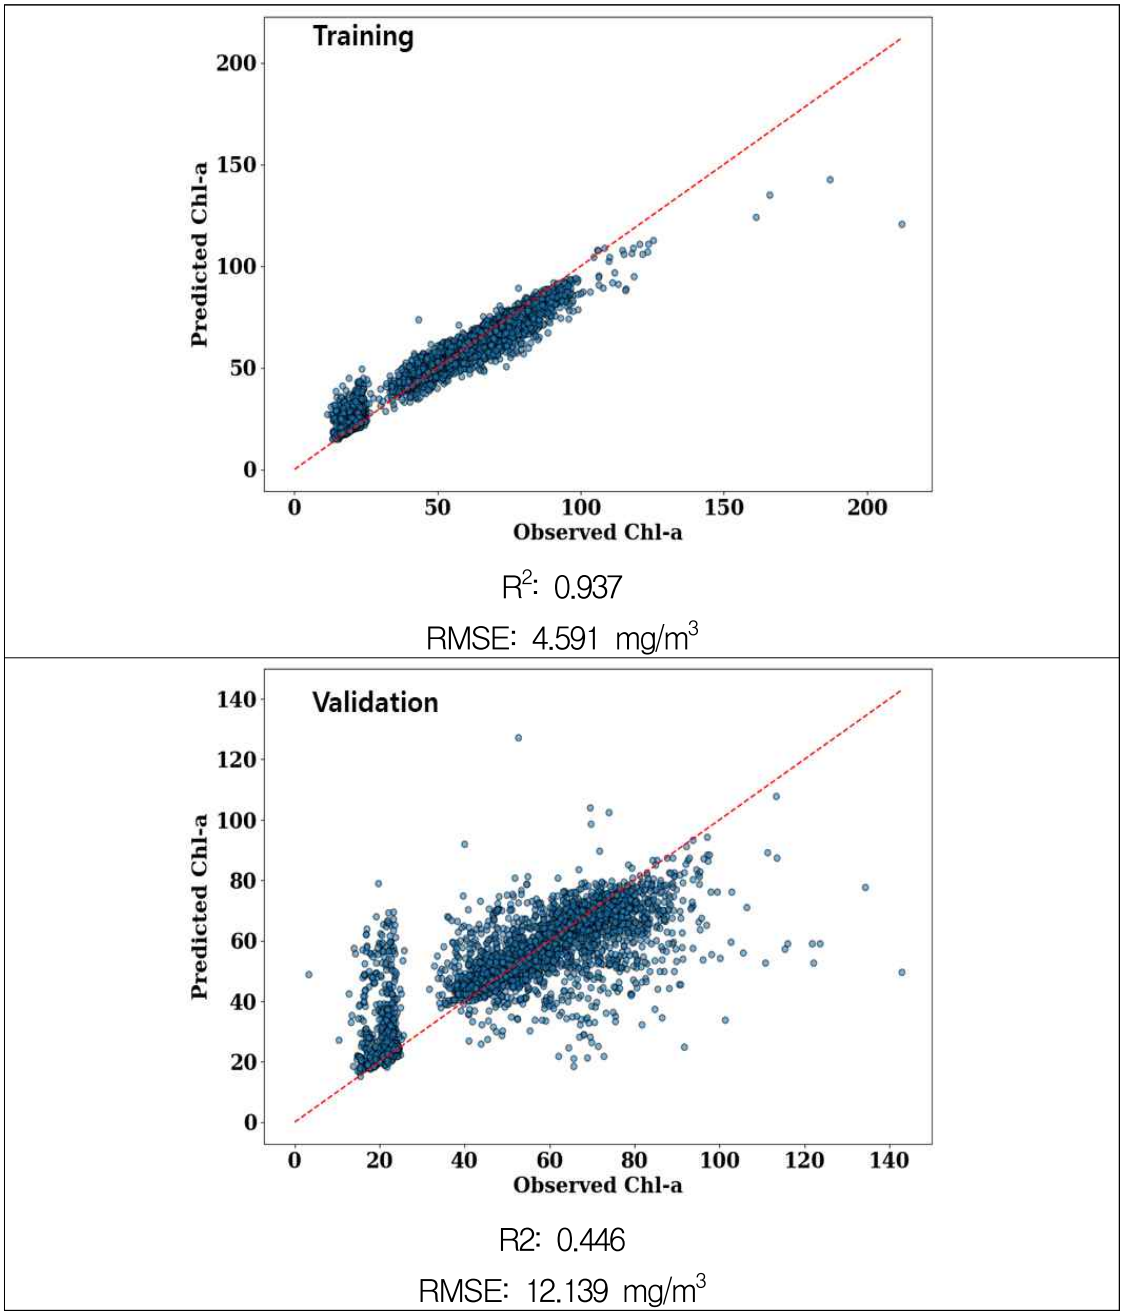


그림 47. CNN 및 RF 기반 7일 후 클로로필-a 예측 성능 (반사도 입력)

위 결과를 통해 CNN기반의 비정형 이미지 데이터와 static한 기상 및 유량데이터의 특징 전처리와 RF의 앙상블기반의 클로로필-a 단기예측 방안이 CNN, 오토인코더 CNN, 멀티모달 방법들과 비교하여 안정적인 성능을 보였다.

기존연구에 따른 RF기반 모델 XGboost와 같은 모델들은 딥러닝 모델과 비슷한 성능을 보이거나 높은 성능을 보일 때도 있다. 하지만, 두 모델은 최적화를 하더라도 dramatic한 성능에 제고에 대한 모습은 보기 힘들기 때문에 딥러닝을 함께 활용하면 추가적인 성능 제고의 가능성을 확인 할 수 있다. 또한 딥러닝 모델을 활용하면 일반화된 모델을 구현하여 구축된 모델을 안정적으로 비슷한 수체 특성을 가진 강 호소에 적용하여 활용 할 수 있을 것으로 판단된다. 해당 보고서에서 최적화된 모델의 구조 및 하이퍼라미터는 한정된 시간동안에 설계가 되었기 때문에 레이어의 수 및 크기와 같은 추가적인 구성 요소의 변화에 대한 최적화 방안이 많이 존재하기 때문에 모델 구조의 추가적인 개선을 통해 모델의 성능을 더욱 시킬 수 있을 것으로 사료된다.

따라서 위성-기상-수문데이터 연계와 AI 기법을 활용하면 녹조 단기예측에 활용되어 효율적이고 시의성 있는 녹조 관리에 적용될 수 있을 것으로 생각된다.

서 지 자 료

(1) 기술분류	(2) 수행방법 자체	(3) 제출일 2025.1.31.
(4) 제목/부제 위성영상기반 공간적 녹조 예측기술 개발		(5) 연구기간 2024.2.1. ~ 2024.12.31.
(6) 연구수행부서 한국수자원공사, K-water연구원 수자원환경연구소		(7) 연구수행자(소속) K-water연구원
(8) 수행부서 주소 대전광역시 유성구 유성대로 1689번길		(9) 연구의뢰기관

(10) 초록

본 연구는 대청댐과 영주댐을 대상지로 하고 있으며 Sentinel-2 위성영상 기반으로 원격 녹조 발생 농도를 추정하고 기상과 수문자료를 연계하여 단기 예측 알고리즘을 개발하고자 하였다. 측정망 자료를 활용하여 앙상블기법과 딥러닝 기법으로 위성영상 기반 원격 녹조발생 농도 추정, 단기예측 알고리즘을 개발하였다. 또한 모델 정확도 개선을 위하여 3차원 수질모델을 활용하여 표층 Chl-a 농도 합성데이터를 생성하여 모델 성능을 개선시키고 최종적으로 물환경 디지털 트윈 요소기술로 활용하는 것을 목표로 하였다. Chl-a 원격관측 모델은 Sentinel-2의 밴드 4~7 반사도값, 밴드조합 파생변수, 기온 활용한 랜덤포레스트 적용시 모델성능 가장 좋았으며, 세포수의 경우에는 대청댐은 관측값보다 과소평가되고 영주댐의 경우에는 다소 과대 평가경향이 나타나 세포수 원격 추정을 위해서 댐 저수지별 개별 모델개발이 필요한 것으로 판단되었다. 위성영상-기상-수문연계 단기 녹조 예측 모델은 Sentinel-2 밴드 1~12 반사도값, 예측기간을 고려하여 일별 평균 기온, 일별 유입량을 활용한 경우에 모델 성능이 가장 좋게 분석되었다. Chl-a 단기 예측은 랜덤포레스트 기법이 세포수 단기 예측은 XGBoost 기법으로 개발한 모델 성능이 가장 좋았으나 데이터 수의 제한으로 2004년 관측값으로 검증한 경우 정확도는 낮아지는 것으로 나타났다. 이에, 3차원모델(AEM3D)을 활용하여 합성데이터를 생성한 후에 Chl-a 단기 예측 모델을 개발한 결과, XGBoost 적용시 모델 성능이 가장 높은 것으로 분석되었다. 댐저수지별 예측 모델 개발시 영주댐의 경우, 랜덤포레스트, CNN-RF 기법 정확도 높아 타댐 확장시 개별 모델 개발이 필요할 것으로 판단되었다. 또한, 예측결과 시각화를 위한 프로그램을 개발하여 사용자가 손쉽게 활용할 수 있도록 하였으며 데이터와 시각화 지도를 저장할 수 있도록 하였다. 이와 같은 프로세스를 통해서 사전에 녹조를 신속하게 파악하고 의사결정지원을 위한 물환경분야 디지털 트윈 요소기술로 활용할 수 있을 것으로 판단된다.

(11) 키워드

algae, spatial monitoring, satellite, prediction, decision support

(12) #태그

(13) 공개여부	(14) 총면수
예/아니오	152

주의사항

본 보고서의 저작권은 한국수자원공사에 있으므로, 본 자료의 내용을 허가없이 인용, 복사, 전재, 재배포를 할 경우 법적 제재를 받을 수 있습니다.

Copyright ⓒ 2024
by
Korea Water Resources Corporation

발행인 : 한국수자원공사 사장 윤석대
발행일 : 2024. 12.
발행처 : 한국수자원공사 K-water연구원
대전광역시 유성구 유성대로 1689번길 125
Tel. (042) 870-7455

한국수자원공사는 친환경 기업윤리 이념을 구현하기 위하여 2000. 12. 00 『**환경경영**』을 선포하고, 모든 보고서 발간에 『**재생용지 및 무코팅 방식**』을 사용하고 있습니다.